

เศรษฐมิติทางการเงินเบื้องต้น

INTRODUCTION TO FINANCIAL  
ECONOMETRICS

เฉลิมพงษ์ คงเจริญ

PUBLISHER

Copyright © 2555-2563 เฉลิมพงษ์ คงเจริญ

**Copying prohibited**

All rights reserved. No part of this publication may be reproduced or transmitted in any form or by any means, electronic or mechanical, including photocopying and recording, or by any information storage or retrieval system, without the prior written permission of the publisher.

Art. No xxxxx

ISBN xxx-xx-xxxx-xx-x

Edition 0.0

Cover design by Cover Designer

Published by Publisher

Printed in Bangkok



วัตถุประสงค์หลักของตำรานี้คือต้องการให้ผู้อ่านมีความรู้เบื้องต้นในการวิเคราะห์ข้อมูลอนุกรมเวลาทางการเงิน เช่น ความเบ้ ความโด่ง ตลอดจนอัตสหสัมพันธ์(autocorrelation)ของตัวแปรผลได้ตอบแทน นอกจากนี้ยังนำเสนอแบบเครื่องมือทางสถิติและแบบจำลองเศรษฐมิติที่เป็นประโยชน์ในการวิเคราะห์ข้อมูลอนุกรมเวลา และคาดหวังให้ผู้อ่านมีความรู้ความเข้าใจในแบบจำลองเศรษฐมิติทางการเงิน ตลอดจนสามารถนำเครื่องมือดังกล่าวไปประยุกต์ใช้ในการวิเคราะห์ข้อมูลอนุกรมเวลาทางการเงิน เพื่อให้ผู้อ่านสามารถประยุกต์ใช้เครื่องมือทางเศรษฐมิติทางการเงินได้ ผู้เขียนได้เผยแพร่ข้อมูลตลอดจน jupyter notebook สำหรับทุกบทไว้ที่ <https://github.com/chaleampong/EC435>





<b>1</b>	<b>บทนำ</b>	<b>9</b>
1.1	ตัวอย่างอนุกรมเวลาทางการเงิน	10
<b>2</b>	<b>อนุกรมเวลาทางการเงินและคุณลักษณะ</b>	<b>14</b>
2.1	การคำนวณผลได้ตอบแทน	14
2.1.1	นิยามของผลได้ตอบแทนของทรัพย์สิน	14
2.1.2	ผลได้ตอบแทนทบต้นอย่างต่อเนื่อง	18
2.2	คุณลักษณะทางสถิติของข้อมูลอนุกรมเวลา	21
2.2.1	การแจกแจงของอนุกรมเวลา (Distribution of time series)	21
2.2.2	คุณลักษณะเรื้อรังรูปร่างของการแจกแจงความน่าจะเป็น	25
2.2.3	การทดสอบพอร์ทแมนโท (Portmanteau test) สำหรับสหสัมพันธ์ในตัว	36
2.2.4	ตัวดำเนินการขยับไปข้างหลัง	37
2.3	แบบฝึกฝน	37
<b>3</b>	<b>แบบจำลองอนุกรมเวลาเชิงเส้นตรง</b>	<b>39</b>
3.1	แบบจำลองออโตรีเกรสซีฟ	40
3.1.1	แบบจำลองออโตรีเกรสซีฟอันดับหนึ่ง	42
3.1.2	แบบจำลองออโตรีเกรสซีฟอันดับสอง	47
3.1.3	แบบจำลองออโตรีเกรสซีฟที่อันดับ $AR(p)$	49
3.1.4	ฟังก์ชันสหสัมพันธ์ในตัวบางส่วนหรือพีเอชเอฟ	50

3.1.5	การประมาณค่าและตรวจสอบแบบจำลอง . . . . .	52
3.1.6	การพยากรณ์ด้วยแบบจำลองออโตรีเกรสซีฟ $AR(p)$ . . . . .	57
<b>3.2</b>	<b>แบบจำลองมูฟวิ้งเอเวอเรจ</b>	<b>60</b>
3.2.1	แบบจำลองมูฟวิ้งเอเวอเรจที่อันดับหนึ่ง ( $MA(1)$ ) . . . . .	61
3.2.2	แบบจำลองมูฟวิ้งเอเวอเรจที่อันดับสอง ( $MA(2)$ ) . . . . .	64
3.2.3	แบบจำลองมูฟวิ้งเอเวอเรจที่อันดับ $q$ ( $MA(q)$ ) . . . . .	65
3.2.4	การประมาณค่าแบบจำลองมูฟวิ้งเอเวอเรจ . . . . .	66
3.2.5	การพยากรณ์จากแบบจำลองมูฟวิ้งเอเวอเรจ . . . . .	69
<b>3.3</b>	<b>แบบจำลองออโตรีเกรสซีฟมูฟวิ้งเอเวอเรจ</b>	<b>70</b>
3.3.1	แบบจำลองอาร์มาที่อันดับ $(1,1)$ ( $ARMA(1,1)$ ) . . . . .	71
3.3.2	การประมาณค่าสมการแบบจำลองอาร์มา . . . . .	73
3.3.3	เกณฑ์การเลือกแบบจำลอง . . . . .	74
3.3.4	การเขียนกระบวนการอาร์มา( $ARMA$ )ในสามรูปแบบ . . . . .	76
3.3.5	การพยากรณ์ (forecasting) . . . . .	77
<b>3.4</b>	<b>อนุกรมเวลาไม่คงที่</b>	<b>78</b>
3.4.1	การทดสอบยูนิทรูทในรูปออโตรีเกรสซีฟ . . . . .	81
<b>3.5</b>	<b>แบบจำลองอินทิเกรตเตอร์มา หรืออะริมา</b>	<b>89</b>
<b>3.6</b>	<b>แบบฝึกฝน</b>	<b>90</b>
<b>4</b>	<b>สมการถดถอยสำหรับข้อมูลอนุกรมเวลา</b>	<b>92</b>
<b>4.1</b>	<b>แบบจำลองถดถอยข้อมูลอนุกรมเวลา</b>	<b>92</b>
4.1.1	การประมาณค่าวิธีกำลังสองน้อยที่สุด . . . . .	93
4.1.2	การวิเคราะห์เรซิดิว . . . . .	93
<b>4.2</b>	<b>สมการถดถอยแบบพลวัต</b>	<b>98</b>
<b>4.3</b>	<b>การอ้างอิงทางสถิติกรณีที่เรซิดิวไม่เป็นไปตามข้อสมมติ</b>	<b>101</b>
4.3.1	การปรับสแตนด์ตาร์ดแอร์เรอกรณีสเฮอร์สกี-ดาสติซี . . . . .	102
4.3.2	การปรับสแตนด์ตาร์ดแอร์เรอกรณีสเฮอร์สกี-ดาสติซี . . . . .	102
<b>5</b>	<b>แบบจำลองความผันผวน</b>	<b>105</b>
<b>5.1</b>	<b>ความผันผวนของสินทรัพย์</b>	<b>105</b>
5.1.1	คุณลักษณะของความผันผวน . . . . .	105
5.1.2	การทดสอบลักษณะอาร์ช . . . . .	106

<b>5.2</b>	<b>แบบจำลองอาร์ช</b>	<b>109</b>
5.2.1	รูปแบบ ของแบบจำลองอาร์ชที่อันดับ $q$ ARCH( $q$ ) . . . . .	109
5.2.2	คุณลักษณะของอาร์ชที่อันดับหนึ่ง . . . . .	110
5.2.3	การประมาณค่าแบบจำลองอาร์ชอันดับหนึ่ง . . . . .	111
<b>5.3</b>	<b>แบบจำลองการชที่อันดับ <math>p, q</math></b>	<b>112</b>
5.3.1	การเขียนแบบจำลองการชในรูปอาร์มา . . . . .	112
5.3.2	คุณลักษณะของแบบจำลองการช . . . . .	113
<b>5.4</b>	<b>การประมาณค่าแบบจำลองการช</b>	<b>114</b>
5.4.1	การตรวจสอบหลังจากการประมาณค่าการช . . . . .	114
5.4.2	การแจกแจงที่ไม่ใช่การแจกแจงแบบปกติ . . . . .	117
5.4.3	การเลือกแบบจำลองที่เหมาะสม (Model selection) . . . . .	119
5.4.4	การขยายแบบจำลองการช . . . . .	119
<b>5.5</b>	<b>การพยากรณ์ด้วยแบบจำลองการช</b>	<b>121</b>
<b>5.6</b>	<b>แบบฝึกฝน</b>	<b>123</b>
<b>6</b>	<b>แบบจำลองอนุกรมเวลาเชิงพหุ . . . . .</b>	<b>125</b>
<b>6.1</b>	<b>ความนิ่งของอนุกรมเวลาและเมตริกซ์สหสัมพันธ์ระหว่างกัน</b>	<b>125</b>
6.1.1	cross-correltaion matrices . . . . .	126
6.1.2	ตัวประมาณค่าสหสัมพันธ์ไขว้ . . . . .	127
6.1.3	การทดสอบสหสัมพันธ์ไขว้ . . . . .	129
<b>6.2</b>	<b>แบบจำลองเวกเตอร์ออโตรีเกรสซีฟ (Vector Autoregressive Model)</b>	<b>130</b>
6.2.1	เงื่อนไขการเป็นอนุกรมเวลานิ่ง . . . . .	132
<b>6.3</b>	<b>การประมาณค่าและการเลือกค่าล่า</b>	<b>133</b>
6.3.1	การประมาณค่า . . . . .	133
6.3.2	การเลือกจำนวนความล่าที่เหมาะสม . . . . .	133
<b>6.4</b>	<b>การพยากรณ์จากแบบจำลองเวกเตอร์ออโตรีเกรสซีฟ</b>	<b>137</b>
<b>6.5</b>	<b>การวิเคราะห์หลังจากการประมาณค่าแบบจำลองเวกเตอร์ออโตรีเกรสซีฟ</b>	<b>140</b>
6.5.1	Granger Causality . . . . .	140
6.5.2	ฟังก์ชันตอบสนองแรงกระตุ้น . . . . .	141
6.5.3	การแยกความแปรปรวนของค่าคลาดเคลื่อนการพยากรณ์ . . . . .	146
<b>6.6</b>	<b>แบบฝึกฝน</b>	<b>148</b>

<b>7</b>	<b>โคอินทิเกรชัน (Cointegration)</b>	<b>149</b>
<b>7.1</b>	<b>สมการความสัมพันธ์เทียม (spurious regression)</b>	<b>149</b>
<b>7.2</b>	<b>นิยามของโคอินทิเกรชัน</b>	<b>151</b>
7.2.1	โคอินทิเกรชันและแบบจำลองเอเรคคอปเรชัน	153
7.2.2	ความสัมพันธ์โคอินทิเกรชันกรณีหลายตัวแปร	156
<b>7.3</b>	<b>การทดสอบโคอินทิเกรชันด้วยวิธีการทดสอบเรซิดิวตามแนวทางของ เองเกิลและเกรนเจอร์</b>	<b>157</b>
7.3.1	การทดสอบกรณีทราบค่าสัมประสิทธิ์โคอินทิเกรชัน	157
7.3.2	การทดสอบกรณีไม่ทราบค่าสัมประสิทธิ์โคอินทิเกรชัน	160
<b>7.4</b>	<b>การประมาณค่าแบบจำลองเอเรคคอปเรชันด้วยวิธีการกำลังสองน้อยที่สุด</b>	<b>162</b>
<b>7.5</b>	<b>แบบจำลองเวกเตอร์เอเรคคอปเรชัน</b>	<b>164</b>
7.5.1	รูปแบบของสมการเวกเตอร์เอเรคคอปเรชัน	164
7.5.2	การทดสอบโคอินทิเกรชันด้วยจำนวนค่าลำดับขั้นตามวิธีของโจแฮนเซน	170
7.5.3	ขั้นตอนในการทดสอบโคอินทิเกรชันและสร้างแบบจำลองเวกเตอร์เอเรคคอปเรชัน	172
<b>7.6</b>	<b>แบบฝึกฝน</b>	<b>178</b>
<b>A</b>	<b>การใช้โปรแกรม R เบื้องต้น</b>	<b>179</b>
<b>A.1</b>	<b>การติดตั้ง R</b>	<b>179</b>
<b>A.2</b>	<b>การติดตั้ง RStudio</b>	<b>179</b>
<b>A.3</b>	<b>ผังของโปรแกรม RStudio</b>	<b>180</b>
<b>A.4</b>	<b>ชุดคำสั่ง (package) หรือห้องสมุด (library)</b>	<b>181</b>
<b>A.5</b>	<b>การทำงานบน Working directory</b>	<b>181</b>
<b>A.6</b>	<b>การใช้งานเบื้องต้น</b>	<b>181</b>
A.6.1	เครื่องหมายเลข	181
A.6.2	พื้นที่ทำงาน (workspace)	182
A.6.3	สเกลาร์ เวกเตอร์ และเมทริกซ์	182
A.6.4	ฟังก์ชัน	182
A.6.5	การวาดแผนภาพ	182
<b>A.7</b>	<b>การช่วยเหลือและเอกสารประกอบฟังก์ชัน</b>	<b>183</b>
<b>A.8</b>	<b>Scripts</b>	<b>183</b>

<b>A.9</b>	<b>โครงสร้างข้อมูล</b>	<b>183</b>
A.9.1	เวกเตอร์ . . . . .	183
A.9.2	เมตริกซ์ . . . . .	184
A.9.3	data frame . . . . .	184
A.9.4	list . . . . .	184
<b>A.10</b>	<b>Graphic</b>	<b>185</b>
<b>A.11</b>	<b>การจัดเก็บข้อมูลและนำเข้าข้อมูล</b>	<b>186</b>
A.11.1	การจัดเก็บข้อมูลในรูปแบบไฟล์ text . . . . .	186
A.11.2	การเรียกข้อมูลในรูปแบบไฟล์ text . . . . .	186
A.11.3	การนำเข้าไฟล์ประเภทอื่นๆ . . . . .	188
A.11.4	การบันทึกข้อมูล . . . . .	188
<b>A.12</b>	<b>การคำนวณผลได้ตอบแทนจากตัวอย่างหุ้น PTT</b>	<b>188</b>
A.12.1	การวาดกราฟ . . . . .	188
A.12.2	การคำนวณผลได้ตอบแทน . . . . .	189
	<b>บรรณานุกรม . . . . .</b>	<b>191</b>



# 1. บทนำ

ในการทำงานด้านเศรษฐศาสตร์และการเงินปัจจุบัน เราจำเป็นต้องใช้ข้อมูลทางการเงินในการตัดสินใจตลอดจนสร้างความเข้าใจต่อความสัมพันธ์ของตัวแปรต่าง ๆ เช่น ตลาดหลักทรัพย์ อัตราดอกเบี้ย ราคาอสังหาริมทรัพย์ และอัตราแลกเปลี่ยน อีกทั้งในภาคการเงิน นักลงทุนยังสนใจต่อการทำนายการเปลี่ยนแปลงของราคาหลักทรัพย์และผลประกอบการของบริษัทต่าง ๆ ในตำรานี้ ผู้เขียนพยายามที่จะนำเสนอเครื่องมือทางสถิติในการตอบปัญหาทางการเงิน หรือการใช้เศรษฐมิติทางการเงิน (financial econometrics) ในการตอบปัญหาทางการเงิน เช่น การทดสอบทฤษฎีทางการเงิน การกำหนดราคาของสินทรัพย์และผลตอบแทน การทดสอบความสัมพันธ์ระหว่างตัวแปรทางการเงินด้วยกัน ความสัมพันธ์ระหว่างตลาดการเงินและตัวแปรเศรษฐกิจมหภาค และการทำนายค่าในอนาคตของตัวแปรทางการเงิน เป็นต้น

เครื่องมือพื้นฐานที่เราใช้ในวิชาเศรษฐมิติทางการเงินจะเหมือนกับในวิชาเศรษฐมิติโดยทั่วไป อย่างไรก็ตาม ข้อมูลตลาดการเงินที่เรานำมาพิจารณาจะมีความแตกต่างในแง่ของ **ความถี่ ความถูกต้อง ฤดูกาล** กับข้อมูลที่เรพบในวิชาเศรษฐมิติทั่วไป ในวิชาเศรษฐศาสตร์เรามักพบปัญหาที่ข้อมูลไม่เพียงพอและสนใจปัญหาที่เกิดจากข้อมูลจำนวนน้อย

ในตลาดการเงินข้อมูลที่เราพบจะมีรูปแบบที่ค่อนข้างต่างกัน แต่โดยทั่วไปที่เราสนใจคือข้อมูลของราคา ณ ระดับที่มีการซื้อขาย ดังนั้นจะมีความถี่ที่สูงกว่าข้อมูลเศรษฐกิจมหภาค ราคาของสินทรัพย์ใด ๆ มักมีตั้งแต่ รายนาฬิกา ชั่วโมงหรือวัน ดังนั้นกลุ่มตัวอย่างในกรณีข้อมูลการเงินมักจะเป็นขนาดใหญ่

## ประเภทของข้อมูล

**ข้อมูลภาคตัดขวาง (cross sectional data)** เป็นข้อมูลที่มีการจัดเก็บ ณ เวลาใดๆ เช่น ราคาหลักทรัพย์ของทั้งตลาด ณ ปีใดปีหนึ่ง, กำไรสุทธิของบริษัทในตลาดหลักทรัพย์ ณ ปีใดปีหนึ่ง ปัญหาที่สามารถใช้ข้อมูลภาคตัดขวางในการศึกษา ตัวอย่างเช่น ความสัมพันธ์ระหว่างขนาดของบริษัทกับผลตอบแทนในการลงทุนในหุ้นนั้นๆ, ความสัมพันธ์ระหว่างระดับของ GDP ของประเทศกับโอกาสในการผิมนัดชำระหนี้ของประเทศใดๆ ในปีใดปีหนึ่ง

**ข้อมูลอนุกรมเวลา (time series)** เป็นข้อมูลที่มีการจัดเก็บตามเวลา โดยจะมีความสัมพันธ์กับความถี่

ในการจัดเก็บ อย่างไรก็ตามข้อมูลทางการเงินบางส่วนมีการบันทึกตามธุรกรรมที่เกิดขึ้น เช่นการซื้อขายหุ้น แบบจำลองเดียวกันจำเป็นที่จะต้องมีความถี่ที่เหมือนกัน ตารางที่ 1.1 เป็นตัวอย่างของข้อมูลอนุกรมเวลา

ตารางที่ 1.1: ตัวอย่างข้อมูลอนุกรมเวลา

สัปดาห์	ปริมาณซื้อขาย	ราคาปิด
7/16/2012	6301500	191.63
7/23/2012	3759100	195.56
7/30/2012	2988800	197.68
8/6/2012	2475200	199.29
8/13/2012	2474700	201.22
8/20/2012	2828000	197.77
8/27/2012	2622700	194.85

ปัญหาที่สามารถใช้ข้อมูลอนุกรมเวลาในการศึกษา ตัวอย่างเช่น ดัชนีราคาหลักทรัพย์แปรผันกับตัวแปรทางเศรษฐกิจของประเทศอย่างไร, มูลค่าของหลักทรัพย์แปรผันตามการประกาศเงินปันผลอย่างไร, อัตราแลกเปลี่ยนมีผลต่อการขาดดุลการค้าอย่างไร


**ข้อมูลแพนอล (panel)** เป็นข้อมูลที่มีทั้งอนุกรมเวลาและภาคตัดขวางเช่น ราคารายวันของหุ้นใน SET50 ตลอดระยะเวลาสองปี

ในตำราเล่มนี้เราจะเน้นการเนื้อหาไปยังการศึกษาโดยใช้ข้อมูลอนุกรมเวลา **ข้อมูลอนุกรมเวลา**

## 1.1 ตัวอย่างอนุกรมเวลาทางการเงิน

ข้อมูลอนุกรมทางการเงินหนึ่งที่เรามักสนใจกันคือราคาของหลักทรัพย์ ซึ่งแหล่งข้อมูลมีหลากหลายซึ่งแหล่งข้อมูลฟรีแหล่งหนึ่งที่เรสามารถใช้ได้คือ **Yahoo Finance** ซึ่งเราสามารถเข้าถึงแหล่งข้อมูลจากเบราว์เซอร์หรืออาจจะใช้ **package** ในโปรแกรม R ชื่อ **quantmod** เพื่อโหลดข้อมูลเมื่อเราทราบ **Ticker** ของหลักทรัพย์ที่เราต้องการข้อมูล เช่นในกรณีนี้ หากเราสนใจราคาหลักทรัพย์ของธนาคารกรุงเทพ เราสามารถค้นหา **Ticker** ได้จาก <https://finance.yahoo.com/lookup> ซึ่งกรณีนี้คือ **BBL.BK** และสามารถโหลดข้อมูลพิจารณาข้อมูล และสร้างกราฟได้จากคำสั่งต่อไปนี้


```
1 > library(quantmod)
2 > getSymbols("BBL.BK", src="yahoo", from="2007-01-01", to="2019-12-30")
3 > plot(BBL.BK$BBL.BK.Close, main="ราคาปิดหุ้นธนาคารกรุงเทพ")
```



รูปที่ 1.1: ราคาปิดของหุ้นธนาคารกรุงเทพระหว่างปี 2007 ถึง 2019


นอกจากนี้เราสามารถคำนวณผลได้ตอบแทนรายวัน และวาดกราฟได้ด้วยคำสั่งต่อไปนี้ (รายละเอียดและคุณสมบัติของผลได้ตอบแทนจะอธิบายในบทที่ 2)

```
1 > p<-(BBL.BK$BBL.BK.Close)
2 > ret<-diff(log(p))*100
3 > plot(ret, main="ผลได้ตอบแทนรายวันของหุ้นธนาคารกรุงเทพ")
```




รูปที่ 1.2: ผลได้ตอบแทนรายวันของหุ้นธนาคารกรุงเทพระหว่างปี 2007 ถึง 2019

ในบทที่ 3 จะอธิบายถึงแบบจำลองที่ใช้อธิบายและพยากรณ์อนุกรมเวลาตัวแปรเดียว




รูปที่ 1.3: อัตราแลกเปลี่ยนบาทต่อดอลลาร์สหรัฐรายวัน



รูปที่ 1.4: อัตราแลกเปลี่ยนบาทต่อดอลลาร์สหรัฐรายวัน

รูปที่ 1.3 แสดงอัตราแลกเปลี่ยนเงินบาทและดอลลาร์สหรัฐรายวันระหว่างปี 1997 ถึง 2011 เมื่อพิจารณาผลได้ตอบแทนในรูปที่ 1.4 จะเห็นได้ว่าช่วงหลังวิกฤติการณ์เงินตราปี 1997 และช่วงวิกฤติแฮมเบอร์เกอร์ ผลได้ตอบแทนมีความผันผวนมากกว่าช่วงอื่นๆ โดยที่แบบจำลองอธิบายความผันผวนจะถูกพิจารณาในบทที่ 5



รูปที่ 1.5: อัตราดอกเบี้ยพันธบัตรรัฐบาล

รูปที่ 1.5 แสดงอัตราดอกเบี้ยพันธบัตรรัฐบาลอายุไม่เกิน 1 ปีและ 3 ปี พบว่าข้อมูลทั้งสองมีความเคลื่อนไหวไปในทิศทางเดียวกัน ซึ่งความสัมพันธ์ระหว่างอนุกรมเวลามากกว่า 1 อนุกรมเวลาจะถูกพิจารณาใน





## 2. อนุกรมเวลาทางการเงินและคุณลักษณะ

ในบทนี้ เราจะพิจารณาลักษณะทางสถิติของอนุกรมเวลาทางการเงิน โดยเฉพาะผลตอบแทน ซึ่งเป็นอนุกรมเวลาที่เราน่าสนใจมากที่สุดในการศึกษาเศรษฐมิติทางการเงิน หัวข้อ 2.1 กล่าวถึงการคำนวณผลตอบแทนจากราคาของสินทรัพย์ทางการเงิน หัวข้อ 2.2 กล่าวถึงคุณลักษณะทางสถิติของอนุกรมเวลาทางการเงิน ตลอดจนการทดสอบสมมติฐานเกี่ยวกับคุณลักษณะของอนุกรมเวลา

### 2.1 การคำนวณผลตอบแทน

การศึกษาปริมาณทางการเงินส่วนใหญ่เรามักจะสนใจผลตอบแทน (return) ของทรัพย์สินมากกว่าราคา (price) เนื่องจากตลาดการเงินมีลักษณะที่ใกล้เคียงกับตลาดแข่งขันสมบูรณ์ ขนาดของการลงทุนไม่ส่งผลต่อการเปลี่ยนแปลงของราคา ดังนั้น ผลตอบแทนของทรัพย์สินเป็นข้อมูลที่มีความสมบูรณ์ และปราศจากผลของหน่วยวัดของโอกาสในการลงทุน (John Y. Campbell and MacKinlay 1997) คุณสมบัติดังกล่าวใช้ในการประเมินโอกาสในการลงทุน เช่นการระบุว่าสินทรัพย์ที่เราถืออยู่ราคาเพิ่มขึ้น 10 บาทมิได้แสดงให้เห็นว่าผลตอบแทนนั้นดีหรือไม่ จำเป็นต้องระบุในรูปของผลตอบแทนเป็นร้อยละ นอกจากนี้อนุกรม (series) ของผลตอบแทนมีคุณสมบัติทางสถิติที่ดีกว่าอนุกรมของราคาในการดำเนินการทางสถิติซึ่งเราจะได้พิจารณาในเนื้อหาบทต่อไป

#### 2.1.1 นิยามของผลตอบแทนของทรัพย์สิน

สมมติให้การซื้อสินทรัพย์ เช่นหุ้น พันธบัตร หรือกองทุนรวม ณ เวลา  $t_0$  ด้วยราคา  $P_{t_0}$  บาทและขายสินทรัพย์ ณ เวลา  $t_1$  ด้วยราคา  $P_{t_1}$  บาท การเปลี่ยนแปลงของราคาสินทรัพย์ในรูปร้อยละสามารถคำนวณได้โดย

$$R(t_0, t_1) = \frac{P_{t_1} - P_{t_0}}{P_{t_0}} \quad (2.1)$$

เราเรียกระยะเวลาระหว่าง  $t_0$  และ  $t_1$  ว่าระยะเวลาการถือสินทรัพย์ (holding period) และสมการ

(2.1) ว่าผลตอบแทนจากระยะเวลาการถือสินทรัพย์ โดยทั่วไปเราอาจจะกำหนดระยะเวลาการถือสินทรัพย์เป็นระยะเวลาใดๆก็ได้ เช่น ราย 15 นาที รายครึ่งเดือน อย่างไรก็ตามในตำรานี้เราจะสมมติให้ระยะเวลาการถือมีลักษณะเพิ่มขึ้นเช่นเดียวกับปฏิทิน เช่น รายนาทึ รายวัน รายเดือน หรือรายปี และในหัวข้อนี้เราจะสมมุติระยะเวลาการพิจารณาเป็นรายเดือน

กำหนดให้  $P_t$  เป็นราคาของสินทรัพย์ ณ เวลาสิ้นเดือน  $t$  และไม่มีการจ่ายเงินปันผล และกำหนดให้  $P_{t-1}$  เป็นราคาของสินทรัพย์ ณ เวลาสิ้นเดือน  $t - 1$  แล้ว ผลได้ตอบแทนรวมอย่างง่ายหนึ่งเดือน (one-month simple gross return) สามารถคำนวณได้ดังนี้

$$1 + R_t = \frac{P_t}{P_{t-1}} \quad (2.2)$$

และผลได้ตอบแทนสุทธิอย่างง่ายหนึ่งเดือน (one-month simple net return) หรือเรามักจะเรียกสั้น ๆ ว่า ผลได้ตอบแทนอย่างง่ายหนึ่งเดือน (one-month simple return)

$$R_t = \frac{P_t}{P_{t-1}} - 1 = \frac{P_t - P_{t-1}}{P_{t-1}} \quad (2.3)$$

โดยที่ผลได้ตอบแทนอย่างง่ายหนึ่งเดือนอธิบายว่าหากเราลงทุนด้วยเงิน 1 บาทในเดือนที่  $t - 1$  เราจะได้รับเงินคืนมาทั้งหมดเท่าไร ซึ่งรวมเงินต้นด้วย หรืออาจมองในแง่ของมูลค่าอนาคตของเงิน 1 บาท นอกจากนี้เราจะสังเกตเห็นได้ว่าราคาของสินทรัพย์ใด ๆ จะต้องเป็นค่าที่ไม่เป็นลบ ดังนั้น ค่าต่ำสุดของ  $R_t$  คือ  $-1$  หรือขาดทุน 100%

#### ตัวอย่างที่ 2.1 การคำนวณผลได้ตอบแทนอย่างง่าย

สมมุติว่าเราพิจารณาผลตอบแทนจากการลงทุนในหลักทรัพย์ธนาคารเอโดยที่เราซื้อหุ้นเมื่อเดือน  $t - 1$  ด้วยราคา  $P_{t-1} = 190$  บาทและขายไปในเดือนต่อไปด้วยราคา  $P_t = 200$  บาทและไม่มีการจ่ายเงินปันผลในระหว่างที่ถือหุ้น ดังนั้นผลได้ตอบแทนสุทธิเท่ากับ

$$R_t = \frac{200 - 190}{190} = \frac{200}{190} - 1 = 1.0526 - 1 = 0.0526$$

และผลได้ตอบแทนอย่างง่ายรวมหนึ่งเดือนจะเท่ากับ

$$1 + R_t = \frac{200}{190} = 1.0526$$

ผลได้ตอบแทนสุทธิหนึ่งเดือนจะเท่ากับ 5.25 % ต่อเดือน หรือการลงทุนในหลักทรัพย์ธนาคารเอ 1 บาทจะได้เงินคืนพร้อมเงินต้น 1.0525 บาท

### ผลได้ตอบแทนหลายเดือน

ผลได้ตอบแทนจากการลงทุนสองเดือนสามารถคำนวณได้จากการเปลี่ยนแปลงของราคา ณ เดือน  $P_t$  และ  $P_{t-2}$  หรือผลได้ตอบแทนอย่างง่ายสองเดือน,  $R_t(2)$ , จะเท่ากับ

$$\begin{aligned} R_t(2) &= \frac{P_t - P_{t-2}}{P_{t-2}} = \frac{P_t}{P_{t-2}} - \frac{P_{t-2}}{P_{t-2}} \\ &= \frac{P_t}{P_{t-2}} - 1 \\ &= \frac{P_t}{P_{t-1}} \frac{P_{t-1}}{P_{t-2}} - 1 \\ &= (1 + R_t)(1 + R_{t-1}) - 1 \end{aligned} \quad (2.4)$$

และผลได้ตอบแทนรวมอย่างง่ายสองเดือนจะเท่ากับ

$$1 + R_t(2) = (1 + R_t)(1 + R_{t-1}) = 1 + R_t + R_{t-1} + R_t R_{t-1} \quad (2.5)$$

ซึ่งคือผลรวมเรขาคณิต (geometric sum) ของผลได้ตอบแทนรวมอย่างง่ายหนึ่งเดือนของเดือน  $t$  และ  $t-1$  ดังนั้นจะเห็นได้ว่า  $R_t(2)$  จะไม่เท่ากับผลรวมของ  $R_t$  และ  $R_{t-1}$

#### ตัวอย่างที่ 2.2 การคำนวณผลได้ตอบแทนอย่างง่ายสองเดือน

พิจารณาต่อเนื่องจากตัวอย่าง 2.1 สมมติให้เราซื้อหลักทรัพย์ ณ เดือนที่  $t-2$  ด้วยราคา  $P_{t-2} = 180$  บาทและไม่มีการจ่ายเงินปันผล ผลได้ตอบแทนสุทธิสองเดือนจะเท่ากับ

$$R_t(2) = \frac{200 - 180}{180} = \frac{200}{180} - 1 = 0.1111$$

หรือ 11.11 % โดยที่ผลได้ตอบแทนหนึ่งเดือนของแต่ละเดือนจะเท่ากับ

$$\begin{aligned} 1 + R_{t-1} &= \frac{190 - 180}{180} = 1.0556 - 1 = 0.0556 \\ 1 + R_t &= \frac{200 - 190}{190} = 1.0526 - 1 = 0.0526 \end{aligned}$$

และผลได้ตอบแทนรวมสองเดือนจะเท่ากับ

$$1 + R_t(2) = 1.0556 \times 1.0526 = 1.1111$$

เราสามารถเขียนผลได้ตอบแทนในรูปทั่วไปได้ดังนี้ ผลได้ตอบแทนรวมอย่างง่าย  $k$  เดือน (k-month simple

gross return) จะเท่ากับ

$$\begin{aligned} 1 + R_t(k) &= \frac{P_t}{P_{t-k}} = \frac{P_t}{P_{t-1}} \times \frac{P_{t-1}}{P_{t-2}} \times \dots \times \frac{P_{t-k+1}}{P_{t-k}} \\ &= (1 + R_t)(1 + R_{t-1}) \dots (1 + R_{t-k+1}) \end{aligned} \quad (2.6)$$

ซึ่งคือผลรวมเรขาคณิตของผลได้ตอบแทนรวมอย่างง่ายรายเดือนของเดือนที่  $t$  ถึงเดือนที่  $t - k + 1$

### ผลได้ตอบแทนของกลุ่มสินทรัพย์ลงทุน (Portfolio)

หากเราลงทุนด้วยเงินจำนวน  $V$  บาทในสินทรัพย์สองตัวคือ  $A$  และ  $B$  โดยสัดส่วนการลงทุนในสินทรัพย์ทั้งสองคือ  $x_A$  และ  $x_B$  แล้วมูลค่าการลงทุนในสินทรัพย์แต่ละชนิดจะเท่ากับ  $Vx_A$  และ  $Vx_B$  โดยเราสมมติให้  $x_A + x_B = 1$  หากกำหนดให้ผลได้ตอบแทนอย่างง่ายหนึ่งเดือนของ  $A$  และ  $B$  คือ  $R_{A,t}$  และ  $R_{B,t}$  แล้ว มูลค่าของกลุ่มสินทรัพย์ลงทุนเมื่อสิ้นเดือนจะเท่ากับ

$$V \times [x_A(1 + R_{A,t}) + x_B(1 + R_{B,t})]$$

โดย  $x_A(1 + R_{A,t}) + x_B(1 + R_{B,t})$  คือผลได้ตอบแทนรวมของกลุ่มสินทรัพย์ลงทุน และอัตราผลตอบแทนจากการลงทุนจะเท่ากับ  $x_AR_{A,t} + x_BR_{B,t}$

### การปรับกรณีเงินปันผล

ถ้าสินทรัพย์มีการจ่ายเงินปันผลเท่ากับ  $D_t$  ในช่วงเวลาระหว่างเดือน  $t$  และ  $t - 1$  แล้วการคำนวณผลได้ตอบแทนสุทธิทั้งหมด (total net return) สามารถคำนวณได้ด้วยสมการต่อไปนี้

$$R_t^{total} = \frac{P_t + D_t - P_{t-1}}{P_{t-1}} = \frac{P_t - P_{t-1}}{P_{t-1}} + \frac{D_t}{P_{t-1}} \quad (2.7)$$

โดยที่ส่วนแรกเป็นกำไรส่วนเกินทุน (capital gain) และส่วนที่สองคืออัตราผลตอบแทนเงินปันผล (dividend yield)

### การแปลงผลได้ตอบแทนเป็นผลได้ตอบแทนรายปี

โดยทั่วไปเรามักจะรายงานผลได้ตอบแทนเป็นรายปีเพื่อใช้ในการตัดสินใจลงทุน ดังนั้นเราจำเป็นต้องมีการแปลงผลได้ตอบแทนที่มีความถี่อื่นๆเป็นรายปี สมมุติว่าเราต้องการหาผลได้ตอบแทนหนึ่งปี  $(1 + R_A)$  จากข้อมูลผลได้ตอบแทนรายเดือน  $(R_t, R_{t-1}, \dots, R_{t-11})$  เราสามารถคำนวณได้โดย

$$\begin{aligned} 1 + R_A &= 1 + R_t(12) = \frac{P_t}{P_{t-12}} = \frac{P_t}{P_{t-1}} \cdot \frac{P_{t-1}}{P_{t-2}} \dots \frac{P_{t-11}}{P_{t-12}} \\ &= (1 + R_t)(1 + R_{t-1}) \dots (1 + R_{t-11}) \end{aligned} \quad (2.8)$$

นอกจากนี้หากเราทราบผลได้ตอบแทนรายหนึ่งเดือน และต้องการประมาณการผลได้ตอบแทนรายปีภายใต้ข้อสมมุติว่าผลได้ตอบแทนคงที่ทุกเดือนเท่ากับ  $R$  เราจะได้ผลได้ตอบแทนรายหนึ่งปีเท่ากับ

$$1 + R_A = 1 + R_t(12) = (1 + R)^{12}$$

ซึ่งก็คือผลได้ตอบแทนทบต้น 12 เดือนนั่นเอง

### 2.1.2 ผลได้ตอบแทนทบต้นอย่างต่อเนื่อง

ในหัวข้อนี้เราจะพิจารณาผลของการคิดผลตอบแทนทบต้น(compounding) สมมุติว่าธนาคารจ่ายดอกเบี้ยเงินฝากในอัตรา 10 % ต่อปี และมีเงินต้นเท่ากับ 100 บาท หากธนาคารจ่ายดอกเบี้ยหนึ่งครั้งเมื่อสิ้นปี มูลค่าสุทธิของเงินฝากดังกล่าวตอนปลายปีจะเท่ากับ  $100(1 + 0.1) = 110$  บาท หากธนาคารแบ่งการจ่ายดอกเบี้ยออกเป็นสองครั้งครึ่งละ 5 % ทุกครึ่งปี จะพบว่ามูลค่าสุทธิจะเท่ากับ  $100(1 + 0.1/2)^2 = 110.25$  บาทหลังจากสิ้นปี จากการพิจารณารูปแบบข้างต้น หากธนาคารจ่ายดอกเบี้ย  $m$  ครั้ง มูลค่าสุทธิ ณ สิ้นปีที่หนึ่งจะมีค่า  $100(1 + 0.1/m)^m$  และถ้าธนาคารจ่ายดอกเบี้ยทบต้นอย่างต่อเนื่อง (continuous compounding) มูลค่าสุทธิ ณ สิ้นปีที่หนึ่งจะเท่ากับ  $100(\exp(0.1)) = 100.517$

#### ผลได้ตอบแทนหนึ่งเดือน

กำหนดให้  $R_t$  เป็นผลได้ตอบแทนอย่างง่ายรายเดือนของการลงทุน เนื่องจากมูลค่าในอนาคตจะเท่ากับมูลค่าปัจจุบันคูณกับตัวคูณทบต้น ( $P_t = P_{t-1} \exp(r_t)$ ) เราสามารถคำนวณผลได้ตอบแทนทบต้นต่อเนื่องหนึ่งเดือน (one-month continuously compounding return) หรือผลได้ตอบแทนในรูปลอการิทึม(one-month log return) ซึ่งใช้สัญลักษณ์แทน  $r_t$  ได้โดย

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right) = \ln(P_t) - \ln(P_{t-1}) = p_t - p_{t-1} \quad (2.9)$$

โดยที่  $p_t = \ln(P_t)$

#### ตัวอย่างที่ 2.3 การคำนวณผลได้ตอบแทนในรูปล็อก

ใช้ข้อมูลจากตัวอย่างที่ 2.1 ผลได้ตอบแทนทบต้นอย่างต่อเนื่องหนึ่งเดือนหรือผลได้ตอบแทนในรูปลอการิทึมหนึ่งเดือนจะเท่ากับ

$$r_t = \ln(1.0526) = 0.0513$$

$$r_t = \ln(200) - \ln(190) = 5.2983 - 5.2470 = 0.0513$$

เนื่องจาก  $1 + R_t = \frac{P_t}{P_{t-1}}$  เราสามารถเขียนความสัมพันธ์ระหว่างผลได้ตอบแทนอย่างง่ายและผลได้ตอบแทนในรูปลอการิทึมได้เป็น

$$r_t = \ln(1 + R_t)$$



และเราสามารถคำนวณผลตอบแทนอย่างง่ายสุทธิได้จากผลได้ตอบแทนในรูปลอการิทึมโดย

$$R_t = \exp(r_t) - 1 \quad (2.10)$$

**ตัวอย่างที่ 2.4** ความสัมพันธ์ระหว่างผลได้ตอบแทน

ใช้ข้อมูลจากตัวอย่าง 2.3 ผลได้ตอบแทนในรูปลอการิทึมหนึ่งเดือนเท่ากับ 5.13 % ดังนั้น

$$R_t = \exp(0.0513) - 1 = 0.0526$$

หากผลได้ตอบแทนมีค่าต่ำ เช่น ผลได้ตอบแทนรายชั่วโมงหรือรายวัน ผลได้ตอบแทนในรูปลอการิทึมและผลได้ตอบแทนอย่างง่ายจะมีค่าใกล้เคียงกัน อย่างไรก็ตาม การคำนวณผลได้ตอบแทนทั้งสองวิธีมีคุณสมบัติที่แตกต่างกัน ดังนี้ หากราคาของสินทรัพย์ลดลงเหลือศูนย์ผลได้ตอบแทนอย่างง่ายจะเท่ากับ  $-1$  ซึ่งเป็นขอบเขตต่ำสุดของผลได้ตอบแทนอย่างง่าย ในขณะที่ขอบเขตล่างของผลได้ตอบแทนในรูปลอการิทึมจะเท่ากับ  $-\infty$  ( $r_t = \ln(1 + R_t) = \ln(1 - 1) = \ln(0)$ ) ดังนั้นหากเราคำนวณผลได้ตอบแทนในรูปลอการิทึมมีค่าติดลบมากๆ จึงไม่ได้หมายความว่าเราสูญเสียเงินมากกว่าเงินต้น หากเราต้องการทราบอัตราผลตอบแทนเราจำเป็นต้องใช้สมการ (2.10) ในการคำนวณกลับไปเป็นผลได้ตอบแทนอย่างง่าย

เนื่องจากผลได้ตอบแทนในรูปลอการิทึมมีคุณสมบัติในการรวมกันที่ง่ายกว่าผลได้ตอบแทนอย่างง่าย ดังนั้นการวิเคราะห์เชิงสถิติหรือการสร้างแบบจำลองเรามักจะใช้ผลได้ตอบแทนในรูปลอการิทึม

### ผลได้ตอบแทนหลายเดือน

หากเราพิจารณาผลได้ตอบแทนในรูปลอการิทึมสองเดือนจะเท่ากับ

$$r_t(2) = \ln(1 + R_t(2)) = \ln\left(\frac{P_t}{P_{t-2}}\right) = p_t - p_{t-2}$$

นอกจากนี้เราสามารถหาความสัมพันธ์ระหว่างผลได้ตอบแทนในรูปลอการิทึมสองเดือนกับผลได้ตอบแทนในรูปลอการิทึมหนึ่งเดือนได้โดย

$$\begin{aligned} r_t(2) &= \ln\left(\frac{P_t}{P_{t-2}}\right) \\ &= \ln\left(\frac{P_t}{P_{t-1}} \frac{P_{t-1}}{P_{t-2}}\right) \\ &= \ln\left(\frac{P_t}{P_{t-1}}\right) + \ln\left(\frac{P_{t-1}}{P_{t-2}}\right) \\ &= r_t + r_{t-1} \end{aligned}$$

ดังนั้นผลได้ตอบแทนในรูปลอการิทึมสองเดือนก็คือผลรวมของผลได้ตอบแทนในรูปลอการิทึมรายเดือนของสองเดือนมารวมกันนั่นเอง ซึ่งแตกต่างจากในกรณีของผลได้ตอบแทนอย่างง่ายที่ต้องใช้ผลรวมเรขาคณิต

**ตัวอย่างที่ 2.5** การคำนวณผลได้ตอบแทนหลายเดือน

จากข้อมูลในตัวอย่างที่ 2.2 เราสามารถคำนวณผลได้ตอบแทนในรูปลอการิทึมสองเดือนได้สองวิธีคือ

$$r_t(2) = \ln(200) - \ln(180) = 5.2983 - 5.1930 = 0.1053$$

หรือรวมผลได้ตอบแทนในรูปลอการิทึมหนึ่งเดือนของแต่ละเดือนเข้าด้วยกัน โดย  $r_t = \ln(200) - \ln(190) = 0.0513$  และ  $r_{t-1} = \ln(190) - \ln(180) = 0.0540$  ดังนั้น

$$r_t(2) = 0.0513 + 0.0540 = 0.1053$$

ในกรณีทั่วไป ผลได้ตอบแทนในรูปลอการิทึม  $k$  เดือนสามารถคำนวณได้จาก

$$\begin{aligned} r_t(k) &= \ln(1 + R_t(k)) = \ln\left(\frac{P_t}{P_{t-k}}\right) = p_t - p_{t-k} \\ &= \sum_{j=0}^{k-1} r_{t-j} \end{aligned}$$

ในขณะที่ผลได้ตอบแทนในรูปลอการิทึมของกลุ่มหลักทรัพย์จะเท่ากับ

$$r_{p,t} = \ln(1 + R_{p,t}) = \ln\left(1 + \sum_{i=1}^n x_i R_{i,t}\right) \neq \sum_{i=1}^n x_i r_{i,t} \quad (2.11)$$

โดยผลได้ตอบแทนในรูปลอการิทึมของกลุ่มหลักทรัพย์จะไม่เท่ากับค่าเฉลี่ยถ่วงน้ำหนักของผลได้ตอบแทนในรูปลอการิทึมของสินทรัพย์

**ตัวอย่างที่ 2.6** การคำนวณผลได้ตอบแทนด้วยโปรแกรม R ในตัวอย่างนี้เราจะคำนวณผลได้ตอบแทนของหลักทรัพย์ ปตท. รายวัน ระหว่างเดือนมกราคม 2002 ถึงเดือนธันวาคม 2019 โดยที่เราสามารถดาวน์โหลดข้อมูลดังกล่าวได้จากเว็บไซต์ Yahoo Finance โดยที่ในช่องของหลักทรัพย์เราค้นหาด้วย PTT ซึ่งชื่อของข้อมูลคือ PTT.BK ในที่นี้ราคาที่ใช้คือราคาปิด (ตัวแปร Price ในไฟล์ ptt\_d\_02\_19.csv) เราสามารถนำเข้าข้อมูลโดยใช้คำสั่ง read.csv และเก็บข้อมูลไว้ในชื่อ ptt ดังคำสั่งข้างล่าง นอกจากนี้เราใช้คำสั่ง head ในการดูข้อมูลช่วงต้น และ nrow ในการหาจำนวนตัวอย่าง ( $T$ )

```
1 > ptt <- read.csv("G:/My Drive/teaching/ec435/book_project/data/ptt_d_02_19.csv")
2 > head(ptt)
3       Date Price
4 1  1/2/2002 3.425
5 2  1/4/2002 3.500
6 3  1/7/2002 3.475
7 4  1/8/2002 3.500
```

```

8 5 1/9/2002 3.475
9 6 1/10/2002 3.500
10 > n<-nrow(ptt)

```

คำนวณผลได้ตอบแทนอย่างง่ายสุทธิโดยการกำหนดเวกเตอร์  $P_t$  และ  $P_{t-1}$  แล้วคำนวณตามสมการ 2.3 โดยที่เราใช้เรียกข้อมูลราคา ณ เวลาที่  $t$  ด้วยการกำหนด `ptt$Price[2:n]` และข้อมูลในช่วงเวลา  $t$  ด้วยการกำหนด `ptt$Price[1:n-1]` ชุดข้อมูลผลได้ตอบแทนอย่างง่ายสุทธิจะถูกเก็บไว้ในชื่อ `ptt.ret` ซึ่งเป็นเวกเตอร์

```

1 > ptt.ret<-(ptt$Price[2:n]-ptt$Price[1:n-1])*100/ptt$Price[1:n-1]
2 > head(ptt.ret)
3 [1] 2.18978 -0.71429 0.71942 -0.71429 0.71942 0.00000
4 > (3.5-3.425)/3.425
5 [1] 0.021898

```

คำนวณผลได้ตอบแทนในรูปลอการิทึมจากสมการ 2.9 โดยเราสามารถใชฟังก์ชัน `diff` ในการหาค่าแตกต่างระหว่าง  $\ln(P_t)$  และ  $\ln(P_{t-1})$  ชุดข้อมูลผลได้ตอบแทนในรูปลอการิทึมจะถูกเก็บไว้ในชื่อ `ptt.lret` ซึ่งเป็นเวกเตอร์

```

1 > ptt.lret<-diff(log(ptt$Price))*100
2 > head(ptt.lret)
3 [1] 2.16615 -0.71685 0.71685 -0.71685 0.71685 0.00000
4 > log(3.5/3.425)
5 [1] 0.021661

```

## 2.2 คุณลักษณะทางสถิติของข้อมูลอนุกรมเวลา

เป้าหมายหลักของการวิเคราะห์ข้อมูลอนุกรมเวลาคือการสร้างแบบจำลองทางคณิตศาสตร์เพื่ออธิบายคุณลักษณะของข้อมูลตัวอย่าง เช่น ข้อมูลผลได้ตอบแทนของหุ้น เพื่อให้เราสามารถสร้างแบบจำลองที่จะอธิบายข้อมูลได้ เราจะสมมุติว่าอนุกรมเวลาสามารถนิยามเป็นตัวแปรสุ่ม (random variables) ที่มีการจัดลำดับตามเวลา เช่นลำดับของข้อมูล  $y_1, y_2, y_3, \dots$  โดยที่  $y_1$  เป็นค่าของอนุกรมที่คาบเวลาที่ 1,  $y_2$  เป็นค่าของอนุกรมที่คาบเวลาที่ 2 ตามลำดับ โดยทั่วไป เราจะเรียกกลุ่มของตัวแปรสุ่มที่มีการจัดลำดับตามเวลา  $Y_t = \{y_t, t = 0, \pm 1, \pm 2, \dots\}$  ว่ากระบวนการสุ่มสุ่ม (Stochastic process) ในวิชานี้เราจะเน้นการวิเคราะห์ข้อมูลอนุกรมเวลาด้วยแบบจำลองเชิงเส้นตรง (Linear model) หมายถึง  $Y_t$  มีความสัมพันธ์ขึ้นอยู่กับค่าในอดีตในลักษณะเป็นเส้นตรง

### 2.2.1 การแจกแจงของอนุกรมเวลา (Distribution of time series)

ตัวแปรสุ่ม  $Y_t$  คือฟังก์ชันที่ใช้อธิบายค่าของเหตุการณ์ที่จะเกิดขึ้นในอนาคตโดยที่เรารู้ค่าทั้งหมดที่จะเป็นไปได้แต่ไม่รู้ว่าจะเกิดอะไรขึ้นแน่นอน เช่น ราคาของหลักทรัพย์ ( $P$ ) เราไม่ทราบว่าราคาในเดือนหน้าจะเป็นเท่าไรแน่นอน แต่เราคิดว่าราคาจะต้องเป็นบวกและไม่สูงมากนัก ดังนั้น  $P$  จึงเป็นตัวแปรสุ่มมีค่าระหว่าง  $[0, M]$

โดยที่  $M$  เป็นค่าที่ไม่สูงมากนัก คำถามอีกคำถามหนึ่งคือตัวแปรสุ่มจะมีการแจกแจงอย่างไร โดยที่หนึ่งในทางเลือกคือการแจกแจงแบบ **log-normal**

นอกจากนี้เราอาจจะสนใจว่าการลงทุนของเราในหนึ่งเดือนข้างหน้าจะมีผลได้ผลตอบแทน( $R_t$ )เป็นอย่างไร ดังนั้น  $R_t$  ก็จะเป็นตัวแปรสุ่มเนื่องจากเราไม่ทราบว่าผลได้ตอบแทนในคาบข้างหน้าจะเป็นอย่างไร ทราบเพียงว่าค่าดังกล่าวเป็นได้ทั้งบวกและลบ โดยที่ลบ(ขาดทุน)ได้อย่างมากไม่เกิน 100% การแจกแจงที่ใช้ประมาณค่าสำหรับผลได้ตอบแทนอย่างง่ายรายเดือนที่ดีคือการแจกแจงแบบปกติ

บางครั้งนักลงทุนอาจจะสนใจว่าราคาจะเปลี่ยนแปลงอย่างไร โดยอาจจะสนใจกรณีที่ราคาปรับตัวขึ้นแทนด้วย 0 และกรณีที่ราคาคงที่หรือลดลงแทนด้วย 1 ในกรณีนี้ปริภูมิตัวอย่าง (sample space) ของตัวแปรสุ่มวิยุต (discrete random variable)

**บทนิยาม 2.1** ตัวแปรสุ่มวิยุต  $Y$  คือตัวแปรสุ่มที่มีปริภูมิตัวอย่างเซตที่มีค่าจำกัด  $S_Y = \{y_1, y_2, \dots, y_n\}$  หรือมีค่าเป็นอนันต์ที่นับได้  $S_Y = \{y_1, y_2, \dots\}$

ฟังก์ชันความหนาแน่นของความน่าจะเป็น (probability density function: *pdf*) ของตัวแปรสุ่มวิยุตสามารถเขียนแทนด้วย  $p(y)$  จะเป็นฟังก์ชัน  $p(y) = Pr(Y = y)$  ความน่าจะเป็นที่ตัวแปรสุ่ม  $Y$  เท่ากับค่า  $y$  โดย *pdf* จะต้องมีความสมบัติคือ (1)  $p(y) \geq 0$  สำหรับทุกค่า  $y \in S_Y$  (2)  $p(y) = 0$  สำหรับทุกค่า  $y \notin S_Y$  และ (3)  $\sum_{y \in S_Y} p(y) = 1$

**ตัวอย่างที่ 2.7** การแจกแจงความน่าจะเป็น สมมุติว่าผลได้ตอบแทนจากหุ้น  $A$  มีค่าที่เป็นไปได้และความน่าจะเป็นดังนี้ ตัวอย่างดังกล่าวพิจารณาค่าน่าจะเป็นไปได้ 5 ค่าของผลได้ตอบแทนของหุ้น  $A$  เราสามารถทำนายค่าที่เป็นไปได้ของแต่ละเหตุการณ์ได้

ตัวอย่างของการแจกแจงแบบ **discrete** อื่นๆ ได้แก่ Bernoulli และ Binomial


**บทนิยาม 2.2** ตัวแปรสุ่มแบบต่อเนื่อง  $Y$  จะมีค่าเป็นเท่าใดก็ได้บนเส้นจำนวนจริง ดังนั้น  $S_Y = \{y : y \in \mathbb{R}\}$

ฟังก์ชันความหนาแน่นของความน่าจะเป็น *pdf* ของตัวแปรสุ่มต่อเนื่อง  $Y$  จะเป็นฟังก์ชันที่ไม่เป็นค่าลบ  $f$  นิยามบนเส้นจำนวนจริงโดยที่สำหรับช่วง  $A$  ใดๆ

$$Pr(Y \in A) = \int_A f(y) dy$$

ดังนั้น  $Pr(Y \in A)$  คือพื้นที่ใต้กราฟความน่าจะเป็นตลอดช่วง  $A$  โดยที่ *pdf*  $f(y)$  จะมีคุณสมบัติดังนี้ (1)  $f(y) \geq 0$  และ (2)  $\int_{-\infty}^{\infty} f(y) dy = 1$  ตัวอย่างเช่นกราฟรูปประฆังรูปที่ 2.1 เป็น *pdf* ฟังก์ชันโดยที่พื้นที่ใต้กราฟระหว่าง  $y = -2$  ถึง  $y = 1$  จะแสดงถึง  $Pr(-2 \leq Y < 1)$

รูปที่ 2.1: ฟังก์ชัน pdf ของการแจกแจงต่อเนื่อง



ตัวอย่างของการแจกแจงความน่าจะเป็นของตัวแปรสุ่มแบบต่อเนื่องคือการแจกแจงปกติมาตรฐาน (standard normal distribution)

**บทนิยาม 2.3** ฟังก์ชันการแจกแจงสะสม (cumulative distribution function:  $cdf$ ) ของตัวแปรสุ่ม  $Y$  (ไม่ว่าจะเป็นตัวแปรสุ่มวิฤตหรือต่อเนื่อง) จะมีสัญลักษณ์เป็น  $F_Y$  ซึ่งแสดงค่าความน่าจะเป็นที่  $Y$  ใดๆ จะมีค่าน้อยกว่าหรือเท่ากับ  $y$


$$F_Y(y) = P(Y \leq y), \quad -\infty \leq y \leq \infty$$

ฟังก์ชันการแจกแจงสะสม ( $cdf$ ) จะมีคุณสมบัติดังนี้

1. ถ้า  $y_1 < y_2$  แล้ว  $F_Y(y_1) \leq F_Y(y_2)$
2.  $F_Y(-\infty) = 0$  และ  $F_Y(\infty) = 1$
3.  $Pr(Y > y) = 1 - F_Y(y)$
4.  $Pr(y_1 < X \leq y_2) = F_Y(y_2) - F_Y(y_1)$
5.  $\frac{\partial F_Y(y)}{\partial y} = f_Y(y)$  ถ้า  $Y$  เป็นตัวแปรสุ่มต่อเนื่องและ  $F_Y(y)$  เป็นฟังก์ชันต่อเนื่องและหาอนุพันธ์ได้



รูปที่ 2.2: ฟังก์ชันความหนาแน่นของความน่าจะเป็นและการแจกแจงสะสมของการแจกแจงปกติมาตรฐาน



### ควอนไทล์ของการแจกแจงความน่าจะเป็นของตัวแปรสุ่ม

หากเราพิจารณาตัวแปรสุ่ม  $Y$  ที่มีฟังก์ชันการแจกแจงสะสม  $F_Y(y)$  หากค่า  $0 \leq \alpha \leq 1$  แล้วค่าควอนไทล์ที่  $100\alpha\%$  ของการแจกแจง  $Y$  คือค่า  $q_\alpha$  ที่ตรงกับเงื่อนไข

$$F_Y(q_\alpha) = \Pr(Y \leq q_\alpha) = \alpha$$

ตัวอย่างเช่น ควอนไทล์ที่ 5% ของ  $Y$  เขียนแทนด้วย  $q_{0.05}$  จะเท่ากับค่าที่ทำให้  $F_Y(q_{0.05}) = \Pr(Y \leq q_{0.05}) = 0.05$  และถ้า  $F_Y$  สามารถหาฟังก์ชันผกผันได้ ดังนั้น  $q_\alpha = F_Y^{-1}(\alpha)$

**ตัวอย่างที่ 2.8** การหาความน่าจะเป็นจากฟังก์ชันแจกแจงความถี่ กำหนดให้  $Y \sim N(0,1)$  ค่าควอนไทล์ของการแจกแจงแบบปกติมาตรฐานจะเท่ากับ

$$q_\alpha = \Phi^{-1}(\alpha) \quad (2.12)$$

โดยที่  $\Phi^{-1}$  คือฟังก์ชันผกผันของฟังก์ชันการแจกแจงสะสม  $\Phi$  ซึ่งค่าควอนไทล์จะเป็นค่าที่แสดงในตารางสถิติในหนังสือเกือบทุกเล่ม โดยค่าดังกล่าว

$$q_{0.005} = \Phi^{-1}(0.005) = -2.58, q_{0.01} = \Phi^{-1}(0.01) = -2.33,$$

$$q_{0.025} = \Phi^{-1}(0.025) = -1.96, q_{0.05} = \Phi^{-1}(0.05) = -1.645$$

โดยทั่วไปค่าควอนไทล์ของการแจกแจงปกติมาตรฐานมักจะแทนด้วย  $Z_\alpha$  อย่างไรก็ตามหนังสือบางเล่มอาจจะเขียนสัญลักษณ์ดังกล่าวแทนค่าควอนไทล์นับจากด้านบน (upper quantile) โดยที่ค่าควอนไทล์นับจากด้านบน 5% จะเท่ากับค่าควอนไทล์ 95 % เป็นต้น

ในโปรแกรม R เราสามารถคำนวณพื้นที่ใต้กราฟ pdf หรือ  $\Pr(Y < z)$  ด้วยคำสั่ง `pnorm(z)` โดยที่

$Pr(Y < -2)$  คำนวณได้โดย  $\text{pnorm}(-2)$  นอกจากนี้เราสามารถหาค่าควอนไทล์ที่  $100\alpha\%$  ได้ด้วยคำสั่ง  $\text{qnorm}(\alpha)$  เช่น  $\text{qnorm}(0.01) = -2.326$

### 2.2.2 คุณลักษณะเรื่งรูปร่างของการแจกแจงความน่าจะเป็น

ในการพิจารณาข้อมูลทางการเงิน เราสนใจเกี่ยวกับรูปร่างของการแจกแจงความน่าจะเป็นของตัวแปรสุ่มที่เราสนใจ เช่น เราต้องการที่จะทราบว่าค่ากลางของการแจกแจงอยู่ที่ตรงไหน หรือการแจกแจงมีการแผ่ขยายไปข้างๆอย่างไร นอกจากนี้เรายังสนใจว่าการแจกแจงมีความเป็นสมมาตรหรือไม่ มีรูปร่างที่เบ้ไปทางซ้ายหรือทางขวา หรือความน่าจะเป็นที่จะเกิดเหตุการณ์ที่ห่างจากค่ากลางมากๆ (extreme value) โดยเฉพาะค่าที่ติดลบมากๆ จากสิ่งที่เราสนใจที่ได้กล่าวมาแล้วคุณลักษณะด้านรูปร่างของการแจกแจงความน่าจะเป็นใดๆจะวัดได้ด้วยคุณลักษณะ 4 ประการ

1. ค่าคาดหวัง (expected value) หรือค่าเฉลี่ยเป็นการวัดค่ากลางของการแจกแจง
2. ความแปรปรวนและค่าเบี่ยงเบนมาตรฐานวัดการแผ่จากค่ากลาง
3. ความเบ้ (skewness) วัดความสมมาตรรอบๆค่ากลาง
4. ค่าความโด่ง (kurtosis) วัดความอ้วนของหาง

**บทนิยาม 2.4** ฟังก์ชันค่าคาดหวัง (mean function) ของตัวแปรสุ่ม  $Y$  ใดๆ ใช้สัญลักษณ์  $E(Y)$  สามารถคำนวณได้ดังนี้ ในกรณีที่  $Y$  เป็นตัวแปรสุ่มวิฤต ค่าคาดหวังจะเท่ากับ

$$\mu_Y = E(Y) = \sum_{y \in S_Y} y \times P(Y = y) \quad (2.13)$$

หรือในกรณีตัวแปรสุ่มต่อเนื่อง ค่าคาดหวังจะเท่ากับ

$$\mu_Y = E(Y) = \int_{-\infty}^{\infty} y f(y) dy \quad (2.14)$$

โดยที่  $E$  คือสัญลักษณ์แทนค่าคาดหวัง (Expected value)

#### ค่าคาดหวังของฟังก์ชันของตัวแปรสุ่ม

ลักษณะเฉพาะอื่นด้านรูปร่างของการแจกแจงของตัวแปรสุ่ม  $Y$  มีพื้นฐานจากค่าคาดหวังของฟังก์ชันของ  $Y$  เช่นสมมติให้  $g(Y)$  เป็นฟังก์ชันของ  $Y$  ถ้า  $Y$  เป็นตัวแปรสุ่มแบบ discrete แล้ว

$$E[g(Y)] = \sum_{y \in S_Y} g(y)P(Y = y)$$

และถ้า  $Y$  เป็นตัวแปรสุ่มแบบต่อเนื่องด้วย pdf  $f(y)$  แล้ว

$$E[g(Y)] = \int_{-\infty}^{\infty} g(y)f(y)dy$$

### ค่าความแปรปรวนและค่าเบี่ยงเบนมาตรฐาน

ค่าแปรปรวนของตัวแปรสุ่ม  $Y$  เขียนแทนด้วย  $Var(Y)$  หรือ  $\sigma_Y^2$  วัดการแผ่ของการแจกแจงจากค่าเฉลี่ย โดยที่ค่าแปรปรวนสามารถนิยามได้โดย

$$\sigma_Y^2 = Var(Y) = E[(Y - \mu_Y)^2] \quad (2.15)$$

นอกจากนี้ยังมีอีกสูตรหนึ่งที่เรามักใช้บ่อยในการคำนวณค่าความแปรปรวน

$$\sigma_Y^2 = Var(Y) = E[Y^2] - \mu_Y^2 \quad (2.16)$$

เนื่องจากหน่วยวัดของค่าความแปรปรวนมีหน่วยที่แตกต่างจากตัวแปรสุ่ม  $Y$  ดังนั้นเรามักจะพิจารณาค่าเบี่ยงเบนมาตรฐานเขียนแทนด้วย  $sd(Y)$  หรือ  $\sigma_Y$  ซึ่งเท่ากับค่ารากที่สองของค่าความแปรปรวน ( $\sqrt{\sigma_Y^2}$ )

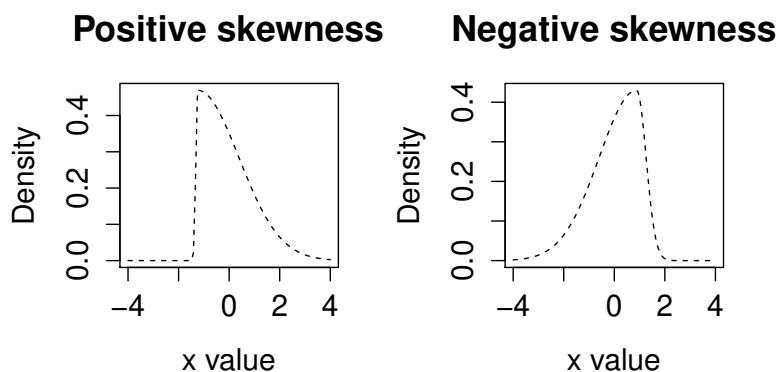
### ค่าความเบ้

ค่าความเบ้ซึ่งสามารถเขียนแทนด้วย  $S(Y)$  วัดความสมมาตรรอบๆค่ากลาง สามารถทำได้โดย

$$S(Y) = \frac{E[(Y - \mu_Y)^3]}{\sigma_Y^3} \quad (2.17)$$

โดยที่หากค่าความเบ้เป็นศูนย์แสดงว่าการแจกแจงมีความสมมาตร ถ้าค่าความเบ้เป็นบวกแสดงว่าข้อมูลถูกดึงไปด้านขวาของการแจกแจง(ทางไปทางขวา) แต่หากค่าความเบ้เป็นลบแสดงว่าข้อมูลถูกดึงไปทางซ้าย(ทางไปทางซ้าย)ในแง่ของการลงทุนหากผลได้ตอบแทนถูกดึงไปด้านซ้าย แสดงว่ามีโอกาสที่เราจะได้ผลลัพธ์ที่สุ่มโต้งค่อนข้างมาก แต่ถ้าทางไปทางขวาโอกาสที่จะเกิดเหตุการณ์ร้ายที่รุนแรงค่อนข้างน้อย ตัวแปรสุ่มที่มีการแจกแจงแบบปกติจะมีค่าความเบ้เป็นศูนย์ เนื่องจากการแจกแจงที่เป็นสมมาตร

รูปที่ 2.3: ฟังก์ชันความถี่ความน่าจะเป็นที่ไม่สมมาตร




### ค่าความโด่ง

ค่าความโด่งใช้วัดความหนาของหางของการแจกแจงซึ่งสามารถเขียนแทนได้ด้วย  $K(Y)$  และสามารถคำนวณได้จาก

$$K(Y) = \frac{E[(Y - \mu_Y)^4]}{\sigma_Y^4} \quad (2.18)$$

เนื่องจากค่าความโด่งเป็นการหาความแตกต่างจากค่ากลางโดยการยกกำลัง 4 ดังนั้นค่าที่ห่างจากจุดศูนย์กลางมากๆจะทำให้ค่าถ่วงน้ำหนักสูงขึ้น และค่าความโด่งสูง ในทางตรงข้ามหากค่าความโด่งต่ำแสดงว่าข้อมูลกระจุกตัวอยู่ตรงกลางและมีโอกาสน้อยที่จะพบข้อมูลที่มีค่าสุดโต่ง ค่าความโด่งของตัวแปรสุ่มที่มีการแจกแจงปกติเท่ากับ 3 โดยเรามักใช้ค่าความโด่งดังกล่าวเป็นมาตรฐานความหนาของหาง หากการแจกแจงใดมีค่าความโด่งมากกว่า 3 แสดงว่าการแจกแจงนั้นมีหางที่อ้วนกว่า (thicker tail) การแจกแจงแบบปกติ แต่ถ้าการแจกแจงมีความความโด่งน้อยกว่า 3 แสดงว่าการแจกแจงมีหางที่ผอมกว่าการแจกแจงปกติ

รูปที่ 2.4: การแจกแจงแบบที



บางครั้งเราแสดงค่าความโด่งในรูปความโด่งเปรียบเทียบกับ การแจกแจงปกติ โดยค่าดังกล่าวเรียกว่าความโด่งส่วนเกิน (excess kurtosis) โดย  $\text{excess } K(Y) = K(Y) - 3$  ถ้าค่าความโด่งส่วนเกินเท่ากับศูนย์แสดงว่าตัวแปรสุ่มมีค่าความโด่งเท่ากับการแจกแจงปกติ ถ้าค่าความโด่งส่วนเกินเป็นบวกแสดงว่าการแจกแจงนั้นมีหางที่อ้วนกว่าการแจกแจงแบบปกติ

ค่าความโด่งของการแจกแจงปกติเป็นเกณฑ์มาตรฐานสำหรับความหนาของหางของการแจกแจงที่เป็นสมมาตร ตัวอย่างการแจกแจงอื่นที่มีลักษณะสมมาตรและมีหางที่อ้วนกว่าการแจกแจงแบบปกติคือ **การแจกแจงแบบที (Student's t)** โดยที่ถ้า  $Y$  มีการแจกแจงแบบทีด้วยองศาเสรี (degree of freedom)  $v$  จะมีค่าเฉลี่ยเท่ากับ 0, ค่าความแปรปรวนเท่ากับ  $v/v - 2$  โดยที่  $v > 2$ , ค่าความเบ้เท่ากับ 0, และค่าความโด่งเท่ากับ  $\frac{6}{(v-4)} - 4$  โดยที่  $v > 4$  เราจะเห็นได้ว่าองศาเสรี  $v$  เป็นตัวกำหนดการแผ่และความหนาของหางของการแจกแจง ถ้าองศาเสรี  $v$  เข้าใกล้ 4 การแจกแจงจะมีหางที่อ้วนมาก แต่ถ้าองศาเสรี  $v$  มีค่าเข้าใกล้อนันต์ ฟังก์ชันการแจกแจง(pdf)ของการแจกแจงจะมีลักษณะเข้าใกล้ฟังก์ชันการแจกแจง(pdf)ของการแจกแจงปกติ การแจกแจงความน่าจะเป็นแบบทีสำหรับค่าองศาเสรีที่ต่างกันสามารถดูได้จากรูปที่ 2.4

### ตัวประมาณค่า(estimator) ของค่าคุณลักษณะของการแจกแจง

ในการประยุกต์เราสามารถประมาณค่าเฉลี่ย ค่าความแปรปรวน ค่าความเบ้และค่าความโด่งได้ด้วยข้อมูลจากกลุ่มตัวอย่าง สมมติให้เราสุ่มตัวอย่าง  $y_1, \dots, y_T$  ซึ่งมีขนาดเท่ากับ  $T$  ค่าเฉลี่ยของตัวอย่าง (sample mean) สามารถคำนวณได้โดย

$$\hat{\mu}_Y = \frac{1}{T} \sum_{t=1}^T y_t \quad (2.19)$$

ค่าความแปรปรวนของตัวอย่างสามารถคำนวณได้โดย

$$\hat{\sigma}_Y^2 = \frac{1}{T-1} \sum_{t=1}^T (y_t - \hat{\mu}_Y)^2 \quad (2.20)$$

ค่าความเบ้ของตัวอย่าง (sample skewness) สามารถคำนวณได้โดย

$$\hat{S}(Y) = \frac{1}{(T-1)\hat{\sigma}_Y^3} \sum_{t=1}^T (y_t - \hat{\mu}_Y)^3 \quad (2.21)$$

และค่าความโด่งของตัวอย่าง (sample kurtosis) สามารถคำนวณได้โดย

$$\hat{K}(Y) = \frac{1}{(T-1)\hat{\sigma}_Y^4} \sum_{t=1}^T (y_t - \hat{\mu}_Y)^4 \quad (2.22)$$

### การทดสอบสมมติฐาน

ภายใต้ข้อสมมุติที่ว่า  $Y_t$  มีการแจกแจงแบบปกติ  $N(0, \sigma^2)$  ค่าเฉลี่ยของตัวอย่างจะมีการแจกแจงแบบปกติ  $N(0, \frac{\sigma^2}{T})$  ดังนั้นในการทดสอบสมมติฐานที่ว่าค่าเฉลี่ยของประชากรมีค่าเท่ากับศูนย์หรือไม่ เราสามารถทำได้โดยใช้ค่าสถิติสัดส่วน  $t$  (t-ratio)

$$t = \frac{\hat{\mu}_Y}{\hat{\sigma}_Y/\sqrt{T}}$$

โดยเราจะปฏิเสธสมมติฐานหลักด้วยระดับนัยสำคัญ(significant level)  $\alpha$  หรือความเชื่อมั่น  $(1 - \alpha/2)100\%$  ถ้า  $|t| > Z_{1-\alpha/2}$  โดยที่  $Z_{1-\alpha/2}$  คือค่าควอนไทล์ที่  $100(1 - \alpha/2)\%$  ของการแจกแจงปกติมาตรฐาน (standard normal)

ค่าความเบ้ของตัวอย่าง ( $\hat{S}(Y)$ ) จะมีการแจกแจงเมื่อกลุ่มตัวอย่างใหญ่เข้าใกล้การแจกแจงปกติโดยมีค่าเฉลี่ยเท่ากับศูนย์และค่าความแปรปรวนเท่ากับ  $6/T$  ส่วนค่าความโด่งส่วนเกินของตัวอย่าง ( $\hat{K}(Y) - 3$ ) จะมีการแจกแจงเมื่อกลุ่มตัวอย่างใหญ่เข้าใกล้การแจกแจงปกติโดยมีค่าเฉลี่ยเท่ากับศูนย์และค่าความแปรปรวนเท่ากับ  $24/T$  ซึ่งคุณสมบัติทั้งสองนำมาใช้ในการทดสอบว่าตัวแปรสุ่ม  $Y_t$  มีการแจกแจงแบบปกติหรือไม่ โดยหากตัวแปรสุ่มมีการแจกแจงแบบปกติค่าความเบ้และค่าความโด่งส่วนเกินจะต้องเท่ากับศูนย์

กำหนดให้เราข้อมูลผลได้ตอบแทน  $y_1, \dots, y_T$  และต้องการทดสอบความเบ้ว่าเท่ากับศูนย์หรือไม่ เราจะตั้ง



สมมุติฐานหลักว่า  $H_0 : S(Y) = 0$  และสมมุติฐานทางเลือกว่า  $H_1 : S(Y) \neq 0$  โดยมีตัวสถิติสัดส่วน  $t$  (t-ratio)

$$t = \frac{\hat{S}(Y)}{\sqrt{6/T}}$$

โดยเราจะปฏิเสธสมมุติฐานหลักที่ระดับนัยสำคัญ  $\alpha$  ถ้า  $|t| > Z_{1-\alpha/2}$  โดยที่  $Z_{1-\alpha/2}$  คือค่าควอนไทล์ที่  $100(1 - \alpha/2)\%$  ของการแจกแจงปกติมาตรฐาน หรือเราอาจจะใช้การคำนวณค่า  $p$  (p-value)

เราสามารถทดสอบค่าความโด่งส่วนเกินได้ด้วยการตั้งสมมุติฐานว่า  $H_0 : \hat{K}(Y) - 3 = 0$  และ  $H_1 : \hat{K}(Y) - 3 \neq 0$  และมีตัวสถิติคือ

$$t = \frac{\hat{K}(Y) - 3}{\sqrt{24/T}}$$

โดยเราจะปฏิเสธสมมุติฐานหลักที่ระดับนัยสำคัญ  $\alpha$  ถ้า  $|t| > Z_{100-\alpha/2}$  โดยที่  $Z_{100-\alpha/2}$  คือค่าควอนไทล์ที่  $100(1 - \alpha/2)\%$  ของการแจกแจงปกติมาตรฐาน

Jarque and Bera (1987) ได้รวมการทดสอบของค่าสถิติทั้งสองเข้าด้วยกันและเสนอตัวสถิติ

$$JB = \frac{\hat{S}^2(Y)}{6/T} + \frac{[\hat{K}(Y) - 3]^2}{24/T}$$

ซึ่งมีการแจกแจงเมื่อกลุ่มตัวอย่างใหญ่เข้าใกล้ไคกำลังสอง ( $\chi^2$ ) ที่มีองศาอิสระเท่ากับ 2 โดยเราจะปฏิเสธสมมุติฐานหลักที่ระดับนัยสำคัญ  $\alpha$  ถ้า  $JB > \chi^2_{(1-\alpha), df=2}$  โดยที่  $\chi^2_{(1-\alpha), df=2}$  คือค่าควอนไทล์ที่  $100(1 - \alpha)\%$  ของการแจกแจงไคกำลังสองที่มีองศาอิสระเท่ากับ 2

นอกจากนี้เรายังมีวิธีการที่เป็นที่นิยมอันหนึ่งคือการวาดแผนภาพ Normal quantile-quantile หรือเรียกย่อๆว่า QQ plot โดยเป็นการวาดจุด (scatterplot) ค่าที่เรียงจากต่ำ (quantile) ของอนุกรมเวลา  $y_t$  กับค่าที่เรียงจากต่ำของตัวแปรสุ่มที่มีการแจกแจงแบบปกติ ดังนั้นถ้าจุดดังกล่าวอยู่ใกล้กับเส้น 45 องศาแสดงว่ากระบวนการ  $y_t$  มีการแจกแจงแบบปกติ

**ตัวอย่างที่ 2.9** การคำนวณคุณลักษณะทางสถิติและการทดสอบสำหรับผลได้ตอบแทนของหลักทรัพย์ปตท. ตัวอย่างนี้ใช้ข้อมูลผลได้ตอบแทนในรูปลอการิทึมจากตัวอย่าง 2.6 ) ในหัวข้อนี้เราจะคำนวณค่าสถิติเบื้องต้นของ `ptt.lret` โดยใช้ชุดคำสั่ง `FBasics` ซึ่งฟังก์ชัน `basicStats` จะคำนวณสถิติเบื้องต้นที่เราสนใจ ดังคำสั่งข้างล่าง

```
1 > library(fBasics)
2 > basicStats(ptt.lret)
3 > basicStats(ptt.lret)
4       ptt.lret
5 nobs      4444.00000
6 NAs        0.00000
7 Minimum   -235.54443
8 Maximum    231.03634
9 1. Quartile -0.95695
10 3. Quartile  1.02085
11 Mean        0.05745
12 Median      0.00000
13 Sum         255.30882
```

```

14 SE Mean      0.49201
15 LCL Mean     -0.90714
16 UCL Mean      1.02205
17 Variance    1075.79844
18 Stdev       32.79937
19 Skewness     0.01196
20 Kurtosis     46.02838

```

จะเห็นว่าค่าเฉลี่ยของผลได้ตอบแทนในรูปลื้อมีค่าเท่ากับ 0.057 % ต่อวัน ค่าเบี่ยงเบนมาตรฐานเท่ากับ 32.799 ค่าความเบ้ของตัวอย่าง (sample skewness) เท่ากับ 0.012 และค่าความโด่งส่วนเกินของตัวอย่าง (sample excess kurtosis) เท่ากับ 46.028 [Kurtosis ที่รายงานใน R เป็นค่าความโด่งส่วนเกินของตัวอย่าง]

### การทดสอบค่าเฉลี่ย

หากต้องการทราบว่าค่าเฉลี่ยของผลได้ตอบแทนมีค่าต่างจากศูนย์หรือไม่ก็สามารถทำได้โดยการคำนวณตัวสถิติ  $t$  โดยที่จำนวนตัวอย่างเท่ากับ `nobs-NA` (จำนวนตัวอย่าง-จำนวนข้อมูลที่ไม่มี) = `4444-0=4444` ดังนั้นค่าสถิติ  $t$  จะเท่ากับ

$$t = \frac{0.057}{32.799/\sqrt{4444}} = 0.1159$$

เมื่อเปรียบเทียบกับค่า  $Z_{1-0.05/2} = 1.96$  ค่าดังกล่าวสามารถคำนวณได้โดย `qnorm(0.975)` เราพบว่าค่า  $|t| < 1.96$  ดังนั้นเราไม่สามารถปฏิเสธสมมุติฐานหลักว่า "ค่าเฉลี่ยของผลได้ตอบแทนมีค่าเท่ากับศูนย์" นอกจากนี้เราสามารถทดสอบค่าเฉลี่ยเท่ากับศูนย์ได้ด้วยฟังก์ชัน `t.test`

```

1 > t.test(ptt.lret)
2
3       One Sample t-test
4
5 data:  ptt.lret
6 t = 0.12, df = 4443, p-value = 0.9
7 alternative hypothesis: true mean is not equal to 0
8 95 percent confidence interval:
9  -0.9071  1.0220
10 sample estimates:
11 mean of x
12  0.05745

```

จะเห็นว่าฟังก์ชันดังกล่าวคำนวณค่า  $t = 0.12$  และค่าพี (p-value) เท่ากับ 0.9 ซึ่งเราไม่สามารถปฏิเสธสมมุติฐานหลักที่นัยสำคัญเท่ากับ 0.05

### การทดสอบความเป็นสมมาตร

จากค่าความเบ้ของตัวอย่าง เราสามารถคำนวณค่าสถิติ  $t$  ที่ใช้ทดสอบ  $H_0$  ว่าข้อมูลมีความสมมาตร ( $S(Y) = 0$ ) ได้เท่ากับ

$$t = \frac{0.012}{\sqrt{6/4444}} = 0.3266$$

เมื่อเปรียบเทียบกับค่า  $|t|$  กับ  $Z_{1-0.05/2} = Z_{0.975} = 1.96$  เราจะได้  $|t| < Z_{0.975} = 1.96$  เราจึงไม่สามารถปฏิเสธ  $H_0$  ที่ว่าผลได้ตอบแทนในรูปลือกมีลักษณะสมมาตร ที่ระดับความเชื่อมั่น 95 %

### การทดสอบความหนาของหาง

$$t = \frac{46.028}{\sqrt{24/4444}} = 626.3$$

เมื่อเปรียบเทียบกับค่า  $|t|$  กับ  $Z_{1-0.05/2} = Z_{0.975} = 1.96$  เราจะได้  $|t| > Z_{0.975} = 1.96$  เราจึงปฏิเสธสมมติฐานหลัก  $H_0$  ที่ว่าผลได้ตอบแทนในรูปลือกมีความหนาของหางเท่ากับการแจกแจงแบบปกติ และจากค่าความโด่งของตัวอย่างเราสามารถอนุมานได้ว่าการแจกแจงมีลักษณะเป็นหางอ้วน (ความโด่งส่วนเกินมากกว่าศูนย์)

### การทดสอบการแจกแจงปกติ

$$JB = \frac{0.012^2}{6/4444} + \frac{46.028^2}{24/4444} = 392290$$

เมื่อเปรียบเทียบกับค่า  $JB > 5.99 (= \chi_{0.95, df=2}^2)$  ค่าดังกล่าวสามารถคำนวณโดยใช้ฟังก์ชัน `qchisq(1-0.05, 2)` เราจึงปฏิเสธสมมติฐานหลัก  $H_0$  ที่ว่าผลได้ตอบแทนในรูปลือกมีการแจกแจงเป็นแบบปกติ โดยการทดสอบข้างต้นสามารถใช้คำสั่ง `normalTest` ใน package `FBasics` โดยที่ระบุ `argument` คือ ตัวแปรที่ต้องการทดสอบ `ptt.lret` และวิธีการทดสอบ `method="jb"` สำหรับการทดสอบ Jarque-Bera ซึ่งคำสั่งและผลสามารถแสดงได้ดังนี้

```
1 > normalTest(ptt.lret, method="jb")
2
3 Title:
4 Jarque - Bera Normality Test
5
6 Test Results:
7 STATISTIC:
8   X-squared: 392672.7583
9   P VALUE:
10  Asymptotic p Value: < 2.2e-16
```

การทดสอบดังกล่าวได้ค่าต่างจากการคำนวณด้วยมือเล็กน้อยเนื่องจากการปัดเศษ นอกจากนี้ในการทดสอบโปรแกรมจะคำนวณค่าที่ซึ่งมีค่าน้อยมาก ( $< 2.2 \times 10^{-16}$ ) ดังนั้นเราจึงปฏิเสธสมมติฐานหลักด้วยนัยสำคัญใดๆมากกว่า  $2.2 \times 10^{-16}$  %

### การแจกแจงของผลได้ตอบแทน

โดยทั่วไปแล้ว เรามักจะสมมติให้พิจารณาผลได้ตอบแทนในรูปของลอกลบและมักจะสมมติให้มีการแจกแจงแบบปกติ นักศึกษาบางคนอาจจะสงสัยว่าทำไมไม่ใช้ผลได้ตอบแทนอย่างง่าย โดยเราสามารถตอบคำถามดังกล่าวได้โดยการสมมติให้ ผลได้ตอบแทนอย่างง่ายมีการแจกแจงแบบปกติ  $R_t \sim N(0.05, (0.5)^2)$  ซึ่งเราทราบว่าราคาสินทรัพย์ใดๆจะมีค่าติดลบไม่ได้ ดังนั้น  $R_t$  จะต้องมีความมากกว่า  $-1$  ซึ่งหากพิจารณาจากข้อสมมุติการแจกแจงปกติจะเห็นได้ว่า  $Pr(R_t < -1) = Pr\left(\frac{R_t - 0.05}{0.5} < \frac{-1 - 0.05}{0.5}\right) = Pr(Z < -2.1) = 0.018$  หรือมีโอกาส 1.8 % ที่ราคาหุ้นจะติดลบ ซึ่งเป็นไปไม่ได้ ดังนั้นหากเราสมมติให้ผลได้ตอบแทนในรูปลอกลบการที่มีการแจกแจงแบบปกติจะเหมาะสมกว่า เช่น  $\ln(1+R_t) = r_t \sim N(0.05, (0.5)^2)$  โดยในกรณีผลได้ตอบแทนในรูปลอกลบสามารถมีค่าน้อยกว่า  $-1$  ได้ ยกตัวอย่าง หาก  $r_t = -2$  จะสัมพันธ์กับผลได้ตอบแทนอย่างง่าย  $R_t = \exp(-2) - 1 = -0.865$  ซึ่งมีโอกาสที่จะเกิดขึ้นเท่ากับ  $Pr(r_t \leq -2) = Pr\left(\frac{r_t - 0.05}{0.5} < \frac{-2 - 0.05}{0.5}\right) = Pr(Z < -4.1) = 0.00002$  ดังนั้นในแบบจำลองในหัวข้อต่อไปเวลาเราพูดถึงผลได้ตอบแทนเรามักจะใช้ผลได้ตอบแทนในรูปลอกลบ (log return)

### ฟังก์ชันเส้นตรงของตัวแปรสุ่ม

หากกำหนดให้  $X$  เป็นตัวแปรสุ่มที่มี  $E[X] = \mu_X$  และ  $Var(X) = \sigma_X^2$  และ  $a$  และ  $b$  เป็นค่าคงที่ หากเรากำหนดตัวแปรสุ่มใหม่  $Y$  เป็นฟังก์ชันเส้นตรงกับตัวแปรสุ่ม  $X$  โดยที่  $Y = a + bX$  แล้ว

- $\mu_Y = E(Y) = a + bE(X) = a + b\mu_X$
- $\sigma_Y^2 = Var(Y) = b^2 Var(X) = b^2 \sigma_X^2$

### ฟังก์ชันค่าแปรปรวนร่วมในตัว (Autocovariance function)

ฟังก์ชันที่ใช้ในการสรุปความสัมพันธ์ขึ้นอยู่ต่อกันตามเวลา (temporal dependence) ในข้อมูลอนุกรมเวลาคือฟังก์ชันค่าแปรปรวนร่วมในตัวซึ่งสามารถคำนวณได้โดย

$$\begin{aligned} \gamma_{k,t} &= Cov(Y_t, Y_{t-k}) = E((y_t - E(Y_t))(y_{t-k} - E(Y_{t-k}))) \\ &= E(y_t y_{t-k}) - E(Y_t)E(Y_{t-k}) \quad \text{for } k = 0, 1, 2, \dots \end{aligned} \quad (2.23)$$

โดยสมการดังกล่าวสอดคล้องกับค่าแปรปรวนร่วม (covariance) ระหว่างตัวแปรสุ่มสองตัวใดๆ

**บทนิยาม 2.5** อนุกรมเวลาคงที่อย่างเข้ม (Strict stationary) อนุกรมเวลา  $Y_t$  ใดๆจะถูกเรียกว่าอนุกรมเวลาคงที่อย่างเข้ม (strictly stationary) ถ้าการแจกแจงร่วม (joint distribution) ของ  $(y_{t_1}, \dots, y_{t_k})$  เหมือนกันกับการแจกแจงร่วมของตัวแปรที่ห่างออกไป  $t$  คาบ  $(y_{t_1+t}, \dots, y_{t_k+t})$  สำหรับทุกค่าของ  $t$

**บทนิยาม 2.6** อนุกรมเวลาคงที่อย่างอ่อน (weakly stationary) หรืออนุกรมเวลาคงที่ค่าความแปรปรวน (covariance stationary) ข้อมูลอนุกรมเวลา  $Y_t$  ใดๆ จะเรียกว่าเป็นอนุกรมเวลาคงที่อย่างอ่อน (Weakly stationary) หรืออนุกรมเวลาคงที่ (stationary) ถ้ามีคุณสมบัติดังนี้

1.  $E(Y_t) = \mu$
2.  $Var(Y_t) = \sigma^2 < \infty$
3.  $\gamma_{k,t} = \gamma_k = Cov(Y_t, Y_{t-k})$  for all  $k$  and  $t$

โดยสรุปแล้วอนุกรมจะมีค่าเฉลี่ยคงที่, ค่าแปรปรวนคงที่และจำกัด (finite) และฟังก์ชันค่าแปรปรวนร่วมในตัวเป็นฟังก์ชันที่ขึ้นกับค่าล่าเท่านั้นและเป็นอิสระกับเวลา

**บทนิยาม 2.7 Ergodic** อนุกรมเวลาใดๆ จะเป็นอนุกรมเวลาเออร์โกดิก (ergodic) ถ้าค่าโมเมนต์ของตัวอย่างมีค่าลู่เข้าในความน่าจะเป็น (converge in probability) ไปสู่ค่าโมเมนต์ของประชากร ตัวอย่างเช่น

$$\bar{y} \xrightarrow{P} \mu$$

$$\widehat{\gamma}_j \xrightarrow{P} \gamma_j$$

$$\widehat{\rho}_j \xrightarrow{P} \rho_j$$

### ฟังก์ชันสหสัมพันธ์ในตัวหรือเอซีเอฟ (Autocorrelation function; ACF)

ในการวิเคราะห์สถิติทั่วไปเรามักจะสนใจสัมประสิทธิ์สหสัมพันธ์ (correlation coefficient) มากกว่าค่าแปรปรวนร่วม(covariance)เนื่องจากปราศจากผลของหน่วยของข้อมูล ดังนั้น ฟังก์ชันสหสัมพันธ์ในตัวที่ช้ากว่ากัน  $k$  คาบเวลา สำหรับอนุกรมที่เป็นอนุกรมเวลาคงที่ที่จะคำนวณได้จาก

$$\rho_k = \frac{Cov(Y_t, Y_{t-k})}{[Var(Y_t)Var(Y_{t-k})]^{1/2}}, \quad k = 0, 1, 2, \dots \quad (2.24)$$

โดยที่  $\rho_0 = 1$  และ  $|\rho_k| \leq 1$  สำหรับทุกค่า  $k$ . สำหรับข้อมูลที่เป็นอนุกรมเวลาคงที่ ค่าความแปรปรวนจะมีค่าเท่ากับทุกช่วงเวลา หรือ  $Var(Y_t) = Var(Y_{t-k}) = \gamma_0$  ดังนั้น

$$\rho_k = \frac{\gamma_k}{\gamma_0}, \quad k = 0, 1, 2, \dots \quad (2.25)$$

เนื่องจากฟังก์ชันฟังก์ชันค่าแปรปรวนร่วมในตนเองมีความเป็นสมมาตรดังนั้น  $\gamma_k = \gamma_{-k}$  และ  $\rho_k = \rho_{-k}$  นอกจากนี้กราฟที่แสดงค่าฟังก์ชันสหสัมพันธ์ในตัวในแกนตั้งและค่าล่า  $k$  ในแกนนอนเราจะเรียกว่าโครีโลแกรม (Correlogram) โดยสรุปแล้วการพิจารณาว่าอนุกรมเวลาคงที่หรือไม่ก็จะพิจารณาจากค่าเฉลี่ย, ค่าความแปรปรวนและฟังก์ชันสหสัมพันธ์ในตัว

นอกจากนี้เรายังมีคุณสมบัติที่น่าสนใจว่าฟังก์ชันของอนุกรมเวลาคงที่ก็จะเป็นอนุกรมเวลาคงที่ด้วย เช่นถ้า  $Y_t$  เป็นอนุกรมเวลาคงที่แล้ว  $Z_t = g(Y_t)$  ก็จะเป็นอนุกรมเวลาคงที่ด้วย

เราสามารถคำนวณค่าแปรปรวนร่วมในตัวที่ช้ากว่ากัน  $k$  คาบเวลาของตัวอย่าง (lag  $k^{th}$  sample autocovariance) และสหสัมพันธ์ในตัวที่ช้ากว่ากัน  $k$  คาบเวลาของตัวอย่าง (lag  $k^{th}$  sample autocorrelation) ได้

จากสูตรดังต่อไปนี้

$$\hat{\gamma}_k = \frac{1}{T} \sum_{t=k+1}^T (y_t - \bar{Y})(y_{t-k} - \bar{Y}) \quad (2.26)$$

และ

$$\hat{\rho}_k = \frac{\hat{\gamma}_k}{\hat{\gamma}_0} \quad (2.27)$$

โดยที่  $\bar{Y} = \frac{1}{T} \sum_{t=1}^T y_t$  คือค่าเฉลี่ยของตัวอย่าง โดยที่ฟังก์ชันสหสัมพันธ์ร่วมในตนเองของตัวอย่าง (sample ACF) จะวาด  $\hat{\rho}_k$  กับ  $k$


ตัวอย่างหนึ่งของอนุกรมเวลานิ่งคือ กระบวนการเกาส์เซียนไวทนอยที่เป็นอิสระต่อกัน (independent Gaussian white noise process) โดยที่เกาส์เซียนหมายถึงการแจกแจงเป็นปกติมันเอง ถ้ากระบวนการ  $y_t$  มีการแจกแจงแบบเกาส์เซียนไวทนอยที่เป็นอิสระต่อกันโดยมีค่าเฉลี่ยเท่ากับ 0 และค่าความแปรปรวนเท่ากับ  $\sigma^2$  กระบวนการ  $y_t$  จะมีค่าเฉลี่ยเท่ากับ 0 นอกจากนี้ค่าความแปรปรวนร่วมในตัวเองและสหสัมพันธ์ในตัวเองก็จะเท่ากับ 0

เราสามารถสร้างข้อมูลที่เป็นเกาส์เซียนไวทนอยที่มีจำนวนตัวอย่างเท่ากับ 500 ได้ด้วยคำสั่ง `rnorm` ใน R

```
1 > set.seed(123456)
2 > y=rnorm(500,0,1)
3 > library(TSA)
4 > par(mfrow=c(1,2))
5 > plot.ts(y,ylab="Y",main="Y")
6 > acf(y,lag.max=20,main="ACF")
```

จะได้แผนภาพดังนี้

รูปที่ 2.5: ข้อมูลเกาส์เซียนไวทนอยและฟังก์ชันสหสัมพันธ์ในตัวเอง



ในโปรแกรม R แผนภาพสำหรับฟังก์ชันสหสัมพันธ์ในตัวเองจะมีเส้นแสดงความเชื่อมั่น 95% จาก 0 ให้เสมอ โดยที่เส้นประดังกล่าวมีพื้นฐานจากการที่  $y_t \sim iidN(0, \sigma^2)$  ดังนั้น

$$\hat{\rho}_k \overset{a}{\sim} N(0, \frac{1}{T}), \quad \text{for } k > 0$$

หมายความว่า การแจกแจงของ  $\hat{\rho}_k$  มีประมาณใกล้เคียงกับการแจกแจงแบบปกติที่มีค่าเฉลี่ยเท่ากับ 0 และค่า

แปรปรวนเท่ากับ  $\frac{1}{T}$  และเมื่อใช้ผลจาก **central limit theorem** เราจะได้ว่า  $\sqrt{T}\hat{\rho}_k \xrightarrow{d} N(0, 1)$  และเส้นประที่แสดงค่าขอบเขตความเชื่อมั่น 95% ที่ค่าสหสัมพันธ์ในตัวเท่ากับศูนย์จะเท่ากับ  $\pm \frac{1.96}{\sqrt{T}}$  ดังนั้นหากค่าสหสัมพันธ์ในตัวของตัวอย่าง ณ คาบล่าช้า  $k$  ไต่อยู่เกินจากขอบเขตดังกล่าวแสดงว่าค่าสหสัมพันธ์ในตัวมีค่าแตกต่างจากศูนย์อย่างมีนัยสำคัญด้วยความเชื่อมั่น 95%

ในกรณีที่  $y_t = \mu + \sum_{i=1}^q \psi_i \varepsilon_{t-i}$  โดยที่  $\varepsilon_i \sim iid(0, \sigma^2)$  การแจกแจงจะเปลี่ยนไปเป็น

$$\hat{\rho}_k \stackrel{a}{\sim} N\left(0, \frac{(1 + 2 \sum_{i=1}^{k-1} \rho_i^2)}{T}\right), \text{ for } k > 0$$

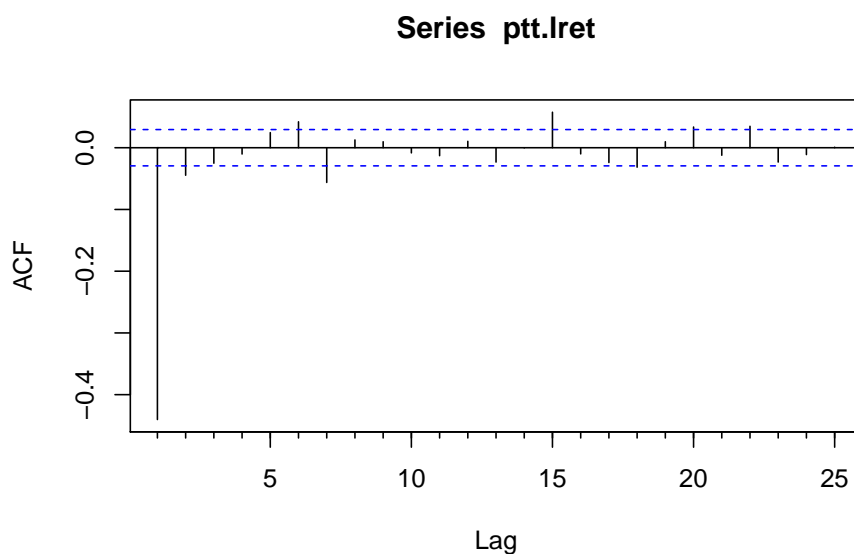
และทำให้ตัวสถิติที่ใช้ในการทดสอบ  $H_0 : \rho_k = 0$  กับ  $H_1 : \rho_k \neq 0$  เปลี่ยนไปเป็น  $\frac{\hat{\rho}_k}{\sqrt{(1 + 2 \sum_{i=1}^{k-1} \rho_i^2)/T}}$  แต่อย่างไรก็ตามโปรแกรมสำเร็จรูปส่วนมากยังใช้  $\sqrt{T}\hat{\rho}$  ในการทดสอบอยู่

### ตัวอย่างการคำนวณฟังก์ชันสหสัมพันธ์ในตัว (หรือเอซีเอฟ) ของผลได้ตอบแทนในรูปล็อกของ PTT

เราพิจารณาผลได้ตอบแทนในรูปล็อกของหุ้น PTT ต่อจากตัวอย่างที่แล้ว โดยเราสามารถคำนวณค่าสหสัมพันธ์ในตัวได้ด้วยฟังก์ชัน `acf` โดยเรากำหนดให้ `argument lag.max` คือจำนวนคาบย้อนหลังสูงสุดที่เราพิจารณา โดยเราจะได้โครีโกลแกรมของผลได้ตอบแทนในรูปล็อก แต่แผนภาพดังกล่าวจะรวม ฟังก์ชันสหสัมพันธ์ในตัวที่ค่าความล่าเท่ากับศูนย์ ( $\rho_0$ ) ซึ่งเท่ากับ 1 ไว้เสมอ ซึ่งทำให้เราอ่านค่าอื่นๆได้ยาก ดังนั้นเราสามารถเรียกใช้ฟังก์ชัน `Acf` หลังจากเรียกชุดคำสั่ง `FORECAST` ซึ่งผลปรากฏในรูปด้านขวา โดยที่ `lag` ที่ 1,2,6,7, 15 มีความสูงเกินจากเส้นประ ( $\pm 2/\sqrt{T}$ ) แสดงว่าค่าสหสัมพันธ์ในตัว ณ ค่าล่าข้างต้นมีความแตกต่างจากศูนย์อย่างมีนัยสำคัญทางสถิติที่นัยสำคัญเท่ากับ 5 %

```
1 > acf(lret, lag.max=25)
2 > library(forecast)
3 > Acf(lret, lag.max=25)
```

รูปที่ 2.6: ฟังก์ชันสหสัมพันธ์ในตัวของผลได้ตอบแทนในรูปล็อกของ PTT



### 2.2.3 การทดสอบพอร์ทแมนโท (Portmanteau test) สำหรับสหสัมพันธ์ในตัวเอง

ในการวิเคราะห์ข้อมูลทางการเงิน เรามักจะเริ่มต้นด้วยการทดสอบว่าข้อมูลมีสหสัมพันธ์ในตัวเองหลาย ๆ คาบ ( $k$ ) ว่าเท่ากับ 0 พร้อมๆ กันหรือไม่ Box and Pierce (1970) ได้เสนอตัวสถิติพอร์ทแมนโทที่คำนวณดังสูตรต่อไปนี้

$$Q^*(m) = T \sum_{k=1}^m \hat{\rho}_k^2 \quad (2.28)$$

ในการทดสอบสมมติฐานหลัก  $H_0 : \rho_1 = \dots = \rho_m = 0$  กับสมมติฐานทางเลือก  $H_1 : \rho_i \neq 0$  สำหรับค่าสหสัมพันธ์ในตัวเองบางคาบย้อนหลังใน  $i \in 1, 2, \dots, m$  โดยภายใต้ข้อสมมุติว่า  $Y_t$  เป็นลำดับที่แจกแจงเป็นอิสระและเหมือนกัน (identical independent distribution: iid) แล้ว  $Q^*(m)$  จะมีการแจกแจงเชิงเส้นกำกับ (asymptotically) เป็นไคกำลังสอง (chi-square) ที่มีองศาเสรีเท่ากับ  $m$  หรือเขียนเป็นสัญลักษณ์  $\chi_m^2$

Ljung and Box (1978) ได้ปรับปรุงตัวสถิติ  $Q^*(m)$  โดยการเพิ่มพลัง(power)ในการทดสอบเมื่อมีตัวอย่างจำกัดโดยเสนอตัวสถิติ

$$Q(m) = T(T+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{T-k} \quad (2.29)$$

โดยเราจะตัดสินใจปฏิเสธสมมติฐานหลัก  $H_0 : \rho_1 = \dots = \rho_m = 0$  ถ้า  $Q(m) > \chi_{1-\alpha, m}^2$  โดยที่  $\chi_{1-\alpha, m}^2$  แสดงถึงควอนไทล์ที่  $100(1-\alpha)$  ของการแจกแจงไคกำลังสองที่มีองศาเสรี  $m$  หรือโปรแกรมสำเร็จรูปส่วนมากก็รายงานค่าพี (p-value) เราก็จะปฏิเสธ  $H_0$  ถ้าค่าพิน้อยกว่าระดับนัยสำคัญ  $\alpha$

ในทางปฏิบัติการเลือกค่า  $m$  จะส่งผลต่อความสามารถในการทดสอบ ดังนั้นงานศึกษาเชิงประจักษ์ส่วนใหญ่มักจะรายงานค่า Ljung-Box  $Q(m)$  หลายๆ ค่าเช่น  $m = 5, 10, 20$  หรืองานวิจัยบางงานพบว่าค่า  $m = \ln(T)$  ให้ผลการทดสอบที่ดี

#### ตัวอย่างการทดสอบพอร์ทแมนโทของผลได้ตอบแทนของ PTT

ฟังก์ชันที่ใช้ในการทดสอบพอร์ทแมนโทคือ `Box.test` โดยเราต้องกำหนด argument คือ ข้อมูลที่ใช้ทดสอบ, จำนวนคาบที่รวมมาทดสอบ ( $m$ ) และชนิดของการทดสอบ (`type="Ljung"`) สำหรับ Ljung and Box (1978)

```
1 > Box.test(ptt.lret, lag=5, type="Ljung")
2
3      Box-Ljung test
4
5 data:  ptt.lret
6 X-squared = 877, df = 5, p-value <2e-16
```

จากการทดสอบจะเห็นได้ว่า  $Q(5) = 877$  และค่าพิน้อยกว่า  $2 \times 10^{-16}$  ซึ่งเราสามารถปฏิเสธ  $H_0$  ที่ว่าฟังก์ชันสหสัมพันธ์ในตัวเองจากคาบ 1 ถึง  $m(=5)$  มีค่าเท่าศูนย์ แสดงว่า  $Y_t$  มีความสัมพันธ์กับตัวเองในคาบใดคาบหนึ่งย้อนหลังไป 1 ถึง 5 คาบ



## 2.2.4 ตัวดำเนินการขยับไปข้างหลัง

**บทนิยาม 2.8** เรานิยาม ตัวดำเนินการขยับไปข้างหลัง (backshift operator) โดย

$$LY_t = Y_{t-1}$$

และสามารถขยายค่ายกกำลังเป็น  $L^2 Y_t = L(LY_t) = LY_{t-1} = Y_{t-2}$  ดังนั้น

$$L^k Y_t = Y_{t-k}$$

นอกจากนี้การหาผลต่าง (differencing) มีบทบาทสำคัญในการวิเคราะห์อนุกรมเวลา ดังนั้นเรามีเครื่องหมายสำหรับการหาผลต่าง โดยการหาผลต่างอันดับที่หนึ่ง (first difference) สามารถเขียนได้โดย

$$\Delta Y_t = Y_t - Y_{t-1} = (1 - L)Y_t \quad (2.30)$$

โดยที่เราสามารถขยายการหาผลต่างต่อไป เช่นการหาผลต่างอันดับที่สอง (second difference) เท่ากับ

$$\Delta^2 Y_t = (1 - L)^2 Y_t = (1 - 2L + L^2)Y_t$$

**บทนิยาม 2.9** การหาผลต่างอันดับ  $d$  (differences of order  $d$ ) สามารถคำนวณได้โดย

$$\Delta^d = (1 - L)^d \quad (2.31)$$

## 2.3 แบบฝึกฝน

**แบบฝึกฝน 2.1** ดาวน์โหลดข้อมูลราคาของหุ้น GM โดยใช้ package *quantmod* และคำสั่ง

```
getSymbols('GM', src='yahoo', return.class='timeSeries', from="2008-01-01", to="2018
```

จะได้ data.frame ชื่อ GM โดยที่ราคาที่ใช้คือ GM.Adjusted

พิจารณาข้อมูลผลตอบแทนรายวันของหุ้น GM หนึ่งหน่วยแล้วตอบคำถามต่อไปนี้

1. จงวาดกราฟเส้นแสดงดัชนีราคารายวัน
2. จงคำนวณผลตอบแทนอย่างง่าย (สุทธิ) (simple net return) ในรูปของเปอร์เซ็นต์แล้วคำนวณหา sample mean, standard deviation, skewness, excess kurtosis, minimum, และ maximum ของผลตอบแทนอย่างง่ายของหุ้น GM
3. จงแปลงค่าผลตอบแทนอย่างง่ายเป็นผลตอบแทนในรูปล็อก แล้วคำนวณหา sample

mean, standard deviation, skewness, excess kurtosis, minimum, และ maximum ของผลได้ตอบแทนในรูปล็อกของหุ้น GM

4. จงทดสอบสมมติฐานหลักที่ว่าค่าเฉลี่ยของผลได้ตอบแทนในรูปล็อกของหุ้น GM มีค่าเป็นศูนย์หรือไม่
5. จงใช้ข้อมูลผลได้ตอบแทนอย่างง่ายเป็นผลได้ตอบแทนในรูปล็อกของหุ้น GM ในข้อ 1 มาทดสอบสมมติฐานหลักที่ว่าตัววัดความเบ้(skewness) ของผลได้ตอบแทนในรูปล็อกของหุ้น GM เท่ากับศูนย์หรือไม่
6. ทดสอบสมมติฐานหลักที่ว่าตัววัด excess kurtosis ของผลได้ตอบแทนในรูปล็อกของหุ้น GM เท่ากับศูนย์หรือไม่
7. ทดสอบสมมติฐานหลักที่ว่าตัววัดการแจกแจงของผลได้ตอบแทนในรูปล็อกของหุ้น GM เป็นแบบปกติหรือไม่

### 3. แบบจำลองอนุกรมเวลาเชิงเส้นตรง

จากบทที่ผ่านมาเราพบว่าหากข้อมูลมีสหสัมพันธ์ในตัว เราสามารถที่จะสร้างแบบจำลองเพื่ออธิบายตัวแปรแทนที่จะอธิบายเพียงคุณลักษณะของตัวแปรนั้น ๆ ในบทนี้ ผู้เขียนจะแนะนำให้รู้จักกับแบบจำลองอนุกรมเวลาเชิงเส้นตรงในรูปแบบที่ง่ายและเป็นที่ยอมรับมากที่สุด โดยที่ในการสร้างแบบจำลองอนุกรมเวลาสำหรับข้อมูลใด ๆ เรามีเป้าหมายเพื่อเข้าใจพฤติกรรมของข้อมูล และพยายามที่จะใช้แบบจำลองดังกล่าวในการพยากรณ์ไปยังช่วงเวลาที่ยังไม่มาถึง ในหัวข้อ 3.1 เราจะพิจารณาแบบจำลองออโตรีเกรสซีฟซึ่งมีลักษณะใกล้เคียงกับแบบจำลองถดถอยในเศรษฐมิติเบื้องต้น หัวข้อ 3.2 อธิบายแบบจำลองมูฟวิ่งเอเวอเรจ หัวข้อ 3.3 อธิบายแบบจำลองออโตรีเกรสซีฟมูฟวิ่งเอเวอเรจ เราจะพิจารณากรณีที่ข้อมูลไม่เป็นอนุกรมเวลาคงที่ในหัวข้อ 3.4 และอธิบายแบบจำลองอินทิเกรตออโตรีเกรสซีฟมูฟวิ่งเอเวอเรจในหัวข้อ 3.5

ในส่วนแรกก่อนที่จะอธิบายแบบจำลองเชิงเส้นตรง แบบจำลองที่จะพูดถึงในบทนี้จะประกอบด้วยส่วนประกอบที่สำคัญคือ กระบวนการไวท์นอยซ์ (white noise) ซึ่งเรามักจะใช้สัญลักษณ์แทนกระบวนการไวท์นอยซ์ด้วย ตัวแปรสุ่ม (random variable)  $\varepsilon_t$  นอกจากนี้เราอาจจะเรียกกระบวนการไวท์นอยซ์ว่าอินโนเวชัน (innovation), ช็อก (shock) หรือตัวรบกวน (disturbance term) ของข้อมูลอนุกรมเวลา

**บทนิยาม 3.1 (กระบวนการไวท์นอยซ์)** กระบวนการ  $\varepsilon_t$  จะเป็นกระบวนการไวท์นอยซ์ถ้าค่าเฉลี่ยของ  $\varepsilon_t$  เท่ากับศูนย์, ค่าความแปรปรวนคงที่และเท่ากับ  $\sigma^2$  และไม่มีสหสัมพันธ์กับช่วงเวลาอื่น (serially uncorrelated) หรือเขียนเป็นเงื่อนไขได้ดังนี้

1.  $E(\varepsilon_t) = 0$
2.  $Var(\varepsilon_t) = \sigma^2$
3.  $\gamma_k = Cov(\varepsilon_t, \varepsilon_{t-k}) = 0$  for  $k \neq 0$

ทฤษฎีบทการแยกส่วนประกอบของโวลด์ (Wold's decomposition theorem) ฟูลเลอร์ (Fuller 1996) ระบุว่าอนุกรมเวลาคงที่  $y_t$  ใด ๆ จะเป็นกระบวนการเส้นตรง (linear process) ถ้าเราสามารถเขียนกระบวนการดังกล่าวในรูปแบบมูฟวิ่งเอเวอเรจที่มีอันดับเป็นอนันต์ (infinite moving average) หรือสามารถ

เขียน  $y_t$  ในรูปต่อไปนี้

$$y_t = \mu + \sum_{i=0}^{\infty} \psi_i \varepsilon_{t-i} \quad (3.1)$$

โดยที่  $\mu$  คือค่าเฉลี่ย,  $\psi_0 = 1$ , และ  $\varepsilon_t$  คือ อันดับของอนุกรมเวลาที่เป็นอิสระและเหมือนกัน (independently identically distributed หรือ ไอไอดี) โดยที่เราสามารถพิจารณา  $\varepsilon_t$  ในฐานะเป็นข้อมูลใหม่ที่เข้ามาในช่วงเวลา  $t$  อันเป็นที่มาของช็อกอินโนเวชัน หรือช็อก ณ เวลา  $t$  นอกจากนี้เราสมมติให้ผลรวมของสัมประสิทธิ์ยกกำลังสองมีค่าจำกัด ( $\sum_{i=1}^{\infty} \psi_i^2 < \infty$ )

ถ้า  $y_t$  เป็นข้อมูลที่เป็นอนุกรมคงที่ (stationary) แล้ว  $y_t$  จะต้องมียกเฉลี่ยคงที่  $E(y_t) = \mu$  และ  $Var(y_t) = \sigma_\varepsilon^2 \sum_{i=1}^{\infty} \psi_i^2$  จะต้องเป็นจำนวนที่จำกัด (finite) ซึ่งจะเกิดขึ้นถ้า  $\sum_{i=1}^{\infty} \psi_i^2$  เข้าลู่เข้าหา (converge) ค่าใดค่าหนึ่ง นอกจากนี้ค่าความแปรปรวนร่วม (covariance)

$$\gamma_l = Cov(y_t, y_{t-l}) = \sigma_\varepsilon^2 \sum_{j=0}^{\infty} \psi_j \psi_{j+l}$$

$$\rho_l = \frac{\sum_{j=0}^{\infty} \psi_j \psi_{j+l}}{\sum_{i=1}^{\infty} \psi_i^2}$$

ดังนั้นรูปแบบของสหสัมพันธ์ในตัวเองของอนุกรมเวลาคงที่ใด ๆ จะถูกกำหนดด้วยตัวถ่วงน้ำหนักค่าเฉลี่ยเคลื่อนที่ (moving average weights;  $\psi_i$ ) นอกจากนี้เราเรียกตัวถ่วงน้ำหนักค่าเฉลี่ยเคลื่อนที่อีกอย่างว่าการตอบสนองแรงกระตุ้น (impulse responses)

$$\frac{\partial y_{t+s}}{\partial \varepsilon_t} = \psi_s, \quad s = 1, 2, 3, \dots \quad (3.2)$$

ในกรณีที่อนุกรมเวลาเป็นอนุกรมคงที่และเออะโกติก  $\lim_{s \rightarrow \infty} \psi_s = 0$  และการตอบสนองแรงกระตุ้นในระยะยาว (long-run cumulative impulse responses) มีค่าจำกัด [ $\sum_{s=0}^{\infty} \psi_s < \infty$ ] นอกจากนี้แผนภาพที่วาด  $\psi_s$  กับ  $s$  เรียกว่าฟังก์ชันการตอบสนองแรงกระตุ้น (impulse response function (IRF))

### 3.1 แบบจำลองออโตรีเกรสซีฟ

แนวคิดพื้นฐานของแบบจำลองออโตรีเกรสซีฟ (autoregressive) คือข้อมูลในเวลาปัจจุบัน ( $y_t$ ) สามารถอธิบายได้ด้วยตัวแปรนั้นในอดีตย้อนหลังไป 1 ถึง  $p$  คาบ ( $y_{t-1}, \dots, y_{t-p}$ ) เราสามารถพิจารณาแบบจำลองดังกล่าวเหมือนกับสมการถดถอย หรือรีเกรสชันที่มีตัวแปร  $y_t$  เป็นตัวแปรที่เราต้องการอธิบาย และตัวแปร  $y_t$  ในอดีตเป็นตัวแปรอธิบาย ดังนั้น แบบจำลองออโตรีเกรสซีฟที่มีอันดับ (order) เท่ากับ  $p$  (เขียนแทนด้วย  $AR(p)$ ) สามารถเขียนได้เป็นสมการได้ดังนี้

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t \quad (3.3)$$

โดยที่  $y_t$  เป็นอนุกรมเวลาคงที่และ  $\varepsilon_t$  เป็นไวท์นอยส์ที่มีค่าเฉลี่ยเท่ากับศูนย์และค่าความแปรปรวนคงที่เท่ากับ  $\sigma_\varepsilon^2$  ในที่นี้ค่าเฉลี่ยของ  $y_t$  เท่ากับศูนย์ ในกรณีดังกล่าว สมการออโตรีเกรสซีฟไม่มีพจน์จุดตัด จากสมการข้างต้น เราสนใจคุณลักษณะของตัวแปร  $y_t$  ซึ่งอธิบายด้วยสมการ 3.3 โดยที่คุณลักษณะแรกคือค่าคาดหวังของ  $y_t$  ( $E(y_t)$ ) ซึ่งเรากำหนดให้เท่ากับ  $\mu$  และเท่ากับในทุกช่วงเวลา เมื่อพิจารณาค่าคาดหวังของ  $y_t$  จากสมการ 3.3 จะได้

$$\underbrace{E(y_t)}_{=\mu} = \phi_1 \underbrace{E(y_{t-1})}_{=\mu} + \phi_2 \underbrace{E(y_{t-2})}_{=\mu} + \dots + \phi_p \underbrace{E(y_{t-p})}_{=\mu} + \underbrace{E(\varepsilon_t)}_{=0}$$

$$\mu = 0/(1 - \phi_1 - \phi_2 - \dots - \phi_p)$$

ในกรณีที่ไม่มีจุดตัด เราจะพบว่าค่าคาดหวังหรือค่าเฉลี่ยของ  $y_t$  จะเท่ากับศูนย์ นอกจากนี้เราสามารถพิจารณาตัวแปร  $y_t$  ในกรณีที่ค่าเฉลี่ยมีค่าเท่ากับค่าคงที่  $\mu$  ใด ๆ ดังสมการต่อไปนี้

$$(y_t - \mu) = \phi_1(y_{t-1} - \mu) + \phi_2(y_{t-2} - \mu) + \dots + \phi_p(y_{t-p} - \mu) + \varepsilon_t \quad (3.4)$$

หรือเราอาจจะเขียนสมการ  $AR(p)$  ในรูปของ

$$y_t = \phi_0 + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t \quad (3.5)$$

โดยที่  $\phi_0 = \mu(1 - \phi_1 - \phi_2 - \dots - \phi_p)$  ซึ่งเราสามารถแสดงได้ว่า  $E(y_t) = \mu = \frac{\phi_0}{(1 - \phi_1 - \phi_2 - \dots - \phi_p)}$

นอกจากนี้เราสามารถเขียนสมการ (3.3) ได้ด้วยเครื่องหมายค่าล่า (lag operator) เป็นสมการดังนี้

$$y_t - \phi_1 L y_t - \phi_2 L^2 y_t - \dots - \phi_p L^p y_t = \varepsilon_t$$

$$(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p) y_t = \varepsilon_t \quad (3.6)$$

หากกำหนดให้  $\phi(L) = 1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p$  ซึ่งเราเรียกว่าพหุนามออโตรีเกรสซีฟ (autoregressive polynomial)

$$\phi(L) y_t = \varepsilon_t \quad (3.7)$$

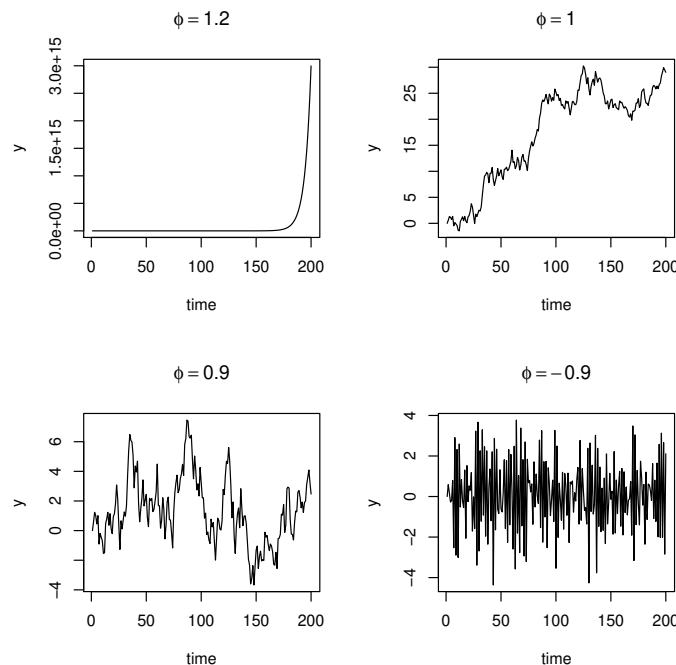
จะได้แบบจำลองออโตรีเกรสซีฟในรูปของพหุนาม ในการสร้างแบบจำลองโดยใช้รูปแบบออโตรีเกรสซีฟหรือรูปแบบอื่น ๆ ที่เราจะกล่าวถึงในบทนี้ เราจำเป็นต้องเข้าใจคุณลักษณะของอนุกรมเวลาซึ่งถูกอธิบายด้วยรูปแบบดังกล่าว ซึ่งคุณลักษณะที่สำคัญได้แก่ ค่าคาดหวัง ค่าความแปรปรวน และค่าสหสัมพันธ์ในตัว (auto-correlation) ซึ่งในกรณีของแบบจำลองออโตรีเกรสซีฟ เราจะเริ่มจากการพิจารณาแบบจำลองอย่างง่ายคือออโตรีเกรสซีฟอันดับหนึ่งแล้วค่อยขยายไปยังออโตรีเกรสซีฟอันดับพี

### 3.1.1 แบบจำลองออโตรีเกรสซีฟอันดับหนึ่ง

ในหัวข้อย่อนี้ เราจะพิจารณาคุณสมบัติของแบบจำลองออโตรีเกรสซีฟอันดับหนึ่ง  $AR(1)$  ซึ่งมีค่าเฉลี่ยเท่ากับ ศูนย์สามารถแสดงได้ด้วยสมการ

$$y_t = \phi y_{t-1} + \varepsilon_t \quad (3.8)$$

จากสมการข้างต้นหากเราเริ่มพิจารณากรณีที่  $y_0 = 0$  และให้  $\varepsilon_t$  มีการแจกแจงแบบปกติมาตรฐาน  $N(0, 1)$  เรา จะได้การเดินทางตามเวลา (time path) ของ  $y_t$  สำหรับค่าสัมประสิทธิ์( $\phi$ )ที่ต่างกันดังที่แสดงในรูป 3.1



รูปที่ 3.1: การจำลองกระบวนการ  $AR(1)$  ที่ค่าสัมประสิทธิ์( $\phi$ )ที่ต่างกัน

จากรูป 3.1 มุมบนซ้ายซึ่งค่า  $|\phi| > 1$  ในกรณีดังกล่าว  $y_t$  จะเพิ่มขึ้นอย่างต่อเนื่องในอัตราที่รุนแรง(explosive)โดยที่ค่าที่  $t = 200$  ค่า  $y_t > 10^{15}$  ในขณะที่มุมบนขวาซึ่งค่า  $|\phi| = 1$  ค่า  $y_t$  จะขยับไปจุดหนึ่งๆและคงค้างอยู่บริเวณนั้นสักพักแล้วก็ไม่เดินทางกลับมาที่จุดเริ่มต้น จะเห็นได้ว่าค่าเฉลี่ยของแต่ละช่วงมีค่าที่แตกต่างกันและค่าความแปรปรวนมีแนวโน้มเพิ่มขึ้นเรื่อย ในกรณีนี้เราจะเรียกกระบวนการนี้ว่า “แรนดอมวอล์ก” (random walk) รูปข้างบนทั้งสองเป็นตัวอย่างของกระบวนการออโตรีเกรสซีฟอันดับหนึ่ง  $AR(1)$  ที่ไม่คงที่ (non-stationary) ในขณะที่รูปล่างทั้งสองรูป  $|\phi| < 1$  ค่า  $y_t$  จะขยับอยู่รอบ ๆ ค่าศูนย์แสดงถึงการเป็นกระบวนการคงที่

จากสมการ 3.8 เราสามารถแทนค่า  $y_t$  ในอดีตไปเรื่อย ๆ แบบเวียนเกิด (recursive)  $k$  ครั้งดังนี้

$$\begin{aligned} y_t &= \phi y_{t-1} + \varepsilon_t = \phi(\phi y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t \\ &= \phi^2 y_{t-2} + \phi \varepsilon_{t-1} + \varepsilon_t \\ &\vdots \\ &= \phi^k y_{t-k} + \sum_{j=0}^{k-1} \phi^j \varepsilon_{t-j} \end{aligned}$$

ด้วยวิธีดังกล่าวข้างต้นและค่า  $|\phi| < 1$  แล้ว  $\lim_{k \rightarrow \infty} \phi^k y_{t-k} = 0$  จะทำให้เราสามารถเขียนแบบจำลอง  $AR(1)$  ในรูปต่อไปนี้

$$y_t = \varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j} \quad (3.9)$$

เราเรียกรูปดังกล่าวว่าการแสดงแบบจำลองออโตรีเกรสซีฟอันดับหนึ่ง  $AR(1)$  ด้วยรูปแบบมูฟวิงเอเวอเรจที่มีอันดับเป็นอนันต์ (infinite moving average representation)

**ค่าคาดหวังหรือค่าเฉลี่ยของ  $y_t$**

หากใส่ค่าคาดหวังทั้งสองข้างของสมการ 3.9 จะได้ข้อสรุปว่ากระบวนการออโตรีเกรสซีฟอันดับหนึ่ง  $AR(1)$  ดังที่ได้แสดงในสมการ 3.8 มีค่าเฉลี่ยเท่ากับศูนย์

$$E(y_t) = E[\varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots]$$

เนื่องจาก  $\varepsilon_t, \varepsilon_{t-1}, \dots$  เป็นอิสระต่อกัน [ทวนความจำ: หาก  $X$  และ  $Z$  เป็นตัวแปรสุ่มที่เป็นอิสระต่อกัน  $E(X + Z) = E(X) + E(Z)$ ] ดังนั้น

$$\begin{aligned} E(y_t) &= E(\varepsilon_t) + E(\phi \varepsilon_{t-1}) + E(\phi^2 \varepsilon_{t-2}) + \dots \\ &= \underbrace{E(\varepsilon_t)}_{=0} + \underbrace{\phi E(\varepsilon_{t-1})}_{=0} + \underbrace{\phi^2 E(\varepsilon_{t-2})}_{=0} + \dots = 0 \end{aligned}$$

จะเห็นได้ว่าค่าเฉลี่ยของ  $y_t$  เท่ากับศูนย์

**ค่าความแปรปรวนของ  $y_t$**

เนื่องจาก  $E(y_t) = 0$  ค่าความแปรปรวน  $Var(y_t) = E[y_t - E(y_t)]^2$  จะเท่ากับ  $Var(y_t) = E(y_t^2)$  หากเราแทนค่า  $y_t$  จากสมการ 3.9 ลงในสูตรดังกล่าว และใช้คุณสมบัติของ  $\varepsilon_t$  ที่ว่า  $Var(\varepsilon_t) = E(\varepsilon_t^2) = \sigma_\varepsilon^2$  และ  $E(\varepsilon_j, \varepsilon_k) = 0$

สำหรับ  $k \neq j$  เราจะได้

$$\begin{aligned}
 E(y_t^2) &= E[(\varepsilon_t + \phi\varepsilon_{t-1} + \phi^2\varepsilon_{t-2} + \dots)(\varepsilon_t + \phi\varepsilon_{t-1} + \phi^2\varepsilon_{t-2} + \dots)] \\
 &= E[\varepsilon_t\varepsilon_t + \varepsilon_t\phi\varepsilon_{t-1} + \varepsilon_t\phi^2\varepsilon_{t-2} + \dots + \phi\varepsilon_{t-1}\varepsilon_t + \phi\varepsilon_{t-1}\phi\varepsilon_{t-1} + \phi\varepsilon_{t-1}\phi^2\varepsilon_{t-2} + \dots \\
 &\quad \phi^2\varepsilon_{t-2}\varepsilon_t + \phi^2\varepsilon_{t-2}\phi\varepsilon_{t-1} + \phi^2\varepsilon_{t-2}\phi^2\varepsilon_{t-2} + \dots] \\
 &= E[\varepsilon_t^2 + \phi\varepsilon_t\varepsilon_{t-1} + \phi^2\varepsilon_t\varepsilon_{t-2} + \dots + \phi\varepsilon_{t-1}\varepsilon_t + \phi^2\varepsilon_{t-1}^2 + \phi^3\varepsilon_{t-1}\varepsilon_{t-2} + \dots \\
 &\quad + \phi^2\varepsilon_{t-2}\varepsilon_t + \phi^3\varepsilon_{t-2}\varepsilon_{t-1} + \phi^4\varepsilon_{t-2}^2 + \dots] \\
 &= \underbrace{E(\varepsilon_t^2)}_{=\sigma_\varepsilon^2} + \underbrace{\phi^2 E(\varepsilon_{t-1}^2)}_{=\sigma_\varepsilon^2} + \underbrace{\phi^4 E(\varepsilon_{t-2}^2)}_{=\sigma_\varepsilon^2} + \dots + \underbrace{\phi E(\varepsilon_t\varepsilon_{t-1})}_{=0} + \underbrace{\phi^2 E(\varepsilon_t\varepsilon_{t-2})}_{=0} + \underbrace{\phi E(\varepsilon_{t-1}\varepsilon_t)}_{=0} + \dots \\
 E(y_t^2) &= (1 + \phi^2 + \phi^4 + \dots)\sigma_\varepsilon^2 = \frac{\sigma_\varepsilon^2}{(1 - \phi^2)} \equiv \gamma_0 \tag{3.10}
 \end{aligned}$$

จากบรรทัดที่ 6 จะเห็นได้ว่าค่าคาดหวังของพจน์ที่คูณกันที่มีตัวห้อยต่างกัน (cross terms) จะเท่ากับศูนย์ นอกจากนี้เราจะใช้สัญลักษณ์  $\gamma_0$  แทนค่าความแปรปรวน

ค่าความแปรปรวนร่วมในตัวเองและฟังก์ชันสหสัมพันธ์ในตัวเอง

หากนำค่า  $y_t$  และ  $y_{t-l}$  ที่เขียนในรูปสมการ 3.9 และค่าเฉลี่ยเท่ากับศูนย์  $E(y_t) = 0$  แทนค่าในสูตรค่าความแปรปรวนร่วมได้ฟังก์ชันค่าความแปรปรวนร่วมในตัวเองที่อันดับแอลจะเท่ากับ

$$\begin{aligned}
 \gamma_l &= Cov(y_t, y_{t-l}) = E[(y_t - E(y_t))(y_{t-l} - E(y_{t-l}))] = E(y_t y_{t-l}) \\
 &= E[(\varepsilon_t + \dots + \phi^l \varepsilon_{t-l} + \phi^{l+1} \varepsilon_{t-l-1} + \phi^{l+2} \varepsilon_{t-l-2} + \dots)(\varepsilon_{t-l} + \phi\varepsilon_{t-l-1} + \phi^2\varepsilon_{t-l-2} + \dots)] \\
 &= E[\text{cross terms} + \dots + \phi^l \varepsilon_{t-l}\varepsilon_{t-l} + \phi^l \varepsilon_{t-l}\phi\varepsilon_{t-l-1} + \phi^l \varepsilon_{t-l}\phi^2\varepsilon_{t-l-2} + \dots \\
 &\quad + \phi^{l+1} \varepsilon_{t-l-1}\varepsilon_{t-l} + \phi^{l+1} \varepsilon_{t-l-1}\phi\varepsilon_{t-l-1} + \phi^{l+1} \varepsilon_{t-l-1}\phi^2\varepsilon_{t-l-2} + \dots \\
 &\quad + \phi^{l+2} \varepsilon_{t-l-2}\varepsilon_{t-l} + \phi^{l+2} \varepsilon_{t-l-2}\phi\varepsilon_{t-l-1} + \phi^{l+2} \varepsilon_{t-l-2}\phi^2\varepsilon_{t-l-2} + \dots + \text{cross terms}] \\
 &= E[\phi^l \varepsilon_{t-l}\varepsilon_{t-l} + \phi^{l+1} \varepsilon_{t-l-1}\phi\varepsilon_{t-l-1} + \phi^{l+2} \varepsilon_{t-l-2}\phi^2\varepsilon_{t-l-2} + \dots + \text{cross terms}] \\
 &= \underbrace{\phi^l E(\varepsilon_{t-l}^2)}_{=\sigma_\varepsilon^2} + \underbrace{\phi^{l+2} E(\varepsilon_{t-l-1}^2)}_{=\sigma_\varepsilon^2} + \underbrace{\phi^{l+4} E(\varepsilon_{t-l-2}^2)}_{=\sigma_\varepsilon^2} + \dots + \underbrace{E(\text{cross terms})}_{=0} \\
 \gamma_l &= \phi^l (1 + \phi^2 + \phi^4 + \dots)\sigma_\varepsilon^2 = \frac{\phi^l \sigma_\varepsilon^2}{(1 - \phi^2)} \tag{3.11}
 \end{aligned}$$

และสหสัมพันธ์ในตัวเองอันดับที่แอลจะเท่ากับ

$$\rho_l = \frac{\gamma_l}{\gamma_0} = \frac{\frac{\phi^l \sigma_\varepsilon^2}{(1 - \phi^2)}}{\frac{\sigma_\varepsilon^2}{(1 - \phi^2)}} = \phi^l \tag{3.12}$$

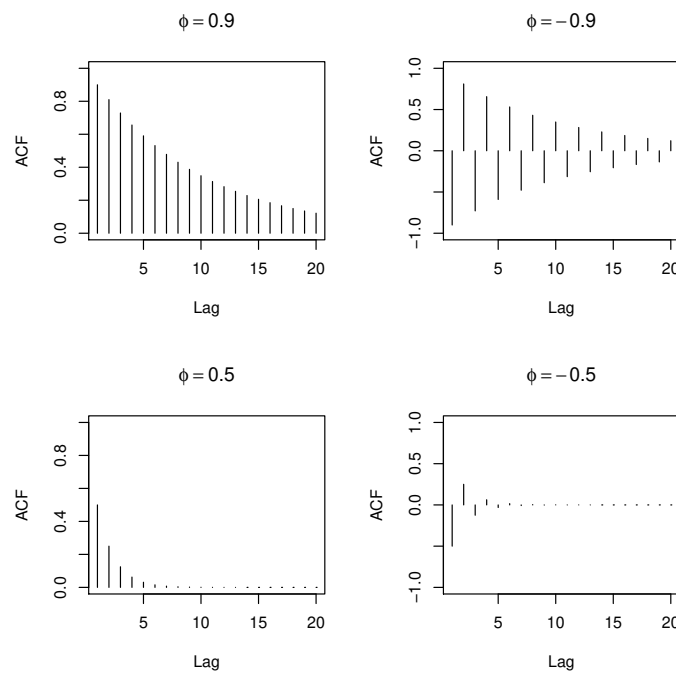


หากเขียนฟังก์ชันระหว่างค่าล่าแอลกับค่าสัมพันธ์ในตัวอันดับที่แอล เราจะเรียกฟังก์ชันดังกล่าวว่าฟังก์ชันสหสัมพันธ์ในตัวหรือเอซีเอฟ ซึ่งหากลองแทนค่า  $\phi$  ด้วยค่าเท่ากับ  $0.9, -0.9, 0.5, -0.5$  จะได้ฟังก์ชันสหสัมพันธ์ในตัวดังตารางต่อไปนี้

ตารางที่ 3.1: ฟังก์ชันสหสัมพันธ์ในตัวของกระบวนการ  $AR(1)$  ที่ค่าสัมประสิทธิ์( $\phi$ )ที่ต่างกัน

$\phi, l$	1	2	3	4	5	6	7	8	9	10
0.9	0.900	0.810	0.729	0.656	0.590	0.531	0.478	0.430	0.387	0.349
-0.9	-0.900	0.810	-0.729	0.656	-0.590	0.531	-0.478	0.430	-0.387	0.349
0.5	0.500	0.250	0.125	0.063	0.031	0.016	0.008	0.004	0.002	0.001
-0.5	-0.500	0.250	-0.125	0.063	-0.031	0.016	-0.008	0.004	-0.002	0.001

จะเห็นว่าค่าสหสัมพันธ์ในตัวของกระบวนการ  $AR(1)$  ในรูปค่าสมบูรณ์มีค่าลดลงเรื่อยๆ โดยที่หากค่า  $\phi$  เป็นลบ เอซีเอฟจะมีลักษณะสลับไปทางบวกและลบสลับกัน นอกจากนี้ค่า  $|\phi|$  ที่เข้าใกล้หนึ่งจะมีเอซีเอฟที่ลดลงช้ากว่ากรณีที่  $|\phi|$  ที่เข้าใกล้ศูนย์ โดยสามารถดูได้จากรูป 3.2



รูปที่ 3.2: ค่าสหสัมพันธ์ร่วมในตัวเองของกระบวนการ  $AR(1)$  ที่ค่าสัมประสิทธิ์( $\phi$ )ที่ต่างกัน

### การพิจารณาเงื่อนไขความเป็นอนุกรมเวลาคงที่จากพหุนามออโตรีเกรสซีฟ

เราสามารถเขียนกระบวนการ  $AR(1)$  ในรูปของพหุนามออโตรีเกรสซีฟได้เป็น

$$\begin{aligned}
 y_t - \phi y_{t-1} &= \varepsilon_t \\
 (1 - \phi L)y_t &= \varepsilon_t
 \end{aligned}
 \tag{3.13}$$

โดยที่เราสามารถเขียนสมการช่วย (auxiliary equation) สำหรับสมการ 3.13 ได้เป็น

$$(1 - \phi m) = 0 \quad (3.14)$$

โดยที่รากของพหุนามออโตรีเกรสซีฟจะเท่ากับ  $m = 1/\phi$  โดยที่เราทราบว่าเงื่อนไขที่กระบวนการ  $AR(1)$  จะเป็นกระบวนการคงที่  $|\phi|$  จะต้องมิต่ำกว่าหนึ่ง ดังนั้นค่าสัมบูรณ์ของรากของพหุนามออโตรีเกรสซีฟจะต้องมีค่ามากกว่าหนึ่ง  $[|m| = |1/\phi| > 1]$

ในขณะเดียวกันเราสามารถเขียนสมการลักษณะเฉพาะ (characteristic equation) สำหรับกระบวนการ  $AR(1)$  จาก  $z^{-1}(z - \phi)y_t = \varepsilon_t$  ได้เป็น

$$(z - \phi) = 0 \quad (3.15)$$

จะเห็นได้ว่ารากของสมการลักษณะเฉพาะจะเท่ากับ  $\phi$  [ $z = \phi$ ] ดังนั้นเราจะได้เงื่อนไขกระบวนการนิ่งว่าค่าสัมบูรณ์ของรากของสมการลักษณะเฉพาะจะต้องมีค่าต่ำกว่าหนึ่ง  $[|z| = |\phi| < 1]$

**ตัวอย่างที่ 3.1 (กระบวนการคงที่)** จงพิจารณาว่ากระบวนการต่อไปนี้ เป็นกระบวนการคงที่หรือไม่

- $y_t - 0.9y_{t-1} = \varepsilon_t$
- $y_t - y_{t-1} = \varepsilon_t$
- $y_t + 1.2y_{t-1} = \varepsilon_t$

เราสามารถเขียนออโตรีเกรสซีฟอันดับหนึ่ง  $AR(1)$  ในรูปทั่วไปเช่นสมการที่ 3.4 หรือ 3.5 โดยที่ในกรณีสมการ 3.4

$$y_t - \mu = \phi(y_{t-1} - \mu) + \varepsilon_t$$

ถ้าเราต้องการหาค่าเฉลี่ยของออโตรีเกรสซีฟกรณีมีค่าเฉลี่ยเท่ากับ  $\mu$  เราสามารถทำได้โดยการใส่ค่าคาดหวังทั้งสองข้างของสมการข้างต้นและใช้ข้อสมมุติที่ว่า  $y_t$  เป็นอนุกรมเวลาหนึ่ง ส่งผลให้ค่าเฉลี่ย ณ เวลาใด ๆ มีค่าคงที่และเท่ากับ  $\mu$  ( $\mu = E(y_t) = E(y_{t-1})$ ) จะได้

$$\begin{aligned} E(y_t) - \mu &= \underbrace{\phi E(y_{t-1})}_{=E(y_t)} - \phi\mu + \underbrace{E(\varepsilon_t)}_{=0} \\ E(y_t) - \mu &= \phi E(y_t) - \phi\mu \\ E(y_t) &= \frac{1 - \phi}{1 - \phi} \mu = \mu \end{aligned}$$

ในกรณีสมการที่ 3.5

$$y_t = \phi_0 + \phi_1 y_{t-1} + \varepsilon_t$$

ถ้าเราต้องการหา  $E(y_t)$  เราสามารถทำได้โดยการใส่ค่าคาดหวังทั้งสองข้างและใช้ข้อสมมุติที่ว่า  $y_t$  เป็น sta-

tionary ( $E(y_t) = E(y_{t-1})$ ) จะได้

$$\begin{aligned} E(y_t) &= \phi_0 + \phi_1 \underbrace{E(y_{t-1})}_{=E(y_t)} + \underbrace{E(\varepsilon_t)}_{=0} \\ (1 - \phi_1)E(y_t) &= \phi_0 \\ E(y_t) &= \frac{\phi_0}{1 - \phi_1} \end{aligned}$$

ดังนั้นเราจะได้ว่า  $\mu = \frac{\phi_0}{1 - \phi_1}$  เราสามารถขยายการวิเคราะห์ดังกล่าวไปยัง  $AR(p)$

### 3.1.2 แบบจำลองออโตรีเกรสซีฟอันดับสอง

แบบจำลองออโตรีเกรสซีฟอันดับที่สอง ( $AR(2)$ ) สามารถเขียนอธิบายได้ด้วยสมการ

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t \quad (3.16)$$

เงื่อนไขการเป็นกระบวนการนี้

เราสามารถพิจารณาความเป็นกระบวนการคงที่ได้โดยการหารากของพหุนามออโตรีเกรสซีฟซึ่งอยู่ในรูป  $(1 - \phi_1 L - \phi_2 L^2)y_t = \varepsilon_t$  สามารถเขียนได้เป็น

$$\phi(m) = 1 - \phi_1 m - \phi_2 m^2$$

โดยแทนค่าเครื่องหมายด้วยตัวแปร  $m$  และพิจารณาสมการช่วย

$$\phi(m) = 1 - \phi_1 m - \phi_2 m^2 = 0 \quad (3.17)$$

โดยที่รากของสมการพหุนามออโตรีเกรสซีฟที่อยู่ในรูปสมการกำลังสอง (quadratic) จะมีด้วยกันสองจำนวน ( $m_1, m_2$ ) เท่ากับ  $\frac{\phi_1 \pm \sqrt{\phi_1^2 + 4\phi_2}}{-2\phi_2}$  ซึ่งรากดังกล่าวสามารถเป็นจำนวนเชิงซ้อนได้ เงื่อนไขที่กระบวนการออโตรีเกรสซีฟอันดับที่สอง  $AR(2)$  จะเป็นกระบวนการคงที่คือ รากของสมการพหุนามออโตรีเกรสซีฟจะต้องมากกว่าหนึ่ง (หรือมอดุลัส (modulus) มากกว่าหนึ่งในกรณีจำนวนเชิงซ้อน) ซึ่งจะเกิดขึ้นเมื่อ

$$\phi_1 + \phi_2 < 1, \quad \phi_2 - \phi_1 < 1, \quad |\phi_2| < 1$$

**ตัวอย่างที่ 3.2 (เงื่อนไขอนุกรมเวลาหนึ่งกรณีออโตรีเกรสซีฟ)** กำหนดให้  $y_t = 0.5y_{t-1} - 0.8y_{t-2} + \varepsilon_t$  เราสามารถพิจารณาสมการพหุนามออโตรีเกรสซีฟ

$$(1 - 0.5m + 0.8m^2) = 0$$

จะเห็นได้ว่า  $\phi_1 = 0.5$  และ  $\phi_2 = -0.8$  เป็นไปตามเงื่อนไข  $\phi_1 + \phi_2 < 1$ ,  $\phi_2 - \phi_1 < 1$ ,  $|\phi_2| < 1$  ดังนั้นกระบวนการ  $y_t$  เป็นกระบวนการนิ่ง นอกจากนี้เราสามารถพิจารณารากของสมการพหุนามออโตรีเกรสซีฟ โดยเราจะเห็นได้ว่า

$$\begin{aligned} m_1, m_2 &= \frac{\phi_1 \pm \sqrt{\phi_1^2 + 4\phi_2}}{-2\phi_2} = \frac{0.5 \pm \sqrt{0.5^2 + 4(-0.8)}}{-2(-0.8)} \\ &= \frac{0.5}{1.6} \pm \frac{\sqrt{-2.95}}{1.6} = \frac{0.5}{1.6} \pm \frac{\sqrt{2.95}\sqrt{-1}}{1.6} \\ &= 0.3125 \pm 1.073473i \end{aligned}$$

โดยที่รากดังกล่าวสามารถคำนวณด้วย R โดยใช้คำสั่ง `polyroot(c(1, -0.5, 0.8))`

ค่ามอดุลัสของจำนวนเชิงซ้อน  $m_1 = a + bi$  จะเท่ากับ  $\sqrt{a^2 + b^2}$  ซึ่งในกรณีนี้เท่ากับ 1.118034 ซึ่งมีค่ามากกว่าหนึ่ง เราสามารถคำนวณมอดุลัสได้โดยใช้คำสั่ง `Mod(arg)` โดยที่ `arg` คือจำนวนเชิงซ้อน

### คุณลักษณะของกระบวนการออโตรีเกรสซีฟอันดับสอง AR(2)

เราสามารถพิจารณาค่าเฉลี่ยของกระบวนการในสมการ 3.16 และพบว่ามีความเฉลี่ยเท่ากับศูนย์ สำหรับฟังก์ชันความแปรปรวนร่วมเราสามารถพิจารณาได้โดยคุณสมบัติของสมการ 3.16 ทั้งสองข้างด้วย  $y_{t-k}$  แล้วใส่ค่าคาดหวังทั้งสองข้างของสมการจะได้

$$\begin{aligned} E(y_t y_{t-k}) &= \phi_1 E(y_{t-1} y_{t-k}) + \phi_2 E(y_{t-2} y_{t-k}) + \underbrace{E(\varepsilon_t y_{t-1})}_{=0} \\ \gamma_k &= \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2} \end{aligned} \quad (3.18)$$

เนื่องจากหากเราเขียน  $y_t$  ในรูปของมูฟวิงเอเวอเรจที่อันดับอนันต์จะได้  $E(\varepsilon_t y_{t-1}) = E(\varepsilon_t \varepsilon_{t-1} + \varepsilon_t \phi_1 \varepsilon_{t-2} + \dots) = 0$  และหาความสัมพันธ์ (3.18) ด้วย  $\gamma_0$  จะได้

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2} \quad (3.19)$$

เราเรียกสมการ 3.18 และ 3.19 ว่าสมการยูวอล์กเกอร์ (Yule-Walker) จากสมการที่ 3.19 หากเราพิจารณากรณีที่  $k = 1$ ,  $\rho_1 = \rho_{-1}$  และ  $\rho_0 = 1$  เราจะได้

$$\rho_1 = \frac{\phi_1}{1 - \phi_2}$$

และกรณีที่  $k = 2$  เราจะได้

$$\rho_2 = \frac{\phi_2(1 - \phi_2) + \phi_1^2}{1 - \phi_2}$$

และกรณี  $k > 2$  เราสามารถแทนค่าแบบเวียนเกิด(recursive)เพื่อให้ได้  $\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2}$  ยกตัวอย่างเช่น กรณีที่  $\phi_1 = 0.3, \phi_2 = 0.4$  เราจะได้

$$\rho_0 = 1, \rho_1 = 0.5, \rho_2 = 0.55, \rho_3 = 0.365, \rho_4 = 0.329, \rho_5 = 0.24485 \dots$$

ซึ่งจะเห็นได้ว่าหลังจากค่าที่ 3 ค่าสหสัมพันธ์ในตัวมีค่าลดลงเรื่อย ๆ

### 3.1.3 แบบจำลองออโตรีเกรสซีฟที่อันดับพี $AR(p)$

แบบจำลอง  $AR(p)$  ที่ได้มีปรับเอาค่าเฉลี่ยออกสามารถเขียนในรูป

$$y_t - \mu = \phi_1(y_{t-1} - \mu) + \phi_2(y_{t-2} - \mu) + \dots + \phi_p(y_{t-p} - \mu) + \varepsilon_t \quad (3.20)$$

หรือเขียนในรูปตัวดำเนินการขยับไปข้างหลัง

$$\phi(L)(y_t - \mu) = \varepsilon_t \quad (3.21)$$

โดยที่  $\phi(L) = 1 - \phi_1 L - \dots - \phi_p L^p$  หรือในรูปสมการถดถอยในตัวเอง

$$\phi(L)y_t = c + \varepsilon_t \quad (3.22)$$

โดยที่เราสามารถแสดงเงื่อนไขที่  $AR(p)$  จะเป็นอนุกรมคงที่และอะโกติกได้ด้วยการพิจารณารากของสมการพหุนามออโตรีเกรสซีฟ

$$\phi(m) = 1 - \phi_1 m - \phi_2 m^2 - \dots - \phi_p m^p = 0$$

หากค่าสัมบูรณ์ของรากทุกตัวของสมการพหุนามออโตรีเกรสซีฟมีค่ามากกว่าหนึ่ง (หรือมอดุลัสมากกว่าหนึ่ง ในกรณีจำนวนเชิงซ้อน) อนุกรมเวลา  $y_t$  จะเป็นอนุกรมเวลาคงที่

นอกจากนี้ในกรณีที่  $AR(p)$  เป็นอนุกรมนิ่ง ค่าคงที่ในรูปแบบถดถอยในตัวเอง( $c$ )จะเท่ากับ  $\mu(1 - \phi_1 - \dots - \phi_p)$  ในทางกลับกัน  $\mu = c/(1 - \phi_1 - \dots - \phi_p)$

หากเราสมมติให้ค่าเฉลี่ย( $\mu$ )เท่าศูนย์และกระบวนการนิ่ง หากเราคูณสมการ 3.20 ด้วย  $y_{t-k}$  แล้วใส่ค่าคาดหวังทั้งสองข้างของสมการและหารด้วยค่าความแปรปรวนในตัวเอง ( $\gamma_0$ ) เราจะได้สมการแสดงความสัมพันธ์แบบเวียนเกิด

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2} + \dots + \phi_p \rho_{k-p}, \quad (3.23)$$

สำหรับทุกค่า  $k \geq 1$  หากเราพิจารณากรณีที่  $k = 1, 2, \dots, p$  และใช้ความสัมพันธ์ที่  $\rho_0 = 1$  และ  $\rho_j = \rho_{-j}$  เราจะได้

ได้สมการยูลอว์กเกอร์ ดังนี้

$$\begin{aligned}\rho_1 &= \phi_1 + \phi_2\rho_1 + \phi_3\rho_2 + \dots + \phi_p\rho_{p-1} \\ \rho_2 &= \phi_1\rho_1 + \phi_2 + \phi_3 + \dots + \phi_p\rho_{p-2} \\ &\vdots \\ \rho_p &= \phi_1\rho_{p-1} + \phi_2\rho_{p-2} + \phi_3\rho_{p-3} + \dots + \phi_p\end{aligned}\quad (3.24)$$

ซึ่งหากเราทราบว่า  $\phi_1, \phi_2, \dots, \phi_p$  เราสามารถหาค่า  $\rho_1, \rho_2, \dots, \rho_p$  ได้ นอกจากนี้

$$E(\varepsilon_t y_t) = E[\varepsilon_t(\phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t)] = E(\varepsilon_t^2) = \sigma^2$$

และหากเราคูณสมการ 3.20 ด้วย  $y_t$  และใส่ค่าคาดหวัง เราจะได้

$$\gamma_0 = \phi_1\gamma_1 + \phi_2\gamma_2 + \dots + \phi_p\gamma_p + \sigma^2 \quad (3.25)$$

และหากใช้ความสัมพันธ์ว่า  $\rho_k = \gamma_k/\gamma_0$  หรือ  $\gamma_k = \rho_k\gamma_0$  จะได้

$$\gamma_0 = \frac{\sigma^2}{1 - \phi_1\rho_1 - \phi_2\rho_2 - \dots - \phi_p\rho_p}$$


เราสามารถแสดงให้เห็นว่าฟังก์ชันสหสัมพันธ์ในตัวของอนุกรมเวลาออโตรีเกรสซีฟมีลักษณะที่ลดลงเรื่อย ๆ คุณลักษณะดังกล่าวช่วยเราในการระบุแบบจำลองที่เหมาะสมกับข้อมูล อย่างไรก็ตาม เราไม่สามารถระบุอันดับที่เหมาะสมจากฟังก์ชันสหสัมพันธ์ในตัวได้

### 3.1.4 ฟังก์ชันสหสัมพันธ์ในตัวบางส่วนหรือพีเอซีเอฟ

ฟังก์ชันสหสัมพันธ์ในตัวบางส่วน (Partial Autocorrelation Function: PACF) เป็นเครื่องมือที่ช่วยในการระบุอันดับของแบบจำลองออโตรีเกรสซีฟ  $AR(p)$  โดยที่ฟังก์ชันสหสัมพันธ์ในตัวบางส่วนมีพื้นฐานจากการประมาณค่าแบบจำลอง  $AR$  กรณีที่กระบวนการที่กำหนดตัวแปรเป็นออโตรีเกรสซีฟที่อันดับ  $p$  หาก  $z_t = y_t - \mu$  เป็นออโตรีเกรสซีฟที่อันดับ  $p$  ค่าสัมประสิทธิ์  $\phi_1, \dots, \phi_p$  มีค่าไม่เท่ากับศูนย์ ในขณะที่ค่าสัมประสิทธิ์  $\phi_{p+1}, \dots$  มีค่าเท่ากับศูนย์ ดังนั้น เราสามารถประมาณค่าสมการออโตรีเกรสซีฟโดยการเพิ่มตัวแปรอธิบายเป็นลำดับดังนี้

$$\begin{aligned}z_t &= \phi_{11}z_{t-1} + \varepsilon_{1t} \\ z_t &= \phi_{21}z_{t-1} + \phi_{22}z_{t-2} + \varepsilon_{2t} \\ &\vdots \\ z_t &= \phi_{p1}z_{t-1} + \phi_{p2}z_{t-2} + \dots + \phi_{pp}z_{t-p} + \varepsilon_{pt}\end{aligned}$$

โดยที่  $z_t = y_t - \mu$  คือข้อมูลที่ได้กำจัดค่าเฉลี่ยแล้ว (demeaned) เราเรียกค่าสัมประสิทธิ์  $\phi_{jj}$  สำหรับ  $j = 1, 2, \dots, p$  (ค่าสัมประสิทธิ์สุดท้ายของแต่ละสมการ) ว่าค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วน ในกรณีที่เราพิจารณาแบบจำลอง  $AR(1)$  ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วนตัวแรก  $\phi_{11}$  จะไม่เท่ากับศูนย์ ส่วนสัมประสิทธิ์ที่เหลือจะเท่ากับศูนย์ เช่นเดียวกันหากเราพิจารณาแบบจำลอง  $AR(2)$  ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วนตัวแรกและตัวที่สอง ( $\phi_{11}$  และ  $\phi_{22}$ ) จะไม่เท่ากับศูนย์ ส่วนสัมประสิทธิ์ที่เหลือ ( $\phi_{jj}$  สำหรับ  $j > 2$ ) จะเท่ากับศูนย์ โดยสรุปแล้ว สำหรับแบบจำลอง  $AR(p)$  ใดๆ ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วน  $p$  ตัวแรกจะไม่เท่ากับศูนย์ และสัมประสิทธิ์ที่เหลือจะเท่ากับศูนย์ โดยจากตัวอย่างใด ๆ เราสามารถประมาณค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วนจากตัวอย่าง (sample PACF) ด้วยวิธีการกำลังสองน้อยที่สุดที่ละสมการ และเก็บค่าประมาณสัมประสิทธิ์  $\hat{\phi}_{jj}$  เมื่อนำค่า  $\hat{\phi}_{jj}$  มาวาดกราฟกับ  $j$  เราจะได้ฟังก์ชันสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วนจากตัวอย่าง (sample PACF) ซึ่งสามารถคำนวณได้โดยใช้ฟังก์ชัน `pacf` ใน R




รูปที่ 3.3: ฟังก์ชันสหสัมพันธ์ในตัวเองบางส่วนของข้อมูลจำลอง  $AR(1)$  และ  $AR(2)$

**ตัวอย่างที่ 3.3** (การสร้างแบบจำลองสำหรับความแตกต่างระหว่างอัตราดอกเบี้ยด้วยแบบจำลองออโตเรเกรสซีฟ  $AR(p)$ ) ในตัวอย่างนี้เราจะพิจารณาความแตกต่างระหว่างอัตราดอกเบี้ย MLR ของไทย<sup>a</sup> และอัตราดอกเบี้ยลูกค้าชั้นดีของสหรัฐอเมริกา<sup>b</sup> รายเดือนระหว่างเดือนมกราคม 1978 ถึงธันวาคม 2004 ซึ่งอยู่ในไฟล์ `mlr.csv` โดยที่คอลัมน์ที่หนึ่งเป็นเดือน คอลัมน์ที่สองเป็นอัตราดอกเบี้ยของไทย คอลัมน์ที่สามเป็นอัตราดอกเบี้ยของสหรัฐอเมริกา และคอลัมน์สี่เป็นส่วนต่าง `diff_th_us` เราจะนำเข้าข้อมูลวาดกราฟ(รูปที่ 3.4)

```

1 > int<-read.csv("https://raw.githubusercontent.com/chaleampong/EC435/
  master/mlr.csv", header = TRUE)
2 > head(int)
3 > ts.plot(int$diff_th_us, ylab="%", xlab="time")

```



รูปที่ 3.4: ความแตกต่างระหว่างอัตราดอกเบี้ยของไทยและสหรัฐอเมริกา


หากเราพิจารณา ACF และ PACF ด้วยคำสั่งดังต่อไปนี้

```

1 > acf(int$diff_th_us)
2 > pacf(int$diff_th_us)

```

จะได้ผลดังรูป



รูปที่ 3.5: ACF และ PACF ของความแตกต่างระหว่างอัตราดอกเบี้ยของไทยและสหรัฐอเมริกา

จากรูปที่ 3.3 เมื่อพิจารณาจากรูป ACF จะเห็นว่าผลต่างของอัตราดอกเบี้ย ( $y_t$ ) มีความสัมพันธ์กับตัวเองในอดีตอย่างมีนัยสำคัญ จากรูป ACF จะพอที่จะเดาได้ว่า  $y_t$  น่าจะมีลักษณะคล้ายกับกระบวนการ  $AR(p)$  ซึ่งเราสามารถพิจารณาได้ด้วยกราฟ PACF ในด้านขวาจะเห็นได้ PACF ต่างจากศูนย์อย่างมีนัยสำคัญจนกระทั่งถึงค่าที่ 3 ดังนั้นเราน่าจะใช้แบบจำลอง  $AR(3)$  ในการประมาณค่าผลต่างของอัตราดอกเบี้ย

<sup>a</sup>ข้อมูลจากธนาคารแห่งประเทศไทย

<sup>b</sup>ข้อมูลจากธนาคารกลางแห่งสหรัฐอเมริกา

### 3.1.5 การประมาณค่าและตรวจสอบแบบจำลอง

การประมาณค่าพารามิเตอร์ของแบบจำลอง  $AR(p)$ : สามารถดำเนินการได้โดยใช้วิธีการกำลังสองน้อยที่สุด เนื่องจากเราสามารถสังเกตตัวแปรทั้งหมดที่ใช้ในการประมาณค่าได้ เนื่องจากตัวแปรอิสระคือตัวแปร  $y_t$  ที่ค่า



ค่า  $1, 2, \dots, p$  นอกจากนี้ตัวประมาณค่า  $\hat{\sigma}^2 = \frac{\sum_{t=p+1}^T \varepsilon_t^2}{T-2p-1}$  อย่างไรก็ตาม ในแบบจำลองอื่นที่จะนำเสนอในบทนี้ไม่สามารถที่จะประมาณค่าได้ด้วยวิธีการกำลังสองน้อยที่สุด วิธีการที่เราใช้ในการประมาณค่าคือวิธีการภาวะน่าจะเป็นสูงสุดหรือเอ็มแอลอี (Maximum Likelihood Estimation หรือ MLE) ซึ่งวิธีการดังกล่าวเริ่มจากการสร้างฟังก์ชันภาวะน่าจะเป็น (likelihood function) แล้วหาตัวประมาณค่าที่ทำให้ภาวะน่าจะเป็นมีค่าสูงสุด

### การประมาณค่าภาวะน่าจะเป็นสูงสุด

หากเราต้องการประมาณค่าแบบจำลองออโตรีเกรสซีฟอันดับหนึ่ง  $AR(1)$  ซึ่งอยู่ในรูปดังต่อไปนี้

$$y_t = \mu + \phi(y_{t-1} - \mu) + \varepsilon_t$$

โดยที่  $\varepsilon_t \sim iidN(0, \sigma^2)$  เนื่องจากข้อมูลอนุกรมเวลาเป็นข้อมูลที่ขึ้นอยู่กับกัน (dependent) ดังนั้น หากเราเก็บข้อมูล  $y_1, \dots, y_T$  แล้วฟังก์ชันภาวะน่าจะเป็นสามารถเขียนได้ดังนี้

$$L(\mu, \phi, \sigma^2) = f(y_1)f(y_2|y_1)f(y_3|y_2) \cdots f(y_T|y_{T-1}) \quad (3.26)$$

เนื่องจาก  $y_t|y_{t-1} \sim N(\mu + \phi(y_{t-1} - \mu), \sigma^2)$  และฟังก์ชันการแจกแจงจะเป็นแบบปกติที่เหมือนกับข้อ

$$f(y_t|y_{t-1}) = f_\varepsilon[(y_t - \mu) - \phi(y_{t-1} - \mu)]$$

และสามารถเขียนฟังก์ชันค่าความควรจะเป็นได้เป็น

$$L(\mu, \phi, \sigma^2) = f(y_1)\Pi_{t=2}^T f_\varepsilon[(y_t - \mu) - \phi(y_{t-1} - \mu)] \quad (3.27)$$

โดยที่เราจำเป็นต้องหาการแจกแจงของ  $f(y_1)$  เราทราบว่าเราสามารถเขียน  $y_1$  ใดๆในรูปของมูฟวิ่งเอเวอเรพที่มีอันดับเป็นอนันต์  $y_1 = \mu + \sum_{j=0}^{\infty} \phi^j \varepsilon_{1-j}$  ซึ่งจะเห็นได้ว่าการแจกแจงเป็นแบบปกติที่มีค่าเฉลี่ย  $\mu$  และค่าความแปรปรวนเท่ากับ  $\sigma^2/(1 - \phi^2)$  ดังนั้นฟังก์ชันภาวะน่าจะเป็นจะเท่ากับ

$$L(\mu, \phi, \sigma^2) = (2\pi\sigma^2)^{-1/2}(1 - \phi^2)^{-1/2} \exp\left(\frac{-(y_1 - \mu)^2}{2\sigma^2/(1 - \phi^2)} + (2\pi\sigma^2)^{-(T-1)/2}\right) \times \exp\left(\frac{\sum_{t=2}^T [(y_t - \mu) - \phi(y_{t-1} - \mu)]}{2\sigma^2}\right) \quad (3.28)$$

การหาประมาณค่าโดยหาค่าพารามิเตอร์ที่ทำให้ลอการิทึมของสมการ (3.28) สูงที่สุดเรียกว่า การประมาณค่าภาวะน่าจะเป็นสูงสุดแบบแม่นยำตรง (exact maximum likelihood estimation) โดยที่ในกรณีนี้เราไม่สามารถหาค่าสูงสุดได้ด้วยการวิเคราะห์หาเงื่อนไขจำเป็น เราต้องใช้กระบวนการด้วยเครื่องคอมพิวเตอร์ในการหาค่าสูงสุด

ในกรณีแบบจำลองออโตรีเกรสซีฟ เราสามารถละเลยค่าเริ่มต้นซึ่งก่อนให้เกิดความไม่เป็นเส้นตรงได้ โดยภายใต้เงื่อนไขสมมติให้ค่าเริ่มต้นเท่ากับศูนย์ เราจะได้ค่าภาวะน่าจะเป็นแบบมีเงื่อนไข (conditional likeli-

hood)

$$L(\mu, \phi, \sigma^2) = \prod_{t=2}^T f_\varepsilon[(y_t - \mu) - \phi(y_{t-1} - \mu)] \quad (3.29)$$

$$= (2\pi\sigma^2)^{-(T-1)/2} \exp\left(-\frac{\sum_{t=2}^T [(y_t - \mu) - \phi(y_{t-1} - \mu)]^2}{2\sigma^2}\right) \quad (3.30)$$

ตัวประมาณค่าที่ได้จากการแสวงหาค่าสูงสุดของสมการ (3.30) เรียกว่าการประมาณค่าภาวน่าจะเป็นสูงสุดแบบมีเงื่อนไข (conditional MLE) หรือเราสามารถเขียนฟังก์ชันในสมการ (3.30) ใหม่เป็น

$$L(\mu, \phi, \sigma^2) = (2\pi\sigma^2)^{-(T-1)/2} \exp\left(-\frac{\sum_{t=2}^T \varepsilon_t^2}{2\sigma^2}\right) \quad (3.31)$$

หรือเราสามารถพิจารณาฟังก์ชันลอการิทึมของฟังก์ชันภาวน่าจะเป็น

$$\ln L(\mu, \phi, \sigma^2) = \frac{-(T-1)}{2} \ln(2\pi) - \frac{(T-1)}{2} \ln(\sigma^2) - \frac{\sum_{t=2}^T \varepsilon_t^2}{2\sigma^2} \quad (3.32)$$

โดยที่ค่าพารามิเตอร์ที่ให้ค่าสูงสุดของ  $\ln L$  จะให้ค่าต่ำสุดของ  $S(\mu, \theta) = \frac{\sum_{t=2}^T \varepsilon_t^2}{2\sigma^2}$  ซึ่งเราเรียกว่าผลรวมของค่าผิดพลาดกำลังสองแบบมีเงื่อนไข (conditional sum of squares) ดังเราจะเรียกการประมาณค่าด้วยวิธี ภาวน่าจะเป็นสูงสุดแบบมีเงื่อนไขว่า การประมาณค่าด้วยผลรวมของค่าผิดพลาดกำลังสองแบบมีเงื่อนไข

ในกรณีที่เราระบุค่าด้วยการหาค่าสูงสุดของสมการ 3.32 เราสามารถตัวประมาณค่าได้ด้วยการหาเงื่อนไขอันดับหนึ่งสำหรับค่าสูงสุด (first order condition)

$$\frac{\partial \ln L}{\partial \phi} = -\frac{1}{2\sigma^2} 2 \sum_{t=2}^T \varepsilon_t (-\phi(y_{t-1} - \mu)) \quad (3.33)$$

$$\frac{\partial \ln L}{\partial \sigma^2} = \frac{-(T-1)}{2} \frac{1}{\sigma^2} + \frac{\sum_{t=2}^T \varepsilon_t^2}{2\sigma^2} \quad (3.34)$$

จากเงื่อนไขแรก

$$\begin{aligned} \sum_{t=2}^T \varepsilon_t (\hat{\phi}(y_{t-1} - \mu)) &= 0 \\ \sum_{t=2}^T [(y_t - \mu) - \hat{\phi}(y_{t-1} - \mu)] (\hat{\phi}(y_{t-1} - \mu)) &= 0 \end{aligned}$$

หลังจากที่จัดรูปใหม่จะได้

$$\hat{\phi} = \frac{\sum_{t=2}^T (y_t - \hat{\mu})(y_{t-1} - \hat{\mu})}{\sum_{t=2}^T (y_t - \hat{\mu})^2}$$

โดยที่ค่า  $\hat{\mu} = \frac{\sum_{t=2}^T y_t}{(T-1)}$  และ จากเงื่อนไขที่สอง  $\hat{\sigma}^2 = \frac{\sum_{t=2}^T \hat{\varepsilon}_t^2}{T-2}$  จะเห็นได้ว่าตัวประมาณค่าที่ได้จากผลรวมของค่าผิดพลาดกำลังสองแบบมีเงื่อนไขเป็นตัวประมาณค่าของวิธีการกำลังสองน้อยที่สุดด้วย

## การประเมินความเหมาะสมของแบบจำลอง

หลังจากที่เราได้ตัวประมาณค่าสำหรับพารามิเตอร์แล้ว เราต้องการทราบว่าแบบจำลองที่ประมาณค่าเหมาะสมในการอธิบายตัวแปร  $y_t$  ที่เราสนใจหรือไม่ โดยที่แนวคิดของการทดสอบคือหากแบบจำลองที่สร้างขึ้นสามารถอธิบาย  $y_t$  ได้อย่างเหมาะสม ค่าส่วนเกินที่เหลือจากแบบจำลองจะต้องไม่มีรูปแบบใด ๆ เหลือ การอธิบายตัวแปร  $y_t$  ด้วยแบบจำลองสามารถคำนวณได้ด้วย ค่าจากสมการประมาณ (fitted value) ของตัวแปรที่เราศึกษา ( $\hat{y}_t = \hat{\phi}_1 y_{t-1} + \dots + \hat{\phi}_p y_{t-p}$ ) ในขณะที่ส่วนที่แบบจำลองไม่สามารถอธิบายได้คือค่าส่วนเกิน (residuals) โดยในที่นี้ค่าส่วนเกินสามารถคำนวณได้จาก  $\varepsilon_t = y_t - \hat{y}_t$  โดยเราจะพิจารณาค่าส่วนเกินว่าเป็นอนุกรมเวลาที่ไม่มีความสัมพันธ์ในตัวเองหรือไวชันนอยซ์หรือไม่

เราอาจจะเริ่มจากการวาดแผนภาพ  $\varepsilon_t$  และฟังก์ชันสหสัมพันธ์ในตัวเองของ  $\varepsilon_t$  เพื่อดูว่าอนุกรมดังกล่าวยังมีความขึ้นอยู่กับกันหรือไม่ โดยที่ภายใต้สมมุติฐานหลักที่ว่า  $\varepsilon_t \sim N(0,1)$  เราสามารถสรุปได้ว่าสหสัมพันธ์ในตัวเองจะมีการแจกแจงเป็น  $N(0,1/T)$  และค่าที่ใช้ในการทดสอบคือ  $\pm 2/\sqrt{T}$

นอกจากนี้เราสามารถทดสอบโดยใช้ค่าสถิติ  $Q(m) = T(T+2) \sum_{k=1}^m \frac{\rho_{\varepsilon_k}^2}{T-k}$  โดยที่  $Q(m) \sim \chi_{m-g}^2$  และเราจะปฏิเสธสมมุติฐานหลักถ้า  $Q(m)$  มีค่ามากกว่าควอนไทล์ที่  $(1-\alpha)$  ของ  $\chi_{m-g}^2$  โดยที่  $g$  คือจำนวนของอันดับในแบบจำลองซึ่งในแบบจำลอง  $AR(p)$  ค่า  $g = p$  และ  $m$  คือจำนวนค่าล่าของความสัมพันธ์ที่พิจารณา

**ตัวอย่างที่ 3.4** การประมาณค่าและตรวจสอบความเหมาะสมของแบบจำลองออโตรีเกรสซีฟ

ต่อเนื่องจากตัวอย่างข้างต้น เราต้องการประมาณค่าแบบจำลอง  $AR(3)$  เราสามารถประมาณค่าได้โดยใช้คำสั่ง `arima` โดยที่ `arg` ที่เราต้องใส่คือ (1) ชื่ออนุกรมเวลาซึ่งในที่นี้คือ `int$diff_th_us` (2) อันดับของอนุกรม `order=c(p, d, q)` โดยที่  $p$  คืออันดับของออโตรีเกรสซีฟ ส่วน  $d$  และ  $q$  คืออันดับของ integration และ moving average ซึ่งเราจะพูดถึงในหัวข้อต่อไป ในหัวข้อนี้เราจะกำหนดให้  $d = 0, q = 0$  โดยที่เราจะเก็บแบบจำลองไว้ใน object ชื่อว่า `m1`

```
1 > m1<-arima(int$diff_th_us, order=c(3,0,0))
2 > m1
3 Call:
4 arima(x = int$diff_th_us, order = c(3, 0, 0))
5 Coefficients:
6          ar1          ar2          ar3  intercept
7          1.3294         -0.4986         0.1334          3.0553
8 s.e.      0.0549         0.0878         0.0549          0.8102
9 sigma^2 estimated as 0.3054:  log likelihood = -269.11,  aic = 548.21
```

โดยที่ค่าสัมประสิทธิ์  $\hat{\phi}_1 = 1.3294, \hat{\phi}_2 = -0.4986, \hat{\phi}_3 = 0.1334, \hat{\mu}(= intercept) = 3.0553$  และมีค่า standard errors อยู่ในบรรทัด s.e. ในโปรแกรม R ค่า `intercept` ที่ได้คือ  $\mu$  มิใช่จุดตัดแกนในสมการที่ 3.5 ดังนั้นถ้าต้องการหาเราต้องการค่า  $\hat{c} = \hat{\mu}(1 - \hat{\phi}_1 - \hat{\phi}_2 - \hat{\phi}_3) = 0.10937$  หรือเราสามารถเขียนผลการประมาณค่าได้โดย

$$(1 - \underset{(0.0549)}{1.3294}L + \underset{(0.0878)}{0.4986}L^2 - \underset{(0.0549)}{0.1334}L^3)(y_t - \underset{(0.8102)}{3.0553}) = \varepsilon_t$$

โดยที่ค่าในวงเล็บคือสแตนดาร์ดแอโร และ  $\hat{\sigma}^2 = 0.3054$

ในการประมาณค่าข้างต้น R จะเลือกใช้การประมาณค่าด้วย CSS ก่อนเพื่อหาจุดเริ่มต้นสำหรับ MLE นอกจากนี้เราสามารถเลือกวิธีการประมาณค่าได้โดยการเพิ่ม argument `method=c("ML")` และ `method=c("CSS")` สำหรับการประมาณค่าด้วย MLE และ CSS ตามลำดับ โดยที่ผลการประมาณค่าจะมีค่าแตกต่างกันเล็กน้อยดังที่ได้แสดงไว้ข้างล่าง

```
1 > m2<-arima(int$diff_th_us, order=c(3,0,0),method=c("ML"))
2 > m2
3 Call:
4 arima(x = int$diff_th_us, order = c(3, 0, 0), method = "ML")
5 Coefficients:
6          ar1          ar2          ar3  intercept
7      1.3295   -0.4987   0.1334      3.056
8 s.e.  0.0549   0.0878   0.0549      0.810
9
10 sigma^2 estimated as 0.3054:  log likelihood = -269.11,  aic = 548.21
11 > m3<-arima(int$diff_th_us, order=c(3,0,0),method=c("CSS"))
12 > m3
13 Call:
14 arima(x = int$diff_th_us, order = c(3, 0, 0), method = "CSS")
15 Coefficients:
16          ar1          ar2          ar3  intercept
17      1.3334   -0.5016   0.1346      3.0793
18 s.e.  0.0551   0.0880   0.0552      0.9195
19 sigma^2 estimated as 0.3082:  part log likelihood = -269.05
```

ถ้าในการประมาณค่าแบบจำลองออโตรีเกรสซีฟ แล้วเราทดสอบค่าเฉลี่ยด้วยการทดสอบที่ว่าไม่มี ความแตกต่างจากศูนย์อย่างมีนัยสำคัญ เราอาจจะปรับรูปแบบสมการเป็นสมการที่ค่าเฉลี่ยเท่ากับ ศูนย์ และประมาณค่าโดยการเพิ่ม argument `include.mean=FALSE` ในคำสั่ง `arima` นอกจากนี้เราสามารถหาค่ารากของสมการพหุนามออโตรีเกรสซีฟได้ตามคำสั่งข้างล่าง

```
1 > p1<-m1$coef
2 > p1
3          ar1          ar2          ar3  intercept
4  1.3294074 -0.4985723  0.1333653  3.0553267
5 > roots=polyroot(p1)
6 > roots
7 [1]  0.4008889+0.5949388i -0.8454280-0.0000000i  0.4008889-0.5949388i
8 > Mod(roots)
9 [1] 0.7174009 0.8454280 0.7174009
```

จะเห็นได้ว่าค่ารากของสมการพหุนามเป็นจำนวนเชิงซ้อนที่มีมอดุลัสน้อยกว่าหนึ่งแสดงว่าอนุกรมที่เรา ประมาณค่าได้เป็นอนุกรมไม่นิ่ง (ซึ่งเราจะกลับมาพิจารณาอนุกรมนี้ในหัวข้อต่อไป)

หลังจากที่เราได้ตัวประมาณค่าของพารามิเตอร์ทั้งหมดแล้วเราจะพิจารณาว่าเรชิตวินั้นยังมีความ สัมพันธ์ระหว่างช่วงเวลาหลงเหลืออยู่หรือไม่ หรือแบบจำลองเพียงพอหรือไม่ โดยการทดสอบ L-B test สำหรับ `m2$residuals` ด้วยคำสั่งข้างล่าง

```
1 > adqtest<-Box.test(m1$residuals, lag=12, type="Ljung")
2 > adqtest
3          Box-Ljung test
```

```

4 data: ml$residuals
5 X-squared = 14.009, df = 12, p-value = 0.3002
6 > #calculate p-value with df=12-3
7 > pv<-1-pchisq(adqtest$statistic, 9)
8 > pv
9 X-squared
10 0.1220215

```

เราทดสอบว่าเรซิดิวของแบบจำลอง `m1` เป็นไวท์นอยซ์หรือไม่ โดยใช้คำสั่ง `Box.test` กับ `ml$residuals` โดยเก็บผลไว้ที่ `adqtest`

จากค่า `LB statistics = 14.009` เราสามารถนำไปเปรียบเทียบกับวิกฤติจากการแจกแจงไคสแคว ( $df=12-3$ ,  $\alpha = 0.05$ ) = 16.92 เนื่องจาก `LB statistics` น้อยกว่าค่าวิกฤติ ดังนั้นเราไม่สามารถปฏิเสธสมมติฐานหลักว่าเรซิดิวเป็นไวท์นอยซ์แสดงว่าแบบจำลอง `AR(3)` เพียงพอในการอธิบาย `diff_th_us`

นอกจากนี้เราสามารถคำนวณค่าพีโดยใช้คำสั่ง `pchisq(value, df)` สำหรับคำนวณหา CDF ไปยังจุดที่ไคสแควเท่ากับ 14.009 และสามารถคำนวณพื้นที่ปลายหางด้วย `1-CDF` ก็จะเป็นค่าพีสำหรับการทดสอบเรซิดิว

ในกรณีนี้ค่าพีเท่ากับ 0.12 ซึ่งมากกว่า  $\alpha (=0.05)$  เราไม่สามารถปฏิเสธสมมติฐานหลักที่ว่าเรซิดิวเป็นไวท์นอยซ์ แสดงว่าแบบจำลอง `AR(3)` เพียงพอที่จะใช้อธิบายความแตกต่างของอัตราดอกเบี้ย

### 3.1.6 การพยากรณ์ด้วยแบบจำลองออโตรีเกรสซีฟ $AR(p)$

การใช้ประโยชน์จากแบบจำลองอนุกรมเวลาที่สำคัญประการหนึ่งคือการพยากรณ์ (forecasting) หากสมมุติให้เรา กำลังอยู่ ณ ช่วงเวลาที่  $h$  แต่ต้องการที่จะพยากรณ์ไปข้างหน้า  $l$  คาบเวลา หรือสนใจค่าของ  $y_{h+l}$  โดยที่  $l \geq 1$  เราเรียก  $h$  ว่าจุดเริ่มต้นการพยากรณ์ (forecast origin) และ  $l$  ว่าขอบเขตการพยากรณ์ (forecast horizon)

กำหนดให้  $\hat{y}_h(l)$  เป็นค่าพยากรณ์ของ  $y_{h+l}$  โดยใช้ข้อมูล ณ เวลาที่  $h$  การพยากรณ์ดังกล่าวจะทำให้ฟังก์ชันสูญเสียที่เกิดจากการค่าผิดพลาดกำลังสอง (squared errors) น้อยที่สุด

$$E[(y_{h+l} - \hat{y}_h(l))^2 | F_h] \leq \min_g E[(y_{h+l} - g)^2 | F_h]$$

โดยที่  $F_h$  เป็นข้อมูลที่มีทั้งหมดในคาบที่  $h$  และเราเรียก  $\hat{y}_h(l)$  ว่าค่าพยากรณ์ของ  $y_t$  ไปข้างหน้า  $l$  คาบเมื่อจุดเริ่มต้นการพยากรณ์อยู่ที่  $h$  ( $l$ -step ahead forecast)

ค่าพยากรณ์ไปข้างหน้า 1 คาบจากแบบจำลอง  $AR(p)$

เราพบว่าค่า  $y_{h+1} = \phi_0 + \phi_1 y_{h+1-1} + \dots + \phi_p y_{h+1-p} + \varepsilon_{h+1}$  ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข (conditional expectation)

$$\begin{aligned}\hat{y}_h(1) &= E(y_{h+1}|F_h) \\ &= E(\phi_0 + \phi_1 y_h + \dots + \phi_p y_{h+1-p}|F_h) + \underbrace{E(\varepsilon_{h+1}|F_h)}_{=0} \\ &= \phi_0 + \phi_1 y_h + \dots + \phi_p y_{h+1-p} = \phi_0 + \sum_{i=1}^p \phi_i y_{h+1-i}\end{aligned}\quad (3.35)$$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ

$$\begin{aligned}e_h(1) &= y_{h+1} - \hat{y}_h(1) \\ &= (\phi_0 + \phi_1 y_h + \dots + \phi_p y_{h+1-p} + \varepsilon_{h+1}) - (\phi_0 + \phi_1 y_h + \dots + \phi_p y_{h+1-p}) = \varepsilon_{h+1}\end{aligned}$$

และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าหนึ่งคาบเท่ากับ

$$Var(e_h(1)) = Var(\varepsilon_{h+1}) = \sigma^2$$

เราสามารถสร้างช่วงความเชื่อมั่น 95 % ของการพยากรณ์ไปข้างหน้า 1 คาบได้โดยช่วงดังกล่าวจะเท่ากับ

$$\hat{y}_h(1) \pm 1.96sd(e_h(1))$$

โดยที่  $sd(e_h(1)) = \sqrt{Var(e_h(1))} = \sqrt{\sigma^2}$  หากแทนค่า  $\sigma^2$  ด้วยตัวประมาณค่า ( $\hat{\sigma}^2$ ) เราจะเรียกค่าดังกล่าวว่าค่าคาดเคลื่อนมาตรฐาน (standard error)

ค่าพยากรณ์ไปข้างหน้า 2 คาบจากแบบจำลอง  $AR(p)$

เราพบว่าค่า  $y_{h+2} = \phi_0 + \phi_1 y_{h+2-1} + \dots + \phi_p y_{h+2-p} + \varepsilon_{h+2}$  ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข

$$\begin{aligned}\hat{y}_h(2) &= E(y_{h+2}|F_h) \\ &= E(\phi_0 + \phi_1 y_{h+1} + \phi_2 y_h + \dots + \phi_p y_{h+2-p}|F_h) + \underbrace{E(\varepsilon_{h+2}|F_h)}_{=0} \\ &= \phi_0 + \phi_1 \underbrace{E(y_{h+1}|F_h)}_{=\hat{y}_h(1)} + \phi_2 y_h + \dots + \phi_p y_{h+2-p} \\ &= \phi_0 + \phi_1 \hat{y}_h(1) + \phi_2 y_{h+2-2} + \dots + \phi_p y_{h+2-p}\end{aligned}\quad (3.36)$$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ

$$\begin{aligned} e_h(2) &= y_{h+2} - \hat{y}_h(2) \\ &= (\phi_0 + \phi_1 y_{h+1} + \dots + \phi_p y_{h+2-p} + \varepsilon_{h+2}) - (\phi_0 + \phi_1 \hat{y}_h(1) + \phi_2 y_{h+2-2} + \dots + \phi_p y_{h+2-p}) \\ &= \varepsilon_{h+2} + \phi_1 (y_{h+1} - \hat{y}_h(1)) = \varepsilon_{h+2} + \phi_1 \varepsilon_{h+1} \end{aligned}$$

และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าหนึ่งคาบเท่ากับ

$$\text{Var}(e_h(2)) = \text{Var}(\varepsilon_{h+2} + \phi_1 \varepsilon_{h+1}) = (1 + \phi_1^2) \sigma^2$$

เราจะสังเกตได้ว่า  $\text{Var}(e_h(2)) \geq \text{Var}(e_h(1))$  ดังนั้นช่วงความเชื่อมั่น 95% ของการพยากรณ์จะมีขนาดที่กว้างขึ้นเรื่อยๆ ซึ่งสะท้อนความแม่นยำของแบบจำลองอนุกรมเวลาเมื่อเราพยากรณ์ไปในอนาคตที่ไกลขึ้น

**ตัวอย่างที่ 3.5** การพยากรณ์ การเปรียบเทียบผลการพยากรณ์กับข้อมูลจริง (in-sample evaluation) ต่อเนื่องจากตัวอย่างที่ผ่านมา เราจะพยากรณ์ไปข้างหน้าโดยใช้ตัวอย่างความแตกต่างของอัตราดอกเบี้ย จำนวนข้อมูลที่เรามีอยู่คือ 324 เดือน เพื่อแสดงให้เห็นความแตกต่างระหว่างค่าจริงและค่าพยากรณ์ เราจะประมาณค่าโดยใช้ข้อมูลเดือนมกราคม 1978 ถึงธันวาคม 2003 เป็นข้อมูลจำนวน 312 โดยเรียกว่าตัวแปร `intdiff.in` ดังคำสั่งในบรรทัดที่ 3 และประมาณค่าด้วยแบบจำลอง  $AR(3)$  และเก็บค่าประมาณไว้ใน Object  $m_4$

```
1 > length(int$diff_th_us)
2 [1] 324
3 > intdiff.in<-int$diff_th_us[1:312]
4 > m4=arima(intdiff.in, order=c(3,0,0))
```

เราสามารถพยากรณ์ไปข้างหน้าโดยใช้คำสั่ง `predict` โดยคำสั่งดังกล่าวจะต้องระบุแบบจำลอง ( $m_4$ ) และจำนวนคาบไปข้างหน้า (`n.ahead`) จะเก็บค่าดังกล่าวไว้ใน object `m4.pred` โดยใน Object ดังกล่าวจะประกอบด้วย

- `$pred` คือค่าพยากรณ์ไปข้างหน้า 1 ถึง 12 คาบซึ่งแสดงค่าในบรรทัดที่ 8-9 ตัวอย่างเช่น  $\hat{y}_{312}(1) = 1.803$  และ  $\hat{y}_{312}(12) = 2.397$
- `$se` คือค่าคาดเคลื่อนมาตรฐานของค่าพยากรณ์ไปข้างหน้า 1 ถึง 12 คาบซึ่งแสดงค่าในบรรทัดที่ 15-16 ตัวอย่างเช่น  $se(e_{312}(1)) = 0.562$  และ  $se(e_{312}(12)) = 1.977$


และสามารถวาดรูปเปรียบเทียบค่าจริง (จากเดือนที่ 313 ถึง 324) และค่าพยากรณ์ (`m4.pred$pred`) พร้อมช่วงความเชื่อมั่น 95 % [ดูคำสั่งในบรรทัด 17 ถึง 20] โดยกราฟดังกล่าวแสดงไว้ที่รูป 3.6

```
1 > m4.pred=predict(m4,n.ahead=12)
2 > m4.pred
3 $pred
4 Time Series:
```

```

5 Start = 313
6 End = 324
7 Frequency = 1
8 [1] 1.803828 1.875260 1.943271 2.005150 2.062937 2.117888 2.170297
   2.220198
9 [9] 2.267658 2.312788 2.355708 2.396527
10 $se
11 Time Series:
12 Start = 313
13 End = 324
14 Frequency = 1
15 [1] 0.5622779 0.9342948 1.1737163 1.3399272 1.4696143 1.5777365
   1.6700163
16 [8] 1.7494732 1.8183586 1.8784737 1.9312318 1.9777417
17 > plot(seq(313,324),int$diff_th_us[313:324],type="l", ylim=c(-2,7),
   ylab="%", xlab="time")
18 > points(seq(313,324), m4.pred$pred)
19 > lines(seq(313,324), m4.pred$pred+1.96*m4.pred$se,lty=2)
20 > lines(seq(313,324), m4.pred$pred-1.96*m4.pred$se,lty=2)

```



รูปที่ 3.6: การพยากรณ์ความแตกต่างระหว่างอัตราดอกเบี้ยของไทยและสหรัฐอเมริกาจาก AR(3)

## 3.2 แบบจำลองมูฟวิงเอเวอเรจ

แบบจำลองมูฟวิงเอเวอเรจหรือค่าเฉลี่ยเคลื่อนที่ (Moving Average หรือ MA) มีพื้นฐานจากแนวคิดที่ว่าอนุกรมเวลาเส้นตรงคงที่ใด ๆ สามารถเขียนให้อยู่ในรูปมูฟวิงเอเวอเรจอันดับเป็นอนันต์ และค่าสัมประสิทธิ์ที่ค่าล่าที่ห่างจากช่วงเวลา  $t$  มีขนาดที่เล็กมากจนกระทั่งเราสามารถละเลยค่าดังกล่าว และสามารถลดจำนวนความล่าของค่าแเอโรให้เหลือจำนวน  $q$  พจน์ที่อยู่ใกล้  $t$  ( $\varepsilon_{t-1}, \dots, \varepsilon_{t-q}$ ) เรียกว่าแบบจำลองมูฟวิงเอเวอเรจที่อันดับ  $q$  ซึ่งเขียนแทนด้วย  $MA(q)$  และแสดงได้ด้วยสมการ

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} = \sum_{j=0}^q \theta_j \varepsilon_{t-j} = \theta(L) \varepsilon_t \quad (3.37)$$



โดยที่  $\theta_0 = 1$  เช่นเดียวกับในกรณีของแบบจำลองออโตรีเกรสซีฟ เราต้องการทราบคุณลักษณะของตัวแปร  $y_t$  หากตัวแปรดังกล่าวถูกอธิบายด้วยรูปแบบมูฟวิ่งเอเวอเรจ โดยที่เราจะเริ่มจากในกรณีที่ง่ายที่สุดคือกรณีแบบจำลองมูฟวิ่งเอเวอเรจอันดับหนึ่ง แล้วพิจารณาไปยังแบบจำลองในรูปแบบทั่วไปที่มีอันดับเท่ากับ  $q$

### 3.2.1 แบบจำลองมูฟวิ่งเอเวอเรจที่อันดับหนึ่ง (MA(1))

สมมติให้  $y_t$  เป็นอนุกรมเวลาในรูปแบบของมูฟวิ่งเอเวอเรจที่อันดับหนึ่ง (MA(1))

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} \quad (3.38)$$

โดยที่  $\varepsilon_t$  มีคุณสมบัติเป็นไวท์นอยส์ ( $E(\varepsilon_t) = 0, Var(\varepsilon_t) = \sigma^2, E(\varepsilon_t, \varepsilon_{t-j}) = 0, \forall j \neq 0$ )

เราเริ่มต้นด้วยการหาค่าคาดหวังของ  $y_t$  โดยการใส่ค่าคาดหวัง (take expectation) ทั้งสองข้างของสมการ (3.38) จะได้

$$E(y_t) = \mu + \underbrace{E(\varepsilon_t)}_{=0} + \theta_1 \underbrace{E(\varepsilon_{t-1})}_{=0} = \mu$$

ต่อไปเราจะพิจารณาค่าความแปรปรวนของ  $y_t$  ( $\gamma_0$ )

$$\begin{aligned} \gamma_0 &= Var(y_t) = E(y_t - E(y_t))^2 \\ &= E(\varepsilon_t + \theta_1 \varepsilon_{t-1})^2 \\ &= E(\varepsilon_t^2 + \theta_1 \varepsilon_t \varepsilon_{t-1} + \theta_1^2 \varepsilon_{t-1}^2) \\ &= \underbrace{E(\varepsilon_t^2)}_{=\sigma_\varepsilon^2} + \theta_1 \underbrace{E(\varepsilon_t \varepsilon_{t-1})}_{=0} + \theta_1^2 \underbrace{E(\varepsilon_{t-1}^2)}_{=\sigma_\varepsilon^2} \\ \gamma_0 &= (1 + \theta_1^2) \sigma_\varepsilon^2 \end{aligned} \quad (3.39)$$

ต่อไปเราจะพิจารณาค่าความแปรปรวนร่วมในตัวเองย้อนไปหนึ่งคาบ (one-lag autocovariance)

$$\begin{aligned} \gamma_1 &= Cov(y_t, y_{t-1}) = E[(y_t - E(y_t))(y_{t-1} - E(y_{t-1}))] \\ &= E[(\varepsilon_t + \theta_1 \varepsilon_{t-1})(\varepsilon_{t-1} + \theta_1 \varepsilon_{t-2})] \\ &= E[\varepsilon_t \varepsilon_{t-1} + \theta_1 \varepsilon_{t-1}^2 + \theta_1 \varepsilon_t \varepsilon_{t-2} + \theta_1^2 \varepsilon_{t-1} \varepsilon_{t-2}] \\ &= \underbrace{E(\varepsilon_t \varepsilon_{t-1})}_{=0} + \theta_1 \underbrace{E(\varepsilon_{t-1}^2)}_{\sigma_\varepsilon^2} + \theta_1 \underbrace{E(\varepsilon_t \varepsilon_{t-2})}_{=0} + \theta_1^2 \underbrace{E(\varepsilon_{t-1} \varepsilon_{t-2})}_{=0} \\ \gamma_1 &= \theta_1 \sigma_\varepsilon^2 \end{aligned} \quad (3.40)$$


พิจารณาค่าความแปรปรวนร่วมในตัวเองย้อนไปที่ห่างกันสองช่วงเวลา

$$\begin{aligned}
 \gamma_2 &= \text{Cov}(y_t, y_{t-2}) = E[(y_t - E(y_t))(y_{t-2} - E(y_{t-2}))] \\
 &= E[(\varepsilon_t + \theta_1 \varepsilon_{t-1})(\varepsilon_{t-2} + \theta_1 \varepsilon_{t-3})] \\
 &= E[\varepsilon_t \varepsilon_{t-2} + \theta_1 \varepsilon_{t-1} \varepsilon_{t-2} + \theta_1 \varepsilon_t \varepsilon_{t-3} + \theta_1^2 \varepsilon_{t-1} \varepsilon_{t-3}] \\
 \gamma_2 &= \underbrace{E(\varepsilon_t \varepsilon_{t-2})}_{=0} + \theta_1 \underbrace{E(\varepsilon_{t-1} \varepsilon_{t-2})}_{=0} + \theta_1 \underbrace{E(\varepsilon_t \varepsilon_{t-3})}_{=0} + \theta_1^2 \underbrace{E(\varepsilon_{t-1} \varepsilon_{t-3})}_{=0} = 0
 \end{aligned} \tag{3.41}$$


จากสมการข้างต้นจะเห็นได้ว่า  $\text{Cov}(y_t, y_{t-k}) = 0$  สำหรับ  $k \geq 2$  ในกรณีที่  $y_t$  เป็น  $MA(1)$  และฟังก์ชันสหสัมพันธ์ร่วมในตนเองเท่ากับ

$$\rho_k = \begin{cases} \frac{\theta_1}{1+\theta_1^2}, & k = 1 \\ 0, & k > 1 \end{cases} \tag{3.42}$$

จะเห็นได้ว่า  $y_t$  มีสหสัมพันธ์กับ  $y_{t-1}$  แต่ไม่สัมพันธ์กับ  $y_{t-2}, \dots$  ซึ่งแตกต่างจาก  $AR(1)$  รูปที่ 3.7 และ 3.8 แสดงอนุกรมเวลา  $y_t$  และ ACF กรณีที่  $\theta = 0.5$  และ  $\theta = -0.5$  ตามลำดับ



รูปที่ 3.7: การจำลองข้อมูลกระบวนการ  $MA(1)$  ที่มีค่าสัมประสิทธิ์  $\theta = 0.5$  และกลุ่มตัวอย่าง 500 หน่วย



รูปที่ 3.8: การจำลองข้อมูลกระบวนการ  $MA(1)$  ที่มีค่าสัมประสิทธิ์  $\theta = -0.5$  และกลุ่มตัวอย่าง 500 หน่วย

เราจะเห็นได้ว่าอนุกรมเวลา  $y_t$  ที่เป็นกระบวนการมูฟวิ้งเอเวอเรจจะเป็นอนุกรมเวลาคงที่เสมอ เนื่องจาก

กระบวนการดังกล่าวเป็นการรวมเชิงเส้นตรง (linear combination) ของอนุกรมเวลาไวท์นอยซ์เข้าด้วยกัน ซึ่งอนุกรมเวลาไวท์นอยซ์จะมีค่าโมเมนต์ที่หนึ่งและสองที่ไม่ขึ้นกับเวลา

### กระบวนการที่หาค่าผกผันได้

นอกจากนี้หากพิจารณาค่าสัมประสิทธิ์ของ  $MA(1)$  จะเห็นได้ว่าค่าความแปรปรวนร่วมในตัวของกระบวนการ  $MA(1)$  ที่มีค่า  $\theta_1 = 5$  และ  $\theta_1 = 1/5$  จะมีค่าเท่ากัน นอกจากนี้ฟังก์ชันสหสัมพันธ์ในตัวของกระบวนการ  $MA(1)$  สองกระบวนการต่อไปนี้มีลักษณะที่เหมือนกัน

$$x_t = w_t + \frac{1}{5}w_{t-1}, \quad w_t \sim iidN(0, 25)$$

และ

$$y_t = v_t + 5v_{t-1}, \quad v_t \sim iidN(0, 1)$$

เมื่อเราสังเกตเห็นเพียงแต่คุณลักษณะของอนุกรมเวลา  $x_t$  หรือ  $y_t$  โดยที่ไม่ทราบอนุกรมของช็อก  $w_t$  หรือ  $v_t$  เราต้องเลือกว่าจะใช้แบบจำลองไหน ซึ่งเราจะเลือกแบบจำลองที่สามารถเขียนแบบจำลองในรูปของออโตรีเกรสซีฟที่อันดับอนันต์ (infinite AR representation) โดยที่อนุกรมที่มีลักษณะดังกล่าวเราจะเรียกว่ากระบวนการที่หาค่าผกผันได้ (invertible) ยกตัวอย่างเช่น  $y_t = (1 + \theta_1 L)\varepsilon_t$  เราสามารถเขียนแบบจำลองดังกล่าวในรูปต่อไปนี้

$$\begin{aligned}(1 + \theta_1 L)^{-1}y_t &= \varepsilon_t \\(1 + (-\theta_1 L) + (-\theta_1 L)^2 + (-\theta_1 L)^3 + \dots)y_t &= \varepsilon_t \\y_t - \theta_1 y_{t-1} + \theta_1^2 y_{t-2} - \theta_1^3 y_{t-3} + \dots &= \varepsilon_t \\y_t &= \varepsilon_t + \theta_1 y_{t-1} - \theta_1^2 y_{t-2} + \theta_1^3 y_{t-3} - \dots\end{aligned}\tag{3.43}$$

ซึ่งสมการ 3.43 คือรูปแบบออโตรีเกรสซีฟที่มีอันดับเป็นอนันต์ของ  $y_t \sim MA(1)$  ซึ่งจะเป็นอนุกรมคงที่หาก  $|\theta_1| < 1$  ดังนั้น เงื่อนไขที่กระบวนการ  $MA(1)$  จะเป็นกระบวนการที่หาค่าผกผันได้ คือ  $|\theta_1| < 1$

เราสามารถเขียนเงื่อนไขของกระบวนการที่หาค่าผกผันได้ด้วยการเขียนกระบวนการ  $MA(1)$  ในรูปสมการพหุนาม

$$y_t - \mu = (1 + \theta_1 L)\varepsilon_t$$

โดยที่สมการช่วยคือ  $(1 + \theta_1 m) = 0$  ดังนั้นรากของสมการพหุนามมูฟวิ่งเอเวอเรจคือ  $m = \frac{-1}{\theta_1}$  เมื่อพิจารณารากของสมการพหุนาม  $|m| = \left|\frac{-1}{\theta_1}\right| = \frac{1}{|\theta_1|} > 1$  จะได้ว่าค่าสัมบูรณ์ของรากของสมการพหุนามมูฟวิ่งเอเวอเรจจะต้องมีค่ามากกว่า 1

### 3.2.2 แบบจำลองมูฟวิ่งเอเวอเรจที่อันดับสอง (MA(2))

กำหนดให้  $y_t$  เป็นกระบวนการมูฟวิ่งเอเวอเรจที่อันดับสอง MA(2) ซึ่งสามารถแสดงได้ด้วยสมการ

$$y_t - \mu = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} \quad (3.44)$$

ซึ่งรูปแบบดังกล่าวจะมีค่าเฉลี่ยเท่ากับ  $\mu$

$$\begin{aligned} E(y_t) - \mu &= \underbrace{E(\varepsilon_t)}_{=0} + \theta_1 \underbrace{E(\varepsilon_{t-1})}_{=0} + \theta_2 \underbrace{E(\varepsilon_{t-2})}_{=0} \\ E(y_t) &= \mu \end{aligned}$$

ค่าความแปรปรวนของ  $y_t$  สามารถหาได้โดย

$$\begin{aligned} Var(y_t) &= E(y_t - \mu)^2 = E[(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2})(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2})] \\ &= E[\varepsilon_t^2 + \theta_1^2 \varepsilon_{t-1}^2 + \theta_2^2 \varepsilon_{t-2}^2 + \text{cross term}] \\ &= \underbrace{E(\varepsilon_t^2)}_{=\sigma_\varepsilon^2} + \theta_1^2 \underbrace{E(\varepsilon_{t-1}^2)}_{=\sigma_\varepsilon^2} + \theta_2^2 \underbrace{E(\varepsilon_{t-2}^2)}_{=\sigma_\varepsilon^2} + \underbrace{E(\text{cross term})}_{=0} \\ &= (1 + \theta_1^2 + \theta_2^2) \sigma_\varepsilon^2 \equiv \gamma_0 \end{aligned} \quad (3.45)$$

ต่อไปเราจะพิจารณาค่าความแปรปรวนร่วมในตัวย้อนไปหนึ่งคาบ

$$\begin{aligned} \gamma_1 &= Cov(y_t, y_{t-1}) = E[(y_t - \mu)(y_{t-1} - \mu)] \\ &= E[(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2})(\varepsilon_{t-1} + \theta_1 \varepsilon_{t-2} + \theta_2 \varepsilon_{t-3})] \\ &= E[\theta_1 \varepsilon_{t-1}^2 + \theta_2 \theta_1 \varepsilon_{t-2}^2 + \text{cross term}] \\ &= \theta_1 \underbrace{E(\varepsilon_{t-1}^2)}_{=\sigma_\varepsilon^2} + \theta_2 \theta_1 \underbrace{E(\varepsilon_{t-2}^2)}_{=\sigma_\varepsilon^2} + \underbrace{E(\text{cross term})}_{=0} \\ &= (\theta_1 + \theta_2 \theta_1) \sigma_\varepsilon^2 \end{aligned} \quad (3.46)$$

ค่าความแปรปรวนร่วมในตัวย้อนไปสองคาบ

$$\begin{aligned}
 \gamma_2 &= Cov(y_t, y_{t-2}) = E[(y_t - \mu)(y_{t-2} - \mu)] \\
 &= E[(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2})(\varepsilon_{t-2} + \theta_1 \varepsilon_{t-3} + \theta_2 \varepsilon_{t-4})] \\
 &= E[\theta_2 \varepsilon_{t-2}^2 + \text{cross term}] \\
 &= \underbrace{\theta_2 E(\varepsilon_{t-2}^2)}_{=\sigma_\varepsilon^2} + \underbrace{E(\text{cross term})}_{=0} \\
 &= \theta_2 \sigma_\varepsilon^2
 \end{aligned} \tag{3.47}$$

และค่าความแปรปรวนร่วมในตัวย้อนไปสามคาบ

$$\begin{aligned}
 \gamma_3 &= Cov(y_t, y_{t-3}) = E[(y_t - \mu)(y_{t-3} - \mu)] \\
 &= E[(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2})(\varepsilon_{t-3} + \theta_1 \varepsilon_{t-4} + \theta_2 \varepsilon_{t-5})] \\
 &= E[\text{cross term}] = 0
 \end{aligned} \tag{3.48}$$

เมื่อพิจารณาค่าสหสัมพันธ์ในตัวของอนุกรมเวลา  $MA(2)$  จะได้ว่า

$$\begin{aligned}
 \rho_0 &= \frac{\gamma_0}{\gamma_0} = 1 \\
 \rho_1 &= \frac{\gamma_1}{\gamma_0} = \frac{(\theta_1 + \theta_2 \theta_1)}{(1 + \theta_1^2 + \theta_2^2)} \\
 \rho_2 &= \frac{\gamma_2}{\gamma_0} = \frac{\theta_2}{(1 + \theta_1^2 + \theta_2^2)} \\
 \rho_3 &= \frac{\gamma_3}{\gamma_0} = 0 \\
 \rho_j &= \frac{\gamma_j}{\gamma_0} = 0
 \end{aligned}$$

กรณีที่  $j > 2$  จากสมการข้างบนจะเห็นว่าเอซีเอฟของ  $MA(2)$  จะมีค่ามากกว่าศูนย์ในกรณีที่  $j = 1$  และ  $j = 2$  และจะลดลงเท่ากับศูนย์ในกรณีที่  $j > 2$

### 3.2.3 แบบจำลองมูฟวิ่งเอเวอเรจที่อันดับ $q$ ( $MA(q)$ )

แบบจำลองมูฟวิ่งเอเวอเรจที่อันดับ  $q$  ( $MA(q)$ ) สามารถเขียนในรูปสมการดังนี้

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}, \quad \varepsilon_t \sim WN(0, \sigma^2) \tag{3.49}$$

อนุกรมเวลามูฟวิงเอเวอเรจที่อันดับ  $q$  เป็นอนุกรมเวลาคงที่และเออร์กอดิก<sup>1</sup> ถ้าค่า  $\theta_1, \dots, \theta_q$  มีค่าจำกัด และแบบจำลองสามารถหาตัวผกผันได้ถ้าค่ารากของพหุนามมูฟวิงเอเวอเรจต่อไปนี้

$$\theta(m) = 1 + \theta_1 m + \dots + \theta_q m^{t-q} = 0 \quad (3.50)$$

มีค่าสัมบูรณ์(หรือค่าโมดูลัส)ของรากของพหุนามมากกว่า 1 และเราสามารถสรุปโมเมนต์ของกระบวนการ  $MA(q)$  ได้ดังนี้

$$\begin{aligned} E(y_t) &= \mu \\ \gamma_0 &= \sigma_\varepsilon^2(1 + \theta_1^2 + \dots + \theta_q^2) \\ \gamma_j &= \begin{cases} (\theta_j + \theta_{j+1}\theta_1 + \theta_{j+2}\theta_2 + \dots + \theta_q\theta_{q-j})\sigma_\varepsilon^2, & j = 1, 2, \dots, q \\ 0 & j > q \end{cases} \end{aligned}$$

และค่าสหสัมพันธ์ในตัวเองจะเท่ากับ

$$\rho_j = \frac{\gamma_j}{\gamma_0} = \frac{(\theta_j + \theta_{j+1}\theta_1 + \theta_{j+2}\theta_2 + \dots + \theta_q\theta_{q-j})}{(1 + \theta_1^2 + \dots + \theta_q^2)}$$

กรณีที่  $j = 1, 2, \dots, q$  และ  $\rho_j = 0$  กรณีที่  $j > q$  จะเห็นได้ว่าเอซีเอฟของ  $MA(q)$  จะมีค่าไม่เท่ากับศูนย์จะกระทั่งช่วงล่า  $q$  และจะเท่ากับศูนย์หลังจากนั้น ในขณะที่พีเอซีเอฟจะมีค้อยลดลงไป

### 3.2.4 การประมาณค่าแบบจำลองมูฟวิงเอเวอเรจ

การประมาณค่าภาวะนั้น่าจะเป็นสูงสุดหรือเอ็มแอลอี เป็นวิธีการทั่วไปที่ใช้ในการประมาณค่าแบบจำลอง  $MA(q)$  เนื่องจากเราไม่สามารถสังเกตค่าช็อกในแต่ละคาบได้

วิธีการประมาณค่าภาวะนั้น่าจะเป็นแบบมีเงื่อนไขสูงสุด

ในหัวข้อนี้จะนำเสนอวิธีการประมาณค่าพารามิเตอร์ในแบบจำลอง  $MA(1)$  ซึ่งสามารถเขียนได้ดังนี้

$$y_t = \mu + \varepsilon_t + \theta\varepsilon_{t-1}$$

โดยที่  $\varepsilon_t \sim iidN(0, \sigma_\varepsilon^2)$  ในกรณีที่เราระประมาณค่าด้วยค่าภาวะนั้น่าจะเป็นแบบมีเงื่อนไขสูงสุด เราจะสมมติให้  $\varepsilon_0 = 0$  ดังนั้น  $y_1 = \mu + \varepsilon_1$

$$y_1 | \varepsilon_0 = 0 \sim N(\mu, \sigma_\varepsilon^2)$$

<sup>1</sup>เนื่องจากแนวคิดเกี่ยวกับอนุกรมเวลาคงที่มีได้อธิบายความสัมพันธ์ระหว่างข้อมูลในช่วงเวลาที่แตกต่างกัน อนุกรมเวลาจะมีคุณสมบัติเป็นเออร์กอดิก ถ้าช่วงของข้อมูลสองช่วงเวลายังมีความสัมพันธ์ระหว่างกันที่ลดลงเมื่อช่วงเวลาที่สองอยู่ห่างกันมากขึ้น

และเมื่อสามารถสังเกตค่า  $y_1$  เราก็สามารถหาค่า  $\varepsilon_1 = y_1 - \mu$  และจากข้อมูลในคาบที่ 1 จะได้ว่า

$$y_2|y_1 = \mu + \varepsilon_2 + \theta\varepsilon_1$$

และเราสามารถหาค่า  $\varepsilon_2 = y_2 - \mu - \theta\varepsilon_1$  และได้ฟังก์ชันความน่าจะเป็น

$$f_{y_2|y_1} = \frac{1}{\sqrt{2\pi\sigma_\varepsilon^2}} \exp\left[\frac{-(y_2 - \mu - \theta\varepsilon_1)^2}{2\sigma_\varepsilon^2}\right]$$

และหากใช้กระบวนการเดียวกันไปเรื่อย เราจะสามารถหาค่า  $\varepsilon_t = y_t - \mu - \theta\varepsilon_{t-1}$  และสร้างฟังก์ชันภาวะน่าจะเป็นแบบมีเงื่อนไข (conditional likelihood function) ได้

$$\begin{aligned} L(\mu, \theta, \sigma_\varepsilon^2) &= \prod_{t=2}^T f_{y_t|y_{t-1}} \\ &= (2\pi\sigma_\varepsilon^2)^{-(T-2)/2} \exp\left[\frac{\sum_{t=2}^T \overbrace{-(y_t - \mu - \theta\varepsilon_{t-1})^2}^{\varepsilon_t^2}}{2\sigma_\varepsilon^2}\right] \end{aligned} \quad (3.51)$$

สมการ 3.51 เราไม่สามารถหาตัวประมาณค่าเป็นสูตรที่ชัดเจนได้ด้วยการวิเคราะห์หอนุพันธ์เช่นในกรณีแบบจำลองออโตรีเกรสซีฟ ในกรณีนี้เราจำเป็นต้องใช้วิธีการทางตัวเลขด้วยคอมพิวเตอร์เพื่อหาค่า  $\hat{\theta}$  ที่ทำให้  $L(\mu, \theta, \sigma_\varepsilon^2)$  มีค่าสูงที่สุด

### วิธีการประมาณค่าความควรจะเป็นแบบแม่นยำตรงสูงสุด


โดยทั่วไปแล้วเราใช้วิธีการสองวิธีการในการคำนวณฟังก์ชันค่าความควรจะเป็นแบบแม่นยำตรง (Exact likelihood function) สำหรับ MA(1) คือ Kalman filter และการใช้ triangular factorization ของ var-cov matrix ซึ่งผู้ที่สนใจสามารถหาอ่านได้จาก Hamilton 1994

**ตัวอย่างที่ 3.6** (การสร้างแบบจำลองสำหรับผลได้ตอบแทนรายเดือนจาก SET โดย MA(q)) ในตัวอย่างนี้เราจะพิจารณาผลได้ตอบแทนรายเดือนของการลงทุนในตลาดหลักทรัพย์แห่งประเทศไทย โดยใช้ข้อมูลราคาปิดรายเดือนตั้งแต่ เมษายน 2518 ถึงเดือนพฤศจิกายน 2555 (ข้อมูลจาก [www.set.or.th/th/market/market\\_statistics.html](http://www.set.or.th/th/market/market_statistics.html)) ซึ่งอยู่ในไฟล์ mset.csv โดยเป็นข้อมูลคอลัมน์เดียว เราสามารถนำเข้าข้อมูลและคำนวณผลได้ตอบแทนได้ด้วยคำสั่งต่อไปนี้

```
1 > mset <- read.csv("https://raw.githubusercontent.com/chaleampong/EC435/master/mset.csv", header = FALSE)
2 > head(mset)
3 > ret <- diff(log(mset$V1))
4 > ts.plot(ret)
```

หลังจากนั้นเราจะพิจารณาแบบจำลองที่เหมาะสมโดยการพิจารณาเอซีเอฟและพีเอซีเอฟจากตัวอย่าง

```
1 > acf(ret)
2 > pacf(ret)
```



รูปที่ 3.9: เอซีเอฟและพีเอซีเอฟของผลได้ตอบแทนรายเดือนจาก SET

จากรูป 3.9 จะเห็นได้ว่าเอซีเอฟมีค่าลดลงจนมีค่าไม่แตกต่างจากศูนย์ที่ค่าล่าเท่ากับ 3 ดังนั้นแบบจำลองที่เหมาะสมน่าจะเป็น  $MA(2)$  ซึ่งประมาณค่าได้ด้วยคำสั่ง `arima` โดยกำหนดอันดับเป็น `c(0, 0, 2)`

```
1 > m1<-arima(ret, order=c(0,0,2))
2 > m1
3 Call:
4 arima(x = ret, order = c(0, 0, 2))
5
6 Coefficients:
7      ma1      ma2  intercept
8      0.0886  0.1001      0.0057
9 s.e.    0.0469  0.0487      0.0046
10
11 sigma^2 estimated as 0.006795: log likelihood = 485.64, aic = -963.28
```

จากผลการประมาณค่าเราได้ค่าสัมประสิทธิ์ดังนี้  $\theta_1 = 0.0886, \theta_2 = 0.1001$  และ  $\mu = 0.0057$  และมีค่าความคาดเคลื่อนมาตรฐาน (s.e.) อยู่ในบรรทัด s.e.

เราสามารถพิจารณาความเหมาะสมของแบบจำลอง `m1` ได้ด้วยการทดสอบ L-B สำหรับเรซิดิวดังกล่าวต่อไปนี้

```
1 > Box.test(m1$residuals, lag=12, type="Ljung")
2      Box-Ljung test
3 data:  m1$residuals
4 X-squared = 13.6075, df = 12, p-value = 0.3265
5 > pv=1-pchisq(13.6075,12-2)
6 > pv
7 [1] 0.1916591
```

เราได้ค่า  $Q(12)$  เท่ากับ 13.6075 ซึ่งสามารถหาค่าพิที่มีองศาอิสระเท่ากับ  $(m - g) = 12 - 2$  โดยที่  $g$  คือจำนวนอันดับของ  $MA$  จะได้ค่าพิเท่ากับ 0.192 แสดงว่าเรซิดิวไม่มีความสัมพันธ์ระหว่างกัน สรุป



ว่าแบบจำลองของเราเพียงพอที่ใช้อธิบายผลได้ตอบแทนรายเดือนของการลงทุนในตลาดหลักทรัพย์แห่งประเทศไทย

### 3.2.5 การพยากรณ์จากแบบจำลองมูฟวิ่งเอเวอเรจ

ในแบบจำลอง  $MA(q)$  ความจำของข้อมูลค่อนข้างจำกัดซึ่งเราสามารถสังเกตเห็นได้จากค่าพยากรณ์ ตัวอย่างเช่นหากเราพิจารณาแบบจำลอง  $MA(1)$ :  $y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}$  โดยเราอยู่ ณ คาบเวลา  $h$

#### การพยากรณ์ไปข้างหน้า 1 คาบ

ในกรณีนี้เราพิจารณา  $y_{h+1} = \mu + \varepsilon_{h+1} + \theta_1 \varepsilon_h$  ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข (conditional expectation)

$$\hat{y}_h(1) = E(y_{h+1}|F_h) = \mu + \underbrace{E(\varepsilon_{h+1}|F_h)}_{=0} + \theta_1 \varepsilon_h = \mu + \theta_1 \varepsilon_h \quad (3.52)$$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ

$$e_h(1) = y_{h+1} - \hat{y}_h(1) = \varepsilon_{h+1}$$

และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าหนึ่งคาบเท่ากับ

$$Var(e_h(1)) = Var(\varepsilon_{h+1}) = \sigma^2$$

ในการพยากรณ์จากแบบจำลอง  $MA(1)$  เราต้องใช้ค่าช็อกซึ่งเราไม่สามารถสังเกตได้ ในทางปฏิบัติเราสามารถคำนวณค่า  $\varepsilon_h$  ได้สองวิธีคือ

- สมมติให้  $\varepsilon_0 = 0$  แล้วแทนค่าใน  $\varepsilon_1 = y_1 - \mu$  และ  $\varepsilon_t = y_t - \mu - \theta_1 \varepsilon_{t-1}$  สำหรับ  $2 \leq t \leq h$
- หรือใช้ค่า  $\hat{\varepsilon}_h$  ที่เป็นค่าเรชิดิวจากการประมาณค่า  $MA(1)$

#### การพยากรณ์ไปข้างหน้า 2 คาบ

พิจารณา  $y_{h+2} = \mu + \varepsilon_{h+2} + \theta_1 \varepsilon_{h+1}$  ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข

$$\hat{y}_h(2) = E(y_{h+2}|F_h) = \mu + \underbrace{E(\varepsilon_{h+2}|F_h)}_{=0} + \theta_1 \underbrace{\varepsilon_{h+1}}_{=0} = \mu \quad (3.53)$$

ซึ่งเท่ากับค่าเฉลี่ยของอนุกรม และค่าผิดพลาดจากการพยากรณ์เท่ากับ

$$e_h(2) = y_{h+2} - \hat{y}_h(2) = \varepsilon_{h+2} + \theta_1 \varepsilon_{h+1}$$

และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าสองคาบเท่ากับ

$$\text{Var}(e_h(2)) = \text{Var}(\varepsilon_{h+2} + \theta_1 \varepsilon_{h+1}) = (1 + \theta_1^2) \sigma^2$$

ซึ่งเราสามารถเขียนสรุปค่าพยากรณ์สำหรับแบบจำลอง  $MA(1)$  ได้ดังนี้

$$\hat{y}_h(k) = \begin{cases} \mu + \theta_1 \varepsilon_k, & k = 1 \\ \mu, & k > 1 \end{cases}$$

คุณสมบัติดังกล่าวสามารถขยายผลไปยัง  $MA(q)$  ใด ๆ ว่าค่าพยากรณ์ไปข้างหน้า  $k$  คาบจะเท่ากับค่าเฉลี่ย หากคาบที่พยากรณ์ไปข้างหน้ามีค่าสูงกว่าอันดับของ  $MA$  ( $k > q$ )

### 3.3 แบบจำลองออโตรีเกรสซีฟมูฟวี่งเอเวอเรจ

จากแบบจำลองออโตรีเกรสซีฟที่ตัวแปร  $y_t$  ขึ้นอยู่กับตัวเองในอดีต กับแบบจำลองมูฟวี่งเอเวอเรจที่ตัวแปรขึ้นอยู่กับข้อผิดพลาด เราสามารถผนวกแบบจำลองที่มีทั้งส่วนประกอบของออโตรีเกรสซีฟและมูฟวี่งเอเวอเรจ ซึ่งหาก  $y_t$  เป็นกระบวนการที่เรียกว่าแบบจำลองออโตรีเกรสซีฟมูฟวี่งเอเวอเรจอันดับ  $(p, q)$  (Autoregressive Moving Average  $(p, q)$ ) หรือเรียกย่อ ๆ ว่า อารมาที่อันดับพีและคิว ( $ARMA(p, q)$ ) ถ้า  $y_t$  มีค่าเฉลี่ยไม่เท่ากับศูนย์ เราสามารถอธิบาย  $y_t$  ได้ด้วย

$$y_t = \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} \quad (3.54)$$

หากเรากำหนดให้  $\alpha = \mu(1 - \phi_1 - \dots - \phi_p)$  และสามารถเขียนแบบจำลองสำหรับ  $y_t$  ได้เป็น

$$y_t = \alpha + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} \quad (3.55)$$

**บทนิยาม 3.2** เราสามารถเขียนแบบจำลองอารมาพีและคิวได้ในรูปพหุนามออโตรีเกรสซีฟ และมูฟวี่งเอเวอเรจได้ดังนี้

$$\phi(L)y_t = \theta(L)\varepsilon_t$$

โดยที่  $\phi(L) = 1 - \phi_1 L - \dots - \phi_p L^p$  และ  $\theta(L) = 1 + \theta_1 L + \dots + \theta_q L^q$

ในขั้นตอนต่อไป เราต้องการทราบคุณลักษณะของอนุกรมเวลาที่เป็นไปตามอารมา และเพื่อความง่ายเรา

พิจารณาคุณสมบัติของแบบจำลองอาร์มา (1,1) เพื่อให้เราเข้าใจความแตกต่างระหว่างแบบจำลองทั้งสาม  $ARMA(1,1)$

### 3.3.1 แบบจำลองอาร์มาที่อันดับ (1,1) ( $ARMA(1,1)$ )

กำหนดให้  $y_t$  เป็นกระบวนการ  $ARMA(1,1)$  ซึ่งสามารถอธิบายได้ด้วยสมการข้างล่าง

$$y_t = \phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1} \quad (3.56)$$

โดยที่  $\varepsilon_t \sim iidN(0, \sigma^2)$  เพื่อสร้างสมการ Yule-Walker เราใช้ความสัมพันธ์ต่อไปนี้

$$\begin{aligned} E(\varepsilon_t y_t) &= E[\varepsilon_t (\phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1})] \\ &= \underbrace{\phi E(\varepsilon_t y_{t-1})}_{=0} + \underbrace{E(\varepsilon_t^2)}_{=\sigma^2} + \underbrace{\theta E(\varepsilon_t \varepsilon_{t-1})}_{=0} = \sigma^2 \end{aligned}$$

และ

$$\begin{aligned} E(\varepsilon_{t-1} y_t) &= E[\varepsilon_{t-1} (\phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1})] \\ &= \underbrace{\phi E(\varepsilon_{t-1} y_{t-1})}_{=\sigma^2} + \underbrace{E(\varepsilon_{t-1} \varepsilon_t)}_{=0} + \underbrace{\theta E(\varepsilon_{t-1}^2)}_{=\sigma^2} \\ &= \phi \sigma^2 + \theta \sigma^2 = (\phi + \theta) \sigma^2 \end{aligned}$$

หากเราคูณสมการ 3.56 ทั้งสองข้างด้วย  $y_{t-k}$  กรณีที่  $k = 0, 1, \dots, j, \dots$  และใส่ค่าคาดหวัง (take expectation) จะได้

$$\begin{aligned} \gamma_0 = E(y_t y_t) &= E((\phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}) y_t) \\ &= \underbrace{\phi E(y_t y_{t-1})}_{=\gamma_1} + \underbrace{E(y_t \varepsilon_t)}_{=\sigma^2} + \underbrace{\theta E(y_t \varepsilon_{t-1})}_{=(\phi+\theta)\sigma^2} \\ &= \phi \gamma_1 + [1 + \theta(\phi + \theta)] \sigma^2 \end{aligned} \quad (3.57)$$

$$\begin{aligned} \gamma_1 = E(y_t y_{t-1}) &= E((\phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}) y_{t-1}) \\ &= \underbrace{\phi E(y_{t-1} y_{t-1})}_{=\gamma_0} + \underbrace{E(y_{t-1} \varepsilon_t)}_{=0} + \underbrace{\theta E(y_{t-1} \varepsilon_{t-1})}_{=\sigma^2} \\ &= \phi \gamma_0 + \theta \sigma^2 \end{aligned} \quad (3.58)$$

$$\begin{aligned}\gamma_j &= E(y_t y_{t-j}) = E((\phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}) y_{t-j}) \\ &= \underbrace{\phi E(y_{t-1} y_{t-j})}_{=\gamma_{j-1}} + \underbrace{E(\varepsilon_t y_{t-j})}_{=0} + \underbrace{\theta E(\varepsilon_{t-1} y_{t-j})}_{=0}\end{aligned}\quad (3.59)$$

$$= \phi \gamma_{j-1} \quad (3.60)$$

กรณีที่  $j \geq 2$  จากสมการ 3.57 และ 3.58 เราจะได้

$$Var(y_t) = \gamma_0 = \frac{(1 + 2\phi\theta + \theta^2)}{1 - \phi^2} \sigma^2$$

และจากสมการ 3.60 เราสามารถหาค่าสหสัมพันธ์ในตัวเอง ณ ค่า  $j$  ใดๆ ที่  $j \geq 2$  ได้

$$\rho_j = \phi \rho_{j-1}$$

กรณีที่  $j \geq 2$  จะเห็นได้ว่าเอซีเอฟมีค่าที่ลดลงเรื่อย ๆ แบบฟังก์ชันเลขชี้กำลัง(exponential) นอกจากนี้เราสามารถเขียนแบบจำลอง  $ARMA(1, 1)$  ในรูปของมูฟวิงเอเวอเรจที่มีอันดับเป็นอนันต์ได้ดังนี้

$$y_t = \varepsilon_t + (\phi - \theta) \sum_{j=1}^{\infty} \phi^{j-1} \varepsilon_{t-j} \quad (3.61)$$

หรือ  $\psi_j = (\phi - \theta)\phi^{j-1}$  จะเห็นได้ว่าเงื่อนไขที่จะทำให้กระบวนการนี้เป็นกระบวนการคงที่คือ  $|\phi| < 1$

กระบวนการ  $ARMA(p, q)$  จะคงที่และเออร์годิก ถ้าค่าสัมบูรณ์ของค่ารากของพหุนามออโตรีเกรสซีฟ  $\phi(m) = 0$  มีค่ามากกว่าหนึ่ง (หรือมอดุลัสมีค่ามากกว่าหนึ่งในกรณีจำนวนเชิงซ้อน) และสามารถหาค่าผกผันได้ถ้ารากของพหุนามมูฟวิงเอเวอเรจ  $\theta(m) = 0$  มีค่ามากกว่าหนึ่ง (หรือมอดุลัสมีค่ามากกว่าหนึ่งในกรณีจำนวนเชิงซ้อน) และพหุนามออโตรีเกรสซีฟและมูฟวิงเอเวอเรจไม่มีตัวประกอบร่วม กระบวนการ  $ARMA(p, q)$  ที่คงที่จะมีค่าเฉลี่ยเท่ากับ

$$\mu = \frac{c}{1 - \phi_1 - \dots - \phi_p}$$

และค่าความแปรปรวนร่วมในตัวเอง ค่าสหสัมพันธ์ในตัวเองและตัวถ่วงน้ำหนักการตอบสนองแรงกระตุ้นสามารถเขียนในลักษณะเวียนเกิดได้ดังนี้


$$\gamma_j = \phi_1 \gamma_{j-1} + \phi_2 \gamma_{j-2} + \dots + \phi_p \gamma_{j-p}$$

$$\rho_j = \phi_1 \rho_{j-1} + \phi_2 \rho_{j-2} + \dots + \phi_p \rho_{j-p}$$

$$\psi_j = \phi_1 \psi_{j-1} + \phi_2 \psi_{j-2} + \dots + \phi_p \psi_{j-p}$$

โดยที่รูปทั่วไปของเอซีเอฟของกระบวนการ  $ARMA(p, q)$  ค่อนข้างยุ่งยาก โดยสรุปแล้วทั้งเอซีเอฟและพีเอซี

รูปที่ 3.10: ACF และ PACF ของอนุกรมเวลา ARMA(1,1)



เอฟจะค่อยๆลดลงเรื่อยแบบฟังก์ชันเลขชี้กำลัง (exponential) ดังตัวอย่างในรูปต่อไปนี้

ตัวอย่าง ความฟุ่มเฟือยของพารามิเตอร์ สมมติว่าเรากำลังพิจารณากระบวนการไวท์นอยซ์  $y_t = \varepsilon_t$  แล้วเราคูณทั้งสองและขยับไปข้างหลังหนึ่งคาบ  $0.5y_{t-1} = 0.5\varepsilon_{t-1}$  หลังจากนั้น เรานำสมการดังกล่าวไปลบจากสมการดั้งเดิมจะได้

$$y_t - 0.5y_{t-1} = \varepsilon_t - 0.5\varepsilon_{t-1} \quad (3.62)$$

จะมีลักษณะเหมือนกับแบบจำลอง  $ARMA(1,1)$  แต่  $y_t$  ก็ยังเป็นไวท์นอยซ์ การใช้พารามิเตอร์อย่างฟุ่มเฟือยหรือใส่พารามิเตอร์มากเกินไป จะทำให้เราเข้าใจผิดว่ากระบวนการมีความสัมพันธ์ระหว่างกัน อย่างไรก็ตามปัญหานี้สามารถหลีกเลี่ยงได้ด้วยการพิจารณาสมการในรูปแบบพหุนามและตัวคูณร่วมของพหุนาม ตัวอย่างเช่นสมการ (3.62) สามารถเขียนได้เป็น

$$(1 - 0.5L)y_t = (1 - 0.5L)\varepsilon_t$$

ซึ่งสามารถเปลี่ยนกลับไปเป็นกระบวนการไวท์นอยซ์ด้วยการคูณทั้งสองข้างด้วย  $(1 - 0.5L)^{-1}$

### 3.3.2 การประมาณค่าสมการแบบจำลองอาร์มา

เราสามารถประมาณค่าแบบจำลอง  $ARMA(p,q)$  ได้ด้วยวิธีการภาวะน่าจะเป็นสูงสุดหรือเอ็มแอลอี ซึ่งเราสามารถใช้รูปแบบ state-space ในการสร้างฟังก์ชันล็อกของภาวะน่าจะเป็น อย่างไรก็ตามฟังก์ชันดังกล่าวที่แน่นอน (exact log-likelihood) นั้นมีรูปแบบที่ค่อนข้างซับซ้อน นอกจากนี้จุดเริ่มต้นของข้อมูลในกรณี exact likelihood จะใช้คุณสมบัติของการแจกแจงที่นิ่งเพื่อสร้างฟังก์ชันค่าควรจะเป็นของค่า  $y_t$   $p$  ค่าแรก และ  $\varepsilon_t$   $q$  ค่าแรก ในขณะที่ conditional likelihood จะสมมติให้  $y_t$   $p$  ค่าแรก และ  $\varepsilon_t$   $q$  ค่าแรกเท่ากับศูนย์ ตัวประมาณค่า Exact MLE จะเกิดจากการหาค่าสูงสุดจาก exact log-likelihood และ Conditional MLE จะเกิดจากการหาค่าสูงสุดจาก conditional log-likelihood โดยในกรณีที่จำนวนตัวอย่างมีจำนวนเข้าใกล้อนันต์จะมีค่าใกล้เคียงกัน แต่ค่าประมาณทั้งสองวิธีจะแตกต่างกันในกรณีตัวอย่างมีจำนวนน้อย

หลังจากที่เราได้ค่าประมาณแล้วเราสามารถทดสอบความเพียงพอของแบบจำลองได้เช่นเดียวกับในกรณีของแบบจำลอง  $AR$  และ  $MA$  โดยที่ตัวสถิติ  $Q(m) \sim \chi^2_{m-p-q}$  และเราจะปฏิเสธสมมติฐานหลักถ้า  $Q(m)$  มีค่ามากกว่าควอนไทล์ที่  $(1 - \alpha)$  ของ  $\chi^2_{m-p-q}$

### 3.3.3 เกณฑ์การเลือกแบบจำลอง

ก่อนที่จะเราจะประมาณค่าแบบจำลอง  $ARMA(p, q)$  สำหรับอนุกรมเวลา  $y_t$  ใดๆ เราจะต้องระบุลำดับของออโตรีเกรสซีฟ ( $p$ ) และมูฟวี่งเอเวอเรจ ( $q$ ) เสียก่อน โดยที่เราสามารถใช้การสังเกตฟังก์ชันเอซีเอฟของตัวอย่าง ในกรณีของแบบจำลองมูฟวี่งเอเวอเรจหรือพีเอซีเอฟของตัวอย่าง ในกรณีของแบบจำลองออโตรีเกรสซีฟ นอกจากนี้ เราสามารถจะใช้เกณฑ์การเลือกแบบจำลอง (model selection) ในการเลือกแบบจำลองที่

ตารางที่ 3.2: สัญลักษณ์ของเอซีเอฟและพีเอซีเอฟสำหรับแบบจำลองอาร์มา

	$AR(p)$	$MA(q)$	$ARMA(p, q)$
เอซีเอฟ	ค่อยๆลดลง	ค่าเท่ากับศูนย์หลังจากช่วงล่าที่ $q$	ค่อยๆลดลง
พีเอซีเอฟ	เท่ากับศูนย์หลังจากช่วงล่าที่ $p$	ค่อยๆลดลง	ค่อยๆลดลง

เหมาะสม ขั้นตอนในการเลือกแบบจำลอง ได้แก่การประมาณค่าแบบจำลองอาร์มา ( $ARMA(p, q)$ ) สำหรับค่าอันดับ  $p$  และ  $q$  ต่าง ๆ โดยที่เราอาจจะกำหนดอันดับสูงสุดที่เราจะพิจารณาเช่น  $p_{max}$  และ  $q_{max}$  สุดท้าย เรา จะเลือกค่า  $p$  และ  $q$  ที่ทำให้ค่าเกณฑ์การเลือกต่ำที่สุด โดยที่เกณฑ์การเลือกจะอยู่ในรูปผลรวมของสองส่วนประกอบ

$$MSC(p, q) = \ln(\hat{\sigma}^2(p, q)) + c_T \varphi(p, q) \quad (3.63)$$

ส่วนแรกคือ  $\hat{\sigma}^2(p, q)$  ตัวประมาณค่าภาวน่าจะเป็นสูงสุดของตัวแปรปรวนของข้อผิดพลาด ซึ่งค่าดังกล่าวจะลดลงเมื่อจำนวนพารามิเตอร์มากขึ้น ส่งผลให้แบบจำลองที่มีพารามิเตอร์มากมีค่าดังกล่าวน้อย ในขณะที่ส่วนที่สองจะเป็นส่วนที่ลงโทษแบบจำลองที่มีพารามิเตอร์มาก ซึ่งคำนวณจากผลคูณของค่า  $c_T$  ลำดับที่ขึ้นกับจำนวนตัวอย่าง และ  $\varphi(p, q)$  คือฟังก์ชันเบี้ยปรับ (penalty function) อะกะอิเกะ (Akaike) ได้นำเสนอเกณฑ์สารสนเทศ (information criteria) โดยระบุให้  $c_T = 2/T$  และเรียกว่าเกณฑ์สารสนเทศของอะกะอิเกะ (Akaike Information Criteria) หรือเอไอซี (AIC) ในขณะที่เกณฑ์สารสนเทศที่เป็นที่นิยมอีกสองเกณฑ์คือ เกณฑ์สารสนเทศของเบย์ (Bayesian Information Criteria) หรือบีไอซี (BIC) และเกณฑ์สารสนเทศของฮานันและควินน์ (Hannan-Quinn Information Criteria) หรือเฮควิวไอซี (HQIC) ซึ่งแสดงได้ด้วยสมการดังนี้

$$\begin{aligned} AIC(p, q) &= \ln(\hat{\sigma}^2(p, q)) + \frac{2}{T}(p + q) \\ BIC(p, q) &= \ln(\hat{\sigma}^2(p, q)) + \frac{\ln T}{T}(p + q) \\ HQIC(p, q) &= \ln(\hat{\sigma}^2(p, q)) + \frac{2 \ln(\ln T)}{T}(p + q) \end{aligned}$$


ในทางทฤษฎีเราสามารถพิสูจน์ได้ว่าบีไอซีและเฮชคิวไอซีมีคุณสมบัติคล่องจอง (consisten) หรือเลือกลำดับที่ใกล้เคียงกับค่าจริงเมื่อกลุ่มตัวอย่างใหญ่ ในขณะที่เอไอซีจะเลือกอันดับที่มากกว่าที่ควรจะเป็น อย่างไรก็ตาม ในตัวอย่างขนาดเล็กเกณฑ์สารสนเทศทั้งสามจะให้ค่าที่ไม่แตกต่างกันนัก

**ตัวอย่างที่ 3.7** การสร้างแบบจำลองสำหรับผลได้ตอบแทนของการซื้อขายเงินตราต่างประเทศโดย ARMA(p,q)

ตัวอย่างนี้เราพิจารณาผลได้ตอบแทนของการซื้อขายเงินตราต่างประเทศโดยคำนวณจากอัตราแลกเปลี่ยนบาทต่อดอลลาร์สหรัฐระหว่างปี 1998 ถึง 2012 ซึ่งอยู่ในไฟล์ thbusd.csv เราสามารถนำเข้าข้อมูลและคำนวณผลได้ตอบแทนได้ดังนี้

```
1 > exc<- read.csv("https://raw.githubusercontent.com/chaleampong/EC435/master/thbusd.csv", header = TRUE)
2 > head(exc)
3   Jul.Day YYYY.MM.DD Wdy THB.USD
4 1 2450816 1/2/1998 Fri 48.023
5 2 2450819 1/5/1998 Mon 50.366
6 3 2450820 1/6/1998 Tue 52.665
7 4 2450821 1/7/1998 Wed 52.203
8 5 2450822 1/8/1998 Thu 53.957
9 6 2450823 1/9/1998 Fri 53.204
10 > excret <- diff(log(exc$THB.USD))
11 > ts.plot(excret, main = "Exchange rate return")
```

รูปที่ 3.11: เอซีเอฟและพีเอซีเอฟของผลได้ตอบแทนรายวันจากการซื้อขายเงินดอลลาร์สหรัฐ



เมื่อพิจารณาเอซีเอฟและพีเอซีเอฟจากรูป 3.11 จะพบว่าแบบจำลองที่เหมาะสมน่าจะเป็น  $ARMA(p,q)$  เนื่องจากฟังก์ชันทั้งสองมีได้ลดลงอย่างมีรูปแบบ ดังนั้นเราจำเป็นต้องเลือกอันดับ  $p$  และ  $q$  ที่เหมาะสมโดยที่เราสามารถเปลี่ยนค่า  $p$  และ  $q$  ในคำสั่ง `arima` ไปเรื่อยๆ  $(0,0), (1,0), (2,0), (0,1), (0,2), (1,1), (2,2), \dots$  และบันทึกค่าเอไอซีหรือบีไอซีที่ได้แล้วเลือกแบบจำลองที่มีค่าเอไอซี หรือบีไอซีน้อยที่สุด

อย่างไรก็ตามชุดคำสั่ง `FORECAST` มีคำสั่ง `auto.arima(series, arguments)` ที่จะทำการทดสอบสร้างแบบจำลองตามค่า  $p$  และ  $q$  สูงสุดที่เรากำหนด แล้วเลือกแบบจำลองตาม

เกณฑ์สารสนเทศที่เราใส่ทางเลือก (arguments) ต่อไปนี้ ค่า  $d = 0$  ,  $D = 0$ ,  $\text{max.p}=6$ ,  $\text{max.q}=6$ ,  $\text{max.order}=[\text{max.p}+\text{max.q}]$ ,  $\text{ic}=\text{c}(\text{"aic"})$  โดยที่เราสามารถเปลี่ยนเป็น  $\text{bic}$ ,  $\text{stepwise}=\text{FALSE}$  แปลว่าให้ทดลองทุกค่าของ  $p$  และ  $q$  ที่น้อยกว่า  $\text{max.p}$  และ  $\text{max.q}$  และ  $\text{trace}=\text{TRUE}$  แปลว่าให้แสดงค่าเกณฑ์สารสนเทศจากการทดลอง

```
1 > library(forecast)
2 > auto.arima(ret, d=0, D=0, max.p=6, max.q=6, ic=c("aic"), stepwise=FALSE,
   trace=TRUE)
3
4 ARIMA(0,0,0) with zero mean      : -27687.05
5 ARIMA(0,0,0) with non-zero mean : -27686.59
6 [omitted]
7 ARIMA(5,0,0) with zero mean      : -27850.55
8 ARIMA(5,0,0) with non-zero mean : -27851.11
9
10 Series: ret
11 ARIMA(4,0,1) with non-zero mean
12
13 Coefficients:
14          ar1      ar2      ar3      ar4
15      -0.5876  -0.0238  -0.0066  -0.0227
16 s.e.    0.2641   0.0196   0.0208   0.0199
17      ma1 intercept
18      0.5981    -1e-04
19 s.e.    0.2636     1e-04
20
21 sigma^2 estimated as 3.432e-05: log likelihood=13849.44
22 AIC=-27684.88   AICc=-27684.85   BIC=-27641.33
```

แบบจำลองที่เราเลือกจากค่าเอไอซีน้อยที่สุดคือแบบจำลอง  $ARMA(4,1)$  ผู้อ่านอาจจะลองใช้เกณฑ์บีไอซีแล้วเปรียบเทียบว่าแบบจำลองที่แนะนำต่างกันหรือไม่

### 3.3.4 การเขียนกระบวนการอาร์มา(ARMA)ในสามรูปแบบ

จากแบบจำลองที่เราอธิบาย  $y_t$  ด้วยแบบจำลอง  $ARMA$  ในรูปแบบพหุนาม

$$\phi(L)y_t = \theta(L)\varepsilon_t$$

โดยที่  $\phi(L) = 1 - \sum_{i=1}^p \phi_i L^i$  และ  $\theta(L) = 1 + \sum_{i=1}^q \theta_i L^i$  เราสามารถแสดง  $y_t$  ในรูปพหุนามเอเวอเรจที่อันดับอนันต์

$$y_t = \psi(L)\varepsilon_t \quad (3.64)$$

โดยที่  $\frac{\theta(L)}{\phi(L)} = 1 + \psi_1 L + \psi_2 L + \dots = \psi(L)$  และ  $y_t$  ในรูปออโตรีเกรสซีฟที่อันดับอนันต์

$$\pi(L)y_t = \varepsilon_t \quad (3.65)$$



โดยที่  $\frac{\phi(L)}{\theta(L)} = 1 - \pi_1 L - \pi_2 L - \dots = \pi(L)$

**ตัวอย่างที่ 3.8** ตัวอย่างการเขียนแบบจำลอง  $ARMA(1,1)$  ในรูปมูฟวิ่งเอเวอเรจ กำหนดให้  $y_t$  อธิบายด้วยแบบจำลอง  $ARMA(1,1)$  ซึ่งแสดงได้ด้วยสมการต่อไปนี้

$$(1 - \phi L)y_t = (1 + \theta L)\varepsilon_t$$

เมื่อหารทั้งสองข้างของสมการด้วย  $(1 - \phi L)$  จะได้

$$\begin{aligned} y_t &= \frac{(1 + \theta L)}{(1 - \phi L)} \varepsilon_t \\ &= (1 + \theta L)(1 + \phi L + (\phi L)^2 + (\phi L)^3 + \dots) \varepsilon_t \\ &= (1 + \theta L) + (1 + \theta L)\phi L + (1 + \theta L)(\phi^2 L^2) + \dots \\ &= 1 + \underbrace{(\phi + \theta)L}_{\psi_1} + \underbrace{(\phi\theta + \phi^2)L^2}_{\psi_2} + \dots \end{aligned}$$

ผู้อ่านสามารถใช้วิธีการเดียวกันในการแสดงค่าสัมประสิทธิ์ออโตรีเกรสซีฟที่อันดับอนันต์ของสมการข้างต้น

### 3.3.5 การพยากรณ์ (forecasting)

จากรูปแบบของแบบจำลอง  $ARMA$  ในหัวข้อที่ผ่านมา เราสามารถแสดงแบบจำลอง  $ARMA(p, q)$  ได้สามรูปแบบคือ รูปแบบที่หนึ่งคือรูปแบบ  $ARMA(p, q)$

$$\phi(L)y_t = \theta(L)\varepsilon_t$$

รูปแบบที่สองคือการแสดงในรูปมูฟวิ่งเอเวอเรจที่อันดับอนันต์

$$y_t = \frac{\theta(L)}{\phi(L)} \varepsilon_t = \psi(L)\varepsilon_t$$

และรูปแบบที่สามคือการแสดงในรูปออโตรีเกรสซีฟที่อันดับอนันต์

$$\frac{\phi(L)}{\theta(L)} y_t = \pi(L)y_t = \varepsilon_t$$

โดยที่  $\psi(L) = 1 + \psi_1 L + \psi_2 L^2 + \dots$  และ  $\pi(L) = 1 - \pi_1 - \pi_2 - \dots$  ดังนั้นเราสามารถพยากรณ์ตัวแปร  $y_{h+1}$  ด้วยสมการใดสมการหนึ่งในสามรูปแบบนี้ได้โดยใช้คุณสมบัติที่ว่า ณ เวลาที่เราอยู่  $h$  เราทราบข้อมูล  $y_t$  และ  $\varepsilon_t$  ในช่วงเวลาก่อนจนกระทั่งเวลาที่  $h$  และใช้ขั้นตอนในการหาค่าพยากรณ์เช่นเดียวกับในหัวข้อที่ผ่านมาคือเขียน

ตัวแปร  $y_t$  ณ เวลาที่เราต้องการพยากรณ์เช่น  $y_{h+1}$  แล้วในข้อมูลถึงช่วงเวลาที่  $h$  ในการพยากรณ์ กรณีใช้รูปแบบ ARMA การพยากรณ์ไปข้างหน้าหนึ่งคาบ ณ ข้อมูลที่คาบ  $h$ ,  $\hat{y}_h(1)$  จะเท่ากับ

$$\begin{aligned}\hat{y}_h(1) &= E(\phi_1 y_h + \dots \phi_p y_{h-p} + \varepsilon_{h+1} + \theta_1 \varepsilon_h + \dots + \theta_q \varepsilon_{h+1-q} | F_h) \\ &= \phi_1 y_h + \dots \phi_p y_{h-p} + \theta_1 \varepsilon_h + \dots + \theta_q \varepsilon_{h+1-q}\end{aligned}\quad (3.66)$$

กรณีใช้แบบออโตรีเกรสซีฟอนันต์ การพยากรณ์ไปข้างหน้าหนึ่งคาบ ณ ข้อมูลที่คาบ  $h$ ,  $\hat{y}_h(1)$  จะเท่ากับ

$$\begin{aligned}\hat{y}_h(1) &= E(\pi_1 y_h + \pi_2 y_{h-1} + \dots | F_h) \\ &= \pi_1 y_h + \pi_2 y_{h-1} + \dots\end{aligned}\quad (3.67)$$

ค่าพยากรณ์ในกรณีขึ้นอยู่กับตัวแปร  $y$  เพียงเท่านั้น เราไม่จำเป็นต้องใช้ตัวแทนของช็อก กรณีการแสดงในรูปแบบพหุเชิงเอเวอเรจอนันต์ การพยากรณ์ไปข้างหน้าหนึ่งคาบ ณ ข้อมูลที่คาบ  $h$ ,  $\hat{y}_h(1)$  จะเท่ากับ

$$\begin{aligned}\hat{y}_h(1) &= E(\varepsilon_{h+1} + \psi_1 \varepsilon_h + \pi_2 \varepsilon_{h-1} + \dots | F_h) \\ &= \psi_1 \varepsilon_h + \pi_2 \varepsilon_{h-1} + \dots\end{aligned}\quad (3.68)$$

กรณีที่สามจะช่วยให้เราในการคำนวณหาค่าความแปรปรวนของค่าผิดพลาดของการพยากรณ์ ซึ่งในกรณีการพยากรณ์ไปข้างหน้าหนึ่งคาบ ค่าผิดพลาดจะเท่ากับ

$$e_h(1) = y_{h+1} - \hat{y}_h(1) = \varepsilon_{h+1}$$

และค่าความแปรปรวนของค่าผิดพลาดของการพยากรณ์เท่ากับ  $Var(e_h(1)) = \sigma^2$

### 3.4 อนุกรมเวลาไม่คงที่

อนุกรมเวลาทางเศรษฐกิจและการเงินจำนวนมากมีพฤติกรรมที่มีแนวโน้ม (trend) ซึ่งสะท้อนว่าค่าเฉลี่ยของมีค่าไม่คงที่ส่งผลตัวแปรดังกล่าวเป็นอนุกรมเวลาที่ไม่คงที่ (non-stationary) ตัวอย่างเช่น ราคาสินทรัพย์ อัตราแลกเปลี่ยน หรือตัวแปรเศรษฐกิจมหภาคเช่น ผลิตภัณฑ์มวลรวมภายในประเทศ (GDP) ในขณะที่แบบจำลองที่ผ่านมา เราสมมุติว่าตัวแปร  $y_t$  ที่เราอธิบายมีลักษณะที่เป็นอนุกรมเวลาคงที่ ดังนั้นในการสร้างแบบจำลองอนุกรมเวลาเชิงเส้นตรงเราจำเป็นต้องแปลงตัวแปรให้เป็นอนุกรมเวลาคงที่ ในอดีต นักเศรษฐศาสตร์จะจัดการกับข้อมูลมีแนวโน้มโดยการกำจัดแนวโน้มออก (detrend) โดยการประมาณค่าตัวแปรกับตัวแปรเวลาจะได้ค่าสัมประสิทธิ์ของแนวโน้ม และนำค่าประมาณของแนวโน้มไปหักออกจากตัวแปร อย่างไรก็ตาม ในช่วงทศวรรษที่ 1970 นักเศรษฐศาสตร์พบว่าข้อมูลทางเศรษฐกิจและการเงินบางตัวอาจจะมีแนวโน้มซึ่งเกิดจากคุณลักษณะของตัวแปรที่เป็นกระบวนการเคลื่อนแบบสุ่ม หรือแรนดอมวอล์ก (random walk)

ดังนั้นในการวิเคราะห์อนุกรมเวลาเราพิจารณาลักษณะของรูปแบบแนวโน้มของข้อมูลว่าเกิดจากการที่

ข้อมูลมีเส้นแนวโน้มที่ระบุได้ชัดเจน (deterministic trend) หรือ เกิดจากการเป็นกระบวนการแรนดอมวอร์ก เนื่องจากคุณลักษณะดังกล่าวจะส่งผลกระทบต่อการใช้งานข้อมูลไปใช้ เช่นในการสร้างแบบจำลอง ARMA เราจำเป็นต้องทำการแปลงข้อมูลให้เป็นอนุกรมเวลาคงที่เสียก่อน ในขณะที่ถ้าข้อมูลมีแนวโน้มเราจำเป็นต้องขจัดแนวโน้มเสียก่อน โดยสรุปแล้ว กระบวนการที่มีลักษณะแนวโน้มอาจจะแบ่งได้เป็นสองกรณีคือกระบวนการแรนดอมวอร์กแบบมีแนวโน้มด้วย (random walk with drift) และกระบวนการที่มีเส้นแนวโน้มที่ระบุได้ชัดเจน

กรณีแรก คือกรณีที่  $y_t$  เป็นกระบวนการแนวดินแบบสุ่มแบบมีแนวโน้มด้วย จะสามารถเขียนสมการอธิบาย  $y_t$  ได้ดังนี้

$$y_t = \mu + y_{t-1} + \varepsilon_t \quad (3.69)$$

โดย  $\varepsilon_t \sim WN(0, \sigma^2)$  และเราเรียก  $\mu$  ว่าตัวสร้างแนวโน้ม (drift) หากเราสมมุติให้  $y_0 = 0$  และแทนค่าแบบเวียนเกิด เราจะสามารถเขียนสมการ (3.69) ได้เป็น

$$y_t = \mu t + \sum_{j=1}^t \varepsilon_j \quad (3.70)$$

จากสมการที่ (3.70) กระบวนการแนวดินแบบสุ่มแบบมีแนวโน้มจะมีค่าคาดหวัง ( $E(y_t)$ ) เท่ากับ  $\mu t$  และค่าความแปรปรวน ( $Var(y_t)$ ) เท่ากับ  $\sigma^2 t$  จะเห็นได้ว่าค่าทั้งสองขึ้นอยู่กับเวลา  $t$  ดังนั้น  $y_t$  จากสมการ (3.69) จะเป็นกระบวนการที่ไม่คงที่ ซึ่งกระบวนการดังกล่าวสามารถแปลงให้เป็นอนุกรมเวลาคงที่ได้โดยการทำการหาผลต่างอันดับหนึ่ง (first difference) จะได้

$$\Delta y_t = y_t - y_{t-1} = \mu + \varepsilon_t$$

จะเห็นได้ว่า  $\Delta y_t$  เป็นผลรวมของค่าคงที่กับอนุกรมไวท์นอยซ์ซึ่งเป็นอนุกรมเวลาคงที่ ดังนั้น  $\Delta y_t$  จะเป็นอนุกรมเวลาคงที่ด้วย (ทำไม?) เนื่องจาก  $y_t$  จะเป็นอนุกรมเวลาคงที่หลังจากทำการหาผลต่างอันดับหนึ่ง เราจะเรียก  $y_t$  ว่าเป็นอนุกรมเวลาคงที่หลังจากหาผลต่าง (difference-stationary)

กรณีสอง คือกรณีที่  $z_t$  กระบวนการที่มีเส้นแนวโน้มที่กำหนดไว้ชัดเจน เช่น เราสามารถเขียนสมการอธิบาย  $z_t$  ได้ด้วย

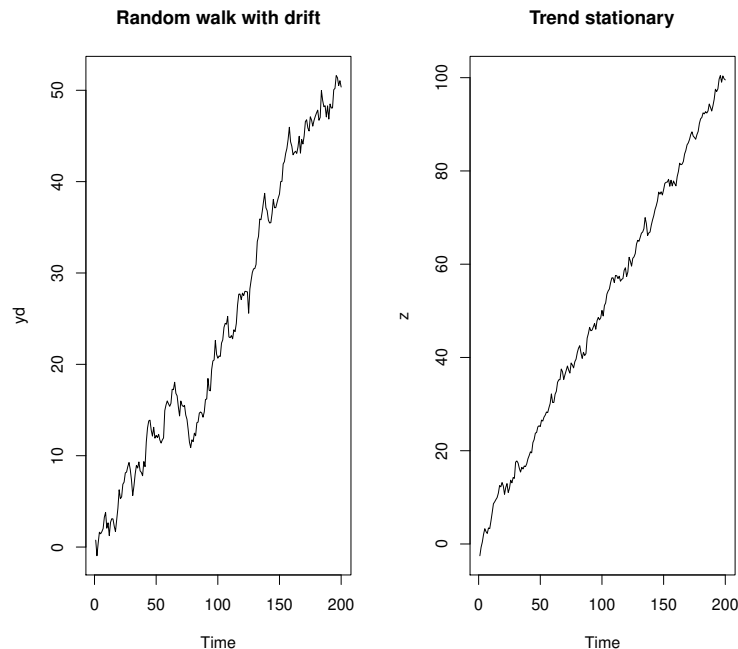
$$z_t = \beta_0 + \beta_1 t + v_t \quad (3.71)$$

โดยที่  $v_t$  เป็นอนุกรมนิ่งใดๆ เช่น กระบวนการไวท์นอยซ์หรือ AR(1) ที่มีค่าสัมบูรณ์ของสัมประสิทธิ์น้อยกว่า 1 จากสมการที่ (3.71) เราสามารถพิสูจน์ได้ว่าค่าคาดหวังของ ( $E(z_t)$ ) จะเท่ากับ  $\beta_0 + \beta_1 t$  ซึ่งเป็นฟังก์ชันเส้นตรงกับเวลา ดังนั้น  $z_t$  จึงเป็นกระบวนการไม่คงที่ โดยที่  $z_t$  จะแกว่งตัวอยู่รอบๆเส้นแนวโน้ม ในขณะที่ค่าความแปรปรวน ( $Var(z_t)$ ) จะเท่ากับ  $Var(v_t)$  ซึ่งจำกัดและไม่แปรผันตามเวลา (เนื่องจากเราสมมุติให้  $v_t$  เป็นอนุกรมนิ่ง) เนื่องจาก  $z_t$  จะเป็นอนุกรมเวลาคงที่หลังจากกำจัดแนวโน้ม เราจะเรียกอนุกรมเวลาดังกล่าวว่า กระบวนการที่คงที่หลังจากกำจัดแนวโน้ม (trend-stationary)

ตัวอย่างของกราฟข้อมูลกระบวนการไม่คงที่จากที่มาทั้งสองได้แก่ อนุกรมเวลาคงที่หลังจากดำเนินการผล

ต่าง และกระบวนการคงที่หลังจากกำจัดแนวโน้ม ถูกแสดงไว้ในรูปที่ 3.12 โดยมองดูเผินๆจะเห็นว่าภาพทั้งสองมีลักษณะที่คล้ายคลึงกัน

รูปที่ 3.12: ข้อมูลจำลองของกระบวนการแนวดินแบบสุ่มแบบมีแนวโน้มและกระบวนการที่นิ่งหลังจากขจัดแนวโน้ม



กระบวนการทั้งสองที่ได้ยกตัวอย่างมา เป็นกระบวนการที่ไม่คงที่ แต่มีคุณลักษณะที่แตกต่างกันดังนั้น วิธีการที่ใช้ในแปลงให้เป็นอนุกรมคงที่จึงแตกต่างกัน โดยวิธีการที่ใช้ทำให้อนุกรมคงที่มีอยู่สองวิธีคือ การดำเนินการผลต่าง (differencing) และการประมาณค่าถดถอยเพื่อกำจัดแนวโน้ม (detrended series)

วิธีการดำเนินการผลต่าง คือการนำข้อมูลที่คาบ  $t$  ลบออกด้วยข้อมูลที่คาบ  $t-1$  หรือเขียนเป็นสัญลักษณ์ได้โดย  $\Delta y_t = y_t - y_{t-1}$  ซึ่งเราเรียกกรณีนี้ว่าการดำเนินการผลต่างครั้งที่หนึ่ง (first difference) หากเรานำอนุกรมที่ได้จากการดำเนินการผลต่างครั้งที่หนึ่งไปดำเนินการผลต่างอีกครั้ง  $\Delta^2 y_t = \Delta y_t - \Delta y_{t-1}$  เราจะเรียกว่า การดำเนินการผลต่างครั้งที่สอง (second difference) วิธีการดำเนินการผลต่างจะเหมาะกับอนุกรมเวลาที่เป็นกระบวนการนิ่งหลังจากดำเนินการผลต่าง โดยที่หากอนุกรมเวลา  $y_t$  เป็นอนุกรมที่นิ่งหลังจากดำเนินการผลต่างครั้งที่หนึ่ง เราจะเรียกอนุกรมเวลา  $y_t$  ว่าอนุกรมเวลาที่มีอันดับอินทิเกรตเท่ากับหนึ่ง (Integrated of order 1 หรือ  $I(1)$ ) หากอนุกรมเวลา  $y_t$  เป็นอนุกรมที่นิ่งหลังจากการดำเนินการผลต่างครั้งที่สอง เราจะเรียกอนุกรมเวลา  $y_t$  ว่าอนุกรมเวลาที่มีอันดับอินทิเกรตเท่ากับสอง (Integrated of order 2 หรือ  $I(2)$ ) ในขณะที่อนุกรมเวลานิ่งจะคือ  $I(0)$

วิธีการที่สองเหมาะกับอนุกรมที่เป็นกระบวนการนิ่งหลังจากกำจัดแนวโน้ม โดยเราจะประมาณค่าสมการ 3.71 ด้วยโอแอลเอส เมื่อได้ค่า  $\hat{\beta}_0$  และ  $\hat{\beta}_1$  เราสามารถสร้างอนุกรมเวลาที่ขจัดแนวโน้มออกไปได้โดยการคำนวณ  $z_t - \hat{\beta}_0 - \hat{\beta}_1 t$  หรือพจน์ดังกล่าวคือเรซิดิวของสมการ เครื่องมือสำคัญที่ใช้ในการระบุว่าตัวแปรที่เราพิจารณาควรจะใช้วิธีการใดในการแปลงให้เป็นอนุกรมเวลาคงที่คือ การทดสอบยูนิตรูท (unit root test)

เพื่อให้เราเข้าใจแนวคิดพื้นฐานในการทดสอบยูนิตรูท เราพิจารณาอนุกรม  $y_t$  ซึ่งสามารถแยกได้เป็นส่วน

ของแนวโน้มและวัฏจักรโดยที่

$$y_t = TD_t + z_t$$

$$TD_t = \alpha + \delta t$$

$$z_t = \phi z_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim WN(0, \sigma^2)$$

โดยที่  $TD_t$  เป็นแนวโน้มเส้นตรงเชิงกำหนด (deterministic linear trend) และ  $z_t$  คือกระบวนการ  $AR(1)$  ถ้า  $|\phi| < 1$  แล้ว  $y_t$  จะเป็นอนุกรมนิ่ง ( $I(0)$ ) รอบๆแนวโน้มเชิงกำหนด  $TD_t$  แต่ถ้า  $\phi = 1$  แล้วอนุกรม  $z_t = z_{t-1} + \varepsilon_t = z_0 + \sum_{j=1}^t \varepsilon_j$  จะกลายเป็นแนวโน้มสโตแคสติก และ  $y_t$  เป็น  $I(1)$  ที่มีค่าคงที่ (drift)

การทดสอบยูนิตรุตในรูปของแบบออโตรีเกรสซีฟมีพื้นฐานจากการทดสอบสมมติฐานหลักว่า  $\phi = 1$  (อนุกรมคงที่หลังจากใช้วิธีการผลต่าง) กับสมมติฐานทางเลือก  $\phi < 1$  (อนุกรมนิ่งหลังจากขจัดแนวโน้ม) โดยที่เราเรียกการทดสอบนี้ว่ายูนิตรุต เนื่องจากภายใต้สมมติฐานหลักรากของพหุนาม  $\phi(z) = (1 - \phi z) = 0$  มีค่าเท่ากับหนึ่ง

### 3.4.1 การทดสอบยูนิตรุตในรูปออโตรีเกรสซีฟ

สมมติว่าเราพิจารณาแบบจำลองออโตรีเกรสซีฟอันดับหนึ่ง ( $AR(1)$ ) ซึ่งเขียนได้ดังนี้

$$y_t = \phi y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim WN(0, \sigma^2) \quad (3.72)$$

สมมติฐานที่เราต้องการทดสอบคือ

$$H_0 : \phi = 1 \quad (y_t \sim I(1))$$

$$H_1 : |\phi| < 1 \quad (y_t \sim I(0))$$

เราสามารถประมาณค่าสมการ 3.72 ด้วยโอแอลเอสและใช้ตัวสถิติที่เรียกว่าตัวสถิติดีกี-ฟูลเลอร์ (Dickey-Fuller  $t$  statistics) ซึ่งคำนวณได้โดย

$$t_{\phi=1} = \frac{\hat{\phi} - 1}{se(\hat{\phi})}$$

โดยที่  $\hat{\phi}$  คือค่าประมาณจากวิธีการกำลังสองน้อยที่สุดและ  $se(\hat{\phi})$  คือค่าผิดพลาดมาตรฐาน การทดสอบนี้เป็นการทดสอบทางเดียวทางซ้าย คือเราจะปฏิเสธสมมติฐานหลักถ้าค่าตัวสถิติน้อยกว่าค่าวิกฤติ และสรุปว่าอนุกรมเวลาเป็นอนุกรมเวลาคงที่ หากเราไม่สามารถปฏิเสธสมมติฐานหลักได้ แสดงว่าอนุกรมดังกล่าวเป็นยูนิตรุต นอกจากนี้เราสามารถใช้อัตถิ normalized bias ซึ่งคำนวณได้ด้วย  $T(\hat{\phi} - 1)$  ในการทดสอบยูนิตรุตเช่นเดียวกัน

สมการ 3.72 ที่เราใช้ในการทดสอบยูนิตรุตยังสามารถเขียนในรูป

$$\Delta y_t = \pi y_{t-1} + \varepsilon_t, \quad (3.73)$$

โดยที่  $\pi = (\phi - 1)$  ซึ่งในที่นี้การทดสอบยูนิทรุจะเป็นการทดสอบ  $H_0 : \pi = 0$  และ  $H_1 : \pi < 0$

ตัวสถิติที่ใช้ในการทดสอบยูนิทรุจะมีการแจกแจงที่ไม่เป็นมาตรฐานและไม่เป็นการแจกแจงแบบปกติเมื่อข้อมูลขนาดใหญ่เหมือนในกรณีทดสอบอื่นๆที่เราเคยพบมา Phillips (1987) ได้พิสูจน์ว่าหาก  $y_t$  เป็นยูนิทรุ การแจกแจงของตัวสถิติทั้งสองที่ใช้ทดสอบยูนิทรุจะมีการแจกแจงดังนี้

$$t_{\phi=1} \xrightarrow{d} \frac{\int_0^1 W(r) dW(r)}{\left(\int_0^1 W(r)^2 dr\right)^{1/2}} \quad (3.74)$$

$$T(\hat{\phi} - 1) \xrightarrow{d} \frac{\int_0^1 W(r) dW(r)}{\int_0^1 W(r)^2 dr} \quad (3.75)$$

โดยที่  $W(r)$  คือการเคลื่อนที่แบบบราวเนียน (Brownian motion) จากสมการข้างต้น ตัวประมาณค่าและตัวสถิติจะไม่มีแจกแจงเข้าสู่การแจกแจงปกติ เราจะเรียกการแจกแจงของ  $t_{\phi=1}$  ว่า การแจกแจงที่ของดิกกี-ฟูลเลอร์ (Dickey-Fuller  $t$  distribution) และการแจกแจงของ  $T(\hat{\phi} - 1)$  ว่าการแจกแจงค่าอคติที่แปลงเป็นแบบปกติของดิกกี-ฟูลเลอร์ (Dickey-Fuller normalized bias)

ตารางสำหรับการแจกแจงดิกกี-ฟูลเลอร์ สามารถใช้คำสั่ง `adfTable` ใน ชุดคำสั่ง `FUnitRoots` โดยระบุรูปแบบของสมการที่ใช้ในการทดสอบ เช่น `trend=c("nc")` กรณีที่สมการทดสอบไม่มีพจน์ค่าคงที่อยู่ (no constant) เช่นในสมการ 3.73 (ในหัวข้อย่อต่อไปจะพิจารณากรณีมีพจน์ค่าคงที่ และจุดตัด) และแสดงการแจกแจงของ  $t$  โดยระบุ `statistics=c("t")` ส่วนการแจกแจงการแจกแจงค่าอคติที่แปลงเป็นแบบปกติของดิกกี-ฟูลเลอร์ จะต้องระบุว่า `statistics=c("n")`

```
1 > library(fUnitRoots)
2 > adfTable(trend=c("nc"), statistic=c("t"))
3 $x
4 [1] 25 50 100 250 500 Inf
5
6 $y
7 [1] 0.010 0.025 0.050 0.100 0.900 0.950 0.975 0.990
8
9 $z
10 0.010 0.025 0.050 0.100 0.900 0.950 0.975 0.990
11 25 -2.66 -2.26 -1.95 -1.60 0.92 1.33 1.70 2.16
12 50 -2.62 -2.25 -1.95 -1.61 0.91 1.31 1.66 2.08
13 100 -2.60 -2.24 -1.95 -1.61 0.90 1.29 1.64 2.03
14 250 -2.58 -2.23 -1.95 -1.62 0.89 1.29 1.63 2.01
15 500 -2.58 -2.23 -1.95 -1.62 0.89 1.28 1.62 2.00
16 Inf -2.58 -2.23 -1.95 -1.62 0.89 1.28 1.62 2.00
17
18 attr(,"class")
19 [1] "gridData"
20 attr(,"control")
21 table trend statistic
22 "adf" "nc" "t"
```

โดยที่  $x$  เป็นจำนวนตัวอย่างและ  $y$  เป็นความถี่สะสม และค่า critical value จะอยู่ในส่วน  $z$  ตัวอย่างเช่น

กลุ่มตัวอย่าง 100 ตัวอย่างที่ค่า ADF เท่ากับ  $-1.95$  จะมีความถี่สะสมเท่ากับ  $0.05$  หรือพื้นที่ใต้กราฟการแจกแจงที่ของดิกกี-ฟูลเลอร์ทางซ้ายของ  $-1.95$  จะเท่ากับ  $5\%$

ตารางที่ 3.3: ค่าวิกฤตของการแจกแจงการแจกแจงที่ของดิกกี-ฟูลเลอร์กรณีไม่มีค่าคงที่

จำนวน ตัวอย่าง	ความถี่สะสม							
	0.01	0.025	0.05	0.1	0.9	0.95	0.975	0.99
25	-2.66	-2.26	-1.95	-1.60	0.92	1.33	1.70	2.16
50	-2.62	-2.25	-1.95	-1.61	0.91	1.31	1.66	2.08
100	-2.60	-2.24	-1.95	-1.61	0.90	1.29	1.64	2.03
250	-2.58	-2.23	-1.95	-1.62	0.89	1.29	1.63	2.01
500	-2.58	-2.23	-1.95	-1.62	0.89	1.28	1.62	2.00
$\infty$	-2.58	-2.23	-1.95	-1.62	0.89	1.28	1.62	2.00

### กรณีอนุกรมเวลามีค่าคงที่และแนวโน้ม

สิ่งสำคัญในการทดสอบยูนิตรุตคือการระบุว่าสมมติฐานหลักและสมมติฐานทางเลือกมีความเหมาะสมกับข้อมูลหรือ โดยเฉพาะแนวโน้ม โดยกรณีที่เราพบว่ามีสองกรณีคือกรณีมีค่าคงที่อย่างเดียว และกรณีมีค่าคงที่และแนวโน้ม

ในกรณีค่าคงที่อย่างเดียว สมการที่ใช้ในการประมาณค่าตัวสถิติทดสอบคือ

$$y_t = c + \phi y_{t-1} + \varepsilon_t \quad (3.76)$$

และสมมติฐานที่เกี่ยวข้องคือ

$$H_0 : \phi = 1 \quad (y_t \sim I(1) \text{ without drift})$$

$$H_1 : |\phi| < 1 \quad (y_t \sim I(0) \text{ with non-zero mean})$$

ในกรณีที่มีค่าคงที่และแนวโน้ม สมการที่ใช้ในการประมาณค่า

$$y_t = c + \delta t + \phi y_{t-1} + \varepsilon_t \quad (3.77)$$

และสมมติฐานที่เกี่ยวข้องกันคือ

$$H_0 : \phi = 1 \quad (y_t \sim I(1) \text{ with drift})$$

$$H_1 : |\phi| < 1 \quad (y_t \sim I(0) \text{ with deterministic time trend})$$

โดยที่รูปแบบของสมการที่ใช้ในการทดสอบมักจะเป็นในรูป

$$\Delta y_t = c + \pi y_{t-1} + \varepsilon_t$$

และ

$$\Delta y_t = c + \delta t + \pi y_{t-1} + \varepsilon_t$$

สำหรับสมการที่มีค่าคงที่และมีค่าคงที่และแนวโน้มตามลำดับ ดังนั้นการตัดสินใจว่าจะใช้สมการรูปแบบไหนสามารถทำได้โดยการพิจารณากราฟเส้นของ  $\Delta y_t$  มีค่าเฉลี่ยต่างจากศูนย์หรือมีเส้นแนวโน้มหรือไม่ โดยที่ตารางสำหรับการแจกแจงทีของดิกกี-ฟูลเลอร์ของแต่ละรูปแบบของสมการจะมีค่าที่แตกต่างกัน โดยที่กรณีมีค่าคงที่จะใช้ตัวเลือก `trend=c("c")` และกรณีมีค่าคงที่และเส้นแนวโน้มจะใช้ `trend=c("ct")` ในคำสั่ง

```
1 > adfTable(trend=c("c"), statistic=c("t"))
2 > adfTable(trend=c("ct"), statistic=c("t"))
```

แล้วจะได้ตารางดังนี้

ตารางที่ 3.4: ค่าวิกฤตของการแจกแจงทีของดิกกี-ฟูลเลอร์กรณีมีค่าคงที่

จำนวน ตัวอย่าง	ความถี่สะสม							
	0.01	0.025	0.05	0.1	0.9	0.95	0.975	0.99
25	-3.75	-3.33	-3.00	-2.63	-0.37	0.00	0.34	0.72
50	-3.58	-3.22	-2.93	-2.60	-0.40	-0.03	0.29	0.66
100	-3.51	-3.17	-2.89	-2.58	-0.42	-0.05	0.26	0.63
250	-3.46	-3.14	-2.88	-2.57	-0.42	-0.06	0.24	0.62
500	-3.44	-3.13	-2.87	-2.57	-0.43	-0.07	0.24	0.61
$\infty$	-3.43	-3.12	-2.86	-2.57	-0.44	-0.07	0.23	0.60

ตารางที่ 3.5: ค่าวิกฤตของการแจกแจงทีของดิกกี-ฟูลเลอร์ กรณีมีค่าคงที่และแนวโน้ม

จำนวน ตัวอย่าง	ความถี่สะสม							
	0.01	0.025	0.05	0.1	0.9	0.95	0.975	0.99
25	-4.38	-3.95	-3.60	-3.24	-1.14	-0.80	-0.50	-0.15
50	-4.15	-3.80	-3.50	-3.18	-1.19	-0.87	-0.58	-0.24
100	-4.04	-3.73	-3.45	-3.15	-1.22	-0.90	-0.62	-0.28
250	-3.99	-3.69	-3.43	-3.13	-1.23	-0.92	-0.64	-0.31
500	-3.98	-3.68	-3.42	-3.13	-1.24	-0.93	-0.65	-0.32
$\infty$	-3.96	-3.66	-3.41	-3.12	-1.25	-0.94	-0.66	-0.33

#### การทดสอบยูนิทรูดิกกี ฟูลเลอร์กรณีมีค่าล่าของตัวแปรตาม

การทดสอบยูนิทรูทที่ได้กล่าวไว้ข้างต้นนั้นจะถูกต้องถ้าอนุกรมเวลาเป็น  $AR(1)$  ที่มีช็อกเป็นไวท์นอยส์ Said and Dickey (1984) ได้เพิ่มตัวแปรในการทดสอบยูนิทรูทด้วยค่าล่าของตัวแปรตามโดยมีพื้นฐานจากแบบจำลอง  $ARMA(p, q)$  แล้วเรียกว่า การทดสอบยูนิทรูทดิกกีฟูลเลอร์แบบแต่งเติม (Augmented Dickey-Fuller) หรือเอดีเอฟ (ADF) ซึ่งตัวทดสอบสามารถประมาณค่าได้จากสมการ

$$y_t = \beta' (D_t) + \phi y_{t-1} + \sum_{j=1}^p \psi_j \Delta y_{t-j} + \varepsilon_t \quad (3.78)$$



หรือเราสามารถประมาณค่าสมการนี้

$$\Delta y_t = \beta' D_t + \pi y_{t-1} + \sum_{j=1}^p \psi_j \Delta y_{t-j} + \varepsilon_t \quad (3.79)$$

โดยที่  $\pi = \phi - 1$  ซึ่งภายใต้สมมุติฐานหลัก  $\Delta y_t$  จะเป็น  $I(0)$  และอนุมานได้ว่า  $\pi = 0$  ดังนั้น ตัวสถิติ  $t$  สำหรับยูนิตรุตด้วยดิกกี ฟูลเลอร์แบบแต่งเติม จะเป็นค่าที่ของสัมประสิทธิ์หน้า  $y_t$

**ตัวอย่างที่ 3.9** การทดสอบยูนิตรุตด้วยการทดสอบเอดีเอฟ ตัวอย่างนี้เราต้องการทดสอบยูนิตรุตของ SET index รายวัน จากข้อมูลในไฟล์ `setindex.txt` ซึ่งมีตัวอย่างเท่ากับ 3642 ตัวอย่าง โดยที่ในโปรแกรมอาร์มีชุดคำสั่งหลายชุดคำสั่งที่สามารถทำการทดสอบ ADF ได้เช่น `URCA`, `STATS`, `TSERIES` แต่ในที่นี้เราจะใช้ชุดคำสั่ง `URCA` โดยเบื้องต้นเราจะพิจารณาเอซีเอฟของอนุกรมเวลาและอนุกรมเวลาที่ได้ปรับผลต่างอันดับหนึ่ง จากเอซีเอฟของอนุกรมเวลา `setd$index` เราพบว่าน่าจะมีปัญหายูนิตรุตเนื่องจากค่าเอซีเอฟลดลงช้ามาก

```
1 > setd <- read.csv("https://raw.githubusercontent.com/chaleampong/EC435/master/setdaily.csv", header = TRUE)
2 > head(setd)
3   X      date index
4 1 1  1/5/1998 366.18
5 2 2  1/6/1998 370.27
6 3 3  1/7/1998 370.31
7 4 4  1/8/1998 360.17
8 5 5  1/9/1998 349.67
9 6 6  1/12/1998 339.17
10 > ts.plot(setd$index)
11 > acf(setd$index)
```

เราสามารถทดสอบยูนิตรุตด้วยคำสั่ง `ur.df` จากชุดคำสั่ง `URCA` ซึ่งเป็นการทดสอบยูนิตรุตด้วยเอดีเอฟ โดยเรากำหนดตัวแปรที่ต้องการทดสอบ `setd$index` แล้วเลือกรูปแบบของสมการที่เราใช้ทดสอบซึ่งสามารถเลือกได้ เป็นสมการที่ไม่มีค่าคงที่ (`none`) มีค่าคงที่ (`drift`) และมีเส้นแนวโน้ม (`trend`) ด้วยการระบุใน `type` เช่น `'type=c("trend")'` แล้วเลือกว่าจะมี lag ของตัวแปรตามเท่ากับเท่าใด ซึ่งมีทางเลือกในการระบุจำนวนเลย เช่น `lags=1` หรือใช้เกณฑ์คัดเลือกแบบจำลองเช่น `selectlags = c("AIC")`

ในกรณีแรกที่เราระบุ `lag=1` เราเก็บผลไว้ในชื่อ `setd.df` ค่าสถิติที่ได้คือ  $-1.863$  ซึ่งมากกว่าค่าวิกฤติที่  $\alpha = 0.05$  เท่ากับ  $-3.41$  ดังนั้น เราไม่สามารถปฏิเสธสมมุติฐานที่ว่า `setd` เป็นยูนิตรุต

```
1 > library(urca)
2 > setd.df<-ur.df(setd$index, type=c("trend"), lags=1 )
3 > summary(setd.df)
4 #####
5 # Augmented Dickey-Fuller Test Unit Root Test #
6 #####
7 Test regression trend
8 Call:
9 lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

```

10 Residuals:
11      Min       1Q   Median       3Q      Max
12 -108.380   -4.745   -0.105    4.837   74.125
13 Coefficients:
14             Estimate Std. Error t value Pr(>|t|)
15 (Intercept)  0.4325591  0.4122648   1.049  0.29414
16 z.lag.1     -0.0021279  0.0011419  -1.864  0.06247 .
17 tt           0.0006223  0.0002840   2.191  0.02851 *
18 z.diff.lag   0.0478816  0.0165720   2.889  0.00388 **
19 ---
20 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
21
22 Residual standard error: 9.355 on 3636 degrees of freedom
23 Multiple R-squared:  0.003526, Adjusted R-squared:  0.002704
24 F-statistic: 4.289 on 3 and 3636 DF, p-value: 0.004982
25
26 Value of test-statistic is: -1.8635 2.3752 2.4005
27
28 Critical values for test statistics:
29      1pct  5pct 10pct
30 tau3 -3.96 -3.41 -3.12
31 phi2  6.09  4.68  4.03
32 phi3  8.27  6.25  5.34

```

ในกรณีแรกที่ระบุ `selectlags = c("AIC")` เราเก็บผลไว้ในชื่อ `setd.df2` ค่าสถิติที่ได้คือ  $-1.864$  ซึ่งมากกว่าค่าวิกฤตที่  $\alpha = 0.05$  เท่ากับ  $-3.41$  ดังนั้น เราไม่สามารถปฏิเสธสมมุติฐานที่ว่า `setd` เป็นยูนิทรูท

```

1 > setd.df2<-ur.df(setd$index, type = c("trend"), selectlags = c("AIC"))
2 > summary(setd.df2)
3 #####
4 # Augmented Dickey-Fuller Test Unit Root Test #
5 #####
6 Test regression trend
7 Call:
8 lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
9 Residuals:
10      Min       1Q   Median       3Q      Max
11 -108.380   -4.745   -0.105    4.837   74.125
12 Coefficients:
13             Estimate Std. Error t value Pr(>|t|)
14 (Intercept)  0.4325591  0.4122648   1.049  0.29414
15 z.lag.1     -0.0021279  0.0011419  -1.864  0.06247 .
16 tt           0.0006223  0.0002840   2.191  0.02851 *
17 z.diff.lag   0.0478816  0.0165720   2.889  0.00388 **
18 ---
19 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
20 Residual standard error: 9.355 on 3636 degrees of freedom
21 Multiple R-squared:  0.003526, Adjusted R-squared:  0.002704
22 F-statistic: 4.289 on 3 and 3636 DF, p-value: 0.004982
23
24 Value of test-statistic is: -1.8635 2.3752 2.4005

```

```

25
26 Critical values for test statistics:
27      1pct  5pct 10pct
28 tau3 -3.96 -3.41 -3.12
29 phi2  6.09  4.68  4.03
30 phi3  8.27  6.25  5.34
    
```

เราได้ค่าสถิติที่จากเอดีเอฟเท่ากับ  $-0.68$  เมื่อเปรียบเทียบกับค่าวิกฤตจากตาราง 3.4 ที่นัยสำคัญ 5 % และ  $N = \infty$  มีค่าเท่ากับ  $-2.86$  จะเห็นได้ว่าสถิติที่จากเอดีเอฟมีค่ามากกว่าค่าวิกฤต ดังนั้นเราไม่สามารถปฏิเสธสมมติฐานที่ว่า **set index** เป็นยูนิทรูท และเราสามารถพิจารณาค่า  $\hat{\pi}$  ซึ่งมีค่าเท่ากับ 0.95 ซึ่งไม่สามารถปฏิเสธว่า **set index** เป็นยูนิทรูท

### ตัวทดสอบยูนิทรูทของฟิลลิปส์ เพอร์รอน

Phillips and Perron 1988 ได้พัฒนาการทดสอบยูนิทรูทซึ่งเป็นการทดสอบอีกวิธีหนึ่งที่เป็นที่นิยม โดยการทดสอบฟิลลิปส์-เพอร์รอน มีความแตกต่างจากการทดสอบยูนิทรูทดิกกี ฟูลเลอร์แบบดั้งเดิมที่สำคัญคือการดำเนินการที่เกี่ยวข้องกับปัญหาออโตคอร์เรชันและเฮเทอโรสกีดาสติซิตีในข้อผิดพลาด โดยที่ในกรณีของการทดสอบเอดีเอฟจะใช้โครงสร้างที่มีรูปแบบอาร์มาในการประมาณตัวแปรข้อผิดพลาด ในขณะที่การทดสอบด้วยวิธีการฟิลลิปส์-เพอร์รอนไม่ได้แก้ไขรูปแบบสมการเพื่อแก้ปัญหออโตคอร์เรชัน และใช้สมการต่อไปนี้ในการประมาณค่า

$$\Delta y_t = \beta' D_t + \pi y_{t-1} + u_t \quad (3.80)$$

โดยที่  $u_t$  เป็น  $I(0)$  และอาจจะมีปัญหาเฮเทอโรสกีดาสติซิตี แต่การทดสอบฟิลลิปส์-เพอร์รอนจะแก้ไขปัญหออโตคอร์เรชันและเฮเทอโรสกีดาสติซิตีในตัวแปรข้อผิดพลาด  $u_t$  โดยการปรับตัวสถิติทดสอบ  $t_{\pi=0}$  และ  $T\hat{\pi}$  โดยตัวสถิติที่ปรับจะอยู่ในรูปดังต่อไปนี้

$$Z_t = \left( \frac{\hat{\sigma}^2}{\hat{\lambda}^2} \right)^{1/2} \times t_{\pi=0} - \frac{1}{2} \left( \frac{\hat{\lambda}^2 - \hat{\sigma}^2}{\hat{\lambda}^2} \right) \times \left( \frac{T \times se(\hat{\pi})}{\hat{\sigma}^2} \right)$$

$$Z_\pi = T\hat{\pi} - \frac{1}{2} \frac{T^2 \times se(\hat{\pi})}{\hat{\sigma}^2} (\hat{\lambda}^2 - \hat{\sigma}^2)$$

โดยที่  $\hat{\sigma}^2$  และ  $\hat{\lambda}^2$  เป็นตัวประมาณค่าที่ **consistent** ของพารามิเตอร์ค่าความแปรปรวน

$$\sigma^2 = \lim_{T \rightarrow \infty} T^{-1} \sum_{t=1}^T E[u_t^2]$$

$$\lambda^2 = \lim_{T \rightarrow \infty} \sum_{t=1}^T E[T^{-1} S_t^2]$$

โดยที่  $S_T = \sum_{t=1}^T u_t$

ภายใต้สมมติฐานหลักที่ว่า  $\pi = 0$  ตัวสถิติ  $Z_t$  และ  $Z_\pi$  ของการทดสอบฟิลลิปส์-เพอร์รอน มีการแจกแจงที่ลู่เข้าหาการแจกแจงแบบทิกกีฟูลเลอร์ และสถิติที่มีอคติและได้ปรับให้เป็นปกติแล้วเมื่อขนาดตัวอย่างใหญ่ ข้อได้เปรียบของฟิลลิปส์เพอร์รอนต่อเอดีเอฟ คือ ฟิลลิปส์เพอร์รอนพิจารณาความน่าจะเป็นที่จะเกิดเฮเทอโรสกีดาสติซิตีของข้อผิดพลาด นอกจากนี้ผู้ใช้ไม่จำเป็นต้องกำหนดอันดับของตัวแปร  $y_t$  เหมือนกับในกรณีของเอดีเอฟ

### ตัวอย่างที่ 3.10 การทดสอบยูนิทรทด้วยวิธีการฟิลลิปส์เพอร์รอน

```

1 > setd.pp<-ur.pp(setd$index, type="Z-tau", model="trend")
2 > summary(setd.pp)
3
4 #####
5 # Phillips-Perron Unit Root Test #
6 #####
7
8 Test regression with intercept and trend
9
10
11 Call:
12 lm(formula = y ~ y.l1 + trend)
13
14 Residuals:
15      Min       1Q   Median       3Q      Max
16 -108.674   -4.712   -0.062    4.765   68.930
17
18 Coefficients:
19             Estimate Std. Error t value Pr(>|t|)
20 (Intercept)  1.4901935   0.7300869   2.041   0.0413 *
21 y.l1         0.9980139   0.0011418 874.061 <2e-16 ***
22 trend        0.0005988   0.0002841   2.108   0.0351 *
23 ---
24 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
25
26 Residual standard error: 9.363 on 3638 degrees of freedom
27 Multiple R-squared:  0.9987,    Adjusted R-squared:  0.9987
28 F-statistic: 1.42e+06 on 2 and 3638 DF,  p-value: < 2.2e-16
29
30
31 Value of test-statistic, type: Z-tau is: -1.8587
32
33      aux. Z statistics
34 Z-tau-mu          1.7473
35 Z-tau-beta        2.1804
36
37 Critical values for Z statistics:
38             1pct      5pct     10pct
39 critical values -3.966098 -3.413711 -3.128565
40

```

ค่าสถิติฟิลลิปส์เพอร์รอนมีค่าเท่ากับ  $-1.8587$  มากกว่าค่าวิกฤติ แสดงว่าเราไม่สามารถปฏิเสธสมมติฐานว่า `setd$index` เป็นยูนิทรท

### 3.5 แบบจำลองอินทิเกรตเตอร์มา หรืออะริมา

**บทนิยาม 3.3** เราจะเรียกกระบวนการ  $y_t$  ว่าอินทิเกรตเตอร์มา (Integrate ARMA) หรืออะริมาที่อันดับ  $(p, d, q)$  ( $ARIMA(p, d, q)$ ) ถ้าตัวแปร  $y$  ที่หาผลต่าง  $d$  ครั้ง ( $\Delta^d y_t = (1 - L)^d y_t$ ) เป็นกระบวนการ  $ARMA(p, q)$  หรือเราสามารถเขียนในรูปทั่วไปเป็น

$$\phi(L)(1 - L)^d y_t = \theta(L)\varepsilon_t \quad (3.81)$$

และถ้าหาก  $E(\Delta^d y_t) = \mu$  เราสามารถเขียนแบบจำลองได้เป็น

$$\phi(L)(1 - L)^d y_t = \delta + \theta(L)\varepsilon_t$$

โดยที่  $\delta = \mu(1 - \phi_1 - \dots - \phi_p)$

ในที่นี้เราอาจจะนึกถึงแบบจำลอง  $ARIMA(p, d, q)$  ว่าเป็นแบบจำลอง  $ARMA(p, q)$  ของอนุกรมเวลาที่ได้ดำเนินการผลต่างไปแล้ว  $d$  ครั้ง โดยที่  $z_t = \Delta^d y_t$  และ  $\phi(L)z_t = \theta(L)\varepsilon_t$  โดยทั่วไปแล้ว  $d$  จะมีค่าไม่เกิน 3

ในทางปฏิบัติ เราสามารถแบ่งแยกขั้นตอนในการสร้างแบบจำลอง  $ARIMA(p, d, q)$  ได้ดังนี้

1. พิจารณา ACF ของข้อมูลว่ามีข้อบ่งชี้ว่ามีปัญหาข้อมูลไม่นิ่ง (nonstationary) หรือไม่
2. ทดสอบยูนิทรูทว่ามีอินทิเกรตที่อันดับเท่าใด หรือหาค่า  $d$  นั้นเอง
3. หลังจากนั้นเราจะพิจารณาอนุกรม  $z_t = \Delta^d y_t$  ซึ่งเป็นอนุกรมเวลาที่นิ่งแล้วหลังจากได้ดำเนินการผลต่างไปแล้ว  $d$  ครั้ง ว่าแบบจำลองที่เหมาะสมในการอธิบาย  $z_t$  ควรจะมีอันดับของ  $p$  และ  $q$  เท่าใด โดยที่เราอาจจะพิจารณาเอซีเอฟและพีเอซีเอฟของ  $z_t$  หรือใช้เกณฑ์สารสนเทศก็ได้

หลังจากที่เราได้ค่า  $d$ ,  $p$  และ  $q$  แล้วเราก็จะได้แบบจำลอง  $ARIMA(p, d, q)$

#### ตัวอย่างที่ 3.11 การสร้างแบบจำลองอาริมา

ต่อจากตัวอย่างที่ผ่านมา เราพิจารณาว่าดัชนีหลักทรัพ์ของไทย เป็นอินทิเกรตที่อันดับเท่าไร โดยการดำเนินการหาผลต่างอันดับหนึ่ง(first differenced) แล้วทดสอบยูนิทรูท พบว่าอนุกรมเวลาที่ดำเนินการหาผลต่างอันดับหนึ่งไม่เป็นยูนิทรูท ดังนั้น set index เป็นอินทิเกรตที่อันดับหนึ่ง (I(1)) และในแบบจำลองอะริมา เราจะกำหนดให้  $d = 1$  ซึ่งเราจะใส่ค่าดังกล่าวในคำสั่ง `auto.arima` เพื่อหา  $p$  และ  $q$  ที่เหมาะสมต่อไป

ขั้นตอนแรกของการสร้างแบบจำลองคือการหาลำดับของอินทิเกรชัน (order of integration) หรือค่า  $d$

จากตัวอย่างที่ผ่านมาเราทราบว่า `setd$index` เป็นยูนิทรูท ดังนั้นเราแปลงข้อมูลด้วยการหาผลต่างอันดับหนึ่ง ( $\Delta \text{setd}_t = \text{setd}_t - \text{setd}_{t-1}$ ) แล้วทดสอบยูนิทรูท

```
i > setd.df.diff<-ur.df(diff(setd$index), type = c("trend"), selectlags =  
c("AIC"))
```

```

2 > summary(setd.df.diff)
3 <Omitted>
4 Value of test-statistic is: -39.9724 532.5983 798.8972
5
6 Critical values for test statistics:
7      1pct  5pct 10pct
8 tau3 -3.96 -3.41 -3.12
9 phi2  6.09  4.68  4.03
10 phi3  8.27  6.25  5.34

```

จากการทดสอบยูนิทรูทกับตัวแปรในรูปผลต่างอันดับหนึ่ง ค่าสถิติทีของเอดีเอฟเท่ากับ  $-39.97$  ซึ่งน้อยกว่าค่าวิกฤติ ( $-3.41$ ) ดังนั้นเราสามารถปฏิเสธสมมติฐานหลักที่ว่า  $\text{diff}(\text{setd})$  เป็นยูนิทรูทแสดงว่า  $\text{diff}(\text{setd})$  เป็นอนุกรมเวลาคงที่และเราสามารถสรุปได้ว่า  $\text{setd}$  เป็นอินทิเกรตที่อันดับหนึ่ง  $I(1)$  หมายความว่าต้องหาลดอันดับหนึ่งกับข้อมูลก่อนจึงจะเป็นอนุกรมเวลาคงที่

แบบจำลองที่เหมาะสมกับ  $\text{setd}$  คือแบบจำลองที่  $d=1$  ดังนั้นเรากำหนดค่าดังกล่าวในคำสั่ง `auto.arima` และให้คำสั่งทดลองหา  $p, q$  ที่เหมาะสม

```

1 > library(forecast)
2 > setd_mod<-auto.arima(setd$index, d=1, max.p=6, max.q=6 , ic= c("bic")
, stepwise = FALSE, trace = TRUE)
3 <Omitted>
4 Best model: ARIMA(0,1,0)
5
6 > setd_mod
7 Series: setd$index
8 ARIMA(0,1,0)
9
10 sigma^2 estimated as 87.77: log likelihood=-13312.56
11 AIC=26627.12 AICc=26627.12 BIC=26633.32
12

```

ซึ่งจากการใช้ป๊อซี พบว่าอันดับที่เหมาะสมคือ  $p = 0$  และ  $q = 0$  ดังนั้นแบบจำลองที่เหมาะสมที่ใช้ประมาณค่าดัชนีหลักทรัพย์แห่งประเทศไทยรายวันคือ  $\text{ARIMA}(0, 1, 0)$  หรือแบบจำลองแรนดอมวอล์กนั่นเอง

## 3.6 แบบฝึกฝน

**แบบฝึกฝน 3.1** ดาวน์โหลดไฟล์ `hw2_60s2.csv` จาก [www.gg.gg/ec435data](http://www.gg.gg/ec435data) ซึ่งเป็นข้อมูลตัวแปร  $y$  จำนวน 400 วัน จงตอบคำถามต่อไปนี้

1. จงวาดกราฟของ  $y_t$  และตรวจสอบว่าเราสามารถสร้างแบบจำลองเพื่ออธิบาย  $y_t$  หรือไม่
2. จงสร้างแบบจำลอง โดยใช้ข้อมูลจาก **ACF** และ **PACF** พร้อมรายงานค่าประมาณจากแบบจำลอง และตรวจสอบแบบจำลองว่าเพียงพอหรือไม่ (โดยใช้  $Q(10)$ )

3. จงทำนายค่า  $y_t$  ไปข้างหน้า 1-คาบ (1-step forecast) ถึง 3-คาบ (3-step forecast) พร้อมทั้งระบุช่วงความเชื่อมั่น 95 %

**แบบฝึกฝน 3.2** จงพิจารณาว่ากระบวนการต่อไปนี้เป็นกระบวนการนิ่ง (stationary) หรือไม่ พร้อมแสดงวิธีทำ [ $\varepsilon_t \sim iidN(0,1)$ ]

1.  $y_t = -0.2y_{t-1} + 0.48y_{t-2} + \varepsilon_t$
2.  $y_t = -1.9y_{t-1} - 0.88y_{t-2} + \varepsilon_t$
3.  $y_t = -1.8y_{t-1} - 0.81y_{t-2} + \varepsilon_t$

**แบบฝึกฝน 3.3** หากเราทราบว่าผลได้ตอบแทนรายวันมีลักษณะเป็นกระบวนการ  $y_t = -0.2y_{t-1} + 0.48y_{t-2} + \varepsilon_t$  โดยที่  $E(\varepsilon_t) = 0$  และ  $Var(\varepsilon_t) = 0.25$  หากเราทราบว่าอัตราผลตอบแทน ณ วันที่ 199 และ 200 เท่ากับ 0.045 และ 0.01 จงพยากรณ์ผลได้ตอบแทนในวันที่ 201 และ 202 พร้อมช่วงความเชื่อมั่น 95 % ของการพยากรณ์

## 4. สมการถดถอยสำหรับข้อมูลอนุกรมเวลา

วิธีการประมาณสมการถดถอยสำหรับข้อมูลอนุกรมเวลาถูกนำมาใช้แพร่หลายในการวิเคราะห์ข้อมูลทางการเงิน และใช้ในการประมาณค่าและทดสอบแบบจำลองเช่น แบบจำลองราคาสินทรัพย์และผลตอบแทนของสินทรัพย์เช่นแบบจำลองการประเมินราคาของหลักทรัพย์ (Capital Asset Pricing Model) หรือแคปเอ็ม (CAPM) หรือแบบจำลองการกำหนดราคาจากการทำกำไรที่ผิดปกติ (Arbitrage Price Model) หรือเอพีที (APT) นอกจากนี้ยังใช้ศึกษาความสัมพันธ์ระหว่างผลตอบแทนของหลักทรัพย์กับสัดส่วนทางการเงิน เพื่อใช้ในการทำนายการเปลี่ยนแปลงของผลตอบแทน วิธีการถดถอยยังใช้ในการทดสอบทฤษฎีประสิทธิภาพของตลาด (Efficient Market)

การศึกษาความสัมพันธ์ทางการเงินที่ใช้ข้อมูลอนุกรมเวลาและวิธีการถดถอยจำเป็นต้องใช้ความระมัดระวัง เนื่องจากข้อมูลส่วนใหญ่ที่ใช้เป็นข้อมูลอนุกรมเวลา ซึ่งจะส่งผลต่อคุณสมบัติของการประมาณค่าถดถอยบางประการ อันส่งผลต่อการอธิบายผลและทดสอบผล โดยทั่วไปข้อมูลที่เรานำมาใช้ในการศึกษามักจะเป็นตัวแปรนิ่ง เช่น ผลตอบแทนของหลักทรัพย์ซึ่งมักจะมีคุณสมบัติที่เป็นตัวแปรนิ่ง การศึกษาสมการถดถอยมักจะพยายามที่จะอธิบายผลได้ตอบแทน ในทางตรงกันข้าม ราคาของสินทรัพย์มักจะมีลักษณะที่ไม่นิ่ง การศึกษาด้วยสมการถดถอยกับตัวแปรดังกล่าวอาจจะไม่เหมาะสม ซึ่งจะเป็นประเด็นที่เราพิจารณาในบทที่ 7 ในขณะที่บทนี้เราจะพิจารณากรณีที่ตัวแปรเป็นตัวแปรนิ่ง

### 4.1 แบบจำลองถดถอยข้อมูลอนุกรมเวลา

พิจารณาแบบจำลองถดถอยข้อมูลอนุกรมเวลาซึ่งอธิบายด้วยสมการต่อไปนี้

$$y_t = \beta_0 + \beta_1 x_{1t} + \dots + \beta_k x_{kt} + \varepsilon_t = \mathbf{x}'_t \boldsymbol{\beta} + \varepsilon_t, \quad t = 1, \dots, T \quad (4.1)$$

โดยที่  $x_{1t}, \dots, x_{kt}$  คือตัวแปรอธิบาย และ  $\varepsilon_t$  เป็น error term และสามารถเขียนในรูปเมทริกซ์ได้

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \quad (4.2)$$



ข้อสมมุติมาตรฐานสำหรับแบบจำลองถดถอยเชิงเส้นในกรณีข้อมูลอนุกรมเวลาคือ

- แบบจำลองในสมการ (4.1.2) เป็นแบบจำลองที่ระบุถูกต้อง
- $y_t, x_t$  เป็นอนุกรมนิ่งและ ergodic
- ตัวแปรต้น  $x_t$  ถูกกำหนดไว้ก่อน (predetermined):  $E(x_{is}\varepsilon_t) = 0$  สำหรับทุกค่าที่  $s \leq t$
- $E(x_t x_t')$  เป็น full rank
- $x_t \varepsilon_t$  เป็นกระบวนการที่ไม่มีสหสัมพันธ์กันในระยะจำกัด

#### 4.1.1 การประมาณค่าวิธีกำลังสองน้อยที่สุด

วิธีการประมาณค่ากำลังสองน้อยที่สุดทั่วไป (Ordinary Least Square: OLS) เป็นการประมาณค่าโดยหาตัวประมาณค่าของพารามิเตอร์ที่ทำให้

$$SSR(\beta) = \sum_{t=1}^T (y_t - x_t' \beta)^2 = \sum_{t=1}^T \varepsilon_t^2 \quad (4.3)$$

และได้แบบจำลอง fitted

$$y_t = x_t' \hat{\beta} + \hat{\varepsilon}_t, \quad t = 1, \dots, T$$

โดยที่  $\hat{\beta} = (X'X)^{-1}X'y$  และ  $\hat{\varepsilon}_t = y_t - \hat{y}_t = y_t - x_t' \hat{\beta}$  โดยมีค่าประมาณ error variance เท่ากับ  $\hat{\sigma}^2 = \hat{\varepsilon}'\hat{\varepsilon}/(T - k - 1)$  และภายใต้ข้อสมมุติข้างต้นตัวประมาณค่า OLS จะ consistent และ asymptotically normal distributed และตัวประมาณค่าของความแปรปรวน

$$\widehat{Aver}(\hat{\beta}) = \hat{\sigma}^2 (X'X)^{-1}$$

และสแตนด์ดาร์ดเออร์เรอร์ของแต่ละตัวประมาณค่า  $\beta_j$  คือค่ารากที่สองของสมาชิกลำดับที่  $j$  ในแนวทแยงมุม

#### 4.1.2 การวิเคราะห์เรซิดิว

ข้อสมมุติสองประการสำคัญของการประมาณค่าด้วยโอแอลเอสคือตัวรบกวนมีค่าความแปรปรวนคงที่หรือไม่มีเฮเทอโรสกีดาสติซิตี (heteroskedasticity) และตัวรบกวนไม่มีสหสัมพันธ์ระหว่างกันหรือออโตคอร์เรชัน (autocorrelation) หากข้อมูลที่เราศึกษาไม่เป็นไปตามข้อสมมุติดังกล่าวจะส่งผลต่อค่าความแปรปรวนของพารามิเตอร์ที่เราประมาณค่าด้วยโอแอลเอส ซึ่งจะไม่ถูกต้องและส่งผลต่อการทดสอบสมมุติฐานด้วยตัวสถิติทีและเอฟซึ่งคำนวณจากค่าความแปรปรวนดังกล่าว<sup>1</sup> หากเราพบว่าข้อมูลที่เราศึกษานั้นเผชิญกับเหตุการณ์ที่ไม่เป็นไปตามข้อสมมุติ วิธีการแก้ไขปัญหานี้คือการปรับการประมาณค่าโดยการผนวกรูปแบบของเฮเทอโรสกีดาสติซิตีหรือออโตคอร์เรชันเข้าไปในการประมาณค่าด้วยการปรับตัวรบกวนให้เป็นไปตามข้อสมมุติ เช่น

<sup>1</sup>ผู้อ่านสามารถทบทวนเนื้อหาเชิงทฤษฎีจากหนังสือเศรษฐมิติเบื้องต้น เช่น Wooldridge

การประมาณค่าด้วยวิธีการกำลังสองน้อยที่สุดทั่วไป (Generalized Least Squared) อย่างไรก็ตาม การปรับวิธีการในการประมาณค่าจำเป็นต้องทราบรูปแบบของเฮเทอโรสกีดาซิตีหรือออโตคอร์เรชันซึ่งมักจะเป็นสิ่งที่เราไม่ทราบ งานศึกษาสมัยใหม่จึงใช้วิธีการประมาณค่าด้วยโอแอลเอสปกติ แล้วปรับสแตนด์ดาร์ดแอร์เรอให้เหมาะสม ซึ่งจะกล่าวถึงในหัวข้อถัดไป อย่างไรก็ตาม ตัวประมาณค่าสแตนด์ดาร์ดแอร์เรอจากวิธีการดังกล่าวจะมีประสิทธิภาพที่ต่ำกว่าสแตนด์ดาร์ดแอร์เรอจากวิธีการโอแอลเอสดั้งเดิม ดังนั้นเราจำเป็นต้องตรวจสอบว่าเราเผชิญกับปัญหาเฮเทอโรสกีดาซิตีหรือออโตคอร์เรชันหรือไม่

### การทดสอบเฮเทอโรสกีดาซิตี

หากเราพิจารณาสมการถดถอยอนุกรมเวลา และพิจารณาความเป็นไปได้ที่ค่าความแปรปรวนของตัวรบกวนจะไม่คงที่ หรือข้อสมมุติ

$$H_0 : \text{Var}(\varepsilon|x_1, \dots, x_k) = \sigma^2$$

ไม่เป็นจริง เนื่องจากเราสมมุติให้  $E(\varepsilon|x_1, \dots, x_k) = 0$  ข้อสมมุติค่าความแปรปรวนของตัวรบกวนคงที่สามารถเขียนเป็นเงื่อนไข

$$H_0 : E(\varepsilon^2|x_1, \dots, x_k) = \sigma^2$$

จากเงื่อนไขดังกล่าว เราสามารถทดสอบข้อสมมุติค่าความแปรปรวนของตัวรบกวนว่าคงที่หรือไม่โดยการพิจารณาความสัมพันธ์ระหว่างตัวรบกวนยกกำลังสองกับตัวแปรอธิบาย ซึ่งสามารถเขียนเป็นสมการได้ดังนี้

$$\varepsilon_t^2 = \delta_0 + \delta_1 x_{1t} + \dots + \delta_k x_{kt} + v_t \quad (4.4)$$

โดยที่  $v_t$  เป็นตัวรบกวนที่มีค่าเฉลี่ยเท่ากับศูนย์และไม่สัมพันธ์กับตัวแปรอธิบาย เราสามารถทดสอบข้อสมมุติค่าความแปรปรวนของตัวรบกวนไม่คงที่ด้วยสมมุติฐานหลักคือ

$$H_0 : \delta_1 = \delta_2 = \dots = \delta_k = 0$$

ซึ่งสามารถทดสอบได้ด้วยการทดสอบนัยสำคัญรวม (overall significance) ของสมการถดถอยระหว่างตัวรบกวนกำลังสองกับตัวแปรอธิบาย ซึ่งในทางปฏิบัติเราจะใช้ค่าเรชชีดิวจากการประมาณโอแอลเอสของสมการดั้งเดิมแทนค่าตัวรบกวน

$$\hat{\varepsilon}_t^2 = \delta_0 + \delta_1 x_{1t} + \dots + \delta_k x_{kt} + v_t \quad (4.5)$$

แล้วคำนวณสถิติเอฟหรือสถิติแอลเอ็ม (LM) สำหรับการทดสอบ หากกำหนดให้  $R_{\hat{\varepsilon}_t^2}^2$  เป็นค่า  $R^2$  จากสมการถดถอย 4.5

$$F = \frac{R_{\hat{\varepsilon}_t^2}^2/k}{(1 - R_{\hat{\varepsilon}_t^2}^2)/(T - k - 1)}$$

ซึ่งมีการแจกแจงแบบเอฟและมืองศาเสรีเท่ากับ  $k, T - k - 1$  และ

$$LM = TR_{\varepsilon^2}^2$$

ซึ่งมีการแจกแจงแบบไคสแควและมืองศาเสรีเท่ากับ  $k$  เราจะปฏิเสธสมมุติฐานหลักที่ว่าตัวรบกวนมีค่าความแปรปรวนคงที่ถ้าค่าสถิติเอฟหรือแอลเอ็มมีค่าสูงกว่าค่าวิกฤติ เราเรียกตัวทดสอบที่ใช้สถิติแอลเอ็มว่าการทดสอบ Breusch-Pagan

### การทดสอบออโตคอร์เรชัน

ในกรณีอนุกรมเวลา ตัวรบกวนในช่วงเวลาที่ใกล้เคียงกันอาจมีความสัมพันธ์ระหว่างกันได้ โดยที่ความสัมพันธ์ที่เรามักจะพบคือช่วงเวลาที่ติดกันหรืออยู่ในรูปแบบออโตรีเกรสซีฟที่อันดับหนึ่ง (AR(1)) ดังแสดงในสมการต่อไปนี้

$$\varepsilon_t = \rho \varepsilon_{t-1} + u_t \quad (4.6)$$

โดยที่  $|\rho| < 1$  ซึ่งหากเราทราบค่าของตัวรบกวน เราสามารถทดสอบว่าตัวรบกวนมีความสัมพันธ์ระหว่างกันหรือไม่โดยการประมาณค่าสมการถดถอยแล้วทดสอบนัยสำคัญหรือทดสอบที ซึ่งเราจะปฏิเสธสมมุติฐานหลักที่ว่า  $\rho = 0$  หากค่าสัมบูรณ์ของทีสูงกว่าค่าวิกฤติ อย่างไรก็ตาม ในทางปฏิบัติเราไม่ทราบค่าตัวรบกวนมีค่าเท่าใด เราจะใช้เรซิดิวของสมการถดถอยอนุกรมเวลา เป็นตัวแทน นอกจากนี้การทดสอบโดยใช้รูปแบบออโตรีเกรสซีฟอันดับหนึ่งยังสามารถค้นพบความสัมพันธ์ที่อยู่ห่างกันมากกว่าหนึ่งคาบได้ด้วยเช่นกัน ในกรณีที่ตัวรบกวนสัมพันธ์กับตัวแปรอธิบายในสมการอนุกรมเวลา การทดสอบออโตคอร์เรชันจะต้องคำนึงถึงตัวแปรดังกล่าว และในการประมาณค่าสมการเพื่อทดสอบจะใช้สมการต่อไปนี้

$$\varepsilon_t = \rho \varepsilon_{t-1} + \delta_1 x_{1t} + \dots + \delta_k x_{kt} + u_t \quad (4.7)$$

แล้วทดสอบนัยสำคัญของค่าสัมประสิทธิ์  $\rho$  เราสามารถขยายการทดสอบไปยังกรณีที่ความสัมพันธ์ระหว่างตัวรบกวนมีรูปแบบที่อันดับสูงขึ้น เช่น หากตัวรบกวนมีความสัมพันธ์ในรูปแบบออโตรีเกรสซีฟอันดับ  $q$  สมการที่เราพิจารณาจะเป็นดังนี้

$$\varepsilon_t = \rho_1 \varepsilon_{t-1} + \dots + \rho_q \varepsilon_{t-q} + \delta_1 x_{1t} + \dots + \delta_k x_{kt} + u_t \quad (4.8)$$

โดยที่สมมุติฐานหลักที่ว่าตัวรบกวนไม่มีออโตคอร์เรชันสามารถเขียนได้ดังนี้

$$H_0 : \rho_1 = \dots = \rho_q = 0$$

ซึ่งเราสามารถทดสอบนัยสำคัญเป็นกลุ่มโดยใช้ตัวสถิติเอฟ หรือการทดสอบแอลเอ็ม โดยที่การทดสอบแอลเอ็มจะมีชื่อเรียกว่าการทดสอบ Breusch-Godfrey

**ตัวอย่างที่ 4.1** การประมาณค่าและทดสอบ Capital Asset Pricing Model

แบบจำลองแคพเอ็ม ซึ่งถูกนำเสนอโดย Sharp, Litner และ Mosen เป็นแบบจำลองซึ่งใช้อธิบายผลตอบแทนส่วนเกิน (Excess return) ของหลักทรัพย์ด้วยผลตอบแทนส่วนเกินของตลาดซึ่งสามารถเขียนเป็นสมการ

$$r_{it} - r_{ft} = \alpha_i + \beta_i(r_{mt} - r_{ft}) + \varepsilon_{it}, \quad i = 1, \dots, N; t = 1, \dots, T \quad (4.9)$$


โดยที่  $r_{it}$  คืออัตราผลตอบแทนของสินทรัพย์  $i$  ( $i = 1, \dots, N$ ) ระหว่างเวลาที่  $t-1$  ถึง  $t$ ,  $r_{mt}$  คืออัตราผลตอบแทนของตลาดระหว่างเวลาที่  $t-1$  ถึง  $t$  และ  $r_{ft}$  คืออัตราผลตอบแทนของสินทรัพย์ที่ไม่มีความเสี่ยงระหว่างเวลาที่  $t-1$  ถึง  $t$  สมมติให้  $\varepsilon_t$  มีการแจกแจงแบบปกติ  $N(0, \sigma_i^2)$  โดยทั่วไปผลตอบแทนของตลาดจะใช้ตะกร้าการลงทุนที่เลียนแบบดัชนีของตลาดเช่นดัชนี SET และผลตอบแทนของสินทรัพย์ที่ไม่มีความเสี่ยงจะเป็นอัตราผลตอบแทนของพันธบัตรรัฐบาล ที่ดูลักษณะ

$$E(r_{it}) - r_{ft} = \beta_i(E(r_{mt}) - r_{ft})$$

สมการแสดงว่าค่าชดเชยความเสี่ยง (risk premium) ของหลักทรัพย์  $i$  จะเท่ากับ  $\beta_i$  นอกจากนี้แคพเอ็มยังอนุมานต่อไปว่า  $\alpha_i = 0$

เราต้องการประมาณค่าสมการแคพเอ็ม 4.9 สำหรับหุ้นพีที (PPT) โดยพิจารณาผลตอบแทนส่วนเกินรายเดือนระหว่างเดือนกุมภาพันธ์ 2002 ถึงเมษายน 2020 และใช้ดัชนีตลาดหลักทรัพย์แห่งประเทศไทยในการคำนวณผลตอบแทนของตลาด และอัตราดอกเบี้ยตราสารหนี้ 30 วันของรัฐบาลเป็นอัตราดอกเบี้ยที่ไม่มีความเสี่ยง ตัวแปร  $ppt$  และ  $set$  เป็นอัตราผลตอบแทนส่วนเกินของหุ้นพีทีและตลาด และจัดเก็บในไฟล์ capm เราสามารถพิจารณาข้อมูลเบื้องต้นได้จากคำสั่งต่อไปนี้

```
1 > data<-read.csv("https://raw.githubusercontent.com/chaleampong/EC435/master/capm.csv")
2 > plot.ts(data$set, ylab="%")
3 > lines(data$ppt, col=2, lty=2)
4 > legend("bottomleft", legend= c("SET", "PTT"), col = 1:2, lty = 1:2)
```



รูปที่ 4.1: ผลตอบแทนส่วนเกินของหุ้นพีทีทีและตลาด

จากรูปจะเห็นได้ว่าผลตอบแทนส่วนเกินมีลักษณะเป็นอนุกรมนิ่ง และมีทิศทางไปในทางเดียวกัน การประมาณค่าสมการเคพเอ็มด้วย OLS จะใช้คำสั่งต่อไปนี้

```
1 > capm_ptt<-lm(ptt~set, data=data)
2 > summary(capm_ptt)
3
4 Call:
5 lm(formula = ptt ~ set, data = data)
6
7 Residuals:
8     Min       1Q   Median       3Q      Max
9 -8.763 -1.405 -0.286  1.120 14.405
10
11 Coefficients:
12             Estimate Std. Error t value Pr(>|t|)
13 (Intercept)  -0.8319     0.1777   -4.68 5.1e-06 ***
14 set           0.5472     0.0292  18.72 < 2e-16 ***
15 ---
16 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
17
18 Residual standard error: 2.54 on 213 degrees of freedom
19 Multiple R-squared:  0.622,    Adjusted R-squared:  0.62
20 F-statistic: 351 on 1 and 213 DF, p-value: <2e-16
```

ค่าประมาณของ  $\beta$  สำหรับหุ้นพีทีที เท่ากับ 0.55 แสดงว่าหุ้นพีทีทีมีความเสี่ยงน้อยกว่าตลาด ในกรณีของหุ้นพีทีที ค่าประมาณของ  $\alpha$  อนุมานได้ว่าค่า  $\alpha$  มีค่าไม่เท่ากับศูนย์

เราสามารถทดสอบข้อสมมุติของการประมาณค่าโอแอลเอส โดยใช้คำสั่ง `bptest` สำหรับการทดสอบเฮเทอโรสเกดาสติซิตีและ `bgtest` สำหรับการทดสอบออโตคอร์เรชันในชุดคำสั่ง `LMTEST`

```
1 > bptest(capm_ptt)
2
3      studentized Breusch-Pagan test
4
5 data:  capm_ptt
```

```

6 BP = 3.9157, df = 1, p-value = 0.04784
7
8 > bgtest(capm_ptt, order=1)
9
10 Breusch-Godfrey test for serial correlation of order up to 1
11
12 data: capm_ptt
13 LM test = 2.5031, df = 1, p-value = 0.1136

```

สำหรับการทดสอบเฮเทอโรสเกดาสติซิตี ค่าพืมีค่าเท่ากับ  $0.048 < 0.05$  (ระดับนัยสำคัญ 5 %) เราสามารถปฏิเสธสมมติฐานหลักที่ว่าตัวรบกวนมีค่าความแปรปรวนคงที่ และสรุปว่าเราเผชิญกับปัญหาเฮเทอโรสเกดาสติซิตี ในส่วนของการทดสอบออโตคอร์เรชัน เรากำหนดค่าล่าที่พิจารณาเท่ากับหนึ่ง และได้ค่าพืเท่ากับ  $0.114$  ซึ่งมากกว่า  $0.05$  เราไม่สามารถปฏิเสธสมมติฐานหลักที่ว่าตัวรบกวนไม่มีสหสัมพันธ์ระหว่างกัน อย่างไรก็ตาม ที่ระดับนัยสำคัญที่สูงกว่าเล็กน้อย เช่น  $0.15$  เราจะพบว่าตัวรบกวนมีออโตคอร์เรชัน และหากประมาณค่าเรชิติวด้วยรูปแบบ  $AR(1)$  จะพบว่าค่าสัมประสิทธิ์  $\rho$  ประมาณ  $0.11$

```

1 > library(dynlm)
2 > eps<-ts(eps, start=c(2002,3), frequency = 12)
3 > dynlm(eps~L(eps)-1)
4
5 Time series regression with "ts" data:
6 Start = 2002(4), End = 2020(1)
7
8 Call:
9 dynlm(formula = eps ~ L(eps) - 1)
10
11 Coefficients:
12 L(eps)
13 0.1076

```

## 4.2 สมการถดถอยแบบพลวัต

ในกรณีที่เราพิจารณาความสัมพันธ์ของตัวแปรด้วยข้อมูลอนุกรมเวลา เราสามารถผนวกค่าล่าของตัวแปรตามและตัวแปรอธิบายเพื่อพิจารณาความสัมพันธ์ในลักษณะพลวัตระหว่างตัวแปรที่เราสนใจ เรียกว่าแบบจำลอง Autoregressive Distributed Lag (ARDL) ซึ่งแสดงได้ดังสมการ

$$y_t = \alpha + \sum_{j=1}^p \phi_j y_{t-j} + \sum_{j=1}^{q_1} \beta_{1j} x_{1t-j} + \dots + \sum_{j=1}^{q_k} \beta_{kj} x_{kt-j} + \epsilon_t \quad (4.10)$$

เพื่อความเข้าใจแบบจำลองดังกล่าว เราจะพิจารณาแบบจำลองสองตัวแปรซึ่งมีค่าล่าย้อนไปแค่ช่วงเวลาเดียว

$$y_t = \alpha + \phi y_{t-1} + \beta_0 x_t + \beta_1 x_{t-1} + \epsilon_t \quad (4.11)$$

โดยที่  $x_t$  เป็นตัวแปรนิ่ง และ  $\epsilon_t \sim WN(0, \sigma^2)$  ซึ่งเราเรียกสมการดังกล่าวว่า  $ARDL(1,1)$

เราสามารถเขียนแบบจำลอง  $ARDL(1,1)$  ในรูปของ  $AR(1)$

$$y_t = \alpha + \phi y_{t-1} + w_t$$

โดยที่  $w_t = \beta_0 + \beta_1 x_t + \epsilon_t$  เป็นตัวรวมความผิดพลาด (composite error) จะเห็นได้ว่า  $y_t$  ซึ่งเป็น  $ARDL(1,1)$  จะเป็นตัวแปรนิ่งก็ต่อเมื่อ  $|\phi| < 1$  ซึ่งหากตัวแปร  $y_t$  เป็นตัวแปรนิ่ง เราสามารถเขียน  $ARDL(1,1)$  ในรูปต่อไปนี้

$$y_t = \mu + \sum_{j=0}^{\infty} \psi_j w_{t-j} \quad (4.12)$$

โดยที่  $\mu = \frac{1}{1-\phi}$  และ  $\psi_j = \phi^j$  และเมื่อแทนค่า  $w_{t-j}$  ลงในสมการ (4.12) จะได้

$$y_t = \mu + \beta_0 x_t + (\beta_1 + \phi \beta_0) x_{t-1} + \phi(\beta_1 + \phi \beta_0) x_{t-2} + \dots \quad (4.13)$$

จากสมการ (4.13) เราสามารถพิจารณาผลของตัวแปรอธิบายต่อตัวแปรตามในแต่ละช่วงเวลาได้ โดยที่ผลของ  $x_t$  ต่อ  $y_t$  ในช่วงเวลาเดียวกันเราเรียกว่า *ตัวทวีคูณผลกระทบทันที* (*immediate impact multiplier*) และคำนวณได้ด้วย

$$\frac{\partial y_t}{\partial x_t} = \beta_0$$

ในขณะที่ตัวทวีคูณล่า (lag multiplier) หนึ่งช่วงเวลา คำนวณได้จาก

$$\frac{\partial y_t}{\partial x_{t-1}} = \beta_1 + \phi \beta_0$$

และเขียนเป็นรูปทั่วไปสำหรับตัวทวีคูณล่า  $k$  ช่วงเวลา คำนวณได้จาก

$$\frac{\partial y_t}{\partial x_{t-k}} = \phi^{k-1} (\beta_1 + \phi \beta_0)$$

เมื่อเรารวมตัวทวีคูณล่าในหลายช่วงเวลาเราจะเรียกว่าเป็นตัวทวีคูณระยะปานกลาง (intermediate multiplier) และถ้าหากเรารวมตัวทวีคูณล่าทุกช่วงเวลาเข้าด้วยกันจะได้ผลกระทบระยะยาว (long-run effect) ซึ่งคำนวณได้ดังนี้

$$\text{long run effect} = \frac{\partial y_t}{\partial x_{t-1}} + \frac{\partial y_t}{\partial x_{t-2}} + \frac{\partial y_t}{\partial x_{t-3}} + \dots = \sum_{k=0}^{\infty} \phi^k (\beta_1 + \phi \beta_0) = \frac{\beta_1 + \phi \beta_0}{1 - \phi}$$

การประยุกต์ใช้สมการ (4.11) เราอาจจะพิจารณาผลกระทบของการเปลี่ยนแปลงปริมาณเงิน ( $x_t$ ) กับ อัตราเงินเฟ้อ ( $y_t$ ) ซึ่งส่งผลทั้งระยะสั้นและระยะยาว ซึ่งมีตัวทวีคูณที่แตกต่างกัน

#### ตัวอย่างที่ 4.2 การประยุกต์สมการถดถอยแบบพลวัตกับแคฟเอ็ม

เราใช้ข้อมูลต่อเนื่องจากตัวอย่างที่ผ่านมา เพื่อความสะดวกในการสร้างตัวแปรที่เป็นค่าล่า เราจะใช้ชุดคำสั่ง `DYNLM` ในการประมาณค่าสมการถดถอย โดยเราสามารถระบุตัวแปรที่เราใช้เป็นข้อมูลอนุกรมเวลาโดยใช้คำสั่ง `ts` แล้วระบุตัวแปรที่ต้องการกำหนดเช่น `data$ptt` จุดเริ่มต้นของข้อมูล ในที่นี้คือ เดือน 2 ปี 2002 โดยการระบุ `start=c(2002, 2)` และความถี่ `frequency=12` เราสามารถประมาณค่าสมการ  $ARDL(1,1)$  สำหรับผลได้ตอบแทนของหุ้น ปตท. ได้จากสมการ

$$r_t - r_{ft} = \alpha + \phi_1(r_{t-1} - r_{f,t-1}) + \beta_0(r_{mt} - r_{ft}) + \beta_1(r_{m,t-1} - r_{f,t-1}) + \varepsilon_t$$

ด้วยคำสั่ง `dynlm` โดยการระบุค่าล่าด้วย `L( )`

```

1
2 > library(dynlm)
3 > head(data)
4 > ptt<-ts(data$ptt, start=c(2002,2), frequency = 12)
5 > set<-ts(data$set, start=c(2002,2), frequency = 12)
6 > m2<-dynlm(ptt~L(ptt)+set+L(set))
7 > summary(m2)
8
9 Time series regression with "ts" data:
10 Start = 2002(3), End = 2019(12)
11
12 Call:
13 dynlm(formula = ptt ~ L(ptt) + set + L(set))
14
15 Residuals:
16     Min       1Q   Median       3Q      Max
17 -8.873 -1.439 -0.244  1.141 13.829
18
19 Coefficients:
20             Estimate Std. Error t value Pr(>|t|)
21 (Intercept)  -0.6632     0.1891  -3.51  0.00056 ***
22 L(ptt)         0.1074     0.0681   1.58  0.11614
23 set           0.5457     0.0299  18.28 < 2e-16 ***
24 L(set)        -0.0150     0.0480  -0.31  0.75569
25 ---
26 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
27
28 Residual standard error: 2.51 on 210 degrees of freedom
29 Multiple R-squared:  0.635, Adjusted R-squared:  0.63
30 F-statistic: 122 on 3 and 210 DF, p-value: <2e-16

```

จากผลการประมาณค่าพบว่าค่าเบต้าในระยะสั้นของหุ้น ปตท. ( $\beta_0$ ) มีค่าเท่ากับ 0.55 และเบต้าในระยะยาวจะเท่ากับ  $\frac{\hat{\beta}_0 + \hat{\beta}_1}{1 - \hat{\phi}} = \frac{0.53}{1 - 0.11} \approx 0.56$  อย่างไรก็ตามจะเห็นได้ว่าการทดสอบสมมติฐานของตัวแปรล่าของทั้งสองตัวแปร ( $\phi$  และ  $\beta_1$ ) มีค่าไม่แตกต่างจากศูนย์อย่างมีนัยสำคัญ แสดงว่าข้อมูลไม่ได้สนับสนุนแบบจำลองแคฟเอ็มที่เป็นพลวัต



### 4.3 การอ้างอิงทางสถิติกรณีที่เรชิตัวไม่เป็นไปตามข้อสมมติ

ในการประยุกต์ ส่วนมากเรามักจะพบว่าเรชิตัว  $\varepsilon_t$  มักจะไม่เป็นไปตามข้อสมมติที่ว่าค่าความแปรปรวนคงที่ และเป็นอิสระจากเรชิตัวในช่วงเวลาอื่น หากเรายังคงรักษาข้อสมมติที่ว่าเรชิตัวเป็นอิสระจากตัวแปรอธิบาย  $x_t$  ตัวประมาณค่า  $\hat{\beta}$  ยังคงเป็นตัวประมาณค่าที่คล่องจอง (consistent) อย่างไรก็ตามค่าความแปรปรวนของ  $\hat{\beta}$  ไม่ได้ต่ำที่สุดในบรรดาตัวประมาณค่าเชิงเส้นตรงอื่น (inefficient) และค่าความแปรปรวนของ  $\hat{\beta}$  จากสูตร  $\sigma^2(X'X)^{-1}$  ไม่ถูกต้อง หากนำค่าดังกล่าวไปใช้ในการอ้างอิงทางสถิติจะได้ผลสรุปที่ผิดพลาด ถ้าหากเราทราบว่ารูปแบบของเฮเทอโรสเกดาสติซิตี (heteroskedasticity) และออโตคอรีเรชัน (autocorrelation) เราสามารถแก้ไขปัญหาค่าความแปรปรวน และได้ตัวประมาณค่าที่มีประสิทธิภาพ (efficient) จากการประมาณค่าด้วยวิธีการ Generalized Least Squares (GLS) โดยทั่วไปเราไม่ทราบว่ารูปแบบของเรชิตัวเป็นอย่างไร ทั้งเฮเทอโรสเกดาสติซิตีและออโตคอรีเรชัน เรามักจะใช้วิธีการในการปรับค่าสแตนด์ดาร์ดแอโรให้ถูกต้อง โดยมีวิธีการดังนี้ เพื่อความง่ายเราจะพิจารณากรณีที่ตัวแปรอธิบายตัวแปรเดียวดังสมการต่อไปนี้

$$y_t = \beta_0 + \beta_1 x_t + \varepsilon_t \quad (4.14)$$

ตัวประมาณค่าของ  $\beta_1$  สามารถคำนวณได้ด้วย

$$\hat{\beta}_1 = \frac{\sum_{t=1}^T (x_t - \bar{x})(y_t - \bar{y})}{\sum_{t=1}^T (x_t - \bar{x})^2} \quad (4.15)$$

ซึ่งสามารถเขียนได้เป็น

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{t=1}^T (x_t - \bar{x})\varepsilon_t}{\sum_{t=1}^T (x_t - \bar{x})^2} \quad (4.16)$$

และสามารถหาค่าความแปรปรวนของ  $\hat{\beta}_1$  ได้จากสมการต่อไปนี้

$$\begin{aligned} Var(\hat{\beta}_1|X) &= Var\left(\beta_1 + \frac{\frac{1}{T} \sum_{t=1}^T (x_t - \bar{x})\varepsilon_t}{\frac{1}{T} \sum_{t=1}^T (x_t - \bar{x})^2} \middle| X\right) \\ &= \frac{Var\left(\frac{1}{T} \sum_{t=1}^T (x_t - \bar{x})\varepsilon_t \middle| X\right)}{\left(\frac{1}{T} \sum_{t=1}^T (x_t - \bar{x})^2\right)^2} \end{aligned} \quad (4.17)$$

โดยที่ตัวเศษของสมการ 4.17 สามารถเขียนในรูปต่อไปนี้

$$\begin{aligned} Var\left(\frac{1}{T} \sum_{t=1}^T (x_t - \bar{x})\varepsilon_t \middle| X\right) &= \frac{1}{T^2} Var\left(\sum_{t=1}^T (x_t - \bar{x})\varepsilon_t \middle| X\right) \\ &= \frac{1}{T^2} \sum_{t=1}^T Var((x_t - \bar{x})\varepsilon_t | X) + \frac{1}{T^2} \sum_{t=1}^T \sum_{s=t+1}^T Cov((x_t - \bar{x})\varepsilon_t, (x_s - \bar{x})\varepsilon_s | X) \end{aligned} \quad (4.18)$$

ในกรณีที่เรสมมติให้ค่าผิดพลาดไม่มีปัญหา heteroskedasticity และ autocorrelation

$$\frac{1}{T^2} \underbrace{\sum_{t=1}^T Var((x_t - \bar{x})\varepsilon_t|X)}_{=\sigma^2 \sum_{t=1}^T (x_t - \bar{x})^2} + \frac{1}{T^2} \sum_{t=1}^T \sum_{s=t+1}^T \underbrace{Cov((x_t - \bar{x})\varepsilon_t, (x_s - \bar{x})\varepsilon_s|X)}_{=0}$$

ดังนั้น  $Var(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{t=1}^T (x_t - \bar{x})^2}$  ซึ่งนำไปคำนวณค่าสแตนด์ดาร์ดแอร์เรอของกรณี OLS ปกติ

#### 4.3.1 การปรับสแตนด์ดาร์ดแอร์เรอกรณีมีเฮเทอโรสเกดาสติซิตี

หากสมมติให้เราเผชิญเฉพาะปัญหาเฮเทอโรสเกดาสติซิตี และสมมติให้ค่าผิดพลาดไม่มีออโตคอร์เรชัน หรือพจน์ที่สองในสมการ 4.18 จะยังคงมีค่าเท่ากับศูนย์แต่ค่าความแปรปรวนของ  $\hat{\beta}_1$  จะเท่ากับ

$$Var(\hat{\beta}_1|X) = \frac{\sum_{t=1}^T (x_t - \bar{x})^2 Var(\varepsilon_t|X)}{\left(\sum_{t=1}^T (x_t - \bar{x})^2\right)^2} \quad (4.19)$$

จากสูตรดังกล่าวจะเห็นได้ว่าค่าความแปรปรวนของ  $\hat{\beta}_1$  กรณีมีเฮเทอโรสเกดาสติซิตีจะแตกต่างจากกรณีที่เป็นไปตามข้อสมมติของ OLS ดังนั้นเราจำเป็นต้องปรับค่าสแตนด์ดาร์ดแอร์เรอให้ถูกต้อง White 1980 เสนอให้ใช้  $\hat{\varepsilon}_t$  ซึ่งเป็นเรขาคณิตจากการประมาณค่าสมการตั้งต้น แล้วแทนค่าเพื่อให้ได้ตัวประมาณค่าของค่าความแปรปรวนของ  $\hat{\beta}_1$  ดังสมการ

$$\widehat{Var(\hat{\beta}_1|X)} = \frac{\sum_{t=1}^T (x_t - \bar{x})^2 \hat{\varepsilon}_t^2}{\left(\sum_{t=1}^T (x_t - \bar{x})^2\right)^2} \quad (4.20)$$

ค่ารากที่สองของตัวประมาณค่าดังกล่าวเราเรียกว่า Heteroskedasticity-robust standard error หรือ Robust standard error

#### 4.3.2 การปรับสแตนด์ดาร์ดแอร์เรอกรณีมีออโตคอร์เรชัน

Wooldridge 1989 ได้นำเสนอรูปแบบสมการในการพิจารณาการวิเคราะห์ถดถอยอนุกรมเวลาตามสมการ 4.1.2 หากเราสนใจการพิจารณาค่าความแปรปรวนของตัวประมาณค่า  $\hat{\beta}_1$  เราสามารถสร้างสมการช่วย

$$x_{1t} = \delta_0 + \delta_2 x_{2t} + \dots + \delta_k x_{kt} + r_t \quad (4.21)$$

โดยที่พจน์ค่าผิดพลาด  $r_t$  มีค่าเฉลี่ยเท่ากับศูนย์และไม่มีสหสัมพันธ์กับตัวแปร  $x_{2t}, \dots, x_{kt}$  Wooldridge แสดงให้เห็นว่าค่าความแปรปรวนของ  $\hat{\beta}_1$  มีค่าเท่ากับ

$$var(\hat{\beta}_1) = \left( \sum_{t=1}^T E(r_t^2) \right)^{-2} var \left( \sum_{t=1}^T r_t \varepsilon_t \right)$$

พจน์  $a_t = r_t \varepsilon_t$  จะขึ้นอยู่กับคุณลักษณะของค่าผิดพลาดว่ามีลักษณะเป็นออโตคอร์เรชันหรือไม่ Newey and West 1987 และ Wooldridge 1989 แสดงให้เห็นว่าค่าสแตนด์ดาร์ดแอร์เรอที่ได้ปรับออโตคอร์เรชัน (autocorrelation-robust standard error) สามารถคำนวณได้จากสูตรต่อไปนี้

$$se(\hat{\beta}_1) = \left[ \frac{se(\hat{\beta}_1)}{\hat{\sigma}} \right] \sqrt{\hat{v}} \quad (4.22)$$

โดยที่ “ $se(\hat{\beta}_1)$ ” คือค่าสแตนด์ดาร์ดแอร์เรอกรณีเป็นไปตามข้อสมมุติของ Gauss-Markov,  $\hat{\sigma}$  คือค่าประมาณของสแตนด์ดาร์ดแอร์เรอของสมการถดถอย และ  $\hat{v}$  คำนวณจากสูตร

$$\hat{v} = \sum_{t=1}^T \hat{a}_t^2 + 2 \sum_{h=1}^g [1 - h/(g+1)] \left( \sum_{t=h+1}^T \hat{a}_t \hat{a}_{t-h} \right)$$

$\hat{v}$  คือเรขาคณิตของสมการถดถอยระหว่าง  $x_{1t}$  และตัวแปรอธิบายที่เหลือ เพื่อให้เข้าใจว่า  $\hat{v}$  ได้พิจารณาความสัมพันธ์ระหว่างเรขาคณิตอย่างไร เราสามารถกำหนดให้  $g = 1$  จะได้

$$\hat{v} = \sum_{t=1}^T \hat{a}_t^2 + \sum_{t=2}^T \hat{a}_t \hat{a}_{t-1}$$

เราสามารถพิจารณาต่อไปได้อีกค่า  $g$  มีขนาดใหญ่ขึ้น เราจะมีพจน์ที่เราใช้ในการปรับออโตคอร์เรชันมากขึ้น ค่าสแตนด์ดาร์ดแอร์เรอจากสมการ 4.22 ยังช่วยในการปรับกรณีที่มีปัญหาเฮเทอโรสกีดาสติซิตี ดังนั้นในงานวิจัยที่ใช้ข้อมูลอนุกรมเวลา ค่าสแตนด์ดาร์ดแอร์เรอดังกล่าวจะถูกเรียกว่า สแตนด์ดาร์ดแอร์เรอที่ได้มีการปรับเฮเทอโรสกีดาสติซิตีและออโตคอร์เรชัน (heteroskedasticity and autocorrelation consistent (HAC) standard error) ในทางปฏิบัติประเด็นที่เราสนใจคือเราจะกำหนดค่า  $g$  เท่ากับเท่าใด โดยทางทฤษฎีแล้ว ค่า  $g$  จะแปรผันตามจำนวนตัวอย่าง ซึ่งเมื่อจำนวนตัวอย่างใหญ่ขึ้นเราควรที่จะกำหนดรูปแบบให้คล่องตัวขึ้นโดยการเพิ่มค่า  $g$  อย่างไรก็ตาม Wooldridge เสนอให้ใช้  $g$  เท่ากับ 1 หรือ 2 สำหรับข้อมูลรายปี  $g$  เท่ากับ 4 หรือ 8 สำหรับข้อมูลรายไตรมาส และ  $g$  เท่ากับ 12 หรือ 24 สำหรับข้อมูลรายเดือน ในขณะที่ Newey and West 1987 เสนอให้ใช้  $g = 4(T/100)^{2/9}$

#### ตัวอย่างที่ 4.3 การปรับค่าสแตนด์ดาร์ดแอร์เรอจากความไม่เหมาะสมของข้อสมมุติ

เราสามารถปรับค่าสแตนด์ดาร์ดแอร์เรอโดยใช้ชุดคำสั่ง **SANDWICH**<sup>a</sup> และใช้คำสั่ง **coefest** ในชุดคำสั่ง **LMTEST** ในการแสดงสแตนด์ดาร์ดแอร์เรอที่ได้ปรับจากข้อสมมุติเฮเทอโรสกีดาสติซิตีและออโตคอร์เรชัน

หลังจากที่เราประมาณค่าด้วยคำสั่ง `lm` และเก็บผลการประมาณค่าไว้ในชื่อ `capm_ptt` เราสามารถแสดงผลสแตนด์ดาร์ดแอร์เรอที่ได้ปรับเฮเทอโรสกีดาสติซิตี โดยการระบุ

`vcov = vcovHC(capm_ptt, type = "HC0")` โดยที่ HC0 ถึง HC4 เป็นการปรับเฮเทอโรสกีดาสติซิตีที่ใช้ตัวหารที่แตกต่างกัน โดยที่ HC3 ให้ผลดีที่สุดในการกรณีที่ตัวอย่างไม่มากนัก จากผลข้างล่างจะเห็นได้ว่าค่าสแตนด์ดาร์ดแอร์เรอมีค่าที่แตกต่างจากกรณีที่เป็นไปตามข้อสมมุติ อย่างไร

ก็ตามผลตอบแทนส่วนเกินของตลาดยังคงมีนัยสำคัญในการอธิบายผลตอบแทนส่วนเกินของหุ้น  
ปตท.

```
1 > library(sandwich)
2 > library(lmtest)
3 > coeftest(capm_ptt, df = Inf, vcov = vcovHC(capm_ptt, type = "HC0"))
4
5 z test of coefficients:
6
7           Estimate Std. Error z value Pr(>|z|)
8 (Intercept)  -0.8319      0.1970   -4.22 2.4e-05 ***
9 set          0.5472      0.0455  12.02 < 2e-16 ***
10 ---
11 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
12
13 > coeftest(capm_ptt, df = Inf, vcov = vcovHC(capm_ptt, type = "HC3"))
14
15 z test of coefficients:
16
17           Estimate Std. Error z value Pr(>|z|)
18 (Intercept)  -0.8319      0.2017   -4.12 3.7e-05 ***
19 set          0.5472      0.0487  11.25 < 2e-16 ***
20 ---
21 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

ในกรณีของการปรับอัตโนมัติเรชัน เราจะระบุ `vcov = NeweyWest(capm_ptt, lag=4)` จะ  
เห็นได้ว่าค่าสแตนด์ดาร์ดแอร์เรมีค่าที่สูงขึ้นกว่ากรณีที่ไม่ได้คำนึงถึงผลของอัตโนมัติเรชัน

```
1 > coeftest(capm_ptt, df = Inf, vcov = NeweyWest(capm_ptt, lag=4))
2
3 z test of coefficients:
4
5           Estimate Std. Error z value Pr(>|z|)
6 (Intercept)  -0.8319      0.2195   -3.79 0.00015 ***
7 set          0.5472      0.0502  10.91 < 2e-16 ***
8 ---
9 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

---

<sup>๕</sup> ล้อกับชื่อเรียกเมตริกซ์ค่าสแตนด์ดาร์ดแอร์เร

## 5. แบบจำลองความผันผวน

เป้าหมายที่สำคัญประการหนึ่งของการศึกษาเศรษฐมิติทางการเงินคือการศึกษาความผันผวน (volatility) ของผลตอบแทนของสินทรัพย์ โดยที่ความผันผวนจะหมายถึงความเบี่ยงเบนมาตรฐานที่มีเงื่อนไข (conditional standard deviation) ของผลตอบแทนของสินทรัพย์ ความผันผวนที่คำนวณได้ถูกนำไปใช้ประยุกต์ในการคำนวณมูลค่าความเสี่ยง (Value-at-Risk; VaR) ของการจัดการความเสี่ยง, การจัดสรรการลงทุนภายใต้วิธีการค่าเฉลี่ยค่าความแปรปรวน (mean-variance) และการเพิ่มประสิทธิภาพในการทำนาย

หัวข้อ 5.1 จะอธิบายแนวคิดเกี่ยวกับความผันผวน และเครื่องมือในการทดสอบข้อมูลว่าควรจะผนวกประเด็นความผันผวนเข้าไปในแบบจำลองหรือไม่ เราจะอธิบายแบบจำลองที่เป็นที่นิยมในการอธิบายความผันผวนได้แก่แบบจำลองอาร์ช (ARCH) และการช (GARCH) ในหัวข้อที่ 5.2 และ 5.3 ตามลำดับ หัวข้อที่ 5.4 และ 5.5 จะนำเสนอการประมาณค่าและการพยากรณ์จากแบบจำลองดังกล่าว

### 5.1 ความผันผวนของสินทรัพย์

#### 5.1.1 คุณลักษณะของความผันผวน

ปัญหาเบื้องต้นของการศึกษาความผันผวนคือเราไม่สามารถสังเกตความผันผวนของสินทรัพย์เช่นหลักทรัพย์ได้เหมือนกับการสังเกตเห็นราคาหลักทรัพย์หรือการคำนวณผลตอบแทนได้จากราคาหลักทรัพย์สิน ในอดีตนักวิชาการได้นำเสนอตัวแทนของความผันผวนเช่น หากกำหนดให้  $P_t$  เป็นราคาหลักทรัพย์ และกำหนดให้  $y_t = \Delta \ln(P_t)$  เป็นผลตอบแทน เราพบว่าอนุกรมของผลตอบแทนมักจะไม่มีสหสัมพันธ์ระหว่างกันผลตอบแทนในอดีต แต่ผลตอบแทนกำลังสอง ( $y_t^2$ ), ค่าสัมบูรณ์ของผลตอบแทน ( $|y_t|$ ), หรือค่ายกกำลังของค่าสัมบูรณ์ของผลตอบแทน ( $|y_t|^p$ ) มีสหสัมพันธ์ค่อนข้างสูง ดังนั้นในอดีตเรามักใช้ค่าดังกล่าวเป็นตัวแทนของความผันผวน อย่างไรก็ตามในปัจจุบันมีการคำนวณความผันผวนด้วยวิธีการอื่นๆเช่น ความผันผวนที่เกิดขึ้นจริง (Realized volatility) ซึ่งคำนวณจากข้อมูลที่มีความถี่สูง และความผันผวนเป็นนัย (Implied volatility) จากทฤษฎีของแบล็ค-โชลส์ (Black-Scholes)

### 5.1.2 การทดสอบลักษณะอาร์ช

ในบทที่ 3 เราสร้างแบบจำลองเส้นตรงเพื่ออธิบายผลได้ตอบแทน ( $y_t$ ) โดยใช้แบบจำลองเช่นออโตรีเกรสซีฟ หรือแบบจำลองอาร์มาในการอธิบายผลได้ตอบแทน ซึ่งเป้าหมายหลักคือการพยากรณ์ในอนาคตของ  $y_t$  โดยใช้สมการที่อธิบายค่าเฉลี่ยจากข้อมูลในอดีต (conditional mean) อย่างไรก็ตาม เราพบว่ายังมีส่วนที่แบบจำลองไม่สามารถอธิบายได้ ซึ่งเรานิยาม  $\varepsilon_t = y_t - \mu_t$  เป็นเรซิดิวของแบบจำลองที่ใช้อธิบายค่าเฉลี่ยซึ่งใช้ข้อมูลถึงช่วงเวลา  $t$  (conditional mean equation) ของผลได้ตอบแทน เราแทนค่าค่าเฉลี่ยมีเงื่อนไข (conditional mean) ด้วยสัญลักษณ์  $\mu_t$  ในบทที่ผ่านมาเราจะทดสอบว่าแบบจำลองเพียงพอที่จะอธิบายค่าเฉลี่ยหรือไม่โดยพิจารณาความสัมพันธ์ในตัวของเรซิดิว ซึ่งหากไม่หลงเหลือความสัมพันธ์แล้วแสดงว่าแบบจำลองเพียงพอในการอธิบาย  $y_t$  อย่างไรก็ตามจากการพิจารณาข้อมูลอนุกรมเวลาเราในอดีต เราพบว่าเรซิดิวของข้อมูลทางการเงินอาจมีความผันผวนซึ่งวัดด้วยค่ายกกำลังสองหรือค่าสัมบูรณ์ที่เปลี่ยนแปลงตามเวลา ซึ่งค่าความผันผวนในช่วงเวลาที่ติดกันมักจะมีความสัมพันธ์กันเช่น หากช่วงเวลาที่  $t-1$  มีความผันผวนสูง เรามักจะพบว่าช่วงเวลา  $t$  ก็จะมีค่าความผันผวนที่สูงด้วยเช่นเดียวกัน ซึ่งหากข้อมูลใด ๆ มีลักษณะดังกล่าว เราสามารถที่จะนำลักษณะดังกล่าวมาสร้างข้อมูล เพื่อใช้ในการพยากรณ์ความผันผวน ตลอดจนเพิ่มความแม่นยำในการพยากรณ์ค่าเฉลี่ยของตัวแปรที่เราสนใจ จากคุณสมบัติที่กล่าวถึง เราต้องการทดสอบว่าข้อมูลของเรามีความผันผวนที่มีความสัมพันธ์ระหว่างกันหรือไม่ ซึ่งในบทนี้เราจะนิยามว่าความผันผวนซึ่งไม่สามารถสังเกตได้นั้น สามารถคำนวณได้จากค่าความแปรปรวนมีเงื่อนไข (conditional variance) ซึ่งจะมีค่าที่ไม่คงที่ (ต่างจากบทที่ผ่านมาที่เราสมมุติให้ค่าแปรปรวนของข้อกมีค่าคงที่) ดังนั้น เราต้องการทดสอบว่าค่าความแปรปรวนเปลี่ยนแปลงตามเวลาและมีความสัมพันธ์ระหว่างกันหรือไม่ ซึ่งความสัมพันธ์ระหว่างกันที่เรามักจะพบคือความแปรปรวนมีเงื่อนไขในช่วงเวลาที่ติดกันมีความสัมพันธ์กันหรือมีความสัมพันธ์ในลักษณะออโตรีเกรสซีฟ การทดสอบที่เราพิจารณาจึงมีชื่อเรียกว่าความแปรปรวนที่ไม่คงที่ที่เปลี่ยนแปลงตามเวลาและมีความสัมพันธ์แบบออโตรี

**เกรสซีฟ (Autoregressive Conditional Heteroskedasticity) หรือเราเรียกสั้น ๆ ว่าอาร์ช(ARCH)** การทดสอบคุณลักษณะดังกล่าวคือการทดสอบว่ามีลักษณะอาร์ชหรือไม่ (ARCH effect test) ซึ่งจากแนวคิดที่ใช้ค่ายกกำลังสองของเรซิดิวเป็นตัววัดความผันผวน เราจะเชื่อว่าข้อมูลอนุกรมเวลาที่เราพิจารณามีลักษณะอาร์ชถ้าค่ายกกำลังสองของอนุกรมเวลานั้น ๆ หรือเรซิดิวมีความสัมพันธ์กัน จากแนวคิดดังกล่าวมีการทดสอบสองวิธีที่เป็นที่นิยมใช้ ได้แก่ (1) การใช้การทดสอบยุง-บ็อกซ์ (Ljung-Box) เพื่อทดสอบอนุกรมเวลา  $\varepsilon_t^2$  (McLeod and Li 1983) และ (2) การทดสอบด้วยตัวคูณลากรองจ์ (Lagrange Multiplier: LM) (Engle 1982)

วิธีแรกเป็นการทดสอบยุง-บ็อกซ์คิว (Ljung-Box  $Q(m)$ ) สำหรับค่ายกกำลังสองของเรซิดิว ( $\varepsilon_t^2$ ) โดยเราใช้  $\varepsilon_t^2$  เป็นตัวแทนค่าแปรปรวนที่เปลี่ยนแปลงตามเวลา ดังนั้นหากค่าความแปรปรวนขึ้นอยู่กับกันจะต้องมีสหสัมพันธ์ระหว่างกัน ดังนั้นเราจะตั้งสมมุติฐานหลักค่ายกกำลังสองของเรซิดิวไม่มีสหสัมพันธ์ระหว่างกันย้อนไปถึงคาบที่  $m$  หากสมมุติฐานหลักเป็นจริงแสดงว่าเรซิดิวไม่มีลักษณะอาร์ช

วิธีสองเป็นการทดสอบโดยใช้ตัวคูณลากรองจ์ โดยเราใช้  $\varepsilon_t^2$  เป็นตัวแทนของค่าความแปรปรวน ณ เวลาที่  $t$  ซึ่งหากเราต้องการทดสอบว่าค่าแปรปรวนขึ้นกับค่าแปรปรวนในอดีตหรือไม่ สามารถประมาณค่าสมการ

$$\varepsilon_t^2 = a_0 + a_1 \varepsilon_{t-1}^2 + \dots + a_m \varepsilon_{t-m}^2 + e_t \quad (5.1)$$

และพิจารณาค่าสัมประสิทธิ์ว่าต่างจากศูนย์อย่างมีนัยสำคัญเชิงสถิติหรือไม่ โดยสมมุติฐานหลักของการทดสอบคือ  $a_1 = a_2 = \dots = a_m = 0$  ซึ่งสอดคล้องกับการที่เรซิดิวไม่มีลักษณะอาร์ช เราสามารถทดสอบได้ด้วย การประมาณค่าสมการ 5.1 จะได้ค่า  $R^2$  แล้วไปคำนวณค่าสถิติ  $LM = TR^2$  โดยที่  $T$  คือจำนวนตัวอย่าง ซึ่งค่าสถิติจากการแจกแจงแบบไคสแควร์ที่องศาเสรีเท่ากับเอ็ม ( $LM \sim \chi^2_{df=m}$ ) เราจะปฏิเสธสมมุติฐานหลักถ้า ค่าสถิติสูงกว่าค่าวิกฤติ  $LM > \chi^2_{df=m}(1-\alpha)$

**ตัวอย่างที่ 5.1** การทดสอบลักษณะอาร์ชของผลได้ตอบแทนรายเดือนจากการลงทุนในตลาดหลักทรัพย์แห่งประเทศไทย

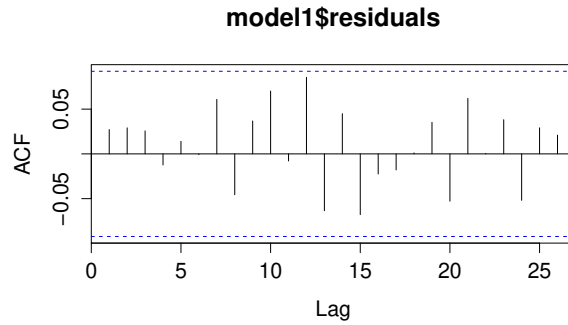
เราจะพิจารณาผลได้ตอบแทนรายเดือนในรูปล็อกของการลงทุนในตลาดหลักทรัพย์แห่งประเทศไทย โดยใช้ข้อมูลราคาปิดรายเดือนตั้งแต่ เมษายน 2518 ถึงเดือนพฤศจิกายน 2555 ซึ่งอยู่ในไฟล์ mset.csv เราสามารถสร้างอนุกรมเวลาผลได้ตอบแทนในรูปล็อกและหารูปแบบจำลองที่เหมาะสมได้ด้วยคำสั่ง auto.arima ได้แบบจำลอง ARMA(2,2) ตามที่แสดงในคำสั่งข้างล่าง

```
1 > mset <- read.csv("https://raw.githubusercontent.com/chaleampong/EC435
  /master/mset.csv", header = FALSE)
2 > head(mset)
3 > ret<-diff(log(mset$V1))
4 > library(forecast)
5 > auto.arima(ret, max.p=6, max.q=6, ic=c("aic"))
6 Series: ret
7 ARIMA(2,0,2) with zero mean
8
9 Coefficients:
10      ar1      ar2      ma1      ma2
11      1.1154 -0.9020 -1.0542  0.9141
12 s.e.  0.0511  0.0754  0.0646  0.0740
13
14 sigma^2 estimated as 0.006749: log likelihood=489.01
15 AIC=-968.03 AICc=-967.89 BIC=-947.47
```

หลังจากนั้นเราประมาณค่าแบบจำลอง ARMA(2,2) และให้ชื่อว่า m เราสามารถพิจารณาเหมาะสมของแบบจำลองได้ด้วยเอซีเอฟของเรซิดิวหรือทดสอบยุง-บ็อกซ์กับเรซิดิว

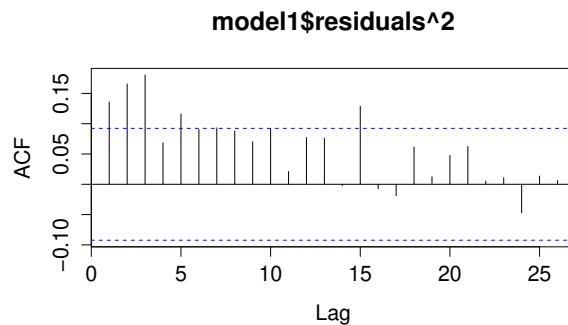
```
1 > m <- arima(ret, order=c(2,0,2))
2 > acf(m$residuals, lag.max=20)
3 > Box.test(m$residuals, lag=12, type="Ljung")
4
5      Box-Ljung test
6
7 data:  m$residuals
8 X-squared = 10.191, df = 12, p-value = 0.5992
```

จะได้



รูปที่ 5.1: ACF ของ residuals

จากรูป 5.1 และค่าสถิติยุง-บ็อกซ์มีค่าเท่ากับ 10 ซึ่งน้อยกว่าค่าวิกฤติ จะเห็นได้ว่าแบบจำลองดังกล่าวเพียงพอในการอธิบายค่าเฉลี่ยของผลได้ตอบแทน และไม่มีสหสัมพันธ์ระหว่างผลได้ตอบแทนเหลืออยู่



รูปที่ 5.2: ACF ของ residuals ยกกำลังสอง

แต่หากเราพิจารณาเอซีเอฟของค่ากำลังสองของเรซิดิว หรือทดสอบยุง-บ็อกซ์กับของค่าของเรซิดิวยกกำลังสอง หรือทดสอบลักษณะอาร์ชในรูปของสถิติแอลเอ็มจะเห็นได้ว่ายังมีลักษณะอาร์ชเหลืออยู่ในเรซิดิว ซึ่งการทดสอบลักษณะของอาร์ชด้วยสถิติแอลเอ็ม จะใช้คำสั่ง `ArchTest(series, q)` จากชุดคำสั่ง `FinTS` โดยต้องระบุ `series` ที่ต้องการทดสอบและค่า `q`

```
1 > acf(m$residuals^2, lag.max = 20)
2 > Box.test(m$residuals^2, lag=12, type="Ljung")
3       Box-Ljung test
4 data:  m$residuals^2
5 X-squared = 64.509, df = 12, p-value = 3.36e-09
6 > library(FinTS)
7 > ArchTest(ret)
8       ARCH LM-test; Null hypothesis: no ARCH effects
9 data:  ret
10 Chi-squared = 35.547, df = 12, p-value = 0.000383
```

กรณีการทดสอบยุง-บ็อกซ์ของค่าเรซิดิวยกกำลังสอง (บรรทัด 2-7) ค่า  $p < 0.0001$  เราปฏิเสธสมมติฐานที่ว่าค่ากำลังสองของเรซิดิวไม่มีสหสัมพันธ์กัน กรณีการทดสอบลักษณะอาร์ชด้วยสถิติแอลเอ็ม (บรรทัด 9-14) ค่า  $p < 0.002$  เราปฏิเสธสมมติฐานหลัก  $a_1 = a_2 = \dots = a_m = 0$  สรุปว่าเราพบว่าเรซิดิวของแบบจำลอง  $ARMA(2,2)$  มีลักษณะอาร์ช



## 5.2 แบบจำลองอาร์ช

เพื่อให้ผู้อ่านเข้าใจแรงจูงใจในการสร้างแบบจำลองอาร์ช (ARCH) ผู้เขียนขอเน้นอีกครั้งว่าแบบจำลองอนุกรมเวลาที่เรากำลังสร้างขึ้นในบทที่ผ่านมา เราพยายามที่จะอธิบายค่าในอนาคตของตัวแปรสุ่มที่เราสนใจโดยที่ค่าเฉลี่ยที่เราพยากรณ์อาจจะอยู่ในรูปค่าเฉลี่ยมีเงื่อนไข (conditional mean) หรือค่าเฉลี่ยไม่มีเงื่อนไข (unconditional mean) เช่นในกรณีแบบจำลอง  $AR(1)$  ซึ่งสามารถแสดงได้ด้วย  $y_t = \phi y_{t-1} + \varepsilon_t$  ซึ่งจากบทที่ผ่านมาเราทราบว่าค่าเฉลี่ย (ที่ไม่มีเงื่อนไข)  $E(y_t) = 0$  และค่าความแปรปรวน  $Var(y_t) = \sigma^2/(1 - \phi^2)$  ซึ่งหากใช้ค่าเฉลี่ยดังกล่าวสำหรับการทำนายไปข้างหน้าจะได้ค่าคาดการณ์ของ  $y$  เท่ากับศูนย์ แต่วิธีการพยากรณ์ที่จะทำให้ค่า MSE ต่ำที่สุดควรจะใช้ค่าเฉลี่ยมีเงื่อนไขจากแบบจำลอง  $AR(1)$  ซึ่งเท่ากับ

$$y_h(1) = E(y_{h+1}|F_h) = \phi y_h$$

และมีค่าความแปรปรวนที่มีเงื่อนไขเท่ากับ

$$Var_h(y_{h+1}) = E_h(y_{h+1} - E_h(y_{h+1}))^2 = E_h(\phi y_h + \varepsilon_{h+1} - \phi y_h)^2 = E_h(\varepsilon_{h+1}^2) = \sigma_{h+1}^2$$

โดยที่  $E_h(\cdot) = E(\cdot|F_h)$  และในบทที่ผ่านมาเราสมมติให้  $\sigma_{h+1}^2$  มีค่าคงที่

Engle 1982 ได้วิเคราะห์โมเมนต์ที่สองที่มีเงื่อนไข โดยที่สร้างแบบจำลองที่ค่าความแปรปรวนสามารถเปลี่ยนแปลงได้ตามเวลา

### 5.2.1 รูปแบบ ของแบบจำลองอาร์ชที่อันดับ q ARCH(q)

ค่าสหสัมพันธ์ในตัวของผลได้ตอบแทนกำลังสองหรือค่าความแปรปรวนมีเงื่อนไข อธิบายได้ด้วยแบบจำลอง AR ของเรซิดิวกำลังสอง ตัวอย่างเช่น กำหนดให้  $y_t$  อนุกรมเวลาหนึ่ง เช่น ผลได้ตอบแทน แล้วกำหนดให้  $y_t$  สามารถอธิบายได้ด้วยแบบจำลอง

$$y_t = \mu_t + \varepsilon_t \quad (5.2)$$

โดยที่  $\mu_t$  เป็นส่วนอธิบายค่าเฉลี่ย ซึ่งอาจจะเป็นค่าคงที่  $c$  หรือ แบบจำลอง  $ARMA(p, q)$  และ  $\varepsilon_t$  เป็นเรซิดิวที่มีค่าเฉลี่ยเท่ากับศูนย์ เพื่อที่จะให้แบบจำลองดังกล่าวมีความผันผวนเป็นกลุ่ม (volatility clustering) หรือค่าแปรปรวนมีเงื่อนไขเปลี่ยนแปลงตามเวลา เราจะสมมติให้ค่าความแปรปรวนมีเงื่อนไขขึ้นอยู่กับข้อมูล ณ คาบที่  $t-1$   $Var_{t-1} = \sigma_t^2$  เขียนเป็นสมการต่อไปนี้

$$\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_q \varepsilon_{t-q}^2 \quad (5.3)$$

เนื่องจาก  $\varepsilon_t$  มีค่าเฉลี่ยเท่ากับศูนย์  $Var_{t-1}(\varepsilon_t) = E_{t-1}(\varepsilon_t^2) = \sigma_t^2$  ดังนั้นเราสามารถเขียนสมการ (5.3) ได้เป็น

$$\varepsilon_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_q \varepsilon_{t-q}^2 + u_t \quad (5.4)$$

โดยที่  $u_t = \varepsilon_t^2 - E_{t-1}(\varepsilon_t^2)$  ซึ่งเป็นกระบวนการไวท์นอยซ์ที่มีค่าเฉลี่ยเท่ากับศูนย์ สมการ (5.2),(5.3) และ (5.4) รวมกันเรียกว่าความแปรปรวนที่ไม่คงที่เปลี่ยนแปลงตามเวลาและมีความสัมพันธ์แบบออโตรีเกรสซีฟ (Autoregressive Conditional Heteroskedasticity) หรือ แบบจำลองอาร์ชที่อันดับ  $q$  ( $ARCH(q)$ )

รูปแบบของ  $ARCH(q)$  อีกแบบจำลองสามารถแสดงได้ดังนี้

$$\begin{aligned} y_t &= \mu_t + \varepsilon_t \\ \varepsilon_t &= z_t \sigma_t \\ \sigma_t^2 &= \omega + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_q \varepsilon_{t-q}^2 \end{aligned} \quad (5.5)$$

โดยที่  $z_t$  เป็นตัวแปรสุ่มเป็นอิสระและเหมือนกันที่มีค่าเฉลี่ยเท่ากับศูนย์และค่าความแปรปรวนเท่ากับหนึ่ง,  $iid(0,1)$  ตัวอย่างเช่น การแจกแจงปกติมาตรฐาน

### 5.2.2 คุณสมบัติของอาร์ชที่อันดับหนึ่ง

เพื่อให้ผู้อ่านเข้าใจแบบจำลองอาร์ช เราจะมาพิจารณาคูณสมบัติของแบบอาร์ชที่อันดับหนึ่ง ( $ARCH(1)$ ) สมมติว่าให้  $y_t$  มีคุณสมบัติตามแบบจำลอง  $ARCH(1)$  โดยที่

$$y_t = \varepsilon_t \quad (5.6)$$

$$\varepsilon_t = z_t \sigma_t \quad (5.7)$$

และ

$$\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 \quad (5.8)$$

หากเรายกกำลังสองทั้งสองข้างของ (5.7) แล้วสลับข้างสมการ (5.8) แล้วนำมาลบจะได้

$$\begin{aligned} \varepsilon_t^2 - \omega - \alpha_1 \varepsilon_{t-1}^2 &= (z_t^2 - 1) \sigma_t^2 \\ \varepsilon_t^2 &= \omega + \alpha_1 \varepsilon_{t-1}^2 + (z_t^2 - 1) \sigma_t^2 \end{aligned}$$

ซึ่งเป็นแบบจำลองของ  $\varepsilon_t^2$  ในรูปออโตรีเกรสซีฟ โดยที่  $u_t = (z_t^2 - 1) \sigma_t^2$  และจากความสัมพันธ์ที่  $y_t^2 = \varepsilon_t^2$  เราสามารถสรุปได้ว่า  $ARCH(1)$  สามารถเขียนในรูปกำลังสองของ  $y_t$  ได้

ค่าเฉลี่ยที่ไม่มีเงื่อนไขของ  $\varepsilon_t$  เท่ากับศูนย์ ซึ่งการคำนวณสามารถแสดงได้ดังนี้

$$\begin{aligned} E(\varepsilon_t) &= E(E(\varepsilon_t | F_{t-1})) = E(E(z_t \sigma_t | F_{t-1})) \\ &= E(\underbrace{\sigma_t E(z_t | F_{t-1})}_{=0}) = 0 \end{aligned}$$

โดยสมการแรกใช้กฎของค่าคาดหวังซ้ำ (Law of Iterated Expectation)

ค่าความแปรปรวนไม่มีเงื่อนไขของ  $\varepsilon_t$  สามารถคำนวณได้ด้วย

$$\begin{aligned} Var(\varepsilon_t) &= E(\varepsilon_t^2) = E(E(\varepsilon_t^2|F_{t-1})) \\ &= E(E(z_t^2 \sigma_t^2|F_{t-1})) \\ &= E(\underbrace{\sigma_t^2 E(z_t^2|F_{t-1})}_{=1}) \\ &= E(\omega + \alpha_1 \varepsilon_{t-1}^2) = \omega + \alpha_1 E(\varepsilon_{t-1}^2) \end{aligned}$$

หากต้องการให้  $\varepsilon_t$  เป็นกระบวนการคงที่  $Var(\varepsilon_t) = E(\varepsilon_t^2) = E(\varepsilon_{t-1}^2)$  ดังนั้น  $Var(\varepsilon_t) = \frac{\omega}{1-\alpha_1}$  และเงื่อนไขที่จะทำให้ค่าความแปรปรวนไม่มีเงื่อนไขเป็นบวกคือ  $0 \leq \alpha_1 < 1$

ในทางปฏิบัติ เราต้องการทราบว่าค่าโมเมนต์ที่สูงกว่าโมเมนต์ที่สองเป็นอย่างไร ภายหลังจากการดำเนินการบางอย่างเราพบว่า โมเมนต์ที่สี่เท่ากับ

$$E(\varepsilon^4) = 3 \frac{\omega(1+\alpha_1)}{(1-\alpha_1)(1-3\alpha_1^2)} \quad (5.9)$$

ดังนั้นเงื่อนไขที่ทำให้โมเมนต์ที่สี่มีค่าจำกัดคือ  $0 \leq \alpha_1 < 1/3$  และค่าความโด่งเท่ากับ

$$\kappa = \frac{E(\varepsilon_t^4)}{[Var(\varepsilon_t)]^2} = 3 \frac{\omega(1+\alpha_1)}{(1-\alpha_1)(1-3\alpha_1^2)} \times \frac{(1-\alpha_1)^2}{\omega^2} = 3 \frac{1-\alpha_1^2}{1-3\alpha_1^2} \quad (5.10)$$

ซึ่งค่าความโด่งจะมากกว่าสามเสมอ แสดงว่าการแจกแจงของช็อกในแบบจำลองอาร์ชจะมีหางที่อ้วนกว่าปกติ

### 5.2.3 การประมาณค่าแบบจำลองอาร์ชอันดับหนึ่ง

การประมาณค่าพารามิเตอร์ในแบบจำลองอาร์ชอันดับหนึ่ง  $ARCH(1)$  สามารถดำเนินการได้ด้วยวิธีการหาค่าสูงสุดของภาวะความน่าจะเป็นสูงสุดแบบมีเงื่อนไข หากสมมติให้  $z_t$  มีการแจกแจงแบบปกติมาตรฐาน จากสมการ (5.7) เราจะได้  $\varepsilon_t \sim N(0, \sigma_t^2)$  และฟังก์ชันภาวะความน่าจะเป็นในรูปล็อกจะเท่ากับ

$$\begin{aligned} \ln L(\omega, \alpha_1; \mathbf{y}) &= \sum_{t=1}^T \ln f(\varepsilon_t | \varepsilon_{t-1}) \\ &= -\frac{1}{2} \sum_{t=1}^T \ln(2\pi) - \frac{1}{2} \sum_{t=1}^T \ln(\sigma_t^2) - \sum_{t=1}^T \left( \frac{y_t^2}{2\sigma_t^2} \right) \end{aligned} \quad (5.11)$$

โดยที่ค่า  $\varepsilon_0$  และ  $\sigma_0^2$  เท่ากับค่าเฉลี่ย เราสามารถหาตัวประมาณค่าพารามิเตอร์ได้จากการหาค่าสูงสุดของสมการ (5.11) อย่างไรก็ตามเราสามารถกำหนดการแจกแจงรูปแบบอื่นที่มีค่าเฉลี่ยเท่ากับศูนย์และค่าความแปรปรวนเท่ากับหนึ่ง เช่นการแจกแจงแบบที่มาตรฐาน (standardized student's t distribution)

### 5.3 แบบจำลองการชที่อันดับ $p, q$

ถ้าเราทดสอบลักษณะอาร์ชด้วยตัวทดสอบ เช่นตัวทดสอบแอลเอ็ม แล้วพบว่าอนุกรมเวลามีลักษณะอาร์ช เราสามารถใช้แบบจำลองการชที่อันดับ  $q$  ใด ๆ  $ARCH(q)$  เพื่อประมาณค่าความผันผวนที่เปลี่ยนแปลงตามเวลา (time varying volatility:  $\sigma_t^2$ ) ซึ่งขึ้นอยู่กับข้อมูลในอดีต อย่างไรก็ตามในทางปฏิบัติ ค่า  $q$  ที่เหมาะสมสำหรับแบบจำลอง  $ARCH(q)$  ค่อนข้างที่จะยาว ส่งผลต่อจำนวนพารามิเตอร์ที่ต้องประมาณค่าและความเหมาะสมของแบบจำลอง ดังนั้น Bollerslev 1986 ได้เสนอรูปแบบของสมการความแปรปรวนเป็น

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2 \quad (5.12)$$

โดยที่มีเงื่อนไขค่าสัมประสิทธิ์  $\alpha_i$  ( $i = 1, \dots, q$ ) และ  $\beta_j$  ( $j = 1, \dots, p$ ) มีค่าเป็นบวกเพื่อให้ค่าแปรปรวนเป็นบวก โดยที่สมการที่ (5.2) และ (5.12) รวมกันเรียกว่าแบบจำลองเจนอรัลไลส์อาร์ช (Generalized ARCH) หรือการชที่อันดับ  $p, q$  ( $GARCH(p, q)$ ) และหากค่า  $p = 0$  แบบจำลองดังกล่าวจะลดรูปเหลือแค่  $ARCH(q)$

ในแบบจำลอง  $GARCH(p, q)$  ค่าความแปรปรวนที่มีเงื่อนไข จะขึ้นอยู่กับค่ากำลังสองของค่าส่วนเกิน (squared residuals) ในช่วง  $q$  คาบก่อน และ ค่าความแปรปรวนที่มีเงื่อนไขในช่วง  $p$  คาบก่อน อย่างไรก็ตามโดยปกติแล้ว แบบจำลอง  $GARCH(1, 1)$  ก็เพียงพอที่จะใช้อธิบายอนุกรมเวลาทางการเงิน

#### 5.3.1 การเขียนแบบจำลองการชในรูปอาร์มา

ในขณะที่แบบจำลองการชที่สามารถเขียนให้อยู่ในรูปของแบบจำลองออโตรีเกรสซีฟของค่าเรซิดิวยกกำลังสอง แบบจำลองการชสามารถเขียนให้อยู่ในรูปของแบบจำลองอาร์มาของเรซิดิวยกกำลังสอง ตัวอย่างเช่นในแบบจำลองการชอันดับ (1,1) ( $GARCH(1, 1)$ ) ซึ่งอยู่ในรูปสมการต่อไปนี้

$$\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2 \quad (5.13)$$

เนื่องจาก  $E_{t-1}(\varepsilon_t^2) = \sigma_t^2$  ดังนั้นสมการ 5.13 สามารถเขียนใหม่ได้เป็น

$$\varepsilon_t^2 = \omega + (\alpha_1 + \beta_1) \varepsilon_{t-1}^2 + u_t - \beta_1 u_{t-1} \quad (5.14)$$

ซึ่งเป็นแบบจำลอง  $ARMA(1, 1)$  โดยที่  $u_t = \varepsilon_t^2 - E_{t-1}(\varepsilon_t^2)$  เป็นตัวแปรช็อกไวท์นอยซ์

แบบจำลองการชในรูปแบบของอาร์มาการชได้ง่ายตัวอย่างเช่นการชที่อันดับ (1,1) จะเป็นอนุกรมคงที่ถ้า  $\alpha_1 + \beta_1 < 1$  เนื่องจาก  $\varepsilon_t^2$  อยู่ในรูป  $AR(1)$  และ  $\alpha_1 + \beta_1$  คือสัมประสิทธิ์ของ  $\varepsilon_{t-1}^2$  ซึ่งจะต้องมีค่าน้อยกว่าหนึ่ง (อย่าลืมว่า  $\alpha_1$  และ  $\beta_1$  จะต้องมีความมากกว่าศูนย์)

หากเราสมมติให้แบบจำลองเป็นอนุกรมนิ่ง เราสามารถหาความแปรปรวนที่ไม่มีเงื่อนไขของ  $\varepsilon_t$  จะเท่ากับ

$Var(\varepsilon_t) = E(\varepsilon_t^2) = \omega/(1 - \alpha_1 - \beta_1)$  เนื่องจาก

$$E(\varepsilon_t^2) = \omega + (\alpha_1 + \beta_1) \underbrace{E(\varepsilon_{t-1}^2)}_{=E(\varepsilon_t^2)}$$

$$E(\varepsilon_t^2) = \omega + (\alpha_1 + \beta_1)E(\varepsilon_t^2)$$

ในกรณี  $GARCH(p, q)$  เราสามารถแสดงให้เห็นว่าเราสามารถเขียนแบบจำลองดังกล่าวให้อยู่ในรูป  $ARMA(\max(p, q), p)$  ของเรซิดิวยกกำลังสอง และแบบจำลองจะเป็นอนุกรมนิ่งถ้า  $\sum_{i=1}^q \alpha_i + \sum_{j=1}^p \beta_j < 1$  และความแปรปรวนที่ไม่มีเงื่อนไขของ  $\varepsilon_t$  จะเท่ากับ

$$Var(\varepsilon_t) = \frac{\omega}{1 - (\sum_{i=1}^q \alpha_i + \sum_{j=1}^p \beta_j)}$$

### 5.3.2 คุณสมบัติของแบบจำลองการช

ในทางปฏิบัติ นักวิจัยได้พบคุณลักษณะหลายประการของความผันผวนของข้อมูลทางการเงิน โดยที่เราสามารถใช้รูปแบบ  $ARMA$  ของ  $GARCH$  ในการแสดงคุณลักษณะต่างๆ โดยคุณลักษณะที่สำคัญสามประการคือ ความผันผวนเป็นกลุ่ม (volatility clustering), หางอ้วน (fat tails) และความผันผวนย้อนกลับมาที่ดุลงภาพ (volatility mean reversion)

#### ความผันผวนเป็นกลุ่ม (volatility clustering)

ในแบบจำลอง  $GARCH(1, 1)$  ที่แสดงในสมการที่ 5.13 ค่าที่ประมาณได้จากข้อมูลรายสัปดาห์และรายวันของ  $\beta_1$  จะมีค่าประมาณ 0.9 แสดงว่าหากค่า  $\sigma_{t-1}^2$  มีขนาดใหญ่จะทำให้  $\sigma_t^2$  มีขนาดใหญ่ด้วยเช่นเดียวกัน แต่ถ้า  $\sigma_{t-1}^2$  มีขนาดเล็กจะทำให้  $\sigma_t^2$  มีขนาดเล็ก ดังนั้นความผันผวนจะมีลักษณะที่เป็นกลุ่ม คือความผันผวนขนาดใหญ่จะอยู่ใกล้ๆกัน

#### หางอ้วน(fat tails)

ข้อมูลทางการเงินที่มีความถี่สูงจะมีหางที่อ้วนมากกว่าการแจกแจงแบบปกติ คือมีความน่าจะเป็นที่จะเกิดการเปลี่ยนแปลงขนาดใหญ่(ที่ปลายหางของการแจกแจง)มากกว่ากรณีการแจกแจงแบบปกติ Bollerslev แสดงให้เห็นว่าภายใต้เงื่อนไขบางประการ เขาสามารถแสดงให้เห็นว่า  $GARCH(1, 1)$  จะให้ค่าเคอร์โทซิสที่มากกว่า 3 ซึ่งคือค่าเคอร์โทซิสของการแจกแจงแบบปกติ ดังนั้นแบบจำลองการชสามารถเลียนแบบพฤติกรรมหางอ้วนในข้อมูลจริง

#### ความผันผวนย้อนกลับมาที่ดุลงภาพ(volatility mean reversion)

แม้ว่าความผันผวนจะสูงขึ้นในช่วงแต่สุดท้ายแล้วจะย้อนกลับไปยังดุลงภาพระยะยาว โดยที่ค่าความแปรปรวนของ  $GARCH(1, 1)$  จะเท่ากับ  $\omega/(1 - \alpha_1 - \beta_1)$  และถ้า  $\alpha_1 + \beta_1 < 1$  กระบวนการ  $GARCH(1, 1)$

จะเป็นกระบวนการนิ่ง และค่าความแปรปรวนจะกลับเข้าสู่ดุลยภาพในระยะยาว  $\omega/(1 - \alpha_1 - \beta_1)$  หรือเรียกว่า "mean reverts" กลับไปสู่ดุลยภาพระยะยาว แต่ถ้า  $\alpha_1 + \beta_1 \geq 1$  กระบวนการ  $GARCH(1,1)$  จะเป็นกระบวนการไม่นิ่ง (nonstationary)

## 5.4 การประมาณค่าแบบจำลองการช

ในหัวข้อนี้เราจะพิจารณาการประมาณค่าแบบจำลอง  $GARCH(p,q)$  โดยที่แบบจำลองสามารถเขียนในรูปแบบ

$$y_t = \mu_t + \varepsilon_t \quad (5.15)$$

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2 \quad (5.16)$$

สำหรับ  $t = 1, 2, \dots, T$  โดยที่  $\sigma_t^2 = Var_{t-1}(\varepsilon_t)$  และ  $\mu_t$  แทนแบบจำลองค่าเฉลี่ยเช่น อาจกำหนดให้เท่ากับค่าคงที่  $c$  หรือแบบจำลอง  $ARMA(p,q)$  หากเราสมมติให้  $\varepsilon_t$  มีการแจกแจงแบบปกติภายใต้ข้อมูลในอดีตเราสามารถเขียนฟังก์ชันภาวะน่าจะเป็นในรูปล็อกของแบบจำลอง  $GARCH(p,q)$  ได้

$$\log L = -\frac{1}{2} \sum_{t=1}^T \ln(2\pi) - \frac{1}{2} \sum_{t=1}^T \ln(\sigma_t^2) - \sum_{t=1}^T \left( \frac{y_t^2}{2\sigma_t^2} \right) \quad (5.17)$$

หากสมมติให้  $\mu_t = c$  ค่าพารามิเตอร์ที่ต้องประมาณค่าคือ  $c, \alpha_i (i = 1, \dots, q), \beta_j (j = 1, \dots, p)$  โดยที่หลังจากที่เราประมาณค่าพารามิเตอร์ดังกล่าวแล้ว เราจะได้ค่า  $\sigma_t$  สำหรับ  $t = 1, \dots, T$

### 5.4.1 การตรวจสอบหลังจากการประมาณค่าการช

หลังจากที่เราประมาณค่าแบบจำลองการชแล้วเราจำเป็นต้องตรวจสอบว่าแบบจำลองดังกล่าวเพียงพอต่อการอธิบายค่าเฉลี่ยที่มีเงื่อนไข และค่าความแปรปรวนที่มีเงื่อนไขหรือไม่ โดยมีพื้นฐานจากข้อสมมติที่ว่า  $z_t = \frac{\varepsilon_t}{\sigma_t} \sim iidN(0,1)$  ดังนั้นเราจำเป็นต้องทดสอบ  $z_t$  ว่ามีคุณสมบัติเป็นอิสระต่อกัน และมีการแจกแจงแบบปกติหรือไม่ โดยที่ตัวแทนของ  $z_t$  คือเรซิดิวที่ปรับให้เป็นการแจกแจงปกติมาตรฐาน (standardized residuals) ( $\hat{z}_t = \frac{\varepsilon_t}{\sigma_t}$ ) โดยเราจะทดสอบดังต่อไปนี้

ประการแรก เราจะทดสอบว่าแบบจำลองเพียงพอต่อการอธิบายค่าเฉลี่ยที่มีเงื่อนไขหรือไม่ โดยการทดสอบว่าเรซิดิวที่ปรับให้เป็นการแจกแจงปกติมาตรฐาน เป็นอิสระต่อกันหรือไม่ โดยการทดสอบยูง-บ็อกซ์ ซึ่งสมมุติฐานหลักคือเรซิดิวที่ปรับให้เป็นการแจกแจงปกติมาตรฐานเป็นอิสระต่อกัน หากเราไม่สามารถปฏิเสธสมมุติฐานหลักได้แสดงว่าแบบจำลองนั้นเพียงพอต่อการอธิบายค่าเฉลี่ยที่มีเงื่อนไข

ประการที่สอง เราจะทดสอบว่าแบบจำลองเพียงพอต่อการอธิบายความแปรปรวนแบบที่มีเงื่อนไขหรือไม่ หากแบบจำลองไม่เพียงพอต่อการอธิบายความแปรปรวนแบบมีเงื่อนไข ค่ายกกำลังสองของเรซิดิวที่ปรับให้เป็นการแจกแจงปกติมาตรฐานจะต้องมีความสัมพันธ์ระหว่างกัน ซึ่งเราสามารถทดสอบ ยูง-บ็อกซ์กับค่า

ยกกำลังสองของเรซิดิวที่ปรับให้เป็นการแจกแจงปกติมาตรฐานหรืออาจจะทดสอบลักษณะอาร์ชของเรซิดิวที่ปรับให้เป็นการแจกแจงปกติมาตรฐาน หากเราไม่สามารถปฏิเสธสมมติฐานหลักแสดงว่าแบบจำลองเพียงพอต่อการอธิบายความแปรปรวนที่มีเงื่อนไข

ประการที่สาม เราสามารถทดสอบว่าข้อสมมุติเกี่ยวกับการแจกแจงของเรซิดิวที่ปรับให้เป็นการแจกแจงปกติมาตรฐาน ที่เราสมมุติว่าการแจกแจงแบบปกติมีความสมเหตุสมผลหรือไม่ โดยตั้งสมมุติฐานหลักว่าเรซิดิวที่ปรับให้เป็นการแจกแจงปกติมาตรฐานมีการแจกแจงแบบปกติ หากเราปฏิเสธสมมติฐานหลัก เราสามารถที่จะปรับปรุงแบบจำลองโดยการสมมุติการแจกแจงอื่นที่มีความคล่องตัวมากกว่าการแจกแจงแบบปกติ ซึ่งจะนำเสนอตัวอย่างในหัวข้อต่อไป

**ตัวอย่างที่ 5.2** การสร้างแบบจำลอง GARCH ต่อจากตัวอย่างที่ผ่านมา เราประมาณค่าสมการค่าเฉลี่ยด้วย  $ARMA(2,2)$  และสมการค่าความแปรปรวนที่มีเงื่อนไขด้วย  $GARCH(1,1)$  หรือใช้สัญลักษณ์ว่า  $ARMA(2,2) - GARCH(1,1)$  โดยเราจะใช้คำสั่ง `ugarchfit` จากชุดคำสั่ง `RUGARCH` ในการประมาณค่าแบบจำลอง การซึ่งเป็นส่วนที่ประมาณค่าความแปรปรวนมีเงื่อนไขเพิ่มขึ้นจากแบบจำลองที่อธิบาย ค่าเฉลี่ยมีเงื่อนไข เช่น  $ARMA(2,2)$

ในการสร้างแบบจำลองเราจะต้องระบุรูปแบบของแบบจำลอง `ugarchspec` โดยที่ `ugarchspec` คือการระบุรูปแบบของสมการการซึ่งประกอบด้วยส่วนหลัก ๆ สามส่วนได้แก่

- `variance.model=list(model="sGARCH", garchOrder=c(1,1))` ส่วนนี้ระบุรูปแบบของค่าความแปรปรวนแบบมีเงื่อนไขเป็น **standard GARCH (sGARCH)** และอันดับ `c(1,1)` คือ **GARCH(1,1)**
- `mean.model=list(armaOrder=c(2,2), include.mean=TRUE)` ส่วนนี้ระบุรูปแบบของค่าเฉลี่ยมีเงื่อนไขเป็น **ARMA(2,2)** และมีส่วนของค่าคงที่ (`include.mean = TRUE`)
- `distribution.model = "norm"` ส่วนนี้ระบุการแจกแจงเป็นแบบปกติ

จะได้ผลดังนี้

```
1 > library(rugarch)
2 > spec.garch11 <- ugarchspec(variance.model=list(model="sGARCH",
  garchOrder=c(1,1)),
3 + mean.model=list(armaOrder=c(2,2), include.mean=TRUE), distribution.
  model="norm")
4 > fit.garch11<-ugarchfit(spec=spec.garch11, data = ret)
5 > show(fit.garch11)
6
7 *-----*
8 *           GARCH Model Fit           *
9 *-----*
10
11 Conditional Variance Dynamics
12 -----
13 GARCH Model      : sGARCH(1,1)
14 Mean Model       : ARFIMA(2,0,2)
15 Distribution      : norm
```

```

16
17 Optimal Parameters
18 -----
19      Estimate   Std. Error   t value Pr(>|t|)
20 mu      0.005168    0.003323    1.5552 0.119893
21 ar1     0.929774    0.105519    8.8114 0.000000
22 ar2    -0.741403    0.131759   -5.6270 0.000000
23 ma1    -0.885132    0.079630  -11.1155 0.000000
24 ma2     0.813870    0.126564    6.4305 0.000000
25 omega   0.000194    0.000084    2.3165 0.020528
26 alpha1  0.221012    0.045507    4.8567 0.000001
27 beta1   0.777524    0.038916   19.9795 0.000000
28
29 Robust Standard Errors:
30      Estimate   Std. Error   t value Pr(>|t|)
31 mu      0.005168    0.004069    1.2701 0.204050
32 ar1     0.929774    0.134138    6.9315 0.000000
33 ar2    -0.741403    0.245777   -3.0166 0.002557
34 ma1    -0.885132    0.082263  -10.7597 0.000000
35 ma2     0.813870    0.253515    3.2103 0.001326
36 omega   0.000194    0.000120    1.6161 0.106077
37 alpha1  0.221012    0.063004    3.5079 0.000452
38 beta1   0.777524    0.051986   14.9564 0.000000
39
40 LogLikelihood : 542.9161

```

เราสามารถแสดงผลการประมาณค่าได้โดย

$$y_t = 0.93y_{t-1} - 0.74y_{t-2} + \varepsilon_t - 0.89\varepsilon_{t-1} + 0.81\varepsilon_{t-2}$$

$$\sigma_t^2 = 0.000194 + 0.22\varepsilon_{t-1}^2 + 0.78\sigma_{t-1}^2$$

นอกจากนี้ ผลการประมาณค่ายังแสดงผลเกณฑ์คัดเลือกแบบจำลอง สำหรับการเปรียบเทียบรูปแบบแบบจำลอง

```

1 Information Criteria
2 -----
3
4 Akaike      -2.3721
5 Bayes      -2.2992
6 Shibata    -2.3727
7 Hannan-Quinn -2.3434

```

นอกจากนี้ คำสั่งดังกล่าวยังแสดงผลการทดสอบเรชิตวที่ปรับให้เป็นการแจกแจงปกติมาตรฐานดังนี้ สำหรับกรณีของเรชิตวที่ปรับให้เป็นการแจกแจงปกติมาตรฐาน หากพิจารณาที่ค่าเล่าที่ 1, 11, 19 พบว่าค่าพิน้อยกว่าระดับนัยสำคัญที่เราเลือก แสดงว่าแบบจำลองในส่วนของการค่าเฉลี่ยมีเงื่อนไขไม่สามารถอธิบายตัวแปรที่เราสนใจได้ (เราจำเป็นต้องปรับแบบจำลองในส่วนของการ ARMA(p,q))

ในขณะที่กรณีของเรชิตวที่ปรับให้เป็นการแจกแจงปกติมาตรฐานยกกำลังสอง หากพิจารณาที่ค่าเล่าที่ 1, 5, 9 พบว่าค่าพิน้อยกว่าระดับนัยสำคัญที่เราเลือก เช่น 0.05 แสดงว่าแบบจำลองในส่วนของการค่า



แปรปรวนมีเงื่อนไข สามารถอธิบายตัวแปรได้

```

1 Weighted Ljung-Box Test on Standardized Residuals
2 -----
3               statistic    p-value
4 Lag[1]                3.351 6.717e-02
5 Lag[2*(p+q)+(p+q)-1][11]    9.220 1.777e-06
6 Lag[4*(p+q)+(p+q)-1][19]    13.350 8.841e-02
7 d.o.f=4
8 H0 : No serial correlation
9
10 Weighted Ljung-Box Test on Standardized Squared Residuals
11 -----
12               statistic    p-value
13 Lag[1]                0.0957 0.7571
14 Lag[2*(p+q)+(p+q)-1][5]    1.8392 0.6569
15 Lag[4*(p+q)+(p+q)-1][9]    3.0164 0.7563
16 d.o.f=2
17
18 Weighted ARCH LM Tests
19 -----
20               Statistic Shape Scale P-Value
21 ARCH Lag[3]          1.876 0.500 2.000 0.1708
22 ARCH Lag[5]          3.360 1.440 1.667 0.2417
23 ARCH Lag[7]          3.586 2.315 1.543 0.4103

```

### 5.4.2 การแจกแจงที่ไม่ใช่การแจกแจงแบบปกติ

ในหัวข้อที่ผ่านมาเราสมมติให้  $\varepsilon_t^2$  มีการแจกแจงแบบปกติมาตรฐานซึ่งข้อมูลทางการเงินบางข้อมูลอาจจะมีลักษณะหางอ้วน ดังนั้น ข้อสมมุติว่า  $\varepsilon_t^2$  มีการแจกแจงอื่นที่มีหางอ้วนน่าจะเหมาะสมกว่า เช่นการแจกแจงแบบที และการแจกแจงค่าผิดพลาดทั่วไป (generalized error distribution (GED))

#### การแจกแจงแบบที

ถ้าตัวแปรสุ่ม  $u_t$  มีการแจกแจงแบบทีด้วยองศาเสรีเท่ากับ  $\nu$  "นิว" และตัวแปรสเกล  $s_t$  จะมีฟังก์ชันความถี่ความน่าจะเป็นเท่ากับ

$$f(u_t) = \frac{\Gamma[(\nu+1)/2]}{(\pi\nu)^{1/2}\Gamma(\nu/2)} \frac{s_t^{-1/2}}{[1 + u_t^2/(s_t\nu)]^{(\nu+1)/2}}$$

โดยที่  $\Gamma()$  เป็นฟังก์ชันแกมมา และค่าความแปรปรวนของ  $u_t$  เท่ากับ

$$Var(u_t) = \frac{s_t\nu}{\nu-2}, \quad \nu > 2$$

ถ้าค่าช็อก  $\varepsilon_t$  ในแบบจำลองการช็อกมีการแจกแจงแบบทีที่มีองศาอิสระเท่ากับ  $\nu$  และมีค่า  $Var_{t-1}(\varepsilon_t) = \sigma_t^2$  แล้วพารามิเตอร์  $s_t$  จะถูกเลือกเพื่อให้  $s_t = \frac{\sigma_t^2(\nu-2)}{\nu}$

เงื่อนไขเพิ่มเติมในคำสั่ง `garchFit` คือ `cond.dist=c("std")` สำหรับการแจกแจงแบบที่

### การแจกแจงค่าผิดพลาดทั่วไป

Nelson (1991) ได้เสนอให้ใช้การแจกแจงการแจกแจงค่าผิดพลาดทั่วไป ในการผนวกคุณลักษณะหางอ้วนในแบบจำลอง ถ้า  $u_t$  มีการแจกแจงแบบ GED ที่มีค่าเฉลี่ยเท่ากับศูนย์และค่าความแปรปรวนเท่ากับหนึ่ง ฟังก์ชันความถี่ความน่าจะเป็น (pdf) เท่ากับ

$$f(u_t) = \frac{\nu \exp[-(1/2)|u_t/\lambda|^\nu]}{\lambda 2^{(\nu+1)/\nu} \Gamma(1/\nu)}$$

โดยที่

$$\lambda = \left[ \frac{2^{-2/\nu} \Gamma(1/\nu)}{\Gamma(3/\nu)} \right]^{1/2}$$

โดยที่  $\nu$  เป็นค่าพารามิเตอร์ที่เป็นบวกที่บอกความหนาของหาง ถ้า  $\nu = 2$  pdf จะลดลงเหลือ pdf ของการแจกแจงปกติมาตรฐาน และถ้า  $\nu < 2$  ความถี่ที่หางจะหนาว่าการแจกแจงแบบปกติ

เงื่อนไขเพิ่มเติมในคำสั่ง `garchFit` คือ `cond.dist=c("ged")` สำหรับ generalized error distribution

#### ตัวอย่างที่ 5.3 การสร้างแบบจำลองการزشด้วยข้อสมมุติการแจกแจงแบบที่

ตัวอย่างนี้ใช้ข้อมูลต่อจากตัวอย่าง ที่ผ่านมา เนื่องจากในตัวอย่างที่ผ่านมาระบุว่าเรชิตัวไม่ได้มีการแจกแจงแบบปกติ ดังนั้นเราอาจใช้การแจกแจงอื่นที่มีหางอ้วนกว่าเช่นการแจกแจงแบบที่และประมาณค่าแบบจำลอง `fit.garch11.t` โดยที่เปลี่ยน `distribution.model="std"`)

```
1 > spec.garch11.t <- ugarchspec(variance.model=list(model="sGARCH",
  garchOrder=c(1,1)),
2 + mean.model=list(armaOrder=c(2,2), include.mean=TRUE), distribution.
  model="std")
3 > fit.garch11.t <- ugarchfit(spec=spec.garch11.t, data = ret)
4 > show(fit.garch11.t)
5
6 *-----*
7 *          GARCH Model Fit          *
8 *-----*
9
10 Conditional Variance Dynamics
11 -----
12 GARCH Model      : sGARCH(1,1)
13 Mean Model       : ARFIMA(2,0,2)
14 Distribution      : std
15
16 Optimal Parameters
17 -----
18      Estimate  Std. Error  t value Pr(>|t|)
19 mu      0.005531    0.003261   1.6962 0.089852
20 ar1     0.977050    0.175427   5.5695 0.000000
```

```

21 ar2      -0.602677    0.150885   -3.9943  0.000065
22 ma1      -0.880078    0.155925   -5.6443  0.000000
23 ma2       0.648087    0.154766    4.1875  0.000028
24 omega     0.000156    0.000104    1.4966  0.134492
25 alpha1    0.184988    0.056949    3.2483  0.001161
26 beta1     0.814012    0.051417   15.8317  0.000000
27 shape     4.918851    1.144499    4.2978  0.000017
28 <Omitted>
29 Information Criteria
30 -----
31
32 Akaike      -2.4373
33 Bayes       -2.3552
34 Shibata     -2.4381
35 Hannan-Quinn -2.4050

```

ในการประมาณค่าด้วยการแจกแจงแบบ *student's t* เราจะได้ค่า *estimated shape* คือตัวประมาณค่าองศาเสรี (*degree of freedom*) ในที่นี้คือ *shape* เท่ากับ 4.92

### 5.4.3 การเลือกแบบจำลองที่เหมาะสม (Model selection)

จากหัวข้อที่ผ่านมาเราจะเห็นได้ว่าเราสามารถประมาณค่าแบบจำลองการชได้หลายรูปแบบ ดังนั้นการเลือกแบบจำลองที่เหมาะสมกับข้อมูลของเราเป็นขั้นตอนที่สำคัญ เนื่องจากเราสามารถเขียนแบบจำลองในรูปของอาร์มา สำหรับ  $\varepsilon_t^2$  ได้ เราจึงสามารถใช้เกณฑ์ในการเลือกแบบจำลองที่เราได้เสนอไว้แล้วในบทที่แล้วเช่นเอไอซีหรือบีไอซีในการเลือกแบบจำลอง

**ตัวอย่างที่ 5.4** การเปรียบเทียบแบบจำลองด้วยเกณฑ์การคัดเลือก

จาก ตัวอย่างที่ 5.2 และ 5.3 เราสามารถนำค่าเอไอซีและบีไอซีมาเปรียบเทียบกันตามตาราง

ตารางที่ 5.1: การเปรียบเทียบแบบจำลอง GARCH

เกณฑ์	ARMA(2,2) – GARCH(1,1) fit.garch11	ARMA(2,2) – GARCH(1,1) t-dist fit.garch11.t
AIC	-2.372	-2.437
BIC	-2.299	-2.355

จะเห็นได้ว่าค่าเอไอซีและบีไอซีของการชที่มีการแจกแจงแบบที่มีค่าน้อยกว่าเอไอซีและบีไอซีของการชที่มีการแจกแจงแบบปกติ แสดงให้เห็นว่าแบบจำลองที่มีการแจกแจงแบบที่น่าจะอธิบายข้อมูลได้ดีกว่า

### 5.4.4 การขยายแบบจำลองการช

แบบจำลอง GARCH สามารถปรับปรุงเพื่อให้สามารถอธิบายความผันผวนของข้อมูลจริงได้ดีขึ้น

### Integrated GARCH

จากตัวอย่างการประมาณค่า  $GARCH(1,1)$  สำหรับผลตอบแทนของหลักทรัพย์มักจะให้ค่าประมาณ  $\hat{\alpha}_1 + \hat{\beta}_1 \approx 1$  ตัวอย่างเช่นการประมาณค่าในตัวอย่างที่ 4.2  $\hat{\alpha}_1 + \hat{\beta}_1 = 0.22 + 0.777 = 0.997$

จากสมการที่ xxx เราพบว่าอนุกรมเวลาความผันผวนมีลักษณะใกล้เคียงกับ unit root หากเราขยายแบบจำลอง GARCH ให้มีลักษณะยูนิทรูท เราเรียกแบบจำลองดังกล่าวว่า Integrated GARCH (IGARCH) โดยที่เราสามารถผนวกเงื่อนไขที่ว่าความผันผวนเป็นยูนิทรูทได้โดยการกำหนดให้  $\alpha_1 + \beta_1 = 1$  หรือแทนค่า  $\beta_1 = 1 - \alpha_1$  ในสมการ (5.13) ส่งผลให้สมการความแปรปรวนมีเงื่อนไขอยู่ในรูปต่อไปนี้

$$\sigma_t^2 = \omega + \alpha_1 \epsilon_{t-1}^2 + (1 - \alpha_1) \sigma_{t-1}^2 \quad (5.18)$$

จะเห็นว่าจำนวนพารามิเตอร์ในแบบจำลองดังกล่าวเหลือเพียงแค่ 2 ตัวได้แก่  $\omega$  กับ  $\alpha_1$

### การเพิ่มตัวแปรในแบบจำลอง GARCH

แนวทางหนึ่งในการขยายแบบจำลองการช คือการเพิ่มตัวแปรในสมการค่าเฉลี่ยและสมการค่าความแปรปรวน เช่นในกรณีของแบบจำลอง  $GARCH(1,1)$  สามารถขยายแบบจำลองได้ดังสมการต่อไปนี้

$$y_t = \mu_t + \gamma_1 x_t + \epsilon_t$$

$$\sigma_t^2 = \omega + \alpha_1 \epsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2 + \lambda w_t$$

โดยที่  $x_t$  และ  $w_t$  คือตัวแปรอธิบายเพิ่มเติมสำหรับสมการค่าเฉลี่ยและสมการค่าความแปรปรวนตามลำดับ ตัวอย่างเช่นค่าความแปรปรวนอาจจะอธิบายได้ด้วยปริมาณการซื้อขาย การประกาศนโยบายของทางการ วันในสัปดาห์ และผลของวันหยุด

### การเปลี่ยนแปลงที่ไม่สมมาตร

ในแบบจำลอง GARCH เราพิจารณาตัวกำหนดความผันผวนด้วย  $\epsilon_{t-1}^2$  โดยที่ไม่ได้สนใจว่าช็อกที่เกิดขึ้นเป็นช็อกทางบวกหรือทางลบ ทั้งๆที่ช็อกทางลบ(ในขนาดที่เท่ากัน)น่าจะทำให้เกิดความผันผวนมากกว่าช็อกทางบวก ดังนั้นแนวทางการขยายแบบจำลอง GARCH อีกทางหนึ่งคือการปรับแบบจำลองให้ผลของช็อกในทางบวกและทางลบมีค่าที่แตกต่างกัน โดยที่แบบจำลองในตลาดหลักทรัพย์เรามักจะพบว่าการปรับตัวลดลงของราคาหลักทรัพย์ส่งผลให้เกิดความผันผวนมากกว่าการปรับตัวขึ้นของราคา แบบจำลองที่ขยายขึ้นมานี้เราเรียกว่าเป็นแบบจำลองที่มีผลไม่สมมาตร

วิธีการแรกในการสร้างแบบจำลองที่มีผลไม่สมมาตรคือ threshold GARCH (TGARCH) ซึ่งสมการค่าความแปรปรวนสามารถอธิบายได้ดังนี้

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \epsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2 + \phi d_{t-1} \epsilon_{t-1}^2 \quad (5.19)$$

โดยที่  $d_{t-1}$  เป็นตัวแปรดัมมี่ที่นิยามได้ดังนี้

$$d_{t-1} = \begin{cases} 1 : & \epsilon_{t-1} < 0 \\ 0 : & \epsilon_{t-1} \geq 0 \end{cases}$$

เพื่อให้ค่าความแปรปรวนเป็นบวก เรากำหนดให้  $\phi > 0$  ดังนั้นหากเกิดข่าวดี ( $\epsilon_{t-1} \geq 0$ ) จะส่งผลต่อความผันผวนเท่ากับ  $\alpha_1$  ในทางตรงข้ามหากเกิดข่าวร้าย ( $\epsilon_{t-1} < 0$ ) จะส่งผลต่อความผันผวนเท่ากับ  $\alpha_1 + \phi$  จะเห็นได้ว่าช็อกทางลบส่งผลต่อความผันผวนมากกว่าช็อกทางบวก

อีกวิธีในการสร้างแบบจำลองที่มีผลไม่สมมาตรคือแบบจำลอง Exponential GARCH (EGARCH) ซึ่งสามารถแสดงได้ด้วยสมการต่อไปนี้

$$\ln \sigma_t^2 = \omega + \alpha_1 \frac{\epsilon_{t-1}}{\sigma_{t-1}} + \phi \left\| \frac{\epsilon_{t-1}}{\sigma_{t-1}} \right\| + \beta_1 \ln \sigma_{t-1}^2 \quad (5.20)$$

### การพิจารณาค่าความเสี่ยงในสมการค่าเฉลี่ย

ในทางการเงินความเสี่ยงที่สูงจะนำมาสู่ผลตอบแทนที่สูงด้วย หรือเราเรียกว่า "เบี้ยความเสี่ยง (risk premium)" Engle, Lilien, and Robins (1987) เสนอให้ขยาย GARCH เพื่อให้พิจารณาเบี้ยความเสี่ยงเป็นปัจจัยหนึ่งในการกำหนดผลตอบแทนในสมการค่าเฉลี่ย หรือสามารถอธิบายได้ด้วยสมการ

$$y_t = c + \alpha g(\sigma_t) + \epsilon_t$$

และเราเรียกแบบจำลองนี้ว่า GARCH-in-the-mean (GARCH-M)

## 5.5 การพยากรณ์ด้วยแบบจำลองการช

เป้าหมายสำคัญของการสร้างแบบจำลองสำหรับความผันผวนที่เปลี่ยนแปลงตามเวลา คือการสร้างการคาดการณ์ที่แม่นยำขึ้นสำหรับการทำนายค่าอนุกรมเวลาที่เราสงสัยในอนาคตและการพยากรณ์ค่าความแปรปรวนมีเงื่อนไข

เนื่องจากในสมการค่าเฉลี่ยเราสมมติให้อนุกรมเวลาถูกอธิบายด้วยแบบจำลองอาร์มา ดังนั้นค่าพยากรณ์ของอนุกรมเวลา  $y_t$  สามารถใช้การพยากรณ์ของ อาร์มาได้อย่างปกติ อย่างไรก็ตามการที่เรายกเว้นข้อสมมุติความแปรปรวนคงที่ และให้ความผันผวนสามารถเปลี่ยนแปลงได้ตามเวลา เช่นแบบจำลอง การ์ชจะทำให้เราได้ค่าผันผวนในอนาคตที่แม่นยำขึ้นโดยเฉพาะการพยากรณ์ในระยะสั้น ในที่นี้เราจะยกตัวอย่างแบบจำลอง GARCH(1,1) ซึ่งสมการความผันผวนสามารถแสดงได้โดย

$$\sigma_t^2 = \omega + \alpha_1 \epsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$

หากเราพิจารณาข้อมูลจนถึงค่าที่  $h$  และการพยากรณ์ไปข้างหน้าหนึ่งค่าสามารถคำนวณได้โดยใช้ค่าคาด

การณมีเงื่อนไข

$$\begin{aligned} E_h(\sigma_{h+1}^2) &= \omega + \alpha_1 E_h(\varepsilon_h^2) + \beta E_h(\sigma_h^2) \\ &= \omega + \alpha_1 \varepsilon_h^2 + \beta \sigma_h^2 \end{aligned}$$

เนื่องจากเราทราบว่า  $\varepsilon_h^2$  และ  $\sigma_h^2$  จากการประมาณค่าแล้ว ต่อไปพิจารณาตอนที่  $h+2$

$$\begin{aligned} E_h(\sigma_{h+2}^2) &= \omega + \alpha_1 E_h(\varepsilon_{h+1}^2) + \beta E_h(\sigma_{h+1}^2) \\ &= \omega + (\alpha_1 + \beta) E_h(\sigma_{h+1}^2) \end{aligned}$$

เนื่องจาก  $E_h(\varepsilon_{h+1}^2) = E_h(\sigma_{h+1}^2)$  จากวิธีการข้างต้นเราสามารถสร้างสมการสำหรับการพยากรณ์ ณ คาบ  $k$  ใดๆ ได้เป็น


$$E_h(\sigma_{h+k}^2) = \omega \sum_{i=1}^{k-2} (\alpha_1 + \beta_1)^i + (\alpha_1 + \beta_1)^{k-1} E_h(\sigma_{h+1}^2) \quad (5.21)$$

สำหรับ  $k \geq 2$  และจะเห็นได้ว่าถ้า  $k \rightarrow \infty$  และ  $GARCH$  เป็นอนุกรมนิ่ง ( $\alpha_1 + \beta_1 < 1$ ) การพยากรณ์ค่าความผันผวนจะเข้าใกล้ค่าความแปรปรวนไม่มีเงื่อนไข  $\omega/(1 - \alpha_1 - \beta_1)$

#### ตัวอย่างที่ 5.5 การคำนวณค่าพยากรณ์ความแปรปรวนแบบมีเงื่อนไข

จากแบบจำลอง **GARCH** เราสามารถคำนวณค่า **predicted conditional variance** หรือ **standard deviation** กับข้อมูลภายในกลุ่มตัวอย่าง (in-sample) เพื่อใช้เป็นตัวแทนของความผันผวน (volatility) สำหรับแบบจำลองทางการเงินต่าง ๆ ในตัวอย่างที่ 5.2 เราได้ประมาณค่าแบบจำลอง **ARMA(2,2)-GARCH(1,1)** ซึ่งเราสามารถคำนวณค่า **predicted conditional standard deviation** ได้จากคำสั่ง `sigma`

```
1 sig.garch11<-sigma(fit.garch11)
2 volatility<-ts(data=sig.garch11[,1], frequency=12, start=c(1975,5), end
  =c(2013,11))
3 plot.ts(volatility, type="l")
```



รูปที่ 5.3: Predicted Conditional Variance

จากรูป 5.3 จะเห็นได้ว่าช่วงที่ตลาดหุ้นไทยผันผวนค่อนข้างสูงและยาวนานคือหลังวิกฤติ 1997 นอกจากนี้ เราสามารถพยากรณ์ออกไปนอกช่วงข้อมูล (out-of sample) ซึ่งเราสามารถพยากรณ์ค่าเฉลี่ยและค่าความแปรปรวน เราสามารถใช้คำสั่ง `ugarchforecast` และระบุแบบจำลอง `fit.garch11` และจำนวนคาบที่จะพยากรณ์ไปข้างหน้า `n.ahead=5` และได้ผลดังต่อไปนี้

```
1 > garch11.fcst=ugarchforecast(fit.garch11, n.ahead=5)
2 > garch11.fcst
3
4 *-----*
5 *          GARCH Model Forecast          *
6 *-----*
7 Model: sGARCH
8 Horizon: 5
9 Roll Steps: 0
10 Out of Sample: 0
11
12 0-roll forecast [T0=1971-03-28 07:00:00]:
13      Series      Sigma
14 T+1  0.0008783 0.04438
15 T+2 -0.0026793 0.04648
16 T+3  0.0010525 0.04849
17 T+4  0.0071598 0.05041
18 T+5  0.0100715 0.05226
```

หรือสามารถเขียนสรุปได้เป็น

ตารางที่ 5.2: การพยากรณ์จากแบบจำลองการrch

horizon	1	2	3	4	5
log return	0.0009	-0.0027	0.0011	0.0072	0.0101
volatility ( $\sigma_t$ )	0.0444	0.0465	0.0485	0.0504	0.0523

## 5.6 แบบฝึกฝน

**แบบฝึกฝน 5.1** พิจารณาผลได้ตอบแทนรายวันของ **exchange trade fund** ระหว่างวันที่ 4 กันยายน 2001 ถึง 30 กันยายน 2011 โดยข้อมูลดังกล่าวอยู่ในไฟล์ `dspey_0111.csv` โดยที่ `rtn` เป็น **simple return** จงแปลงข้อมูลเป็น **log return** แล้วตอบคำถามต่อไปนี้

1. จงประมาณค่าแบบจำลองสำหรับ **log return** โดยเลือกแบบจำลอง **ARMA(p,q)** ที่เหมาะสมโดยให้ค่า **p** และ **q** สูงสุดเท่ากับ 5 พร้อมอธิบายว่าแบบจำลองเพียงพอหรือไม่ในการอธิบาย **log return** หรือไม่

2. จงอธิบายผลการทดสอบ **ARCH effect** ของแบบจำลองในข้อ (1)
3. จงเขียนผลการประมาณค่าแบบจำลองที่ เพิ่มการอธิบาย **conditional variance** ด้วย **GARCH(1,1)** โดยที่สมมติให้ **error term** มีการแจกแจงแบบปกติ
4. จงตรวจสอบแบบจำลองในข้อ (3) และแนวทางที่สามารถปรับปรุงได้
5. จงเขียนผลการทำนาย **log return** และ **conditional variance** ไปอีก 2 period ข้างหน้าจากแบบจำลองในข้อ (2)

**แบบฝึกฝน 5.2** สมมติให้แบบจำลอง **ARCH(1)**:  $r_t - \mu = \varepsilon_t$ ,  $\varepsilon_t = z_t \sigma_t$ ,  $\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2$  จงแสดงวิธีหาค่า **unconditional variance** ( $Var(\varepsilon_t)$ ) โดยที่  $r_t$  คืออัตราผลตอบแทน  $\mu$  คือค่าเฉลี่ย และ  $\varepsilon_t$  คือ **residuals** ของสมการค่าเฉลี่ย

**แบบฝึกฝน 5.3** สมมติให้แบบจำลองที่อธิบายผลตอบแทน( $r_t$ )สามารถแสดงได้ด้วย **ARMA(0,0)-GARCH(1,1)**

$$r_t = 0.03 + \varepsilon_t, \quad \varepsilon_t = z_t \sigma_t, \quad z_t \sim N(0, 1)$$

$$\sigma_t^2 = 0.144 + 0.07 \varepsilon_{t-1}^2 + 0.83 \sigma_{t-1}^2$$

และค่า  $\sigma_{100}^2 = 0.6$  และ  $\varepsilon_{100} = -0.1$  จงทำนายค่า  $r_{101}$  พร้อม **95% confidence interval** โดยมีจุดเริ่มต้นที่ 100



## 6. แบบจำลองอนุกรมเวลาเชิงพหุ

เนื่องจากตลาดการเงินของโลกมีความเชื่อมโยงกันมากขึ้น การเปลี่ยนแปลงที่เกิดขึ้นในตลาดการเงินหนึ่งสามารถส่งผ่านต่อไปยังตลาดอื่นได้ง่าย ดังนั้น บางครั้งเราจำเป็นต้องพิจารณาการเปลี่ยนแปลงของอนุกรมเวลาทางการเงินไปพร้อมๆ กัน โดยเราเรียกแบบจำลองที่พิจารณาอนุกรมเวลาหลายๆ อนุกรมพร้อมกันว่าแบบจำลองอนุกรมเวลาเชิงพหุ(multivariate time series) โดยเราสามารถเขียนอนุกรมเวลาในรูปของเวกเตอร์  $\mathbf{Y}_t = (y_{1t}, y_{2t}, \dots, y_{nt})'$  โดยที่  $y_{it}$  แทนอนุกรมเวลา  $i$  และ  $n$  คือจำนวนอนุกรมเวลาที่เรากำลังพิจารณาร่วมกัน<sup>1</sup> เช่น  $y_{1t}, y_{2t}, \dots, y_{nt}$  แทนผลได้ตอบแทนในรูปร้อยละของหุ้นในตลาดหลักทรัพย์แห่งประเทศไทย

### 6.1 ความนิ่งของอนุกรมเวลาและเมตริกซ์สหสัมพันธ์ระหว่างกัน

$\mathbf{Y}_t = (y_{1t}, y_{2t}, \dots, y_{nt})'$  จะเป็นอนุกรมเวลานิ่ง (stationary) ถ้าโมเมนต์ที่หนึ่งและสองไม่ขึ้นอยู่กับการเปลี่ยนแปลงของเวลา (time-invariant) ซึ่งในที่นี้เราจะต้องพิจารณาเวกเตอร์ของค่าเฉลี่ย (mean vector)  $\boldsymbol{\mu} = E(\mathbf{Y}_t)$  โดยที่  $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)'$  เมตริกซ์ของความแปรปรวนร่วม (covariance matrix) ใช้สัญลักษณ์  $\Gamma_0$  สามารถคำนวณได้โดย

$$\begin{aligned}\Gamma_0 &= E[(\mathbf{Y}_t - \boldsymbol{\mu})(\mathbf{Y}_t - \boldsymbol{\mu})'] \\ &= \begin{pmatrix} E(y_{1t} - \mu_1)^2 & E(y_{1t} - \mu_1)(y_{2t} - \mu_2) & \dots & E(y_{1t} - \mu_1)(y_{nt} - \mu_n) \\ \vdots & \vdots & \ddots & \vdots \\ E(y_{nt} - \mu_n)(y_{1t} - \mu_1) & E(y_{nt} - \mu_n)(y_{2t} - \mu_2) & \dots & E(y_{nt} - \mu_n)^2 \end{pmatrix} \\ &= \begin{pmatrix} \text{Var}(y_{1t}) & \text{Cov}(y_{1t}, y_{2t}) & \dots & \text{Cov}(y_{1t}, y_{nt}) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(y_{nt}, y_{1t}) & \text{Cov}(y_{nt}, y_{2t}) & \dots & \text{Var}(y_{nt}) \end{pmatrix}\end{aligned}$$

จะเห็นว่าพจน์ในแนวทแยงมุมจะเป็นค่าความแปรปรวนของแต่ละอนุกรมเวลา ในขณะที่พจน์ที่  $(i, j)$

<sup>1</sup>สัญลักษณ์ ' แทน transpose ของเมตริกซ์

จะเป็นสหสัมพันธ์ระหว่าง  $y_{it}$  และ  $y_{jt}$  ในคาบเวลาเดียวกัน

### 6.1.1 cross-correltaion matrices

กำหนดให้  $D$  เป็นเมตริกซ์  $n \times n$  ที่ประกอบด้วยค่าเบี่ยงเบนมาตรฐาน (standard deviation) ของ  $y_{it}$  ในพจน์แท่งมุม โดยที่  $\Gamma_{ii}(0)$  เป็นสัญลักษณ์แทนค่าความแปรปรวนของ  $y_{it}$  ดังนั้นเราสามารถเขียนเมตริกซ์  $D$  ได้ดังนี้

$$D = \begin{pmatrix} \sqrt{\Gamma_{11}(0)} & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \sqrt{\Gamma_{nn}(0)} \end{pmatrix}$$

เราสามารถนิยามเมตริกซ์สหสัมพันธ์ข้ามตัวแปร (cross-correlation) ที่คาบเวลาเดียวกัน (concurrent) ได้ด้วย

$$\rho_0 = [\rho_{ij}(0)] = D^{-1} \Gamma_0 D^{-1}$$

โดยที่  $\rho_{ij}(0) = \frac{\Gamma_{ij}(0)}{\sqrt{\Gamma_{ii}(0)\Gamma_{jj}(0)}} = \frac{Cov(y_{it}, y_{jt})}{std(y_{it})std(y_{jt})}$  ซึ่งคือสหสัมพันธ์ระหว่าง  $y_{it}$  และ  $y_{jt}$  โดยที่ในการวิเคราะห์อนุกรมเวลาเราจะเรียกสหสัมพันธ์ดังกล่าวว่าเป็นสหสัมพันธ์ในคาบเดียวกัน (concurrent หรือ contemporaneous)

นอกจากนี้ การวิเคราะห์อนุกรมเวลาเชิงพหุ เราสนใจความสัมพันธ์ในเชิงตัวแปรที่นำหรือตาม (lead-lag relationship) ระหว่างตัวแปรที่เราสนใจ ดังนั้นเราต้องการหาเมตริกซ์สหสัมพันธ์ข้ามตัวแปรที่ใช้วัดความสัมพันธ์ระหว่างช่วงเวลาเช่น เมตริกซ์ความแปรปรวนร่วมข้ามตัวแปรที่มีค่าเท่ากับหนึ่งใช้สัญลักษณ์  $\Gamma_1$  ดังที่ได้แสดงในสมการต่อไปนี้

$$\begin{aligned} \Gamma_1 &= E[(Y_t - \mu)(Y_{t-1} - \mu)'] \\ &= \begin{pmatrix} E(y_{1t} - \mu_1)(y_{1,t-1} - \mu_1) & E(y_{1t} - \mu_1)(y_{2,t-1} - \mu_2) & \dots & E(y_{1t} - \mu_1)(y_{n,t-1} - \mu_n) \\ \vdots & \vdots & \ddots & \vdots \\ E(y_{nt} - \mu_n)(y_{1,t-1} - \mu_1) & E(y_{nt} - \mu_n)(y_{2,t-1} - \mu_2) & \dots & E(y_{nt} - \mu_n)(y_{n,t-1} - \mu_n) \end{pmatrix} \\ &= \begin{pmatrix} Cov(y_{1t}, y_{1,t-1}) & Cov(y_{1t}, y_{2,t-1}) & \dots & Cov(y_{1t}, y_{n,t-1}) \\ \vdots & \vdots & \ddots & \vdots \\ Cov(y_{nt}, y_{1,t-1}) & Cov(y_{nt}, y_{2,t-1}) & \dots & Cov(y_{nt}, y_{n,t-1}) \end{pmatrix} \end{aligned}$$

เราสามารถคำนวณเมตริกซ์สหสัมพันธ์ข้ามตัวแปร (cross-correlation) ที่มีค่าเท่ากับหนึ่ง ได้ด้วย

$$\rho_1 = [\rho_{ij}(1)] = D^{-1} \Gamma_1 D^{-1}$$

โดยที่  $\rho_{ij}(1) = \frac{\Gamma_{ij}(1)}{\sqrt{\Gamma_{ii}(0)\Gamma_{jj}(0)}} = \frac{Cov(y_{it}, y_{j,t-1})}{std(y_{it})std(y_{jt})}$  ซึ่งคือสหสัมพันธ์ระหว่าง  $y_{it}$  และ  $y_{j,t-1}$  หากค่า  $\rho_{ij}(1) \neq 0$  แสดงว่าการเปลี่ยนแปลงของ  $y_{jt}$  ในคาบที่ผ่านมาส่งผลต่อการเปลี่ยนแปลงของ  $y_{it}$  ในคาบปัจจุบัน ดังนั้น  $y_{jt}$  เป็นตัวแปรนำ (lead)  $y_{it}$

ความสัมพันธ์ดังกล่าวสามารถขยายไปยังกรณี  $\Gamma_l, l = \dots, -2, -1, 0, 1, 2, \dots$  ถ้าหากค่า  $\rho_{ij}(l) \neq 0$  กรณีที่  $l > 0$  แสดงว่า  $y_{jt}$  เป็นตัวแปรนำ (lead)  $y_{it}$  แต่ถ้า  $\rho_{ij}(l) \neq 0$  กรณีที่  $l < 0$  แสดงว่า  $y_{it}$  เป็นตัวแปรนำ (lead)  $y_{jt}$

### 6.1.2 ตัวประมาณค่าสหสัมพันธ์ไขว้

กำหนดให้  $\mathbf{Y}_t$  เป็นเวกเตอร์ของตัวอย่างจากเวลาที่  $t = 1, \dots, T$  เราสามารถคำนวณหาตัวประมาณค่าของเวกเตอร์ค่าเฉลี่ยและเมตริกซ์ตัวแปรปรวนร่วมไขว้ (cross-covariance) ได้จากสมการต่อไปนี้

$$\begin{aligned}\widehat{\boldsymbol{\mu}}_Y &= \frac{1}{T} \sum_{t=1}^T \mathbf{Y}_t \\ \widehat{\boldsymbol{\Gamma}}_0 &= \frac{1}{T-1} \sum_{t=1}^T (\mathbf{Y}_t - \widehat{\boldsymbol{\mu}}_Y)(\mathbf{Y}_t - \widehat{\boldsymbol{\mu}}_Y)'\end{aligned}\quad (6.1)$$

ในขณะที่ตัวประมาณค่าเมตริกซ์ตัวแปรปรวนร่วมไขว้ที่ค่า  $l$  คำนวณได้จากสมการ

$$\widehat{\boldsymbol{\Gamma}}_l = \frac{1}{T-1} \sum_{t=l+1}^T (\mathbf{Y}_{t-l} - \widehat{\boldsymbol{\mu}}_Y)(\mathbf{Y}_t - \widehat{\boldsymbol{\mu}}_Y)'$$

จากตัวประมาณค่าข้างต้น ตัวประมาณค่าเมตริกซ์สหสัมพันธ์ไขว้ที่ค่า  $l$  สามารถคำนวณได้จาก

$$\widehat{\boldsymbol{\rho}}_l = \widehat{\mathbf{D}}^{-1} \widehat{\boldsymbol{\Gamma}}_l \widehat{\mathbf{D}}^{-1}$$

โดยที่  $\widehat{\mathbf{D}}^{-1}$  คือเมตริกซ์ทแยงมุมที่ตำแหน่งที่  $(i, i)$  คือค่ารากที่สองของสมาชิกตำแหน่งที่  $(i, i)$  ในเมตริกซ์  $\widehat{\boldsymbol{\Gamma}}_0$  ภายใต้ข้อสมมุติว่า  $\mathbf{Y}_t$  เป็นตัวแปรนิ่งและโมเมนต์ที่สี่เป็นพจน์จำกัด (finite) เราสามารถแสดงได้ว่า  $\widehat{\boldsymbol{\rho}}_l$  เป็นตัวประมาณค่าคล่องจองของ  $\boldsymbol{\rho}_l$

ในการวิเคราะห์ข้อมูลเบื้องต้น เรามักจะใช้ตัวประมาณค่าสหสัมพันธ์ไขว้ในการอธิบายความสัมพันธ์เชิงพลวัตของตัวแปรที่เราสนใจ นอกจากนี้เราสามารถใช้อย่างมีประสิทธิภาพโดยเปรียบเทียบค่าวิกฤต  $(t/\sqrt{T})$  เช่นกรณีกำหนดระดับนัยสำคัญ 0.05 หากค่า  $\widehat{\rho}_{l,ij}$  สูงกว่า  $2/\sqrt{T}$  แสดงว่ามีสหสัมพันธ์เป็นบวก ในทางตรงข้ามหาก ค่า  $\widehat{\rho}_{l,ij}$  ต่ำกว่า  $2/\sqrt{T}$  แสดงว่ามีสหสัมพันธ์เป็นลบ ซึ่งเราสามารถพิจารณาจากกราฟสหสัมพันธ์ไขว้


**ตัวอย่างที่ 6.1** ตัวอย่างสหสัมพันธ์ไขว้ของอัตราผลตอบแทนรายสัปดาห์ของตลาดหลักทรัพย์ไทยและมาเลเซีย

เราใช้คำสั่ง `ccf` ในการคำนวณสหสัมพันธ์ไขว้ โดยกำหนดตัวแปรตัวที่หนึ่งและสอง และเลือกเงื่อนไข `type=c("correlation")` และ `plot=FALSE` จะได้ผลการคำนวณดังนี้ ที่ค่าล่าศูนย์ แสดงสหสัมพันธ์ระหว่างผลได้ตอบแทนของสองตลาดซึ่งมีค่าเท่ากับ 0.409 ในขณะที่ค่าล่าเท่ากับลบหนึ่ง หมายถึงสหสัมพันธ์ระหว่าง  $r_{th,t}$  กับ  $r_{my,t-1}$  ซึ่งมีค่าเท่ากับ 0.126 แสดงว่าตัวแปรทั้งสองห่ากันหนึ่งคาบมีความสัมพันธ์ทางบวกหากผลตอบแทนในมาเลเซียเพิ่มขึ้นในคาบที่ผ่านมา ผลตอบแทนในไทยจะปรับตัวเพิ่มขึ้นในคาบปัจจุบัน ในขณะที่ค่าล่าเท่ากับหนึ่ง หมายถึงสหสัมพันธ์ระหว่าง  $r_{th,t}$

กับ  $r_{my,t+1}$  ซึ่งเท่ากับสหสัมพันธ์ระหว่าง  $r_{th,t-1}$  กับ  $r_{my,t}$  ซึ่งมีค่าเท่ากับ 0.031 แสดงว่าตัวแปรทั้งสองห่างกันหนึ่งคาบมีความสัมพันธ์ทางบวกหากผลตอบแทนในไทยเพิ่มขึ้นในคาบที่ผ่านมา ผลตอบแทนในมาเลเซียจะปรับตัวเพิ่มขึ้นในคาบปัจจุบัน นอกจากนี้เราสามารถพิจารณารูปสหสัมพันธ์ โดยใช้เงื่อนไข `plot=TRUE` หรือไม่ต้องการกำหนดเนื่องจากเป็นค่าโดยปริยาย

```
1 > head(lret_thmy)
2           TH           MY
3 1998-01-02  4.264711  1.941946
4 1998-01-09 -6.375712 -15.140368
5 1998-01-16  9.107125  9.384820
6 1998-01-23  9.900370  3.386636
7 1998-01-30 15.795750  1.939640
8 1998-02-06  7.907455 24.578566
9 > ccf(lret_thmy$TH, lret_thmy$MY, type=c("correlation"), lag.max = 10,
10       plot=FALSE)
11 Autocorrelations of series ``X, by lag
12
13      -10      -9      -8      -7      -6      -5      -4      -3      -2      -1
14      0.038  0.109  0.093  0.050  0.063  0.035  0.033  0.094  0.139  0.126
15      0.409  0.031  0.127  0.047  0.025
16      5      6      7      8      9     10
17      0.097 -0.047 -0.004 -0.035 -0.005 -0.064
18 > ccf(lret_thmy$TH, lret_thmy$MY, type=c("correlation"), lag.max = 10,
19       ylab="cross-correlation")
```

**lret\_thmy\$TH & lret\_thmy\$MY**



### 6.1.3 การทดสอบสหสัมพันธ์ไขว้

ขั้นตอนแรกก่อนที่เราจะสร้างแบบจำลองเพื่ออธิบายความสัมพันธ์เชิงพลวัตระหว่างตัวแปรพหุคือการทดสอบว่าข้อมูลของตัวแปรเหล่านั้นมีความสัมพันธ์เชิงพลวัตกัน หรือทดสอบสมมติฐานหลักว่าเมื่อพิจารณาอันไป  $m$  คาบเราไม่พบสหสัมพันธ์หรือเขียนเป็นสัญลักษณ์  $H_0 : \rho_1 = \rho_2 = \dots = \rho_m$  ในขณะที่สมมติฐานทางเลือกคือมีสหสัมพันธ์ไขว้ ณ ค่าล่าใดค่าหนึ่งมีค่าไม่เท่ากับศูนย์ หรือเขียนเป็นสัญลักษณ์  $H_1 : \rho_i \neq 0$  สำหรับค่าใดค่าหนึ่งของ  $i = 1, \dots, m$  Li and McLeod (1981) ได้เสนอการทดสอบพอร์ทแมนโทซึ่งได้ขยายการทดสอบจากตัวแปรเดียวเป็นตัวแปรพหุ ซึ่งค่าสถิติลู้งบ็อกซ์กรณีพหุตัวแปร (multivariate Ljung-Box test statistics) สามารถเขียนได้ดังนี้

$$Q_n(m) = T^2 \sum_{l=1}^m \frac{1}{T-l} \text{tr}(\widehat{\Gamma}_l' \widehat{\Gamma}_0^{-1} \widehat{\Gamma}_l \widehat{\Gamma}_0^{-1})$$

โดยที่  $\text{tr}(A)$  คือเทรซของเมทริกซ์  $A$  และ  $T$  คือจำนวนตัวอย่าง ภายใต้สมมติฐานหลักที่ถูกตั้งค่าสถิติ  $Q_n(m)$  จะมีการแจกแจงลู่เข้าสู่การแจกแจงแบบไคสแควที่มีองศาเสรีเท่ากับ  $mn^2$  ( $\chi_{mn^2}^2$ ) ดังนั้นหากค่าสถิติลู้งบ็อกซ์มากกว่าค่าวิกฤตเราจะปฏิเสธสมมติฐาน และยอมรับว่าตัวแปรมีสหสัมพันธ์ไขว้ที่ค่าล่าค่าใดค่าหนึ่ง

**ตัวอย่างที่ 6.2** เราทดสอบพอร์ทแมนโทกับผลตอบแทนรายสัปดาห์จากตลาดหลักทรัพย์ไทยและมาเลเซียด้วยคำสั่ง `mql` จากชุดคำสั่ง **MTS** ซึ่งในที่นี้เราจะเลือกค่า  $m = 10$  โดยการระบุ `lag=10` ส่วน `adj` เป็นการปรับค่าองศาเสรีซึ่งในกรณีข้อมูลเดิมเราไม่จำเป็นต้องปรับ (หากเป็นค่าเรชชีวเราจะต้องระบุพารามิเตอร์ซึ่งประมาณค่า ซึ่งจะกล่าวถึงในหัวข้อถัดไป จากผลการทดสอบที่  $m = 10$  ค่าสถิติเท่ากับ 176.5 และมีค่าพีเข้าใกล้ศูนย์ แสดงว่าเราสามารถปฏิเสธสมมติฐานหลักที่ว่าตัวแปรทั้งสองเป็นอิสระจากกันในทุกคาบเวลาไขว้

```
1 > mql(lret_thmy, lag=10, adj=0)
2 Ljung-Box Statistics:
3
```

	m	Q (m)	df	p-value	
4	[1, ]	1.0	20.4	4.0	0
5	[2, ]	2.0	65.4	8.0	0
6	[3, ]	3.0	79.2	12.0	0
7	[4, ]	4.0	102.2	16.0	0
8	[5, ]	5.0	114.6	20.0	0
9	[6, ]	6.0	125.6	24.0	0
10	[7, ]	7.0	135.5	28.0	0
11	[8, ]	8.0	151.6	32.0	0
12	[9, ]	9.0	168.3	36.0	0
13	[10, ]	10.0	176.5	40.0	0

## 6.2 แบบจำลองเวกเตอร์ออโตรีเกรสซีฟ (Vector Autoregressive Model)

กำหนดให้  $\mathbf{Y}_t = (y_{1t}, y_{2t}, \dots, y_{nt})'$  แทน  $(n \times 1)$  เวกเตอร์ของตัวแปรอนุกรมเวลาจำนวน  $n$  ตัวแปร แล้วแบบจำลองเวกเตอร์ออโตรีเกรสซีฟที่มีค่าล่าเท่ากับ  $p$  ซึ่งใช้สัญลักษณ์  $VAR(p)$  สามารถเขียนในรูป

$$\mathbf{Y}_t = \mathbf{c} + \Phi_1 \mathbf{Y}_{t-1} + \dots + \Phi_p \mathbf{Y}_{t-p} + \boldsymbol{\varepsilon}_t, \quad t = 1, 2, \dots, T \quad (6.2)$$

โดยที่  $\Phi_i$  เป็นเมทริกซ์สัมประสิทธิ์ที่มีขนาด  $n \times n$  และ  $\boldsymbol{\varepsilon}_t$  เป็นเวกเตอร์ของกระบวนการไวทนอชที่มีค่าเฉลี่ยเท่ากับศูนย์ และมีเมทริกซ์ความแปรปรวนร่วมที่ไม่แปรผันตามเวลา  $\Sigma$  ตัวอย่างเช่น หากเราสนใจแบบจำลอง  $VAR$  ที่มีตัวแปรที่เราสนใจสองตัวและมีค่าล่าเท่ากับ 1 เราสามารถเขียนในรูปเมทริกซ์ได้เป็น

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} + \begin{pmatrix} \phi_{11}^1 & \phi_{12}^1 \\ \phi_{21}^1 & \phi_{22}^1 \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad (6.3)$$

หรือเขียนเป็นรูปสมการของแต่ละตัวแปรที่เราสนใจ

$$\begin{aligned} y_{1t} &= c_1 + \phi_{11}^1 y_{1t-1} + \phi_{12}^1 y_{2t-1} + \varepsilon_{1t} \\ y_{2t} &= c_2 + \phi_{21}^1 y_{1t-1} + \phi_{22}^1 y_{2t-1} + \varepsilon_{2t} \end{aligned}$$

โดยที่  $Cov(\varepsilon_{1t}, \varepsilon_{2s}) = \sigma_{12}$  ถ้า  $s = t$  และ  $Cov(\varepsilon_{1t}, \varepsilon_{2s}) = 0$  ถ้า  $s \neq t$  (คือไม่มีสหสัมพันธ์ข้ามเวลาระหว่างข้อของตัวแปรที่ต่างกัน) จากแบบจำลองข้างต้นจะเป็นได้ว่าตัวแปร  $y_{1t}$  ถูกอธิบายด้วย ค่าในอดีตของตัวเอง  $y_{1t-1}$  และตัวแปรอื่น  $y_{2t-1}$

ค่าสัมประสิทธิ์แต่ละตัวจะเป็นค่าที่บอกความสัมพันธ์ระหว่างตัวแปรที่ต่างเวลากัน ตัวอย่างเช่น  $\phi_{12}^1$  จะแสดงความสัมพันธ์ระหว่าง  $y_{1t}$  และ  $y_{2t-1}$  ซึ่งถ้า  $\phi_{12}^1 = 0$  แล้ว  $y_{1t}$  จะไม่ขึ้นกับค่า  $y_{2t-1}$  และขึ้นอยู่กับค่าในอดีตของ  $y_{1t}$  เท่านั้น เช่นเดียวกับค่า  $\phi_{21}^1$  จะแสดงความสัมพันธ์ระหว่าง  $y_{2t}$  และ  $y_{1t-1}$  ซึ่งจะเห็นได้ว่าค่าสัมประสิทธิ์ในสมการ 6.3 อธิบายพลวัตของอนุกรมเวลาที่เราสนใจ (lead-lag) แต่ไม่ได้อธิบายความสัมพันธ์ระหว่างอนุกรมเวลาในช่วงเวลาเดียวกัน (concurrent หรือ contemporaneous) ให้อย่างชัดเจน เราสามารถดูความสัมพันธ์ดังกล่าวได้ในเมทริกซ์ความแปรปรวนของข้อ หรือพูดให้ชัดเจนคือการพิจารณาค่า  $Cov(\varepsilon_{1t}, \varepsilon_{2t})$  นั่นเอง เราเรียกแบบจำลองเวกเตอร์ออโตรีเกรสซีฟในรูป 6.3 ว่า **สมการในรูปลดรูป (reduced form)**

เราสามารถเขียนความสัมพันธ์ระหว่างอนุกรมเวลาในช่วงเดียวกันได้อย่างชัดเจนโดยใช้การแปลงรูปสมการที่ 6.3 ได้ดังนี้ เนื่องจาก  $\Sigma$  เป็นเมทริกซ์ที่มีคุณลักษณะเป็น **positive definite** ดังนั้นเราสามารถสร้างเม

ทริกซ์ lower triangular

$$L = \begin{pmatrix} 1 & 0 & \dots & 0 \\ l_{21} & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & \dots & 1 \end{pmatrix}$$

และเมตริกซ์แทนยงม  $G$  ที่ทำให้  $\Sigma = LGL'$  เราเรียกการแยกส่วนประกอบนี้ว่า Cholesky decomposition

กำหนดให้  $\eta_t = L^{-1}\varepsilon_t$  เราจะได้ว่า

$$E(\eta_t) = L^{-1}E(\varepsilon_t) = 0$$

$$Var(\eta_t) = L^{-1}Var(\varepsilon_t)(L^{-1})' = L^{-1}\Sigma(L^{-1})' = L^{-1}LGL'(L^{-1})' = G$$

เนื่องจาก  $G$  เป็นเมตริกซ์แทนยงม ดังนั้นส่วนประกอบของ  $\eta_t$  จะไม่มีความสัมพันธ์ระหว่างกัน

หากเราคูณข้างหน้าสมการ 6.2 ด้วย  $L^{-1}$  จะได้

$$L^{-1}Y_t = L^{-1}c + L^{-1}\Phi_1 Y_{t-1} + \dots + L^{-1}\Phi_p Y_{t-p} + L^{-1}\varepsilon_t, \quad t = 1, 2, \dots, T$$

$$L^{-1}Y_t = c^* + \Phi_1^* Y_{t-1} + \dots + \Phi_p^* Y_{t-p} + \eta_t \quad (6.4)$$

โดยที่เมตริกซ์  $L^{-1}$  จะแสดงความสัมพันธ์ระหว่างอนุกรมเวลาในคาบเดียวกัน และเราเรียกแบบจำลองเวกเตอร์ออโตรีเกรสซีฟในรูป 6.4 ว่าสมการในรูปโครงสร้าง (structural equation)

**ตัวอย่างที่ 6.3** การแปลงสมการในรูปลดรูปไปเป็นรูปโครงสร้าง

กำหนดให้แบบจำลองเวกเตอร์ออโตรีเกรสซีฟที่มีสองตัวแปรและมีอันดับเท่ากับหนึ่ง (หรือเรียกย่อๆ ว่า Bivariate VAR(1)) สามารถแสดงในรูปลดรูปได้ดังนี้

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 0.2 & 0.3 \\ -0.6 & 1.1 \end{pmatrix} \begin{pmatrix} y_{1,t-1} \\ y_{2,t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad (6.5)$$

โดยที่  $\Sigma = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}$  โดยที่เราสามารถใช้ Cholesky decomposition หาเมตริกซ์  $L^{-1} = \begin{pmatrix} 1 & 0 \\ -0.5 & 1 \end{pmatrix}$

หากเราคูณสมการ 6.5 ด้วย  $L^{-1}$  จะได้

$$\begin{pmatrix} 1 & 0 \\ -0.5 & 1 \end{pmatrix} \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 0.2 & 0.3 \\ -0.7 & 0.95 \end{pmatrix} \begin{pmatrix} y_{1,t-1} \\ y_{2,t-1} \end{pmatrix} + \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \end{pmatrix} \quad (6.6)$$

โดยที่  $G = Var(\eta_t) = \begin{pmatrix} 2 & 0 \\ 0 & 0.5 \end{pmatrix}$  จากสมการที่สองของ 6.6 เราสามารถเขียนความสัมพันธ์ได้เป็น

$$y_{2t} = 0.5y_{1t} - 0.7y_{1,t-1} + 0.95y_{2,t-1} + \eta_{2t}$$

ซึ่งแสดงความสัมพันธ์ระหว่าง  $y_{1t}$  และ  $y_{2t}$  ในช่วงเวลาเดียวกันไว้อย่างชัดเจน

เราจะเห็นว่าเราสามารถแปลงแบบจำลองเวกเตอร์ออโตรีเกรสซีฟในรูปลดรูปไปเป็นรูปโครงสร้างได้ด้วย Cholesky decomposition อย่างไรก็ตามในการวิเคราะห์อนุกรมเวลาเรามักจะใช้สมการในรูปลดรูป เนื่องจากเป็นรูปที่ง่ายในการประมาณค่า และเรามักจะเน้นผลในการพยากรณ์ของแบบจำลองซึ่งเราไม่สามารถใช้แบบจำลองในรูปโครงสร้างพยากรณ์ข้อมูลได้เนื่องจากเราไม่ทราบข้อมูลของอนุกรมเวลาอื่นๆในคาบเดียวกัน

### 6.2.1 เงื่อนไขการเป็นอนุกรมเวลานิ่ง

แบบจำลอง  $VAR(p)$  สามารถเขียนในรูปเครื่องหมายขยับไปข้างหลัง (lag operator) ได้ดังนี้

$$\Phi(L)Y_t = c + \varepsilon_t \quad (6.7)$$

โดยที่  $\Phi(L) = I_n - \Phi_1 L - \dots - \Phi_p L^p$  แบบจำลอง  $VAR(p)$  จะมีเสถียรภาพถ้ารากของ

$$\det(I_n - \Phi_1 z - \dots - \Phi_p z^p) = 0$$

มีค่ามากกว่าหนึ่ง (หรือโมดูลัสมากกว่าหนึ่งในกรณีจำนวนเชิงซ้อน) ถ้าสมมติให้กระบวนการดังกล่าวมีค่าในอดีตที่เป็นอนันต์ แล้วกระบวนการ  $VAR(p)$  ที่มีเสถียรภาพจะเป็นกระบวนการนิ่งและ ergodic โดยมีค่าเฉลี่ยค่าความแปรปรวนและค่าความแปรปรวนร่วมในตัวเองที่ไม่ขึ้นกับเวลา

**ตัวอย่างที่ 6.4** การพิจารณา stability ของ VAR สมมติว่าเราพิจารณาแบบจำลอง  $VAR(1)$  ของสองตัวแปรดังมีเมทริกซ์สัมประสิทธิ์ดังตัวอย่างที่ 5.1 เราสามารถเขียนแบบจำลอง  $VAR$  ในรูปของ polynomial matrix ได้ดังนี้

$$\left( \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} - \begin{bmatrix} 0.2 & 0.3 \\ -0.6 & 1.1 \end{bmatrix} L \right) \begin{bmatrix} y_{1t} \\ y_{2t} \end{bmatrix} = \begin{bmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{bmatrix}$$

โดยที่ polynomial matrix สามารถจัดรูปได้เป็น

$$\Phi(L) = \begin{bmatrix} 1 - 0.2L & -0.3L \\ 0.6L & 1 - 1.1L \end{bmatrix}$$

ซึ่งดีเทอร์มิแนนต์เท่ากับ  $|\Phi(L)| = (1 - 0.2L)(1 - 1.1L) + (0.6)(0.3)L^2 = 1 - 1.3L + 0.4L^2$  เราสามารถหาคำตอบของสมการพหุนามได้เท่ากับ 2 และ 1.25 ซึ่งต่างมีค่าสัมบูรณ์มากกว่าหนึ่ง เราสามารถสรุปได้ว่าตัวแปรในแบบจำลอง  $VAR$  ที่มีเมทริกซ์สัมประสิทธิ์ดังกล่าวเป็นตัวแปรนิ่ง (stationary) ด้วยกันทั้งคู่



## 6.3 การประมาณค่าและการเลือกค่าล่า

### 6.3.1 การประมาณค่า

การเราพิจารณาสมการ 6.2 แต่ละสมการจะมีตัวแปรที่เหมือนกัน เราสามารถพิจารณาสมการสำหรับแต่ละตัวแปรออกเป็น

$$y_i = Z\phi_i + e_i, \quad i = 1, \dots, n$$

โดยที่  $y_i$  คือ เวกเตอร์  $(T \times 1)$  ของตัวแปรตามในสมการที่  $i$  ในขณะที่  $Z$  คือเมทริกซ์  $(T \times k)$  ที่แถว  $t$  แทนด้วย  $Z'_t = (1, Y'_{t-1}, \dots, Y'_{t-p})$ ,  $k = np + 1$  และ  $\phi_i$  คือ  $(k \times 1)$  เวกเตอร์ของพารามิเตอร์ และ  $e_i$  คือ error term ที่มีเวกเตอร์ค่าความแปรปรวนร่วม  $\sigma_i^2 I_T$  จะเห็นได้ว่าแต่ละสมการสามารถประมาณค่าได้ด้วย ordinary least squares (OLS) แยกแต่ละสมการ และจะได้  $\hat{\Phi} = [\hat{\phi}_1, \dots, \hat{\phi}_n]$  เป็นเมทริกซ์  $(k \times n)$  ของค่าสัมประสิทธิ์จากการประมาณค่าด้วย OLS หากกำหนดให้เครื่องหมาย  $vec$  แทนการนำเมทริกซ์มาเรียงต่อกัน เราจะได้

$$vec(\hat{\Phi}) = \begin{pmatrix} \hat{\phi}_1 \\ \vdots \\ \hat{\phi}_n \end{pmatrix}$$

ภายใต้ข้อสมมุติที่แบบจำลองเป็นแบบกระบวนการนิ่งและ ergodic เราจะได้  $vec(\hat{\Phi})$  มีคุณสมบัติ consistent และมีการแจกแจงแบบปกติเมื่อกลุ่มตัวอย่างใหญ่โดยมีเมทริกซ์ค่าความแปรปรวนเท่ากับ

$$\widehat{aver}(vec(\hat{\Phi})) = \hat{\Sigma} \otimes (Z'Z)^{-1}$$

โดยที่  $\hat{\Sigma} = \frac{1}{T-k} \sum_{t=1}^T \hat{\varepsilon}_t \hat{\varepsilon}_t'$  และ  $\hat{\varepsilon}_t = Y_t - \hat{\Phi}' Z_t$  เป็น residuals จากการประมาณค่า

### 6.3.2 การเลือกจำนวนความล่าที่เหมาะสม

การหาความล่าที่เหมาะสมของแบบจำลองเวกเตอร์ออโตรีเกรสซีฟอาจทำได้โดยการใช้สูตรการเลือกความล่า โดยการประมาณค่าแบบจำลองเวกเตอร์ออโตรีเกรสซีฟที่มีความล่าเท่ากับ  $0, 1, \dots, p_{max}$  แล้วเลือกค่า  $p$  ที่ทำให้ค่าที่ใช้เลือกมีค่าต่ำที่สุด โดยจะมีสูตรดังนี้

$$IC(p) = \ln|\tilde{\Sigma}(p)| + c_T(n, p) \quad (6.8)$$

โดยที่  $\tilde{\Sigma}(p) = T^{-1} \sum_{t=1}^T \hat{\varepsilon}_t \hat{\varepsilon}_t'$  คือ residual covariance matrix จาก  $VAR(p)$ ,  $c_T$  คือลำดับที่ขึ้นกับจำนวนตัวอย่าง และ  $c_T(n, p)$  คือฟังก์ชันเบี่ยงปรับ (penalty function) กรณีที่เราเลือก  $n$  และ  $p$  มากๆ โดยที่แบบเกณฑ์ที่เป็นที่นิยมสามเกณฑ์ได้แก่ Akaike (AIC) Schwarz-Bayesian (BIC) และ Hannan-Quinn (HQIC)

ซึ่งแสดงได้ด้วยสมการดังนี้

$$AIC(p) = \ln |\tilde{\Sigma}(p)| + \frac{2}{T}(pn^2)$$

$$BIC(p) = \ln |\tilde{\Sigma}(p)| + \frac{\ln T}{T}(pn^2)$$

$$HQIC(p) = \ln |\tilde{\Sigma}(p)| + \frac{2\ln(\ln T)}{T}(pn^2)$$

**ตัวอย่างที่ 6.5** แบบจำลอง VAR สำหรับผลตอบแทนรายสัปดาห์ของตลาดหลักทรัพย์ไทย (SET) และ มาเลเซีย (KLSE)

ในตัวอย่างนี้เราจะพิจารณาความสัมพันธ์ระหว่างผลได้ตอบแทนรายสัปดาห์จากการลงทุนในตลาดหลักทรัพย์แห่งประเทศไทย (lret\_thmy\$TH) และตลาดหุ้นมาเลเซีย (lret\_thmy\$MY) โดยใช้ข้อมูลรายสัปดาห์ระหว่างวันที่ 2 มกราคม 2541 ถึง 31 ธันวาคม 2562 (ข้อมูลจากธนาคารแห่งประเทศไทย โดยข้อมูลที่ตลาดใดตลาดหนึ่งปิดจะถูกแทนที่ด้วยวันก่อนหน้า และข้อมูลผลได้ตอบแทนอยู่ในไฟล์ lret\_3countries\_w9819.txt) เราจะเขียนข้อมูลทั้งสองในรูปของเมตริกซ์ที่นำเวกเตอร์ทั้งสองมาต่อกันโดยใช้คำสั่ง cbind

```
1 > lret3 <- read.csv("~/lret_3countries_w9819.txt")
2 > lret_thmy<-cbind(lret3$SET, lret3$KLSE)
3 > colnames(lret_thmy)<-c("TH", "MY")
4 > rownames(lret_thmy)<-lret3$Index
```

หากเราต้องการประมาณค่าด้วยแบบจำลองเวกเตอร์ออโตรีเกรสซีฟ เราจะใช้ชุดคำสั่ง vars เราอาจจะเริ่มจากการหาค่า  $p$  ที่เหมาะสมโดยการใช้คำสั่ง VAR พร้อมระบุเมตริกซ์ของข้อมูล lret\_thmy จำนวนค่าล่าสูงสุด lag.max เท่ากับ 5 และ เกณฑ์ในการเลือกค่า  $ic=c("AIC")$  โดยที่ "SC" จะแทน Schwarz-Bayesian (BIC) และ "HQ" Hannan-Quinn (HQIC)

```
1 > library(vars)
2 > msel_aic<-VAR(lret_thmy, lag.max=5, ic=c("AIC"))
3 > msel_aic
4
5 VAR Estimation Results:
6 =====
7
8 Estimated coefficients for equation TH:
9 =====
10 Call:
11 TH = TH.l1 + MY.l1 + TH.l2 + MY.l2 + TH.l3 + MY.l3 + TH.l4 + MY.l4 +
    const
12
13      TH.l1      MY.l1      TH.l2      MY.l2      TH.l3      MY.l3      TH.l4      MY.l4
14      const
15 0.01524 0.00904 0.13483 0.12268 0.04040 0.04239 -0.13186 0.05922
16 0.08477
17 Estimated coefficients for equation MY:
```

```

18 =====
19 Call:
20 MY = TH.l1 + MY.l1 + TH.l2 + MY.l2 + TH.l3 + MY.l3 + TH.l4 + MY.l4 +
    const
21
22 TH.l1 MY.l1 TH.l2 MY.l2 TH.l3 MY.l3 TH.l4 MY.l4 const
23 0.1003 -0.0248 0.0823 0.0847 0.0372 0.0354 0.0161 -0.0721 0.0583

```

จากเกณฑ์ AIC จะเห็นได้ว่าค่าที่เหมาะสมคือ  $p = 4$  ถ้าลองใช้เกณฑ์ SIC จะได้ค่าที่เหมาะสมเท่ากับ  $p = 2$  ดังนั้นเราจะเลือกใช้  $p = 2$  ในการสร้างแบบจำลอง model1

```

1 > msel_bic<-VAR(lret_thmy, lag.max=5, ic=c("SC"))
2 > msel_bic
3
4 VAR Estimation Results:
5 =====
6
7 Estimated coefficients for equation TH:
8 =====
9 Call:
10 TH = TH.l1 + MY.l1 + TH.l2 + MY.l2 + const
11
12 TH.l1 MY.l1 TH.l2 MY.l2 const
13 0.0247 0.0051 0.1273 0.0950 0.1027
14
15
16 Estimated coefficients for equation MY:
17 =====
18 Call:
19 MY = TH.l1 + MY.l1 + TH.l2 + MY.l2 + const
20
21 TH.l1 MY.l1 TH.l2 MY.l2 const
22 0.1102 -0.0361 0.0833 0.0786 0.0737
23
24 > model1<-VAR(lret_thmy, p=2)
25 > summary(model1)
26
27 VAR Estimation Results:
28 =====
29 Endogenous variables: TH, MY
30 Deterministic variables: const
31 Sample size: 1147
32 Log Likelihood: -5497.069
33 Roots of the characteristic polynomial:
34 0.47 0.408 0.148 0.0737
35 Call:
36 VAR(y = lret_thmy, p = 2)
37
38
39 Estimation results for equation TH:
40 =====
41 TH = TH.l1 + MY.l1 + TH.l2 + MY.l2 + const
42

```

```

43      Estimate Std. Error t value Pr(>|t|)
44 TH.l1    0.0248    0.0319   0.78   0.438
45 MY.l1    0.0051    0.0413   0.12   0.902
46 TH.l2    0.1273    0.0321   3.96 7.9e-05 ***
47 MY.l2    0.0950    0.0410   2.32  0.021 *
48 const    0.1027    0.0941   1.09  0.275
49 ---
50 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
51
52 Residual standard error: 3.18 on 1142 degrees of freedom
53 Multiple R-Squared:  0.0307,    Adjusted R-squared:  0.0273
54 F-statistic: 9.03 on 4 and 1142 DF,  p-value: 3.51e-07
55
56 Estimation results for equation MY:
57 =====
58 MY = TH.l1 + MY.l1 + TH.l2 + MY.l2 + const
59
60      Estimate Std. Error t value Pr(>|t|)
61 TH.l1    0.1102    0.0243   4.54 6.3e-06 ***
62 MY.l1   -0.0361    0.0315  -1.15 0.25179
63 TH.l2    0.0833    0.0245   3.41 0.00068 ***
64 MY.l2    0.0786    0.0312   2.52 0.01196 *
65 const    0.0737    0.0716   1.03 0.30389
66 ---
67 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
68
69 Residual standard error: 2.42 on 1142 degrees of freedom
70 Multiple R-Squared:  0.0436,    Adjusted R-squared:  0.0403
71 F-statistic: 13 on 4 and 1142 DF,  p-value: 2.27e-10
72
73 Covariance matrix of residuals:
74      TH    MY
75 TH 10.1 3.00
76 MY  3.0 5.86
77
78 Correlation matrix of residuals:
79      TH    MY
80 TH 1.000 0.389
81 MY 0.389 1.000

```

จากผลการประมาณค่าจะเห็นได้ว่าสัมประสิทธิ์ส่วนใหญ่มีนัยสำคัญทางสถิติ และเราสามารถเขียนสมการแสดงผลการประมาณค่าสำหรับสมการของ  $\log$  return ของตลาดหุ้นไทย ( $r_{th,t}$ ) และมาเลเซีย ( $r_{my,t}$ ) ได้ดังนี้

$$r_{th,t} = 0.1027 + 0.0248r_{th,t-1} + 0.0051r_{my,t-1} + 0.1273r_{th,t-2} + 0.095r_{my,t-2}$$

$$r_{my,t} = 0.0737 + 0.1102r_{th,t-1} - 0.0361r_{my,t-1} + 0.0833r_{th,t-2} + 0.0786r_{my,t-2}$$

## 6.4 การพยากรณ์จากแบบจำลองเวกเตอร์ออโตรีเกรสซีฟ

เป้าหมายหลักประการหนึ่งของการพัฒนาแบบจำลองเวกเตอร์ออโตรีเกรสซีฟ ( $VAR(p)$ ) คือการพยากรณ์จากแบบจำลองดังกล่าวเช่นเดียวกับแบบจำลองออโตรีเกรสซีฟ ( $AR(p)$ ) หากเราพิจารณาแบบจำลองเวกเตอร์ออโตรีเกรสซีฟอันดับหนึ่ง ( $VAR(1)$ ) ซึ่งแสดงได้ด้วยสมการต่อไปนี้

$$\mathbf{Y}_t = \Phi \mathbf{Y}_{t-1} + \varepsilon_t$$

เราต้องการพยากรณ์ไปข้างหน้าหนึ่งคาบด้วยข้อมูลที่มี ณ เวลาที่  $h$  หรือพยากรณ์ค่า

$$\mathbf{Y}_{h+1} = \Phi \mathbf{Y}_h + \varepsilon_{h+1} \quad (6.9)$$

เราหาค่าพยากรณ์โดยการคำนวณค่าคาดหวังอย่างมีเงื่อนไข (conditional expectation) ด้วยข้อมูล  $h$ ,  $E_h(\mathbf{Y}_{h+1})$ , เราจะได้ค่าพยากรณ์เท่ากับ

$$\widehat{\mathbf{Y}}_h(1) = E_h(\mathbf{Y}_{h+1}) = \Phi \mathbf{Y}_h + \underbrace{E_h(\varepsilon_{h+1})}_{=0} = \Phi \mathbf{Y}_h \quad (6.10)$$

และค่าคาดเคลื่อนของการพยากรณ์ (forecast error) ของการพยากรณ์ไปข้างหน้าหนึ่งคาบ,  $e(1)$ , จะเท่ากับ

$$e(1) = \mathbf{Y}_{h+1} - E_h(\mathbf{Y}_{h+1}) = \varepsilon_{h+1} \quad (6.11)$$

หากพิจารณากรณีตัวแปรสองตัวแปร  $\mathbf{Y}_t = [Y_{1t} \ Y_{2t}]'$  เราจะพบว่า

$$\widehat{Y}_{1,h}(1) = \phi_{11} Y_{1,h} + \phi_{12} Y_{2,h}$$

$$\widehat{Y}_{2,h}(1) = \phi_{21} Y_{1,h} + \phi_{22} Y_{2,h}$$

$$e_1(1) = \varepsilon_{1,h+1}$$

$$e_2(1) = \varepsilon_{2,h+1}$$

ซึ่งแสดงให้เห็นว่าค่าพยากรณ์ของ  $Y_{1t}$  และ  $Y_{2t}$  ขึ้นอยู่กับตัวแปรทั้งสองในอดีต

สำหรับค่าพยากรณ์สองคาบข้างหน้า เมื่อเราพิจารณาค่าจริง ณ เวลาที่  $h+2$ ,  $\mathbf{Y}_{h+2}$ , จะเท่ากับ

$$\mathbf{Y}_{h+2} = \Phi \mathbf{Y}_{h+1} + \varepsilon_{h+2} = \Phi(\Phi \mathbf{Y}_h + \varepsilon_{h+1}) + \varepsilon_{h+2} = \Phi^2 \mathbf{Y}_h + \Phi \varepsilon_{h+1} + \varepsilon_{h+2} \quad (6.12)$$

เราหาค่าพยากรณ์โดยการคำนวณค่าคาดหวังอย่างมีเงื่อนไขด้วยข้อมูล  $h$  เท่ากับ

$$\widehat{Y}_h(2) = E_h(Y_{h+2}) = \Phi^2 Y_h + \underbrace{\Phi E_h(\varepsilon_{h+1})}_{=0} + \underbrace{E_h(\varepsilon_{h+2})}_{=0} = \Phi^2 Y_h \quad (6.13)$$

และค่าคาดเคลื่อนของการพยากรณ์ (forecast error) ของการพยากรณ์ไปข้างหน้าสองคาบ,  $e(2)$  จะเท่ากับ

$$e(2) = Y_{h+2} - E_h(Y_{h+2}) = \Phi \varepsilon_{h+1} + \varepsilon_{h+2} \quad (6.14)$$

เมื่อเราพิจารณากรณีของตัวแปรสองตัวแปร เราจะเห็นได้ว่าค่าคาดเคลื่อนของการพยากรณ์ไปข้างหน้าสองคาบของแต่ละตัวแปรจะขึ้นอยู่กับข้อคของตัวแปรทุกตัวในแบบจำลองดังที่แสดงในสมการต่อไปนี้

$$e_1(2) = \phi_{11}\varepsilon_{1,h+1} + \phi_{12}\varepsilon_{2,h+1} + \varepsilon_{1,h+2} \quad (6.15)$$

$$e_2(2) = \phi_{21}\varepsilon_{1,h+1} + \phi_{22}\varepsilon_{2,h+1} + \varepsilon_{2,h+2} \quad (6.16)$$

ค่าพยากรณ์ไปข้างหน้าสองคาบ  $Y_{h+2}$  ด้วยข้อมูลที่มี ณ คาบที่  $h$  จะเท่ากับ

$$\widehat{Y}_h(2) = c + \Phi_1 \widehat{Y}_h(1) + \dots + \Phi_p Y_{h+2-p} \quad (6.17)$$

โดยที่ค่าความผิดพลาดจากการพยากรณ์ (forecast error) เท่ากับ  $e(2) = Y_{h+2} - \widehat{Y}_h(2) = \varepsilon_{h+2} + \Phi_1 [\widehat{Y}_h(1) - Y_{h+1}] = \varepsilon_{h+2} + \Phi_1 \varepsilon_{h+1}$  หากเราดำเนินการด้วยวิธีการเดิมไปเรื่อยๆ จะได้ค่าพยากรณ์ไปข้างหน้า  $l$  คาบ ( $Y_{h+l}$ ) ด้วยข้อมูลที่มี ณ คาบที่  $h$  เท่ากับ

$$\widehat{Y}_h(l) = E_h(Y_{h+l}) = \Phi^l Y_h \quad (6.18)$$

ในขณะที่ค่าคาดเคลื่อนของการพยากรณ์ไปข้างหน้า  $l$  คาบจะเท่ากับ

$$e(l) = \Phi^{l-1} \varepsilon_{h+1} + \Phi^{l-2} \varepsilon_{h+2} + \Phi^{l-3} \varepsilon_{h+3} + \dots + \varepsilon_{h+l} \quad (6.19)$$

จากสมการ (6.18) เราจะเห็นได้ว่าแบบจำลอง VAR สามารถนำมาใช้ในการสร้างค่าพยากรณ์ตัวแปรต่างๆ ได้ง่าย และใช้เพียงแค่ตัวแปร ณ เวลาที่  $h$  หรือก่อนหน้า  $h$

นอกจากนี้หากเราต้องพยากรณ์แบบช่วง เราสามารถแสดงช่วงความเชื่อมั่น  $(1 - \alpha)\%$  ของการพยากรณ์ได้ด้วย

$$\widehat{Y}_{i,h}(l) \pm z_{\alpha/2} \sqrt{\text{Var}(e_i(l))}$$

โดยที่  $z$  คือค่าวิกฤตจากการแจกแจงแบบปกติ และ  $e_i(l)$  คือค่าคาดเคลื่อนการพยากรณ์ของตัวแปร  $i$

ในกรณีของแบบจำลองเวกเตอร์ออโตรีเกรสซีฟในรูปแบบโครงสร้าง (structural form VAR) เราสามารถสร้างค่าพยากรณ์ได้ด้วยวิธีการเดียวกัน ยกตัวอย่างเช่น แบบจำลองเวกเตอร์ออโตรีเกรสซีฟในรูปแบบ

โครงสร้างอันดับหนึ่งที่มีตัวแปรสองตัวแปร และอธิบายความสัมพันธ์ด้วยสมการดังต่อไปนี้

$$\begin{bmatrix} 1 & 0 \\ l_{21} & 1 \end{bmatrix} \begin{bmatrix} Y_{1t} \\ Y_{2t} \end{bmatrix} = \begin{bmatrix} \phi_{11}^* & \phi_{12}^* \\ \phi_{21}^* & \phi_{22}^* \end{bmatrix} \begin{bmatrix} Y_{1,t-1} \\ Y_{2,t-1} \end{bmatrix} + \begin{bmatrix} \eta_{1t} \\ \eta_{2t} \end{bmatrix} \quad (6.20)$$

ค่าพยากรณ์  $Y_{1t}$  ไปข้างหน้าหนึ่งคาบเท่ากับ

$$E_h(Y_{1,h+1}) = \phi_{11}^* Y_{1,h} + \phi_{12}^* Y_{2,h}$$

และค่าคลาดเคลื่อนของการพยากรณ์  $Y_{1t}$  ไปข้างหน้าหนึ่งคาบ,  $e_1(1)$ , เท่ากับ

$$e_1(1) = Y_{1,h+1} - E_h(Y_{1,h+1}) = \eta_{1,h+1}$$

ในขณะที่ค่าพยากรณ์  $Y_{2t}$  ไปข้างหน้าหนึ่งคาบเท่ากับ

$$E_h(Y_{2,h+1}) = -l_{21} E_h(Y_{1,h+1}) + \phi_{21}^* Y_{1,h} + \phi_{22}^* Y_{2,h}$$

และค่าคลาดเคลื่อนของการพยากรณ์  $Y_{2t}$  ไปข้างหน้าหนึ่งคาบ,  $e_2(1)$ , เท่ากับ

$$\begin{aligned} e_2(1) &= Y_{2,h+1} - E_h(Y_{2,h+1}) = -l_{21}(Y_{1,h+1} - E_h(Y_{1,h+1})) + \eta_{2,h+1} \\ &= -l_{21}\eta_{1,h+1} + \eta_{2,h+1} \end{aligned} \quad (6.21)$$

**ตัวอย่างที่ 6.6** การพยากรณ์จากแบบจำลอง VAR เราสามารถทำนายผลได้ตอบแทนไปข้างหน้าของทั้งสองตลาดที่เราสนใจได้ด้วยคำสั่ง `predict` โดยระบุแบบจำลองที่ใช้และคาบที่ทำนายไปข้างหน้า

```
1 > model1.predict<-predict(model1, n.ahead=5)
2 > model1.predict
3 $TH
4           fcst lower upper  CI
5 [1,]  0.14364 -6.09   6.38 6.23
6 [2,] -0.00965 -6.24   6.23 6.24
7 [3,]  0.13630 -6.19   6.46 6.32
8 [4,]  0.10392 -6.22   6.43 6.33
9 [5,]  0.13238 -6.20   6.46 6.33
10
11 $MY
12           fcst lower upper  CI
13 [1,]  0.1644 -4.58   4.91 4.75
14 [2,] -0.0153 -4.80   4.77 4.79
15 [3,]  0.0980 -4.75   4.94 4.85
16 [4,]  0.0832 -4.77   4.93 4.85
17 [5,]  0.1012 -4.75   4.95 4.85
```

เราจะได้ผลการพยากรณ์ดังแสดงได้ด้วยตารางดังต่อไปนี้

ตารางที่ 6.1: การพยากรณ์ผลได้ตอบแทนรายสัปดาห์ของตลาดหลักทรัพย์ไทยและมาเลเซียจากแบบจำลอง VAR(2)

คาบไปข้างหน้า	1	2	3	4	5
log return ของตลาดหุ้นไทย	0.144	-0.010	0.136	0.104	0.132
log return ของตลาดหุ้นมาเลเซีย	0.164	-0.015	0.098	0.083	0.101

## 6.5 การวิเคราะห์หลังจากการประมาณค่าแบบจำลองเวกเตอร์ออโตรีเกรสซีฟ

แบบจำลองเวกเตอร์ออโตรีเกรสซีฟโดยทั่วไปแล้วจะมีพารามิเตอร์จำนวนมากและอาจมีความยุ่งยากในการพิจารณาเนื่องจากความขึ้นอยู่ต่อกันอันจะส่งผลไปมาระหว่างตัวแปร ดังนั้นในการอธิบายความสัมพันธ์ระหว่างตัวแปรจะต้องมีการวิเคราะห์เพิ่มเติมไม่สามารถดูความสัมพันธ์ได้จากแบบจำลองเลยเช่นเดียวกับแบบจำลองอนุกรมเวลาอย่างง่าย

### 6.5.1 Granger Causality

โครงสร้างของแบบจำลอง VAR ช่วยให้ข้อมูลกับเราว่าตัวแปรหรือกลุ่มของตัวแปรมีความสามารถในการทำนายตัวแปรอื่นหรือไม่ โดยแนวคิดเกี่ยวกับความสามารถในการทำนายถูกนำเสนอโดย Granger (1969) ว่า ถ้าตัวแปร  $y_1$  ช่วยในการทำนายตัวแปรอื่น  $y_2$  เราจะเรียกว่า  $y_1$  แกรงเจอร์คอส (Granger-cause)  $y_2$  แต่ถ้า  $y_1$  ไม่ช่วยในการทำนายตัวแปร  $y_2$  เราจะพูดว่า  $y_1$  ไม่แกรงเจอร์คอส (does not Granger-cause)  $y_2$

นิยามอย่างเป็นทางการคือ หาก  $y_1$  ไม่แกรงเจอร์คอส (does not Granger-cause)  $y_2$  แสดงว่าทุกค่าของ  $s > 0$  ค่า MSE ของการพยากรณ์  $y_{2,t+s}$  ด้วยข้อมูลจาก  $(y_{2,t}, y_{2,t-1}, \dots)$  ไม่มีความแตกต่างจาก ค่า MSE ของการพยากรณ์  $y_{2,t+s}$  ด้วยข้อมูลจาก  $(y_{2,t}, y_{2,t-1}, \dots)$  และ  $(y_{1,t}, y_{1,t-1}, \dots)$  เราจะต้องระลึกไว้อยู่เสมอว่า แกรงเจอร์คอสเป็นการอนุมานไปยังความสามารถในการพยากรณ์เท่านั้น ไม่ได้เป็นเหตุเป็นผลจริงๆ ของตัวแปร

#### ตัวอย่างกรณีตัวแปรสองตัว

ในหัวข้อนี้เราพิจารณาแบบจำลอง VAR(2) ที่มีตัวแปรสองตัว ซึ่งสามารถเขียนเป็นสมการได้ดังนี้

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} + \begin{pmatrix} \phi_{11}^1 & \phi_{12}^1 \\ \phi_{21}^1 & \phi_{22}^1 \end{pmatrix} \begin{pmatrix} y_{1,t-1} \\ y_{2,t-1} \end{pmatrix} + \begin{pmatrix} \phi_{11}^2 & \phi_{12}^2 \\ \phi_{21}^2 & \phi_{22}^2 \end{pmatrix} \begin{pmatrix} y_{1,t-2} \\ y_{2,t-2} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad (6.22)$$

ในสมการที่ (6.22) หาก  $y_{2t}$  ไม่แกรงเจอร์คอส  $y_{1t}$  ค่าสัมประสิทธิ์  $\phi_{12}^1$  และ  $\phi_{12}^2$  จะมีค่าเท่ากับศูนย์ในทางตรงข้าม ถ้า  $y_{1t}$  ไม่แกรงเจอร์คอส  $y_{2t}$  ค่าสัมประสิทธิ์  $\phi_{21}^1$  และ  $\phi_{21}^2$  จะมีค่าเท่ากับศูนย์



ดังนั้นในการทดสอบว่า  $y_{2t}$  แกรงเจอร์คอส  $y_{1t}$  หรือไม่ เราจะตั้งสมมุติฐานหลักว่า  $H_0 : \phi_{12}^1 = \phi_{12}^2 = 0$  และสมมุติฐานทางเลือกคือมีสัมประสิทธิ์  $\phi_{12}^1$  หรือ  $\phi_{12}^2$  ตัวใดตัวหนึ่งมีค่าไม่เท่ากับศูนย์ ซึ่งการทดสอบดังกล่าวคือการทดสอบหลายเงื่อนไขหรือการทดสอบเอฟ(F-test) นั่นเอง

**ตัวอย่างที่ 6.7** การทดสอบ Granger Causality จากแบบจำลอง VAR ต่อเนื่องจากตัวอย่าง 5.3 เราต้องการทดสอบว่า `lret_thmy$TH` แกรงเจอร์คอส `lret_thmy$MY` หรือไม่ (สมมุติฐานหลักคือ `lret_thmy$TH` ไม่แกรงเจอร์คอส `lret_thmy$MY`) เราสามารถทดสอบโดยใช้คำสั่ง `causality` โดยที่เราจะต้องระบุแบบจำลองที่ใช้และตัวแปรที่เป็นสาเหตุ (cause) ซึ่งในที่นี้คือ `lret_thmy$TH`

```
1 > causality(model1, cause="TH")
2 $Granger
3
4      Granger causality H0: TH do not Granger-cause MY
5
6 data:  VAR object model1
7 F-Test = 16, df1 = 2, df2 = 2284, p-value = 2e-07
8
9 $Instant
10
11      H0: No instantaneous causality between: TH and MY
12
13 data:  VAR object model1
14 Chi-squared = 151, df = 1, p-value <2e-16
```

จากบรรทัดที่ 2-5 เป็นผลการทดสอบแกรงเจอร์คอส โดยที่ค่าสถิติ F ที่ได้คือ 16 หรือมีค่าที่เท่ากับ  $2 \times 10^{-7}$  ดังนั้นเราสามารถปฏิเสธสมมุติฐานหลักได้ด้วยระดับนัยสำคัญ 5 % เราสรุปได้ว่า `lret_thmy$TH` แกรงเจอร์คอส `lret_thmy$MY` หรือการทราบผลตอบแทนของตลาดหุ้นไทยช่วยในการพยากรณ์ผลตอบแทนในตลาดหุ้นมาเลเซีย

นอกจากนี้บรรทัดที่ 7-10 ได้ทดสอบความสัมพันธ์ในระหว่างช่วงเวลาเดียวกัน (instantaneous causality)

### 6.5.2 ฟังก์ชันตอบสนองแรงกระตุ้น

การทดสอบสมมุติฐานสำหรับกลุ่มสัมประสิทธิ์ (การทดสอบด้วยตัวสถิติ F) หรือการทดสอบแกรงเจอร์คอสช่วยระบุว่าตัวแปรใดๆ มีผลกระทบอย่างมีนัยสำคัญต่อตัวแปรอื่นหรือไม่ อย่างไรก็ตาม การทดสอบดังกล่าวไม่ได้บอกทิศทางของความสัมพันธ์และระยะเวลาที่การเปลี่ยนแปลงของตัวแปรหนึ่งจะส่งผลต่ออีกตัวแปรว่าจะมีผลยาวนานแค่ไหน โดยที่เครื่องมือที่จะใช้ศึกษาความสัมพันธ์ดังกล่าวคือฟังก์ชันตอบสนองแรงกระตุ้น (impulse response function) โดยที่นิยามคือ การตอบสนองของตัวแปรตามอันเนื่องมาจากการเปลี่ยนแปลงของตัวแปรอีกตัวหนึ่ง โดยที่หากเกิดการเปลี่ยนแปลงในช็อกหนึ่งหน่วยจะส่งผลอย่างไรต่อแต่ละตัวแปรในคาบที่ต่อจากการเปลี่ยนแปลงนั้นๆ (เนื่องจากบางกรณีขนาดของตัวแปรที่เราสนใจอาจจะมีหน่วยที่ต่างกันมาก เราอาจจะใช้การเปลี่ยนแปลงหนึ่ง s.d.)

ตัวอย่างเช่น หากเราพิจารณาแบบจำลอง  $VAR(1)$  ที่มีตัวแปรสองตัวแปร ซึ่งสามารถแสดงได้ด้วยสมการ

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad (6.23)$$

สมมติว่าเราพิจารณาว่าในปีที่ 0 เกิดช็อกในตัวแปร  $y_{1t}$  หนึ่งหน่วย ( $\varepsilon_{10} = 1$ ) และช็อกในตัวแปร  $y_{2t}$  เท่ากับศูนย์ และช็อกในปีอื่นๆเท่ากับศูนย์ สมมติให้  $y_{1t}$  และ  $y_{2t}$  เท่ากับศูนย์ในปีก่อนหน้าปี 0 จะได้ว่า

$$\begin{aligned} Y_0 &= \begin{pmatrix} \varepsilon_{10} \\ \varepsilon_{20} \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \\ Y_1 &= \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} Y_0 = \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.5 \\ 0 \end{pmatrix} \\ Y_2 &= \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} Y_1 = \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} \begin{pmatrix} 0.25 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.25 \\ 0 \end{pmatrix} \\ &\vdots \end{aligned}$$

หรือในหากเราพิจารณา เกิดช็อกในตัวแปร  $y_{2t}$  หนึ่งหน่วย ( $\varepsilon_{20} = 1$ ) และช็อกในตัวแปร  $y_{1t}$  เท่ากับศูนย์ และช็อกในปีอื่นๆเท่ากับศูนย์ สมมติให้  $y_{1t}$  และ  $y_{2t}$  เท่ากับศูนย์ในปีก่อนหน้าปี 0 จะได้ว่า

$$\begin{aligned} Y_0 &= \begin{pmatrix} \varepsilon_{10} \\ \varepsilon_{20} \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \\ Y_1 &= \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} Y_0 = \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0.3 \\ 0.2 \end{pmatrix} \\ &\vdots \end{aligned}$$

**ฟังก์ชันตอบสนองแรงกระตุ้นในกรณีทั่วไป**

ในกรณี  $VAR(p)$  ที่เป็นกระบวนการนิ่งใดๆ จะสามารถแสดงในรูป Wold ดังนี้

$$Y_t = \mu + \varepsilon_t + \Psi_1 \varepsilon_{t-1} + \Psi_2 \varepsilon_{t-2} + \dots \quad (6.24)$$

โดยที่  $\Psi_i$  คือ  $n \times n$  เมทริกซ์ของสัมประสิทธิ์ moving average โดยที่ค่าสัมประสิทธิ์ดังกล่าวสามารถคำนวณได้จาก

$$(I - \Phi_1 L - \dots - \Phi_p L^p)(I + \Psi_1 L + \Psi_2 L^2 + \dots) = I$$

จากสมการ (6.24) เราอาจต้องการที่จะอธิบาย  $\phi_{ij}^s$  ว่าเป็นการเปลี่ยนแปลงของ

$$\frac{\partial y_{i,t+s}}{\partial \varepsilon_{j,t}} = \frac{\partial y_{i,t}}{\partial \varepsilon_{j,t-s}} = \psi_{i,j}^s$$

อย่างไรก็ตามคำอธิบายข้างต้นจะเป็นจริงหากเมทริกซ์ความแปรปรวนและความแปรปรวนร่วม  $\text{var}(\varepsilon) = \Sigma$  เป็นเมทริกซ์ทแยงมุม หรือไม่มีความสัมพันธ์  $\varepsilon_t$  ในคาบเดียวกัน

Sims (1980) เสนอให้ประมาณค่าด้วยแบบจำลอง triangular structural VAR(p)

$$\begin{aligned} y_{1t} &= c_1 + \gamma'_{11} \mathbf{Y}_{t-1} + \dots + \gamma'_{1p} \mathbf{Y}_{t-p} + \eta_{1t} \\ y_{2t} &= c_2 + \beta_{21} y_{1t} + \gamma'_{21} \mathbf{Y}_{t-1} + \dots + \gamma'_{2p} \mathbf{Y}_{t-p} + \eta_{2t} \\ y_{3t} &= c_3 + \beta_{31} y_{1t} + \beta_{32} y_{2t} + \gamma'_{31} \mathbf{Y}_{t-1} + \dots + \gamma'_{3p} \mathbf{Y}_{t-p} + \eta_{3t} \\ &\vdots \\ y_{nt} &= c_n + \beta_{n1} y_{1t} + \dots + \beta_{n,n-1} y_{n-1,t} + \gamma'_{n1} \mathbf{Y}_{t-1} + \dots + \gamma'_{np} \mathbf{Y}_{t-p} + \eta_{nt} \end{aligned} \quad (6.25)$$

เราสามารถเขียนความสัมพันธ์ดังกล่าวในรูปของเมทริกซ์ดังนี้

$$\mathbf{B}\mathbf{Y}_t = \mathbf{c} + \mathbf{\Gamma}_1 \mathbf{Y}_{t-1} + \dots + \mathbf{\Gamma}_p \mathbf{Y}_{t-p} + \boldsymbol{\eta}_t \quad (6.26)$$

โดยที่

$$\mathbf{B} = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ -\beta_{21} & 1 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ -\beta_{n1} & -\beta_{n2} & -\beta_{n3} & \dots & 1 \end{pmatrix}$$

โดยที่ Orthogonal error ( $\eta_t$ ) หรือ error ที่ไม่มีความสัมพันธ์ระหว่างกัน ซึ่งก็คือ structural errors

โครงสร้างแบบจำลองโครงสร้าง (structural model) อย่างในสมการ (6.25) จะกำหนดให้ความสัมพันธ์ของตัวแปรมีลำดับคือ  $y_1$  เป็นตัวกำหนด  $y_2$  และ  $y_2$  เป็นตัวกำหนด  $y_3$  เป็นลำดับไปเรื่อยๆ

$$y_1 \longrightarrow y_2 \longrightarrow y_3 \longrightarrow \dots \longrightarrow y_n$$

แสดงว่าค่าของตัวแปรด้านซ้ายจะกระทบตัวแปรด้านขวาในคาบเดียวกัน (contemporaneous) แต่ตัวแปรด้านขวาจะต้องใช้เวลาหนึ่งคาบถึงจะกระทบกลับมายังตัวแปรด้านซ้าย โดยที่ผลกระทบในคาบเดียวกันจะสะท้อนผ่านตัวแปร  $\beta_{ij}$  โดยที่ลำดับของการเรียงตัวแปรในแบบจำลอง VAR(p) ตามสมการที่ (6.25) จะขึ้นอยู่กับทฤษฎีเป็นตัวกำหนด

หลังจากที่เราได้จัดเรียงตัวแปรแล้ว Wold representation ของ  $\mathbf{Y}_t$  จากค่าช็อกเชิงตั้งฉาก (orthogonal er-

rors) ได้เป็น

$$Y_t = \mu + \Theta_0 \eta_t + \Theta_1 \eta_{t-1} + \Theta_2 \eta_{t-2} + \dots \quad (6.27)$$

โดยที่  $\Theta_0 = B^{-1}$  และการตอบสนองแรงกระตุ้นจากช็อกเชิงตั้งฉาก  $\eta_{jt}$  จะเท่ากับ

$$\frac{\partial y_{i,t+s}}{\partial \eta_{j,t}} = \frac{\partial y_{i,t}}{\partial \eta_{j,t-s}} = \theta_{ij}^s, \quad i, j = 1, \dots, n; s > 0 \quad (6.28)$$

โดยที่  $\theta_{ij}^s$  คือ ตำแหน่ง  $(i, j)$  ของเมทริกซ์  $\Theta_s$  เราเรียกแผนภาพที่วาด  $\theta_{ij}^s$  ในแกนตั้งและ  $s$  ในแกนนอนว่า ฟังก์ชันตอบสนองแรงกระตุ้นเชิงตั้งฉาก (orthogonal impulse response function) ของ  $y_i$  จากช็อก  $\eta_j$

ในทางปฏิบัติเราสามารถคำนวณ ฟังก์ชันตอบสนองแรงกระตุ้นเชิงตั้งฉากจากผลการประมาณค่า reduced VAR ในสมการ 6.2 ได้ด้วยการแยกส่วนประกอบ(decompose)ของ เมทริกซ์ค่าความแปรปรวนร่วมของ residuals  $\Sigma$  ด้วย Cholesky decomposition ดังนี้  $\Sigma = LGL'$  และ  $\eta_t = L^{-1}\varepsilon_t$  จากความสัมพันธ์ดังกล่าวเราสามารถเขียน Wold representation ในสมการ 6.24 ใหม่ได้เป็น

$$\begin{aligned} Y_t &= \mu + LL^{-1}\varepsilon_t + \Psi_1 LL^{-1}\varepsilon_{t-1} + \Psi_2 LL^{-1}Y_{t-2} + \dots \\ &= \mu + \Theta_0 \eta_t + \Theta_1 \eta_{t-1} + \Theta_2 \eta_{t-2} + \dots \end{aligned} \quad (6.29)$$

โดยที่  $\Theta_j = \Psi_j L$  โดยที่เมทริกซ์  $B$  ในสมการ 6.26 คือ  $L^{-1}$  นั่นเอง

**ตัวอย่างที่ 6.8** การสร้าง Impulse Response Function จากแบบจำลอง VAR ต่อเนื่องจากตัวอย่าง โดยเราจะสร้าง Impulse response function ด้วยคำสั่ง irf โดยที่ default ในคำสั่งนี้คือการสร้าง orthogonal impulse response function (ortho=TRUE) โดยในคำสั่งนี้เราจะระบุแบบจำลองที่ใช้และคาบที่เราดูผลหลังจากที่เรา shock 1 s.d. โดยที่การเรียงตัวแปรใน lret ที่เรียง lret\_thmy\$TH ก่อน lret\_thmy\$MY หมายความว่าเราสมมติให้ structural shock ของ lret\_thmy\$MY ไม่มีผลทันที(contemporaneous)ต่อ lret\_thmy\$TH แต่ structural shock ของ lret\_thmy\$TH มีผลทันทีต่อ lret\_thmy\$MY

```
1 > model1.irf<-irf(model1, n.ahead=5)
2 > model1.irf
3
4 Impulse response coefficients
5 $TH
6           TH      MY
7 [1,] 3.180 0.942
8 [2,] 0.084 0.316
9 [3,] 0.498 0.337
10 [4,] 0.055 0.075
11 [5,] 0.097 0.071
12 [6,] 0.017 0.019
13
14 $MY
15           TH      MY
```

```


16 [1,] 0.0e+00 2.2303
17 [2,] 1.1e-02 -0.0805
18 [3,] 2.1e-01 0.1795
19 [4,] -4.3e-05 0.0115
20 [5,] 4.4e-02 0.0313
21 [6,] 2.3e-03 0.0046
22 > plot(model1.irf)

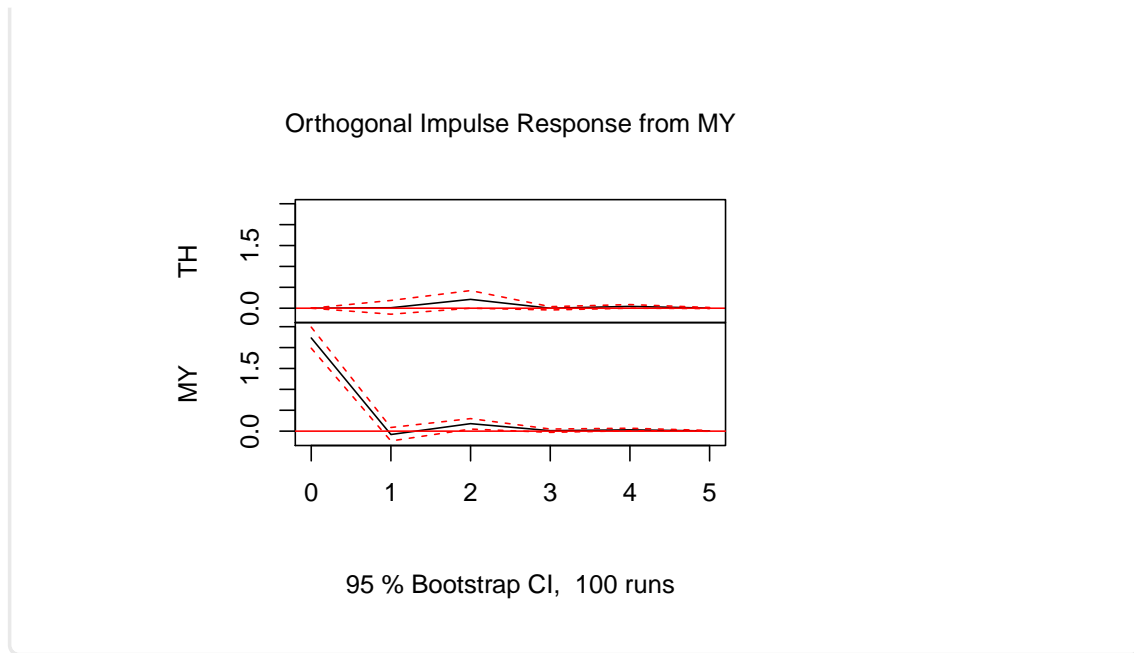
```

ส่วนแรก \$TH\$ เป็นผลจากการเปลี่ยนแปลงใน structural shock ของ `lret_thmy$TH` หนึ่ง s.d. (=3.18) ในคาบที่ศูนย์ (ในที่นี้แทนด้วยบรรทัดที่ [1]) ทำให้ `lret_thmy$MY` เปลี่ยนแปลงทันที 0.942 และส่งผลต่อ `lret_thmy$TH` และ `lret_thmy$MY` ในคาบที่ 1 (หลังจาก shock) เท่ากับ 0.084 และ 0.316 ตามลำดับ (ในที่นี้แทนด้วยบรรทัดที่ [2])

ส่วนสอง เป็นผลจากการเปลี่ยนแปลงใน structural shock ของ `lret_thmy$MY` หนึ่ง s.d.(=2.23) ในคาบที่ศูนย์ (ในที่นี้แทนด้วยบรรทัดที่ [1]) ไม่ทำให้ `lret_thmy$TH` เปลี่ยนแปลงในคาบที่เกิดช็อก แต่ส่งผลในคาบต่อไป

นอกจากนี้คำสั่งดังกล่าวยังให้ช่วงความเชื่อมั่น 95% และเราสามารถสร้างกราฟ IRF ได้ด้วยคำสั่ง `plot(model1.irf)` จะได้รูปต่อไปนี้





### 6.5.3 การแยกความแปรปรวนของค่าคาดเคลื่อนการพยากรณ์

จากหัวข้อการพยากรณ์จากแบบจำลองเวกเตอร์ออโตรีเกรสซีฟ เราจะเห็นได้ว่าค่าพยากรณ์ของตัวแปรแต่ละตัวแปรนั้นขึ้นอยู่กับทั้งตัวแปรนั้นๆ และตัวแปรอื่นๆ ในแบบจำลอง ดังนั้น แนวทางอีกประการในการอธิบายผลจากแบบจำลองเวกเตอร์ออโตรีเกรสซีฟ คือการแยกส่วนประกอบของค่าคาดเคลื่อนของการพยากรณ์ (Forecast Error Variance Decomposition) ว่ามีที่มาจากตัวแปรแต่ละตัวมากน้อยแค่ไหน

ยกตัวอย่าง แบบจำลอง  $VAR(1)$  ที่มีตัวแปรสองตัว เราพบว่าการพยากรณ์  $Y_{1t}$  ไปข้างหน้าหนึ่งคาบมีค่าคาดเคลื่อนจากการพยากรณ์ (forecast error) ตามสมการที่ (6.11) เท่ากับ

$$e_1(1) = \varepsilon_{1,h+1}$$

ซึ่งค่าคาดเคลื่อนเกิดจากข้อผิดพลาดในตัวแปร  $Y_{1t}$  เพียงอย่างเดียว และมีค่าความแปรปรวนของค่าความคาดเคลื่อนจากการพยากรณ์ไปข้างหน้าหนึ่งคาบ (one-period forecast error variance) เท่ากับ

$$Var(e_1(1)) = Var(\varepsilon_{1,h+1}) = \sigma_1^2$$

ในขณะที่การพยากรณ์  $Y_{1t}$  ไปข้างหน้าสองคาบมีค่าคาดเคลื่อนจากการพยากรณ์ตามสมการที่ 6.15 เท่ากับ

$$e_1(2) = \phi_{11}\varepsilon_{1,h+1} + \phi_{12}\varepsilon_{2,h+1} + \varepsilon_{1,h+2}$$

ซึ่งค่าคาดเคลื่อนเกิดจากข้อผิดพลาดของตัวแปร  $Y_{1t}$  และตัวแปร  $Y_{2t}$  เราสามารถคำนวณหาความแปรปรวนของค่า

ความคลาดเคลื่อนจากการพยากรณ์ไปข้างหน้าสองคาบได้ดังสมการต่อไปนี้

$$\begin{aligned} Var(e_1(2)) &= Var(\phi_{11}\varepsilon_{1,h+1}) + Var(\phi_{12}\varepsilon_{2,h+1}) + Var(\varepsilon_{1,h+2}) \\ &= \phi_{11}^2\sigma_1^2 + \phi_{12}^2\sigma_2^2 + \sigma_1^2 \end{aligned} \quad (6.30)$$

$$= (1 + \phi_{11}^2)\sigma_1^2 + \phi_{12}^2\sigma_2^2 \quad (6.31)$$

และสามารถแยกส่วนประกอบของค่าความแปรปรวนของค่าความคลาดเคลื่อนจากการพยากรณ์ไปข้างหน้าสองคาบว่ามาจาก  $Y_{1t}$  เท่ากับ

$$\frac{(1 + \phi_{11}^2)\sigma_1^2}{(1 + \phi_{11}^2)\sigma_1^2 + \phi_{12}^2\sigma_2^2}$$

และมาจาก  $Y_{2t}$  เท่ากับ

$$\frac{\sigma_2^2}{(1 + \phi_{11}^2)\sigma_1^2 + \phi_{12}^2\sigma_2^2}$$

เราสามารถอธิบายได้ว่าตัวแปรแต่ละตัวมีอิทธิพลต่อค่าความแปรปรวนการพยากรณ์ตัวแปรที่เราสนใจมากน้อยแค่ไหน

#### ตัวอย่างที่ 6.9 การหา Variance Decomposition

ต่อเนื่องจากตัวอย่าง 5.3 เราสามารถแยกความแปรปรวนของค่าผิดพลาดจากการพยากรณ์ได้ด้วยคำสั่ง fevd

```
1 > fevd(model1, n.ahead=5)
2 $TH
3      TH      MY
4 [1,]  1 0.0e+00
5 [2,]  1 1.3e-05
6 [3,]  1 4.3e-03
7 [4,]  1 4.3e-03
8 [5,]  1 4.5e-03
9
10 $MY
11      TH      MY
12 [1,] 0.15 0.85
13 [2,] 0.17 0.83
14 [3,] 0.18 0.82
15 [4,] 0.18 0.82
16 [5,] 0.18 0.82
```

ส่วนที่สอง \$MY แสดงการแยกความแปรปรวนของค่าคลาดเคลื่อนของการพยากรณ์ lret\_thmy\$MY ไป 1 ถึง 5 คาบ ยกตัวอย่างเช่น การพยากรณ์ไปข้างหน้า 5 คาบ ความแปรปรวนของค่าพยากรณ์เกิดจาก lret\_thmy\$MY เอง 82 % และเกิดจาก lret\_thmy\$TH 18 %

## 6.6 แบบฝึกฝน

**ตัวอย่างที่ 6.10** นักลงทุนต้องการศึกษาความสัมพันธ์ของผลตอบแทนจากตลาดหุ้นสองตลาดได้แก่ ไทย ( $R_{TH}$ ) และ สิงคโปร์ ( $R_{SG}$ ) โดยใช้แบบจำลอง **vector Autoregressive** โดยใช้ข้อมูลจาก `mkt_th_sg.xls`

1. จงประมาณค่าแบบจำลอง **VAR** โดยเลือกอันดับที่เหมาะสมโดย **BIC(SIC)** แล้วเขียนผลการประมาณค่า
2. จงทดสอบสมมติฐานว่า “ $R_{TH}$  ไม่ได้ Granger causes  $R_{SG}$ ” และ “ $R_{SG}$  ไม่ได้ Granger causes  $R_{TH}$ ”
3. หากเกิดช็อกทางบวก 1 s.d. เกิดขึ้นกับ  $R_{SG}$  (impulse) จะส่งผลอย่างไรต่อ  $R_{TH}$  ในช่วง 5 period ข้างหน้า (นักศึกษาสามารถทดลองใช้คำสั่ง `plot` ในการสร้างกราฟ **IRF**)
4. จงพิจารณา **forecast error variance decomposition** ของ  $R_{TH}$
5. จงพยากรณ์ผลตอบแทนของดัชนีหลักทรัพย์ของตลาดทั้งสองในอีก 5 วันข้างหน้า



## 7. โคอินทิเกรชัน (Cointegration)

ในการวิเคราะห์ถดถอยเชิงเส้นสำหรับอนุกรมเวลาและแบบจำลองเวกเตอร์ออโตรีเกรสซีฟตัวแปรจะต้องเป็นข้อมูลที่นิ่งหรืออินทิเกรตที่อันดับศูนย์ เช่นอัตราผลตอบแทนของสินทรัพย์หรืออัตราการเติบโตของตัวแปรเศรษฐกิจมหภาค ในขณะที่ในการพิจารณาความสัมพันธ์ระหว่างตัวแปรตามทฤษฎีเศรษฐศาสตร์บางตัวแปรเราพบว่าอาจจะมีกรณีที่ตัวแปรไม่นิ่งหรืออินทิเกรตที่อันดับมากกว่าศูนย์ แต่ผู้ศึกษาต้องการพิจารณาตัวแปรดังกล่าว ซึ่งในบางกรณีผลรวมเชิงเส้นตรงของตัวแปรเหล่านั้น อาจจะมีลักษณะเป็นอนุกรมนิ่ง และเราเรียกตัวแปรเหล่านั้นว่าโคอินทิเกรตกัน ซึ่งแนวคิดดังกล่าวถูกนำเสนอโดย Engle and Granger 1987

### 7.1 สมการความสัมพันธ์เทียม (spurious regression)

ในการวิเคราะห์ถดถอยสำหรับข้อมูลอนุกรมเวลา ตัวแปรที่เราใช้ในการวิเคราะห์จำเป็นต้องเป็น  $I(0)$  เพื่อที่จะทำให้การทดสอบเชิงสถิติมีความเหมาะสม หากตัวแปรในแบบจำลองบางตัวหรือทั้งหมดเป็น  $I(1)$  การทดสอบสถิติอาจจะไม่ถูกต้อง ตัวอย่างเช่นในกรณีที่ตัวแปรทั้งหมดเป็น  $I(1)$  และไม่ได้โคอินทิเกรตกัน ตัวทดสอบที่ได้จากแบบจำลองจะไม่เหมาะสม เราจะพบความสัมพันธ์ระหว่างตัวแปรต่างๆที่จริงๆแล้วตัวแปรทั้งหลายไม่มีความสัมพันธ์กัน หรือเราเรียกสมการความสัมพันธ์เทียม (spurious regression)

**ตัวอย่างที่ 7.1** ตัวแปรที่มีอันดับอินทิเกรตเท่ากันหนึ่งและมีความสัมพันธ์เทียม

หากเราพิจารณาอนุกรมเวลาสองกระบวนการที่เป็น  $I(1)$  และเป็นอิสระต่อกัน เราสามารถแสดงความสัมพันธ์ของแต่ละตัวแปรได้ดังนี้

$$y_{1t} = y_{1,t-1} + \varepsilon_{1t} \quad \varepsilon_{1t} \sim WN(0,1)$$


$$y_{2t} = y_{2,t-1} + \varepsilon_{2t} \quad \varepsilon_{2t} \sim WN(0,1)$$

โดยที่  $Cov(\varepsilon_{1t}, \varepsilon_{2t}) = 0$  ซึ่งแสดงว่าทั้งสองอนุกรมเวลาเป็นอิสระต่อกัน เราสามารถใช้โปรแกรม R สร้างตัวแปรทั้งสองด้วยคำสั่งต่อไปนี้

```

1 > set.seed(123456)
2 > e1<-rnorm(1000)
3 > e2<-rnorm(1000)
4 > y1<-cumsum(e1)
5 > y2<-cumsum(e2)

```



รูปที่ 7.1: การจำลองกระบวนการ  $I(1)$  สองอนุกรมเวลา

แผนภาพของอนุกรมเวลาทั้งสองสามารถแสดงได้ดังรูปที่ 7.1

เมื่อนำอนุกรมเวลาทั้งสองมาพิจารณาความสัมพันธ์เชิงถดถอย  $y_{1t} = \alpha + \beta y_{2t} + u_t$  จะพบว่า  $\hat{\beta}$  มีค่าเท่ากับ 0.16 และแตกต่างจากศูนย์อย่างมีนัยสำคัญ ( $t_{\hat{\beta}} = 5.6$ )

```

1 > summary(lm(y1~y2))
2 Call:
3 lm(formula = y1 ~ y2)
4
5 Coefficients:
6             Estimate Std. Error t value Pr(>|t|)
7 (Intercept) 11.43603    0.31329  36.503  < 2e-16 ***
8 y2           0.16237    0.02885   5.628 2.36e-08 ***
9 ---
10 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
11
12 Residual standard error: 9.905 on 998 degrees of freedom
13 Multiple R-squared:  0.03077,    Adjusted R-squared:  0.02979
14 F-statistic: 31.68 on 1 and 998 DF,  p-value: 2.363e-08

```

หากเราพิจารณาสมการ  $\Delta y_{1t} = \beta \Delta y_{2t} + v_t$  จะพบว่า  $\hat{\beta}$  มีค่าเท่ากับ 0.0034 และไม่แตกต่างจากศูนย์อย่างมีนัยสำคัญ

```

1 > summary(lm(diff(y1)~diff(y2)-1))
2
3 Call:
4 lm(formula = diff(y1) ~ diff(y2) - 1)
5
6 Coefficients:
7             Estimate Std. Error t value Pr(>|t|)
8 diff(y2) 0.003455    0.030827   0.112   0.911
9
10 Residual standard error: 0.9921 on 998 degrees of freedom

```

<sup>11</sup> Multiple R-squared: 1.258e-05, Adjusted R-squared: -0.0009894  
<sup>12</sup> F-statistic: 0.01256 on 1 and 998 DF, p-value: 0.9108

จากตัวอย่างข้างต้นเราจำเป็นต้องระมัดระวังในการพิจารณาความสัมพันธ์ระหว่างอนุกรมเวลาในกรณีที่ตัวแปรที่เราสนใจมีลักษณะเป็น  $I(1)$  ซึ่งในกรณีทั่วไปเราจำเป็นต้องปรับให้ตัวแปรดังกล่าวเป็น  $I(0)$  ก่อนที่จะพิจารณาความสัมพันธ์ด้วยสมการเช่น  $\Delta y_t = \beta \Delta x_t + v_t$  โดยค่าสัมประสิทธิ์  $\beta$  ก็จะอธิบายการเปลี่ยนแปลงของ  $\Delta x_t$  ต่อการเปลี่ยนแปลงของ  $\Delta y_t$  อย่างไรก็ตามในบางกรณีที่เรายังจะสามารถศึกษาความสัมพันธ์ระหว่างตัวแปรที่เป็น  $I(1)$  ก็ได้ซึ่งในกรณีดังกล่าวคือกรณีที่ตัวแปรเป็น **cointegration**

## 7.2 นิยามของโคอินทิเกรชัน

กำหนดให้  $\mathbf{Y}_t = (y_{1t}, y_{2t}, \dots, y_{nt})'$  แทนเวกเตอร์  $(n \times 1)$  ของอนุกรมเวลาที่เป็น  $I(1)$  แล้ว ตัวแปรใน  $\mathbf{Y}_t$  จะโคอินทิเกรตกัน ถ้ามีเวกเตอร์  $\beta = (\beta_1, \dots, \beta_n)'$  ที่ทำให้

$$\beta' \mathbf{Y}_t = \beta_1 y_{1t} + \dots + \beta_n y_{nt} \sim I(0) \quad (7.1)$$

ซึ่งหมายความว่าผลรวมเชิงเส้น (linear combination) ของตัวแปรที่เป็น  $I(1)$  มีลักษณะเป็น  $I(0)$  โดยที่ผลรวมเชิงเส้นมักจะได้อาจมาจากทฤษฎีทางเศรษฐศาสตร์ และเรียกสมการดังกล่าวว่าเป็นความสัมพันธ์ใน **ดุลยภาพระยะยาว (long-run equilibrium)** ซึ่งสะท้อนการที่อนุกรมเวลา  $I(1)$  มีความสัมพันธ์ในดุลยภาพระยะยาวด้วยกันอยู่ ดังนั้นตัวแปรดังกล่าวจะไม่แยกห่างจากกันที่ดุลยภาพ โดยจะมีแรงปรับให้ตัวแปรเข้าสู่ดุลยภาพ

เวกเตอร์  $\beta$  ไม่ได้มีลักษณะเป็นรูปแบบอย่างเดียว (unique) เนื่องจากเวกเตอร์ที่เป็นจำนวนเท่าของ  $c\beta'$  ก็สามารถสอดคล้องกับเงื่อนไขในคำนิยามข้างต้นได้ ดังนั้น เรามักจะสนใจในรูปแบบที่ปรับเป็นบรรทัดฐาน (normalized) ซึ่งเขียนสมการโคอินทิเกรชันได้ดังนี้

$$\beta' \mathbf{Y}_t = y_{1t} - \beta_2 y_{2t} - \dots - \beta_n y_{nt} \sim I(0)$$

หรือเป็นสมการ

$$y_{1t} = \beta_2 y_{2t} + \dots + \beta_n y_{nt} + u_t \quad (7.2)$$

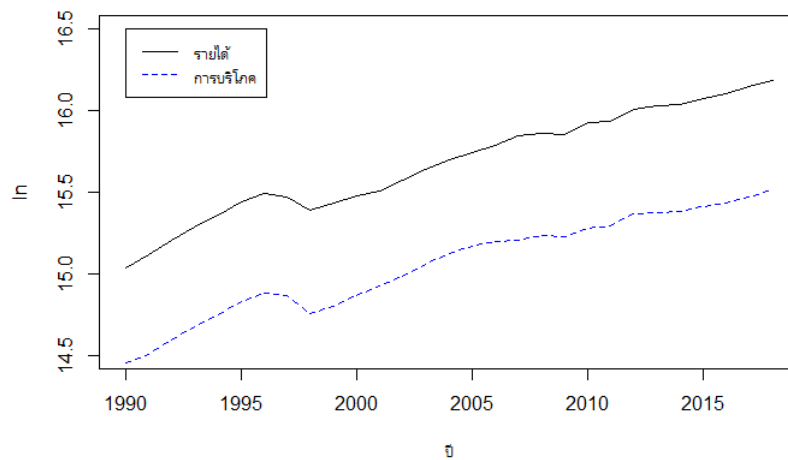
โดยที่  $u_t \sim I(0)$  และเราเรียกพจน์  $u_t$  ว่าค่าคลาดเคลื่อนจากดุลยภาพ (disequilibrium error) หรือ **cointegrating residuals** ซึ่งหากเราอยู่ในดุลยภาพระยะยาวค่าคลาดเคลื่อนจากดุลยภาพจะมีค่าเท่ากับศูนย์ เราจะได้ความสัมพันธ์ระยะยาวจะเท่ากับ  $y_{1t} = \beta_2 y_{2t} + \dots + \beta_n y_{nt}$

เพื่อให้ผู้อ่านเข้าใจความสัมพันธ์ระยะยาวระหว่างตัวแปรทางเศรษฐกิจ ตัวอย่างต่อไปนี้จะนำเสนอตัวแปรทางเศรษฐกิจที่เรามักจะพบว่าเป็นตัวแปรที่ไม่นิ่ง และผลรวมเชิงเส้นมีลักษณะเป็นตัวแปรนิ่ง

**ตัวอย่างที่ 7.2** ทฤษฎีการบริโภค รายได้ถาวร ทฤษฎีการบริโภค รายได้ถาวรเสนอว่าความสัมพันธ์ระยะยาวระหว่างการบริโภคในรูปลอการิทึมกับรายได้ในรูปลอการิทึมสามารถเขียนเป็นสมการ

$$\ln(rc_t) = \beta_0 + \beta_1 \ln(ry_t) + u_t$$

โดยที่  $\varepsilon_t$  คือพจน์ตัวรบกวน จากรูป 7.2 จะเห็นได้ว่าแม้ว่าการบริโภคและรายได้ประชาชาติจะเป็นตัวแปรไม่นิ่งแต่ตัวแปรทั้งสองขยับไปด้วยกันในระยะยาว แม้ว่าจะมีบางช่วงที่ตัวแปรทั้งสองจะขยับออกจากกันเนื่องจากการเปลี่ยนแปลงในวัฏจักรธุรกิจ




รูปที่ 7.2: การบริโภคภาคเอกชนและรายได้ประชาชาติของไทย ณ คาคงที่ระหว่างปี 1990 ถึง 2018

**ตัวอย่างที่ 7.3** ทฤษฎีโครงสร้างอัตราดอกเบี้ยตามระยะเวลาไถ่ถอน โครงสร้างอัตราดอกเบี้ยตามระยะเวลาไถ่ถอน (term structure of interest rate) อธิบายความสัมพันธ์ระหว่างอัตราดอกเบี้ยพันธบัตรที่มีช่วงเวลาไถ่ถอนที่แตกต่างกัน สำหรับพันธบัตรที่มีความเสี่ยงเท่ากันอัตราผลตอบแทนในระยะยาวจะเท่ากับผลรวมของอัตราผลตอบแทนระยะสั้นตลอดช่วงเวลาดังกล่าว ดังนั้นผลตอบแทนระยะยาวจะสูงกว่าผลตอบแทนระยะสั้น และจะมีการเปลี่ยนแปลงไปในทิศทางเดียวกัน ดังรูป 7.3 อัตราดอกเบี้ยทั้งสามระยะเวลาคือตัวแปรไม่นิ่ง แต่ตัวแปรทั้งสามมีความสัมพันธ์ระยะยาวซึ่งสามารถแสดงได้ด้วยสมการ

$$r_{3m,t} = \beta_{0,1} + \beta_{1,1}r_{1m,t} + u_{1t}$$

$$r_{5y,t} = \beta_{0,2} + \beta_{1,2}r_{1m,t} + u_{2t}$$

โดยที่  $r_{1m}, r_{3m}, r_{5y}$  คืออัตราดอกเบี้ยของตราสารหนี้และพันธบัตรที่อายุไถ่ถอน 1 เดือน 3 เดือนและ 5 ปีตามลำดับ โดยที่  $\varepsilon_{1t}$  และ  $\varepsilon_{2t}$  เป็นตัวรบกวนซึ่งเป็นตัวแปรนิ่ง




รูปที่ 7.3: อัตราดอกเบี้ยตราสารหนี้และพันธบัตรรัฐบาลรายเดือนระหว่างเดือนมกราคม 2005 ถึง มีนาคม 2017

## 7.2.1 โคอินทิเกรชันและแบบจำลองเอเรคคอเรชัน

จากหัวข้อที่ผ่านมาเราพบว่าหากตัวแปรใดมีคุณลักษณะเป็นโคอินทิเกรชัน เราสามารถอธิบายความสัมพันธ์ระยะยาวระหว่างตัวแปรระยะยาวที่มีความสัมพันธ์อย่างไรในระยะยาว เช่นหากตัวแปรมีความสัมพันธ์ในทางบวกการเปลี่ยนแปลงของตัวแปรหนึ่งย่อมส่งผลให้ตัวแปรอีกตัวหนึ่งเปลี่ยนแปลงไปในทิศทางเดียวกัน ดังเช่นตัวอย่างการบริโภคตามรายได้ถาวรซึ่งสามารถเขียนเป็นสมการในรูปทั่วไปสำหรับกรณีตัวแปรสองตัวแปร ( $y_{1t}$  และ  $y_{2t}$ ) ซึ่งเป็นตัวแปรที่อินทิเกรตที่อันดับที่หนึ่งดังนี้

$$y_{1t} = \beta_1 + \beta_2 y_{2t} + u_t \quad (7.3)$$

ในระยะยาวตัวแปรทั้งสองจะเคลื่อนไหวไปด้วยกันตามความสัมพันธ์  $y_{1t} = \beta_1 + \beta_2 y_{2t}$  และมีพจน์ที่แสดงการเบี่ยงเบนจากดุลยภาพ (disequilibrium:  $u_t$ ) ซึ่งพจน์ดังกล่าวเป็นตัวแปรนิ่ง สิ่งที่เราสงสัยต่อไปคือหากเกิดภาวะที่ในระยะสั้นตัวแปรขยับออกจากดุลยภาพในระยะยาว จะมีกลไกในการปรับตัวเข้าสู่ดุลยภาพระยะยาวอย่างไร ตัวอย่างเช่นหากสมมติให้ตัวแปรในสมการ 7.3 มีความสัมพันธ์ในเชิงบวก  $\beta_2 = 1$  และ  $\beta_1$  มีค่าเป็นบวกตัวแปรทั้งสองจะขยับไปด้วยกันในระยะยาวดังเส้นทึบในรูป 7.4



รูปที่ 7.4: การปรับตัวของตัวแปรในระยะสั้น

หากในคาบที่  $t-1$  ตัวแปรขยับจากดุลยภาพเช่น  $u_{t-1} > 0$  ซึ่งเกิดจาก  $y_{1,t-1} > \beta_1 + \beta_2 y_{2,t-1}$  ซึ่งแสดงด้วยจุด B ในระยะยาวตัวแปรทั้งสองจะต้องขยับไปในทิศทางเดียวกันด้วยระยะห่าง  $\beta_1$  อีกครั้ง ซึ่งการปรับตัวอาจเกิดจาก

1. การปรับตัวโดย  $y_{1t}$  เพียงตัวแปรเดียว ในกรณีดังกล่าวตัวแปร  $y_{1t}$  จะปรับตัวลดลงมาเพื่อกลับเข้าสู่เส้นทางเดิม ในขณะที่  $y_{2t}$  ไม่เปลี่ยนแปลงไปจากเส้นทางเดิม ซึ่งการปรับตัวสามารถอธิบายได้ด้วย

$$y_{1t} = y_{1,t-1} + \alpha_1 u_{t-1} + v_{1,t}$$

โดยที่  $\alpha_1 < 0$  และ  $v_{1,t}$  เป็นตัวรบกวนของการปรับตัว

2. การปรับตัวโดย  $y_{2t}$  เพียงตัวแปรเดียว ในกรณีนี้ ตัวแปร  $y_{1t}$  จะเดินทางบนเส้นทางใหม่ที่ขยับสูงไปกว่าเดิม ดังนั้นเพื่อให้เข้าสู่ดุลยภาพอีกครั้ง  $y_{2t}$  จะต้องปรับตัวสูงขึ้น ซึ่งสามารถอธิบายได้ด้วยสมการ

$$y_{2t} = y_{2,t-1} + \alpha_2 u_{t-1} + v_{2,t}$$

โดยที่  $\alpha_2 > 0$  และ  $v_{2,t}$  เป็นตัวรบกวนของการปรับตัว

3. กรณีที่ตัวแปรทั้งสองปรับตัวเข้าสู่เส้นทางใหม่ซึ่งทั้งสองตัวแปรห่างกัน  $\beta_1$  โดยในกรณีนี้การปรับตัวจะขึ้นอยู่กับขนาดของ  $\alpha_1$  และ  $\alpha_2$

การปรับตัวดังกล่าวสามารถอธิบายได้ด้วยแบบจำลองเอเรคโคเรชัน หรือ อีซีเอ็ม (Error Correction Model: ECM) ซึ่งถูกนำเสนอโดย Engle and Granger 1987 แสดงให้เห็นว่าการปรับตัวในระยะสั้นสามารถแสดงได้ในรูป

$$\begin{aligned}\Delta y_{1t} &= c_1 + \alpha_1(y_{1,t-1} - \beta_1 - \beta_2 y_{2,t-1}) + \sum_{j=1}^p \psi_{11}^j \Delta y_{1,t-j} + \sum_{j=1}^p \psi_{12}^j \Delta y_{2,t-j} + \varepsilon_{1t} \\ \Delta y_{2t} &= c_2 + \alpha_2(y_{1,t-1} - \beta_1 - \beta_2 y_{2,t-1}) + \sum_{j=1}^p \psi_{21}^j \Delta y_{1,t-j} + \sum_{j=1}^p \psi_{22}^j \Delta y_{2,t-j} + \varepsilon_{2t}\end{aligned}\quad (7.4)$$

สมการข้างต้นแสดงพฤติกรรมเชิงพลวัตของ  $y_{1t}$  และ  $y_{2t}$  โดยแสดงการปรับตัวระยะสั้นเมื่อตัวแปรตัวใดตัวหนึ่งเคลื่อนตัวออกไปจากดุลยภาพ ซึ่งแบบจำลองเอเรคโคเรชันถูกนำไปใช้ในการอธิบายการปรับตัวระยะสั้นของตัวแปรทางการเงินทั้งหลายที่ส่วนใหญ่มักจะมีลักษณะเป็นอินทิเกรตที่อันดับหนึ่ง

**ตัวอย่างที่ 7.4** แบบจำลองเอเรคโคเรชันสำหรับราคาหุ้นและเงินปันผล กำหนดให้ล็อกของราคาหุ้น ( $s_t$ ) และล็อกของเงินปันผล ( $d_t$ ) เป็น  $I(1)$  ถ้าล็อกของสัดส่วนเงินปันผลต่อราคา ( $\log(D_t/S_t)$ ) เป็น  $I(0)$  ดังนั้น  $d_t - s_t \sim I(0)$  หรือเขียนเป็นสมการความสัมพันธ์ระยะยาวได้เป็น

$$d_t = s_t + \mu + u_t \quad (7.5)$$

โดยที่  $u_t \sim I(0)$  และสามารถเขียน ECM ได้ดังนี้

$$\Delta s_t = c_s + \alpha_s(d_{t-1} - s_{t-1} - \mu) + \varepsilon_{st} \quad (7.6)$$

$$\Delta d_t = c_d + \alpha_d(d_{t-1} - s_{t-1} - \mu) + \varepsilon_{dt} \quad (7.7)$$

โดยที่สมการ 7.6 แสดงความสัมพันธ์ระหว่างอัตราการเปลี่ยนแปลงของราคาหุ้นกับ disequilibrium error ( $d_{t-1} - s_{t-1} - \mu$ ) ในขณะที่สมการ 7.7 แสดงความสัมพันธ์ระหว่างอัตราการเปลี่ยนแปลงของเงินปันผลกับ disequilibrium error โดยมีการตอบสนองของราคาหุ้นและเงินปันผลขึ้นอยู่กับค่าสัมประสิทธิ์การปรับตัว (adjustment coefficient)  $\alpha_s$  และ  $\alpha_d$

สมมุติให้  $\alpha_s = 0.5$  และ  $\alpha_d = 0$  จะได้

$$\Delta s_t = c_s + 0.5(d_{t-1} - s_{t-1} - \mu) + \varepsilon_{st}$$

$$\Delta d_t = c_d + \varepsilon_{dt}$$

ดังนั้นมีเพียงราคาหุ้นที่ตอบสนองต่อ disequilibrium error โดยที่ค่าเฉลี่ยของการเปลี่ยนแปลงของตัวแปรทั้งสองจะขึ้นอยู่กับข้อมูลในอดีต

$$E(\Delta s_t | F_{t-1}) = c_s + 0.5(d_{t-1} - s_{t-1} - \mu)$$

$$E(\Delta d_t | F_{t-1}) = c_d$$

ซึ่งเราสามารถพิจารณาการเปลี่ยนแปลงได้ดังนี้

1. หาก  $d_{t-1} - s_{t-1} - \mu = 0$  ดังนั้น  $E(\Delta s_t | F_{t-1}) = c_s$  และ  $E(\Delta d_t | F_{t-1}) = c_d$  หากไม่มีการเปลี่ยนแปลงออกจากดุลยภาพระยะยาวในคาบที่ผ่านมา อัตราการเปลี่ยนแปลงของทั้งสองตัวแปรจะเท่ากับค่าเฉลี่ยของการเปลี่ยนแปลง
2. หาก  $d_{t-1} - s_{t-1} - \mu > 0$  ดังนั้น  $E(\Delta s_t | F_{t-1}) = c_s + 0.5(d_{t-1} - s_{t-1} - \mu) > c_s$  เนื่องจากเงินปันผลสูงกว่าราคาหุ้นที่จะรักษาดุลยภาพระยะยาว ดังนั้น ECM พยากรณ์ว่า  $s_t$  จะเปลี่ยนแปลงที่อัตราสูงกว่าอัตราที่ดุลยภาพในระยะยาว ( $> c_s$ ) เพื่อรักษาสัดส่วนราคาหุ้นต่อเงินปันผล โดยที่ความเร็วในการปรับตัว (speed of adjustment) แสดงได้ด้วยพารามิเตอร์  $\alpha_s = 0.5$

## 7.2.2 ความสัมพันธ์โคอินทิเกรชันกรณีหลายตัวแปร

กรณีที่มีตัวแปรที่เราพิจารณามากกว่าสองตัวแปรเช่น กรณีที่เราสนใจเวกเตอร์ของอนุกรมเวลาของตัวแปร  $n$  ตัวแปร  $\mathbf{Y}_t = (y_{1t}, \dots, y_{nt})'$  ซึ่งเป็นอนุกรมเวลาที่โคอินทิเกรตกัน ความสัมพันธ์ระหว่างตัวแปรทั้ง  $n$  ตัวแปรนั้นอาจจะเท่ากับ  $r$  รูปแบบ ซึ่ง  $0 < r < n$  ตัวอย่างเช่นกรณีที่เราพิจารณาตัวแปร 3 ตัวแปร ได้แก่  $y_{1t}, y_{2t}, y_{3t}$  ซึ่งสามารถเขียนเป็นเวกเตอร์ได้ดังนี้  $\mathbf{Y}_t = (y_{1t}, y_{2t}, y_{3t})'$  ซึ่งตัวแปรทั้งสามอาจจะมีผลรวมเชิงเส้นสองสมการซึ่งเป็นตัวแปรหนึ่ง ได้แก่

$$\beta_{11}y_{1t} + \beta_{12}y_{2t} + \beta_{13}y_{3t} \sim I(0)$$

และ

$$\beta_{21}y_{1t} + \beta_{22}y_{2t} + \beta_{23}y_{3t} \sim I(0)$$

และเราเรียกเวกเตอร์ของค่าสัมประสิทธิ์  $(\beta_{11} \ \beta_{12} \ \beta_{13})'$  และ  $(\beta_{21} \ \beta_{22} \ \beta_{23})'$  ว่าเวกเตอร์สัมประสิทธิ์โคอินทิเกรต (cointegrating vector)

จากนิยามโคอินทิเกรชัน และความสัมพันธ์ระยะยาวของตัวแปรที่พิจารณา ในการประยุกต์กับข้อมูลทางการเงินหรือเศรษฐกิจ เราต้องการที่จะทราบว่าตัวแปรไม่หนึ่งที่เรากำลังพิจารณาอยู่นั้นมีความสัมพันธ์ในลักษณะโคอินทิเกรชันหรือไม่ ในหัวข้อ 7.3 ผู้เขียนจะอธิบายการทดสอบว่าตัวแปรมีลักษณะโคอินทิเกรชันหรือไม่ โดยใช้แนวทางของ Engle and Granger 1987 ซึ่งต้องการทดสอบว่าตัวแปรโคอินทิเกรตกันเมื่อพิจารณาสมการเพียงสมการเดียว ในขณะที่หัวข้อที่ 7.5 จะทดสอบโคอินทิเกรชันและหาจำนวนของความสัมพันธ์ระยะยาวตามแนวทางของ Johansen (Johansen 1988)



## 7.3 การทดสอบโคอินทิเกรชันด้วยวิธีการทดสอบเรซิดิวตามแนวทางของ เองเกลและเกรนเจอร์

เองเกล (Engle) และเกรนเจอร์ (Granger) ได้นำเสนอวิธีการในการทดสอบโคอินทิเกรชันในบทความ Engle and Granger 1987 โดยใช้แนวคิดจากนิยามของโคอินทิเกรชันซึ่งหากตัวแปรที่พิจารณาโคอินทิเกรตกัน ผลรวมเชิงเส้นตรงของตัวแปรจะเป็นตัวแปรนิ่ง นอกจากนี้เราสามารถเขียนสมการถดถอยของตัวแปรที่พิจารณาและเทียบเทียบเรซิดิว (residual) กับผลรวมเชิงเส้นตรงได้ ผลรวมเชิงเส้นตรงเป็นตัวแปรนิ่งก็ต่อเมื่อเรซิดิวเป็นตัวแปรนิ่งด้วย ดังนั้น Engle และ Granger ได้นำเสนอการทดสอบโคอินทิเกรชันโดยใช้วิธีการสองขั้นตอนดังนี้

1. สร้างเรซิดิวของสมการโคอินทิเกรชัน (cointegrating residuals) โดยที่  $u_t = \beta_1 y_{1t} + \dots + \beta_n y_{nt}$
2. ทดสอบว่าเรซิดิวเป็นตัวแปรนิ่งหรือไม่ ด้วยการทดสอบยูนิทรูท หาก  $u_t$  เป็นตัวแปรนิ่งหรืออินทิเกรตที่อันดับศูนย์ ( $I(0)$ ) แสดงว่าตัวแปร  $y_{1t}, \dots, y_{nt}$  โคอินทิเกรตกัน อนึ่งการทดสอบดังกล่าวมีสมมุติฐานหลักว่า  $u_t$  อินทิเกรตที่อันดับหนึ่ง หรือตัวแปร  $y_{1t}, \dots, y_{nt}$  ไม่โคอินทิเกรตกันนั่นเอง

อย่างไรก็ตามการทดสอบโคอินทิเกรชันตามแนวทางของ Engle และ Granger ขึ้นอยู่กับการสร้างเรซิดิวซึ่งต้องใช้ค่าสัมประสิทธิ์โคอินทิเกรชัน ซึ่งในทางปฏิบัติเราอาจจะแบ่งออกได้เป็นสองกรณีคือ *กรณีที่หนึ่ง* เราทราบความสัมพันธ์ของอนุกรมเวลาที่เราสนใจ เช่น จากทฤษฎีเราทราบความสัมพันธ์ระหว่างล็อกของราคาหุ้น ( $s_t$ ) และล็อกของเงินปันผล ( $d_t$ ) ว่าสามารถแสดงเป็นสมการ  $s_t - d_t = u_t$  หรือเวกเตอร์โคอินทิเกรชันสามารถแสดงได้โดย  $\beta = (1 \ -1)'$  ดังนั้นเราสามารถคำนวณเรซิดิวของสมการโคอินทิเกรชันได้ทันที *กรณีที่สอง* กรณีที่เราไม่ทราบความสัมพันธ์ระหว่างตัวแปร ในกรณีนี้เราจำเป็นต้องประมาณค่าสัมประสิทธิ์โคอินทิเกรชัน ( $\hat{\beta}$ ) และสร้างตัวประมาณค่าของเรซิดิวจาก  $\hat{u}_t = \hat{\beta}' Y_t$


### 7.3.1 การทดสอบกรณีทราบค่าสัมประสิทธิ์โคอินทิเกรชัน

ในการศึกษาความสัมพันธ์ระหว่างตัวแปร เรามักจะมีทฤษฎีที่อธิบายความสัมพันธ์ของตัวแปรที่เราสนใจ ในกรณีดังกล่าวเราสามารถสร้างเรซิดิวโคอินทิเกรชันจากค่าสัมประสิทธิ์จากทฤษฎี เช่นกำหนดให้  $Y_t$  เป็นเวกเตอร์  $n \times 1$  ตัวแปรซึ่งอินทิเกรตที่อันดับหนึ่ง ( $I(1)$ ) และโคอินทิเกรตกันด้วยสมการความสัมพันธ์สามารถแสดงได้ด้วยเวกเตอร์โคอินทิเกรชัน  $\beta$  เราสามารถคำนวณเรซิดิวได้จากสมการ  $u_t = \beta' Y_t$  หลังจากนั้นเราจะทดสอบเรซิดิวภายใต้สมมุติฐานหลักที่ว่า เรซิดิวมีลักษณะเป็นอินทิเกรตที่อันดับหนึ่ง  $H_0 : u_t = \beta' Y_t \sim I(1)$  หรือไม่ซึ่งสมมุติฐานหลักสะท้อนว่าตัวแปรที่เราพิจารณาไม่มีโคอินทิเกรต ในขณะที่สมมุติฐานทางเลือกคือเรซิดิวมีลักษณะอินทิเกรตที่อันดับศูนย์ หรือตัวแปรที่พิจารณาโคอินทิเกรตกัน  $H_1 : u_t = \beta' Y_t \sim I(0)$

เราจะเห็นได้ว่าเรซิดิวที่สร้างขึ้นเป็นการผนวกเอาตัวแปรที่พิจารณาเข้าด้วยกัน ดังนั้นเราสามารถทดสอบยูนิทรูทของเรซิดิวด้วยตัวทดสอบที่เราได้กล่าวถึงแล้วในบทที่ผ่านมาเช่น Augmented Dickey Fuller หรือ Phillip-Perron กับตัวแปร  $u_t$  ซึ่งหากเราปฏิเสธสมมุติฐานหลัก เราจะสรุปว่า  $Y_t$  โคอินทิเกรตกัน

**ตัวอย่างที่ 7.5** การพิจารณาความสัมพันธ์ระหว่างราคาปัจจุบันและราคาฟิวเจอร์ของดัชนีหลักทรัพย์ SET50

เราพิจารณาความสัมพันธ์ระหว่างราคาปัจจุบัน (spot price:  $S_t$ ) และราคาฟิวเจอร์ (future price:  $F_t$ ) ของดัชนีราคาหลักทรัพย์ SET50 ระหว่างเมษายน 2006 ถึงกันยายน 2016 ซึ่งรูปแสดงราคาทั้งสอง



รูปที่ 7.5: ราคาปัจจุบันและราคาฟิวเจอร์ของดัชนีหลักทรัพย์ SET50

ตัวแปรทั้งสองมีความสัมพันธ์ตามแบบจำลองต้นทุนการถือทรัพย์ (cost of carry model) ซึ่งอธิบายว่า ราคาฟิวเจอร์จะเท่ากับราคาปัจจุบันบวกด้วยต้นทุนของการถือทรัพย์นั้น หรือลือกของราคาปัจจุบัน ( $s_t$ ) จะเท่ากับลือกของราคาฟิวเจอร์ ( $f_t$ ) บวกกับค่าคงที่ (ซึ่งสะท้อนต้นทุนในการถือสินทรัพย์)

$$f_t = s_t + c$$

ก่อนการทดสอบโคอินทิเกรชัน เราจะพิจารณาอันดับของอินเกรชันของตัวแปรทั้งสอง โดยการทดสอบยูนิทรูทด้วยวิธีการ Augmented Dickey Fuller ด้วยคำสั่ง `ur.df` จากชุดคำสั่ง `urca` โดยใช้คำสั่งดังต่อไปนี้

```
1 > set50 <- read_csv("G:/My Drive/teaching/ec435/data/set50_m0619.csv")
2 > lspot<-log(set50$spot)
3 > lfutures<-log(set50$futures)
4 > library(urca)
5 > summary(ur.df(lspot, type="drift", selectlags = "BIC"))
6 Value of test-statistic is: -1.3894 1.3627
7
8 Critical values for test statistics:
9      1pct  5pct 10pct
10 tau2 -3.46 -2.88 -2.57
11 phi1  6.52  4.63  3.81
12
```

```

13 > summary(ur.df(diff(lspot), type="drift", selectlags = "BIC"))
14
15 Value of test-statistic is: -8.9508 40.0633
16
17 Critical values for test statistics:
18      1pct   5pct 10pct
19 tau2 -3.46 -2.88 -2.57
20 phil  6.52  4.63  3.81
21
22 > summary(ur.df(lfutures, type="drift", selectlags = "BIC"))
23
24 Value of test-statistic is: -1.4079 1.3667
25
26 Critical values for test statistics:
27      1pct   5pct 10pct
28 tau2 -3.46 -2.88 -2.57
29 phil  6.52  4.63  3.81
30
31 > summary(ur.df(diff(lfutures), type="drift", selectlags = "BIC"))
32
33 Value of test-statistic is: -9.1078 41.4813
34
35 Critical values for test statistics:
36      1pct   5pct 10pct
37 tau2 -3.46 -2.88 -2.57
38 phil  6.52  4.63  3.81

```

กรณีของ *lspot* พบว่าค่าสถิติที่เท่ากับ -1.389 มากกว่าค่าวิกฤตที่นัยสำคัญ 0.05 (-2.88) เราไม่สามารถปฏิเสธสมมุติฐานได้ แสดงว่า *lspot* เป็นยูนิรูท หากเราแปลงตัวแปรดังกล่าวด้วยการหาผลต่างอันดับที่หนึ่ง หรือพิจารณา *diff(lspot)* พบว่าค่าสถิติที่เท่ากับ -8.591 น้อยกว่าค่าวิกฤตที่แสดงว่า *diff(lspot)* เป็นตัวแปรนิ่ง และ *lspot* เป็นอินทิเกรตที่อันดับหนึ่ง

เมื่อเราพิจารณา *lfuture* เราได้ข้อสรุปเช่นเดียวกัน คือ *lfuture* เป็นอินทิเกรตที่อันดับหนึ่ง ดังนั้น เราไม่สามารถประมาณค่าความสัมพันธ์ระหว่างตัวแปรทั้งสองด้วยวิธีการกำลังสองน้อยที่สุดได้ ยกเว้นกรณีที่ตัวแปรทั้งสองโคอินทิเกรตกัน

ขั้นตอนถัดไป เราทดสอบโคอินทิเกรชัน โดยที่เราหาตัวแปรทั้งสองมีความสัมพันธ์ตามทฤษฎีต้นทุนการถือทรัพย์ จากความสัมพันธ์ระหว่างตัวแปรทั้งสองข้างต้น เราสามารถเขียนสมการความสัมพันธ์ระยะยาวได้เป็น

$$f_t = s_t + c + u_t$$

กรณีนี้สินทรัพย์ที่ถือเป็นสินทรัพย์ทางการเงิน เราอาจจะสมมติให้ต้นทุน (*c*) มีค่าเท่ากับศูนย์และเราสามารถเขียนเรซิดิวโคอินทิเกรชันได้ด้วยสมการ  $u_t = f_t - s_t$  หรือเวกเตอร์สัมประสิทธิ์โคอินทิเกรชันสามารถแทนได้ด้วยเวกเตอร์  $\beta = (1 \quad -1)'$  เมื่อเรากำหนดเรซิดิวแล้วสามารถทดสอบยูนิรูทได้ด้วยตัวทดสอบเช่น Augmented Dickey Fuller ด้วยคำสั่งต่อไปนี้

```

1 > u<-lfutures-lspot
2 > summary(ur.df(u, type="drift", selectlags = "BIC"))

```

```

3
4 Value of test-statistic is: -6.0538 18.3258
5
6 Critical values for test statistics:
7      1pct  5pct 10pct
8 tau2 -3.46 -2.88 -2.57
9 phi1  6.52  4.63  3.81

```

จากการทดสอบยูนิทรูทกับตัวแปร  $u_t$  พบว่าค่าสถิติที่เท่ากับ -6.054 ซึ่งน้อยกว่าค่าวิกฤติที่ระดับนัยสำคัญ 0.05 (-2.88) เราสามารถปฏิเสธสมมติฐานว่า  $u_t$  เป็นยูนิทรูทหรือเรซิดิวมีลักษณะเป็นตัวแปรนิ่ง แสดงว่าตัวแปรทั้งสองโคอินทิเกรตกัน

### 7.3.2 การทดสอบกรณีไม่ทราบค่าสัมประสิทธิ์โคอินทิเกรชัน

ในการศึกษาความสัมพันธ์ระหว่างตัวแปรอนุกรมเวลา บางครั้งเราไม่ทราบสัมประสิทธิ์ความสัมพันธ์ของตัวแปรเราจำเป็นต้องประมาณค่าเวกเตอร์สัมประสิทธิ์โคอินทิเกรชันขึ้นมา ขั้นตอนแรกของการทดสอบโคอินทิเกรชันเราจำเป็นต้องประมาณค่าสัมประสิทธิ์โคอินทิเกรชัน  $\beta$  โดยที่เรากำหนดให้ค่าสัมประสิทธิ์ของตัวแปรตัวใดตัวหนึ่ง ในกรณีนี้คือ  $y_{1t}$  มีค่าเท่ากับหนึ่ง และสัมประสิทธิ์ของตัวแปรตัวอื่นมีค่าเท่ากับ  $\beta_2, \dots, \beta_n$  เราเรียกสมการดังกล่าวว่าเป็นการเขียนในรูปบรรทัดฐาน (normalized) และแสดงในรูปสมการต่อไปนี้

$$y_{1t} = \beta_1 + \beta_2 y_{2t} + \dots + \beta_n y_{nt} + u_t \quad (7.8)$$

โดยที่สมการดังกล่าวอาจจะมีค่าคงที่หรือไม่มีก็ได้ หรืออาจจะมีพจน์ที่แสดงแนวโน้มเพิ่มเข้ามาก็ได้ หลังจากที่เราประมาณค่าสมการดังกล่าวด้วยวิธีการกำลังสองน้อยที่สุด จะได้ค่าประมาณของสัมประสิทธิ์ และสามารถคำนวณค่าประมาณของเรซิดิวได้ด้วยสมการ  $\hat{u}_t = y_{1t} - \hat{\beta}_1 - \hat{\beta}_2 y_{2t} - \dots - \hat{\beta}_n y_{nt}$  โดยที่  $\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_n$  เป็นตัวประมาณค่าจากวิธีการกำลังสองน้อยที่สุด เราจะทดสอบยูนิทรูทกับตัวประมาณค่าของเรซิดิว ซึ่งหากตัวประมาณค่าของเรซิดิวเป็นตัวแปรนิ่ง แสดงว่าตัวแปร  $y_{1t}, \dots, y_{nt}$  โคอินทิเกรตกัน

เนื่องจากตัวประมาณค่าของเรซิดิวคำนวณจากตัวประมาณค่าของสัมประสิทธิ์ และอาจจะเผชิญกับปัญหาความสัมพันธ์เทียม Phillips and Ouliaris 1990 แสดงให้เห็นว่าค่าสถิติที่คำนวณจากการทดสอบด้วย Augmented Dickey Fuller หรือ Phillips-Perron ไม่ได้มีการแจกแจงแบบ Dickey-Fuller ดังนั้น เราไม่สามารถเปรียบเทียบสถิติกับตารางค่าวิกฤติของการแจกแจง Dickey-Fuller ปกติได้ Phillips and Ouliaris 1990 ได้คำนวณค่าวิกฤติสำหรับการทดสอบโคอินทิเกรชันกรณีที่ต้องประมาณค่าสัมประสิทธิ์โคอินทิเกรต ซึ่งค่าวิกฤติขึ้นอยู่กับรูปแบบของสมการโคอินทิเกรชันที่ประมาณ ได้แก่ สมการที่ไม่มีค่าคงที่ สมการที่มีค่าคงที่และสมการที่มีค่าคงที่และแนวโน้ม และจำนวนของตัวแปรในสมการ โดยค่าวิกฤติแสดงอยู่ในตาราง 7.1

ตารางที่ 7.1: ค่าวิกฤติสำหรับการทดสอบโคอินทิเกรชันกรณีที่ต้องประมาณค่าสัมประสิทธิ์โคอินทิเกรชัน

	ไม่มีค่าคงที่			มีค่าคงที่			มีค่าคงที่และแนวโน้ม		
	ระดับนัยสำคัญ			ระดับนัยสำคัญ			ระดับนัยสำคัญ		
n-1	0.1	0.05	0.01	0.1	0.05	0.01	0.1	0.05	0.01
1	-2.4505	-2.7619	-3.3865	-3.0657	-3.3654	-3.9618	-3.5184	-3.8	-4.3628
2	-2.9873	-3.2667	-3.8395	-3.4494	-3.7675	-4.3078	-3.8429	-4.1567	-4.6451
3	-3.4446	-3.7371	-4.3038	-3.8329	-4.1121	-4.7325	-4.195	-4.4895	-5.0433
4	-3.8068	-4.1261	-4.672	-4.1565	-4.4542	-5.0728	-4.4625	-4.7423	-5.3576
5	-4.1416	-4.3999	-4.9897	-4.4309	-4.7101	-5.2812	-4.7311	-5.0282	-5.5849

ที่มา: Phillips and Ouliaris 1990),  $n$  คือจำนวนตัวแปรในสมการโคอินทิเกรชัน

**ตัวอย่างที่ 7.6** การทดสอบความสัมพันธ์ระหว่างราคาปัจจุบันและราคาฟิวเจอร์กรณีไม่ทราบค่าสัมประสิทธิ์

เพื่อความต่อเนื่องของตัวอย่าง เราจะสมมุติว่าเราไม่ทราบค่าสัมประสิทธิ์ความสัมพันธ์ระหว่างราคาฟิวเจอร์และราคาปัจจุบัน และสมมุติให้ความสัมพันธ์ระหว่างตัวแปรทั้งสองแสดงได้ด้วยสมการถดถอย  $f_t = \beta_1 + \beta_2 s_t + u_t$  ซึ่งหลังจากที่เราประมาณค่าด้วยวิธีการกำลังสองน้อยที่สุดด้วยคำสั่ง `lm` ในชุดคำสั่งหลัก หรือในกรณีนี้เราจะใช้คำสั่ง `dynlm` จากชุดคำสั่ง `dynlm` เนื่องจากในตัวอย่างถัดไปเราจะใช้ค่าและค่าต่างสำหรับตัวแปรที่พิจารณา หลังจากได้ค่าประมาณเราสามารถคำนวณค่า  $\hat{u}_t = f_t - \hat{\beta}_1 - \hat{\beta}_2 s_t$  ตามขั้นตอนในคำสั่งข้างล่าง

อนึ่งในขั้นตอนแรกของการใช้ชุดคำสั่ง `dynlm` เราจะต้องระบุว่าตัวแปรที่เราพิจารณาเป็นตัวแปรอนุกรมเวลาโดยใช้คำสั่ง `ts` ระบุจุดเริ่มต้นและความถี่ของข้อมูล ตามคำสั่งต่อไปนี้

```

1 > lspot<-ts(lspot, start=c(2006,4), frequency = 12)
2 > lfutures<-ts(lfutures, start=c(2006,4), frequency = 12)
3 > library(dynlm)
4 > m1<-dynlm(lfutures~lspot)
5 > summary(m1)
6
7 Time series regression with "ts" data:
8 Start = 2006(4), End = 2019(12)
9
10 Call:
11 dynlm(formula = lfutures ~ lspot)
12
13 Residuals:
14      Min       1Q   Median       3Q      Max
15 -0.0198129 -0.0038723 -0.0000842  0.0025807  0.0281109
16
17 Coefficients:
18             Estimate Std. Error t value Pr(>|t|)
19 (Intercept) -0.06423    0.01090  -5.895  2.1e-08 ***
20 lspot        1.00909    0.00164 615.341 < 2e-16 ***
21 ---
22 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
23

```

```

24 Residual standard error: 0.00747 on 163 degrees of freedom
25 Multiple R-squared: 0.9996, Adjusted R-squared: 0.9996
26 F-statistic: 3.786e+05 on 1 and 163 DF, p-value: < 2.2e-16

```

ค่าสัมประสิทธิ์  $\beta_2$  เท่ากับ 1.006 ซึ่งใกล้เคียงกับ 1 หลังจากนั้นเราก็จะทดสอบยูนิทรูทของค่าประมาณเรซิดูด้วยการทดสอบ Dickey Fuller

```

1 > uhat<-ts(ml$residuals, start=c(2006,4), frequency = 12)
2 > library(urca)
3 > summary(ur.df(uhat, type="drift", selectlags = "BIC"))
4
5 Value of test-statistic is: -6.71 22.5
6
7 Critical values for test statistics:
8      1pct  5pct 10pct
9 tau2 -3.46 -2.88 -2.57
10 phil  6.52  4.63  3.81

```

ค่าสถิติที่เท่ากับ -6.71 เมื่อนำไปเปรียบเทียบกับค่าวิกฤติในตาราง Phillips-Orliaris 7.1 กรณีที่สมการโคอินทิเกรชันมีค่าคงที่ และจำนวนตัวอย่างลบหนึ่ง เท่ากับ 1 (เนื่องจากในกรณีนี้เรามีตัวแปรในสมการโคอินทิเกรชันสองตัวแปร) ที่นัยสำคัญ 0.05 มีค่าเท่ากับ -3.3656 พบว่าค่าสถิติที่มีค่าต่ำกว่าค่าวิกฤติ (สังเกตว่าค่าวิกฤติจากตาราง Dickey Fuller มีค่า -2.88) ดังนั้นเราสามารถปฏิเสธหลักที่ว่าเรซิดูเป็นตัวแปรนิ่ง และสรุปได้ว่าตัวแปรทั้งสองโคอินทิเกรตกัน

## 7.4 การประมาณค่าแบบจำลองเอเรอโคเรชันด้วยวิธีการกำลังสองน้อยที่สุด

สมมติว่าเราสนใจตัวแปร  $(y_{1t} \ y_{2t})'$  ซึ่งมีความสัมพันธ์โคอินทิเกรชันแสดงได้ด้วยสมการ  $y_{1t} = \beta_2 y_{2t} + u_t$  (หรือ  $y_{1t} - \beta_2 y_{2t} = u_t \sim I(0)$ ) หากเรามีตัวประมาณค่า  $\hat{\beta}_2$  ที่มีคุณลักษณะเป็นค่าประมาณที่คล่องจอง (consistent) และเราต้องประมาณค่าแบบจำลองเอเรอโคเรชันตามสมการต่อไปนี้

$$\Delta y_{1t} = c_1 + \alpha_1(y_{1,t-1} - \beta_2 y_{2,t-1}) + \sum_{i=1}^p \psi_{11}^j \Delta y_{1,t-j} + \sum_{i=1}^p \psi_{12}^j \Delta y_{2,t-j} + \varepsilon_{1t} \quad (7.9)$$

$$\Delta y_{2t} = c_2 + \alpha_2(y_{1,t-1} - \beta_2 y_{2,t-1}) + \sum_{i=1}^p \psi_{21}^j \Delta y_{1,t-j} + \sum_{i=1}^p \psi_{22}^j \Delta y_{2,t-j} + \varepsilon_{2t} \quad (7.10)$$

เราสามารถแทนค่า  $\hat{\beta}_2$  ลงในสมการเหมือนเป็นพารามิเตอร์ที่เราทราบค่า หรือพิจารณาพจน์โคอินทิเกรชันเรซิดู  $(y_{1,t-1} - \beta_2 y_{2,t-1})$  เหมือนเป็นตัวแปรที่ทราบค่า เนื่องจากตัวแปรทุกตัวในสมการ 7.9 และ 7.10 เป็นตัวแปรนิ่ง เราสามารถประมาณค่าสมการดังกล่าวด้วยวิธีการกำลังสองน้อยที่สุด นอกจากนี้ในแบบจำลองข้างต้นสามารถเลือกค่าค่าที่เหมาะสมสำหรับการเปลี่ยนแปลงของตัวแปรทั้งสองในอดีต ( $p$ ) ด้วยตัวเลือกแบบจำลอง AIC หรือ BIC

**ตัวอย่างที่ 7.7** การประมาณค่าแบบจำลองเอเรอโคเรชันสำหรับสมการราคาปัจจุบันและราคาฟิวเจอร์ของ SET50

เราประมาณค่าแบบจำลองเอเรอโคเรชันสำหรับลียอกของราคาปัจจุบันและลียอกของราคาฟิวเจอร์ต่อเนื่องจากตัวอย่างที่ผ่านมา ในที่นี้เราสมมติให้แบบจำลองของเป็นดังนี้

$$\Delta f_t = c_1 + \alpha_1 \hat{u}_{t-1} + \psi_{11} \Delta s_{t-1} + \psi_{12} \Delta f_{t-1} + \varepsilon_{ft} \quad (7.11)$$

$$\Delta s_t = c_2 + \alpha_2 \hat{u}_{t-1} + \psi_{21} \Delta s_{t-1} + \psi_{22} \Delta f_{t-1} + \varepsilon_{st} \quad (7.12)$$

ในการประมาณค่าแบบจำลองพลวัตดังกล่าว สามารถใช้ชุดคำสั่ง `dynlm` และคำสั่ง `dynlm` ในการประมาณค่า โดยที่ `diff(x)` แทน  $\Delta X_t$  และ `L(diff(x))` แทน  $\Delta X_{t-1}$  และประมาณค่าแบบจำลองด้วยคำสั่งต่อไปนี้

```
1 > ecm1<-dynlm(diff(lfutures)~L(uhat)+L(diff(lspot))+L(diff(lfutures)))
2 > summary(ecm1)
3
4           Estimate Std. Error t value Pr(>|t|)
5 (Intercept)    0.00384    0.00483   0.80   0.4277
6 L(uhat)        -2.15315    0.77455  -2.78   0.0061 **
7 L(diff(lspot)) -0.50830    0.76794  -0.66   0.5090
8 L(diff(lfutures)) 0.68421    0.73417   0.93   0.3528
9 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
10
11 > ecm2<-dynlm(diff(lspot)~L(uhat)+L(diff(lspot))+L(diff(lfutures)))
12 > summary(ecm2)
13
14           Estimate Std. Error t value Pr(>|t|)
15 (Intercept)    0.00390    0.00457   0.85   0.395
16 L(uhat)        -1.56235    0.73337  -2.13   0.035 *
17 L(diff(lspot)) -0.55125    0.72711  -0.76   0.449
18 L(diff(lfutures)) 0.71785    0.69514   1.03   0.303
```

เขียนเป็นผลการประมาณค่าได้ดังนี้

$$\Delta f_t = 0.004 - 2.153\hat{u}_{t-1} - 0.508\Delta s_{t-1} + 0.684\Delta f_{t-1} + \varepsilon_{ft}$$

$$\Delta s_t = 0.004 - 1.562\hat{u}_{t-1} - 0.551\Delta s_{t-1} + 0.718\Delta f_{t-1} + \varepsilon_{st}$$

หากพิจารณาจากตัวอย่าง 7.6 ถ้า  $f_{t-1} > \beta_1 + \beta_2 s_{t-1}$  จะส่งผลให้  $\hat{u}_{t-1}$  มากกว่าศูนย์ จากค่าสัมประสิทธิ์ของเรซิดิวในสมการอีซีเอ็มของราคาฟิวเจอร์ ( $\hat{\alpha}_1$ ) มีค่าเท่ากับ  $-2.153$  แสดงว่าอัตราการเปลี่ยนแปลงของราคาฟิวเจอร์มีค่าเป็นลบ ราคาฟิวเจอร์ในคาบที่  $t$  จะลดลงมาเพื่อปรับเข้าสู่ดุลยภาพ ในขณะที่สมการอีซีเอ็มของราคาปัจจุบัน ค่าสัมประสิทธิ์ของเรซิดิวเท่ากับ  $-1.562$  แสดงว่าราคาปัจจุบันในคาบที่  $1$  ก็จะปรับตัวลงด้วย แต่ด้วยขนาดที่น้อยกว่าราคาฟิวเจอร์ ( $f_t \downarrow > \beta_1 + \beta_2 s_t \downarrow$ ) การปรับตัวจะดำเนินจนกระทั่งราคาทั้งสองปรับเข้าสู่ดุลยภาพระยะยาวอีกครั้ง

## 7.5 แบบจำลองเวกเตอร์เอเรคโคเรชัน

Engle และ Granger นำเสนอแบบจำลองโคอินทิเกรตที่อธิบายความสัมพันธ์ระยะยาว และแบบจำลองเอเรคโคเรชันซึ่งนำเสนอการปรับตัวระยะสั้น ซึ่งการประมาณค่าแบบจำลองเอเรคโคเรชันเป็นการประมาณค่าสองขั้นตอน ซึ่งตัวประมาณค่าไม่มีประสิทธิภาพ (inefficient) เนื่องจากการประมาณค่าในขั้นตอนแรกอาจจะเผชิญกับปัญหาความสัมพันธ์เทียม Johansen 1991 ได้ผนวกความสัมพันธ์ทั้งระยะยาวและการปรับตัวระยะสั้นในรูปแบบของสมการของเวกเตอร์ตัวแปร โดยมีพื้นฐานจากแบบจำลองเวกเตอร์ออโตรีเกรสชัน ซึ่งหากพิจารณาตัวแปร  $y_{1t}, \dots, y_{nt}$  ในรูปเวกเตอร์  $(n \times 1)$  เขียนเป็นสัญลักษณ์  $\mathbf{Y}_t$  ในรูปสมการเวกเตอร์ออโตรีเกรสชันอันดับ  $p$  ( $VAR(p)$ ) ดังต่อไปนี้

$$\mathbf{Y}_t = \Pi_1 \mathbf{Y}_{t-1} + \dots + \Pi_p \mathbf{Y}_{t-p} + \boldsymbol{\epsilon}_t, t = 1, \dots, T$$

ถ้าตัวแปรบางตัวหรือทุกตัวในแบบจำลองเวกเตอร์ออโตรีเกรสชันมีลักษณะเป็นมีคุณสมบัติไม่นิ่ง แบบจำลองดังกล่าวอาจจะเผชิญกับปัญหาความสัมพันธ์เทียม เช่นเดียวกับกรณีสมการเดี่ยว ซึ่งเราต้องพิจารณาต่อไปว่าตัวแปรเหล่านั้นโคอินทิเกรตกันหรือไม่

### 7.5.1 รูปแบบของสมการเวกเตอร์เอเรคโคเรชัน

Johansen 1991 ได้เสนอแบบจำลองเวกเตอร์เอเรคโคเรชัน (Vector Error Correction Model) หรือเวคเอ็ม (VECM) โดยมีพื้นฐานจากแบบจำลองเวกเตอร์ออโตรีเกรสชันของ  $\mathbf{Y}_t = (Y_{1t}, \dots, Y_{nt})'$  ซึ่งตัวแปรทั้งหมดอินทิเกรตที่อันดับหนึ่ง เพื่อความง่ายเราจะพิจารณากรณีเวกเตอร์ออโตรีเกรสชันอันดับหนึ่ง เขียนเป็นสมการได้ดังนี้

$$\mathbf{Y}_t = \mu + \Phi_1 \mathbf{Y}_{t-1} + \boldsymbol{\epsilon}_t \quad (7.13)$$

หากลบทั้งสองข้างของสมการด้วย  $\mathbf{Y}_{t-1}$  จะได้

$$\begin{aligned} \mathbf{Y}_t - \mathbf{Y}_{t-1} &= \mu - (I - \Phi_1) \mathbf{Y}_{t-1} + \boldsymbol{\epsilon}_t \\ \Delta \mathbf{Y}_t &= \mu - \Phi(1) \mathbf{Y}_{t-1} + \boldsymbol{\epsilon}_t \end{aligned} \quad (7.14)$$

ด้วยวิธีการเดียวกัน เราสามารถแสดงได้ว่า เราสามารถแปลงเวกเตอร์ออโตรีเกรสชันอันดับ  $p$  ( $VAR(p)$ )

$$\mathbf{Y}_t = \mu + \Phi_1 \mathbf{Y}_{t-1} + \dots + \Phi_p \mathbf{Y}_{t-p} + \boldsymbol{\epsilon}_t \quad (7.15)$$

เป็นแบบจำลองเวกเตอร์เอเรคโคเรชันอันดับ  $p$  หนึ่ง ( $VECM(p-1)$ )

$$\Delta \mathbf{Y}_t = \mu - \Phi(1) \mathbf{Y}_{t-1} \Gamma_1 \Delta \mathbf{Y}_{t-1} + \dots + \Gamma_{p-1} \Delta \mathbf{Y}_{t-p} + \boldsymbol{\epsilon}_t \quad (7.16)$$



โดยที่  $\Phi(1) = I_n - \Phi_1 - \dots - \Phi_p$  จะเห็นได้ว่าสมการ 7.16 คือแบบจำลอง  $VAR(p-1)$  ของ  $\Delta Y_t$  โดยที่เมทริกซ์  $\Phi(1)$  คือเมทริกซ์สัมประสิทธิ์ที่แสดงความสัมพันธ์ระยะยาว และ  $\Gamma_k$  คือเมทริกซ์สัมประสิทธิ์ที่อธิบายผลของการปรับตัวระยะสั้นในคาบที่ผ่านมา หากพิจารณาแบบจำลองเวกเตอร์เอเรอโคเรชันในสมการ 7.16 เราพบว่า  $\Delta Y_t$  และค่าล่าของ  $\Delta Y_t$  มีคุณลักษณะหนึ่งหรืออินทิเกรตที่อันดับศูนย์ ( $I(0)$ ) จะเห็นได้ว่า เหลือเพียงพจน์  $\Phi(1)Y_{t-1}$  ที่มีโอกาสเป็นอินทิเกรตที่อันดับหนึ่ง ( $I(1)$ ) หาก  $\Phi(1)Y_{t-1}$  เป็น  $I(0)$  จะส่งผลให้  $\Delta Y_t$  จะเป็น  $I(0)$  ด้วย ดังนั้นพจน์  $\Phi(1)Y_{t-1}$  จะเป็นเมทริกซ์ที่ระบุความสัมพันธ์ระยะยาวหากตัวแปรโคอินทิเกรตกัน เนื่องจาก  $Y_{t-1}$  เป็นตัวแปรที่ไม่นิ่ง เราจะพิจารณาเมทริกซ์  $\Phi(1)$  ว่าส่งผลให้พจน์ดังกล่าวมีคุณลักษณะหนึ่งหรือไม่ อนุกรมเวลา  $Y_t$  จะโคอินทิเกรตกันถ้ามีเมทริกซ์  $\beta$  ที่มีค่าลำดับชั้นคอลัมน์เต็ม (full column rank)<sup>1</sup> ขนาด  $n \times r$  โดยที่  $1 \leq r < n$  ซึ่งสามารถสร้างผลรวมเชิงเส้น  $r$  ความสัมพันธ์ดังสมการต่อไปนี้

$$\beta' Y_t = u_t$$

แล้วมีคุณลักษณะหนึ่ง เราเรียก  $r$  ว่าค่าลำดับชั้นโคอินทิเกรชัน (cointegrating rank) และคอลัมน์ของสัมประสิทธิ์เมทริกซ์  $\beta$  ว่าเวกเตอร์โคอินทิเกรชัน (cointegrating vector) ระบบสมการที่แสดงความสัมพันธ์ระยะยาวเป็นดังนี้

$$\begin{bmatrix} \beta_{1,1} & \beta_{1,2} & \dots & \beta_{1,r} \\ \beta_{2,1} & \beta_{2,2} & \dots & \beta_{2,r} \\ \vdots & \vdots & \ddots & \vdots \\ \beta_{n,1} & \beta_{n,2} & \dots & \beta_{n,r} \end{bmatrix}' \begin{bmatrix} Y_{1t} \\ Y_{2t} \\ \vdots \\ Y_{nt} \end{bmatrix} = \begin{bmatrix} u_{1t} \\ u_{2t} \\ \vdots \\ u_{rt} \end{bmatrix}$$

หากตัวแปร  $n$  ตัวแปรมีจำนวนความสัมพันธ์ระยะยาวเท่ากับ  $r$  แสดงว่าตัวแปรดังกล่าวถูกผลักดันด้วยแนวโน้มร่วม (common trend) ซึ่งเป็นอินทิเกรตที่อันดับหนึ่งจำนวน  $n-r$  ส่วนประกอบ เช่น กรณีของอัตราดอกเบี้ยพันธบัตรที่มีอายุไถ่ถอน 3 ระยะ ( $n=3$ ) หากเราพบว่ามีสมการความสัมพันธ์ระยะยาวเท่ากับสอง ( $r=2$ ) แสดงว่าอัตราดอกเบี้ยทั้งสามถูกผลักดันด้วยแนวโน้มร่วมเพียงเส้นเดียว Engle and Granger 1987 นำเสนอทฤษฎีบทการนำเสนอของเกรนเจอร์ (Granger representation theorem) ซึ่งอธิบายความสัมพันธ์ระหว่างสมการโคอินทิเกรชัน และแบบจำลองเวกเตอร์เอเรอโคเรชันไว้ดังนี้

1. ถ้า  $\Phi(1)$  มีค่าอันดับชั้นเต็ม (full rank) คือ  $r=n$  แล้ว  $Y_t$  มีคุณลักษณะหนึ่ง
2. ถ้า  $\Phi(1)$  มีค่าอันดับชั้นลด (reduced rank) เท่ากับ  $r$  โดยที่  $0 < r < n$  และ  $\Phi(1) = -\alpha\beta'$  ซึ่งทั้ง  $\alpha$  และ  $\beta$  เป็นเมทริกซ์ขนาด  $n \times r$  ที่มี ค่าลำดับชั้นคอลัมน์เต็ม แล้ว  $Y_t$  เป็น  $I(1)$  และตัวแปรโคอินทิเกรตกัน โดยมี  $r$  จำนวนความสัมพันธ์ และเวกเตอร์โคอินทิเกรชันคือคอลัมน์ของ  $\beta$
3. ถ้า  $\Phi(1)$  มีค่าอันดับชั้นเท่ากับศูนย์ แล้ว  $\Phi(1) = 0$  และ  $Y_t$  เป็น  $I(1)$  ซึ่งตัวแปรมิได้โคอินทิเกรตกัน และแบบจำลอง  $VECM(p-1)$  จะลดลงเหลือแค่  $VAR(p-1)$  ของตัวแปรในรูปผลต่างหนึ่งอันดับ

จากคุณสมบัติข้างต้น การทดสอบโคอินทิเกรชันตามวิธีของ Johansen จะพิจารณา  $\Phi(1)$

<sup>1</sup> ค่าลำดับชั้น (rank) ของเมทริกซ์  $A$  ใด ๆ คือจำนวนของแถวที่มีสมาชิกไม่เป็นศูนย์ของเมทริกซ์ขั้นบันไดตามแถว (row-echelon matrix) ที่สมมูล (equivalent) กับเมทริกซ์  $A$

ในกรณีที่เราทดสอบแล้วพบว่ามีจำนวนความสัมพันธ์เท่ากับ  $r$  เราสามารถพิจารณาเวกเตอร์  $\Phi(1)$  ซึ่งสามารถแยกออกได้เป็นเมทริกซ์  $\alpha$  และ  $\beta'$  ซึ่งมีมิติเท่ากับ  $n \times r$  และ  $r \times n$  ตามลำดับ

$$\Phi(1) = \alpha\beta'$$

ตัวอย่างเช่น หากเราพิจารณากรณีที่ตัวแปรเท่ากับ 4 หากเราพบความสัมพันธ์เท่ากับหนึ่ง ( $r = 1$ )

$$\Phi(1) = \alpha\beta' = \begin{bmatrix} \alpha_{11} \\ \alpha_{12} \\ \alpha_{13} \\ \alpha_{14} \end{bmatrix} \begin{bmatrix} \beta_{11} & \beta_{12} & \beta_{13} & \beta_{14} \end{bmatrix}$$

หากเราพบความสัมพันธ์เท่ากับสอง ( $r=2$ )

$$\Phi(1) = \alpha\beta' = \begin{bmatrix} \alpha_{11} & \alpha_{21} \\ \alpha_{12} & \alpha_{22} \\ \alpha_{13} & \alpha_{23} \\ \alpha_{14} & \alpha_{24} \end{bmatrix} \begin{bmatrix} \beta_{11} & \beta_{12} & \beta_{13} & \beta_{14} \\ \beta_{21} & \beta_{22} & \beta_{23} & \beta_{24} \end{bmatrix}$$

ในกรณีของความสัมพันธ์เท่ากับหนึ่ง เราสามารถเขียนส่วนของ  $\Phi(1)Y_{t-1}$  ได้เป็น

$$\Phi(1)Y_{t-1} = \begin{bmatrix} \alpha_{11} \\ \alpha_{12} \\ \alpha_{13} \\ \alpha_{14} \end{bmatrix} (\beta_{11}y_{1,t-1} + \beta_{12}y_{2,t-1} + \beta_{13}y_{3,t-1} + \beta_{14}y_{4,t-1})$$

ซึ่งเราสามารถนำไปเขียนสมการเอเรอโคเรชันสำหรับแต่ละตัวแปรได้ เช่น

$$\Delta Y_{1t} = \alpha_{11}(\beta_{11}y_{1,t-1} + \beta_{12}y_{2,t-1} + \beta_{13}y_{3,t-1} + \beta_{14}y_{4,t-1}) + \dots$$

นอกจากนี้เราสามารถปรับค่าสัมประสิทธิ์ของตัวแปรตัวใดตัวหนึ่งมีค่าเท่ากับหนึ่งได้ (normalized) ในการทดสอบโคอินทิเกรชันและการประมาณค่าแบบจำลองเวกเตอร์เอเรอโคเรชันขึ้นอยู่กับรูปแบบของพจน์เชิงกำหนด (deterministic term) ในสมการที่ประมาณค่า Johansen 1995 นำเสนอรูปแบบพจน์เชิงกำหนดแบบจำลองออกเป็น 5 กรณีโดยระบุพจน์ดังกล่าวในส่วนของสมการโคอินทิเกรชัน หรือในส่วนของสมการเวกเตอร์เอเรอโคเรชัน ซึ่งแต่ละรูปแบบจะแสดงลักษณะของตัวแปร  $Y_t$  ที่แตกต่างกัน เพื่อให้เห็นรูปแบบจำลอง เราจะพิจารณากรณีที่มิตัวแปรเพียงสองตัวแปรและพจน์การปรับตัวในคาบก่อนจากแบบจำลอง

## 1. กรณีไม่มีค่าคงที่ทั้งสองสมการ (no constant)

$$\Delta Y_{1t} = \alpha_1(Y_{1,t-1} - \beta_2 Y_{2,t-1}) + v_{1t}$$

$$\Delta Y_{2t} = \alpha_2(Y_{1,t-1} - \beta_2 Y_{2,t-1}) + v_{2t}$$

ตัวแปรทั้งสองจะอินทิเกรตที่อันดับหนึ่งและไม่มีดริฟท์และสมการโคอินทิเกรชันจะมีค่าเฉลี่ยเท่ากับ ศูนย์

## 2. กรณีมีค่าคงที่ในสมการโคอินทิเกรชันเพียงอย่างเดียว (restricted constant)

$$\Delta Y_{1t} = \alpha_1(Y_{1,t-1} - \beta_2 Y_{2,t-1} - \mu) + v_{1t}$$

$$\Delta Y_{2t} = \alpha_2(Y_{1,t-1} - \beta_2 Y_{2,t-1} - \mu) + v_{2t}$$

ตัวแปรทั้งสองจะอินทิเกรตที่อันดับหนึ่งและไม่มีดริฟท์และสมการโคอินทิเกรชันจะมีค่าเฉลี่ยไม่เท่ากับ ศูนย์

## 3. กรณีมีค่าคงที่ในสมการโคอินทิเกรชันและสมการเวกเตอร์เอเรอโคเรชัน (unrestricted constant)

$$\Delta Y_{1t} = \delta_1 + \alpha_1(Y_{1,t-1} - \beta_2 Y_{2,t-1} - \mu) + v_{1t}$$

$$\Delta Y_{2t} = \delta_2 + \alpha_2(Y_{1,t-1} - \beta_2 Y_{2,t-1} - \mu) + v_{2t}$$

ตัวแปรทั้งสองจะอินทิเกรตที่อันดับหนึ่งและมีดริฟท์เท่ากับ  $\delta_1$  และ  $\delta_2$  ส่วนสมการโคอินทิเกรชันจะมีค่าเฉลี่ยไม่เท่ากับศูนย์

## 4. กรณีมีทั้งค่าคงที่และแนวโน้มในสมการโคอินทิเกรชัน และมีค่าคงที่ในสมการเวกเตอร์เอเรอโคเรชัน (restricted trend)

$$\Delta Y_{1t} = \delta_1 + \alpha_1(Y_{1,t-1} - \beta_2 Y_{2,t-1} - \mu - \rho T) + v_{1t}$$

$$\Delta Y_{2t} = \delta_2 + \alpha_2(Y_{1,t-1} - \beta_2 Y_{2,t-1} - \mu - \rho T) + v_{2t}$$

ตัวแปรทั้งสองจะอินทิเกรตที่อันดับหนึ่งและมีดริฟท์เท่ากับ  $\delta_1$  และ  $\delta_2$  ส่วนสมการโคอินทิเกรชันจะมีเส้นแนวโน้ม

## 5. กรณีมีทั้งค่าคงที่และแนวโน้มทั้งสองสมการ (unrestricted trend)


$$\Delta Y_{1t} = \delta_1 + \theta_1 T + \alpha_1(Y_{1,t-1} - \beta_2 Y_{2,t-1} - \mu - \rho T) + v_{1t}$$

$$\Delta Y_{2t} = \delta_2 + \theta_2 T + \alpha_2(Y_{1,t-1} - \beta_2 Y_{2,t-1} - \mu - \rho T) + v_{2t}$$


ตัวแปรทั้งสองจะอินทิเกรตที่อันดับหนึ่งและมีเส้นแนวโน้มเป็นเส้นตรง ตัวแปรทั้งสองจะมีลักษณะเป็น

เส้นแนวโน้ม ส่วนสมการโคอินทิเกรชันจะมีเส้นแนวโน้มแบบโค้ง (quadratic trend)


รูปที่ 7.6: No constant




รูปที่ 7.7: restricted constant




รูปที่ 7.8: unrestricted constant



รูปที่ 7.9: restricted trend



รูปที่ 7.10: unrestricted trend



กรณีที่ 1 มักจะไม่เกิดขึ้นจริงในการประยุกต์กับข้อมูลจริง ในขณะที่กรณีที่ 2 มักใช้กับข้อมูลทีอินทิเกรตที่อันดับหนึ่งและไม่มีแนวโน้มเช่นอัตราดอกเบี้ยหรืออัตราแลกเปลี่ยน ส่วนกรณีที่ 3 เหมาะกับข้อมูลเช่นราคาหลักทรัพย์หรือข้อมูลเศรษฐกิจมหภาคมวลรวมเช่น GDP การบริโภคหรือการจ้างงาน กรณีที่ 4 สามารถใช้กับข้อมูลที่มีแนวโน้ม แต่สมการความสัมพันธ์ระยะยาวมีลักษณะที่เป็นเส้นแนวโน้มด้วย ในขณะที่กรณีที่ 5 ควรใช้กับกรณีที่ข้อมูลมีแนวโน้มเส้นโค้ง เช่นการประยุกต์กับข้อมูลที่เป็นตัวเงินหรืออัตราเงินเฟ้อสูงผิดปกติ (extreme inflation)

### 7.5.2 การทดสอบโคอินทิเกรชันด้วยจำนวนค่าลำดับชั้นตามวิธีของโจแฮนเซน

จากทฤษฎีบทของเกรนเจอร์ เราทราบว่าจำนวนของความสัมพันธ์ระยะยาวจะเท่ากับจำนวนค่าลำดับชั้น (rank) ของเมทริกซ์  $\Phi(1)$  ดังนั้น โจแฮนเซนนำเสนอว่าการทดสอบโคอินทิเกรชันสามารถทำได้โดยการทดสอบว่าเมทริกซ์  $\Phi(1)$  เป็นเมทริกซ์ที่มีค่าลำดับชั้นลดรูปเท่ากับ  $r$  หรือไม่ จากพีชคณิตเชิงเส้น เราทราบว่าจำนวนของค่าลำดับชั้นของเมทริกซ์จะเท่ากับจำนวนของค่าเฉพาะ (eigenvalue) ซึ่งไม่เท่ากับศูนย์<sup>2</sup> ค่าเฉพาะ  $\lambda_i$  จะถูกจัดเรียงตามขนาด  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$  และค่าเฉพาะมีคุณสมบัติ  $|\lambda_i| < 1$  และ  $\lambda_i \geq 0$  ค่าเฉพาะตัวแรก ( $\lambda_1$ ) จะมีค่ามากที่สุด และค่าเฉพาะตัวสุดท้าย ( $\lambda_n$ ) จะมีค่าน้อยที่สุดและใกล้ศูนย์ ถ้าตัวแปรทั้งหมดไม่โคอินทิเกรตกัน ค่าเฉพาะทุกตัวจะมีค่าไม่แตกต่างจากศูนย์อย่างมีนัยสำคัญ ตัวสถิติที่ใช้ทดสอบจะถูกคำนวณจาก  $\ln(1 - \lambda_i)$  ซึ่งมีค่าเท่ากับศูนย์เมื่อค่าเฉพาะ  $\lambda_i$  มีค่าเท่ากับศูนย์ ถ้าค่าเฉพาะมีค่าไม่เท่ากับศูนย์แล้ว  $\ln(1 - \lambda_i) < 0$  ตัวอย่างเช่น ถ้าค่าลำดับชั้น  $\Phi(1) = 1$  แล้ว  $\ln(1 - \lambda_1) < 0$  และ  $\ln(1 - \lambda_i) = 0$  สำหรับ  $i > 1$

<sup>2</sup>ค่าเฉพาะของเมทริกซ์  $A$  เขียนแทนด้วย  $\lambda$  คือจำนวนจริงที่เป็นคำตอบของระบบสมการเชิงเส้น  $Ax = \lambda x$  และเราเรียกผลเฉลยนี้ว่าเวกเตอร์เฉพาะ (eigenvector) ทั้งนี้ค่าเฉพาะสามารถหาได้จากการแก้สมการ  $(A - \lambda I)x = 0$  ซึ่งจะมีคำตอบเมื่อ  $\det(A - \lambda I) = 0$  ตัวอย่างเช่น  $A = \begin{bmatrix} 0 & 1 \\ -2 & -3 \end{bmatrix}$  เราต้องการหาคำตอบของ  $|A - \lambda I| = \begin{vmatrix} -\lambda & 1 \\ -2 & -3 - \lambda \end{vmatrix} = \lambda^2 + 3\lambda + 2 = 0$  จะได้  $\lambda_1 = -1, \lambda_2 = -2$  คือค่าเฉพาะของเมทริกซ์  $A$  นอกจากนี้เราสามารถหาเวกเตอร์เฉพาะ ( $x_1$ ) ที่สัมพันธ์กับ  $\lambda_1 = -1$  จากสมการ  $Ax_1 = \lambda_1 x_1$  ซึ่งได้แก่  $x_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$

ถ้าตัวแปรใน  $\mathbf{Y}_t$  ไม่ได้โคอินทิเกรตกัน ค่าลำดับของ  $\Pi$  จะไม่แตกต่างจากศูนย์อย่างมีนัยสำคัญ ดังนั้น  $\lambda_i \approx 0$  สำหรับทุกค่าของ  $i$  อย่างไรก็ตาม ในการทดสอบเราจะพิจารณา  $\ln(1-\lambda_i)$  ซึ่งหาก  $\lambda_i = 0$  แล้ว  $\ln(1-\lambda_i) = 0$

โจแฮนเซนเสนอการทดสอบสองวิธีที่มีพื้นฐานจากการหาค่าเฉพาะของเมทริกซ์  $\Phi(1)$  ได้แก่ การทดสอบ Maximal eigenvalue และการทดสอบ Trace

### Johansen's Trace Statistic

Johansen's Trace statistic ทดสอบสมมุติฐานต่อไปนี้

$$H_0(r_0) : r = r_0 \quad \text{vs} \quad H_1(r_0) : r > r_0$$

โดยที่ LR Trace statistics และคำนวณได้ดังนี้

$$LR_{trace}(r_0) = -T \sum_{i=r_0+1}^n \ln(1 - \hat{\lambda}_i)$$

โดยที่  $r_0$  คือจำนวนความสัมพันธ์ในสมมุติฐานหลัก และ  $\hat{\lambda}_i$  คือค่าประมาณของค่าลักษณะเฉพาะอันดับที่  $i$  ซึ่งหาก  $rank(\Pi) = r_0$  แล้ว  $\hat{\lambda}_{r_0+1}, \dots, \hat{\lambda}_n$  จะมีค่าเข้าใกล้ศูนย์ และ  $LR_{trace}(r_0)$  ควรจะมีค่าน้อย

### Johansen's Maximum Eigenvalue Statistic

Johansen ยังได้เสนอการทดสอบ LR Maximum Eigenvalue statistic สำหรับสมมุติฐานต่อไปนี้

$$H_0(r_0) : r = r_0 \quad \text{vs} \quad H_1(r_0) : r = r_0 + 1$$

โดยเราเรียก LR statistic ว่า *maximum eigenvalue statistic* และคำนวณได้ดังนี้

$$LR_{max}(r_0) = -T \ln(1 - \hat{\lambda}_{r_0+1})$$

Johansen and Juselius 1990 เสนอว่าค่าวิกฤตที่ใช้ทดสอบสำหรับตัวสถิติทั้งสองมีการแจกแจงขึ้นอยู่กับรูปแบบของสมการ ซึ่งหากค่าสถิติสูงกว่าค่าวิกฤตที่ Johansen เสนอ เราจะปฏิเสธสมมุติฐานหลักที่ว่าตัวแปรมีความสัมพันธ์  $r_0$  สมการ และยอมรับว่ามีความสัมพันธ์มากกว่า  $r_0$  สำหรับการทดสอบ Trace statistics ในขณะที่หากเราใช้การทดสอบ Max Eigenvalue statistic เราจะยอมรับว่ามีความสัมพันธ์เท่ากับ  $r_0 + 1$  ความสัมพันธ์

Johansen เสนอการทดสอบในลักษณะที่เป็นอันดับ (sequential testing procedure) โดยที่กระบวนการดังกล่าวจะระบุจำนวนของความสัมพันธ์ได้อย่างคงเส้นคงว่า โดยที่กระบวนการเป็นดังนี้

- ขั้นตอนแรกเราทดสอบ  $H_0(r_0 = 0)$  กับ  $H_1(r_0 > 0)$  ถ้าเราไม่สามารถปฏิเสธสมมุติฐานหลัก ตัวแปรไม่โคอินทิเกรตกัน

ถ้าเราปฏิเสธ  $H_0(r_0 = 0)$  เราสามารถสรุปได้ว่า มีจำนวนความสัมพันธ์อย่างน้อยหนึ่งความสัมพันธ์อย่างน้อยหนึ่งความสัมพันธ์และทดสอบในขั้นต่อไป

- ทดสอบ  $H_0(r_0 = 1)$  กับ  $H_1(r_0 > 1)$  ถ้าเราไม่สามารถปฏิเสธสมมติฐานหลัก เราสรุปว่ามีจำนวนความสัมพันธ์เท่ากับหนึ่ง
- แต่ถ้า เราปฏิเสธสมมติฐาน แสดงว่า มีจำนวนความสัมพันธ์อย่างน้อยสองสมการ
- กระบวนการที่เป็นอันดับดังกล่าวจะดำเนินไปเรื่อยๆจนกระทั่งสมมติฐานหลักถูกปฏิเสธ

### 7.5.3 ขั้นตอนในการทดสอบโคอินทิเกรชันและสร้างแบบจำลองเวกเตอร์เอเรอโคเรชัน

ขั้นตอนในการสร้างแบบจำลอง Cointegration ของ Johansen คือ

- ระบุ Order และประมาณค่า VAR(p) สำหรับ  $Y_t$
- สร้าง likelihood ratio tests สำหรับการทดสอบ rank of  $\Pi$  เพื่อระบุจำนวน cointegrating vectors
- หากจำเป็นเราอาจจะสมมุติ normalization และระบุเงื่อนไขของ cointegrating vectors
- จาก normalized cointegrating vectors ที่ได้ระบุไว้ เราสามารถประมาณค่า cointegrated VECM ด้วย MLE

การทดสอบตามแนวทางของโจแฮนเซนขึ้นอยู่กับรูปแบบของสมการและจำนวนของค่าสำหรับการปรับตัวของตัวแปรในอดีต ( $p - 1$ ) สำหรับการทดสอบโคอินทิเกรชันตามแนวทางของโจแฮนเซนด้วยโปรแกรม R จะใช้ชุดคำสั่ง `urca` และคำสั่ง `ca.jo` โดยที่ในคำสั่งดังกล่าวมีตัวเลือกที่เราต้องระบุดังนี้

- `spec=c("transitory")` หมายถึงการตอบสนองของตัวแปรเกิดจากการออกนอกดุลยภาพในคาบที่แล้ว ( $u_{t-1}$ )
- สถิติที่ใช้ในการทดสอบระหว่าง `type=c("trace")` หรือ `type=c("eigen")`
- ระบุนับของค่าในสมการเวกเตอร์รีเกรสซีฟ ( $p$ ) ซึ่งในคำสั่งนี้คือ  $k$  อย่างไรก็ตามอันดับขั้นต่ำของ  $p$  คือ 2
- รูปแบบของพจน์เชิงกำหนดในสมการระยะยาวซึ่งมีทางเลือกคือ `"none"`, `"const"`, `"trend"`

**ตัวอย่างที่ 7.8** ทดสอบเวกเตอร์เอเรอโคเรชันตามแนวทางของโจแฮนเซนกับราคาปัจจุบันและราคาฟิวเจอร์ของ SET50

เราจะพิจารณาข้อมูลในตัวอย่างที่ 7.6 ด้วยแบบจำลองเวกเตอร์เอเรอโคเรชันซึ่งประมาณค่าสมการระยะยาวและสมการเวกเตอร์เอเรอโคเรชันไปพร้อม ๆ กัน รวมถึงการทดสอบโคอินทิเกรชัน

ขั้นตอนแรก คือการหาอันดับที่เหมาะสมสำหรับแบบจำลองเวกเตอร์เอเรอโคเรชัน (  $VECM(p-1)$  ) โดยจะเป็นอันดับที่น้อยกว่าของเวกเตอร์ออโตรีเกรสซีฟหนึ่งอันดับ (  $VAR(p)$  ) ซึ่งในที่นี้เราจะใช้ชุดคำสั่ง `vars` และคำสั่ง `VAR` ในการประมาณค่าข้อมูล `fsprice` ซึ่งเป็นเมทริกซ์ที่ประกอบด้วยข้อมูล `lfutures` กับ `lspot` และเลือกใช้ `BIC` ในการหาอันดับที่เหมาะสม โดยใช้คำสั่งต่อไปนี้



```

1 > fsprice<-cbind(lfutures,lspot)
2 > library(vars)
3 > var.mod<-VAR(fsprice, lag.max = 4, ic = c("SC"))
4 > var.mod
5 VAR Estimation Results:
6 =====
7 Estimated coefficients for equation lfutures:
8 =====
9 Call:
10 lfutures = lfutures.l1 + lspot.l1 + const
11
12 lfutures.l1    lspot.l1    const
13    -0.47626    1.47463    0.00916
14
15 Estimated coefficients for equation lspot:
16 =====
17 Call:
18 lspot = lfutures.l1 + lspot.l1 + const
19
20 lfutures.l1    lspot.l1    const
21    -0.881    1.875    0.042

```

จากผลการประมาณค่า เราจะเห็นได้ว่าค่า  $p$  ที่เหมาะสมคือ 1 ซึ่งแสดงด้วยสัญลักษณ์ .l1 แสดงว่าแบบจำลองที่เหมาะสม คือ VAR(1) และ VECM(0) อย่างไรก็ตามเนื่องจากข้อจำกัดของคำสั่ง ca.jo เราจะระบุค่า  $K=2$

ในการทดสอบโคอินทิเกรชัน เราจะต้องระบุข้อมูล (sprice) วิธีในการทดสอบด้วยตัวสถิติเทรซ (type=c("trace")) รูปแบบของสมการ (ecdet=c("const")) และจำนวนค่าล่าในแบบจำลองเวกเตอร์ออโตรีเกรสซีฟ ซึ่งในที่นี้คือ  $K=2$  โดยเก็บผลการทดสอบไว้ในชื่อ fsprice.rc และเรียกดูผลด้วย summary(fsprice.rc)

```

1 > library(urca)
2 > fsprice.rc <-ca.jo(fsprice, type = c("trace"), ecdet = c("const"), K
   =2)
3 > summary(fsprice.rc)
4
5 #####
6 # Johansen-Procedure #
7 #####
8
9 Test type: trace statistic , without linear trend and constant in
   cointegration
10
11 Eigenvalues (lambda):
12 [1] 2.24e-01 1.72e-02 2.26e-17
13
14 Values of teststatistic and critical values of test:
15
16          test 10pct  5pct 1pct
17 r <= 1 |   2.83   7.52  9.24 13.0
18 r = 0  |  44.18 17.85 19.96 24.6

```

จะได้ค่าสถิติซึ่งมีการทดสอบแบบเป็นลำดับ

- $H_0 : r = 0$  vs  $H_1 : r > 0$  ค่าสถิติ 44.18 มากกว่าค่า c.v.19.96 กรณี significance level = 0.05 เราสามารถปฏิเสธสมมุติฐานหลัก และสรุปว่า  $r > 0$
- $H_0 : r = 1$  vs  $H_1 : r > 1$  ค่าสถิติ 2.83 น้อยกว่าค่า c.v. 9.24 กรณี significance level = 0.05 เราไม่สามารถปฏิเสธสมมุติฐานหลัก และยอมรับว่า  $r = 1$  หรือ  $lfutures$  และ  $lspot$  โคอินทิเกรตด้วยความสัมพันธ์ 1 ความสัมพันธ์

เราสามารถสร้างสมการเวกเตอร์เอเรอโคเรชัน ได้ด้วยคำสั่ง `cajorls` โดยระบุว่าจะใช้รูปแบบจาก `fsprice.rc` และจำนวนความสัมพันธ์เท่ากับ 1 ( $r = 1$ )

```
1 > fsprice.vecm <-cajorls(fsprice.rc, r= 1)
2 > fsprice.vecm
3 $rlm
4
5 Call:
6 lm(formula = substitute(form1), data = data.mat)
7
8 Coefficients:
9             lfutures.d  lspot.d
10 ect1             -2.219      -1.626
11 lfutures.dl1      -1.525      -0.899
12 lspot.dl1         1.726       1.087
13
14
15 $beta
16             ect1
17 lfutures.l2    1.0000
18 lspot.l2       -1.0078
19 constant       0.0556
```

จากคำสั่งดังกล่าว เราสามารถเขียนสมการเวกเตอร์เอเรอโคเรชันซึ่งอยู่ในส่วน `$rlm` และแต่ละสมการเรียงตามแต่ละคอลัมน์ได้ดังนี้

$$\Delta f_t = -2.219u_{t-1} - 1.525\Delta f_{t-1} + 1.726\Delta s_{t-1}$$

$$\Delta s_t = -1.626u_{t-1} - 0.899\Delta f_{t-1} + 1.087\Delta s_{t-1}$$

โดยที่สมการความสัมพันธ์ระยะยาวอยู่ในส่วน `$beta` ได้แก่

$$u_t = f_t - 1.008s_t + 0.056$$

จะเห็นว่าค่าสัมประสิทธิ์ที่ได้แตกต่างจากการประมาณค่าสองขั้นตอนของเองเจลและแกรงเจอร์

**ตัวอย่างที่ 7.9** การทดสอบและประมาณค่า VECM สมการอัตราผลตอบแทนพันธบัตรรัฐบาล

```

1 > tbond <- read.csv("https://raw.githubusercontent.com/chaleampong/EC435
  /master/tbond.csv", header = TRUE)
2 > head(tbond)
3 > m1<-tbond$m1
4 > m3<-tbond$m3
5 > y5<-tbond$y5

```

ขั้นตอนแรกของการทดสอบคือการหาอันดับที่เหมาะสมของ VECM โดยการจัดตัวแปรทั้งสามให้อยู่ในรูปเมทริกซ์ 'rterm' ด้วยคำสั่ง 'cbind' หลังจากนั้น ประมาณค่า VAR ด้วย package 'vars' และ คำสั่ง 'VAR' โดยระบุข้อมูลที่ประมาณค่าคือ 'rterm' จำนวนอันดับที่สูงที่สุด 'lag.max=6' และเลือก model selection คือ AIC ด้วย 'ic=c("AIC")' และเพื่อให้พิจารณาค่าสัมประสิทธิ์ได้ง่ายเราอาจจะใช้ option(digits=2)

```

1 > library(vars)
2 > rterm <- cbind(m1, m3, y5)
3 > var.mod <- VAR(rterm, lag.max=6, ic= c("AIC"))
4 > options(digits = 2)
5 > var.mod
6
7 VAR Estimation Results:
8 =====
9
10 Estimated coefficients for equation m1:
11 =====
12 Call:
13 m1 = m1.l1 + m3.l1 + y5.l1 + m1.l2 + m3.l2 + y5.l2 + m1.l3 + m3.l3 + y5
  .l3 + const
14
15      m1.l1      m3.l1      y5.l1      m1.l2      m3.l2      y5.l2      m1.l3      m3.l3      y5.l3
16 -0.1482    1.4685    0.0179    0.3192   -0.5652    0.0358   -0.1006    0.0154   -0.0550
17      const
18 -0.0098
19
20 Estimated coefficients for equation m3:
21 =====
22 Call:
23 m3 = m1.l1 + m3.l1 + y5.l1 + m1.l2 + m3.l2 + y5.l2 + m1.l3 + m3.l3 + y5
  .l3 + const
24
25      m1.l1      m3.l1      y5.l1      m1.l2      m3.l2      y5.l2      m1.l3      m3.l3      y5.l3
26 -0.7726    2.0692    0.0735    0.4037   -0.6330   -0.0066   -0.3514    0.2566   -0.0572
27      const
28 0.0035
29
30 Estimated coefficients for equation y5:
31 =====
32 Call:

```

```

31 y5 = m1.l1 + m3.l1 + y5.l1 + m1.l2 + m3.l2 + y5.l2 + m1.l3 + m3.l3 + y5
    .l3 + const
32
33 m1.l1 m3.l1 y5.l1 m1.l2 m3.l2 y5.l2 m1.l3 m3.l3 y5.l3 const
34 -0.947 1.027 1.272 -0.419 0.018 -0.410 0.340 0.017 0.060 0.120

```

หากพิจารณาแบบจำลอง VAR ที่เหมาะสมคือ VAR(3) ดังนั้น เราจะประมาณค่าแบบจำลอง VECM(2)

เราทดสอบ Johansen's test โดยใช้คำสั่ง 'ca.jo' ใน package 'urca' โดยระบุตัวสถิติที่ใช้คือ trace statistic ด้วย 'type=c("trace")' และรูปแบบของ cointegration มีค่าคงที่ 'ecdet=c("const")' และจำนวนอันดับของ VAR 'k=3' โดยเก็บผลไว้ในชื่อ 'rterm.rc' และเรียกดูผลด้วย 'summary(rterm.rc)'

```

1 > rterm.rc <-ca.jo(rterm, type=c("trace"), ecdet=c("const"), K=3)
2 > summary(rterm.rc)
3 #####
4 # Johansen-Procedure #
5 #####
6
7 Test type: trace statistic , without linear trend and constant in
  cointegration
8
9 Eigenvalues (lambda):
10 [1] 0.16 0.10 0.03 0.00
11
12 Values of teststatistic and critical values of test:
13
14      test 10pct 5pct 1pct
15 r <= 2 | 4.3   7.5  9.2   13
16 r <= 1 | 19.7  17.9 20.0   25
17 r = 0  | 44.5  32.0 34.9   41
18
19 Eigenvectors, normalised to first column:
20 (These are the cointegration relations)
21
22      m1.l3 m3.l3 y5.l3 constant
23 m1.l3    1.000  1.00  1.00     1.0
24 m3.l3   -1.018 -1.83 -1.14    -1.4
25 y5.l3    0.023  0.67  0.44     1.0
26 constant 0.011 -0.14 -1.05    -4.8
27
28 Weights W:
29 (This is the loading matrix)
30
31      m1.l3 m3.l3 y5.l3 constant
32 m1.d -0.96  0.0343 -0.005  2.7e-16
33 m3.d -0.75  0.0524 -0.018  2.2e-16
34 y5.d -0.90 -0.0043 -0.124  3.5e-16

```

จากค่าสถิติซึ่งมีการทดสอบแบบเป็นลำดับ (ในกรณีนี้ใช้ significance level เท่ากับ 0.1)

- $H_0 : r = 0$  vs  $H_1 : r > 0$  ค่าสถิติเท่ากับ 44.49 > Critical value (=32) เราสามารถปฏิเสธ

สมมุติฐานหลักที่ว่า  $r = 0$  และยอมรับว่า  $r > 0$

- $H_0 : r = 1$  vs  $H_1 : r > 1$  ค่าสถิติเท่ากับ  $19.69 > \text{Critical value } (=17.85)$  เราสามารถปฏิเสธสมมุติฐานหลักที่ว่า  $r = 1$  และยอมรับว่า  $r > 1$
- $H_0 : r = 2$  vs  $H_1 : r > 2$  ค่าสถิติเท่ากับ  $4.31 < \text{Critical value } (=7.52)$  เราไม่สามารถปฏิเสธสมมุติฐานหลักที่ว่า  $r = 2$

สรุปว่าตัวแปรทั้ง 3 cointegrated กัน และมีความสัมพันธ์ 2 สมการ จากผลการทดสอบเราสามารถประมาณ VECM ด้วยคำสั่ง `cajorls` โดยระบุรูปแบบสมการเช่นเดียวกับ `rterm.rc` และจำนวนความสัมพันธ์ 'r=2 โดยเก็บผลการประมาณค่าไว้ในชื่อ `rterm.vecm`

```
1 > rterm.vecm <-cajorls(rterm.rc, r=2)
2 > rterm.vecm
3 $rlm
4
5 Call:
6 lm(formula = substitute(form1), data = data.mat)
7
8 Coefficients:
9           m1.d           m3.d           y5.d
10 ect1      -0.9245      -0.7024      -0.9016
11 ect2       0.9131       0.6724       0.9210
12 m1.dl1     -1.1489     -0.7751     -0.9638
13 m3.dl1      1.4676      1.0658      1.0036
14 y5.dl1      0.0195      0.0792      0.3112
15 m1.dl2     -0.8288     -0.3682     -1.3602
16 m3.dl2      0.9017      0.4301      1.0025
17 y5.dl2      0.0548      0.0708     -0.1110
18
19
20 $beta
21           ect1           ect2
22 m1.l3      1.0e+00      2.2e-16
23 m3.l3     -4.4e-16      1.0e+00
24 y5.l3     -7.8e-01     -7.9e-01
25 constant  2.0e-01      1.8e-01
```

ซึ่งเมื่อเรียกผลออกมา จะสามารถแบ่งออกเป็นสองส่วน

ส่วนแรกในบริเวณ `$beta` จะระบุความสัมพันธ์ระยะยาว หรือสมการ cointegration ตามคอลัมน์ โดยที่ที่และคอมันจะระบุด้วยชื่อ `ect1` และ `ect2` ซึ่งสามารถเขียนเป็นสมการได้ดังนี้

$ect1_{t-1} = 1m1_t - (-4.44 \times 10^{-16})m3_t - 0.78y5_t + 0.195$  ซึ่งเราค่าสัมประสิทธิ์หน้า `m3` มีค่าน้อยมาก เราสามารถตัดออก และเขียนสมการใหม่ได้เป็น  $m1_t = 0.78y5_t - 0.195 + ect1_{t-1}$

$ect2_{t-1} = (2.22 \times 10^{-16})m1_t + 1m3_t - 0.794y5_t - t + 0.181$  ซึ่งเราค่าสัมประสิทธิ์หน้า `m1` มีค่าน้อยมาก เราสามารถตัดออก และเขียนสมการใหม่ได้เป็น  $1m3_t = 0.794y5_t - t - 0.181 + ect2_{t-1}$

ส่วนสองในบริเวณ `$rlm` จะระบุการปรับตัวในระยะสั้น หรือ VECM โดยแต่ละคอลัมน์จะแทนแต่ละสมการ ได้แก่ `m1.d` ( $\Delta m1_t$ ) `m3.d` ( $\Delta m3_t$ ) และ `y5.d` ( $\Delta y5_t$ ) ยกตัวอย่างเช่น สมการ `m1.d` สามารถ

เขียนได้ดังนี้

$$\Delta m1_t = -0.92ect1_{t-1} + 0.91ect2_{t-1} - 1.14\Delta m1_{t-1} + 1.46\Delta m3_{t-1} + 0.02\Delta y5_{t-1} - 0.82\Delta m1_{t-2} + 0.90\Delta m3_{t-2} + 0.05\Delta y5_{t-2}$$

## 7.6 แบบฝึกฝน

**แบบฝึกฝน 7.1** หากเราต้องการศึกษาความสัมพันธ์ระหว่างดัชนีตลาดหลักทรัพย์ไทย (SET) และ มาเลเซีย (KLSE) ว่ามีความสัมพันธ์กันหรือไม่ จงตอบคำถามต่อไปนี้ โดยใช้ข้อมูลจาก ps5\_2.txt [คอลัมน์แรกคือดัชนีราคา SET และ คอลัมน์ที่สองคือดัชนีราคา KLSE]

1. จงทดสอบ unit root ในดัชนีราคา SET และ KLSE
2. จงทดสอบ cointegration ของดัชนีราคา SET และ KLSE โดยใช้วิธี Engle-Granger พร้อมอธิบายผลการทดสอบอย่างละเอียด
3. จงประมาณค่าแบบจำลอง Error Correction Model พร้อมเขียนผลการประมาณค่า
4. จงทดสอบ cointegration โดยใช้วิธีของ Johansen พร้อมเขียนผลการประมาณค่าจาก VECM

**แบบฝึกฝน 7.2** ทฤษฎี purchasing power parity (PPP) เสนอว่าในระยะยาวอัตราแลกเปลี่ยนที่เป็นตัวเงินจะปรับตัวตามความแตกต่างระหว่างราคาในประเทศกับต่างประเทศ

$$S = \frac{P}{F}$$

เราสามารถเขียนเป็นความสัมพันธ์ระยะยาวได้ดังนี้

$$s_t = \beta_1 + \beta_2 p_t + \beta_3 f_t + u_t$$

โดยที่  $s_t, p_t, f_t$  เป็นอัตราแลกเปลี่ยน ราคาในประเทศ และราคาต่างประเทศในรูปลอการิทึมตามลำดับ

**แบบฝึกฝน 7.3** สมมติฐานของฟิชเชอร์ (Fisher Hypothesis) เสนอว่าในระยะยาวอัตราดอกเบี้ยที่แท้จริงเป็นตัวเงินจะสะท้อนอัตราเงินเฟ้อ ซึ่งแสดงได้ด้วยสมการ

$$i_t = \beta_1 + \beta_2 \pi_t + u_t$$

โดยที่  $\beta_2 = 1$

## A. การใช้โปรแกรม R เบื้องต้น

โปรแกรม R เป็นโปรแกรมภาษาคอมพิวเตอร์ขั้นสูงที่ถูกออกแบบมาสำหรับการคำนวณทางสถิติ และใช้กันอย่างแพร่หลายในแวดวงสถิติและการเงิน โปรแกรม R เป็นโปรแกรมที่ให้ผู้ใช้งานสามารถใช้ได้ฟรี และมีคู่มือมากมายที่อธิบายวิธีการใช้ สำหรับการสอนในวิชานี้เราจะใช้โปรแกรมต่อประสาน (interface) ชื่อว่า RStudio สำหรับการทำงานร่วมกับโปรแกรม R เนื่องจากมีหน้าต่างของคำสั่งที่ได้ใช้ตลอดจนผลการวาดกราฟในหน้าต่างย่อย นอกจากนี้เนื่องจากนักศึกษาจำนวนมากอาจจะคุ้นเคยการใช้โปรแกรมผ่าน Graphic User Interface ในวิชานี้ เราจะใช้ Rstudio ช่วยในการนำเข้าข้อมูล

### A.1 การติดตั้ง R

เพื่อที่จะติดตั้งโปรแกรม R เราสามารถดาวน์โหลดได้ที่ <http://www.cran.r-project.org> โดยที่เราสามารถเลือกระบบปฏิบัติการที่สอดคล้องกับเครื่องคอมพิวเตอร์ของเราได้ไม่ว่าเป็น Microsoft Windows, Linux หรือ Mac OS X ซึ่งในการติดตั้งนี้จะอธิบายในกรณีของระบบปฏิบัติการ Windows

- คลิก CRAN ตรงเมนูด้านซ้ายมือ
- เลือก Operation ซึ่งในที่นี้ผมเลือก R for Windows
- เลือก Base
- คลิก Download R x.x.x for Windows และเลือก default ทุกคำถามที่ถาม

### A.2 การติดตั้ง RStudio

หลังจากที่เราได้ติดตั้งโปรแกรม R แล้วเราจะมี Icon R อยู่บน Desktop เมื่อคลิกที่ไอคอนดังกล่าวจะมี Interface ในการทำงานขึ้นมา อย่างไรก็ตามในวิชานี้เราจะใช้ RStudio Interface ในการทำงาน โดยเราสามารถ

ดาวน์โหลด RStudio ได้ที่ <http://www.rstudio.com/ide/download/> ซึ่งสามารถเลือกระบบปฏิบัติการที่สอดคล้องกับเครื่องที่ใช้ได้อยู่ได้

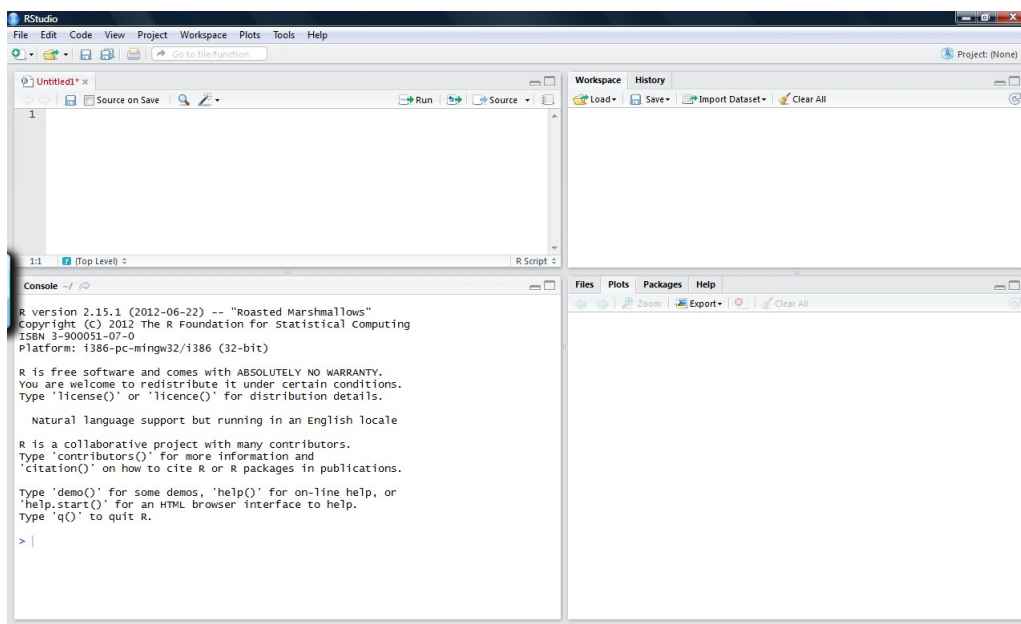
- คลิก Download RStudio Desktop เพื่อดาวน์โหลด
- คลิกไฟล์ที่อยู่ใต้หัวข้อ Recommended For Your System
- Save File และรันโปรแกรม

เนื่องจากโปรแกรม R จำเป็นต้องมีการติดตั้งโปรแกรมสำเร็จรูปย่อย (package) ดังนั้น เราจะประมวลผลโปรแกรม R จาก Flashdrive หรือ External harddisk หรือ Drive D: ในห้องคอมพิวเตอร์ที่เรามีสิทธิที่จะแก้ไขเปลี่ยนแปลงข้อมูลได้ โดยการคัดลอกโฟลเดอร์ R/R-x.x.x และ RStudio จากโฟลเดอร์ Program Files แล้ววางใน Flashdrive และเรียกโปรแกรมมาใช้โดยการคลิก rstudio.exe ในโฟลเดอร์ RStudio/bin โดยในครั้งแรกอาจจะมีการถามถึงโฟลเดอร์ที่มีโปรแกรม R อยู่ใน Flashdrive

## A.3 ผังของโปรแกรม RStudio

ผังของโปรแกรม RStudio จะประกอบด้วยหน้าต่างดังที่แสดงในรูป A.1

รูปที่ A.1: ผังโปรแกรม RStudio



หน้าต่างล่างซ้ายเรียกว่า **Console window** หรือ **Command window** ในหน้าต่างดังกล่าวจะมี ">" prompt ซึ่งเราจะใส่คำสั่งหลังเครื่องหมายนั้นเพื่อให้โปรแกรม R ดำเนินการ

หน้าต่างบนซ้ายเรียกว่า **Editor window** หรือ **Script window** เป็นหน้าต่างที่ใช้เก็บชุดคำสั่งเพื่อที่จะเก็บและสามารถเรียกมาใช้ในภายหลังได้

หน้าต่างบนขวาเป็นหน้าต่าง **Workspace/ History window** เป็นหน้าต่างเราสามารถดูข้อมูลหรือค่าต่างๆที่เรากำลังเรียกมาอยู่ในหน่วยความจำ และคำสั่งเก่าๆที่ได้ดำเนินการไปแล้ว



หน้าต่างล่างขวาเป็นหน้าต่าง **Files/Plots/Packages/Help window** เป็นหน้าต่างที่เราสามารถเรียกข้อมูลขึ้นมา ดูกราฟ และติดตั้งหรือเรียกชุดคำสั่ง (packages)

## A.4 ชุดคำสั่ง (package) หรือห้องสมุด (library)

โปรแกรม R สามารถวิเคราะห์ข้อมูลและสถิติได้อย่างหลากหลาย โดยชุดคำสั่งที่ใช้ร่วมกันจะถูกเก็บใน *packages* หรือ *libraries* โดยในการติดตั้งทั่วไปจะมีการติดตั้ง *packages* ที่ใช้บ่อยๆอยู่แล้ว โดยที่เราสามารถเรียกดู *packages* ที่ติดตั้งไว้แล้วในหน้าต่าง *packages* หรือพิมพ์คำสั่ง `library()` หากกล่องหน้า *packages* มีเครื่องหมายถูกแสดงว่า *packages* นั้นได้ถูกโหลดมาไว้ในหน่วยความจำและสามารถใช้งานได้ทันที

ในขณะที่ *packages* ที่ยังไม่ได้ติดตั้งหรือยังไม่ได้โหลดเข้ามาในหน่วยความจำสามารถดำเนินการได้โดยง่ายใน RStudio ตัวอย่างเช่น หากเราต้องการติดตั้ง *package* ที่ชื่อว่า Rcmdr

- การติดตั้ง *package* (install package): คลิก `install package` ใน *package window* แล้วพิมพ์ชื่อ *package* ที่ต้องการเช่น Rcmdr แล้วคลิก `Install` หรือพิมพ์ `install.packages("Rcmdr")` ในหน้าต่างคำสั่ง
- การใช้งาน *package*: เลือกกล่องเพื่อให้เครื่องหมายถูกหน้า *package* ที่เราต้องการเช่น Rcmdr หรือพิมพ์ `library("Rcmdr")` ในหน้าต่างคำสั่ง

## A.5 การทำงานบน Working directory

*Working directory* เป็นโฟลเดอร์ที่เราจะทำงาน โดยโปรแกรม R จะหาข้อมูลตลอดจนโปรแกรมที่เราเขียนไว้จากโฟลเดอร์ดังกล่าว ตลอดจนข้อมูลและรูปภาพที่เราบันทึกไว้จะอยู่ในโฟลเดอร์นั้น ดังนั้นก่อนการเริ่มงานบน R เราควรกำหนดโฟลเดอร์ดังกล่าวด้วยคำสั่งใน *command window* `setwd("directoryname")` เช่น

```
1 > setwd("D:/Teaching/EC435/R")
```

หรือบน RStudio เมนูเลือก Tools → Set Working Directory → Choose Directory

## A.6 การใช้งานเบื้องต้น

### A.6.1 เครื่องคิดเลข

โปรแกรม RStudio เราสามารถคำนวณกระบวนการทางคณิตศาสตร์ได้ด้วยเครื่องหมายดังต่อไปนี้ โดยพิมพ์คำสั่งดังกล่าวในหน้าต่าง *Console* แล้ว Enter

```
1 > 2+3 # Addition
2 > 2-3 # Subtraction
3 > 2*3 # Multiplication
4 > 2/3 # Division
```

```
5 > 2^3 # 2 to the power of 3
6 > sqrt(3) # Square roots
7 > log(3) # Logarithms (to the base e)
```

### A.6.2 พื้นที่ทำงาน (workspace)

เราสามารถเก็บผลการคำนวณไว้ในตัวแปรใดๆได้โดยใช้ “assignment operator” `<-` , หรือ `=` เช่น

```
1 > a <- 2 * 3
2 > 2 * a
3 [1] 12
```

### A.6.3 สเกลาร์ เวกเตอร์ และเมทริกซ์

ข้อมูลตัวเลขใน R จะถูกบันทึกในรูปแบบสเกลาร์ เวกเตอร์ หรือเมทริกซ์ เช่นในตัวอย่างที่ผ่านมา `a` คือสเกลาร์ที่มีค่าเท่ากับ 6 หรือเราสามารถสร้างเวกเตอร์ได้โดยใช้ฟังก์ชัน `c` ดังนี้ เช่นเวกเตอร์ `b` ประกอบด้วยสมาชิกคือ 2,3,4

```
1 > b=c(2, 3, 4)
2 > b
3 [1] 2 3 4
```

### A.6.4 ฟังก์ชัน

บางครั้งเราต้องการคำนวณค่าบางค่าที่ต้องใช้คำสั่งหลายบรรทัด บางครั้งเราสามารถใช้ฟังก์ชันที่มีอยู่แล้วในโปรแกรมหลักของ R หรือใน `package` ต่างๆ เช่น การหาค่าเฉลี่ยสามารถใช้ฟังก์ชัน `mean()` เช่นเราต้องการหาค่าเฉลี่ยของ 5,9,13,4 เราต้องรวมค่าทั้งหมดไว้ในเวกเตอร์และหาค่าเฉลี่ยดังนี้

```
1 > x=c(5, 9, 13, 4)
2 > mean(x)
3 [1] 7.75
```

โดยที่ค่าหรือตัวเลือกที่ต้องกำหนดในวงเล็บเรียกว่า *arguments* ตัวอย่างของฟังก์ชันอีกอันของฟังก์ชันคือฟังก์ชัน `rnorm` ที่ใช้ในการสร้างค่าทดลอง (generate) ค่าจากการแจกแจงแบบปกติ

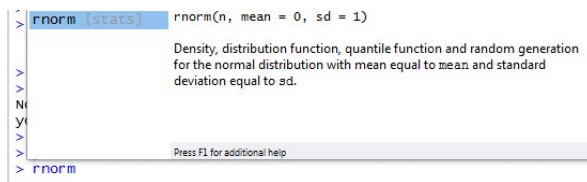
```
1 > rnorm(10)
2 [1] 0.60299 -0.75383 0.97095 1.06657 0.26545 -0.51994 -0.89247 -0.01616
3 [9] 1.11192 -0.31573
```

RStudio มีส่วนประกอบที่ช่วยเหลือเกี่ยวกับ *arguments* ที่เราจะต้องใส่สำหรับแต่ละฟังก์ชันเราสามารถเขียนฟังก์ชันใน `command window` แล้วกดปุ่ม `Tab` จะมีตัวอย่างของ *arguments* ขึ้นมาให้เช่นรูป A.2

### A.6.5 การวาดแผนภาพ

```
1 > x=rnorm(100)
2 > plot(x)
```

รูปที่ A.2: Tab ช่วยเหลือใน RStudio



## A.7 การช่วยเหลือและเอกสารประกอบฟังก์ชัน

เมื่อพิมพ์ฟังก์ชัน `help` จะมีเอกสารช่วยเหลือในหน้าต่าง `help`

```
1 > help(rnorm)
```

หรือเราสามารถใช้ฟังก์ชัน `example` เพื่อดูตัวอย่างคำสั่งและผลของฟังก์ชัน

```
1 > example(rnorm)
```

## A.8 Scripts

นอกจากการพิมพ์คำสั่งใน `command window` แล้วเราสามารถประมวลผลโปรแกรมจาก `script` ซึ่งมีนามสกุล `.R` โดยการเลือกเปิดไฟล์จาก `File` → `Open File` แล้วเลือก `Script` ขึ้นมาแล้วคลิก `run` ในเมนู `editor window`

## A.9 โครงสร้างข้อมูล

### A.9.1 เวกเตอร์

เราสามารถสร้างเวกเตอร์ได้ด้วยฟังก์ชัน `c` เช่นคำสั่งในบรรทัดที่ 1 นอกจากนี้เราสามารถเรียกดูข้อมูลในตำแหน่งที่  $i$  ด้วยคำสั่ง `vectorname[i]` เช่นบรรทัดที่ 4 นอกจากนี้เราสามารถสร้างเวกเตอร์ที่มีระยะเท่ากันด้วยฟังก์ชัน `seq` ดังเช่นในบรรทัดที่ 9

```
1 > vec1=c(2,4,6,8,10)
2 > vec1
3 [1] 2 4 6 8 10
4 > vec1[5]
5 [1] 10
6 > vec1[3]=12
7 > vec1
8 [1] 2 4 12 8 10
9 > vec2=seq(from=0,to=1,length=5)
10 > vec2
11 [1] 0.00 0.25 0.50 0.75 1.00
12 > vec1+vec2
13 [1] 2.00 4.25 12.50 8.75 11.00
```

## A.9.2 เมตริกซ์

เราสามารถสร้างเมตริกซ์โดยการระบุข้อมูลและขนาดของเมตริกซ์ด้วย **argument** `nrow` หรือ `ncol` ซึ่งระบุจำนวนแถวหรือคอลัมน์ของเมตริกซ์

```
1 > m=matrix(data=c(1, 2, 3, 4, 5, 6), ncol=3)
2 > m
3      [,1] [,2] [,3]
4 [1,]    1    3    5
5 [2,]    2    4    6
```

**arguments** `data` ในฟังก์ชัน `matrix` กำหนดข้อมูลที่จะใส่ในเมตริกซ์โดยที่ `ncol` เป็นตัวกำหนดจำนวนคอลัมน์ของเมตริกซ์ โดยที่เราอาจเลือกกำหนด `nrow` ก็ได้

การเรียกข้อมูลแต่ละตำแหน่งสามารถทำได้โดยใช้ `[row, column]`

```
1 > m[1,2]
2 [1] 3
3 > m[1,]
4 [1] 1 3 5
5 > m[,2]
6 [1] 3 4
```

## A.9.3 data frame

ข้อมูลอนุกรมเวลามักถูกจัดเก็บในรูปของ **data frame** โดยที่หัวคอลัมน์เป็นชื่อของคอลัมน์ ดังนั้นเราสามารถเรียกคอลัมน์นั้นๆมาใช้โดยไม่ต้องทราบตำแหน่งของข้อมูลเช่น

```
1 > t=data.frame(x=c(1, 2, 3), y=c(10, 20, 30), z=c(100, 200, 300))
2 > t
3      x  y  z
4 1 1 10 100
5 2 2 20 200
6 3 3 30 300
7 > mean(t$y)
8 [1] 20
9 > mean(t[["z"]])
10 [1] 200
```

## A.9.4 list

โครงสร้างของข้อมูลอีกแบบคือ **list** โดยที่ข้อมูลจะถูกเก็บเป็นคอลัมน์ซึ่งไม่ได้เรียงลำดับและไม่จำเป็นต้องมีความยาวเท่ากัน โดยที่ฟังก์ชันในการสร้าง **list** ก็คือ `list` นั่นเอง โดยที่ใน **argument** เราจะใส่ตัวแปรต่างๆลงไป โดยในที่ตัวแปร `one` เป็นตัวแปรสเกลาร์ที่มีค่าเท่ากับ 1 ตัวแปร `two` เป็นตัวแปรเวกเตอร์ และตัวแปร `five` เป็นเวกเตอร์ที่มีสมาชิกห้าตัว

```
1 > L=list(one=1, two=c(1,2), five=seq(1,4, length=5))
2 > L
3 $one
```

```

4 [1] 1
5 $two
6 [1] 1 2
7 $five
8 [1] 1.00 1.75 2.50 3.25 4.00
9 > L$five+10
10 [1] 11.00 11.75 12.50 13.25 14.00

```

## A.10 Graphic

คำสั่งในการสร้างรูปภาพคือ `plot` โดยที่ **argument** ตัวแรกคือ ข้อมูลที่เราจะ `plot` ในที่นี้คือข้อมูลสุ่มที่สร้างขึ้นจากการแจกแจงแบบปกติจำนวน 100 ตัวอย่าง `rnorm(100)` สำหรับ **argument** ที่เหลือเป็นการกำหนดรูปและส่วนประกอบได้แก่ `type` คือประเภทของกราฟในที่นี้ "l" แทนกราฟเส้น `col` คือสีของกราฟ `ylab` คือชื่อแกน Y `xlab` คือชื่อแกน X และ `main` คือชื่อกราฟ

```

1 > plot(rnorm(100), type="l", col="blue", ylab="values", xlab="observations", main=
    "Generated Data of N(0,1)")

```

หรือหากเราจะสร้างเส้นหลายเส้นสามารถทำได้โดยการเพิ่มเส้นทีละเส้น โดยในคำสั่งแรกจะต้องกำหนดระยะแกน Y ให้ครอบคลุมทั้งสามเส้นด้วยคำสั่ง `ylim`


```

1 > plot(t$x, type="l", ylim=range(t), lwd=3)
2 > lines(t$y, type="s", col="red")
3 > points(t$z, pch=20, cex=5, col="blue")

```

และจะได้รูปที่ A.3

รูปที่ A.3: ตัวอย่างการสร้างกราฟฟิก



## A.11 การจัดเก็บข้อมูลและนำเข้าข้อมูล

### A.11.1 การจัดเก็บข้อมูลในรูปแบบไฟล์ text

เราสามารถนำเข้าข้อมูลโดยการสร้าง data frame และจัดเก็บในรูปแบบไฟล์ text (นามสกุล .txt) โดยใช้คำสั่ง `write.table` ใน argument ประกอบด้วย ชื่อ data frame, ชื่อไฟล์ที่จัดเก็บ และชื่อของตัวแปร ซึ่งในที่นี่ได้กำหนดไว้แล้วใน data frame

```
1 > d=data.frame(a=c(3, 4, 5), b=c(12, 13, 15))
2 > d
3   a  b
4 1 3 12
5 2 4 13
6 3 5 15
7 > write.table(d, file="ts0.txt", row.names=FALSE)
```

### A.11.2 การเรียกข้อมูลในรูปแบบไฟล์ text

เราสามารถเรียกข้อมูลที่จัดเก็บในรูปแบบไฟล์ text ด้วยฟังก์ชัน `read.table` โดย argument คือชื่อไฟล์และการระบุว่ามีชื่อตัวแปรหรือไม่ซึ่งในที่นี้คือมีชื่อตัวแปร `header=TRUE`

```
1 > d2=read.table(file="ts0.txt", header=TRUE)
2 > d2
3   a  b
4 1 3 12
5 2 4 13
6 3 5 15
```

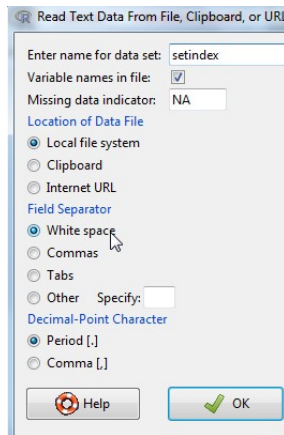
ผู้อ่านสามารถทดลองนำเข้าข้อมูลไฟล์ text ชื่อว่า `setindex.txt`<sup>1</sup> เมื่อเปิดไฟล์ดังกล่าวด้วยโปรแกรมเช่น Notepad จะเห็นได้ว่าข้อมูลมีการแบ่งด้วยช่องว่าง เราสามารถนำเข้าข้อมูลด้วย R Commander โดยขั้นตอน

```
1 date index
2 1/5/1998 366.18
3 1/6/1998 370.27
4 1/7/1998 370.31
5 1/8/1998 360.17
6 1/9/1998 349.67
7 1/12/1998 339.17
8 1/13/1998 348.96
9 1/14/1998 367.69
10 1/15/1998 364.12
```


ต่อไปนี้

1. เลือก Data/Import Data/From text file, clipboard, or URL แล้วคลิก
2. จะได้กล่องให้ใส่เงื่อนไขต่างๆ ใส่ชื่อ Data set เป็น `setindex` และดูว่า มีการแบ่งข้อมูล(Field separator) เป็น white space ตามรูป
3. จะได้กล่องให้เราระบุตำแหน่งของไฟล์ เลือก Folder และ ไฟล์ที่เราต้องการ (ในที่นี้คือ `setindex.txt`) แล้ว Open

<sup>1</sup>download จาก Moodle ไปยัง workspace directory



4. จะเห็นได้ว่าในพื้นที่ใต้เมนู จะมีชื่อ Dataset เป็น setindex ที่เรานำเข้ามา และเราสามารถเรียกดูข้อมูลได้โดยคลิก view data



ไฟล์ text อีกประเภทหนึ่งที่เรามักจะเจอเวลาเราดาวน์โหลดข้อมูลคือ .csv โดยเราสามารถนำเข้าข้อมูลได้โดยใช้คำสั่ง read.csv เช่นในที่นี้ชื่อไฟล์ pttstock.csv เมื่อเปิดไฟล์ดังกล่าวด้วยโปรแกรมเช่น Notepad จะเห็นได้ว่าข้อมูลมีการแบ่งด้วย Comma


```
1 date,price
2 6/17/2003,65.5
3 6/18/2003,66
4 6/19/2003,67
5 6/20/2003,66.5
6 6/23/2003,68
7 6/24/2003,66.5
8 6/25/2003,66
9 6/26/2003,67.5
10 6/27/2003,66
11 6/30/2003,66.5
12 7/1/2003,66.5
```

เราสามารถนำเข้าข้อมูลด้วย R Commander โดยขั้นตอนต่อไปนี้

1. เลือก Data/Import Data/From text file, clipboard, or URL แล้วคลิก
2. จะได้อีกกล่องให้ใส่เงื่อนไขต่างๆ ใส่ชื่อ Data set เป็น ptt และดูว่า มีการแบ่งข้อมูล(Field separator) เป็น comma
3. จะได้อีกกล่องให้เราระบุตำแหน่งของไฟล์ เลือก Folder และ ไฟล์ที่เราต้องการ (ในที่นี้คือ pttstock.csv) แล้ว Open
4. จะเห็นได้ว่าในพื้นที่ใต้เมนู จะมีชื่อ Dataset เป็น ptt ที่เรานำเข้ามา

### A.11.3 การนำเข้าไฟล์ประเภทอื่นๆ

เราสามารถนำเข้าไฟล์ได้หลายประเภทเช่น SPSS, STATA และ Excel ได้ด้วยการเลือก Data/Import Data แล้วเลือกประเภทของไฟล์ที่ต้องการนำเข้าตามรูป



### A.11.4 การบันทึกข้อมูล

เราสามารถบันทึกข้อมูลที่เรานำเข้าและสร้างตัวแปรใหม่ได้โดยการเลือก Data/Active data set/Save active data set... แล้วเลือก Folder ที่เราต้องการบันทึก และกำหนดชื่อ (ชนิดไฟล์ Rdata) แล้ว Save

ในการเปิดไฟล์ที่เราบันทึกครั้งต่อไปเราสามารถเลือก Data/Load data set

นอกจากนี้เราสามารถ Export ข้อมูลในรูปไฟล์ชนิดอื่นเช่น .txt หรือ .csv สำหรับนำเข้าในโปรแกรมอื่นได้ด้วยการเลือก Data/Active data set/Export active data set... เลือกวิธีการแบ่งคอลัมน์แล้วคลิก OK หลังจากนั้นกำหนดชื่อไฟล์และชนิดไฟล์ที่ต้องการ

## A.12 การคำนวณผลได้ตอบแทนจากตัวอย่างหุ้น PTT

### A.12.1 การวาดกราฟ


จากข้อมูล ptt เราสามารถวาดกราฟได้โดย เปลี่ยน active data set เป็น ptt โดยคลิกที่ Data set แล้วเลือก ptt

เราสามารถสร้างกราฟได้โดยการเลือก Graphs ในที่นี้ข้อมูลของเราเป็นอนุกรมเวลา เราจะเลือก Graphs/epack- time series plots จะได้รูปดังต่อไปนี้ เราสามารถบันทึกรูปไว้โดยเลือก File/Save as แล้วเลือกประเภทไฟล์ที่ต้องการ หรือหากต้องการนำไปวางในโปรแกรมเอกสารเช่น Word เราสามารถเลือก File/Copy to the clipboard

เนื่องจาก data frame ที่เรานำเข้ามายังไม่ได้ระบุตัวแปรเวลาสำหรับการเรียงข้อมูล เราจะใช้ package zoo ในการจัดการข้อมูลให้เรียงตามเวลาที่ระบุใน data frame ดังต่อไปนี้ โดยที่ตัวแปรใหม่จะถูกจัดเก็บใน data set ptt โดยการใส่ชื่อ ptt.z ต่อท้าย ptt\$

```
1 > library(zoo)
2 > ptt$ptt.z<-zoo(x=ptt$price, order.by=as.Date(ptt$date, "%m/%d/%Y"))
3 > head(ptt$ptt.z)
4 2003-06-17 2003-06-18 2003-06-19 2003-06-20 2003-06-23 2003-06-24
```






```

5      65.5      66.0      67.0      66.5      68.0      66.5
6 > plot(ptt$ptt.z,xlab="Year",ylab="Baht/share", main="PTT Stock Price")

```

แล้วเราจะได้รูป A.4

รูปที่ A.4: ราคาหุ้น PTT



## A.12.2 การคำนวณผลได้ตอบแทน

การคำนวณผลได้ตอบแทนด้วยคำสั่งหลักใน R

เราสามารถคำนวณผลได้ตอบแทนอย่างง่ายได้โดยนำราคาในตำแหน่งที่  $i$  ลบด้วยตำแหน่งที่  $i-1$  แล้วหารด้วย  $i-1$  โดยการเขียนคำสั่งในบรรทัดที่ 1 อย่างไรก็ตามผลลัพธ์ที่ได้จะมีจำนวนหายไปหนึ่งตำแหน่ง หากเราจะนำข้อมูลไปรวมใน data frame จะต้องมีการสมมุติให้ตำแหน่งแรกเป็นศูนย์ตามบรรทัดที่ 2

```

1 > n=length(ptt$price)
2 > sret=(ptt$price[2:n]-ptt$price[1:n-1])/(ptt$price[1:n-1])

```

หากเราต้องการรวมตัวแปรใน **data frame** เราต้องเพิ่มตัวอย่างแรกในตัวแปร **sret** เพื่อให้ความยาวเท่ากัน

```
1 > head(sret)
2 [1] 0.007634 0.015152 -0.007463 0.022556 -0.022059 -0.007519
3 > ptt$sret=c(NA, sret)
4 > head(ptt)
5      date price      sret
6 1 6/17/2003 65.5      NA
7 2 6/18/2003 66.0 0.007634
```

หรือสามารถคำนวณผลได้ตอบแทนในรูปของล็อกได้ด้วยคำสั่งในบรรทัดที่ 1 หรือบรรทัดที่สอง หรือแปลงค่าจากผลได้ตอบแทนอย่างง่าย

```
1 > lret=log(ptt$price[2:n])-log(ptt$price[1:n-1])
2 > lret2=diff(log(ptt$price))
3 > lret3=log(1+sret)
4 > head(lret)
5 [1] 0.007605 0.015038 -0.007491 0.022306 -0.022306 -0.007547
6 > ptt$lret=c(NA, lret)
7 > head(ptt)
8      date price      sret      lret
9 1 6/17/2003 65.5      NA      NA
10 2 6/18/2003 66.0 0.007634 0.007605
11 3 6/19/2003 67.0 0.015152 0.015038
12 4 6/20/2003 66.5 -0.007463 -0.007491
13 5 6/23/2003 68.0 0.022556 0.022306
14 6 6/24/2003 66.5 -0.022059 -0.022306
```

เราสามารถบันทึก **data frame** **ptt** เป็นไฟล์ **csv** ด้วยคำสั่ง

```
1 > write.csv(ptt, file="pttreturn.csv", row.names=FALSE)
```

### R package สำหรับคำนวณผลได้ตอบแทน

เราสามารถคำนวณผลได้ตอบแทนได้ด้วย **package** **PerformanceAnalytics** โดยที่ตัวแปรนั้นต้องอยู่ในรูป **zoo** ซึ่งในที่นี้คือ **ptt\$pttz** คำสั่งที่ใช้ในการคำนวณ คือ **Return.calculate(price, method)** โดยที่ **discrete** คือ **simple return**


```
1 > ptt$sret2=Return.calculate(ptt$pttz, method = "discrete")
2 > ptt$lret2=Return.calculate(ptt$pttz, method = "log")
3 > head(ptt)
4      date price ptt.z      sret      lret      sret2      lret2
5 1 6/17/2003 65.5 65.5      NA      NA      NA      NA
6 2 6/18/2003 66.0 66.0 0.007633588 0.007604599 0.007633588 0.007604599
7 3 6/19/2003 67.0 67.0 0.015151515 0.015037877 0.015151515 0.015037877
8 4 6/20/2003 66.5 66.5 -0.007462687 -0.007490672 -0.007462687 -0.007490672
9 5 6/23/2003 68.0 68.0 0.022556391 0.022305758 0.022556391 0.022305758
10 6 6/24/2003 66.5 66.5 -0.022058824 -0.022305758 -0.022058824 -0.022305758
```

เนื่องจากข้อมูลในแถวแรกเป็น **NA** เราอาจจะลบข้อมูลในแถวแรก

แล้วสามารถวาดแผนภาพของผลได้ตอบแทนได้ในรูปล็อกได้ตามรูปที่ A.5

```
1 > plot(ptt$lret2,xlab="Year",ylab="%", main="Log Return of PTT Stock Price",  
      col="blue")
```

รูปที่ A.5: ผลได้ตอบแทนจากราคาหุ้น PTT



- Bollerslev, Tim. 1986. "Generalized autoregressive conditional heteroskedasticity". *Journal of Econometrics* 31, no. 3 (): 307–327.
- Engle, Robert F. 1982. "Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation". *Econometrica* 50 (4): 987–1007.
- Engle, Robert F., and C. W. J. Granger. 1987. "Co-Integration and Error Correction: Representation, Estimation, and Testing". *Econometrica* 55 (2): 251–276.
- Fuller, Wayne A. 1996. *Introduction to Statistical Time Series*. Wiley.
- Hamilton, James D. 1994. *Time Series Analysis*. Princeton University Press.
- Johansen, Soren. 1991. "Estimation and Hypothesis Testing of Cointegration Vectors in Gaussian Vector Autoregressive Models". *Econometrica* 59 (6): 1551–1580.
- . 1995. *Likelihood-Based Inference in Cointegrated Vector Autoregressive Models*. Oxford University Press.
- . 1988. "Statistical analysis of cointegration vectors". *Journal of Economic Dynamics and Control* 12 (2-3): 231–254.
- Johansen, Soren, and Katarina Juselius. 1990. "Maximum Likelihood Estimation and Inference on Cointegration with Applications to the Demand for Money". *Oxford Bulletin of Economics and Statistics* 52 (2): 169–210.
- John Y. Campbell, Andrew W. Lo, and A.Craig MacKinlay. 1997. *The Econometrics of Financial Markets*. Princeton University Press.

- McLeod, A. I., and W. K. Li. 1983. "DIAGNOSTIC CHECKING ARMA TIME SERIES MODELS USING SQUARED-RESIDUAL AUTOCORRELATIONS". *Journal of Time Series Analysis* 4 (4): 269–273.
- Newey, Whitney K., and Kenneth D. West. 1987. "A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix". *Econometrica* 55 (3): 703–708.
- Phillips, P. C. B., and S. Ouliaris. 1990. "Asymptotic Properties of Residual Based Tests for Cointegration". *Econometrica* 58 (1): 165–193.
- Phillips, P.C.B., and P. Perron. 1988. "Testing for a unit root in time series regression". *Biometrika* 75, no. 2 (): 335–346.
- White, Halbert. 1980. "A Heteroskedasticity-Consistent Covariance Matrix Estimator and a Direct Test for Heteroskedasticity". *Econometrica* 48 (4): 817–838.
- Wooldridge, Jeffrey M. 1989. "A computationally simple heteroskedasticity and serial correlation robust standard error for the linear regression model". *Economics Letters* 31, no. 3 (): 239–243.
- . *Introductory Econometrics: A Modern Approach*.

