

EC435

บทที่ 2 แบบจำลองอนุกรมเวลาเชิงเส้นตรง

เฉลิมพงษ์ คงเจริญ ©2556-61

คณะเศรษฐศาสตร์ มหาวิทยาลัยธรรมศาสตร์

September 3, 2019



กระบวนการไวท์นอยซ์ (white noise)

ข้อมูลอนุกรมเวลาที่ง่ายที่สุดคือกระบวนการไวท์นอยซ์ (white noise) โดยที่เรามักจะเขียนแทนด้วย random variable ε_t

นิยาม 2.1

ตัวแปร ε_t จะเรียกว่ากระบวนการไวท์นอยซ์ถ้ามีค่าเฉลี่ยเท่ากับศูนย์, มีค่าความแปรปรวนคงที่เท่ากับ σ^2 และไม่มีสหสัมพันธ์ข้ามเวลา (serially uncorrelated) หรือเขียนเป็นเงื่อนไขได้ดังนี้

- 1 $E(\varepsilon_t) = 0$
- 2 $Var(\varepsilon_t) = \sigma_\varepsilon^2$
- 3 $\gamma_k = Cov(\varepsilon_t, \varepsilon_{t-k}) = 0$ for $k \neq 0$



กระบวนการเส้นตรง (Linear process)

Wold's decomposition theorem ระบุว่าอนุกรมเวลานิ่ง y_t สามารถเขียนในรูปกระบวนการเส้นตรงหรือตัวแทนรูปแบบค่าเฉลี่ยเคลื่อนที่ที่มีอันดับเป็นอนันต์ (infinite moving average) และถ้าสามารถเขียน y_t ในรูป

$$y_t = \mu + \sum_{i=0}^{\infty} \psi_i \varepsilon_{t-i} \quad (1)$$

โดยที่ μ คือค่าเฉลี่ย, $\psi_0 = 1$, และ ε_t คือ (iid) โดยที่เราสามารถพิจารณา ε_t ในฐานะเป็นข้อมูลใหม่ที่เข้ามาในช่วงเวลา t หรือเป็น innovation หรือ shock ณ เวลา t และ $\sum_{i=1}^{\infty} \psi_i^2 < \infty$



แบบจำลองออโตรีเกรสซีฟ

แนวคิดพื้นฐานของแบบจำลองออโตรีเกรสซีฟ (autoregressive) คือข้อมูลในเวลาปัจจุบัน (y_t) สามารถอธิบายได้ด้วยตัวแปรนั้นในอดีตย้อนหลังไป 1 ถึง p ช่วงเวลา (y_{t-1}, \dots, y_{t-p})

แบบจำลองออโตรีเกรสซีฟที่มีอันดับ (order) เท่ากับ p (เขียนแทนด้วย $AR(p)$) สามารถเขียนได้เป็น

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t, \quad (2.3)$$

โดยที่ y_t เป็นข้อมูลที่นิ่งและ ε_t เป็นไวทน์ออกส์ที่มีค่าเฉลี่ยเท่ากับศูนย์และค่าความแปรปรวนคงที่เท่ากับ σ_ε^2



แบบจำลองออโตรีเกรสซีฟ: ค่าเฉลี่ย

ค่าเฉลี่ยของ y_t เท่ากับ

$$E(y_t) =$$

หากเราเขียน $AR(p)$ ในรูป

$$(y_t - \mu) = \phi_1(y_{t-1} - \mu) + \phi_2(y_{t-2} - \mu) + \dots + \phi_p(y_{t-p} - \mu) + \varepsilon_t, \quad (2.4)$$

หรือ $y_t = \phi_0 + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t, \quad (2.5)$

$$E(y_t) =$$



การเขียน AR(p) ในรูป backshift operator

นอกจากนี้เราสามารถเขียนสมการ (2.3) ได้ด้วยเครื่องมือ backshift operator เป็นสมการดังนี้

$$(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p) y_t = \varepsilon_t, \quad (2.5)$$

$$\phi(L) y_t = \varepsilon_t$$

โดยที่เราเรียก $\phi(L) = 1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p$ ว่าพหุนามออโตรีเกรสซีฟ (autoregressive polynomial)



AR(1) model

เราจะพิจารณาคูณสมบัติของแบบจำลอง $AR(1)$ ซึ่งมีค่าเฉลี่ยเท่ากับศูนย์ สามารถแสดงได้โดย


$$y_t = \phi y_{t-1} + \varepsilon_t, \quad (2.8)$$

จากสมการข้างต้นหากเราเริ่มพิจารณากรณีที่ $y_0 = 0$ และให้ ε_t มีการแจกแจงแบบ $N(0, 1)$ เราจะได้การเดินทางตามเวลา (time path) ของ y_t สำหรับค่าสัมประสิทธิ์(ϕ)ที่ต่างกันดังที่แสดงในรูปต่อไปนี้



AR(1) model

Figure: การจำลองกระบวนการ $AR(1)$ ที่ค่าสัมประสิทธิ์(ϕ)ที่ต่างกัน



จากสมการ (2.8) เราสามารถแทนค่า y_t ในอดีตไปเรื่อยๆ แบบเวียนเกิด (recursive) k ครั้งดังนี้

ด้วยวิธีดังกล่าวข้างต้นและค่า $|\phi| < 1$ แล้ว $\lim_{k \rightarrow \infty} \phi^k y_{t-k} = 0$ จะทำให้เราสามารถเขียนแบบจำลอง AR(1) ในรูปต่อไปนี้

$$y_t = \varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}, \quad (2.9)$$

เราเรียกอุปดังกล่าวว่าการแสดงแบบจำลอง AR(1) ด้วย infinite moving average representation



ค่าความแปรปรวนของ y_t

เนื่องจาก $E(y_t) = 0$ ค่าความแปรปรวน $Var(y_t) = E[y_t - E(y_t)]^2$ จะเท่ากับ $Var(y_t) = E(y_t^2)$ หากเราแทนค่า y_t จากสมการ (2.9) ลงในสูตรดังกล่าว และใช้คุณสมบัติของ ε_t ที่ว่า $Var(\varepsilon_t) = E(\varepsilon_t^2) = \sigma_t^2$ และ $E(\varepsilon_j, \varepsilon_k) = 0$ สำหรับ $k \neq j$ เราจะได้

$$E(y_t^2) =$$



ค่าความแปรปรวนร่วม

หากนำค่า y_t และ y_{t-l} ที่เขียนในรูปสมการ (2.9) และค่าเฉลี่ยเท่ากับศูนย์ $E(y_t) = 0$ แทนค่าในสูตรค่าความแปรปรวนร่วมได้ฟังก์ชันค่าความแปรปรวนร่วมจะเท่ากับ

$$\gamma_l =$$



ฟังก์ชันสหสัมพันธ์ร่วมในตัวเอง (ACF)

$$\text{ฟังก์ชันสหสัมพันธ์ร่วมในตัวเอง (ACF) เท่ากับ } \rho_l = \frac{\gamma_l}{\gamma_0} = \frac{\frac{\phi^l \sigma_\varepsilon^2}{(1-\phi^2)}}{\frac{\sigma_\varepsilon^2}{(1-\phi^2)}} = \phi^l$$

หากลองแทนค่า ϕ ด้วยค่าเท่ากับ 0.9, -0.9, 0.5, -0.5 จะได้ฟังก์ชันสหสัมพันธ์ร่วมในตัวเองดังตารางต่อไปนี้

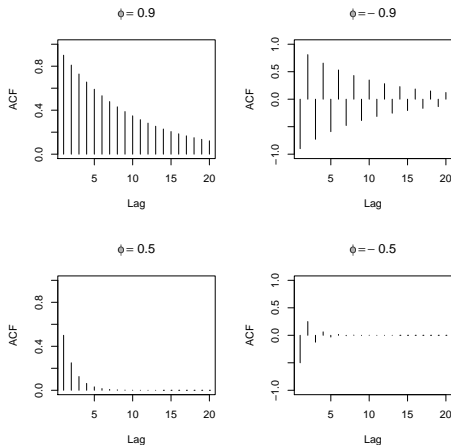
Table: Autocorrelation ของ AR(1) ที่ค่าสัมประสิทธิ์(ϕ)ที่ต่างกัน

$\phi \setminus l$	1	2	3	4	5	6	7	8	9	10
0.9	0.900	0.810	0.729	0.656	0.590	0.531	0.478	0.430	0.387	0.349
-0.9	-0.900	0.810	-0.729	0.656	-0.590	0.531	-0.478	0.430	-0.387	0.349
0.5	0.500	0.250	0.125	0.063	0.031	0.016	0.008	0.004	0.002	0.001
-0.5	-0.500	0.250	-0.125	0.063	-0.031	0.016	-0.008	0.004	-0.002	0.001



ฟังก์ชันสหสัมพันธ์ร่วมในตัวเอง (ACF)

Figure: ค่าสหสัมพันธ์ร่วมในตัวเองของกระบวนการ $AR(1)$ ที่ค่าสัมประสิทธิ์(ϕ)ที่ต่างกัน



เงื่อนไขความเป็นอนุกรมหนึ่ง

เราสามารถเขียนกระบวนการ $AR(1)$ ในรูปของพหุนามออโตรีเกรสซีฟได้
เป็น

$$\begin{aligned}y_t - \phi y_{t-1} &= \varepsilon_t \\(1 - \phi L)y_t &= \varepsilon_t\end{aligned}\quad (2.13)$$

โดยที่เราสามารถเขียน auxiliary equation ได้เป็น

$$(1 - \phi m) = 0$$



Example 1

จงพิจารณาว่ากระบวนการต่อไปนี้^๒เป็นกระบวนการนิ่งหรือไม่

■ $y_t - 0.9y_{t-1} = \varepsilon_t$

■ $y_t - y_{t-1} = \varepsilon_t$

■ $y_t + 1.2y_{t-1} = \varepsilon_t$



แบบจำลอง AR(1) ที่มีค่าเฉลี่ย

เราสามารถเขียน AR(1) ในรูปทั่วไปเช่น $y_t - \mu = \phi(y_{t-1} - \mu) + \varepsilon_t$ ถ้าเราต้องการหา $E(y_t)$

กรณีสมการ $y_t = \phi_0 + \phi_1 y_{t-1} + \varepsilon_t$ ถ้าเราต้องการหา $E(y_t)$



แบบจำลอง $AR(2)$

แบบจำลอง $AR(2)$ สามารถเขียนอธิบายได้ด้วยสมการ

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

เราสามารถพิจารณาความเป็นกระบวนการนิ่งได้โดยการหารากของพหุนามออโตรีเกรสซีฟซึ่ง $(1 - \phi_1 L - \phi_2 L^2)y_t = \varepsilon_t$ สามารถเขียนได้เป็น

$$\phi(m) = 1 - \phi_1 m - \phi_2 m^2$$

$\phi(m) = 1 - \phi_1 m - \phi_2 m^2 = 0$ โดยที่รากของสมการพหุนามออโตรีเกรสซีฟที่อยู่ในรูปสมการกำลังสอง (quadratic) จะมีด้วยกันสองจำนวน (m_1, m_2) เท่ากับ $\frac{\phi_1 \pm \sqrt{\phi_1^2 + 4\phi_2}}{-2\phi_2}$ โดยที่เงื่อนไขที่คือ รากของสมการพหุนามออโตรีเกรสซีฟจะต้องมากกว่าหนึ่ง (หรือมอดุลัส (modulus) มากกว่าหนึ่งในกรณีจำนวนเชิงซ้อน) ซึ่งจะเกิดขึ้นเมื่อ

$$\phi_1 + \phi_2 < 1, \quad \phi_2 - \phi_1 < 1, \quad |\phi_2| < 1$$



คุณลักษณะของกระบวนการ $AR(2)$

ฟังก์ชันความแปรปรวนร่วมเราสามารถพิจารณาได้โดยคุณสมบัติ (2.16)
ทั้งสองข้างด้วย y_{t-k} แล้ว take expectation เราจะได้

$$E(y_t y_{t-k}) =$$

และหากรู้ด้วย γ_0 จะได้

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2}$$

เราเรียกสมการทั้งสองว่าสมการ Yule-Walker



คุณลักษณะของกระบวนการ $AR(2)$

หากเราพิจารณากรณีที่ $k = 1$, $\rho_1 = \rho_{-1}$ และ $\rho_0 = 1$ เราจะได้

$$\rho_1 = \frac{\phi_1}{1 - \phi_2}$$

และกรณีที่ $k = 2$ เราจะได้

$$\rho_2 = \frac{\phi_2(1 - \phi_2) + \phi_1^2}{1 - \phi_2}$$

และเราสามารถแทนค่าแบบเวียนเกิด(recursive)เพื่อให้ได้ ρ_k กรณี $k > 2$
ให้ไปอ่านเนื้อหาสำหรับแบบจำลอง $AR(p)$



แบบจำลอง $AR(p)$

กรณีที่ $AR(p)$ เป็นอนุกรมนิ่ง ค่าคงที่ในรูปแบบถดถอยในตัวเอง(c)จะเท่ากับ $\mu(1 - \phi_1 - \dots - \phi_p)$ ในทางกลับกัน $\mu = c/(1 - \phi_1 - \dots - \phi_p)$ หากเราสมมติให้ค่าเฉลี่ย(μ)เท่าศูนย์และกระบวนการนิ่ง เราจะได้

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2} + \dots + \phi_p \rho_{k-p},$$

สำหรับทุกค่า $k \geq 1$ หากเราพิจารณากรณีที่ $k = 1, 2, \dots, p$ และใช้ความสัมพันธ์ที่ $\rho_0 = 1$ และ $\rho_j = \rho_{-j}$ เราจะได้สมการ Yule-Walker

$$\rho_1 = \phi_1 + \phi_2 \rho_1 + \phi_3 \rho_2 + \dots + \phi_p \rho_{p-1}$$

$$\rho_2 = \phi_1 \rho_1 + \phi_2 + \phi_3 + \dots + \phi_p \rho_{p-2}$$

$$\vdots$$

$$\rho_p = \phi_1 \rho_{p-1} + \phi_2 \rho_{p-2} + \phi_3 \rho_{p-3} + \dots + \phi_p \quad (2)$$



แบบจำลอง $AR(p)$

ซึ่งหากเราทราบว่า $\phi_1, \phi_2, \dots, \phi_p$ เราสามารถหาค่า $\rho_1, \rho_2, \dots, \rho_p$ ได้
นอกจากนี้

$$E(\varepsilon_t y_t) = E[\varepsilon_t(\phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t)] = E(\varepsilon_t^2) = \sigma^2$$

และหากเราคูณสมการ (2.20) ด้วย y_t และใส่ค่าคาดหมาย เราจะได้

$$\gamma_0 = \phi_1 \gamma_1 + \phi_2 \gamma_2 + \dots + \phi_p \gamma_p + \sigma^2 \quad (3)$$

และหากใช้ความสัมพันธ์ว่า $\rho_k = \gamma_k / \gamma_0$ จะได้

$$\gamma_0 = \frac{\sigma^2}{1 - \phi_1 \rho_1 - \phi_2 \rho_2 - \dots - \phi_p \rho_p}$$



Partial Autocorrelation Function

PACF ป็นเครื่องมือที่เป็นประโยชน์ในการระบุแบบจำลอง $AR(p)$

$$z_t = \phi_{11}z_{t-1} + \varepsilon_{1t}$$

$$z_t = \phi_{21}z_{t-1} + \phi_{22}z_{t-2} + \varepsilon_{2t}$$

$$\vdots$$

$$z_t = \phi_{p1}z_{t-1} + \phi_{p2}z_{t-2} + \dots + \phi_{pp}z_{t-p} + \varepsilon_{pt}$$

โดยที่ $z_t = y_t - \mu$ คือข้อมูลที่ได้กำจัดค่าเฉลี่ยแล้ว (demeaned) เราเรียกค่าสัมประสิทธิ์ ϕ_{jj} สำหรับ $j = 1, 2, \dots, p$ (ค่าสัมประสิทธิ์สุดท้ายของแต่ละสมการ) ว่าค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วน



PACF

ในกรณีที่เราพิจารณาแบบจำลอง $AR(1)$ ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วนตัวแรก ϕ_{11} จะไม่เท่ากับศูนย์ ส่วนสัมประสิทธิ์ที่เหลือจะเท่ากับศูนย์


หากเราพิจารณาแบบจำลอง $AR(2)$ ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วนตัวแรกและตัวที่สอง (ϕ_{11} และ ϕ_{22}) จะไม่เท่ากับศูนย์ ส่วนสัมประสิทธิ์ที่เหลือ (ϕ_{jj} สำหรับ $j > 2$) จะเท่ากับศูนย์

โดยสรุปแล้ว สำหรับแบบจำลอง $AR(p)$ ใดๆ ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วน p ตัวแรกจะไม่เท่ากับศูนย์ และสัมประสิทธิ์ที่เหลือจะเท่ากับศูนย์



สามารถคำนวณได้โดยใช้ฟังก์ชัน `pacf` ใน R

Figure: ฟังก์ชันสหสัมพันธ์ในตัวเองบางส่วนของข้อมูลจำลอง $AR(1)$




ตัวอย่าง 2.3

```

1 > int<-read.csv(file="mlr.csv", header=T)
2 > head(int)
3 > plot(int$diff_th_us,type="l", ylab="%", xlab="time")

```

Figure: ความแตกต่างระหว่างอัตราดอกเบี้ยของไทยและสหรัฐอเมริกา




ตัวอย่างที่ 2.3: PACF

```

1 > par(mfrow=c(1,2))
2 > library(TSA)
3 > Acf(int$diff_th_us)
4 > pacf(int$diff_th_us)

```

Figure: ACF และ PACF ของความแตกต่างระหว่างอัตราดอกเบี้ยของไทยและสหรัฐอเมริกา



MLE estimation

หากเราสนใจที่จะประมาณค่าแบบจำลอง $AR(1)$ ซึ่งอยู่ในรูปดังต่อไปนี้

$$y_t = \mu + \phi(y_{t-1} - \mu) + \varepsilon_t$$

โดยที่ $\varepsilon_t \sim iidN(0, \sigma^2)$ เนื่องจากข้อมูลอนุกรมเวลาเป็นข้อมูลที่ขึ้นอยู่ต่อกัน (dependent) ดังนั้น หากเราเก็บข้อมูล y_1, \dots, y_T แล้วฟังก์ชันค่าความควรจะเป็นสามารถเขียนได้ดังนี้

$$L(\mu, \phi, \sigma^2) = f(y_1)f(y_2|y_1)f(y_3|y_2) \cdots f(y_T|y_{T-1}) \quad (4)$$

เนื่องจาก $y_t|y_{t-1} \sim N(\mu + \phi(y_{t-1} - \mu), \sigma^2)$ และฟังก์ชันการแจกแจงจะเป็นแบบปกติที่เหมือนกับช็อก

$$f(y_t|y_{t-1}) = f_\varepsilon[(y_t - \mu) - \phi(y_{t-1} - \mu)]$$



MLE estimation

$$L(\mu, \phi, \sigma^2) = \exp \left(\frac{\sum_{t=2}^T [(y_t - \mu) - \phi(y_{t-1} - \mu)]}{2\sigma^2} \right) \quad (2.30)$$

การหาประมาณค่าโดยหาค่าพารามิเตอร์ที่ทำให้ log ของสมการ (2.30) สูงที่สุด เรียกว่า การประมาณค่าความควรจะเป็นสูงสุดแบบแม่นยำ (exact maximum likelihood estimation)

กรณีนี้เราไม่สามารถหาค่าสูงสุดได้ด้วยการวิเคราะห์หาเงื่อนไขจำเป็น เราต้องใช้กระบวนการด้วยเครื่องคอมพิวเตอร์ในการหาค่าสูงสุด



Model Checking

หลังจากที่เราได้ตัวประมาณค่าสำหรับพารามิเตอร์แล้ว ขั้นตอนต่อไปเราก็จะหาค่า fitted ของตัวแปรที่เราศึกษา (\hat{y}_t)

แล้วก็จะตรวจสอบแบบจำลองโดยการวิเคราะห์ค่าส่วนเกิน (residuals) โดยในที่นี้ค่าส่วนเกินสามารถคำนวณได้จาก $\hat{\varepsilon}_t = y_t - \hat{y}_t$ โดยเราจะประเมินค่าส่วนเกินดังต่อไปนี้

เราอาจจะเริ่มจากการวาดแผนภาพ ACF ของ $\hat{\varepsilon}_t$ เพื่อดูว่าอนุกรมดังกล่าวยังมีความขึ้นอยู่กับกันหรือไม่

นอกจากนี้เราสามารถทดสอบโดยใช้ค่าสถิติ $Q(m) = T(T+2) \sum_{k=1}^m \frac{\hat{\rho}_{\varepsilon_k}^2}{T-k}$ โดยที่ $Q(m) \sim \chi_{m-g}^2$ โดยที่ g คือจำนวนของอันดับในแบบจำลองซึ่งในแบบจำลอง $AR(p)$ ถ้า $g = p$ และ m คือจำนวนค่าล่าของความสัมพันธ์ที่พิจารณา



ตัวอย่าง 2.3 ต่อ

```
1 > m1<-arima(int$diff_th_us, order=c(3,0,0))
2 > m1
3 Call:
4 arima(x = int$diff_th_us, order = c(3, 0, 0))
5 Coefficients:
6      ar1      ar2      ar3  intercept
7      1.3294  -0.4986  0.1334    3.0553
8 s.e.  0.0549   0.0878  0.0549   0.8102
9 sigma^2 estimated as 0.3054:  log likelihood = -269.11,  aic = 548.21
```

โดยที่ค่าสัมประสิทธิ์

$\phi_1 = 1.3294, \phi_2 = -0.4986, \phi_3 = 0.1334, \mu(= \text{intercept}) = 3.0553$ และมีค่า standard errors อยู่ในบรรทัด s.e.



ตัวอย่าง 2.3 ต่อ

ในโปรแกรม R ค่า intercept ที่ได้คือ μ มีใช้จุดตัดแกนในสมการที่ ?? ดังนั้นถ้าต้องการหาเราต้องการค่า $c = \mu(1 - \phi_1 - \phi_2 - \phi_3) = 0.10937$ เราสามารถเขียนผลการประมาณค่าได้โดย

$$\left(1 - \underset{(0.0549)}{1.3294L} + \underset{(0.0878)}{0.4986L^2} - \underset{(0.0549)}{0.1334L^3}\right)(y_t - \underset{(0.8102)}{3.0553}) = \varepsilon_t$$

โดยที่ค่าในวงเล็บคือ standard errors และ $\hat{\sigma}^2 = 0.3054$



ตัวอย่าง 2.3 ต่อ

```
1 > m2<-arima(int$diff_th_us, order=c(3,0,0),method=c("ML"))
2 > m2
3 Coefficients:
4           ar1           ar2           ar3      intercept
5           1.3295        -0.4987         0.1334          3.056
6 s.e.         0.0549         0.0878         0.0549          0.810
7
8 sigma^2 estimated as 0.3054:  log likelihood = -269.11,  aic = 548.21
9 > m3<-arima(int$diff_th_us, order=c(3,0,0),method=c("CSS"))
10
11 Coefficients:
12           ar1           ar2           ar3      intercept
13           1.3334        -0.5016         0.1346          3.0793
14 s.e.         0.0551         0.0880         0.0552          0.9195
15 sigma^2 estimated as 0.3082:  part log likelihood = -269.05
```



ตัวอย่าง 2.3 ต่อ

หลังจากที่เราได้ตัวประมาณค่าของพารามิเตอร์ทั้งหมดแล้วเราจะพิจารณาว่าค่า residuals นั้นยังมีความสัมพันธ์ระหว่างช่วงเวลาหลงเหลืออยู่หรือไม่ หรือแบบจำลองเพียงพอหรือไม่ โดยการทดสอบ L-B test สำหรับ `m2$residuals` ด้วยคำสั่งข้างล่าง

```
1 > Box.test(m2$residuals, lag=12, type="Ljung")
2 ^^IBox-Ljung test
3 data: m2$residuals
4 X-squared = 14.0085, df = 12, p-value = 0.3002
5 > pv=1-pchisq(14.0085,9)
6 > pv
7 [1] 0.1220232
```



การพยากรณ์ด้วยแบบจำลอง $AR(p)$

สมมติให้เรากำลังอยู่ ณ ช่วงเวลาที่ h แต่ต้องการที่จะพยากรณ์ไปข้างหน้า l คาบเวลา หรือสนใจค่าของ y_{h+l} โดยที่ $l \geq 1$ เราเรียก h ว่าจุดเริ่มต้นการพยากรณ์ (forecast origin) และ l ว่าขอบเขตการพยากรณ์ (forecast horizon)

กำหนดให้ $\hat{y}_h(l)$ เป็นค่าพยากรณ์ของ y_{h+l} โดยการพยากรณ์ดังกล่าวจะทำให้ฟังก์ชันสูญเสียที่เกิดจากการค่าผิดพลาดกำลังสอง (squared errors) น้อยที่สุด

$$E[(y_{h+l} - \hat{y}_h(l))^2 | F_h] \leq \min_g E[(y_{h+l} - g)^2 | F_h]$$

โดยที่ F_h เป็นข้อมูลที่มีทั้งหมดในคาบที่ h และเราเรียก $\hat{y}_h(l)$ ว่าค่าพยากรณ์ของ y_t ไปข้างหน้า l คาบเมื่อเริ่มต้นการพยากรณ์อยู่ที่ h



ค่าพยากรณ์ไปข้างหน้า 1 คาบจาก $AR(p)$

เราพบว่าค่า $y_{h+1} = \phi_0 + \phi_1 y_{h+1-1} + \dots + \phi_p y_{h+1-p} + \varepsilon_{h+1}$ ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณแบบมีเงื่อนไข (conditional expectation)

$$\hat{y}_h(1) =$$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ $e_h(1) =$

และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าหนึ่งคาบเท่ากับ $Var(e_h(1)) =$

เราสามารถสร้างช่วงความเชื่อมั่น 95 % ของการพยากรณ์ไปข้างหน้า 1 คาบได้โดยช่วงดังกล่าวจะเท่ากับ $\hat{y}_h(1) \pm 1.96sd(e_h(1))$



ค่าพยากรณ์ไปข้างหน้า 2 คาบจาก $AR(p)$

เราพบว่าค่า $y_{h+2} = \phi_0 + \phi_1 y_{h+2-1} + \dots + \phi_p y_{h+2-p} + \varepsilon_{h+2}$ ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข (conditional expectation)

$$\hat{y}_h(2) =$$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ

$$e_h(2) =$$

และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าหนึ่งคาบเท่ากับ

$$Var(e_h(2)) =$$

เราจะสังเกตได้ว่า $Var(e_h(2)) \geq Var(e_h(1))$



ตัวอย่าง 2.3 ผลการพยากรณ์

```
1 > m4.pred=predict(m4,n.ahead=12)
2 > m4.pred
3 $pred
4 Time Series:
5 Start = 313
6 End = 324
7 Frequency = 1
8 [1] 1.803828 1.875260 1.943271 2.005150 2.062937 2.117888 2.170297 2.220198
9 [9] 2.267658 2.312788 2.355708 2.396527
10 $se
11 Time Series:
12 Start = 313
13 End = 324
14 Frequency = 1
15 [1] 0.5622779 0.9342948 1.1737163 1.3399272 1.4696143 1.5777365 1.6700163
16 [8] 1.7494732 1.8183586 1.8784737 1.9312318 1.9777417
```



แบบจำลองมูวี่งเอเวอเรจ (Moving Average; $MA(q)$)

แบบจำลองนี้มีพื้นฐานมากจากแนวคิดที่ว่าอนุกรมเวลาเส้นตรงนิ่ง (stationary) สามารถเขียนให้อยู่ในรูป infinite MA

แบบจำลองมูวี่งเอเวอเรจอันดับ q และเขียนแทนด้วย $MA(q)$ และแสดงได้ด้วยสมการ

$$\begin{aligned} y_t &= \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} \\ &= \sum_{j=0}^q \theta_j \varepsilon_{t-j} = \theta(L) \varepsilon_t \quad (2.37) \end{aligned}$$

โดยที่ $\theta_0 = 1$



แบบจำลอง $MA(1)$

สมมติให้ y_t เป็นอนุกรม $MA(1)$ โดยที่ ε_t มีคุณสมบัติเป็นไวท์นอยซ์

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} \quad (2.38)$$

ค่าคาดหวังของ y_t , $E(y_t)$, เท่ากับ

$$E(y_t) =$$

ค่าความแปรปรวนของ y_t (γ_0)

$$\gamma_0 = \text{Var}(y_t) =$$



แบบจำลอง $MA(1)$

one-lag autocovariance

$$\gamma_1 = Cov(y_t, y_{t-1}) =$$

two-lag autocovariance

$$\gamma_2 = Cov(y_t, y_{t-2}) =$$



แบบจำลอง $MA(1)$

จากสมการข้างต้นจะเห็นได้ว่า $Cov(y_t, y_{t-k}) = 0$ สำหรับ $k \geq 2$ ในกรณีที่ y_t เป็น $MA(1)$

k-lag autocorrelation เท่ากับ

$$\rho_k = \begin{cases} \frac{\theta_1}{1+\theta_1^2} & , k = 1 \\ 0 & , k > 1 \end{cases}$$


จะเห็นได้ว่า y_t มีสหสัมพันธ์กับ y_{t-1} แต่ไม่สัมพันธ์กับ y_{t-2}, \dots ซึ่งแตกต่างจาก $AR(1)$

เราจะเห็นได้ว่าอนุกรมเวลา y_t ที่เป็นกระบวนการเคลื่อนที่เฉลี่ยจะเป็นอนุกรมเวลานิ่ง (stationary) เสมอ



ตัวอย่างข้อมูลที่เป็น $MA(1)$

Figure: การจำลองข้อมูลกระบวนการ $MA(1)$ ที่มีค่าสัมประสิทธิ์ $\theta = 0.5$



Invertible process

ฟังก์ชันสหสัมพันธ์ร่วมในตัวเองของกระบวนการ $MA(1)$ สองกระบวนการต่อไปนี้จะมีลักษณะที่เหมือนกัน

$$x_t = w_t + \frac{1}{5}w_t, \quad w_t \sim iidN(0, 25)$$

และ

$$y_t = v_t + 5v_t, \quad v_t \sim iidN(0, 1)$$

เราต้องเลือกจะใช้แบบจำลองไหน ซึ่งเราจะเลือกแบบจำลองที่สามารถเขียนแบบจำลองในรูปของ infinite AR representation โดยที่อนุกรมที่มีลักษณะดังกล่าวเราจะเรียกว่ากระบวนการที่หาตัวผกผันได้ (invertible process)

เงื่อนไขที่ $MA(1)$ จะเป็นกระบวนการที่หาตัวผกผันได้ คือ $|\theta_1| < 1$



แบบจำลอง $MA(2)$

กำหนดให้ y_t เป็นกระบวนการ $MA(2)$ ซึ่งสามารถแสดงได้ด้วยสมการ

$$y_t - \mu = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}$$

เมื่อพิจารณาค่าสหสัมพันธ์ในตัวเองของ $MA(2)$ จะได้

$$\rho_0 = \frac{\gamma_0}{\gamma_0} = 1$$

$$\rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{(\theta_1 + \theta_2 \theta_1)}{(1 + \theta_1^2 + \theta_2^2)}$$

$$\rho_2 = \frac{\gamma_2}{\gamma_0} = \frac{\theta_2}{(1 + \theta_1^2 + \theta_2^2)}$$

$$\rho_3 = \frac{\gamma_3}{\gamma_0} = 0$$

$$\rho_j = \frac{\gamma_j}{\gamma_0} = 0$$



แบบจำลอง $MA(q)$

แบบจำลอง $MA(q)$ สามารถเขียนในรูปสมการดังนี้

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}, \quad \varepsilon_t \sim WN(0, \sigma^2)$$

แบบจำลอง $MA(q)$ นี้และ ergodic ถ้าค่า $\theta_1, \dots, \theta_q$ มีค่าจำกัด และสามารถหาตัวผกผันได้ถ้าค่าราก (roots) ของพหุนาม MA

$\theta(m) = 1 + \theta_1 m + \dots + \theta_q m^{t-q} = 0$ มีค่าสัมบูรณ์(หรือค่าโมดูลัส)ของรากของพหุนามมากกว่า 1



แบบจำลอง $MA(q)$

โมเมนต์ของกระบวนการ $MA(q)$ ได้ดังนี้

$$E(y_t) = \gamma_0 = \gamma_j =$$

และค่าสหสัมพันธ์ในตัวเองจะเท่ากับ

$$\rho_j = \frac{\gamma_j}{\gamma_0} =$$

ในขณะที่ PACF จะมีค่าลดลงไป



การประมาณค่าแบบจำลอง $MA(q)$

การประมาณค่า MLE เป็นวิธีการทั่วไปที่ใช้ในการประมาณค่าแบบจำลอง $MA(q)$

ประมาณค่าแบบจำลอง $MA(1)$ ซึ่งสามารถเขียนได้ดังนี้

$$y_t = \mu + \varepsilon_t + \theta\varepsilon_{t-1}$$

โดยที่ $\varepsilon_t \sim iidN(0, \sigma_\varepsilon^2)$ ในกรณีที่ conditional MLE เราจะสมมติให้ $\varepsilon_0 = 0$ ดังนั้น $y_1 = \mu + \varepsilon_1$

$$y_1 | \varepsilon_0 = 0 \sim N(\mu, \sigma_\varepsilon^2)$$

จากข้อมูลในคาบที่ 1 จะได้ว่า $y_2 | y_1 = \mu + \varepsilon_2 + \theta\varepsilon_1$ และได้ฟังก์ชันความน่าจะเป็น

$$f_{y_2|y_1} = \frac{1}{\sqrt{2\pi\sigma_\varepsilon^2}} \exp \left[\frac{-(y_2 - \mu - \theta\varepsilon_1)^2}{2\sigma_\varepsilon^2} \right]$$



การประมาณค่าแบบจำลอง MA(q)

หากใช้กระบวนการเดียวกันไปเรื่อย เราจะสามารถหาค่า $\varepsilon_t = y_t - \mu - \theta\varepsilon_{t-1}$ และสร้าง conditional likelihood function ได้

$$L(\mu, \theta, \sigma_\varepsilon^2) = \prod_{t=2}^T f_{y_t|y_{t-1}} \\ = (2\pi\sigma_\varepsilon^2)^{-(T-2)/2} \exp \left[\frac{\sum_{t=2}^T - \overbrace{(y_t - \mu - \theta\varepsilon_{t-1})^2}^{\varepsilon_t^2}}{2\sigma_\varepsilon^2} \right] \quad (2.50)$$


สมการ (2.50) เราไม่สามารถหาตัวประมาณค่าได้ด้วยการวิเคราะห์อนุพันธ์เช่นในกรณี AR ในกรณีนี้เราจำเป็นต้องใช้วิธีการทางตัวเลขด้วยคอมพิวเตอร์เพื่อหาค่า $\hat{\theta}$ ที่ทำให้ $L(\mu, \theta, \sigma_\varepsilon^2)$ มีค่าสูงที่สุด



ตัวอย่างที่ 2.6

ในตัวอย่างนี้เราจะพิจารณาผลได้ตอบแทนรายเดือนของการลงทุนในตลาดหลักทรัพย์แห่งประเทศไทย โดยใช้ข้อมูลราคาปิดรายเดือนตั้งแต่ เมษายน 2518 ถึงเดือนพฤศจิกายน 2555

Figure: ACF และ PACF ของผลได้ตอบแทนรายเดือนจาก SET



ตัวอย่างที่ 2.6

แบบจำลองที่เหมาะสมน่าจะเป็น $MA(2)$ ซึ่งประมาณค่าได้ด้วยคำสั่ง `arima` โดยกำหนดอันดับเป็น `c(0,0,2)`

```
1 > m1<-arima(ret, order=c(0,0,2))
2 > m1
3 Call:
4 arima(x = ret, order = c(0, 0, 2))
5
6 Coefficients:
7      ma1      ma2  intercept
8  0.0886  0.1001    0.0057
9  s.e.  0.0469  0.0487    0.0046
10
11 sigma^2 estimated as 0.006795:  log likelihood = 485.64,  aic = -963.28
```



ตัวอย่างที่ 2.6

เราสามารถพิจารณาความพอเพียงของแบบจำลอง $m1$ ได้ด้วยการทดสอบ L-B สำหรับ residuals ดังคำสั่งต่อไปนี้

```
1 > Box.test(m1$residuals, lag=12, type="Ljung")
2 ^^IBox-Ljung test
3 data: m1$residuals
4 X-squared = 13.6075, df = 12, p-value = 0.3265
5 > pv=1-pchisq(13.6075,12-2)
6 > pv
7 [1] 0.1916591
```



การพยากรณ์ไปข้างหน้า 1 คาบ

พิจารณาแบบจำลอง $MA(1)$: $y_{h+1} = \mu + \varepsilon_{h+1} + \theta_1 \varepsilon_h$ ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข (conditional expectation)

$$\hat{y}_h(1)$$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ $e_h(1) =$

และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าหนึ่งคาบเท่ากับ $Var(e_h(1)) =$

ในทางปฏิบัติค่า ε_h จะสามารถคำนวณได้สองวิธีคือ

- สมมติให้ $\varepsilon_0 = 0$
- หรือใช้ค่า $\hat{\varepsilon}_h$ ที่เป็นค่า residual จากการประมาณค่า $MA(1)$



การพยากรณ์ไปข้างหน้า 2 คาบ

พิจารณา $y_{h+2} = \mu + \varepsilon_{h+2} + \theta_1 \varepsilon_{h+1}$ ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสีย
น้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข

$$\hat{y}_h(2) =$$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ $e_h(2) =$

และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าสองคาบเท่ากับ
 $Var(e_h(2)) =$



Autoregressive Moving Average; $ARMA(p, q)$

แบบจำลองที่มีทั้งส่วนประกอบของ AR และ MA ซึ่งหาก y_t เป็นกระบวนการที่เรียกว่าแบบจำลองออโตรีเกรสซีฟมูวี่งเอเวอเรจอันดับ (p, q) หรือเรียกย่อๆว่า อารมา $ARMA(p, q)$ ถ้า y_t มีค่าเฉลี่ยไม่เท่ากับศูนย์ เราจะสามารถอธิบาย y_t ได้ด้วย

$$y_t = \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} \quad (2.53)$$

หากเรากำหนดให้ $\alpha = \mu(1 - \phi_1 - \dots - \phi_p)$ และสามารถเขียนแบบจำลองสำหรับ y_t ได้เป็น

$$y_t = \alpha + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} \quad (2.54)$$



Autoregressive Moving Average; $ARMA(p, q)$

เราสามารถเขียนสมการอาร์มาได้ในรูป AR และ MA polynomials ได้ดังนี้

$$\phi(L)y_t = \theta(L)\varepsilon_t$$

โดยที่ $\phi(L) = 1 - \phi_1L - \dots - \phi_pL^p$ และ $\theta(L) = 1 + \theta_1L + \dots + \theta_qL^q$

พิจารณาคูณสมบัติของแบบจำลองอาร์มาได้ด้วยการพิจารณา $ARMA(1, 1)$

$$y_t = \phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1} \quad (2.55)$$

โดยที่ $\varepsilon_t \sim iidN(0, \sigma^2)$



คุณสมบัติ $ARMA(1,1)$

เราใช้ความสัมพันธ์ต่อไปนี้

$$E(\varepsilon_t y_t) =$$

$$E(\varepsilon_{t-1} y_t) =$$

$$E(y_t) =$$



คุณสมบัติ $ARMA(1,1)$

คุณสมบัติของ $ARMA(1,1)$ จะได้

$$\gamma_0 =$$

$$\gamma_1 =$$

$$\gamma_j =$$



คุณสมบัติ $ARMA(1,1)$

กรณีที่ $j \geq 2$ จากสมการที่ (2.56) และ (2.57) เราจะได้
 $Var(y_t) = \gamma_0 =$

ACF ณ ค่า j ใดๆที่ $j \geq 2$ ได้

$$\rho_j = \phi \rho_{j-1}$$

กรณีที่ $j \geq 2$ จะเห็นได้ว่า ACF มีค่าที่ลดลงเรื่อยๆด้วยอัตราแบบ exponential)



คุณสมบัติ $ARMA(1,1)$

แบบจำลอง $ARMA(1, 1)$ ในรูปของมูววิ่งเอเวอเรจที่มีอันดับเป็นอนันต์ (infinite MA) ได้เป็น

$$y_t = \varepsilon_t + (\phi - \theta) \sum_{j=1}^{\infty} \phi^{j-1} \varepsilon_{t-j}$$

หรือ $\psi_j = (\phi - \theta)\phi^{j-1}$ จะเห็นได้ว่าเงื่อนไขที่จะทำให้กระบวนการนี้เป็นกระบวนการนิ่งคือ $|\phi| < 1$



สรุปคุณสมบัติของ $ARMA(p, q)$

- กระบวนการ $ARMA(p, q)$ จะ stationary และ ergodic ถ้าค่าสัมบูรณ์ของค่ารากของพหุนามออโตรีเกรสซีฟ $\phi(m) = 0$ มีค่ามากกว่าหนึ่ง
- และสามารถหาค่าผกผันได้ถ้ารากของพหุนามมูวี่งเอเวอเรจ $\theta(m) = 0$ มีค่ามากกว่าหนึ่ง
- พหุนาม AR และ MA ไม่มีตัวประกอบร่วม

รูปทั่วไปของ ACF ของกระบวนการ $ARMA(p, q)$ ค่อนข้างยุ่งยาก โดยสรุปแล้ว ทั้ง ACF และ PACF จะค่อยๆ ลดลงเรื่อยๆ แบบเลขชี้กำลัง (exponential)



การประมาณค่าสมการแบบจำลอง ARMA

เราสามารถประมาณค่าแบบจำลอง $ARMA(p, q)$ ได้ด้วยวิธีการค่าความควรจะเป็นสูงสุด (MLE)

- ฟังก์ชันที่แน่นอน (exact log-likelihood) นั้นมีรูปแบบที่ค่อนข้างซับซ้อน นอกจากนี้จุดเริ่มต้นของข้อมูลในกรณี exact likelihood จะใช้คุณสมบัติของการแจกแจงที่นิ่งเพื่อสร้างฟังก์ชันค่าควรจะเป็นของค่า y_t p ค่าแรก และ ε_t q ค่าแรก
 - conditional likelihood จะสมมติให้ y_t p ค่าแรก และ ε_t q ค่าแรกเท่ากับศูนย์
- กรณีที่จำนวนตัวอย่างมีจำนวนเข้าใกล้อนันต์ค่าประมาณจากสองวิธีจะมีค่าใกล้เคียงกัน แต่จะแตกต่างกันในกรณีตัวอย่างมีจำนวนน้อย



การประมาณค่าสมการแบบจำลอง ARMA

ทดสอบความเพียงพอของแบบจำลองได้เช่นเดียวกับในกรณีของแบบจำลอง AR และ MA โดยที่ตัวสถิติ $Q(m) \sim \chi^2_{m-p-q}$ และเราจะปฏิเสธสมมุติฐานหลักถ้า $Q(m)$ มีค่ามากกว่าควอนไทล์ที่ $(1 - \alpha)$ ของ χ^2_{m-p-q}

ก่อนที่จะประมาณค่าแบบจำลอง $ARMA(p, q)$ สำหรับอนุกรมเวลา y_t ใดๆ เราจะเป็นต้องระบุลำดับของ $AR(p)$ และ $MA(q)$ เสียก่อน



เกณฑ์การเลือกแบบจำลอง (Model Selection Criteria)

เราสามารถใช้การสังเกต ACF ของตัวอย่าง ในกรณีของ MA หรือ PACF ของตัวอย่าง ในกรณีของ AR

Table: สรุปลักษณะของ ACF และ PACF สำหรับแบบจำลอง ARMA

	$AR(p)$	$MA(q)$	$ARMA(p, q)$
ACF	ค่อยๆ ลดลง	ค่าเท่ากับศูนย์ หลังจากช่วงค่าที่ q	ค่อยๆ ลดลง
PACF	เท่ากับศูนย์ หลังจากช่วงค่าที่ p	ค่อยๆ ลดลง	ค่อยๆ ลดลง



เกณฑ์การเลือกแบบจำลอง (Model Selection Criteria)

อีกทางเลือกหนึ่งเราสามารถจะใช้เกณฑ์การเลือกแบบจำลอง
แนวคิดคือการประมาณค่าแบบจำลอง $ARMA(p, q)$ สำหรับค่าอันดับ p และ
 q ต่างๆที่น้อยกว่าค่าหนึ่งที่เรากำหนดไว้ p_{max} และ q_{max} และเลือกค่า p และ q ที่
ทำให้ค่าเกณฑ์การเลือกต่ำที่สุด โดยที่เกณฑ์การเลือกจะอยู่ในรูป

$$MSC(p, q) = \ln(\tilde{\sigma}^2(p, q)) + c_T \varphi(p, q)$$



เกณฑ์การเลือกแบบจำลอง (Model Selection Criteria)

โดยที่แบบเกณฑ์ที่เป็นที่นิยมสามเกณฑ์ได้แก่ Akaike (AIC)
Schwarz-Bayesian (BIC) และ Hannan-Quinn (HQIC)

$$AIC(p, q) = \ln(\tilde{\sigma}^2(p, q)) + \frac{2}{T}(p + q)$$

$$BIC(p, q) = \ln(\tilde{\sigma}^2(p, q)) + \frac{\ln T}{T}(p + q)$$

$$HQIC(p, q) = \ln(\tilde{\sigma}^2(p, q)) + \frac{2 \ln(\ln T)}{T}(p + q)$$

กรณี T ใหญ่ เกณฑ์ AIC จะเลือกอันดับที่มากกว่าที่ควรจะเป็น ในขณะที่เกณฑ์
BIC และ HQIC เลือกค่าที่ consistent


อย่างไรก็ตามใน T ขนาดเล็กเกณฑ์ทั้งสามจะให้ค่าที่ไม่แตกต่าง



ตัวอย่างที่ 2.7

log return on forex B/\$ ปี 1998 ถึง 2012

Figure: ACF และ PACF ของผลได้ตอบแทนรายวันจากการซื้อขายเงินดอลลาร์สหรัฐ



ตัวอย่างที่ 2.7

อย่างไรก็ตาม package "forecast" มีคำสั่ง `auto.arima(series, arguments)` เลือก optimal p & q

```

1 > library(forecast)
2 > auto.arima(ret,d=0,D=0,max.p=6,max.q=6,ic=c("aic"),stepwise=FALSE,trace=TRUE)
3
4 ARIMA(0,0,0) with zero mean      : -27687.05
5 ARIMA(0,0,0) with non-zero mean : -27686.59
6 [omitted]
7 ARIMA(5,0,0) with zero mean      : -27850.55
8 ARIMA(5,0,0) with non-zero mean : -27851.11
9
10 Series: ret
11 ARIMA(4,0,1) with non-zero mean
12
13 Coefficients:
14      ar1      ar2      ar3      ar4
15  -0.5876  -0.0238  -0.0066  -0.0227
16 s.e.    0.2641   0.0196   0.0208   0.0199
17      ma1 intercept
18    0.5981      -1e-04
19 s.e.  0.2636      1e-04
20
21 sigma^2 estimated as 3.432e-05:  log likelihood=13849.44
22 AIC=-27684.88   AICc=-27684.85   BIC=-27641.33

```



การเขียนกระบวนการอาร์มา(ARMA)ในสามรูปแบบ

จากแบบจำลองที่เราอธิบาย y_t ด้วยแบบจำลอง $ARMA$ ในรูปแบบพหุนาม

$$\phi(L)y_t = \theta(L)\varepsilon_t$$

โดยที่ $\phi(L) = 1 - \sum_{i=1}^p \phi_i L^i$ และ $\theta(L) = 1 + \sum_{i=1}^q \theta_i L^i$ เราสามารถแสดง y_t โดยใช้

$$\frac{\theta(L)}{\phi(L)} = 1 + \psi_1 L + \psi_2 L + \dots = \psi(L) \quad (2.63)$$

และ

$$\frac{\phi(L)}{\theta(L)} = 1 - \pi_1 L - \pi_2 L - \dots = \pi(L) \quad (2.64)$$



การพยากรณ์ (forecasting)

เราสามารถแสดงแบบจำลอง $ARMA(p, q)$ ได้สามรูปแบบ ซึ่งเราสามารถใช้รูปแบบใดรูปแบบหนึ่งในการสร้างการพยากรณ์
กรณีใช้รูปแบบ $ARMA$

$$\hat{y}_h(1) =$$



การพยากรณ์ (forecasting)

กรณีใช้รูปแบบออโตรีเกรสซีฟอนันต์

$$\hat{y}_h(1)$$



การพยากรณ์ (forecasting)

กรณีรูปแบบมูวี่งเอเวอเรจอนันต์

$$\hat{y}_h(1)$$



Nonstationary series

อนุกรมเวลาทางเศรษฐกิจจำนวนมากมีพฤติกรรมที่มีแนวโน้ม(trend)หรือมีลักษณะไม่นิ่ง (non-stationary) ตัวอย่างเช่น ราคาสินทรัพย์ อัตราแลกเปลี่ยน GDP

รูปแบบแนวโน้มของข้อมูลว่าเกิดจากความไม่นิ่งหรือเป็นแนวโน้ม การสร้างแบบจำลอง *ARMA* เราจำเป็นต้องทำการแปลงข้อมูลในนิ่งเสีย ก่อน ในขณะที่ถ้าข้อมูลมีแนวโน้มเราจำเป็นต้องขจัดแนวโน้มเสียก่อน

โดยที่กระบวนการที่มีลักษณะแนวโน้มอาจจะแบ่งได้เป็น (1) random walk with drift (2) trend stationary



Difference-stationary

กำหนดให้ y_t เป็น random walk with drift

$$y_t = \mu + y_{t-1} + \varepsilon_t \quad (2.68)$$

โดย $\varepsilon_t \sim WN(0, \sigma^2)$ และเราเรียก μ ว่าตัวสร้างแนวโน้ม (drift) หากเราสมมติให้ $y_0 = 0$ จะได้

กระบวนการเคลื่อนแบบสุ่มแบบมีแนวโน้มจะมีค่าคาดหวัง ($E(y_t)$) เท่ากับ
ค่าความแปรปรวน ($Var(y_t)$) เท่ากับ



Trend- stationary

กำหนดให้ z_t เป็น trend-stationary


$$z_t = \beta_0 + \beta_1 t + v_t \quad (2.70)$$

โดยที่ v_t เป็นอนุกรมนิ่งใดๆ เช่น AR(1)
 ค่าคาดหมายของ $(E(z_t))$ จะเท่ากับ
 ค่าความแปรปรวน $(Var(z_t))$ จะเท่ากับ



Difference- and Trend- stationary

Figure: ข้อมูลจำลองของกระบวนการแวนเดินแบบสุ่มแบบมีแนวโน้มและกระบวนการที่นิ่งหลังจากขจัดแนวโน้ม



กระบวนการทั้งสองที่ได้ยกตัวอย่างมา เป็นกระบวนการที่ไม่นิ่ง (non-stationary) แต่มีคุณลักษณะที่แตกต่างกันดังนั้น วิธีการที่ใช้ในทำให้อนุกรมนิ่งจึงแตกต่างกัน

Difference-stationary

วิธีการการทำ first difference $\Delta y_t = y_t - y_{t-1}$

$\Delta^2 y_t = \Delta y_t - \Delta y_{t-1}$ เราจะเรียกว่า second difference

วิธีการดำเนินการผลต่างจะเหมาะสมกับอนุกรมเวลาที่เป็นกระบวนการนิ่งหลังจากดำเนินการผลต่าง โดยที่หากอนุกรมเวลา y_t เป็น stationary หลังจากการทำ first difference เราจะเรียกอนุกรมเวลา y_t Integrated of order 1 หรือ $I(1)$

ในขณะทีอนุกรมเวลานิ่งจะคือ $I(0)$

วิธีการที่สองเหมาะสมกับอนุกรมที่เป็นกระบวนการนิ่งหลังจากกำจัดแนวโน้ม



การทดสอบยูนิตรูทในรูป $AR(1)$

เครื่องมือสำคัญที่ใช้ในการระบุว่าควรจะใช้วิธีการใดในการกำจัดแนวโน้ม
คือการทดสอบยูนิตรูท (unit root test)

สมมติว่าเราพิจารณาแบบจำลอง $AR(1)$ ซึ่งเขียนได้ดังนี้

$$y_t = \phi y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim WN(0, \sigma^2) \quad (2.71)$$

การทดสอบยูนิตรูทมีพื้นฐานจากการทดสอบสมมติฐานหลักว่าหาก $\phi = 1$ แล้ว
 y_t จะเป็น unit root และมีลักษณะเป็น random walk

ดังนั้นสมมติฐานที่เราต้องการทดสอบคือ

$$H_0 : \phi = 1 \quad (y_t \sim I(1))$$

$$H_1 : \phi < 1 \quad (y_t \sim I(0))$$



การทดสอบยูนิตรูทในรูป AR(1)

เราสามารถประมาณค่าสมการ (2.71) ด้วย OLS และใช้ตัวสถิติที่เรียกว่าตัวสถิติ Dickey-Fuller t ซึ่งคำนวณได้โดย

$$t_{\phi=1} = \frac{\hat{\phi} - 1}{se(\hat{\phi})}$$

การทดสอบนี้เป็นการทดสอบทางเดียวทางซ้าย คือเราจะปฏิเสธสมมุติฐานหลักถ้าค่าตัวสถิติน้อยกว่าค่าวิกฤติ และสรุปว่าอนุกรมเวลาเป็นอนุกรมนิ่ง หากเราไม่สามารถปฏิเสธสมมุติฐานหลักได้ แสดงว่าอนุกรมดังกล่าวเป็นยูนิตรูท



การทดสอบยูนิตรุตในรูปแบบ AR(1)

สมการ (2.71) ที่เราใช้ในการทดสอบยูนิตรุตยังสามารถเขียนในรูปแบบ

$$\Delta y_t = \pi y_{1-t} + \varepsilon_t, \quad (2.72)$$

โดยที่ $\pi = (\phi - 1)$ ซึ่งในที่นี้การทดสอบยูนิตรุตจะเป็นการทดสอบ $H_0 : \pi = 0$ และ $H_1 : \pi < 0$

ตัวสถิติที่ใช้ในการทดสอบยูนิตรุตจะมีการแจกแจงที่ไม่เป็นมาตรฐานและไม่เป็นการแจกแจงแบบปกติเมื่อข้อมูลขนาดใหญ่เหมือนในกรณีทดสอบอื่นๆที่เราเคยพบมา Phillips (1987) ได้พิสูจน์ว่าหาก y_t เป็นยูนิตรุต $t_{\phi=1}$ และ $T(\hat{\phi} - 1)$ จะมีการแจกแจงแบบ Dickey-Fuller t และ Dickey-Fuller normalized bias



การแจกแจง Dickey-Fuller

ตารางสำหรับการแจกแจง Dickey-Fuller สามารถใช้คำสั่ง `adfTable` ใน `library(fUnitRoots)` โดยสมการทดสอบมีได้ 3 รูปแบบ

`trend=c("nc")` - no constant เช่นในสมการ (2.72) (ในหัวข้อย่อต่อไป จะพิจารณากรณีมีพจน์ค่าคงที่ และจุดตัด) และแสดงการแจกแจงของ t โดยระบุ `statistics=c("t")` ส่วนการแจกแจง Dickey-Fuller normalized bias จะต้องระบุ `statistics=c("n")`

```

1 > library(fUnitRoots)
2 > adfTable(trend=c("nc"), statistic=c("t"))
3 $x
4 [1] 25 50 100 250 500 Inf
5
6 $y
7 [1] 0.010 0.025 0.050 0.100 0.900 0.950 0.975 0.990
8
9 $z
10 [1] 0.010 0.025 0.050 0.100 0.900 0.950 0.975 0.990
11 25 -2.66 -2.26 -1.95 -1.60 0.92 1.33 1.70 2.16
12 50 -2.62 -2.25 -1.95 -1.61 0.91 1.31 1.66 2.08
13 100 -2.60 -2.24 -1.95 -1.61 0.90 1.29 1.64 2.03
14 250 -2.58 -2.23 -1.95 -1.62 0.89 1.29 1.63 2.01
15 500 -2.58 -2.23 -1.95 -1.62 0.89 1.28 1.62 2.00
16 Inf -2.58 -2.23 -1.95 -1.62 0.89 1.28 1.62 2.00

```



การทดสอบ unit root

สิ่งสำคัญในการทดสอบยูนิตรูทคือการระบุว่าสมมุติฐานหลักและสมมุติฐานทางเลือกมีความเหมาะสมกับข้อมูลหรือ โดยเฉพาะแนวโน้ม โดยกรณีที่เราพบบ้อยมีสองกรณีคือกรณีมีค่าคงที่อย่างเดียว และกรณีมีค่าคงที่และแนวโน้ม

ในกรณีค่าคงที่อย่างเดียว สมการที่ใช้ในการประมาณค่าตัวสถิติทดสอบคือ

$$y_t = c + \phi y_{t-1} + \varepsilon_t \quad (5)$$

และสมมุติฐานที่เกี่ยวข้องคือ

$$H_0 : \phi = 1 \quad (y_t \sim I(1) \text{ without drift})$$

$$H_1 : \phi < 1 \quad (y_t \sim I(0) \text{ with non-zero mean})$$



การทดสอบ unit root

ในกรณีที่มีค่าคงที่และแนวโน้ม สมการที่ใช้ในการประมาณค่า

$$y_t = c + \delta t + \phi y_{t-1} + \varepsilon_t \quad (6)$$

และสมมุติฐานที่เกี่ยวข้องกันคือ

$$H_0 : \phi = 1 \quad (y_t \sim I(1) \text{ with drift})$$

$$H_1 : \phi < 1 \quad (y_t \sim I(0) \text{ with deterministic time trend})$$

โดยที่รูปแบบของสมการที่ใช้ในการทดสอบมักจะเป็นในรูป

$$\Delta y_t = c + \pi y_{t-1} + \varepsilon_t$$

และ

$$\Delta y_t = c + \delta t + \pi y_{t-1} + \varepsilon_t$$



Augmented DF test

การทดสอบยูนิตรุตด้วยพจน์ที่เพิ่มเข้าไปโดยมีพื้นฐานจากแบบจำลอง $ARMA(p, q)$ แล้วเรียกว่า Augmented Dickey-Fuller ซึ่งตัวทดสอบสามารถประมาณค่าได้จากสมการ

$$y_t = \beta' (D_t) + \phi y_{t-1} + \sum_{j=1}^p \psi_j \Delta y_{t-j} + \varepsilon_t$$

หรือเราสามารถประมาณค่าสมการนี้

$$\Delta y_t = \beta' D_t + \pi y_{t-1} + \sum_{j=1}^p \psi_j \Delta y_{t-j} + \varepsilon_t$$

โดยที่ $\pi = \phi - 1$ ซึ่งภายใต้สมมุติฐานหลัก Δy_t จะเป็น $I(0)$ และอนุมานได้ว่า $\pi = 0$



ตัวอย่าง 2.8

ทดสอบยูนิตรุตของ SET index รายวัน จากข้อมูลในไฟล์ setindex.txt แต่ในที่นี้เราจะใช้ชุดคำสั่ง fUnitRoots โดยเบื้องต้นเราจะพิจารณา ACF ของอนุกรมเวลาและอนุกรมเวลาที่ได้ปรับผลต่างอันดับหนึ่ง (first-differenced) จาก ACF ของอนุกรมเวลา set\$index เราพบว่าน่าจะมีปัญหายูนิตรุตเนื่องจากค่า ACF ลดลงช้ามาก

```
1 > set=read.table(file="setindex.txt", header=TRUE)
2 > library(fUnitRoots)
3 > acf(set$index)
4 > acf(diff(set$index))
5 > plot(diff(set$index),type="l")
```



เราจะทดสอบยูนิตรุตโดยใช้ Augmented Dickey-Fuller test โดยคำสั่งที่ใช้ในที่นี้ค่า `adfTest` โดยเราต้องระบุค่าค่าของ y_t ที่เราจะรวมในสมการ โดยในที่นี้จะเลือก `lags=10` และรูปแบบของสมการ `type` (ไม่มีค่าคงที่ (nc), มีค่าคงที่ (c) และมีค่าคงที่และเส้นแนวโน้ม (ct)) จากกราฟ Δy_t เราพบว่ามีค่าจุดตัดต่างจากศูนย์แต่ไม่มีแนวโน้มดังนั้นเราจะเลือก `type=c("c")`

```
1 > adfTest(set$index, lags=10, type=c("c"))
2
3 Title:
4   Augmented Dickey-Fuller Test
5
6 Test Results:
7   PARAMETER:
8     Lag Order: 10
9   STATISTIC:
10    Dickey-Fuller: -0.0682
11    P VALUE:
12      0.9501
```



ARIMA

Definition 2

เราจะเรียกกระบวนการ y_t ว่า $ARIMA(p, d, q)$ ถ้า $\Delta^d y_t = (1 - L)^d y_t$ เป็นกระบวนการ $ARMA(p, d, q)$ หรือเราสามารถเขียนในรูปทั่วไปเป็น

$$\phi(L)(1 - L)^d y_t = \theta(L)\varepsilon_t \quad (7)$$

และถ้าหาก $E(\Delta^d y_t) = \mu$ เราสามารถเขียนแบบจำลองได้เป็น

$$\phi(L)(1 - L)^d y_t = \delta + \theta(L)\varepsilon_t$$

โดยที่ $\delta = \mu(1 - \phi_1 - \dots - \phi_p)$



ARIMA

ในทางปฏิบัติ เราสามารถแบ่งแยกขั้นตอนในการสร้างแบบจำลอง $ARIMA(p, d, q)$ ได้ดังนี้

- ❶ พิจารณา ACF ของข้อมูลว่ามีข้อบ่งชี้ว่ามีปัญหาข้อมูลไม่นิ่ง (nonstationary) หรือไม่
- ❷ ทดสอบยูนิทรูทว่ามีอินทิเกรตที่อันดับเท่าใด หรือหาค่า d นั้นเอง
- ❸ หลังจากนั้นเราจะพิจารณาอนุกรม $z_t = \Delta^d y_t$ ว่าแบบจำลองที่เหมาะสมในการอธิบาย z_t ควรจะมีอันดับของ p และ q เท่าใด

หลังจากที่เราได้ค่า d, p และ q แล้วเราก็จะได้แบบจำลอง $ARIMA(p, d, q)$



ตัวอย่างที่ 2.9

ต่อจากตัวอย่างที่ 2.8 เราพิจารณาว่า set index

```

1 > adfTest(diff(set$index), lags=10, type=c("c"))
2 Title:
3 Augmented Dickey-Fuller Test
4 Test Results:
5 PARAMETER:
6 Lag Order: 10
7 STATISTIC:
8 Dickey-Fuller: -16.7697
9 P VALUE:
10 0.01
11 > library(forecast)
12 > auto.arima(set$index
13 ,d=1,D=0,max.p=12,max.q=12,ic=c("bic"),stepwise=FALSE,trace=FALSE)
14 Series: set$index
15 ARIMA(0,1,0)
16 sigma^2 estimated as 87.77: log likelihood=-13312.56
AIC=26627.12 AICc=26627.12 BIC=26633.32

```

ซึ่งจากการใช้ BIC พบว่าอันดับที่เหมาะสมคือ $p = 0$ และ $q = 0$ ดังนั้นแบบจำลองที่เหมาะสมที่ใช้ประมาณค่า set index รายวันคือ ARIMA(0,1,0) หรือแบบจำลอง random walk นั่นเอง

