


統計分析 I

Univariate



นรภ. เพชร์ ลดา อดิเรก

(นรภ. ต่อไป  $y_{t-1}, y_{t-2}, \dots$ )

EC435

## บทที่ 2 แบบจำลองอนุกรรมเวลาเชิงเส้นตรัง

1)  $y_t$  กับ  $y_{t-k}$

ความสัมพันธ์


กันแม่นๆ

เฉลิมพงษ์ คงเจริญ ©2556-61

คณะเศรษฐศาสตร์ มหาวิทยาลัยธรรมศาสตร์

↑  
ทดลอง ACF/LB-Q Int

September 4, 2019



ความสัมพันธ์

ระยะ dist

→ นรภ. เพชร์ ลดา อดิเรก

⇒ ไม่สามารถ นรภ. เพชร์

# กระบวนการไวท์โนയซ์ (white noise)

ข้อมูลอนุกรมเวลาที่ง่ายที่สุดคือกระบวนการไวท์โนยซ์ (white noise) โดยที่เรามักจะเขียนแทนด้วย random variable  $\varepsilon_t$

## นิยาม 2.1

ตัวแปร  $\varepsilon_t$  จะเรียกว่ากระบวนการไวท์โนยซ์ถ้ามีค่าเฉลี่ยเท่ากับศูนย์, มีความแปรปรวนคงที่เท่ากับ  $\sigma^2$  และไม่มีสหสัมพันธ์ข้ามเวลา (serially uncorrelated) หรือเขียนเป็นเงื่อนไขได้ดังนี้

- 1  $E(\varepsilon_t) = 0$   $\text{ค่าเฉลี่ย} = 0$
- 2  $Var(\varepsilon_t) = \sigma_\varepsilon^2$   $\text{V ar } \text{ กอง } = \sigma_\varepsilon^2$
- 3  $\gamma_k = Cov(\varepsilon_t, \varepsilon_{t-k}) = 0 \text{ for } k \neq 0$   $\rightarrow \text{Autocov} = 0 \text{ ทุก lag } (\neq 0)$

$\downarrow$   
 $\varepsilon_t$  ไม่ร่วม彼此 กับ  $\varepsilon_{t-k}$

White noise process  
- ปัจจุบัน vs Stationary




# กระบวนการเส้นตรง (Linear process) $\rightarrow$ ဝါဒများ $y_t = \mu + \sum_{i=0}^{\infty} \psi_i \varepsilon_{t-i}$

Wold's decomposition theorem ระบุว่าอนุกรมเวลา  $y_t$  สามารถเขียนในรูปกระบวนการเส้นตรงหรือตัวแทนรูปแบบค่าเฉลี่ยเคลื่อนที่ที่มีอันดับเป็นอนันต์ (infinite moving average) และถ้าสามารถเขียน  $y_t$  ในรูป

$$y_t = \mu + \sum_{i=0}^{\infty} \psi_i \varepsilon_{t-i} \quad (1)$$

โดยที่  $\mu$  คือค่าเฉลี่ย,  $\psi_0 = 1$ , และ  $\varepsilon_t$  คือ (iid) โดยที่เราสามารถพิจารณา  $\varepsilon_t$  ในฐานะเป็นข้อมูลใหม่ที่เข้ามาในช่วงเวลา  $t$  หรือเป็น innovation หรือ shock ณ เวลา  $t$  และ  $\sum_{i=1}^{\infty} \psi_i^2 < \infty$



# แบบจำลองออโตรีเกรสซีฟ (Auto regressive Mode)


แนวคิดพื้นฐานของแบบจำลองออโตรีเกรสซีฟ (autoregressive) ก็คือข้อมูลในเวลาปัจจุบัน ( $y_t$ ) สามารถอธิบายได้ด้วยตัวแปรนี้ในอดีตย้อนหลังไป  $p$  ถึง  $p$  ช่วงเวลา ( $y_{t-1}, \dots, y_{t-p}$ )

แบบจำลองออโตรีเกรสซีฟที่มีอันดับ (order) เท่ากับ  $p$  (เขียนแทนด้วย  $\underline{AR(p)}$ ) สามารถเขียนได้เป็น

$$\hat{y}_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t, \quad (2.3)$$

$\phi_i$  - coefficient

โดยที่  $y_t$  เป็นข้อมูลที่นิ่งและ  $\varepsilon_t$  เป็นไวท์โนแซตส์ที่มีค่าเฉลี่ยเท่ากับศูนย์และค่าความแปรปรวนคงที่เท่ากับ  $\sigma_\varepsilon^2$



แบบจำลองอ้อ โตรีเกรสซีฟ: ค่าเฉลี่ย  $\overbrace{AR(P) - \text{ไม่ถูกต้อง}}^{\text{ก็ } Y_t \text{ เป็นพหุค่า } AR(P)}$

ค่าเฉลี่ยของ  $y_t$  เท่ากับ

$$E(y_t) = E(\phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_t)$$

ตรวจสอบ  $E(Y_t)$   
ดูว่า  $E(Y_t) = \phi_1 E(Y_{t-1}) + \phi_2 E(Y_{t-2}) + \dots + \phi_p E(Y_{t-p}) + E(\varepsilon_t)$

$$= \phi_1 E(Y_{t-1}) + \phi_2 E(Y_{t-2}) + \dots + \phi_p E(Y_{t-p}) + E(\varepsilon_t)$$

หากเราเขียน  $AR(p)$  ในรูป Stationary  $E(Y_t) = E(Y_{t-1}) = \dots = E(Y_{t-p})$

$$(1 - \phi_1 - \phi_2 - \dots - \phi_p) E(Y_t) = E(\varepsilon_t) = 0$$

$$(y_t - \mu) = \phi_1(y_{t-1} - \mu) + \phi_2(y_{t-2} - \mu) + \dots + \phi_p(y_{t-p} - \mu) + \varepsilon_t, \quad \begin{array}{l} \text{ตรวจสอบ} \\ \varepsilon_t \sim WN(0, \sigma_\varepsilon^2) \end{array} \quad (2.4)$$

ให้  $y_t = \phi_0 + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t, \quad (2.5)$

$E(y_t) = \frac{\phi_0}{1 - \phi_1 - \dots - \phi_p} \equiv \mu$  ตรวจสอบ  $\sum \phi_i = 1$

$\phi_0 = 0$  แล้ว  $E(Y_t) = 0$  ถูกต้อง



# การเขียน AR(p) ในรูป backshift operator [lag operator]

นอกจากนี้เรายังสามารถเขียนสมการ (2.3) ได้ด้วยเครื่องมือ backshift operator เป็นสมการดังนี้

ดังนั้น

$$\begin{aligned}
 & L \cdot y_t = y_{t-1} \\
 & L(y_{t-1}) = y_{t-2} \\
 & L^2 y_t = y_{t-2} \\
 & (1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p) y_t = \varepsilon_t, \\
 & \quad \text{หมายเหตุ} \\
 & \quad \boxed{\phi(L) y_t = \varepsilon_t}
 \end{aligned}
 \tag{2.5}$$

$\underbrace{y_t}_{\text{AR}(p)}$   $\underbrace{\phi_1 y_{t-1}}_{L y_t}$   $\underbrace{\phi_2 y_{t-2}}_{L^2 y_t}$   $\dots$   $\underbrace{\phi_p y_{t-p}}_{L^p y_t}$

โดยที่เรียก  $\underline{\phi(L)} = 1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p$  ว่าพหุนามอัตโนมัติ (autoregressive polynomial)

## AR(1) model

เราจะพิจารณาคุณสมบัติของแบบจำลอง  $AR(1)$  ซึ่งมีค่าเฉลี่ยเท่ากับศูนย์ สามารถแสดงได้โดย


$$y_t = \phi y_{t-1} + \varepsilon_t, \quad (2.8)$$

จากสมการข้างต้นหากเราริ่มพิจารณากรณีที่  $y_0 = 0$  และให้  $\varepsilon_t$  มีการแจกแจงแบบ  $N(0, 1)$  เราจะได้การเดินทางตามเวลา (time path) ของ  $y_t$  สำหรับค่าสัมประสิทธิ์ ( $\phi$ ) ที่ต่างกันดังที่แสดงในรูปต่อไปนี้



# AR(1) model

Figure: การจำลองกระบวนการ  $AR(1)$  ที่ค่าสัมประสิทธิ์( $\phi$ )ที่ต่างกัน



## ② $\text{Var}(Y_t)$

จากสมการ (2.8) เราสามารถแทนค่า  $y_t$  ในอดีตไปเรื่อยๆแบบเวียนเกิด (recursive)  $k$  ครั้งดังนี้  $\rightarrow$  ที่จะแปล  $y_t$  ถูกพิจารณาเป็นลำดับ กันทวน  $y_t, y_{t-1}, \dots$

AR(1)

$$y_t = \phi y_{t-1} + \varepsilon_t$$

$$\frac{\text{from AR(1)}}{y_t} y_t = \phi (\phi y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t = \phi^2 y_{t-2} + \phi \varepsilon_{t-1} + \varepsilon_t$$

$$\begin{aligned} &= \phi^3 y_{t-3} + \phi^2 \varepsilon_{t-2} + \phi \varepsilon_{t-1} + \varepsilon_t \\ &\vdots \\ &= \phi^K y_{t-K} + \varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \phi^3 \varepsilon_{t-3} \end{aligned}$$

linear  
combination  
no shock

ด้วยวิธีดังกล่าวข้างต้นแต่ค่า  $|\phi| < 1$  และ  $\lim_{k \rightarrow \infty} \phi^k y_{t-k} = 0$  จะทำให้เราสามารถเปลี่ยนแบบจำลอง AR(1) ในรูปต่อไปนี้

$y_t$  stationary

$$y_t = \varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}, \quad (2.9)$$

↑ AR(1)

เราเรียกรูปดังกล่าวว่าการแสดงแบบจำลอง AR(1) ด้วย infinite moving average representation

$$0 = E(y_t) = E(\varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots) = E(\varepsilon_t) + \phi E(\varepsilon_{t-1}) + \dots$$



ค่าความแปรปรวนของ  $y_t \rightarrow AR(1)$

$$y_t = \phi y_{t-1} + \varepsilon_t$$

$$\Rightarrow y_t = \varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots$$

เนื่องจาก  $E(y_t) = 0$  ค่าความแปรปรวน  $Var(y_t) = E[y_t - E(y_t)]^2$  จะเท่ากับ  $Var(y_t) = E(y_t^2)$  หากเราแทนค่า  $y_t$  จากสมการ (2.9) ลงในสูตรดังกล่าว และใช้คุณสมบัติของ  $\varepsilon_t$  ที่ว่า  $Var(\varepsilon_t) = E(\varepsilon_t^2) = \sigma_\varepsilon^2$  และ  $E(\varepsilon_j, \varepsilon_k) = 0$  สำหรับ  $k \neq j$  เราจะได้

$$\begin{aligned}
 E(y_t^2) &= E(y_t \cdot y_t) \\
 &= E[(\varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots)(\varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots)] \\
 &= E[\underbrace{\varepsilon_t^2}_{\text{red}} + \underbrace{\varepsilon_t \phi \varepsilon_{t-1}}_{\text{green}} + \underbrace{\varepsilon_t \phi^2 \varepsilon_{t-2}}_{\text{green}} + \underbrace{\phi \varepsilon_{t-1} \varepsilon_t}_{\text{green}} + \underbrace{\phi^2 \varepsilon_{t-1}^2}_{\text{red}} + \underbrace{\phi \varepsilon_{t-1} \phi \varepsilon_{t-2}}_{\text{green}}] \\
 &= E(\varepsilon_t^2) + \phi E(\varepsilon_t \varepsilon_{t-1}) + \dots + E(\varepsilon_{t-1} \varepsilon_t) + \phi^2 E(\varepsilon_{t-1}^2) \\
 &\quad \underbrace{\qquad\qquad\qquad}_{\text{red}} \quad \underbrace{\qquad\qquad\qquad}_{\text{green}} \quad \underbrace{\qquad\qquad\qquad}_{\text{green}} \quad \underbrace{\qquad\qquad\qquad}_{\text{green}} \quad \underbrace{\qquad\qquad\qquad}_{\text{red}} \\
 &= \sigma_\varepsilon^2 + \underbrace{0}_{\text{red}} + \underbrace{0}_{\text{green}} + \underbrace{0}_{\text{green}} + \underbrace{0}_{\text{green}} + \underbrace{\phi^2 \sigma_\varepsilon^2}_{\text{red}} + \underbrace{0}_{\text{green}} + \underbrace{0}_{\text{green}} + \underbrace{0}_{\text{green}} + \underbrace{0}_{\text{red}} \\
 &= \sigma_\varepsilon^2 + \phi^2 \sigma_\varepsilon^2 + \phi^4 \sigma_\varepsilon^2 + \phi^6 \sigma_\varepsilon^2 + \dots \\
 &= \sigma_\varepsilon^2 (1 + \phi^2 + \phi^4 + \phi^6 + \dots)
 \end{aligned}$$

## ค่าความแปรปรวนร่วม

$$\text{Var}(Y_t) = E(Y_t^2) = \frac{\sigma^2}{1-\phi^2}$$
②

$|\phi| < 1$   
(stationary)

หากนำค่า  $y_t$  และ  $y_{t-l}$  ที่เขียนในรูปสมการ (2.9) และค่าเฉลี่ยเท่ากับศูนย์  $E(y_t) = 0$  แทนค่าในสูตรค่าความแปรปรวนร่วมได้ฟังก์ชันค่าความแปรปรวนร่วมจะเท่ากับ

$$\begin{aligned}
 \gamma_l &= E[(Y_t - E(Y_t))(Y_{t-l} - E(Y_{t-l}))] = E[Y_t Y_{t-l}] \\
 &= E[(\epsilon_t + \phi \epsilon_{t-1} + \phi^2 \epsilon_{t-2} + \dots)(\epsilon_{t-l} + \phi \epsilon_{t-l-1} + \phi^2 \epsilon_{t-l-2} + \dots)] \\
 &= E[\underbrace{\phi^l \epsilon_{t-l} \epsilon_{t-l}}_{\text{auto term}} + \underbrace{\phi^{l+1} \epsilon_{t-l-1} \epsilon_{t-l-1}}_{t-(l+1)} + \underbrace{\phi^{l+2} \epsilon_{t-l-2} \epsilon_{t-l-2}}_{t-(l+2)} + \dots + \text{cross term}] \\
 &= \phi^l E(\epsilon_{t-l}^2) + \phi^{l+2} E(\epsilon_{t-l-1}^2) + \phi^{l+4} E(\epsilon_{t-l-2}^2) + \dots + E(\text{cross term}) \\
 &= \sigma_\epsilon^2 (\phi^l + \phi^{l+2} + \phi^{l+4} + \phi^{l+6} + \dots)
 \end{aligned}$$



# ฟังก์ชันสหสัมพันธ์ร่วมในตัวเอง (ACF)

ฟังก์ชันสหสัมพันธ์ร่วมในตัวเอง (ACF) เท่ากับ  $\rho_l = \frac{\gamma_l}{\gamma_0} = \frac{\frac{\phi^l \sigma_\varepsilon^2}{(1-\phi^2)}}{\frac{\sigma_\varepsilon^2}{(1-\phi^2)}} = \phi^l$

หากลองแทนค่า  $\phi$  ด้วยค่าเท่ากับ  $0.9, -0.9, 0.5, -0.5$  จะได้ฟังก์ชันสหสัมพันธ์ร่วมในตัวเองดังตารางต่อไปนี้

Table: Autocorrelation ของ  $AR(1)$  ที่ค่าสัมประสิทธิ์( $\phi$ )ที่ต่างกัน

$\phi \setminus l$	1	2	3	4	5	6	7	8	9	10
0.9	0.900	0.810	0.729	0.656	0.590	0.531	0.478	0.430	0.387	0.349
-0.9	-0.900	0.810	-0.729	0.656	-0.590	0.531	-0.478	0.430	-0.387	0.349
0.5	0.500	0.250	0.125	0.063	0.031	0.016	0.008	0.004	0.002	0.001
-0.5	-0.500	0.250	-0.125	0.063	-0.031	0.016	-0.008	0.004	-0.002	0.001



# ฟังก์ชันสหสัมพันธ์ร่วมในตัวเอง (ACF)


Figure: ค่าสหสัมพันธ์ร่วมในตัวเองของกระบวนการ  $AR(1)$  ที่ค่าสัมประสิทธิ์( $\phi$ )ที่ต่างกัน

## ACF ณ $AR(1)$

1.  $\phi > 0$   
 ACF ณ : ชั้นทดักลด  
 เร็วๆ (กราฟ down)  
 คลื่นไ逼 0 )

2.  $|\phi| \geq 1$

ACF ณ : สูงมากกว่า  
 กว่า  $|\phi| \geq 0$



# เงื่อนไขความเป็นอนุกรมนิ่ง (Stationary) $AR(1)$ , กรณี Stationary $|\phi| < 1$

เราสามารถเขียนกระบวนการ  $AR(1)$  ในรูปของพหุนามออโตรีเกรสซีฟได้เป็น

$$Y_t = \phi Y_{t-1} + \varepsilon_t$$

$L \cdot Y_t$

Autoregressive  
Polynomial

$$y_t - \phi y_{t-1} = \varepsilon_t$$

$$(1 - \phi L)y_t = \varepsilon_t \quad (2.13)$$

โดยที่เราสามารถเขียน auxiliary equation  $\underbrace{\text{พหุนาม}}_{\text{ใหม่ } L \text{ ต่อหัวใจ } m}$  ให้เป็น  $\underbrace{\text{operator}}_{m}$

$$(1 - \phi m) = 0$$

Root of Polynomial

$$\rightarrow |m| = \left| \frac{1}{\phi} \right|$$

กรณี  $AR(1)$  ให้  
① stationary

$$|m| > 1$$

$$|\phi| < 1$$

Stationary

ค่าน้ำหนัก  $\Rightarrow$  Root of Polynomial  
จะต้องมากกว่า 1



## Example 1

จงพิจารณาว่ากระบวนการต่อไปนี้เป็นกระบวนการนิ่งหรือไม่

■  $y_t - 0.9y_{t-1} = \varepsilon_t$  [  $\phi_1 < 0.9\phi_{-1} + \varepsilon_t$  ]

$$\underline{|\phi| < 1}$$

■  $y_t - y_{t-1} = \varepsilon_t$

$$|\phi| = 1 \quad \text{not stationary}$$

■  $y_t + 1.2y_{t-1} = \varepsilon_t$

$$|\phi| = 1.2 > 1 \quad \text{not stationary}$$

แบบจำลอง AR(1) ที่มีค่าเฉลี่ย ≠ 0

เราสามารถเขียน AR(1) ในรูปทั่วไป เช่น  $y_t - \mu = \phi(y_{t-1} - \mu) + \varepsilon_t$  ถ้าเราต้องการหา  $E(y_t)$

$$\textcircled{1}) E(\psi_t) = \frac{c}{1-\phi}$$

$$\textcircled{2}) \text{Var}(\psi_t)$$

$$\textcircled{3}) \gamma_e, \rho_e$$

กรณีสมการ  $y_t = \phi_0 + \phi_1 y_{t-1} + \varepsilon_t$  ถ้าเราต้องการหา  $E(y_t)$



# แบบจำลอง AR(2) คุณสมบัติ

$E(y_t)$  ✓  
 $\text{Var}(y_t)$  ✗  
 $\rho_1, \rho_2$  ✗

ACF vs AR(2)

แบบจำลอง AR(2) สามารถเปลี่ยนอธิบายได้ด้วยสมการ

ในรูปแบบ

จัดรูป stationary ได้คือ  $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$

เราสามารถพิจารณาความเป็นกระบวนการนิ่งได้โดยการหารากของพหุนามของโตรีเกรสซีฟซึ่ง  $(1 - \phi_1 L - \phi_2 L^2)y_t = \varepsilon_t$  สามารถเปลี่ยนได้เป็น

รากของ  $L \rightarrow m$  (roots)  
 $\phi(m) = 1 - \phi_1 m - \phi_2 m^2 = 0$  เทศภาคย์  
 $\hookrightarrow (m_1, m_2)$

$\phi(m) = 1 - \phi_1 m - \phi_2 m^2 = 0$  โดยที่รากของสมการพหุนามของโตรีเกรสซีฟที่อยู่ในรูปสมการกำลังสอง (quadratic) จะมีคี่วิญญาณสองจำนวน ( $m_1, m_2$ ) ท่ากับ  $\frac{\phi_1 \pm \sqrt{\phi_1^2 + 4\phi_2}}{-2\phi_2}$  โดยที่เงื่อนไขที่คือ ตัวราก vs Root โดยที่เงื่อนไขที่คือ รากของสมการพหุนามของโตรีเกรสซีฟจะต้องมากกว่าหนึ่ง (หรือมอดูลัส (modulus) มากกว่าหนึ่งในกรณีจำนวนเชิงซ้อน) ซึ่งจะเกิดขึ้นเมื่อ  $|m_1| > 1, |m_2| > 1$   $\rightarrow y_t$  ไม่ stationary



$$\phi_1 + \phi_2 < 1, \quad \phi_2 - \phi_1 < 1, \quad |\phi_2| < 1$$



คุณลักษณะของกระบวนการ  $AR(2)$   $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$

ฟังก์ชันความแปรปรวนร่วมเราสามารถพิจารณาได้โดยคุณสมการ (2.16)

ทั้งสองข้างด้วย  $y_{t-k}$  และ take expectation เราจะได้

$$\begin{aligned}\gamma_k &= E(y_t y_{t-k}) = E[(\phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t) y_{t-k}] \\ &\stackrel{k>0}{=} E[\phi_1 y_{t-1} y_{t-k}] + E[\phi_2 y_{t-2} y_{t-k}] + E[\varepsilon_t y_{t-k}] \\ &= \phi_1 E[y_{t-1} y_{t-k}] + \phi_2 E[y_{t-2} y_{t-k}] + E[\varepsilon_t y_{t-k}] \\ &\quad \boxed{\gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2}}\end{aligned}$$

และหากหารด้วย  $\gamma_0$  จะได้

theoretical Autocorrelation lag k vs AR(2)  $\Rightarrow$

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2}$$

เรารียกสมการทั้งสองว่าสมการ Yule-Walker


$$\text{ให้นด้วย } k=1 \rightarrow \rho_1 = \phi_1 \cdot \rho_0 + \phi_2 \rho_{-1}$$



# คุณลักษณะของการบวนการ AR(2)

หากเราพิจารณากรณีที่  $k = 1$ ,  $\rho_1 = \rho_{-1}$  และ  $\rho_0 = 1$  เราจะได้

$$\rho_1 = \frac{\phi_1}{1 - \phi_2}$$



และกรณีที่  $k = 2$  เราจะได้  $\rho_2 = \phi_1 \rho_1 + \phi_2 \rho_0 = \pm$

$$\rho_2 = \frac{\phi_2(1 - \phi_2) + \phi_1^2}{1 - \phi_2}$$

$$\rho_3 = \phi_1 \rho_2 + \phi_2 \rho_1$$

⋮

และเราสามารถแทนค่าแบบเวียนเกิด(recursive)เพื่อให้ได้  $\rho_k$  กรณี  $k > 2$

ให้ไปอ่านเนื้อหาสำหรับแบบจำลอง AR(p)

ACF vs AR(2)

ก็จะคล้ายๆ กันแต่ต่ำลง  
ใช้มาต์ติกัน ACF AR(1)



แบบจำลอง  $AR(p)$

กรณีที่  $AR(p)$  เป็นอนุกรมนิ่ง ค่าคงที่ในรูปแบบลดด้อยในตัวเอง( $c$ )จะเท่ากับ  $\mu(1 - \phi_1 - \dots - \phi_p)$  ในทางกลับกัน  $\mu = c/(1 - \phi_1 - \dots - \phi_p)$

หากเราสมมุติให้ค่าเฉลี่ย( $\mu$ )เท่าศูนย์และกระบวนการนิ่ง เราจะได้

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2} + \dots + \phi_p \rho_{k-p},$$

สำหรับทุกค่า  $k \geq 1$  หากเราพิจารณากรณีที่  $k = 1, 2, \dots, p$  และใช้ความสัมพันธ์ที่  $\rho_0 = 1$  และ  $\rho_j = \rho_{-j}$  เราจะได้สมการ Yule-Walker ( $\text{|| ลิตเตอร์ ชัฟฟ์ ร์: อะ } \rho_k$ )


$$k=1 \rightarrow \rho_1 = \phi_1 + \phi_2 \rho_1 + \phi_3 \rho_2 + \dots + \phi_p \rho_{p-1}$$

$$k=2 \rightarrow \rho_2 = \phi_1 \rho_1 + \phi_2 + \phi_3 + \dots + \phi_p \rho_{p-2}$$

$\vdots$

$$k=p \rightarrow \rho_p = \phi_1 \rho_{p-1} + \phi_2 \rho_{p-2} + \phi_3 \rho_{p-3} + \dots + \phi_p$$

ACF ของ  $AR(p)$  หาดูได้ยากมาก: ห้ามลืม!



# แบบจำลอง $AR(p)$

ซึ่งหากเราทราบว่า  $\phi_1, \phi_2, \dots, \phi_p$  เราสามารถหาค่า  $\rho_1, \rho_2, \dots, \rho_3$  ได้  
นอกจานี้

$$E(\varepsilon_t y_t) = E[\varepsilon_t (\phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t)] = E(\varepsilon_t^2) = \sigma^2$$

และหากเราคุณสมการ (2.20) ด้วย  $y_t$  และใส่ค่าคาดหมาย เราจะได้

$$\gamma_0 = \phi_1 \gamma_1 + \phi_2 \gamma_2 + \dots + \phi_p \gamma_p + \sigma^2 \quad (3)$$

และหากใช้ความสัมพันธ์ว่า  $\rho_k = \gamma_k / \gamma_0$  จะได้

$$\gamma_0 = \frac{\sigma^2}{1 - \phi_1 \rho_1 - \phi_2 \rho_2 - \dots - \phi_p \rho_p}$$



# Partial Autocorrelation Function

$$AR(1) \quad Y_t = \phi_1 Y_{t-1} + \epsilon_t \quad | \text{from } Y_t \sim Y_{t-1}$$

$Y_t \rightarrow \text{run regression } Y_t \sim Y_{t-1}$

PACF ปั้นเครื่องมือที่เป็นประโยชน์ในการระบุแบบจำลอง AR( $p$ )

AR( $p$ )  $Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \dots + \phi_p Z_{t-p} + \epsilon_t$

$\phi_{kk}$  Partial Autocorrelation Function (PACF)

$\phi_{11}, \phi_{22}, \phi_{33}, \dots, \phi_{pp}$

$\phi_{11}, \phi_{21}, \phi_{31}, \dots, \phi_{p1}$

$\phi_{12}, \phi_{22}, \phi_{32}, \dots, \phi_{p2}$

$\phi_{13}, \phi_{23}, \phi_{33}, \dots, \phi_{p3}$

$\vdots$

$z_t = \phi_{11} z_{t-1} + \epsilon_{1t} \rightarrow \hat{\phi}_{11} \rightarrow \phi_1 \neq 0$

$z_t = \phi_{21} z_{t-1} + \phi_{22} z_{t-2} + \epsilon_{2t} \rightarrow \hat{\phi}_{21}, \hat{\phi}_{22} \rightarrow \phi_1, \phi_2 \neq 0$

$z_t = \phi_{p1} z_{t-1} + \phi_{p2} z_{t-2} + \dots + \phi_{pp} z_{t-p} + \epsilon_{pt}$

$\hat{\phi}_{p+1, p+1} z_{t-p-1} \rightarrow \hat{\phi}_{pp} \rightarrow \phi_p = 0$

$\hat{Y}_t = \hat{\phi}_1 Y_{t-1} + \hat{\phi}_2 Y_{t-2} + \dots + \hat{\phi}_p Y_{t-p} + \epsilon_t$

OLS  $\hat{\phi}_1, \hat{\phi}_2 \rightarrow \text{significance test}$

ในกรณี  $\hat{\phi}_2 = 0$  ให้ทดสอบ  $H_0: \phi_2 = 0$

โดยที่  $z_t = y_t - \mu$  คือข้อมูลที่ได้กำจัดค่าเฉลี่ยแล้ว (demeaned) เราเรียกค่าสัมประสิทธิ์  $\phi_{jj}$  สำหรับ  $j = 1, 2, \dots, p$  (ค่าสัมประสิทธิ์สุดท้ายของแต่ละสมการ) ว่าค่าสัมประสิทธิ์สหสัมพันธ์ในตัวของบางส่วน



# PACF

ในการณ์ที่เราพิจารณาแบบจำลอง  $AR(1)$  ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วนตัวแรก  $\phi_{11}$  จะไม่เท่ากับศูนย์ ส่วนสัมประสิทธิ์ที่เหลือจะเท่ากับศูนย์

หากเราพิจารณาแบบจำลอง  $AR(2)$  ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วนตัวแรกและตัวที่สอง ( $\phi_{11}$  และ  $\phi_{22}$ ) จะไม่เท่ากับศูนย์ ส่วนสัมประสิทธิ์ที่เหลือ ( $\phi_{jj}$  สำหรับ  $j > 2$ ) จะเท่ากับศูนย์

โดยสรุปแล้ว สำหรับแบบจำลอง  $AR(p)$  ใดๆ ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วน  $p$  ตัวแรกจะ ไม่เท่ากับศูนย์ และสัมประสิทธิ์ที่เหลือจะเท่ากับศูนย์

$AR(P)$




$$\phi_{p+1, p+1} \dots = 0$$



สามารถคำนวณได้โดยใช้ฟังก์ชัน pacf ใน R

Figure: ฟังก์ชันสหสัมพันธ์ในตัวเรองบางส่วนของข้อมูลจำลอง AR(1)




## ตัวอย่าง 2.3

```

1 > int<-read.csv(file="mlr.csv", header=T)
2 > head(int)
3 > plot(int$diff_th_us, type="l", ylab="%", xlab="time")

```

Figure: ความแตกต่างระหว่างอัตราดอกเบี้ยของไทยและสหรัฐอเมริกา





## ตัวอย่างที่ 2.3: PACF

```

1 > par(mfrow=c(1,2))
2 > library(TSA)
3 > Acf(int$diff_th_us)
4 > pacf(int$diff_th_us)

```

Figure: ACF และ PACF ของความแตกต่างระหว่างอัตราดอกเบี้ยของไทยและสหรัฐอเมริกา



② Maximum Likelihood Estimation  
MLE estimation  $y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \phi_3 y_{t-3} + \varepsilon_t$   
 $\rightarrow$  ประมาณการโดยOLS

หากเราสนใจที่จะประมาณค่าแบบจำลอง AR(1) ซึ่งอยู่ในรูปดังต่อไปนี้

ตามที่ M5(10.7/10)  
Normal

$$y_t = \mu + \phi(y_{t-1} - \mu) + \varepsilon_t$$

โดยที่  $\varepsilon_t \sim iidN(0, \sigma^2)$  เนื่องจากข้อมูลอนุกรมเวลาเป็นข้อมูลที่ขึ้นอยู่ต่อกัน (dependent) ดังนั้น หากเราเก็บข้อมูล  $y_1, \dots, y_T$  และพึงก์ชันค่าความควรจะเป็นสามารถเขียนได้ดังนี้

Likelihood Function

$$L(\mu, \phi, \sigma^2) = f(y_1)f(y_2|y_1)f(y_3|y_2)\cdots f(y_T|y_{T-1}) \quad (4)$$

เนื่องจาก  $y_t|y_{t-1} \sim N(\mu + \phi(y_{t-1} - \mu), \sigma^2)$  และพึงก์ชันการแจกแจงจะเป็นแบบปกติที่เหมือนกับซอก

$$f(y_t|y_{t-1}) = f_\varepsilon[(y_t - \mu) - \phi(y_{t-1} - \mu)]$$

MLE - ①: Maximize L โดยทราบ  $\phi$



# MLE estimation

$$L(\mu, \phi, \sigma^2) = \exp \left( \frac{\sum_{t=2}^T [(y_t - \mu) - \phi(y_{t-1} - \mu)]}{2\sigma^2} \right) \quad (2.30)$$

การหาประมาณค่าโดยหาค่าพารามิเตอร์ที่ทำให้ log ของสมการ (2.30) สูงที่สุด  
เรียกว่า การประมาณค่าความควรจะเป็นสูงสุดแบบแม่นตรง (exact maximum likelihood estimation)

กรณีนี้เราไม่สามารถหาค่าสูงสุดได้ด้วยการวิเคราะห์หาจุดสูงสุด  
ต้องใช้กระบวนการด้วยเครื่องคอมพิวเตอร์ในการหาค่าสูงสุด

$$\text{OLS, MLE} \rightarrow \hat{y}_t = \hat{c} + \hat{\phi}_1 y_{t-1} + \hat{\phi}_2 y_{t-2} + \hat{\phi}_3 y_{t-3}$$

AR(3) หมายความว่า อะไร呀？



# Model Checking (ทดสอบแนวทั่วไป.)

ในชุดที่  $(AR(3))$  ที่มี

หลังจากที่เราได้ตัวประมาณค่าสำหรับพารามิเตอร์แล้ว ขึ้นต่อไปเราจะหาค่า fitted ของตัวแปรที่เราศึกษา ( $\hat{y}_t$ )

$$\hat{y}_t(\text{จริง}) - \hat{y}_t(\text{ประมาณ}) = \hat{\epsilon}_t$$

แล้วก็จะตรวจสอบแบบจำลองโดยการวิเคราะห์ค่าส่วนเกิน (residuals) โดยในที่นี้ค่าส่วนเกินสามารถคำนวณได้จาก  $\hat{\epsilon}_t = y_t - \hat{y}_t$  โดยเราจะประเมินค่าส่วนเกินดังต่อไปนี้

ด้วย  $\hat{\epsilon}_t$  เป็นตัวอย่างพิเศษ  
(เพียงพอ)

เมื่อ  $\hat{\epsilon}_t$  เป็นตัวอย่างพิเศษ  
ให้  $\hat{\epsilon}_{t-k}$

- ACF vs  $\hat{\epsilon}_t$   
LB Test

ทดสอบว่า  $\hat{\epsilon}_t$  เป็น White Noise

1) ACF vs  $\hat{\epsilon}_t$   $\rightarrow$  ทดสอบว่า  $\text{lag } \Rightarrow \rho_j$  ทุก lag นั้นทางลงตัว

2) LB Q test กับ  $\hat{\epsilon}_t$   
 $Q(m) \sim \chi^2_{df=m-g}$  จำนวน lag vs AR



# Model Checking

หลังจากที่เราได้ตัวประมาณค่าสำหรับพารามิเตอร์แล้ว ขั้นตอนไปเราก็จะหาค่า fitted ของตัวแปรที่เราศึกษา ( $\hat{y}_t$ )

แล้วก็จะตรวจสอบแบบจำลองโดยการวิเคราะห์ค่าส่วนเกิน (residuals) โดยในที่นี้ค่าส่วนเกินสามารถคำนวณได้จาก  $\hat{\epsilon}_t = y_t - \hat{y}_t$  โดยเราจะประเมินค่าส่วนเกินดังต่อไปนี้

เราอาจจะเริ่มจากการวัดแผนภาพ ACF ของ  $\hat{\epsilon}_t$  เพื่อดูว่าอนุกรมดังกล่าวยังมีความขึ้นอยู่ต่อกันหรือไม่



# Model Checking

หลังจากที่เราได้ตัวประมาณค่าสำหรับพารามิเตอร์แล้ว ขึ้นต่อไปเราจะหาค่า fitted ของตัวแปรที่เราศึกษา ( $\hat{y}_t$ )

แล้วก็จะตรวจสอบแบบจำลองโดยการวิเคราะห์ค่าส่วนเกิน (residuals) โดยในที่นี้ค่าส่วนเกินสามารถคำนวณได้จาก  $\hat{\varepsilon}_t = y_t - \hat{y}_t$  โดยเราจะประเมินค่าส่วนเกินดังต่อไปนี้

① เราอาจจะเริ่มจากการวัดแผนภาพ ACF ของ  $\hat{\varepsilon}_t$  เพื่อดูว่าอนุกรมดังกล่าวยังมีความขึ้นอยู่ต่อกันหรือไม่

② นอกจากนี้เราสามารถทดสอบโดยใช้ค่าสถิติ  $Q(m) = T(T+2) \sum_{k=1}^m \frac{\hat{\rho}_{\varepsilon_k}^2}{T-k}$  โดยที่  $Q(m) \sim \chi^2_{m-g}$  โดยที่  $g$  คือจำนวนของอันดับในแบบจำลองซึ่งในแบบจำลอง  $AR(p)$  ค่า  $g = p$  และ  $m$  คือจำนวนค่าล่าของความสัมพันธ์ที่พิจารณา



# ព័វិមានយោង 2,3 ពេទ្យ

$\text{A} \cap \text{ACF}$  1st min  
 $\text{AR}(3)$  order vs  $\text{AR}(P)$

```

1 > m1<-arima(int$diff_th_us, order=c(3,0,0))
2 > m1
3 Call:
4 arima(x = int$diff_th_us, order = c(3, 0, 0))
5 Coefficients:
6          ar1     ar2     ar3   intercept
7  s.e. 0.0549  0.0878  0.0549  0.8102
8 sigma^2 estimated as 0.3054: log likelihood = -269.11, aic = 548.21
9

```

$\hat{\mu} = \frac{\phi_0}{1-\phi_1-\phi_2-\phi_3}$

sec(1)  $\text{na} \text{na} \text{na} \text{na} \text{na}$   $H_0: \phi_1 = 0$  vs  $H_1: \phi_1 \neq 0$  |  $\phi_1$

## ໂຄຍກົມ

$$\phi_1 = 0 \text{ vs } H_1: \phi_1 \neq 0 \quad | \quad \phi_1, \phi_2, \phi_3 \neq 0$$

$\rightarrow t = \frac{1.32}{0.05}$

(population)

$\hat{\phi}_1 = 1.3294$ ,  $\hat{\phi}_2 = -0.4986$ ,  $\hat{\phi}_3 = 0.1334$ ,  $\hat{\mu} (= intercept) = 3.0553$  และมีค่า standard errors อยู่ในบรรทัด s.e.



## ตัวอย่าง 2.3 ต่อ

ในโปรแกรม R ค่า intercept ที่ได้คือ  $\mu$  มิใช่จุดตัดแกนในสมการที่ ?? ดังนั้นถ้าต้องการหาค่าต้องการค่า  $c = \mu(1 - \phi_1 - \phi_2 - \phi_3) = 0.10937$   
เราสามารถเขียนผลการประมาณค่าได้โดย

$$(1 - \frac{1.3294}{(0.0549)}L + \frac{0.4986}{(0.0878)}L^2 - \frac{0.1334}{(0.0549)}L^3)(y_t - \frac{3.0553}{(0.8102)}) = \varepsilon_t$$

โดยที่ค่าในวงเล็บคือ standard errors และ  $\hat{\sigma}^2 = 0.3054$



# ตัวอย่าง 2.3 ต่อ

```

1 > m2<-arima(int$diff_th_us, order=c(3,0,0),method=c("ML"))
2 > m2
3 Coefficients:
4     ar1      ar2      ar3  intercept
5     1.3295   -0.4987   0.1334    3.056
6 s.e.  0.0549   0.0878   0.0549    0.810
7
8 sigma^2 estimated as 0.3054:  log likelihood = -269.11, aic = 548.21
9 > m3<-arima(int$diff_th_us, order=c(3,0,0),method=c("CSS"))
10
11 Coefficients:
12     ar1      ar2      ar3  intercept
13     1.3334   -0.5016   0.1346    3.0793
14 s.e.  0.0551   0.0880   0.0552    0.9195
15 sigma^2 estimated as 0.3082:  part log likelihood = -269.05

```

MLE

OLS



## ตัวอย่าง 2.3 ต่อ AR(3) ผิดพลาด ?

หลังจากที่เราได้ตัวประมาณค่าของพารามิเตอร์ทั้งหมดแล้วเราจะพิจารณาว่าค่า residuals นั้นยังมีความสัมพันธ์ระหว่างช่วงเวลาลงเหลืออยู่หรือไม่ หรือแบบจำลองเพียงพอหรือไม่ โดยการทดสอบ L-B test สำหรับ  $m2$residuals$  ด้วยคำสั่งข้างล่าง

① Plot ACF vs  $\sum_m$  [ $m \neq \text{residuals}$ ]  $\rightarrow \text{acf}(m \neq \text{residuals})$

②

```

1 > Box.test(m2$residuals, lag=12, type="Ljung")
2   ^Box-Ljung test
3 data: m2$residuals
4 X-squared = 14.0085, df = 12, p-value = 0.3002
5 > pv=1-pchisq(14.0085, 9)
6 > pv
7 [1] 0.1220232
  
```

$$LB Q(12) = 14.0085 \sim \chi^2_{df=12-3=9} \quad \text{order AR}$$

ดังนั้น  $Q(12) < CV$  หมายความว่า  $H_0: \epsilon_t$  ไม่ WN


|| สรุปว่าแบบจำลอง AR(3) ผิดพลาดที่  $\epsilon_t$  ไม่ WN

$\rightarrow$  ปรับเปลี่ยนแบบต่อไปนี้  $\hat{\epsilon}_t = \text{diff}_t - \text{us}$



# การพยากรณ์ด้วยแบบจำลอง $AR(p)$

สมมุติให้เรากำลังอยู่ในช่วงเวลาที่  $h$  แต่ต้องการที่จะพยากรณ์ไปข้างหน้า  $l$  คาบเวลา หรือสนับสนุนค่าของ  $y_{h+l}$  โดยที่  $l \geq 1$  เราเรียก  $h$  ว่าจุดเริ่มต้นการพยากรณ์ (forecast origin) และ  $l$  ว่าขอบเขตการพยากรณ์ (forecast horizon)



# การพยากรณ์ด้วยแบบจำลอง $AR(p)$

สมมุติให้เรากำลังอยู่ในช่วงเวลาที่  $h$  แต่ต้องการที่จะพยากรณ์ไปข้างหน้า  $l$  คาบเวลา หรือสนับสนุนค่าของ  $y_{h+l}$  โดยที่  $l \geq 1$  เราเรียก  $h$  ว่าจุดเริ่มต้นการพยากรณ์ (forecast origin) และ  $l$  ว่าขอบเขตการพยากรณ์ (forecast horizon) กำหนดให้  $\hat{y}_h(l)$  เป็นค่าพยากรณ์ของ  $y_{h+l}$  โดยการพยากรณ์ดังกล่าวจะทำให้ฟังก์ชันสูญเสียที่เกิดจาก การค่าผิดพลาดกำลังสอง (squared errors) น้อยที่สุด

$$E \left[ (\underbrace{y_{h+l}}_{\text{หัวรุ้ง}} - \underbrace{\hat{y}_h(l)}_{\text{หักก้มต์หง}})^2 | F_h \right] \leq \min_g E \left[ (y_{h+l} - g)^2 | F_h \right]$$

หัวรุ้ง      หักก้มต์หง  
forecast      forecast origin & period

โดยที่  $F_h$  เป็นข้อมูลที่มีทั้งหมดในคาบที่  $h$  และเราเรียก  $\hat{y}_h(l)$  ว่าค่าพยากรณ์ของ  $y_t$  ไปข้างหน้า  $l$  คาบ เมื่อเริ่มต้นการพยากรณ์อยู่ที่  $h$



ค่าพยากรณ์ไปข้างหน้า 1 คาบจาก  $AR(p) \rightarrow Y_t$  ตามการอธิบายด้วย  


$$Y_{t+1} = \phi_0 + \phi_1 Y_t + \phi_2 Y_{t-1} + \dots + \phi_p Y_{t-p} + \varepsilon_{t+1}$$
 AR(p)

เราพบว่าค่า  $\underline{y_{h+1}} = \phi_0 + \phi_1 y_{h+1-1} + \dots + \phi_p y_{h+1-p} + \varepsilon_{h+1}$  ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข (conditional expectation)

$$\hat{y}_h(1) = E(Y_{h+1} | F_h)$$

ก้าวแรก

$$\begin{aligned}
 & \text{โดยทั่วไป } \hat{y}_h(1) = E(Y_{h+1} | F_h) \\
 & = E(\phi_0 + \phi_1 Y_h + \phi_2 Y_{h-1} + \dots + \phi_p Y_{h+1-p} + \varepsilon_{h+1} | F_h) \\
 & = E(\phi_0 | F_h) + E(\phi_1 Y_h | F_h) + E(\phi_2 Y_{h-1} | F_h) + \dots + E(\phi_p Y_{h+1-p} | F_h) + E(\varepsilon_{h+1} | F_h) \\
 & = \phi_0 + \phi_1 E(Y_h | F_h) + \phi_2 E(Y_{h-1} | F_h) + \dots + \phi_p E(Y_{h+1-p} | F_h) + E(\varepsilon_{h+1} | F_h) \\
 & = \phi_0 + \phi_1 Y_{h-1} + \phi_2 Y_{h-2} + \dots + \phi_p Y_{h+1-p} + \varepsilon_{h+1} - \mu
 \end{aligned}$$

หมายเหตุ:   
 1. คำนวณตั้งแต่  $h$   
 2. คำนวณตั้งแต่  $h-1, h-2, \dots, h+1-p$   
 3.  $E(\varepsilon_{h+1} | F_h) = 0$

หมายเหตุ:   
 1. คำนวณตั้งแต่  $h$   
 2. คำนวณตั้งแต่  $h-1, h-2, \dots, h+1-p$   
 3.  $E(\varepsilon_{h+1} | F_h) = 0$

$$\hat{y}_h(1) = \phi_0 + \phi_1 Y_h + \phi_2 Y_{h-1} + \dots + \phi_p Y_{h+1-p}$$

# ค่าพยากรณ์ไปข้างหน้า 1 คาบจาก $AR(p)$

เราพบว่าค่า  $y_{h+1} = \phi_0 + \phi_1 y_{h+1-1} + \dots + \phi_p y_{h+1-p} + \varepsilon_{h+1}$  ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข (conditional expectation)

$$\hat{y}_h(1) =$$

*forecast error ของการพยากรณ์ N 1 period*  
 $\text{ดิจิต} - \text{ดิจิต}$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ  $e_h(1) = \underline{Y}_{h+1} - \hat{Y}_h(1)$


$\equiv \varepsilon_{h+1}$



# ค่าพยากรณ์ไปข้างหน้า 1 คาบจาก $AR(p)$

เราพบว่าค่า  $y_{h+1} = \phi_0 + \phi_1 y_{h+1-1} + \dots + \phi_p y_{h+1-p} + \varepsilon_{h+1}$  ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมิเงื่อนไข (conditional expectation)

$$\hat{y}_h(1) =$$



และค่าผิดพลาดจากการพยากรณ์เท่ากับ  $e_h(1) =$

*/ Var vs forecast error.*

และค่า แปรปรวนจากการพยากรณ์ไปข้างหน้าหนึ่งคาบท่ากับ  $\underline{Var}(e_h(1)) = \underline{Var}(\varepsilon_{h+1}) = \sigma_\varepsilon^2$

$$\sqrt{\underline{Var}(e_h(1))}$$

95%  
Forecast Interval ของ  $\hat{y}_{h+1} = \hat{y}_h(1) \pm Z_{\alpha=0.05} \cdot \underline{Se}(e_h(1))$



# ค่าพยากรณ์ไปข้างหน้า 1 ค่าจาก AR(p)

เราพบว่าค่า  $y_{h+1}$  <sup>AR(p)</sup> ที่  $\hat{y}_h(1) = E(y_{h+1} | F_h)$  ซึ่งเป็นการประมาณตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข (conditional expectation)

$$\hat{y}_h(1) = E(y_{h+1} | F_h) = \phi_0 + \phi_1 y_h + \phi_2 y_{h-1} + \dots + \phi_p y_{h+1-p}$$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ  $e_h(1) = y_{h+1} - \hat{y}_h(1)$

*forecast variance*


และค่า แปรปรวนจากการพยากรณ์ไปข้างหน้าหนึ่งค่าเท่ากับ  $Var(e_h(1)) = Var(\varepsilon_{h+1})$

$$Var(e_h(1)) = Var(\varepsilon_{h+1}) = \sigma_\varepsilon^2$$

เราสามารถสร้างช่วงความเชื่อมั่น 95% ของการพยากรณ์ไปข้างหน้า 1 ค่าได้โดยช่วงคงคล่องเท่ากับ  $\hat{y}_h(1) \pm 1.96sd(e_h(1))$

95% forecast interval =

$$Z_{\alpha=0.05}$$



Note:  $Var(\hat{y}_h(1)) = Var(e_h(1))$   
 $sd(\hat{y}_h(1)) = sd(e_h(1))$


# ค่าพยากรณ์ไปข้างหน้า 2 期 ของ AR(p)

เราพบว่าค่า  $y_{h+2}$  ที่ ดูแล้ว คือ  $y_{h+2} = \phi_0 + \phi_1 y_{h+1} + \dots + \phi_p y_{h+2-p} + \varepsilon_{h+2}$  ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข (conditional expectation)

$$\hat{y}_{h+2} = E(Y_{h+2} | F_h)$$

$$\text{โดยทั่วไป } \hat{y}_{h+2} = E(\phi_0 + \phi_1 Y_{h+1} + \phi_2 Y_h + \phi_3 Y_{h-1} + \dots + \phi_p Y_{h+2-p} + \varepsilon_{h+2} | F_h)$$

$$\begin{aligned} \text{โดยทั่วไป} \hat{y}_{h+2} &= \phi_0 + \phi_1 E(Y_{h+1} | F_h) + \phi_2 E(Y_h | F_h) + \dots + \phi_p E(Y_{h+2-p} | F_h) + E(\varepsilon_{h+2} | F_h) \\ &= \phi_0 + \phi_1 \hat{y}_h + \phi_2 \hat{y}_h + \dots + \phi_p \hat{y}_h + E(\varepsilon_{h+2} | F_h) \end{aligned}$$



$$\hat{y}_{h+2} = \phi_0 + \phi_1 \cdot \hat{y}_h + \phi_2 Y_h + \dots + \phi_p Y_{h+2-p}$$

Info of period h



# ค่าพยากรณ์ไปข้างหน้า 2 คาบจาก $AR(p)$

เราพบว่าค่า  $y_{h+2} = \phi_0 + \phi_1 y_{h+2-1} + \dots + \phi_p y_{h+2-p} + \varepsilon_{h+2}$  ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข (conditional expectation)

$$\hat{y}_h(2) =$$

*forecast error*      ตัวหนังสือ 2 คำ

และค่าผิดพลาดจากการพยากรณ์เท่ากับ

$$e_h(2) = \underbrace{y_{h+2}}_{\text{ดังนี้}} - \hat{y}_h(2)$$

$$= 0 + \phi_1 (\underbrace{\hat{y}_{h+1} - \hat{y}_h(1)}_{e_h(1)}) + 0 + \dots + 0 + \underbrace{\varepsilon_{h+2}}_{=}$$

$$e_h(2) = \phi_1 \varepsilon_{h+1} + \varepsilon_{h+2}$$

# ค่าพยากรณ์ไปข้างหน้า 2 คาบจาก $AR(p)$

เราพบว่าค่า  $y_{h+2} = \phi_0 + \phi_1 y_{h+2-1} + \dots + \phi_p y_{h+2-p} + \varepsilon_{h+2}$  ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมิเงื่อนไข (conditional expectation)

$$\hat{y}_h(2) =$$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ

$$e_h(2) =$$

และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าหนึ่งคาบท่างกับ

$$Var(e_h(2)) = Var(\phi_1 \varepsilon_{h+1} + \varepsilon_{h+2})$$

independent

$$= \phi_1^2 Var(\varepsilon_{h+1}) + Var(\varepsilon_{h+2})$$

$$= \phi_1^2 (\phi_1^2 + 1) \sigma_\varepsilon^2$$

เราจะสังเกตได้ว่า  $Var(e_h(2)) \geq Var(e_h(1))$

$\hat{y}_h(2) \pm 1.96 \cdot sd(e_h(2))$



## แบบจำลองม้วงเวอเรจ (Moving Average; $\overline{MA}(q)$ )

แบบจำลองนี้มีพื้นฐานมากจากแนวคิดที่ว่าอนุกรมเวลาเส้นตรงนั่ง (stationary) สามารถเขียนให้อยู่ในรูป infinite MA (linear combination von  $\varepsilon_t$ )

$$\hat{y}_t = \mu + c_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}$$

||| หมายเหตุ: อนุกรมต่อไปนี้ไม่สิ้นสุด

$\theta_{q+1} \varepsilon_{t-q-1} + \dots + \theta_q \varepsilon_t + \dots + \infty$

ไม่ควรนำ

แบบจำลองมูร์วิ่งเอเวอเรจอันดับ  $q$  และเขียนแทนด้วย  $MA(q)$  และแสดงได้ด้วยสมการ

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

L ·  $\varepsilon_t$ 
 $\frac{\text{out}}{\text{in}}$ 
 $L^q \cdot \varepsilon_t$ 
order  $q$

$$y_t - \mu = \sum_{j=0}^q \theta_j \varepsilon_{t-j} = \underline{\theta(L) \varepsilon_t} \quad (2.37)$$

$\theta(L) = (\underbrace{1 + \theta_1 L + \dots + \theta_q L^q}_{\theta(L)})$

โดยที่  $\theta_0 = 1$

## Moving Average Polynomial

# แบบจำลอง MA(1)

$$\text{Cov}(\varepsilon_t, \varepsilon_{t-j}) = 0$$

$$\varepsilon_t \sim \text{WN}(0, \sigma^2_\varepsilon)$$

สมมุติให้  $y_t$  เป็นอนุกรม  $MA(1)$  โดยที่  $\varepsilon_t$  มีคุณสมบัติเป็นไวท์นอร์ม

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} \quad (2.38)$$

ค่าคาดหมายของ  $y_t$ ,  $E(y_t)$ , เท่ากับ

$$\begin{aligned} \textcircled{1} \quad E(y_t) &= E(\mu + \epsilon_t + \theta_1 \epsilon_{t-1}) = E(\mu) + E(\epsilon_t) + \theta_1 E(\epsilon_{t-1}) \\ &= \mu + 0 + \theta_1 \cdot 0 = \mu. \end{aligned}$$

## ค่าความแปรปรวนของ $y_t$ ( $\gamma_0$ )

$$\begin{aligned}
 ② \underline{\gamma_0} = \text{Var}(y_t) &= E(\underline{y}_t - E(\underline{y}_t))^2 = E((\mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}) - \mu) \\
 &= E[(\varepsilon_t + \theta_1 \varepsilon_{t-1})^2] \\
 &= E[\varepsilon_t^2 + 2\varepsilon_t \theta_1 \varepsilon_{t-1} + \theta_1^2 \varepsilon_{t-1}^2] \\
 &= E(\varepsilon_t^2) + 2\theta_1 \underbrace{E(\varepsilon_t \varepsilon_{t-1})}_{\text{Cov}(\varepsilon_t \varepsilon_{t-1})} + \theta_1^2 \underbrace{E(\varepsilon_{t-1}^2)}_{\text{Var}(\varepsilon_{t-1})}
 \end{aligned}$$

$$\text{Var}(\hat{Y}_t) = \sigma_{\epsilon}^2 (1 + \theta_1^2)$$




## แบบจำลอง MA(1)

$$\text{MA}(1) \quad Y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

one-lag autocovariance

$$\begin{aligned} \gamma_1 &= Cov(y_t, y_{t-1}) = E((Y_t - E(Y_t))(Y_{t-1} - E(Y_{t-1}))) \\ &= E[(\cancel{\mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}} - \cancel{\mu})(\cancel{\mu + \varepsilon_{t-1} + \theta_1 \varepsilon_{t-2}} - \cancel{\mu})] \\ &= E[\varepsilon_t \varepsilon_{t-1} + \varepsilon_t \theta_1 \varepsilon_{t-2} + \theta_1^2 \varepsilon_{t-1}^2 + \theta_1^2 \varepsilon_{t-1} \varepsilon_{t-2}] \\ &= E(\varepsilon_t \varepsilon_{t-1}) + \theta_1 E(\varepsilon_t \varepsilon_{t-2}) + \theta_1 E(\varepsilon_{t-1}^2) + \theta_1^2 E(\varepsilon_{t-1} \varepsilon_{t-2}) \\ &\quad \text{Cov}(\varepsilon_t \varepsilon_{t-1}) \quad \text{Cov}(\varepsilon_t \varepsilon_{t-2}) \quad \sigma_\varepsilon^2 \quad \text{Cov}(\varepsilon_{t-1} \varepsilon_{t-2}) \\ &\quad \stackrel{!!}{0} \quad \stackrel{!!}{0} \quad \stackrel{!!}{\sigma_\varepsilon^2} \quad \stackrel{!!}{0} \end{aligned}$$

two-lag autocovariance

$$\begin{aligned} \gamma_2 &= Cov(y_t, y_{t-2}) = E((Y_t - E(Y_t))(Y_{t-2} - E(Y_{t-2}))) \\ &= E[(\cancel{\mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}} - \cancel{\mu})(\cancel{\mu + \varepsilon_{t-2} + \theta_1 \varepsilon_{t-3}} - \cancel{\mu})] \\ &= 0 \end{aligned}$$

$$\left| \begin{array}{l} \gamma_3 = 0, \gamma_4 = 0, \dots \\ \rho_3 = 0, \rho_4 = 0, \dots \end{array} \right.$$

$$\rho_2 = \frac{\gamma_2}{\gamma_0} = \frac{0}{(1+\theta_1)^2 \sigma_\varepsilon^2} = 0$$

# แบบจำลอง MA(1)

จากสมการข้างต้นจะเห็นได้ว่า  $Cov(y_t, y_{t-k}) = 0$  สำหรับ  $k \geq 2$  ในการนี้ที่  $y_t$  เป็น  $MA(1)$

**k-lag autocorrelation** เท่ากับ

$$\rho_k = \begin{cases} \frac{\theta_1}{1+\theta_1^2} & , k = 1 \\ 0 & , k > 1 \end{cases}$$

จะเห็นได้ว่า  $y_t$  มีสหสัมพันธ์กับ  $y_{t-1}$  แต่ไม่สัมพันธ์กับ  $y_{t-2}, \dots$  ซึ่งแตกต่างจาก  $AR(1)$

เราจะเห็นได้ว่าอนุกรมเวลา  $y_t$  ที่เป็นกระบวนการมูร์วิ่งเฉลี่ยวเร็วจะเป็นอนุกรมเวลาани้ง (stationary) เช่นเดียวกัน

แบบจำลอง MA(1) คือ  $y_t = \theta_1 y_{t-1} + \epsilon_t$

อนุกรมเวลาani้ง (stationary) หมายความว่า  $\theta_1$  ต้องอยู่ในช่วง  $-1 < \theta_1 < 1$

การคำนวณค่า MA(1) ได้ดังนี้

- 1)  $E(y_t) = \theta_1 E(y_{t-1}) + \epsilon_t = \theta_1 y_{t-1} + \epsilon_t$  (ต้อง  $\theta_1 < 1$ )
- 2)  $Var(y_t) = \theta_1^2 Var(y_{t-1}) + \sigma_\epsilon^2 = \theta_1^2 (1 + \theta_1^2) \sigma_\epsilon^2$  (ต้อง  $\theta_1 < 1$ )
- 3)  $Cov(y_t, y_{t-k}) = \theta_1^k \sigma_\epsilon^2$  (ต้อง  $\theta_1 < 1$ )

# ตัวอย่างข้อมูลที่เป็น MA(1)




$$\text{PACF vs MA(1)} \quad y_t \in \text{Augmented AR Model} \\ \text{MA(1)} \quad y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} \Rightarrow (\text{AR})$$

$$\text{Reinhard polynomial} \quad y_+ = (1 + \theta_1 L) e_+$$

$$1 + \theta_1 L F$$

$$1 + \theta_1 L^F$$

$$\frac{1}{1+\theta_1 L} = \frac{1}{1-(-\theta_1 L)} = 1 + (-\theta_1 L) + (-\theta_1 L)^2 + (-\theta_1 L)^3 + \dots$$



## Invertible process

$$\rho_1 = \frac{\theta_1}{1+\theta_1^2}$$

$$\left| \begin{array}{l} \rho_1 \\ \hline \end{array} \right|$$

ฟังก์ชันสหสัมพันธ์รวมในตัวของกระบวนการ  $MA(1)$  สองกระบวนการต่อไปนี้จะมีลักษณะที่เหมือนกัน

$$MA(1) \quad x_t = w_t + \left(\frac{1}{5}\right)^{\theta_1} w_t, \quad w_t \sim iidN(0, 25) \quad \rightarrow \rho_1 = \frac{1/5}{1+(1/5)^2}$$

และ

$$MA(1) \quad y_t = v_t + 5^{\theta_1} v_t, \quad v_t \sim iidN(0, 1) \quad \left. \begin{array}{l} \text{||} \text{ลาก} \text{||} \text{หา} \text{ด้วย} \\ \text{||} \text{ยก} \text{ตัว} \text{||} \text{ลง} \text{ให้} \text{เหลือ} \end{array} \right\}$$

เราต้องเลือกว่าจะใช้แบบจำลองไหน ซึ่งเราจะเลือกแบบจำลองที่สามารถเขียนแบบจำลองในรูปของ infinite AR representation โดยที่อนุกรมที่มีลักษณะดังกล่าวเราจะเรียกว่ากระบวนการที่หาตัวผูกพันได้ (invertible process)

เนื่องจาก  $MA(1)$  จะเป็นกระบวนการที่หาตัวผูกพันได้ คือ  $|\theta_1| < 1$



# แบบจำลอง $MA(2)$

กำหนดให้  $y_t$  เป็นกระบวนการ  $MA(2)$  ซึ่งสามารถแสดงได้ด้วยสมการ


$$\underline{y_t - \mu = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}}$$

$$E(\psi_t) = \mu$$

เมื่อพิจารณาค่าสหสัมพันธ์ในตัวของ  $MA(2)$  จะได้

$$\text{Var}(\psi_t) = \sigma^2 \left[ 1 + \theta_1^2 + \theta_2^2 \right]$$

ACF vs MA(2)



↓  
order MA ?

$$\rho_0 = \frac{\gamma_0}{\gamma_0} = 1$$


$$\rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{(\theta_1 + \theta_2 \theta_1)}{(1 + \theta_1^2 + \theta_2^2)}$$

$$\rho_2 = \frac{\gamma_2}{\gamma_0} = \frac{\theta_2}{(1 + \theta_1^2 + \theta_2^2)}$$

$$\rho_3 = \frac{\gamma_3}{\gamma_0} = 0$$

$$\rho_j = \frac{\gamma_j}{\gamma_0} = 0$$

PACF vs MA(2)



# แบบจำลอง $MA(q)$

แบบจำลอง  $MA(q)$  สามารถเขียนในรูปสมการดังนี้

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}, \quad \varepsilon_t \sim WN(0, \sigma^2)$$

แบบจำลอง  $MA(q)$  นิ่งและ ergodic ถ้าค่า  $\theta_1, \dots, \theta_q$  มีค่าจำกัด และสามารถหาตัวผกผันได้ถ้าค่าราก (roots) ของพหุนาม MA

$\theta(m) = 1 + \theta_1 m + \dots + \theta_q m^{t-q} = 0$  มีค่าสัมบูรณ์ (หรือค่าไม่ดุลล์ส) ของรากของพหุนามมากกว่า 1




# แบบจำลอง $MA(q)$

โภมเมนต์ของกระบวนการ  $MA(q)$  ได้ดังนี้

$$E(y_t) = \gamma_0 = \gamma_j =$$

และค่าสหสัมพันธ์ในตัวองจะเท่ากับ  
 $\rho_j = \frac{\gamma_j}{\gamma_0} =$

ในขณะที่ PACF จะมีค่าลดลงไป



# การประมาณค่าแบบจำลอง $MA(q)$

การประมาณค่า MLE เป็นวิธีการทั่วไปที่ใช้ในการประมาณค่าแบบจำลอง  $MA(q)$

ประมาณค่าแบบจำลอง  $MA(1)$  ซึ่งสามารถเขียนได้ดังนี้

$$y_t = \mu + \varepsilon_t + \theta \varepsilon_{t-1}$$

โดยที่  $\varepsilon_t \sim iidN(0, \sigma_\varepsilon^2)$  ในกรณีที่ conditional MLE เราจะสมมุติให้  $\varepsilon_0 = 0$  ดังนั้น  $y_1 = \mu + \varepsilon_1$

$$y_1 | \varepsilon_0 = 0 \sim N(\mu, \sigma_\varepsilon^2)$$

จากข้อมูลในภาพที่ 1 จะได้ว่า  $y_2 | y_1 = \mu + \varepsilon_2 + \theta \varepsilon_1$  และได้ฟังก์ชันความน่าจะเป็น

$$f_{y_2|y_1} = \frac{1}{\sqrt{2\pi\sigma_\varepsilon^2}} \exp \left[ \frac{-(y_2 - \mu - \theta \varepsilon_1)^2}{2\sigma_\varepsilon^2} \right]$$



# การประมาณค่าแบบจำลอง $MA(q)$

หากใช้กระบวนการเดียวกันไปเรื่อย เราจะสามารถหาค่า  $\varepsilon_t = y_t - \mu - \theta\varepsilon_{t-1}$  และสร้าง conditional likelihood function ได้

$$\begin{aligned}
 L(\mu, \theta, \sigma_\varepsilon^2) &= \prod_{t=2}^T f_{y_t|y_{t-1}} \\
 &= (2\pi\sigma_\varepsilon^2)^{-(T-2)/2} \exp \left[ \frac{\sum_{t=2}^T -\overbrace{(y_t - \mu - \theta\varepsilon_{t-1})^2}^{\varepsilon_t^2}}{2\sigma_\varepsilon^2} \right] \quad (2.50)
 \end{aligned}$$

สมการ (2.50) เราไม่สามารถหาตัวประมาณค่าได้ด้วยการวิเคราะห์อนุพัณฑ์ เช่นในกรณี  $AR$  ในกรณีนี้เราจำเป็นต้องใช้วิธีการทางตัวเลขด้วยคอมพิวเตอร์เพื่อหาค่า  $\hat{\theta}$  ที่ทำให้  $L(\mu, \theta, \sigma_\varepsilon^2)$  มีค่าสูงที่สุด




## ตัวอย่างที่ 2.6

ในตัวอย่างนี้เราจะพิจารณาผล ได้ตอบแทนรายเดือนของการลงทุนในตลาดหลักทรัพย์แห่งประเทศไทย โดยใช้ข้อมูลราคาปิดรายเดือนตั้งแต่ เมษายน 2518 ถึงเดือนพฤษจิกายน 2555

Figure: ACF และ PACF ของผลได้ตوبแทนรายเดือนจาก SET

① (ມີນຳໃຈໝາຍເນ  
 ບໍລິສັດອົບປະ  
 ເກມໃຫຍ່?  
 ມີ ACF ຂໍ  
 lag 1, 2 ສະໜັບ  
 ທີ່ມີມີ່ລວມ 0  
 → ລົງຈາກແພື່ນ  
 AR MA



## ตัวอย่างที่ 2.6

แบบจำลองที่เหมาะสมน่าจะเป็น  $\underline{\underline{MA(2)}}$  ซึ่งประมาณค่าได้ด้วยคำสั่ง arima โดยกำหนดอันดับเป็น  $c(0,0,2)$

$\downarrow$   $V_{0x}$   $P \rightarrow S$  AR  $\downarrow$   $q V_{0x} MA$

```
1 > m1<-arima(ret, order=c(0,0,2))
2 > m1
3 Call:
4 arima(x = ret, order = c(0, 0, 2))
5
6 Coefficients: ^ / μ
7          ma1    ma2  intercept
8          0.0886  0.1001     0.0057
9 s.e.    0.0469  0.0487     0.0046
10
11 sigma^2 estimated as 0.006795:  log likelihood = 485.64,  aic = -963.28
```



## ตัวอย่างที่ 2.6

เราสามารถพิจารณาความพอดีของแบบจำลอง  $m1$  ได้ด้วยการทดสอบ L-B สำหรับ residuals ดังคำสั่งต่อไปนี้


```

1 > Box.test(m1$residuals, lag=12, type="Ljung")
2   ^Box-Ljung test
3 data: m1$residuals
4 X-squared = 13.6075, df = 12, p-value = 0.3265
5 > pv=1-pchisq(13.6075,12-2)
6 > pv
7 [1] 0.1916591

```

$\chi^2 = 13.6075$  เท่ากับ  $cV \chi^2$   $df = m - q = 12 - 2 = 10$   
 พบว่า  $\chi^2 < cV \chi^2$  ไม่สามารถปฏิเสธ  $H_0: \varepsilon_t$  ไม่เป็น MA(2) ให้ผลลัพธ์ ret.

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}$$



# การพยากรณ์ไปข้างหน้า 1 คาบ

**พิจารณาแบบจำลอง  $MA(1)$ :**  $y_{h+1} = \mu + \varepsilon_{h+1} + \theta_1 \varepsilon_h$  ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข (conditional expectation)

$$\hat{y}_h(1) = E(y_{h+1} | F_h) = E(\mu + \varepsilon_{h+1} + \theta_1 \varepsilon_h | F_h) = \mu + E(\varepsilon_{h+1} | F_h) + \theta_1 \varepsilon_h$$

ดูที่, - ดูผลรวม

$$\text{และค่าผิดพลาดจากการพยากรณ์เท่ากับ } e_h(1) = y_{h+1} - \hat{y}_h(1) \\ = 0 + \varepsilon_{h+1} + 0 = \varepsilon_{h+1}$$

และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าหนึ่งคาบเท่ากับ  
 $Var(e_h(1)) = Var(\varepsilon_{h+1}) = \sigma_\varepsilon^2$

ในทางปฏิบัติค่า  $\varepsilon_h$  จะสามารถคำนวณได้สองวิธีคือ

- สมมุติให้  $\varepsilon_0 = 0$

$$y_1 = \mu + \varepsilon_1 + \theta_1 \varepsilon_0 \Rightarrow \varepsilon_1 = y_1 - \mu$$

$$y_2 = \mu + \varepsilon_2 + \theta_1 \varepsilon_1 \quad \varepsilon_2 =$$

- หรือใช้ค่า  $\hat{\varepsilon}_h$  ที่เป็นค่า residual จากการประมาณค่า  $MA(1)$

$$95\% \text{ C.I. } \hat{y}_h(1) \pm 1.96 \text{ Sd}(e_h(1))$$



## การพยากรณ์ไปข้างหน้า 2 คาบ

พิจารณา  $y_{h+2} = \mu + \varepsilon_{h+2} + \theta_1 \varepsilon_{h+1}$  ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข

$$\hat{y}_h(2) =$$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ  $e_h(2) =$

และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าสองคาบเท่ากับ  
 $Var(e_h(2)) =$

