

# Autoregressive Moving Average; $ARMA(p, q)$ )

แบบจำลองที่มีหัวใจส่วนประกอบของ AR และ MA ซึ่งหาก  $y_t$  เป็นกระบวนการ  
การที่เรียกว่าแบบจำลองออโตรีเกรสซีฟมูวิ่งเอเวอเรจอันดับ  $(p, q)$  หรือเรียก  
ย่อๆว่า อารมา  $ARMA(p, q)$  ถ้า  $y_t$  มีค่าเฉลี่ยไม่เท่ากับศูนย์ เราจะสามารถอธิบาย  
 $y_t$  ได้ด้วย (อนุพัฒนา ป. 1 ใน 10 ตอน)  $\text{AR part}$  (อนุพัฒนา ป. 4 ใน 10 ตอน)  $\text{MA part}$

$$\textcircled{1} \quad y_t = \underbrace{\phi_1 y_{t-1} + \dots + \phi_p y_{t-p}}_{\text{แบบจำลอง AR}} + \varepsilon_t + \underbrace{\theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}}_{\text{แบบจำลอง MA}} \quad (2.53)$$

หากเรากำหนดให้  $\alpha = \mu(1 - \phi_1 - \dots - \phi_p)$  และสามารถเขียนแบบจำลอง  
สำหรับ  $y_t$  ได้เป็น

$$\textcircled{2} \quad \begin{matrix} \text{แบบจำลอง} \\ y_t = \underline{\alpha} + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} \end{matrix} \quad (2.54)$$

$\varepsilon_t \sim WN(0, \sigma_\varepsilon^2)$

คุณลักษณะ: vs  $ARMA(p, q)$ ?

# Autoregressive Moving Average; $ARMA(p, q)$ )

เราสามารถเขียนสมการอารมาได้ในรูป AR และ MA polynomials ได้ดังนี้

$$\underline{\phi(L)y_t = \theta(L)\varepsilon_t}$$

โดยที่  $\phi(L) = 1 - \phi_1L - \dots - \phi_p L^p$  และ  $\theta(L) = 1 + \theta_1L + \dots + \theta_q L^q$

พิจารณาคุณสมบัติของแบบจำลองอารมาได้ด้วยการพิจารณา  $ARMA(1, 1)$

$$y_t = \phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1} \quad (2.55)$$

โดยที่  $\varepsilon_t \sim iidN(0, \sigma^2)$

กุณสมบัติ

1)  $E(y_t)$

2)  $\text{var}(y_t)$

3)  $\text{Corr}(y_t, y_{t-k})$

$$E(y_t) = E(\phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1})$$

$$= \phi E(y_{t-1}) + E(\varepsilon_t) + \theta E(\varepsilon_{t-1})$$

กุณสมบัติ  
stationary  $E(y_t)$

$$= 0$$

①  $E(y_t) = 0$

$$(y_t - \mu) = \phi(y_{t-1} - \mu) + \varepsilon_t + \theta \varepsilon_{t-1}$$

(2.55)

$$y_t = \alpha + \beta y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}$$

$$E(y_t) = \frac{\alpha}{1-\phi} = \mu$$



คุณสมบัติ ARMA(1,1)  $\Rightarrow$   $y_t = \phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}$

เราใช้ความสัมพันธ์ต่อไปนี้

$$\begin{aligned} E(\varepsilon_t y_t) &= E[\varepsilon_t (\phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1})] \\ &= \phi E(\varepsilon_t y_{t-1}) + E(\varepsilon_t^2) + \theta E(\varepsilon_t \varepsilon_{t-1}) \end{aligned}$$

$$(1 - \phi L)y_t = (1 + \theta L)\varepsilon_t$$

$$\boxed{\text{MA}(q)} \quad y_t = \frac{(1 + \theta L)}{1 - \phi L} \varepsilon_t$$

$$\begin{aligned} E(\varepsilon_t y_t) &= \phi E(\varepsilon_t y_{t-1}) + \sigma_\varepsilon^2 + \theta E(\varepsilon_t \varepsilon_{t-1}) \\ &= \phi E(\varepsilon_{t-1} y_{t-1}) + \sigma_\varepsilon^2 + \theta E(\varepsilon_{t-1} \varepsilon_t) \\ &= \phi^2 E(\varepsilon_{t-2} y_{t-2}) + \sigma_\varepsilon^2 + \theta^2 E(\varepsilon_{t-2} \varepsilon_{t-1}) \\ &\vdots \\ &= \sigma_\varepsilon^2 \quad \text{for } t \geq 1 \end{aligned}$$

$$\text{Var}(\varepsilon_t) = \sigma_\varepsilon^2$$

$$\text{Cov}(\varepsilon_t, \varepsilon_{t-1}) = 0$$

~~$E(y_t)$~~

$$E(\varepsilon_{t-1} y_t) = [\phi + \theta] \sigma_\varepsilon^2$$



# คุณสมบัติ ARMA(1,1)

คุณสมบัติของ ARMA(1,1) จะได้

$$\text{Var}(\gamma_1) = \gamma_0 = E((\gamma_t - E(\gamma_t))^2) = E(\gamma_t^2) = E(\gamma_t \cdot \gamma_t)$$

$$\gamma_0 = E(\gamma_t (\phi \gamma_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1})) = \phi E(\gamma_t \gamma_{t-1}) + E(\gamma_t \varepsilon_t) + \theta E(\gamma_t \varepsilon_{t-1}) = \phi \gamma_1 + \theta \sigma_\varepsilon^2 (\phi + \theta) \sigma_\varepsilon^2 \quad \text{--- (1)}$$

$$\gamma_1 = E[(\gamma_t - E(\gamma_t))(\gamma_{t-1} - E(\gamma_{t-1}))] = E[\gamma_t \cdot \gamma_{t-1}]$$

$$= E[(\phi \gamma_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}) \gamma_{t-1}]$$

$$\gamma_1 = \phi E(\gamma_{t-1}^2) + E(\varepsilon_t \gamma_{t-1}) + \theta E(\varepsilon_{t-1} \gamma_{t-1}) = \phi \gamma_0 + \theta \sigma_\varepsilon^2 \quad \text{--- (2)}$$

จาก (1) & (2)

$$\gamma_2 = E[\gamma_t \gamma_{t-2}] = E[(\phi \gamma_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}) \gamma_{t-2}] = \phi E[\gamma_{t-1} \gamma_{t-2}] + E[\varepsilon_t \gamma_{t-2}] + \theta E[\varepsilon_{t-1} \gamma_{t-2}]$$

$$\gamma_3 = E[\gamma_t \gamma_{t-3}] = \phi \gamma_2$$

$$\gamma_j = \phi \gamma_{j-1} \quad \text{สำหรับ } j > 2$$

# คุณสมบัติ ARMA(1,1)

กรณีที่  $j \geq 2$  จากสมการที่ (2.56) และ (2.57) เราจะได้

$$Var(y_t) = \gamma_0 = \frac{[1 + 2\phi\theta + \theta^2]}{1 - \phi^2}$$



แทนด้วยสูตร ② ที่ได้  $\underline{\gamma_1}$

ACF ณ ค่าลำ  $j$  โดยที่  $j \geq 2$  ได้

$$\rho_j = \phi\rho_{j-1}$$

$$\begin{aligned} \rho_1 &= \frac{\gamma_1}{\gamma_0} \\ \text{ดังนั้น } \gamma_2 &= \phi\gamma_1 \\ \rho_2 &= \phi\rho_1 \\ \rho_j &= \phi\rho_{j-1} \end{aligned}$$

กรณีที่  $j \geq 2$  จะเห็นได้ว่า ACF มีค่าที่ลดลงเรื่อยๆ ด้วยอัตราแบบ exponential)



คุณสมบัติ ARMA(1,1)  $\rightarrow$  Stationary มีอันดับเป็นอนันต์ ?

แบบจำลอง ARMA(1,1) ในรูปของมูลวิ่งเออเวอเรจที่มีอันดับเป็นอนันต์ (infinite MA) ได้เป็น

$$y_t = \varepsilon_t + (\phi - \theta) \sum_{j=1}^{\infty} \phi^{j-1} \varepsilon_{t-j}$$

หรือ  $\psi_j = (\phi - \theta) \phi^{j-1}$  จะเห็นได้ว่าเงื่อนไขที่จะทำให้กระบวนการนี้เป็นกระบวนการนิ่งคือ  $|\phi| < 1$

Stationary




AR(1)



## สรุปคุณสมบัติของ ARMA( $p, q$ )

มีการจำแนก: AR part  
 $\phi(L) \gamma_t = \theta(L) \xi_t$

- ✓ ■ กระบวนการ  $ARMA(p, q)$  จะ stationary และ ergodic ถ้าค่าสัมบูรณ์ของค่ารากของพหุนามออโตรีเกรสซีฟ  $\phi(m) = 0$  มีค่ามากกว่าหนึ่ง
- และสามารถหาค่าพกผันได้ถ้ารากของพหุนามมุ้วงเออเรจ  $\theta(m) = 0$  มีค่ามากกว่าหนึ่ง
- ✗ ■ พหุนาม AR และ MA ไม่มีตัวประกอบร่วม รูปที่วิปของ ACF ของกระบวนการ  $ARMA(p, q)$  ค่อนข้างยุ่งยาก โดยสรุปแล้วที่ ACF และ PACF จะค่อยๆลดลงเรื่อยแบบเลขชี้กำลัง (exponential)



ค่าคงที่ของค่าปั่นหุ้น (ค่าคงที่ของค่าปั่นหุ้น)

ARMA (2,1)

$$(1 - 0.8L - 0.15L^2)\gamma_t = (1 - 0.5L)\xi_t$$

~~$$(1 - 0.5L)(1 + 0.3L)\gamma_t = (1 - 0.5L)\xi_t$$~~

$$AR(1) - (1 + 0.3L)\gamma_t = \xi_t$$



# การประมาณค่าสมการแบบจำลอง ARMA

เราสามารถประมาณค่าแบบจำลอง  $ARMA(p, q)$  ได้ด้วยวิธีการค่าความควรจะเป็นสูงที่สุด (MLE)

- พังก์ชันที่แน่นอน (exact log-likelihood) นั้นมีรูปแบบที่ค่อนข้างซับซ้อน นอกจากนี้จุดเริ่มต้นของข้อมูลในกรณี exact likelihood จะใช้คุณสมบัติของการแยกเงงที่นิ่งเพื่อสร้างพังก์ชันค่าควรจะเป็นของค่า  $y_t$   $p$  ค่าแรก และ  $\varepsilon_t$   $q$  ค่าแรก
- conditional likelihood จะสมมุติให้  $y_t$   $p$  ค่าแรก และ  $\varepsilon_t$   $q$  ค่าแรกเท่ากับศูนย์กรณีที่จำนวนตัวอย่างมีจำนวนเข้าใกล้อนันต์ค่าประมาณจากสองวิธีจะมีค่าใกล้เคียงกัน แต่จะแตกต่างกันในกรณีตัวอย่างมีจำนวนน้อย



# การประมาณค่าสมการแบบจำลอง ARMA

ทดสอบความเพียงพอขององแบบจำลอง ได้เช่นเดียวกับในกรณีของแบบจำลอง  $AR$  และ  $MA$  โดยที่ตัวสถิติ  $\underline{Q(m)} \sim \chi^2_{m-p-q}$  และเราจะปฏิเสธสมมุติฐานหลักถ้า  $Q(m)$  มีค่ามากกว่าค่าอนุที่  $(1 - \alpha)$  ของ  $\chi^2_{m-p-q}$

ก่อนที่เราจะประมาณค่าแบบจำลอง  $ARMA(p, q)$  สำหรับอนุกรมเวลา  $y_t$  ใดๆ เราจะเป็นต้องระบุลำดับของ  $AR(p)$  และ  $MA(q)$  เสียก่อน



# เกณฑ์การเลือกแบบจำลอง (Model Selection Criteria)

เราสามารถใช้การสังเกต ACF ของตัวอย่าง ในกรณีของ MA หรือ PACF ของตัวอย่าง ในกรณีของ AR


Table: สรุปลักษณะของ ACF และ PACF สำหรับแบบจำลอง ARMA

	$AR(p)$	$MA(q)$	$ARMA(p,q)$ .
ACF	ค่อยๆลดลง	ค่าเท่ากับศูนย์ หลังจากช่วงล่าที่ $q$	ค่อยๆลดลง
PACF	เท่ากับศูนย์ หลังจากช่วงล่าที่ $p$	ค่อยๆลดลง	ค่อยๆลดลง

↑  
ต่อไป  
มาก order  
AR, MA
↑  
P  
15M วัน
↑  
น้ำกรองไฟ  
sample ACF  
↑ PACF

## เกณฑ์การเลือกแบบจำลอง (Model Selection Criteria)

อีกทางเลือกหนึ่งเรายสามารถใช้เกณฑ์การเลือกแบบจำลอง  
แนวคิดคือการประมาณค่าแบบจำลอง  $ARMA(p, q)$  สำหรับค่าอันดับ  $p$  และ  $q$  ต่างๆที่น้อยกว่าค่าหนึ่งที่เรากำหนดไว้  $p_{max}$  และ  $q_{max}$  และเลือกค่า  $p$  และ  $q$  ที่ทำให้ค่า **เกณฑ์การเลือกต่ำที่สุด** โดยที่เกณฑ์การเลือกจะอยู่ในรูป



$MSC(p, q) =$

$$) = \ln(\tilde{\sigma}^2(p, q)) + c_T \varphi(p, q)$$

↑  
Variance vs. error

↑ Variance  
↑ (Measurement error)  
↓ Measurement error  
↓ Variance  $\downarrow$   
 $p, q \uparrow$

↑  
Penalty  
↑  
Pillai's criterion

## เกณฑ์การเลือกแบบจำลอง (Model Selection Criteria)

โดยที่แบบเกณฑ์ที่เป็นที่นิยมสามเกณฑ์ได้แก่ Akaike (AIC) In 10, Schwarz-Bayesian (BIC) Bayes 10 และ Hannan-Quinn (HQIC)

- ✓  $\underline{AIC}(p, q) = \ln(\tilde{\sigma}^2(p, q)) + \frac{2}{T}(p + q)$
- ✓  $BIC(p, q) = \ln(\tilde{\sigma}^2(p, q)) + \frac{\ln T}{T}(p + q)$
- $HQIC(p, q) = \ln(\tilde{\sigma}^2(p, q)) + \frac{2 \ln(\ln T)}{T}(p + q)$

กรณี T ใหญ่ เกณฑ์ AIC จะเลือกอันดับที่มากกว่าที่ควรจะเป็น ในขณะที่เกณฑ์ BIC และ HQIC เลือกค่าที่ consistent  $P_{\text{ตัวอย่าง}} \rightarrow P_{\text{จริง}}, q_{\text{ตัวอย่าง}} \rightarrow q_{\text{จริง}}$   
อย่างไรก็ตามใน T ขนาดเล็กเกณฑ์ทั้งสามจะให้ค่าที่ไม่แตกต่าง  
 $\rightarrow$  มาก-น้อย  $p, q$  เนื่องจาก



# ตัวอย่างที่ 2.7

log return on forex B/\$ ปี 1998 ถึง 2012

Figure: ACF และ PACF ของผลได้ต่อเนื่องรายวันจากการซื้อขายเงินดอลลาร์สหรัฐ

① ก่อให้เกิดสาเหตุ?


เวลา ACF เก็บมา

มีความน่าจะเป็น


ก่อให้เกิด ACF หักลง

ก่อให้เกิด ACF หักขึ้น

ACF



PACF



# ตัวอย่างที่ 2.7

↑ install

อย่างไรก็ตาม package "forecast" มีคำสั่ง auto.arima(series, arguments) เลือก optimal p & q

↑ Model selection criteria (aic/bic)  
เลือกแบบช้าๆ

```

1 > library(forecast)
2 > auto.arima(ret, d=0, D=0, max.p=6, max.q=6, ic=c("aic"), stepwise=FALSE, trace=TRUE)
3
4 ARIMA(0,0,0) with zero mean : -27687.05
5 ARIMA(0,0,0) with non-zero mean : -27686.59
6 [omitted]
7 ARIMA(5,0,0) with zero mean : -27850.55
8 ARIMA(5,0,0) with non-zero mean : -27851.11
9
10 Series: ret
11 ARIMA(4,0,1) with non-zero mean ARMA(4,1)
12
13 Coefficients:
14      ar1      ar2      ar3      ar4
15     -0.5876   -0.0238   -0.0066   -0.0227
16 s.e.  0.2641    0.0196    0.0208    0.0199
17      ma1  intercept
18     0.5981    -1e-04
19 s.e.  0.2636    1e-04
20
21 sigma^2 estimated as 3.432e-05: log likelihood=13849.44
22 AIC=-27684.88 AICc=-27684.85 BIC=-27641.33

```

m1 ← arima()  
ผิดพลาด ? ตรวจสอบ m1\$residuals ให้ WN ?  
✓ ถูก ตรวจสอบ ⇒ forecast

# การเขียนกระบวนการอาร์มา(ARMA)ในสามรูปแบบ

จากแบบจำลองที่เราอธิบาย  $y_t$  ด้วยแบบจำลอง ARMA ในรูปแบบพหุนาม

$$\textcircled{1} \quad \phi(L)y_t = \theta(L)\varepsilon_t$$

โดยที่  $\phi(L) = 1 - \sum_{i=1}^p \phi_i L^i$  และ  $\theta(L) = 1 + \sum_{i=1}^q \theta_i L^i$  เราสามารถแสดง  $y_t$   
โดยใช้

$$\textcircled{2} \quad \text{MA}(\infty) \quad \frac{\theta(L)}{\phi(L)} = 1 + \psi_1 L + \psi_2 L + \dots = \psi(L) \quad (2.63)$$

และ

$$\textcircled{3} \quad \frac{\phi(L)}{\theta(L)} = 1 - \pi_1 L - \pi_2 L - \dots = \pi(L) \quad (2.64)$$

AR( $\infty$ )



# การพยากรณ์ (forecasting)

เราสามารถแสดงแบบจำลอง  $ARMA(p, q)$  ได้สามรูปแบบ ซึ่งเราสามารถใช้รูปแบบใดรูปแบบหนึ่งในการสร้างการพยากรณ์

กรณีใช้รูปแบบ  $ARMA$

$$\boxed{h \rightarrow 1}$$

$ARMA(1,1)$

$$y_t = \phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}$$

$$y_{t+1} = \phi y_t + \varepsilon_{t+1} + \theta \varepsilon_t$$

$$\hat{y}_h(1) = E(y_{h+1} | F_h) = E(\phi y_h + \varepsilon_{h+1} + \theta \varepsilon_h | F_h)$$

$$= \phi y_h + \theta \varepsilon_h$$



# การพยากรณ์ (forecasting)

กรณีใช้รูปแบบออโตรีเกรสซีฟอนั่นต์

$$\hat{y}_h(1)$$



# การพยากรณ์ (forecasting)

กรณีรูปแบบมุ่งวิ่งอเวอเรจอนันต์

$$\hat{y}_h(1)$$



## Nonstationary series

อนุกรมเวลาทางเศรษฐกิจจำนวนมากมีพฤติกรรมที่มีแนวโน้ม(trend)หรือมีลักษณะไม่นิ่ง (non-stationary) ตัวอย่างเช่น ราคางานทั่วไป อัตราแลกเปลี่ยน GDP *Trend* *Nonstationary (Random Walk)*

โดยที่กระบวนการที่มีลักษณะแนวโน้มอาจจะแบ่งได้เป็น (1) random walk with drift (2) trend stationary

ஸ்டாஷனேம்  
Stationary

# รุ่นที่ 1 Random walk with drift

## Difference-stationary


กำหนดให้  $y_t$  เป็น random walk with drift

$$y_t = \mu + y_{t-1} + \varepsilon_t \quad (2.68)$$

*drift*

Random walk

$$y_t = y_{t-1} + \varepsilon_t$$



โดย  $\varepsilon_t \sim WN(0, \sigma^2)$  และเราเรียก  $\mu$  ว่าตัวสร้างแนวโน้ม (drift) หากเราสมมุติให้  $y_0 = 0$  จะได้

$$y_1 = \mu + y_0 + \varepsilon_1$$

$$\begin{aligned} y_2 &= \mu + y_1 + \varepsilon_2 = \mu + (\mu + y_0 + \varepsilon_1) + \varepsilon_2 \\ &= 2\mu + \varepsilon_1 + \varepsilon_2 \end{aligned}$$

$$y_t = t\mu + \varepsilon_1 + \varepsilon_2 + \dots + \varepsilon_t$$

Random walk  
with drift  
เป็น Nonstationary

↑ กระบวนการแนวเดินแบบสุ่มแบบมีแนวโน้มจะมีค่าคาดหมาย ( $E(y_t)$ ) เท่ากับ  $E(y_t) = E(t\mu + \varepsilon_1 + \varepsilon_2 + \dots + \varepsilon_t) = t\mu + E(\varepsilon_1) + \dots + E(\varepsilon_t)$  ค่าความแปรปรวน ( $Var(y_t)$ ) เท่ากับ  $Var(y_t) = Var(\mu + \varepsilon_1 + \varepsilon_2 + \dots + \varepsilon_t) = t \cdot \sigma_\varepsilon^2$  ตามที่

↑ แนวโน้ม ( $y_t$ )  
Stationary  
diff. ของ  $y_t$   
↑ แนวโน้ม ( $y_t$ )

# รากหนึ่ง และ รากสองนี่เป็นต่อๆ กัน (Deterministic Trend)

## Trend-stationary

กำหนดให้  $z_t$  เป็น trend-stationary

$$z_t = \beta_0 + \beta_1 t + v_t \quad (2.70)$$

โดยที่  $v_t$  เป็นอนุกรมนิ่งโดยชั้น AR(1)

ค่าคาดหมายของ ( $E(z_t)$ ) จะเท่ากับ


ค่าความแปรปรวน ( $Var(z_t)$ ) จะเท่ากับ

$$E(z_t) = E(\beta_0 + \beta_1 t + v_t) = \underbrace{\beta_0 + \beta_1 t}_{\text{Trend}} + \boxed{E(v_t)}$$

$\rightarrow$  Nonstationary

$z_t$  ที่ Nonstationary

การดำเนินต่อไปจะมีผลลัพธ์ดังนี้  $\rightarrow$  Nonstationary  $\rightarrow$  Stationary



from  
stationary

AR/MA  
ARnA



# Difference- and Trend- stationary


Figure: ข้อมูลจำลองของกระบวนการแนวเดินแบบสุ่มแบบมีแนวโน้มและกระบวนการที่นิ่งหลังจากขัดแนวโน้ม  
การลบ trend หรือ detrend

1. กรณี

$$y_t = \beta_0 + \beta_1 t + \varepsilon_t$$

$$\hat{y}_t = \hat{\beta}_0 + \hat{\beta}_1 t \rightarrow \text{Trend}$$

2.  $\frac{y_t - \hat{y}_t}{\text{detrend}}$  กรณี



กระบวนการที่นิ่งหลังจากขัดแนวโน้ม  
การลบ trend หรือ detrend

$$y_t = y_{t-1} + \varepsilon_t$$

$$\underbrace{y_t - y_{t-1}}_{\text{first difference}} = \varepsilon_t$$

1970 S กรณี GDP  
 กรณี deterministic  
 trend  $\Rightarrow$  Random walk

ms detrend R.W. ใจหาย  
 ให้กับ series ไม่สามารถ  
 stationary

การลบ trend ของ series difference

กระบวนการทั้งสองที่ได้ยกตัวอย่างมา เป็นกระบวนการที่ไม่นิ่ง (non-stationary) แต่มีคุณลักษณะที่แตกต่างกันดังนี้ วิธีการที่ใช้ในทำให้อนุกรมนิ่งจึงแตกต่างกัน



# Difference-stationary

วิธีการการทำ first difference  $\Delta y_t = y_t - y_{t-1}$  เราจะเรียกว่า second difference  
 $\Delta^2 y_t = \Delta y_t - \Delta y_{t-1}$

$$\begin{aligned} y_t &= \mu + y_{t-1} + \epsilon_t \\ y_t - y_{t-1} &= \mu + \epsilon_t \\ \Delta y_t &= \mu + \epsilon_t \end{aligned}$$

$E(\Delta y_t) = \mu$   
 $\text{Var}(\Delta y_t) = \sigma_\epsilon^2$

วิธีการดำเนินการผลต่างจะเหมาะกับอนุกรรมเวลาที่เป็นกระบวนการนิ่งหลังจากดำเนินการผลต่าง โดยที่หากอนุกรรมเวลา  $y_t$  เป็น stationary หลังจากการทำ first difference เราจะเรียกอนุกรรมเวลา  $y_t$  Integrated of order 1 หรือ  $I(1)$  ในขณะที่อนุกรรมเวลาที่นิ่งจะคือ  $I(0)$

วิธีการที่สองเหมาะกับอนุกรรมที่เป็นกระบวนการนิ่งหลังจากการกำจัดแนวโน้ม

- $y_t \sim I(1)$  แล้ว  $\Delta y_t$  เป็น stationary
- ก็  $\Delta y_t$  ยังเป็น Nonstationary  $\Rightarrow \Delta(\Delta y_t) = \Delta^2 y_t$  IID stationary  
หมายเหตุ  $y_t \sim I(2)$
- ถ้า  $y_t$  IID stationary อุบัติ  $I(0)$



# การทดสอบยูนิทรูทในรูป AR(1)

เครื่องมือสำคัญที่ใช้ในการระบุว่าควรจะใช้วิธีการใดในการกำหนดแนวโน้มคือการทดสอบยูนิทรูท (unit root test)

สมมติว่าเราพิจารณาแบบจำลอง AR(1) ซึ่งเขียนได้ดังนี้

R.W. เป็น

กรณีเด่นๆ  
 $AR(1) \Rightarrow \phi = 1$

$y_t = \phi y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim WN(0, \sigma^2)$  (2.71)

$\phi \leftarrow 1$

$\rightarrow R.W. (Unit root)$

การทดสอบยูนิทรูทมีพื้นฐานจากการทดสอบสมมุติฐานหลักว่าหาก  $\phi = 1$  และ  $y_t$  จะเป็น unit root และมีลักษณะเป็น random walk

ดังนั้นสมมุติฐานที่เราต้องการทดสอบคือ

$\phi > 1 \quad y_t \text{ Nonstationary}$

$H_0 : \phi = 1$

$\phi < 1 \quad y_t \text{ stationary}$

$H_1 : \phi < 1$

$$t = \frac{\phi - 1}{\text{se}(\phi)}$$

หมายเหตุ: หาก  $\phi > 1$  ให้  $y_t$  คือ  $y_t = y_{t-1} + \varepsilon_t$   
Random walk [  $y_t = y_{t-1} + \varepsilon_t$  ]  
กรณี AR(1)  
กรณี AR(1)  
 $y_t = \phi y_{t-1} + \varepsilon_t$   
กรณี  $\phi = 1$

$$(1 - \phi L) y_t = \varepsilon_t$$

$$1 - \phi Z = 0$$

$$Z = 1/\phi = 1$$

Z (Root of Polynomial)  
กรณี  $\phi = 1$

$$Z = 1$$

$\downarrow$   
Unit root

Nonstationary  
( $y_t$  R.W.) ( $y_t \sim I(1)$ )

( $y_t$  Not R.W.) ( $y_t \sim I(0)$ )


Stationary.



# การทดสอบยูนิทรูทในรูป AR(1)

เราสามารถประมาณค่าสมการ (2.71) ด้วย OLS และใช้ตัวสถิติที่เรียกว่าตัวสถิติ Dickey-Fuller  $t$  ซึ่งคำนวณได้โดย

$$t_{\phi=1} = \frac{\hat{\phi} - 1}{se(\hat{\phi})}$$



การทดสอบนี้เป็นการทดสอบทางเดียวทางซ้าย คือเราจะปฏิเสธสมมุติฐานหลักถ้าค่าตัวสถิติน้อยกว่าค่าวิกฤติ และสรุปว่าอนุกรรมเวลาเป็นอนุกรรมนิ่ง หากเราไม่สามารถปฏิเสธสมมุติฐานหลักได้แสดงว่าอนุกรรมดังกล่าวเป็นยูนิทรูท

- Dickey-Fuller พบรากันต์ + หาขนาด分布 ไม่ได้ dist เมื่อ t

(เมื่อ t มาก มากตาม + มาก)

$\Rightarrow$  ขนาด C.V. ไหน [Dickey-Fuller + distribution]

$$\text{กน } y_{t+1} \xrightarrow{\text{หูชูฟัน}} y_t = \phi y_t - 1 + a_t \quad \Rightarrow \quad H_0: \phi = 1 \xrightarrow{\text{ตัวอย่าง}} = 0?$$

$$y_t - y_{t-1} = (\phi - 1) y_{t-1} + a_t$$



# การทดสอบยูนิทรูทในรูป AR(1)

สมการ (2.71) ที่เราใช้ในการทดสอบยูนิทรูทยังสามารถเขียนในรูป

Reg

$$\Delta y_t = \pi y_{t-1} + \varepsilon_t, \quad (2.72)$$

$$H_0: \phi = 1$$

โดยที่  $\pi = (\phi - 1)$  ซึ่งในที่นี้การทดสอบยูนิทรูทจะเป็นการทดสอบ  $H_0: \pi = 0$  และ  $H_1: \pi < 0 \Leftarrow [H_1: \phi < 1]$

ตัวสถิติที่ใช้ในการทดสอบยูนิทรูทจะมีการแจกแจงที่ไม่เป็นมาตรฐานและไม่เป็นการแจกแจงแบบปกติเมื่อข้อมูลขนาดใหญ่เหมือนในการทดสอบอื่นๆ ที่เราเคยพูดมา Phillips (1987) ได้พิสูจน์ว่าหาก  $y_t$  เป็นยูนิทรูท  $t_{\phi=1}$  และ  $T(\hat{\phi} - 1)$  จะมีการแจกแจงแบบ Dickey-Fuller t และ Dickey-Fuller normalized bias

$$DF \quad t = \frac{\hat{\pi} - 0}{\text{se}(\hat{\pi})} \sim DF \text{ t distribution} \quad (\text{ที่อยู่ } t \text{ dist หลัง})$$



## การแจกแจง Dickey-Fuller

จุดเด่นของรูปแบบ  
DF + dist  
 1) ไม่มี intercept (No constant)  
 2) มี intercept (Constant)  
 3) Trend

ตารางสำหรับการแจกแจง Dickey-Fuller สามารถใช้คำสั่ง **adfTable** ใน **library(fUnitRoots)** โดยสมการทดสอบมีได้ 3 รูปแบบ

`trend=c("nc")` - no constant เช่นในสมการ (2.72) (ในหัวข้ออยู่อยู่ต่อไปจะพิจารณากรณีมีพจน์ค่าคงที่ และจุดตัด) และแสดงการแจงของ  $t$  โดยระบุ `statistics=c("t")` ส่วนการแจกแจง Dickey-Fuller normalized bias จะต้องระบุว่า `statistics=c("n")`

No constant

$$t\text{-statistics} \cdot \left( \frac{\hat{\phi}-1}{\text{se}(\hat{\phi})}, \frac{\hat{\tau}-0}{\text{se}(\hat{\tau})} \right)$$

```

1 > library(fUnitRoots)
2 > adfTable(trend=c("nc"), statistic=c("t"))
3 $x
4 [1] 25 50 100 250 500 Inf
5
6 $y
7 [1] 0.010 0.025 0.050 0.100 0.900 0.950 0.975 0.990
8  $\alpha=0.05$ 
9 $z
10 [1] 0.010 0.025 0.050 0.100 0.900 0.950 0.975 0.990
11  $\alpha$  ←  $\alpha$ 
12 | -2.66 -2.26 -1.95 -1.60 0.92 1.33 1.70 2.16
13 | 50 -2.62 -2.25 -1.95 -1.61 0.91 1.31 1.66 2.08
14 | 100 -2.60 -2.24 -1.95 -1.61 0.90 1.29 1.64 2.03
15 | 250 -2.58 -2.23 -1.95 -1.62 0.89 1.29 1.63 2.01
16 | 500 -2.58 -2.23 -1.95 -1.62 0.89 1.28 1.62 2.00
  Inf -2.58 -2.23 -1.95 -1.62 0.89 1.28 1.62 2.00

```

# การทดสอบ unit root

สิ่งสำคัญในการทดสอบยูนิทรูทคือการระบุว่าสมมุติฐานหลักและสมมุติฐานทางเลือกมีความหมายเดียวกันหรือไม่ โดยเฉพาะแนวโน้ม โดยกรณีที่เราพบบ่อยมีสองกรณีคือกรณีมีค่าคงที่อย่างเดียว และกรณีมีค่าคงที่และแนวโน้ม

ในกรณีค่าคงที่อย่างเดียว สมการที่ใช้ในการประมาณค่าตัวสถิติทดสอบคือ

$$\textcircled{2} \quad \boxed{\text{Constant}} \quad y_t = \underline{c} + \phi y_{t-1} + \varepsilon_t \quad (5)$$

และสมมุติฐานที่เกี่ยวเนื่องคือ

$$H_0 : \phi = 1 \quad (y_t \sim I(1) \text{ without drift})$$

$$H_1 : \phi < 1 \quad (y_t \sim I(0) \text{ with non-zero mean})$$



# การทดสอบ unit root

ในการณ์ที่มีค่าคงที่และแนวโน้ม สมการที่ใช้ในการประมาณค่า

$$\textcircled{3} \text{ Trend. } y_t = \underline{c} + \underline{\delta t} + \underline{\phi y_{t-1}} + \varepsilon_t \quad (6)$$

และสมมุติฐานที่เกี่ยวเนื่องกันคือ

$$H_0 : \phi = 1 \quad (y_t \sim I(1) \text{ with drift})$$

$$H_1 : \phi < 1 \quad (y_t \sim I(0) \text{ with deterministic time trend})$$

โดยที่รูปแบบของสมการที่ใช้ในการทดสอบมักจะเป็นในรูป

$$\Delta y_t = c + \pi y_{t-1} + \varepsilon_t$$

และ

$$\Delta y_t = c + \delta t + \pi y_{t-1} + \varepsilon_t$$

ในรัฐธรรมนูญ

Dickey Fuller Unit Root Test

↑ Autocorrelation?

$$\underline{y_t} = \phi \underline{y_{t-1}} + \varepsilon_t$$



# Augmented DF test

- เวลาแก้ไขปัญหา Autocorrelation

หาผลเพิ่ม lag vs dependent var

การทดสอบยูนิทรูทด้วยพจน์ที่เพิ่มเข้าไปโดยมีพื้นฐานจากแบบจำลอง

$ARMA(p, q)$  และเรียกว่า Augmented Dickey-Fuller ซึ่งตัวทดสอบสามารถประมาณค่าได้จากการสมการ

$$y_t = \beta'(D_t) + \phi y_{t-1} + \sum_{j=1}^p \psi_j \Delta y_{t-j} + \varepsilon_t$$

จึงจะมีรูปแบบ

หรือเราสามารถประมาณค่าสมการนี้

Augmented  
Dickey Fuller  
Unit Root  
test (ADF unit root test)

$$\Delta y_t = \beta' D_t + \pi y_{t-1} + \sum_{j=1}^p \psi_j \Delta y_{t-j} + \varepsilon_t$$

lag  $\Delta y_t$   
 $(\Delta y_{t-1}, \Delta y_{t-2}, \dots)$

$\Delta y_t - P$   
Model Selection (AIC)  
(BIC)

โดยที่  $\pi = \phi - 1$  ซึ่งภายใต้สมมุติฐานหลัก  $\Delta y_t$  จะเป็น  $I(0)$  และอนุมานได้ว่า

$\pi = 0$

$$H_0: \pi = 0 \quad \text{หรือ} \quad H_1: \pi < 0$$




## ตัวอย่าง 2.8

ทดสอบยูนิทรูทของ SET index รายวัน จากข้อมูลในไฟล์ setindex.txt  
 แต่ในที่นี่เราจะใช้ชุดคำสั่ง fUnitRoots โดยเบื้องต้นเราจะ พิจารณา ACF  
ของอนุกรมเวลา และ อนุกรมเวลาที่ได้ปรับผลต่างอันดับหนึ่ง (first-differenced)  
 จาก ACF ของอนุกรมเวลา set\$index เราพบว่าจะมีปัญหา yunithroot เนื่องจาก  
 ค่า ACF ลดลงช้ามาก

```

1 > set=read.table(file="setindex.txt", header=TRUE)
2 > library(fUnitRoots)
3 > acf(set$index)
4 > acf(diff(set$index))
5 > plot(diff(set$index), type="l")
    
```



$\text{M}_t \text{ ให้ } R.W.$   
 $\text{ACF ของ } \text{setindex} \text{ ก็จะ } \text{ลดลงช้า}$   
 $\text{มาก}$

Point

สรุปได้เลยว่า  $\text{M}_t$  ให้ Unit root  
 $\Rightarrow$  ทดสอบ ADF Unit Root test



เราจะทดสอบยูนิทรูทโดยใช้ Augmented Dickey-Fuller test โดยคำสั่งที่ใช้ในที่นี่คือ adfTest โดยเราต้องระบุค่าล่าของ  $y_t$  ที่เราจะรวมในสมการ โดยในที่นี่จะเลือก lags=10 และรูปแบบของสมการ type (ไม่มีค่าคงที่ (nc), มีค่าคงที่ (c) และมีค่าคงที่และเส้นแนวโน้ม (ct)) จากกราฟ  $\Delta y_t$  เราพบว่ามีค่าจุดตัดต่างจากศูนย์เต็มไม่มีแนวโน้มดังนั้นเราจะเลือก type=c ("c")

```

1 > adfTest(set$index, lags=10, type=c("c"))
2 Title:
3   Augmented Dickey-Fuller Test
4
5 Test Results:
6   PARAMETER:
7     Lag Order: 10
8   STATISTIC:
9     Dickey-Fuller: -0.0682
10  P VALUE:
11    0.9501
12

```

SET INDEX  $\rightarrow$  Unit root  
 $(Y_t)$   $\rightarrow$  1st diff 11 ลำดับ stationary  $\Rightarrow Y_t \sim I(1)$   
 $I(?)$   $\rightarrow$   $\Delta Y_t$  (stationary)  $\Rightarrow$  ทางนนี้ ARMA(p,q)

ARIMA

Integrated ARMA

↓  
อธิบาย NonStationary

I(d)  $\int$  จำนวนครั้งที่ Diff  
 ทั้งหมด  $\Delta^d y_t$  จะเป็น stationary

## Definition 2

เราจะเรียกกระบวนการ  $y_t$  ว่า ARIMA(p, d, q) ถ้า  $\Delta^d y_t = (1 - L)^d y_t$  เป็นกระบวนการ ARMA(p, q) หรือเราสามารถเขียนในรูปปัจจุบันเป็น

$$\underbrace{\phi(L)(1 - L)^d y_t}_{\text{AR}} = \underbrace{\theta(L)\varepsilon_t}_{\text{MA}} \quad (7)$$

และถ้าหาก  $E(\Delta^d y_t) = \mu$  เราสามารถเขียนแบบจำลองได้เป็น

$$\phi(L)(1 - L)^d y_t = \delta + \theta(L)\varepsilon_t$$

$$\text{โดยที่ } \delta = \mu(1 - \phi_1 - \dots - \phi_p)$$



# ARIMA

ในทางปฏิบัติ เราสามารถแบ่งแยกขั้นตอนในการสร้างแบบจำลอง

## ARIMA( $p, d, q$ ) ຖຸດັ່ງນີ້

## Nonstationary ARF

- พิจารณา ACF ของข้อมูลว่ามีข้อบ่งชี้ว่ามีปัญหาข้อมูลไม่นิ่ง (nonstationary) หรือไม่  $\rightarrow$  Unit Root กอนอน
  - ทดสอบยุนิทรุว่ามีอินทิเกรตที่อันดับเท่าใด หรือหาก  $d$  นั้นเอง  $I(d)$ ?
  - หลังจากนั้นเราจะพิจารณาอนุกรม  $z_t = \Delta^d y_t$  ว่าแบบจำลองที่เหมาะสมใน การอธิบาย  $z_t$  ควรจะมีอันดับของ  $p$  และ  $q$  เท่าใด  $\xrightarrow{ARMA(p,d)}$   
หลังจากที่เราได้ค่า  $d, p$  และ  $q$  แล้วเราจะได้แบบจำลอง  $ARIMA(p,d,q)$

MU. 2,8

SET INDEX I(1)

$$Z_t = y_t - y_{t-1}$$

$\downarrow$

ARMA( $p, q$ )

$Z \leftarrow \text{diff}(y)$



# ตัวอย่างที่ 2.9

ต่อจากตัวอย่างที่ 2.8 เราพิจารณาว่า set index

```

1 > adfTest(diff(set$index), lags=10, type=c("c"))
2 Title:
3 Augmented Dickey-Fuller Test
4 Test Results:
5 PARAMETER:
6 Lag Order: 10
7 STATISTIC:
8 Dickey-Fuller: -16.7697
9 P VALUE:
10 0.01
11 > library(forecast)
12 > auto.arima(set$index)
13 ,d=1,D=0,max.p=12,max.q=12,ic=c("bic"),stepwise=FALSE,trace=FALSE)
14 Series: set$index
15 ARIMA(0,1,0) → p=0, q=0
16 sigma^2 estimated as 87.77: log likelihood=-13312.56
AIC=26627.12 AICc=26627.12 BIC=26633.32

```

ซึ่งจากการใช้ BIC พบร่วมกับค่า  $p = 0$  และ  $q = 0$  ดังนั้น  
แบบจำลองที่เหมาะสมที่ใช้ประมาณค่า set index รายวันคือ ARIMA(0,1,0)  
หรือแบบจำลอง random walk นั่นเอง

