

พัฒนาอย่าง y_t ← พัฒนาอย่าง (y_{t-1}, y_{t-2}, \dots)
 วัตถุประสงค์?]

EC435

บทที่ 3 แบบจำลองอนุกรรมเวลาเชิงเส้นตรัง

ก) y_t ตาม y_{t-j} , $j=1, 2, \dots, q$ ก → ทราบใจดีแค่ไหน?

จุดเด่นสำคัญ

y_{t-j} ตัวแปร
อย่าง y_t

การประเมินจาก
อย่าง y_t

เฉลิมพงษ์ คงเจริญ ©2556-2563

คณะเศรษฐศาสตร์ มหาวิทยาลัยธรรมศาสตร์

August 26, 2020

1) ACF ($H_0: \rho_j = 0$
vs $H_1: \rho_j \neq 0$)

2) LB Q test
($H_0: \rho_1 = \dots = \rho_m = 0$
vs $H_1: \rho_j \neq 0 \exists j$)

{ พบร. $\rho_j \neq 0$
สรุปแบบๆ กันๆ
 $\forall \rho_j = 0$
 y_t เป็น WN.
ไม่สามารถระบุได้

กระบวนการไวท์โนയซ์ (white noise)

ข้อมูลอนุกรมเวลาที่ง่ายที่สุดคือกระบวนการ ไวท์โนยซ์ (white noise) โดยที่เรามักจะเขียนแทนด้วย random variable ε_t — epsilon_t

นิยาม 2.1

ตัวแปร ε_t จะเรียกว่ากระบวนการ ไวท์โนยซ์ ถ้ามีค่าเฉลี่ยเท่ากับศูนย์, มีความแปรปรวนคงที่เท่ากับ σ^2 และไม่มีสหสัมพันธ์ข้ามเวลา (serially uncorrelated) หรือเขียนเป็นเงื่อนไขได้ดังนี้

- ① $E(\varepsilon_t) = 0$ [ด้วย $\varepsilon_t = 0$]
- ② $Var(\varepsilon_t) = \sigma_\varepsilon^2$ [ด้วย ε_t คงที่ ॥ ร. เท่ากับ σ_ε^2]
- ③ $Cov(\varepsilon_t, \varepsilon_{t-k}) = 0$ for $k \neq 0$ [ε_t กับ ε_{t-k} $\forall k \neq 0$ นั้น]

W.N. process —
เป็นต่ออช. แนวๆ \rightarrow stationary
กันนิรห์กัน (อัตราผล)



กระบวนการเส้นตรง (Linear process)

Wold's decomposition theorem ระบุว่าอนุกรมเวลา y_t สามารถเขียนในรูปกระบวนการเส้นตรงหรือตัวแทนรูปแบบค่าเฉลี่ยเคลื่อนที่ที่มีอันดับเป็นอนันต์ (infinite moving average) และถ้าสามารถเขียน y_t ในรูป

$$y_t = \mu + \sum_{i=0}^{\infty} \psi_i \varepsilon_{t-i} \quad (1)$$

พจนานุกรม เน้นความ ε_{t-j}


$\text{cov} = 0$

โดยที่ μ คือค่าเฉลี่ย, $\psi_0 = 1$, และ ε_t จิอ (iid) โดยที่เราสามารถพิจารณา ε_t ใน

ฐานะเป็นข้อมูลใหม่ที่เข้ามาในช่วงเวลา t หรือเป็น innovation หรือ shock ณ เวลา t และ $\sum_{i=1}^{\infty} \psi_i^2 < \infty$

y_{t-1}
อนุกรมเส้นตรง

เมื่อนำ y_{t-1} ไปคำนวณ y_t



แบบจำลองออโตรีเกรสซีฟ

$$Y_t \leftarrow Y_{t-1}, \dots, Y_{t-p}$$

Regression $Y_t = Y_{t-1} \dots Y_{t-p}$


แนวคิดพื้นฐานของแบบจำลองออโตรีเกรสซีฟ (autoregressive) คือข้อมูลในเวลาปัจจุบัน (y_t) สามารถอธิบายได้ด้วยตัวแปรนี้ในอดีตย้อนหลังไป p ถึง p ช่วงเวลา (y_{t-1}, \dots, y_{t-p})

แบบจำลองออโตรีเกรสซีฟที่มีอันดับ (order) เท่ากับ p (เขียนแทนด้วย $AR(p)$) สามารถเขียนได้เป็น

$$\underline{AR(p)} - y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t, \quad (2.3)$$

phi ↓ Shock ผมนุ่ม WN ↓

โดยที่ y_t เป็นข้อมูลที่นิ่งและ ε_t เป็นไวท์โนแซลส์ที่มีค่าเฉลี่ยเท่ากับศูนย์และค่าความแปรปรวนคงที่เท่ากับ σ^2_ε



ทดสอบ Y_t กับ Y_{t-j} วัดผลสัมฤทธิ์

แบบจำลองเพื่อ验证 \underline{ret}_t .

หาก: ก้าว 1 แบบจำลองได้?
ผิดพลาด ก้าว 2 แบบจำลองได้?

แบบจำลองออ โตรีเกรสซีฟ: ค่าเฉลี่ย

diagonal

ที่มา

$$Y_t = \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + \varepsilon_t$$

Reg ให้ชี้เป็น AR(p)

diagonal ให้ชี้เป็น WN.

ค่าเฉลี่ยของ y_t ที่มา

$$\begin{aligned} E(y_t) &= E(\phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_t) \\ &= E(\phi_1 Y_{t-1}) + E(\phi_2 Y_{t-2}) + \dots + E(\phi_p Y_{t-p}) + E(\varepsilon_t) // \\ &= \phi_1 E(Y_{t-1}) + \phi_2 E(Y_{t-2}) + \dots + \phi_p E(Y_{t-p}) + E(\varepsilon_t) \end{aligned}$$

การหาค่าเฉลี่ยของ y_t ที่มา

หากเราเขียน $AR(p)$ ในรูป

$(1 - \phi_1 - \phi_2 - \dots - \phi_p) E(Y_t) = 0$

$$(y_t - \mu) = \phi_1(y_{t-1} - \mu) + \phi_2(y_{t-2} - \mu) + \dots + \phi_p(y_{t-p} - \mu) + \varepsilon_t, \quad (3.4)$$

$$\text{หรือ } y_t = \phi_0 + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t \quad (3.5)$$

$$E(y_t) = \frac{\phi_0}{1 - \phi_1 - \dots - \phi_p} \stackrel{\text{หมายความ}}{=} \mu$$

มติ: เล็ตต์อยู่ที่ ϕ_0 นั่นไง - ที่นองค์รวมกัน \Rightarrow ที่เหลือ = 0 ?



การเขียน AR(p) ในรูป backshift operator (lag operator)

นอกจากนี้เรายังสามารถเขียนสมการ (2.3) ได้ด้วยเครื่องมือ backshift operator เป็นสมการดังนี้

def lag operator

$$\text{def lag operator} \quad L \cdot y_t = y_{t-1}$$

$$L^2 \cdot y_t = L \cdot y_{t-1} = y_{t-2}$$

$$(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p) y_t = \varepsilon_t, \quad (2.5)$$

AR(p) polynomial

$$\phi(L) y_t = \varepsilon_t$$

โดยที่เรียก $\phi(L) = 1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p$ ว่า พหุนามออ โตรีเกรสซีฟ (autoregressive polynomial)



AR(1) model


$$Y_t = \phi Y_{t-1} + \varepsilon_t$$

เราจะพิจารณาคุณสมบัติของแบบจำลอง AR(1) ซึ่งมีค่าเฉลี่ยเท่ากับศูนย์ สามารถแสดงได้โดย

$$\left\{ \begin{array}{l} y_t = \phi y_{t-1} + \varepsilon_t, \\ \varepsilon_t \sim WN(0, \sigma^2) \end{array} \right. \quad (2.8)$$


จากสมการข้างต้นหากเริ่มพิจารณากรณีที่ $y_0 = 0$ และให้ ε_t มีการแจกแจงแบบ $N(0, 1)$ เราจะได้การเดินทางตามเวลา (time path) ของ y_t สำหรับค่าสัมประสิทธิ์ (ϕ) ที่ต่างกันดังที่แสดงในรูปต่อไปนี้

$$\begin{aligned} y_1 &= \phi y_0 + \varepsilon_1 \\ y_2 &= \phi y_1 + \varepsilon_2 \end{aligned}$$



AR(1) model

Figure: การจำลองกระบวนการ $AR(1)$ ที่ค่าสัมประสิทธิ์(ϕ)ที่ต่างกัน



② $\text{Var}(\psi_t)$ กรณี $\psi_t - AR(1)$

จากสมการ (2.8) เราสามารถแทนค่า y_t ในอัตโนมัติไปเรื่อยๆแบบเวียนเกิด (recursive) k ครั้งดังนี้

$$\psi_t = \lim_{k \rightarrow \infty} \phi^k \psi_{t-k} + \varepsilon_t$$

$$\begin{aligned}\psi_t &= \phi \psi_{t-1} + \varepsilon_t \\ &= \phi(\phi \psi_{t-2} + \varepsilon_{t-1}) + \varepsilon_t \\ &= \phi[\phi(\phi \psi_{t-3} + \varepsilon_{t-2}) + \varepsilon_{t-1}] + \varepsilon_t\end{aligned}$$

ด้วยวิธีดังกล่าวข้างต้นและค่า $|\phi| < 1$ แล้ว $\lim_{k \rightarrow \infty} \phi^k y_{t-k} = 0$ จะทำให้เราสามารถเปลี่ยนแบบจำลอง $AR(1)$ ในรูปต่อไปนี้

$$\psi_t = \phi \psi_{t-1} + \varepsilon_t$$

$$y_t = \underbrace{\varepsilon_t}_{-} + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j},$$

Moving Average (MA)

เราเรียกรูปดังกล่าวว่าการแสดงแบบจำลอง $AR(1)$ ด้วย infinite moving average representation หมายความว่า ψ_t จาก รูปที่ 3.9

$$\begin{aligned}E(\psi_t) &= \dots \\ \rightarrow \text{Var}(\psi_t) &= 0\end{aligned}$$

รูปที่ 3.9
เป็น $AR(1)$
หมายความ
 $MA(\infty)$



2

ความแปรปรวนของ y_t

$$\text{Var}(y_t) = ? \quad \text{AR(1)} \quad y_t = \phi y_{t-1} + \varepsilon_t \Rightarrow \text{MA}(\infty)$$

$$y_t = \varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots$$

เนื่องจาก $E(y_t) = 0$ ค่าความแปรปรวน $\text{Var}(y_t) = E[y_t - E(y_t)]^2$ จะเท่ากับ $\text{Var}(y_t) = E(y_t^2)$ หากเราแทนค่า y_t จากสมการ (2.9) ลงในสูตรดังกล่าว และใช้คุณสมบัติของ ε_t ที่ว่า $\text{Var}(\varepsilon_t) = E(\varepsilon_t^2) = \sigma_t^2$ และ $E(\varepsilon_j, \varepsilon_k) = 0$ สำหรับ $k \neq j$ เราจะได้

$$E(y_t^2) = E[(\varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots)(\varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots)]$$

$$= E[\varepsilon_t \varepsilon_t + \varepsilon_t \phi \varepsilon_{t-1} + \varepsilon_t \phi^2 \varepsilon_{t-2} + \dots + \phi \varepsilon_{t-1} \varepsilon_t + \phi \varepsilon_{t-1}^2 + \phi^2 \varepsilon_{t-1} \varepsilon_{t-2} + \dots + \phi^2 \varepsilon_{t-2} \varepsilon_t + \phi^3 \varepsilon_{t-2} \phi \varepsilon_{t-1} + \phi^4 \varepsilon_{t-2}^2 + \dots]$$

$$E(\text{Cross Term}) = 0$$

$$= E(\varepsilon_t^2) + \phi E(\varepsilon_t \varepsilon_{t-1}) + \phi^2 E(\varepsilon_t \varepsilon_{t-2}) + \dots + \phi^{t-1} E(\varepsilon_t \varepsilon_1) + \phi^t E(\varepsilon_t^2)$$

$$\text{COV}(\varepsilon_{t-1}, \varepsilon_{t-2}) = \phi^2 E(\varepsilon_{t-1} \varepsilon_{t-2}) + \dots + \phi^2 E(\varepsilon_{t-2} \varepsilon_{t-1}) + \phi^3 E(\varepsilon_{t-2} \varepsilon_{t-3}) + \phi^4 E(\varepsilon_{t-2}^2)$$

$$(\varepsilon_t \text{ ปัจจุบัน}) = E(\varepsilon_t^2) + \phi^2 E(\varepsilon_{t-1}^2) + \phi^4 E(\varepsilon_{t-2}^2) + \dots + 0 + 0 + 0$$

$$\sigma^2 = \text{Var}(\varepsilon_t) = E(\varepsilon_t - E(\varepsilon_t))^2$$

(3) ค่าความแปรปรวนร่วม

$$\text{ตากดูนั้นเป็นอย่างนี้} \quad 1 + \phi^2 + \phi^4 + \dots = \frac{1}{1 - \phi^2} \quad \text{ถ้า } |\phi| < 1$$

$$\left[1 + k + k^2 + k^3 + \dots = \frac{1}{1 - k} \right]$$

หากนำค่า y_t และ y_{t-l} ที่เขียนในรูปสมการ (2.9) และค่าเฉลี่ยเท่ากับศูนย์ $E(y_t) = 0$ แทนค่าในสูตรค่าความแปรปรวนร่วมได้ฟังก์ชันค่าความแปรปรวนร่วมจะเท่ากับ

$$\gamma_l = E((y_t - E(y_t))(y_{t-l} - E(y_{t-l})))$$

$$\gamma_l = E(y_t \cdot y_{t-l})$$

$y_t \sim N$ vs MA(∞)

$$= E[(\varepsilon_t + \phi\varepsilon_{t-1} + \phi^2\varepsilon_{t-2} + \dots)(\varepsilon_{t-l} + \phi\varepsilon_{t-l-1} + \phi^2\varepsilon_{t-l-2} + \dots)]$$

$$\phi^l \varepsilon_{t-l} + \phi^{l+1} \varepsilon_{t-l-1}$$

$$= E[\phi^l \varepsilon_{t-l}^2 + \text{cross term} + \dots + \phi^{l+2} \varepsilon_{t-l-1}^2 + \dots]$$

$$= \phi^l E(\varepsilon_{t-l}^2) + \phi^{l+2} E(\varepsilon_{t-l-1}^2) + \phi^{l+4} E(\varepsilon_{t-l-2}^2) + \dots$$

$$\gamma_l = 6\phi^l (1 + \phi^2 + \phi^4 + \dots) = \frac{6\phi^l}{1 - \phi^2} \quad \leftarrow \text{Autocov vs } y_t \sim AR(1)$$



พึงก์ชันสหสัมพันธ์ร่วมในตัวเอง (ACF) $\rightarrow \rho_l$ - lag 1 autocorr
 $y_t = \phi y_{t-1} + \epsilon_t$ vs $y_t \sim AR(1)$

พึงก์ชันสหสัมพันธ์ร่วมในตัวเอง (ACF) เท่ากับ $\rho_l = \frac{\gamma_l}{\gamma_0} = \frac{\frac{\phi^l \sigma_\epsilon^2}{(1-\phi^2)}}{\frac{\sigma_\epsilon^2}{(1-\phi^2)}} = \phi^l$

หากลองแทนค่า ϕ ด้วยค่าเท่ากับ $0.9, -0.9, 0.5, -0.5$ จะได้พึงก์ชันสหสัมพันธ์ร่วมในตัวเองดังตารางต่อไปนี้

$$\begin{aligned}\rho_1 &= \phi' = \phi \\ \rho_2 &= \phi^2\end{aligned}$$




Table: Autocorrelation ของ $AR(1)$ ที่ค่าสัมประสิทธิ์ (ϕ) ที่ต่างกัน

$\phi \setminus l$	1	2	3	4	5	6	7	8	9	10
0.9	0.900	0.900	0.810	0.900	0.729	0.656	0.590	0.531	0.478	0.430
-0.9	-0.900	0.810	-0.729	0.656	-0.590	0.531	-0.478	0.430	-0.387	0.349
0.5	0.500	0.250	0.125	0.063	0.031	0.016	0.008	0.004	0.002	0.001
-0.5	-0.500	0.250	-0.125	0.063	-0.031	0.016	-0.008	0.004	-0.002	0.001



พึงก์ชั้นสหสัมพันธ์ร่วมในตัวเอง (ACF)



Figure: ค่าสหสัมพันธ์ร่วมในตัวเองของกระบวนการ $AR(1)$ ที่ค่าสัมประสิทธิ์(ϕ)ที่ต่างกัน

$$\checkmark Y_t = \phi Y_{t-1} + \varepsilon_t$$



Theoretical ACF

ใน $AR(1)$

1. ด้านล่างนี้เป็น ACF
ของ $AR(1)$ มีผลลัพธ์
ที่อยู่ (กูเกิล)



2. กรณี $|\phi| > 1$
ACF จะสูงช้าๆ
กรณี $|\phi| \leq 1$ จะลดลงเรื่อยๆ



เนื่องจากความเป็นอนุกรมนิ่ง (Stationary) $y_t \sim AR(1)$
 $E(y_t) = 0, Var = \frac{\sigma^2}{1-\phi^2}$

เราสามารถเขียนกระบวนการ $AR(1)$ ในรูปของพหุนามออ โตรีเกรสซีฟได้
 เป็น $y_t = \phi y_{t-1} + \epsilon_t$ (รูปแบบตัวเลข หรือ Var y_t) $| \phi | < 1$ Var y_t = σ^2 exist
 $y_t - \phi y_{t-1} = \epsilon_t$ $\phi = 1, -1$
 $(1 - \phi L) y_t = \epsilon_t$ | \phi | > 1 Var y_t ลบ Polynomial (2.13)

โดยที่เราสามารถเขียน auxiliary equation ได้เป็น

สมการหัว

$$(1 - \phi m) = 0$$

根

$$|m| = \frac{1}{|\phi|} > 1$$

ตัวรากของพหุนาม

(Root of Polynomial)

เมื่อ y_t ให้ stationary - ตัวรากของพหุนาม m ต้อง < 1 .



Example 1

จงพิจารณาว่ากระบวนการต่อไปนี้เป็นกระบวนการนิ่งหรือไม่

■ $y_t - 0.9y_{t-1} = \varepsilon_t$

$$|\phi = 0.9| < 1 \text{ Stationary}$$

$$\rightarrow |m = \frac{1}{0.9}| > 1$$

■ $y_t - y_{t-1} = \varepsilon_t$

$$\phi = 1 \quad \text{Not stationary}$$

■ $y_t + 1.2y_{t-1} = \varepsilon_t$

$$\phi = 1.2 \quad \text{Not stationary.}$$

แบบจำลอง AR(1) ที่มีค่าเฉลี่ย

เรารสามารถเขียน AR(1) ในรูปทั่วไป เช่น $y_t - \mu = \phi(y_{t-1} - \mu) + \varepsilon_t$ ถ้าเราต้องการหา $E(y_t)$

$$y_t = \phi y_{t-1} + \varepsilon_t \rightarrow E(y_t) = 0$$

$$y_t = \phi_0 + \phi_1 y_{t-1} + \varepsilon_t$$

$$(y_t - \mu) = \phi (y_{t-1} - \mu) + \varepsilon_t$$

$$E(y_t) = \mu$$

- $\text{Var}(y_t)$ (มีด้วย)
ใช้ได้
 - $\text{Cov}(y_t, y_{t-l})$ (ใช้ได้)
ก่อนการคำนวณ

(✓) AR(1) ต้องมี $\phi \neq 0$

(✓) $E(y_t) = 0$ (ใช้ได้)
 ACF อยู่ในชุดเดียว

กรณีสมการ $y_t = \phi_0 + \phi_1 y_{t-1} + \varepsilon_t$ ถ้าเราต้องการหา $E(y_t)$

$$E(y_t) = E(\phi_0 + \phi_1 y_{t-1} + \varepsilon_t) \xrightarrow{\phi_0 \text{ เป็น const}} 0 \quad (\varepsilon_t \text{ ไม่เป็น WN})$$

$$= \phi_0 + \phi_1 E(y_{t-1}) + \cancel{E(\varepsilon_t)} \xrightarrow{\phi_1 \neq 1} 0$$

$$E(y_t) = \frac{\phi_0}{1 - \phi_1} \equiv \mu \quad E(y_t) \text{ คงที่ stationary } (|\phi_1| < 1)$$

แบบจำลอง $AR(2)$

แบบจำลอง $\underbrace{AR(2)}$ สามารถเปลี่ยนอธิบายได้ด้วยสมการ

$$\rightarrow y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t \rightarrow y_t - \phi_1 y_{t-1} - \phi_2 y_{t-2} = \varepsilon_t$$

เราสามารถพิจารณาความเป็น กระบวนการนิ่ง ได้โดยการหารากของพหุนามออโตรีเกรสซีฟซึ่ง $(1 - \phi_1 L - \phi_2 L^2)y_t = \varepsilon_t$ สามารถเปลี่ยนได้เป็น

$$\phi(m) = 1 - \phi_1 m - \phi_2 m^2 = 0 \rightarrow \frac{|m_1|, |m_2| > 1}{\text{หาก factor}} \text{ หมายความ}$$

$\phi(m) = 1 - \phi_1 m - \phi_2 m^2 = 0$ โดยที่รากของสมการพหุนามออโตรีเกรสซีฟที่อยู่ในรูปสมการกำลังสอง (quadratic) จะมีค่าหันสองจำนวน (m_1, m_2) เท่ากับ $\frac{\phi_1 \pm \sqrt{\phi_1^2 + 4\phi_2}}{-2\phi_2}$ โดยที่เงื่อนไขที่คือ รากของสมการพหุนามออโตรีเกรสซีฟจะต้องมากกว่าหนึ่ง (หรือมอดูลัส (modulus) มากกว่าหนึ่งในการนิจจำนวนเชิงซ้อน) ซึ่งจะเกิดขึ้นเมื่อ $|m_1|, |m_2| > 1$ เมื่อ

$$\rightarrow 1) \phi_1 + \phi_2 < 1, \quad 2) \phi_2 - \phi_1 < 1, \quad 3) |\phi_2| < 1$$

) AR(2)
If Stationary.



คุณลักษณะของกระบวนการ $AR(2)$

$$\begin{aligned} 1) E(Y_t) &= 0 \\ 2) \text{Var}(Y_t) &= \text{Cov}(Y_t, Y_t) \\ 3) \text{Cov}(Y_t, Y_{t-l}) &= \gamma_l \end{aligned}$$

พึงกชั่นความแปรปรวนร่วมเราสามารถพิจารณาได้โดยคุณสมการ (2.16)

ทั้งสองข้างด้วย y_{t-k} และ take expectation เราจะได้

$$\phi_k = E(y_t y_{t-k}) = E[(\phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \epsilon_t) Y_{t-k}]$$

$$\begin{aligned} &= \underbrace{\phi_1 E(Y_{t-1} Y_{t-k})}_{k=0,1,2,\dots} + \underbrace{\phi_2 E(Y_{t-2} Y_{t-k})}_{k=0,1,2,\dots} + \underbrace{E(\epsilon_t Y_{t-k})}_{k=0,1,2,\dots} \\ \phi_k &= \phi_1 Y_{t-1} + \phi_2 Y_{t-2} \end{aligned}$$

$\cancel{E \text{ cross term}}$
 $\cancel{\phi_1 Y_{t-1}}$
 $\cancel{\phi_2 Y_{t-2}}$
 $\downarrow \text{AR}(2)$
 $\downarrow \text{BWN}$
 $\downarrow \text{MA}(\infty)$

$$\frac{\gamma_k}{\gamma_0} = \phi_1 \frac{\gamma_{k-1}}{\gamma_0} + \phi_2 \frac{\gamma_{k-2}}{\gamma_0}$$


Auto corr
in AR(2)

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2}$$

$\epsilon_{t-k}, \epsilon_{t-k-1}, \dots$
 $k>0$

เราเรียกสมการทั้งสองว่าสมการ Yule-Walker

ACF



คุณลักษณะของการบวนการ AR(2)

หากเราพิจารณากรณีที่ $k = 1$, $\rho_1 = \rho_{-1}$ และ $\rho_0 = 1$ เราจะได้

$$k=1 \quad \text{ตัวอย่าง}$$

$$\rho_1 = \phi_1 \rho_0 + \phi_2 \rho_{-1} = \rho_1$$

$$\rho_1 = \frac{\phi_1}{1 - \phi_2}$$

และกรณีที่ $k = 2$ เราจะได้

$$\rho_2 = \phi_1 \rho_1 + \phi_2 \rho_0$$


$$\rho_2 = \frac{\phi_2(1 - \phi_2) + \phi_1^2}{1 - \phi_2}$$

$$\rho_3 = \phi_1 \rho_2 + \phi_2 \rho_1$$

$$\vdots$$

และเราสามารถแทนค่าแบบเวียนเกิด(recursive)เพื่อให้ได้ ρ_k กรณี $k > 2$

ให้ไปอ่านเนื้อหาสำหรับแบบจำลอง AR(p)



แบบจำลอง $AR(p)$

กรณีที่ $AR(p)$ เป็นอนุกรมนิ่ง ค่าคงที่ในรูปแบบลดด้อยในตัวเอง(c)จะเท่ากับ $\mu(1 - \phi_1 - \dots - \phi_p)$ ในทางกลับกัน $\mu = c/(1 - \phi_1 - \dots - \phi_p)$
หากเราสมมุติให้ค่าเฉลี่ย(μ)เท่าศูนย์และกระบวนการนิ่ง เราจะได้

$$\rho_k = \phi_1\rho_{k-1} + \phi_2\rho_{k-2} + \dots + \phi_p\rho_{k-p},$$

สำหรับทุกค่า $k \geq 1$ หากเราพิจารณากรณีที่ $k = 1, 2, \dots, p$ และใช้ความสัมพันธ์ที่ $\rho_0 = 1$ และ $\rho_j = \rho_{-j}$ เราจะได้สมการ Yule-Walker

$$\rho_1 = \phi_1 + \phi_2\rho_1 + \phi_3\rho_2 + \dots + \phi_p\rho_{p-1}$$

$$\rho_2 = \phi_1\rho_1 + \phi_2 + \phi_3 + \dots + \phi_p\rho_{p-2}$$

$$\vdots$$

$$\rho_p = \phi_1\rho_{p-1} + \phi_2\rho_{p-2} + \phi_3\rho_{p-3} + \dots + \phi_p \quad (2)$$



แบบจำลอง $AR(p) \rightarrow ACF$ ตารางที่อยู่ (ทฤษฎี $y_t \sim AR(p)$)
แสดงว่า เห็นได้ชัดเจน.

ซึ่งหากเราทราบว่า $\phi_1, \phi_2, \dots, \phi_p$ เราสามารถหาค่า $\rho_1, \rho_2, \dots, \rho_p$ ได้
นอกจานี้

$$E(\varepsilon_t y_t) = E[\varepsilon_t (\phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t)] = E(\varepsilon_t^2) = \sigma^2$$

และหากเราคูณสมการ (2.20) ด้วย y_t และใส่ค่าคาดหมาย เราจะได้

$$\gamma_0 = \phi_1 \gamma_1 + \phi_2 \gamma_2 + \dots + \phi_p \gamma_p + \sigma^2 \quad (3)$$

และหากใช้ความสัมพันธ์ว่า $\rho_k = \gamma_k / \gamma_0$ จะได้

$$\gamma_0 = \frac{\sigma^2}{1 - \phi_1 \rho_1 - \phi_2 \rho_2 - \dots - \phi_p \rho_p}$$

ข้อสรุป \rightarrow Plot Sample ACF - วงกลมเห็น ถูกต้องตามที่คาด


ACF Return  \rightarrow AR



Partial Autocorrelation Function


แบบจำลอง AR(1) $y_t = \phi_1 y_{t-1} + \varepsilon_t$
 ก็จะ y_t Run reg ① $y_t = \phi_{11} y_{t-1} + \varepsilon_{1t}$

PACF เป็นเครื่องมือที่เป็นประโยชน์ในการระบุแบบจำลอง AR(p)



$$\textcircled{2} \quad y_t = \phi_{21} y_{t-1} + \phi_{22} y_{t-2} + \varepsilon_{2t}$$

$$\phi_{21} \rightarrow \phi_1 \quad \phi_{22} \rightarrow 0$$



โดยที่ $z_t = y_t - \mu$ คือข้อมูลที่ได้กำจัดค่าเฉลี่ยแล้ว (demeaned) เราเรียกค่าสัมประสิทธิ์ ϕ_{jj} สำหรับ $j = 1, 2, \dots, p$ (ค่าสัมประสิทธิ์สุดท้ายของแต่ละสมการ) ว่าค่าสัมประสิทธิ์สหสัมพันธ์ในตัวของบางส่วน

Partial ACE



PACF

ในกรณีที่เราพิจารณาแบบจำลอง $AR(1)$ ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วนตัวแรก ϕ_{11} จะไม่เท่ากับศูนย์ ส่วนสัมประสิทธิ์ที่เหลือจะเท่ากับศูนย์

หากเราพิจารณาแบบจำลอง $AR(2)$ ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วนตัวแรกและตัวที่สอง (ϕ_{11} และ ϕ_{22}) จะไม่เท่ากับศูนย์ ส่วนสัมประสิทธิ์ที่เหลือ (ϕ_{jj} สำหรับ $j > 2$) จะเท่ากับศูนย์

โดยสรุปแล้ว สำหรับแบบจำลอง $AR(p)$ ใดๆ ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วน p ตัวแรกจะไม่เท่ากับศูนย์ และสัมประสิทธิ์ที่เหลือจะเท่ากับศูนย์




สามารถคำนวณได้โดยใช้ฟังก์ชัน pacf ใน R


Figure: พังก์ชันสหสัมพันธ์ในตัวของบางส่วนของข้อมูลจำลอง AR(1)

$$y_t \sim AR(1), \phi = 0.9$$

AR(1), phi=0.9



$$\phi = -0.9$$



pacf
ตัวอย่าง
sample PACF

$H_0: \phi_1 = 0$ vs
 $H_1: \phi_1 \neq 0$
 $\hat{\phi}_t = \phi_{II}$
secular
C.I.
lag
vs. หมายเหตุ
 $\phi_k = 0$



ตัวอย่าง 3.3


 $\text{t}_t - \text{t}_{t-1}$

```

1 > int<-read.csv(file="mlr.csv", header=T)
2 > head(int)
3 > plot(int$diff_th_us, type="l", ylab="%", xlab="time")

```

Figure: ความแตกต่างระหว่างอัตราดอกเบี้ยของไทยและสหรัฐอเมริกา





ตัวอย่างที่ 3.3: PACF

```

1 > par(mfrow=c(1, 2))
2 > library(TSA)
3 > Acf(int$diff_th_us) → โน้ต  $\rho_0 = 1$ 
4 > pacf(int$diff_th_us)

```

Figure: ACF และ PACF ของความแตกต่างระหว่างอัตราดอกเบี้ยของไทยและสหราชอาณาจักร



②

MLE estimation

maximum Likelihood Est. → นวม *likelihood function* (นร์เจ้าก็)

หากเราสนใจที่จะประมาณค่าแบบจำลอง AR(1) ซึ่งอยู่ในรูปดังต่อไปนี้ แทน

$$y_t = \mu + \phi(y_{t-1} - \mu) + \varepsilon_t$$

โดยที่ $\varepsilon_t \sim iidN(0, \sigma^2)$ เนื่องจากข้อมูลอนุกรมเวลาเป็นข้อมูลที่ขึ้นอยู่ต่อกัน (dependent) ดังนั้น หากเราเก็บข้อมูล y_1, \dots, y_T และพึงก์ชันค่าความควรจะเป็นสามารถเขียนได้ดังนี้

↑
Max
MLE

$$L(\mu, \phi, \sigma^2) = f(y_1)f(y_2|y_1)f(y_3|y_2) \cdots f(y_T|y_{T-1}) \quad (4)$$

เนื่องจาก $y_t|y_{t-1} \sim N(\mu + \phi(y_{t-1} - \mu), \sigma^2)$ และพึงก์ชันการแจกแจงจะเป็นแบบปกติที่เหมือนกับซอก

$$f(y_t|y_{t-1}) = f_\varepsilon[(y_t - \mu) - \phi(y_{t-1} - \mu)]$$



MLE estimation

$$L(\mu, \phi, \sigma^2) = \exp \left(\frac{\sum_{t=2}^T [(y_t - \mu) - \phi(y_{t-1} - \mu)]}{2\sigma^2} \right) \quad (2.30)$$

การหาประมาณค่าโดยหาค่าพารามิเตอร์ที่ทำให้ \log ของสมการ (2.30) สูงที่สุด
เรียกว่า การประมาณค่าความควรจะเป็นสูงสุดแบบแม่นตรง (exact maximum likelihood estimation)

กรณีนี้เราไม่สามารถหาค่าสูงสุดได้ด้วยการวิเคราะห์หาจุดสูงสุด เราต้องใช้กระบวนการคัดกรองคอมพิวเตอร์ในการหาค่าสูงสุด



Model Checking

(ทดสอบแบบตัวอย่าง ว่า เม็ดพองในพอด淳ย์ AR(3) เป็นพองในพอด淳ย์ หรือไม่)

หลังจากที่เราได้ตัวประมาณค่าสำหรับพารามิเตอร์แล้ว ขั้นต่อไปเราจะมาค่า fitted ของตัวแปรที่เรารู้จัก (\hat{y}_t)

แล้วก็จะตรวจสอบแบบจำลองโดยการวิเคราะห์ค่าส่วนเกิน (residuals) โดยในที่นี้ค่าส่วนเกินสามารถคำนวณได้จาก $\hat{\epsilon}_t = y_t - \hat{y}_t$ โดยเราจะประเมินค่าส่วนเกินดังต่อไปนี้

$$\text{กูนที่แน่นจัดของ} \hat{Y}_t = \hat{\phi}_1 \hat{Y}_{t-1} + \hat{\phi}_2 \hat{Y}_{t-2} + \hat{\phi}_3 \hat{Y}_{t-3}$$

\downarrow

$$Y_t - \hat{Y}_t = \hat{\epsilon}_t$$

กูนที่แน่นจัดของ $\hat{\epsilon}_t$ (residuals) \rightarrow กูน AR(3) ผิดพลาด

กูนของ $\hat{\epsilon}_t$ ไม่ใช่ White Noise \rightarrow ไม่วัดตามที่มันควรจะ

- 1) ACF ของ $\hat{\epsilon}_t$
- 2) กูน LB Q test ของ $\hat{\epsilon}_t \rightarrow df.$

Model Checking

หลังจากที่เราได้ตัวประมาณค่าสำหรับพารามิเตอร์แล้ว ขั้นต่อไปเราจะมา check ของตัวแปรที่เราศึกษา (\hat{y}_t)

แล้วก็จะตรวจสอบแบบจำลองโดยการวิเคราะห์ค่าส่วนเกิน (residuals) โดยในที่นี้ค่าส่วนเกินสามารถคำนวณได้จาก $\hat{\epsilon}_t = y_t - \hat{y}_t$ โดยเราจะประเมินค่าส่วนเกินดังต่อไปนี้

- ① เราอาจจะเริ่มจากการวัดแผนภาพ ACF ของ $\hat{\epsilon}_t$ เพื่อดูว่าอนุกรมดังกล่าวยังมีความขึ้นอยู่ต่อกันหรือไม่



Model Checking

หลังจากที่เราได้ตัวประมาณค่าสำหรับพารามิเตอร์แล้ว ขั้นต่อไปเราจะ
ค่า fitted ของตัวแปรที่เราศึกษา (\hat{y}_t)

แล้วก็จะตรวจสอบแบบจำลองโดยการวิเคราะห์ค่าส่วนเกิน (residuals) โดย
ในที่นี้ค่าส่วนเกินสามารถคำนวณได้จาก $\hat{\epsilon}_t = y_t - \hat{y}_t$ โดยเราจะประเมินค่าส่วน
เกินดังต่อไปนี้

- (1) เราอาจจะเริ่มจากการวัดแผนภาพ ACF ของ $\hat{\epsilon}_t$ เพื่อดูว่าอนุกรมดังกล่าว
มีความขึ้นอยู่ต่อกันหรือไม่
- (2) นอกจากนี้เราสามารถทดสอบโดยใช้ค่าสถิติ $Q(m)$ กบ นุ่ง
โดยที่ $Q(m) \sim \chi^2_{m-g}$ โดยที่ g คือจำนวนของอันดับในแบบจำลองซึ่งในแบบ
จำลอง $AR(p)$ ค่า $g = p$ และ m คือจำนวนค่าล้าของความสัมพันธ์ที่พิจารณา
\ จำนวน parameter (\phi)



ตัวอย่าง 3.3 ต่อ 9.7 PACF $\rightarrow \psi_+ \sim AR(3)$
 ก็จะได้สูตรไปประมาณด้วย arima

ก็จะได้สูตรไปประมาณด้วย arima

```

1 > m1<-arima(int$diff_th_us, order=c(3,0,0))... → MLE
2
3 Call:
4 arima(x = int$diff_th_us, order = c(3, 0, 0))
5 Coefficients:
6             ar1  $\hat{\phi}_1$      ar2  $\hat{\phi}_2$      ar3  $\hat{\phi}_3$  intercept
7      1.3294    -0.4986    0.1334     3.0553
8 s.e.   0.0549    0.0878    0.0549     0.8102
9 sigma^2 estimated as 0.3054: log likelihood = -269.11, aic = 548.21
  
```

$\hat{\mu} = \frac{\hat{\phi}_0 + \hat{\phi}_1 - \hat{\phi}_2 - \hat{\phi}_3}{1 - \hat{\phi}_1 - \hat{\phi}_2 - \hat{\phi}_3}$

$se(\hat{\phi}_1) \rightarrow$ ทดสอบ $H_0: \phi_1 = 0$ vs $H_1: \phi_1 \neq 0$

โดยที่ค่าสัมประสิทธิ์ $t = \frac{\hat{\phi}_1}{se(\hat{\phi}_1)}$

$\phi_1 = 1.3294, \phi_2 = -0.4986, \phi_3 = 0.1334, \mu (= intercept) = 3.0553$ และมีค่า standard errors อยู่ในบรรทัด s.e.



ตัวอย่าง 3.3 ต่อ

ในโปรแกรม R ค่า intercept ที่ได้คือ μ มิใช่จุดตัดแกนในสมการที่ ?? ดังนั้นถ้าต้องการหากเราต้องการค่า $\hat{\mu} = \mu(1 - \phi_1 - \phi_2 - \phi_3) = 0.10937$ เราสามารถเขียนผลการประมาณค่าได้โดย

$$(1 - \frac{1.3294}{(0.0549)}L + \frac{0.4986}{(0.0878)}L^2 - \frac{0.1334}{(0.0549)}L^3)(y_t - \frac{3.0553}{(0.8102)}) = \varepsilon_t$$

โดยที่ค่าในวงเล็บคือ standard errors และ $\hat{\sigma}^2 = 0.3054$



ตัวอย่าง 3.3 ต่อ

```

1 > m2<-arima(int$diff_th_us, order=c(3,0,0),method=c("ML"))
2 > m2
3 Coefficients:
4     ar1      ar2      ar3  intercept
5     1.3295   -0.4987   0.1334    3.056
6 s.e.  0.0549    0.0878   0.0549    0.810
7
8 sigma^2 estimated as 0.3054:  log likelihood = -269.11,  aic = 548.21
9 > m3<-arima(int$diff_th_us, order=c(3,0,0),method=c("CSS"))
10
11 Coefficients:
12     ar1      ar2      ar3  intercept
13     1.3334   -0.5016   0.1346    3.0793
14 s.e.  0.0551    0.0880   0.0552    0.9195
15 sigma^2 estimated as 0.3082:  part log likelihood = -269.05

```

OLS



ຕົວອ່າງ 3.3 ຕ່ອ


AR(3)

ພວກເຮົາ ຖະນາຍາ

หลังจากที่เราได้ตัวประมาณค่าของพารามิเตอร์ทั้งหมดแล้วเราจะพิจารณา
ว่าค่า residuals นั้นยังมีความสัมพันธ์ระหว่างช่วงเวลาลงเหลืออยู่หรือไม่ หรือ
แบบจำลองเพียงพอหรือไม่ โดยการทดสอบ L-B test สำหรับ `m2$residuals`
ด้วยคำสั่งข้างล่าง  

② LB-Q 터터루 \hat{q}

```
1 > Box.test(m2$residuals, lag=12, type="Ljung")
2   Box-Ljung test
3   data: m2$residuals
4   X-squared = 14.0085, df = 12, p-value = 0.3002
5   > pv=1-pchisq(14.0085,9)
6   > pv
7   [1] 0.1220232
```



Wenwood

$$Q(12) = 14.0085 \sim \chi^2_{df=12-1=9} < C.V. = 16.9$$

wa df=9

$$Q(12) < c \nu \rightarrow \text{if } \sigma_{\text{min}} \left[H_0 : p_1 = \dots = p_m = 0 \right]$$


ມີມານຈົກສອງ AR(3) ເພີ້ມ ມີ
ກຸລາມກວດສອບນີ້ y_t

◀ வாய்மீ
+ IDH W.N. (பூர்வாகங்கள்)
வாய்மீ



การพยากรณ์ด้วยแบบจำลอง $AR(p)$

สมมุติให้เรากำลังอยู่ในช่วงเวลาที่ h แต่ต้องการที่จะพยากรณ์ไปข้างหน้า l คาบเวลา หรือสนับสนใจค่าของ y_{h+l} โดยที่ $l \geq 1$ เราเรียก h ว่า จุดเริ่มต้นการพยากรณ์ (forecast origin) และ l ว่า ขอบเขตการพยากรณ์ (forecast horizon)



การพยากรณ์ด้วยแบบจำลอง $AR(p)$

สมมุติให้เรากำลังอยู่ณ ช่วงเวลาที่ h แต่ต้องการที่จะพยากรณ์ไปข้างหน้า l คาบเวลา หรือสันใจค่าของ y_{h+l} โดยที่ $l \geq 1$ เราเรียก h ว่าจุดเริ่มต้นการพยากรณ์ (forecast origin) และ l ว่าขอบเขตการพยากรณ์ (forecast horizon)

กำหนดให้ $\hat{y}_h(l)$ เป็นค่าพยากรณ์ของ y_{h+l} โดยการพยากรณ์ดังกล่าวจะทำให้ฟังก์ชันสูญเสียที่เกิดจากการค่าผิดพลาดกำลังสอง (squared errors) น้อยที่สุด

$$E \left[(y_{h+l} - \hat{y}_h(l))^2 | F_h \right] \leq \min_g E \left[(y_{h+l} - g)^2 | F_h \right]$$

↑ ດາວວະ ດັນທັກຫຼິ້ນ

โดยที่ F_h เป็นข้อมูลที่มีทั้งหมดในคาบที่ h และเราเรียก $\hat{y}_h(l)$ ว่าค่าพยากรณ์ของ y_t ในช่วงหน้า l ความเมื่อเริ่มต้นการพยากรณ์อยู่ที่ $h = 1$

~~Conditional Expected Value vs Y_{h+1} ចូលទៅ~~

$$\hat{Y}_h(l) = E(Y_{h+1} | \text{Info } \tilde{F}_h)$$

~~ក្នុង h~~

~~វគ្គសារណ៍~~

ค่าพยากรณ์ไปข้างหน้า 1 步 มาจาก $AR(p)$
 $y_t = \phi_0 + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \epsilon_t$
 $y_{t+1} = \phi_0 + \phi_1 y_{t+1-1} + \phi_2 y_{t+1-2} + \dots + \phi_p y_{t+1-p} + \epsilon_{t+1}$

ทราบว่าค่า $y_{t+1} = \phi_0 + \phi_1 y_{t+1-1} + \dots + \phi_p y_{t+1-p} + \epsilon_{t+1}$ ตัวพยากรณ์ที่ ϵ_{t+1}
 จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมิเงื่อนไข (conditional expectation) ขั้นตอน 2 หาหัวใจ $E(y_{t+1} | F_t)$

$$\hat{y}_t(1) = E(y_{t+1} | F_t) \quad \text{ประมาณ}$$

$$y_{t+1} = E(\phi_0 + \phi_1 y_t + \phi_2 y_{t-1} + \dots + \phi_p y_{t+1-p} + \epsilon_{t+1} | F_t)$$

$$\begin{aligned} &= E(\phi_0 | F_t) + E(\phi_1 y_t | F_t) + \dots + E(\phi_p y_{t+1-p} | F_t) + E(\epsilon_{t+1} | F_t) \\ &= \underbrace{\phi_0}_{\text{คงต่อ}} + \underbrace{\phi_1 E(y_t | F_t)}_{\substack{\text{ประมาณ} \\ = y_t}} + \underbrace{\phi_p y_{t+1-p}}_{\substack{\text{คงต่อ} \\ = 0}} + E(\epsilon_{t+1} | F_t) \\ &= \underbrace{\phi_0}_{\substack{\text{คงต่อ} \\ = 0}} + \underbrace{\phi_1 y_t}_{\substack{\text{ประมาณ} \\ = y_t}} + \underbrace{\phi_p y_{t+1-p}}_{\substack{\text{คงต่อ} \\ = 0}} + E(\epsilon_{t+1} | F_t) \end{aligned}$$

$$\hat{y}_t(1) = \phi_0 + \phi_1 y_t + \dots + \phi_p y_{t+1-p} \leftarrow \begin{array}{l} \text{คงต่อ} \\ \text{ประมาณ} \end{array}$$



ค่าพยากรณ์ไปข้างหน้า 1 คาบจาก AR(p)

เราพบว่าค่า \hat{y}_{h+1} ที่
จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมิเงื่อนไข (conditional expectation)

$$\hat{y}_h(1) =$$

forecast error

และค่าผิดพลาดจากการพยากรณ์เท่ากับ $e_h(1) = \hat{y}_{h+1} - \hat{y}_h(1)$

$$= (\cancel{\phi_0 + \phi_1 y_h + \dots + \phi_p y_{h+1-p}} + \underline{\varepsilon_{h+1}}) - (\cancel{\phi_0 + \phi_1 y_h + \dots + \phi_p y_{h+1-p}})$$

$$e_h(1) = \varepsilon_{h+1} \quad [\text{หมายความว่า } \varepsilon_{h+1} \text{ ไม่รวมใน } \hat{y}_h(1)]$$




ค่าพยากรณ์ไปข้างหน้า 1 คาบจาก $AR(p)$

เราพบว่าค่า $y_{h+1} = \phi_0 + \phi_1 y_{h+1-1} + \dots + \phi_p y_{h+1-p} + \varepsilon_{h+1}$ ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมิเงื่อนไข (conditional expectation)

$$\hat{y}_h(1) =$$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ $e_h(1) = \varepsilon_{h+1}$

Variance vs forecast error
และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าหนึ่งคาบท่ากับ $Var(e_h(1)) = Var(\varepsilon_{h+1}) = \sigma^2$



forecast Interval



ค่าพยากรณ์ไปข้างหน้า 1 คาบจาก $AR(p)$

เราพบว่าค่า $y_{h+1} = \phi_0 + \phi_1 y_{h+1-1} + \dots + \phi_p y_{h+1-p} + \varepsilon_{h+1}$ ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมิเงื่อนไข (conditional expectation)

$$\hat{y}_h(1) =$$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ $e_h(1) =$

และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าหนึ่งคาบท่ากับ $Var(e_h(1)) =$

95% forecast Interval
 เราสามารถสร้างช่วงความเชื่อมั่น 95 % ของการพยากรณ์ไปข้างหน้า 1 คาบได้โดยช่วงดังกล่าวจะเท่ากับ $\hat{y}_h(1) \pm 1.96sd(e_h(1))$

$$\uparrow Z_{\alpha/2} = 1.96$$

$$sd(e_h(1)) = \sqrt{Var(e_h)}$$

ค่าพยากรณ์ไปข้างหน้า 2 คาบจาก $AR(p)$

เราพบว่าค่า $y_{h+2} = \phi_0 + \phi_1 y_{h+2-1} + \dots + \phi_p y_{h+2-p} + \varepsilon_{h+2}$ ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข (conditional expectation)

$$\begin{aligned}
 ② \hat{y}_h(2) &= E(Y_{h+2} | F_h) \\
 &= \phi_0 + \underbrace{\phi_1 E(Y_{h+1} | F_h)}_{\hat{Y}_h(1)} + \underbrace{\phi_2 E(Y_h | F_h)}_{= Y_h} + \dots + \underbrace{\phi_p E(Y_{h+2-p} | F_h)}_{= Y_{h+2-p}} + E(E_{h+2} | F_h) \\
 \hat{Y}_h(2) &= \phi_0 + \phi_1 \hat{Y}_h(1) + \phi_2 Y_h + \dots + \phi_p Y_{h+2-p} \\
 &\quad \uparrow \\
 &\quad \phi_0 + \phi_1 Y_h + \dots + \phi_p Y_{h+1-p}
 \end{aligned}$$



ค่าพยากรณ์ไปข้างหน้า 2 คาบจาก AR(p)

ทราบว่าค่า $y_{h+2} = \phi_0 + \phi_1 y_{h+2-1} + \dots + \phi_p y_{h+2-p} + \varepsilon_{h+2}$ ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมิเงื่อนไข (conditional expectation)

$$\hat{y}_h(2) =$$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ = $\text{ด้าว} - \text{ดัมเบลล์}$

$$\begin{aligned}
 e_h(2) &= Y_{h+2} - \hat{Y}_h(2) \\
 &= (\phi_0 + \phi_1 Y_{h+1} + \phi_2 Y_h + \dots + \phi_p Y_{h+2-p} + \varepsilon_{h+2}) - (\phi_0 + \phi_1 Y_{h+1} + \phi_2 Y_h + \dots + \phi_{h+2-p} Y_{h+2-p}) \\
 &= \phi_1 (Y_{h+1} - \hat{Y}_h(1)) + \varepsilon_{h+2} \\
 &\quad \equiv e_h(1) \\
 &= \varepsilon_{h+1} + \varepsilon_{h+2} \quad (\text{โดย } \varepsilon_{h+1}, \varepsilon_{h+2})
 \end{aligned}$$




ค่าพยากรณ์ไปข้างหน้า 2 步 จาก $AR(p)$

เราพบว่าค่า $y_{h+2} = \phi_0 + \phi_1 y_{h+2-1} + \dots + \phi_p y_{h+2-p} + \varepsilon_{h+2}$ ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข (conditional expectation)

$$\hat{y}_h(2) =$$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ
 $e_h(2) =$

$$\begin{aligned} \text{และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าหนึ่ง步 ค่าเท่ากับ} \\ Var(e_h(2)) &= Var(\phi_1 \varepsilon_{h+1} + \varepsilon_{h+2}) \stackrel{\text{ind.}}{=} Var(\phi_1 \varepsilon_{h+1}) + Var(\varepsilon_{h+2}) \\ \text{เราจะสังเกตได้ว่า } Var(e_h(2)) &\geq Var(e_h(1)) \\ &= \phi_1^2 Var(\varepsilon_{h+1}) + Var(\varepsilon_{h+2}) \\ &= \sigma^2 (1 + \phi_1^2) \sigma^2 \end{aligned}$$



ตัวอย่าง 3.3 ผลการพยากรณ์ $\hat{y}_t = f_{TH} - f_{VS} \Rightarrow AR(3)$

$m4$ ไฟฟ้า $\xrightarrow{\text{พนักงาน}} [1:312] \Rightarrow arima (AR(3))$

\hat{y} 12 ชั่วโมง $\xrightarrow{\text{forecast}}$ จันทร์ 312 $T = 324$

```

1 > m4.pred=predict(m4,n.ahead=12)
2 > m4.pred
3 $pred หัวหน้า ล
4 Time Series: (1) แบบจำลอง
5 Start = 313
6 End = 324
7 Frequency = 1
8 [1] 1.803828 1.875260 1.943271 2.005150 2.062937 2.117888 2.170297 2.220198
9 [9] 2.267658 2.312788 2.355708 2.396527
10 $se se vs forecast error (se(e_n))
11 Time Series:
12 Start = 313
13 End = 324
14 Frequency = 1
15 [1] 0.5622779 0.9342948 1.1737163 1.3399272 1.4696143 1.5777365 1.6700163
16 [8] 1.7494732 1.8183586 1.8784737 1.9312318 1.9777417

```

AR(3)
sample \leftarrow out of sample

$m4.pred$ \downarrow pred

vector \downarrow \hat{y}

$$\hat{y} \pm 1.96 \cdot se \Rightarrow \text{lower} \quad \Rightarrow \text{upper}$$

int.Th-vs[313:324]

ดูว่า

$$m4.pred + 1.96 * m4.pred $se$$

ล่างกว่า
ที่จริง
ดังนั้น

ไฟฟ้า \downarrow วันที่ 1-324 (m_1)
 $\text{predict}(m_1, n.ahead=12) \rightarrow 325-336$!

