

# แบบจำลองมูววิ้งเอเวอเรจ (Moving Average; $MA(q)$ )

แบบจำลองนี้มีพื้นฐานมาจากแนวคิดที่ว่าอนุกรมเวลาเส้นตรงนิ่ง (stationary) สามารถเขียนให้อยู่ในรูป infinite MA (linear comb.)

$$y_t = \varepsilon_t + \alpha_1 \varepsilon_{t-1} + \alpha_2 \varepsilon_{t-2} + \dots$$

*coeff → weight*

แบบจำลองมูววิ้งเอเวอเรจอันดับ  $q$  และเขียนแทนด้วย  $MA(q)$  และแสดงได้

ด้วยสมการ

Moving Average  
of order  $q$   
( $MA(q)$ )

$$y_t = \underbrace{\mu}_{\text{Intercept}} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

$$= \sum_{j=0}^q \theta_j \varepsilon_{t-j} = \theta(L) \varepsilon_t \quad (2.37)$$

$\theta(L)$   
MA polynomial

โดยที่  $\theta_0 = 1$

$MA(q) \rightarrow$  คุณสมบัติ: จาก  $\theta_1, \dots, \theta_q$

แบบจำลอง  $MA(1)$ 

สมมติให้  $y_t$  เป็นอนุกรม  $MA(1)$  โดยที่  $\varepsilon_t$  มีคุณสมบัติเป็นไวทนออกซ์

- 1)  $E(\varepsilon_t) = 0$
- 2)  $Var(\varepsilon_t) = \sigma^2$  คงที่
- 3)  $Cov(\varepsilon_t, \varepsilon_{t-j}) = 0 \quad j \neq 0$

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} \quad (2.38)$$

ค่าคาดหวังของ  $y_t$ ,  $E(y_t)$ , เท่ากับ

$$E(y_t) = E(\mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}) = E(\mu) + E(\varepsilon_t) + \theta_1 E(\varepsilon_{t-1})$$

$\underbrace{E(\mu)}_{\mu} + \underbrace{E(\varepsilon_t)}_{=0} + \theta_1 \underbrace{E(\varepsilon_{t-1})}_{=0}$

$E(y_t) = \mu$

ค่าความแปรปรวนของ  $y_t$  ( $\gamma_0$ )

$$\begin{aligned} \gamma_0 = Var(y_t) &= E(y_t - E(y_t))^2 \\ &= E[(\cancel{\mu} + \varepsilon_t + \theta_1 \varepsilon_{t-1}) - \cancel{\mu}]^2 \\ &= E[(\varepsilon_t + \theta_1 \varepsilon_{t-1})^2] \\ &= E[\varepsilon_t^2 + 2\varepsilon_t \theta_1 \varepsilon_{t-1} + \theta_1^2 \varepsilon_{t-1}^2] \\ &= E(\varepsilon_t^2) + 2\theta_1 E(\varepsilon_t \varepsilon_{t-1}) + \theta_1^2 E(\varepsilon_{t-1}^2) \end{aligned}$$

$\underbrace{E(\varepsilon_t^2)}_{\sigma^2} + 2\theta_1 \underbrace{E(\varepsilon_t \varepsilon_{t-1})}_{Cov(\varepsilon_t, \varepsilon_{t-1})=0} + \theta_1^2 \underbrace{E(\varepsilon_{t-1}^2)}_{\sigma^2}$

$\gamma_0 = \sigma^2 [1 + \theta_1^2]$

แบบจำลอง  $MA(1)$ 

one-lag autocovariance

$$\begin{aligned}
 \gamma_1 &= \text{Cov}(y_t, y_{t-1}) = E[(y_t - E(y_t))(y_{t-1} - E(y_{t-1}))] \\
 &= E[(\cancel{\mu} + \cancel{\varepsilon_t} + \theta_1 \varepsilon_{t-1}) - \cancel{\mu}] [\cancel{\mu} + \cancel{\varepsilon_{t-1}} + \theta_1 \varepsilon_{t-2}) - \cancel{\mu}] \\
 &= E(\underbrace{\varepsilon_t \varepsilon_{t-1}}_{\text{Cov}(\varepsilon_t, \varepsilon_{t-1})}) + \underbrace{\theta_1 E(\varepsilon_t \varepsilon_{t-2})}_{=0} + \underbrace{\theta_1 E(\varepsilon_{t-1}^2)}_{\sigma^2} + \underbrace{\theta_1^2 E(\varepsilon_{t-1} \varepsilon_{t-2})}_{=0}
 \end{aligned}$$

$$\gamma_1 = \theta_1 \cdot \sigma^2$$

two-lag autocovariance

$$\begin{aligned}
 \gamma_2 &= \text{Cov}(y_t, y_{t-2}) = E[(y_t - E(y_t))(y_{t-2} - E(y_{t-2}))] \\
 &= E[(\varepsilon_t + \theta_1 \varepsilon_{t-1})(\varepsilon_{t-2} + \theta_1 \varepsilon_{t-3})] \\
 &= E(\text{cross}) = 0
 \end{aligned}$$

$$\gamma_3 = 0$$

$$\gamma_j = 0 \quad ; j > 1 \quad \text{สำหรับ } y_t \sim MA(1)$$



## แบบจำลอง MA(1)


$$\rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{\theta_1 \cdot \cancel{\sigma^2}}{(1+\theta_1^2) \cdot \cancel{\sigma^2}} \quad \rho_j = 0; j > 1$$

$$\rho_2 = \frac{\gamma_2}{\gamma_0} = 0$$

จากสมการข้างต้นจะเห็นได้ว่า  $\text{Cov}(y_t, y_{t-k}) = 0$  สำหรับ  $k \geq 2$  ในกรณีที่  $y_t$  เป็น MA(1)

**k-lag autocorrelation** เท่ากับ

$$\rho_k = \begin{cases} \frac{\theta_1}{1+\theta_1^2}, & k = 1 \\ 0, & k > 1 \end{cases}$$



จะเห็นได้ว่า  $y_t$  มีสหสัมพันธ์กับ  $y_{t-1}$  แต่ไม่สัมพันธ์กับ  $y_{t-2}, \dots$  ซึ่งแตกต่างจาก AR(1)

เราจะเห็นได้ว่าอนุกรมเวลา  $y_t$  ที่เป็นกระบวนการเคลื่อนที่เฉลี่ยจะเป็นอนุกรมเวลานิ่ง (stationary) เสมอ

MA(1) เป็น stationary

with  $\theta_1$  ใดๆก็ได้

- 1)  $E(y_t)$  คงที่ ( $\mu$ ) ✓
  - 2)  $\text{Var}(y_t)$  คงที่  $\sigma^2(1+\theta_1^2)$  ✓
  - 3)  $\text{Cov}(y_t)$  ไม่ขึ้นกับ  $t$  ✓
- $\gamma_1 = \sigma^2\theta_1$  ✓  $\gamma_2 = 0$  ✓

# ตัวอย่างข้อมูลที่เป็น $MA(1)$

Figure: การจำลองข้อมูลกระบวนการ  $MA(1)$  ที่มีค่าสัมประสิทธิ์  $\theta = 0.5$

drop  $\mu$  down

ACF

AR(1) MA(1)

$y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1}$

polynomial

$y_t = (1 + \theta_1 L) \varepsilon_t$

$MA(1) \Rightarrow AR$

Note:  $1 + z + z^2 + \dots = \frac{1}{1-z}$  if  $|z| < 1$

$\frac{1}{1 + \theta_1 L} = \frac{1}{1 - (-\theta_1 L)} = 1 + (-\theta_1 L) + (-\theta_1 L)^2 + (-\theta_1 L)^3 + \dots$

$= 1 - \theta_1 L + \theta_1^2 L^2 - \theta_1^3 L^3 + \dots$

$y_t (1 - \theta_1 L + \theta_1^2 L^2 - \theta_1^3 L^3 + \dots) = \varepsilon_t$

$y_t - \theta_1 y_{t-1} + \theta_1^2 y_{t-2} - \theta_1^3 y_{t-3} + \dots = \varepsilon_t$

$AR(\infty) \Rightarrow MA(1)$

$MA(1) \Rightarrow AR(\infty)$

หมายเหตุ: 1d

$AR(\infty)$

เงื่อนไข  $|\theta_1| < 1$

Invertible process  $\rightarrow y_t$  เป็นอนุกรมเวลาที่สามารถ Invertible ได้ AR ได้.

ฟังก์ชันสหสัมพันธ์ร่วมในตัวเองของกระบวนการ  $MA(1)$  สองกระบวนการต่อไปนี้จะมีลักษณะที่เหมือนกัน

$$\rho_1 = \frac{\theta_1}{1 + \theta_1^2}$$

$$x_t = w_t + \frac{1}{5}w_t, \quad w_t \sim iidN(0, 25)$$

$$\rightarrow \rho_1 = \frac{5}{26}$$

[ $MA(1)$  จะสามารถ แปลงเป็น  $AR(\infty)$  ได้]

และ


$$y_t = v_t + 5v_t, \quad v_t \sim iidN(0, 1)$$

เราต้องเลือกที่จะใช้แบบจำลองไหน ซึ่งเราจะเลือกแบบจำลองที่สามารถเขียนแบบจำลองในรูปของ infinite AR representation โดยที่อนุกรมที่มีลักษณะดังกล่าวเราจะเรียกว่ากระบวนการที่หาตัวผกผันได้ (invertible process)

เงื่อนไขที่  $MA(1)$  จะเป็นกระบวนการที่หาตัวผกผันได้ คือ  $|\theta_1| < 1$

Partial ACF for  $MA(1)$

↳ สหสัมพันธ์ใน  $y_{t-j}$  ใน AR



จาก slide 4 แล้ว

$$y_t = \theta_1 y_{t-1} - \theta_1^2 y_{t-2} + \theta_1^3 y_{t-3} - \dots$$

# แบบจำลอง MA(2)

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} \rightarrow E(y_t) = \mu$$

กำหนดให้  $y_t$  เป็นกระบวนการ MA(2) ซึ่งสามารถแสดงได้ด้วยสมการ


$$\underline{y_t - \mu} = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}$$

เมื่อพิจารณาค่าสหสัมพันธ์ในตัวเองของ MA(2) จะได้

$$\begin{aligned} 2) \text{var}(y_t) &= E(y_t - \mu)^2 \\ &= E(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2})^2 \\ &= \sigma^2 + \theta_1^2 \sigma^2 + \theta_2^2 \sigma^2 + \text{E cross term} \end{aligned}$$

$$\gamma_0 = \sigma^2(1 + \theta_1^2 + \theta_2^2)$$

ACF MA(2)



PACF ของ MA(2)

$$\begin{aligned} y_t &= \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} \\ &= (1 + \theta_1 L + \theta_2 L^2) \varepsilon_t \end{aligned}$$

$$\begin{aligned} 3) \gamma_1 &= E[(y_t - \mu)(y_{t-1} - \mu)] \\ &= E[(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}) \\ &\quad (\varepsilon_{t-1} + \theta_1 \varepsilon_{t-2} + \theta_2 \varepsilon_{t-3})] \end{aligned}$$

$$\rho_0 = \frac{\gamma_0}{\gamma_0} = 1$$

$$\rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{(\theta_1 + \theta_2 \theta_1)}{(1 + \theta_1^2 + \theta_2^2)}$$

$$\rho_2 = \frac{\gamma_2}{\gamma_0} = \frac{\theta_2}{(1 + \theta_1^2 + \theta_2^2)}$$

$$\rho_3 = \frac{\gamma_3}{\gamma_0} = 0$$

$$\rho_j = \frac{\gamma_j}{\gamma_0} = 0$$

$\rightarrow$  MA(q)  $\rho_j = 0$   $j > q$

$$\gamma_3 = 0$$

$$\gamma_p = 0$$



แบบจำลอง  $MA(q)$ 

$MA(2) \Rightarrow AR(\infty)$   
 PACF ของ  $MA(2)$   
 ที่อนันต์จะลดลง

$$\frac{y_t}{(1+\theta_1 L + \theta_2 L^2)} = \varepsilon_t$$

$$\frac{1}{(1+\theta_1 L + \theta_2 L^2)} = \frac{1}{(1+a_1 L)(1+a_2 L)}$$

$$= (1+(-a_1 L) + (-a_1 L)^2 + \dots)(1+(-a_2 L) + (-a_2 L)^2 + \dots)$$

แบบจำลอง  $MA(q)$  สามารถเขียนในรูปสมการดังนี้

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}, \quad \varepsilon_t \sim WN(0, \sigma^2)$$

แบบจำลอง  $MA(q)$  นี้และ ergodic ถ้าค่า  $\theta_1, \dots, \theta_q$  มีค่าจำกัด และสามารถหาตัวผกผันได้ถ้าราก (roots) ของพหุนาม MA

$$\theta(m) = 1 + \theta_1 m + \dots + \theta_q m^{t-q} = 0$$

มีค่าสัมบูรณ์ (หรือค่าโมดูลัส) ของรากของพหุนามมากกว่า 1





แบบจำลอง  $MA(q)$ 

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

โมเมนต์ของกระบวนการ  $MA(q)$  ได้ดังนี้

$$E(y_t) = \mu$$

$$\gamma_0 = \text{Var}(y_t) = \sigma^2 (1 + \theta_1^2 + \theta_2^2 + \dots + \theta_q^2)$$

$$\gamma_1 =$$

$$\gamma_2 =$$

$$\vdots$$

$$\gamma_q =$$


$$\gamma_{q+1} = 0, \dots$$

และค่าสหสัมพันธ์ในตัวเองจะเท่ากับ

$$\rho_j = \frac{\gamma_j}{\gamma_0} =$$

ในขณะที่ PACF จะมีค้อยลลดลงไป

ACF ของ  $MA(q)$



PACF ของ  $MA(q)$



การประมาณค่าแบบจำลอง  $MA(q) \rightarrow$  Maximum Likelihood Est.

การประมาณค่า MLE เป็นวิธีการทั่วไปที่ใช้ในการประมาณค่าแบบจำลอง  $MA(q)$

ประมาณค่าแบบจำลอง  $MA(1)$  ซึ่งสามารถเขียนได้ดังนี้

$$y_t = \mu + \varepsilon_t + \theta \varepsilon_{t-1}$$

$\swarrow$   $\mu$  (ค่าคงที่)       $\swarrow$   $\theta$  (Parameter)

โดยที่  $\varepsilon_t \sim iidN(0, \sigma_\varepsilon^2)$  ในกรณีที่ conditional MLE เราจะสมมติให้  $\varepsilon_0 = 0$  ดังนั้น  $y_1 = \mu + \varepsilon_1$

$$y_1 | \varepsilon_0 = 0 \sim N(\mu, \sigma_\varepsilon^2)$$

จากข้อมูลในคาบที่ 1 จะได้ว่า  $y_2 | y_1 = \mu + \varepsilon_2 + \theta \varepsilon_1$  และได้ฟังก์ชันความน่าจะเป็น

$$f_{y_2|y_1} = \frac{1}{\sqrt{2\pi\sigma_\varepsilon^2}} \exp \left[ \frac{-(y_2 - \mu - \theta \varepsilon_1)^2}{2\sigma_\varepsilon^2} \right]$$

Likelihood function  
 $\rightarrow$  joint pdf of  $y_t$   
 $t=1, \dots, T$

# การประมาณค่าแบบจำลอง $MA(q)$

หากใช้กระบวนการเดียวกันไปเรื่อย เราจะสามารถหาค่า

$\varepsilon_t = y_t - \mu - \theta\varepsilon_{t-1}$  และสร้าง conditional likelihood function ได้

Max

$$L(\mu, \theta, \sigma_\varepsilon^2) = \prod_{t=2}^T f_{y_t|y_{t-1}}$$

↓

$\hat{\mu}, \hat{\theta}, \hat{\sigma}_\varepsilon^2$   
MLE

$$= (2\pi\sigma_\varepsilon^2)^{-(T-2)/2} \exp \left[ -\frac{\sum_{t=2}^T \overbrace{(y_t - \mu - \theta\varepsilon_{t-1})^2}^{\varepsilon_t^2}}{2\sigma_\varepsilon^2} \right] \quad (2.50)$$

สมการ (2.50) เราไม่สามารถหาตัวประมาณค่าได้ด้วยการวิเคราะห์อนุพันธ์เช่น  
ในกรณี  $AR$  ในกรณีนี้เราจำเป็นต้องใช้วิธีการทางตัวเลขด้วยคอมพิวเตอร์เพื่อหา  
ค่า  $\hat{\theta}$  ที่ทำให้  $L(\mu, \theta, \sigma_\varepsilon^2)$  มีค่าสูงที่สุด



## ตัวอย่างที่ 3.6

ในตัวอย่างนี้เราจะพิจารณาผลได้ตอบแทนรายเดือนของการลงทุนใน  
ตลาดหลักทรัพย์แห่งประเทศไทย โดยใช้ข้อมูลราคาปิดรายเดือนตั้งแต่ เมษายน  
2518 ถึงเดือนพฤศจิกายน 2555

Figure: ACF และ PACF ของผลได้ตอบแทนรายเดือนจาก SET

1. เปรียบเทียบ ผลต่าง  
ของ  $y_t$ ?

ACF


ที่ lag 1, 2

$p_1$  และ  $p_2$  มีค่า  
ใกล้เคียงศูนย์

$p_j = 0$   $j=3, \dots$   
Sample ACF

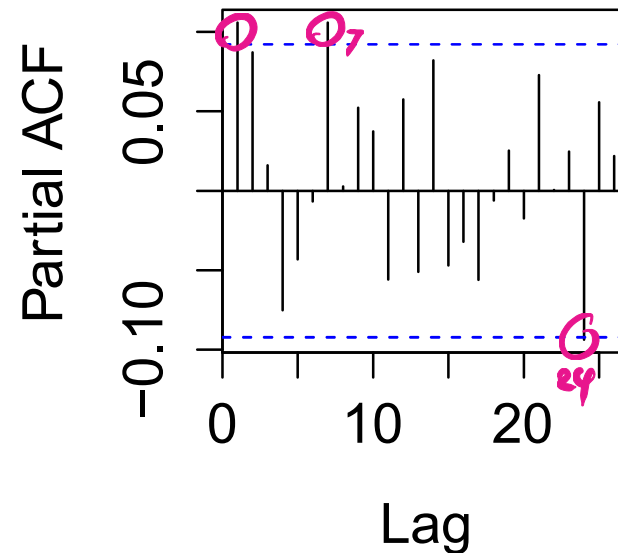
lag  
1 2 3 ...

ACF



ได้ผลได้ของ  $MA(2)$

PACF



→ PACF  
ใช้ตรวจสอบ  
ว่าค่าเป็นศูนย์

## ตัวอย่างที่ 3.6

แบบจำลองที่เหมาะสมน่าจะเป็น  $MA(2)$  ซึ่งประมาณค่าได้ด้วยคำสั่ง arima โดยกำหนดอันดับเป็น  $c(0,0,2)$

↓  
AR I MA(2)

```

1 > m1<-arima(ret, order=c(0,0,2))
2 > m1
3 Call:
4 arima(x = ret, order = c(0, 0, 2))
5
6 Coefficients:
7      ma1      ma2 intercept
8 0.08866 0.1001 0.0057
9 s.e. 0.0469 0.0487 0.0046
10
11 sigma^2 estimated as 0.006795: log likelihood = 485.64, aic = -963.28

```

estimate  
s.e.  
sigma^2

$$(y_t - 0.0057) = \varepsilon_t + 0.0886\varepsilon_{t-1} + 0.1001\varepsilon_{t-2}$$

(se) (se) (se)

ทดสอบว่าแบบจำลอง  $MA(2)$  เป็น white noise

$H_0: \varepsilon_t$  เป็น WN.

ใช้ LB  $Q(n)$  กับ  $\hat{\varepsilon}_t$



## ตัวอย่างที่ 3.6


เราสามารถพิจารณาความพอเพียงของแบบจำลอง  $m1$  ได้ด้วยการทดสอบ L-B สำหรับ residuals ดังคำสั่งต่อไปนี้

```

1 > Box.test(m1$residuals, lag=12, type="Ljung")
2 ^^IBox-Ljung test
3 data: m1$residuals
4 X-squared = 13.6075, df = 12, p-value = 0.3265
5 > pv=1-pchisq(13.6075,12-2) ← ค่า P.
6 > pv
7 [1] 0.1916591

```

LB  $Q(12)$  ทด  $\hat{\chi}^2 = 13.6075 \sim \chi^2_{df=m-q=12-2}$



ทำไมสมมติว่า  $H_0: \epsilon_t$  เป็น WN  $\Rightarrow$  แทนค่าเฉลี่ยของ  $y_t$  ในอนุกรม  $y_t$

$$y_t = \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} \Rightarrow \text{พยากรณ์?}$$

การพยากรณ์ไปข้างหน้า 1 คาบ  $MA(1)$   $y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}$   
 $h \sim h+1$  ①  $y_{h+1} = \mu + \varepsilon_{h+1} + \theta_1 \varepsilon_h$

พิจารณาแบบจำลอง  $MA(1)$ :  $y_{h+1} = \mu + \varepsilon_{h+1} + \theta_1 \varepsilon_h$  ตัวพยากรณ์ที่จะ  
 ทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข (conditional  
 expectation) ②

$$\hat{y}_h(1) = E(y_{h+1} | F_h) = E(\mu + \varepsilon_{h+1} + \theta_1 \varepsilon_h | F_h) = \mu + \underbrace{E(\varepsilon_{h+1} | F_h)}_{\text{ไม่ทราบ} = 0} + \theta_1 \underbrace{E(\varepsilon_h | F_h)}_{\text{ทราบ} = \varepsilon_h}$$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ  $e_h(1) =$

forecast error พหุคูณ 1 คาบ = observed - observed

$$e_h(1) = (\mu + \varepsilon_{h+1} + \theta_1 \varepsilon_h) - (\mu + \theta_1 \varepsilon_h) = \varepsilon_{h+1}$$

$$\hat{y}_h(1) = \mu + \theta_1 \varepsilon_h$$

และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าหนึ่งคาบเท่ากับ

$$Var(e_h(1)) = Var(\varepsilon_{h+1}) = \sigma^2$$

ในทางปฏิบัติค่า  $\varepsilon_h$  จะสามารถคำนวณได้สองวิธีคือ

1) สมมติให้  $\varepsilon_0 = 0$

แทนค่า

$$\varepsilon_1 = y_1 - \mu - \theta_1(0)$$

$$\varepsilon_2 = y_2 - \mu - \theta_1 \varepsilon_1$$

$$\varepsilon_h = y_h - \mu - \theta_1 \varepsilon_{h-1}$$

2) หรือใช้ค่า  $\hat{\varepsilon}_h$  ที่เป็นค่า residual จากการประมาณค่า  $MA(1)$

$$\hat{\varepsilon}_h = y_h - \mu - \theta_1 \hat{\varepsilon}_{h-1}$$

$$MA(1) \quad y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

$$\varepsilon_t = y_t - \mu - \theta_1 \varepsilon_{t-1}$$



## การพยากรณ์ไปข้างหน้า 2 คาบ

พิจารณา  $y_{h+2} = \mu + \varepsilon_{h+2} + \theta_1 \varepsilon_{h+1}$  ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียที่น้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข

$$\hat{y}_h(2) = E(y_{h+2} | F_h) = \mu$$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ  $e_h(2) = \varepsilon_{h+2} + \theta_1 \varepsilon_{h+1}$

และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าสองคาบเท่ากับ

$$\text{Var}(e_h(2)) = \text{Var}(\varepsilon_{h+2} + \theta_1 \varepsilon_{h+1})$$

ind  $\text{Var}(\varepsilon_{h+2}) + \theta_1^2 \text{Var}(\varepsilon_{h+1}) = (1 + \theta_1^2) \sigma^2$

Forecast Interval =  $\hat{y} \pm t \cdot \sqrt{\text{var}(e_h)}$

$\mu \pm t \cdot \sqrt{(1 + \theta_1^2) \sigma^2}$

$\mu - t \cdot \sqrt{(1 + \theta_1^2) \sigma^2}$

Autoregressive Moving Average;  $ARMA(p, q)$ 

แบบจำลองที่มีทั้งส่วนประกอบของ AR และ MA ซึ่งหาก  $y_t$  เป็นกระบวนการที่เรียกว่าแบบจำลองออโตรีเกรสซีฟมูวี่งเอเวอเรจอันดับ  $(p, q)$  หรือเรียกย่อๆว่า อารมา  $ARMA(p, q)$  ถ้า  $y_t$  มีค่าเฉลี่ยไม่เท่ากับศูนย์ เราจะสามารถอธิบาย  $y_t$  ได้ด้วย

$y_t$  + AR part  $y_t$  + MA part line comb of  $\varepsilon_t$

$$(1) \quad y_t = \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} \quad (2.53)$$

ไม่สุ่ม

หากเรากำหนดให้  $\alpha = \mu(1 - \phi_1 - \dots - \phi_p)$  และสามารถเขียนแบบจำลองสำหรับ  $y_t$  ได้เป็น

$$(2) \quad y_t = \alpha + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} \quad (2.54)$$

สุ่ม

$$\varepsilon_t \sim WN(0, \sigma^2)$$



Autoregressive Moving Average;  $ARMA(p, q)$ 

เราสามารถเขียนสมการอาร์มาได้ในรูป AR และ MA polynomials ได้ดังนี้

$$\textcircled{2} \quad \underline{\phi(L)y_t} = \underline{\theta(L)\varepsilon_t}$$

โดยที่  $\phi(L) = 1 - \phi_1 L - \dots - \phi_p L^p$  และ  $\theta(L) = 1 + \theta_1 L + \dots + \theta_q L^q$

พิจารณาคูณสมบัติของแบบจำลองอาร์มาได้ด้วยการพิจารณา  $ARMA(1, 1)$

คุณสมบัติของ  
 $ARMA(p, q)$

สมการ  $ARMA(1, 1)$

$$y_t = \phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1} \quad (2.55)$$

โดยที่  $\varepsilon_t \sim iidN(0, \sigma^2)$

$$\begin{aligned} 1) \quad E(y_t) &= E(\phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}) \\ &= \phi E(y_{t-1}) + \cancel{E(\varepsilon_t)} + \theta \cancel{E(\varepsilon_{t-1})} \end{aligned}$$

สมมติ  $E(y_t) = \mu$   
stationary

$$E(y_t) = 0$$

$$y_t = \alpha + \phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}$$

$$E(y_t) = \frac{\alpha}{1-\phi} = \mu$$

$$(y_t - \mu) = \phi(y_{t-1} - \mu) + \varepsilon_t + \theta \varepsilon_{t-1}$$

คุณสมบัติ ARMA(1,1)  $\rightarrow$  2)  $\text{Var}(Y_t) = E(Y_t^2)$   $E(\varepsilon_t Y_{t-j}) = 0$  for  $j > 0$

$$Y_t = \phi Y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}$$

เราใช้ความสัมพันธ์ต่อไปนี้

$$E(\varepsilon_t Y_t) = E[\varepsilon_t (\phi Y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1})]$$

$$= \phi E(Y_{t-1} Y_t) + E(\varepsilon_t^2) + \theta E(\varepsilon_t \varepsilon_{t-1})$$

?                      ?

~~$E(\varepsilon_{t-1} Y_t) =$~~

$$= \phi E(\varepsilon_t Y_{t-1}) + E(\varepsilon_t^2) + \theta E(\varepsilon_t \varepsilon_{t-1})$$

$\varepsilon_t, \varepsilon_{t-1}, \varepsilon_{t-2}, \dots$                        $\text{Cov} = 0$

~~$E(Y_t) =$~~

$$E(\varepsilon_t Y_t) = \sigma^2 \quad (*)$$

$E(\varepsilon_{t-1} Y_t) = E[\varepsilon_{t-1} (\phi Y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1})]$

$$= \phi E(\varepsilon_{t-1} Y_{t-1}) + E(\varepsilon_{t-1} \varepsilon_t) + \theta E(\varepsilon_{t-1}^2)$$

$\text{Cov} = 0$                        $\sigma^2$

$$E(\varepsilon_{t-1} Y_t) = \sigma^2(\phi + \theta)$$

คุณสมบัติ  $ARMA(1,1)$ คุณสมบัติของ  $ARMA(1,1)$  จะได้

$$\gamma_0 = \underbrace{\phi E(Y_t Y_{t-1})}_{\gamma_1} + \underbrace{E(Y_t \varepsilon_t)}_{\sigma^2} + \theta \underbrace{E(Y_t \varepsilon_{t-1})}_{\sigma^2(\phi + \theta)}$$

$$(1) \quad \gamma_0 = \phi \gamma_1 + \sigma^2(1 + \phi + \theta)$$

$$\begin{aligned} \gamma_1 &= E(Y_t \cdot Y_{t-1}) = E[(\phi Y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}) Y_{t-1}] \\ &= \phi E(Y_{t-1}^2) + E(\varepsilon_t Y_{t-1}) + \theta E(\varepsilon_{t-1} Y_{t-1}) \\ &= \phi \gamma_0 + 0 + \theta \sigma^2 \end{aligned}$$

$$(2) \quad \gamma_1 = \phi \gamma_0 + \theta \sigma^2$$

(1) & (2)  $\Rightarrow$  แก้สมการหา  $\gamma_0, \gamma_1$ 

$$\begin{aligned} \gamma_2 &= E(Y_t Y_{t-2}) = E[(\phi Y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}) Y_{t-2}] \\ &= \phi E(Y_{t-1} Y_{t-2}) \\ &= \phi \gamma_1 \end{aligned}$$

$$\gamma_2 = \phi \gamma_1$$


## คุณสมบัติ ARMA(1,1)

กรณีที่  $j \geq 2$  จากสมการที่ (2.56) และ (2.57) เราจะได้

$$\text{Var}(y_t) = \gamma_0 =$$

$$\begin{aligned} \rho_1 &= \gamma_1/\gamma_0 \\ \rho_2 &= \phi \rho_1 \\ \rho_3 &= \phi \rho_2 \end{aligned}$$

$$\left[ \frac{\gamma_2}{\gamma_0} = \phi \frac{\gamma_1}{\gamma_0} \Rightarrow \rho_2 = \phi \rho_1 \right]$$



ACF ณ ค่า  $j$  ใดๆ ที่  $j \geq 2$  ได้

$$\rho_j = \phi \rho_{j-1}$$

กรณีที่  $j \geq 2$  จะเห็นได้ว่า ACF มีค่าที่ลดลงเรื่อยๆ ด้วยอัตราแบบ exponential)

PACF (สังเกต: สังเกตว่า AR(∞))

[ARMA(1,1) → AR(∞)]

$$(1 - \phi L) y_t = (1 + \theta L) \varepsilon_t$$

$$\begin{aligned} (1 - \phi L)(1 - \theta L + \theta^2 L^2 - \theta^3 L^3 + \dots) y_t &= \varepsilon_t \\ (1 - \theta L + \theta^2 L^2 - \theta^3 L^3 + \dots - \phi L + \phi \theta L^2 - \phi \theta^2 L^3 + \phi \theta^3 L^4 - \dots) y_t &= \varepsilon_t \\ (1 - (\theta + \phi)L + (\theta^2 + \phi\theta)L^2 - (\theta^3 + \phi\theta^2)L^3 + \dots) y_t &= \varepsilon_t \end{aligned}$$

$$\frac{(1 - \phi L)}{(1 + \theta L)} y_t = \varepsilon_t$$

$$\frac{1}{1 - (-\theta L)} = 1 + (-\theta L) + (-\theta L)^2 + (-\theta L)^3 + \dots$$

คุณสมบัติ  $ARMA(1,1)$ 


$|\theta| < 1$  หมายถึงค่าของ  $AR(1)$  ที่รูป Absolute  
 $\rightarrow$  PACF ของ  $ARMA(1,1)$  จะตัดที่ค่าหนึ่ง

แบบจำลอง  $ARMA(1,1)$  ในรูปของมูวี่งเอเวอเรจที่มีอันดับเป็นอนันต์ (infinite MA) ได้เป็น

$$y_t = \varepsilon_t + (\phi - \theta) \sum_{j=1}^{\infty} \phi^{j-1} \varepsilon_{t-j}$$

หรือ  $\psi_j = (\phi - \theta)\phi^{j-1}$  จะเห็นได้ว่าเงื่อนไขที่จะทำให้กระบวนการนี้เป็นกระบวนการนิ่งคือ  $|\phi| < 1$

$\text{Var } ARMA(1,1) = \frac{\sigma^2(1 + 2\phi\theta + \theta^2)}{1 - \phi^2}$   
 หมายเหตุ:  $|\phi| < 1$   
 เงื่อนไขของ stationarity สำหรับ  $ARMA(1,1)$





# สรุปคุณสมบัติของ $ARMA(p, q)$

- กระบวนการ  $ARMA(p, q)$  จะ stationary และ ergodic ถ้าค่าสัมบูรณ์ของค่ารากของพหุนามออโตรีเกรสซีฟ  $\phi(m) = 0$  มีค่ามากกว่าหนึ่ง  $|m_i| > 1$   
*root vs polynomial*  
*นิยาม AR(p) part*  
 $(1 - \phi_1 L - \dots - \phi_p L^p) = 0$   
 $(1 - \phi_1 m - \phi_2 m^2 - \dots - \phi_p m^p) = 0$
- และสามารถหาค่าผกผันได้ถ้ารากของพหุนามมูวี่งเอเวอเรจ  $\theta(m) = 0$  มีค่ามากกว่าหนึ่ง  $|m_i| > 1$   
*Invert จาก ARMA  $\rightarrow$  AR( $\infty$ )*  
 $(1 + \theta_1 L + \dots + \theta_q L^q)$   
 $(1 + \theta_1 m + \dots + \theta_q m^q) = 0$
- พหุนาม AR และ MA ไม่มีตัวประกอบร่วม  $|m_i| > 1$

รูปทั่วไปของ ACF ของกระบวนการ  $ARMA(p, q)$  ค่อนข้างยุ่งยาก โดยสรุปแล้ว ทั้ง ACF และ PACF จะค่อยๆ ลดลงเรื่อยๆ แบบเลขชี้กำลัง (exponential)

ARMA สามารถใช้ parameter ได้ทุกชุดที่:  $|m_i| > 1$

$$AR(1) \equiv ARMA(1, 0)$$

$$AR(1) \quad (1 - 0.5L)Y_t = \varepsilon_t$$

$$\uparrow \quad (1 - 0.5L)(1 + 0.7L)Y_t = (1 + 0.7L)\varepsilon_t$$

$$ARMA(2, 1) \quad (1 + 0.2L - 0.35L^2)Y_t = (1 + 0.7L)\varepsilon_t$$

# การประมาณค่าสมการแบบจำลอง ARMA

เราสามารถประมาณค่าแบบจำลอง  $ARMA(p, q)$  ได้ด้วยวิธีการค่าความควรจะเป็นสูงสุด (MLE)

- ฟังก์ชันที่แน่นอน (exact log-likelihood) นั้นมีรูปแบบที่ค่อนข้างซับซ้อน นอกจากนี้จุดเริ่มต้นของข้อมูลในกรณี exact likelihood จะใช้คุณสมบัติของการแจกแจงที่หนึ่งเพื่อสร้างฟังก์ชันค่าควรจะเป็นของค่า  $y_t$   $p$  ค่าแรก และ  $\varepsilon_t$   $q$  ค่าแรก
  - conditional likelihood จะสมมติให้  $y_t$   $p$  ค่าแรก และ  $\varepsilon_t$   $q$  ค่าแรกเท่ากับศูนย์
- กรณีที่จำนวนตัวอย่างมีจำนวนเข้าใกล้อนันต์ค่าประมาณจากสองวิธีจะมีค่าใกล้เคียงกัน แต่จะแตกต่างกันในกรณีตัวอย่างมีจำนวนน้อย



# การประมาณค่าสมการแบบจำลอง ARMA

→ ทดสอบ residuals เช่น LB Q test

ทดสอบความเพียงพอของแบบจำลองได้เช่นเดียวกับในกรณีของแบบจำลอง  $AR$  และ  $MA$  โดยที่ตัวสถิติ  $Q(m) \sim \chi^2_{m-p-q}$  และเราจะปฏิเสธสมมุติฐานหลักถ้า  $Q(m)$  มีค่ามากกว่าควอนไทล์ที่  $(1 - \alpha)$  ของ  $\chi^2_{m-p-q}$

ก่อนที่จะเราจะประมาณค่าแบบจำลอง  $ARMA(p, q)$  สำหรับอนุกรมเวลา  $y_t$  ใดๆ เราจะเป็นต้องระบุลำดับของ  $AR(p)$  และ  $MA(q)$  เสียก่อน



# เกณฑ์การเลือกแบบจำลอง (Model Selection Criteria)

เราสามารถใช้การสังเกต ACF ของตัวอย่าง ในกรณีของ MA หรือ PACF ของตัวอย่าง ในกรณีของ AR

**Table:** สรุปลักษณะของ ACF และ PACF สำหรับแบบจำลอง ARMA

	$AR(p)$	$MA(q)$	$ARMA(p, q)$
ACF	ค่อยๆ ลดลง	ค่าเท่ากับศูนย์ หลังจากช่วงล่าที่ $q$	ค่อยๆ ลดลง
PACF	เท่ากับศูนย์ หลังจากช่วงล่าที่ $p$	ค่อยๆ ลดลง	ค่อยๆ ลดลง



# เกณฑ์การเลือกแบบจำลอง (Model Selection Criteria)

325/425 → เลือกแบบจำลอง SSR (หรือ  $R^2$ )

อีกทางเลือกหนึ่งเราสามารถใช้เกณฑ์การเลือกแบบจำลอง Akaike

แนวคิดคือการประมาณค่าแบบจำลอง  $ARMA(p, q)$  สำหรับค่าอันดับ  $p$  และ  $q$  ต่างๆ ที่น้อยกว่าค่าหนึ่งที่เรากำหนดไว้  $p_{max}$  และ  $q_{max}$  และเลือกค่า  $p$  และ  $q$  ที่ทำให้ค่าเกณฑ์การเลือกต่ำที่สุด โดยที่เกณฑ์การเลือกจะอยู่ในรูป

$ARMA(1,0)$   
 $ARMA(1,1)$   
 $ARMA(0,1)$

$p, q \uparrow$  var vs error ↓  
 จากแบบจำลอง

$$MSC(p, q) = \underbrace{\ln(\tilde{\sigma}^2(p, q))}_{\substack{\uparrow \text{ var vs error} \\ \text{จากแบบจำลอง}}} + \underbrace{c_T \varphi(p, q)}_{\substack{\uparrow \text{ var vs error} \\ \text{จากแบบจำลอง}}} \Rightarrow \text{Information Criteria}$$

Penalty (การโทษ)



# เกณฑ์การเลือกแบบจำลอง (Model Selection Criteria)

โดยที่แบบเกณฑ์ที่เป็นที่นิยมสามเกณฑ์ได้แก่ Akaike (AIC)  
Schwarz-Bayesian (BIC) และ Hannan-Quinn (HQIC)  $T - \#$  ตัวแปร.

Bayesian

$$AIC(p, q) = \ln(\tilde{\sigma}^2(p, q)) + \frac{2}{T}(p + q)$$

$$BIC(p, q) = \ln(\tilde{\sigma}^2(p, q)) + \frac{\ln T}{T}(p + q)$$

$$HQIC(p, q) = \ln(\tilde{\sigma}^2(p, q)) + \frac{2 \ln(\ln T)}{T}(p + q)$$

$\ln T > 2$

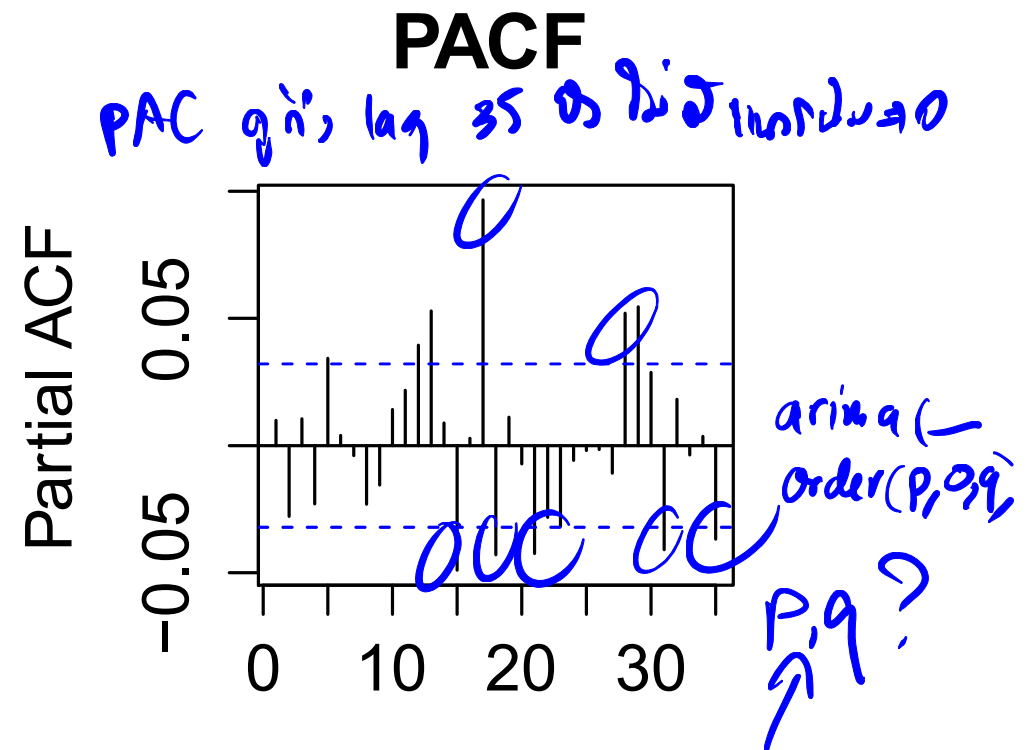
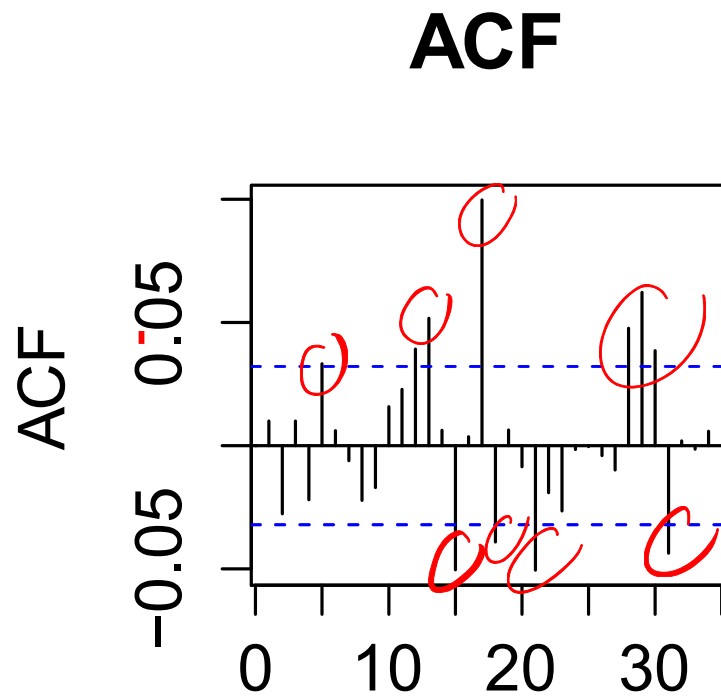
กรณี  $T$  ใหญ่ เกณฑ์ AIC จะเลือกอันดับที่มากกว่าที่ควรจะเป็น ในขณะที่เกณฑ์ BIC และ HQIC เลือกค่าที่ consistent  $[T \rightarrow \infty \text{ ถ้า } p, q \text{ คงที่: จะเลือกค่าที่จริง}]$   
อย่างไรก็ตามใน  $T$  ขนาดเล็กเกณฑ์ทั้งสามจะให้ค่าที่ไม่แตกต่างกัน

- หมายเหตุ: เกณฑ์ BIC/HQIC มีชื่ออีกอย่างว่า Consistent
- BIC ใช้เพิ่ม penalty สูงกว่า AIC  $\Rightarrow$  BIC มักจะเลือก order ที่ต่ำกว่า AIC

# ตัวอย่างที่ 3.7

log return on forex B/\$ ปี 1998 ถึง 2012

Figure: ACF และ PACF ของผลได้ตอบแทนรายวันจากการซื้อขายเงินดอลลาร์สหรัฐ



ACF ดูไม่ชัด lag 35 ยังไม่หายไป

แบบจำลองที่หา: ARMA



## ตัวอย่างที่ 3.7

อย่างไรก็ตาม package "forecast" มีคำสั่ง `auto.arima(series, arguments)` เลือก optimal  $p$  &  $q$

คำสั่งใน R: `library(forecast)`  
`auto.arima(ret, d=0, D=0, max.p=6, max.q=6, ic=c("aic"), stepwise=FALSE, trace=TRUE)`

Handwritten notes: *ทำให้ง่ายกว่า p,q* (pointing to `d=0, D=0`), *TRUE ให้ง่ายกว่า* (pointing to `trace=TRUE`), *bic* (pointing to `ic=c("aic")`).

Output:

```

1  > library(forecast)
2  > auto.arima(ret, d=0, D=0, max.p=6, max.q=6, ic=c("aic"), stepwise=FALSE, trace=TRUE)
3
4  ARIMA(0,0,0) with zero mean      : -27687.05
5  ARIMA(0,0,0) with non-zero mean : -27686.59
6  [omitted]
7  ARIMA(5,0,0) with zero mean      : -27850.55
8  ARIMA(5,0,0) with non-zero mean : -27851.11
9
10 Series: ret
11 ARIMA(4,0,1) with non-zero mean
12
13 Coefficients:
14      ar1      ar2      ar3      ar4
15  -0.5876  -0.0238  -0.0066  -0.0227
16  s.e.    0.2641   0.0196   0.0208   0.0199
17      ma1  intercept
18    0.5981      -1e-04
19  s.e.    0.2636      1e-04
20
21 sigma^2 estimated as 3.432e-05:  log likelihood=13849.44
22 AIC=-27684.88  AICc=-27684.85  BIC=-27641.33

```

Handwritten notes: *ARMA(4,1)* (pointing to `ARIMA(4,0,1)`), *no* (pointing to `stepwise=FALSE`), *AIC/BIC ทุกกรณี* (pointing to `ic=c("aic")`), *แล้วพบ* (pointing to `trace=TRUE`).

Handwritten table:

p	0	6
q	0	0