

# EC435

## บทที่ 5 แบบจำลอง Multiple Time Series

เฉลิมพงษ์ คงเจริญ ©2556

คณะเศรษฐศาสตร์ มหาวิทยาลัยธรรมศาสตร์

October 31, 2019



# บทนำ

การเปลี่ยนแปลงที่เกิดขึ้นในตลาดการเงินหนึ่งสามารถส่งผ่านไปยังตลาดอื่นได้ง่าย ดังนั้น บางครั้งเราจำเป็นต้องพิจารณาการเปลี่ยนแปลงของอนุกรมเวลาทางการเงินไปพร้อมๆ กัน

โดยเราเรียกแบบจำลองที่พิจารณาอนุกรมเวลาหลายๆ อนุกรมพร้อมกันว่าแบบจำลองอนุกรมเวลาเชิงพหุตัวแปร (multivariate time series) โดยเราสามารถเขียนอนุกรมเวลาในรูปของเวกเตอร์

$$\mathbf{Y}_t = \begin{bmatrix} y_{1t} \\ y_{2t} \\ \vdots \\ y_{nt} \end{bmatrix}$$

โดยที่  $y_{it}$  แทนอนุกรมเวลา  $i$  และ  $n$  คือจำนวนอนุกรมเวลาที่เราพิจารณาร่วมกันเช่น  $y_{1t}, y_{2t}, \dots, y_{nt}$  แทนผลได้ตอบแทนในรูปบล็อกของหุ้นในตลาดหลักทรัพย์แห่งประเทศไทย



# แบบจำลองเวกเตอร์ออโตรีเกรสซีฟ (Vector Autoregressive Model)

แบบจำลองเวกเตอร์ออโตรีเกรสซีฟที่มีค่าล่าเท่ากับ  $p$ ,  $VAR(p)$ , สามารถเขียนในรูป

$$Y_t = c + \Phi_1 Y_{t-1} + \dots + \Phi_p Y_{t-p} + \varepsilon_t, \quad t = 1, 2, \dots, T \quad (5.1)$$

โดยที่  $\Phi_i$  เป็นเมทริกซ์สัมประสิทธิ์ที่มีขนาด  $n \times n$  และ  $\varepsilon_t$  เป็นเวกเตอร์ของกระบวนการไวทนอซที่มีค่าเฉลี่ยเท่ากับศูนย์ และมีเมตริกซ์ความแปรปรวนร่วมที่ไม่แปรผันตามเวลา  $\Sigma$

ตัวอย่างเช่น หากเราสนใจแบบจำลอง  $VAR(1)$

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} + \begin{pmatrix} \phi_{11} & \phi_{12} \\ \phi_{21} & \phi_{22} \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad (5.2)$$



## VAR

หรือเขียนเป็นรูปสมการของแต่ละตัวแปรที่เราสนใจ

$$y_{1t} = c_1 + \phi_{11}^1 y_{1t-1} + \phi_{12}^1 y_{2t-1} + \varepsilon_{1t}$$

$$y_{2t} = c_2 + \phi_{21}^1 y_{1t-1} + \phi_{22}^1 y_{2t-1} + \varepsilon_{2t}$$

โดยที่  $Cov(\varepsilon_{1t}, \varepsilon_{2s}) = \sigma_{12}$  ถ้า  $s = t$  และ  $Cov(\varepsilon_{1t}, \varepsilon_{2s}) = 0$  ถ้า  $s \neq t$

ค่าสัมประสิทธิ์แต่ละตัวจะเป็นค่าที่บอกความสัมพันธ์ระหว่างตัวแปรที่ต่างเวลากัน

■  $\phi_{12}^1$

■  $\phi_{21}^1$

ค่าสัมประสิทธิ์ในสมการ (5.2) อธิบายพลวัตของอนุกรมเวลาที่เราสนใจ (lead-lag) แต่ไม่ได้อธิบาย concurrent หรือ contemporaneous ไว้อย่างชัดเจน เราสามารถดูความสัมพันธ์ดังกล่าวได้ในเมทริกซ์ความแปรปรวนของข้อผิดพลาด เราเรียกแบบจำลองเวกเตอร์ออโตรีเกรสซีฟในรูป (5.2) ว่าสมการในรูปลดรูป (reduced form)



## VAR

เราสามารถเขียนความสัมพันธ์ระหว่างอนุกรมเวลาในช่วงเดียวกันได้อย่างชัดเจนโดยใช้การแปลงรูปสมการที่ (5.2) ได้ดังนี้

เนื่องจาก  $\Sigma$  เป็นเมตริกซ์ positive definite ดังนั้นเราสามารถสร้างเมตริกซ์ lower triangular

$$L = \begin{pmatrix} 1 & 0 & \dots & 0 \\ l_{21} & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & \dots & 1 \end{pmatrix}$$

และเมตริกซ์เทงมม  $G$  ที่ทำให้  $\Sigma = LGL'$  เราเรียกการแยกส่วนประกอบนี้ว่า Cholesky decomposition

กำหนดให้  $\eta_t = L^{-1}\varepsilon_t$  เราจะได้ว่า

$$E(\eta_t) =$$

$$Var(\eta_t) =$$



## VAR

หากเราคูณข้างหน้าสมการ (5.1) ด้วย  $L^{-1}$  จะได้  
 $L^{-1}Y_t =$

$L^{-1}$  จะแสดงความสัมพันธ์ระหว่างอนุกรมเวลาในคาบเดียวกัน  
 เราเรียกแบบจำลองเวกเตอร์ออโตรีเกรสซีฟในรูปนี้ว่าสมการในรูปโครงสร้าง  
 (structural equation)



## ตัวอย่างที่ 5.1

กำหนด Bivariate VAR(1)) สามารถแสดงในรูปลดรูปได้ดังนี้

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 0.2 \\ 0.4 \end{pmatrix} + \begin{pmatrix} 0.2 & 0.3 \\ -0.6 & 1.1 \end{pmatrix} \begin{pmatrix} y_{1,t-1} \\ y_{2,t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

โดยที่  $\Sigma = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}$



## VAR

- เราจะเห็นได้ว่าเราสามารถแปลงแบบจำลองเวกเตอร์ออโตรีเกรสซีฟในรูปลดรูปไปเป็นรูปโครงสร้างได้ด้วย Cholesky decomposition
- อย่างไรก็ตามในการวิเคราะห์อนุกรมเวลาเรามักจะใช้สมการในรูป Reduced form เนื่องจากเป็นรูปที่ง่ายในการประมาณค่า
- เรามักจะเน้นผลในการพยากรณ์ของแบบจำลองซึ่งเราไม่สามารถใช้แบบจำลองในรูปโครงสร้างพยากรณ์ข้อมูลได้เนื่องจากเราไม่ทราบข้อมูลของอนุกรมเวลาอื่นๆในคาบเดียวกัน





# เงื่อนไขการเป็นอนุกรมเวลาหนึ่ง

แบบจำลอง  $VAR(p)$  สามารถเขียนในรูปเครื่องหมายขยับไปข้างหลัง (lag operator) ได้ดังนี้

$$\Phi(L)Y_t = c + \varepsilon_t$$

โดยที่  $\Phi(L) = I_n - \Phi_1 L - \dots - \Phi_p L^p$  แบบจำลอง  $VAR(p)$  จะมีเสถียรภาพถ้ารากของ

$$\det(I_n - \Phi_1 z - \dots - \Phi_p z^p) = 0$$

มีค่ามากกว่าหนึ่ง (หรือโมดูลัสมากกว่าหนึ่งในกรณีจำนวนเชิงซ้อน) ถ้าสมมติให้กระบวนการดังกล่าวมีค่าในอดีตที่เป็นอนันต์ แล้วกระบวนการ  $VAR(p)$  ที่มีเสถียรภาพจะเป็นกระบวนการนิ่งและ ergodic โดยมีค่าเฉลี่ย ค่าความแปรปรวนและค่าความแปรปรวนร่วมในตัวเองที่ไม่ขึ้นกับเวลา



# การประมาณค่า


การเราพิจารณาสมการ (5.1) แต่ละสมการจะมีตัวแปรที่เหมือนกัน เราสามารถพิจารณาสมการสำหรับแต่ละตัวแปรออกเป็น

$$y_i = \mathbf{Z}\phi_i + e_i, \quad i = 1, \dots, n$$

แต่ละสมการสามารถประมาณค่าได้ด้วย ordinary least squares (OLS) แยกแต่ละสมการ และจะได้  $\hat{\Phi} = [\hat{\phi}_1, \dots, \hat{\phi}_n]$  เป็นเมตริกซ์ ( $k \times n$ ) ของค่าสัมประสิทธิ์จากการประมาณค่าด้วย OLS

ภายใต้ข้อสมมุติที่แบบจำลองเป็นแบบกระบวนการนิ่งและ ergodic เราจะได้  $\text{vec}(\hat{\Phi})$  มีคุณสมบัติ consistent และมีการแจกแจงแบบปกติเมื่อกลุ่มตัวอย่างใหญ่โดยมีเมตริกซ์ค่าความแปรปรวนเท่ากับ

$$\widehat{\text{aver}}(\text{vec}(\hat{\Phi})) = \hat{\Sigma} \otimes (\mathbf{Z}'\mathbf{Z})^{-1}$$

โดยที่  $\hat{\Sigma} = \frac{1}{T-k} \sum_{t=1}^T \hat{e}_t \hat{e}_t'$  และ  $\hat{e}_t = \mathbf{Y}_t - \hat{\Phi}' \mathbf{Z}_t$  เป็น residuals จากการประมาณค่า 

## การเลือกจำนวนความล่าที่เหมาะสม

การหาความล่าที่เหมาะสมของแบบจำลองเวกเตอร์ออโตรีเกรสซีฟอาจทำได้โดยใช้สูตรการเลือกความล่า โดยการประมาณค่าแบบจำลองเวกเตอร์ออโตรีเกรสซีฟที่มีความล่าเท่ากับ  $0, 1, \dots, p_{max}$  แล้วเลือกค่า  $p$  ที่ทำให้ค่าที่ใช้เลือกมีค่าต่ำที่สุด โดยจะมีสูตรดังนี้

$$IC(p) = \ln |\tilde{\Sigma}(p)| + c_T(n, p)$$

โดยที่  $\tilde{\Sigma}(p) = T^{-1} \sum_{t=1}^T \hat{\varepsilon}_t \hat{\varepsilon}_t'$  คือ residual covariance matrix จาก  $VAR(p)$ ,  $c_T$  คือ ลำดับที่ขึ้นกับจำนวนตัวอย่าง

$$AIC(p) = \ln |\tilde{\Sigma}(p)| + \frac{2}{T}(pn^2)$$

$$BIC(p) = \ln |\tilde{\Sigma}(p)| + \frac{\ln T}{T}(pn^2)$$

$$HQIC(p) = \ln |\tilde{\Sigma}(p)| + \frac{2 \ln(\ln T)}{T}(pn^2)$$



## ตัวอย่าง 5.2

ในตัวอย่างนี้เราจะพิจารณาความสัมพันธ์ระหว่างผลได้ตอบแทนรายวันจากการลงทุนในตลาดหลักทรัพย์แห่งประเทศไทย (lret\_set) และตลาดหุ้นดาวโจนส์ (lret\_dowjones) ข้อมูลอยู่ในไฟล์ set\_dj.csv

เราจะได้ข้อมูลสองชุดคือ lret\_set และ lret\_dowjones เราจะเขียนข้อมูลทั้งสองในรูปของเมตริกซ์ที่นำเวกเตอร์ทั้งสองมาต่อกันโดยใช้คำสั่ง cbind

```
1 > lret<-cbind(lret_set, lret_dowjones)
```

เราสามารถพิจารณาค่าสถิติเบื้องต้นได้จากคำสั่ง basicStats และ acf เหมือนกับที่เราเคยใช้ในหัวข้อก่อนได้



## ตัวอย่าง

หากเราต้องการประมาณค่า VAR(p) เราจะใช้ `library(vars)` โดยที่เราอาจจะเริ่มจากการหาค่า  $p$  ที่เหมาะสมโดยการใช้คำสั่ง VAR พร้อมระบุเมตริกซ์ของข้อมูล `lret` จำนวนค่าล่าสูงสุด `lag.max` และ เกณฑ์ในการเลือกค่าล่า `ic=c("AIC")` โดยที่ "SC" จะแทน Schwarz-Bayesian (BIC) และ "HQ" Hannan-Quinn (HQIC)

```

1 > library(vars)
2 > msel=VAR(lret, lag.max=10, ic=c("AIC"))
3 > msel
4
5 VAR Estimation Results:
6 =====
7
8 Estimated coefficients for equation lret_set:
9 =====
10 <Omitted>
11
12      lret_set.l1 lret_dowjones.l1      lret_set.l2 lret_dowjones.l2
13      0.05556382      0.22898590      -0.33541086      0.32270310
14      lret_set.l3 lret_dowjones.l3      lret_set.l4 lret_dowjones.l4
15      0.01244410      0.21790099      -0.13694929      0.17900004
16      lret_set.l5 lret_dowjones.l5      lret_set.l6 lret_dowjones.l6
17      -0.01107252      0.04790222      -0.06473588      0.12631799
18      lret_set.l7 lret_dowjones.l7      lret_set.l8 lret_dowjones.l8
19      0.01517100      0.05964304      -0.02897568      0.02785310
20      lret_set.l9 lret_dowjones.l9      const
21      0.03837222      0.08783703      -0.00332124

```



## ตัวอย่าง 5.2

```

1 > model1=VAR(lret, p=4)
2 > summary(model1)
3
4 VAR Estimation Results:
5 =====
6 Endogenous variables: lret_set, lret_dowjones
7 Deterministic variables: const
8 Sample size: 3803
9 Log Likelihood: -15650.859
10 Roots of the characteristic polynomial:
11 0.62 0.62 0.5867 0.5867 0.3557 0.3557 0.2886 0.2886
12 Call:
13 VAR(y = lret, p = 4)
14
15 Estimation results for equation lret_set:
16 =====
17 lret_set = lret_set.l1 + lret_dowjones.l1 + lret_set.l2 + lret_dowjones.l2 +
18 lret_set.l3 + lret_dowjones.l3 + lret_set.l4 + lret_dowjones.l4 + const
19
20
21 Estimate Std. Error t value Pr(>|t|)
22 lret_set.l1 0.059621 0.016288 3.660 0.000255 ***
23 lret_dowjones.l1 0.222804 0.032471 6.862 7.91e-12 ***
24 lret_set.l2 -0.320847 0.016256 -19.738 < 2e-16 ***
25 lret_dowjones.l2 0.313004 0.032696 9.573 < 2e-16 ***
26 lret_set.l3 0.023840 0.016122 1.479 0.139313
27 lret_dowjones.l3 0.205041 0.032958 6.221 5.47e-10 ***
28 lret_set.l4 -0.103471 0.016011 -6.462 1.16e-10 ***
29 lret_dowjones.l4 0.151876 0.032994 4.603 4.30e-06 ***
30 const 0.002529 0.043532 0.058 0.953684
31 ---
32 Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
33
34 Residual standard error: 2.683 on 3794 degrees of freedom
35 Multiple R-Squared: 0.1409, Adjusted R-squared: 0.1391
36 F-statistic: 77.78 on 8 and 3794 DF, p-value: < 2.2e-16

```



## ตัวอย่าง 5.2

```
1 Estimation results for equation lret_dowjones:
2 =====
3 <omitted>
4
5 Covariance matrix of residuals:
6           lret_set lret_dowjones
7 lret_set      7.199      -0.556
8 lret_dowjones -0.556      1.839
9
10 Correlation matrix of residuals:
11           lret_set lret_dowjones
12 lret_set      1.0000      -0.1528
13 lret_dowjones -0.1528      1.0000
```



## การพยากรณ์จากแบบจำลอง VAR

หากเราพิจารณาแบบจำลอง  $VAR(p)$  โดยที่เราทราบค่าพารามิเตอร์  $\Phi$  ค่าพยากรณ์ไปข้างหน้าหนึ่งคาบ  $Y_{h+1}$  ด้วยข้อมูลที่มี ณ คาบที่  $h$  ได้ด้วยการเขียนสมการแสดงค่า  $Y_{h+1}$

แล้วหา conditional expectation ด้วยข้อมูล ณ  $h$  เราจะได้ค่าพยากรณ์เท่ากับ

$$\hat{Y}_h(1) =$$

โดยที่ค่าความผิดพลาดจากการพยากรณ์ (forecast error) เท่ากับ

$$e(1) = Y_{h+1} - \hat{Y}_h(1) =$$

ค่าพยากรณ์ไปข้างหน้าสองคาบ  $Y_{h+2}$  ด้วยข้อมูลที่มี ณ คาบที่  $h$  จะเท่ากับ

$$\hat{Y}_h(2) =$$

โดยที่ค่าความผิดพลาดจากการพยากรณ์ (forecast error) เท่ากับ

$$e(2) = Y_{h+2} - \hat{Y}_h(2) =$$





## การพยากรณ์จากแบบจำลอง VAR

หากแทนค่าด้วยวิธีการ recursive จะได้ค่าพยากรณ์ไปข้างหน้า  $l$  คาบ  $Y_{h+l}$  ด้วยข้อมูลที่มี ณ คาบที่  $h$  เท่ากับ

$$\hat{Y}_h(l) = c + \Phi_1 \hat{Y}_h(l-1) + \dots + \Phi_p \hat{Y}_h(l-p)$$

ค่าคาดเคลื่อนของการพยากรณ์ (forecast errors) จะเขียนในรูป

$$\hat{Y}_h(l) - Y_{h+l} = \sum_{s=0}^{l-1} \Psi_s \epsilon_{h+l-s}$$

โดยที่เมตริกซ์  $\Psi_s$  สามารถคำนวณได้โดย  $\Psi_s = \sum_{j=1}^{p-1} \Psi_{s-j} \Phi_j$

ในขณะที่ MSE ของ  $\hat{Y}_h(l)$  จะเท่ากับ

$$\Sigma(l) = MSE(Y_{h+l} - \hat{Y}_h(l)) = \sum_{s=0}^{l-1} \Psi_s \Sigma \Psi_s'$$



## ตัวอย่าง 5.3

ต่อเนื่องจากตัวอย่าง 5.2 เราสามารถทำนายผลได้ตอบแทนไปข้างหน้าของทั้งสองตลาดที่เราสนใจได้ด้วยคำสั่ง `predict` โดยระบบแบบจำลองที่ใช้และคาบที่ทำนายไปข้างหน้า

```

1 > model1.predict=predict(model1, n.ahead=5)
2 > model1.predict
3 $lret_set
4      fcst      lower      upper      CI
5 [1,]  0.23354446 -5.025286  5.492375  5.258830
6 [2,] -0.01504318 -5.311043  5.280957  5.296000
7 [3,]  0.08053962 -5.572718  5.733797  5.653258
8 [4,] -0.02118987 -5.682718  5.640339  5.661528
9 [5,] -0.04475454 -5.707153  5.617644  5.662399
10
11 $lret_dowjones
12      fcst      lower      upper      CI
13 [1,] -0.046835523 -2.705029  2.611358  2.658193
14 [2,]  0.023569365 -2.639844  2.686983  2.663413
15 [3,]  0.005536266 -2.686514  2.697586  2.692050
16 [4,]  0.021958580 -2.670142  2.714059  2.692101
17 [5,]  0.031192947 -2.661288  2.723674  2.692481

```



# Granger Causality

โครงสร้างของแบบจำลอง VAR ช่วยให้ข้อมูลกับเราว่าตัวแปรหรือกลุ่มของตัวแปรมีความสามารถในการทำนายตัวแปรอื่นหรือไม่

Granger (1969) เสนอว่า

- ถ้าตัวแปร  $y_1$  ช่วยในการทำนายตัวแปรอื่น  $y_2$  เราจะเรียกว่า  $y_1$  แกรงเจอร์คอส (Granger-cause)  $y_2$
- ถ้า  $y_1$  ไม่ช่วยในการทำนายตัวแปร  $y_2$  เราจะพูดว่า  $y_1$  ไม่แกรงเจอร์คอส (does not Granger-cause)  $y_2$

เราจะต้องระลึกไว้อยู่เสมอว่าแกรงเจอร์คอสเป็นการอนุมานไปยังความสามารถในการพยากรณ์เท่านั้น ไม่ได้เป็นความเป็นเหตุเป็นผลจริงๆของตัวแปร



## Granger Causality

ในหัวข้อนี้เราพิจารณาแบบจำลอง  $VAR(2)$  ที่มีตัวแปรสองตัว ซึ่งสามารถเขียนเป็นสมการได้ดังนี้

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} + \begin{pmatrix} \phi_{11}^1 & \phi_{12}^1 \\ \phi_{21}^1 & \phi_{22}^1 \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \phi_{11}^2 & \phi_{12}^2 \\ \phi_{21}^2 & \phi_{22}^2 \end{pmatrix} \begin{pmatrix} y_{1t-2} \\ y_{2t-2} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad (5.13)$$

- หาก  $y_{2t}$  ไม่แรงเจอร์คอส  $y_{1t}$  ค่าสัมประสิทธิ์  $\phi_{12}^1$  และ  $\phi_{12}^2$  จะมีค่าเท่ากับศูนย์
  - ถ้า  $y_{1t}$  ไม่แรงเจอร์คอส  $y_{2t}$  ค่าสัมประสิทธิ์  $\phi_{21}^1$  และ  $\phi_{21}^2$  จะมีค่าเท่ากับศูนย์
- ดังนั้นในการทดสอบว่า  $y_{2t}$  แรงเจอร์คอส  $y_{1t}$  หรือไม่ เราจะตั้งสมมุติฐานหลักว่า  $H_0 : \phi_{12}^1 = \phi_{12}^2 = 0$  และสมมุติฐานทางเลือกคือมีสัมประสิทธิ์  $\phi_{12}^1$  หรือ  $\phi_{12}^2$  ตัวใดตัวหนึ่งมีค่าไม่เท่ากับศูนย์ ซึ่งการทดสอบดังกล่าวคือการทดสอบ F นั้นเอง (Wald)



## ตัวอย่าง 5.4

ต่อเนื่องจากตัวอย่าง 5.3 เราต้องการทดสอบว่า `lret_dowjones` แกรงเจอร์  
คอส `lret_set` หรือไม่(

เราสามารถทดสอบโดยใช้คำสั่ง `causality` โดยที่เราจะต้องระบุแบบจำลองที่  
ใช้และตัวแปรที่เป็นสาเหตุ (cause) ซึ่งในที่นี้คือ `lret_dowjones`

```
1 > causality(model1, cause="lret_dowjones")
2 $Granger
3 ^^IGranger causality H0: lret_dowjones do not Granger-cause lret_set
4 data: VAR object model1
5 F-Test = 43.5947, df1 = 4, df2 = 7588, p-value < 2.2e-16
6
7 $Instant
8 ^^IH0: No instantaneous causality between: lret_dowjones and lret_set
9 data: VAR object model1
10 Chi-squared = 86.7677, df = 1, p-value < 2.2e-16
```



## Impulse Response Function

หรือการทดสอบแรงจอร์คอสช่วยระบุว่าตัวแปรใดๆมีผลกระทบอย่างมีนัยสำคัญต่อตัวแปรอื่นหรือไม่ อย่างไรก็ตาม การทดสอบดังกล่าวไม่ได้บอกทิศทางของความสัมพันธ์และระยะเวลาที่การเปลี่ยนแปลงของตัวแปรหนึ่งจะส่งผลต่ออีกตัวแปรว่าจะมีผลยาวนานแค่ไหน

impulse response function ซึ่งหมายถึง การตอบสนองของตัวแปรตาม(response)อันเนื่องมาจากการเปลี่ยนแปลงของตัวแปรอีกตัวหนึ่ง (impulse) โดยที่หากเกิดการเปลี่ยนแปลงในช็อกหนึ่งหน่วยจะส่งผลอย่างไรต่อแต่ละตัวแปรในคาบที่ต่อจากการเปลี่ยนแปลงนั้นๆ(เราอาจจะใช้การเปลี่ยนแปลงหนึ่ง s.d.)

ตัวอย่างเช่น หากเราพิจารณาแบบจำลอง  $VAR(1)$  ที่มีตัวแปรสองตัวแปร ซึ่งสามารถแสดงได้ด้วยสมการ

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad (5.14)$$



## Impulse Response Function

สมมติว่าเราพิจารณาว่าในปีที่ 0 เกิดช็อกในตัวแปร  $y_{1t}$  หนึ่งหน่วย ( $\varepsilon_{10} = 1$ ) และช็อกในตัวแปร  $y_{2t}$  เท่ากับศูนย์ และช็อกในปีอื่นๆเท่ากับศูนย์ สมมติให้  $y_{1t}$  และ  $y_{2t}$  เท่ากับศูนย์ในปีก่อนหน้าปี 0 จะได้ว่า

$$Y_0 = \begin{pmatrix} \varepsilon_{10} \\ \varepsilon_{20} \end{pmatrix} =$$

$$Y_1 = \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} Y_0 =$$

$$Y_2 = \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} Y_1 =$$

$$\vdots$$


# Impulse Response Function

ในกรณี  $VAR(p)$  ที่เป็นกระบวนการนิ่งใดๆ

$$Y_t = \mu + \varepsilon_t + \Psi_1 \varepsilon_{t-1} + \Psi_2 \varepsilon_{t-2} + \dots$$

$$\frac{\partial y_{i,t+s}}{\partial \varepsilon_{j,t}} = \frac{\partial y_{i,t}}{\partial \varepsilon_{j,t-s}} = \psi_{i,j}^s$$

อย่างไรก็ตามคำอธิบายข้างต้นจะเป็นจริงหาก  $\text{var}(\varepsilon) = \Sigma$  เป็นเมทริกซ์เทยงมุม  
ดังนั้นเรามักจะพิจารณา VAR ในรูป structural ซึ่ง

$$BY_t = c + \Gamma_1 Y_{t-1} + \dots + \Gamma_p Y_{t-p} + \eta_t \quad (5.17)$$

โดยที่ Orthogonal error ( $\eta_t$ )

โครงสร้างแบบจำลองโครงสร้าง (structural model) จะกำหนดให้ความสัมพันธ์  
ของตัวแปรมีลำดับคือ  $y_1$  เป็นตัวกำหนด  $y_2$  และ  $y_2$  เป็นตัวกำหนด  $y_3$  เป็นลำดับไป  
เรื่อยๆ ซึ่งใช้ทฤษฎีเป็นตัวกำหนด





## ตัวอย่างที่ 5.5

เราจะสร้าง Impulse response function ด้วยคำสั่ง `irf` โดยที่ default ในคำสั่งนี้คือการสร้าง orthogonal impulse response function (`ortho=TRUE`)

การเรียงตัวแปรใน `lret` ที่เรียง `lret_set` ก่อน `lret_dowjones`

```

1 > model1.irf=irf(model1, n.ahead=10)
2 > model1.irf
3 Impulse response coefficients
4 $lret_set
5      lret_set  lret_dowjones
6 [1,]  2.6831259181 -0.2072364167
7 [2,]  0.1137971489  0.0030468719
8 [3,] -0.9182763350  0.1667746830
9 <omitted>
10 [11,]  0.0030760182 -0.0002311969
11 $lret_dowjones
12      lret_set  lret_dowjones
13 [1,]  0.0000000000  1.3403194745
14 [2,]  0.2986284632 -0.0849824924
15 [3,]  0.4183950540 -0.1100409438
16 <omitted>
17 [11,]  0.0006173344 -0.0002757296

```



## Variance Decomposition

Forecast Error Variance Decomposition จากข้อมูล ณ คาบที่  $h$  เราต้องการตอบคำถามว่าช็อกโครงสร้าง  $\eta_j$  เป็นที่มาของความแปรปรวนของค่าผิดพลาดจากการพยากรณ์  $y_{i,h+l}$  ในสัดส่วนเท่าใด

หากเราพิจารณาเพียงตัวแปรเดียวเช่น  $y_{i,h+l}$  เนื่องจากเมทริกซ์ค่าความแปรปรวนของช็อกโครงสร้างเป็นเมทริกซ์แท่งมุม

$$\text{var}(y_{i,h+l} - \hat{y}_h(l)) = \sigma_{\eta_1}^2 \sum_{s=0}^{l-1} (\theta_{i1}^s)^2 + \dots + \sigma_{\eta_n}^2 \sum_{s=0}^{l-1} (\theta_{in}^s)^2$$

สัดส่วนของ  $\text{var}(y_{i,h+l} - \hat{y}_h(l))$  อันมีสาเหตุมาจากช็อก  $\eta_j$  เท่ากับ

$$VD_{ij}(l) = \frac{\sigma_{\eta_j}^2 \sum_{s=0}^{l-1} (\theta_{ij}^s)^2}{\sigma_{\eta_1}^2 \sum_{s=0}^{l-1} (\theta_{i1}^s)^2 + \dots + \sigma_{\eta_n}^2 \sum_{s=0}^{l-1} (\theta_{in}^s)^2}, \quad i, j = 1, \dots, n \quad (5.21)$$



## ตัวอย่าง 5.6

เราสามารถแยกความแปรปรวนของค่าผิดพลาดจากการพยากรณ์ได้ด้วยคำสั่ง  
`fevd`

```
1 > fevd(model1, n.ahead = 5)
2 $lret_set
3     lret_set lret_dowjones
4 [1,] 1.0000000 0.0000000
5 [2,] 0.9877859 0.01221413
6 [3,] 0.9682396 0.03176043
7 [4,] 0.9655329 0.03446710
8 [5,] 0.9654222 0.03457779
9
10 $lret_dowjones
11     lret_set lret_dowjones
12 [1,] 0.02334830 0.9766517
13 [2,] 0.02326189 0.9767381
14 [3,] 0.03751278 0.9624872
15 [4,] 0.03751192 0.9624881
16 [5,] 0.03750568 0.9624943
```

