

EC435  
บทที่ 5 แบบจำลอง Multiple Time Series

เฉลิมพงษ์ คงเจริญ ©2556

คณะเศรษฐศาสตร์ มหาวิทยาลัยธรรมศาสตร์

November 1, 2019



บทนำ

return

**SET**

မြန်မာရုပ်ပန်

return  
Min T & ↓

การเปลี่ยนแปลงที่เกิดขึ้นในตลาดการเงินหนึ่งสามารถส่งผ่านต่อไปยังตลาดอื่นได้ง่าย ดังนั้น บางครั้งเราจำเป็นต้องพิจารณาการเปลี่ยนแปลงของอนุกรรมเวลาทางเงินไปพร้อมๆ กัน หากหัวใจเปรียบ  $\rightarrow$  แนวโน้ม พากลุ่ม ตามไปพร้อมกันในอดีต จะเป็น โดยเราเรียกแบบจำลองที่พิจารณาอนุกรรมเวลาหลายๆ อย่าง อนุกรรมพหุตัวแปร (multivariate time series) โดยเราสามารถเขียน อนุกรรมเวลาในรูปของเวกเตอร์ ตัวแปรนัวตัว  $y_{1t}, y_{2t}, \dots, y_{ht}$

row  $y_T$  minijets

## AR, MA, ARMA

โดยที่  $y_{it}$  แทนอนุกรมเวลา  $i$  และ  $n$  คือจำนวนอนุกรมเวลาที่เราพิจารณารวมกัน เช่น  $y_{1t}, y_{2t}, \dots, y_{nt}$  แทนผลได้ต่อบแทนในรูปลีกของหุ้นในตลาดหลักทรัพย์แห่งประเทศไทย

ຕົວຢ່າງນອານຫິດ

## vector

$$Y_t = \begin{bmatrix} y_{1t} \\ y_{2t} \\ \vdots \\ y_{nt} \end{bmatrix}$$

$y_{1t}, y_{2t}, \dots, y_{nt}$   
 $)$        $($   
 return      return  
 SET      DowJONE

~~Vector ARMA~~

Vector AF  $\rightarrow$  MA

~~Vecto MA~~

~~VecM~~

## ~~Vector ART~~

# แบบจำลองเวลาเตอร์อโติรีเกรสซีฟ (Vector Autoregressive Model) – VAR(p) $y_t$ ถูกอยู่ใน $y_{t-1}, \dots, y_{t-p}$

แบบจำลองเวลาเตอร์อโติรีเกรสซีฟที่มีค่าล่าทึ่งกับ  $p$ ,  $\underline{VAR(p)}$ , สามารถเขียนในรูป

$$\begin{bmatrix} y_{1t} \\ y_{2t} \\ \vdots \\ y_{nt} \end{bmatrix} = Y_t = c + \Phi_1 Y_{t-1} + \dots + \Phi_p Y_{t-p} + \varepsilon_t, \quad t = 1, 2, \dots, T \quad (5.1)$$

ดูภาพ

$c$  คือ  $n \times 1$   
 $\Phi_i$  คือ  $n \times n$   
 $\varepsilon_t$  คือ  $n \times 1$

โดยที่  $\Phi_i$  เป็นเมตริกซ์สัมประสิทธิ์ที่มีขนาด  $n \times n$  และ  $\varepsilon_t$  เป็นเวลาเตอร์ของกระบวนการไวทอนอซที่มีค่าเฉลี่ยเท่ากับศูนย์ และมีเมตริกซ์ความแปรปรวนร่วมที่ไม่แปรผันตามเวลา  $\Sigma$

# แบบจำลองเวลาเตอร์อโติรีเกรสซีฟ (Vector Autoregressive Model)

แบบจำลองเวลาเตอร์อโติรีเกรสซีฟที่มีค่าล่าท่ากับ  $p$ ,  $VAR(p)$ , สามารถเขียนในรูป

$$\text{หกต่อ } \boxed{Y_t} = c + \Phi_1 Y_{t-1} + \dots + \Phi_p Y_{t-p} + \varepsilon_t, \quad t = 1, 2, \dots, T \quad (5.1)$$

โดยที่  $\Phi_i$  เป็นเมตริกซ์สัมประสิทธิ์ที่มีขนาด  $n \times n$  และ  $\varepsilon_t$  เป็นเวลาเตอร์ของกระบวนการไวทอนอซที่มีค่าเฉลี่ยเท่ากับศูนย์ และมีเมตริกซ์ความแปรปรวนร่วมที่ไม่แปรผันตามเวลา  $\Sigma$

ตัวอย่างเช่น หากเราสนใจแบบจำลอง  $VAR(1)$  จะต้องเป็น 2 ตัว.

VAR(1) Vector 
$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} + \underbrace{\begin{pmatrix} \phi_{11}^1 & \phi_{12}^1 \\ \phi_{21}^1 & \phi_{22}^1 \end{pmatrix}}_{2 \times 2} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad (5.2)$$

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} + \left( \begin{matrix} \phi_{11}^1 y_{1,t-1} + \phi_{12}^1 y_{2,t-1} \\ \phi_{21}^1 y_{1,t-1} + \phi_{22}^1 y_{2,t-1} \end{matrix} \right) + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$



# VAR – ย่อมาจาก Univariate TS (AR)

หรือเขียนเป็นรูปสมการของแต่ละตัวแปรที่เราสนใจ

รูปแบบ

SET

$$y_{1t} = c_1 + \phi_{11}^1 y_{1t-1} + \phi_{12}^1 y_{2t-1} + \varepsilon_{1t}$$

↑ *Dynamic relationship*

DJ

$$y_{2t} = c_2 + \phi_{21}^1 y_{1t-1} + \phi_{22}^1 y_{2t-1} + \varepsilon_{2t}$$

↑ *Dynamic relationship*

โดยที่  $\text{Cov}(\varepsilon_{1t}, \varepsilon_{2s}) = \sigma_{12}$  ถ้า  $s = t$  และ  $\text{Cov}(\varepsilon_{1t}, \varepsilon_{2s}) = 0$  ถ้า  $s \neq t$

shock

- ข้อสังนึก 1)  $E(\varepsilon_t) = 0 \rightarrow E(\varepsilon_{1t}) = 0$   $\text{ดังนั้น} = 0$

$$\varepsilon_t = \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

$$2) \text{Var}(\varepsilon_t) = E[\varepsilon_t \varepsilon_t'] = E\left[\begin{pmatrix} \varepsilon_{1t} & \varepsilon_{2t} \end{pmatrix} \begin{pmatrix} \varepsilon_{1t} & \varepsilon_{2t} \end{pmatrix}'\right]$$

ความสัมพันธ์ res shock ตามที่ได้ระบุไว้ในห้องเรียน

$$3) E[\varepsilon_t \varepsilon_s'] = 0 \quad t \neq s$$

$$= \begin{bmatrix} E(\varepsilon_{1t} \varepsilon_{1s}) & 0 \\ 0 & E(\varepsilon_{2t} \varepsilon_{2s}) \end{bmatrix}_{t-1}$$

matrix

$$\text{var-Cov } \varepsilon_t = \begin{bmatrix} 2 \times 1 & 1 \times 2 \\ E(\varepsilon_{1t}^2) & E(\varepsilon_{1t} \varepsilon_{2t}) \\ E(\varepsilon_{2t} \varepsilon_{1t}) & E(\varepsilon_{2t}^2) \end{bmatrix} = \Sigma$$

$$\underline{\sigma_{11}^2} = \text{var}(\varepsilon_{1t})$$

$$\underline{\sigma_{12}^2} = \text{cov}(\varepsilon_{1t}, \varepsilon_{2t})$$

$$\underline{\sigma_{22}^2} = \text{var}(\varepsilon_{2t})$$

VAR ↗  $\frac{\text{sum}}{\text{sum}}$

Reduced Form VAR - one period  
one variable per period

Our Liabilities  
are subdivided in periods  
Years Altogether

หรือเก็บเป็นรูปถมการของแต่ละตัวแปรที่เราสนใจ

VAR(1)

$$y_{1t} = c_1 + \phi_{11}^1 y_{1t-1} + \phi_{12}^1 y_{2t-1} + \varepsilon_{1t} \quad \text{and} \quad y_{2t} = c_2 + \phi_{21}^1 y_{1t-1} + \phi_{22}^1 y_{2t-1} + \varepsilon_{2t}$$

$\sum = \begin{cases} \text{Var}(\varepsilon_{1t}) & \text{Cov}(\varepsilon_{1t}, \varepsilon_{2t}) \\ \text{Cov}(\varepsilon_{1t}, \varepsilon_{2t}) & \text{Var}(\varepsilon_{2t}) \end{cases}$

$\varepsilon_{1t}, \varepsilon_{2t} \equiv \sigma_{12} \neq 0 \Rightarrow \text{Cov}(\varepsilon_{1t}, \varepsilon_{2t}) \neq 0$

โดยที่  $Cov(\varepsilon_{1t}, \varepsilon_{2s}) = \sigma_{12}$  ถ้า  $s = t$  และ  $Cov(\varepsilon_{1t}, \varepsilon_{2s}) = 0$  ถ้า  $s \neq t$

ค่าสัมประสิทธิ์แต่ละตัวจะเป็นค่าที่บอกความสัมพันธ์ระหว่างตัวแปรที่ต่างเวลา กัน **ช่วงเวลา (Time-series) (Dynamic Relationship)**.

■  $\phi_{12}^1$

$y_{1t}$  no: J.J. odysseus m  $y_{2t-1}$  Włoszczowa 1 ulica.

■  $\phi_{21}^1$

UF  $\psi_{2,t}$  a: JU. odsatz  $\psi_1$   $\psi_{1,t-1}$   $\psi_{2,t}$  an  $\psi_{1,t-1}$  verbraucht

ค่าสัมประสิทธิ์ในสมการ (5.2) อยู่ในช่วงเวลาที่เราสนใจ  $y_{1t} y_{2t}$  (lead-lag) แต่ไม่ได้อยู่ในช่วง concurrent หรือ contemporaneous ไว้อย่างชัดเจน

เราสามารถดูความสัมพันธ์ดังกล่าวได้ในเมทริกซ์ความแปรปรวนของชีอก ง

เราเรียกแบบจำลองเวลาเตอร์อ็อตอีกรสซีฟในรูป (5.2) ว่าสมการในรูป

**(reduced form)**

# VAR

เราสามารถเขียนความสัมพันธ์ระหว่างอนุกรมเวลาในช่วงเดียวกันได้อย่างชัดเจนโดยใช้การแปลงรูปสมการที่ (5.2) ได้ดังนี้

เนื่องจาก  $\Sigma$  เป็นเมตริกซ์ positive definite ดังนั้นเราสามารถสร้างเมตริกซ์ lower triangular  $L$  ให้  $\text{Var-cov}(\epsilon) = \Sigma$

$$L = \begin{pmatrix} 1 & 0 & \dots & 0 \\ l_{21} & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & \dots & 1 \end{pmatrix}$$

$$G = \begin{pmatrix} * & 0 & 0 & 0 \\ g_1 & 0 & 0 & 0 \\ 0 & g_2 & 0 & - \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & - & g_n \end{pmatrix}$$

และเมตริกซ์แทนยงมุม  $G$  ที่ทำให้  $\Sigma = LGL'$  เราเรียกการแยกส่วนประกอบนี้ว่า Cholesky decomposition

กูน  $L^{-1}$  ก็คือ Reduced form VAR(1)

กูน lower triangular matrix

$$\begin{pmatrix} 1 & 0 \\ l_{21} & 1 \\ l_{31} & l_{32} & 1 \\ \vdots & \vdots & \vdots & \vdots \\ l_{n1} & l_{n2} & \dots & 1 \end{pmatrix}$$

$$L^{-1} Y_t = L^{-1} C + L^{-1} \Phi_1 Y_{t-1} + L^{-1} E_t$$

↑ VAR กูน  
Structural Form VAR

(Y<sub>1t</sub>)  
(Y<sub>nt</sub>) Shock กูน

η<sub>t</sub> Error term

# VAR

เราสามารถเขียนความสัมพันธ์ระหว่างอนุกรมเวลาในช่วงเดียวกันได้อย่างชัดเจน โดยใช้การแปลงรูปสมการที่ (5.2) ได้ดังนี้

เนื่องจาก  $\Sigma$  เป็นเมตริกซ์ positive definite ดังนั้นเราสามารถสร้างเมตริกซ์ lower triangular

$$G = \begin{pmatrix} g_1 & & & \\ & g_2 & & \\ 0 & & \ddots & \\ & & & g_n \end{pmatrix} \quad L = \begin{pmatrix} 1 & 0 & \dots & 0 \\ l_{21} & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & \dots & 1 \end{pmatrix}$$

↑ จงตรวจสอบให้  $L$  คือ  
กบ  $G$

และเมตริกซ์แทนยมุน  $G$  ที่ทำให้  $\Sigma = LGL'$  เราเรียกการแยกส่วนประกอบนี้ว่า Cholesky decomposition

กำหนดให้  $\eta_t = L^{-1}\varepsilon_t$  เราจะได้ว่า

$$\begin{aligned} E(\eta_t) &= E(L^{-1}\varepsilon_t) = L^{-1}E(\varepsilon_t) = L^{-1}0 = 0 \\ G = Var(\eta_t) &= Var(L^{-1}\varepsilon_t) = L^{-1}Var(\varepsilon_t)L^{-1} = L^{-1}\Sigma L^{-1} = L^{-1}L^T = I \end{aligned}$$

$\Sigma$

structural form  
shock  $\Rightarrow d\eta_t = 0$

## VAR

หากเราคูณข้างหน้าสมการ (5.1) ด้วย  $L^{-1}$  จะได้  $\hat{Y}_t = \hat{C} + \hat{\Phi}_1 Y_{t-1} + \hat{\varepsilon}_t$

$$L^{-1} Y_t = L^{-1} C + L^{-1} \Phi_1 Y_{t-1} + L^{-1} \varepsilon_t$$

$$\begin{pmatrix} 1 & 0 \\ L^{21} & 1 \end{pmatrix} \begin{pmatrix} Y_{1t} \\ Y_{2t} \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ L^{21} & 1 \end{pmatrix} \begin{pmatrix} C_1 \\ C_2 \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ L^{21} & 1 \end{pmatrix} \begin{pmatrix} \Phi_{11} & \Phi_{12} \\ \Phi_{21} & \Phi_{22} \end{pmatrix} \begin{pmatrix} Y_{1t-1} \\ Y_{2t-1} \end{pmatrix} + \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \end{pmatrix}$$

$$\begin{pmatrix} Y_{1t} \\ L^{21} Y_{1t} + Y_{2t} \end{pmatrix} = \begin{pmatrix} C_1 \\ C_1 L^{21} + C_2 \end{pmatrix} + \begin{bmatrix} \Phi_{11}^* & \Phi_{12}^* \\ \Phi_{21}^* & \Phi_{22}^* \end{bmatrix} \begin{pmatrix} Y_{1t-1} \\ Y_{2t-1} \end{pmatrix} + \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \end{pmatrix}$$

Structural  
form  
VAR

$$L^{21} Y_{1t} + Y_{2t} = C_2^* + \Phi_{21}^* Y_{1t-1} + \Phi_{22}^* Y_{2t-1} + \eta_{2t}$$

$$Y_{2t} = C_2^* - L^{21} Y_{1t} + \Phi_{21}^* Y_{1t-1} + \Phi_{22}^* Y_{2t-1} + \eta_{2t}$$

dynamic relationship (lead-lag)  
 หมายความว่าใน period ต่อมา  
 $L^{21} < 0 \Rightarrow Y_{2t} \rightarrow Y_{1t}$  แสดงความล่าช้าของ information  
 contemporaneous relationship.

# VAR

หากเราคุณข้างหน้าสมการ (5.1) ด้วย  $L^{-1}$  จะได้  
 $L^{-1} Y_t =$

$L^{-1}$  จะแสดงความสัมพันธ์ระหว่างอนุกรมเวลาในความเดียวกัน  
เราเรียกแบบจำลองเวลาเดอร์อัตโนมัติเรgresซีฟในรูปนี้ว่าสมการในรูปโครงสร้าง  
**(structural equation)**

# ตัวอย่างที่ 5.1 กัน lecture note .

กำหนด Bivariate VAR(1) สามารถแสดงในรูปดังนี้

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 0.2 \\ 0.4 \end{pmatrix} + \begin{pmatrix} 0.2 & 0.3 \\ -0.6 & 1.1 \end{pmatrix} \begin{pmatrix} y_{1,t-1} \\ y_{2,t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

โดยที่  $\Sigma = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix} \Rightarrow L G L'$

$VAR \Rightarrow 2 \text{ จุด } \rightarrow$  Reduced form VAR      Structural Form VAR       $y_t \sim \mu + y_{t-1} + \dots$   
 Reduced form       $\text{Structural Form VAR}$        $\text{ที่มีส่วนของ } y_t \text{ อยู่ด้วย}$

• เราจะเห็นได้ว่าสามารถแปลงแบบจำลองเวลาเตอร์อโติรีเกรสซีฟในรูปคลรูปไปเป็นรูปโครงสร้างได้ด้วย Cholesky decomposition  $E_t = L G L'$

• อย่างไรก็ตามในการวิเคราะห์อนุกรมเวลาเรามักจะใช้สมการในรูป Reduced form เนื่องจากเป็นรูปที่ง่ายในการประมาณค่า

• เราสามารถเน้นผลใน การพยากรณ์ ของแบบจำลองซึ่งเราไม่สามารถใช้แบบจำลองในรูปโครงสร้างพยากรณ์ข้อมูลได้เนื่องจากเราไม่ทราบข้อมูลของอนุกรมเวลาอื่นๆ ในการเดียวกัน

Mo. 9.5 Reduced form VAR แบบพากย์  
 (ช่วงเวลา period Abu)

# เงื่อนไขการเป็นอนุกรมเวลาที่นิ่ง (Stationary)

แบบจำลอง  $VAR(p)$  สามารถเขียนในรูปเครื่องหมายขบวนไปข้างหลัง (lag operator) ได้ดังนี้

$$\Phi(L)Y_t = c + \varepsilon_t$$

โดยที่  $\Phi(L) = I_n - \Phi_1L - \dots - \Phi_pL^p$  แบบจำลอง  $VAR(p)$  จะมีเสถียรภาพถ้าหากของ

$$\det(I_n - \Phi_1z - \dots - \Phi_pz^p) = 0$$

มีค่ามากกว่าหนึ่ง (หรือไม่คูลัสมากกว่าหนึ่งในกรณีจำนวนเชิงซ้อน) ถ้าสมมุติให้กระบวนการดังกล่าวมีค่าในอดีตที่เป็นอนันต์ แล้วกระบวนการ  $VAR(p)$  ที่มีเสถียรภาพจะเป็นกระบวนการนิ่งและ ergodic โดยมีค่าเฉลี่ย ค่าความแปรปรวนและค่าความแปรปรวนร่วมในตัวเองที่ไม่ขึ้นกับเวลา

$$\text{การประมาณค่า} \rightarrow \text{Reduced form VAR(1)}$$

$$Y_{1t} = C_1 + \phi_{11} Y_{1,t-1} + \phi_{12} Y_{2,t-1} + \varepsilon_{1t}$$

$$Y_{2t} = C_2 + \phi_{21} Y_{1,t-1} + \phi_{22} Y_{2,t-1} + \varepsilon_{2t}$$

การเราระพิจารณาสมการ (5.1) แต่ละสมการจะมีตัวแปรที่เหมือนกัน เราสามารถพิจารณาสมการสำหรับแต่ละตัวแปรออกเป็น

$$y_i = Z\phi_i + e_i, \quad i = 1, \dots, n$$

การประมาณค่า OLS ประจำ  
ตัวแปร: ของตัวแปร

แต่ละสมการสามารถประมาณค่าได้ด้วย ordinary least squares (OLS) แยกแต่ละสมการ และจะได้  $\hat{\Phi} = [\hat{\phi}_1, \dots, \hat{\phi}_n]$  เป็นเมตริกซ์ ( $k \times n$ ) ของค่าสัมประสิทธิ์จากการประมาณค่าด้วย OLS

ภายใต้ข้อสมมุติที่แบบจำลองเป็นแบบกระบวนการนิ่งและ ergodic เราจะได้  $\text{vec}(\hat{\Phi})$  มีคุณสมบัติ consistent และมีการแจกแจงแบบปกติเมื่อกลุ่มตัวอย่างใหญ่โดยมีเมตริกซ์ค่าความแปรปรวนเท่ากัน

$$\widehat{\text{aver}}(\text{vec}(\hat{\Phi})) = \hat{\Sigma} \otimes (\mathbf{Z}' \mathbf{Z})^{-1}$$

โดยที่  $\hat{\Sigma} = \frac{1}{T-k} \sum_{t=1}^T \hat{\varepsilon}_t \hat{\varepsilon}_t'$  และ  $\hat{\varepsilon}_t = \mathbf{Y}_t - \hat{\Phi}' \mathbf{Z}_t$  เป็น residuals จากการประมาณค่า

# การเลือกจำนวนความล่าที่เหมาะสม

order  $VAR(p)$   $\Rightarrow$  Information criteria  $AIC$   $BIC$

การหาความล่าที่เหมาะสมของแบบจำลองเวคเตอร์อัตโนมัติ เกรสซีฟอาจจะทำได้โดยการใช้สูตรการเลือกความล่า โดยการประมาณค่าแบบจำลองเวคเตอร์อัตโนมัติ เกรสซีฟที่มีความล่าเท่ากับ  $0, 1, \dots, p_{max}$  และเลือกค่า  $p$  ที่ทำให้ค่าที่ใช้เลือกมีค่าต่ำที่สุด โดยจะมีสูตรดังนี้

$$IC(p) = \ln |\tilde{\Sigma}(p)| + c_T(n, p)$$

$AIC, BIC$

มาก, บวก  $p$  มาก  $BIC$

โดยที่  $\tilde{\Sigma}(p) = T^{-1} \sum_{t=1}^T \hat{\varepsilon}_t \hat{\varepsilon}_t'$  คือ residual covariance matrix จาก  $VAR(p)$ ,  $c_T$  คือ ลำดับที่ขึ้นกับจำนวนตัวอย่าง

$$AIC(p) = \ln |\tilde{\Sigma}(p)| + \frac{2}{T} (pn^2)$$

$$BIC(p) = \ln |\tilde{\Sigma}(p)| + \frac{\ln T}{T} (pn^2)$$

$$HQIC(p) = \ln |\tilde{\Sigma}(p)| + \frac{2 \ln(\ln T)}{T} (pn^2)$$

## ตัวอย่าง 5.2

ในตัวอย่างนี้เราจะพิจารณาความสัมพันธ์ระหว่างผล ได้ตอบแทนรายวันจากการลงทุนในตลาดหลักทรัพย์แห่งประเทศไทย (lret\_set) และตลาดหุ้นดาวโจนส์ (lret\_dowjones) ข้อมูลอยู่ในไฟล์ set\_dj.csv)

เราจะ ได้ข้อมูลสองชุดคือ lret\_set และ lret\_dowjones เราจะเปียนข้อมูล ทั้งสองในรูปของเมตริกซ์ที่นำเวกเตอร์ทั้งสองมาต่อกันโดยใช้คำสั่ง cbind

$$\text{lret} = \begin{bmatrix} \text{lret\_set} & \text{lret\_dowjones} \end{bmatrix}$$

1 > lret <- cbind(lret\_set, lret\_dowjones)

เราสามารถพิจารณาค่าสถิติเบื้องต้นได้จากคำสั่ง basicStats และ acf เหมือนกับที่เราเคยใช้ในหัวข้อก่อนได้

$$\text{VAR}(p) \text{ von } \mathbf{y}_t = \begin{bmatrix} \text{lret\_set}_t \\ \text{lret\_DowJones}_t \end{bmatrix}$$

# ตัวอย่าง

หากเราต้องการประมาณค่า VAR( $p$ ) เราจะใช้ library(vars) โดยที่เราอาจจะเริ่มจากการหาค่า  $p$  ที่เหมาะสมโดยการใช้คำสั่ง VAR พร้อมระบุเมตริกซ์ของข้อมูล lret จำนวนค่าล่าสูงสุด lag.max และ เกณฑ์ในการเลือกค่าล่า ic=c("AIC") โดยที่ "SC" จะแทน Schwarz-Bayesian (BIC) และ "HQ" Hannan-Quinn (HQIC)

log10       $P_{max}=10$       Info Criteria

```

1 > library(vars)
2 > msel=VAR(lret, lag.max=10, ic=c("AIC"))
3 > msel
4
5 VAR Estimation Results:
6 =====
7
8 Estimated coefficients for equation lret_set:
9 =====
10 <Omitted>
11
12   lret_sett-1   lret_dowjonest-1
13   0.0556382    0.22898590   lret_set.12 lret_dowjones.12
14   lret_set.13 lret_dowjones.13   -0.33541086    0.32270310
15   0.01244410   0.21790099   lret_set.14 lret_dowjones.14
16   lret_set.15 lret_dowjones.15   -0.13694929    0.17900004
17   -0.01107252   0.04790222   lret_set.16 lret_dowjones.16
18   lret_set.17 lret_dowjones.17   -0.06473588    0.12631799
19   0.01517100   0.05964304   lret_set.18 lret_dowjones.18
20   lret_set.19 lret_dowjones.19   -0.02897568    0.02785310
21   0.03837222   0.08783703   const
                                
```

AIC น้อยกว่า VAR(9)

lret\_dowjones<sub>t-g</sub>

ព័ត៌មាន 5.2

Wodl "Sc" [BIC] Anq. für order durch AIC (<9)  
 $\underline{\underline{P=4}}$   $y = \begin{pmatrix} \text{lref-set} \\ \text{lref-Doujones} \end{pmatrix}$

```

1 > model1=VAR(lret, p=4)
2 > summary(model1)
3 Analisis VAR(4) t-5:4
4 VAR Estimation Results:
5 =====
6 Endogenous variables: lret_set, lret_dowjones
7 Deterministic variables: const
8 Sample size: 3803
9 Log Likelihood: -15650.859
10 Roots of the characteristic polynomial:
11 0.62 0.62 0.5867 0.5867 0.3557 0.3557 0.2886 0.2886
12 Call:
13 VAR(y = lret, p = 4)
14
15
16 Estimation results for equation lret_set:
17 =====
18 lret_set = lret_set.11 + lret_dowjones.11 + lret_set.12 + lret_dowjones.12 +
19 lret_set.13 + lret_dowjones.13 + lret_set.14 + lret_dowjones.14 + const
20
21 lret_set.11 t-1 Estimate Std. Error t value Pr(>|t|) lret_set_t =
22 lret_dowjones.11 0.222804 0.032471 6.862 7.91e-12 ***
23 lret_set.12 -0.320847 0.016256 -19.738 < 2e-16 ***
24 lret_dowjones.12 0.313004 0.032696 9.573 < 2e-16 ***
25 lret_set.13 0.023840 0.016122 1.479 0.139313
26 lret_dowjones.13 0.205041 0.032958 6.221 5.47e-10 ***
27 lret_set.14 -0.103471 0.016011 -6.462 1.16e-10 ***
28 lret_dowjones.14 0.151876 0.032994 4.503 4.30e-06 ***
29 const t-4 0.002529 0.043532 0.058 0.953684 lret_dowjones_t =
30
31 Signif. codes: 0 *** 0.001 ** 0.01 * 0.05 . 0.1 .
32
33
34 Residual standard error: 2.683 on 3794 degrees of freedom
35 Multiple R-Squared: 0.1409, Adjusted R-squared: 0.1391
36 F-statistic: 77.78 on 8 and 3794 DF, p-value: < 2.2e-16

```

## ตัวอย่าง 5.2

$$\hat{\Sigma} = \begin{bmatrix} \text{var}(lret\_set_t) & \text{cov}(lret\_set_t, lret\_DJ_t) \\ \text{cov}(lret\_set_t, lret\_DJ_t) & \text{var}(lret\_DJ_t) \end{bmatrix}$$

```

1 Estimation results for equation lret_dowjones:
2 =====
3 <omitted>
4 Covariance matrix of residuals:
5
6  $\text{Var}(lret\_set)$   $\text{lret\_set}$   $\text{lret\_dowjones}$   $\Rightarrow lret\_set, lret\_DJ_t$ 
7  $lret\_set$  7.199 -0.556  $\text{Cov}(\hat{\epsilon}_{set}, \epsilon_{DJ}) = -0.556$  ความผันผวน
8  $lret\_dowjones$  -0.556 1.839  $\text{Var}(lret\_DJ)$   $\Rightarrow$  ความผันผวน
9 Correlation matrix of residuals:
10
11  $\text{lret\_set}$   $\text{lret\_set}$   $\text{lret\_dowjones}$ 
12  $lret\_set$  1.0000 -0.1528
13  $lret\_dowjones$  -0.1528 1.0000
  
```

$\rightarrow$  กรณี Reduced form VAR ให้  $\Sigma$  ของ  $\epsilon$  แทน  $\Sigma$  ของ  $lret\_set_t$  และ  $lret\_DJ_t$

$$lret\_set_t = 0.059 lret\_set_{t-1} + \dots$$

$$lret\_DJ_t = \dots$$

กรณี VARCP

$$\frac{1) \text{ แนวโน้ม } Y_t}{2) \text{ ความผันผวน } Y_t} \xrightarrow{h+1}$$

2) ความผันผวนของ  $Y_t$  ที่คำนวณโดยใช้ VAR(1)  $\xrightarrow{\text{Dynamic}}$



การพยากรณ์จากแบบจำลอง  $VAR^{(p)}$  [แบบ AR(p)]  $\hat{Y}_{h+1}$

แบบชั้นต่ำ  $VAR(1)$   $\hat{Y}_t = \Phi Y_{t-1} + \varepsilon_t$

① หากเราพิจารณาแบบจำลอง  $VAR(p)$  โดยที่เราทราบค่าพารามิเตอร์  $\Phi$  ค่าพยากรณ์ไปข้างหน้าหนึ่ง步  $Y_{h+1}$  ด้วยข้อมูลที่มี ณ ครบที่  $h$  ได้ด้วยการเขียนสมการแสดงค่า  $Y_{h+1} = \Phi Y_h + \varepsilon_{h+1}$

② แล้วหา conditional expectation ด้วยข้อมูล ณ  $h$  เราจะได้ค่าพยากรณ์เท่ากับ

$$\hat{Y}_h(1) = E(Y_{h+1} | F_h) = E(\Phi Y_h + \varepsilon_{h+1} | F_h) = \Phi Y_h + E(\varepsilon_{h+1} | F_h) = \Phi Y_h = \begin{pmatrix} \phi_{11} & \phi_{12} \\ \phi_{21} & \phi_{22} \end{pmatrix} \begin{pmatrix} Y_{1h} \\ Y_{2h} \end{pmatrix}$$

โดยที่ค่าความผิดพลาดจากการพยากรณ์ (forecast error) เท่ากับ

$$e(1) = Y_{h+1} - \hat{Y}_h(1) = (\Phi Y_h + \varepsilon_{h+1}) - (\Phi Y_h) = \varepsilon_{h+1} = \begin{pmatrix} \varepsilon_{1,h+1} \\ \varepsilon_{2,h+1} \end{pmatrix} \quad \begin{pmatrix} Y_{1h}(1) \\ Y_{2h}(1) \end{pmatrix} = \begin{pmatrix} \phi_{11} Y_{1h} + \phi_{12} Y_{2h} \\ \phi_{21} Y_{1h} + \phi_{22} Y_{2h} \end{pmatrix}$$

ค่าพยากรณ์ไปข้างหน้าสอง步  $Y_{h+2}$  ด้วยข้อมูลที่มี ณ ครบที่  $h$  จะเท่ากับ

$$\hat{Y}_h(2) = E(Y_{h+2} | F_h) = E[\Phi Y_{h+1} + \varepsilon_{h+2} | F_h] = \Phi E(Y_{h+1} | F_h) + E(\varepsilon_{h+2} | F_h) = \Phi \hat{Y}_h(1) + \varepsilon_{h+2}$$

โดยที่ค่าความผิดพลาดจากการพยากรณ์ (forecast error) เท่ากับ

$$e(2) = Y_{h+2} - \hat{Y}_h(2) = (\Phi Y_{h+1} + \varepsilon_{h+2}) - \Phi \hat{Y}_h(1) = \Phi Y_h + \varepsilon_{h+1} - \Phi \hat{Y}_h(1) = \Phi Y_h + \varepsilon_{h+1} - \Phi(\Phi Y_h) = \varepsilon_{h+1}$$

$$= (\Phi^2 Y_h + \Phi \varepsilon_{h+1} + \varepsilon_{h+2}) - \Phi^2 Y_h = \Phi \varepsilon_{h+1} + \varepsilon_{h+2}$$

$$e(2) = \frac{1}{\Phi} \varepsilon_{h+1} + \varepsilon_{h+2}$$

$$\hat{Y}_h(1) = \Phi^1 Y_h$$

$$\text{forecast error vs } \hat{Y}_{h+1}(2) \quad \begin{pmatrix} e_1(2) \\ e_2(2) \end{pmatrix} = \begin{pmatrix} \phi_{11}\varepsilon_{1,h+1} + \phi_{12}\varepsilon_{2,h+1} + \varepsilon_{1,h+2} \\ \phi_{21}\varepsilon_{1,h+1} + \phi_{22}\varepsilon_{2,h+1} + \varepsilon_{2,h+2} \end{pmatrix}$$

forecast error รากที่สอง ถูกกีบับ ตรวจสอบ shock รอบนั้น

หากแทนค่าด้วยวิธีการ recursive จะได้ค่าพยากรณ์ไปข้างหน้า / ค่า  $Y_{h+1}$  ด้วย ดูใน  
ข้อมูลที่มี ณ ครบที่  $h$  เท่ากับ

$$\hat{Y}_h(l) = c + \Phi_1 \hat{Y}_h(l-1) + \dots + \Phi_p \hat{Y}_h(l-p)$$

ค่าคาดเดลี่อนของการพยากรณ์ (forecast errors) จะเขียนในรูป  
 $\hat{Y}_h(l) - Y_{h+l} = \sum_{s=0}^{l-1} \Psi_s \varepsilon_{h+l-s}$

$$\text{โดยที่ เมตริกซ์ } \Psi_s \text{ สามารถคำนวณได้โดย } \Psi_s = \sum_{j=1}^{p-1} \Psi_{s-j} \Phi_j$$

ในขณะที่ MSE ของ  $\hat{Y}_h(l)$  จะเท่ากับ

$$\Sigma(l) = MSE(Y_{h+l} - \hat{Y}_h(l)) = \sum_{s=0}^{l-1} \Psi_s \Sigma \Psi_s'$$

$\uparrow$   
 Var vs forecast error  
 รากที่สอง นิ่งตอนที่  
 $2 \times 2 \quad 2 \times 2$   
 $\text{Var}(\varepsilon(2)) = \underline{\Phi} \underline{\varepsilon} \underline{\Phi}' + \varepsilon$

- Var vs forecast  
 $\text{Error vs next period}$   
 $\text{Var}(\varepsilon(1)) = E(\varepsilon(1)\varepsilon(1)')$   
 $= E(\varepsilon_{h+1}\varepsilon_{h+1}')$   
 $= \bar{\varepsilon}$

- Var vs forecast error  
 vs 2 period

$$\text{Var}(\varepsilon(2)) = E(\varepsilon(2)\varepsilon(2)')$$

$$= E[(\underline{\Phi} \underline{\varepsilon}_{h+1} + \varepsilon_{h+2})(\underline{\Phi} \underline{\varepsilon}_{h+1} + \varepsilon_{h+2})']$$

$$= E[(\underline{\Phi} \underline{\varepsilon}_{h+1} + \varepsilon_{h+2})(\underline{\varepsilon}'_{h+1} \underline{\Phi}' + \varepsilon'_{h+2})]$$

$$= \underline{\Phi} E(\varepsilon_{h+1} \varepsilon'_{h+1}) \underline{\Phi}' + E(\varepsilon_{h+2} \varepsilon'_{h+2}) + O$$

## ตัวอย่าง 5.3

ต่อเนื่องจากตัวอย่าง 5.2 เราสามารถทำนายผลได้ด้วยแบบ predict โดยระบุแบบจำลองที่ใช้และค่าที่ทำนายไปข้างหน้า

VAR(4)  
forecasting period

```

1 > model1.predict=predict(model1, n.ahead=5)
2 > model1.predict
3 $lret_set
4 period fcst lower upper CI
5 [1,] 0.23354446 -5.025286 5.492375 5.258830
6 [2,] -0.01504318 -5.311043 5.280957 5.296000
7 [3,] 0.08053962 -5.572718 5.733797 5.653258
8 [4,] -0.02118987 -5.682718 5.640339 5.661528
9 [5,] -0.04475454 -5.707153 5.617644 5.662399
10
11 $lret_dowjones
12 fcst lower upper CI
13 [1,] -0.046835523 -2.705029 2.611358 2.658193
14 [2,] 0.023569365 -2.639844 2.686983 2.663413
15 [3,] 0.005536266 -2.686514 2.697586 2.692050
16 [4,] 0.021958580 -2.670142 2.714059 2.692101
17 [5,] 0.031192947 -2.661288 2.723674 2.692481

```

ในการพยากรณ์การเคลื่อนไหวของ VAR ท่องก วนทริกท์  
ก วนทริกท์ ( $\phi$ ) ไม่ดี ( $\phi$ ) - อินเด็กซ์ ของตัวแปร  
(lag ของตัวแปร เช่น 12 เดือน)

การวัดความสัมพันธ์ VAR  
1) Granger Causality 2) Impulse Response Function 3) Variance Decomposition



① Granger Causality คือ ตัวแปร Y<sub>t</sub>, ความเป็นเหตุ เป็น เหตุ Regression ตัวแปร X<sub>t</sub> ทุกอย่าง X → Y  
ตัวแปร VAR ต่อไป ไม่ต้องมีกฎ (Atheoretical) หันไป Causality ความเป็น因  
โครงสร้างของแบบจำลอง VAR ช่วยให้ ข้อมูลกับเรา ว่าตัวแปรหรือกลุ่มของตัวแปรนี้ ความสามารถในการทำนายตัวแปรอื่นหรือไม่

Granger (1969) เสนอว่า  $\hat{y}_2 = \Phi_{22} y_{2,t-1} + \Phi_{21} y_{1,t-1} + \varepsilon_{2t}$

- ถ้าตัวแปร  $y_1$  ช่วยในการทำนายตัวแปรอื่น  $y_2$  เราจะเรียกว่า  $y_1$  แกรงเจอร์คอส (Granger-cause)  $y_2$  [ไม่สามารถยันได้ว่า  $y_1$  เป็น因  $y_2$  มาก]
- ถ้า  $y_1$  ไม่ช่วยในการทำนายตัวแปร  $y_2$  เราจะพูดว่า  $y_1$  ไม่แกรงเจอร์คอส (does not Granger-cause)  $y_2$

เราจะต้องระลึกไว้อยู่เสมอว่า แกรงเจอร์คอส เป็นการอนุมาน ไปยังความสามารถในการพยากรณ์เท่านั้น ไม่ได้เป็นความเป็นเหตุเป็นผลจริงๆ ของตัวแปร

VAR(1) Economic Causality (ตัวแปรทางเศรษฐกิจ)  
สมมติฐาน Granger Causality (ตัวแปรทางเศรษฐกิจ)  
 $H_0: \text{ตัวแปรทางเศรษฐกิจ } (Y_1, Y_2 \text{ & c. } Y_2) \quad H_1: Y_1 \text{ ตัวแปรทางเศรษฐกิจ } Y_2$   
 $\Phi_{21} = 0 \quad \Phi_{21} \neq 0$   
 $t\text{-test ประมาณ}$

# Granger Causality

ในหัวข้อนี้เราพิจารณาแบบจำลอง  $VAR(2)$  ที่มีตัวแปรสองตัว ซึ่งสามารถเขียนเป็นสมการได้ดังนี้

$$H_0: \phi_{12}^1 = \phi_{12}^2 = 0 \quad \text{vs} \quad H_1: \text{มีตัวแปรตัวที่ } \phi_{12}, \phi_{21} \neq 0 \rightarrow \text{ใช้ F-test, Wald}$$

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} + \begin{pmatrix} \phi_{11}^1 & \phi_{12}^1 \\ \phi_{21}^1 & \phi_{22}^1 \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \phi_{11}^2 & \phi_{12}^2 \\ \phi_{21}^2 & \phi_{22}^2 \end{pmatrix} \begin{pmatrix} y_{1t-2} \\ y_{2t-2} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad (5.13)$$

$\text{Y}_{2t} \text{ G.C. } \text{Y}_{1t}$  หรือ  $\text{Y}_{1t} \text{ G.C. } \text{Y}_{2t}$

- หาก  $y_{2t}$  ไม่แกรงเจอร์คอส  $y_{1t}$  ค่าสัมประสิทธิ์  $\phi_{12}^1$  และ  $\phi_{12}^2$  จะมีค่าเท่ากับศูนย์
  - ถ้า  $y_{1t}$  ไม่แกรงเจอร์คอส  $y_{2t}$  ค่าสัมประสิทธิ์  $\phi_{21}^1$  และ  $\phi_{21}^2$  จะมีค่าเท่ากับศูนย์
- ดังนั้นในการทดสอบว่า  $y_{2t}$  แกรงเจอร์คอส  $y_{1t}$  หรือไม่ เราจะต้องสมมุติฐานหลักว่า  $H_0: \phi_{12}^1 = \phi_{12}^2 = 0$  และสมมุติฐานทางเลือกคือมีสัมประสิทธิ์  $\phi_{12}^1$  หรือ  $\phi_{12}^2$  ตัวใดตัวหนึ่งมีค่าไม่เท่ากับศูนย์ ซึ่งการทดสอบดังกล่าวคือการทดสอบ F นั่นเอง (Wald)

## ตัวอย่าง 5.4

lret\_Dowjones  $\xrightarrow{G.C.}$  lret\_set ผลิตภัณฑ์ VAR

ต่อเนื่องจากตัวอย่าง 5.3 เราต้องการทดสอบว่า lret\_dowjones แกรงเจอร์ คือ lret\_set หรือไม่ (

เราสามารถทดสอบโดยใช้คำสั่ง causality โดยที่เราจะต้องระบุแบบจำลองที่ใช้และตัวแปรที่เป็นสาเหตุ (cause) ซึ่งในที่นี้คือ lret\_dowjones

แบบจำลอง VAR(4)

$$\begin{aligned} \text{lret-set}_t = & \phi_1 \text{lret-set}_{t-1} + \dots + \phi_4 \text{lret-set}_{t-4} \\ & + \phi_5 \text{lret-dowjones}_{t-1} + \dots + \phi_8 \text{lret-dowjones}_{t-4} \end{aligned}$$

```

1 > causality(model1, cause="lret_dowjones")
2 $Granger
3 ~~IGranger causality H0: lret_dowjones do not Granger-cause lret_set
4 data: VAR object model1
5 F-Test = 43.5947, df1 = 4, df2 = 7588, p-value < 2.2e-16
6
7 $Instant
8 ~~IHO: No instantaneous causality between: lret_dowjones and lret_set
9 data: VAR object model1
10 Chi-squared = 86.7677, df = 1, p-value < 2.2e-16

```

F-stat = 43.59 > critical F

ปัจจุบัน p-value < 0.05

หาก  $H_0$  ไม่ถูกปฏิเสธ ให้ตั้ง H0: ไม่มีสาเหตุ lret\_dowjones G.C. lret\_set.  
[ ไม่พบ lret\_dowjones ท่องเที่ยวนอน葛根 lret\_set ]

ถ้าต้อง G.C.  $\rightarrow$  ต้องมีความทึบตื้นที่ต้องมีความสนับสนุน  
กระบวนการที่ดูเหมือน Dyamic relationship

[ lret\_dowjones ที่ G.C.  
lret\_set ]

$H_1: \phi_5 \neq \phi_6, \phi_7 \neq \phi_8$   
คุณปัจจุบัน แต่  $\neq 0$

## ① Impulse Response Function

ห้องเรียน 1 ห้อง 1 ห้อง ห้องนี้เป็นห้องที่ 1  
 ห้องนัด ห้องนัด เป็นห้องที่ 2  $\Rightarrow$  ห้องนัดคือห้อง impulse (Impulse)  
 ห้องเรียน ห้องเรียน ห้องเรียน ห้องเรียน (Response)

หรือการทดสอบแกรงเจอร์คือส่วนที่ระบุว่าตัวแปรใดๆ มีผลกระทบอย่างมีนัยสำคัญต่อตัวแปรอื่นหรือไม่ อย่างไรก็ตาม การทดสอบดังกล่าวไม่ได้บอกทิศทางของความสัมพันธ์และระยะเวลาที่การเปลี่ยนแปลงของตัวแปรหนึ่งจะส่งผลต่ออีกตัวแปรว่าจะมีผลยานานแค่ไหน

impulse response function ซึ่งหมายถึง การตอบสนองของตัวแปรตาม(response) อันเนื่องมาจากการเปลี่ยนแปลงของตัวแปรอีกตัวหนึ่ง (impulse) โดยที่หากเกิดการเปลี่ยนแปลงในช่วงหนึ่ง impulse นั้นๆ จะส่งผลอย่างไรต่อแต่ละตัวแปรใน ค่าที่ต้องการเปลี่ยนแปลงนั้นๆ (เราอาจจะใช้การเปลี่ยนแปลงหนึ่ง s.d.)

ตัวอย่างเช่น หากเราพิจารณาแบบจำลอง VAR(1) ที่มีตัวแปรสองตัวแปร ซึ่งสามารถแสดงได้ด้วยสมการ

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad (5.14)$$

ก็  $y_1$  V.I. 1 รอบ  $\rightarrow$  ก้าวแรก  $y_2$   
 (Impulse) (เกิดขึ้นใน period 0) (Response)

## Impulse Response Function

$$Y_t = \begin{pmatrix} 0.5 & 0.3 \\ 0 & 0.2 \end{pmatrix} Y_{t-1} + \varepsilon_t$$

$$Y_0 = \begin{pmatrix} Y_{10} \\ Y_{20} \end{pmatrix} = \begin{pmatrix} 0.5 & 0.3 \\ 0 & 0.2 \end{pmatrix} \begin{pmatrix} Y_{1,-1} \\ Y_{2,-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{10} \\ \varepsilon_{20} \end{pmatrix}$$

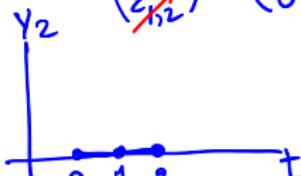
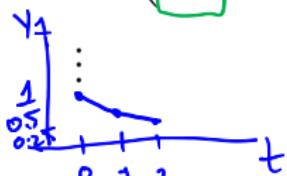
สมมุติว่าเราพิจารณาว่าในปีที่ 0 เกิดช็อกในตัวแปร  $y_{1t}$  หนึ่งหน่วย ( $\varepsilon_{10} = 1$ ) และช็อกในตัวแปร  $y_{2t}$  เท่ากับศูนย์ และช็อกในปีอื่นๆ เท่ากับศูนย์ สมมุติให้  $y_{1t}$  และ  $y_{2t}$  เท่ากับศูนย์ในปีก่อนหน้า ( $t=0$ ) จะได้ว่า  $\varepsilon_{1,t}=0, \varepsilon_{2,t}=0 \quad \forall t=1,2,3,\dots$

$$\begin{pmatrix} Y_{10} \\ Y_{20} \end{pmatrix} = Y_0 = \begin{pmatrix} \varepsilon_{10} \\ \varepsilon_{20} \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

หมายเหตุ shock หรือ period อยู่ที่  $t=0$

$$Y_1 = \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} Y_0 + \begin{pmatrix} \varepsilon_{11} \\ \varepsilon_{21} \end{pmatrix} = \begin{pmatrix} 0.5 & 0.3 \\ 0 & 0.2 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.5+0 \\ 0+0 \end{pmatrix} = \begin{pmatrix} 0.5 \\ 0 \end{pmatrix}$$

$$Y_2 = \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} Y_1 + \begin{pmatrix} \varepsilon_{12} \\ \varepsilon_{22} \end{pmatrix} = \begin{pmatrix} 0.5 & 0.3 \\ 0 & 0.2 \end{pmatrix} \begin{pmatrix} 0.5 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.25 \\ 0 \end{pmatrix}$$



Impulse Response for  
Impulse -  $y_1$ , Response -  $y_2$

กราฟแสดง impulse ของ  $y_1$   
 $y_2$  คือผลของการ

# Impulse Response Function

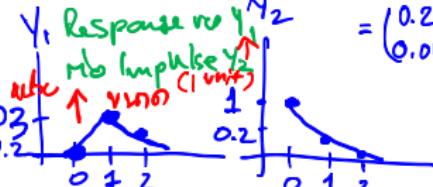
ในกรณี  $VAR(p)$  ที่เป็นกระบวนการนิ่งๆ ได้

กรณี  $|RF| > \sqrt{1 - \rho_{kk}}$   
shock ตัวใดตัวหนึ่ง  $\varepsilon_{it} = 1$  ให้:  
 $\rho_{kk} = 0$

เมื่อ  $\varepsilon_t$  กับ  $\varepsilon_{t+1}$  เป็นส่วนของ  $Cov(\varepsilon_t, \varepsilon_{t+1}) = 0$   
ดูในกรณี  $Reduced\ Form\ VAR$   
มักจะ:  $\varepsilon_t$   $Cov(\varepsilon_{1t}, \varepsilon_{2t}) \neq 0$

$$\frac{\partial y_{i,t+s}}{\partial \varepsilon_{j,t}} = \frac{\partial y_{i,t}}{\partial \varepsilon_{j,t-s}} = \psi_{i,j}^s$$

$$\begin{aligned} Y_2 - \text{impulse} \rightarrow \text{Response } Y_1 \\ (\varepsilon_{20}=1) \quad (Y_{10}) = (0.5 \ 0.3) \begin{pmatrix} 0 \\ 0 \end{pmatrix} + \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \\ (Y_{20}) = (0.5 \ 0.3) \begin{pmatrix} 0 \\ 0 \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ (Y_{11}) = (0.5 \ 0.3) \begin{pmatrix} 0 \\ 1 \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0.3 \end{pmatrix} \\ (Y_{21}) = (0.5 \ 0.3) \begin{pmatrix} 1 \\ 0 \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.5 \\ 0 \end{pmatrix} \\ (Y_{12}) = (0.5 \ 0.3) \begin{pmatrix} 0.3 \\ 0 \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ (Y_{22}) = (0.5 \ 0.3) \begin{pmatrix} 0.3 \\ 0.2 \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.2 \\ 0.04 \end{pmatrix} \end{aligned}$$



อย่างไรก็ตาม คำอธิบายข้างต้นจะเป็นจริงหาก  $var(\varepsilon) = \sum$  เป็นแมตริกซ์ແທยงมุม

ดังนั้นเรามักจะพิจารณา VAR ในรูป structural ซึ่ง ผู้สอน  $\boxed{Cov(Y_{1t}, Y_{2t}) = 0}$

$$BY_t = c + \Gamma_1 Y_{t-1} + \dots + \Gamma_p Y_{t-p} + \eta_t \quad (5.17)$$

โดยที่ Orthogonal error ( $\eta_t$ )  $\rightarrow$  กรณีนี้ต้อง  $\eta_{10} = 1$  และ  $\eta_{20} = 0$  ตามเหตุการณ์

โครงสร้างแบบจำลอง โครงสร้าง (structural model) จะกำหนดให้ความสัมพันธ์ของตัวแปรมีลำดับกือ  $y_1$  เป็นตัวกำหนด  $y_2$  และ  $y_2$  เป็นตัวกำหนด  $y_3$  เป็นลำดับไปเรื่อยๆ ซึ่งใช้ทฤษฎีเป็นตัวกำหนด

# ตัวอย่างที่ 5.5

เราจะสร้าง Impulse response function ด้วยคำสั่ง `irf` โดยที่ default ในคำสั่งนี้คือการสร้าง orthogonal impulse response function (`ortho=TRUE`)

การเรียกตัวแปรใน `lret` ที่เรียกว่า `lret_set` ก่อน `lret_dowjones`

```

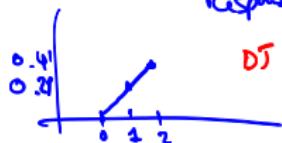
1 > model1.irf=irf(model1, n.ahead=10)
2 > model1.irf
3 Impulse response coefficients
4 $lret_set
5   lret_set lret_dowjones
6 [1,] 2.6831259181 -0.2072364167
7 [2,] 0.1137971489 0.0030468719
8 [3,] -0.9182763350 0.1667746830
9 <omitted>
10 p[11,] 0.00030760182 -0.0002311969
11 $lret_dowjones
12   lret_set lret_dowjones
13 [1,] 0.0000000000 1.3403194745
14 [2,] 0.2986284632 -0.0849824924
15 [3,] 0.4183950540 -0.1100409438
16 <omitted>
17 [11,] 0.0006173344 -0.0002757296

```

↑ VAR      ↑ Period พิจารณา N ต่อหนึ่ง  
 ↑ ผู้รับ影響      ↑ ผู้ให้影响  
 ↑ ผู้รับ影響      ↑ ผู้ให้影响  
 ↑ Response vs Dowjones ของ SET  
 ↑ Response vs Dowjones ของ SET  
 ↑ 1.467  
 ↑ 0.003  
 ↑ -0.257  
 ↑ 1

Response vs SET ของ DJ

DJ  $\uparrow \rightarrow$  SET  $\uparrow$



VAR

1) Granger Causality

2) Impulse Response Function

## ๓) Variance Decomposition

Forecast Error Variance Decomposition จากข้อมูล ณ ครบที่  $h$  เราต้องการตอบ  
คำถามว่าช่องทาง  $\eta_j$  เป็นที่มาของความแปรปรวนของค่าผิดพลาดจากการ  
พยากรณ์  $y_{i,h+1}$  ในสัดส่วนเท่าใด

หากเราพิจารณาเพียงตัวแปรเดียว เช่น  $y_{i,h+1}$  เนื่องจากเมทริกซ์ค่าความแปรปรวน  
ของช่องทางเป็นเมทริกซ์ແທยงมูน

$$\text{var}(y_{i,h+1} - \hat{y}_h(l)) = \sigma_{\eta_1}^2 \sum_{s=0}^{l-1} (\theta_{i1}^s)^2 + \dots + \sigma_{\eta_n}^2 \sum_{s=0}^{l-1} (\theta_{in}^s)^2$$

สัดส่วนของ  $\text{var}(y_{i,h+1} - \hat{y}_h(l))$  อันมีสาเหตุมาจากช่องทาง  $\eta_j$  เท่ากับ

$$VD_{ij}(l) = \frac{\sigma_{\eta_j}^2 \sum_{s=0}^{l-1} (\theta_{ij}^s)^2}{\sigma_{\eta_1}^2 \sum_{s=0}^{l-1} (\theta_{i1}^s)^2 + \dots + \sigma_{\eta_n}^2 \sum_{s=0}^{l-1} (\theta_{in}^s)^2}, \quad i,j = 1, \dots, n \quad (5.21)$$

# ตัวอย่าง 5.6

เราสามารถแยกความแปรปรวนของค่าผิดพลาดจากการพยากรณ์ได้ด้วยคำสั่ง

fevd

FEV vs lret\_wSER  
VAR(4)

Stock Market Spillover

```
> fevd(model1, n.ahead = 5)
```

```
$lret_set
```

```
1 1.0000000000000000 = 0%
```

```
2 0.9877859000000000 = 1.2%
```

```
3 0.9682396000000000 = 3.4%
```

```
4 0.9655329000000000 = 3.4%
```

```
5 0.9654222000000000 = 3.4%
```

```
FEV vs lret_wDJ
```

```
$lret_dowjones
```

```
1 0.02334830000000000 = 0.9766517
```

```
2 0.02326189000000000 = 0.9767381
```

```
3 0.03751278000000000 = 0.9624872
```

```
4 0.03751192000000000 = 0.9624881
```

```
5 0.03750568000000000 = 0.9624943 = 96.14%
```

$Y_1 \ Y_2 \ Y_3 \ Y_4 \ Y_5$

$h = 2$

$$\frac{FEV \text{ von } Y_1}{FEV \text{ ทั้งหมด}} = \frac{\phi_{11}^2 + \phi_{12}^2}{\phi_{11}^2 + \phi_{12}^2 + \phi_{21}^2 + \phi_{22}^2} = 100\% \quad (1)$$

$$\frac{FEV \text{ von } Y_2}{FEV \text{ ทั้งหมด}} = \frac{\phi_{21}^2}{\phi_{11}^2 + \phi_{12}^2 + \phi_{21}^2 + \phi_{22}^2} = 0\% \quad (2)$$

Forecast Error Variance vs  $h=1$

$$\text{Var}(e_{1(1)}) = \begin{pmatrix} \text{Var}(e_{1,h+1}) \\ \text{Var}(e_{2,h+1}) \end{pmatrix} = \begin{pmatrix} \epsilon_1^2 \\ \epsilon_2^2 \end{pmatrix} \quad \begin{array}{l} \text{Forecast Error Variance von } Y_1 \\ \text{FEV von } Y_2 \end{array}$$

FEV von  $h=2$

$$\begin{pmatrix} \text{Var}(e_{1(2)}) \\ \text{Var}(e_{2(2)}) \end{pmatrix} = \begin{pmatrix} \text{var}(\phi_{11}\epsilon_{1,h+1} + \phi_{12}\epsilon_{2,h+1} + \epsilon_{1,h+2}) \\ \text{var}(\phi_{21}\epsilon_{1,h+1} + \phi_{22}\epsilon_{2,h+1} + \epsilon_{2,h+2}) \end{pmatrix} = \begin{pmatrix} \phi_{11}^2\epsilon_1^2 + \phi_{12}^2\epsilon_2^2 + \epsilon_1^2 \\ \phi_{21}^2\epsilon_1^2 + \phi_{22}^2\epsilon_2^2 + \epsilon_2^2 \end{pmatrix}$$