

$y_t$  ← return ตรวจสอบ SET

กรณีที่  $y_t$  return ไม่ติดต่อ แล้ว → ต้อง ตรวจสอบ SET  
EC435

บทที่ 6 แบบจำลองอนุกรมเวลาเชิงพหุ

Multivariate Time Series

เฉลิมพงษ์ คงเจริญ ©2556-2563

คณะเศรษฐศาสตร์ มหาวิทยาลัยธรรมศาสตร์

October 28, 2020

## บทนำ

การเปลี่ยนแปลงที่เกิดขึ้นในตลาดการเงินหนึ่งสามารถส่งผ่านต่อไปยังตลาดอื่นได้ง่าย ดังนั้น บางครั้งเราจำเป็นต้องพิจารณาการเปลี่ยนแปลงของอนุกรมเวลาทางเงินไปพร้อมๆ กัน

โดยเรารีบกแบบจำลองที่พิจารณาอนุกรมเวลาหลายๆ อนุกรมพร้อมกันว่าแบบจำลอง อนุกรมเวลาเชิงพหุตัวแปร(multivariate time series) โดยเราสามารถเขียนอนุกรมเวลาในรูป ของเวกเตอร์

$$\underline{Y}_t = \begin{bmatrix} y_{1t} \\ y_{2t} \\ \vdots \\ y_{nt} \end{bmatrix} \quad \left. \begin{array}{l} \text{ตัวแปร } n \text{ ตัว } \\ \text{vector } \text{ แนวตั้ว } \end{array} \right\}$$

โดยที่  $y_{it}$  แทนอนุกรมเวลา  $i$  และ  $n$  คือจำนวนอนุกรมเวลาที่เราพิจารณาร่วมกัน เช่น  $y_{1t}, y_{2t}, \dots, y_{nt}$  แทนผลได้ตอบแทนในรูปลักษณะของหุ้นในตลาดหลักทรัพย์แห่งประเทศไทย

$$\rightarrow \text{ลักษณะชุด } 0 \text{ ตัว } \quad \underline{Y}_t = \begin{pmatrix} Y_{1t} \\ \vdots \\ Y_{nt} \end{pmatrix} \quad \left. \begin{array}{l} \Rightarrow \text{ แนวตั้ว } \\ \text{ตัวแปร } n \text{ ตัว } \end{array} \right\}$$

หมายเหตุ: รูปแบบนี้ใช้สำหรับการสอนในชั้นเรียน

# เมตริกซ์ความแปรปรวนระหว่างกัน

 $y_{1t}$ 
 $y_{1,t-1}, y_{1,t-2}, \dots$   
 $y_{2,t}, y_{2,t-1}, y_{2,t-2}, \dots$ 

$\underline{Y_t} = (y_{1t}, y_{2t}, \dots, y_{nt})'$  จะเป็นอนุกรมเวลา นิ่ง (stationary) ถ้าไม่มีเมนต์ที่หนึ่งและสองไม่ขึ้นอยู่กับเวลา (time-invariant) ซึ่งในที่นี่เราจะต้องพิจารณาเวกเตอร์ของค่าเฉลี่ย (mean vector)  $\mu = E(\underline{Y_t})$  โดยที่  $\mu = (\mu_1, \dots, \mu_n)'$

ไม่ขึ้นอยู่กับเวลา

เมตริกซ์ของความแปรปรวนร่วม (covariance matrix) ใช้สัญลักษณ์  $\Gamma_0$  สามารถคำนวณได้โดย

gamma

$$\Gamma_0 = E[(\underline{Y_t} - \mu)(\underline{Y_t} - \mu)']$$

$$= \begin{pmatrix} E(y_{1t} - \mu_1)^2 & E(y_{1t} - \mu_1)(y_{2t} - \mu_2) & \dots & E(y_{1t} - \mu_1)(y_{nt} - \mu_n) \\ \vdots & E(y_{2t} - \mu_2)^2 = var(y_{2t}) & \ddots & \vdots \\ E(y_{nt} - \mu_n)(y_{1t} - \mu_1) & E(y_{nt} - \mu_n)(y_{2t} - \mu_2) & \dots & E(y_{nt} - \mu_n)^2 \\ \vdots & \vdots & \ddots & \vdots \\ Cov(y_{1t}, y_{2t}) & Cov(y_{1t}, y_{nt}) & \dots & Cov(y_{nt}, y_{nt}) \end{pmatrix}$$

$$Var(y_{1t}) \quad Cov(y_{1t}, y_{2t}) \quad \dots \quad Cov(y_{1t}, y_{nt})$$

$$\vdots \qquad \vdots \qquad \ddots \qquad \vdots$$

$$Cov(y_{nt}, y_{1t}) \quad Cov(y_{nt}, y_{2t}) \quad \dots \quad Var(y_{nt})$$

## Covariance matrix



## cross-correlation matrices

กำหนดให้  $D$  เป็นเมตริกซ์  $n \times n$  ที่ประกอบด้วยค่าเบี่ยงเบนมาตรฐาน (standard deviation) ของ  $y_{it}$  ในพจน์แทบทุก โดยที่  $\Gamma_{ii}(0)$  เป็นสัญลักษณ์แทนค่าความแปรปรวนของ  $y_{it}$  ดังนั้นเราสามารถเขียนเมตริกซ์  $D$  ได้ดังนี้

$$D^{-1} = \begin{bmatrix} \frac{1}{\sqrt{\Gamma_{11}(0)}} & & \\ & \ddots & \\ & & \frac{1}{\sqrt{\Gamma_{nn}(0)}} \end{bmatrix} \quad D = \begin{pmatrix} \sqrt{\Gamma_{11}(0)} & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \sqrt{\Gamma_{nn}(0)} \end{pmatrix}$$

$\Gamma_{11}(0) \text{ หมาย喻 } \gamma_{11} = \text{Var}(y_{1t})$   
 $\text{SD}(y_{nt})$

เราสามารถนิยามเมตริกซ์สหสัมพันธ์ข้ามตัวแปร (cross-correlation) ที่ความเวลาเดียวกัน (concurrent) ได้ด้วย

$$\boxed{\rho_0 = [\rho_{ij}(0)] = D^{-1} \Gamma_0 D^{-1}}$$

*covariance*

โดยที่  $\rho_{ij}(0) = \frac{\Gamma_{ij}(0)}{\sqrt{\Gamma_{ii}(0)\Gamma_{jj}(0)}} = \frac{\text{cov}(y_{it}, y_{jt})}{\text{std}(y_{it})\text{std}(y_{jt})}$  ซึ่งคือสหสัมพันธ์ระหว่าง  $y_{it}$  และ  $y_{jt}$  โดยที่ในการวิเคราะห์อนุกรมเวลาเราจะเรียกสหสัมพันธ์ดังกล่าวว่าเป็นสหสัมพันธ์ในความเดียวกัน (concurrent หรือ contemporaneous)



## cross correlation matrices

ความสัมพันธ์ในเชิงตัวแปรที่นำหรือตาม (lead-lag relationship) เมทริกซ์ความ  
แปรปรวนร่วมข้ามตัวแปรที่มีค่าล่าท่ากับหนึ่งใช้สัญลักษณ์  $\Gamma_1$  ดังที่ได้แสดงในสมการต่อ  
ไปนี้

$$\begin{aligned} \Gamma_1 &= E[(\underline{Y_t} - \mu)(\underline{Y_{t-1}} - \mu)'] \\ &= \begin{pmatrix} E(y_{1t} - \mu_1)(y_{1,t-1} - \mu_1) & E(y_{1t} - \mu_1)(y_{2,t-1} - \mu_2) & \dots & E(y_{1t} - \mu_1)(y_{nt}) \\ \vdots & \vdots & \ddots & \vdots \\ E(y_{nt} - \mu_n)(y_{1,t-1} - \mu_1) & E(y_{nt} - \mu_n)(y_{2,t-1} - \mu_2) & \dots & E(y_{nt} - \mu_n)(y_{n,t-1}) \end{pmatrix} \\ &= \begin{pmatrix} Cov(y_{1t}, y_{1,t-1}) & Cov(y_{1t}, y_{2,t-1}) & \dots & Cov(y_{1t}, y_{n,t-1}) \\ \vdots & \vdots & \ddots & \vdots \\ Cov(y_{nt}, y_{1,t-1}) & Cov(y_{nt}, y_{2,t-1}) & \dots & Cov(y_{nt}, y_{n,t-1}) \end{pmatrix} \end{aligned}$$

1-lag Cross-covariance matrix

$$\boxed{\Gamma_1 = D^{-1} \Gamma_1 D^{-1}}$$



# ตัวประมาณค่าสหสัมพันธ์ไขว้

ตัวประมาณค่าของเกกเตอร์ค่าเฉลี่ยและเมตริกซ์ตัวแปรปรวนร่วมไขว้ (cross-covariance) ได้จากการต่อไปนี้

$$\hat{\Gamma}_l = E((Y_t - \mu)(Y_{t-l} - \mu)')$$

*Sample mean vector*

$$\hat{\mu}_Y = \frac{1}{T} \sum_{t=1}^T Y_t \quad (1)$$

sample cross-cov

$$\hat{\Gamma}_0 = \frac{1}{T-1} \sum_{t=1}^T (\underline{Y_t} - \hat{\mu}_Y) \underbrace{((\underline{Y_t} - \hat{\mu}_Y))'}$$

$$\hat{\Gamma}_l = \frac{1}{T-1} \sum_{t=l+1}^T (\underline{Y_{t-l}} - \hat{\mu}_Y) \underbrace{((\underline{Y_t} - \hat{\mu}_Y))'}$$

จากตัวประมาณค่าข้างต้น ตัวประมาณค่าเมตริกซ์สหสัมพันธ์ไขว้ที่ค่าล่าที่  $l$  สามารถคำนวณได้จาก

$$\hat{\rho}_l = \underline{\hat{D}^{-1} \hat{\Gamma}_l \hat{D}^{-1}}$$



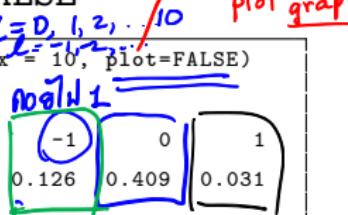
ตัวอย่างที่ 6.1 หาสัมพันธ์ไขว้ log return ของตลาดเงิน TH & MY  
Cross-correlation function.

เราใช้คำสั่ง `ccf` ในการคำนวณสหสัมพันธ์ไขว้ โดยกำหนดตัวแปรตัวที่หนึ่งและสอง และเลือกเงื่อนไข `type=c("correlation")` และ `plot=FALSE` `default → TRUE` `plot graph`

```

1 > ccf(lret_thmy$TH, lret_thmy$MY, type=c("correlation"), lag.max = 10, plot=FALSE)
2 Autocorrelations of series ''X, by lag
3
4 -10      -9      -8      -7      -6      -5      -4      -3      -2
5 0.038   0.109   0.093   0.050   0.063   0.035   0.033   0.094   0.139
6 0.127   0.047   0.025
7 0.097   -0.047  -0.004  -0.035  -0.005  -0.064
8
9 > ccf(lret_thmy$TH, lret_thmy$MY, type=c("correlation"), lag.max = 10,
       ylab="cross-correlation")

```



## Contemporanea

lead  
- lag

$\text{Corr}(\gamma_{1t}, \gamma_{2,t-1}) = 0.126 \rightarrow \text{log return } M\gamma_1^{\text{fut}}[t-1] \text{ and } \gamma_2^{\text{fut}}[t-1]$

~ log return  $\equiv$  first

$\text{corr}(\underline{\eta_{1t}}, \underline{\eta_{2,t+1}}) = 0.031 \rightarrow \text{log return}_1 \text{ vs } \text{log return}_2$

dynamite

សំណើម៉ោងរួចរាល់នៅ  $P_0 = 0$  ? ( $\text{អី} = 0$  និងដឹងត្រូវ)

# การทดสอบสหสัมพันธ์ไขว้

แนวคิด ไม่ต้องนับฟังก์ชัน ใช้พจน์

การทดสอบว่าข้อมูลของตัวแปรเหล่านี้มีความสัมพันธ์เชิงพลวัตกัน หรือทดสอบสมมุติฐานหลักว่าเมื่อพิจารณาข้อมูลไป  $m$  คาบเรามิ่งพบรหสหสัมพันธ์หรือเป็นสัญลักษณ์  $H_0 : \rho_1 = \rho_2 = \dots = \rho_m = 0$  ในขณะที่สมมุติฐานทางเลือกคือมีสหสัมพันธ์ไขว้ ณ ค่าล่าได้ค่าหนึ่งมีค่าไม่เท่ากับศูนย์ หรือเป็นสัญลักษณ์  $H_1 : \rho_i \neq 0$  สำหรับค่าใดค่าหนึ่งของ  $i = 1, \dots, m$  Li and McLeod (1981) ได้เสนอการทดสอบพอร์ทแมน โถช์ ได้ขยายการทดสอบจากตัวแปรเดียวเป็นตัวแปรพหุ ซึ่งค่าสถิติลุงบีอกซ์กรีฟพหุตัวแปร (multivariate Ljung-Box test statistics) สามารถเขียนได้ดังนี้

laq อะไ?

$$\text{Q}_n(m) = T^2 \sum_{l=1}^m \frac{1}{T-l} \text{tr}(\hat{\Gamma}'_l \hat{\Gamma}_0^{-1} \hat{\Gamma}_l \hat{\Gamma}_0^{-1}) \sim \chi^2_{df=m \cdot n^2}$$

ตัวแปร  $n$

拒否  $H_0 : Q_n(m) > \text{critical value } \chi^2_{df=m^2}$

โดยที่  $\text{tr}(A)$  คือเทรเซของเมตริกซ์  $A$  และ  $T$  คือจำนวนตัวอย่าง ภายใต้สมมุติฐานหลักที่ถูกต้องค่าสถิติ  $Q_n(m)$  จะมีการแจกแจงลู่เข้าสู่การแจกแจงแบบไคสแควร์ที่มีองค์เสียงเท่ากับ  $mn^2 (\chi^2_{mn^2})$



## ตัวอย่างที่ 6.2

$\text{lret-thmy}$  ~~\$THI \$MY~~

เราทดสอบพอร์ทแม่น โทกับผลตอบแทนรายสัปดาห์จากตลาดหลักทรัพย์ไทยและมาเลเซียด้วยคำสั่ง mq จากชุดคำสั่ง MTS ซึ่งในที่นี่เราจะเลือกค่า  $m = 10$  โดยการระบุ  $\text{lag}=10$  ส่วน  $\text{adj}$  เป็นการปรับค่าองศาเสริช์ในกรณีข้อมูลเดิมเราไม่จำเป็นต้องปรับ (หากเป็นค่าเรซิดิวเราจะต้องระบบพารามิเตอร์ซึ่งประมาณค่า

library(MTS),  $m=10$  จึงจะได้

1	>	<u>mq(lret_thmy, lag=10, adj=0)</u>	
2	Ljung-Box Statistics:		
3	<u><math>m</math></u>	<u><math>Q(m)</math></u>	<u><math>df</math></u>
4	[1,]	1.0	4.0
5	[2,]	2.0	8.0
6	[3,]	3.0	12.0
7	[4,]	4.0	16.0
8	[5,]	5.0	20.0
9	[6,]	6.0	24.0
10	[7,]	7.0	28.0
11	[8,]	8.0	32.0
12	[9,]	9.0	36.0
13	[10,]	<u>10.0</u>	<u>176.5</u>
			<u>40.0</u>

$P\text{-value} < \alpha (0.05)$  ทางการทดสอบ hypothesis

$$Y_t = \begin{pmatrix} Y_{t-1} \\ Y_t \end{pmatrix}^T$$

แบบต่อ續? AR, MA, MRMA?

กรณี AR  $Y_t = \Phi Y_{t-1} + \varepsilon_t$

กรณี MRMA  $Y_t = \Phi Y_{t-1} + \varepsilon_t + \Theta \varepsilon_{t-1}$

Vector AR  $Y_t = \Phi Y_{t-1} + \varepsilon_t$

Vector ARMA  $Y_t = \Phi Y_{t-1} + \varepsilon_t + \Theta \varepsilon_{t-1}$

เมื่อ  $\Phi$  บวก correlation  
ที่มีห่วงกัน  $\Phi \Phi^T$

ทางการทดสอบว่า แบบต่อ續  
 $\downarrow$   
dynamic อย่าง  $Y_t | Y_{t-1}$   
dynamic  $\Rightarrow$  VAR(?) ต้องรู้ตัวแปรทั้งหมด

หมายเหตุ: ไฟล์ Vector AR (VAR) ฐานะตัวแปร  $y_t$

## แบบจำลองเวลาเดอร์อ้อโตรีเกรสซีฟ (Vector Autoregressive Model)

แบบจำลองเวลาเดอร์อ้อโตรีเกรสซีฟที่มีค่าล่าท้ายกับ  $p$ ,  $VAR(p)$ , สามารถเขียนในรูป

$$\begin{pmatrix} y_{1t} \\ \vdots \\ y_{nt} \end{pmatrix} = \begin{pmatrix} Y_t \\ \vdots \\ y_{nt} \end{pmatrix} = c + \Phi_1 \begin{pmatrix} y_{1t-1} \\ \vdots \\ y_{nt-1} \end{pmatrix} + \dots + \Phi_p \begin{pmatrix} y_{1t-p} \\ \vdots \\ y_{nt-p} \end{pmatrix} + \varepsilon_t \quad t = 1, 2, \dots, T \quad (6.1)$$

โดยที่  $\Phi_i$  เป็นเมตริกซ์สัมประสิทธิ์ที่มีขนาด  $n \times n$  และ  $\varepsilon_t$  เป็นเวคเตอร์ของกระบวนการไวационซ์ที่มีค่าเฉลี่ยเท่ากับศูนย์ และมี เมตริกซ์ความแปรปรวนร่วมที่ไม่แปรผันตามเวลา  $\Sigma$

$$\varepsilon_t \sim N(0, \Sigma) \quad E(\varepsilon_t) = 0 \quad \begin{bmatrix} E(\varepsilon_{1t}) = 0 \\ E(\varepsilon_{2t}) = 0 \\ \vdots \\ E(\varepsilon_{nt}) = 0 \end{bmatrix}$$

$$2) \text{Var}(\varepsilon_t) = E[\varepsilon_t \varepsilon_t'] \quad \text{จะมีผลลัพธ์ตามด้าน}$$

แบบจำลองเวกเตอร์อัตโนมัติเกรสซีฟ (Vector Autoregressive Model)

แบบจำลองเวกเตอร์อ โตรีเกรสซีฟที่มีค่าล่าท่ากับ  $p$ ,  $\underline{VAR}(p)$ , สามารถเขียนในรูป

$$\rightarrow Y_t = c + \Phi_1 Y_{t-1} + \dots + \Phi_p Y_{t-p} + \varepsilon_t, \quad t = 1, 2, \dots, T \quad (6.1)$$

โดยที่  $\Phi_i$  เป็นเมตริกซ์สัมประสิทธิ์ที่มีขนาด  $n \times n$  และ  $\varepsilon_i$  เป็นเวกเตอร์ของกระบวนการไวนอนซ์ที่มีค่าเฉลี่ยเท่ากับศูนย์ และมีเมตริกซ์ความแปรปรวนร่วมที่ไม่แปรผันตามเวลา  $\Sigma$   $\Phi_i$  คือ  $\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$   $\varepsilon_i = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$ ,  $\Sigma = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$ ,  $P=1$

## VAR

หรือเขียนเป็นรูปสมการของแต่ละตัวแปรที่เราสนใจ

$$y_{1t} = c_1 + \phi_{11}^1 y_{1t-1} + \phi_{12}^1 y_{2t-1} + \varepsilon_{1t}$$

$$y_{2t} = c_2 + \phi_{21}^1 y_{1t-1} + \phi_{22}^1 y_{2t-1} + \varepsilon_{2t}$$

โดยที่  $Cov(\varepsilon_{1t}, \varepsilon_{2s}) = \sigma_{12}$  ถ้า  $s = t$  และ  $Cov(\varepsilon_{1t}, \varepsilon_{2s}) = 0$  ถ้า  $s \neq t$

ตรวจสอบว่า  $\varepsilon_t = \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$  ตาม W.N.

$$1) E(\varepsilon_t) = 0$$

$$2) Var(\varepsilon_t) = E[(\varepsilon_t - 0)(\varepsilon_t - 0)']$$

$$\begin{aligned} &= E \left[ \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \begin{pmatrix} \varepsilon_{1t} & \varepsilon_{2t} \end{pmatrix}' \right] \\ &= \begin{pmatrix} E(\varepsilon_{1t}^2) & E(\varepsilon_{1t}\varepsilon_{2t}) \\ E(\varepsilon_{2t}\varepsilon_{1t}) & E(\varepsilon_{2t}^2) \end{pmatrix} \quad Cov(\varepsilon_{1t}, \varepsilon_{2t}) = \sigma_{12} ? \end{aligned}$$

$$3) \sum_{\text{Sigma}} \leftarrow \frac{Var(\varepsilon_t)}{\text{Cov}_{\text{period}}}$$

หมายความว่า  $y_{2t-1}$   
 $\rightarrow$  พยากรณ์  $y_{1t}$   
 $\rightarrow$  คาดเดา  $y_{2t}$   
 $\rightarrow$  มนต์มนต์  $y_{1t}$   
 $\rightarrow$  มนต์มนต์  $y_{2t-1}$

$$3) E(\varepsilon_t \cdot \varepsilon_s') = E \left[ \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \begin{pmatrix} \varepsilon_{1s} & \varepsilon_{2s} \end{pmatrix}' \right]$$

$\text{Cov}(\varepsilon_{1t}, \varepsilon_{2t})$

$$= \begin{cases} E(\varepsilon_{1t}\varepsilon_{1s}) & E(\varepsilon_{1t}\varepsilon_{2s}) \\ E(\varepsilon_{2t}\varepsilon_{1s}) & E(\varepsilon_{2t}\varepsilon_{2s}) \end{cases}$$

ทั้ง  $s=t-1$

ทั้ง  $s=t$

ทั้ง  $s=t+1$

(shock ในช่วง period 0 ถึง period 1)

# VAR

หรือเขียนเป็นรูปสมการของแต่ละตัวแปรที่เราสนใจ

Reduced form  
VAR

$$\begin{cases} \underline{y_{1t}} = c_1 + \phi_{11}^1 y_{1t-1} + \phi_{12}^1 y_{2t-1} + \varepsilon_{1t} \\ \underline{y_{2t}} = c_2 + \phi_{21}^1 y_{1t-1} + \phi_{22}^1 y_{2t-1} + \varepsilon_{2t} \end{cases}$$

โครงสร้างของ VAR  
ค่าคงที่ในตัวแปร  
ตัวแปรตัวที่ 1 คือ  $y_{1t}$   
whi ค่าคงที่ในตัวแปร  
res shock  
 $\text{Cov}(\varepsilon_{1t}, \varepsilon_{2t}) = \sigma_{12}$   
ให้  $G_{12} = \sigma_{12}$

โดยที่  $\text{Cov}(\varepsilon_{1t}, \varepsilon_{2s}) = \sigma_{12}$  ถ้า  $s = t$  และ  $\text{Cov}(\varepsilon_{1t}, \varepsilon_{2s}) = 0$  ถ้า  $s \neq t$

ค่าสัมประสิทธิ์แต่ละตัวจะเป็นค่าที่บ่งบอกความสัมพันธ์ระหว่างตัวแปรที่ต่างเวลากัน

- $\phi_{12}^1 \Rightarrow \underline{y_{2t-1}}$  ป. 1 เมื่อ  $\underline{y_{1t}}$  อยู่ในช่วง  $\phi_{12}^1$
  - $\phi_{21}^1 \Rightarrow \underline{y_{1t-1}}$  ป. 1 เมื่อ  $\underline{y_{2t}}$  อยู่ในช่วง  $\phi_{21}^1$
- dynamic

ค่าสัมประสิทธิ์ในสมการ (6.2) ใช้บายพลวัตของอนุกรมเวลาที่เราสนใจ (lead-lag) แต่ไม่ได้อธิบาย concurrent หรือ contemporaneous ไว้อย่างชัดเจน ( $\underline{y_{1t}} \rightarrow \underline{y_{2t}}$ )

เราสามารถดูความสัมพันธ์ดังกล่าวได้ในเมตริกซ์ความแปรปรวนของชีอก

เราเรียกแบบจำลองเวลาเดอร์อโตรีเกรสซีฟในรูป (6.2) ว่าสมการในรูปลดรูป (reduced form)

VAR

อาจ Reduced form VAR เท่านี้ก็สามารถเขียนเป็น  
 $y_{it} \sim y_{it} + \epsilon_{it}$  (ค่า  $\sigma_{12}$ )  $\Rightarrow$  ที่ทั้งต้นนี้เดา ปัจจุบัน  
 (ไม่รู้ว่ามีปัจจัยอะไร)

เราสามารถเขียนความสัมพันธ์ระหว่างอนุกรมเวลาในช่วงเดียวกันได้อย่างชัดเจนโดย  
 ใช้การแปลงรูปสมการที่ (6.2) ได้ดังนี้

เนื่องจาก  $\Sigma$  เป็นเมตริกซ์ positive definite ดังนั้นเราสามารถสร้างเมตริกซ์ lower  
 triangular

(การแยกประกอบ)  
 (decomposition)

$$L = \begin{pmatrix} 1 & 0 & \dots & 0 \\ l_{21} & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & \dots & 1 \end{pmatrix}$$

$$G = \begin{pmatrix} g_1 & 0 & 0 & 0 \\ 0 & g_2 & & \\ \vdots & & \ddots & \\ 0 & - & \dots & g_n \end{pmatrix}$$

และเมทริกซ์แทนมุม  $G$  ที่ทำให้  $\Sigma = LGL'$  ราเรียกการแยกส่วนประกอบนี้ว่า Cholesky  
 decomposition

อาจเขียน  $L^{-1}$  =  $\begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$   
 ดังนั้น  $L^{-1} \epsilon_t$

อาจเรียกว่า Reduced form VAR(1)  
 $L^{-1} y_t = L^{-1} c + L^{-1} \Phi_1 y_{t-1} + L^{-1} \epsilon_t$   
 A structural form VAR

# VAR

เราสามารถเขียนความสัมพันธ์ระหว่างอนุกรมเวลาในช่วงเดียวกันได้อย่างชัดเจนโดยใช้การแปลงรูปสมการที่ (6.2) ได้ดังนี้

เนื่องจาก  $\Sigma$  เป็นเมตริกซ์ positive definite ดังนั้นเราสามารถสร้างเมตริกซ์ lower triangular

$$\mathbf{L} = \begin{pmatrix} 1 & 0 & \dots & 0 \\ l_{21} & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & \dots & 1 \end{pmatrix}$$

และเมตริกซ์แทนนม  $G$  ที่ทำให้  $\Sigma = \mathbf{L}\mathbf{G}\mathbf{L}'$  น้าเรียกวิธีการแยกส่วนประกอบนี้ว่า Cholesky decomposition *shock vs structure in Reduced VAR*

กำหนดให้  $\eta_t = \mathbf{L}^{-1} \varepsilon_t$  จะได้ว่า

$$E(\eta_t) = E(\mathbf{L}^{-1} \varepsilon_t) = \mathbf{L}^{-1} E(\varepsilon_t) = \mathbf{L}^{-1} \underline{0} = \underline{0} \quad \eta_t + \text{部分扰动} = 0$$

$$Var(\eta_t) = Var(\mathbf{L}^{-1} \varepsilon_t) = \mathbf{L}^{-1} Var(\varepsilon_t) (\mathbf{L}^{-1})' = \frac{\mathbf{L}^{-1} (LGL') (L')} {\mathbf{I}} = G$$

$G$  คือ diagonal matrix  $\rightarrow \eta_t + \text{部分扰动} \sim N(0, G)$

## VAR

$\eta_t$  แทนสิ่งที่ไม่สามารถพยากรณ์ได้ (error)  
 $\text{Cov}(\eta_{1t}, \eta_{2t}) = 0$

หากเราคุณข้างหน้าสมการ (6.1) ด้วย  $L^{-1}$  จะได้  $\eta_t$

$$L^{-1} Y_t = L^{-1} C + L^{-1} \Phi_1 Y_{t-1} + L^{-1} \varepsilon_t$$

$$\begin{pmatrix} 1 & 0 \\ \ell^{21} & 1 \end{pmatrix} \begin{pmatrix} Y_{1t} \\ Y_{2t} \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ \ell^{21} & 1 \end{pmatrix} \begin{pmatrix} C_1 \\ C_2 \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ \ell^{21} & 1 \end{pmatrix} \begin{pmatrix} \Phi_{11} & \Phi_{12} \\ \Phi_{21} & \Phi_{22} \end{pmatrix} \begin{pmatrix} Y_{1t-1} \\ Y_{2t-1} \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ \ell^{21} & 1 \end{pmatrix} \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

$$\begin{pmatrix} Y_{1t} \\ \ell^{21} Y_{1t} + Y_{2t} \end{pmatrix} = \begin{pmatrix} C_1 \\ \ell^{21} C_1 + C_2 \end{pmatrix} + \underbrace{\begin{pmatrix} \Phi_{11} & \Phi_{12} \\ \ell^{21} \Phi_{11} + \Phi_{21} & \ell^{21} \Phi_{12} + \Phi_{22} \end{pmatrix}}_{\Phi_1^*} \begin{pmatrix} Y_{1t-1} \\ Y_{2t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \ell^{21} \varepsilon_{1t} + \varepsilon_{2t} \end{pmatrix} \quad \downarrow \begin{matrix} \text{dynamic} \\ \eta_t = \begin{pmatrix} Y_{1t} \\ Y_{2t} \end{pmatrix} \end{matrix}$$

นรรพก 2

$$Y_{2t} = -\ell^{21} Y_{1t} + \text{constant} + \text{dynamic shock.}$$

↓  
 contemporaneous relationship  
 (Period instant)

# VAR

หากเราคูณข้างหน้าสมการ (6.1) ด้วย  $L^{-1}$  จะได้  
 $L^{-1} Y_t =$

$L^{-1}$  จะแสดงความสัมพันธ์ระหว่างอนุกรรมเวลาในความเดียวกัน  
 เราเรียกแบบจำลองเวกเตอร์อัตโนมัติ regressor ในรูปนี้ว่า สมการในรูปโครงสร้าง  
**(structural equation)**

## ตัวอย่างที่ 6.3

## of the Lecture

กำหนด Bivariate VAR(1) สามารถแสดงในรูปครุภัณฑ์ดังนี้

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 0.2 \\ 0.4 \end{pmatrix} + \begin{pmatrix} 0.2 & 0.3 \\ -0.6 & 1.1 \end{pmatrix} \begin{pmatrix} y_{1,t-1} \\ y_{2,t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

$$\text{โดยที่ } \Sigma = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix} \Rightarrow \underbrace{LGL^{-1}}_{\substack{\rightarrow L = ? \\ \downarrow L^{-1} = ?}} \quad \underline{\underline{}}$$

# VAR

- เราจะเห็นได้ว่าเราสามารถแปลงแบบจำลองเวลาเตอร์อโติวีเรกซีฟในรูปดังไปเป็นรูปโครงสร้าง ได้ด้วย Cholesky decomposition
- อย่างไรก็ตามในการวิเคราะห์อนุกรมเวลาเรามักจะใช้สมการในรูป Reduced form เนื่องจากเป็นรูปที่ง่ายในการประมาณค่า
  - รามักจะเน้นผลในการพยากรณ์ของแบบจำลองซึ่งเราไม่สามารถใช้แบบจำลองในรูปโครงสร้างพยากรณ์ข้อมูล ได้เนื่องจากเราไม่ทราบข้อมูลของอนุกรมเวลาอื่นๆในความเดียวกัน

# เงื่อนไขการเป็นอนุกรมเวลาที่นิ่ง ✓

แบบจำลอง  $VAR(p)$  สามารถเขียนในรูปเครื่องหมายขึ้นไปข้างหลัง (lag operator) ได้ดังนี้

$$\Phi(L)Y_t = c + \varepsilon_t$$

โดยที่  $\Phi(L) = I_n - \Phi_1L - \dots - \Phi_pL^p$  แบบจำลอง  $VAR(p)$  จะมีเสถียรภาพถ้าหากของ

$$\det(I_n - \Phi_1z - \dots - \Phi_pz^p) = 0$$

มีค่ามากกว่าหนึ่ง (หรือไม่คูณมากกว่าหนึ่งในกรณีจำนวนเชิงซ้อน) ถ้าสมมุติให้กระบวนการคั่งกล่าวมีค่าในอดีตที่เป็นอนันต์ แล้วกระบวนการ  $VAR(p)$  ที่มีเสถียรภาพจะเป็นกระบวนการนิ่งและ ergodic โดยมีค่าเฉลี่ย ค่าความแปรปรวนและค่าความแปรปรวนร่วมในตัวเองที่ไม่ขึ้นกับเวลา

การประมาณค่า VAR - Reduced form  $\rightarrow$  ทาง form Reduced form  
 \* ปัจจุบัน ลดตัวแปร OLS  $\Rightarrow$  ดูต่อไป  $\rightarrow$  ทาง Preidic structural form VAR

การเราระพิจารณาสมการ (6.2) แต่ละสมการจะมีตัวแปรที่เหมือนกัน เราสามารถพิจารณา  
สมการสำหรับแต่ละตัวแปรออกเป็น

$$\text{OLS} \quad y_t = \sum_{i=1}^k \phi_{it} + e_t$$

$$y_1 = \phi_{11} y_{1t} + \phi_{12} y_{2t} + \dots + e_1$$

$$y_2 = \phi_{21} y_{1t} + \phi_{22} y_{2t} + \dots + e_2$$

$$\vdots$$

$$y_i = Z\phi_i + e_i, \quad i = 1, \dots, n$$

แต่ละสมการสามารถประมาณค่าได้ด้วย ordinary least squares (OLS) แยกแต่ละ  
สมการ และจะได้  $\hat{\Phi} = [\hat{\phi}_1, \dots, \hat{\phi}_n]$  เป็นเมตริกซ์ ( $k \times n$ ) ของค่าสัมประสิทธิ์จากการ  
ประมาณค่าด้วย OLS

ภายใต้ข้อสมมุติที่แบบจำลองเป็นแบบกระบวนการนิ่งและ ergodic เราจะได้  $\text{vec}(\hat{\Phi})$  มี  
คุณสมบัติ consistent และมีการแจกแจงแบบปกติเมื่อกลุ่มตัวอย่างใหญ่โดยมีเมตริกซ์ค่า  
ความแปรปรวนเท่ากัน

$$\widehat{\text{aver}}(\text{vec}(\hat{\Phi})) = \hat{\Sigma} \otimes (Z' Z)^{-1}$$

โดยที่  $\hat{\Sigma} = \frac{1}{T-k} \sum_{t=1}^T \hat{e}_t \hat{e}_t'$  และ  $\hat{e}_t = Y_t - \hat{\Phi}' Z_t$  เป็น residuals จากการประมาณค่า

## การเลือกจำนวนความล่าที่เหมาะสม

(P?)

$AIC/BIC$

การหาความล่าที่เหมาะสมของแบบจำลองเวคเตอร์อัตโนมัติอาจทำได้โดยการใช้สูตรการเลือกความล่า โดยการประมาณค่าแบบจำลองเวคเตอร์อัตโนมัติที่มีความล่าเท่ากับ  $0, 1, \dots, p_{max}$  แล้วเลือกค่า  $p$  ที่ทำให้ค่าที่ใช้เลือกมีค่าต่ำที่สุด โดยจะมีสูตรดังนี้

$$IC(p) = \ln |\tilde{\Sigma}(p)| + c_T(n, p)$$

โดยที่  $\tilde{\Sigma}(p) = T^{-1} \sum_{t=1}^T \hat{\epsilon}_t \hat{\epsilon}_t'$  คือ residual covariance matrix จาก  $VAR(p)$ ,  $c_T$  คือคำนับที่ขึ้นกับจำนวนตัวอย่าง

✓  $BIC - consistent$

( $P_{\text{จริง}} \rightarrow P_{\text{ที่เลือก}}$ )  
เมื่อ  $T$  มาก  
→ เลือก  $P$  ที่ดีที่สุด AIC

$$AIC(p) = \ln |\tilde{\Sigma}(p)| + \frac{2}{T} (pn^2)$$

$$BIC(p) = \ln |\tilde{\Sigma}(p)| + \frac{\ln T}{T} (pn^2)$$

$$HQIC(p) = \ln |\tilde{\Sigma}(p)| + \frac{2 \ln(\ln T)}{T} (pn^2)$$

ตัวอย่าง 6.5

## ก า gross Correlation เทพหะน์ตามนี้ครับ $\Rightarrow \text{VAR}$

พิจารณาความสัมพันธ์ระหว่างผลได้ตอบแทนรายสัปดาห์จากการลงทุนในตลาดหลักทรัพย์แห่งประเทศไทย (lret\_thmy\$TH) และตลาดหุ้นมาเลเซีย (lret\_thmy\$MY) โดยใช้ข้อมูลรายสัปดาห์ระหว่างวันที่ 2 มกราคม 2541 ถึง 31 ธันวาคม 2562 ข้อมูลอยู่ในไฟล์ lret\_3countries\_w9819.txt)

data frame

```

1 > lret3 <- read.csv("~/lret_3countries_w9819.txt")
2 > lret_thmy<-cbind(lret3$SET, lret3$KSE)
3 > colnames(lret_thmy)<-c("TH", "MY")
4 > rownames(lret_thmy)<-lret3$Index
      ) - หมาย col/row

```

เราสามารถพิจารณาค่าสถิติเบื้องต้นได้จากคำสั่ง basicStats และ acf เมื่อนอกบันทึก เราเคยใช้ในหัวข้อก่อนได้

lret\_thmy

ตัวอย่าง 6.5

$$\begin{bmatrix} Y_{1t} \\ Y_{2t} \end{bmatrix} \Rightarrow \begin{bmatrix} Y_{TH,t} \\ Y_{MY,t} \end{bmatrix} = VAR(p) \sim R ?$$

หากเราต้องการประมาณค่า  $VAR(p)$  เราจะใช้ library(vars) โดยที่เราอาจจะเริ่มจากการหาค่า  $p$  ที่เหมาะสมโดยการใช้คำสั่ง VAR พร้อมระบุเมตริกซ์ของข้อมูล lret จำนวนค่าล่าสุด lag.max และ เกณฑ์ในการเลือกค่าล่า ic=c("AIC") โดยที่ "SC" จะแทน Schwarz-Bayesian (BIC) และ "HQ" Hannan-Quinn (HQIC)

```

1 <redacted>
2 > library(vars)
3 > msel_aic <- VAR(lret_thmy, lag.max=5, ic=c("AIC"))
4 > msel_aic
5
6 VAR Estimation Results:
7 =====
8 Estimated coefficients for equation TH: <--> ผู้มร 1
9 =====
10 Call: <--> ผู้มร 2
11 TH = TH.11 + MY.11 + TH.12 + MY.12 + TH.13 + MY.13 + TH.14 + MY.14 + const
12
13 <--> ผู้มร 3
14 <--> ผู้มร 4
15 TH.11 MY.11 TH.12 MY.12 TH.13 MY.13 TH.14 MY.14 const
0.01524 0.00904 0.13483 0.12268 0.04040 0.04239 -0.13186 0.05922 0.08477

```

วงจรอุบัติลง VAR  
ก็ AIC => P=4

$Y_{1t-1}$   $Y_{2,t-1}$  |  $(MY)$  ผู้มร.  $t-4$

$msel_bic <- VAR(\dots, "SC") \rightarrow P=2$

BIC  $VAR(2)$



## ตัวอย่าง 6.5

หมายเหตุ

VAR(2)

```

1 > model1<-VAR(lret_thmy, p=2)
2 > summary(model1)
3
4 VAR Estimation Results:
5 =====
6 Endogenous variables: TH, MY
7 Deterministic variables: const
8 Sample size: 1147
9 Log Likelihood: -5497.069
10 Roots of the characteristic polynomial:
11 0.47 0.408 0.148 0.0737
12 Call:
13 VAR(y = lret_thmy, p = 2)
14
15 Estimation results for equation TH:
16 =====
17
18 TH = TH.11 + MY.11 + TH.12 + MY.12 + const
19
20 Estimate Std. Error t value Pr(>|t|)
21 TH.11 0.0248 0.0319 0.78 0.438
22 MY.11 0.0051 0.0413 0.12 0.902
23 TH.12 0.1278 0.0321 3.96 7.9e-05 ***
24 MY.12 0.0950 0.0410 2.32 0.021*
25 const 0.1027 0.0941 1.09 0.275
26
27 Signif. codes: 0 *** 0.001 ** 0.01 * 0.05 . 0.1 .
28
29 Residual standard error: 3.18 on 1142 degrees of freedom
30 Multiple R-Squared: 0.0307, Adjusted R-squared: 0.0273
31 F-statistic: 9.03 on 4 and 1142 DF, p-value: 3.51e-07

```

$$\hat{Y}_{TH,t} = 0.0248 \hat{Y}_{TH,t-1} + 0.0051 \hat{Y}_{MY,t-1} + \dots$$

## ตัวอย่าง 6.5

$$\hat{Y}_{MY,t} = 0.11 \hat{Y}_{TH,t-1} - 0.0364 \hat{Y}_{MY,t-1} + \dots - (2)$$

```

Estimation results for equation MY:
=====
3   MY = TH.11 + MY.11 + TH.12 + MY.12 + const
4
5   Estimate Std. Error t value Pr(>|t|)  ผู้ตรวจสอบ parameter
6   TH.11    0.1102    0.0243   4.54  6.3e-06 ***
7   MY.11   -0.0361    0.0315  -1.15  0.25179
8   TH.12    0.0833    0.0245   3.41  0.00068 ***
9   MY.12    0.0786    0.0312   2.52  0.01196 *
10  const     0.0737    0.0716   1.03  0.30389
11  ---
12 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
13
14 Residual standard error: 2.42 on 1142 degrees of freedom
15 Multiple R-Squared:  0.0436, Adjusted R-squared:  0.0403
16 F-statistic: 13 on 4 and 1142 DF, p-value: 2.27e-10
17
18 Covariance matrix of residuals:
19   TH      MY
20 TH 10.1  3.00  Cov(E_{1t}, E_{2t})
21 MY  3.0  5.86  Cov(E_{2t}, E_{2t})
22
23 Correlation matrix of residuals:
24   TH      MY
25 TH  1.000 0.389
26 MY  0.389 1.000

```

$$\Sigma = \begin{bmatrix} \text{Var}(E_{1t}) & \text{Cov}(E_{1t}, E_{2t}) \\ \text{Cov}(E_{1t}, E_{2t}) & \text{Var}(E_{2t}) \end{bmatrix}$$

อัตราส่วนของ cov สองตัวคงที่ 0.389 ไม่เท่ากับ 1  
(ไม่ใช่สหสัมพันธ์)

ตัวบ่งชี้แสดงว่า  $\hat{Y}_t$  กับ  $\hat{Y}_{t+1}$  มีความสหสัมพันธ์

ตัวบ่งชี้แสดงว่า

ดังนั้น  $\text{Corr}(E_{1t}, E_{2t}) = 0.4$

$$\left( \begin{array}{c} Y_{1t} \\ Y_{2t} \end{array} \right) = Y_t = c + \Phi_1 Y_{t-1} + \Phi_2 Y_{t-2} + \varepsilon_t$$

$\Rightarrow$  1) หาค่าราก  
2) หาค่าส่วนของสหสัมพันธ์

ดังนั้น  $\text{Corr}(E_{1t}, E_{2t}) = 0.4$



การพยากรณ์จากแบบจำลอง VAR<sup>(1)</sup>  $\begin{pmatrix} Y_{1t} \\ Y_{2t} \end{pmatrix} = Y_t = \Phi Y_{t-1} + \varepsilon_t$   
กรณี AR(p)  $\Rightarrow h \sim h+1$   
1)  $Y_{h+1} = \Phi Y_{(h+1)-1} + \varepsilon_{h+1}$

หากเราพิจารณาแบบจำลอง VAR( $p$ ) โดยที่เราทราบค่าพารามิเตอร์  $\Phi$  ค่าพยากรณ์ไปข้างหน้าหนึ่ง步  $Y_{h+1}$  ด้วยข้อมูลที่มี ณ ครบที่  $h$  ได้ด้วยการเขียนสมการแสดงค่า  $Y_{h+1}$  แล้วหา conditional expectation ด้วยข้อมูล ณ  $h$  เราจะได้ค่าพยากรณ์เท่ากับ

$$\hat{Y}_h(1) = E(Y_{h+1} | F_h) = E(\Phi Y_h + \varepsilon_{h+1} | F_h) = \Phi Y_h + E(\varepsilon_{h+1} | F_h) = \Phi Y_h - \underbrace{E(\varepsilon_{h+1})}_{\text{forecast error}} = \Phi Y_h - (\phi_{11} \phi_{12} / \phi_{21} \phi_{22}) \varepsilon_{2h}$$

โดยที่ค่าความผิดพลาดจากการพยากรณ์ (forecast error) เท่ากับ  $E(\varepsilon_{h+1}) = 0$   
 $e(1) = Y_{h+1} - \hat{Y}_h(1) = [\Phi Y_h + \varepsilon_{h+1}] - \Phi Y_h = (\varepsilon_{1,h+1} / \varepsilon_{2,h+1}) \rightarrow \text{forecast error vs } Y_1$   
 $\text{ค่าพยากรณ์ไปข้างหน้าสอง步 } Y_{h+2} \text{ ด้วยข้อมูลที่มี ณ ครบที่ } h \text{ จะเท่ากับ}$

$$\hat{Y}_h(2) = E(Y_{h+2} | F_h) = E(\Phi Y_{h+1} + \varepsilon_{h+2} | F_h) = \Phi E(Y_{h+1} | F_h) + E(\varepsilon_{h+2} | F_h) = \Phi Y_h + E(\varepsilon_{h+2}) = \Phi Y_h$$

โดยที่ค่าความผิดพลาดจากการพยากรณ์ (forecast error) เท่ากับ  $E(\varepsilon_{h+2}) = 0$   
 $e(2) = Y_{h+2} - \hat{Y}_h(2) = [\Phi Y_{h+1} + \varepsilon_{h+2}] - \Phi Y_h = [\Phi Y_h + \varepsilon_{h+1} + \varepsilon_{h+2}] - \Phi Y_h = \varepsilon_{h+1} + \varepsilon_{h+2}$

$$\hat{Y}_h(1) = \begin{pmatrix} \hat{Y}_{1,h}(1) \\ \hat{Y}_{2,h}(1) \end{pmatrix} = \begin{pmatrix} \phi_{11} & \phi_{12} \\ \phi_{21} & \phi_{22} \end{pmatrix} \begin{pmatrix} Y_{1,h} \\ Y_{2,h} \end{pmatrix} = \begin{pmatrix} \phi_{11} Y_{1,h} + \phi_{12} Y_{2,h} \\ \phi_{21} Y_{1,h} + \phi_{22} Y_{2,h} \end{pmatrix} \rightarrow \hat{Y}_{1,h}(1) = \phi_{11} Y_{1,h} + \phi_{12} Y_{2,h}$$

$$(1) \quad \text{Var}(e(1)) = E(e(1) e(1)') = E(\varepsilon_{h+1} \varepsilon_{h+1}') = \text{Var}(\varepsilon_{h+1}) = \Sigma$$

$$E[e(1)^2] = \text{forecast error } Y_1 = \sigma_1^2$$

$$\text{Var vs f.e. } Y_2 = \sigma_2^2$$

# การพยากรณ์จากแบบจำลอง VAR

$$\textcircled{2} \quad e_1(1) = \underline{\varepsilon_{1,h+1}} \rightarrow \text{Var}(e_1(1)) = \text{Var}(\varepsilon_{1,h+1}) = \sigma_1^2$$

$$e_2(1) = \underline{\varepsilon_{2,h+1}} \rightarrow \text{Var}(e_2(1)) = \text{Var}(\varepsilon_{2,h+1}) = \sigma_2^2$$

หากแทนค่าด้วยวิธีการ recursive จะได้ค่าพยากรณ์ไปข้างหน้า  $l$  คาบ  $Y_{h+l}$  ด้วยข้อมูลที่มีในคาบที่  $h$  เท่ากับ  $\hat{Y}_{h+l} = \dots$

VAR(p)

$$\hat{Y}_h(l) = c + \Phi_1 \hat{Y}_h(l-1) + \dots + \Phi_p \hat{Y}_h(l-p)$$

กระบวนการ  
 ตัวแปรคงที่  
 VAR  
 ทางลัด

ค่าคาดเคลื่อนของการพยากรณ์ (forecast errors) จะเป็นไปในรูป

$$\hat{Y}_h(l) - Y_{h+l} = \sum_{s=0}^{l-1} \Psi_s \varepsilon_{h+l-s}$$

โดยที่เมตริกซ์  $\Psi_s$  สามารถคำนวณได้โดย  $\Psi_s = \sum_{j=1}^{p-1} \Psi_{s-j} \Phi_j$

ในขณะที่ MSE ของ  $\hat{Y}_h(l)$  จะเท่ากับ

$$\Sigma(l) = \text{MSE}(Y_{h+l} - \hat{Y}_h(l)) = \sum_{s=0}^{l-1} \Psi_s \Sigma \Psi_s'$$

forecast error var  $\hat{Y}_1$   
 ต้องใช้  $2$  คาบ  
 $e_1(2) = \underline{\varepsilon_{1,h+1}} + \varepsilon_{h+2} = (\phi_{11} \phi_{12}) (\underline{\varepsilon_{1,h+1}}) + (\varepsilon_{1,h+2})$   
 $e_2(2) = (\phi_{21} \phi_{22}) (\underline{\varepsilon_{2,h+1}}) + (\varepsilon_{2,h+2})$

$$e_1(2) = \frac{(\phi_{11} \varepsilon_{1,h+1} + \phi_{12} \varepsilon_{2,h+1}) + (\varepsilon_{1,h+2})}{\phi_{11} \varepsilon_{1,h+1} + \phi_{21} \varepsilon_{2,h+1}} \rightarrow \text{Var}(e_1(2))$$

fe var  $\hat{Y}_1$   
 ต้องใช้  $2$  คาบ รวม  $\varepsilon_{2,h+1}$

## ตัวอย่าง 6.6

$$\begin{bmatrix} Y_{TH} \\ Y_{MY} \end{bmatrix}$$

ต่อเนื่องจากตัวอย่าง 6.5 เราสามารถทำนายผลได้ตوبแทนไปข้างหน้าของทั้งสองตลาดที่เราสนใจได้ด้วยคำสั่ง predict โดยระบุแบบจำลองที่ใช้และค่าที่ทำนายไปข้างหน้า

VAR(2)

 $l=5$ 

```

1 > model1.predict
2 > model1.predict
3 $TH
4 fcst lower upper CI
5 [1,] 0.14364 -6.09 6.38 6.23
6 [2,] -0.00965 -6.24 6.23 6.24
7 [3,] 0.13630 -6.19 6.46 6.32
8 [4,] 0.10392 -6.22 6.43 6.33
9 [5,] 0.13238 -6.20 6.46 6.33
10
11 $MY
12 fcst lower upper CI
13 [1,] 0.1644 -4.58 4.91 4.75
14 [2,] -0.0153 -4.80 4.77 4.79
15 [3,] 0.0980 -4.75 4.94 4.85
16 [4,] 0.0832 -4.77 4.93 4.85
17 [5,] 0.1012 -4.75 4.95 4.85

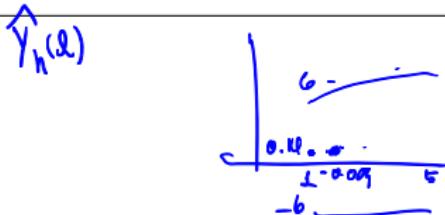
```

$$\hat{Y}_h(l) \pm t_{\alpha=0.05} \times \sqrt{\text{var}(f_{\text{forecast error}})}$$

1.96

$$\text{lower } \hat{Y}_h(l) - t_{\alpha=0.05} \times \sqrt{\text{var}(f_e)}$$

C.I.



① Granger Causality

② Impulse Response Function

อนุมานความสัมพันธ์ทาง VAR  $Y_{t+1}, Y_{t+2}$   
ใน VAR ไม่ใช่ลักษณะของการอธิบายความน่าจะเป็น  
ก็ตามทฤษฎี MR ที่ต้องการให้ทางนี้เป็น  
โครงสร้างของตัวแปร

Variation de compo-

sition

# ① เน้นด้วย Cause Granger Causality

เดรซช์มัต → ทฤษฎี  $X \rightarrow Y$   
 ทิ้งไปใน VAR อาจ: ไม่สอดคล้อง (Theoretical)

โครงสร้างของแบบจำลอง VAR ช่วยให้ข้อมูลกับเราว่าตัวแปรหรือกลุ่มของตัวแปรมี  
 ความสามารถในการทำนายตัวแปรอื่นหรือไม่

Granger (1969) เสนอว่า VARU  $y_{2,t} = \phi_{21}y_{1,t-1} + \phi_{22}y_{2,t-1} + \varepsilon_t$

ถ้าตัวแปร  $y_1$  ช่วยในการทำนายตัวแปรอื่น  $y_2$  เราจะเรียกว่า  $y_1$  แกรงเจอร์คอส  
(Granger-cause)  $y_2$

ถ้า  $y_1$  ไม่ช่วยในการทำนายตัวแปร  $y_2$  เราจะพูดว่า  $y_1$  ไม่แกรงเจอร์คอส (does not  
Granger-cause)  $y_2$

เราจะต้องระลึกไว้อยู่เสมอว่า แกรงเจอร์คอส เป็นการอนุมานไปยังความสามารถในการ  
 พยากรณ์เท่านั้น ไม่ได้เป็นความเป็นเหตุเป็นผลจริงๆ ของตัวแปร

$$H_0 : \phi_{21} = 0 \quad \text{vs} \quad H_1 : \phi_{21} \neq 0$$

$$(Y_{1,t} \text{ ต. c. } Y_{2,t}) \quad (Y_{1,t} \text{ G.C. } Y_{2,t})$$

$$\text{ทดสอบ } t - \text{stat} = \frac{\hat{\phi}_{21}}{\text{se}(\hat{\phi}_{21})} > \text{c.v. } \text{ ปฏิเสธ } H_0$$

# Granger Causality

ในหัวข้อนี้เราพิจารณาแบบจำลอง  $VAR(2)$  ที่มีตัวแปรสองตัว ซึ่งสามารถเขียนเป็น  
สมการได้ดังนี้  $y_{2t} \text{ G.C. } y_{1t} ?$  ตาม GL. หมายความว่า  $y_{2t-1, t-2} \text{ กับ } y_{1t} = 0$

$VAR(2)$

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} + \begin{pmatrix} \phi_{11}^1 & \boxed{\phi_{12}^1} \\ \boxed{\phi_{21}^1} & \phi_{22}^1 \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \phi_{11}^2 & \boxed{\phi_{12}^2} \\ \boxed{\phi_{21}^2} & \phi_{22}^2 \end{pmatrix} \begin{pmatrix} y_{1t-2} \\ y_{2t-2} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad (6.22)$$

$$H_0: \phi_{12}^1 = \phi_{12}^2 = 0$$

- หาก  $y_{2t}$  ไม่แกร่งเจ้อร์คอส  $y_{1t}$  ค่าสัมประสิทธิ์  $\phi_{12}^1$  และ  $\phi_{12}^2$  จะมีค่าเท่ากับศูนย์
  - ถ้า  $y_{1t}$  ไม่แกร่งเจ้อร์คอส  $y_{2t}$  ค่าสัมประสิทธิ์  $\phi_{21}^1$  และ  $\phi_{21}^2$  จะมีค่าเท่ากับศูนย์
- ดังนั้นในการทดสอบว่า  $y_{2t}$  แกร่งเจ้อร์คอส  $y_{1t}$  หรือไม่ เราจะต้องสมมุติฐานหลักว่า  
 $H_0: \phi_{12}^1 = \phi_{12}^2 = 0$  และสมมุติฐานทางเลือกคือมีสัมประสิทธิ์  $\phi_{12}^1$  หรือ  $\phi_{12}^2$  ตัวใดตัวหนึ่งมีค่าไม่เท่ากับศูนย์ ซึ่งการทดสอบดังกล่าวคือการทดสอบ F นั่นเอง (Wald)

~~~~~



## ตัวอย่าง 6.7

ต่อเนื่องจากตัวอย่าง 6.5 เราต้องการทดสอบว่า lret\_thmy\$TH แกรงเจอร์คือ lret\_thmy\$MY หรือไม่

เราสามารถทดสอบโดยใช้คำสั่ง causality โดยที่เราจะต้องระบุแบบจำลองที่ใช้ และตัวแปรที่เป็นสาเหตุ (cause) ซึ่งในที่นี้คือ lret\_thmy\$TH

|ret\_TH G.C. |ret\_MY ?

```

1 > causality(model1, cause="TH")
2 $Granger TH บังคับ VAR (2)
3 ~~IGranger causality H0: TH do not Granger-cause MY
4
5 data: VAR object model1
6 F-Test = 16, df1 = 2, df2 = 2284, p-value = 2e-07 =  $2 \times 10^{-7} < \alpha(0.05)$ 
7 $Instant
8 ~~IHO: No instantaneous causality between: TH and MY
9
10 data: VAR object model1
11 Chi-squared = 151, df = 1, p-value <2e-16
12
13
14

```

ปัจจุบัน H<sub>0</sub> ว่า TH ไม่ G.C. MY  
ซึ่งว่า TH G.C. MY  
[ ผลติดลบ t-stat ]

Contemporaneous

lret\_TH อยู่ในร่วมกับ lret\_MY

→ lret\_TH G.C. lret\_MY ⇒ ผลมาด้วยความเชื่อมโยง  
ต่อไป ?

②

Impulse Response Function  $\rightarrow$  ฟังก์ชัน และ ขนาดของความสัมพันธ์ ของต้น เอ็งกูร์ฟ์ฟ์ฟ์ กับ มนตรีเดริน กับ ภาระผู้คนในปี (Impulse) แห่งๆ ของตัวเป้าหมาย (Response)

หรือการทดสอบแกรงเจอร์คือสิ่งที่ระบุว่าตัวแปรใดๆ มีผลกระทบอย่างมีนัยสำคัญต่อตัวแปรอื่นหรือไม่ อย่างไรก็ตาม การทดสอบดังกล่าวไม่ได้เน้นทิศทางของความสัมพันธ์ และระยะเวลาที่การเปลี่ยนแปลงของตัวแปรหนึ่งจะส่งผลต่ออีกด้วยตัวแปรว่าจะมีผลยาวนานแค่ไหน

$$\gamma_1 \text{ พลุ } = \dots + \boxed{\varepsilon_{1t}} \pm \boxed{\varepsilon_{2t}}$$

impulse response function ซึ่งหมายถึง การตอบสนองของตัวแปรตาม(response)อันเนื่องมาจากการเปลี่ยนแปลงของตัวแปรอีกด้วยหนึ่ง (impulse) โดยที่หากเกิดการเปลี่ยนแปลงในช่วงหนึ่งหน่วยจะส่งผลอย่างไรต่อแต่ละตัวแปรในระบบที่ต่อจากการเปลี่ยนแปลงนั้นๆ (เราว่าจะใช้การเปลี่ยนแปลงหนึ่ง s.d.)  $\rightarrow$  ให้ยกตัวอย่าง  $y_{1t}, \dots, y_{nt}$

ตัวอย่างเช่น หากเราพิจารณาแบบจำลอง VAR(1) ที่มีตัวแปรสองตัวแปร ซึ่งสามารถแสดงได้ด้วยสมการ  $y_t = \Phi y_{t-1} + \varepsilon_t$

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} \begin{pmatrix} y_{1,t-1} \\ y_{2,t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad (6.23)$$

กับผลตัว  
หลักปรับปรุง

หน้างานของระบบ ปั๊ม 1 จุดเดียว

Impulse ( $y_{1t}$ )ปั๊มผลิต  $y_{2t}$  (Response)

## Impulse Response Function

การประมวลผล 1 จุดเดียว

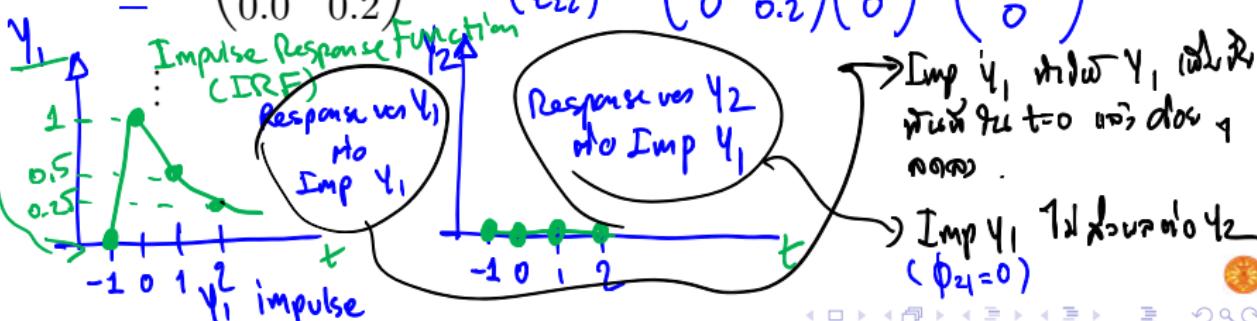
สมมุติว่าเราพิจารณาว่า ในปีที่ 0 เกิดช็อกในตัวแปร  $y_{1t}$  หนึ่งหน่วย ( $\varepsilon_{10} = 1$ ) และช็อกในตัวแปร  $y_{2t}$  เท่ากับศูนย์ และช็อกในปีอื่นๆ เท่ากับศูนย์ สมมุติให้  $y_{1t}$  และ  $y_{2t}$  เท่ากับศูนย์ในปีก่อนหน้าปี 0 จะได้ว่า

( $t=-1$ )  $y_{1,-1} = 0, y_{2,-1} = 0$  [กรณีที่  $y_1 + y_2 = 0$  ก็จะได้  $\varepsilon_{10} = \varepsilon_{20}$ ]

$$y_{-1} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad Y_0 = \begin{pmatrix} \varepsilon_{10} \\ \varepsilon_{20} \end{pmatrix} = \begin{pmatrix} 0.5 & 0.3 \\ 0 & 0.2 \end{pmatrix} \begin{pmatrix} 0 \\ 0 \end{pmatrix} + \begin{pmatrix} \varepsilon_{10} \\ \varepsilon_{20} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} + \begin{pmatrix} \varepsilon_{10} \\ \varepsilon_{20} \end{pmatrix} = \begin{pmatrix} \varepsilon_{10} \\ \varepsilon_{20} \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

$$Y_1 = \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} Y_0 + \begin{pmatrix} \varepsilon_{11} \\ \varepsilon_{21} \end{pmatrix} = \begin{pmatrix} 0.5 & 0.3 \\ 0 & 0.2 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.5 \\ 0 \end{pmatrix}$$

$$Y_2 = \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} Y_1 + \begin{pmatrix} \varepsilon_{12} \\ \varepsilon_{22} \end{pmatrix} = \begin{pmatrix} 0.5 & 0.3 \\ 0 & 0.2 \end{pmatrix} \begin{pmatrix} 0.5 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.25 \\ 0 \end{pmatrix}$$



# Impulse Response Function

ในกรณี  $VAR(p)$  ที่เป็นกระบวนการนึงๆ ได้  
 คุณสมบัติที่ดีที่สุด Reduced form VAR

$$\text{IRF} \text{ คือ } \text{IMP} = \sum_{t=1}^{\infty} Y_t = \mu + \varepsilon_t + \Psi_1 \varepsilon_{t-1} + \Psi_2 \varepsilon_{t-2} + \dots \quad \text{IMP} = \begin{pmatrix} 0.5 & 0.3 \\ 0 & 0.2 \end{pmatrix} \begin{pmatrix} 0.3 \\ 0.2 \end{pmatrix} = \begin{pmatrix} 0.3 \\ 0.2 \end{pmatrix}$$

$\varepsilon_t \rightarrow \text{Var}(\varepsilon_t) = \sum_{t=1}^{\infty} \text{Cov}(\varepsilon_{1t}, \varepsilon_{2t}) \text{ กรณี } \neq 0$

ตัวอย่างกรณี  $\text{IRF} \neq \text{IMP}$   
 shock เกิดขึ้นที่  $y_1$  ปรับตัวไม่ตามที่คาดไว้,  
 $\frac{\partial y_{1,t+s}}{\partial \varepsilon_{j,t}} = \frac{\partial y_{1,t}}{\partial \varepsilon_{j,t-s}} = \psi_{i,j}^s$   
 $\text{IMP} = \text{Cov}(\varepsilon_{1t}, \varepsilon_{2t}) = 0$

อย่างไรก็ตามคำอธิบายข้างต้นจะเป็นจริงหาก  $\text{var}(\varepsilon) = \sum$  เป็นเมตริกซ์แท้ไขมุน

ดังนั้นเรามักจะพิจารณา VAR ในรูป structural ซึ่ง  
 สำหรับ IRF มาก  $\text{IMP} = \text{Cov}(\eta_{1t}, \eta_{2t}) = 0$

$$B Y_t = c + \Gamma_1 Y_{t-1} + \dots + \Gamma_p Y_{t-p} + \eta_t \quad (6.25)$$

$\text{Cov}(\eta_{1t}, \eta_{2t}) = 0 \rightarrow \text{shock ไม่ส่ง影 ไม่กัน} = BE +$   
 โดยที่ Orthogonal error ( $\eta_t$ )  $\text{และ } \eta_{1t} \text{ ตามบทที่ } 1 \text{ จะมี } \eta_{1t} = 0 \text{ และ } \eta_{2t} = 0$

โครงสร้างแบบจำลองโครงสร้าง (structural model) จะกำหนดให้ความสัมพันธ์ของ  
 ตัวแปรมีลำดับคือ  $y_1$  เป็นตัวกำหนด  $y_2$  และ  $y_2$  เป็นตัวกำหนด  $y_3$  เป็นลำดับไปเรื่อยๆ ซึ่งใช้  
 ทฤษฎีเป็นตัวกำหนด

IMP

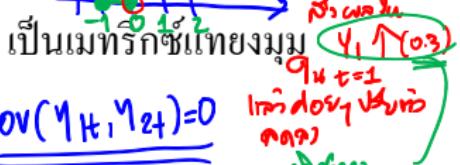
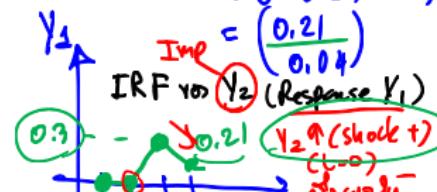
$\text{Imp } \eta_2 (\eta_{20} = 1)$

$$\eta_0 = \begin{pmatrix} 0.5 & 0.3 \\ 0 & 0.2 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} + \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

$$\eta_1 = \begin{pmatrix} 0.5 & 0.3 \\ 0 & 0.2 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.3 \\ 0.2 \end{pmatrix}$$

$$\eta_2 = \begin{pmatrix} 0.5 & 0.3 \\ 0 & 0.2 \end{pmatrix} \begin{pmatrix} 0.3 \\ 0.2 \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\text{IMP} = \begin{pmatrix} 0.21 \\ 0.04 \end{pmatrix}$$



$q_{1t} t=1$   
 ก้าว 1 ของ y1 คือ 0.3  
 ก้าว 2 ของ y2 คือ -0.21

ผลลัพธ์  
 + กัน

ผลลัพธ์  
 ของ y2  
 ของ y3

## ตัวอย่างที่ 6.8

IRF ตาก Structural VAR  $\Rightarrow$  Orthogonal IRF  
 กันๆ ก็ B ให้ triangular matrix  $\Rightarrow$  ให้ period 1 ต่อไป  $y_1 \rightarrow y_2 \rightarrow y_3 \rightarrow$

เราจะสร้าง Impulse response function ด้วยคำสั่ง irf โดยที่ default ในคำสั่งนี้คือการสร้าง orthogonal impulse response function (ortho=TRUE)

การเรียกดูแบบใน lret ที่เรียก lret\_thmy\$TH ก่อน lret\_thmy\$MY

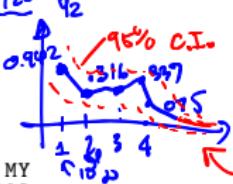
VAR(2) ผ่าน period

```

1 > model1.irf<-irf(model1, n.ahead=5)
2 > model1.irf
3
4 Impulse response coefficients
5 $TH Impulse response coefficients
6 TH MY
7 [1,] 3.180 0.942 =  $y_{20}$   $y_2$ 
8 [2,] 0.084 0.316
9 [3,] 0.498 0.337
10 [4,] 0.055 0.075
11 [5,] 0.097 0.071
12 [6,] 0.017 0.019
13
14 $MY Impulse Intensity
15 TH MY
16 [1,] 0.0e+00 2.2303
17 [2,] 1.1e-02 -0.0805
18 [3,] 2.1e-01 0.1795
19 [4,] -4.3e-05 0.0115
20 [5,] 4.4e-02 0.0313
21 [6,] 2.3e-03 0.0046
22 > plot(model1.irf)

```

ortho=TRUE  
 - IRF ที่ได้ตาม模型 structural VAR  
 - shock = 1 s.d.



Imp res lret TH ตัวอย่าง  
 lret MY ↑ ประกอบด้วย ปรบต  
 80%

Imp res lret MY 7 ตัวอย่าง lret TH

ก. ตัวอย่าง IRF confidence interval vs IRF ไม่ต้องห่วง  
 ข. ตัวอย่าง IRF ไม่ต้องห่วง

IRF period 0  
 $y_{10} = 1 \rightarrow y_{10}$   
 $y_{20}$

MSA ของตัวอย่าง  
 ตัวอย่างที่ 6.8

(3)

## Variance Decomposition

$$\text{ต.ก Forecast } \stackrel{\text{ของ VAR(1)}}{=} \underline{\Phi_{11}} \begin{pmatrix} Y_{1,t} \\ Y_{2,t} \end{pmatrix} + \begin{pmatrix} \epsilon_{1t} \\ \epsilon_{2t} \end{pmatrix} \Rightarrow \hat{Y}_{1,h} = \underline{\Phi_{11}} Y_h$$

Forecast Error Variance Decomposition จากข้อมูล ณ ครบที่  $h$  เราต้องการตอบคำถามว่าชีอกโครงสร้าง  $\eta_j$  เป็นที่มาของความแปรปรวนของค่าผิดพลาดจากการพยากรณ์  $y_{i,h+1}$  ในสัดส่วนเท่าใด

แบบจำลอง  $VAR(1)$  ที่มีตัวแปรสองตัว เราพบว่าการพยากรณ์  $Y_1$ , ไปข้างหน้าหนึ่งครบ มีค่าคาดเคลื่อนจากการพยากรณ์ (forecast error) ตามสมการที่ (?) เท่ากับ

$$\underline{e(1)} = \underline{\epsilon_{h+1}} \quad \xrightarrow{\text{fe. var } Y_{1,t}} \underline{e_1(1)} = \underline{\epsilon_{1,h+1}}$$

ซึ่งค่าคาดเคลื่อนเกิดจากชีอกในตัวแปร  $Y_1$ , เพียงอย่างเดียว และมีความแปรปรวนของค่าความคาดเคลื่อนจากการพยากรณ์ไปข้างหน้าหนึ่งครบ (one-period forecast error variance) เท่ากับ

$$\underline{\underline{Var(e_1(1))}} = \underline{\underline{Var(\epsilon_{1,h+1})}} = \underline{\underline{\sigma_1^2}}$$

Variance vs FE  
vs  $Y_1$  ภูมิศาสตร์  
เกิดจาก ณ 10 พัน%

## Variance Decomposition

$$\hat{Y}_h(2) = \Phi^2 Y_h \Rightarrow e(2) = \underline{\Phi \varepsilon_{h+1} + \varepsilon_{h+2}}$$

ในขณะที่การพยากรณ์  $Y_{1t}$  ไปข้างหน้าสอง步 มีค่าคาดเคลื่อนจากการพยากรณ์ตามสมการที่ ?? เท่ากับ

FE vs  $Y_1$  ตรงกัน  $\rightarrow$  ต่อ  $Y_1$  100

$$\underline{e_1(2)} = \phi_{11}\varepsilon_{1,h+1} + \phi_{12}\varepsilon_{2,h+1} + \varepsilon_{1,h+2}$$

ซึ่งค่าคาดเคลื่อนเกิดจากช็อคของตัวแปร  $Y_{1t}$  และตัวแปร  $Y_{2t}$  เราสามารถคำนวณหาค่าความแปรปรวนของค่าความคาดเคลื่อนจากการพยากรณ์ไปข้างหน้าสอง步 ได้ดังสมการต่อไปนี้

ลงชุด 2 เมื่อต่อไป

$$\underline{Var(e_1(2))} = Var(\phi_{11}\varepsilon_{1,h+1}) + Var(\phi_{12}\varepsilon_{2,h+1}) + Var(\varepsilon_{1,h+2})$$

$$\begin{aligned} &= \boxed{\phi_{11}^2 \sigma_1^2} + \boxed{\phi_{12}^2 \sigma_2^2} + \boxed{\sigma_1^2} \\ &= (1 + \phi_{11}^2)\sigma_1^2 + \phi_{12}^2\sigma_2^2 \end{aligned} \quad (2)$$

$$\frac{\phi_{11}^2 \sigma_1^2 + \sigma_1^2}{Var(e_1(2))} = ? \% \quad (3)$$

หมายเหตุ: กว่า vs FE variance

Spillover

[  
ต่อไป  $Y_2$  ต่อไปพอดี  $Y_2$   
ไม่ว่าจะเป็น  $Y_1$ ]

$$\frac{\phi_{12}^2 \sigma_2^2}{Var(e_1(2))} = ? \%$$



## Variance Decomposition

สามารถแยกส่วนประกอบของค่าความแปรปรวนของค่าความคลาดเคลื่อนจากการพยากรณ์ไปข้างหน้าสองค่าบวกกัน  $Y_{1t}$  เท่ากับ

$$\frac{(1 + \phi_{11}^2)\sigma_1^2}{(1 + \phi_{11}^2)\sigma_1^2 + \phi_{12}^2\sigma_2^2}$$

และมาจากการ  $Y_{2t}$  เท่ากับ

$$\frac{\sigma_2^2}{(1 + \phi_{11}^2)\sigma_1^2 + \phi_{12}^2\sigma_2^2}$$

## ตัวอย่าง 6.9

เราสามารถแยกความแปรปรวนของค่าผิดพลาดจากการพยากรณ์ได้ด้วยคำสั่ง fevd  
*model1 fevd TH MY*

```

1 > fevd(model1, n.ahead=5)
2 $TH
3   TH      MY
4 [1,] 1 0.0e+00
5 [2,] 1 1.3e-05
6 [3,] 1 4.3e-03
7 [4,] 1 4.3e-03
8 [5,] 1 4.5e-03
9
10 $MY
11   TH      MY
12 [1,] 0.15 0.85
13 [2,] 0.17 0.83
14 [3,] 0.18 0.82
15 [4,] 0.18 0.82
16 [5,] 0.18 0.82
  
```

*ผลลัพธ์* *Iret TH*  
*ผลลัพธ์* *Iret MY*  
 $\rightarrow$  85% var FE variance ของ MY, 15% ของ TH  
 $\rightarrow$  18% ก่อต้น TH