

EC435

บทที่ 6 โคอินทิเกรชัน (Cointegration)

เฉลิมพงษ์ คงเจริญ ©2556

คณะเศรษฐศาสตร์ มหาวิทยาลัยธรรมศาสตร์

November 18, 2019

spurious regression

กรณีที่ตัวแปรทั้งหมดเป็น $I(1)$ และไม่ได้เป็น cointegrated ตัวทดสอบที่ได้จากแบบจำลองจะไม่เหมาะสม เราจะพบความสัมพันธ์ระหว่างตัวแปรต่างๆที่จริงๆแล้วตัวแปรทั้งหลายไม่มีความสัมพันธ์กัน (spurious regression)

spurious regression

กรณีที่ตัวแปรทั้งหมดเป็น $I(1)$ และไม่ได้เป็น cointegrated ตัวทดสอบที่ได้จากแบบจำลองจะไม่เหมาะสม เราจะพบความสัมพันธ์ระหว่างตัวแปรต่างๆ ที่จริงๆ แล้วตัวแปรทั้งหลายไม่มีความสัมพันธ์กัน (spurious regression)

หากเราพิจารณาอนุกรมเวลาสองกระบวนการที่เป็น $I(1)$ และเป็นอิสระต่อกัน เราสามารถแสดงความสัมพันธ์ของแต่ละตัวแปรได้ดังนี้


$$y_{1t} = y_{1,t-1} + \varepsilon_{1t} \quad \varepsilon_{1t} \sim WN(0, 1)$$

$$y_{2t} = y_{2,t-1} + \varepsilon_{2t} \quad \varepsilon_{2t} \sim WN(0, 1)$$

โดยที่ $Cov(\varepsilon_{1t}, \varepsilon_{2t}) = 0$ ซึ่งแสดงว่าทั้งสองอนุกรมเวลาเป็นอิสระต่อกัน


Spurious regression

Figure: การจำลองกระบวนการ $I(1)$ สองอนุกรมเวลา



Spurious regression

Figure: การจำลองกระบวนการ $I(1)$ สองอนุกรมเวลา



พิจารณาความสัมพันธ์เชิงถดถอย $y_{1t} = \alpha + \beta y_{2t} + u_t$

```

1 > summary(lm(y1~y2))
2 Call:
3 lm(formula = y1 ~ y2)
4
5 Coefficients:
6             Estimate Std. Error t value Pr(>|t|)
7 (Intercept)  11.43603   0.31329   36.503 < 2e-16 ***
8 y2           0.16237   0.02885    5.628 2.36e-08 ***
9 ---
10 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
11
12 Residual standard error: 9.905 on 998 degrees of freedom
13 Multiple R-squared:  0.03077, Adjusted R-squared:  0.02979
14 F-statistic: 31.68 on 1 and 998 DF, p-value: 2.363e-08

```



Spurious regression

หากเราพิจารณาสมการ $\Delta y_{1t} = \beta \Delta y_{2t} + v_t$

```

1 > summary(lm(diff(y1)-diff(y2)-1))
2
3 Call:
4 lm(formula = diff(y1) ~ diff(y2) - 1)
5
6 Coefficients:
7             Estimate Std. Error t value Pr(>|t|)
8 diff(y2) 0.003455    0.030827   0.112   0.911
9
10 Residual standard error: 0.9921 on 998 degrees of freedom
11 Multiple R-squared: 1.258e-05, Adjusted R-squared: -0.0009894
12 F-statistic: 0.01256 on 1 and 998 DF,  p-value: 0.9108

```

Spurious regression

หากเราพิจารณาสมการ $\Delta y_{1t} = \beta \Delta y_{2t} + v_t$

```

1 > summary(lm(diff(y1)-diff(y2)-1))
2
3 Call:
4 lm(formula = diff(y1) ~ diff(y2) - 1)
5
6 Coefficients:
7             Estimate Std. Error t value Pr(>|t|)
8 diff(y2) 0.003455    0.030827   0.112   0.911
9
10 Residual standard error: 0.9921 on 998 degrees of freedom
11 Multiple R-squared: 1.258e-05, Adjusted R-squared: -0.0009894
12 F-statistic: 0.01256 on 1 and 998 DF, p-value: 0.9108

```

จากตัวอย่างข้างต้นเราจำเป็นต้องระมัดระวังในการพิจารณาความสัมพันธ์ระหว่างอนุกรมเวลาในกรณีที่ตัวแปรที่เราสนใจมีลักษณะเป็น $I(1)$ ซึ่งในกรณีทั่วไปเราจำเป็นต้องปรับให้ตัวแปรดังกล่าวเป็น $I(0)$

Spurious regression

หากเราพิจารณาสมการ $\Delta y_{1t} = \beta \Delta y_{2t} + v_t$

```

1 > summary(lm(diff(y1)-diff(y2)-1))
2
3 Call:
4 lm(formula = diff(y1) ~ diff(y2) - 1)
5
6 Coefficients:
7             Estimate Std. Error t value Pr(>|t|)
8 diff(y2) 0.003455    0.030827   0.112   0.911
9
10 Residual standard error: 0.9921 on 998 degrees of freedom
11 Multiple R-squared: 1.258e-05, Adjusted R-squared: -0.0009894
12 F-statistic: 0.01256 on 1 and 998 DF, p-value: 0.9108

```

จากตัวอย่างข้างต้นเราจำเป็นต้องระมัดระวังในการพิจารณาความสัมพันธ์ระหว่างอนุกรมเวลาในกรณีที่ตัวแปรที่เราสนใจมีลักษณะเป็น $I(1)$ ซึ่งในกรณีทั่วไปเราจำเป็นต้องปรับให้ตัวแปรดังกล่าวเป็น $I(0)$

ในบางกรณีที่เราอาจจะสามารถศึกษาความสัมพันธ์ระหว่างตัวแปรที่เป็น $I(1)$ ก็ได้ซึ่งในกรณีดังกล่าวคือกรณีที่ตัวแปรเป็น cointegration

บทนำ

หากเราพิจารณาสมการถดถอยของตัวแปรทั้งสอง อาจจะมีเหตุการณ์เกิดขึ้นได้ 4 เหตุการณ์

กรณีที่ 1: ทั้ง y และ x เป็น *stationary* เราสามารถใช้ OLS ปกติในการวิเคราะห์

บทนำ

หากเราพิจารณาสมการถดถอยของตัวแปรทั้งสอง อาจจะมีเหตุการณ์เกิดขึ้นได้ 4 เหตุการณ์

กรณีที่ 1: ทั้ง y และ x เป็น *stationary* เราสามารถใช้ OLS ปกติในการวิเคราะห์

กรณีที่ 2: y และ x เป็น *non-stationary* แต่ *integrated* ที่อันดับต่างกัน เราไม่สามารถใช้ OLS ศึกษาความสัมพันธ์ของทั้งสอง



บทนำ

หากเราพิจารณาสมการถดถอยของตัวแปรทั้งสอง อาจจะมีเหตุการณ์เกิดขึ้นได้ 4 เหตุการณ์

กรณีที่ 1: ทั้ง y และ x เป็น *stationary* เราสามารถใช้ OLS ปกติในการวิเคราะห์

กรณีที่ 2: y และ x เป็น *non-stationary* แต่ *integrated* ที่อันดับต่างกัน เราไม่สามารถใช้ OLS ศึกษาความสัมพันธ์ของทั้งสอง

กรณีที่ 3: y และ x เป็น *non-stationary* และ *integrated* ที่อันดับเดียวกัน แต่ ϵ เป็น *random walk* เราไม่สามารถใช้ OLS วิเคราะห์ แต่เราอาจจะพิจารณาสมการที่เรา difference ทั้งสองข้าง

บทนำ

หากเราพิจารณาสมการถดถอยของตัวแปรทั้งสอง อาจจะมีเหตุการณ์เกิดขึ้นได้ 4 เหตุการณ์

กรณีที่ 1: ทั้ง y และ x เป็น *stationary* เราสามารถใช้ OLS ปกติในการวิเคราะห์

กรณีที่ 2: y และ x เป็น *non-stationary* แต่ *integrated* ที่อันดับต่างกัน เราไม่สามารถใช้ OLS ศึกษาความสัมพันธ์ของทั้งสอง

กรณีที่ 3: y และ x เป็น *non-stationary* และ *integrated* ที่อันดับเดียวกัน แต่ ϵ เป็น *random walk* เราไม่สามารถใช้ OLS วิเคราะห์ แต่เราอาจจะพิจารณาสมการที่เรา difference ทั้งสองข้าง

กรณีที่ 4: y และ x เป็น *non-stationary* โดยมีอันดับ *integrated* ที่เหมือนกัน และ *error term* เป็น *stationary*. เราเรียกว่า y และ x เป็น **cointegrated**.

Cointegration

กำหนดให้ $\mathbf{Y}_t = (y_{1t}, y_{2t}, \dots, y_{nt})'$ แทนเวกเตอร์ $(n \times 1)$ ของอนุกรมเวลาที่เป็น $I(1)$ แล้ว \mathbf{Y}_t จะเป็น cointegrated ถ้ามีเวกเตอร์ $\boldsymbol{\beta} = (\beta_1, \dots, \beta_n)'$ ที่ทำให้

$$\boldsymbol{\beta}' \mathbf{Y}_t = \beta_1 y_{1t} + \dots + \beta_n y_{nt} \sim I(0) \quad (6.1)$$

ซึ่งหมายความว่าผลรวมเชิงเส้น (linear combination) ของตัวแปรที่เป็น $I(1)$ มีลักษณะเป็น $I(0)$

ผลรวมเชิงเส้นมักจะได้อาจมาจากทฤษฎีทางเศรษฐศาสตร์ และเรียกสมการดังกล่าวว่าเป็น ความสัมพันธ์ในดุลยภาพระยะยาว (long-run equilibrium)

Cointegration

เวกเตอร์ β ไม่ได้มีลักษณะเป็นรูปแบบอย่างเดี๋ยว (unique) เนื่องจากเวกเตอร์ที่เป็นจำนวนเท่าของ $c\beta'$

Cointegration

เวกเตอร์ β ไม่ได้มีลักษณะเป็นรูปแบบอย่างเดี๋ยวน (unique) เนื่องจากเวกเตอร์ที่เป็นจำนวนเท่าของ $c\beta'$

เรามักจะสนใจในรูปแบบที่ normalized ซึ่งเขียนเป็นความสัมพันธ์ cointegration ได้เป็น

$$\beta' Y_t = y_{1t} - \beta_2 y_{2t} - \dots - \beta_n y_{nt} \sim I(0)$$

หรือเป็นสมการ

$$y_{1t} = \beta_2 y_{2t} + \dots + \beta_n y_{nt} + u_t \quad (6.2)$$

โดยที่ $u_t \sim I(0)$ และเราเรียกพจน์ u_t ว่า disequilibrium error หรือ cointegrating residuals

Cointegration

เวกเตอร์ β ไม่ได้มีลักษณะเป็นรูปแบบอย่างเดี๋ยวน (unique) เนื่องจากเวกเตอร์ที่เป็นจำนวนเท่าของ $c\beta'$

เรามักจะสนใจในรูปแบบที่ normalized ซึ่งเขียนเป็นความสัมพันธ์ cointegration ได้เป็น

$$\beta' Y_t = y_{1t} - \beta_2 y_{2t} - \dots - \beta_n y_{nt} \sim I(0)$$

หรือเป็นสมการ

$$y_{1t} = \beta_2 y_{2t} + \dots + \beta_n y_{nt} + u_t \quad (6.2)$$

โดยที่ $u_t \sim I(0)$ และเราเรียกพจน์ u_t ว่า disequilibrium error หรือ cointegrating residuals

ในดุลยภาพระยะยาวค่า disequilibrium error จะเท่ากับศูนย์ และความสัมพันธ์ระยะยาวจะเท่ากับ $y_{1t} = \beta_2 y_{2t} + \dots + \beta_n y_{nt}$

Error Correction Models

หากเกิดภาวะที่ในระยะสั้นตัวแปรขยับออกจากดุลยภาพในระยะยาว จะมีกลไกในการปรับตัวเข้าสู่ดุลยภาพระยะยาวอย่างไร ซึ่งสามารถอธิบายผ่านแบบจำลอง Error Correction Model (ECM)

Error Correction Models

หากเกิดภาวะที่ในระยะสั้นตัวแปรขยับออกจากดุลยภาพในระยะยาว จะมีกลไกในการปรับตัวเข้าสู่ดุลยภาพระยะยาวอย่างไร ซึ่งสามารถอธิบายผ่านแบบจำลอง Error Correction Model (ECM)

หากเราพิจารณา cointegration ที่มีตัวแปรสองตัวแปรที่มีลักษณะ $I(1)$ คือ y_{1t} และ y_{2t} โดยมีความสัมพันธ์ cointegration เขียนได้เป็น $y_{1t} - \beta_2 y_{2t} \sim I(0)$ Engle and Granger (1987) แสดงให้เห็นว่ามีแบบจำลอง error correction model (ECM) ที่สามารถแสดงได้ในรูป

$$\Delta y_{1t} = c_1 + \alpha_1(y_{1,t-1} - \beta_2 y_{2,t-1}) + \sum_{j=1}^p \psi_{11}^j \Delta y_{1,t-j} + \sum_{j=1}^p \psi_{12}^j \Delta y_{2,t-j} + \varepsilon_{1t}$$

$$\Delta y_{2t} = c_2 + \alpha_2(y_{1,t-1} - \beta_2 y_{2,t-1}) + \sum_{j=1}^p \psi_{21}^j \Delta y_{1,t-j} + \sum_{j=1}^p \psi_{22}^j \Delta y_{2,t-j} + \varepsilon_{2t}$$

Error Correction Models

หากเกิดภาวะที่ในระยะสั้นตัวแปรขยับออกจากดุลยภาพในระยะยาว จะมีกลไกในการปรับตัวเข้าสู่ดุลยภาพระยะยาวอย่างไร ซึ่งสามารถอธิบายผ่านแบบจำลอง Error Correction Model (ECM)

หากเราพิจารณา cointegration ที่มีตัวแปรสองตัวแปรที่มีลักษณะ $I(1)$ คือ y_{1t} และ y_{2t} โดยมีความสัมพันธ์ cointegration เขียนได้เป็น $y_{1t} - \beta_2 y_{2t} \sim I(0)$ Engle and Granger (1987) แสดงให้เห็นว่ามีแบบจำลอง error correction model (ECM) ที่สามารถแสดงได้ในรูป

$$\Delta y_{1t} = c_1 + \alpha_1(y_{1,t-1} - \beta_2 y_{2,t-1}) + \sum_{j=1}^p \psi_{11}^j \Delta y_{1,t-j} + \sum_{j=1}^p \psi_{12}^j \Delta y_{2,t-j} + \varepsilon_{1t}$$

$$\Delta y_{2t} = c_2 + \alpha_2(y_{1,t-1} - \beta_2 y_{2,t-1}) + \sum_{j=1}^p \psi_{21}^j \Delta y_{1,t-j} + \sum_{j=1}^p \psi_{22}^j \Delta y_{2,t-j} + \varepsilon_{2t}$$

สมการข้างต้นแสดงพฤติกรรมเชิงพลวัตของ y_{1t} และ y_{2t} โดยแสดงการปรับตัวระยะสั้นเมื่อตัวแปรตัวใดตัวหนึ่งเคลื่อนตัวออกไปจากดุลยภาพ ซึ่งแบบจำลอง ECM ส่งผลให้เกิดประโยชน์ในการวิเคราะห์ข้อมูลการเงิน

ตัวอย่างที่ 6.2

ตัวอย่าง ECM สำหรับราคาหุ้นและเงินปันผล

กำหนดให้ล็อกของราคาหุ้น (s_t) และล็อกของเงินปันผล (d_t) เป็น $I(1)$ ถ้าล็อกของสัดส่วนเงินปันผลต่อราคา ($\log(D_t/S_t)$) เป็น $I(0)$ ดังนั้น $d_t - s_t \sim I(0)$ หรือเขียนเป็นสมการความสัมพันธ์ระยะยาวได้เป็น

$$d_t = s_t + \mu + u_t \quad (6.4)$$

โดยที่ $u_t \sim I(0)$ และสามารถเขียน ECM ได้ดังนี้

$$\Delta s_t = c_s + \alpha_s(d_{t-1} - s_{t-1} - \mu) + \varepsilon_{st} \quad (6.5)$$

$$\Delta d_t = c_d + \alpha_d(d_{t-1} - s_{t-1} - \mu) + \varepsilon_{dt} \quad (6.6)$$

ตัวอย่างที่ 6.2

สมมติให้ $\alpha_s = 0.5$ และ $\alpha_d = 0$ จะได้

$$\Delta s_t = c_s + 0.5(d_{t-1} - s_{t-1} - \mu) + \varepsilon_{st}$$

$$\Delta d_t = c_d + \varepsilon_{dt}$$

ดังนั้นมีเพียงราคาหุ้นที่ตอบสนองต่อ disequilibrium error โดยที่ค่าเฉลี่ยของการเปลี่ยนแปลงของตัวแปรทั้งสองจะขึ้นอยู่กับข้อมูลในอดีต

$$E(\Delta s_t | F_{t-1}) = c_s + 0.5(d_{t-1} - s_{t-1} - \mu)$$

$$E(\Delta d_t | F_{t-1}) = c_d$$

multiple cointegrating relationship

เวกเตอร์ของอนุกรมเวลา $Y_t = (y_{1t}, \dots, y_{nt})'$ ซึ่งเป็นอนุกรมเวลาที่ cointegrated กัน อาจ会有ความสัมพันธ์ระยะยาวได้ r รูปแบบ ซึ่ง $0 < r < n$ เช่นกรณีที่ $Y_t = (y_{1t}, y_{2t}, y_{3t})'$ อาจ会有ความสัมพันธ์ในรูปแบบ $\beta_{11}y_{1t} + \beta_{12}y_{2t} + \beta_{13}y_{3t} \sim I(0)$ และ $\beta_{21}y_{1t} + \beta_{22}y_{2t} + \beta_{23}y_{3t} \sim I(0)$ และเราเรียกเวกเตอร์ $(\beta_{11} \quad \beta_{12} \quad \beta_{13})'$ และ $(\beta_{21} \quad \beta_{22} \quad \beta_{23})'$ ว่า cointegrating vector

การทดสอบ cointegration

หากเรากำหนดให้ Y_t เป็นเวกเตอร์ $n \times 1$ ของอนุกรมเวลา $I(1)$ ซึ่งมี r ($0 < r < n$) cointegrating vectors ซึ่งแสดงเป็นสัญลักษณ์ได้ดังนี้

$$\begin{pmatrix} \beta_1' Y_t \\ \vdots \\ \beta_r' Y_t \end{pmatrix} = \begin{pmatrix} u_{1t} \\ \vdots \\ u_{rt} \end{pmatrix} \sim I(0) \quad (6.7)$$

การทดสอบ cointegration อาจจะแบ่งได้เป็นสองกรณีคือ

- ❶ การทดสอบว่ามีความสัมพันธ์ cointegrating อย่างน้อยหนึ่งรูปแบบหรือไม่ (Engle and Granger(1986))
- ❷ การทดสอบว่ามี cointegrating vector $0 \leq r < n$ หรือไม่ (Johansen (1988))

การทดสอบ cointegration

การทดสอบในประเด็นแรกได้ถูกนำเสนอโดย Engle and Granger (1986) ซึ่งเสนอการทดสอบสองขั้นตอน (two-step cointegration test) ซึ่งประกอบด้วย

- ❶ สร้าง cointegrating residuals โดยที่ $u_t = y_{1t} - \beta_2 y_{2t} - \dots - \beta_n y_{nt}$
- ❷ ทดสอบ unit root ของ u_t เพื่อแสดงว่า u_t เป็น $I(0)$ หรือไม่ โดยสมมุติฐานหลักของการทดสอบนี้คือไม่มี cointegration ซึ่งสมมุติฐานดังกล่าวสอดคล้องกับ u_t เป็น $I(1)$

การทดสอบ cointegration ตามวิธีการของ Engle and Granger สามารถแบ่งออกได้เป็นสองกรณีคือ

กรณีที่หนึ่ง เราทราบความสัมพันธ์ของอนุกรมเวลาที่เราสนใจ

กรณีที่สอง เราจำเป็นต้องประมาณค่าสำหรับ cointegrating vector และสร้าง

cointegrating vector จาก $\hat{u}_t = \hat{\beta}' Y_t$

การทดสอบกรณีทราบ cointegration vector

กำหนดให้ Y_t เป็นเวกเตอร์ $n \times 1$ ของ $I(1)$ และ cointegrated กัน โดยที่มีความสัมพันธ์สามารถแสดงได้ด้วย cointegrating vector β ซึ่ง $u_t = \beta' Y_t$ เราต้องการทดสอบสมมติฐานหลัก $H_0 : u_t = \beta' Y_t \sim I(1)$ หรือไม่มี cointegration กับสมมติฐานรอง $H_1 : u_t = \beta' Y_t \sim I(0)$ หรือมี cointegration

เราสามารถทดสอบสมมติฐานข้างต้นได้ด้วยการทดสอบยูนิทรูทเช่น ADF หรือ PP กับตัวแปร u_t ซึ่งเราจะสรุปว่า Y_t เป็น cointegrated ถ้าเราปฏิเสธสมมติฐานหลัก

ตัวอย่างที่ 6.3

ในตัวอย่างนี้เราจะพิจารณาความสัมพันธ์ระหว่างราคาปัจจุบัน (spot price: S_t) และราคาฟิวเจอร์ (future price: F_t) ของอัตราแลกเปลี่ยน โดยที่ตัวแปรทั้งสองมีความสัมพันธ์ตามแบบจำลอง cost of carry model ซึ่งลือกของราคาปัจจุบัน (s_t) จะเท่ากับลือกของราคาฟิวเจอร์ (f_t) บวกกับค่าคงที่ (ซึ่งสะท้อนต้นทุนในการถือสินทรัพย์)

$$f_t = s_t + c$$

ดังนั้นในกรณีนี้เราสามารถเขียน $u_t = f_t - s_t$ หรือ $\beta = (1 \quad -1)'$

```

1 > set50_m <- read.csv("C:/teaching/ec435/r/set50_m.csv")
2 > lfutures<-log(set50_m$futures)
3 > lspot<-log(set50_m$spot)
4 > u<-lfutures-lspot
5 > adfTest(u, lags=2, type=c("nc"))
6 Title:
7 Augmented Dickey-Fuller Test
8 Test Results:
9 PARAMETER:
10 Lag Order: 2
11 STATISTIC:
12 Dickey-Fuller: -7.2144
13 P VALUE:
14 0.01

```

การทดสอบกรณีที่เราไม่ทราบค่า cointegrating vector

ในกรณีนี้เราจำเป็นต้องประมาณค่า cointegrating vector ขึ้นมา

ขั้นตอนแรกของการทดสอบเราจำเป็นต้องประมาณค่า β โดยที่เราอาจจะเขียนในรูป บรรทัดฐาน (normalized) ซึ่งเขียนเป็นสมการได้

$$y_{1t} = c + \beta_2 y_{2t} + \dots + \beta_n y_{nt} + u_t \quad (6.8)$$

การทดสอบ cointegration จะเป็นการทดสอบ unit root ของ

$\hat{u}_t = y_{1t} - \hat{c} - \hat{\beta}_2 y_{2t} - \dots - \hat{\beta}_n y_{nt}$ โดยที่ $\hat{c}, \hat{\beta}_2, \dots, \hat{\beta}_n$ เป็นตัวประมาณค่า OLS ของ สัมประสิทธิ์

Phillips and Ouliaris (1990) ได้แสดงให้เห็นว่าตัวทดสอบ ADF และ PP ของ cointegrating residual ในกรณีที่เราต้องประมาณค่าสัมประสิทธิ์ของ cointegrating vector ไม่ได้มีการแจกแจงแบบ ADF distribution แบบปกติ

ตัวอย่างที่ 6.4

ต่อเนื่องจากตัวอย่างที่ผ่านมา ในกรณีนี้สมมุติว่าเราไม่ทราบค่าของ cointegrating vector ดังนั้นสมมุติให้ $\beta = (1 \quad -\beta_2)'$ ดังนั้นเราสามารถพิจารณาสมการถดถอย $s_t = c + \beta_2 f_t + u_t$ ซึ่งหลังจากที่เราประมาณค่าด้วย OLS เราสามารถที่จะหาค่า $\hat{u}_t = s_t - \hat{c} - \hat{\beta}_2 f_t$ ตามขั้นตอนในคำสั่งข้างล่าง

```

1 > m1<-lm(lfutures~lspot)
2 > summary(m1)
3 Coefficients:
4             Estimate Std. Error t value Pr(>|t|)
5 (Intercept) -0.044097   0.023113  -1.908   0.0587 .
6 lspot       1.006206   0.003535 284.610 <2e-16 ***
7 ---
8 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
9
10 Residual standard error: 0.01349 on 124 degrees of freedom
11 Multiple R-squared:  0.9985, Adjusted R-squared:  0.9985
12 F-statistic: 8.1e+04 on 1 and 124 DF,  p-value: < 2.2e-16
13
14 > uhat<-m1$residuals

```

ตัวอย่างที่ 6.4

```
1 > adfTest(uhat,lags=2, type=c("nc"))
2
3 Title:
4   Augmented Dickey-Fuller Test
5
6 Test Results:
7   PARAMETER:
8     Lag Order: 2
9   STATISTIC:
10    Dickey-Fuller: -8.4232
11    P VALUE:
12      0.01
```

การประมาณค่า ECM ด้วย OLS

สมมติว่าเราสนใจตัวแปร $(y_{1t} \quad y_{2t})'$ ซึ่งมีความสัมพันธ์ cointegration แสดงได้ด้วยสมการ $y_{1t} = \beta_2 y_{2t} + u_t$ (หรือ $y_{1t} - \beta_2 y_{2t} = u_t \sim I(0)$) และเรามีตัวประมาณค่า $\hat{\beta}_2$ ที่มีคุณลักษณะเป็น consistent และเราต้องประมาณค่า ECM ในรูปแบบ

$$\Delta y_{1t} = c_1 + \alpha_1 (y_{1,t-1} - \beta_2 y_{2,t-1}) + \sum_{i=1}^p \psi_{11}^j \Delta y_{1,t-j} + \sum_{i=1}^p \psi_{12}^j \Delta y_{2,t-j} + \varepsilon_{1t} \quad (6.9)$$

$$\Delta y_{2t} = c_2 + \alpha_2 (y_{1,t-1} - \beta_2 y_{2,t-1}) + \sum_{i=1}^p \psi_{21}^j \Delta y_{1,t-j} + \sum_{i=1}^p \psi_{22}^j \Delta y_{2,t-j} + \varepsilon_{2t} \quad (6.10)$$

เราสามารถแทนค่า $\hat{\beta}_2$ ลงในสมการเหมือนเป็นพารามิเตอร์ที่เราทราบค่า

เราสามารถพิจารณา disequilibrium error $(y_{1,t-1} - \beta_2 y_{2,t-1})$ เหมือนเป็นตัวแปรที่ทราบค่า เนื่องจากตัวแปรทุกตัวในสมการ (6.9) และ (6.10) เป็น $I(0)$ เราสามารถประมาณค่าสมการดังกล่าวด้วย OLS

ตัวอย่างที่ 6.5

เราต้องการประมาณค่าสมการ ECM สำหรับลือกของราคาปัจจุบันและลือกของราคาฟิวเจอร์ซึ่งเราจำเป็นต้องหาอันดับของค่าล่าของผลต่างที่เหมาะสม ซึ่งอาจจะใช้ AIC, BIC ในการเลือก แต่ในที่นี้เราสมมุติให้แบบจำลองของเป็นดังนี้

$$\Delta s_t = c_1 + \alpha_1 \hat{u}_{t-1} + \psi_{11} \Delta s_{t-1} + \psi_{12} \Delta f_{t-1} + \varepsilon_{ft} \quad (6.11)$$

$$\Delta f_t = c_2 + \alpha_2 \hat{u}_{t-1} + \psi_{21} \Delta s_{t-1} + \psi_{22} \Delta f_{t-1} + \varepsilon_{st} \quad (6.12)$$

```

1 > ecm1<-lm(dlfutures[2:125]~uhat[1:124]+dlfutures[1:124]+dlspot[1:124])
2 > summary(ecm1)
3 Coefficients:
4             Estimate Std. Error t value Pr(>|t|)
5 (Intercept)  0.004115   0.006281   0.655   0.5136
6 uhat[1:124] -1.152182   0.598961  -1.924   0.0568 .
7 dlfutures[1:124] 0.071715  0.478109   0.150   0.8810
8 dlspot[1:124]  0.137282  0.498649   0.275   0.7836
9 ---
10 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
11
12 Residual standard error: 0.06973 on 120 degrees of freedom
13 Multiple R-squared:  0.06491, Adjusted R-squared:  0.04154
14 F-statistic: 2.777 on 3 and 120 DF, p-value: 0.04424

```



VAR models และ cointegration

Granger representation theorem เชื่อมโยง cointegration กับ error correction models

Johansen สร้างแบบจำลอง cointegration และ error correction models โดยใช้โครงร่าง vector autoregression

พิจารณาตัวแปรในระดับ level ในรูป $VAR(p)$ โดยมีตัวแปรอยู่ในรูปเวกเตอร์ $(n \times 1)$ เขียนเป็นสัญลักษณ์ Y_t

$$Y_t = \Pi_1 Y_{t-1} + \dots + \Pi_p Y_{t-p} + \epsilon_t, t = 1, \dots, T$$

ถ้า $VAR(p)$ มีลักษณะเป็น unit root แสดงว่าตัวแปรบางตัวหรือทั้งหมดใน Y_t มีลักษณะเป็น $I(1)$ และตัวแปรเหล่านั้นอาจจะ cointegrate กันได้

Cointegrated VAR

ความสัมพันธ์ลักษณะ cointegrating สามารถพิจารณาได้อย่างชัดเจนขึ้นหากเราแปลง level VAR เป็น **vector error correction model (VECM)**

$$\Delta Y_t = \Pi Y_{t-1} + \Gamma_1 \Delta Y_{t-1} + \dots + \Gamma_{p-1} \Delta Y_{t-p+1} + \epsilon_t$$

โดยที่เมตริกซ์ Π ถูกเรียกว่า *long run impact matrix* และ Γ_k ถูกเรียกว่า *short run impact matrices*

ในแบบจำลอง VECM เราพบว่า ΔY_t และ Lag ของ ΔY_t เป็น $I(0)$

จะเห็นได้ว่า เหลือเพียงพจน์ ΠY_{t-1} ที่มีโอกาสเป็น $I(1)$ และหากเราพิจารณา ΔY_t เราพบว่า ΔY_t จะเป็น $I(0)$ ถ้า ΠY_{t-1} เป็น $I(0)$

ดังนั้น ΠY_{t-1} จะเป็นเมตริกซ์ที่ระบุ cointegrating relations หากตัวแปร cointegrate กัน

Cointegrated VAR

ถ้า VAR(p) process มีลักษณะเป็น unit roots เราพบว่า Π จะเป็น singular matrix และถ้า Π เป็น singular แล้วมันจะมี reduced rank ($\text{rank}(\Pi) = r < n$) ซึ่งค่าดังกล่าวเป็นไปได้สองกรณีคือ

- $\text{rank}(\Pi) = 0$ แสดงว่า Π และ Y_t เป็น $I(1)$ และตัวแปรนี้ได้ cointegrate กัน และแบบจำลอง VECM จะลดลงเหลือแค่ VAR(p-1) ของตัวแปรในรูปแบบ first differences
- $0 < \text{rank}(\Pi) = r < n$ กรณีนี้แสดงว่า Y_t เป็น $I(1)$ โดยที่มี r linear independent cointegrating vectors

Johansen's Methodology for Modeling Cointegration

ขั้นตอนในการสร้างแบบจำลอง Cointegration ของ Johansen คือ

- ระบุ Order และประมาณค่า VAR(p) สำหรับ Y_t
- สร้าง likelihood ratio tests สำหรับการทดสอบ rank of Π เพื่อระบุจำนวน cointegrating vectors
- หากจำเป็นเราอาจจะสมมุติ normalization และระบุเงื่อนไขของ cointegrating vectors
- จาก normalized cointegrating vectors ที่ได้ระบุไว้ เราสามารถประมาณค่า cointegrated VECM ด้วย MLE

Specification of Deterministic Terms

Johansen (1995) ใช้ specification ของ VECM ในรูปแบบต่อไปนี้

$$Y_t = \Phi D_t + \Pi_1 Y_{t-1} + \dots + \Pi_p Y_{t-p} + \epsilon_t, t = 1, \dots, T$$

โดยที่ $\Phi D_t = \mu_t = \mu_0 + \mu_1 t$ เป็น deterministic terms โดยที่พฤติกรรมของ deterministic term ของ Y_t สามารถแยกออกได้เป็น 5 กรณี:

- Model $H_2(r) : \mu_0$ (no constant)
- Model $H_1^*(r) : \mu_t = \mu_0 = \alpha \rho_0$ (restricted constant)
- Model $H_1(r) : \mu_t = \mu_0$ (unrestricted constant)
- Model $H^*(r) : \mu_t = \mu_0 + \alpha \rho_1 t$ (restricted trend)
- Model $H(r) : \mu_t = \mu_0 + \mu_1 t$ (unrestricted constant and trend)

Likelihood Ratio Tests for the Number of Cointegrating Vectors

หากเราใช้ $H(r)$ เป็นสัญลักษณ์แทน unrestricted cointegrated VECM แล้ว แบบจำลอง $I(1)$ ของ $H(r)$ สามารถเขียนเป็นเงื่อนไขของ rank ของ Π มีค่าน้อยกว่าหรือเท่ากับ r เราสามารถสร้าง nested set ของแบบจำลอง

$$H(0) \subset \dots \subset H(r) \subset \dots \subset H(n)$$

โดยที่ $H(0)$ แสดงถึง non-cointegrated VAR model โดยที่ $\Pi = \mathbf{0}$ และ $H(n)$ แสดงถึง unrestricted stationary VAR(p)

เนื่องจาก rank ของ Π เป็นตัวระบุจำนวน cointegrating relationships ในตัวแปร Y_t ดังนั้น Johansen ได้เสนอตัวทดสอบ LR statistics สำหรับจำนวน cointegrating relationships ซึ่งเป็น LR statistics สำหรับการระบุ rank ของ Π

Johansen's Trace Statistics

การทดสอบของ Johansen มีพื้นฐานจากการตัวประมาณค่า eigenvalues $\hat{\lambda}_1 > \hat{\lambda}_2 > \dots > \hat{\lambda}_n$ ของเมตริกซ์ Π (rank ของเมตริกซ์ มีค่าเท่ากับจำนวนของ eigenvalue ที่มีค่าไม่เท่ากับศูนย์)

Johansen's Trace Statistic

Johansen's LR statistic ทดสอบสมมติฐานในลักษณะเป็น nested hypotheses

$$H_0(r_0) : r = r_0 \quad \text{vs} \quad H_1(r_0) : r > r_0$$

โดยที่ LR statistic ถูกเรียกว่า *trace statistic* และคำนวณได้ดังนี้

$$LR_{trace}(r_0) = -T \sum_{i=r_0+1}^n \ln(1 - \hat{\lambda}_i)$$

ถ้า $rank(\Pi) = r_0$ แล้ว $\hat{\lambda}_{r_0+1}, \dots, \hat{\lambda}_n$ จะมีค่าเข้าใกล้ศูนย์ และ $LR_{trace}(r_0)$ ควรจะมีค่าน้อย

การแจกแจง(เมื่อตัวอย่างใหญ่ asymptotic) ของ $LR_{trace}(r_0)$ เมื่อ H_0 เป็นจริงจะเป็น multivariate distribution ของ Dickey-Fuller unit-root distribution



Sequential Procedure

Johansen เสนอการทดสอบในลักษณะที่เป็นอันดับ (sequential testing procedure) โดยที่กระบวนการดังกล่าวจะระบุจำนวนของ cointegrating vectors ได้อย่าง consistently

- ขั้นตอนแรกเราทดสอบ $H_0(r = 0)$ กับ $H_1(r > 0)$ ถ้าเราไม่สามารถปฏิเสธสมมติฐานหลัก แสดงว่าไม่มี cointegrating vectors
ถ้าเราปฏิเสธ $H_0(r = 0)$ เราสามารถสรุปได้ว่า มี cointegrating vector อย่างน้อยหนึ่งค่า และทดสอบในขั้นต่อไป
- ทดสอบ $H_0(r = 1)$ กับ $H_1(r > 1)$ ถ้าเราไม่สามารถปฏิเสธสมมติฐานหลัก เราสรุปว่ามี cointegrating vector เท่ากับหนึ่ง
แต่ถ้า เราปฏิเสธสมมติฐานหลัก แสดงว่า มี cointegrating vectors อย่างน้อยสองค่า
- กระบวนการที่เป็นอันดับดังกล่าวจะดำเนินไปเรื่อยๆจนกระทั่งสมมติฐานหลักไม่สามารถปฏิเสธ สรุปว่ามีความสัมพันธ์เท่ากับ r_0

Johansen's Maximum Eigenvalue Statistic

Johansen ยังได้เสนอการทดสอบ LR statistic สำหรับสมมติฐานต่อไปนี้

$$H_0(r_0) : r = r_0 \quad \text{vs} \quad H_1(r_0) : r = r_0 + 1$$

โดยเราเรียก LR statistic ว่า *maximum eigenvalue statistic* และคำนวณได้ดังนี้

$$LR_{max}(r_0) = -T \ln(1 - \hat{\lambda}_{r_0+1})$$

ตัวอย่างที่ 6.6

เราจะพิจารณาข้อมูลในตัวอย่างที่ 6.5 ด้วยแบบจำลอง VECM

```

1 > fsprice<-cbind(lfutures, lspot)
2 > library(vars)
3 > var.mod<-VAR(fsprice, lag.max=4, ic=c("SC"))
4 > var.mod
5
6 VAR Estimation Results:
7 =====
8
9 Estimated coefficients for equation lfutures:
10 =====
11 Call:
12 lfutures = lfutures.l1 + lspot.l1 + const
13
14 lfutures.l1    lspot.l1    const
15 0.07057597 0.91654897 0.08517149
16
17
18 Estimated coefficients for equation lspot:
19 =====
20 Call:
21 lspot = lfutures.l1 + lspot.l1 + const
22
23 lfutures.l1    lspot.l1    const
24 -0.1508610 1.1346435 0.1098629

```

ตัวอย่างที่ 6.6

แบบจำลองที่เหมาะสมคือ $VAR(1)$ package ที่ใช้ในการทดสอบ Johansen และประมาณค่า VECM คือ *urca* โดยที่คำสั่งที่ใช้ในการทดสอบ Johansen คือ *ca.jo* โดยที่เราต้องระบุข้อมูล (*fsprice*) วิธีในการทดสอบ (trace) รูปแบบของสมการ (*const*) และจำนวน lag ในแบบจำลอง VAR อย่างไรก็ตามใน package นี้กำหนด lag ขั้นต่ำเท่ากับ 2 (VECM(1))

```

1 > library(urca)
2 > fsprice.rc<-ca.jo(fsprice, type=c("trace"), ecdet=c("const"), K=2)
3 > summary(fsprice.rc)
4
5 #####
6 # Johansen-Procedure #
7 #####
8
9 Test type: trace statistic , without linear trend and constant in cointegration
10
11 Eigenvalues (lambda):
12 [1] 3.779375e-01 1.865708e-02 -2.281477e-17
13
14 Values of teststatistic and critical values of test:
15
16      test 10pct  5pct  1pct
17 r <= 1 |  2.34  7.52  9.24 12.97
18 r = 0  | 61.20 17.85 19.96 24.60

```

ตัวอย่างที่ 6.6

เราสามารถสร้างสมการเวกเตอร์เอเรคคอเรชัน ได้ด้วยคำสั่ง *cajorls* โดยระบุว่าใช้รูปแบบจาก *fsprice.rc* และจำนวนความสัมพันธ์เท่ากับ 1 ($r = 1$)

```

1 > fsprice.vecm<-cajorls(fsprice.rc, r=1)
2 > fsprice.vecm
3 $rlm
4
5 Call:
6 lm(formula = substitute(form1), data = data.mat)
7
8 Coefficients:
9             lfutures.d  lspot.d
10      ect1          -1.1705      -0.2296
11 lfutures.dl1    -1.0964      -0.3301
12 lspot.dl1       1.3179       0.5226
13
14 $beta
15             ect1
16 lfutures.l2  1.00000000
17 lspot.l2     -1.00496480
18 constant    0.03639024

```