

# **เศรษฐมิติทางการเงินเบื้องต้น** **Introduction to Financial Econometrics**

**เฉลิมพงษ์ คงเจริญ**

©2555-2562

**คณะเศรษฐศาสตร์ มหาวิทยาลัยธรรมศาสตร์**

<http://econ.tu.ac.th/archan/Chaleampong/>

ร่างแรก พฤศจิกายน 2555 ปรับปรุงครั้งล่าสุด 13 สิงหาคม 2562

# สารบัญ

0	บทนำ: ความหมายของเศรษฐมิติทางการเงิน	5
1	อนุกรมเวลาทางการเงินและคุณลักษณะ	11
1.1	การคำนวณผลตอบแทน (return)	11
1.1.1	นิยามของผลได้ตอบแทนของทรัพย์สิน	11
1.1.2	ผลได้ตอบแทนทบต้นอย่างต่อเนื่อง	15
1.2	แบบจำลองสำหรับข้อมูลอนุกรมเวลา	18
1.2.1	การแจกแจงของอนุกรมเวลา (Distribution of time series)	19
1.2.2	คุณลักษณะเรื้อรังรูปร่างของการแจกแจงความน่าจะเป็น	22
1.2.3	ตัวอย่างการคำนวณค่าสถิติและการทดสอบสมมติฐานจากผลได้ตอบแทนหุ้น PTT	27
1.2.4	การทดสอบพอร์ทแมนโท (Portmanteau test) สำหรับสหสัมพันธ์ในตัวเอง	34
1.2.5	ตัวดำเนินการขยับไปข้างหลัง	35
2	แบบจำลองอนุกรมเวลาเชิงเส้นตรง	36
2.1	แบบจำลองออโตรีเกรสซีฟ	37
2.1.1	แบบจำลองออโตรีเกรสซีฟอันดับหนึ่ง ( $AR(1)$ )	38
2.1.2	แบบจำลอง $AR(2)$	43
2.1.3	แบบจำลอง $AR(p)$	45
2.1.4	ฟังก์ชันสหสัมพันธ์ในตัวเองบางส่วน (Partial Autocorrelation Function; PACF)	46
2.1.5	การประมาณค่าและตรวจสอบแบบจำลอง	48
2.1.6	การพยากรณ์ด้วยแบบจำลอง $AR(p)$	53
2.2	แบบจำลองมูวี่งเอเวอเรจ (Moving Average; $MA(q)$ )	57
2.2.1	แบบจำลอง $MA(1)$	58

2.2.2	แบบจำลอง $MA(2)$ . . . . .	61
2.2.3	แบบจำลอง $MA(q)$ . . . . .	62
2.2.4	การประมาณค่าแบบจำลอง $MA(q)$ . . . . .	63
2.2.5	การพยากรณ์จากแบบจำลอง $MA(q)$ . . . . .	66
2.3	แบบจำลอง ออโตรีเกรสซีฟมูวี่งเอเวอเรจ (Autoregressive Moving Average; $ARMA(p, q)$ ) . . . . .	68
2.3.1	แบบจำลอง $ARMA(1, 1)$ . . . . .	68
2.3.2	การประมาณค่าสมการแบบจำลอง ARMA . . . . .	71
2.3.3	เกณฑ์การเลือกแบบจำลอง (Model Selection Criteria) . . . . .	71
2.3.4	การเขียนกระบวนการอาร์มา (ARMA) ในสามรูปแบบ . . . . .	74
2.3.5	การพยากรณ์ (forecasting) . . . . .	74
2.4	Unit Root Nonstationary . . . . .	75
2.4.1	การทดสอบยูนิทรูทในรูปแบบสมการถดถอยในตัวเอง . . . . .	77
2.5	ARIMA (Integrated ARMA) . . . . .	87
2.6	แบบจำลองตามฤดูกาล . . . . .	88
<b>3</b>	<b>สมการถดถอยสำหรับข้อมูลอนุกรมเวลา</b>	<b>91</b>
3.1	แบบจำลองถดถอยเชิงเส้นตรงสำหรับข้อมูลอนุกรมเวลา . . . . .	91
3.1.1	การประมาณค่าวิธีกำลังสองน้อยที่สุด . . . . .	92
3.2	Heteroskedasticity and Autocorrelation Consistent Covariance Matrix Estimation . . . . .	93
3.2.1	White . . . . .	93
3.2.2	Newey-West . . . . .	93
<b>4</b>	<b>แบบจำลอง GARCH</b>	<b>95</b>
4.1	ความผันผวนของสินทรัพย์ . . . . .	95
4.1.1	คุณลักษณะของความผันผวน . . . . .	95
4.1.2	การทดสอบ ARCH effect . . . . .	95
4.2	แบบจำลอง ARCH . . . . .	98
4.2.1	รูปแบบของแบบจำลอง ARCH(q) . . . . .	99
4.2.2	คุณสมบัติของ ARCH(1) . . . . .	100
4.2.3	การประมาณค่าแบบจำลอง ARCH(1) . . . . .	101
4.3	แบบจำลอง GARCH(p,q) . . . . .	101
4.3.1	ARMA representation of GARCH . . . . .	102

4.3.2	คุณลักษณะเฉพาะของแบบจำลอง GARCH . . . . .	103
4.4	การประมาณค่าแบบจำลอง GARCH . . . . .	104
4.4.1	การตรวจสอบหลังจากการประมาณค่า GARCH . . . . .	104
4.4.2	การแจกแจงที่ไม่ใช่การแจกแจงแบบปกติ . . . . .	107
4.4.3	การเลือกแบบจำลองที่เหมาะสม (Model selection) . . . . .	109
4.4.4	การขยายแบบจำลอง <i>GARCH</i> . . . . .	110
4.5	การพยากรณ์ด้วยแบบจำลอง <i>GARCH</i> . . . . .	112
<b>5</b>	<b>แบบจำลองอนุกรมเวลาเชิงพหุ (Multivariate time series model)</b>	<b>115</b>
5.1	ความนิ่งของอนุกรมเวลาและเมตริกซ์สหสัมพันธ์ระหว่างกัน . . . . .	115
5.1.1	cross-correltaion matrices . . . . .	116
5.2	แบบจำลองเวกเตอร์ออโตรีเกรสซีฟ (Vector Autoregressive Model) . . . . .	117
5.2.1	เงื่อนไขการเป็นอนุกรมเวลานิ่ง . . . . .	120
5.3	การประมาณค่าและการเลือกค่าค่า . . . . .	121
5.3.1	การประมาณค่า . . . . .	121
5.3.2	การเลือกจำนวนความล่าที่เหมาะสม . . . . .	121
5.4	การพยากรณ์จากแบบจำลองเวกเตอร์ออโตรีเกรสซีฟ . . . . .	125
5.5	การวิเคราะห์หลังจากการประมาณค่าแบบจำลองเวกเตอร์ออโตรีเกรสซีฟ . . . . .	128
5.5.1	Granger Causality . . . . .	128
5.5.2	ฟังก์ชันตอบสนองแรงกระตุ้น . . . . .	129
5.5.3	การแยกความแปรปรวนของค่าคลาดเคลื่อนการพยากรณ์ . . . . .	133
<b>6</b>	<b>โคอินทิเกรชัน (Cointegration)</b>	<b>136</b>
6.1	สมการความสัมพันธ์เทียม (spurious regression) . . . . .	136
6.2	นิยามของโคอินทิเกรชัน . . . . .	138
6.2.1	Cointegration และแบบจำลอง Error Correction Models . . . . .	139
6.2.2	multiple cointegrating relationship . . . . .	140
6.3	การทดสอบ cointegration . . . . .	140
6.3.1	การทดสอบกรณีที่เรารู้ค่า cointegrating vector . . . . .	141
6.3.2	การทดสอบกรณีที่เรารู้ค่า cointegrating vector . . . . .	143
6.4	การประมาณค่า ECM ด้วย OLS . . . . .	145
6.5	แบบจำลองเวกเตอร์เอเรคเคชัน (Vector Error Correction Model: VECM) . . . . .	148
6.5.1	รูปแบบของสมการ . . . . .	148
6.5.2	การทดสอบโคอินทิเกรชันตามวิธีของ Johansen . . . . .	149

6.5.3	ขั้นตอนในการทดสอบ โคอินทิเกรชันและสร้างแบบจำลอง เวกเตอร์เอเรอเคอเรชัน . . . . .	151
<b>A</b>	<b>การใช้โปรแกรม R เบื้องต้น</b>	<b>160</b>
A.1	การติดตั้ง R . . . . .	160
A.2	การติดตั้ง RStudio . . . . .	160
A.3	ผังของโปรแกรม RStudio . . . . .	161
A.4	ชุดคำสั่ง (package) หรือห้องสมุด (library) . . . . .	162
A.5	การทำงานบน Working directory . . . . .	162
A.6	การใช้งานเบื้องต้น . . . . .	162
A.6.1	เครื่องหมาย . . . . .	162
A.6.2	พื้นที่ทำงาน (workspace) . . . . .	163
A.6.3	สเกลาร์ เวกเตอร์ และเมทริกซ์ . . . . .	163
A.6.4	ฟังก์ชัน . . . . .	163
A.6.5	การวาดแผนภาพ . . . . .	164
A.7	การช่วยเหลือและเอกสารประกอบฟังก์ชัน . . . . .	164
A.8	Scripts . . . . .	164
A.9	โครงสร้างข้อมูล . . . . .	164
A.9.1	เวกเตอร์ . . . . .	164
A.9.2	เมทริกซ์ . . . . .	165
A.9.3	data frame . . . . .	165
A.9.4	list . . . . .	166
A.10	Graphic . . . . .	166
A.11	การจัดเก็บข้อมูลและนำเข้าข้อมูล . . . . .	167
A.11.1	การจัดเก็บข้อมูลในรูปแบบไฟล์ text . . . . .	167
A.11.2	การเรียกข้อมูลในรูปแบบไฟล์ text . . . . .	167
A.11.3	การนำเข้าไฟล์ประเภทอื่นๆ . . . . .	169
A.11.4	การบันทึกข้อมูล . . . . .	169
A.12	การคำนวณผลได้ตอบแทนจากตัวอย่างหุ้น PTT . . . . .	170
A.12.1	การวาดกราฟ . . . . .	170
A.12.2	การคำนวณผลได้ตอบแทน . . . . .	170

# บทที่ 0

## บทนำ: ความหมายของเศรษฐมิติทางการเงิน

เศรษฐมิติทางการเงิน (financial econometrics) คือการใช้วิธีการทางเศรษฐมิติในการตอบปัญหาทางการเงิน โดยที่เศรษฐมิติทางการเงินจะเป็นประโยชน์ในการทดสอบทฤษฎีทางการเงิน การกำหนดราคาของสินทรัพย์และผลตอบแทน การทดสอบความสัมพันธ์ระหว่างตัวแปรทางการเงินด้วยกัน ความสัมพันธ์ระหว่างตลาดการเงินและตัวแปรเศรษฐกิจมหภาค และการทำนายค่าในอนาคตของตัวแปรทางการเงิน เป็นต้น

ตัวอย่างคำถามทางการเงินที่สามารถนำเครื่องมือเศรษฐมิติไปใช้<sup>1</sup>

- ทดสอบความตลาดการเงินมีประสิทธิภาพหรือไม่ (weak-form efficient)
- ทดสอบว่าแบบจำลอง Capital Asset Pricing Model (CAPM) หรือ Arbitrage Pricing Theory (APT) เป็นแบบจำลองที่ดีกว่ากันในการอธิบายผลตอบแทนของสินทรัพย์เสี่ยง
- วัดและคาดการณ์ความผันผวน (volatility) ของผลตอบแทนในพันธบัตร
- อธิบายตัวกำหนด credit rating
- สร้างแบบจำลองอธิบายความสัมพันธ์ระยะยาวระหว่างราคาและอัตราแลกเปลี่ยน
- กำหนด optimal hedge ratio สำหรับ spot position
- ทดสอบ technical trading rules เพื่อหาวิธีที่จะทำกำไรได้มากที่สุด
- ทดสอบสมมุติฐานว่าการประกาศผลตอบแทนหรือเงินปันผลมีผลต่อราคาหุ้นหรือไม่
- การทดสอบว่าตลาด spot หรือ future ตอบสนองต่อข่าวต่างกันอย่างไร
- การทำนายความสัมพันธ์ระหว่างตลาดหลักทรัพย์ในสองประเทศ

---

<sup>1</sup>Brooks (2007, 2)

## ความแตกต่างระหว่างเศรษฐมิติ (economic econometrics) กับเศรษฐมิติทางการเงิน

เครื่องมือพื้นฐานที่เราใช้ในวิชาเศรษฐมิติทางการเงินจะเหมือนกับในวิชาเศรษฐมิติโดยทั่วไป อย่างไรก็ตาม ข้อมูลตลาดการเงินที่เรานำมาพิจารณาจะมีความแตกต่างในแง่ของ **ความถี่ ความถูกต้อง ฤดูกาล** กับข้อมูลที่เรพบในวิชาเศรษฐมิติทั่วไป ในวิชาเศรษฐศาสตร์เรามักพบปัญหาที่ข้อมูลไม่เพียงพอและสนใจปัญหาที่เกิดจากข้อมูลจำนวนน้อย

ในตลาดการเงินข้อมูลที่เราพบจะมีรูปแบบที่ค่อนข้างต่างกัน แต่โดยทั่วไปที่เราสนใจคือข้อมูลของราคา ณ ระดับที่มีการซื้อขาย ดังนั้นจะมีความถี่ที่สูงกว่าข้อมูลเศรษฐกิจมหภาค ราคาของสินทรัพย์ใดๆ มักมีตั้งแต่ รายนาที่ ชั่วโมงหรือวัน ดังนั้นกลุ่มตัวอย่างในกรณีข้อมูลการเงินมักจะเป็นขนาดใหญ่

## ประเภทของข้อมูล

**ข้อมูลภาคตัดขวาง (cross sectional data)** เป็นข้อมูลที่มีการจัดเก็บ ณ เวลาใดๆ เช่น ราคาหลักทรัพย์ของทั้งตลาด ณ ปีใดปีหนึ่ง, กำไรสุทธิของบริษัทในตลาดหลักทรัพย์ ณ ปีใดปีหนึ่ง ปัญหาที่สามารถใช้ข้อมูลภาคตัดขวางในการศึกษา ตัวอย่างเช่น ความสัมพันธ์ระหว่างขนาดของบริษัทกับผลตอบแทนในการลงทุนในหุ้นนั้นๆ, ความสัมพันธ์ระหว่างระดับของ GDP ของประเทศกับโอกาสในการผลิตซ้ำระยะหนึ่งของประเทศใดๆ ในปีใดปีหนึ่ง

**ข้อมูลอนุกรมเวลา (time series)** เป็นข้อมูลที่มีการจัดเก็บตามเวลา โดยจะมีความสัมพันธ์กับความถี่ในการจัดเก็บ อย่างไรก็ตามข้อมูลทางการเงินบางส่วนมีการบันทึกตามธุรกรรมที่เกิด เช่นการซื้อขายหุ้น แบบจำลองเดียวกันจำเป็นที่จะต้องมีความถี่ที่เหมือนกัน ตารางที่ ?? เป็นตัวอย่างของข้อมูลอนุกรมเวลา

ตารางที่ 1: ตัวอย่างข้อมูลอนุกรมเวลา

สัปดาห์	ปริมาณซื้อขาย	ราคาปิด
7/16/2012	6301500	191.63
7/23/2012	3759100	195.56
7/30/2012	2988800	197.68
8/6/2012	2475200	199.29
8/13/2012	2474700	201.22
8/20/2012	2828000	197.77
8/27/2012	2622700	194.85

ปัญหาที่สามารถใช้ข้อมูลอนุกรมเวลาในการศึกษา ตัวอย่างเช่น ดัชนีราคาหลักทรัพย์แปรผันกับตัวแปรทางเศรษฐกิจของประเทศอย่างไร, มูลค่าของหลักทรัพย์แปรผันตามการประกาศเงินปันผลอย่างไร, อัตราแลกเปลี่ยนมีผลต่อการขาดดุลการค้าอย่างไร

**ข้อมูลแพนอล (panel)** เป็นข้อมูลที่มีทั้งอนุกรมเวลาและภาคตัดขวางเช่น ราคารายวันของ

หุ้นใน SET50 ตลอดระยะเวลาสองปี

ในตำราเล่มนี้เราจะเน้นการเนื้อหาไปยังการศึกษาโดยใช้ข้อมูลอนุกรมเวลาข้อมูลอนุกรมเวลา

## เป้าหมายของตำรา

วัตถุประสงค์หลักของตำราคือการให้อ่านมีความรู้เบื้องต้นในการวิเคราะห์ข้อมูลอนุกรมเวลาทางการเงิน เช่น ความเบ้ ความโค้ง ตลอดจนสหสัมพันธ์(autocorrelation)ของตัวแปรผลได้ตอบแทน นอกจากนี้ยังนำเสนอแบบเครื่องมือทางสถิติและแบบจำลองเศรษฐมิติที่เป็นประโยชน์ในการวิเคราะห์ข้อมูลอนุกรมเวลา และคาดหวังให้อ่านมีความรู้ความเข้าใจในแบบจำลองเศรษฐมิติทางการเงิน ตลอดจนสามารถนำเครื่องมือดังกล่าวไปประยุกต์ใช้ในการวิเคราะห์ข้อมูลอนุกรมเวลาทางการเงิน

## ตัวอย่างอนุกรมเวลาทางการเงิน

ตัวอย่างของข้อมูลอนุกรมเวลาถูกนำมาแสดงในหัวข้อนี้ รูปที่ ?? แสดงราคาปิดของหุ้น APPLE ระหว่างปี 2001 และ 2012 ซึ่งข้อมูลดังกล่าวนำมาคำนวณผลได้ตอบแทนรายวันของหุ้น และแสดงอยู่ในรูปที่ ??


รูปที่ 1: ราคาปิดหุ้น APPLE co. รายวัน




จากรูปที่ ?? จะเห็นได้ว่า ผลได้ตอบแทนมีค่าอยู่รอบๆศูนย์ โดยที่บางช่วงจะมีความผันผวนสูงกว่าบางช่วง (มีผลได้ตอบแทนอยู่ห่างจากศูนย์มากกว่าปกติ) รูปที่ ?? แสดงการแจกแจงผลได้ตอบแทนของหุ้น APPLE โดยที่เส้นที่บ่งชี้แสดงการแจกแจงจากข้อมูลจริง ในขณะที่เส้นประแสดงการแจกแจงแบบปกติ



รูปที่ 2: ผลได้ตอบแทนรายวันของหุ้น APPLE co.




รูปที่ 3: การแจกแจงผลได้ตอบแทนรายวันของหุ้น APPLE co.




รูปที่ ?? แสดงอัตราแลกเปลี่ยนเงินบาทและดอลลาร์สหรัฐรายวันระหว่างปี 1997 ถึง 2011 เมื่อพิจารณาผลได้ตอบแทนในรูปที่ ?? จะเห็นได้ว่าช่วงหลังวิกฤติการณ์เงินตราปี 1997 และช่วงวิกฤติแฮมเบอร์เกอร์ ผลได้ตอบแทนมีความผันผวนมากกว่าช่วงอื่นๆ โดยที่แบบจำลองอธิบายความผันผวนจะถูกพิจารณาในบทที่ 3

รูปที่ 4: อัตราแลกเปลี่ยนบาทต่อดอลลาร์สหรัฐรายวัน




รูปที่ 5: อัตราแลกเปลี่ยนบาทต่อดอลลาร์สหรัฐรายวัน



รูปที่ ?? แสดงอัตราดอกเบี้ยพันธบัตรรัฐบาลอายุไม่เกิน 1 ปีและ 3 ปี พบว่าข้อมูลทั้งสองมีความเคลื่อนไหวไปในทิศทางเดียวกัน ซึ่งความสัมพันธ์ระหว่างอนุกรมเวลามากกว่า 1 อนุกรมเวลา จะถูกพิจารณาในบทที่ 5 และ 6

รูปที่ 6: อัตราดอกเบี้ยพันธบัตรรัฐบาล



# บทที่ 1

## อนุกรมเวลาทางการเงินและคุณลักษณะ

### 1.1 การคำนวณผลตอบแทน (return)

การศึกษาปริมาณทางการเงินส่วนใหญ่เรามักจะสนใจผลตอบแทน(return)ของหลักทรัพย์มากกว่าราคา (price) เนื่องจากผลตอบแทนของหลักทรัพย์มีความสมบูรณ์ (complete) และปราศจากผลของหน่วยวัด (Campbell, Lo and Mackinley (1997)) คุณสมบัติดังกล่าวใช้ในการประเมินโอกาสในการลงทุน เช่นการระบุว่าสินทรัพย์ที่เราถืออยู่ราคาเพิ่มขึ้น 10 บาทมิได้แสดงให้เห็นว่าผลตอบแทนนั้นดีหรือไม่ จำเป็นต้องระบุในรูปของผลตอบแทนเป็นร้อยละ นอกจากนี้อนุกรม (series) ของผลตอบแทนมีคุณสมบัติทางสถิติที่ดีกว่าอนุกรมของราคาในการดำเนินการทางสถิติซึ่งเราจะได้พิจารณาในเนื้อหาบทต่อไป

#### 1.1.1 นิยามของผลตอบแทนของหลักทรัพย์

สมมติให้การซื้อสินทรัพย์ เช่นหุ้น พันธบัตร หรือกองทุนรวม ณ เวลา  $t_0$  ด้วยราคา  $P_{t_0}$  บาท และขายสินทรัพย์ ณ เวลา  $t_1$  ด้วยราคา  $P_{t_1}$  บาท การเปลี่ยนแปลงของราคาสินทรัพย์ในรูปร้อยละสามารถคำนวณได้โดย

$$R(t_0, t_1) = \frac{P_{t_1} - P_{t_0}}{P_{t_0}} \quad (1.1)$$

เราเรียกระยะเวลาระหว่าง  $t_0$  และ  $t_1$  ว่าระยะเวลาการถือสินทรัพย์ (holding period) และสมการ (??) ว่าผลตอบแทนจากระยะเวลาการถือสินทรัพย์ โดยทั่วไปเราอาจจะกำหนดระยะเวลาการถือสินทรัพย์เป็นระยะเวลาใดๆก็ได้ เช่น ราย 15 นาที รายครึ่งเดือน อย่างไรก็ตามในการศึกษาวิชานี้เราจะสมมติให้ระยะเวลาการถือมีลักษณะเพิ่มขึ้นเช่นเดียวกับปฏิทิน เช่น รายนาทีย รายวัน รายเดือน หรือรายปี และในหัวข้อนี้เราจะสมมุติระยะเวลาการพิจารณาเป็นรายเดือน

กำหนดให้  $P_t$  เป็นราคาของสินทรัพย์ ณ เวลาสิ้นเดือน  $t$  และไม่มีการจ่ายเงินปันผล และกำหนดให้  $P_{t-1}$  เป็นราคาของสินทรัพย์ ณ เวลาสิ้นเดือน  $t - 1$  แล้ว ผลตอบแทนรวมอย่างง่าย

หนึ่งเดือน (one-month simple gross return) สามารถคำนวณได้ดังนี้

$$1 + R_t = \frac{P_t}{P_{t-1}} \quad (1.2)$$

และผลได้ตอบแทนสุทธิอย่างง่ายหนึ่งเดือน (one-month simple net return) หรือ ผลได้ตอบแทนอย่างง่ายหนึ่งเดือน (one-month simple return)

$$R_t = \frac{P_t}{P_{t-1}} - 1 = \frac{P_t - P_{t-1}}{P_{t-1}} \quad (1.3)$$

โดยที่ผลได้ตอบแทนอย่างง่ายหนึ่งเดือนอธิบายว่าหากเราลงทุนด้วยเงิน 1 บาทในเดือนที่  $t - 1$  เราจะได้รับเงินคืนมาทั้งหมดเท่าไร หรืออาจมองในแง่ของมูลค่าอนาคตของเงิน 1 บาท นอกจากนี้เราจะสังเกตเห็นได้ว่าราคาของสินทรัพย์ใดๆ จะต้องเป็นค่าที่ไม่เป็นลบ ดังนั้น ค่าต่ำสุดของ  $R_t$  คือ -1 หรือขาดทุน 100%

### Example 1

#### ตัวอย่างที่ 1.1 การคำนวณผลได้ตอบแทนอย่างง่าย

สมมติว่าเราพิจารณาผลตอบแทนจากการลงทุนในหุ้น APPLE โดยที่เราซื้อหุ้นเมื่อเดือน  $t - 1$  ด้วยราคา  $P_{t-1} = 190$  ดอลลาร์สหรัฐและขายไปในเดือนต่อไปด้วยราคา  $P_t = 200$  ดอลลาร์สหรัฐและไม่มีการจ่ายเงินปันผลในระหว่างที่ถือหุ้น ดังนั้นผลได้ตอบแทนสุทธิเท่ากับ

$$R_t = \frac{200 - 190}{190} = \frac{200}{190} - 1 = 1.0526 - 1 = 0.0526$$

และผลได้ตอบแทนอย่างง่ายรวมหนึ่งเดือนจะเท่ากับ

$$1 + R_t = \frac{200}{190} = 1.0526$$

ผลได้ตอบแทนสุทธิหนึ่งเดือนจะเท่ากับ 5.25 % ต่อเดือน หรือการลงทุนในหุ้น APPLE 1 ดอลลาร์สหรัฐจะได้เงินคืนพร้อมเงินต้น 1.0525 ดอลลาร์สหรัฐ

## ผลได้ตอบแทนหลายเดือน

ผลได้ตอบแทนจากการลงทุนสองเดือนสามารถคำนวณได้จากการเปลี่ยนแปลงของราคา ณ เดือน  $P_t$  และ  $P_{t-2}$  หรือผลได้ตอบแทนอย่างง่ายสองเดือน,  $R_t(2)$ , จะเท่ากับ

$$\begin{aligned} R_t(2) &= \frac{P_t - P_{t-2}}{P_{t-2}} = \frac{P_t}{P_{t-2}} - \frac{P_{t-2}}{P_{t-2}} \\ &= \frac{P_t}{P_{t-2}} - 1 \\ &= \frac{P_t}{P_{t-1}} \frac{P_{t-1}}{P_{t-2}} - 1 \\ &= (1 + R_t)(1 + R_{t-1}) - 1 \end{aligned} \quad (1.4)$$

และผลได้ตอบแทนรวมอย่างง่ายสองเดือนจะเท่ากับ

$$1 + R_t(2) = (1 + R_t)(1 + R_{t-1}) = 1 + R_t + R_{t-1} + R_t R_{t-1} \quad (1.5)$$

ซึ่งคือการรวมเรขาคณิต (geometric sum) ของผลได้ตอบแทนรวมอย่างง่ายหนึ่งเดือนของเดือน  $t$  และ  $t - 1$  ดังนั้นจะเห็นได้ว่า  $R_t(2)$  จะไม่เท่ากับผลรวมของ  $R_t$  และ  $R_{t-1}$

## ตัวอย่างที่ 1.2 การคำนวณผลได้ตอบแทนอย่างง่ายสองเดือน

พิจารณาต่อเนื่องจากตัวอย่าง 1.1 สมมติให้เราซื้อหุ้น ณ เดือนที่  $t-2$  ด้วยราคา  $P_{t-2} = 180$  ดอลลาร์และไม่มี การจ่ายเงินปันผล ผลได้ตอบแทนสุทธิสองเดือนจะเท่ากับ

$$R_t(2) = \frac{200 - 180}{180} = \frac{200}{180} - 1 = 0.1111$$

หรือ 11.11 % โดยที่ผลได้ตอบแทนหนึ่งเดือนของแต่ละเดือนจะเท่ากับ

$$\begin{aligned} 1 + R_{t-1} &= \frac{190 - 180}{180} = 1.0556 - 1 = 0.0556 \\ 1 + R_t &= \frac{200 - 190}{190} = 1.0526 - 1 = 0.0526 \end{aligned}$$

และผลได้ตอบแทนรวมสองเดือนจะเท่ากับ

$$1 + R_t(2) = 1.0556 \times 1.0526 = 1.1111$$

เราสามารถเขียนผลได้ตอบแทนในรูปทั่วไปได้ดังนี้ ผลได้ตอบแทนรวมอย่างง่าย  $k$  เดือน

(k-month simple gross return):

$$\begin{aligned} 1 + R_t(k) &= \frac{P_t}{P_{t-k}} = \frac{P_t}{P_{t-1}} \times \frac{P_{t-1}}{P_{t-2}} \times \cdots \times \frac{P_{t-k+1}}{P_{t-k}} \\ &= (1 + R_t)(1 + R_{t-1}) \cdots (1 + R_{t-k+1}) \end{aligned} \quad (1.6)$$

ซึ่งคือการรวมเรขาคณิตของผลได้ตอบแทนรวมอย่างง่ายรายเดือนของเดือนที่  $t$  ถึงเดือนที่  $t - k + 1$

### ผลได้ตอบแทนของกลุ่มสินทรัพย์ลงทุน (Portfolio)

หากเราลงทุนด้วยเงินจำนวน  $V$  บาทในสินทรัพย์สองตัวคือ  $A$  และ  $B$  โดยสัดส่วนการลงทุนในสินทรัพย์ทั้งสองคือ  $x_A$  และ  $x_B$  แล้วมูลค่าการลงทุนในสินทรัพย์แต่ละชนิดจะเท่ากับ  $Vx_A$  และ  $Vx_B$  โดยเราสมมติให้  $x_A + x_B = 1$  หากกำหนดให้ผลได้ตอบแทนอย่างง่ายหนึ่งเดือนของ  $A$  และ  $B$  คือ  $R_{A,t}$  และ  $R_{B,t}$  แล้ว มูลค่าของกลุ่มสินทรัพย์ลงทุนเมื่อสิ้นเดือนจะเท่ากับ

$$V \times [x_A(1 + R_{A,t}) + x_B(1 + R_{B,t})]$$

โดย  $x_A(1 + R_{A,t}) + x_B(1 + R_{B,t})$  คือผลได้ตอบแทนรวมของกลุ่มสินทรัพย์ลงทุน และอัตราผลตอบแทนจากการลงทุนจะเท่ากับ  $x_AR_{A,t} + x_BR_{B,t}$

### การปรับกรณีเงินปันผล

ถ้าสินทรัพย์มีการจ่ายเงินปันผลเท่ากับ  $D_t$  ในช่วงเวลาระหว่างเดือน  $t$  และ  $t - 1$  แล้วการคำนวณผลได้ตอบแทนสุทธิทั้งหมด (total net return) สามารถคำนวณได้ด้วยสมการต่อไปนี้

$$R_t^{total} = \frac{P_t + D_t - P_{t-1}}{P_{t-1}} = \frac{P_t - P_{t-1}}{P_{t-1}} + \frac{D_t}{P_{t-1}} \quad (1.7)$$

โดยที่ส่วนแรกเป็นกำไรส่วนเกินทุน (capital gain) และส่วนที่สองคืออัตราผลตอบแทนเงินปันผล (dividend yield)

### การแปลงผลได้ตอบแทนเป็นผลได้ตอบแทนรายปี

โดยทั่วไปเรามักจะรายงานผลได้ตอบแทนเป็นรายปีเพื่อใช้ในการตัดสินใจลงทุน ดังนั้นเราจำเป็นต้องมีการแปลงผลได้ตอบแทนที่มีความถี่อื่นๆเป็นรายปี สมมติว่าเราต้องการหาผลได้ตอบแทนหนึ่งปี ( $1 + R_A$ ) จากข้อมูลผลได้ตอบแทนรายเดือน ( $R_t, R_{t-1}, \dots, R_{t-11}$ ) เราสามารถคำนวณได้โดย

$$\begin{aligned} 1 + R_A &= 1 + R_t(12) = \frac{P_t}{P_{t-12}} = \frac{P_t}{P_{t-1}} \cdot \frac{P_{t-1}}{P_{t-2}} \cdots \frac{P_{t-11}}{P_{t-12}} \\ &= (1 + R_t)(1 + R_{t-1}) \cdots (1 + R_{t-11}) \end{aligned} \quad (1.8)$$

นอกจากนี้ หากเราทราบผลได้ตอบแทนรายหนึ่งเดือน และต้องการประมาณการผลได้ตอบแทนรายปีภายใต้ข้อสมมุติว่าผลได้ตอบแทนคงที่ทุกเดือนเท่ากับ  $R$  เราจะได้ผลได้ตอบแทนรายหนึ่งปีเท่ากับ

$$1 + R_A = 1 + R_t(12) = (1 + R)^{12}$$

ซึ่งก็คือผลได้ตอบแทนทบต้น 12 เดือนนั่นเอง

### 1.1.2 ผลได้ตอบแทนทบต้นอย่างต่อเนื่อง

ในหัวข้อนี้เราจะพิจารณาผลของการคิดผลตอบแทนทบต้น(compounding) สมมุติว่าธนาคารจ่ายดอกเบี้ยเงินฝากในอัตรา 10 % ต่อปี และมีเงินต้นเท่ากับ 100 บาท หากธนาคารจ่ายดอกเบี้ยหนึ่งครั้งเมื่อสิ้นปี มูลค่าสุทธิของเงินฝากดังกล่าวตอนปลายปีจะเท่ากับ  $100(1 + 0.1) = 110$  บาท หากธนาคารแบ่งการจ่ายดอกเบี้ยออกเป็นสองครั้งครั้งละ 5 % ทุกครั้งปี จะพบว่ามูลค่าสุทธิจะเท่ากับ  $100(1 + 0.1/2)^2 = 110.25$  บาทหลังจากสิ้นปี จากการพิจารณารูปแบบข้างต้น หากธนาคารจ่ายดอกเบี้ย  $m$  ครั้ง มูลค่าสุทธิ ณ สิ้นปีที่หนึ่งจะมีค่า  $100(1 + 0.1/m)^m$  และถ้าธนาคารจ่ายดอกเบี้ยทบต้นอย่างต่อเนื่อง (continuous compounding) มูลค่าสุทธิ ณ สิ้นปีที่หนึ่งจะเท่ากับ  $100(\exp(0.1)) = 100.517$

#### ผลได้ตอบแทนหนึ่งเดือน

กำหนดให้  $R_t$  เป็นผลได้ตอบแทนอย่างง่ายรายเดือนของการลงทุน เนื่องจากมูลค่าในอนาคตจะเท่ากับมูลค่าปัจจุบันคูณกับตัวคูณทบต้น ( $P_t = P_{t-1} \exp(r_t)$ ) เราสามารถคำนวณผลได้ตอบแทนทบต้นต่อเนื่องหนึ่งเดือน (one-month continuously compounding return) หรือผลได้ตอบแทนในรูปลอการิทึม(one-month log return) ซึ่งใช้สัญลักษณ์แทน  $r_t$  ได้โดย

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right) = \ln(P_t) - \ln(P_{t-1}) = p_t - p_{t-1} \quad (1.9)$$

โดยที่  $p_t = \ln(P_t)$

### ตัวอย่างที่ 1.3 การคำนวณผลได้ตอบแทนในรูปลอการิทึม

ใช้ข้อมูลจากตัวอย่างที่ 1.1 ผลได้ตอบแทนทบต้นอย่างต่อเนื่องหนึ่งเดือนหรือผลได้ตอบแทนในรูปลอการิทึมหนึ่งเดือนจะเท่ากับ

$$r_t = \ln(1.0526) = 0.0513$$

$$r_t = \ln(200) - \ln(190) = 5.2983 - 5.2470 = 0.0513$$



เนื่องจาก  $1 + R_t = \frac{P_t}{P_{t-1}}$  เราสามารถเขียนความสัมพันธ์ระหว่างผลได้ตอบแทนอย่างง่ายและผลได้ตอบแทนในรูปลอการิทึมได้เป็น

$$r_t = \ln(1 + R_t)$$

และเราสามารถคำนวณผลตอบแทนอย่างง่ายสุทธิได้จากผลได้ตอบแทนในรูปลอการิทึมโดย

$$R_t = \exp(r_t) - 1 \quad (1.10)$$

## ตัวอย่างที่ 1.4 ความสัมพันธ์ระหว่างผลได้ตอบแทน

ใช้ข้อมูลจากตัวอย่างที่ผ่านมา ผลได้ตอบแทนในรูปลอการิทึมหนึ่งเดือนเท่ากับ 5.13 % ดังนั้น

$$R_t = \exp(0.0513) - 1 = 0.0526$$

หากผลได้ตอบแทนมีค่าต่ำ เช่น ผลได้ตอบแทนรายชั่วโมงหรือรายวัน ผลได้ตอบแทนในรูปลอการิทึมและผลได้ตอบแทนอย่างง่ายจะมีค่าใกล้เคียงกัน อย่างไรก็ตาม การคำนวณผลได้ตอบแทนทั้งสองวิธีมีคุณสมบัติที่แตกต่างกัน ดังนี้ หากราคาของสินทรัพย์ลดลงเหลือศูนย์ผลได้ตอบแทนอย่างง่ายจะเท่ากับ  $-1$  ซึ่งเป็นขอบเขตต่ำสุดของผลได้ตอบแทนอย่างง่าย ในขณะที่ขอบเขตล่างของผลได้ตอบแทนในรูปลอการิทึมจะเท่ากับ  $-\infty$  ( $r_t = \ln(1 + R_t) = \ln(1 - 1) = \ln(0)$ ) ดังนั้นหากเราคำนวณผลได้ตอบแทนในรูปลอการิทึมมีค่าติดลบมากๆ จึงไม่ได้หมายความว่าเราสูญเสียเงินมากกว่าเงินต้น หากเราต้องการทราบอัตราผลตอบแทนเราจำเป็นต้องใช้สมการ (??) ในการคำนวณกลับไปเป็นผลได้ตอบแทนอย่างง่าย

เนื่องจากผลได้ตอบแทนในรูปลอการิทึมมีคุณสมบัติในการรวมกันที่ง่ายกว่าผลได้ตอบแทนอย่างง่าย ดังนั้นการวิเคราะห์เชิงสถิติหรือการสร้างแบบจำลองเรามักจะใช้ผลได้ตอบแทนในรูปลอการิทึม

## ผลได้ตอบแทนหลายเดือน

หากเราพิจารณาผลได้ตอบแทนในรูปลอการิทึมสองเดือนจะเท่ากับ

$$r_t(2) = \ln(1 + R_t(2)) = \ln\left(\frac{P_t}{P_{t-2}}\right) = p_t - p_{t-2}$$

นอกจากนี้เราสามารถหาความสัมพันธ์ระหว่างผลได้ตอบแทนในรูปลอการิทึมสองเดือนกับผลได้ตอบแทนในรูปลอการิทึมหนึ่งเดือนได้โดย

$$\begin{aligned} r_t(2) &= \ln\left(\frac{P_t}{P_{t-2}}\right) \\ &= \ln\left(\frac{P_t}{P_{t-1}} \frac{P_{t-1}}{P_{t-2}}\right) \\ &= \ln\left(\frac{P_t}{P_{t-1}}\right) + \ln\left(\frac{P_{t-1}}{P_{t-2}}\right) \\ &= r_t + r_{t-1} \end{aligned}$$

ดังนั้นผลได้ตอบแทนในรูปลอการิทึมสองเดือนก็จะคือผลรวมของผลได้ตอบแทนในรูปลอการิทึมรายเดือนของสองเดือนมารวมกันนั่นเอง ซึ่งแตกต่างจากในกรณีของผลได้ตอบแทนอย่างง่ายที่ต้องใช้ผลรวมเรขาคณิต

### ตัวอย่างที่ 1.5 การคำนวณผลได้ตอบแทนหลายเดือน

จากข้อมูลในตัวอย่างที่ 1.2 เราสามารถคำนวณผลได้ตอบแทนในรูปลอการิทึมสองเดือนได้สองวิธีคือ

$$r_t(2) = \ln(200) - \ln(180) = 5.2983 - 5.1930 = 0.1053$$

หรือรวมผลได้ตอบแทนในรูปลอการิทึมหนึ่งเดือนของแต่ละเดือนเข้าด้วยกัน โดย  $r_t = \ln(200) - \ln(190) = 0.0513$  และ  $r_{t-1} = \ln(190) - \ln(180) = 0.0540$  ดังนั้น

$$r_t(2) = 0.0513 + 0.0540 = 0.1053$$

ในกรณีทั่วไป ผลได้ตอบแทนในรูปลอการิทึม  $k$  เดือนสามารถคำนวณได้จาก

$$\begin{aligned} r_t(k) &= \ln(1 + R_t(k)) = \ln\left(\frac{P_t}{P_{t-k}}\right) = p_t - p_{t-k} \\ &= \sum_{j=0}^{k-1} r_{t-j} \end{aligned}$$

ในขณะที่ผลได้ตอบแทนในรูปลอการิทึมของกลุ่มหลักทรัพย์จะเท่ากับ

$$r_{p,t} = \ln(1 + R_{p,t}) = \ln\left(1 + \sum_{i=1}^n x_i R_{i,t}\right) \neq \sum_{i=1}^n x_i r_{i,t} \quad (1.11)$$

โดยผลได้ตอบแทนในรูปลอการิทึมของกลุ่มหลักทรัพย์จะไม่เท่ากับค่าเฉลี่ยถ่วงน้ำหนักของผลได้ตอบแทนในรูปลอการิทึมของสินทรัพย์

## การคำนวณผลได้ตอบแทนด้วยโปรแกรม R

เลือกโฟลเดอร์ที่จะใช้เก็บข้อมูล เราเรียกว่า work directory (ในกรณีนี้คือ D:/Teaching/EC435/R/) พร้อมกับคัดลอก (copy) ไฟล์ aapl-m.csv ซึ่งเป็นข้อมูลราคาของหุ้น APPLE รายเดือน ตั้งแต่ มกราคม 2010 ถึงตุลาคม 2012 จาก Moodle ไปยังโฟลเดอร์ดังกล่าว หลังจากนั้นเปิดโปรแกรม RStudio ขึ้นมาพร้อมนำเข้าข้อมูลตามคำสั่งต่อไปนี้

```
1 > setwd("D:/Teaching/EC435/R/")
2 > aapl<-read.csv("aapl-m.csv", header=T)
3 > head(aapl)
4   Date Price
5 1 4/1/10 190.37
6 2 1/2/10 202.82
7 3 1/3/10 232.93
8 4 1/4/10 258.79
9 5 3/5/10 254.62
10 6 1/6/10 249.32
```

การคำนวณผลได้ตอบแทนอย่างง่ายสุทธิโดยการกำหนดเวกเตอร์  $P_t$  และ  $P_{t-1}$  แล้วคำนวณตามสมการ ??

```
1 > n=nrow(aapl)
2 > aapl$ret=aapl$Price[2:n]/aapl$Price[2:n-1]-1
3 > head(aapl$ret)
4 [1] 0.06539896 0.14845676 0.11102048 -0.01611345 -0.02081533 0.02274186
```

การคำนวณผลได้ตอบแทนในรูปลอการิทึมจากสมการ ??

```
1 > aapl.lret=diff(log(aapl$Price))
2 > head(aapl.lret)
3 [1] 0.06334934 0.13841909 0.10527894 -0.01624468 -0.02103503 0.02248712
```

## 1.2 แบบจำลองสำหรับข้อมูลอนุกรมเวลา

เป้าหมายหลักของการวิเคราะห์ข้อมูลอนุกรมเวลาคือการสร้างแบบจำลองทางคณิตศาสตร์เพื่ออธิบายคุณลักษณะของข้อมูลตัวอย่าง เช่น ข้อมูลผลได้ตอบแทนของหุ้น เพื่อที่จะให้เราสามารถสร้างแบบจำลองที่จะอธิบายข้อมูลได้ เราจะสมมุติว่าอนุกรมเวลาสามารถนิยามเป็นตัวแปรสุ่ม (random variables) ที่มีการจัดลำดับตามเวลา เช่น ลำดับของข้อมูล  $y_1, y_2, y_3, \dots$  โดยที่  $y_1$  เป็นค่าของอนุกรมที่คาบเวลาที่ 1,  $y_2$  เป็นค่าของอนุกรมที่คาบเวลาที่ 2 ตามลำดับ โดยทั่วไป เราจะเรียกกลุ่มของตัวแปรสุ่มที่มีการจัดลำดับตามเวลา  $Y_t = \{y_t, t = 0, \pm 1, \pm 2, \dots\}$  ว่ากระบวนการสโตแคสติก (Stochastic process) ในวิชานี้เราจะเน้นการวิเคราะห์ข้อมูลอนุกรมเวลาด้วยแบบจำลองเชิงเส้นตรง (Linear model) หมายถึง  $Y_t$  มีความสัมพันธ์ขึ้นอยู่กับค่าในอดีตในลักษณะเป็นเส้นตรง

### 1.2.1 การแจกแจงของอนุกรมเวลา (Distribution of time series)

ตัวแปรสุ่ม  $Y_t$  คือฟังก์ชันที่ใช้อธิบายค่าของเหตุการณ์ที่จะเกิดขึ้นในอนาคตโดยที่เรารู้ค่าทั้งหมดที่จะเป็นไปได้แต่ไม่รู้ว่าเกิดอะไรขึ้นแน่นอน เช่น ราคาของหลักทรัพย์( $P$ ) เราไม่ทราบว่าราคาในเดือนหน้าจะเป็นเท่าไรแน่นอน แต่เราคิดว่าราคาจะต้องเป็นบวกและไม่สูงมากนัก ดังนั้น  $P$  จึงเป็นตัวแปรสุ่มมีค่าระหว่าง  $[0, M]$  โดยที่  $M$  เป็นค่าที่ไม่สูงมากนัก คำถามอีกคำถามหนึ่งคือตัวแปรสุ่มจะมีการแจกแจงอย่างไร โดยที่หนึ่งในทางเลือกคือการแจกแจงแบบ log-normal

นอกจากนี้ เราอาจสนใจว่าการลงทุนของเราในหนึ่งเดือนข้างหน้าจะมีผลได้ผลตอบแทน( $R_t$ )เป็นอย่างไร ดังนั้น  $R_t$  ก็จะเป็นตัวแปรสุ่มเนื่องจากเราไม่ทราบว่าผลได้ผลตอบแทนในคาบข้างหน้าจะเป็นอย่างไร ทราบเพียงว่าค่าดังกล่าวเป็นได้ทั้งบวกและลบ โดยที่ลบ(ขาดทุน)ได้อย่างมากไม่เกิน 100% การแจกแจงที่ใช้ประมาณค่าสำหรับผลได้ตอบแทนอย่างง่ายรายเดือนที่ดีคือการแจกแจงแบบปกติ

บางครั้งนักลงทุนอาจจะสนใจว่าราคาจะเปลี่ยนแปลงอย่างไร โดยอาจจะสนใจกรณีที่ราคาปรับตัวขึ้นแทนด้วย 0 และกรณีที่ราคาคงที่หรือลดลงแทนด้วย 1 ในกรณีนี้ปริภูมิตัวอย่าง (sample space) ของตัวแปรสุ่มวิฤต (discrete random variable)

**นิยาม 1.1.** ตัวแปรสุ่มวิฤต  $Y$  คือตัวแปรสุ่มที่มีปริภูมิตัวอย่างเซตที่มีค่าจำกัด  $S_Y = \{y_1, y_2, \dots, y_n\}$  หรือมีค่าเป็นอนันต์ที่นับได้  $S_Y = \{y_1, y_2, \dots\}$

ฟังก์ชันความหนาแน่นของความน่าจะเป็น (probability density function: pdf) ของตัวแปรสุ่มวิฤตสามารถเขียนแทนด้วย  $p(y)$  จะเป็นฟังก์ชัน  $p(y) = Pr(Y = y)$  ความน่าจะเป็นที่ตัวแปรสุ่ม  $Y$  เท่ากับค่า  $y$  โดย pdf จะต้องมีคุณสมบัติคือ (1)  $p(y) \geq 0$  สำหรับทุกค่า  $y \in S_y$  (2)  $p(y) = 0$  สำหรับทุกค่า  $y \notin S_y$  และ (3)  $\sum_{y \in S_y} p(y) = 1$

#### ตัวอย่างที่ 1.6 การแจกแจงความน่าจะเป็น

สมมติว่าผลได้ตอบแทนจากหุ้น A มีค่าที่เป็นไปได้และความน่าจะเป็นดังนี้ ตัวอย่างดัง

$S_Y$	$p(y) = Pr(Y = y)$
-0.30	0.05
0.0	0.20
0.10	0.50
0.20	0.20
0.50	0.05

กล่าวพิจารณาค่าน่าจะเป็นไปได้ 5 ค่าของผลได้ตอบแทนของหุ้น A เราสามารถทำนายค่าที่เป็นไปได้ของแต่ละเหตุการณ์ได้

ตัวอย่างของการแจกแจงแบบ discrete อื่นๆ ได้แก่ Bernoulli และ Binomial

**นิยาม 1.2.** ตัวแปรสุ่มแบบต่อเนื่อง  $Y$  จะมีค่าเป็นเท่าใดก็ได้บนเส้นจำนวนจริง ดังนั้น  $S_Y = \{y : y \in \mathbb{R}\}$

ฟังก์ชันความหนาแน่นของความน่าจะเป็น  $pdf$  ของตัวแปรสุ่มแบบต่อเนื่อง  $Y$  จะเป็นฟังก์ชันที่ไม่เป็นค่าลบ  $f$  นิยามบนเส้นจำนวนจริงโดยที่สำหรับช่วง  $A$  ใดๆ

$$Pr(Y \in A) = \int_A f(y)dy$$

ดังนั้น  $Pr(Y \in A)$  คือพื้นที่ใต้กราฟความน่าจะเป็นตลอดช่วง  $A$  โดยที่  $pdf$   $f(y)$  จะมีคุณสมบัติดังนี้ (1)  $f(y) \geq 0$  และ (2)  $\int_{-\infty}^{\infty} f(y)dy = 1$

**Example 2** ตัวอย่างเช่นกราฟรูปประฆังรูปที่ ?? เป็น  $pdf$  ฟังก์ชัน โดยที่พื้นที่ใต้กราฟระหว่าง  $y = -2$  ถึง  $y = 1$  จะแสดงถึง  $Pr(-2 \leq Y < 1)$

ตัวอย่างของการแจกแจงความน่าจะเป็นของตัวแปรสุ่มแบบต่อเนื่องคือการแจกแจงปกติมาตรฐาน (standard normal distribution)

**นิยาม 1.3.** ฟังก์ชันการแจกแจงสะสม (cumulative distribution function:  $cdf$ ) ของตัวแปรสุ่ม  $Y$  (ไม่ว่าจะเป็นตัวแปรสุ่มวิฤตหรือต่อเนื่อง) จะมีสัญลักษณ์เป็น  $F_Y$  ซึ่งแสดงค่าความน่าจะเป็นที่  $Y$  ใดๆจะมีค่าน้อยกว่าหรือเท่ากับ  $y$

$$F_Y(y) = P(Y \leq y), \quad -\infty \leq y \leq \infty$$

ฟังก์ชันการแจกแจงสะสม ( $cdf$ ) จะมีคุณสมบัติดังนี้


1. ถ้า  $y_1 < y_2$  แล้ว  $F_Y(y_1) \leq F_Y(y_2)$
2.  $F_Y(-\infty) = 0$  และ  $F_Y(\infty) = 1$
3.  $Pr(Y > y) = 1 - F_Y(y)$
4.  $Pr(y_1 < Y \leq y_2) = F_Y(y_2) - F_Y(y_1)$
5.  $\frac{\partial F_Y(y)}{\partial y} = f_Y(y)$  ถ้า  $Y$  เป็นตัวแปรสุ่มต่อเนื่องและ  $F_Y(y)$  เป็นฟังก์ชันต่อเนื่องและหาอนุพันธ์ได้

**ควอนไทล์ของการแจกแจงความน่าจะเป็นของตัวแปรสุ่ม**

หากเราพิจารณาตัวแปรสุ่ม  $Y$  ที่มีฟังก์ชันการแจกแจงสะสม  $F_Y(y)$  หากค่า  $0 \leq \alpha \leq 1$  แล้วค่าควอนไทล์ที่  $100\alpha\%$  ของการแจกแจง  $Y$  คือค่า  $q_\alpha$  ที่ตรงกับเงื่อนไข

$$F_Y(q_\alpha) = Pr(Y \leq q_\alpha) = \alpha$$

รูปที่ 1.1: ฟังก์ชัน pdf ของการแจกแจงต่อเนื่อง



ตัวอย่างเช่น ควอนไทล์ที่ 5% ของ  $Y$  เขียนแทนด้วย  $q_{0.05}$  จะเท่ากับค่าที่ทำให้  $F_Y(q_{0.05}) = Pr(Y \leq q_{0.05}) = 0.05$  และถ้า  $F_Y$  สามารถหาฟังก์ชันผกผันได้ ดังนั้น  $q_\alpha = F_Y^{-1}(\alpha)$

### ตัวอย่างที่ 1.7 การหาความน่าจะเป็นจากฟังก์ชันแจกแจงความถี่

กำหนดให้  $Y \sim N(0, 1)$  ค่าควอนไทล์ของการแจกแจงแบบปกติมาตรฐานจะเท่ากับ

$$q_\alpha = \Phi^{-1}(\alpha) \quad (1.12)$$

โดยที่  $\Phi^{-1}$  คือฟังก์ชันผกผันของฟังก์ชันการแจกแจงสะสม  $\Phi$  ซึ่งค่าควอนไทล์จะเป็นค่าที่แสดงในตารางสถิติในหนังสือเกือบทุกเล่ม โดยค่าดังกล่าว

$$q_{0.005} = \Phi^{-1}(0.005) = -2.58, q_{0.01} = \Phi^{-1}(0.01) = -2.33,$$

$$q_{0.025} = \Phi^{-1}(0.025) = -1.96, q_{0.05} = \Phi^{-1}(0.05) = -1.645$$

โดยทั่วไปค่าควอนไทล์ของการแจกแจงปกติมาตรฐานมักจะแทนด้วย  $Z_\alpha$  อย่างไรก็ตามหนังสือบางเล่มอาจจะเขียนสัญลักษณ์ดังกล่าวแทนค่าควอนไทล์นับจากด้านบน (upper quantile) โดยที่ค่าควอนไทล์นับจากด้านบน 5% จะเท่ากับค่าควอนไทล์ 95 % เป็นต้น

### การคำนวณพื้นที่ใต้กราฟด้วย R

ใน โปรแกรม R เราสามารถคำนวณพื้นที่ใต้กราฟ pdf หรือ  $Pr(Y < z)$  ด้วยคำสั่ง `pnorm(z)` โดยที่  $Pr(Y < -2)$  คำนวณได้โดย `pnorm(-2)` นอกจากนี้เราสามารถหาค่าควอนไทล์ที่  $100\alpha\%$  ได้ด้วยคำสั่ง `qnorm( $\alpha$ )` เช่น `qnorm(0.01)=-2.326`

### 1.2.2 คุณลักษณะเรีองรูปร่างของการแจกแจงความน่าจะเป็น

ในการพิจารณาข้อมูลทางการเงิน เราสนใจเกี่ยวกับรูปร่างของการแจกแจงความน่าจะเป็นของตัวแปรสุ่มที่เราสนใจ เช่น เราต้องการที่จะทราบว่าค่ากลางของการแจกแจงอยู่ที่ตรงไหน หรือการแจกแจงมีการแผ่ขยายไปข้างๆอย่างไร นอกจากนี้เรายังสนใจว่าการแจกแจงมีความเป็นสมมาตรหรือไม่ มีรูปร่างที่เบ้ไปทางซ้ายหรือทางขวา หรือความน่าจะเป็นที่จะเกิดเหตุการณ์ที่ห่างจากค่ากลางมากๆ (extreme value) โดยเฉพาะค่าที่ติดลบมากๆ จากสิ่งที่เราสนใจที่ได้กล่าวมาแล้ว คุณลักษณะด้านรูปร่างของการแจกแจงความน่าจะเป็นใดๆจะวัดได้ด้วยคุณลักษณะ 4 ประการ

1. ค่าคาดหวัง (expected value) หรือค่าเฉลี่ยเป็นการวัดค่ากลางของการแจกแจง
2. ความแปรปรวนและค่าเบี่ยงเบนมาตรฐานวัดการแผ่จากค่ากลาง
3. ความเบ้ (skewness) วัดความสมมาตรรอบๆค่ากลาง
4. ค่าความโด่ง (kurtosis) วัดความอ้วนของหาง

**นิยาม 1.4. ฟังก์ชันค่าคาดหวัง (mean function) ของตัวแปรสุ่ม  $Y$  ใดๆ ใช้สัญลักษณ์  $E(Y)$  สามารถคำนวณได้ดังนี้ ในกรณีที่  $Y$  เป็นตัวแปรสุ่มวิฤต ค่าคาดหวังจะเท่ากับ**

$$\mu_Y = E(Y) = \sum_{y \in S_Y} y \times P(Y = y) \quad (1.13)$$

หรือในกรณีตัวแปรสุ่มต่อเนื่อง ค่าคาดหวังจะเท่ากับ

$$\mu_Y = E(Y) = \int_{-\infty}^{\infty} y f(y) dy \quad (1.14)$$

โดยที่  $E$  คือสัญลักษณ์แทนค่าคาดหวัง (Expected value)

**ค่าคาดหวังของฟังก์ชันของตัวแปรสุ่ม**

ลักษณะเฉพาะอื่นด้านรูปร่างของการแจกแจงของตัวแปรสุ่ม  $Y$  มีพื้นฐานจากค่าคาดหวังของฟังก์ชันของ  $Y$  เช่นสมมติให้  $g(Y)$  เป็นฟังก์ชันของ  $Y$  ถ้า  $Y$  เป็นตัวแปรสุ่มแบบ discrete แล้ว

$$E[g(Y)] = \sum_{y \in S_Y} g(y)P(Y = y)$$

และถ้า  $Y$  เป็นตัวแปรสุ่มแบบต่อเนื่องด้วย pdf  $f(y)$  แล้ว

$$E[g(Y)] = \int_{-\infty}^{\infty} g(y)f(y)dy$$

## ค่าความแปรปรวนและค่าเบี่ยงเบนมาตรฐาน

ค่าแปรปรวนของตัวแปรสุ่ม  $Y$  เขียนแทนด้วย  $Var(Y)$  หรือ  $\sigma_Y^2$  วัดการแผ่ของการแจกแจงจากค่าเฉลี่ย โดยที่ค่าแปรปรวนสามารถนิยามได้โดย

$$\sigma_Y^2 = Var(Y) = E[(Y - \mu_Y)^2] \quad (1.15)$$

นอกจากนี้ยังมีอีกสูตรหนึ่งที่เรามักใช้บ่อยในการคำนวณค่าความแปรปรวน

$$\sigma_Y^2 = Var(Y) = E[Y^2] - \mu_Y^2 \quad (1.16)$$

เนื่องจากหน่วยวัดของค่าความแปรปรวนมีหน่วยที่แตกต่างจากตัวแปรสุ่ม  $Y$  ดังนั้น เรามักจะพิจารณาค่าเบี่ยงเบนมาตรฐานเขียนแทนด้วย  $sd(Y)$  หรือ  $\sigma_Y$  ซึ่งเท่ากับค่ารากที่สองของค่าความแปรปรวน ( $\sqrt{\sigma_Y^2}$ )

## ค่าความเบ้

ค่าความเบ้ซึ่งสามารถเขียนแทนด้วย  $(S(Y))$  วัดความสมมาตรรอบๆค่ากลาง สามารถทำได้โดย

$$S(Y) = \frac{E[(Y - \mu_Y)^3]}{\sigma_Y^3} \quad (1.17)$$

โดยที่หากค่าความเบ้เป็นศูนย์แสดงว่าการแจกแจงมีความสมมาตร ถ้าค่าความเบ้เป็นบวกแสดงว่าข้อมูลถูกดึงไปด้านขวาของการแจกแจง(หางไปทางขวา) แต่หากค่าความเบ้เป็นลบแสดงว่าข้อมูลถูกดึงไปทางซ้าย(หางไปทางซ้าย)ในแง่ของการลงทุนหากผลได้ตอบแทนถูกดึงไปด้านซ้าย แสดงว่ามีโอกาสที่เราจะได้ผลลัพธ์ที่สุดโต่งค่อนข้างมาก แต่ถ้าหางไปทางขวาโอกาสที่จะเกิดเหตุการณ์ร้ายที่รุนแรงค่อนข้างน้อย ตัวแปรสุ่มที่มีการแจกแจงแบบปกติจะมีค่าความเบ้เป็นศูนย์ เนื่องจากมีการแจกแจงที่เป็นสมมาตร

## ค่าความโด่ง


ค่าความโด่งใช้วัดความหนาของหางของการแจกแจงซึ่งสามารถเขียนแทนได้ด้วย  $K(Y)$  และสามารถคำนวณได้จาก

$$K(Y) = \frac{E[(Y - \mu_Y)^4]}{\sigma_Y^4} \quad (1.18)$$

เนื่องจากค่าความโด่งเป็นการหาความแตกต่างจากค่ากลางโดยการยกกำลัง 4 ดังนั้นค่าที่ห่างจากจุดศูนย์กลางมากๆจะทำให้ค่าถ่วงน้ำหนักสูงขึ้น และค่าความโด่งสูง ในทางตรงข้ามหากค่าความโด่งต่ำแสดงว่าข้อมูลกระจุกตัวอยู่ตรงกลางและมีโอกาสน้อยที่จะพบข้อมูลที่มีค่าสุดโต่ง ค่าความโด่งของตัวแปรสุ่มที่มีการแจกแจงปกติเท่ากับ 3 โดยเรามักใช้ค่าความโด่งดังกล่าวเป็นมาตรฐานความหนาของหาง หากการแจกแจงใดมีค่าความโด่งมากกว่า 3 แสดงว่าการแจกแจงนั้นมีหางที่



รูปที่ 1.2: ฟังก์ชันความหนาแน่นของความน่าจะเป็นและการแจกแจงสะสมของการแจกแจงปกติมาตรฐาน




อ้วนกว่า (thicker tail) การแจกแจงแบบปกติ แต่ถ้การแจกแจงมีความความโด่งน้อยกว่า 3 แสดงว่าการแจกแจงมีหางที่พอมกว่าการแจกแจงปกติ

บางครั้งเราแสดงค่าความ โด่ง ในรูปความโด่งเปรียบเทียบกับกรแจกแจงปกติ โดยค่าดังกล่าวเรียกว่าความ โด่ง ส่วนเกิน (excess kurtosis) โดย  $\text{excess } K(Y) = K(Y) - 3$  ถ้าค่าความโด่งส่วนเกินเท่ากับศูนย์แสดงว่าตัวแปรสุ่มมีค่าความโด่งเท่ากับการแจกแจงปกติ ถ้าค่าความโด่งส่วนเกินเป็นบวกแสดงว่าการแจกแจงนั้นมีหางที่อ้วนกว่าการแจกแจงแบบปกติ

ค่าความโด่งของการแจกแจงปกติเป็นเกณฑ์มาตรฐานสำหรับความหนาของหางของการแจกแจงที่เป็นสมมาตร ตัวอย่างการแจกแจงอื่นที่มีลักษณะสมมาตรและมีหางที่อ้วนกว่าการแจกแจงแบบปกติคือ การแจกแจงแบบที (Student's t) โดยที่ถ้า  $Y$  มีการแจกแจงแบบทีด้วยองศาเสรี (degree of freedom)  $v$  จะมีค่าเฉลี่ยเท่ากับ 0, ค่าความแปรปรวนเท่ากับ  $v/v - 2$  โดยที่  $v > 2$ , ค่าความเบ้เท่ากับ 0, และค่าความโด่งเท่ากับ  $\frac{6}{(v-4)} - 4$  โดยที่  $v > 4$  เราจะเห็นได้ว่าองศาเสรี  $v$  เป็นตัวกำหนดการแผ่และความหนาของหางของการแจกแจง ถ้าองศาเสรี  $v$  เข้าใกล้ 4 การแจกแจงจะมีหางที่อ้วนมาก แต่ถ้าองศาเสรี  $v$  มีค่าเข้าใกล้อนันต์ ฟังก์ชันการแจกแจง(pdf)ของการแจกแจงที่จะมีลักษณะเข้าใกล้ฟังก์ชันการแจกแจง(pdf)ของการแจกแจงปกติ การแจกแจงความน่าจะเป็นแบบทีสำหรับค่าองศาเสรีที่ต่างกันสามารถดูไปจากรูปที่ ??

รูปที่ 1.4: การแจกแจงแบบที



### ตัวประมาณค่า(estimator) ของค่าคุณลักษณะของการแจกแจง

ในการประยุกต์เราสามารถประมาณค่าเฉลี่ย ค่าความแปรปรวน ค่าความเบ้และค่าความโด่งได้ด้วยข้อมูลจากกลุ่มตัวอย่าง สมมติให้เราสุ่มตัวอย่าง  $y_1, \dots, y_T$  ซึ่งมีขนาดเท่ากับ  $T$  ค่าเฉลี่ยของตัวอย่าง (sample mean) สามารถคำนวณได้โดย

$$\hat{\mu}_Y = \frac{1}{T} \sum_{t=1}^T y_t \quad (1.19)$$

ค่าความแปรปรวนของตัวอย่างสามารถคำนวณได้โดย

$$\hat{\sigma}_Y^2 = \frac{1}{T-1} \sum_{t=1}^T (y_t - \hat{\mu}_Y)^2 \quad (1.20)$$

ค่าความเบ้ของตัวอย่าง (sample skewness) สามารถคำนวณได้โดย

$$\hat{S}(Y) = \frac{1}{(T-1)\hat{\sigma}_Y^3} \sum_{t=1}^T (y_t - \hat{\mu}_Y)^3 \quad (1.21)$$

และค่าความโด่งของตัวอย่าง (sample kurtosis) สามารถคำนวณได้โดย

$$\hat{K}(Y) = \frac{1}{(T-1)\hat{\sigma}_Y^4} \sum_{t=1}^T (y_t - \hat{\mu}_Y)^4 \quad (1.22)$$

### การทดสอบสมมติฐาน

ภายใต้ข้อสมมุติที่ว่า  $Y_t$  มีการแจกแจงแบบปกติ  $N(0, \sigma^2)$  ค่าเฉลี่ยของตัวอย่างจะมีการแจกแจงแบบปกติ  $N(0, \frac{\sigma^2}{T})$  ดังนั้นในการทดสอบสมมติฐานที่ว่าค่าเฉลี่ยของประชากรมีค่าเท่ากับศูนย์หรือไม่ เราสามารถทำได้โดยใช้ค่าสถิติสัดส่วน  $t$  (t-ratio)

$$t = \frac{\hat{\mu}_Y}{\hat{\sigma}_Y/\sqrt{T}}$$

โดยเราจะปฏิเสธสมมติฐานหลักด้วยระดับนัยสำคัญ(significant level)  $\alpha$  หรือความเชื่อมั่น  $(1 - \alpha/2)100\%$  ถ้า  $|t| > Z_{1-\alpha/2}$  โดยที่  $Z_{1-\alpha/2}$  คือค่าควอนไทล์ที่  $100(1 - \alpha/2)\%$  ของการแจกแจงปกติมาตรฐาน (standard normal)

ค่าความเบ้ของตัวอย่าง ( $\hat{S}(Y)$ ) จะมีการแจกแจงเมื่อกลุ่มตัวอย่างใหญ่เข้าใกล้การแจกแจงปกติ โดยมีค่าเฉลี่ยเท่ากับศูนย์และค่าความแปรปรวนเท่ากับ  $6/T$  ส่วนค่าความโด่งส่วนเกินของตัวอย่าง ( $\hat{K}(Y) - 3$ ) จะมีการแจกแจงเมื่อกลุ่มตัวอย่างใหญ่เข้าใกล้การแจกแจงปกติ โดยมีค่าเฉลี่ยเท่ากับศูนย์และค่าความแปรปรวนเท่ากับ  $24/T$  ซึ่งคุณสมบัติทั้งสองนำมาใช้ในการทดสอบว่าตัว-

แปรสุ่ม  $Y_t$  มีการแจกแจงแบบปกติหรือไม่ โดยหากตัวแปรสุ่มมีการแจกแจงแบบปกติค่าความเบ้และความโด่งส่วนเกินจะต้องเท่ากับศูนย์

กำหนดให้เรามีข้อมูลผลได้ตอบแทน  $y_1, \dots, y_T$  และต้องการทดสอบความเบ้ว่าเท่ากับศูนย์หรือไม่ เราจะตั้งสมมติฐานหลักว่า  $H_0 : S(Y) = 0$  และสมมติฐานทางเลือกว่า  $H_1 : S(Y) \neq 0$  โดยมีตัวสถิติสัดส่วน  $t$  (t-ratio)

$$t = \frac{\hat{S}(Y)}{\sqrt{6/T}}$$

โดยเราจะปฏิเสธสมมติฐานหลักที่ระดับนัยสำคัญ  $\alpha$  ถ้า  $|t| > Z_{1-\alpha/2}$  โดยที่  $Z_{1-\alpha/2}$  คือค่าควอนไทล์ที่  $100(1 - \alpha/2)\%$  ของการแจกแจงปกติมาตรฐาน หรือเราอาจจะใช้การคำนวณค่าพี (p-value)

เราสามารถทดสอบค่าความโด่งส่วนเกินได้ด้วยการตั้งสมมติฐานว่า  $H_0 : \hat{K}(Y) - 3 = 0$  และ  $H_1 : \hat{K}(Y) - 3 \neq 0$  และมีตัวสถิติคือ

$$t = \frac{\hat{K}(Y) - 3}{\sqrt{24/T}}$$

โดยเราจะปฏิเสธสมมติฐานหลักที่ระดับนัยสำคัญ  $\alpha$  ถ้า  $|t| > Z_{100-\alpha/2}$  โดยที่  $Z_{100-\alpha/2}$  คือค่าควอนไทล์ที่  $100(1 - \alpha/2)\%$  ของการแจกแจงปกติมาตรฐาน

Jarque and Bera (1987) ได้รวมการทดสอบของค่าสถิติทั้งสองเข้าด้วยกันและเสนอตัวสถิติ

$$JB = \frac{\hat{S}^2(Y)}{6/T} + \frac{[\hat{K}(Y) - 3]^2}{24/T}$$

ซึ่งมีการแจกแจงเมื่อกลุ่มตัวอย่างใหญ่เข้าใกล้ไคกำลังสอง ( $\chi^2$ ) ที่มีองศาอิสระเท่ากับ 2 โดยเราจะปฏิเสธสมมติฐานหลักที่ระดับนัยสำคัญ  $\alpha$  ถ้า  $JB > \chi^2_{(1-\alpha), df=2}$  โดยที่  $\chi^2_{(1-\alpha), df=2}$  คือค่าควอนไทล์ที่  $100(1 - \alpha)\%$  ของการแจกแจงไคกำลังสองที่มีองศาอิสระเท่ากับ 2

นอกจากนี้เรายังมีวิธีการที่เป็นที่นิยมอันหนึ่งคือการวาดแผนภาพ Normal quantile-quantile หรือเรียกย่อๆว่า QQ plot โดยเป็นการวาดจุด (scatterplot) ค่าที่เรียงจากต่ำ (quantile) ของอนุกรมเวลา  $y_t$  กับค่าที่เรียงจากต่ำของตัวแปรสุ่มที่มีการแจกแจงแบบปกติ ดังนั้นถ้าจุดดังกล่าวอยู่ใกล้กับเส้น 45 องศาแสดงว่ากระบวนการ  $y_t$  มีการแจกแจงแบบปกติ

### 1.2.3 ตัวอย่างการ คำนวณค่าสถิติและการ ทดสอบ สมมติฐาน จากผลได้ตอบแทนหุ้น PTT

ตัวอย่างนี้ใช้ข้อมูลผลได้ตอบแทนจากภาคผนวก A [ptt.Rdata] ซึ่งเราได้คำนวณค่าผลได้ตอบแทนในรูปล็อกของหุ้น PTT(ptt\$1ret) ซึ่งในหัวข้อนี้เราจะคำนวณค่าสถิติเบื้องต้นของ ptt\$1ret โดยใช้ package fBasics โดยใช้ฟังก์ชัน basicStats

```

1 > library(fBasics)
2 > basicStats(ptt$lret)
3           X..ptt.lret
4 nobs      2089.000000
5 NAS       1.000000
6 Minimum   -0.185899
7 Maximum    0.149532
8 1. Quartile -0.009569
9 3. Quartile  0.010989
10 Mean      0.000774
11 Median    0.000000
12 Sum       1.617043
13 SE Mean   0.000490
14 LCL Mean  -0.000187
15 UCL Mean   0.001736
16 Variance   0.000502
17 Stdev      0.022405
18 Skewness   -0.068862
19 Kurtosis   6.228529

```

จะเห็นได้ว่าค่าเฉลี่ยของผลได้ตอบแทนในรูปล็อกมีค่าเท่ากับ 0.00077 หรือ 0.077 % ต่อวัน ค่าเบี่ยงเบนมาตรฐานเท่ากับ 0.0224 ค่าความเบ้ของตัวอย่าง (sample skewness) เท่ากับ -0.0669 และค่าความโด่งส่วนเกินของตัวอย่าง (sample excess kurtosis) เท่ากับ 6.2285 [kurtosis ที่รายงานใน R เป็นค่าความโด่งส่วนเกินของตัวอย่าง]

### การทดสอบค่าเฉลี่ย

หากต้องการทราบว่าค่าเฉลี่ยของผลได้ตอบแทนมีค่าต่างจากศูนย์หรือไม่ก็สามารถทำได้ โดยการคำนวณตัวสถิติ  $t$  โดยที่จำนวนตัวอย่างเท่ากับ  $nobs - NA$  (จำนวนตัวอย่าง-จำนวนข้อมูลที่ไม่มี) =  $2089 - 1 = 2088$  ดังนั้นค่าสถิติ  $t$  จะเท่ากับ

$$t = \frac{0.00077}{0.0224/\sqrt{2088}} = 1.579$$

เมื่อเปรียบเทียบกับค่า  $Z_{1-0.05/2} = 1.96$  ค่าดังกล่าวสามารถคำนวณได้โดย `qnorm(0.975)` เราพบว่าค่า  $|t| < 1.96$  ดังนั้นเราไม่สามารถปฏิเสธสมมติฐานหลักว่า "ค่าเฉลี่ยของผลได้ตอบแทนมีค่าเท่ากับศูนย์" นอกจากนี้เราสามารถทดสอบค่าเฉลี่ยเท่ากับศูนย์ได้ด้วยฟังก์ชัน `t.test`

```

1 > t.test(ptt$lret)
2   One Sample t-test
3 data:  ptt$lret
4 t = 1.5795, df = 2087, p-value = 0.1144
5 alternative hypothesis: true mean is not equal to 0
6 95 percent confidence interval:
7  -0.000187103  0.001735994
8 sample estimates:
9   mean of x
10 0.0007744456

```

จะเห็นว่าฟังก์ชันดังกล่าวคำนวณค่า  $t = 1.5795$  และค่าพี (p-value) เท่ากับ 0.1144 ซึ่งเราไม่สามารถปฏิเสธสมมติฐานหลักที่นัยสำคัญเท่ากับ 0.05

### การทดสอบความเป็นสมมาตร

จากค่าความเบ้ของตัวอย่าง เราสามารถคำนวณค่าสถิติ  $t$  ที่ใช้ทดสอบ  $H_0$  ว่าข้อมูลมีความสมมาตร ( $S(Y) = 0$ ) ได้เท่ากับ

$$t = \frac{-0.0689}{\sqrt{6/2088}} = -1.2846$$

เมื่อเปรียบเทียบกับค่า  $|t|$  กับ  $Z_{1-0.05/2} = Z_{0.975} = 1.96$  เราจะได้  $|t| < Z_{0.975} = 1.96$  เราจึงไม่สามารถปฏิเสธ  $H_0$  ที่ว่าผลได้ตอบแทนในรูปลือกมีลักษณะสมมาตร ที่ระดับความเชื่อมั่น 95 %

### การทดสอบความหนาของหาง

$$t = \frac{6.2285}{\sqrt{24/2088}} = 58.0959$$

เมื่อเปรียบเทียบกับค่า  $|t|$  กับ  $Z_{1-0.05/2} = Z_{0.975} = 1.96$  เราจะได้  $|t| > Z_{0.975} = 1.96$  เราจึงปฏิเสธสมมติฐานหลัก  $H_0$  ที่ว่าผลได้ตอบแทนในรูปลือกมีความหนาของหางเท่ากับการแจกแจงแบบปกติ และจากค่าความโด่งของตัวอย่างเราสามารถอนุมานได้ว่าการแจกแจงมีลักษณะเป็นหางอ้วน (ความโด่งส่วนเกินมากกว่าศูนย์)

### การทดสอบการแจกแจงปกติ

$$JB = \frac{-0.0689^2}{6/2088} + \frac{6.2285^2}{24/2088} = 3376$$

เมื่อเปรียบเทียบกับค่า  $JB > 5.99 (= \chi^2_{0.95, df=2})$  ค่าดังกล่าวสามารถคำนวณโดยใช้ฟังก์ชัน `qchisq(1-0.05, 2)` เราจึงปฏิเสธสมมติฐานหลัก  $H_0$  ที่ว่าผลได้ตอบแทนในรูปลือกมีการแจกแจงเป็นแบบปกติ โดยการทดสอบข้างต้นสามารถใช้คำสั่ง `normalTest` ใน package `fBasics` โดยที่ระบุ argument คือ ตัวแปรที่ต้องการทดสอบ `lret` และวิธีการทดสอบ `method="jb"` สำหรับการทดสอบ Jarque-Bera ซึ่งคำสั่งและผลสามารถแสดงได้ดังนี้

```

1 > normalTest(ptt$ret, method="jb")
2
3 Title:
4 Jarque — Bera Normality Test
5
6 Test Results:
7 STATISTIC:
8 X-squared: 3386.3742
9 P VALUE:
10 Asymptotic p Value: < 2.2e-16

```

การทดสอบดังกล่าวได้ค่าต่างจากการคำนวณด้วยมือเล็กน้อยเนื่องจากการปัดเศษ นอกจากนี้ในการทดสอบโปรแกรมจะคำนวณค่าพีซึ่งมีค่าน้อยมาก ( $< 2.2 \times 10^{-16}$ ) ดังนั้นเราจึงปฏิเสธสมมติฐานหลักด้วยนัยสำคัญใดๆมากกว่า  $2.2 \times 10^{-16} \%$

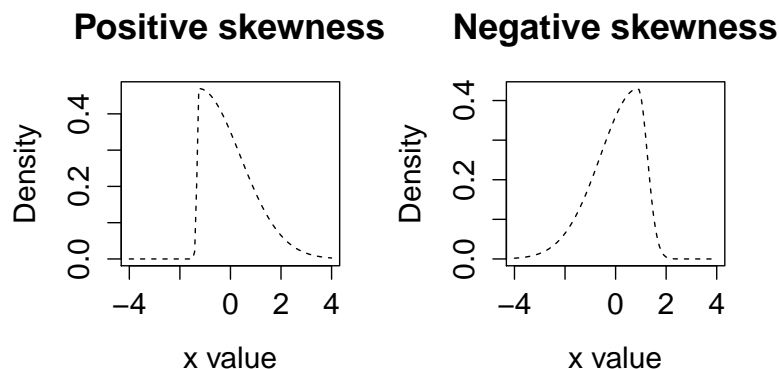
เราสามารถสร้างแผนภาพการแจกแจงข้อมูล (empirical density) โดยใช้คำสั่ง density ซึ่งแสดงในเส้น kernel density ในรูปที่ ?? นอกจากนี้ยังมีแผนภาพแสดงการแจกแจงปกติที่มีค่าเฉลี่ยเท่ากับ 0.00077 และค่าเบี่ยงเบนมาตรฐานเท่ากับ 0.0244

```

1 > plot(density(ptt$ret), main="Density of log return")

```

รูปที่ 1.3: ฟังก์ชันความถี่ความน่าจะเป็นที่ไม่สมมาตร



### การแจกแจงของผลได้ตอบแทน

โดยทั่วไปแล้ว เรามักจะสมมุติให้พิจารณาผลได้ตอบแทนในรูปของล๊อคและมักจะสมมุติให้มีการแจกแจงแบบปกติ นักศึกษาบางคนอาจจะสงสัยว่าทำไมไม่ใช้ผลได้ตอบแทนอย่างง่าย โดยเราสามารถตอบคำถามดังกล่าวได้โดยการสมมุติให้ ผลได้ตอบแทนอย่างง่ายมีการแจกแจงแบบปกติ  $R_t \sim N(0.05, (0.05)^2)$  ซึ่งเราทราบว่าราคาสินทรัพย์ใดๆจะมีค่าติดลบไม่ได้ ดังนั้น  $R_t$  จะต้องมีย่านค่ามากกว่า  $-1$  ซึ่งหากพิจารณาจากข้อสมมุติการแจกแจงปกติจะเห็นได้ว่า  $Pr(R_t < -1) = 0.018$  หรือมีโอกาส 1.8 % ที่ราคาหุ้นจะติดลบ! ซึ่งเป็นไปไม่ได้ ดัง

นั่นจึงมีความเหมาะสมมากกว่าที่จะสมมติให้ผลได้ตอบแทนในรูปลอการิทึมมีการแจกแจงแบบปกติ  $\ln(1 + R_t) = r_t \sim N(0.05, (0.5)^2)$  โดยในกรณีผลได้ตอบแทนในรูปลอการิทึมสามารถจะมีค่าน้อยกว่า  $-1$  ได้ เช่น หาก  $r_t = -2$  จะสัมพันธ์กับ  $R_t = \exp(-2) - 1 = -0.865$  ดังนั้น  $Pr(r_t \leq -2) = Pr(R_t \leq -0.865) = 0.00002$  ดังนั้นในแบบจำลองในหัวข้อต่อไปเวลาเราพูดถึงผลได้ตอบแทนเรามักจะใช้ผลได้ตอบแทนในรูปลอการิทึม (log return)

### ฟังก์ชันเส้นตรงของตัวแปรสุ่ม

หากกำหนดให้  $X$  เป็นตัวแปรสุ่มที่มี  $E[X] = \mu_X$  และ  $Var(X) = \sigma_X^2$  และ  $a$  และ  $b$  เป็นค่าคงที่ หากเรากำหนดตัวแปรสุ่มใหม่  $Y$  เป็นฟังก์ชันเส้นตรงกับตัวแปรสุ่ม  $X$  โดยที่  $Y = a + bX$  แล้ว

- $\mu_Y = E(Y) = a + bE(X) = a + b\mu_X$
- $\sigma_Y^2 = Var(Y) = b^2Var(X) = b^2\sigma_X^2$

### ฟังก์ชันค่าแปรปรวนร่วมในตนเอง (Autocovariance function)

ฟังก์ชันที่ใช้ในการสรุปความสัมพันธ์ขึ้นอยู่กับเวลา (temporal dependence) ในข้อมูลอนุกรมเวลาคือ ฟังก์ชันค่าแปรปรวนร่วมในตนเองซึ่งสามารถคำนวณได้โดย

$$\begin{aligned}\gamma_{k,t} &= Cov(Y_t, Y_{t-k}) = E((y_t - E(Y_t))(y_{t-k} - E(Y_{t-k}))) \\ &= E(y_t y_{t-k}) - E(Y_t)E(Y_{t-k}) \quad \text{for } k = 0, 1, 2, \dots\end{aligned}\quad (1.23)$$

โดยสมการดังกล่าวสอดคล้องกับค่าแปรปรวนร่วม (covariance) ระหว่างตัวแปรสุ่มสองตัวใดๆ

**นิยาม 1.5. (Strict stationary)** อนุกรมเวลา  $Y_t$  ใดๆจะถูกเรียกว่า *strictly stationary* ถ้าการแจกแจงร่วม (joint distribution) ของ  $(y_{t_1}, \dots, y_{t_k})$  เหมือนกันกับการแจกแจงร่วมของ  $(y_{t_1+t}, \dots, y_{t_k+t})$  สำหรับทุกค่าของ  $t$

**นิยาม 1.6. (weakly stationary หรือ covariance stationary)** ข้อมูลอนุกรมเวลา  $Y_t$  ใดๆ จะเรียกว่าเป็น *Weakly stationary* ถ้ามีคุณสมบัติดังนี้

1.  $E(Y_t) = \mu$
2.  $Var(Y_t) = \sigma^2 < \infty$
3.  $\gamma_{k,t} = \gamma_k = Cov(Y_t, Y_{t-k})$  for all  $k$  and  $t$

โดยสรุปแล้วอนุกรมจะมีค่าเฉลี่ยคงที่, ค่าแปรปรวนจำกัด (finite) และฟังก์ชันค่าแปรปรวนร่วมในตนเองที่เป็นฟังก์ชันที่ขึ้นกับค่าล่าเท่านั้นและเป็นอิสระกับเวลา

**นิยาม 1.7. Ergodic** อนุกรมเวลาใดๆ จะเป็นอนุกรมเวลาเออร์โกดิก (ergodic) ถ้าค่าโมเมนต์ของตัวอย่างมีค่าลู่เข้าในความน่าจะเป็น (converge in probability) ไปสู่ค่าโมเมนต์ของประชากร ตัวอย่างเช่น

$$\begin{aligned}\bar{y} &\xrightarrow{p} \mu \\ \hat{\gamma}_j &\xrightarrow{p} \gamma_j \\ \hat{\rho}_j &\xrightarrow{p} \rho_j\end{aligned}$$

### ฟังก์ชันสหสัมพันธ์ในตัวเอง (Autocorrelation function; ACF)

ในการวิเคราะห์สถิติทั่วไปเรามักจะสนใจสัมประสิทธิ์สหสัมพันธ์ (correlation coefficient) มากกว่าค่าแปรปรวนร่วม(covariance)เนื่องจากปราศจากผลของหน่วยของข้อมูล ดังนั้น ฟังก์ชันสหสัมพันธ์ในตัวเองที่ช้ากว่ากัน  $k$  คาบเวลา สำหรับอนุกรมที่เป็น weakly stationary จะคำนวณได้จาก

$$\rho_k = \frac{Cov(Y_t, Y_{t-k})}{[Var(Y_t)Var(Y_{t-k})]^{1/2}}, \quad k = 0, 1, 2, \dots \quad (1.24)$$

โดยที่  $\rho_0 = 1$  และ  $|\rho_k| \leq 1$  สำหรับทุกค่า  $k$ . สำหรับข้อมูลที่เป็น weakly stationary  $Var(Y_t) = Var(Y_{t-k}) = \gamma_0$  ดังนั้น

$$\rho_k = \frac{\gamma_k}{\gamma_0}, \quad k = 0, 1, 2, \dots \quad (1.25)$$

เนื่องจากฟังก์ชันฟังก์ชันค่าแปรปรวนร่วมในตนเองมีความเป็นสมมาตร ดังนั้น  $\gamma_k = \gamma_{-k}$  และ  $\rho_k = \rho_{-k}$  นอกจากนี้กราฟที่แสดงค่าฟังก์ชันสหสัมพันธ์ในตัวเองในแกนตั้งและค่า  $k$  ในแกนนอนเราจะเรียกว่าโครีโลแกรม (Correlogram) โดยสรุปแล้วการพิจารณาว่าอนุกรมเวลานิ่งไม่ก็จะพิจารณาจากค่าเฉลี่ย, ค่าความแปรปรวนและฟังก์ชันสหสัมพันธ์ในตัวเอง

นอกจากนี้เรายังมีคุณสมบัติที่น่าสนใจว่าฟังก์ชันของอนุกรมเวลานิ่งก็จะเป็นอนุกรมเวลานิ่งด้วย เช่นถ้า  $Y_t$  เป็นอนุกรมเวลานิ่งแล้ว  $Z_t = g(Y_t)$  ก็จะเป็นอนุกรมเวลานิ่งด้วย

เราสามารถคำนวณค่าแปรปรวนร่วมในตนเองที่ช้ากว่ากัน  $k$  คาบเวลาของตัวอย่าง (lag  $k^{th}$  sample autocovariance) และสหสัมพันธ์ร่วมในตนเองที่ช้ากว่ากัน  $k$  คาบเวลาของตัวอย่าง (lag  $k^{th}$  sample autocorrelation) ได้จากสูตรดังต่อไปนี้

$$\hat{\gamma}_k = \frac{1}{T} \sum_{t=k+1}^T (y_t - \bar{Y})(y_{t-k} - \bar{Y}) \quad (1.26)$$

และ

$$\hat{\rho}_k = \frac{\hat{\gamma}_k}{\hat{\gamma}_0} \quad (1.27)$$

โดยที่  $\bar{Y} = \frac{1}{T} \sum_{t=1}^T y_t$  คือค่าเฉลี่ยของตัวอย่าง โดยที่ฟังก์ชันสหสัมพันธ์ร่วมในตนเองของตัวอย่าง (sample ACF) จะวาด  $\hat{\rho}_k$  กับ  $k$



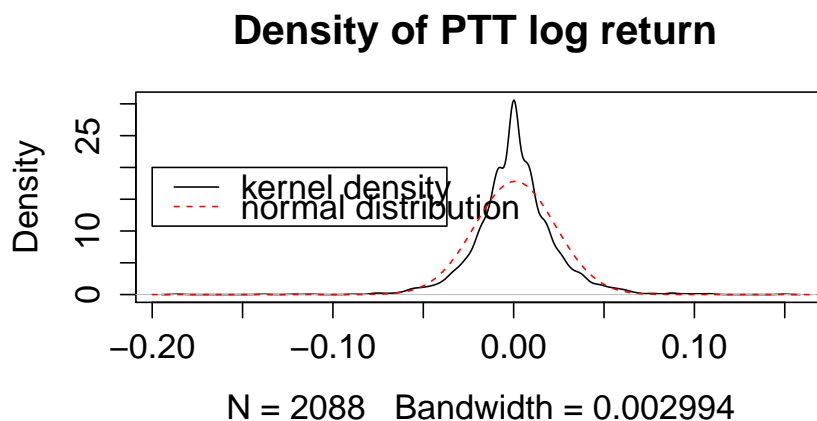
ตัวอย่างหนึ่งของอนุกรมเวลานึงคือ กระบวนการเกาซเชียนไวทนอซที่เป็นอิสระต่อกัน (independent Gaussian white noise process) โดยที่เกาซเชียนหมายถึงการแจกแจงเป็นปกติมันเอง ถ้ากระบวนการ  $y_t$  มีการแจกแจงแบบเกาซเชียนไวทนอซที่เป็นอิสระต่อกัน โดยมีค่าเฉลี่ยเท่ากับ 0 และค่าความแปรปรวนเท่ากับ  $\sigma^2$  กระบวนการ  $y_t$  จะมีค่าเฉลี่ยเท่ากับ 0 นอกจากนี้ค่าความแปรปรวนร่วมในตัวเองและสหสัมพันธ์ในตัวเองก็จะเท่ากับ 0

เราสามารถสร้างข้อมูลที่เป็นเกาซเชียนไวทนอซที่มีจำนวนตัวอย่างเท่ากับ 500 ได้ด้วยคำสั่ง mnorm ใน R

```
1 > set.seed(123456)
2 > y=rnorm(500,0,1)
3 > library(TSA)
4 > par(mfrow=c(1,2))
5 > plot.ts(y,ylab="Y",main="Y")
6 > acf(y,lag.max=20,main="ACF")
```

จะได้แผนภาพดังนี้

รูปที่ 1.5: density ของผลได้ตอบแทนในรูปล็อกของ PTT



ในโปรแกรม R แผนภาพสำหรับฟังก์ชันสหสัมพันธ์ในตัวเองจะมีเส้นแสดงความเชื่อมั่น 95% จาก 0 ให้เสมอ โดยที่เส้นประดังกล่าวมีพื้นฐานจากการที่  $y_t \sim iidN(0, \sigma^2)$  ดังนั้น

$$\hat{\rho}_k \overset{a}{\sim} N(0, \frac{1}{T}), \quad \text{for } k > 0$$

หมายความว่าค่าการแจกแจงของ  $\hat{\rho}_k$  มีประมาณใกล้เคียงกับการแจกแจงแบบปกติที่มีค่าเฉลี่ยเท่ากับ 0 และค่าแปรปรวนเท่ากับ  $\frac{1}{T}$  และเมื่อใช้ผลจาก central limit theorem เราจะได้ว่า  $\sqrt{T}\hat{\rho}_k \xrightarrow{d} N(0, 1)$  และเส้นประที่แสดงค่าขอบเขตความเชื่อมั่น 95% ที่ค่าสหสัมพันธ์ในตัวเองเท่ากับศูนย์จะเท่ากับ  $\pm \frac{1.96}{\sqrt{T}}$  ดังนั้นหากค่าสหสัมพันธ์ในตัวเองของตัวอย่าง ณ คาบล่าช้า  $k$  ใดๆอยู่เกินจากขอบเขตดังกล่าวแสดงว่าค่าสหสัมพันธ์ในตัวเองมีค่าแตกต่างจากศูนย์อย่างมีนัยสำคัญด้วยความเชื่อมั่น 95%

ในกรณีที่  $y_t = \mu + \sum_{i=1}^q \psi_i \varepsilon_{t-i}$  โดยที่  $\varepsilon_i \sim iid(0, \sigma^2)$  การแจกแจงจะเปลี่ยนไปเป็น

$$\hat{\rho}_k \stackrel{a}{\sim} N(0, \frac{(1 + 2 \sum_{i=1}^{k-1} \rho_i^2)}{T}), \quad \text{for } k > 0$$

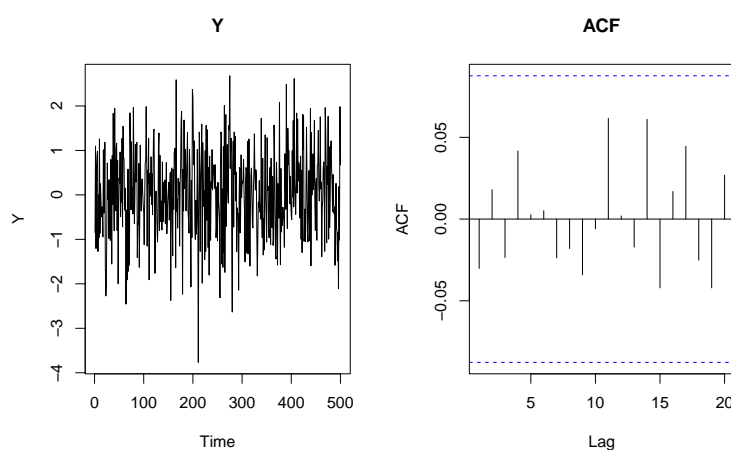
และทำให้ตัวสถิติที่ใช้ในการทดสอบ  $H_0 : \rho_k = 0$  กับ  $H_1 : \rho_k \neq 0$  เปลี่ยนไปเป็น  $\frac{\hat{\rho}_k}{\sqrt{(1 + 2 \sum_{i=1}^{k-1} \rho_i^2)/T}}$  แต่อย่างไรก็ตามโปรแกรมสำเร็จรูปส่วนมากยังใช้  $\sqrt{T}\hat{\rho}$  ในการทดสอบอยู่

**ตัวอย่างการคำนวณฟังก์ชันสหสัมพันธ์ในตัวเอง (ACF) ของผลได้ตอบแทนในรูปล็อกของ PTT**

เราพิจารณาผลได้ตอบแทนในรูปล็อกของหุ้น PTT ต่อจากตัวอย่างที่แล้ว โดยเราสามารถคำนวณค่า autocorrelation ได้ด้วยฟังก์ชัน acf โดยเรากำหนดให้ argument lag.max คือจำนวนคาบย้อนหลังสูงสุดที่เราพิจารณา โดยเราจะได้โครีโลแกรมของผลได้ตอบแทนในรูปล็อกด้านซ้ายของรูป ?? แต่เราจะสังเกตเห็นได้ว่าแผนภาพดังกล่าวจะรวม ฟังก์ชันสหสัมพันธ์ในตัวเองที่ค่าความล่าเท่ากับศูนย์ ( $\rho_0$ ) ซึ่งเท่ากับ 1 ไว้เสมอ ซึ่งทำให้เราอ่านค่าอื่นๆ ได้ยาก ดังนั้นเราสามารถเรียกใช้ฟังก์ชัน acf หลังจากเรียก package library(TSA) ซึ่งผลปรากฏในรูปด้านขวา โดยที่ lag ที่ 1,6,13,14 มีความสูงเกินจากเส้นประ ( $\pm 2/\sqrt{T}$ ) แสดงว่าค่าสหสัมพันธ์ในตัวเอง ณ ค่าล่าข้างต้นมีความแตกต่างจากศูนย์อย่างมีนัยสำคัญทางสถิติที่นัยสำคัญเท่ากับ 5 %

```
1 > acf(lret, lag.max=25)
2 > library(TSA)
3 > acf(lret, lag.max=25)
```

รูปที่ 1.6: ข้อมูลเกาซเซียนไวทนอชและฟังก์ชันสหสัมพันธ์ในตัวเอง



### 1.2.4 การทดสอบพอร์ทแมนโท (Portmanteau test) สำหรับสหสัมพันธ์ในตัวเอง

ในการวิเคราะห์ข้อมูลทางการเงิน เรามักจะเริ่มต้นด้วยการทดสอบว่าข้อมูลมีสหสัมพันธ์ในตัวเองในหลายๆคาบ ( $k$ ) ว่าเท่ากับ 0 พร้อมๆกันหรือไม่ Box and Pierce (1970) ได้เสนอตัวสถิติพอร์ทแมนโทที่คำนวณดังสูตรต่อไปนี้

$$Q^*(m) = T \sum_{k=1}^m \hat{\rho}_k^2 \quad (1.28)$$

ในการทดสอบสมมติฐานหลัก  $H_0 : \rho_1 = \dots = \rho_m = 0$  กับสมมติฐานทางเลือก  $H_1 : \rho_i \neq 0$  สำหรับค่าสหสัมพันธ์ในตัวเองบางคาบย้อนหลังใน  $i \in 1, 2, \dots, m$  โดยภายใต้ข้อสมมุติว่า  $Y_t$  เป็นลำดับที่แจกแจงเป็นอิสระและเหมือนกัน (identical independent distribution: iid) แล้ว  $Q^*(m)$  จะมีการแจกแจงเชิงเส้นกำกับ (asymptotically) เป็นไคกำลังสอง (chi-square) ที่มีองศาเสรีเท่ากับ  $m$  หรือเขียนเป็นสัญลักษณ์  $\chi_m^2$

Ljung and Box (1978) ได้ปรับปรุงตัวสถิติ  $Q^*(m)$  โดยการเพิ่มพลัง(power)ในการทดสอบเมื่อมีตัวอย่างจำกัดโดยเสนอตัวสถิติ

$$Q(m) = T(T+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{T-k} \quad (1.29)$$

โดยเราจะตัดสินใจปฏิเสธสมมติฐานหลัก  $H_0 : \rho_1 = \dots = \rho_m = 0$  ถ้า  $Q(m) > \chi_{1-\alpha, m}^2$  โดยที่  $\chi_{1-\alpha, m}^2$  แสดงถึงควอนไทล์ที่  $100(1-\alpha)$  ของการแจกแจงไคกำลังสองที่มีองศาเสรี  $m$  หรือโปรแกรมสำเร็จรูปส่วนมากก็รายงานค่าพี (p-value) เราก็จะปฏิเสธ  $H_0$  ถ้าค่าพิน้อยกว่าระดับนัยสำคัญ  $\alpha$

ในทางปฏิบัติการเลือกค่า  $m$  จะส่งผลต่อความสามารถในการทดสอบ ดังนั้นงานศึกษาเชิงประจักษ์ส่วนใหญ่มักจะรายงานค่า Ljung-Box  $Q(m)$  หลายๆค่าเช่น  $m = 5, 10, 20$  หรืองานวิจัยบางงานพบว่าค่า  $m = \ln(T)$  ให้ผลการทดสอบที่ดี

#### ตัวอย่างการทดสอบพอร์ทแมนโทของผลได้ตอบแทนของ PTT

ฟังก์ชันที่ใช้ในการทดสอบพอร์ทแมนโทคือ `Box.test` โดยเราต้องกำหนด argument คือข้อมูลที่ให้ทดสอบ, จำนวนคาบที่รวมมาทดสอบ ( $m$ ) และชนิดของการทดสอบ (`type="Ljung"`) สำหรับ Ljung and Box (1978)

```
1 > Box.test(lret, lag=5, type="Ljung")
2 Box-Ljung test
3 data: lret
4 X-squared = 16.2609, df = 5, p-value = 0.006137
```

จากการทดสอบจะเห็นได้ว่า  $Q(5) = 16.26$  และค่าพีเท่ากับ 0.0061 ซึ่งเราสามารถปฏิเสธ  $H_0$  ที่ว่าฟังก์ชันสหสัมพันธ์ในตัวเองจากคาบ 1 ถึง  $m(= 5)$  มีค่าเท่าศูนย์ แสดงว่า  $Y_t$  มีความสัมพันธ์กับตัวเองในคาบใดคาบหนึ่งย้อนหลังไป 1 ถึง 5 คาบ

### 1.2.5 ตัวดำเนินการขยับไปข้างหลัง

**นิยาม 1.8.** เรานิยาม ตัวดำเนินการขยับไปข้างหลัง (*backshift operator*) โดย

$$LY_t = Y_{t-1}$$

และสามารถขยายค่ายกกำลังเป็น  $L^2Y_t = L(LY_t) = LY_{t-1} = Y_{t-2}$  ดังนั้น

$$L^kY_t = Y_{t-k}$$

นอกจากนี้การหาผลต่าง (differencing) มีบทบาทสำคัญในการวิเคราะห์อนุกรมเวลา ดังนั้นเรามีเครื่องหมายสำหรับการหาผลต่าง โดยการหาผลต่างอันดับที่หนึ่ง (first difference) สามารถเขียนได้โดย

$$\Delta Y_t = Y_t - Y_{t-1} = (1 - L)Y_t \quad (1.30)$$

โดยที่เราสามารถขยายการหาผลต่างต่อไป เช่นการหาผลต่างอันดับที่สอง (second difference) เท่ากับ

$$\Delta^2 Y_t = (1 - L)^2 Y_t = (1 - 2L + L^2)Y_t$$

**นิยาม 1.9.** การหาผลต่างอันดับ  $d$  (*differences of order  $d$* ) สามารถคำนวณได้โดย

$$\Delta^d = (1 - L)^d \quad (1.31)$$

## บทที่ 2

### แบบจำลองอนุกรมเวลาเชิงเส้นตรง

ข้อมูลอนุกรมเวลาที่ยากที่สุดคือกระบวนการไวท์นอยซ์ (white noise) โดยที่เรามักจะเขียนแทนกระบวนการไวท์นอยซ์ด้วย ตัวแปรสุ่ม (random variable)  $\varepsilon_t$  โดยส่วนใหญ่เราจะเรียกตัวแปรสุ่ม กระบวนการไวท์นอยซ์ว่า innovation, shock หรือ disturbance term ของข้อมูลอนุกรมเวลา

**นิยาม 2.1** (กระบวนการไวท์นอยซ์). ตัวแปร  $\varepsilon_t$  จะเรียกว่ากระบวนการไวท์นอยซ์ถ้ามีค่าเฉลี่ยเท่ากับศูนย์, มีค่าความแปรปรวนคงที่เท่ากับ  $\sigma^2$  และไม่มีสหสัมพันธ์ข้ามเวลา (serially uncorrelated) หรือเขียนเป็นเงื่อนไขได้ดังนี้

1.  $E(\varepsilon_t) = 0$
2.  $Var(\varepsilon_t) = \sigma_\varepsilon^2$
3.  $\gamma_k = Cov(\varepsilon_t, \varepsilon_{t-k}) = 0$  for  $k \neq 0$

ทฤษฎีบทการแยกส่วนประกอบของโวลด์ (Wold's decomposition theorem) ฟูลเลอร์ (Fuller, 1996) ระบุว่าอนุกรมเวลานิ่ง  $y_t$  สามารถเขียนในรูปกระบวนการเส้นตรงหรือตัวแทนรูปแบบค่าเฉลี่ยเคลื่อนที่ที่มีอันดับเป็นอนันต์ (infinite moving average) และถ้าสามารถเขียน  $y_t$  ในรูป

$$y_t = \mu + \sum_{i=0}^{\infty} \psi_i \varepsilon_{t-i} \quad (2.1)$$

โดยที่  $\mu$  คือค่าเฉลี่ย,  $\psi_0 = 1$ , และ  $\varepsilon_t$  คือ อันดับของอนุกรมเวลาที่เป็นอิสระและเหมือนกัน (iid) โดยที่เราสามารถพิจารณา  $\varepsilon_t$  ในฐานะเป็นข้อมูลใหม่ที่เข้ามาในช่วงเวลา  $t$  หรือเป็น innovation หรือ shock ณ เวลา  $t$  และ  $\sum_{i=1}^{\infty} \psi_i^2 < \infty$

ถ้า  $y_t$  เป็นข้อมูลที่เป็นอนุกรมนิ่ง (stationary) แล้ว  $y_t$  จะต้องมียุทธศาสตร์ค่าเฉลี่ยคงที่  $E(y_t) = \mu$  และ  $Var(y_t) = \sigma_\varepsilon^2 \sum_{i=1}^{\infty} \psi_i^2$  จะต้องเป็นจำนวนที่จำกัด (finite) ซึ่งจะเกิดขึ้นถ้า  $\sum_{i=1}^{\infty} \psi_i^2$  เข้าสู่ค่าหา

(converge) ค่าใดค่าหนึ่ง นอกจากนี้ค่าความแปรปรวนร่วม (covariance)

$$\gamma_l = Cov(y_t, y_{t-l}) = \sigma_\varepsilon^2 \sum_{j=0}^{\infty} \psi_j \psi_{j+l}$$

$$\rho_l = \frac{\sum_{j=0}^{\infty} \psi_j \psi_{j+l}}{\sum_{i=1}^{\infty} \psi_i^2}$$

ดังนั้นรูปแบบของสหสัมพันธ์ในตัวเองของอนุกรมเวลานิ่งใดๆจะถูกกำหนดด้วยตัวถ่วงน้ำหนักค่าเฉลี่ยเคลื่อนที่ (moving average weights;  $\psi_i$ ) นอกจากนี้เราเรียกตัวถ่วงน้ำหนักค่าเฉลี่ยเคลื่อนที่อีกอย่างว่าการตอบสนองแรงกระตุ้น (impulse responses)

$$\frac{\partial y_{t+s}}{\partial \varepsilon_t} = \psi_s, \quad s = 1, 2, 3, \dots \quad (2.2)$$

ในกรณีที่อนุกรมเวลาเป็นอนุกรมนิ่งและเออะ โกดิก  $\lim_{s \rightarrow \infty} \psi_s = 0$  และการตอบสนองแรงกระตุ้นในระยะยาว (long-run cumulative impulse responses) มีค่าจำกัด  $[\sum_{s=0}^{\infty} \psi_s < \infty]$  นอกจากนี้แผนภาพที่วาด  $\psi_s$  กับ  $s$  เรียกว่าฟังก์ชันการตอบสนองแรงกระตุ้น (impulse response function (IRF))

## 2.1 แบบจำลองออโตรีเกรสซีฟ

แนวคิดพื้นฐานของแบบจำลองออโตรีเกรสซีฟ (autoregressive) คือข้อมูลในเวลาปัจจุบัน ( $y_t$ ) สามารถอธิบายได้ด้วยตัวแปรนั้นในอดีตย้อนหลังไป 1 ถึง  $p$  ช่วงเวลา ( $y_{t-1}, \dots, y_{t-p}$ )

แบบจำลองออโตรีเกรสซีฟที่มีอันดับ (order) เท่ากับ  $p$  (เขียนแทนด้วย  $AR(p)$ ) สามารถเขียนได้เป็น

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t \quad (2.3)$$

โดยที่  $y_t$  เป็นข้อมูลที่นิ่งและ  $\varepsilon_t$  เป็นไวทน์ออกส์ที่มีค่าเฉลี่ยเท่ากับศูนย์และความแปรปรวนคงที่เท่ากับ  $\sigma_\varepsilon^2$  ในที่นี้ค่าเฉลี่ยของ  $y_t$  เท่ากับศูนย์

$$\underbrace{E(y_t)}_{=\mu} = \phi_1 \underbrace{E(y_{t-1})}_{=\mu} + \phi_2 \underbrace{E(y_{t-2})}_{=\mu} + \dots + \phi_p \underbrace{E(y_{t-p})}_{=\mu} + \underbrace{E(\varepsilon_t)}_{=0}$$

$$\mu = 0 / (1 - \phi_1 - \phi_2 - \dots - \phi_p)$$

หากค่าเฉลี่ยของ  $y_t$  เท่ากับ  $\mu$  เราสามารถแสดงสมการ  $AR(p)$  ได้เป็น

$$(y_t - \mu) = \phi_1 (y_{t-1} - \mu) + \phi_2 (y_{t-2} - \mu) + \dots + \phi_p (y_{t-p} - \mu) + \varepsilon_t \quad (2.4)$$

หรือเขียนได้เป็น

$$y_t = \phi_0 + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t \quad (2.5)$$

โดยที่  $\phi_0 = \mu(1 - \phi_1 - \phi_2 - \dots - \phi_p)$  หรือ  $E(y_t) = \mu = \frac{\phi_0}{(1 - \phi_1 - \phi_2 - \dots - \phi_p)}$

นอกจากนี้เราสามารถเขียนสมการ (??) ได้ด้วยเครื่องมือ backshift operator เป็นสมการดังนี้

$$(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p) y_t = \varepsilon_t \quad (2.6)$$

หรือ

$$\phi(L) y_t = \varepsilon_t \quad (2.7)$$

โดยที่เราเรียก  $\phi(L) = 1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p$  ว่าพหุนามออโตรีเกรสซีฟ (autoregressive polynomial)

### 2.1.1 แบบจำลองออโตรีเกรสซีฟอันดับหนึ่ง (AR(1))

เราจะพิจารณาคูสมบัติของแบบจำลองออโตรีเกรสซีฟจากกระบวนการ AR(1) ซึ่งมีค่าเฉลี่ยเท่ากับศูนย์สามารถแสดงได้โดย

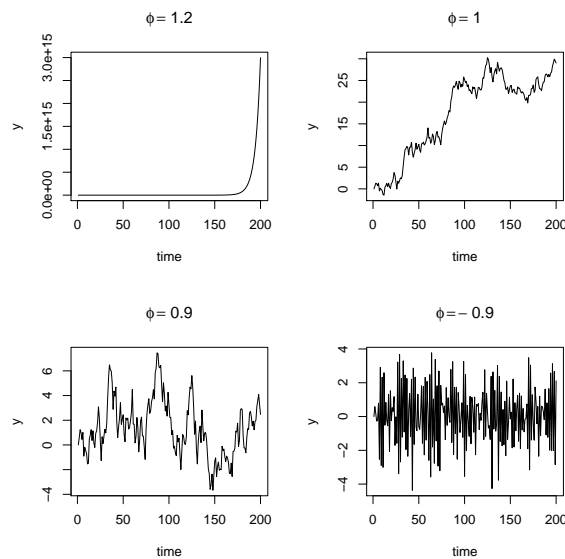
$$y_t = \phi y_{t-1} + \varepsilon_t \quad (2.8)$$

จากสมการข้างต้นหากเราเริ่มพิจารณากรณีที่  $y_0 = 0$  และให้  $\varepsilon_t$  มีการแจกแจงแบบ  $N(0, 1)$  เราจะได้การเดินทางตามเวลา (time path) ของ  $y_t$  สำหรับค่าสัมประสิทธิ์ ( $\phi$ ) ที่ต่างกันดังที่แสดงในรูป ?? จากรูป ?? มุมบนซ้ายซึ่งค่า  $|\phi| > 1$  ในกรณีดังกล่าว  $y_t$  จะเพิ่มขึ้นอย่างต่อเนื่องในอัตราที่รุนแรง (explosive) โดยที่ค่าที่  $t = 200$  ค่า  $y_t > 10^{15}$  ในขณะที่มุมบนขวาซึ่งค่า  $|\phi| = 1$  ค่า  $y_t$  จะขยับไปจุดหนึ่งๆ และคงค้างอยู่บริเวณนั้นสักพักแล้วก็ไม่เดินทางกลับมาที่จุดเริ่มต้น จะเห็นได้ว่าค่าเฉลี่ยของแต่ละช่วงมีค่าที่แตกต่างกันและค่าความแปรปรวนมีแนวโน้มเพิ่มขึ้นเรื่อย ในกรณีนี้เราจะเรียกกระบวนการนี้ว่า "random walk" รูปข้างบนทั้งสองเป็นตัวอย่างของกระบวนการ AR(1) ที่ไม่นิ่ง (non-stationary) ในขณะที่รูปล่างทั้งสองรูป  $|\phi| < 1$  ค่า  $y_t$  จะขยับอยู่รอบๆ ค่าศูนย์แสดงถึงการเป็นกระบวนการนิ่ง (stationary)

จากสมการ ?? เราสามารถแทนค่า  $y_t$  ในอดีตไปเรื่อยๆ แบบเวียนเกิด (recursive)  $k$  ครั้งดังนี้

$$\begin{aligned} y_t &= \phi y_{t-1} + \varepsilon_t = \phi(\phi y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t \\ &= \phi^2 y_{t-2} + \phi \varepsilon_{t-1} + \varepsilon_t \\ &\vdots \\ &= \phi^k y_{t-k} + \sum_{j=0}^{k-1} \phi^j \varepsilon_{t-j} \end{aligned}$$

รูปที่ 2.1: การจำลองกระบวนการ  $AR(1)$  ที่ค่าสัมประสิทธิ์( $\phi$ )ที่ต่างกัน



ด้วยวิธีดังกล่าวข้างต้นและค่า  $|\phi| < 1$  แล้ว  $\lim_{k \rightarrow \infty} \phi^k y_{t-k} = 0$  จะทำให้เราสามารถเขียนแบบจำลอง  $AR(1)$  ในรูปต่อไปนี้

$$y_t = \varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j} \quad (2.9)$$

เราเรียกรูปดังกล่าวว่าการแสดงแบบจำลอง  $AR(1)$  ด้วยมูฟวิงเอเวอเรจที่มีอันดับเป็นอนันต์ (infinite moving average representation)

ค่าคาดหวังหรือค่าเฉลี่ยของ  $y_t$

หากใส่ค่าคาดหวัง (take expectation) ทั้งสองข้างของสมการ ?? จะได้ข้อสรุปว่ากระบวนการ  $AR(1)$  ดังที่ได้แสดงในสมการ ?? มีค่าเฉลี่ยเท่ากับศูนย์

$$E(y_t) = E[\varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots]$$

เนื่องจาก  $\varepsilon_t, \varepsilon_{t-1}, \dots$  เป็นอิสระต่อกัน [ทวนความจำ: หาก  $X$  และ  $Z$  เป็นตัวแปรสุ่มที่เป็นอิสระต่อกัน  $E(X + Z) = E(X) + E(Z)$ ] ดังนั้น

$$\begin{aligned} E(y_t) &= E(\varepsilon_t) + E(\phi \varepsilon_{t-1}) + E(\phi^2 \varepsilon_{t-2}) + \dots \\ &= \underbrace{E(\varepsilon_t)}_{=0} + \phi \underbrace{E(\varepsilon_{t-1})}_{=0} + \phi^2 \underbrace{E(\varepsilon_{t-2})}_{=0} + \dots = 0 \end{aligned}$$



จะเห็นว่าค่าเฉลี่ยของ  $y_t$  เท่ากับศูนย์

ค่าความแปรปรวนของ  $y_t$

เนื่องจาก  $E(y_t) = 0$  ค่าความแปรปรวน  $Var(y_t) = E[y_t - E(y_t)]^2$  จะเท่ากับ  $Var(y_t) = E(y_t^2)$  หากเราแทนค่า  $y_t$  จากสมการ ?? ลงในสูตรดังกล่าว และใช้คุณสมบัติของ  $\varepsilon_t$  ที่ว่า  $Var(\varepsilon_t) = E(\varepsilon_t^2) = \sigma_\varepsilon^2$  และ  $E(\varepsilon_j, \varepsilon_k) = 0$  สำหรับ  $k \neq j$  เราจะได้

$$\begin{aligned}
 E(y_t^2) &= E[(\varepsilon_t + \phi\varepsilon_{t-1} + \phi^2\varepsilon_{t-2} + \dots)(\varepsilon_t + \phi\varepsilon_{t-1} + \phi^2\varepsilon_{t-2} + \dots)] \\
 &= E[\varepsilon_t\varepsilon_t + \varepsilon_t\phi\varepsilon_{t-1} + \varepsilon_t\phi^2\varepsilon_{t-2} + \dots + \phi\varepsilon_{t-1}\varepsilon_t + \phi\varepsilon_{t-1}\phi\varepsilon_{t-1} + \phi\varepsilon_{t-1}\phi^2\varepsilon_{t-2} + \dots \\
 &\quad \phi^2\varepsilon_{t-2}\varepsilon_t + \phi^2\varepsilon_{t-2}\phi\varepsilon_{t-1} + \phi^2\varepsilon_{t-2}\phi^2\varepsilon_{t-2} + \dots] \\
 &= E[\varepsilon_t^2 + \phi\varepsilon_t\varepsilon_{t-1} + \phi^2\varepsilon_t\varepsilon_{t-2} + \dots + \phi\varepsilon_{t-1}\varepsilon_t + \phi^2\varepsilon_{t-1}^2 + \phi^3\varepsilon_{t-1}\varepsilon_{t-2} + \dots \\
 &\quad + \phi^2\varepsilon_{t-2}\varepsilon_t + \phi^3\varepsilon_{t-2}\varepsilon_{t-1} + \phi^4\varepsilon_{t-2}^2 + \dots] \\
 &= \underbrace{E(\varepsilon_t^2)}_{=\sigma_\varepsilon^2} + \phi^2 \underbrace{E(\varepsilon_{t-1}^2)}_{=\sigma_\varepsilon^2} + \phi^4 \underbrace{E(\varepsilon_{t-2}^2)}_{=\sigma_\varepsilon^2} + \dots + \underbrace{\phi E(\varepsilon_t\varepsilon_{t-1})}_{=0} + \underbrace{\phi^2 E(\varepsilon_t\varepsilon_{t-2})}_{=0} + \underbrace{\phi E(\varepsilon_{t-1}\varepsilon_t)}_{=0} + \dots \\
 E(y_t^2) &= (1 + \phi^2 + \phi^4 + \dots)\sigma_\varepsilon^2 = \frac{\sigma_\varepsilon^2}{(1 - \phi^2)} \equiv \gamma_0 \tag{2.10}
 \end{aligned}$$

จากบรรทัดที่ 6 จะเห็นได้ว่าค่าคาดหวังของพจน์ที่คูณกันที่มีตัวห้อยต่างกัน (cross terms) จะเท่ากับศูนย์ นอกจากนี้เราจะใช้สัญลักษณ์  $\gamma_0$  แทนค่าความแปรปรวน

ค่าความแปรปรวนร่วมในตัวเองและฟังก์ชันสหสัมพันธ์ร่วมในตัวเอง

หากนำค่า  $y_t$  และ  $y_{t-l}$  ที่เขียนในรูปสมการ ?? และค่าเฉลี่ยเท่ากับศูนย์  $E(y_t) = 0$  แทนค่าในสูตรค่าความแปรปรวนร่วมได้ฟังก์ชันค่าความแปรปรวนร่วมจะเท่ากับ

$$\begin{aligned}
 \gamma_l = Cov(y_t, y_{t-l}) &= E[(y_t - E(y_t))(y_{t-l} - E(y_{t-l}))] = E(y_t y_{t-l}) \\
 &= E[(\varepsilon_t + \dots + \phi^l \varepsilon_{t-l} + \phi^{l+1} \varepsilon_{t-l-1} + \phi^{l+2} \varepsilon_{t-l-2} + \dots)(\varepsilon_{t-l} + \phi\varepsilon_{t-l-1} + \phi^2\varepsilon_{t-l-2} + \dots)] \\
 &= E[\text{cross terms} + \dots + \phi^l \varepsilon_{t-l} \varepsilon_{t-l} + \phi^l \varepsilon_{t-l} \phi \varepsilon_{t-l-1} + \phi^l \varepsilon_{t-l} \phi^2 \varepsilon_{t-l-2} + \dots \\
 &\quad + \phi^{l+1} \varepsilon_{t-l-1} \varepsilon_{t-l} + \phi^{l+1} \varepsilon_{t-l-1} \phi \varepsilon_{t-l-1} + \phi^{l+1} \varepsilon_{t-l-1} \phi^2 \varepsilon_{t-l-2} + \dots \\
 &\quad + \phi^{l+2} \varepsilon_{t-l-2} \varepsilon_{t-l} + \phi^{l+2} \varepsilon_{t-l-2} \phi \varepsilon_{t-l-1} + \phi^{l+2} \varepsilon_{t-l-2} \phi^2 \varepsilon_{t-l-2} + \dots + \text{cross terms}] \\
 &= E[\phi^l \varepsilon_{t-l} \varepsilon_{t-l} + \phi^{l+1} \varepsilon_{t-l-1} \phi \varepsilon_{t-l-1} + \phi^{l+2} \varepsilon_{t-l-2} \phi^2 \varepsilon_{t-l-2} + \dots + \text{cross terms}] \\
 &= \phi^l \underbrace{E(\varepsilon_{t-l}^2)}_{=\sigma_\varepsilon^2} + \phi^{l+2} \underbrace{E(\varepsilon_{t-l-1}^2)}_{=\sigma_\varepsilon^2} + \phi^{l+4} \underbrace{E(\varepsilon_{t-l-2}^2)}_{=\sigma_\varepsilon^2} + \dots + \underbrace{E(\text{cross terms})}_{=0} \\
 \gamma_l &= \phi^l (1 + \phi^2 + \phi^4 + \dots) \sigma_\varepsilon^2 = \frac{\phi^l \sigma_\varepsilon^2}{(1 - \phi^2)} \tag{2.11}
 \end{aligned}$$

และฟังก์ชันสหสัมพันธ์ร่วมในตัวเอง (ACF) เท่ากับ

$$\rho_l = \frac{\gamma_l}{\gamma_0} = \frac{\frac{\phi^l \sigma_\varepsilon^2}{(1-\phi^2)}}{\frac{\sigma_\varepsilon^2}{(1-\phi^2)}} = \phi^l \quad (2.12)$$

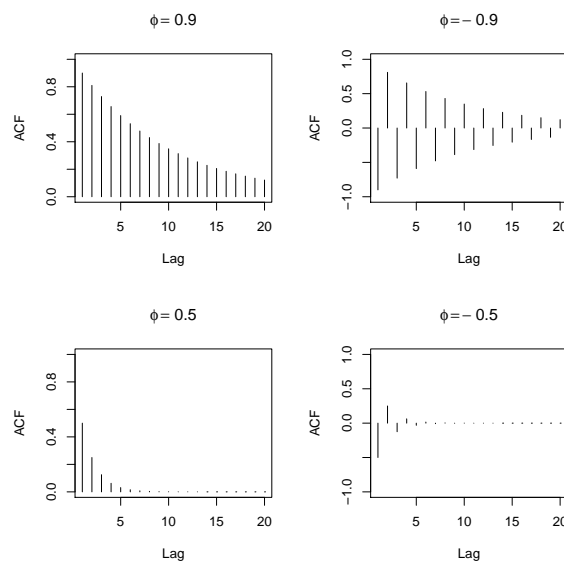
หากลองแทนค่า  $\phi$  ด้วยค่าเท่ากับ 0.9, -0.9, 0.5, -0.5 จะได้ฟังก์ชันสหสัมพันธ์ร่วมในตัวเองดังตารางต่อไปนี้

ตารางที่ 2.1: ค่าสหสัมพันธ์ร่วมในตัวเองของกระบวนการ  $AR(1)$  ที่ค่าสัมประสิทธิ์( $\phi$ )ที่ต่างกัน

$\phi \backslash l$	1	2	3	4	5	6	7	8	9	10
0.9	0.900	0.810	0.729	0.656	0.590	0.531	0.478	0.430	0.387	0.349
-0.9	-0.900	0.810	-0.729	0.656	-0.590	0.531	-0.478	0.430	-0.387	0.349
0.5	0.500	0.250	0.125	0.063	0.031	0.016	0.008	0.004	0.002	0.001
-0.5	-0.500	0.250	-0.125	0.063	-0.031	0.016	-0.008	0.004	-0.002	0.001

จะเห็นได้ว่าค่าสหสัมพันธ์ร่วมในตัวเองของกระบวนการ  $AR(1)$  ในรูปค่าสมบูรณมีค่าลดลงเรื่อยๆ โดยที่หากค่า  $\phi$  เป็นลบ ACF จะมีลักษณะสลับไปทางบวกและลบสลับกัน นอกจากนี้ค่า  $|\phi|$  ที่เข้าใกล้หนึ่งจะมี ACF ที่ลดลงช้ากว่ากรณีที่  $|\phi|$  ที่เข้าใกล้ศูนย์ โดยสามารถดูได้จากรูป ??

รูปที่ 2.2: ค่าสหสัมพันธ์ร่วมในตัวเองของกระบวนการ  $AR(1)$  ที่ค่าสัมประสิทธิ์( $\phi$ )ที่ต่างกัน



## การพิจารณาเงื่อนไขความเป็นอนุกรมหนึ่งจากพหุนามออโตรีเกรสซีฟ

เราสามารถเขียนกระบวนการ  $AR(1)$  ในรูปของพหุนามออโตรีเกรสซีฟได้เป็น

$$\begin{aligned} y_t - \phi y_{t-1} &= \varepsilon_t \\ (1 - \phi L)y_t &= \varepsilon_t \end{aligned} \quad (2.13)$$

โดยที่เราสามารถเขียนสมการช่วย (auxiliary equation) สำหรับสมการ ?? ได้เป็น

$$(1 - \phi m) = 0 \quad (2.14)$$

โดยที่รากของพหุนามออโตรีเกรสซีฟจะเท่ากับ  $m = 1/\phi$  โดยที่เราทราบว่าเงื่อนไขที่กระบวนการ  $AR(1)$  จะเป็นกระบวนการนิ่ง  $|\phi|$  จะต้องมีย่านน้อยกว่าหนึ่ง ดังนั้นค่าสัมบูรณ์ของรากของพหุนามออโตรีเกรสซีฟจะต้องมีค่ามากกว่าหนึ่ง  $[|m| = |1/\phi| > 1]$

ใน ขณะเดียวกัน เราสามารถ เขียน สมการ ลักษณะ เฉพาะ (characteristic equation) สำหรับกระบวนการ  $AR(1)$  จาก  $z^{-1}(z - \phi)y_t = \varepsilon_t$  ได้เป็น

$$(z - \phi) = 0 \quad (2.15)$$

จะเห็นได้ว่ารากของสมการลักษณะเฉพาะจะเท่ากับ  $\phi$   $[z = \phi]$  ดังนั้นเราจะได้เงื่อนไขกระบวนการนิ่งว่า ค่าสัมบูรณ์ของรากของสมการลักษณะเฉพาะจะต้องมีค่าน้อยหนึ่ง  $[|z| = |\phi| < 1]$

## ตัวอย่างที่ 2.1: กระบวนการนิ่ง

จงพิจารณาว่ากระบวนการต่อไปนี้เป็นกระบวนการนิ่งหรือไม่

- $y_t - 0.9y_{t-1} = \varepsilon_t$
- $y_t - y_{t-1} = \varepsilon_t$
- $y_t + 1.2y_{t-1} = \varepsilon_t$

เราสามารถเขียน  $AR(1)$  ในรูปทั่วไปเช่นสมการที่ ?? หรือ ?? โดยที่ในกรณีสมการ ??

$$y_t - \mu = \phi(y_{t-1} - \mu) + \varepsilon_t$$

ถ้าเราต้องการหา  $E(y_t)$  เราสามารถทำได้โดยการใส่ค่าคาดหวังทั้งสองข้างและใช้ข้อสมมุติที่ว่า

$y_t$  เป็น stationary ( $E(y_t) = E(y_{t-1})$ ) จะได้ว่า

$$\begin{aligned} E(y_t) - \mu &= \phi \underbrace{E(y_{t-1})}_{=E(y_t)} - \phi\mu + \underbrace{E(\varepsilon_t)}_{=0} \\ E(y_t) - \mu &= \phi E(y_t) - \phi\mu \\ E(y_t) &= \frac{1-\phi}{1-\phi}\mu = \mu \end{aligned}$$

ในกรณีสมการที่ ??

$$y_t = \phi_0 + \phi_1 y_{t-1} + \varepsilon_t$$

ถ้าเราต้องการหา  $E(y_t)$  เราสามารถทำได้โดยการใส่ค่าคาดหวังทั้งสองข้างและใช้ข้อสมมุติที่ว่า  $y_t$  เป็น stationary ( $E(y_t) = E(y_{t-1})$ ) จะได้ว่า

$$\begin{aligned} E(y_t) &= \phi_0 + \phi_1 \underbrace{E(y_{t-1})}_{=E(y_t)} + \underbrace{E(\varepsilon_t)}_{=0} \\ (1 - \phi_1)E(y_t) &= \phi_0 \\ E(y_t) &= \frac{\phi_0}{1 - \phi_1} \end{aligned}$$

ดังนั้นเราจะได้ว่า  $\mu = \frac{\phi_0}{1-\phi_1}$  เราสามารถขยายการวิเคราะห์ดังกล่าวไปยัง  $AR(p)$

### 2.1.2 แบบจำลอง $AR(2)$

แบบจำลอง  $AR(2)$  สามารถเขียนอธิบายได้ด้วยสมการ

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t \quad (2.16)$$

เงื่อนไขการเป็นกระบวนการนิ่ง

เราสามารถพิจารณาความเป็นกระบวนการนิ่งได้โดยการหารากของพหุนามออโตรีเกรสซีฟซึ่ง  $(1 - \phi_1 L - \phi_2 L^2)y_t = \varepsilon_t$  สามารถเขียนได้เป็น

$$\phi(m) = 1 - \phi_1 m - \phi_2 m^2$$

และพิจารณาสมการช่วย

$$\phi(m) = 1 - \phi_1 m - \phi_2 m^2 = 0 \quad (2.17)$$

โดยที่รากของสมการพหุนามออโตรีเกรสซีฟที่อยู่ในรูปสมการกำลังสอง (quadratic) จะมีด้วยกันสองจำนวน ( $m_1, m_2$ ) เท่ากับ  $\frac{\phi_1 \pm \sqrt{\phi_1^2 + 4\phi_2}}{-2\phi_2}$  ซึ่งรากดังกล่าวสามารถเป็นจำนวนเชิงซ้อน โดยที่

เงื่อนไขที่กระบวนการ  $AR(2)$  จะเป็นกระบวนการนิ่งคือ รากของสมการพหุนามออโตรีเกรสซีฟ จะต้องมากกว่าหนึ่ง (หรือมอดุลัส (modulus) มากกว่าหนึ่งในกรณีจำนวนเชิงซ้อน) ซึ่งจะเกิดขึ้นเมื่อ

$$\phi_1 + \phi_2 < 1, \quad \phi_2 - \phi_1 < 1, \quad |\phi_2| < 1$$

## ตัวอย่างที่ 2.2 เงื่อนไขอนุกรมเวลานิ่งกรณีออโตรีเกรสซีฟ

กำหนดให้  $y_t = 0.5y_{t-1} - 0.8y_{t-2} + \varepsilon_t$  เราสามารถพิจารณาสมการพหุนามออโตรีเกรสซีฟ

$$(1 - 0.5m + 0.8m^2) = 0$$

จะเห็นว่า  $\phi_1 = 0.5$  และ  $\phi_2 = -0.8$  เป็นไปตามเงื่อนไข  $\phi_1 + \phi_2 < 1$ ,  $\phi_2 - \phi_1 < 1$ ,  $|\phi_2| < 1$  ดังนั้นกระบวนการ  $y_t$  เป็นกระบวนการนิ่ง นอกจากนี้เราสามารถพิจารณารากของสมการพหุนามออโตรีเกรสซีฟ โดยเราจะเห็นว่า

$$\begin{aligned} m_1, m_2 &= \frac{\phi_1 \pm \sqrt{\phi_1^2 + 4\phi_2}}{-2\phi_2} = \frac{0.5 \pm \sqrt{0.5^2 + 4(-0.8)}}{-2(-0.8)} \\ &= \frac{0.5}{1.6} \pm \frac{\sqrt{-2.95}}{1.6} = \frac{0.5}{1.6} \pm \frac{\sqrt{2.95}\sqrt{-1}}{1.6} \\ &= 0.3125 \pm 1.073473i \end{aligned}$$

โดยที่รากดังกล่าวสามารถคำนวณด้วย R โดยใช้คำสั่ง `polyroot(c(1, -0.5, 0.8))`

ค่ามอดุลัสของจำนวนเชิงซ้อน  $m_1 = a + bi$  จะเท่ากับ  $\sqrt{a^2 + b^2}$  ซึ่งในกรณีนี้เท่ากับ 1.118034 ซึ่งมีค่ามากกว่าหนึ่ง เราสามารถคำนวณมอดุลัสได้โดยใช้คำสั่ง `Mod(arg)` โดยที่ `arg` คือจำนวนเชิงซ้อน

## คุณลักษณะของกระบวนการ $AR(2)$

เราสามารถพิจารณาค่าเฉลี่ยของกระบวนการในสมการ ?? และพบว่ามีความเกี่ยวข้องกับศูนย์สำหรับฟังก์ชันความแปรปรวนร่วมเราสามารถพิจารณาได้โดยคุณสมบัติ ?? ทั้งสองข้างด้วย  $y_{t-k}$  แล้วใส่ค่าคาดหวัง (take expectation) เราจะได้สมการ

$$\begin{aligned} E(y_t y_{t-k}) &= \phi_1 E(y_{t-1} y_{t-k}) + \phi_2 E(y_{t-2} y_{t-k}) + \underbrace{E(\varepsilon_t y_{t-1})}_{=0} \\ \gamma_k &= \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2} \end{aligned} \quad (2.18)$$

เนื่องจากหากเราเขียน  $y_t$  ในรูปของ infinite MA จะได้  $E(\varepsilon_t y_{t-1}) = E(\varepsilon_t \varepsilon_{t-1} + \varepsilon_t \psi_1 \varepsilon_{t-2} + \dots) = 0$  และหากหาความสัมพันธ์ (??) ด้วย  $\gamma_0$  จะได้

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2} \quad (2.19)$$

เราเรียกสมการ ?? และ ?? ว่าสมการ Yule-Walker จากสมการที่ ?? หากเราพิจารณากรณีที่  $k = 1$ ,  $\rho_1 = \rho_{-1}$  และ  $\rho_0 = 1$  เราจะได้

$$\rho_1 = \frac{\phi_1}{1 - \phi_2}$$

และกรณีที่  $k = 2$  เราจะได้

$$\rho_2 = \frac{\phi_2(1 - \phi_2) + \phi_1^2}{1 - \phi_2}$$

และเราสามารถแทนค่าแบบเวียนเกิด(recursive)เพื่อให้ได้  $\rho_k$  กรณี  $k > 2$

### 2.1.3 แบบจำลอง $AR(p)$

แบบจำลอง  $AR(p)$  ที่ได้มีปรับเอาค่าเฉลี่ยออกสามารถเขียนในรูป

$$y_t - \mu = \phi_1(y_{t-1} - \mu) + \phi_2(y_{t-2} - \mu) + \dots + \phi_p(y_{t-p} - \mu) + \varepsilon_t \quad (2.20)$$

หรือเขียนในรูปตัวดำเนินการขยับไปข้างหลัง

$$\phi(L)(y_t - \mu) = \varepsilon_t \quad (2.21)$$

โดยที่  $\phi(L) = 1 - \phi_1 L - \dots - \phi_p L^p$  หรือในรูปสมการถดถอยในตัวเอง

$$\phi(L)y_t = c + \varepsilon_t \quad (2.22)$$

โดยที่เราสามารถแสดงเงื่อนไขที่  $AR(p)$  จะเป็นอนุกรมนิ่งและอะโกดิกได้ด้วยการพิจารณารากของสมการพหุนามออโตรีเกรสซีฟ

$$\phi(m) = 1 - \phi_1 m - \phi_2 m^2 - \dots - \phi_p m^p = 0$$

หากค่าสัมบูรณ์ของรากทุกตัวของสมการพหุนามออโตรีเกรสซีฟมีค่ามากกว่าหนึ่ง (หรือมอดุลัสมากกว่าหนึ่งในกรณีจำนวนเชิงซ้อน) อนุกรมเวลา  $y_t$  จะเป็นอนุกรมเวลานิ่ง

นอกจากนี้ในกรณีที่  $AR(p)$  เป็นอนุกรมนิ่ง ค่าคงที่ในรูปแบบถดถอยในตัวเอง( $c$ )จะเท่ากับ  $\mu(1 - \phi_1 - \dots - \phi_p)$  ในทางกลับกัน  $\mu = c/(1 - \phi_1 - \dots - \phi_p)$

หากเราสมมุติให้ค่าเฉลี่ย( $\mu$ )เท่าศูนย์และกระบวนการนิ่ง หากเราคูณสมการ ?? ด้วย  $y_{t-k}$  แล้วใส่ค่าคาดหวังทั้งสองข้างของสมการและหารด้วยค่าความแปรปรวนในตัวเอง ( $\gamma_0$ ) เราจะได้

สมการแสดงความสัมพันธ์แบบเวียนเกิด

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2} + \dots + \phi_p \rho_{k-p}, \quad (2.23)$$

สำหรับทุกค่า  $k \geq 1$  หากเราพิจารณากรณีที่  $k = 1, 2, \dots, p$  และใช้ความสัมพันธ์ที่  $\rho_0 = 1$  และ  $\rho_j = \rho_{-j}$  เราจะได้สมการ Yule-Walker ดังนี้

$$\begin{aligned} \rho_1 &= \phi_1 + \phi_2 \rho_1 + \phi_3 \rho_2 + \dots + \phi_p \rho_{p-1} \\ \rho_2 &= \phi_1 \rho_1 + \phi_2 + \phi_3 + \dots + \phi_p \rho_{p-2} \\ &\vdots \\ \rho_p &= \phi_1 \rho_{p-1} + \phi_2 \rho_{p-2} + \phi_3 \rho_{p-3} + \dots + \phi_p \end{aligned} \quad (2.24)$$

ซึ่งหากเราทราบว่า  $\phi_1, \phi_2, \dots, \phi_p$  เราสามารถหาค่า  $\rho_1, \rho_2, \dots, \rho_p$  ได้ นอกจากนี้

$$E(\varepsilon_t y_t) = E[\varepsilon_t (\phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t)] = E(\varepsilon_t^2) = \sigma^2$$

และหากเราคูณสมการ ?? ด้วย  $y_t$  และใส่ค่าคาดหวัง เราจะได้

$$\gamma_0 = \phi_1 \gamma_1 + \phi_2 \gamma_2 + \dots + \phi_p \gamma_p + \sigma^2 \quad (2.25)$$

และหากใช้ความสัมพันธ์ว่า  $\rho_k = \gamma_k / \gamma_0$  จะได้

$$\gamma_0 = \frac{\sigma^2}{1 - \phi_1 \rho_1 - \phi_2 \rho_2 - \dots - \phi_p \rho_p}$$

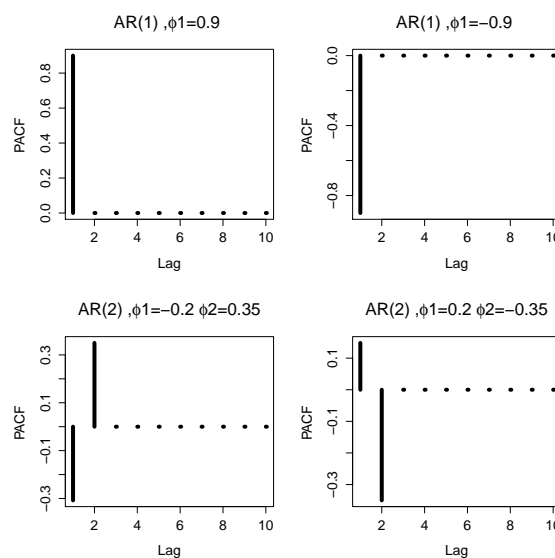
#### 2.1.4 ฟังก์ชัน สห สัมพันธ์ ใน ตัว เอง บาง ส่วน (Partial Autocorrelation Function; PACF)

ฟังก์ชันสหสัมพันธ์ในตัวเองบางส่วนเป็นเครื่องมือที่เป็นประโยชน์ในการระบุแบบจำลอง  $AR(p)$  โดยที่ฟังก์ชันสหสัมพันธ์ในตัวเองบางส่วนมีพื้นฐานจากการประมาณค่าแบบจำลอง  $AR$  เป็นลำดับดังนี้

$$\begin{aligned} z_t &= \phi_{11} z_{t-1} + \varepsilon_{1t} \\ z_t &= \phi_{21} z_{t-1} + \phi_{22} z_{t-2} + \varepsilon_{2t} \\ &\vdots \\ z_t &= \phi_{p1} z_{t-1} + \phi_{p2} z_{t-2} + \dots + \phi_{pp} z_{t-p} + \varepsilon_{pt} \end{aligned}$$

โดยที่  $z_t = y_t - \mu$  คือข้อมูลที่ได้นำค่าเฉลี่ยแล้ว (demeaned) เราเรียกค่าสัมประสิทธิ์  $\phi_{jj}$  สำหรับ  $j = 1, 2, \dots, p$  (ค่าสัมประสิทธิ์สุดท้ายของแต่ละสมการ) ว่าค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วน ในกรณีที่เรากำลังพิจารณาแบบจำลอง  $AR(1)$  ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วนตัวแรก  $\phi_{11}$  จะไม่เท่ากับศูนย์ ส่วนสัมประสิทธิ์ที่เหลือจะเท่ากับศูนย์ เช่นเดียวกันหากเราพิจารณาแบบจำลอง  $AR(2)$  ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วนตัวแรกและตัวที่สอง ( $\phi_{11}$  และ  $\phi_{22}$ ) จะไม่เท่ากับศูนย์ ส่วนสัมประสิทธิ์ที่เหลือ ( $\phi_{jj}$  สำหรับ  $j > 2$ ) จะเท่ากับศูนย์ โดยสรุปแล้ว สำหรับแบบจำลอง  $AR(p)$  ใดๆ ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วน  $p$  ตัวแรกจะไม่เท่ากับศูนย์ และสัมประสิทธิ์ที่เหลือจะเท่ากับศูนย์ โดยจากตัวอย่างใดๆ เราสามารถประมาณค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วนจากตัวอย่าง (sample PACF) ด้วยวิธีการกำลังสองน้อยที่สุดที่ละสมการ และเก็บค่าประมาณสัมประสิทธิ์  $\hat{\phi}_{jj}$  เมื่อนำค่า  $\hat{\phi}_{jj}$  มาวาดกราฟกับ  $j$  เราจะได้ฟังก์ชันสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วนจากตัวอย่าง (sample PACF) ซึ่งสามารถคำนวณได้โดยใช้ฟังก์ชัน `pacf` ใน R

รูปที่ 2.3: ฟังก์ชันสหสัมพันธ์ในตัวเองบางส่วนของข้อมูลจำลอง  $AR(1)$  และ  $AR(2)$



### ตัวอย่างที่ 2.3: การสร้างแบบจำลองสำหรับความแตกต่างระหว่างอัตราดอกเบี้ยด้วย $AR(p)$

ในตัวอย่างนี้เราจะพิจารณาความแตกต่างระหว่างอัตราดอกเบี้ย MLR ของไทย<sup>1</sup> และอัตราดอกเบี้ยลูกค้าชั้นดีของสหรัฐอเมริกา<sup>2</sup> รายเดือนระหว่างเดือนมกราคม 1978 ถึงธันวาคม 2004 ซึ่งอยู่ในไฟล์ `m1r.csv` โดยที่คอลัมน์ที่หนึ่งเป็นเดือน คอลัมน์ที่สองเป็นอัตราดอกเบี้ยของไทย คอลัมน์

<sup>1</sup>ข้อมูลจากธนาคารแห่งประเทศไทย


<sup>2</sup>ข้อมูลจากธนาคารกลางแห่งสหรัฐอเมริกา



ที่สามเป็นอัตราดอกเบี้ยของสหรัฐอเมริกา และคอลัมน์สี่เป็นส่วนต่าง `diff_th_us` เราจะนำเข้าข้อมูล วาดกราฟ(รูปที่ ??)

```
1 > int<-read.csv("https://raw.githubusercontent.com/chalearmong/EC435/master/mlr.csv",
2   header = TRUE)
3 > head(int)
3 > ts.plot(int$diff_th_us, ylab="%", xlab="time")
```

รูปที่ 2.4: ความแตกต่างระหว่างอัตราดอกเบี้ยของไทยและสหรัฐอเมริกา




เราพิจารณา ACF และ PACF จะได้ว่ารูปที่ ?? เมื่อพิจารณาจากรูป ACF จะเห็นได้ว่าผลต่างของอัตราดอกเบี้ย ( $y_t$ ) มีความสัมพันธ์กับตัวเองในอดีตอย่างมีนัยสำคัญ จากรูป ACF จะพอที่จะเดาได้ว่า  $y_t$  น่าจะมีลักษณะคล้ายกับกระบวนการ  $AR(p)$  ซึ่งเราสามารถพิจารณาได้ด้วยกราฟ PACF ในด้านขวาจะเห็นได้ PACF ต่างจากศูนย์อย่างมีนัยสำคัญจนกระทั่งถึงค่าลำดับที่ 3 ดังนั้นเราน่าจะใช้แบบจำลอง  $AR(3)$  ในการประมาณค่าผลต่างของอัตราดอกเบี้ย

```
1 > acf(int$diff_th_us)
2 > pacf(int$diff_th_us)
```

## 2.1.5 การประมาณค่าและตรวจสอบแบบจำลอง

การประมาณค่าพารามิเตอร์ของแบบจำลอง  $AR(p)$ : สามารถดำเนินการได้โดยใช้วิธีการกำลังสองน้อยที่สุด โดยตัวแปรอิสระคือตัวแปร  $y_t$  ที่ค่าลำดับ 1, 2, ...,  $p$  โดยที่ตัวประมาณค่า  $\hat{\sigma}^2 = \frac{\sum_{t=p+1}^T \hat{\epsilon}_t^2}{T-2p-1}$

รูปที่ 2.5: ACF และ PACF ของความแตกต่างระหว่างอัตราดอกเบี้ยของไทยและสหรัฐอเมริกา



### การประมาณค่าความควรจะเป็นสูงที่สุด (Maximum Likelihood Estimation)

หากเราสนใจที่จะประมาณค่าแบบจำลอง  $AR(1)$  ซึ่งอยู่ในรูปดังต่อไปนี้

$$y_t = \mu + \phi(y_{t-1} - \mu) + \varepsilon_t$$

โดยที่  $\varepsilon_t \sim iidN(0, \sigma^2)$  เนื่องจากข้อมูลอนุกรมเวลาเป็นข้อมูลที่ขึ้นอยู่กับกัน (dependent) ดังนั้น หากเราเก็บข้อมูล  $y_1, \dots, y_T$  แล้วฟังก์ชันค่าความควรจะเป็นสามารถเขียนได้ดังนี้

$$L(\mu, \phi, \sigma^2) = f(y_1)f(y_2|y_1)f(y_3|y_2) \cdots f(y_T|y_{T-1}) \quad (2.26)$$

เนื่องจาก  $y_t|y_{t-1} \sim N(\mu + \phi(y_{t-1} - \mu), \sigma^2)$  และฟังก์ชันการแจกแจงจะเป็นแบบปกติที่เหมือนกับข้อ

$$f(y_t|y_{t-1}) = f_\varepsilon[(y_t - \mu) - \phi(y_{t-1} - \mu)]$$

และสามารถเขียนฟังก์ชันค่าความควรจะเป็นได้เป็น

$$L(\mu, \phi, \sigma^2) = f(y_1)\Pi_{t=2}^T f_\varepsilon[(y_t - \mu) - \phi(y_{t-1} - \mu)] \quad (2.27)$$

โดยที่เราจำเป็นต้องหาการแจกแจงของ  $f(y_1)$  เราทราบว่าเราสามารถเขียน  $y_1$  ใดๆ ในรูปของ MA ที่มีอันดับเป็นอนันต์  $y_1 = \mu + \sum_{j=0}^{\infty} \phi^j \varepsilon_{1-j}$  ซึ่งจะเห็นได้ว่าการแจกแจงเป็นแบบปกติที่มีค่า

เฉลี่ย  $\mu$  และค่าความแปรปรวนเท่ากับ  $\sigma^2/(1 - \phi^2)$  ดังนั้นฟังก์ชันค่าความควรจะเป็นจะเท่ากับ

$$L(\mu, \phi, \sigma^2) = (2\pi\sigma^2)^{-1/2}(1 - \phi^2)^{-1/2} \exp\left(\frac{-(y_1 - \mu)^2}{2\sigma^2/(1 - \phi^2)} + (2\pi\sigma^2)^{-(T-1)/2}\right) \times \exp\left(\frac{\sum_{t=2}^T [(y_t - \mu) - \phi(y_{t-1} - \mu)]}{2\sigma^2}\right) \quad (2.28)$$

การหาประมาณค่าโดยหาค่าพารามิเตอร์ที่ทำให้ log ของสมการ (??) สูงที่สุดเรียกว่า การประมาณค่าความควรจะเป็นสูงสุดแบบแม่นยำตรง (exact maximum likelihood estimation) โดยที่ในกรณีนี้ เราไม่สามารถหาค่าสูงสุดได้ด้วยการวิเคราะห์หาเงื่อนไขจำเป็น เราต้องใช้กระบวนการด้วยเครื่องคอมพิวเตอร์ในการหาค่าสูงสุด

ในกรณีแบบจำลอง AR เราสามารถละเลยค่าเริ่มต้นซึ่งก่อนให้เกิดความไม่เป็นเส้นตรงได้ โดยภายใต้เงื่อนไขสมมุติให้ค่าเริ่มต้นเท่ากับศูนย์ เราจะได้ค่าความควรจะเป็นแบบมีเงื่อนไข (conditional likelihood)

$$L(\mu, \phi, \sigma^2) = \Pi_{t=2}^T f_\varepsilon[(y_t - \mu) - \phi(y_{t-1} - \mu)] \quad (2.29)$$

$$= (2\pi\sigma^2)^{-(T-1)/2} \exp\left(-\frac{\sum_{t=2}^T [(y_t - \mu) - \phi(y_{t-1} - \mu)]^2}{2\sigma^2}\right) \quad (2.30)$$

ตัวประมาณค่าที่ได้จากการแสวงหาค่าสูงสุดของสมการ (??) เรียกว่าการประมาณค่าความควรจะเป็นสูงสุดแบบมีเงื่อนไข (conditional MLE) หรือเราสามารถเขียนฟังก์ชันในสมการ (??) ใหม่เป็น

$$L(\mu, \phi, \sigma^2) = (2\pi\sigma^2)^{-(T-1)/2} \exp\left(-\frac{\sum_{t=2}^T \varepsilon_t^2}{2\sigma^2}\right) \quad (2.31)$$

หรือเราสามารถพิจารณาฟังก์ชัน log-likelihood

$$\ln L(\mu, \phi, \sigma^2) = \frac{-(T-1)}{2} \ln(2\pi) - \frac{(T-1)}{2} \ln(\sigma^2) - \frac{\sum_{t=2}^T \varepsilon_t^2}{2\sigma^2} \quad (2.32)$$

โดยที่ค่าพารามิเตอร์ที่ให้ค่าสูงสุดของ  $\ln L$  จะให้ค่าต่ำสุดของ  $S(\mu, \theta) = \frac{\sum_{t=2}^T \varepsilon_t^2}{2\sigma^2}$  ซึ่งเราเรียกว่า conditional sum of squares (CSS) ดังเราจะเรียกการประมาณค่าด้วยวิธี conditional MLE ว่า การประมาณค่าด้วย conditional sum of squares

ในกรณีที่เรากำหนดค่าด้วยการหาค่าสูงสุดของสมการ ?? เราสามารถตัวประมาณค่าได้

ด้วยการหาเงื่อนไขอันดับหนึ่งสำหรับค่าสูงสุด (first order condition)

$$\frac{\partial \ln L}{\partial \phi} = -\frac{1}{2\sigma^2} 2 \sum_{t=2}^T \varepsilon_t (-\phi(y_{t-1} - \mu)) \quad (2.33)$$

$$\frac{\partial \ln L}{\partial \sigma^2} = \frac{-(T-1)}{2} \frac{1}{\sigma^2} + \frac{\sum_{t=2}^T \varepsilon_t^2}{2\sigma^2} \quad (2.34)$$

จากเงื่อนไขแรก

$$\sum_{t=2}^T \varepsilon_t (\hat{\phi}(y_{t-1} - \mu)) = 0$$

$$\sum_{t=2}^T [(y_t - \mu) - \hat{\phi}(y_{t-1} - \mu)] (\hat{\phi}(y_{t-1} - \mu)) = 0$$

หลังจากที่จัดรูปใหม่จะได้

$$\hat{\phi} = \frac{\sum_{t=2}^T (y_t - \hat{\mu})(y_{t-1} - \hat{\mu})}{\sum_{t=2}^T (y_t - \hat{\mu})^2}$$

โดยที่ค่า  $\hat{\mu} = \frac{\sum_{t=2}^T y_t}{(T-1)}$  และ จากเงื่อนไขที่สอง  $\hat{\sigma}^2 = \frac{\sum_{t=2}^T \hat{\varepsilon}_t^2}{T-2}$  จะเห็นได้ว่าตัวประมาณค่าที่ได้จาก CSS เป็นตัวประมาณค่า OLS ด้วย

### การประเมินความถูกต้องของแบบจำลอง (Model Checking)

หลังจากที่เราได้ตัวประมาณค่าสำหรับพารามิเตอร์แล้ว ขั้นตอนต่อไปเราก็จะหาค่า fitted ของตัวแปรที่เราศึกษา ( $\hat{y}_t$ ) แล้วก็จะตรวจสอบแบบจำลองโดยการวิเคราะห์ค่าส่วนเกิน (residuals) โดยในที่นี้ค่าส่วนเกินสามารถคำนวณได้จาก  $\hat{\varepsilon}_t = y_t - \hat{y}_t$  โดยเราจะประเมินค่าส่วนเกินดังต่อไปนี้

เราอาจจะเริ่มจากการวาดแผนภาพ  $\hat{\varepsilon}_t$  และฟังก์ชันสหสัมพันธ์ในตัวเองของ  $\hat{\varepsilon}_t$  เพื่อดูว่าอนุกรมดังกล่าวยังมีความขึ้นอยู่กับกันหรือไม่ โดยที่ภายใต้สมมุติฐานหลักที่ว่า  $\varepsilon_t \sim N(0, 1)$  เราสามารถสรุปได้ว่าสหสัมพันธ์ในตัวเองจะมีการแจกแจงเป็น  $N(0, 1/T)$  และค่าที่ใช้ในการทดสอบคือ  $\pm 2/\sqrt{T}$

นอกจากนี้เราสามารถทดสอบโดยใช้ค่าสถิติ  $Q(m) = T(T+2) \sum_{k=1}^m \frac{\hat{\rho}_{\varepsilon_k}^2}{T-k}$  โดยที่  $Q(m) \sim \chi_{m-g}^2$  และเราจะปฏิเสธสมมุติฐานหลักถ้า  $Q(m)$  มีค่ามากกว่าควอนไทล์ที่  $(1 - \alpha)$  ของ  $\chi_{m-g}^2$  โดยที่  $g$  คือจำนวนของอันดับในแบบจำลองซึ่งในแบบจำลอง  $AR(p)$  ค่า  $g = p$  และ  $m$  คือจำนวนค่าล่าของความสัมพันธ์ที่พิจารณา

## ตัวอย่าง

ต่อเนื่องจากตัวอย่างข้างต้น เราต้องการประมาณค่าแบบจำลอง  $AR(3)$  เราสามารถประมาณค่าได้โดยใช้คำสั่ง `arima` โดยที่ `arg` ที่เราต้องใส่คือ (1) ชื่ออนุกรมเวลาซึ่งในที่นี้คือ `int$diff_th_us` (2) อันดับของอนุกรม `order=c(p,d,q)` โดยที่  $p$  คืออันดับของออโตรีเกรสซีฟ ส่วน  $d$  และ  $q$  คืออันดับของ integration และ moving average ซึ่งเราจะพูดถึงในหัวข้อต่อไป ในหัวข้อนี้เราจะกำหนดให้  $d = 0, q = 0$  โดยที่เราจะเก็บแบบจำลองไว้ใน object ชื่อว่า `m1`

```

1 > m1<-arima(int$diff_th_us, order=c(3,0,0))
2 > m1
3 Call:
4 arima(x = int$diff_th_us, order = c(3, 0, 0))
5 Coefficients:
6      ar1      ar2      ar3  intercept
7      1.3294 -0.4986  0.1334      3.0553
8 s.e.  0.0549  0.0878  0.0549      0.8102
9 sigma^2 estimated as 0.3054:  log likelihood = -269.11,  aic = 548.21

```

โดยที่ค่าสัมประสิทธิ์  $\phi_1 = 1.3294, \phi_2 = -0.4986, \phi_3 = 0.1334, \mu (= intercept) = 3.0553$  และมีค่า standard errors อยู่ในบรรทัด `s.e.` ในโปรแกรม R ค่า `intercept` ที่ได้คือ  $\mu$  มิใช่จุดตัดแกนในสมการที่?? ดังนั้นถ้าต้องการหาเราต้องการค่า  $c = \mu(1 - \phi_1 - \phi_2 - \phi_3) = 0.10937$  หรือเราสามารถเขียนผลการประมาณค่าได้โดย

$$(1 - \underset{(0.0549)}{1.3294}L + \underset{(0.0878)}{0.4986}L^2 - \underset{(0.0549)}{0.1334}L^3)(y_t - \underset{(0.8102)}{3.0553}) = \varepsilon_t$$

โดยที่ค่าในวงเล็บคือ standard errors และ  $\hat{\sigma}^2 = 0.3054$

ในการประมาณค่าข้างต้น R จะเลือกใช้การประมาณค่าด้วย CSS ก่อนเพื่อหาจุดเริ่มต้นสำหรับ MLE นอกจากนี้เราสามารถเลือกวิธีการประมาณค่าได้โดยการเพิ่ม argument `method=c("ML")` และ `method=c("CSS")` สำหรับการประมาณค่าด้วย MLE และ CSS ตามลำดับ โดยที่ผลการประมาณค่าจะมีค่าแตกต่างกันเล็กน้อยดังที่ได้แสดงไว้ข้างล่าง

```

1 > m2<-arima(int$diff_th_us, order=c(3,0,0),method=c("ML"))
2 > m2
3 Call:
4 arima(x = int$diff_th_us, order = c(3, 0, 0), method = "ML")
5 Coefficients:
6      ar1      ar2      ar3  intercept
7      1.3295 -0.4987  0.1334      3.056
8 s.e.  0.0549  0.0878  0.0549      0.810
9
10 sigma^2 estimated as 0.3054:  log likelihood = -269.11,  aic = 548.21
11 > m3<-arima(int$diff_th_us, order=c(3,0,0),method=c("CSS"))
12 > m3
13 Call:
14 arima(x = int$diff_th_us, order = c(3, 0, 0), method = "CSS")
15 Coefficients:
16      ar1      ar2      ar3  intercept
17      1.3334 -0.5016  0.1346      3.0793
18 s.e.  0.0551  0.0880  0.0552      0.9195
19 sigma^2 estimated as 0.3082:  part log likelihood = -269.05

```

ถ้าในการประมาณค่าแบบจำลอง *AR* แล้วเราทดสอบค่าเฉลี่ยด้วย t-test แล้วไม่มีความแตกต่างจากศูนย์อย่างมีนัยสำคัญ เราอาจจะปรับรูปแบบสมการเป็นสมการที่ค่าเฉลี่ยเท่ากับศูนย์ และประมาณค่าโดยการเพิ่ม argument `include.mean=FALSE` ในคำสั่ง `arima`

นอกจากนี้เราสามารถหาค่ารากของสมการพหุนามออโตรีเกรสซีฟได้ตามคำสั่งข้างล่าง

```

1 > p1<-m1$coef
2 > p1
3      ar1      ar2      ar3  intercept
4      1.3294074 -0.4985723  0.1333653  3.0553267
5 > roots=polyroot(p1)
6 > roots
7 [1] 0.4008889+0.5949388i -0.8454280-0.0000000i  0.4008889-0.5949388i
8 > Mod(roots)
9 [1] 0.7174009 0.8454280 0.7174009

```

จะเห็นว่าค่ารากของสมการพหุนามเป็นจำนวนเชิงเส้นที่มีมอดุลัสน้อยกว่าหนึ่งแสดงว่าอนุกรมที่เราประมาณค่าได้เป็นอนุกรมไม่นิ่ง (ซึ่งเราจะกลับมาพิจารณาอนุกรมนี้ในหัวข้อต่อไป)

หลังจากที่เราได้ตัวประมาณค่าของพารามิเตอร์ทั้งหมดแล้วเราจะพิจารณาว่าค่า residuals นั้นยังมีความสัมพันธ์ระหว่างช่วงเวลาหลงเหลืออยู่หรือไม่ หรือแบบจำลองเพียงพอหรือไม่ โดยการทดสอบ L-B test สำหรับ `m2$residuals` ด้วยคำสั่งข้างล่าง

```

1 > adqtest<-Box.test(m1$residuals, lag=12, type="Ljung")
2 > adqtest
3 Box-Ljung test
4 data:  m1$residuals
5 X-squared = 14.009, df = 12, p-value = 0.3002
6 > #calculate p-value with df=12-3
7 > pv<-1-pchisq(adqtest$statistic, 9)
8 > pv
9 X-squared
10 0.1220215

```

เราทดสอบว่า residuals ของแบบจำลอง m1 เป็น white noise หรือไม่ โดยใช้คำสั่ง `Box.test` กับ `m1$residuals` โดยเก็บผลไว้ที่ `adqtest`

จากค่า LB statistics = 14.009 เราสามารถนำไปเปรียบเทียบกับ critical chi-square ( $df=12-3$ ,  $\alpha = 0.05$ ) = 16.92 เนื่องจาก LB statistics < critical chi-sq เราไม่สามารถปฏิเสธสมมติฐานหลักว่า residuals เป็น white noise แสดงว่าแบบจำลอง AR(3) เพียงพอในการอธิบาย *diff\_hus*

นอกจากนี้เราสามารถคำนวณค่า p-value โดยใช้คำสั่ง `pchisq(value, df)` สำหรับคำนวณหา CDF ไปยังจุดที่ chi-square เท่ากับ 14.009 และสามารถคำนวณพื้นที่ปลายหางด้วย 1-CDF ก็จะเป็นค่า p-value

ในกรณีนี้  $p\text{-value} = 0.12 > \alpha (=0.05)$  เราไม่สามารถปฏิเสธสมมติฐานหลักที่ว่า residuals เป็น white noise แสดงว่าแบบจำลองของเราเพียงพอที่จะใช้อธิบายความแตกต่างของอัตราดอกเบี้ย

### 2.1.6 การพยากรณ์ด้วยแบบจำลอง $AR(p)$

การใช้ประโยชน์จากแบบจำลองอนุกรมเวลาที่สำคัญประการหนึ่งคือการพยากรณ์ (forecasting) หากสมมติให้เรากำลังอยู่ ณ ช่วงเวลาที่  $h$  แต่ต้องการที่จะพยากรณ์ไปข้างหน้า  $l$  คาบเวลา หรือสนใจค่าของ  $y_{h+l}$  โดยที่  $l \geq 1$  เราเรียก  $h$  ว่าจุดเริ่มต้นการพยากรณ์ (forecast origin) และ  $l$  ว่าขอบเขตการพยากรณ์ (forecast horizon)

กำหนดให้  $\hat{y}_h(l)$  เป็นค่าพยากรณ์ของ  $y_{h+l}$  โดยการพยากรณ์ดังกล่าวจะทำให้ฟังก์ชันสูญเสียที่เกิดจากการค่าผิดพลาดกำลังสอง (squared errors) น้อยที่สุด

$$E[(y_{h+l} - \hat{y}_h(l))^2 | F_h] \leq \min_g E[(y_{h+l} - g)^2 | F_h]$$

โดยที่  $F_h$  เป็นข้อมูลที่มีทั้งหมดในคาบที่  $h$  และเราเรียก  $\hat{y}_h(l)$  ว่าค่าพยากรณ์ของ  $y_t$  ไปข้างหน้า  $l$  คาบเมื่อจุดเริ่มต้นการพยากรณ์อยู่ที่  $h$  ( $l$ -step ahead forecast)

ค่าพยากรณ์ไปข้างหน้า 1 คาบจากแบบจำลอง  $AR(p)$

เราพบว่าค่า  $y_{h+1} = \phi_0 + \phi_1 y_{h+1-1} + \dots + \phi_p y_{h+1-p} + \varepsilon_{h+1}$  ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข (conditional expectation)

$$\begin{aligned}\hat{y}_h(1) &= E(y_{h+1}|F_h) \\ &= E(\phi_0 + \phi_1 y_h + \dots + \phi_p y_{h+1-p} | F_h) + \underbrace{E(\varepsilon_{h+1} | F_h)}_{=0} \\ &= \phi_0 + \phi_1 y_h + \dots + \phi_p y_{h+1-p} = \phi_0 + \sum_{i=1}^p \phi_i y_{h+1-i}\end{aligned}\quad (2.35)$$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ

$$\begin{aligned}e_h(1) &= y_{h+1} - \hat{y}_h(1) \\ &= (\phi_0 + \phi_1 y_h + \dots + \phi_p y_{h+1-p} + \varepsilon_{h+1}) - (\phi_0 + \phi_1 y_h + \dots + \phi_p y_{h+1-p}) = \varepsilon_{h+1}\end{aligned}$$

และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าหนึ่งคาบเท่ากับ

$$Var(e_h(1)) = Var(\varepsilon_{h+1}) = \sigma^2$$

เราสามารถสร้างช่วงความเชื่อมั่น 95 % ของการพยากรณ์ไปข้างหน้า 1 คาบได้โดยช่วงดังกล่าวจะเท่ากับ

$$\hat{y}_h(1) \pm 1.96sd(e_h(1))$$

โดยที่  $sd(e_h(1)) = \sqrt{Var(e_h(1))} = \sqrt{\sigma^2}$  หากแทนค่า  $\sigma^2$  ด้วยตัวประมาณค่า ( $\hat{\sigma}^2$ ) เราจะเรียกค่าดังกล่าวว่าค่าคาดเคลื่อนมาตรฐาน (standard error)

ค่าพยากรณ์ไปข้างหน้า 2 คาบจากแบบจำลอง  $AR(p)$

เราพบว่าค่า  $y_{h+2} = \phi_0 + \phi_1 y_{h+2-1} + \dots + \phi_p y_{h+2-p} + \varepsilon_{h+2}$  ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข (conditional expectation)

$$\begin{aligned}\hat{y}_h(2) &= E(y_{h+2}|F_h) \\ &= E(\phi_0 + \phi_1 y_{h+1} + \phi_2 y_h + \dots + \phi_p y_{h+2-p} | F_h) + \underbrace{E(\varepsilon_{h+2} | F_h)}_{=0} \\ &= \phi_0 + \phi_1 \underbrace{E(y_{h+1} | F_h)}_{=\hat{y}_h(1)} + \phi_2 y_h + \dots + \phi_p y_{h+2-p} \\ &= \phi_0 + \phi_1 \hat{y}_h(1) + \phi_2 y_{h+2-2} + \dots + \phi_p y_{h+2-p}\end{aligned}\quad (2.36)$$



และค่าผิดพลาดจากการพยากรณ์เท่ากับ

$$\begin{aligned} e_h(2) &= y_{h+2} - \hat{y}_h(2) \\ &= (\phi_0 + \phi_1 y_{h+1} + \dots + \phi_p y_{h+2-p} + \varepsilon_{h+2}) - (\phi_0 + \phi_1 \hat{y}_h(1) + \phi_2 y_{h+2-2} + \dots + \phi_p y_{h+2-p}) \\ &= \varepsilon_{h+2} + \phi_1 (y_{h+1} - \hat{y}_h(1)) = \varepsilon_{h+2} + \phi_1 \varepsilon_{h+1} \end{aligned}$$

และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าหนึ่งคาบเท่ากับ

$$\text{Var}(e_h(2)) = \text{Var}(\varepsilon_{h+2} + \phi_1 \varepsilon_{h+1}) = (1 + \phi_1^2) \sigma^2$$

เราจะสังเกตได้ว่า  $\text{Var}(e_h(2)) \geq \text{Var}(e_h(1))$  ดังนั้นช่วงความเชื่อมั่น 95% ของการพยากรณ์จะมีขนาดที่กว้างขึ้นเรื่อยๆ ซึ่งสะท้อนความแม่นยำของแบบจำลองอนุกรมเวลาเมื่อเราพยากรณ์ไปในอนาคตที่ไกลขึ้น

## ตัวอย่างที่ 2.4 การพยากรณ์ การเปรียบเทียบผลการพยากรณ์กับข้อมูลจริง (in-sample evaluation)

ต่อเนื่องจากตัวอย่าง ?? เราจะพยากรณ์ไปข้างหน้าโดยใช้ตัวอย่างความแตกต่างของอัตราดอกเบี้ย จำนวนข้อมูลที่เรามีอยู่คือ 324 เดือน เพื่อแสดงให้เห็นความแตกต่างระหว่างค่าจริงและค่าพยากรณ์ เราจะประมาณค่าโดยใช้ข้อมูลเดือนมกราคม 1978 ถึงธันวาคม 2003 เป็นข้อมูลจำนวน 312 โดยเรียกว่าตัวแปร `intdiff.in` ดังคำสั่งในบรรทัดที่ 3 และประมาณค่าด้วยแบบจำลอง  $AR(3)$  และเก็บค่าประมาณไว้ใน Object  $m_4$

```
1 > length(int$diff_th_us)
2 [1] 324
3 > intdiff.in<-int$diff_th_us[1:312]
4 > m4=arima(intdiff.in,order=c(3,0,0))
```

เราสามารถพยากรณ์ไปข้างหน้าโดยใช้คำสั่ง `predict` โดยคำสั่งดังกล่าวจะต้องระบุแบบจำลอง ( $m_4$ ) และจำนวนคาบไปข้างหน้า (`n.ahead`) จะเก็บค่าดังกล่าวไว้ใน object `m4.pred` โดยใน Object ดังกล่าวจะประกอบด้วย

- `$pred` คือค่าพยากรณ์ไปข้างหน้า 1 ถึง 12 คาบซึ่งแสดงค่าในบรรทัดที่ 8-9 ตัวอย่างเช่น  $\hat{y}_{312}(1) = 1.803$  และ  $\hat{y}_{312}(12) = 2.397$
- `$se` คือค่าคาดเคลื่อนมาตรฐานของค่าพยากรณ์ไปข้างหน้า 1 ถึง 12 คาบซึ่งแสดงค่าในบรรทัดที่ 15-16 ตัวอย่างเช่น  $se(e_{312}(1)) = 0.562$  และ  $se(e_{312}(12)) = 1.977$


และสามารถวาดรูปเปรียบเทียบค่าจริง (จากเดือนที่ 313 ถึง 324) และค่าพยากรณ์ (`m4.pred$pred`) พร้อมช่วงความเชื่อมั่น 95 % [ดูคำสั่งในบรรทัด 17 ถึง 20] โดยกราฟดังกล่าวแสดงไว้ที่รูป ??

```

1 > m4.pred=predict(m4,n.ahead=12)
2 > m4.pred
3 $pred
4 Time Series:
5 Start = 313
6 End = 324
7 Frequency = 1
8 [1] 1.803828 1.875260 1.943271 2.005150 2.062937 2.117888 2.170297 2.220198
9 [9] 2.267658 2.312788 2.355708 2.396527
10 $se
11 Time Series:
12 Start = 313
13 End = 324
14 Frequency = 1
15 [1] 0.5622779 0.9342948 1.1737163 1.3399272 1.4696143 1.5777365 1.6700163
16 [8] 1.7494732 1.8183586 1.8784737 1.9312318 1.9777417
17 > plot(seq(313,324),int$diff_th_us[313:324],type="l", ylim=c(-2,7), ylab="%",
18 xlab="time")
19 > points(seq(313,324), m4.pred$pred)
20 > lines(seq(313,324), m4.pred$pred+1.96*m4.pred$se,lty=2)
> lines(seq(313,324), m4.pred$pred-1.96*m4.pred$se,lty=2)

```

รูปที่ 2.6: การพยากรณ์ความแตกต่างระหว่างอัตราดอกเบี้ยของไทยและสหรัฐอเมริกาจาก  $AR(3)$



## 2.2 แบบจำลองมูววิ้งเอเวอเรจ (Moving Average; $MA(q)$ )

แบบจำลองนี้มีพื้นฐานมากจากแนวคิดที่ว่าอนุกรมเวลาเส้นตรงนิ่ง (stationary) สามารถเขียนให้อยู่ในรูปมูววิ้งเอเวอเรจอันดับเป็นอนันต์ (infinite moving average representation) และสามารถลดจำนวนความล่า (lag) ให้เหลือ  $q$  เรียกว่าแบบจำลองมูววิ้งเอเวอเรจอันดับ  $q$  และเขียนแทนด้วย  $MA(q)$  และแสดงได้ด้วยสมการ

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} = \sum_{j=0}^q \theta_j \varepsilon_{t-j} = \theta(L) \varepsilon_t \quad (2.37)$$

โดยที่  $\theta_0 = 1$

### 2.2.1 แบบจำลอง MA(1)

สมมติให้  $y_t$  เป็นอนุกรม  $MA(1)$  โดยที่  $\varepsilon_t$  มีคุณสมบัติเป็นไวท์นอยซ์

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} \quad (2.38)$$

เราเริ่มต้นด้วยการหาค่าคาดหมายของ  $y_t$  โดยการใส่ค่าคาดหมาย (take expectation) ทั้งสองข้างของสมการ (??) จะได้

$$E(y_t) = \mu + \underbrace{E(\varepsilon_t)}_{=0} + \theta_1 \underbrace{E(\varepsilon_{t-1})}_{=0} = \mu$$

ต่อไปเราจะพิจารณาค่าความแปรปรวนของ  $y_t$  ( $\gamma_0$ )

$$\begin{aligned} \gamma_0 &= Var(y_t) = E(y_t - E(y_t))^2 \\ &= E(\varepsilon_t + \theta_1 \varepsilon_{t-1})^2 \\ &= E(\varepsilon_t^2 + \theta_1 \varepsilon_t \varepsilon_{t-1} + \theta_1^2 \varepsilon_{t-1}^2) \\ &= \underbrace{E(\varepsilon_t^2)}_{=\sigma_\varepsilon^2} + \theta_1 \underbrace{E(\varepsilon_t \varepsilon_{t-1})}_{=0} + \theta_1^2 \underbrace{E(\varepsilon_{t-1}^2)}_{=\sigma_\varepsilon^2} \\ \gamma_0 &= (1 + \theta_1^2) \sigma_\varepsilon^2 \end{aligned} \quad (2.39)$$

ต่อไปเราจะพิจารณาค่าความแปรปรวนร่วมในตัวเองย้อนไปหนึ่งคาบ (one-lag autocovariance)

$$\begin{aligned} \gamma_1 &= Cov(y_t, y_{t-1}) = E[(y_t - E(y_t))(y_{t-1} - E(y_{t-1}))] \\ &= E[(\varepsilon_t + \theta_1 \varepsilon_{t-1})(\varepsilon_{t-1} + \theta_1 \varepsilon_{t-2})] \\ &= E[\varepsilon_t \varepsilon_{t-1} + \theta_1 \varepsilon_{t-1}^2 + \theta_1 \varepsilon_t \varepsilon_{t-2} + \theta_1^2 \varepsilon_{t-1} \varepsilon_{t-2}] \\ &= \underbrace{E(\varepsilon_t \varepsilon_{t-1})}_{=0} + \theta_1 \underbrace{E(\varepsilon_{t-1}^2)}_{=\sigma_\varepsilon^2} + \theta_1 \underbrace{E(\varepsilon_t \varepsilon_{t-2})}_{=0} + \theta_1^2 \underbrace{E(\varepsilon_{t-1} \varepsilon_{t-2})}_{=0} \\ \gamma_1 &= \theta_1 \sigma_\varepsilon^2 \end{aligned} \quad (2.40)$$

พิจารณาค่าความแปรปรวนร่วมในตัวเองย้อนไปที่ห่างกันสองช่วงเวลา


$$\begin{aligned} \gamma_2 &= Cov(y_t, y_{t-2}) = E[(y_t - E(y_t))(y_{t-2} - E(y_{t-2}))] \\ &= E[(\varepsilon_t + \theta_1 \varepsilon_{t-1})(\varepsilon_{t-2} + \theta_1 \varepsilon_{t-3})] \\ &= E[\varepsilon_t \varepsilon_{t-2} + \theta_1 \varepsilon_{t-1} \varepsilon_{t-2} + \theta_1 \varepsilon_t \varepsilon_{t-3} + \theta_1^2 \varepsilon_{t-1} \varepsilon_{t-3}] \\ \gamma_2 &= \underbrace{E(\varepsilon_t \varepsilon_{t-2})}_{=0} + \theta_1 \underbrace{E(\varepsilon_{t-1} \varepsilon_{t-2})}_{=0} + \theta_1 \underbrace{E(\varepsilon_t \varepsilon_{t-3})}_{=0} + \theta_1^2 \underbrace{E(\varepsilon_{t-1} \varepsilon_{t-3})}_{=0} = 0 \end{aligned} \quad (2.41)$$

จากสมการข้างต้นจะเห็นได้ว่า  $Cov(y_t, y_{t-k}) = 0$  สำหรับ  $k \geq 2$  ในกรณีที่  $y_t$  เป็น  $MA(1)$  และฟังก์ชันสหสัมพันธ์ร่วมในตนเองเท่ากับ

$$\rho_k = \begin{cases} \frac{\theta_1}{1+\theta_1^2} & , k = 1 \\ 0 & , k > 1 \end{cases} \quad (2.42)$$

จะเห็นได้ว่า  $y_t$  มีสหสัมพันธ์กับ  $y_{t-1}$  แต่ไม่สัมพันธ์กับ  $y_{t-2}, \dots$  ซึ่งแตกต่างจาก  $AR(1)$  รูปที่ ?? และ ?? แสดงอนุกรมเวลา  $y_t$  และ ACF กรณีที่  $\theta = 0.5$  และ  $\theta = -0.5$  ตามลำดับ

รูปที่ 2.7: การจำลองข้อมูลกระบวนการ  $MA(1)$  ที่มีค่าสัมประสิทธิ์  $\theta = 0.5$  และกลุ่มตัวอย่าง 500 หน่วย




เราจะเห็นได้ว่าอนุกรมเวลา  $y_t$  ที่เป็นกระบวนการมูวริงเอเวอเรจจะเป็นอนุกรมเวลานิ่ง (stationary) เสมอ เนื่องจากกระบวนการดังกล่าวเป็นการรวมเชิงเส้นตรง (linear combination) ของอนุกรมเวลาไวท์นอยซ์เข้าด้วยกัน ซึ่งอนุกรมเวลาไวท์นอยซ์จะมีค่าโมเมนต์ที่หนึ่งและสองที่ไม่ขึ้นกับเวลา

**กระบวนการที่หาค่าผกผันได้ (invertible)**

นอกจากนี้หากพิจารณาค่าสัมประสิทธิ์ของ  $MA(1)$  จะเห็นได้ว่าค่าความแปรปรวนร่วมในตัวเองของกระบวนการ  $MA(1)$  ที่มีค่า  $\theta_1 = 5$  และ  $\theta_1 = 1/5$  จะมีค่าเท่ากัน นอกจากนี้ฟังก์ชันสหสัมพันธ์ร่วมในตัวเองของกระบวนการ  $MA(1)$  สองกระบวนการต่อไปนี้มีลักษณะที่เหมือนกัน

$$x_t = w_t + \frac{1}{5}w_{t-1}, \quad w_t \sim iidN(0, 25)$$

รูปที่ 2.8: การจำลองข้อมูลกระบวนการ  $MA(1)$  ที่มีค่าสัมประสิทธิ์  $\theta = -0.5$  และกลุ่มตัวอย่าง 500 หน่วย



และ

$$y_t = v_t + 5v_{t-1}, \quad v_t \sim iidN(0, 1)$$

เมื่อเราสังเกตเห็นเพียงแต่อนุกรม  $x_t$  หรือ  $y_t$  โดยที่ไม่ทราบอนุกรมของช็อก  $w_t$  หรือ  $v_t$  ดังนั้นเราต้องเลือกว่าจะใช้แบบจำลองไหน ซึ่งเราจะเลือกแบบจำลองที่สามารถเขียนแบบจำลองในรูปของ infinite AR representation โดยที่อนุกรมที่มีลักษณะดังกล่าวเราจะเรียกว่ากระบวนการที่หาตัวผกผันได้ (invertible process) ยกตัวอย่างเช่น  $y_t = (1 + \theta_1 L)\varepsilon_t$  เราสามารถเขียนแบบจำลองดังกล่าวในรูปต่อไปนี้

$$\begin{aligned} (1 + \theta_1 L)^{-1} y_t &= \varepsilon_t \\ (1 + (-\theta_1 L) + (-\theta_1 L)^2 + (-\theta_1 L)^3 + \dots) y_t &= \varepsilon_t \\ y_t - \theta_1 y_{t-1} + \theta_1^2 y_{t-2} - \theta_1^3 y_{t-3} + \dots &= \varepsilon_t \\ y_t &= \varepsilon_t + \theta_1 y_{t-1} - \theta_1^2 y_{t-2} + \theta_1^3 y_{t-3} + \dots \end{aligned} \quad (2.43)$$

ซึ่งสมการ ?? คือรูปแบบ AR ที่มีอันดับเป็นอนันต์ของ  $y_t \sim MA(1)$  ซึ่งจะเป็นอนุกรมนี้หาก  $|\theta_1| < 1$  ดังนั้น เงื่อนไขที่  $MA(1)$  จะเป็นกระบวนการที่หาตัวผกผันได้ คือ  $|\theta_1| < 1$

เราสามารถเขียนเงื่อนไขที่สามารถเขียนกระบวนการที่หาตัวผกผันได้ด้วยการเขียนกระ-

กระบวนการ  $MA(1)$  ในรูปสมการพหุนาม

$$y_t - \mu = (1 + \theta_1 L)\varepsilon_t$$

โดยที่สมการช่วยคือ  $(1 + \theta_1 m) = 0$  ดังนั้นรากของสมการพหุนามมูวิงเอเวอเรจคือ  $m = \frac{-1}{\theta_1}$  เมื่อพิจารณารากของสมการพหุนาม  $|m| = \left|\frac{-1}{\theta_1}\right| = \frac{1}{|\theta_1|} > 1$  จะได้ว่าค่าสัมบูรณ์ของรากของสมการพหุนามมูวิงเอเวอเรจจะต้องมีค่ามากกว่า 1

### 2.2.2 แบบจำลอง $MA(2)$

กำหนดให้  $y_t$  เป็นกระบวนการ  $MA(2)$  ซึ่งสามารถแสดงได้ด้วยสมการ

$$y_t - \mu = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} \quad (2.44)$$

ซึ่งรูปแบบดังกล่าวจะมีค่าเฉลี่ยเท่ากับ  $\mu$

$$\begin{aligned} E(y_t) - \mu &= \underbrace{E(\varepsilon_t)}_{=0} + \theta_1 \underbrace{E(\varepsilon_{t-1})}_{=0} + \theta_2 \underbrace{E(\varepsilon_{t-2})}_{=0} \\ E(y_t) &= \mu \end{aligned}$$

ค่าความแปรปรวนของ  $y_t$  สามารถหาได้โดย

$$\begin{aligned} Var(y_t) &= E(y_t - \mu)^2 = E[(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2})(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2})] \\ &= E[\varepsilon_t^2 + \theta_1^2 \varepsilon_{t-1}^2 + \theta_2^2 \varepsilon_{t-2}^2 + \text{cross term}] \\ &= \underbrace{E(\varepsilon_t^2)}_{=\sigma_\varepsilon^2} + \theta_1^2 \underbrace{E(\varepsilon_{t-1}^2)}_{=\sigma_\varepsilon^2} + \theta_2^2 \underbrace{E(\varepsilon_{t-2}^2)}_{=\sigma_\varepsilon^2} + \underbrace{E(\text{cross term})}_{=0} \\ &= (1 + \theta_1^2 + \theta_2^2)\sigma_\varepsilon^2 \equiv \gamma_0 \end{aligned} \quad (2.45)$$

ต่อไปเราจะพิจารณาค่าความแปรปรวนในตัวเองย้อนไปหนึ่งคาบ

$$\begin{aligned} \gamma_1 &= Cov(y_t, y_{t-1}) = E[(y_t - \mu)(y_{t-1} - \mu)] \\ &= E[(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2})(\varepsilon_{t-1} + \theta_1 \varepsilon_{t-2} + \theta_2 \varepsilon_{t-3})] \\ &= E[\theta_1 \varepsilon_{t-1}^2 + \theta_2 \theta_1 \varepsilon_{t-2}^2 + \text{cross term}] \\ &= \theta_1 \underbrace{E(\varepsilon_{t-1}^2)}_{=\sigma_\varepsilon^2} + \theta_2 \theta_1 \underbrace{E(\varepsilon_{t-2}^2)}_{=\sigma_\varepsilon^2} + \underbrace{E(\text{cross term})}_{=0} \\ &= (\theta_1 + \theta_2 \theta_1)\sigma_\varepsilon^2 \end{aligned} \quad (2.46)$$

ค่าความแปรปรวนในตัวเองย้อนไปสองคาบ

$$\begin{aligned}
 \gamma_2 &= Cov(y_t, y_{t-2}) = E[(y_t - \mu)(y_{t-2} - \mu)] \\
 &= E[(\varepsilon_t + \theta_1\varepsilon_{t-1} + \theta_2\varepsilon_{t-2})(\varepsilon_{t-2} + \theta_1\varepsilon_{t-3} + \theta_2\varepsilon_{t-4})] \\
 &= E[\theta_2\varepsilon_{t-2}^2 + \text{cross term}] \\
 &= \theta_2 \underbrace{E(\varepsilon_{t-2}^2)}_{=\sigma_\varepsilon^2} + \underbrace{E(\text{cross term})}_{=0} \\
 &= \theta_2\sigma_\varepsilon^2
 \end{aligned} \tag{2.47}$$

และค่าความแปรปรวนในตัวเองย้อนไปสามคาบ

$$\begin{aligned}
 \gamma_3 &= Cov(y_t, y_{t-3}) = E[(y_t - \mu)(y_{t-3} - \mu)] \\
 &= E[(\varepsilon_t + \theta_1\varepsilon_{t-1} + \theta_2\varepsilon_{t-2})(\varepsilon_{t-3} + \theta_1\varepsilon_{t-4} + \theta_2\varepsilon_{t-5})] \\
 &= E[\text{cross term}] = 0
 \end{aligned} \tag{2.48}$$

เมื่อพิจารณาค่าสหสัมพันธ์ในตัวเองของอนุกรมเวลา  $MA(2)$  จะได้ว่า

$$\begin{aligned}
 \rho_0 &= \frac{\gamma_0}{\gamma_0} = 1 \\
 \rho_1 &= \frac{\gamma_1}{\gamma_0} = \frac{(\theta_1 + \theta_2\theta_1)}{(1 + \theta_1^2 + \theta_2^2)} \\
 \rho_2 &= \frac{\gamma_2}{\gamma_0} = \frac{\theta_2}{(1 + \theta_1^2 + \theta_2^2)} \\
 \rho_3 &= \frac{\gamma_3}{\gamma_0} = 0 \\
 \rho_j &= \frac{\gamma_j}{\gamma_0} = 0
 \end{aligned}$$

กรณีที่  $j > 2$  จากสมการข้างบนจะเห็นได้ว่า ACF ของ  $MA(2)$  จะมีค่ามากกว่าศูนย์ในกรณีที่  $j = 1$  และ  $j = 2$  และจะลดลงเท่ากับศูนย์ในกรณีที่  $j > 2$

### 2.2.3 แบบจำลอง $MA(q)$

แบบจำลอง  $MA(q)$  สามารถเขียนในรูปสมการดังนี้

$$y_t = \mu + \varepsilon_t + \theta_1\varepsilon_{t-1} + \dots + \theta_q\varepsilon_{t-q}, \quad \varepsilon_t \sim WN(0, \sigma^2) \tag{2.49}$$

แบบจำลอง  $MA(q)$  หนึ่งและ ergodic<sup>3</sup> ถ้าค่า  $\theta_1, \dots, \theta_q$  มีค่าจำกัด และแบบจำลองสามารถหาตัวผกผันได้ถ้าค่าราก (roots) ของพหุนาม MA ต่อไปนี้

$$\theta(m) = 1 + \theta_1 m + \dots + \theta_q m^{t-q} = 0 \quad (2.50)$$

มีค่าสัมบูรณ์(หรือค่าโมดูลัส)ของรากของพหุนามมากกว่า 1 และเราสามารถสรุปโมเมนต์ของกระบวนการ  $MA(q)$  ได้ดังนี้

$$\begin{aligned} E(y_t) &= \mu \\ \gamma_0 &= \sigma_\varepsilon^2(1 + \theta_1^2 + \dots + \theta_q^2) \\ \gamma_j &= \begin{cases} (\theta_j + \theta_{j+1}\theta_1 + \theta_{j+2}\theta_2 + \dots + \theta_q\theta_{q-j})\sigma_\varepsilon^2, & j = 1, 2, \dots, q \\ 0 & j > q \end{cases} \end{aligned}$$

และค่าสหสัมพันธ์ในตัวเองจะเท่ากับ

$$\rho_j = \frac{\gamma_j}{\gamma_0} = \frac{(\theta_j + \theta_{j+1}\theta_1 + \theta_{j+2}\theta_2 + \dots + \theta_q\theta_{q-j})}{(1 + \theta_1^2 + \dots + \theta_q^2)}$$

กรณีที่  $j = 1, 2, \dots, q$  และ  $\rho_j = 0$  กรณีที่  $j > q$  จะเห็นได้ว่า ACF ของ  $MA(q)$  จะมีค่าไม่เท่ากับศูนย์จะกระทั่งช่วงค่า  $q$  และจะเท่ากับศูนย์หลังจากนั้น ในขณะที่ PACF จะมีค้อยลดลงไป

## 2.2.4 การประมาณค่าแบบจำลอง $MA(q)$

การประมาณค่าความควรจะเป็นสูงสุด (maximum likelihood estimation) เป็นวิธีการทั่วไปที่ใช้ในการประมาณค่าแบบจำลอง  $MA(q)$

วิธีการประมาณค่าความควรจะเป็นแบบมีเงื่อนไข (Conditional maximum likelihood) สูงสุด

ในหัวข้อนี้จะประมาณค่าแบบจำลอง  $MA(1)$  ซึ่งสามารถเขียนได้ดังนี้

$$y_t = \mu + \varepsilon_t + \theta\varepsilon_{t-1}$$

โดยที่  $\varepsilon_t \sim iidN(0, \sigma_\varepsilon^2)$  ในกรณีที่เราระประมาณค่าด้วยค่าความควรจะเป็นแบบมีเงื่อนไขสูงสุด เราจะสมมุติให้  $\varepsilon_0 = 0$  ดังนั้น  $y_1 = \mu + \varepsilon_1$

$$y_1|\varepsilon_0 = 0 \sim N(\mu, \sigma_\varepsilon^2)$$

<sup>3</sup>เนื่องจากแนวคิดเกี่ยวกับอนุกรมเวลาหนึ่งมิได้อธิบายความสัมพันธ์ระหว่างข้อมูลในช่วงเวลาที่แตกต่างกัน อนุกรมเวลาจะมีคุณสมบัติเป็น ergodic ถ้าช่วงของข้อมูลสองช่วงเวลายังมีความสัมพันธ์ระหว่างกันที่ลดลงเมื่อช่วงเวลาดังกล่าวอยู่ห่างกันมากขึ้น



และเมื่อสามารถสังเกตค่า  $y_1$  เราก็สามารถหาค่า  $\varepsilon_1 = y_1 - \mu$  และจากข้อมูลในคาบที่ 1 จะได้ว่า

$$y_2|y_1 = \mu + \varepsilon_2 + \theta\varepsilon_1$$

และเราสามารถหาค่า  $\varepsilon_2 = y_2 - \mu - \theta\varepsilon_1$  และได้ฟังก์ชันความน่าจะเป็น

$$f_{y_2|y_1} = \frac{1}{\sqrt{2\pi\sigma_\varepsilon^2}} \exp \left[ \frac{-(y_2 - \mu - \theta\varepsilon_1)^2}{2\sigma_\varepsilon^2} \right]$$

และหากใช้กระบวนการเดียวกัน ไปเรื่อย เราจะสามารถหาค่า  $\varepsilon_t = y_t - \mu - \theta\varepsilon_{t-1}$  และสร้าง conditional likelihood function ได้

$$\begin{aligned} L(\mu, \theta, \sigma_\varepsilon^2) &= \prod_{t=2}^T f_{y_t|y_{t-1}} \\ &= (2\pi\sigma_\varepsilon^2)^{-(T-2)/2} \exp \left[ \frac{\sum_{t=2}^T -\overbrace{(y_t - \mu - \theta\varepsilon_{t-1})^2}^{\varepsilon_t^2}}{2\sigma_\varepsilon^2} \right] \end{aligned} \quad (2.51)$$

สมการ ?? เราไม่สามารถหาตัวประมาณค่าได้ด้วยการวิเคราะห์หอนุพันธ์เช่นในกรณี AR ในกรณีนี้ เราจำเป็นต้องใช้วิธีการทางตัวเลขด้วยคอมพิวเตอร์เพื่อหาค่า  $\hat{\theta}$  ที่ทำให้  $L(\mu, \theta, \sigma_\varepsilon^2)$  มีค่าสูงที่สุด

**วิธีการประมาณค่าความควรจะเป็นแบบแม่นยำตรง (Exact maximum likelihood) สูงสุด**

โดยทั่วไปแล้วเราใช้วิธีการ สอง วิธีการ ในการ คำนวณ ฟังก์ชัน ค่าความควรจะเป็นแบบแม่นยำตรง (Exact likelihood function) สำหรับ MA(1) คือ Kalman filter และการใช้ triangular factorization ของ var-cov matrix ซึ่งผู้ที่สนใจสามารถหาอ่านได้จาก Hamilton (1993)

**ตัวอย่างที่ 2.5: การสร้างแบบจำลองสำหรับผลได้ตอบแทนรายเดือนจาก SET โดย MA(q)**


ในตัวอย่างนี้เราจะพิจารณาผลได้ตอบแทนรายเดือนของการลงทุนในตลาดหลักทรัพย์แห่งประเทศไทย โดยใช้ข้อมูลราคาปิดรายเดือนตั้งแต่ เมษายน 2518 ถึงเดือนพฤศจิกายน 2555 (ข้อมูลจาก [www.set.or.th/th/market/market\\_statistics.html](http://www.set.or.th/th/market/market_statistics.html)) ซึ่งอยู่ในไฟล์ mset.csv โดยเป็นข้อมูลคอลัมน์เดียว เราสามารถนำเข้าข้อมูลและคำนวณผลได้ตอบแทนได้ด้วยคำสั่งต่อไปนี้

```
1 > mset <-  
  read.csv("https://raw.githubusercontent.com/chaileampong/EC435/master/mset.csv",  
  header = FALSE)  
2 > head(mset)  
3 > ret<-diff(log(mset$V1))  
4 > ts.plot(ret)
```

หลังจากนั้นเราจะพิจารณาแบบจำลองที่เหมาะสมโดยการพิจารณา ACF และ PACF

```
1 > acf(ret)
2 > pacf(ret)
```

รูปที่ 2.9: ACF และ PACF ของผลได้ตอบแทนรายเดือนจาก SET



จากรูป ?? จะเห็นได้ว่า ACF มีค่าลดลงจนมีค่าไม่แตกต่างจากศูนย์ที่ค่าเท่ากับ 3 ดังนั้นแบบจำลองที่เหมาะสมน่าจะเป็น  $MA(2)$  ซึ่งประมาณค่าได้ด้วยคำสั่ง `arima` โดยกำหนดอันดับเป็น `c(0,0,2)`

```
1 > m1<-arima(ret, order=c(0,0,2))
2 > m1
3 Call:
4 arima(x = ret, order = c(0, 0, 2))
5
6 Coefficients:
7      ma1      ma2 intercept
8  0.0886  0.1001   0.0057
9 s.e.  0.0469  0.0487   0.0046
10
11 sigma^2 estimated as 0.006795: log likelihood = 485.64, aic = -963.28
```

จากผลการประมาณค่าเราได้ค่าสัมประสิทธิ์ดังนี้  $\theta_1 = 0.0886$ ,  $\theta_2 = 0.1001$  และ  $\mu = 0.0057$  และมีค่าความคลาดเคลื่อนมาตรฐาน (s.e.) อยู่ในบรรทัด s.e.

เราสามารถพิจารณาความพอเพียงของแบบจำลอง `m1` ได้ด้วยการทดสอบ L-B สำหรับ residuals ดังคำสั่งต่อไปนี้

```

1 > Box.test(m1$residuals, lag=12, type="Ljung")
2   Box-Ljung test
3 data:  m1$residuals
4 X-squared = 13.6075, df = 12, p-value = 0.3265
5 > pv=1-pchisq(13.6075,12-2)
6 > pv
7 [1] 0.1916591

```

เราได้ค่า  $Q(12)$  เท่ากับ 13.6075 ซึ่งสามารถหาค่าพีที่มีองศาอิสระเท่ากับ  $(m-g) = 12-2$  โดยที่  $g$  คือจำนวนอันดับของ  $MA$  จะได้ค่าพีเท่ากับ 0.192 แสดงว่าค่าส่วนเกิน (residuals) ไม่มีความสัมพันธ์ระหว่างกัน แสดงว่าแบบจำลองของเราเพียงพอที่ใช้อธิบายผลได้ตอบแทนรายเดือนของการลงทุนในตลาดหลักทรัพย์แห่งประเทศไทย

## 2.2.5 การพยากรณ์จากแบบจำลอง $MA(q)$

ในแบบจำลอง  $MA(q)$  ความจำของข้อมูลก่อนข้างจำกัดซึ่งเราสามารถสังเกตเห็นได้จากค่าพยากรณ์ ตัวอย่างเช่นหากเราพิจารณาแบบจำลอง  $MA(1)$ :  $y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}$  โดยเราอยู่ ณ คาบเวลา  $h$

### การพยากรณ์ไปข้างหน้า 1 คาบ

ในกรณีนี้เราพิจารณา  $y_{h+1} = \mu + \varepsilon_{h+1} + \theta_1 \varepsilon_h$  ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสีย น้อยที่สุดคือค่าคาดการณ์แบบมีเงื่อนไข (conditional expectation)

$$\hat{y}_h(1) = E(y_{h+1}|F_h) = \mu + \underbrace{E(\varepsilon_{h+1}|F_h)}_{=0} + \theta_1 \varepsilon_h = \mu + \theta_1 \varepsilon_h \quad (2.52)$$

และค่าผิดพลาดจากการพยากรณ์เท่ากับ

$$e_h(1) = y_{h+1} - \hat{y}_h(1) = \varepsilon_{h+1}$$

และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าหนึ่งคาบเท่ากับ

$$Var(e_h(1)) = Var(\varepsilon_{h+1}) = \sigma^2$$

ในการพยากรณ์จากแบบจำลอง  $MA(1)$  เราต้องใช้ค่าช็อกซึ่งเราไม่สามารถสังเกตได้ ในทางปฏิบัติ ค่า  $\varepsilon_h$  จะสามารถคำนวณได้สองวิธีคือ

- สมมติให้  $\varepsilon_0 = 0$  แล้วแทนค่าใน  $\varepsilon_1 = y_1 - \mu$  และ  $\varepsilon_t = y_t - \mu - \theta_1 \varepsilon_{t-1}$  สำหรับ  $2 \leq t \leq h$
- หรือใช้ค่า  $\hat{\varepsilon}_h$  ที่เป็นค่าตกค้าง (residual) จากการประมาณค่า  $MA(1)$

### การพยากรณ์ไปข้างหน้า 2 คาบ

พิจารณา  $y_{h+2} = \mu + \varepsilon_{h+2} + \theta_1 \varepsilon_{h+1}$  ตัวพยากรณ์ที่จะทำให้ค่าฟังก์ชันสูญเสียน้อยที่สุดคือ ค่าคาดการณ์แบบมีเงื่อนไข

$$\hat{y}_h(2) = E(y_{h+2}|F_h) = \mu + \underbrace{E(\varepsilon_{h+2}|F_h)}_{=0} + \theta_1 \underbrace{\varepsilon_{h+1}}_{=0} = \mu \quad (2.53)$$

ซึ่งเท่ากับค่าเฉลี่ยของอนุกรม และค่าผิดพลาดจากการพยากรณ์เท่ากับ

$$e_h(2) = y_{h+2} - \hat{y}_h(2) = \varepsilon_{h+2} + \theta_1 \varepsilon_{h+1}$$

และค่าแปรปรวนจากการพยากรณ์ไปข้างหน้าสองคาบเท่ากับ

$$Var(e_h(2)) = Var(\varepsilon_{h+2} + \theta_1 \varepsilon_{h+1}) = (1 + \theta_1^2)\sigma^2$$

ซึ่งเราสามารถเขียนสรุปค่าพยากรณ์สำหรับแบบจำลอง  $MA(1)$  ได้ดังนี้

$$\hat{y}_h(k) = \begin{cases} \mu + \theta_1 \varepsilon_k, & k = 1 \\ \mu, & k > 1 \end{cases}$$

คุณสมบัติดังกล่าวสามารถขยายผลไปยัง  $MA(q)$  ใดๆว่าค่าพยากรณ์ไปข้างหน้า  $k$  คาบจะเท่ากับค่าเฉลี่ย หากคาบที่พยากรณ์ไปข้างหน้ามีค่าสูงกว่าอันดับของ  $MA$  ( $k > q$ )

## 2.3 แบบจำลองออโตรีเกรสซีฟมูวี่งเอเวอเรจ (Autoregressive Moving Average; $ARMA(p, q)$ )

เราสามารถสร้างแบบจำลองที่มีทั้งส่วนประกอบของออโตรีเกรสซีฟและมูวี่งเอเวอเรจ ซึ่งหาก  $y_t$  เป็นกระบวนการที่เรียกว่าแบบจำลองออโตรีเกรสซีฟมูวี่งเอเวอเรจอันดับ  $(p, q)$  หรือเรียกย่อว่า อารมา  $ARMA(p, q)$  ถ้า  $y_t$  มีค่าเฉลี่ยไม่เท่ากับศูนย์ เราจะสามารถอธิบาย  $y_t$  ได้ด้วย

$$y_t = \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} \quad (2.54)$$

หากเรากำหนดให้  $\alpha = \mu(1 - \phi_1 - \dots - \phi_p)$  และสามารถเขียนแบบจำลองสำหรับ  $y_t$  ได้เป็น

$$y_t = \alpha + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} \quad (2.55)$$

**นิยาม 2.2.** เราสามารถเขียนสมการอารมาได้ในรูปพหุนามออโตรีเกรสซีฟ และมูวี่งเอเวอเรจได้ดังนี้

$$\phi(L)y_t = \theta(L)\varepsilon_t$$

โดยที่  $\phi(L) = 1 - \phi_1 L - \dots - \phi_p L^p$  และ  $\theta(L) = 1 + \theta_1 L + \dots + \theta_q L^q$

เราสามารถพิจารณาคูสมบัติของแบบจำลองอารมาได้ด้วยการพิจารณา  $ARMA(1, 1)$

### 2.3.1 แบบจำลอง $ARMA(1, 1)$

กำหนดให้  $y_t$  เป็นกระบวนการ  $ARMA(1, 1)$  ซึ่งสามารถอธิบายได้ด้วยสมการข้างล่าง

$$y_t = \phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1} \quad (2.56)$$

โดยที่  $\varepsilon_t \sim iidN(0, \sigma^2)$  เพื่อสร้างสมการ Yule-Walker เราใช้ความสัมพันธ์ต่อไปนี้

$$\begin{aligned} E(\varepsilon_t y_t) &= E[\varepsilon_t(\phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1})] \\ &= \phi \underbrace{E(\varepsilon_t y_{t-1})}_{=0} + \underbrace{E(\varepsilon_t^2)}_{=\sigma^2} + \theta \underbrace{E(\varepsilon_t \varepsilon_{t-1})}_{=0} = \sigma^2 \end{aligned}$$

และ

$$\begin{aligned} E(\varepsilon_{t-1} y_t) &= E[\varepsilon_{t-1}(\phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1})] \\ &= \phi \underbrace{E(\varepsilon_{t-1} y_{t-1})}_{=\sigma^2} + \underbrace{E(\varepsilon_{t-1} \varepsilon_t)}_{=0} + \theta \underbrace{E(\varepsilon_{t-1}^2)}_{=\sigma^2} \\ &= \phi \sigma^2 + \theta \sigma^2 = (\phi + \theta) \sigma^2 \end{aligned}$$

หากเราคูณสมการ ?? ทั้งสองข้างด้วย  $y_{t-k}$  กรณีที่  $k = 0, 1, \dots, j, \dots$  และใส่ค่าคาดหวัง (take expectation) จะได้

$$\begin{aligned}\gamma_0 &= E(y_t y_t) = E((\phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}) y_t) \\ &= \phi \underbrace{E(y_t y_{t-1})}_{=\gamma_1} + \underbrace{E(y_t \varepsilon_t)}_{=\sigma^2} + \theta \underbrace{E(y_t \varepsilon_{t-1})}_{=(\phi+\theta)\sigma^2} \\ &= \phi \gamma_1 + [1 + \theta(\phi + \theta)] \sigma^2\end{aligned}\quad (2.57)$$

$$\begin{aligned}\gamma_1 &= E(y_t y_{t-1}) = E((\phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}) y_{t-1}) \\ &= \phi \underbrace{E(y_{t-1} y_{t-1})}_{=\gamma_0} + \underbrace{E(y_{t-1} \varepsilon_t)}_{=0} + \theta \underbrace{E(y_{t-1} \varepsilon_{t-1})}_{=\sigma^2} \\ &= \phi \gamma_0 + \theta \sigma^2\end{aligned}\quad (2.58)$$

$$\begin{aligned}\gamma_j &= E(y_t y_{t-j}) = E((\phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}) y_{t-j}) \\ &= \phi \underbrace{E(y_{t-1} y_{t-j})}_{=\gamma_{j-1}} + \underbrace{E(\varepsilon_t y_{t-j})}_{=0} + \theta \underbrace{E(\varepsilon_{t-1} y_{t-j})}_{=0}\end{aligned}\quad (2.59)$$

$$= \phi \gamma_{j-1} \quad (2.60)$$

กรณีที่  $j \geq 2$  จากสมการ ?? และ ?? เราจะได้

$$Var(y_t) = \gamma_0 = \frac{(1 + 2\phi\theta + \theta^2)}{1 - \phi^2} \sigma^2$$

และจากสมการ ?? เราสามารถหาค่าสหสัมพันธ์ในตัวเอง ณ ค่า  $j$  ใดๆ ที่  $j \geq 2$  ได้

$$\rho_j = \phi \rho_{j-1}$$


กรณีที่  $j \geq 2$  จะเห็นได้ว่า ACF มีค่าที่ลดลงเรื่อยๆ แบบฟังก์ชันเลขชี้กำลัง (exponential) นอกจากนี้ เราสามารถเขียนแบบจำลอง  $ARMA(1, 1)$  ในรูปของมูวี่งเอเวอเรจที่มีอันดับเป็นอนันต์ (infinite MA) ได้เป็น

$$y_t = \varepsilon_t + (\phi - \theta) \sum_{j=1}^{\infty} \phi^{j-1} \varepsilon_{t-j} \quad (2.61)$$

หรือ  $\psi_j = (\phi - \theta)\phi^{j-1}$  จะเห็นได้ว่าเงื่อนไขที่จะทำให้กระบวนการนี้เป็นกระบวนการนิ่งคือ  $|\phi| < 1$

กระบวนการ  $ARMA(p, q)$  จะนิ่งและ ergodic ถ้าค่าสัมบูรณ์ของค่ารากของพหุนามออโตรีเกรสซีฟ  $\phi(m) = 0$  มีค่ามากกว่าหนึ่ง (หรือมอดุลัสมีค่ามากกว่าหนึ่งในกรณีจำนวนเชิงซ้อน)

รูปที่ 2.10: ACF และ PACF ของอนุกรมเวลา ARMA(1,1)



และสามารถหาค่าผกผันได้ถ้ารากของพหุนามมูวี่งเอเวอเรจ  $\theta(m) = 0$  มีค่ามากกว่าหนึ่ง (หรือมอดูลัสมีค่ามากกว่าหนึ่งในกรณีจำนวนเชิงซ้อน) และพหุนาม AR และ MA ไม่มีตัวประกอบร่วมกระบวนการ  $ARMA(p, q)$  ที่หนึ่งจะมีค่าเฉลี่ยเท่ากับ

$$\mu = \frac{c}{1 - \phi_1 - \dots - \phi_p}$$

และค่าความแปรปรวนร่วมในตัวเอง ค่าสหสัมพันธ์ในตัวเองและตัวถ่วงน้ำหนักการตอบสนองแรงกระตุ้นสามารถเขียนในลักษณะเวียนเกิด (recursive) ได้ดังนี้

$$\begin{aligned}\gamma_j &= \phi_1 \gamma_{j-1} + \phi_2 \gamma_{j-2} + \dots + \phi_p \gamma_{j-p} \\ \rho_j &= \phi_1 \rho_{j-1} + \phi_2 \rho_{j-2} + \dots + \phi_p \rho_{j-p} \\ \psi_j &= \phi_1 \psi_{j-1} + \phi_2 \psi_{j-2} + \dots + \phi_p \psi_{j-p}\end{aligned}$$

โดยที่รูปทั่วไปของ ACF ของกระบวนการ  $ARMA(p, q)$  ค่อนข้างยุ่งยาก โดยสรุปแล้วทั้ง ACF และ PACF จะค่อยๆ ลดลงเรื่อยๆ แบบฟังก์ชันเลขชี้กำลัง (exponential) ดังตัวอย่างในรูปต่อไปนี้

ตัวอย่าง ความฟุ่มเฟือยของพารามิเตอร์ สมมติว่าเรากำลังพิจารณากระบวนการไวท์นอยซ์  $y_t = \varepsilon_t$  แล้วเรากำหนดทั้งสองและขยับไปข้างหลังหนึ่งคาบ  $0.5y_{t-1} = 0.5\varepsilon_{t-1}$  หลังจากนั้น เรานำสมการดังกล่าวไปลบจากสมการดั้งเดิมจะได้

$$y_t - 0.5y_{t-1} = \varepsilon_t - 0.5\varepsilon_{t-1} \quad (2.62)$$

จะมีลักษณะเหมือนกับแบบจำลอง  $ARMA(1, 1)$  แต่  $y_t$  ก็ยังเป็นไวท์นอยซ์ การใช้พารามิเตอร์อย่างฟุ่มเฟือยหรือใส่พารามิเตอร์มากเกินไป จะทำให้เราเข้าใจผิดว่ากระบวนการมีความสัมพันธ์ระหว่างกัน อย่างไรก็ตาม ปัญหาที่สามารถหลีกเลี่ยงได้ด้วยการพิจารณา polynomial และตัวคูณร่วม

ของ polynomial ตัวอย่างเช่นสมการ (??) สามารถเขียนได้เป็น

$$(1 - 0.5L)y_t = (1 - 0.5L)\varepsilon_t$$

ซึ่งสามารถเปลี่ยนกลับไปเป็นกระบวนการไวทน์อชด้วยการคูณทั้งสองข้างด้วย  $(1 - 0.5L)^{-1}$

### 2.3.2 การประมาณค่าสมการแบบจำลอง ARMA

เราสามารถประมาณค่าแบบจำลอง  $ARMA(p, q)$  ได้ด้วยวิธีการค่าความควรจะเป็นสูงที่สุด (MLE) ซึ่งเราสามารถใช้รูปแบบ state-space ในการสร้างฟังก์ชันล็อกไลเคิลฮูด อย่างไรก็ตาม ฟังก์ชันดังกล่าวที่แน่นอน (exact log-likelihood) นั้นมีรูปแบบที่ค่อนข้างซับซ้อน นอกจากนี้จุดเริ่มต้นของข้อมูลในกรณี exact likelihood จะใช้คุณสมบัติของการแจกแจงที่นิ่งเพื่อสร้างฟังก์ชันค่าควรจะเป็นของค่า  $y_t$   $p$  ค่าแรก และ  $\varepsilon_t$   $q$  ค่าแรก ในขณะที่ conditional likelihood จะสมมติให้  $y_t$   $p$  ค่าแรก และ  $\varepsilon_t$   $q$  ค่าแรกเท่ากับศูนย์ ตัวประมาณค่า Exact MLE จะเกิดจากการหาค่าสูงสุดจาก exact log-likelihood และ Conditional MLE จะเกิดจากการหาค่าสูงสุดจาก conditional log-likelihood โดยในกรณีที่จำนวนตัวอย่างมีจำนวนเข้าใกล้อนันต์จะมีค่าใกล้เคียงกัน แต่ค่าประมาณทั้งสองวิธีจะแตกต่างกันในกรณีที่ตัวอย่างมีจำนวนน้อย

หลังจากที่เราได้ค่าประมาณแล้วเราสามารถทดสอบความเพียงพอของแบบจำลองได้เช่นเดียวกับในกรณีของแบบจำลอง AR และ MA โดยที่ตัวสถิติ  $Q(m) \sim \chi^2_{m-p-q}$  และเราจะปฏิเสธสมมุติฐานหลักถ้า  $Q(m)$  มีค่ามากกว่าควอนไทล์ที่  $(1 - \alpha)$  ของ  $\chi^2_{m-p-q}$

### 2.3.3 เกณฑ์การเลือกแบบจำลอง (Model Selection Criteria)

ก่อนที่จะเราจะประมาณค่าแบบจำลอง  $ARMA(p, q)$  สำหรับอนุกรมเวลา  $y_t$  ใดๆ เราจะเป็นต้องระบุลำดับของ AR ( $p$ ) และ MA ( $q$ ) เสียก่อน โดยที่เราสามารถใช้การสังเกต ACF ของตัวอย่างในกรณีของ MA หรือ PACF ของตัวอย่าง ในกรณีของ AR อีกทางเลือกหนึ่งเราสามารถจะใช้เกณฑ์

ตารางที่ 2.2: สรุปลักษณะของ ACF และ PACF สำหรับแบบจำลอง ARMA

	$AR(p)$	$MA(q)$	$ARMA(p, q)$
ACF	ค่อยๆ ลดลง	ค่าเท่ากับศูนย์หลังจากช่วงล่าที่ $q$	ค่อยๆ ลดลง
PACF	เท่ากับศูนย์หลังจากช่วงล่าที่ $p$	ค่อยๆ ลดลง	ค่อยๆ ลดลง

การเลือกแบบจำลอง โดยที่แนวคิดคือการประมาณค่าแบบจำลอง  $ARMA(p, q)$  สำหรับค่าอันดับ  $p$  และ  $q$  ต่างๆ ที่น้อยกว่าค่าหนึ่งที่เรากำหนดไว้  $p_{max}$  และ  $q_{max}$  และเลือกค่า  $p$  และ  $q$  ที่ทำให้ค่าเกณฑ์การเลือกต่ำที่สุด โดยที่เกณฑ์การเลือกจะอยู่ในรูป

$$MSC(p, q) = \ln(\hat{\sigma}^2(p, q)) + c_T \varphi(p, q) \quad (2.63)$$



โดยที่  $\tilde{\sigma}^2(p, q)$  คือตัวประมาณค่าความแปรปรวนของข้อผิดพลาด  $c_T$  คือลำดับที่ขึ้นกับจำนวนตัวอย่าง และ  $\varphi(p, q)$  คือฟังก์ชันเบี่ยงปรับ (penalty function) กรณีที่เราเลือก  $p$  และ  $q$  มากๆ โดยที่แบบเกณฑ์ที่เป็นที่นิยมสามเกณฑ์ได้แก่ Akaike (AIC) Schwarz-Bayesian (BIC) และ Hannan-Quinn (HQIC) ซึ่งแสดงได้ด้วยสมการดังนี้

$$\begin{aligned} AIC(p, q) &= \ln(\tilde{\sigma}^2(p, q)) + \frac{2}{T}(p + q) \\ BIC(p, q) &= \ln(\tilde{\sigma}^2(p, q)) + \frac{\ln T}{T}(p + q) \\ HQIC(p, q) &= \ln(\tilde{\sigma}^2(p, q)) + \frac{2 \ln(\ln T)}{T}(p + q) \end{aligned}$$

โดยที่ในกรณีที่กลุ่มตัวอย่างใหญ่ เกณฑ์ AIC จะเลือกอันดับที่มากกว่าที่ควรจะเป็น ในขณะที่เกณฑ์ BIC และ HQIC เลือกค่าที่ใกล้เคียงความเป็นจริง (consistent) อย่างไรก็ตามในตัวอย่างขนาดเล็ก เกณฑ์ทั้งสามจะให้ค่าที่ไม่แตกต่างกันนัก

## ตัวอย่างที่ 2.6: การสร้างแบบจำลองสำหรับผลได้ตอบแทนของการซื้อขายเงินตราต่างประเทศโดย ARMA(p,q)


ตัวอย่างนี้เราพิจารณาผลได้ตอบแทนของการซื้อขายเงินตราต่างประเทศโดยคำนวณจากอัตราแลกเปลี่ยนบาทต่อดอลลาร์สหรัฐระหว่างปี 1998 ถึง 2012 ซึ่งอยู่ในไฟล์ `thbusd.csv` เราสามารถนำเข้าข้อมูลและคำนวณผลได้ตอบแทนได้ดังนี้

```
1 > exc<-
  read.csv("https://raw.githubusercontent.com/chaileampong/EC435/master/thbusd.csv",
  header = TRUE)
2 > head(exc)
3   Jul.Day YYYY.MM.DD wdy THB.USD
4 1 2450816 1/2/1998 Fri 48.023
5 2 2450819 1/5/1998 Mon 50.366
6 3 2450820 1/6/1998 Tue 52.665
7 4 2450821 1/7/1998 wed 52.203
8 5 2450822 1/8/1998 Thu 53.957
9 6 2450823 1/9/1998 Fri 53.204
10 > excret <- diff(log(exc$THB.USD))
11 > ts.plot(excret, main = "Exchange rate return")
```

เมื่อพิจารณา ACF และ PACF จากรูป ?? จะพบว่าแบบจำลองที่เหมาะสมน่าจะเป็น  $ARMA(p, q)$  เนื่องจาก ฟังก์ชันทั้งสองมิได้ลดลงอย่างมีรูปแบบ ดังนั้นเราจำเป็นต้องเลือกอันดับ  $p$  และ  $q$  ที่เหมาะสม โดยที่เราสามารถเปลี่ยนค่า  $p$  และ  $q$  ในคำสั่ง `arima` ไปเรื่อยๆ  $(0, 0), (1, 0), (2, 0), (0, 1), (0, 2), (1, 1), (2, 2), \dots$  และบันทึกค่า AIC หรือ BIC ที่ได้แล้วเลือกแบบจำลองที่มีค่า AIC หรือ BIC น้อยที่สุด

อย่างไรก็ตาม package "forecast" มีคำสั่ง `auto.arima(series, arguments)` ที่ จะทำการทดลองสร้างแบบจำลองตามค่า  $p$  และ  $q$  สูงสุดที่เรากำหนด แล้วเลือกแบบจำลองตาม

รูปที่ 2.11: ACF และ PACF ของผลได้ตอบแทนรายวันจากการซื้อขายเงินดอลลาร์สหรัฐ



Information criteria ที่เราได้ arguments ต่อไปนี้ ค่า  $d = 0$ ,  $D = 0$ ,  $\max.p=6$ ,  $\max.q=6$ ,  $\max.order=[\max.p+\max.q]$ ,  $ic=c("aic")$  โดยที่เราสามารถเปลี่ยนเป็น  $bic$ ,  $stepwise=FALSE$  แปลว่าให้ทดลองทุกค่าของ  $p$  และ  $q$  ที่น้อยกว่า  $\max.p$  และ  $\max.q$  และ  $trace=TRUE$  แปลว่าให้แสดงค่า IC จากทุกการทดลอง

```

1 > library(forecast)
2 > auto.arima(ret,d=0,D=0,max.p=6,max.q=6,ic=c("aic"),stepwise=FALSE,trace=TRUE)
3
4 ARIMA(0,0,0) with zero mean      : -27687.05
5 ARIMA(0,0,0) with non-zero mean : -27686.59
6 [omitted]
7 ARIMA(5,0,0) with zero mean      : -27850.55
8 ARIMA(5,0,0) with non-zero mean : -27851.11
9
10 Series: ret
11 ARIMA(4,0,1) with non-zero mean
12
13 Coefficients:
14      ar1      ar2      ar3      ar4
15  -0.5876  -0.0238  -0.0066  -0.0227
16 s.e.    0.2641   0.0196   0.0208   0.0199
17      ma1 intercept
18    0.5981    -1e-04
19 s.e.  0.2636     1e-04
20
21 sigma^2 estimated as 3.432e-05:  log likelihood=13849.44
22 AIC=-27684.88  AICC=-27684.85  BIC=-27641.33

```

แบบจำลองที่เราเลือกจากค่า AIC น้อยที่สุดคือแบบจำลอง  $ARMA(4, 1)$  ผู้อ่านอาจจะลองใช้เกณฑ์ BIC แล้วเปรียบเทียบว่าแบบจำลองที่แนะนำต่างกันหรือไม่

### 2.3.4 การเขียนกระบวนการอาร์มา(ARMA)ในสามรูปแบบ

จากแบบจำลองที่เราอธิบาย  $y_t$  ด้วยแบบจำลอง ARMA ในรูปแบบพหุนาม

$$\phi(L)y_t = \theta(L)\varepsilon_t$$

โดยที่  $\phi(L) = 1 - \sum_{i=1}^p \phi_i L^i$  และ  $\theta(L) = 1 + \sum_{i=1}^q \theta_i L^i$  เราสามารถแสดง  $y_t$  โดยใช้

$$\frac{\theta(L)}{\phi(L)} = 1 + \psi_1 L + \psi_2 L^2 + \dots = \psi(L) \quad (2.64)$$

และ

$$\frac{\phi(L)}{\theta(L)} = 1 - \pi_1 L - \pi_2 L^2 - \dots = \pi(L) \quad (2.65)$$

### 2.3.5 การพยากรณ์ (forecasting)

จากรูปแบบของแบบจำลอง ARMA ในหัวข้อที่ผ่านมา เราสามารถแสดงแบบจำลอง ARMA( $p, q$ ) ได้สามรูปแบบคือ รูปแบบที่หนึ่งคือรูปแบบ ARMA( $p, q$ )

$$\phi(L)y_t = \theta(L)\varepsilon_t$$

รูปแบบที่สองคือการแสดงในรูปมูวี่งเอเวอเรจอนันต์ (Infinite moving average representation)

$$y_t = \frac{\theta(L)}{\phi(L)}\varepsilon_t = \psi(L)\varepsilon_t$$

และรูปแบบที่สามคือการแสดงในรูปออโตรีเกรสซีฟอนันต์ (Infinite autoregressive representation)

$$\frac{\phi(L)}{\theta(L)}y_t = \pi(L)y_t = \varepsilon_t$$

โดยที่  $\psi(L) = 1 + \psi_1 L + \psi_2 L^2 + \dots$  และ  $\pi(L) = 1 - \pi_1 L - \pi_2 L^2 - \dots$  ดังนั้นเราสามารถพยากรณ์ตัวแปร  $y_{h+l}$  ด้วยสมการใดสมการหนึ่งในสามรูปแบบนี้ได้ ยกตัวอย่างเช่น กรณีใช้รูปแบบ ARMA การพยากรณ์ไปข้างหน้าหนึ่งคาบ ณ ข้อมูลที่คาบ  $h$ ,  $\hat{y}_h(1)$  จะเท่ากับ

$$\begin{aligned} \hat{y}_h(1) &= E(\phi_1 y_h + \dots + \phi_p y_{h-p} + \varepsilon_{h+1} - \theta_1 \varepsilon_h + \dots + \theta_q \varepsilon_{h+1-q} | F_h) \\ &= \phi_1 y_h + \dots + \phi_p y_{h-p} - \theta_1 \varepsilon_h + \dots + \theta_q \varepsilon_{h+1-q} \end{aligned} \quad (2.66)$$

กรณีใช้รูปแบบออโตรีเกรสซีฟอนันต์ การพยากรณ์ไปข้างหน้าหนึ่งคาบ ณ ข้อมูลที่คาบ  $h$ ,  $\hat{y}_h(1)$  จะเท่ากับ

$$\begin{aligned}\hat{y}_h(1) &= E(\pi_1 y_h + \pi_2 y_{h-1} + \dots | F_h) \\ &= \pi_1 y_h + \pi_2 y_{h-1} + \dots\end{aligned}\quad (2.67)$$

และกรณีการแสดงในรูปมูวึงเอเวอเรจอนันต์ การพยากรณ์ไปข้างหน้าหนึ่งคาบ ณ ข้อมูลที่คาบ  $h$ ,  $\hat{y}_h(1)$  จะเท่ากับ

$$\begin{aligned}\hat{y}_h(1) &= E(\varepsilon_{h+1} + \psi_1 \varepsilon_h + \pi_2 \varepsilon_{h-1} + \dots | F_h) \\ &= \psi_1 \varepsilon_h + \pi_2 \varepsilon_{h-1} + \dots\end{aligned}\quad (2.68)$$

## 2.4 Unit Root Nonstationary

อนุกรมเวลาทางเศรษฐกิจและการเงินจำนวนมากมีพฤติกรรมที่มีแนวโน้ม (trend) หรือมีลักษณะไม่นิ่ง (non-stationary) ตัวอย่างเช่น ราคาหลักทรัพย์ อัตราแลกเปลี่ยน หรือตัวแปรเศรษฐกิจมหภาคเช่น ผลิตภัณฑ์มวลรวมภายในประเทศ (GDP) ดังนั้นในการวิเคราะห์อนุกรมเวลาเราพิจารณาลักษณะของรูปแบบแนวโน้มของข้อมูลว่าเกิดจากความไม่นิ่งหรือเป็นแนวโน้ม เนื่องจากคุณลักษณะดังกล่าวจะส่งผลกระทบต่อการใช้ข้อมูลไปใช้ เช่น ในการสร้างแบบจำลอง *ARMA* เราจำเป็นต้องทำการแปลงข้อมูลในนิ่งเสียก่อน ในขณะที่ถ้าข้อมูลมีแนวโน้มเราจำเป็นต้องขจัดแนวโน้มเสียก่อน โดยที่กระบวนการที่มีลักษณะแนวโน้มอาจจะแบ่งได้เป็นสองกรณีคือกระบวนการเดินแบบสุ่ม (random walk) แบบมีแนวโน้มด้วย (with drift) และกระบวนการที่นิ่งหลังจากกำจัดแนวโน้ม (trend stationary)

กรณีแรก คือกรณีที่  $y_t$  เป็นกระบวนการที่นิ่งหลังจากดำเนินการผลต่าง (difference-stationary) หากกระบวนการ  $y_t$  เป็นกระบวนการเดินแบบสุ่มแบบมีแนวโน้มด้วย จะสามารถเขียนสมการอธิบาย  $y_t$  ได้ดังนี้

$$y_t = \mu + y_{t-1} + \varepsilon_t \quad (2.69)$$

โดย  $\varepsilon_t \sim WN(0, \sigma^2)$  และเราเรียก  $\mu$  ว่าตัวสร้างแนวโน้ม (drift) หากเราสมมุติให้  $y_0 = 0$  และแทนค่าแบบ recursive เราจะสามารถเขียนสมการ (??) ได้เป็น

$$y_t = \mu t + \sum_{j=1}^t \varepsilon_j \quad (2.70)$$

จากสมการที่ (??) กระบวนการเดินแบบสุ่มแบบมีแนวโน้มจะมีค่าคาดหวัง ( $E(y_t)$ ) เท่ากับ  $\mu t$  และค่าความแปรปรวน ( $Var(y_t)$ ) เท่ากับ  $\sigma^2 t$  จะเห็นได้ว่าค่าทั้งสองขึ้นอยู่กับเวลา  $t$  ดังนั้น  $y_t$  จากสมการ (??) จะเป็นกระบวนการที่ไม่นิ่ง (non-stationary)

กรณีสอง คือกรณีที่  $z_t$  เป็นกระบวนการที่นิ่งหลังจากกำจัดแนวโน้ม (trend-stationary) เรา

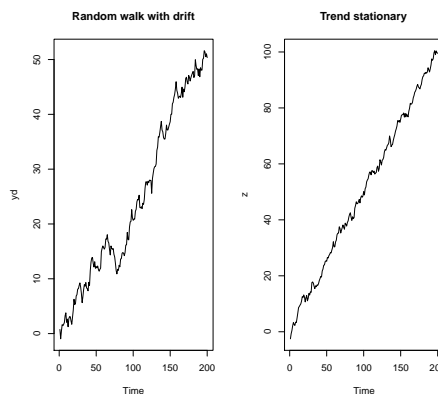
สามารถเขียนสมการอธิบาย  $z_t$  ได้ด้วย

$$z_t = \beta_0 + \beta_1 t + v_t \quad (2.71)$$

โดยที่  $v_t$  เป็นอนุกรมนิ่งใดๆเช่น กระบวนการไวท์นอยส์หรือ  $AR(1)$  ที่มีค่าสัมบูรณ์ของสัมประสิทธิ์น้อยกว่า 1 จากสมการที่ (??) เราสามารถพิสูจน์ได้ว่าค่าคาดหวังของ  $(E(z_t))$  จะเท่ากับ  $\beta_0 + \beta_1 t$  ซึ่งเป็นฟังก์ชันเส้นตรงกับเวลา ดังนั้น  $z_t$  จึงเป็นกระบวนการ non-stationary โดยที่  $z_t$  จะแกว่งตัวอยู่รอบๆเส้นแนวโน้ม ในขณะที่ ค่าความแปรปรวน ( $Var(z_t)$ ) จะเท่ากับ  $Var(v_t)$  ซึ่งจำกัดและไม่แปรผันตามเวลา (เนื่องจากเราสมมติให้  $v_t$  เป็นอนุกรมนิ่ง)

ตัวอย่างของกราฟข้อมูลกระบวนการนิ่งหลังจากดำเนินการผลต่าง (difference-stationary) และกระบวนการนิ่งหลังจากกำจัดแนวโน้ม (trend-stationary) ถูกแสดงไว้ในรูปที่ ?? โดยมองดูดีๆจะเห็นได้ว่าภาพทั้งสองมีลักษณะที่คล้ายคลึงกัน

รูปที่ 2.12: ข้อมูลจำลองของกระบวนการแนวโน้มแบบสุ่มแบบมีแนวโน้มและกระบวนการที่นิ่งหลังจากขจัดแนวโน้ม



กระบวนการทั้งสองที่ได้ยกตัวอย่างมา เป็นกระบวนการที่ไม่นิ่ง (non-stationary) แต่มีคุณลักษณะที่แตกต่างกัน ดังนั้น วิธีการที่ใช้ในทำให้อนุกรมนิ่งจึงแตกต่างกัน โดยวิธีการที่ใช้ทำให้อนุกรมนิ่งมีอยู่สองวิธีคือ การดำเนินการผลต่าง (differencing) และการประมาณค่าถดถอยเพื่อกำจัดแนวโน้ม (detrended series)

วิธีการดำเนินการผลต่าง คือการนำข้อมูลที่คาบ  $t$  ลบออกด้วยข้อมูลที่คาบ  $t - 1$  หรือเขียนเป็นสัญลักษณ์ได้โดย  $\Delta y_t = y_t - y_{t-1}$  ซึ่งเราเรียกกรณีนี้ว่าการดำเนินการผลต่างครั้งที่หนึ่ง (first difference) หากเรานำอนุกรมที่ได้จากการดำเนินการผลต่างครั้งที่หนึ่งไปดำเนินการผลต่างอีกครั้ง  $\Delta^2 y_t = \Delta y_t - \Delta y_{t-1}$  เราจะเรียกว่า การดำเนินการผลต่างครั้งที่สอง (second difference) วิธีการดำเนินการผลต่างจะเหมาะกับอนุกรมเวลาที่เป็นกระบวนการนิ่งหลังจากดำเนินการผลต่าง โดยที่หากอนุกรมเวลา  $y_t$  เป็นอนุกรมที่นิ่งหลังจากการดำเนินการผลต่างครั้งที่หนึ่ง เราจะเรียกอนุกรมเวลา  $y_t$  ว่าอนุกรมเวลาที่มีอันดับอินทิเกรตเท่ากับหนึ่ง (Integrated of order 1 หรือ  $I(1)$ ) หากอนุกรมเวลา  $y_t$  เป็นอนุกรมที่นิ่งหลังจากการดำเนินการผลต่างครั้งที่สอง เราจะเรียกอนุกรมเวลา  $y_t$  ว่า

อนุกรมเวลาที่มีอันดับอินทิเกรตเท่ากับสอง (Integrated of order 2 หรือ  $I(2)$ ) ในขณะที่อนุกรมเวลานิ่งก็คือ  $I(0)$

วิธีการที่สองเหมาะกับอนุกรมที่เป็นกระบวนการนิ่งหลังจากกำจัดแนวโน้ม โดยเราจะประมาณค่าสมการ ?? ด้วย OLS เมื่อได้ค่า  $\hat{\beta}_0$  และ  $\hat{\beta}_1$  เราสามารถสร้างอนุกรมเวลาที่ขจัดแนวโน้มออกไปได้โดยการคำนวณ  $z_t = y_t - \hat{\beta}_0 - \hat{\beta}_1 t$  โดยเครื่องมือสำคัญที่ใช้ในการระบุว่าควรจะใช้วิธีการใดในการกำจัดแนวโน้มคือ การทดสอบยูนิตรูท (unit root test)

เพื่อให้เราเข้าใจ แนวคิด พื้นฐาน ในการ ทดสอบ ยูนิต รูท และการ ทดสอบ ความ นิ่ง (stationary) เราพิจารณาอนุกรม  $y_t$  ซึ่งสามารถแยกได้เป็นส่วนของแนวโน้มและวัฏจักรโดยที่

$$\begin{aligned} y_t &= TD_t + z_t \\ TD_t &= k + \delta t \\ z_t &= \phi z_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim WN(0, \sigma^2) \end{aligned}$$

โดยที่  $TD_t$  เป็นแนวโน้มเส้นตรงเชิงกำหนด (deterministic linear trend) และ  $z_t$  คือกระบวนการ  $AR(1)$  ถ้า  $|\phi| < 1$  แล้ว  $y_t$  จะเป็นอนุกรมนิ่ง ( $I(0)$ ) รอบๆแนวโน้มเชิงกำหนด  $TD_t$  แต่ถ้า  $\phi = 1$  แล้วอนุกรม  $z_t$  จะกลายเป็นแนวโน้มสโตแคสติก และ  $y_t$  เป็น  $I(1)$  ที่มี drift

การทดสอบยูนิตรูทในรูปของแบบถดถอยในตัวเองมีพื้นฐานจากการทดสอบสมมติฐานหลักว่า  $\phi = 1$  (อนุกรมนิ่งหลังจาก differencing) กับสมมติฐานทางเลือก  $\phi < 1$  (อนุกรมนิ่งหลังจากขจัดแนวโน้ม) โดยที่เราเรียกการทดสอบนี้ว่ายูนิตรูท เนื่องจากภายใต้สมมติฐานหลักรากของพหุนาม  $\phi(z) = (1 - \phi z) = 0$  มีค่าเท่ากับหนึ่ง

#### 2.4.1 การทดสอบยูนิตรูทในรูปสมการถดถอยในตัวเอง

สมมติว่าเราพิจารณาแบบจำลอง  $AR(1)$  ซึ่งเขียนได้ดังนี้

$$y_t = \phi y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim WN(0, \sigma^2) \quad (2.72)$$

โดยที่สมมติฐานที่เราต้องการทดสอบคือ

$$\begin{aligned} H_0 : \phi &= 1 & (y_t \sim I(1)) \\ H_1 : |\phi| &< 1 & (y_t \sim I(0)) \end{aligned}$$

เราสามารถประมาณค่าสมการ ?? ด้วย OLS และใช้ตัวสถิติที่เรียกว่าตัวสถิติ Dickey-Fuller  $t$  ซึ่งคำนวณได้โดย

$$t_{\phi=1} = \frac{\hat{\phi} - 1}{se(\hat{\phi})}$$

โดยที่  $\hat{\phi}$  คือค่าประมาณจากวิธีการกำลังสองน้อยที่สุดและ  $se(\hat{\phi})$  คือค่าผิดพลาดมาตรฐาน (standard error) โดยที่การทดสอบนี้เป็นการทดสอบทางเดียวทางซ้าย คือเราจะปฏิเสธสมมติฐานหลักถ้าค่าตัวสถิติน้อยกว่าค่าวิกฤติ และสรุปว่าอนุกรมเวลาเป็นอนุกรมนิ่ง หากเราไม่สามารถปฏิเสธสมมติฐานหลักได้ แสดงว่าอนุกรมดังกล่าวเป็นยูนิทรูท นอกจากนี้เราสามารถใช้อยู่ตัวสถิติ normalized bias ซึ่งคำนวณได้ด้วย  $T(\hat{\phi} - 1)$  ในการทดสอบยูนิทรูทเช่นเดียวกัน

สมการ ?? ที่เราใช้ในการทดสอบยูนิทรูทยังสามารถเขียนในรูป

$$\Delta y_t = \pi y_{t-1} + \varepsilon_t, \quad (2.73)$$

โดยที่  $\pi = (\phi - 1)$  ซึ่งในที่นี้การทดสอบยูนิทรูทจะเป็นการทดสอบ  $H_0 : \pi = 0$  และ  $H_1 : \pi < 0$  ตัวสถิติที่ใช้ในการทดสอบยูนิทรูทจะมีการแจกแจงที่ไม่เป็นมาตรฐานและไม่เป็นการแจกแจงแบบปกติเมื่อข้อมูลขนาดใหญ่เหมือนในกรณีทดสอบอื่นๆที่เราเคยพบมา Phillips (1987) ได้พิสูจน์ว่าหาก  $y_t$  เป็นยูนิทรูท การแจกแจงของตัวสถิติทั้งสองที่ใช้ทดสอบยูนิทรูทจะมีการแจกแจงดังนี้

$$t_{\phi=1} \xrightarrow{d} \frac{\int_0^1 W(r) dW(r)}{\left( \int_0^1 W(r)^2 dr \right)^{1/2}} \quad (2.74)$$

$$T(\hat{\phi} - 1) \xrightarrow{d} \frac{\int_0^1 W(r) dW(r)}{\int_0^1 W(r)^2 dr} \quad (2.75)$$

โดยที่  $W(r)$  คือการเคลื่อนที่แบบบราวเนียน (Brownian motion) จากสมการข้างต้น ตัวประมาณค่าและตัวสถิติจะไม่มีการแจกแจงเข้าสู่การแจกแจงปกติ เราจะเรียกการแจกแจงของ  $t_{\phi=1}$  ว่า การแจกแจง Dickey-Fuller  $t$  และการแจกแจงของ  $T(\hat{\phi} - 1)$  ว่าการแจกแจง Dickey-Fuller normalized bias

ตาราง สำหรับ การ แจกแจง Dickey-Fuller สามารถ ใช้ คำ สั่ง `adfTable` ใน `Library(funitRoots)` โดยระบุรูปแบบของสมการที่ใช้ในการทดสอบ เช่น `trend=c("nc")` กรณีที่สมการทดสอบไม่มีพจน์ค่าคงที่อยู่ (no constant) เช่นในสมการ ?? (ในหัวข้อย่อต่อไปจะพิจารณากรณีมีพจน์ค่าคงที่ และจุดตัด) และแสดงการแจกแจงของ  $t$  โดยระบุ `statistics=c("t")` ส่วนการแจกแจง Dickey-Fuller normalized bias จะต้องระบุว่า `statistics=c("n")`

```

1 > library(fUnitRoots)
2 > adfTable(trend=c("nc"), statistic=c("t"))
3 $x
4 [1] 25 50 100 250 500 Inf
5
6 $y
7 [1] 0.010 0.025 0.050 0.100 0.900 0.950 0.975 0.990
8
9 $z
10 0.010 0.025 0.050 0.100 0.900 0.950 0.975 0.990
11 25 -2.66 -2.26 -1.95 -1.60 0.92 1.33 1.70 2.16
12 50 -2.62 -2.25 -1.95 -1.61 0.91 1.31 1.66 2.08
13 100 -2.60 -2.24 -1.95 -1.61 0.90 1.29 1.64 2.03
14 250 -2.58 -2.23 -1.95 -1.62 0.89 1.29 1.63 2.01
15 500 -2.58 -2.23 -1.95 -1.62 0.89 1.28 1.62 2.00
16 Inf -2.58 -2.23 -1.95 -1.62 0.89 1.28 1.62 2.00
17
18 attr("class")
19 [1] "gridData"
20 attr("control")
21 table trend statistic
22 "adf" "nc" "t"

```

โดยที่  $x$  เป็นจำนวนตัวอย่างและ  $y$  เป็นความถี่สะสม และค่า critical value จะอยู่ในส่วน  $z$  ตัวอย่างเช่นกลุ่มตัวอย่าง 100 ตัวอย่างที่ค่า ADF เท่ากับ -1.95 จะมีความถี่สะสมเท่ากับ 0.05 หรือพื้นที่ใต้กราฟการแจกแจง Dickey-Fuller ทางซ้ายของ -1.95 จะเท่ากับ 5 %

ตารางที่ 2.3: ค่าวิกฤตของการแจกแจง Dickey-Fuller  $t$  statistics กรณีไม่มีค่าคงที่

จำนวน ตัวอย่าง	ความถี่สะสม							
	0.01	0.025	0.05	0.1	0.9	0.95	0.975	0.99
25	-2.66	-2.26	-1.95	-1.60	0.92	1.33	1.70	2.16
50	-2.62	-2.25	-1.95	-1.61	0.91	1.31	1.66	2.08
100	-2.60	-2.24	-1.95	-1.61	0.90	1.29	1.64	2.03
250	-2.58	-2.23	-1.95	-1.62	0.89	1.29	1.63	2.01
500	-2.58	-2.23	-1.95	-1.62	0.89	1.28	1.62	2.00
$\infty$	-2.58	-2.23	-1.95	-1.62	0.89	1.28	1.62	2.00

### กรณีอนุกรมเวลามีค่าคงที่และแนวโน้ม

สิ่งสำคัญในการทดสอบยูนิทรคือการระบุว่าสมมุติฐานหลักและสมมุติฐานทางเลือกมีความเหมาะสมกับข้อมูลหรือ โดยเฉพาะแนวโน้ม โดยกรณีที่เราพบบ้อยมีสองกรณีคือกรณีมีค่าคงที่อย่างเดียว และกรณีมีค่าคงที่และแนวโน้ม

ในกรณีค่าคงที่อย่างเดียว สมการที่ใช้ในการประมาณค่าตัวสถิติทดสอบคือ

$$y_t = c + \phi y_{t-1} + \varepsilon_t \quad (2.76)$$



และสมมุติฐานที่เกี่ยวข้องคือ

$$\begin{aligned} H_0 : \phi &= 1 & (y_t \sim I(1) \text{ without drift}) \\ H_1 : |\phi| &< 1 & (y_t \sim I(0) \text{ with non-zero mean}) \end{aligned}$$

ในกรณีที่มีค่าคงที่และแนวโน้ม สมการที่ใช้ในการประมาณค่า

$$y_t = c + \delta t + \phi y_{t-1} + \varepsilon_t \quad (2.77)$$

และสมมุติฐานที่เกี่ยวข้องกันคือ

$$\begin{aligned} H_0 : \phi &= 1 & (y_t \sim I(1) \text{ with drift}) \\ H_1 : |\phi| &< 1 & (y_t \sim I(0) \text{ with deterministic time trend}) \end{aligned}$$

โดยที่รูปแบบของสมการที่ใช้ในการทดสอบมักจะเป็นในรูปแบบ

$$\Delta y_t = c + \pi y_{t-1} + \varepsilon_t$$

และ

$$\Delta y_t = c + \delta t + \pi y_{t-1} + \varepsilon_t$$

สำหรับสมการที่มีค่าคงที่และมีค่าคงที่และแนวโน้มตามลำดับ ดังนั้นการตัดสินใจว่าจะใช้สมการรูปแบบไหน สามารถทำได้โดยการพิจารณากราฟเส้นของ  $\Delta y_t$  มีค่าเฉลี่ยต่างจากศูนย์หรือมีเส้นแนวโน้มหรือไม่ โดยที่ตารางสำหรับการแจกแจง Dickey-Fuller ของแต่ละรูปแบบของสมการจะมีค่าที่แตกต่างกัน โดยที่กรณีมีค่าคงที่จะใช้ตัวเลือก `trend=c("c")` และกรณีมีค่าคงที่และเส้นแนวโน้มจะใช้ `trend=c("ct")` ในคำสั่ง

```
1 > adfTable(trend=c("c"), statistic=c("t"))
2 > adfTable(trend=c("ct"), statistic=c("t"))
```

แล้วจะได้ตารางดังนี้

### การทดสอบยูนิทรูททิกกี ฟูลเลอร์แบบแต่งเติม(Augmented Dickey-Fuller)

การทดสอบยูนิทรูทที่ได้อีกว่าไว้ข้างต้นนั้นจะต้องถ้าวอนุกรมเวลาเป็น  $AR(1)$  ที่มีชื่อเป็น ไวทน้อยซ Said and Dickey (1984) ได้เสริมการทดสอบยูนิทรูทด้วยพจน์ที่เพิ่มเข้าไป โดยมีพื้นฐานจากแบบจำลอง  $ARMA(p, q)$  แล้วเรียกว่า การทดสอบยูนิทรูททิกกี ฟูลเลอร์แบบแต่ง

ตารางที่ 2.4: ค่าวิกฤตของการแจกแจง Dickey-Fuller กรณีมีค่าคงที่

จำนวน ตัวอย่าง	ความถี่สะสม							
	0.01	0.025	0.05	0.1	0.9	0.95	0.975	0.99
25	-3.75	-3.33	-3.00	-2.63	-0.37	0.00	0.34	0.72
50	-3.58	-3.22	-2.93	-2.60	-0.40	-0.03	0.29	0.66
100	-3.51	-3.17	-2.89	-2.58	-0.42	-0.05	0.26	0.63
250	-3.46	-3.14	-2.88	-2.57	-0.42	-0.06	0.24	0.62
500	-3.44	-3.13	-2.87	-2.57	-0.43	-0.07	0.24	0.61
$\infty$	-3.43	-3.12	-2.86	-2.57	-0.44	-0.07	0.23	0.60

ตารางที่ 2.5: ค่าวิกฤตของการแจกแจง Dickey-Fuller กรณีมีค่าคงที่และแนวโน้ม

จำนวน ตัวอย่าง	ความถี่สะสม							
	0.01	0.025	0.05	0.1	0.9	0.95	0.975	0.99
25	-4.38	-3.95	-3.60	-3.24	-1.14	-0.80	-0.50	-0.15
50	-4.15	-3.80	-3.50	-3.18	-1.19	-0.87	-0.58	-0.24
100	-4.04	-3.73	-3.45	-3.15	-1.22	-0.90	-0.62	-0.28
250	-3.99	-3.69	-3.43	-3.13	-1.23	-0.92	-0.64	-0.31
500	-3.98	-3.68	-3.42	-3.13	-1.24	-0.93	-0.65	-0.32
$\infty$	-3.96	-3.66	-3.41	-3.12	-1.25	-0.94	-0.66	-0.33

เต็ม(Augmented Dickey-Fuller) ซึ่งตัวทดสอบสามารถประมาณค่าได้จากสมการ

$$y_t = \beta'(D_t) + \phi y_{t-1} + \sum_{j=1}^p \psi_j \Delta y_{t-j} + \varepsilon_t \quad (2.78)$$

หรือเราสามารถประมาณค่าสมการนี้

$$\Delta y_t = \beta' D_t + \pi y_{t-1} + \sum_{j=1}^p \psi_j \Delta y_{t-j} + \varepsilon_t \quad (2.79)$$

โดยที่  $\pi = \phi - 1$  ซึ่งภายใต้สมมุติฐานหลัก  $\Delta y_t$  จะเป็น  $I(0)$  และอนุมานได้ว่า  $\pi = 0$  ดังนั้น ตัวสถิติ  $t$  สำหรับยูนิทรูทด้วยดิกกี ฟูลเลอร์แบบแต่งเต็ม จะเป็นค่าที่ของสัมประสิทธิ์หน้า  $y_t$

## ตัวอย่างที่ 2.7 การทดสอบ Augmented Dickey Fuller Unit root

ตัวอย่าง นี้ เรา ต้องการ ทดสอบ ยู นิ ทรูท ของ SET index ราย วัน จาก ข้อมูล ใน ไฟล์ setindex.txt ซึ่งมีตัวอย่างเท่ากับ 3642 ตัวอย่าง โดยที่ในโปรแกรมอาร์มีชุดคำสั่งหลายชุดคำสั่งที่สามารถทำการทดสอบ ADF ได้เช่น urca, stats, tseries แต่ในที่นี้เราจะใช้ชุดคำสั่ง

urca โดยเบื้องต้นเราจะพิจารณา ACF ของอนุกรมเวลาและอนุกรมเวลาที่ได้ปรับผลต่างอันดับหนึ่ง (first-differenced) จาก ACF ของอนุกรมเวลา `setd$index` เราพบว่าน่าจะมีปัญหายูนิทรุตเนื่องจากค่า ACF ลดลงช้ามาก

```
1 > setd <-
    read.csv("https://raw.githubusercontent.com/chalearmong/EC435/master/setdaily.csv",
    header = TRUE)
2 > head(setd)
3   X      date  index
4 1 1  1/5/1998 366.18
5 2 2  1/6/1998 370.27
6 3 3  1/7/1998 370.31
7 4 4  1/8/1998 360.17
8 5 5  1/9/1998 349.67
9 6 6 1/12/1998 339.17
10 > ts.plot(setd$index)
11 > acf(setd$index)
```

เราสามารถทดสอบ unit root ด้วยคำสั่ง `ur.df` จาก package `urca` ซึ่งเป็นการทดสอบ Dickey Fuller Unit root โดยเรากำหนดตัวแปรที่ต้องการทดสอบ `setd$index` แล้วเลือกรูปแบบของสมการที่เราใช้ทดสอบซึ่งสามารถเลือกได้เป็นสมการที่ไม่มีค่าคงที่ (none) มีค่าคงที่ (drift) และมีเส้นแนวโน้ม (trend) ด้วยการระบุใน type เช่น ``type=c("trend")`` แล้วเลือกว่าจะมี lag ของตัวแปรตามเท่ากับเท่าใด ซึ่งมีทางเลือกในการระบุจำนวนเลข เช่น `lags=1` หรือใช้ model selection criteria เช่น `selectlags = c("AIC")`

ในกรณีแรกที่ระบุ `lags=1` เราเก็บผลไว้ในชื่อ `setd.df` ค่าสถิติที่ได้คือ `-1.863` ซึ่งมากกว่า critical value ที่  $\alpha = 0.05$  เท่ากับ `-3.41` ดังนั้น เราไม่สามารถปฏิเสธสมมติฐานที่ว่า `setd` เป็น unit root

```

1 > library(urca)
2 > setd.df<-ur.df(setd$index, type=c("trend"), lags=1 )
3 > summary(setd.df)
4 #####
5 # Augmented Dickey-Fuller Test Unit Root Test #
6 #####
7 Test regression trend
8 Call:
9 lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
10 Residuals:
11      Min       1Q   Median       3Q      Max
12 -108.380  -4.745  -0.105   4.837   74.125
13 Coefficients:
14             Estimate Std. Error t value Pr(>|t|)
15 (Intercept)  0.4325591  0.4122648   1.049  0.29414
16 z.lag.1      -0.0021279  0.0011419  -1.864  0.06247 .
17 tt           0.0006223  0.0002840   2.191  0.02851 *
18 z.diff.lag    0.0478816  0.0165720   2.889  0.00388 **
19 ---
20 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
21
22 Residual standard error: 9.355 on 3636 degrees of freedom
23 Multiple R-squared:  0.003526, Adjusted R-squared:  0.002704
24 F-statistic: 4.289 on 3 and 3636 DF, p-value: 0.004982
25
26 Value of test-statistic is: -1.8635 2.3752 2.4005
27
28 Critical values for test statistics:
29      1pct  5pct 10pct
30 tau3 -3.96 -3.41 -3.12
31 phi2  6.09  4.68  4.03
32 phi3  8.27  6.25  5.34

```

ในกรณีแรกที่ระบุ `selectlags = c("AIC")` เราเก็บผลไว้ในชื่อ `setd.df2` ค่าสถิติที่ได้คือ -1.864 ซึ่งมากกว่า critical value ที่  $\alpha = 0.05$  เท่ากับ -3.41 ดังนั้น เราไม่สามารถปฏิเสธสมมุติฐานที่ว่า `setd` เป็น unit root

```

1 > setd.df2<-ur.df(setd$index, type = c("trend"), selectlags = c("AIC"))
2 > summary(setd.df2)
3 #####
4 # Augmented Dickey-Fuller Test Unit Root Test #
5 #####
6 Test regression trend
7 Call:
8 lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
9 Residuals:
10      Min       1Q   Median       3Q      Max
11 -108.380  -4.745  -0.105   4.837   74.125
12 Coefficients:
13             Estimate Std. Error t value Pr(>|t|)
14 (Intercept)  0.4325591  0.4122648   1.049  0.29414
15 z.lag.1      -0.0021279  0.0011419  -1.864  0.06247 .
16 tt           0.0006223  0.0002840   2.191  0.02851 *
17 z.diff.lag    0.0478816  0.0165720   2.889  0.00388 **
18
19 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
20 Residual standard error: 9.355 on 3636 degrees of freedom
21 Multiple R-squared:  0.003526, Adjusted R-squared:  0.002704
22 F-statistic: 4.289 on 3 and 3636 DF, p-value: 0.004982
23
24 Value of test-statistic is: -1.8635 2.3752 2.4005
25
26 Critical values for test statistics:
27      1pct   5pct 10pct
28 tau3 -3.96 -3.41 -3.12
29 phi2  6.09  4.68  4.03
30 phi3  8.27  6.25  5.34

```

เราได้ค่า ADF t statistics เท่ากับ -0.68 เมื่อเปรียบเทียบกับค่าวิกฤตจากตาราง ?? ที่นัยสำคัญ 5 % และ  $N = \infty$  มีค่าเท่ากับ -2.86 จะเห็นได้ว่า ADF t statistics มีค่ามากกว่าค่าวิกฤต ดังนั้นเราไม่สามารถปฏิเสธสมมติฐานที่ว่า set index เป็นยูนิทรูท หรือเราสามารถพิจารณาค่า  $t$  ซึ่งมีความเท่ากับ 0.95 ซึ่งเราไม่สามารถปฏิเสธว่า set index เป็นยูนิทรูท

### ตรวจสอบยูนิทรูทของฟิลิปส์ เปอรรอง

Phillips and Perron (1998) ได้พัฒนาการทดสอบยูนิทรูทซึ่งเป็นการทดสอบอีกวิธีหนึ่งที่เป็นที่นิยม โดยการทดสอบฟิลิปส์-เปอรรอง มีความแตกต่างจากการทดสอบยูนิทรูทดิกกี ฟูลเลอร์แบบดั้งเดิมที่สำคัญคือการดำเนินการที่เกี่ยวข้องกับปัญหา serial correlation และ heteroskedasticity ในข้อนี้ โดยที่ในกรณีของการทดสอบ ADF จะใช้โครงสร้างที่มีรูปแบบ ARMA ในการประมาณตัวแปรข้อผิดพลาด ในขณะที่การทดสอบ PP เพิกเฉยต่อ serial correlation ในสมการทดสอบ โดยใช้สมการต่อไปนี้ในการประมาณค่า

$$\Delta y_t = \beta' D_t + \pi y_{t-1} + u_t \quad (2.80)$$

โดยที่  $u_t$  เป็น  $I(0)$  และอาจจะมีปัญหา heteroskedasticity การทดสอบ PP จะแก้ไขปัญหามานี้ serial correlation และ heteroskedasticity ในตัวแปรข้อผิดพลาด  $u_t$  โดยการปรับตัวสถิติทดสอบ  $t_{\pi=0}$  และ  $T\hat{\pi}$

โดยตัวสถิติที่ปรับจะอยู่ในรูปดังต่อไปนี้

$$Z_t = \left( \frac{\hat{\sigma}^2}{\hat{\lambda}^2} \right)^{1/2} \times t_{\pi=0} - \frac{1}{2} \left( \frac{\hat{\lambda}^2 - \hat{\sigma}^2}{\hat{\lambda}^2} \right) \times \left( \frac{T \times se(\hat{\pi})}{\hat{\sigma}^2} \right)$$

$$Z_\pi = T\hat{\pi} - \frac{1}{2} \frac{T^2 \times se(\hat{\pi})}{\hat{\sigma}^2} (\hat{\lambda}^2 - \hat{\sigma}^2)$$

โดยที่  $\hat{\sigma}^2$  และ  $\hat{\lambda}^2$  เป็นตัวประมาณค่าที่ consistent ของพารามิเตอร์ค่าความแปรปรวน

$$\sigma^2 = \lim_{T \rightarrow \infty} T^{-1} \sum_{t=1}^T E[u_t^2]$$

$$\lambda^2 = \lim_{T \rightarrow \infty} \sum_{t=1}^T E[T^{-1} S_t^2]$$

โดยที่  $S_T = \sum_{t=1}^T u_t$

ภายใต้สมมติฐานหลักที่ว่า  $\pi = 0$  ตัวสถิติ  $Z_t$  และ  $Z_\pi$  ของ PP มีการแจกแจงที่ลู่เข้าหา ADF t-stat และ Normalized bias statistics เมื่อขนาดตัวอย่างใหญ่ ข้อได้เปรียบของ PP เมื่อเทียบกับ ADF คือ PP พิจารณาความน่าจะเป็นที่จะเกิด heteroskedasticity ของข้อบกพร่อง นอกจากนี้ผู้ใช้ไม่จำเป็นต้องกำหนดอันดับของตัวแปร  $y_t$  ในสมการทดสอบเช่นเดียวกับ ADF

## ตัวอย่างที่ 2.8 การทดสอบ Phillips Perron Unit root

```

1 > setd.pp<-ur.pp(setd$index, type="Z-tau", model="trend")
2 > summary(setd.pp)
3
4 #####
5 # Phillips-Perron Unit Root Test #
6 #####
7
8 Test regression with intercept and trend
9
10
11 Call:
12 lm(formula = y ~ y.l1 + trend)
13
14 Residuals:
15      Min       1Q   Median       3Q      Max
16 -108.674   -4.712   -0.062    4.765   68.930
17
18 Coefficients:
19             Estimate Std. Error t value Pr(>|t|)
20 (Intercept)  1.4901935  0.7300869   2.041  0.0413 *
21 y.l1         0.9980139  0.0011418 874.061 <2e-16 ***
22 trend        0.0005988  0.0002841   2.108  0.0351 *
23 ---
24 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
25
26 Residual standard error: 9.363 on 3638 degrees of freedom
27 Multiple R-squared:  0.9987, Adjusted R-squared:  0.9987
28 F-statistic: 1.42e+06 on 2 and 3638 DF, p-value: < 2.2e-16
29
30
31 Value of test-statistic, type: Z-tau is: -1.8587
32
33      aux. Z statistics
34 Z-tau-mu      1.7473
35 Z-tau-beta    2.1804
36
37 Critical values for Z statistics:
38      1pct      5pct     10pct
39 critical values -3.966098 -3.413711 -3.128565

```

ค่าสถิติ Phillips Perron มีค่าเท่ากับ -1.8587 มากกว่า critical value แสดงว่าเราไม่สามารถปฏิเสธสมมติฐานว่า setd\$index เป็น unit root

## ตัวทดสอบความนิ่ง(Stationary tests)

ในการทดสอบยูนิทด้วย ADF หรือ PP จะพิจารณาสมมติฐานหลักว่าอนุกรมเวลา  $y_t$  เป็น  $I(1)$  ในทางตรงข้าม การทดสอบอนุกรมนิ่งมีสมมติฐานหลักว่า  $y_t$  เป็น  $I(0)$  โดยที่ตัวทดสอบที่เป็นที่นิยมคือการทดสอบ KPSS ซึ่งเสนอโดย Kwiatkowski, Phillips, Schmidt, and Shin (1992)

## 2.5 ARIMA (Integrated ARMA)

**นิยาม 2.3.** เราจะเรียกกระบวนการ  $y_t$  ว่า  $ARIMA(p, d, q)$  ถ้า  $\Delta^d y_t = (1 - L)^d y_t$  เป็นกระบวนการ  $ARMA(p, q)$  หรือเราสามารถเขียนในรูปทั่วไปเป็น

$$\phi(L)(1 - L)^d y_t = \theta(L)\varepsilon_t \quad (2.81)$$

และถ้าหาก  $E(\Delta^d y_t) = \mu$  เราสามารถเขียนแบบจำลองได้เป็น

$$\phi(L)(1 - L)^d y_t = \delta + \theta(L)\varepsilon_t$$

โดยที่  $\delta = \mu(1 - \phi_1 - \dots - \phi_p)$

ในที่นี้เราอาจจะนึกถึงแบบจำลอง  $ARIMA(p, d, q)$  ว่าเป็นแบบจำลอง  $ARMA(p, q)$  ของอนุกรมเวลาที่ได้ดำเนินการผลต่างไปแล้ว  $d$  ครั้ง โดยที่  $z_t = \Delta^d y_t$  และ  $\phi(L)z_t = \theta(L)\varepsilon_t$  โดยทั่วไปแล้ว  $d$  จะมีค่าไม่เกิน 3

ในทางปฏิบัติ เราสามารถแบ่งแยกขั้นตอนในการสร้างแบบจำลอง  $ARIMA(p, d, q)$  ได้ดังนี้

1. พิจารณา ACF ของข้อมูลว่ามีข้อบ่งชี้ว่ามีปัญหาข้อมูลไม่นิ่ง (nonstationary) หรือไม่
2. ทดสอบยูนิทรูทว่ามีอินทิเกรตที่อันดับเท่าใด หรือหาค่า  $d$  นั้นเอง
3. หลังจากนั้นเราจะพิจารณาอนุกรม  $z_t = \Delta^d y_t$  ซึ่งเป็นอนุกรมเวลาที่นิ่งแล้วหลังจากได้ดำเนินการผลต่างไปแล้ว  $d$  ครั้ง ว่าแบบจำลองที่เหมาะสมในการอธิบาย  $z_t$  ควรจะมีอันดับของ  $p$  และ  $q$  เท่าใด โดยที่เราอาจจะพิจารณา ACF และ PACF ของ  $z_t$  หรือใช้ information criteria ก็ได้

หลังจากที่เราได้ค่า  $d, p$  และ  $q$  แล้วเราก็จะได้แบบจำลอง  $ARIMA(p, d, q)$

### ตัวอย่าง

ต่อจากตัวอย่างที่ ?? เราพิจารณาว่า set index เป็นอินทิเกรตที่อันดับเท่าไร โดยการดำเนินการหาผลต่างอันดับหนึ่ง(first differenced) แล้วทดสอบยูนิทรูท พบว่าอนุกรมเวลาที่ดำเนินการหาผลต่างอันดับหนึ่งไม่เป็นยูนิทรูท ดังนั้น set index เป็น  $I(1)$  และในแบบจำลอง  $ARIMA$  เราจะกำหนดให้  $d = 1$  ซึ่งเราจะใส่ค่าดังกล่าวในคำสั่ง `auto.arima` เพื่อหา  $p$  และ  $q$  ที่เหมาะสมต่อไป



## ตัวอย่างที่ 2.9 การสร้างแบบจำลอง ARIMA

ขั้นตอนแรกของการสร้างแบบจำลองคือการหาลำดับของอินทิเกรชัน (order of integration) หรือค่า  $d$

จากตัวอย่างที่ผ่านมาเราทราบว่า `setd$index` เป็น unit root ดังนั้นเราแปลงข้อมูลด้วย first difference ( $\Delta setd_t = setd_t - setd_{t-1}$ ) แล้วทดสอบ Unit root

```
1 > setd.df.diff<-ur.df(diff(setd$index), type = c("trend"), selectlags = c("AIC"))
2 > summary(setd.df.diff)
3 <Omitted>
4 Value of test-statistic is: -39.9724 532.5983 798.8972
5
6 Critical values for test statistics:
7      1pct  5pct 10pct
8 tau3  -3.96 -3.41 -3.12
9 phi2   6.09  4.68  4.03
10 phi3   8.27  6.25  5.34
```

จากการทดสอบ unit root กับตัวแปรในรูปแบบ first difference ค่าสถิติเท่ากับ -39.97 ซึ่งน้อยกว่า critical value -3.41 ดังนั้นเราสามารถปฏิเสธสมมติฐานหลักที่ว่า `diff(setd)` เป็น unit root แสดงว่า `diff(setd)` เป็น stationary และเราสามารถสรุปได้ว่า `setd` เป็น  $I(1)$  ซึ่งต้องทำ first difference ถึงจะเป็น stationary

แบบจำลองที่เหมาะสมกับ `setd` คือแบบจำลองที่  $d=1$  ดังนั้นเรากำหนดค่าดังกล่าวในคำสั่ง `auto.arima` และให้คำสั่งทดลองหา  $p, q$  ที่เหมาะสม ซึ่งในกรณีนี้  $p$

```
1 > library(forecast)
2 > setd_mod<-auto.arima(setd$index, d=1, max.p=6, max.q=6 , ic= c("bic"), stepwise
  = FALSE, trace = TRUE)
3 <Omitted>
4 Best model: ARIMA(0,1,0)
5
6 > setd_mod
7 Series: setd$index
8 ARIMA(0,1,0)
9
10 sigma^2 estimated as 87.77: log likelihood=-13312.56
11 AIC=26627.12 AICC=26627.12 BIC=26633.32
```

ซึ่งจากการใช้ BIC พบว่าอันดับที่เหมาะสมคือ  $p = 0$  และ  $q = 0$  ดังนั้นแบบจำลองที่เหมาะสมที่ใช้ประมาณค่า `set index` รายวันคือ  $ARIMA(0, 1, 0)$  หรือแบบจำลอง random walk นั้นเอง

## 2.6 แบบจำลองตามฤดูกาล

อนุกรมเวลาทางการเงินบางอนุกรมเช่น ผลตอบแทนต่อหุ้น (earning per share) มีพฤติกรรมเป็นวงจรหรือเป็นช่วงเวลา (cyclical) โดยที่ในบางไตรมาสอาจจะมีผลตอบแทนต่อหุ้นที่สูง

กว่าไตรมาสอื่น ดังนั้นในการสร้างแบบจำลองเพื่ออธิบายอนุกรมดังกล่าวจำเป็นต้องผลของฤดูกาลด้วย

สมมติให้อนุกรมเวลามีลักษณะตามฤดูกาล  $s$  เราสามารถกำจัดผลของฤดูกาลได้โดยการจัดการผลต่างฤดูกาล (seasonal differencing) หรือเขียนในรูปที่ใช้ตัวดำเนินการความล่า- $s$  (lag- $s$  operator) ในพจน์สุดท้ายของสมการต่อไปนี้

$$\Delta_s y_t = y_t - y_{t-s} = y_t - L^s y_t = (1 - L^s) y_t \quad (2.82)$$

จากตัวดำเนินการดังกล่าวนำมาสู่แนวคิดในการสร้างแบบจำลอง seasonal  $ARMA(P, Q)_s$  ซึ่งสามารถแสดงได้ด้วยสมการต่อไปนี้

$$\Phi_P(L^s) y_t = \Theta_Q(L^s) \varepsilon_t \quad (2.83)$$

โดยที่  $\Phi_P(L^s) = 1 - \Phi_1 L^s - \Phi_2 L^{2s} - \dots - \Phi_P L^{Ps}$  และ  $\Theta_Q(L^s) = 1 + \Theta_1 L^s - \Theta_2 L^{2s} - \dots - \Theta_Q L^{qs}$  โดยที่คุณสมบัติคล้ายกับ  $ARMA(p, q)$  คืออนุกรมเวลาจะนิ่งถ้ารากของ  $\Phi_P(z^s)$  อยู่นอกวงกลมหนึ่งหน่วย และสามารถเขียนหาตัวผกผันได้ถ้ารากของ  $\Theta_Q(z^s)$  อยู่นอกวงกลมหนึ่งหน่วย

ตัวอย่างเช่นแบบจำลองฤดูกาล  $SARMA(1, 1)_{12}$  โดยที่ข้อมูลเป็นรายเดือนค่าฤดูกาล  $s = 12$  สามารถเขียนเป็นสมการได้ดังนี้

$$(1 - \Phi L^{12}) y_t = (1 + \Theta L^{12}) \varepsilon_t \quad (2.84)$$

หรือ  $y_t = \Phi x_{12} + \varepsilon_t + \Theta \varepsilon_{t-12}$  โดยที่อนุกรมเวลานี้จะนิ่งถ้า  $|\Phi| < 1$  และหาตัวผกผันได้ถ้า  $|\Theta| < 1$

สำหรับแบบจำลอง  $SMA(1)_{12}$ ,  $y_t = \varepsilon_t + \Theta \varepsilon_{t-12}$  จะมีค่าความแปรปรวนในตัวเองและค่าสหสัมพันธ์ในตัวเองดังนี้

$$\begin{aligned} \gamma_0 &= (1 + \Theta^2) \sigma^2 \\ \gamma_{12} &= \Theta \sigma^2 \\ \gamma_j &= 0, \quad j \neq 0, j \neq 12 \\ \rho_{12} &= \Theta / (1 + \Theta^2) \end{aligned}$$

ส่วนแบบจำลอง  $SAR(1)_{12}$ ,  $y_t = \Phi y_{t-12} + \varepsilon_t$  จะมีค่าความแปรปรวนในตัวเองและค่า

สหสัมพันธ์ในตัวเองดังนี้

$$\begin{aligned}\gamma_0 &= \sigma^2 / (1 - \Phi^2) \\ \gamma_{12k} &= \sigma^2 \Phi^k / (1 - \Phi^2), \quad k = 1, 2, 3, \dots \\ \gamma_j &= 0, \quad j \neq 0, j \neq 12 \\ \rho_{12k} &= \Phi^k, \quad k = 0, 1, 2, \dots\end{aligned}$$

โดยทั่วไปเราจะ รวม ส่วน ที่ ไม่ เป็น ฤดูกาล และ เป็น ฤดูกาล เข้า ด้วย กัน ใน แบบ จำลอง multiplicative seasonal  $ARMA(p, q) \times (P, Q)_s$

$$\Phi_P(L^s)\phi(L)y_t = \Theta_Q(L^s)\theta(L)\varepsilon_t \quad (2.85)$$

ตัวอย่าง  $ARMA(0, 1) \times (1, 0)_{12}$

$$y_t = \Phi y_{t-12} + \varepsilon_t - \theta \varepsilon_{t-1} \quad (2.86)$$

แบบจำลอง multiplicative seasonal  $ARIMA(p, d, q) \times (P, D, Q)_s$

$$\Phi_P(L^s)\phi(L)\Delta_s^D \Delta^d y_t = \Theta_Q(L^s)\theta(L)\varepsilon_t \quad (2.87)$$

โดยที่  $\Delta^d = (1 - L)^d$  และ  $\Delta_s^D = (1 - L^s)^D$

ตัวอย่าง  $ARIMA(0, 1, 1) \times (0, 1, 1)_{12}$

$$(1 - L^{12})(1 - L)y_t = (1 + \Theta L^{12})(1 + \theta L)\varepsilon_t \quad (2.88)$$

ซึ่งสามารถขยายได้เป็น

$$(1 - L - L^{12} + L^{13})y_t = (1 + \theta L + \Theta L^{12} + \Theta \theta L^{13})\varepsilon_t$$

## บทที่ 3

# สมการถดถอยสำหรับข้อมูลอนุกรมเวลา

วิธีการประมาณ สมการ ถดถอย สำหรับ ข้อมูล อนุกรมเวลา ถูกนำมาใช้แพร่หลาย ในการวิเคราะห์ข้อมูลทางการเงิน และใช้ในการประมาณค่าและทดสอบแบบจำลองเช่น แบบจำลองราคาสินทรัพย์และผลได้ตอบแทนของสินทรัพย์เช่น Capital Asset Pricing Model (CAPM) หรือ Arbitrage Price Model นอกจากนี้ยังใช้ศึกษาความสัมพันธ์ระหว่างผลได้ตอบแทนของทรัพย์สินกับสัดส่วนทางการเงิน เพื่อใช้ในการทำนายการเปลี่ยนแปลงของผลได้ตอบแทน

อย่างไรก็ตาม การศึกษาความสัมพันธ์ทางการเงินที่ใช้ข้อมูลอนุกรมเวลาและวิธีการถดถอย จำเป็นที่จะต้องระมัดระวัง เนื่องจากคุณสมบัติของการประมาณค่าถดถอยบางประการอาจได้รับผลกระทบจากข้อมูลที่เป็นอนุกรมเวลา อันจะส่งผลต่อการอธิบายผลและทดสอบผล โดยทั่วไป ข้อมูลที่เราจะนำมาใช้ในการศึกษามักจะเป็นข้อมูลที่นิ่ง ( $I(0)$ ) เช่น ผลได้ตอบแทนของทรัพย์สิน

### 3.1 แบบจำลองถดถอยเชิงเส้นตรงสำหรับข้อมูลอนุกรมเวลา

$$y_t = \beta_0 + \beta_1 x_{1t} + \dots + \beta_k x_{kt} + \varepsilon_t = \mathbf{x}_t' \boldsymbol{\beta} + \varepsilon_t, \quad t = 1, \dots, T \quad (3.1)$$

โดยที่เราสามารถเขียนให้อยู่ในรูปเมทริกซ์ได้

ข้อสมมุติมาตรฐานสำหรับแบบจำลองถดถอยเชิงเส้นในกรณีข้อมูลอนุกรมเวลาคือ

- แบบจำลองในสมการ (??) เป็นแบบจำลองที่ระบุถูกต้อง
- $y_t, \mathbf{x}_t$  เป็นอนุกรมนิ่งและ ergodic
- ตัวแปรต้น  $\mathbf{x}_t$  ถูกกำหนดไว้ก่อน (predetermined):  $E(x_{is}\varepsilon_t) = 0$  สำหรับทุกค่าที่  $s \leq t$
- $E(\mathbf{x}_t \mathbf{x}_t')$  เป็น full rank
- $\mathbf{x}_t \varepsilon_t$  เป็นกระบวนการที่ไม่มีสหสัมพันธ์กันในระยะจำกัด

### 3.1.1 การประมาณค่าวิธีกำลังสองน้อยที่สุด

วิธีการประมาณค่ากำลังสองน้อยที่สุดทั่วไป (Ordinary Least Square: OLS) เป็นการประมาณค่าโดยหาตัวประมาณค่าของพารามิเตอร์ที่ทำให้

$$SSR(\beta) = \sum_{t=1}^T (y_t - \mathbf{x}'_t \beta)^2 = \sum_{t=1}^T \varepsilon_t^2 \quad (3.2)$$

และได้แบบจำลอง fitted

$$y_t = \mathbf{x}'_t \hat{\beta} + \hat{\varepsilon}_t, \quad t = 1, \dots, T$$

โดยที่  $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$  และ  $\hat{\varepsilon}_t = y_t - \hat{y}_t = y_t - \mathbf{x}'_t \hat{\beta}$  โดยมีค่าประมาณ error variance เท่ากับ  $\hat{\sigma}^2 = \hat{\varepsilon}'\hat{\varepsilon}/(T - k - 1)$  และภายใต้ข้อสมมุติข้างต้นตัวประมาณค่า OLS จะ consistent และ asymptotically normally distributed และตัวประมาณค่าของความแปรปรวน

$$\widehat{Aver}(\hat{\beta}) = \hat{\sigma}^2 (\mathbf{X}'\mathbf{X})^{-1}$$

และค่า standard errors ของแต่ละตัวประมาณค่า  $\beta_j$  คือค่ารากที่สองของสมาชิกลำดับที่  $j$  ในแนวทแยงมุม

#### การวิเคราะห์ค่าส่วนเกิน (residuals)

หลังจากการประมาณค่าแล้วค่าสถิติสองสามตัวจะถูกใช้ในการตรวจสอบตัวสถิติ โดยที่ตัวสถิติเหล่านี้จะทำหน้าที่ในการตรวจสอบว่าค่าส่วนเกินเป็นไปตามทฤษฎีหรือไม่ โดยตัวสถิติที่ใช้โดยปกติคือการตรวจสอบ serial correlation ด้วยการวิเคราะห์ตัวประมาณค่าส่วนเกิน  $\hat{\varepsilon}_t$  ที่เรียกว่าตัวสถิติ Durbin-Watson

$$DW = \frac{\sum_{t=2}^T (\hat{\varepsilon}_t - \hat{\varepsilon}_{t-1})^2}{\sum_{t=2}^T \hat{\varepsilon}_t^2}$$

โดยที่  $DW \approx 2(1 - \rho)$  โดยที่  $\rho$  คือความสัมพันธ์ระหว่าง  $\varepsilon_t$  และ  $\varepsilon_{t-1}$  และค่า DW จะมีค่าอยู่ระหว่าง 0 และ 4 โดยที่ค่าใกล้เคียงสองแสดงว่าไม่มีสหสัมพันธ์ระหว่างกัน นอกจากนี้เรายังมีตัวสถิติอีกตัวคือ Ljung-Box Q

### 3.2 Heteroskedasticity and Autocorrelation Consistent Covariance Matrix Estimation

$$\begin{aligned} Var(\hat{\beta}_1 | \mathbf{X}) &= Var(\beta_1 + \frac{\frac{1}{T} \sum_{t=1}^T (x_t - \bar{x}) \varepsilon_t | X)}{\frac{1}{T} \sum_{t=1}^T (x_t - \bar{x})^2}) \\ &= \frac{Var(\frac{1}{T} \sum_{t=1}^T (x_t - \bar{x}) \varepsilon_t | X)}{\left(\frac{1}{T} \sum_{t=1}^T (x_t - \bar{x})^2\right)^2} \end{aligned} \quad (3.3)$$

โดยที่ตัวส่วนของสูตรข้างบนสามารถเขียนในรูปต่อไปนี้

$$\begin{aligned} Var\left(\frac{1}{T} \sum_{t=1}^T (x_t - \bar{x}) \varepsilon_t | X\right) &= \frac{1}{T^2} Var\left(\sum_{t=1}^T (x_t - \bar{x}) \varepsilon_t | X\right) \\ &= \frac{1}{T^2} \sum_{t=1}^T Var((x_t - \bar{x}) \varepsilon_t | X) + \frac{1}{T^2} \sum_{t=1}^T \sum_{s=t+1}^T Cov((x_t - \bar{x}) \varepsilon_t, (x_s - \bar{x}) \varepsilon_s | X) \end{aligned} \quad (3.4)$$

ในกรณีที่เราสสมมติให้ค่าผิดพลาดไม่มีปัญหา heteroskedasticity และ autocorrelation

$$\underbrace{\frac{1}{T^2} \sum_{t=1}^T Var((x_t - \bar{x}) \varepsilon_t | X)}_{=\sigma^2 \sum_{t=1}^T (x_t - \bar{x})^2} + \frac{1}{T^2} \sum_{t=1}^T \sum_{s=t+1}^T \underbrace{Cov((x_t - \bar{x}) \varepsilon_t, (x_s - \bar{x}) \varepsilon_s | X)}_{=0}$$

$$\text{ดังนั้น } Var(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{t=1}^T (x_t - \bar{x})^2}$$

#### 3.2.1 White

#### 3.2.2 Newey-West

ในกรณีที่เรากำลังต้องการแก้ไขความคลาดเคลื่อนมาตรฐานเราจำเป็นต้องประมาณค่าสมการ (??) อย่างไรก็ตามสมการดังกล่าวมีพจน์ที่คูณกันอยู่ค่อนข้างเยอะ Newey-West เสนอว่าเราไม่จำเป็นต้องใช้พจน์ทั้งหมดที่คูณกันอยู่เพียงประมาณค่าแค่ช่วงหนึ่งก็พอ โดยการเลือกค่า  $L$  ค่าหนึ่งซึ่งทำให้

$$Var(\hat{\beta}_1) = \frac{1}{T} \sum_{l=1}^L \sum_{t=l+1}^T W_{l\varepsilon_t \varepsilon_{t-l} (\tilde{x}_t \tilde{x}_{t-l} - \tilde{x}_{t-l} \tilde{x}_t)} \quad (3.5)$$

โดยที่  $W_l = \frac{l}{L+1}$  และ  $\tilde{x}_t = x_t - \bar{x}$  ปัญหาในทางปฏิบัติคือเราจะเลือก  $L$  เท่าใด โดยหลักแล้วถ้าข้อมูลยาวมากๆ  $L$  ก็น่าจะยาวด้วย Newey and West เสนอให้ใช้  $L = 4(T/100)^{2/9}$

## บทที่ 4

### แบบจำลอง *GARCH*

เป้าหมายที่สำคัญประการหนึ่งของการศึกษาเศรษฐมิติทางการเงินคือการศึกษาความผันผวน (volatility) ของผลได้ตอบแทนของสินทรัพย์ โดยที่ความผันผวนจะหมายถึงความเบี่ยงเบนมาตรฐานที่มีเงื่อนไข (conditional standard deviation) ของผลได้ตอบแทนของสินทรัพย์

ความผันผวนที่คำนวณได้ถูกนำไปใช้ประยุกต์ในการคำนวณ Value-at-Risk (VaR) ของการจัดการความเสี่ยง, การจัดสรรการลงทุนภายใต้วิธีการ mean-variance และการเพิ่มประสิทธิภาพในการทำนาย

#### 4.1 ความผันผวนของสินทรัพย์

##### 4.1.1 คุณสมบัติของความผันผวน

ปัญหาเบื้องต้นของการศึกษาความผันผวนคือเราไม่สามารถสังเกตความผันผวนของสินทรัพย์เช่นหลักทรัพย์ได้เหมือนกับการสังเกตเห็นราคาหลักทรัพย์หรือการคำนวณผลตอบแทนได้จากราคาหลักทรัพย์ ในอดีตนักวิชาการได้นำเสนอตัวแทนของความผันผวนเช่น หากกำหนดให้  $P_t$  เป็นราคาหลักทรัพย์ และกำหนดให้  $y_t = \Delta \ln(P_t)$  เป็นผลได้ตอบแทน เราพบว่าอนุกรมของผลได้ตอบแทนมักจะไม่มีสหสัมพันธ์ระหว่างกันผลได้ตอบแทนในอดีต แต่ผลได้ตอบแทนกำลังสอง ( $y_t^2$ ), ค่าสัมบูรณ์ของผลได้ตอบแทน ( $|y_t|$ ), หรือค่ายกกำลังของค่าสัมบูรณ์ของผลได้ตอบแทน ( $|y_t|^\delta$ ) มีสหสัมพันธ์ค่อนข้างสูง ดังนั้นในอดีตเรามักใช้คำดังกล่าวเป็นตัวแทนของความผันผวน อย่างไรก็ตามในปัจจุบันมีการคำนวณความผันผวนด้วยวิธีการอื่นๆเช่น Realized volatility และ Implied volatility ด้วย Black-Scholes

##### 4.1.2 การทดสอบ ARCH effect

หลังจากที่เราสร้างแบบจำลองเพื่ออธิบายผลได้ตอบแทน ( $y_t$ ) แล้ว หากนิยาม  $\varepsilon_t = y_t - \mu_t$  เป็น residuals ของแบบจำลองที่ใช้อธิบายค่าเฉลี่ย (mean equation) ของผลได้ตอบแทนซึ่งแทน



ด้วยสัญลักษณ์  $\mu_t$  ซึ่งแบบจำลองที่ใช้ อาจจะเป็นแบบจำลอง  $AR(p)$  หรือ  $ARIMA(p, d, q)$  ในบทที่ผ่านมาเราจะทดสอบว่าแบบจำลองเพียงพอที่จะอธิบายค่าเฉลี่ยหรือไม่ โดยพิจารณาอัตโนมัติสัมพันธ์ของ residuals ซึ่งหากไม่หลงเหลือความสัมพันธ์แล้ว แสดงว่าแบบจำลองเพียงพอ อย่างไรก็ตามจากการพิจารณาข้อมูลอนุกรมเวลาเราในอดีต เราพบว่า residuals อาจจะมีค่าผันผวนที่เปลี่ยนแปลงตามเวลา ดังนั้น เราต้องการทดสอบว่าข้อมูลของเรามีความแปรปรวนที่เปลี่ยนแปลงตามเวลา (conditional heteroskedasticity) หรือไม่ เราเรียกการทดสอบนี้ว่าการทดสอบ ARCH effect ซึ่งลักษณะของอนุกรมเวลาที่จะมีค่าความแปรปรวนเปลี่ยนแปลงตามเวลาก็ต่อเมื่อค่ากำลังสองของอนุกรมเวลานั้นๆ มีความสัมพันธ์กัน จากแนวคิดดังกล่าว มีการทดสอบสองวิธีที่เป็นที่นิยมใช้ได้แก่ (1) การใช้การทดสอบ Ljung-Box เพื่อทดสอบอนุกรมเวลา  $\varepsilon_t^2$  (McLeod and Li, 1983) และ (2) การทดสอบ Lagrange multiplier (Engle 1982)

วิธีแรกเป็นการทดสอบ Ljung-Box  $Q(m)$  สำหรับค่ายกกำลังสองของ residuals ( $\varepsilon_t^2$ ) โดยเราใช้  $\varepsilon_t^2$  เป็นตัวแทนค่าแปรปรวนที่เปลี่ยนแปลงตามเวลา ดังนั้นหากค่าความแปรปรวนขึ้นอยู่กับค่าก่อนหน้าจะต้องมีสหสัมพันธ์ระหว่างกัน ดังนั้นเราจะตั้งสมมติฐานหลักค่ายกกำลังสองของ residuals ไม่มีสหสัมพันธ์ระหว่างกันย้อนไปถึงค่าที่  $m$  หากสมมติฐานหลักเป็นจริงแสดงว่า residuals ไม่มีลักษณะของ ARCH (หรือไม่มี ARCH effect)

วิธีสองเป็นการทดสอบ Lagrange Multiplier (LM) โดยเราใช้  $\varepsilon_t^2$  เป็นตัวแทนของค่าความแปรปรวน ซึ่งหากเราต้องการทดสอบว่าค่าแปรปรวนขึ้นกับค่าแปรปรวนในอดีตหรือไม่ สามารถประมาณค่าสมการ

$$\varepsilon_t^2 = a_0 + a_1\varepsilon_{t-1}^2 + \dots + a_m\varepsilon_{t-m}^2 + e_t \quad (4.1)$$

และพิจารณาว่าค่าสัมประสิทธิ์มีนัยสำคัญเชิงสถิติต่างจากศูนย์หรือไม่ โดยสมมติฐานหลักคือ  $a_1 = a_2 = \dots = a_m = 0$  หรือไม่มี ARCH effect โดยเราสามารถทำการทดสอบได้โดยการประมาณค่าสมการ ?? จะได้ค่า  $R^2$  แล้วไปคำนวณค่าสถิติ  $LM = TR^2$  โดยที่  $T$  คือจำนวนตัวอย่าง และ  $LM \sim \chi_{df=m}^2$  เราจะปฏิเสธสมมติฐานหลักถ้า  $LM > \chi_{df=m}^2(1 - \alpha)$

#### ตัวอย่างที่ 4.1: การทดสอบ ARCH Effect ผลตอบแทนรายเดือนจากการลงทุนในตลาดหลักทรัพย์แห่งประเทศไทย

เราจะพิจารณาผลได้ตอบแทนรายเดือนในรูปลือกของการลงทุนในตลาดหลักทรัพย์แห่งประเทศไทย โดยใช้ข้อมูลราคาปิดรายเดือนตั้งแต่ เมษายน 2518 ถึงเดือนพฤศจิกายน 2555 ซึ่งอยู่ในไฟล์ `mset.csv` เราสามารถสร้างอนุกรมเวลาผลได้ตอบแทนในรูปลือกและหารูปแบบจำลองที่เหมาะสมได้ด้วยคำสั่ง `auto.arima` ได้แบบจำลอง  $ARMA(2, 2)$  ตามที่แสดงในคำสั่งข้างล่าง

```

1 > mset <-
  read.csv("https://raw.githubusercontent.com/chaleampong/EC435/master/mset.csv",
    header = FALSE)
2 > head(mset)
3 > ret<-diff(log(mset$V1))
4 > library(forecast)
5 > auto.arima(ret, max.p=6, max.q=6, ic=c("aic"))
6 Series: ret
7 ARIMA(2,0,2) with zero mean
8
9 Coefficients:
10      ar1      ar2      ma1      ma2
11      1.1154 -0.9020 -1.0542  0.9141
12 s.e.  0.0511  0.0754  0.0646  0.0740
13
14 sigma^2 estimated as 0.006749: log likelihood=489.01
15 AIC=-968.03 AICC=-967.89 BIC=-947.47

```

หลังจากนั้นเราประมาณค่าแบบจำลอง  $ARMA(2, 2)$  และให้ชื่อว่า  $m$  เราสามารถพิจารณาความพอเพียงของแบบจำลองได้ด้วย ACF ของ residuals หรือ Ljung-Box test ของ residuals


```

1 > m <- arima(ret, order=c(2,0,2))
2 > acf(m$residuals, lag.max=20)
3 > Box.test(m$residuals, lag=12, type="Ljung")
4
5 Box-Ljung test
6
7 data: m$residuals
8 X-squared = 10.191, df = 12, p-value = 0.5992

```

จะได้

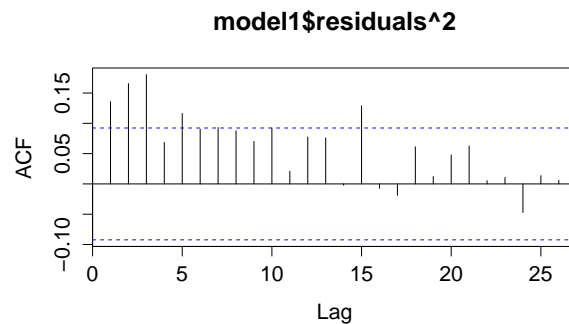
รูปที่ 4.1: ACF ของ residuals



จากรูป ?? และค่า Ljung-Box statistics = 10 ซึ่งน้อยกว่า critical value จะเห็นได้ว่าแบบจำลองดังกล่าวเพียงพอในการอธิบาย log return และไม่มีสหสัมพันธ์ระหว่าง log return เหลืออยู่

แต่หากเราพิจารณา ACF ของค่ากำลังสองของ residuals หรือ Ljung-Box test ของค่ากำลังสองของ residuals กำลังสอง หรือทดสอบ LM ARCH effect จะเห็นได้ว่ายังมีผลของ ARCH เหลืออยู่

รูปที่ 4.2: ACF ของ residuals



ใน residuals โดยในการทดสอบ LM ARCH effect จะต้องใช้คำสั่ง `ArchTest(series, q)` จาก `library(FinTS)` โดยต้องระบุ series ที่ต้องการทดสอบและค่า  $q$

```
1 > acf(m$residuals^2, lag.max = 20)
2 > Box.test(m$residuals^2, lag=12, type="Ljung")
3   Box-Ljung test
4 data:  m$residuals^2
5 X-squared = 64.509, df = 12, p-value = 3.36e-09
6 > library(FinTS)
7 > ArchTest(ret)
8   ARCH LM-test; Null hypothesis: no ARCH effects
9 data:  ret
10 Chi-squared = 35.547, df = 12, p-value = 0.000383
```

กรณีการทดสอบ *Ljung-Box* ของค่ากำลังสองของ residuals (บรรทัด 2-7) ค่า  $p < 0.0001$  เราปฏิเสธสมมติฐานที่ว่าค่ากำลังสองของ residuals ไม่มีสหสัมพันธ์กัน กรณีการทดสอบ *LM ARCH effect* (บรรทัด 9-14) ค่า  $p < 0.002$  เราปฏิเสธสมมติฐานหลัก  $a_1 = a_2 = \dots = a_m = 0$  สรุปว่าเราพบว่า residuals ของแบบจำลอง *ARMA(2, 2)* มี ARCH effect

## 4.2 แบบจำลอง ARCH

เพื่อให้ผู้อ่านเข้าใจแรงจูงใจในการสร้างแบบจำลอง ARCH ผู้เขียนขอเน้นอีกครั้งว่าแบบจำลองอนุกรมเวลาที่เรากำลังสร้างขึ้นมาในบทที่ผ่านมา เราพยายามที่จะอธิบายค่าในอนาคตของตัวแปรสุ่มที่เราสนใจโดยที่ค่าเฉลี่ยที่เราพยากรณ์อาจจะอยู่ในรูปค่าเฉลี่ยที่มีเงื่อนไข (conditional mean) หรือค่าเฉลี่ยที่ไม่มีเงื่อนไข (unconditional mean) เช่นในกรณีแบบจำลอง *AR(1)* ซึ่งสามารถแสดงได้ด้วย  $y_t = \phi y_{t-1} + \varepsilon_t$  ซึ่งจากบทที่ผ่านมาเราทราบว่าค่าเฉลี่ย (ที่ไม่มีเงื่อนไข)  $E(y_t) = 0$  และค่าความแปรปรวน  $Var(y_t) = \sigma^2 / (1 - \phi^2)$  ซึ่งหากใช้ค่าเฉลี่ยดังกล่าวสำหรับการทำนายไปข้างหน้าจะได้ค่าคาดการณ์ของ  $y$  เท่ากับศูนย์ แต่วิธีการพยากรณ์ที่จะทำให้ค่า MSE ค่าที่ต่ำสุดควรจะใช้

ค่าเฉลี่ยที่มีเงื่อนไขจากแบบจำลอง  $AR(1)$  ซึ่งเท่ากับ

$$y_h(1) = E(y_{h+1}|F_h) = \phi y_h$$

และมีค่าความแปรปรวนที่มีเงื่อนไขเท่ากับ

$$Var_h(y_{h+1}) = E_h(y_{h+1} - E_h(y_{h+1}))^2 = E_h(\phi y_h + \varepsilon_{h+1} - \phi y_h)^2 = E_h(\varepsilon_{h+1}^2) = \sigma_{h+1}^2$$

โดยที่  $E_h(\cdot) = E(\cdot|F_h)$  และในบทที่ผ่านมาเราสมมติให้  $\sigma_{h+1}^2$  มีค่าคงที่

Engle (1982) ได้วิเคราะห์โมเมนต์ที่สองที่มีเงื่อนไข โดยที่สร้างแบบจำลองที่ค่าความแปรปรวนสามารถเปลี่ยนแปลงได้ตามเวลา

#### 4.2.1 รูปแบบของแบบจำลอง ARCH(q)

ค่าสหสัมพันธ์ในตัวเองของผลได้ตอบแทนกำลังสองหรือ conditional heteroskedasticity สามารถอธิบายได้ด้วยแบบจำลอง AR ของค่าส่วนเกิน (residuals) กำลังสอง ตัวอย่างเช่น กำหนดให้  $y_t$  อนุกรมเวลานิ่ง เช่น ผลได้ตอบแทน แล้วกำหนดให้  $y_t$  สามารถอธิบายได้ด้วยแบบจำลอง

$$y_t = \mu_t + \varepsilon_t \quad (4.2)$$

โดยที่  $\mu_t$  เป็น ส่วนอธิบายค่าเฉลี่ย (mean equation) ซึ่งอาจจะเป็นค่าคงที่  $c$  หรือ แบบจำลอง  $ARMA(p, q)$  และ  $\varepsilon_t$  เป็น iid ที่มีค่าเฉลี่ยเท่ากับศูนย์ เพื่อที่จะให้แบบจำลองดังกล่าวมีความผันผวนเป็นกลุ่ม (volatility clustering) หรือ conditional heteroskedasticity เราจะสมมติให้ค่าความแปรปรวนที่ขึ้นอยู่กับข้อมูล ณ เวลาที่  $t-1$   $Var_{t-1} = \sigma_t^2$  เขียนเป็นสมการต่อไปนี้

$$\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_q \varepsilon_{t-q}^2 \quad (4.3)$$

เนื่องจาก  $\varepsilon_t$  มีค่าเฉลี่ยเท่ากับศูนย์  $Var_{t-1}(\varepsilon_t) = E_{t-1}(\varepsilon_t^2) = \sigma_t^2$  ดังนั้นเราสามารถเขียนสมการ (??) ได้เป็น

$$\varepsilon_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_q \varepsilon_{t-q}^2 + u_t \quad (4.4)$$

โดยที่  $u_t = \varepsilon_t^2 - E_{t-1}(\varepsilon_t^2)$  ซึ่งเป็นกระบวนการไวท์นอยซ์ที่มีค่าเฉลี่ยเท่ากับศูนย์ สมการ (??),(??) และ (??) รวมกันเรียกว่า autoregressive conditional heteroskedasticity (ARCH) หรือ แบบจำลอง  $ARCH(q)$

รูปแบบของ  $ARCH(q)$  อีกแบบจำลองสามารถแสดงได้ดังนี้

$$\begin{aligned} y_t &= \mu_t + \varepsilon_t \\ \varepsilon_t &= z_t \sigma_t \\ \sigma_t^2 &= \omega + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_q \varepsilon_{t-q}^2 \end{aligned} \quad (4.5)$$

โดยที่  $z_t$  เป็นตัวแปรสุ่มเป็นอิสระและเหมือนกันที่มีค่าเฉลี่ยเท่ากับศูนย์และค่าความแปรปรวนเท่ากับหนึ่ง,  $iid(0, 1)$  ตัวอย่างเช่น การแจกแจงปกติมาตรฐาน

#### 4.2.2 คุณสมบัติของ ARCH(1)

เพื่อให้ผู้อ่านเข้าใจแบบจำลอง ARCH เราจะมาพิจารณาคูสมบัติของแบบอนุกรมเวลา ARCH(1) สมมติว่าให้  $y_t$  มีคุณลักษณะตามแบบจำลอง ARCH(1) โดยที่

$$y_t = \varepsilon_t \quad (4.6)$$

$$\varepsilon_t = z_t \sigma_t \quad (4.7)$$

และ

$$\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 \quad (4.8)$$

หากเรายกกำลังสองทั้งสองข้างของ (4.6) แล้วสลับข้างสมการ (4.8) แล้วนำมาลบจะได้

$$\begin{aligned} \varepsilon_t^2 - \omega - \alpha_1 \varepsilon_{t-1}^2 &= (z_t^2 - 1) \sigma_t^2 \\ \varepsilon_t^2 &= \omega + \alpha_1 \varepsilon_{t-1}^2 + (z_t^2 - 1) \sigma_t^2 \end{aligned}$$

ซึ่งเป็นแบบจำลองของ  $\varepsilon_t^2$  ในรูป AR โดยที่  $u_t = (z_t^2 - 1) \sigma_t^2$  และจากความสัมพันธ์ที่  $y_t^2 = \varepsilon_t^2$  เราสามารถสรุปได้ว่า ARCH(1) สามารถเขียนในรูปกำลังสองของ  $y_t$  ได้

ค่าเฉลี่ยที่ไม่มีเงื่อนไข(unconditional mean)ของ  $\varepsilon_t$  เท่ากับศูนย์ ซึ่งการคำนวณสามารถแสดงได้ดังนี้

$$\begin{aligned} E(\varepsilon_t) &= E(E(\varepsilon_t | F_{t-1})) = E(E(z_t \sigma_t | F_{t-1})) \\ &= E(\sigma_t \underbrace{E(z_t | F_{t-1})}_{=0}) = 0 \end{aligned}$$

โดยสมการแรกใช้ Law of Iterated Expectation

ค่าความแปรปรวน (unconditional variance) ของ  $\varepsilon_t$  สามารถคำนวณได้โดย

$$\begin{aligned} Var(\varepsilon_t) &= E(\varepsilon_t^2) = E(E(\varepsilon_t^2 | F_{t-1})) \\ &= E(E(z_t^2 \sigma_t^2 | F_{t-1})) \\ &= E(\sigma_t^2 \underbrace{E(z_t^2 | F_{t-1})}_{=1}) \\ &= E(\omega + \alpha_1 \varepsilon_{t-1}^2) = \omega + \alpha_1 E(\varepsilon_{t-1}^2) \end{aligned}$$

หากต้องการให้  $\varepsilon_t$  เป็นกระบวนการนิ่ง  $Var(\varepsilon_t) = E(\varepsilon_t^2) = E(\varepsilon_{t-1}^2)$  ดังนั้น  $Var(\varepsilon_t) = \frac{\omega}{1-\alpha_1}$

และเงื่อนไขที่จะทำให้ค่าความแปรปรวนเป็นบวกคือ  $0 \leq \alpha_1 < 1$

ในทางปฏิบัติ เราต้องการทราบว่าค่าโมเมนต์ที่สูงกว่าโมเมนต์ที่สองเป็นอย่างไร ภายหลังจากการดำเนินการบางอย่างเราพบว่า โมเมนต์ที่สี่เท่ากับ

$$E(\varepsilon^4) = 3 \frac{\omega(1 + \alpha_1)}{(1 - \alpha_1)(1 - 3\alpha_1^2)} \quad (4.9)$$

ดังนั้นเงื่อนไขที่ทำให้โมเมนต์ที่มีค่าจำกัดคือ  $0 \leq \alpha_1 < 1/3$  และค่าความโค้งเท่ากับ

$$\kappa = \frac{E(\varepsilon_t^4)}{[Var(\varepsilon_t)]^2} = 3 \frac{\omega(1 + \alpha_1)}{(1 - \alpha_1)(1 - 3\alpha_1^2)} \times \frac{(1 - \alpha_1)^2}{\omega^2} = 3 \frac{1 - \alpha_1^2}{1 - 3\alpha_1^2} \quad (4.10)$$

ซึ่งค่าความโค้งจะมากกว่าสามเสมอ แสดงว่าการแจกแจงของช็อกในแบบจำลอง ARCH จะมีหางที่อ้วนกว่าปกติ

### 4.2.3 การประมาณค่าแบบจำลอง ARCH(1)

การประมาณค่าพารามิเตอร์ในแบบจำลอง ARCH(1) สามารถดำเนินการได้ด้วยวิธีการ conditional maximum likelihood หากสมมติให้  $z_t$  มีการแจกแจงแบบปกติมาตรฐาน จากสมการ (??) เราจะได้  $\varepsilon_t \sim N(0, \sigma_t^2)$  และฟังก์ชันล็อกไลกลิตูดจะเท่ากับ

$$\begin{aligned} \ln L(\cdot, \alpha_1; \mathbf{y}) &= \sum_{t=1}^T \ln f(\varepsilon_t | \varepsilon_{t-1}) \\ &= -\frac{1}{2} \sum_{t=1}^T \ln(2\pi) - \frac{1}{2} \sum_{t=1}^T \ln(\sigma_t^2) - \sum_{t=1}^T \left( \frac{y_t^2}{2\sigma_t^2} \right) \end{aligned} \quad (4.11)$$

โดยที่ค่า  $\varepsilon_0$  และ  $\sigma_0^2$  เท่ากับค่าเฉลี่ย เราสามารถหาตัวประมาณค่าพารามิเตอร์ได้จากการหาค่าสูงสุดของสมการ (??) อย่างไรก็ตามเราสามารถกำหนดการแจกแจงรูปแบบอื่นที่มีค่าเฉลี่ยเท่ากับศูนย์ และค่าความแปรปรวนเท่ากับหนึ่ง เช่น standardized student's t distribution

## 4.3 แบบจำลอง GARCH(p,q)

ถ้าเราทดสอบ ARCH effect ด้วยตัวทดสอบเช่น LM ARCH effect แล้วพบว่าอนุกรมเวลามีผลของ ARCH เราสามารถใช้แบบจำลอง ARCH(q) เพื่อประมาณค่าความผันผวนที่เปลี่ยนแปลงตามเวลา (time varying volatility:  $\sigma_t^2$ ) ซึ่งขึ้นอยู่กับข้อมูลในอดีต อย่างไรก็ตามในทางปฏิบัติ ค่า q ที่เหมาะสมสำหรับแบบจำลอง ARCH(q) ค่อนข้างที่จะยาว ส่งผลต่อจำนวนพารามิเตอร์ที่ต้องประมาณค่าและความเหมาะสม (goodness of fit) ของแบบจำลอง ดังนั้น Bollerslev (1986) ได้เสนอ

รูปแบบของสมการความแปรปรวนเป็น

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2 \quad (4.12)$$

โดยที่มีเงื่อนไขค่าสัมประสิทธิ์  $\alpha_i$  ( $i = 1, \dots, q$ ) และ  $\beta_j$  ( $j = 1, \dots, p$ ) มีค่าเป็นบวกเพื่อให้ค่าแปรปรวนเป็นบวก โดยที่สมการที่ (??) และ (??) รวมกันเรียกว่าแบบจำลอง Generalized ARCH หรือ  $GARCH(p, q)$  และหากค่า  $p = 0$  แบบจำลองดังกล่าวจะลดรูปเหลือแค่  $ARCH(q)$

ในแบบจำลอง  $GARCH(p, q)$  ค่าความแปรปรวนที่มีเงื่อนไข จะขึ้นอยู่กับค่ากำลังสองของค่าส่วนเกิน (squared residuals) ในช่วง  $q$  คาบก่อน และ ค่าความแปรปรวนที่มีเงื่อนไขในช่วง  $p$  คาบก่อน อย่างไรก็ตาม โดยปกติแล้ว แบบจำลอง  $GARCH(1, 1)$  ก็เพียงพอที่จะใช้อธิบายอนุกรมเวลาทางการเงิน

#### 4.3.1 ARMA representation of GARCH

ในขณะที่แบบจำลอง  $ARCH$  ที่สามารถเขียนให้อยู่ในรูปของแบบจำลอง  $AR$  ของค่า residuals ยกกำลังสอง แบบจำลอง  $GARCH$  สามารถเขียนให้อยู่ในรูปของแบบจำลอง  $ARMA$  ของค่า residuals ยกกำลังสอง ตัวอย่างเช่นในแบบจำลอง  $GARCH(1, 1)$

$$\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2 \quad (4.13)$$

เนื่องจาก  $E_{t-1}(\varepsilon_t^2) = \sigma_{t-1}^2$  ดังนั้นสมการ ?? สามารถเขียนใหม่ได้เป็น

$$\varepsilon_t^2 = \omega + (\alpha_1 + \beta_1) \varepsilon_{t-1}^2 + u_t - \beta_1 u_{t-1} \quad (4.14)$$

ซึ่งเป็นแบบจำลอง  $ARMA(1, 1)$  โดยที่  $u_t = \varepsilon_t^2 - E_{t-1}(\varepsilon_t^2)$  เป็นตัวแปรช็อกไวท์นอยซ์

แบบจำลอง  $GARCH$  ในรูปแบบของ  $ARMA$  สามารถใช้แสดงคุณสมบัติของแบบจำลอง  $GARCH$  ได้ง่ายตัวอย่างเช่น  $GARCH(1, 1)$  จะเป็นอนุกรมนิ่งถ้า  $\alpha_1 + \beta_1 < 1$  เนื่องจาก  $\varepsilon_t^2$  อยู่ในรูป  $AR(1)$  และ  $\alpha_1 + \beta_1$  คือสัมประสิทธิ์ของ  $\varepsilon_{t-1}^2$  ซึ่งจะต้องมีค่าน้อยกว่าหนึ่ง (อย่าลืมว่า  $\alpha_1$  และ  $\beta_1$  จะต้องมีความมากกว่าศูนย์)

หากเราสมมุติให้แบบจำลองเป็นอนุกรมนิ่ง เราสามารถหาความแปรปรวนที่ไม่มีเงื่อนไข (unconditional variance) ของ  $\varepsilon_t$  จะเท่ากับ  $Var(\varepsilon_t) = E(\varepsilon_t^2) = \omega / (1 - \alpha_1 - \beta_1)$  เนื่องจาก

$$\begin{aligned} E(\varepsilon_t^2) &= \omega + (\alpha_1 + \beta_1) \underbrace{E(\varepsilon_{t-1}^2)}_{=E(\varepsilon_t^2)} \\ E(\varepsilon_t^2) &= \omega + (\alpha_1 + \beta_1) E(\varepsilon_t^2) \end{aligned}$$

ในกรณี  $GARCH(p, q)$  ทั่วไปเราสามารถแสดงให้เห็นว่าเราสามารถเขียนแบบจำลอง

ดังกล่าวให้อยู่ในรูป  $ARMA(\max(p, q), p)$  ของ residuals ยกกำลังสอง และแบบจำลองจะเป็นอนุกรมหนึ่งถ้า  $\sum_{i=1}^q \alpha_i + \sum_{j=1}^p \beta_j < 1$  และความแปรปรวนที่ไม่มีเงื่อนไข (unconditional variance) ของ  $\varepsilon_t$  จะเท่ากับ

$$Var(\varepsilon_t) = \frac{\omega}{1 - \left( \sum_{i=1}^q \alpha_i + \sum_{j=1}^p \beta_j \right)}$$

### 4.3.2 คุณสมบัติเฉพาะของแบบจำลอง GARCH

ในทางปฏิบัติ นักวิจัยได้พบคุณสมบัติหลายประการของความผันผวนของข้อมูลทางการเงิน โดยที่เราสามารถใช้รูปแบบ  $ARMA$  ของ  $GARCH$  ในการแสดงคุณสมบัติต่างๆ โดยคุณสมบัติที่สำคัญสามประการคือ ความผันผวนเป็นกลุ่ม (volatility clustering), หางอ้วน (fat tails) และความผันผวนย้อนกลับมาที่ดุลยภาพ (volatility mean reversion)

#### ความผันผวนเป็นกลุ่ม (volatility clustering)

ในแบบจำลอง  $GARCH(1, 1)$  ที่แสดงในสมการที่ ?? ค่าที่ประมาณได้จากข้อมูลรายสัปดาห์และรายวันของ  $\beta_1$  จะมีค่าประมาณ 0.9 แสดงว่าหากค่า  $\sigma_{t-1}^2$  มีขนาดใหญ่จะทำให้  $\sigma_t^2$  มีขนาดใหญ่ด้วยเช่นเดียวกัน แต่ถ้า  $\sigma_{t-1}^2$  มีขนาดเล็กจะทำให้  $\sigma_t^2$  มีขนาดเล็ก ดังนั้นความผันผวนจะมีลักษณะที่เป็นกลุ่ม (clustering) คือความผันผวนขนาดใหญ่จะอยู่ใกล้ๆ กัน

#### หางอ้วน (fat tails)

ข้อมูลทางการเงินที่มีความถี่สูงจะมีหางที่อ้วนมากกว่าการแจกแจงแบบปกติ คือมีความน่าจะเป็นที่จะเกิดการเปลี่ยนแปลงขนาดใหญ่ (ที่ปลายหางของการแจกแจง) มากกว่ากรณีการแจกแจงแบบปกติ Bollerslev แสดงให้เห็นว่าภายใต้เงื่อนไขบางประการ เขาสามารถแสดงให้เห็นว่า  $GARCH(1, 1)$  จะให้ค่าเคอร์โทซิสที่มากกว่า 3 ซึ่งคือค่าเคอร์โทซิสของการแจกแจงแบบปกติ ดังนั้นแบบจำลอง  $GARCH$  สามารถเลียนแบบพฤติกรรมหางอ้วนในข้อมูลจริง

#### ความผันผวนย้อนกลับมาที่ดุลยภาพ (volatility mean reversion)

แม้ว่าความผันผวนจะสูงขึ้นในช่วงแต่สุดท้ายแล้วจะย้อนกลับไปยังดุลยภาพระยะยาว โดยที่ค่าความแปรปรวนของ  $GARCH(1, 1)$  จะเท่ากับ  $\omega / (1 - \alpha_1 - \beta_1)$  และถ้า  $\alpha_1 + \beta_1 < 1$  กระบวนการ  $GARCH(1, 1)$  จะเป็นกระบวนการนิ่ง และค่าความแปรปรวนจะกลับเข้าสู่ดุลยภาพในระยะยาว  $\omega / (1 - \alpha_1 - \beta_1)$  หรือเรียกว่า "mean reverts" กลับไปสู่ดุลยภาพระยะยาว แต่ถ้า  $\alpha_1 + \beta_1 \geq 1$  กระบวนการ  $GARCH(1, 1)$  จะเป็นกระบวนการไม่นิ่ง (nonstationary)



## 4.4 การประมาณค่าแบบจำลอง GARCH

ในหัวข้อนี้เราจะพิจารณาการประมาณค่าแบบจำลอง  $GARCH(p, q)$  โดยที่แบบจำลองสามารถเขียนในรูปแบบ

$$y_t = \mu_t + \varepsilon_t \quad (4.15)$$

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2 \quad (4.16)$$

สำหรับ  $t = 1, 2, \dots, T$  โดยที่  $\sigma_t^2 = Var_{t-1}(\varepsilon_t)$  และ  $\mu_t$  แทนแบบจำลองค่าเฉลี่ยเช่น อาจจะกำหนดให้เท่ากับค่าคงที่  $c$  หรือแบบจำลอง  $ARMA(p, q)$  หากเราสมมติให้  $\varepsilon_t$  มีการแจกแจงแบบปกติภายใต้ข้อมูลในอดีตเราสามารถเขียน log-likelihood function ของแบบจำลอง  $GARCH(p, q)$  ได้

$$\log L = -\frac{1}{2} \sum_{t=1}^T \ln(2\pi) - \frac{1}{2} \sum_{t=1}^T \ln(\sigma_t^2) - \sum_{t=1}^T \left( \frac{y_t^2}{2\sigma_t^2} \right) \quad (4.17)$$

หากสมมติให้  $\mu_t = c$  ค่าพารามิเตอร์ที่ต้องประมาณค่าคือ  $c, \alpha_i (i = 1, \dots, q), \beta_j (j = 1, \dots, p)$  โดยที่หลังจากที่เราประมาณค่าพารามิเตอร์ดังกล่าวแล้ว เราจะได้ค่า  $\sigma_t$  สำหรับ  $t = 1, \dots, T$

### 4.4.1 การตรวจสอบหลังจากการประมาณค่า GARCH

หลังจากที่เราประมาณค่าแบบจำลอง GARCH แล้วเราจำเป็นต้องตรวจสอบว่าแบบจำลองดังกล่าวเพียงพอต่อการอธิบายค่าเฉลี่ยที่มีเงื่อนไข (conditional mean) และค่าความแปรปรวนที่มีเงื่อนไข (conditional variance) หรือไม่ โดยมีพื้นฐานจากข้อสมมุติที่ว่า  $\varepsilon_t = \frac{\varepsilon_t}{\sigma_t} \sim iidN(0, 1)$  ดังนั้นเราจำเป็นต้องทดสอบ  $z_t$  ว่ามีคุณสมบัติเป็นอิสระต่อกัน และมีการแจกแจงแบบปกติหรือไม่ โดยที่ตัวแทนของ  $z_t$  คือ standardized residuals ( $\hat{z}_t = \frac{\varepsilon_t}{\sigma_t}$  โดยเราจะทดสอบดังต่อไปนี้

ประการแรก เราจะทดสอบว่าแบบจำลองเพียงพอต่อการอธิบายค่าเฉลี่ยที่มีเงื่อนไขหรือไม่ โดยการทดสอบว่า standardized residuals เป็นอิสระต่อกันหรือไม่ โดยการทดสอบ Ljung-Box ซึ่งสมมุติฐานหลักคือ standardized residuals เป็นอิสระต่อกัน หากเราไม่สามารถปฏิเสธสมมุติฐานหลักได้แสดงว่าแบบจำลองนั้นเพียงพอต่อการอธิบายค่าเฉลี่ยที่มีเงื่อนไข

ประการที่สอง เราจะทดสอบว่าแบบจำลองเพียงพอต่อการอธิบายความแปรปรวนแบบที่มีเงื่อนไขหรือไม่ หากแบบจำลองไม่เพียงพอต่อการอธิบายความแปรปรวนแบบมีเงื่อนไข ค่ายกกำลังสองของ standardized residuals จะต้องมีความสัมพันธ์ระหว่างกัน ซึ่งเราสามารถทดสอบ Ljung-Box กับค่ายกกำลังสองของ standardized residuals หรืออาจจะทดสอบ ARCH effect ของ standardized residuals หากเราไม่สามารถปฏิเสธสมมุติฐานหลักแสดงว่าแบบจำลองเพียงพอต่อการอธิบายความแปรปรวนที่มีเงื่อนไข

ประการที่สาม เราสามารถทดสอบว่าข้อสมมุติเกี่ยวกับการแจกแจงของ standardized

residuals ที่เราสมมุติว่ามีการแจกแจงแบบปกติมีความสมเหตุสมผลหรือไม่ โดยตั้งสมมุติหลักว่า standardized residuals มีการแจกแจงแบบปกติ หากเราปฏิเสธสมมุติฐานหลัก เราสามารถที่จะปรับปรุงแบบจำลองโดยการสมมุติการแจกแจงอื่นที่มีความคล่องตัวมากกว่าการแจกแจงแบบปกติ ซึ่งจะนำเสนอตัวอย่างในหัวข้อต่อไป

## ตัวอย่างที่ 4.2 การสร้างแบบจำลอง GARCH

ต่อจากตัวอย่าง 4.1 เราจะประมาณค่าสมการค่าเฉลี่ยด้วย  $ARMA(2, 2)$  และ สมการค่าความแปรปรวน ที่มีเงื่อนไข ด้วย  $GARCH(1, 1)$  หรือ ใช้สัญลักษณ์ว่า  $ARMA(2, 2) - GARCH(1, 1)$  โดยเราจะใช้คำสั่ง `ugarchfit` จาก package `rugarch` ในการประมาณค่าแบบจำลอง GARCH ซึ่งเป็นส่วนที่ประมาณค่า conditional variance เพิ่มขึ้นจากแบบจำลองที่อธิบาย conditional mean เช่น  $ARMA(2, 2)$

ในการ สร้าง แบบ จำลอง เรา จะ ต้อง ระบุ รูปแบบ ของ แบบ จำลอง `ugarchspec` โดยที่ `ugarchspec` คือการระบุรูปแบบของสมการ univariate GARCH ซึ่งประกอบด้วยส่วนหลัก ๆ สาม ส่วนได้แก่

- `variance.model=list(model="sGARCH", garchOrder=c(1, 1))` ส่วนนี้ระบุรูปแบบของ conditional variance เป็น standard GARCH (sGARCH) และอันดับ  $c(1, 1)$  คือ  $GARCH(1, 1)$
- `mean.model=list(armaOrder=c(2, 2), include.mean=TRUE)` ส่วนนี้ระบุรูปแบบของ conditional mean เป็น  $ARMA(2, 2)$  และมีส่วนของค่าคงที่ (`include.mean = TRUE`)
- `distribution.model = "norm"` ส่วนนี้ระบุการแจกแจงเป็นแบบปกติ

จะได้ผลดังนี้

```

1 > library(rugarch)
2 > spec.garch11 <- ugarchspec(variance.model=list(model="sGARCH",
3   garchOrder=c(1,1)),
4   + mean.model=list(armaOrder=c(2,2), include.mean=TRUE), distribution.model="norm")
5 > fit.garch11<-ugarchfit(spec=spec.garch11, data = ret)
6 > show(fit.garch11)
7
8 *-----*
9 *          GARCH Model Fit          *
10 *-----*
11
12 Conditional Variance Dynamics
13 -----
14 GARCH Model : sGARCH(1,1)
15 Mean Model  : ARFIMA(2,0,2)
16 Distribution : norm
17
18 Optimal Parameters
19 -----
20      Estimate Std. Error t value Pr(>|t|)
21 mu      0.005168   0.003323   1.5552 0.119893
22 ar1     0.929774   0.105519   8.8114 0.000000
23 ar2    -0.741403   0.131759  -5.6270 0.000000
24 ma1    -0.885132   0.079630 -11.1155 0.000000
25 ma2     0.813870   0.126564   6.4305 0.000000
26 omega   0.000194   0.000084   2.3165 0.020528
27 alpha1  0.221012   0.045507   4.8567 0.000001
28 beta1   0.777524   0.038916  19.9795 0.000000
29
30 Robust Standard Errors:
31      Estimate Std. Error t value Pr(>|t|)
32 mu      0.005168   0.004069   1.2701 0.204050
33 ar1     0.929774   0.134138   6.9315 0.000000
34 ar2    -0.741403   0.245777  -3.0166 0.002557
35 ma1    -0.885132   0.082263 -10.7597 0.000000
36 ma2     0.813870   0.253515   3.2103 0.001326
37 omega   0.000194   0.000120   1.6161 0.106077
38 alpha1  0.221012   0.063004   3.5079 0.000452
39 beta1   0.777524   0.051986  14.9564 0.000000
40
41 LogLikelihood : 542.9161

```

เราสามารถแสดงผลการประมาณค่าได้โดย

$$y_t = 0.93y_{t-1} - 0.74y_{t-2} + \varepsilon_t - 0.89\varepsilon_{t-1} + 0.81\varepsilon_{t-2}$$

$$\sigma_t^2 = 0.000194 + 0.22\varepsilon_{t-1}^2 + 0.78\sigma_{t-1}^2$$

นอกจากนี้ ผลการประมาณค่ายังแสดงผล Information Criteria สำหรับการเปรียบเทียบรูปแบบแบบจำลอง

1	Information Criteria	
2		
3		
4	Akaike	-2.3721
5	Bayes	-2.2992
6	Shibata	-2.3727
7	Hannan-Quinn	-2.3434

นอกจากนี้ คำสั่งดังกล่าวยังแสดงผลการทดสอบ Standardized Residuals ดังนี้

สำหรับกรณีของ Standardized Residuals หากพิจารณาที่ lag 1, 11, 19 พบว่าค่า p-value น้อยกว่าระดับนัยสำคัญที่เราเลือก แสดงว่าแบบจำลองในส่วน of conditional mean ไม่สามารถอธิบายตัวแปรที่เราสนใจได้ (เราจำเป็นต้องปรับแบบจำลองในส่วน of ARMA(p,q))

ในขณะที่กรณีของ Standardized Squared Residuals หากพิจารณาที่ lag 1, 5, 9 พบว่าค่า p-value มากกว่าระดับนัยสำคัญที่เราเลือก เช่น 0.05 แสดงว่าแบบจำลองในส่วน of conditional variance สามารถอธิบายตัวแปรได้

1 Weighted Ljung-Box Test on Standardized Residuals

2

3

4 statistic p-value

5 Lag[1] 3.351 6.717e-02

6 Lag[2\*(p+q)+(p+q)-1][11] 9.220 1.777e-06

7 Lag[4\*(p+q)+(p+q)-1][19] 13.350 8.841e-02

8 d.o.f=4

9 H0 : No serial correlation

10

10 Weighted Ljung-Box Test on Standardized Squared Residuals

11

12

13 statistic p-value

14 Lag[1] 0.0957 0.7571

15 Lag[2\*(p+q)+(p+q)-1][5] 1.8392 0.6569

16 Lag[4\*(p+q)+(p+q)-1][9] 3.0164 0.7563

17 d.o.f=2

18

18 Weighted ARCH LM Tests

19

20

21 Statistic Shape Scale P-Value

22 ARCH Lag[3] 1.876 0.500 2.000 0.1708

23 ARCH Lag[5] 3.360 1.440 1.667 0.2417

24 ARCH Lag[7] 3.586 2.315 1.543 0.4103

#### 4.4.2 การแจกแจงที่ไม่ใช่การแจกแจงแบบปกติ

ในหัวข้อที่ผ่านมาเราสมมติให้  $\varepsilon_t^2$  มีการแจกแจงแบบปกติมาตรฐานซึ่งข้อมูลทางการเงินบางข้อมูลอาจจะมีลักษณะหางอ้วน (fat tail) ดังนั้น ข้อสมมุติว่า  $\varepsilon_t^2$  มีการแจกแจงอื่นที่มีหางอ้วนน่าจะเหมาะสมกว่า เช่นการแจกแจงแบบ student't และ generalized error distribution (GED)

### การแจกแจงแบบ Student's $t$

ถ้าตัวแปรสุ่ม  $u_t$  มีการแจกแจงแบบ  $t$  ด้วยองศาเสรี (degree of freedom) เท่ากับ  $\nu$  "นิว" และตัวแปรสเกล  $s_t$  จะมีฟังก์ชันความถี่ความน่าจะเป็น (pdf) เท่ากับ

$$f(u_t) = \frac{\Gamma[(\nu + 1)/2]}{(\pi\nu)^{1/2}\Gamma(\nu/2)} \frac{s_t^{-1/2}}{[1 + u_t^2/(s_t\nu)]^{(\nu+1)/2}}$$

โดยที่  $\Gamma(\cdot)$  เป็นฟังก์ชันแกมมา และค่าความแปรปรวนของ  $u_t$  เท่ากับ

$$\text{Var}(u_t) = \frac{s_t\nu}{\nu - 2}, \quad \nu > 2$$

ถ้าค่าช็อก  $\varepsilon_t$  ในแบบจำลอง GARCH มีการแจกแจงแบบ  $t$  ที่มีองศาอิสระเท่ากับ  $\nu$  และมีค่า  $\text{Var}_{t-1}(\varepsilon_t) = \sigma_t^2$  แล้วพารามิเตอร์  $s_t$  จะถูกเลือกเพื่อให้  $s_t = \frac{\sigma_t^2(\nu-2)}{\nu}$

เงื่อนไขเพิ่มเติมในคำสั่ง garchFit คือ cond.dist=c("std") สำหรับการแจกแจงแบบ student's  $t$

### Generalized Error Distribution

Nelson (1991) ได้เสนอให้ใช้การแจกแจง generalized error distribution (GED) ในการผนวกคุณลักษณะหางอ้วนในแบบจำลอง ถ้า  $u_t$  มีการแจกแจงแบบ GED ที่มีค่าเฉลี่ยเท่ากับศูนย์ และค่าความแปรปรวนเท่ากับหนึ่ง ฟังก์ชันความถี่ความน่าจะเป็น (pdf) เท่ากับ

$$f(u_t) = \frac{\nu \exp[-(1/2)|u_t/\lambda|^\nu]}{\lambda 2^{(\nu+1)/\nu} \Gamma(1/\nu)}$$

โดยที่

$$\lambda = \left[ \frac{2^{-2/\nu} \Gamma(1/\nu)}{\Gamma(3/\nu)} \right]^{1/2}$$

โดยที่  $\nu$  เป็นค่าพารามิเตอร์ที่เป็นบวกที่บอกความหนาของหาง ถ้า  $\nu = 2$  pdf จะลดลงเหลือ pdf ของการแจกแจงปกติมาตรฐาน และถ้า  $\nu < 2$  ความถี่ที่หางจะหนาว่าการแจกแจงแบบปกติ

เงื่อนไขเพิ่มเติมในคำสั่ง garchFit คือ cond.dist=c("ged") สำหรับ generalized error distribution

### ตัวอย่าง 4.3: การสร้างแบบจำลอง GARCH ด้วยข้อสมมุติการแจกแจงแบบ $t$

ตัวอย่างนี้ใช้ข้อมูลต่อจากตัวอย่าง 4.2 เนื่องจากในตัวอย่างที่ผ่านมาเราพบว่า residuals ไม่ได้มีการแจกแจงแบบปกติ ดังนั้นเราอาจใช้การแจกแจงอื่นที่มีหางอ้วนกว่า เช่น การแจกแจงแบบ student's  $t$  และประมาณค่าแบบจำลอง fit.garch11.t โดยที่เปลี่ยน

```
distribution.model="std")
```

```
1 > spec.garch11.t <- ugarchspec(variance.model=list(model="sgarch",
2   garchorder=c(1,1)),
3   + mean.model=list(armaOrder=c(2,2), include.mean=TRUE), distribution.model="std")
4 > fit.garch11.t<-ugarchfit(spec=spec.garch11.t, data = ret)
5 > show(fit.garch11.t)
6
7 *-----*
8 *          GARCH Model Fit          *
9 *-----*
10 Conditional Variance Dynamics
11
12 GARCH Model : sgarch(1,1)
13 Mean Model  : ARFIMA(2,0,2)
14 Distribution : std
15
16 Optimal Parameters
17
18      Estimate Std. Error t value Pr(>|t|)
19 mu      0.005531   0.003261   1.6962 0.089852
20 ar1     0.977050   0.175427   5.5695 0.000000
21 ar2    -0.602677   0.150885  -3.9943 0.000065
22 ma1    -0.880078   0.155925  -5.6443 0.000000
23 ma2     0.648087   0.154766   4.1875 0.000028
24 omega   0.000156   0.000104   1.4966 0.134492
25 alpha1  0.184988   0.056949   3.2483 0.001161
26 beta1   0.814012   0.051417  15.8317 0.000000
27 shape   4.918851   1.144499   4.2978 0.000017
28 <Omitted>
29 Information Criteria
30
31
32 Akaike      -2.4373
33 Bayes       -2.3552
34 Shibata     -2.4381
35 Hannan-Quinn -2.4050
```

ในการประมาณค่าด้วยการแจกแจงแบบ student's  $t$  เราจะได้ค่า estimated shape คือตัวประมาณค่าองศาเสรี (degree of freedom) ในที่นี้คือ shape เท่ากับ 4.92

#### 4.4.3 การเลือกแบบจำลองที่เหมาะสม (Model selection)

จากหัวข้อที่ผ่านมาเราจะเห็นได้ว่าเราสามารถประมาณค่าแบบจำลอง GARCH ได้หลายรูปแบบ ดังนั้นการเลือกแบบจำลองที่เหมาะสมกับข้อมูลของเราเป็นขั้นตอนที่สำคัญ เนื่องจากเราสามารถเขียนแบบจำลองในรูปของ ARMA สำหรับ  $\varepsilon_t^2$  ได้ เราจึงสามารถใช้เกณฑ์ในการเลือกแบบจำลองที่เราได้เสนอไว้แล้วในบทที่แล้วเช่น Akaike information criteria (AIC) หรือ Bayesian information criteria (BIC) ในการเลือกแบบจำลอง

## ตัวอย่าง

จาก ตัวอย่างที่ 5.2 และ 5.3 เราสามารถนำค่า AIC และ BIC มาเปรียบเทียบกับตาราง

ตารางที่ 4.1: การเปรียบเทียบแบบจำลอง GARCH

เกณฑ์	$ARMA(2, 2) - GARCH(1, 1)$ fit.garch11	$ARMA(2, 2) - GARCH(1, 1)$ t-dist fit.garch11.t
AIC	-2.372	-2.437
BIC	-2.299	-2.355

จะเห็นได้ว่าค่า AIC และ BIC ของ GARCH ที่มีการแจกแจงแบบ student's  $t$  มีค่าน้อยกว่า AIC และ BIC ของ GARCH ที่มีการแจกแจงแบบปกติ แสดงให้เห็นว่าแบบจำลองที่มีการแจกแจงแบบ student's  $t$  น่าจะอธิบายข้อมูลได้ดีกว่า

#### 4.4.4 การขยายแบบจำลอง GARCH

แบบจำลอง GARCH สามารถปรับปรุงเพื่อให้สามารถอธิบายความผันผวนของข้อมูลจริงได้ดีขึ้น

##### Integrated GARCH

จากตัวอย่างการประมาณค่า  $GARCH(1, 1)$  สำหรับผลตอบแทนของหลักทรัพย์มักจะให้ค่าประมาณ  $\hat{\alpha}_1 + \hat{\beta}_1 \approx 1$  ตัวอย่างเช่นการประมาณค่าในตัวอย่างที่ 4.2  $\hat{\alpha}_1 + \hat{\beta}_1 = 0.22 + 0.777 = 0.997$

จากสมการที่ xxx เราพบว่าอนุกรมเวลาความผันผวนมีลักษณะใกล้เคียงกับ unit root หากเราขยายแบบจำลอง GARCH ให้มีลักษณะ unit root เราเรียกแบบจำลองดังกล่าวว่า Integrated GARCH (IGARCH) โดยที่เราสามารถผนวกเงื่อนไขที่ว่าความผันผวนเป็น unit root ได้โดยการกำหนดให้  $\alpha_1 + \beta_1 = 1$  หรือแทนค่า  $\beta_1 = 1 - \alpha_1$  ในสมการ (??) ส่งผลให้ conditional variance เท่ากับ

$$\sigma_t^2 = \omega + \alpha_1 \epsilon_{t-1}^2 + (1 - \alpha_1) \sigma_{t-1}^2 \quad (4.18)$$

จะเห็นได้ว่าจำนวนพารามิเตอร์ในแบบจำลองดังกล่าวเหลือเพียงแค่ 2 ตัวได้แก่  $\omega$  กับ  $\alpha_1$

##### การเพิ่มตัวแปรในแบบจำลอง GARCH

แนวทางหนึ่งในการขยายแบบจำลอง GARCH คือการเพิ่มตัวแปรในสมการค่าเฉลี่ยและสมการค่าความแปรปรวน เช่นในกรณีของแบบจำลอง  $GARCH(1, 1)$  สามารถขยายแบบจำลอง

ได้ดังสมการต่อไปนี้

$$y_t = \mu_t + \gamma_1 x_t + \epsilon_t$$

$$\sigma_t^2 = \omega + \alpha_1 \epsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2 + \lambda w_t$$

โดยที่  $x_t$  และ  $w_t$  คือตัวแปรอธิบายเพิ่มเติมสำหรับสมการค่าเฉลี่ยและสมการค่าความแปรปรวนตามลำดับ ตัวอย่างเช่นค่าความแปรปรวนอาจจะอธิบายได้ด้วยปริมาณการซื้อขาย การประกาศนโยบายของทางการ วันในสัปดาห์ และผลของวันหยุด

### การเปลี่ยนแปลงที่ไม่สมมาตร

ในแบบจำลอง GARCH เราพิจารณาตัวกำหนดความผันผวนด้วย  $\epsilon_{t-1}^2$  โดยที่ไม่ได้สนใจว่าช็อกที่เกิดขึ้นเป็นช็อกทางบวกหรือทางลบ ทั่วๆไปช็อกทางลบ(ในขนาดที่เท่ากัน)น่าจะทำให้เกิดความผันผวนมากกว่าช็อกทางบวก ดังนั้นแนวทางการขยายแบบจำลอง GARCH อีกทางหนึ่งคือการปรับแบบจำลองให้ผลของช็อกในทางบวกและทางลบมีค่าที่แตกต่างกัน โดยที่แบบจำลองในตลาดหลักทรัพย์เรามักจะพบว่า การปรับตัวลดลงของราคาหลักทรัพย์ส่งผลให้เกิดความผันผวนมากกว่าการปรับตัวขึ้นของราคา แบบจำลองที่ขยายขึ้นมานี้เราเรียกว่าเป็นแบบจำลองที่มีผลไม่สมมาตร

วิธีการแรกในการสร้างแบบจำลองที่มีผลไม่สมมาตรคือ threshold GARCH (TGARCH) ซึ่งสมการค่าความแปรปรวนสามารถอธิบายได้ดังนี้

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \epsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2 + \phi d_{t-1} \epsilon_{t-1}^2 \quad (4.19)$$

โดยที่  $d_{t-1}$  เป็นตัวแปรดัมมี่ที่นิยามได้ดังนี้

$$d_{t-1} = \begin{cases} 1 : & \epsilon_{t-1} < 0 \\ 0 : & \epsilon_{t-1} \geq 0 \end{cases}$$

เพื่อให้ค่าความแปรปรวนเป็นบวก เรากำหนดให้  $\phi > 0$  ดังนั้นหากเกิดข่าวดี ( $\epsilon_{t-1} \geq 0$ ) จะส่งผลต่อความผันผวนเท่ากับ  $\alpha_1$  ในทางตรงข้ามหากเกิดข่าวร้าย ( $\epsilon_{t-1} < 0$ ) จะส่งผลต่อความผันผวนเท่ากับ  $\alpha_1 + \phi$  จะเห็นได้ว่าช็อกทางลบส่งผลต่อความผันผวนมากกว่าช็อกทางบวก

อีกวิธีในการสร้างแบบจำลองที่มีผลไม่สมมาตรคือแบบจำลอง Exponential GARCH (EGARCH) ซึ่งสามารถแสดงได้ด้วยสมการต่อไปนี้

$$\ln \sigma_t^2 = \omega + \alpha_1 \frac{\epsilon_{t-1}}{\sigma_{t-1}} + \phi \left\| \frac{\epsilon_{t-1}}{\sigma_{t-1}} \right\| + \beta_1 \ln \sigma_{t-1}^2 \quad (4.20)$$



### การพิจารณาค่าความเสี่ยงในสมการค่าเฉลี่ย

ในทางการเงินความเสี่ยงที่สูงจะนำมาสู่ผลตอบแทนที่สูงด้วย หรือเราเรียกว่า "เบี้ยความเสี่ยง (risk premium)" Engle, Lilien, and Robins (1987) เสนอให้ขยาย *GARCH* เพื่อให้พิจารณาเบี้ยความเสี่ยงเป็นปัจจัยหนึ่งในการกำหนดผลตอบแทนในสมการค่าเฉลี่ย หรือสามารถอธิบายได้ด้วยสมการ

$$y_t = c + \alpha g(\sigma_t) + \varepsilon_t$$

และเราเรียกแบบจำลองนี้ว่า GARCH-in-the-mean (*GARCH - M*)

## 4.5 การพยากรณ์ด้วยแบบจำลอง GARCH

เป้าหมายสำคัญของการสร้างแบบจำลองสำหรับ conditional volatility คือการสร้างการคาดการณ์ที่แม่นยำขึ้นสำหรับการทำนายค่าอนุกรมเวลาที่เราสนใจในอนาคตและการพยากรณ์ conditional variance

เนื่องจากในสมการค่าเฉลี่ยเราสมมติให้อนุกรมเวลาถูกอธิบายด้วยแบบจำลอง *ARMA* ดังนั้นค่าพยากรณ์ของอนุกรมเวลา  $y_t$  สามารถใช้การพยากรณ์ของ *ARMA* ได้อย่างปกติ อย่างไรก็ตามการที่เราอนุญาตให้ความผันผวนสามารถเปลี่ยนแปลงได้ตามเวลา เช่นแบบจำลอง *GARCH* จะทำให้เราได้ค่าผันผวนในอนาคตที่แม่นยำขึ้นโดยเฉพาะการพยากรณ์ในระยะสั้น ในที่นี้เราจะยกตัวอย่างแบบจำลอง *GARCH*(1, 1) ซึ่งสมการความผันผวนสามารถแสดงได้โดย

$$\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$

หากเราพิจารณาข้อมูลจนถึงคาบที่  $h$  และการพยากรณ์ไปข้างหน้าหนึ่งคาบสามารถคำนวณได้โดยใช้ conditional expectation

$$\begin{aligned} E_h(\sigma_{h+1}^2) &= \omega + \alpha_1 E_h(\varepsilon_h^2) + \beta_1 E_h(\sigma_h^2) \\ &= \omega + \alpha_1 \varepsilon_h^2 + \beta_1 \sigma_h^2 \end{aligned}$$

เนื่องจากเราทราบว่า  $\varepsilon_h^2$  และ  $\sigma_h^2$  จากการประมาณค่าแล้ว ต่อไปพิจารณาคาบที่  $h+2$

$$\begin{aligned} E_h(\sigma_{h+2}^2) &= \omega + \alpha_1 E_h(\varepsilon_{h+1}^2) + \beta_1 E_h(\sigma_{h+1}^2) \\ &= \omega + (\alpha_1 + \beta_1) E_h(\sigma_{h+1}^2) \end{aligned}$$

เนื่องจาก  $E_h(\varepsilon_{h+1}^2) = E_h(\sigma_{h+1}^2)$  จากวิธีการข้างต้นเราสามารถสร้างสมการสำหรับการพยากรณ์ ณ

ค่า  $k$  ใดๆได้เป็น

$$E_h(\sigma_{h+k}^2) = \omega \sum_{i=1}^{k-2} (\alpha_1 + \beta_1)^i + (\alpha_1 + \beta_1)^{k-1} E_h(\sigma_{h+1}^2) \quad (4.21)$$


สำหรับ  $k \geq 2$  และจะเห็นได้ว่าถ้า  $k \rightarrow \infty$  และ GARCH เป็นอนุกรมหนึ่ง ( $\alpha_1 + \beta_1 < 1$ ) การพยากรณ์ค่าความผันผวนจะเข้าใกล้ unconditional variance  $\omega/(1 - \alpha_1 - \beta_1)$

#### ตัวอย่าง 4.4 การคำนวณ predicted conditional variance และการพยากรณ์

จากแบบจำลอง GARCH เราสามารถคำนวณค่า predicted conditional variance หรือ standard deviation กับข้อมูลภายในกลุ่มตัวอย่าง (in-sample) เพื่อใช้เป็นตัวแทนของความผันผวน (volatility) สำหรับแบบจำลองทางการเงินต่าง ๆ ในตัวอย่างที่ 5.2 เราได้ประมาณค่าแบบจำลอง ARMA(2,2)-GARCH(1,1) ซึ่งเราสามารถคำนวณค่า predicted conditional standard deviation ได้จากคำสั่ง |sigma|

```
1 sig.garch11<-sigma(fit.garch11)
2 volatility<-ts(data=sig.garch11[,1], frequency=12, start=c(1975,5),
   end=c(2013,11))
3 plot.ts(volatility, type="l")
```

รูปที่ 4.3: ACF ของ residuals



จากรูป ?? จะเห็นได้ว่าช่วงที่ตลาดหุ้นไทยผันผวนค่อนข้างสูงและยาวนานคือหลังวิกฤติ 1997

นอกจากนี้ เราสามารถพยากรณ์ออกไปนอกช่วงข้อมูล (out-of sample) ซึ่งเราสามารถพยากรณ์ค่าเฉลี่ยและค่าความแปรปรวน เราสามารถใช้คำสั่ง ugarchforecast และระบุแบบจำลอง |

fit.garch11| และจำนวนคาบที่จะพยากรณ์ไปข้างหน้า n.ahead=5 และได้ผลดังต่อไปนี้

```

1 > garch11.fcst=ugarchforecast(fit.garch11, n.ahead=5)
2 > garch11.fcst
3
4 *-----*
5 *      GARCH Model Forecast      *
6 *-----*
7 Model: sGARCH
8 Horizon: 5
9 Roll Steps: 0
10 Out of Sample: 0
11
12 O-roll forecast [T0=1971-03-28 07:00:00]:
13      Series      Sigma
14 T+1  0.0008783  0.04438
15 T+2 -0.0026793  0.04648
16 T+3  0.0010525  0.04849
17 T+4  0.0071598  0.05041
18 T+5  0.0100715  0.05226

```

หรือสามารถเขียนสรุปได้เป็น

horizon	1	2	3	4	5
log return	0.0009	-0.0027	0.0011	0.0072	0.0101
volatility ( $\sigma_t$ )	0.0444	0.0465	0.0485	0.0504	0.0523

## บทที่ 5

# แบบจำลองอนุกรมเวลาเชิงพหุ (Multivariate time series model)

เนื่องจากตลาดการเงินของโลกมีความเชื่อมโยงกันมากขึ้น การเปลี่ยนแปลงที่เกิดขึ้นในตลาดการเงินหนึ่งสามารถส่งผ่านต่อไปยังตลาดอื่นได้ง่าย ดังนั้น บางครั้งเราจำเป็นต้องพิจารณาการเปลี่ยนแปลงของอนุกรมเวลาทางเงินไปพร้อมๆ กัน โดยเราเรียกแบบจำลองที่พิจารณาอนุกรมเวลาหลายๆ อนุกรมพร้อมกันว่าแบบจำลองอนุกรมเวลาเชิงพหุ (multivariate time series) โดยเราสามารถเขียนอนุกรมเวลาในรูปของเวกเตอร์  $\mathbf{Y}_t = (y_{1t}, y_{2t}, \dots, y_{nt})'$  โดยที่  $y_{it}$  แทนอนุกรมเวลา  $i$  และ  $n$  คือจำนวนอนุกรมเวลาที่เราพิจารณาร่วมกัน<sup>1</sup> เช่น  $y_{1t}, y_{2t}, \dots, y_{nt}$  แทนผลได้ตอบแทนในรูปดอกเบี้ยของหุ้นในตลาดหลักทรัพย์แห่งประเทศไทย

## 5.1 ความนิ่งของอนุกรมเวลาและเมตริกซ์สหสัมพันธ์ระหว่างกัน

$\mathbf{Y}_t = (y_{1t}, y_{2t}, \dots, y_{nt})'$  จะเป็นอนุกรมเวลานิ่ง (stationary) ถ้าโมเมนต์ที่หนึ่งและสองไม่ขึ้นอยู่กับเวลา (time-invariant) ซึ่งในที่นี้เราจะต้องพิจารณาเวกเตอร์ของค่าเฉลี่ย (mean vector)  $\boldsymbol{\mu} = E(\mathbf{Y}_t)$  โดยที่  $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)'$

เมตริกซ์ของความแปรปรวนร่วม (covariance matrix) ใช้สัญลักษณ์  $\Gamma_0$  สามารถคำนวณได้

---

<sup>1</sup> สัญลักษณ์ ' แทน transpose ของเมตริกซ์

โดย

$$\begin{aligned}\Gamma_0 &= E[(\mathbf{Y}_t - \boldsymbol{\mu})(\mathbf{Y}_t - \boldsymbol{\mu})'] \\ &= \begin{pmatrix} E(y_{1t} - \mu_1)^2 & E(y_{1t} - \mu_1)(y_{2t} - \mu_2) & \dots & E(y_{1t} - \mu_1)(y_{nt} - \mu_n) \\ \vdots & \vdots & \ddots & \vdots \\ E(y_{nt} - \mu_n)(y_{1t} - \mu_1) & E(y_{nt} - \mu_n)(y_{2t} - \mu_2) & \dots & E(y_{nt} - \mu_n)^2 \end{pmatrix} \\ &= \begin{pmatrix} Var(y_{1t}) & Cov(y_{1t}, y_{2t}) & \dots & Cov(y_{1t}, y_{nt}) \\ \vdots & \vdots & \ddots & \vdots \\ Cov(y_{nt}, y_{1t}) & Cov(y_{nt}, y_{2t}) & \dots & Var(y_{nt}) \end{pmatrix}\end{aligned}$$

จะเห็นได้ว่าพจน์ในแนวทแยงมุมจะเป็นค่าความแปรปรวนของแต่ละอนุกรมเวลา ในขณะที่พจน์ที่  $(i, j)$  จะเป็นสหสัมพันธ์ระหว่าง  $y_{it}$  และ  $y_{jt}$  ในคาบเวลาเดียวกัน

### 5.1.1 cross-correltaion matrices

กำหนดให้  $D$  เป็นเมทริกซ์  $n \times n$  ที่ประกอบด้วยค่าเบี่ยงเบนมาตรฐาน (standard deviation) ของ  $y_{it}$  ในพจน์ทแยงมุม โดยที่  $\Gamma_{ii}(0)$  เป็นสัญลักษณ์แทนค่าความแปรปรวนของ  $y_{it}$  ดังนั้นเราสามารถเขียนเมทริกซ์  $D$  ได้ดังนี้

$$D = \begin{pmatrix} \sqrt{\Gamma_{11}(0)} & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \sqrt{\Gamma_{nn}(0)} \end{pmatrix}$$

เราสามารถ นิยาม เม ทริกซ์ สห สัมพันธ์ ข้าม ตัวแปร (cross-correlation) ที่ คาบ เวลา เดียวกัน (concurrent) ได้ด้วย

$$\boldsymbol{\rho}_0 = [\rho_{ij}(0)] = D^{-1}\Gamma_0 D^{-1}$$

โดยที่  $\rho_{ij}(0) = \frac{\Gamma_{ij}(0)}{\sqrt{\Gamma_{ii}(0)\Gamma_{jj}(0)}} = \frac{Cov(y_{it}, y_{jt})}{std(y_{it})std(y_{jt})}$  ซึ่งคือสหสัมพันธ์ระหว่าง  $y_{it}$  และ  $y_{jt}$  โดยที่ในการวิเคราะห์อนุกรมเวลาเราจะเรียกสหสัมพันธ์ดังกล่าวว่าเป็นสหสัมพันธ์ในคาบเดียวกัน (concurrent หรือ contemporaneous)

นอกจากนี้ การวิเคราะห์อนุกรมเวลาเชิงพหุ เราสนใจความสัมพันธ์ในเชิงตัวแปรที่นำหรือตาม (lead-lag relationship) ระหว่างตัวแปรที่เราสนใจ ดังนั้นเราต้องการหาเมทริกซ์สหสัมพันธ์ข้ามตัวแปรที่ใช้วัดความสัมพันธ์ระหว่างช่วงเวลาเช่น เมทริกซ์ความแปรปรวนร่วมข้ามตัวแปรที่มี

ค่าเล่าเท่ากับหนึ่งใช้สัญลักษณ์  $\Gamma_1$  ดังที่ได้แสดงในสมการต่อไปนี้

$$\begin{aligned}\Gamma_1 &= E[(\mathbf{Y}_t - \boldsymbol{\mu})(\mathbf{Y}_{t-1} - \boldsymbol{\mu})'] \\ &= \begin{pmatrix} E(y_{1t} - \mu_1)(y_{1,t-1} - \mu_1) & E(y_{1t} - \mu_1)(y_{2,t-1} - \mu_2) & \dots & E(y_{1t} - \mu_1)(y_{n,t-1} - \mu_n) \\ \vdots & \vdots & \ddots & \vdots \\ E(y_{nt} - \mu_n)(y_{1,t-1} - \mu_1) & E(y_{nt} - \mu_n)(y_{2,t-1} - \mu_2) & \dots & E(y_{nt} - \mu_n)(y_{n,t-1} - \mu_n) \end{pmatrix} \\ &= \begin{pmatrix} Cov(y_{1t}, y_{1,t-1}) & Cov(y_{1t}, y_{2,t-1}) & \dots & Cov(y_{1t}, y_{n,t-1}) \\ \vdots & \vdots & \ddots & \vdots \\ Cov(y_{nt}, y_{1,t-1}) & Cov(y_{nt}, y_{2,t-1}) & \dots & Cov(y_{nt}, y_{n,t-1}) \end{pmatrix}\end{aligned}$$

เราสามารถคำนวณเมทริกซ์สหสัมพันธ์ข้ามตัวแปร (cross-correlation) ที่มีค่าเล่าเท่ากับหนึ่ง ได้ด้วย

$$\boldsymbol{\rho}_1 = [\rho_{ij}(1)] = \mathbf{D}^{-1}\Gamma_1\mathbf{D}^{-1}$$

โดยที่  $\rho_{ij}(1) = \frac{\Gamma_{ij}(1)}{\sqrt{\Gamma_{ii}(0)\Gamma_{jj}(0)}} = \frac{Cov(y_{it}, y_{j,t-1})}{std(y_{it})std(y_{jt})}$  ซึ่งคือสหสัมพันธ์ระหว่าง  $y_{it}$  และ  $y_{j,t-1}$  หากค่า  $\rho_{ij}(1) \neq 0$  แสดงว่าการเปลี่ยนแปลงของ  $y_{jt}$  ในคาบที่ผ่านมาส่งผลต่อการเปลี่ยนแปลงของ  $y_{it}$  ในคาบปัจจุบัน ดังนั้น  $y_{jt}$  เป็นตัวแปรนำ (lead)  $y_{it}$

ความสัมพันธ์ดังกล่าวสามารถขยายไปยังกรณี  $\Gamma_l, l = \dots, -2, -1, 0, 1, 2, \dots$  ถ้าหากค่า  $\rho_{ij}(l) \neq 0$  กรณีที่  $l > 0$  แสดงว่า  $y_{jt}$  เป็นตัวแปรนำ (lead)  $y_{it}$  แต่ถ้า  $\rho_{ij}(l) \neq 0$  กรณีที่  $l < 0$  แสดงว่า  $y_{it}$  เป็นตัวแปรนำ (lead)  $y_{jt}$

## 5.2 แบบจำลองเวกเตอร์ออโตรีเกรสซีฟ (Vector Autoregressive Model)

กำหนดให้  $\mathbf{Y}_t = (y_{1t}, y_{2t}, \dots, y_{nt})'$  แทน  $(n \times 1)$  เวกเตอร์ของตัวแปรอนุกรมเวลาจำนวน  $n$  ตัวแปร แล้วแบบจำลองเวกเตอร์ออโตรีเกรสซีฟที่มีค่าเล่าเท่ากับ  $p$  ซึ่งใช้สัญลักษณ์  $VAR(p)$  สามารถเขียนในรูป

$$\mathbf{Y}_t = \mathbf{c} + \Phi_1\mathbf{Y}_{t-1} + \dots + \Phi_p\mathbf{Y}_{t-p} + \boldsymbol{\varepsilon}_t, \quad t = 1, 2, \dots, T \quad (5.1)$$

โดยที่  $\Phi_i$  เป็นเมทริกซ์สัมประสิทธิ์ที่มีขนาด  $n \times n$  และ  $\boldsymbol{\varepsilon}_t$  เป็นเวกเตอร์ของกระบวนการไวทนอชที่มีค่าเฉลี่ยเท่ากับศูนย์และมีเมทริกซ์ความแปรปรวนร่วมที่ไม่แปรผันตามเวลา  $\Sigma$  ตัวอย่างเช่น หากเราสนใจแบบจำลอง  $VAR$  ที่มีตัวแปรที่เราสนใจสองตัวและมีค่าเล่าเท่ากับ 1 เราสามารถเขียนใน

รูปเมตริกซ์ได้เป็น

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} + \begin{pmatrix} \phi_{11}^1 & \phi_{12}^1 \\ \phi_{21}^1 & \phi_{22}^1 \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad (5.2)$$

หรือเขียนเป็นรูปสมการของแต่ละตัวแปรที่เราสนใจ

$$\begin{aligned} y_{1t} &= c_1 + \phi_{11}^1 y_{1t-1} + \phi_{12}^1 y_{2t-1} + \varepsilon_{1t} \\ y_{2t} &= c_2 + \phi_{21}^1 y_{1t-1} + \phi_{22}^1 y_{2t-1} + \varepsilon_{2t} \end{aligned}$$

โดยที่  $Cov(\varepsilon_{1t}, \varepsilon_{2s}) = \sigma_{12}$  ถ้า  $s = t$  และ  $Cov(\varepsilon_{1t}, \varepsilon_{2s}) = 0$  ถ้า  $s \neq t$  (คือไม่มีสหสัมพันธ์ข้ามเวลาระหว่างข้อของตัวแปรที่ต่างกัน) จากแบบจำลองข้างต้นจะเป็นได้ว่าตัวแปร  $y_{1t}$  ถูกอธิบายด้วย ค่าในอดีตของตัวเอง  $y_{1t-1}$  และตัวแปรอื่น  $y_{2t-1}$

ค่าสัมประสิทธิ์แต่ละตัวจะเป็นค่าที่บอกความสัมพันธ์ระหว่างตัวแปรที่ต่างเวลากัน ตัวอย่างเช่น  $\phi_{12}^1$  จะแสดงความสัมพันธ์ระหว่าง  $y_{1t}$  และ  $y_{2t-1}$  ซึ่งถ้า  $\phi_{12}^1 = 0$  แล้ว  $y_{1t}$  จะไม่ขึ้นกับค่า  $y_{2t-1}$  และขึ้นอยู่กับค่าในอดีตของ  $y_{1t}$  เท่านั้น เช่นเดียวกับค่า  $\phi_{21}^1$  จะแสดงความสัมพันธ์ระหว่าง  $y_{2t}$  และ  $y_{1t-1}$  ซึ่งจะเห็นได้ว่าค่าสัมประสิทธิ์ในสมการ ?? อธิบายพลวัตของอนุกรมเวลาที่เราสนใจ (lead-lag) แต่มีได้อธิบายความสัมพันธ์ระหว่างอนุกรมเวลาในช่วงเวลาเดียวกัน (concurrent หรือ contemporaneous) ใช้อย่างชัดเจน เราสามารถดูความสัมพันธ์ดังกล่าวได้ในเมทริกซ์ความแปรปรวนของข้อหรือพูดให้ชัดเจนคือการพิจารณาค่า  $Cov(\varepsilon_{1t}, \varepsilon_{2t})$  นั่นเอง เราเรียกแบบจำลองเวกเตอร์ออโตรีเกรสซีฟในรูป ?? ว่าสมการในรูปลดรูป (reduced form)

เราสามารถเขียนความสัมพันธ์ระหว่างอนุกรมเวลาในช่วงเดียวกันได้อย่างชัดเจน โดยใช้การแปลงรูปสมการที่ ?? ได้ดังนี้ เนื่องจาก  $\Sigma$  เป็นเมทริกซ์ที่มีคุณลักษณะเป็น positive definite ดังนั้นเราสามารถสร้างเมทริกซ์ lower triangular

$$L = \begin{pmatrix} 1 & 0 & \dots & 0 \\ l_{21} & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & \dots & 1 \end{pmatrix}$$

และเมทริกซ์เทงมู  $G$  ที่ทำให้  $\Sigma = LGL'$  เราเรียกการแยกส่วนประกอบนี้ว่า Cholesky decomposition

กำหนดให้  $\eta_t = L^{-1}\varepsilon_t$  เราจะได้ว่า

$$E(\eta_t) = L^{-1}E(\varepsilon_t) = 0$$

$$Var(\eta_t) = L^{-1}Var(\varepsilon_t)(L^{-1})' = L^{-1}\Sigma(L^{-1})' = L^{-1}LGL'(L^{-1})' = G$$

เนื่องจาก  $G$  เป็นเมทริกซ์เทงมู ดังนั้นส่วนประกอบของ  $\eta_t$  จะไม่มีความสัมพันธ์ระหว่างกัน

หากเราคูณข้างหน้าสมการ ?? ด้วย  $L^{-1}$  จะได้

$$\begin{aligned} L^{-1}Y_t &= L^{-1}c + L^{-1}\Phi_1 Y_{t-1} + \dots + L^{-1}\Phi_p Y_{t-p} + L^{-1}\epsilon_t, \quad t = 1, 2, \dots, T \\ L^{-1}Y_t &= c^* + \Phi_1^* Y_{t-1} + \dots + \Phi_p^* Y_{t-p} + \eta_t \end{aligned} \quad (5.3)$$

โดยที่เมทริกซ์  $L^{-1}$  จะแสดงความสัมพันธ์ระหว่างอนุกรมเวลาในคาบเดียวกัน และเราเรียกแบบจำลองเวกเตอร์ออโตรีเกรสซีฟในรูป ?? ว่าสมการในรูปโครงสร้าง (structural equation)

### ตัวอย่าง 5.1: การแปลงสมการในรูปลดรูปไปเป็นรูปโครงสร้าง

กำหนดให้แบบจำลองเวกเตอร์ออโตรีเกรสซีฟที่มีสองตัวแปรและมีอันดับเท่ากับหนึ่ง (หรือเรียกย่อๆว่า Bivariate VAR(1)) สามารถแสดงในรูปลดรูปได้ดังนี้

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 0.2 & 0.3 \\ -0.6 & 1.1 \end{pmatrix} \begin{pmatrix} y_{1,t-1} \\ y_{2,t-1} \end{pmatrix} + \begin{pmatrix} \epsilon_{1t} \\ \epsilon_{2t} \end{pmatrix} \quad (5.4)$$

โดยที่  $\Sigma = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}$  โดยที่เราสามารถใช้ Cholesky decomposition หาเมทริกซ์  $L^{-1} = \begin{pmatrix} 1 & 0 \\ -0.5 & 1 \end{pmatrix}$  หากเราคูณสมการ ?? ด้วย  $L^{-1}$  จะได้

$$\begin{pmatrix} 1 & 0 \\ -0.5 & 1 \end{pmatrix} \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 0.2 & 0.3 \\ -0.7 & 0.95 \end{pmatrix} \begin{pmatrix} y_{1,t-1} \\ y_{2,t-1} \end{pmatrix} + \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \end{pmatrix} \quad (5.5)$$

โดยที่  $G = Var(\eta_t) = \begin{pmatrix} 2 & 0 \\ 0 & 0.5 \end{pmatrix}$  จากสมการที่สองของ ?? เราสามารถเขียนความสัมพันธ์ได้เป็น

$$y_{2t} = 0.5y_{1t} - 0.7y_{1,t-1} + 0.95y_{2,t-1} + \eta_{2t}$$

ซึ่งแสดงความสัมพันธ์ระหว่าง  $y_{1t}$  และ  $y_{2t}$  ในช่วงเวลาเดียวกันไว้อย่างชัดเจน

เราจะเห็นได้ว่าเราสามารถแปลงแบบจำลองเวกเตอร์ออโตรีเกรสซีฟในรูปลดรูปไปเป็นรูปโครงสร้างได้ด้วย Cholesky decomposition อย่างไรก็ตามในการวิเคราะห์อนุกรมเวลาเรามักจะใช้สมการในรูปลดรูป เนื่องจากเป็นรูปที่ง่ายในการประมาณค่า และเรามักจะเน้นผลในการพยากรณ์ของแบบจำลองซึ่งเราไม่สามารถใช้แบบจำลองในรูปโครงสร้างพยากรณ์ข้อมูลได้เนื่องจากเราไม่ทราบข้อมูลของอนุกรมเวลาอื่นๆในคาบเดียวกัน



### 5.2.1 เงื่อนไขการเป็นอนุกรมเวลาหนึ่ง

แบบจำลอง  $VAR(p)$  สามารถเขียนในรูปเครื่องหมายขยับไปข้างหลัง (lag operator) ได้ดังนี้

$$\Phi(L)Y_t = c + \varepsilon_t \quad (5.6)$$

โดยที่  $\Phi(L) = I_n - \Phi_1 L - \dots - \Phi_p L^p$  แบบจำลอง  $VAR(p)$  จะมีเสถียรภาพถ้ารากของ

$$\det(I_n - \Phi_1 z - \dots - \Phi_p z^p) = 0$$

มีค่ามากกว่าหนึ่ง (หรือ โมดูลัสมากกว่าหนึ่งในกรณีจำนวนเชิงซ้อน) ถ้าสมมติให้กระบวนการดังกล่าวมีค่าในอดีตที่เป็นอนันต์ แล้วกระบวนการ  $VAR(p)$  ที่มีเสถียรภาพจะเป็นกระบวนการนิ่งและ ergodic โดยมีค่าเฉลี่ย ค่าความแปรปรวนและค่าความแปรปรวนร่วมในตัวเองที่ไม่ขึ้นกับเวลา

### ตัวอย่างที่ 5.2

สมมติว่าเราพิจารณาแบบจำลอง  $VAR(1)$  ของสองตัวแปรดังมีเมทริกซ์สัมประสิทธิ์ดังตัวอย่างที่ 5.1 เราสามารถเขียนแบบจำลอง  $VAR$  ในรูปของ polynomial matrix ได้ดังนี้

$$\left( \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} - \begin{bmatrix} 0.2 & 0.3 \\ -0.6 & 1.1 \end{bmatrix} L \right) \begin{bmatrix} y_{1t} \\ y_{2t} \end{bmatrix} = \begin{bmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{bmatrix}$$

โดยที่ polynomial matrix สามารถจัดรูปได้เป็น

$$\Phi(L) = \begin{bmatrix} 1 - 0.2L & -0.3L \\ 0.6L & 1 - 1.1L \end{bmatrix}$$

ซึ่งดีเทอร์มิแนนต์เท่ากับ  $|\Phi(L)| = (1 - 0.2L)(1 - 1.1L) + (0.6)(0.3)L^2 = 1 - 1.3L + 0.4L^2$  เราสามารถหาคำตอบของสมการพหุนามได้เท่ากับ 2 และ 1.25 ซึ่งต่างมีค่าสัมบูรณ์มากกว่าหนึ่ง เราสามารถสรุปได้ว่าตัวแปรในแบบจำลอง  $VAR$  ที่มีเมทริกซ์สัมประสิทธิ์ดังกล่าวเป็นตัวแปรนิ่ง (stationary) ด้วยกันทั้งคู่

## 5.3 การประมาณค่าและการเลือกค่า

### 5.3.1 การประมาณค่า

การเราพิจารณาสมการ ?? แต่ละสมการจะมีตัวแปรที่เหมือนกัน เราสามารถพิจารณาสมการสำหรับแต่ละตัวแปรออกเป็น

$$\mathbf{y}_i = \mathbf{Z}\boldsymbol{\phi}_i + \mathbf{e}_i, \quad i = 1, \dots, n$$

โดยที่  $\mathbf{y}_i$  คือ เวกเตอร์  $(T \times 1)$  ของตัวแปรตามในสมการที่  $i$  ในขณะที่  $\mathbf{Z}$  คือเมทริกซ์  $(T \times k)$  ที่แถว  $t$  แทนด้วย  $\mathbf{Z}'_t = (1, \mathbf{Y}'_{t-1}, \dots, \mathbf{Y}'_{t-p})$ ,  $k = np + 1$  และ  $\boldsymbol{\phi}_i$  คือ  $(k \times 1)$  เวกเตอร์ของพารามิเตอร์ และ  $\mathbf{e}_i$  คือ error term ที่มีเวกเตอร์ค่าความแปรปรวนร่วม  $\sigma_i^2 \mathbf{I}_T$  จะเห็นได้ว่าแต่ละสมการสามารถประมาณค่าได้ด้วย ordinary least squares (OLS) แยกแต่ละสมการ และจะได้  $\hat{\boldsymbol{\Phi}} = [\hat{\boldsymbol{\phi}}_1, \dots, \hat{\boldsymbol{\phi}}_n]$  เป็นเมทริกซ์  $(k \times n)$  ของค่าสัมประสิทธิ์จากการประมาณค่าด้วย OLS หากกำหนดให้เครื่องหมาย  $\text{vec}$  แทนการนำเมทริกซ์มาเรียงต่อกัน เราจะได้

$$\text{vec}(\hat{\boldsymbol{\Phi}}) = \begin{pmatrix} \hat{\boldsymbol{\phi}}_1 \\ \vdots \\ \hat{\boldsymbol{\phi}}_n \end{pmatrix}$$

ภายใต้ข้อสมมุติที่แบบจำลองเป็นแบบกระบวนการนิ่งและ ergodic เราจะได้  $\text{vec}(\hat{\boldsymbol{\Phi}})$  มีคุณสมบัติ consistent และมีการแจกแจงแบบปกติเมื่อกลุ่มตัวอย่างใหญ่ โดยมีเมทริกซ์ค่าความแปรปรวนเท่ากัน

$$\widehat{\text{aver}}(\text{vec}(\hat{\boldsymbol{\Phi}})) = \hat{\boldsymbol{\Sigma}} \otimes (\mathbf{Z}'\mathbf{Z})^{-1}$$

โดยที่  $\hat{\boldsymbol{\Sigma}} = \frac{1}{T-k} \sum_{t=1}^T \hat{\mathbf{e}}_t \hat{\mathbf{e}}'_t$  และ  $\hat{\mathbf{e}}_t = \mathbf{Y}_t - \hat{\boldsymbol{\Phi}}' \mathbf{Z}_t$  เป็น residuals จากการประมาณค่า

### 5.3.2 การเลือกจำนวนความล่าที่เหมาะสม

การหาความล่าที่เหมาะสมของแบบจำลองเวกเตอร์ออโตรีเกรสซีฟอาจทำได้โดยใช้สูตรการเลือกความล่า โดยการประมาณค่าแบบจำลองเวกเตอร์ออโตรีเกรสซีฟที่มีความล่าเท่ากับ  $0, 1, \dots, p_{\max}$  แล้วเลือกค่า  $p$  ที่ทำให้ค่าที่ใช้เลือกมีค่าต่ำที่สุด โดยจะมีสูตรดังนี้

$$IC(p) = \ln |\tilde{\boldsymbol{\Sigma}}(p)| + c_T(n, p) \quad (5.7)$$

โดยที่  $\tilde{\boldsymbol{\Sigma}}(p) = T^{-1} \sum_{t=1}^T \hat{\mathbf{e}}_t \hat{\mathbf{e}}'_t$  คือ residual covariance matrix จาก  $\text{VAR}(p)$ ,  $c_T$  คือลำดับที่ขึ้นกับจำนวนตัวอย่าง และ  $c_T(n, p)$  คือฟังก์ชันเบี่ยงปรับ (penalty function) กรณีที่เราเลือก  $n$  และ  $p$  มากๆ โดยที่แบบเกณฑ์ที่เป็นที่นิยมสามเกณฑ์ได้แก่ Akaike (AIC) Schwarz-Bayesian (BIC) และ

Hannan-Quinn (HQIC) ซึ่งแสดงได้ด้วยสมการดังนี้

$$AIC(p) = \ln |\tilde{\Sigma}(p)| + \frac{2}{T}(pn^2)$$

$$BIC(p) = \ln |\tilde{\Sigma}(p)| + \frac{\ln T}{T}(pn^2)$$

$$HQIC(p) = \ln |\tilde{\Sigma}(p)| + \frac{2 \ln(\ln T)}{T}(pn^2)$$

### ตัวอย่าง 5.3: แบบจำลอง VAR สำหรับผลตอบแทนรายวันของ SET และ DOWJONES

ในตัวอย่างนี้เราจะพิจารณาความสัมพันธ์ระหว่างผลได้ตอบแทนรายวันจากการลงทุนในตลาดหลักทรัพย์แห่งประเทศไทย (1ret\_set) และตลาดหุ้นดาวโจนส์ (1ret\_dowjones) โดยใช้ข้อมูลระหว่างวันที่ 2 มกราคม 2540 ถึง 18 มกราคม 2556 (ข้อมูลจากธนาคารแห่งประเทศไทย โดยข้อมูลที่ตลาดใดตลาดหนึ่งปิดจะถูกกลบออกจากข้อมูล และข้อมูลดัชนีราคาของตลาดหุ้นทั้งสองอยู่ในไฟล์ set\_dj.csv)

เราสามารถนำเข้าข้อมูลและคำนวณผลได้ตอบแทนในรูปลอกลูกได้จากคำสั่งต่อไปนี้

```
1 > setdj<-read.csv(file="set_dj.csv", header=TRUE)
2 > head(setdj)
3 > set<-setdj$set
4 > 1ret_set<-diff(log(set))*100
5 > dowjones<-setdj$dowjones
6 > 1ret_dowjones<-diff(log(dowjones))*100
```

เราได้ข้อมูลสองชุดคือ 1ret\_set และ 1ret\_dowjones เราจะเขียนข้อมูลทั้งสองในรูปแบบของเมตริกซ์ที่นำเวกเตอร์ทั้งสองมาต่อกันโดยใช้คำสั่ง cbind

```
1 > 1ret<-cbind(1ret_set, 1ret_dowjones)
```

เราสามารถพิจารณาค่าสถิติเบื้องต้นได้จากคำสั่ง basicStats และ acf เหมือนกับที่เราเคยใช้ในหัวข้อก่อนได้

หากเราต้องการ ประมาณ ค่า ด้วย แบบ จำลอง เวก เทอร์ ออ โต รี เกร ส ซีฟ เรา จะ ใช้ library(vars) โดยที่เราอาจจะเริ่มจากการหาค่า  $p$  ที่เหมาะสมโดยการใช้คำสั่ง VAR พร้อมระบุเมตริกซ์ของข้อมูล 1ret จำนวนค่าล่าสูงสุด lag.max และ เกณฑ์ในการเลือกค่าล่า ic=c("AIC") โดยที่ "sc" จะแทน Schwarz-Bayesian (BIC) และ "HQ" Hannan-Quinn (HQIC)

```

1 > library(vars)
2 > msel=VAR(lret, lag.max=10, ic=c("AIC"))
3 > msel
4
5 VAR Estimation Results:
6 =====
7
8 Estimated coefficients for equation lret_set:
9 =====
10 Call:
11 lret_set = lret_set.l1 + lret_dowjones.l1 + lret_set.l2 + lret_dowjones.l2 +
    lret_set.l3 + lret_dowjones.l3 + lret_set.l4 + lret_dowjones.l4 + lret_set.l5
    + lret_dowjones.l5 + lret_set.l6 + lret_dowjones.l6 + lret_set.l7 +
    lret_dowjones.l7 + lret_set.l8 + lret_dowjones.l8 + lret_set.l9 +
    lret_dowjones.l9 + const
12
13      lret_set.l1 lret_dowjones.l1      lret_set.l2 lret_dowjones.l2
14      0.05556382      0.22898590     -0.33541086      0.32270310
15      lret_set.l3 lret_dowjones.l3      lret_set.l4 lret_dowjones.l4
16      0.01244410      0.21790099     -0.13694929      0.17900004
17      lret_set.l5 lret_dowjones.l5      lret_set.l6 lret_dowjones.l6
18     -0.01107252      0.04790222     -0.06473588      0.12631799
19      lret_set.l7 lret_dowjones.l7      lret_set.l8 lret_dowjones.l8
20      0.01517100      0.05964304     -0.02897568      0.02785310
21      lret_set.l9 lret_dowjones.l9      const
22      0.03837222      0.08783703     -0.00332124
23
24
25 Estimated coefficients for equation lret_dowjones:
26 =====
27 <Omitted>

```

จากเกณฑ์ AIC จะเห็นได้ว่าค่าที่เหมาะสมคือ  $p = 9$  ถ้าลองใช้เกณฑ์ SIC จะได้ค่าที่เหมาะสมเท่ากับ  $p = 4$  ดังนั้นเราจะเลือกใช้  $p = 4$  ในการสร้างแบบจำลอง model1

```

1  > msel2=VAR(lret, lag.max=10, ic=c("SC"))
2  <omitted>
3
4  > model1=VAR(lret, p=4)
5  > summary(model1)
6
7  VAR Estimation Results:
8  =====
9  Endogenous variables: lret_set, lret_dowjones
10 Deterministic variables: const
11 Sample size: 3803
12 Log Likelihood: -15650.859
13 Roots of the characteristic polynomial:
14  0.62  0.62  0.5867  0.5867  0.3557  0.3557  0.2886  0.2886
15 Call:
16 VAR(y = lret, p = 4)
17
18
19 Estimation results for equation lret_set:
20 =====
21 lret_set = lret_set.l1 + lret_dowjones.l1 + lret_set.l2 + lret_dowjones.l2 +
22           lret_set.l3 + lret_dowjones.l3 + lret_set.l4 + lret_dowjones.l4 + const
23
24           Estimate Std. Error t value Pr(>|t|)
25 lret_set.l1      0.059621   0.016288   3.660 0.000255 ***
26 lret_dowjones.l1 0.222804   0.032471   6.862 7.91e-12 ***
27 lret_set.l2     -0.320847   0.016256 -19.738 < 2e-16 ***
28 lret_dowjones.l2 0.313004   0.032696   9.573 < 2e-16 ***
29 lret_set.l3      0.023840   0.016122   1.479 0.139313
30 lret_dowjones.l3 0.205041   0.032958   6.221 5.47e-10 ***
31 lret_set.l4     -0.103471   0.016011  -6.462 1.16e-10 ***
32 lret_dowjones.l4 0.151876   0.032994   4.603 4.30e-06 ***
33 const           0.002529   0.043532   0.058 0.953684
34
35 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
36
37 Residual standard error: 2.683 on 3794 degrees of freedom
38 Multiple R-Squared:  0.1409, Adjusted R-squared:  0.1391
39 F-statistic: 77.78 on 8 and 3794 DF,  p-value: < 2.2e-16
40
41
42 Estimation results for equation lret_dowjones:
43 =====
44 <omitted>
45
46 Covariance matrix of residuals:
47           lret_set lret_dowjones
48 lret_set      7.199      -0.556
49 lret_dowjones -0.556      1.839
50
51 Correlation matrix of residuals:
52           lret_set lret_dowjones
53 lret_set      1.0000      -0.1528
54 lret_dowjones -0.1528      1.0000

```

จากผลการประมาณค่าเราสามารถเขียนสมการแสดงผลการประมาณค่าสำหรับสมการของ

log return ของ SET( $set_t$ ) ได้ดังนี้

$$set_t = 0.0025 + 0.0596set_{t-1} + 0.2228dj_{t-1} - 0.3208set_{t-2} + 0.313dj_{t-2} \\ 0.0238set_{t-3} + 0.205dj_{t-3} - 0.1035set_{t-4} + 0.1519dj_{t-4}$$

## 5.4 การพยากรณ์จากแบบจำลองเวกเตอร์ออโตรีเกรสซีฟ

เป้าหมายหลักประการหนึ่งของการพัฒนาแบบจำลองเวกเตอร์ออโตรีเกรสซีฟ ( $VAR(p)$ ) คือการพยากรณ์จากแบบจำลองดังกล่าวเช่นเดียวกับแบบจำลองออโตรีเกรสซีฟ ( $AR(p)$ ) หากเราพิจารณาแบบจำลองเวกเตอร์ออโตรีเกรสซีฟอันดับหนึ่ง ( $VAR(1)$ ) ซึ่งแสดงได้ด้วยสมการต่อไปนี้

$$\mathbf{Y}_t = \Phi \mathbf{Y}_{t-1} + \varepsilon_t$$

เราต้องการพยากรณ์ไปข้างหน้าหนึ่งคาบด้วยข้อมูลที่มี ณ เวลาที่  $h$  หรือพยากรณ์ค่า

$$\mathbf{Y}_{h+1} = \Phi \mathbf{Y}_h + \varepsilon_{h+1} \quad (5.8)$$

เราหาค่าพยากรณ์โดยการคำนวณค่าคาดหวังอย่างมีเงื่อนไข (conditional expectation) ด้วยข้อมูล  $h$ ,  $E_h(\mathbf{Y}_{h+1})$ , เราจะได้ค่าพยากรณ์เท่ากับ

$$\hat{\mathbf{Y}}_h(1) = E_h(\mathbf{Y}_{h+1}) = \Phi \mathbf{Y}_h + \underbrace{E_h(\varepsilon_{h+1})}_{=0} = \Phi \mathbf{Y}_h \quad (5.9)$$

และค่าคาดเคลื่อนของการพยากรณ์ (forecast error) ของการพยากรณ์ไปข้างหน้าหนึ่งคาบ,  $e(1)$ , จะเท่ากับ

$$e(1) = \mathbf{Y}_{h+1} - E_h(\mathbf{Y}_{h+1}) = \varepsilon_{h+1} \quad (5.10)$$

หากพิจารณากรณีตัวแปรสองตัวแปร  $\mathbf{Y}_t = [Y_{1t} \quad Y_{2t}]'$  เราจะพบว่า

$$\hat{Y}_{1,h}(1) = \phi_{11}Y_{1,h} + \phi_{12}Y_{2,h}$$

$$\hat{Y}_{2,h}(1) = \phi_{21}Y_{1,h} + \phi_{22}Y_{2,h}$$

$$e_1(1) = \varepsilon_{1,h+1}$$

$$e_2(1) = \varepsilon_{2,h+1}$$

ซึ่งแสดงให้เห็นว่าค่าพยากรณ์ของ  $Y_{1t}$  และ  $Y_{2t}$  ขึ้นอยู่กับตัวแปรทั้งสองในอดีต

สำหรับค่าพยากรณ์สองคาบข้างหน้าเมื่อเราพิจารณาค่าจริง ณ เวลาที่  $h+2$ ,  $Y_{h+2}$ , จะเท่ากับ

$$\mathbf{Y}_{h+2} = \Phi \mathbf{Y}_{h+1} + \varepsilon_{h+2} = \Phi(\Phi \mathbf{Y}_h + \varepsilon_{h+1}) + \varepsilon_{h+2} = \Phi^2 \mathbf{Y}_h + \Phi \varepsilon_{h+1} + \varepsilon_{h+2} \quad (5.11)$$

เราหาค่าพยากรณ์โดยการคำนวณค่าคาดหวังอย่างมีเงื่อนไขด้วยข้อมูล  $h$  เท่ากับ

$$\hat{Y}_h(2) = E_h(\mathbf{Y}_{h+2}) = \Phi^2 \mathbf{Y}_h + \underbrace{\Phi E_h(\boldsymbol{\varepsilon}_{h+1})}_{=0} + \underbrace{E_h(\boldsymbol{\varepsilon}_{h+2})}_{=0} = \Phi^2 \mathbf{Y}_h \quad (5.12)$$

และค่าคาดเคลื่อนของการพยากรณ์ (forecast error) ของการพยากรณ์ไปข้างหน้าสองคาบ,  $e(2)$  จะเท่ากับ

$$e(2) = \mathbf{Y}_{h+2} - E_h(\mathbf{Y}_{h+2}) = \Phi \boldsymbol{\varepsilon}_{h+1} + \boldsymbol{\varepsilon}_{h+2} \quad (5.13)$$

เมื่อเราพิจารณากรณีของตัวแปรสองตัวแปร เราจะเห็นได้ว่าค่าคาดเคลื่อนของการพยากรณ์ไปข้างหน้าสองคาบของแต่ละตัวแปรจะขึ้นอยู่กับข้อของตัวแปรทุกตัวในแบบจำลองดังที่แสดงในสมการต่อไปนี้

$$e_1(2) = \phi_{11}\varepsilon_{1,h+1} + \phi_{12}\varepsilon_{2,h+1} + \varepsilon_{1,h+2} \quad (5.14)$$

$$e_2(2) = \phi_{21}\varepsilon_{1,h+1} + \phi_{22}\varepsilon_{2,h+1} + \varepsilon_{2,h+2} \quad (5.15)$$

หากเราดำเนินการด้วยวิธีการเดิมไปเรื่อยๆ จะได้ค่าพยากรณ์ไปข้างหน้า  $l$  คาบ ( $\mathbf{Y}_{h+l}$ ) ด้วยข้อมูลที่มี ณ คาบที่  $h$  เท่ากับ

$$\hat{Y}_h(l) = E_h(\mathbf{Y}_{h+l}) = \Phi^l \mathbf{Y}_h \quad (5.16)$$

ในขณะที่ค่าคาดเคลื่อนของการพยากรณ์ไปข้างหน้า  $l$  คาบจะเท่ากับ

$$e(l) = \Phi^{l-1}\boldsymbol{\varepsilon}_{h+1} + \Phi^{l-2}\boldsymbol{\varepsilon}_{h+2} + \Phi^{l-3}\boldsymbol{\varepsilon}_{h+3} + \dots + \boldsymbol{\varepsilon}_{h+l} \quad (5.17)$$

จากสมการ (??) เราจะเห็นได้ว่าแบบจำลอง VAR สามารถนำมาใช้ในการสร้างค่าพยากรณ์ตัวแปรต่างๆ ได้ง่าย และใช้เพียงแค่ตัวแปร ณ เวลาที่  $h$  หรือก่อนหน้า  $h$

นอกจากนี้หากเราต้องพยากรณ์แบบช่วง เราสามารถแสดงช่วงความเชื่อมั่น  $(1 - \alpha)\%$  ของการพยากรณ์ได้ด้วย

$$\hat{Y}_{i,h}(l) \pm z_{\alpha/2} \sqrt{\text{Var}(e_i(l))}$$

โดยที่  $z$  คือค่าวิกฤตจากการแจกแจงแบบปกติ และ  $e_i(l)$  คือค่าคาดเคลื่อนการพยากรณ์ของตัวแปร  $i$

ในกรณีของแบบจำลองเวกเตอร์ออโตรีเกรสซีฟในรูปแบบโครงสร้าง (structural form VAR) เราสามารถสร้างค่าพยากรณ์ได้ด้วยวิธีการเดียวกัน ยกตัวอย่างเช่น แบบจำลองเวกเตอร์ออโตรีเกรสซีฟในรูปแบบโครงสร้างอันดับหนึ่งที่มีตัวแปรสองตัวแปร และอธิบายความสัมพันธ์ด้วยสมการดังต่อไปนี้

$$\begin{bmatrix} 1 & 0 \\ l_{21} & 1 \end{bmatrix} \begin{bmatrix} Y_{1t} \\ Y_{2t} \end{bmatrix} = \begin{bmatrix} \phi_{11}^* & \phi_{12}^* \\ \phi_{21}^* & \phi_{22}^* \end{bmatrix} \begin{bmatrix} Y_{1,t-1} \\ Y_{2,t-1} \end{bmatrix} + \begin{bmatrix} \eta_{1t} \\ \eta_{2t} \end{bmatrix} \quad (5.18)$$

ค่าพยากรณ์  $Y_{1t}$  ไปข้างหน้าหนึ่งคาบเท่ากับ

$$E_h(Y_{1,h+1}) = \phi_{11}^* Y_{1,h} + \phi_{12}^* Y_{2,h}$$

และค่าคลาดเคลื่อนของการพยากรณ์  $Y_{1t}$  ไปข้างหน้าหนึ่งคาบ,  $e_1(1)$ , เท่ากับ

$$e_1(1) = Y_{1,h+1} - E_h(Y_{1,h+1}) = \eta_{1,h+1}$$

ในขณะที่ค่าพยากรณ์  $Y_{2t}$  ไปข้างหน้าหนึ่งคาบเท่ากับ

$$E_h(Y_{2,h+1}) = -l_{21}E_h(Y_{1,h+1}) + \phi_{21}^* Y_{1,h} + \phi_{22}^* Y_{2,h}$$

และค่าคลาดเคลื่อนของการพยากรณ์  $Y_{2t}$  ไปข้างหน้าหนึ่งคาบ,  $e_2(1)$ , เท่ากับ

$$\begin{aligned} e_2(1) &= Y_{2,h+1} - E_h(Y_{2,h+1}) = -l_{21}(Y_{1,h+1} - E_h(Y_{1,h+1})) + \eta_{2,h+1} \\ &= -l_{21}\eta_{1,h+1} + \eta_{2,h+1} \end{aligned} \quad (5.19)$$

## ตัวอย่างที่ 5.4: การพยากรณ์จากแบบจำลอง VAR

เราสามารถทำนายผลได้ตอบแทน ไปข้างหน้าของทั้งสองตลาดที่เราสนใจ ได้ด้วยคำสั่ง predict โดยระบุแบบจำลองที่ใช้และคาบที่ทำนายไปข้างหน้า

```
1 > model1.predict=predict(model1, n.ahead=5)
2 > model1.predict
3 $lret_set
4      fcst      lower      upper      CI
5 [1,] 0.23354446 -5.025286 5.492375 5.258830
6 [2,] -0.01504318 -5.311043 5.280957 5.296000
7 [3,] 0.08053962 -5.572718 5.733797 5.653258
8 [4,] -0.02118987 -5.682718 5.640339 5.661528
9 [5,] -0.04475454 -5.707153 5.617644 5.662399
10
11 $lret_dowjones
12      fcst      lower      upper      CI
13 [1,] -0.046835523 -2.705029 2.611358 2.658193
14 [2,] 0.023569365 -2.639844 2.686983 2.663413
15 [3,] 0.005536266 -2.686514 2.697586 2.692050
16 [4,] 0.021958580 -2.670142 2.714059 2.692101
17 [5,] 0.031192947 -2.661288 2.723674 2.692481
```

เราจะได้ผลการพยากรณ์ดังแสดงได้ด้วยตารางดังต่อไปนี้

คาบไปข้างหน้า	1	2	3	4	5
log return ของ SET	0.233	-0.015	0.081	-0.021	-0.044
log return ของ Dow Jones	-0.467	0.024	0.006	0.022	0.031



## 5.5 การวิเคราะห์หลังจากการประมาณค่าแบบจำลองเวกเตอร์ออโตรีเกรสซีฟ

แบบจำลองเวกเตอร์ออโตรีเกรสซีฟโดยทั่วไปแล้วจะมีพารามิเตอร์จำนวนมากและอาจมีความยุ่งยากในการพิจารณาเนื่องจากความขึ้นอยู่กับกันอันจะส่งผลไปมาระหว่างตัวแปร ดังนั้นในการอธิบายความสัมพันธ์ระหว่างตัวแปรจะต้องมีการวิเคราะห์เพิ่มเติมไม่สามารถดูความสัมพันธ์ได้จากแบบจำลองเลขเช่นเดียวกับแบบจำลองอนุกรมเวลาอย่างง่าย

### 5.5.1 Granger Causality

โครงสร้างของแบบจำลอง VAR ช่วยให้ข้อมูลกับเราว่าตัวแปรหรือกลุ่มของตัวแปรมีความสามารถในการทำนายตัวแปรอื่นหรือไม่ โดยแนวคิดเกี่ยวกับความสามารถในการทำนายถูกนำเสนอโดย Granger (1969) ว่า ถ้าตัวแปร  $y_1$  ช่วยในการทำนายตัวแปรอื่น  $y_2$  เราจะเรียกว่า  $y_1$  แกรงเจอร์คอส (Granger-cause)  $y_2$  แต่ถ้า  $y_1$  ไม่ช่วยในการทำนายตัวแปร  $y_2$  เราจะพูดว่า  $y_1$  ไม่แกรงเจอร์คอส (does not Granger-cause)  $y_2$

นิยามอย่างเป็นทางการคือ หาก  $y_1$  ไม่แกรงเจอร์คอส (does not Granger-cause)  $y_2$  แสดงว่าทุกค่าของ  $s > 0$  ค่า MSE ของการพยากรณ์  $y_{2,t+s}$  ด้วยข้อมูลจาก  $(y_{2,t}, y_{2,t-1}, \dots)$  ไม่มีความแตกต่างจาก ค่า MSE ของการพยากรณ์  $y_{2,t+s}$  ด้วยข้อมูลจาก  $(y_{2,t}, y_{2,t-1}, \dots)$  และ  $(y_{1,t}, y_{1,t-1}, \dots)$  เราจะต้องระลึกไว้อยู่เสมอว่าแกรงเจอร์คอสเป็นการอนุมานไปยังความสามารถในการพยากรณ์เท่านั้น ไม่ได้เป็นความเป็นเหตุเป็นผลจริงๆของตัวแปร

#### ตัวอย่างกรณีตัวแปรสองตัว

ในหัวข้อนี้เราพิจารณาแบบจำลอง  $VAR(2)$  ที่มีตัวแปรสองตัว ซึ่งสามารถเขียนเป็นสมการได้ดังนี้

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} + \begin{pmatrix} \phi_{11}^1 & \phi_{12}^1 \\ \phi_{21}^1 & \phi_{22}^1 \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \phi_{11}^2 & \phi_{12}^2 \\ \phi_{21}^2 & \phi_{22}^2 \end{pmatrix} \begin{pmatrix} y_{1t-2} \\ y_{2t-2} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad (5.20)$$

ในสมการที่ (??) หาก  $y_{2t}$  ไม่แกรงเจอร์คอส  $y_{1t}$  ค่าสัมประสิทธิ์  $\phi_{12}^1$  และ  $\phi_{12}^2$  จะมีค่าเท่ากับศูนย์ในทางตรงข้าม ถ้า  $y_{1t}$  ไม่แกรงเจอร์คอส  $y_{2t}$  ค่าสัมประสิทธิ์  $\phi_{21}^1$  และ  $\phi_{21}^2$  จะมีค่าเท่ากับศูนย์

ดังนั้นในการทดสอบว่า  $y_{2t}$  แกรงเจอร์คอส  $y_{1t}$  หรือไม่ เราจะตั้งสมมุติฐานหลักว่า  $H_0 : \phi_{12}^1 = \phi_{12}^2 = 0$  และสมมุติฐานทางเลือกคือมีสัมประสิทธิ์  $\phi_{12}^1$  หรือ  $\phi_{12}^2$  ตัวใดตัวหนึ่งมีค่าไม่เท่ากับศูนย์ ซึ่งการทดสอบดังกล่าวคือการทดสอบหลายเงื่อนไขหรือการทดสอบเอฟ(F-test) นั่นเอง

## ตัวอย่าง 5.5 การทดสอบ Granger Causality จากแบบจำลอง VAR

ต่อเนื่องจากตัวอย่าง 5.3 เราต้องการทดสอบว่า  $lret\_dowjones$  แกรงเจอร์คอส  $lret\_set$  หรือไม่ (สมมุติฐานหลักคือ  $lret\_dowjones$  ไม่แกรงเจอร์คอส  $lret\_set$ ) เราสามารถทดสอบโดยใช้คำสั่ง `causality` โดยที่เราจะต้องระบุแบบจำลองที่ใช้และตัวแปรที่เป็นสาเหตุ (cause) ซึ่งในที่นี้คือ `lret\_dowjones`

```
1 > causality(model1, cause="lret_dowjones")
2 $Granger
3   Granger causality H0: lret_dowjones do not Granger-cause lret_set
4 data:  VAR object model1
5 F-Test = 43.5947, df1 = 4, df2 = 7588, p-value < 2.2e-16
6
7 $Instant
8   H0: No instantaneous causality between: lret_dowjones and lret_set
9 data:  VAR object model1
10 Chi-squared = 86.7677, df = 1, p-value < 2.2e-16
```

จากบรรทัดที่ 2-5 เป็นผลการทดสอบแกรงเจอร์คอส โดยที่ค่าสถิติ F ที่ได้คือ 43 หรือมีค่าที่เท่ากับ  $< 2.2 \times 10^{-16}$  ดังนั้นเราสามารถปฏิเสธสมมุติฐานหลักได้ด้วยระดับนัยสำคัญ 5 % (หรือค่าใดๆที่มากกว่า  $2.2 \times 10^{-16}$ ) เราสรุปได้ว่า  $lret\_dowjones$  แกรงเจอร์คอส  $lret\_set$  หรือการทราบผลตอบแทนของตลาดหุ้นดาวโจนส์ช่วยในการพยากรณ์ผลตอบแทนในตลาดหุ้นไทย

นอกจากนี้ บรรทัด ที่ 7-10 ได้ ทดสอบ ความ สัมพันธ์ ใน ระหว่าง ช่วง เวลา เดียวกัน (instantaneous causality)

### 5.5.2 ฟังก์ชันตอบสนองแรงกระตุ้น

การ ทดสอบ สมมุติฐาน สำหรับ กลุ่ม สัมประสิทธิ์ (การ ทดสอบ ด้วย ตัว สถิติ F) หรือ การ ทดสอบ แกรงเจอร์คอส ช่วย ระบุ ว่า ตัวแปร ใดๆ มี ผลกระทบ อย่าง มี นัย สำคัญ ต่อ ตัวแปร อื่น หรือ ไม่ อย่างไร ก็ ตาม การ ทดสอบ ดัง กล่าว ไม่ ได้ บอก ทิศทาง ของ ความ สัมพันธ์ และ ระยะเวลา ที่ การ เปลี่ยนแปลง ของ ตัวแปร หนึ่ง จะ ส่งผล ต่อ อีก ตัวแปร ว่า จะ มี ผล ยาวนาน แค่ ไหน โดย ที่ เครื่องมือ ที่ จะ ใช้ ศึกษา ความ สัมพันธ์ ดัง กล่าว คือ ฟังก์ชัน ตอบสนอง แรงกระตุ้น (impulse response function) โดย ที่ นิยาม คือ การ ตอบสนอง ของ ตัวแปร ตาม อันเนื่อง มา จาก การ เปลี่ยนแปลง ของ ตัวแปร อีก ตัวหนึ่ง โดย ที่ หาก เกิด การ เปลี่ยนแปลง ใน ข้อ ก หนึ่ง หน่วย จะ ส่งผล อย่างไร ต่อ แต่ละ ตัวแปร ใน คาบ ที่ ต่อ จาก การ เปลี่ยนแปลง นั้นๆ (เนื่องจาก บางกรณี ขนาด ของ ตัวแปร ที่ เรา สนใจ อาจ จะมี หน่วย ที่ ต่าง กัน มาก เรา อาจ จะ ใช้ การ เปลี่ยนแปลง หนึ่ง s.d.)

ตัวอย่าง เช่น หาก เรา พิจารณา แบบจำลอง  $VAR(1)$  ที่ มี ตัวแปร สอง ตัวแปร ซึ่ง สามารถ แสดง ได้ ด้วย สมการ

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad (5.21)$$

สมมุติว่า เรา พิจารณา ว่า ใน ปี ที่ 0 เกิด ข้อ ก ใน ตัวแปร  $y_{1t}$  หนึ่ง หน่วย ( $\varepsilon_{10} = 1$ ) และ ข้อ ก ใน ตัวแปร

$y_{2t}$  เท่ากับศูนย์ และช็อกในปีอื่นๆเท่ากับศูนย์ สมมติให้  $y_{1t}$  และ  $y_{2t}$  เท่ากับศูนย์ในปีก่อนหน้าปี 0 จะได้ว่า

$$\begin{aligned} Y_0 &= \begin{pmatrix} \varepsilon_{10} \\ \varepsilon_{20} \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \\ Y_1 &= \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} Y_0 = \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.5 \\ 0 \end{pmatrix} \\ Y_2 &= \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} Y_1 = \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} \begin{pmatrix} 0.25 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.125 \\ 0 \end{pmatrix} \\ &\vdots \end{aligned}$$

หรือในหากเราพิจารณาเกิดช็อกในตัวแปร  $y_{2t}$  หนึ่งหน่วย ( $\varepsilon_{20} = 1$ ) และช็อกในตัวแปร  $y_{1t}$  เท่ากับศูนย์ และช็อกในปีอื่นๆเท่ากับศูนย์ สมมติให้  $y_{1t}$  และ  $y_{2t}$  เท่ากับศูนย์ในปีก่อนหน้าปี 0 จะได้ว่า

$$\begin{aligned} Y_0 &= \begin{pmatrix} \varepsilon_{10} \\ \varepsilon_{20} \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \\ Y_1 &= \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} Y_0 = \begin{pmatrix} 0.5 & 0.3 \\ 0.0 & 0.2 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0.3 \\ 0.2 \end{pmatrix} \\ &\vdots \end{aligned}$$

ฟังก์ชันตอบสนองแรงกระตุ้นในกรณีทั่วไป

ในกรณี  $VAR(p)$  ที่เป็นกระบวนการนิ่งใดๆ จะสามารถแสดงในรูป Wold ดังนี้

$$Y_t = \mu + \varepsilon_t + \Psi_1 \varepsilon_{t-1} + \Psi_2 \varepsilon_{t-2} + \dots \quad (5.22)$$

โดยที่  $\Psi_i$  คือ  $n \times n$  เมทริกซ์ของสัมประสิทธิ์ moving average โดยที่ค่าสัมประสิทธิ์ดังกล่าวสามารถคำนวณได้จาก

$$(I - \Phi_1 L - \dots - \Phi_p L^p)(I + \Psi_1 L + \Psi_2 L^2 + \dots) = I$$

จากสมการ (??) เราอาจต้องการที่จะอธิบาย  $\phi_{ij}^s$  ว่าเป็นการเปลี่ยนแปลงของ

$$\frac{\partial y_{i,t+s}}{\partial \varepsilon_{j,t}} = \frac{\partial y_{i,t}}{\partial \varepsilon_{j,t-s}} = \psi_{i,j}^s$$

อย่างไรก็ตามคำอธิบายข้างต้นจะเป็นจริงหากเมทริกซ์ความแปรปรวนและความแปรปรวนร่วม  $var(\varepsilon) = \Sigma$  เป็นเมทริกซ์ทแยงมุม หรือไม่มีความสัมพันธ์  $\varepsilon_t$  ในคาบเดียวกัน

Sims (1980) เสนอให้ประมาณค่าด้วยแบบจำลอง triangular structural  $VAR(p)$

$$\begin{aligned} y_{1t} &= c_1 + \gamma'_{11} \mathbf{Y}_{t-1} + \dots + \gamma'_{1p} \mathbf{Y}_{t-p} + \eta_{1t} \\ y_{2t} &= c_2 + \beta_{21} y_{1t} + \gamma'_{21} \mathbf{Y}_{t-1} + \dots + \gamma'_{2p} \mathbf{Y}_{t-p} + \eta_{2t} \\ y_{3t} &= c_3 + \beta_{31} y_{1t} + \beta_{32} y_{2t} + \gamma'_{31} \mathbf{Y}_{t-1} + \dots + \gamma'_{3p} \mathbf{Y}_{t-p} + \eta_{3t} \\ &\vdots \\ y_{nt} &= c_n + \beta_{n1} y_{1t} + \dots + \beta_{n,n-1} y_{n-1,t} + \gamma'_{n1} \mathbf{Y}_{t-1} + \dots + \gamma'_{np} \mathbf{Y}_{t-p} + \eta_{nt} \end{aligned} \quad (5.23)$$

เราสามารถเขียนความสัมพันธ์ดังกล่าวในรูปของเมทริกซ์ดังนี้

$$\mathbf{B}\mathbf{Y}_t = \mathbf{c} + \mathbf{\Gamma}_1 \mathbf{Y}_{t-1} + \dots + \mathbf{\Gamma}_p \mathbf{Y}_{t-p} + \boldsymbol{\eta}_t \quad (5.24)$$

โดยที่

$$\mathbf{B} = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ -\beta_{21} & 1 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ -\beta_{n1} & -\beta_{n2} & -\beta_{n3} & \dots & 1 \end{pmatrix}$$

โดยที่ Orthogonal error ( $\eta_t$ ) หรือ error ที่ไม่มีความสัมพันธ์ระหว่างกัน ซึ่งก็คือ structural errors

โครงสร้างแบบจำลองโครงสร้าง (structural model) อย่างในสมการ (??) จะกำหนดให้ความสัมพันธ์ของตัวแปรมีลำดับคือ  $y_1$  เป็นตัวกำหนด  $y_2$  และ  $y_2$  เป็นตัวกำหนด  $y_3$  เป็นลำดับไปเรื่อยๆ

$$y_1 \longrightarrow y_2 \longrightarrow y_3 \longrightarrow \dots \longrightarrow y_n$$

แสดงว่าค่าของตัวแปรด้านซ้ายจะกระทบตัวแปรด้านขวาในคาบเดียวกัน (contemporaneous) แต่ตัวแปรด้านขวาจะต้องใช้เวลาหนึ่งคาบถึงจะกระทบกลับมายังตัวแปรด้านซ้าย โดยที่ผลกระทบในคาบเดียวกันจะสะท้อนผ่านตัวแปร  $\beta_{ij}$  โดยที่ลำดับของการเรียงตัวแปรในแบบจำลอง  $VAR(p)$  ตามสมการที่ (??) จะขึ้นอยู่กับทฤษฎีเป็นตัวกำหนด

หลังจากที่เราได้จัดเรียงตัวแปรแล้ว Wold representation ของ  $\mathbf{Y}_t$  จากค่าช็อกเชิงตั้งฉาก (orthogonal errors) ได้เป็น

$$\mathbf{Y}_t = \boldsymbol{\mu} + \boldsymbol{\Theta}_0 \boldsymbol{\eta}_t + \boldsymbol{\Theta}_1 \boldsymbol{\eta}_{t-1} + \boldsymbol{\Theta}_2 \boldsymbol{\eta}_{t-2} + \dots \quad (5.25)$$

โดยที่  $\boldsymbol{\Theta}_0 = \mathbf{B}^{-1}$  และการตอบสนองแรงกระตุ้นจากช็อกเชิงตั้งฉาก  $\eta_{jt}$  จะเท่ากับ

$$\frac{\partial y_{i,t+s}}{\partial \eta_{j,t}} = \frac{\partial y_{i,t}}{\partial \eta_{j,t-s}} = \theta_{ij}^s, \quad i, j = 1, \dots, n; s > 0 \quad (5.26)$$

โดยที่  $\theta_{ij}^s$  คือ ตำแหน่ง  $(i, j)$  ของเมทริกซ์  $\boldsymbol{\Theta}_s$  เราเรียกแผนภาพที่วาด  $\theta_{ij}^s$  ในแกนตั้งและ  $s$  ในแกน

นอนว่า ฟังก์ชันตอบสนองแรงกระตุ้นเชิงตั้งฉาก (orthogonal impulse response function) ของ  $y_i$  จากช็อก  $\eta_j$

ในทางปฏิบัติเราสามารถคำนวณ ฟังก์ชันตอบสนองแรงกระตุ้นเชิงตั้งฉากจากผลการประมาณค่า reduced VAR ในสมการ ?? ได้ด้วยการแยกส่วนประกอบ(decompose)ของ เมทริกซ์ค่าความแปรปรวนร่วมของ residuals  $\Sigma$  ด้วย Cholesky decomposition ดังนี้  $\Sigma = LGL'$  และ  $\eta_t = L^{-1}\varepsilon_t$  จากความสัมพันธ์ดังกล่าวเราสามารถเขียน Wold representation ในสมการ ?? ใหม่ได้เป็น

$$\begin{aligned} Y_t &= \mu + LL^{-1}\varepsilon_t + \Psi_1 LL^{-1}\varepsilon_{t-1} + \Psi_2 LL^{-1}Y_{t-2} + \dots \\ &= \mu + \Theta_0\eta_t + \Theta_1\eta_{t-1} + \Theta_2\eta_{t-2} + \dots \end{aligned} \quad (5.27)$$

โดยที่  $\Theta_j = \Psi_j L$  โดยที่เมทริกซ์  $B$  ในสมการ ?? คือ  $L^{-1}$  นั่นเอง

### ตัวอย่างที่ 5.6: การสร้าง Impulse Response Function จากแบบจำลอง VAR

ต่อเนื่องจากตัวอย่าง โดยเราจะสร้าง Impulse response function ด้วยคำสั่ง `irf` โดยที่ default ในคำสั่งนี้คือการสร้าง orthogonal impulse response function (ortho=TRUE) โดยในคำสั่งนี้เราจะระบุแบบจำลองที่ใช้และคาบที่เราดูผลหลังจากที่เรา shock 1 s.d. โดยที่การเรียงตัวแปรใน `lret` ที่เรียง `lret_set` ก่อน `lret_dowjones` หมายความว่าเราสมมุติให้ structural shock ของ `lret_dowjones` ไม่มีผลทันที(contemporaneous)ต่อ `lret_set` แต่ structural shock ของ `lret_set` มีผลทันที(contemporaneous)ต่อ `lret_dowjones` [ข้อสมมุตินี้อาจจะไม่สมเหตุสมผลนัก ผู้อ่านอาจจะลองสร้างเมทริกซ์ใหม่ `lret2 <- cbind(lret_dowjones, lret_set)` แล้วประมาณค่าและหา IRF ใหม่]

```

1 > model1.irf=irf(model1, n.ahead=10)
2 > model1.irf
3 Impulse response coefficients
4 $lret_set
5      lret_set lret_dowjones
6 [1,]  2.6831259181 -0.2072364167
7 [2,]  0.1137971489  0.0030468719
8 [3,] -0.9182763350  0.1667746830
9 <omitted>
10 [11,] 0.0030760182 -0.0002311969
11 $lret_dowjones
12      lret_set lret_dowjones
13 [1,]  0.0000000000  1.3403194745
14 [2,]  0.2986284632 -0.0849824924
15 [3,]  0.4183950540 -0.1100409438
16 <omitted>
17 [11,] 0.0006173344 -0.0002757296
18
19
20 Lower Band, CI= 0.95
21 <omitted>
22
23 > plot(model1.irf)

```

บรรทัดที่ 4-10 เป็นผลจากการเปลี่ยนแปลงใน structural shock ของ  $lret\_set$  หนึ่ง s.d. (=2.683) ในคาบที่ศูนย์ (ในที่นี้แทนด้วยบรรทัดที่ [1,]) ทำให้  $lret\_dowjones$  เปลี่ยนแปลงทันที -0.207 และส่งผลต่อ  $lret\_set$  และ  $lret\_dowjones$  ในคาบที่ 1 (หลังจาก shock) เท่ากับ 0.114 และ 0.003 ตามลำดับ (ในที่นี้แทนด้วยบรรทัดที่ [2,])

ส่วนบรรทัดที่ 11-16 เป็นผลจากการเปลี่ยนแปลงใน structural shock ของ  $lret\_dowjones$  หนึ่ง s.d.(=1.34) ในคาบที่ศูนย์ (ในที่นี้แทนด้วยบรรทัดที่ [1,]) ไม่ทำให้  $lret\_set$  เปลี่ยนแปลงในคาบที่เกิดช็อก แต่ส่งผลในคาบต่อไป

นอกจากนี้คำสั่งดังกล่าวยังให้ช่วงความเชื่อมั่น 95% และเราสามารถสร้างกราฟ IRF ได้ด้วยคำสั่ง `plot(model1.irf)`

### 5.5.3 การแยกความแปรปรวนของค่าคาดเคลื่อนการพยากรณ์

จากหัวข้อการพยากรณ์จากแบบจำลองเวกเตอร์ออโตรีเกรสซีฟ เราจะเห็นได้ว่าค่าพยากรณ์ของตัวแปรแต่ละตัวแปรนั้นขึ้นอยู่กับทั้งตัวแปรนั้นๆ และตัวแปรอื่นๆ ในแบบจำลอง ดังนั้น แนวทางอีกประการในการอธิบายผลจากแบบจำลองเวกเตอร์ออโตรีเกรสซีฟ คือการแยกส่วนประกอบของค่าคาดเคลื่อนของการพยากรณ์ (Forecast Error Variance Decomposition) ว่ามีที่มาจากตัวแปรแต่ละตัวมากน้อยแค่ไหน

ยกตัวอย่าง แบบจำลอง  $VAR(1)$  ที่มีตัวแปรสองตัว เราพบว่าการพยากรณ์  $Y_{1t}$  ไปข้างหน้าหนึ่งคาบมีค่าคาดเคลื่อนจากการพยากรณ์ (forecast error) ตามสมการที่ (??) เท่ากับ

$$e_1(1) = \varepsilon_{1,h+1}$$

ซึ่งค่าคลาดเคลื่อนเกิดจากข้อผิดพลาดในตัวแปร  $Y_{1t}$  เพียงอย่างเดียว และมีค่าความแปรปรวนของค่าความคลาดเคลื่อนจากการพยากรณ์ไปข้างหน้าหนึ่งคาบ (one-period forecast error variance) เท่ากับ

$$\text{Var}(e_1(1)) = \text{Var}(\varepsilon_{1,h+1}) = \sigma_1^2$$

ในขณะที่การพยากรณ์  $Y_{1t}$  ไปข้างหน้าสองคาบมีค่าคลาดเคลื่อนจากการพยากรณ์ตามสมการที่ ?? เท่ากับ

$$e_1(2) = \phi_{11}\varepsilon_{1,h+1} + \phi_{12}\varepsilon_{2,h+1} + \varepsilon_{1,h+2}$$

ซึ่งค่าคลาดเคลื่อนเกิดจากข้อผิดพลาดของตัวแปร  $Y_{1t}$  และตัวแปร  $Y_{2t}$  เราสามารถคำนวณหาค่าความแปรปรวนของค่าความคลาดเคลื่อนจากการพยากรณ์ไปข้างหน้าสองคาบได้ดังสมการต่อไปนี้

$$\begin{aligned} \text{Var}(e_1(2)) &= \text{Var}(\phi_{11}\varepsilon_{1,h+1}) + \text{Var}(\phi_{12}\varepsilon_{2,h+1}) + \text{Var}(\varepsilon_{1,h+2}) \\ &= \phi_{11}^2\sigma_1^2 + \phi_{12}^2\sigma_2^2 + \sigma_1^2 \end{aligned} \quad (5.28)$$

$$= (1 + \phi_{11}^2)\sigma_1^2 + \phi_{12}^2\sigma_2^2 \quad (5.29)$$

และสามารถแยกส่วนประกอบของค่าความแปรปรวนของค่าความคลาดเคลื่อนจากการพยากรณ์ไปข้างหน้าสองคาบว่ามาจาก  $Y_{1t}$  เท่ากับ

$$\frac{(1 + \phi_{11}^2)\sigma_1^2}{(1 + \phi_{11}^2)\sigma_1^2 + \phi_{12}^2\sigma_2^2}$$

และมาจาก  $Y_{2t}$  เท่ากับ

$$\frac{\sigma_2^2}{(1 + \phi_{11}^2)\sigma_1^2 + \phi_{12}^2\sigma_2^2}$$

เราสามารถอธิบายได้ว่าตัวแปรแต่ละตัวมีอิทธิพลต่อค่าความแปรปรวนการพยากรณ์ตัวแปรที่เราสนใจมากน้อยแค่ไหน

## ตัวอย่างที่ 5.7 การหา Variance Decomposition

ต่อเนื่องจากตัวอย่าง 5.3 เราสามารถแยกความแปรปรวนของค่าผิดพลาดจากการพยากรณ์ได้ด้วยคำสั่ง fevd

```
1 > fevd(model1, n.ahead = 5)
2 $lret_set
3   lret_set lret_dowjones
4 [1,] 1.0000000 0.0000000
5 [2,] 0.9877859 0.01221413
6 [3,] 0.9682396 0.03176043
7 [4,] 0.9655329 0.03446710
8 [5,] 0.9654222 0.03457779
9
10 $lret_dowjones
11   lret_set lret_dowjones
12 [1,] 0.02334830 0.9766517
13 [2,] 0.02326189 0.9767381
14 [3,] 0.03751278 0.9624872
15 [4,] 0.03751192 0.9624881
16 [5,] 0.03750568 0.9624943
```

บรรทัด ที่ 4-8 แสดง การ แยก ความ แปรปรวน ของ ค่า คลาด เคลื่อน ของ การ พยากรณ์ `lret_set` ไป 1 ถึง 5 คาบ ยกตัวอย่างเช่น การพยากรณ์ไปข้างหน้า 5 คาบ ความแปรปรวนของค่าพยากรณ์เกิดจาก `lret_set` เอง 96.56 % และเกิดจาก `lret_dowjones` 3.46 %



## บทที่ 6

### โคอินทิเกรชัน (Cointegration)

ข้อมูลที่เหมาะสมกับการวิเคราะห์หาคออินทิเกรชันสำหรับอนุกรมเวลาและแบบจำลองเวกเตอร์ออโตรีเกรสซีฟจะต้องเป็นข้อมูลที่นิ่ง ( $I(0)$ ) เช่น อัตราผลได้ตอบแทนของสินทรัพย์หรืออัตราการเติบโตของตัวแปรเศรษฐกิจมหภาค อย่างไรก็ตาม ในการพิจารณาความสัมพันธ์ตามทฤษฎีเศรษฐศาสตร์บางครั้งเราจำเป็นต้องพิจารณาข้อมูลที่มีได้มีการปรับรูปแบบซึ่งมักจะเป็น  $I(1)$

#### 6.1 สมการความสัมพันธ์เทียม (spurious regression)

ในการวิเคราะห์หาคออินทิเกรชันสำหรับข้อมูลอนุกรมเวลา ตัวแปรที่เราใช้ในการวิเคราะห์จำเป็นต้องเป็น  $I(0)$  เพื่อที่จะทำให้การทดสอบเชิงสถิติมีความเหมาะสม หากตัวแปรในแบบจำลองบางตัวหรือทั้งหมดเป็น  $I(1)$  การทดสอบสถิติอาจจะไม่ถูกต้อง ตัวอย่างเช่น ในกรณีที่ตัวแปรทั้งหมดเป็น  $I(1)$  และไม่ได้โคอินทิเกรตกัน ตัวทดสอบที่ได้จากแบบจำลองจะไม่เหมาะสม เราจะพบความสัมพันธ์ระหว่างตัวแปรต่างๆที่จริงๆแล้วตัวแปรทั้งหลายไม่มีความสัมพันธ์กัน หรือเราเรียกสมการความสัมพันธ์เทียม (spurious regression)

##### ตัวอย่างที่ 6.1

หากเราพิจารณาอนุกรมเวลาสองกระบวนการที่เป็น  $I(1)$  และเป็นอิสระต่อกัน เราสามารถแสดงความสัมพันธ์ของแต่ละตัวแปรได้ดังนี้

$$y_{1t} = y_{1,t-1} + \varepsilon_{1t} \quad \varepsilon_{1t} \sim WN(0, 1)$$

$$y_{2t} = y_{2,t-1} + \varepsilon_{2t} \quad \varepsilon_{2t} \sim WN(0, 1)$$

โดยที่  $Cov(\varepsilon_{1t}, \varepsilon_{2t}) = 0$  ซึ่งแสดงว่าทั้งสองอนุกรมเวลาเป็นอิสระต่อกัน เราสามารถใช้โปรแกรม R สร้างตัวแปรทั้งสองด้วยคำสั่งต่อไปนี้

```

1 > set.seed(123456)
2 > e1<-rnorm(1000)
3 > e2<-rnorm(1000)
4 > y1<-cumsum(e1)
5 > y2<-cumsum(e2)

```

แผนภาพของอนุกรมเวลาทั้งสองสามารถแสดงได้ดังรูปที่ ??

เมื่อนำอนุกรมเวลาทั้งสองมาพิจารณาความสัมพันธ์เชิงถดถอย  $y_{1t} = \alpha + \beta y_{2t} + u_t$  จะพบว่า  $\hat{\beta}$  มีค่าเท่ากับ 0.16 และแตกต่างจากศูนย์อย่างมีนัยสำคัญ ( $t_{\hat{\beta}} = 5.6$ )

```

1 > summary(lm(y1~y2))
2 Call:
3 lm(formula = y1 ~ y2)
4
5 Coefficients:
6             Estimate Std. Error t value Pr(>|t|)
7 (Intercept) 11.43603    0.31329  36.503  < 2e-16 ***
8 y2           0.16237    0.02885   5.628 2.36e-08 ***
9
10 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
11
12 Residual standard error: 9.905 on 998 degrees of freedom
13 Multiple R-squared:  0.03077, Adjusted R-squared:  0.02979
14 F-statistic: 31.68 on 1 and 998 DF, p-value: 2.363e-08

```

หากเราพิจารณาสมการ  $\Delta y_{1t} = \beta \Delta y_{2t} + v_t$  จะพบว่า  $\hat{\beta}$  มีค่าเท่ากับ 0.0034 และไม่แตกต่างจากศูนย์อย่างมีนัยสำคัญ


```

1 > summary(lm(diff(y1)~diff(y2)-1))
2 Call:
3 lm(formula = diff(y1) ~ diff(y2) - 1)
4
5 Coefficients:
6             Estimate Std. Error t value Pr(>|t|)
7 diff(y2) 0.003455    0.030827   0.112   0.911
8
9 Residual standard error: 0.9921 on 998 degrees of freedom
10 Multiple R-squared:  1.258e-05, Adjusted R-squared: -0.0009894
11 F-statistic: 0.01256 on 1 and 998 DF, p-value: 0.9108

```

จากตัวอย่างข้างต้นเราจำเป็นต้องระมัดระวังในการพิจารณาความสัมพันธ์ระหว่างอนุกรมเวลาในกรณีที่ตัวแปรที่เราสนใจมีลักษณะเป็น  $I(1)$  ซึ่งในกรณีทั่วไปเราจำเป็นต้องปรับให้ตัวแปรดังกล่าวเป็น  $I(0)$  ก่อนที่จะพิจารณาความสัมพันธ์ด้วยสมการเช่น  $\Delta y_t = \beta \Delta x_t + v_t$  โดยค่าสัมประสิทธิ์  $\beta$  ก็จะอธิบายการเปลี่ยนแปลงของ  $\Delta x_t$  ต่อการเปลี่ยนแปลงของ  $\Delta y_t$  อย่างไรก็ตามในบางกรณีที่เราอาจจะสามารถศึกษาความสัมพันธ์ระหว่างตัวแปรที่เป็น  $I(1)$  ก็ได้ซึ่งในกรณีดังกล่าวคือกรณีที่ตัวแปรเป็น cointegration

รูปที่ 6.1: การจำลองกระบวนการ  $I(1)$  สองอนุกรมเวลา



## 6.2 นิยามของโคอินทิเกรชัน

กำหนดให้  $\mathbf{Y}_t = (y_{1t}, y_{2t}, \dots, y_{nt})'$  แทนเวกเตอร์  $(n \times 1)$  ของอนุกรมเวลาที่เป็น  $I(1)$  แล้ว ตัวแปรใน  $\mathbf{Y}_t$  จะโคอินทิเกรตกัน ถ้ามีเวกเตอร์  $\beta = (\beta_1, \dots, \beta_n)'$  ที่ทำให้

$$\beta' \mathbf{Y}_t = \beta_1 y_{1t} + \dots + \beta_n y_{nt} \sim I(0) \quad (6.1)$$

ซึ่งหมายความว่าผลรวมเชิงเส้น (linear combination) ของตัวแปรที่เป็น  $I(1)$  มีลักษณะเป็น  $I(0)$  โดยที่ผลรวมเชิงเส้นมักจะได้อาจมาจากทฤษฎีทางเศรษฐศาสตร์ และเรียกสมการดังกล่าวว่าเป็นความสัมพันธ์ในดุลยภาพระยะยาว (long-run equilibrium) ซึ่งสะท้อนการที่อนุกรมเวลา  $I(1)$  มีความสัมพันธ์ในดุลยภาพระยะยาวด้วยกันอยู่ ดังนั้นตัวแปรดังกล่าวจะไม่แยกห่างจากกันที่ดุลยภาพ โดยจะมีแรงปรับให้ตัวแปรเข้าสู่ดุลยภาพ

เวกเตอร์  $\beta$  ไม่ได้มีลักษณะเป็นรูปแบบอย่างเดียว (unique) เนื่องจากเวกเตอร์ที่เป็นจำนวนเท่าของ  $c\beta'$  ก็สามารถสอดคล้องกับเงื่อนไขในคำนิยามข้างต้นได้ ดังนั้น เรามักจะสนใจในรูปแบบที่ปรับเป็นบรรทัดฐาน (normalized) ซึ่งเขียนสมการโคอินทิเกรชันได้ดังนี้

$$\beta' \mathbf{Y}_t = y_{1t} - \beta_2 y_{2t} - \dots - \beta_n y_{nt} \sim I(0)$$

หรือเป็นสมการ

$$y_{1t} = \beta_2 y_{2t} + \dots + \beta_n y_{nt} + u_t \quad (6.2)$$

โดยที่  $u_t \sim I(0)$  และเราเรียกพจน์  $u_t$  ว่าค่าคลาดเคลื่อนจากดุลยภาพ (disequilibrium error) หรือ cointegrating residuals ซึ่งหากเราอยู่ในดุลยภาพระยะยาวค่าคลาดเคลื่อนจากดุลยภาพจะมีค่าเท่ากับศูนย์ เราจะได้ความสัมพันธ์ระยะยาวจะเท่ากับ  $y_{1t} = \beta_2 y_{2t} + \dots + \beta_n y_{nt}$

### 6.2.1 Cointegration และแบบจำลอง Error Correction Models

จากหัวข้อที่ผ่านมาเราพบว่าหากตัวแปรที่มีคุณลักษณะเป็น cointegration เราสามารถอธิบายได้ว่าในระยะยาวการเปลี่ยนแปลงของตัวแปรหนึ่งส่งผลอย่างไรต่อตัวแปรอื่น ในดุลยภาพระยะยาว สิ่งที่เราสนใจต่อไปคือหากเกิดภาวะที่ในระยะสั้นตัวแปรขยับออกจากดุลยภาพในระยะยาว จะมีกลไกในการปรับตัวเข้าสู่ดุลยภาพระยะยาวอย่างไร ซึ่งสามารถอธิบายผ่านแบบจำลอง Error Correction Model (ECM)

หากเราพิจารณา cointegration ที่มีตัวแปรสองตัวแปรที่มีลักษณะ  $I(1)$  คือ  $y_{1t}$  และ  $y_{2t}$  โดยมีความสัมพันธ์ cointegration เขียนได้เป็น  $y_{1t} - \beta_2 y_{2t} \sim I(0)$  Engle and Granger (1987) แสดงให้เห็นว่ามีแบบจำลอง error correction model (ECM) ที่สามารถแสดงได้ในรูป

$$\begin{aligned}\Delta y_{1t} &= c_1 + \alpha_1(y_{1,t-1} - \beta_2 y_{2,t-1}) + \sum_{j=1}^p \psi_{11}^j \Delta y_{1,t-j} + \sum_{j=1}^p \psi_{12}^j \Delta y_{2,t-j} + \varepsilon_{1t} \\ \Delta y_{2t} &= c_2 + \alpha_2(y_{1,t-1} - \beta_2 y_{2,t-1}) + \sum_{j=1}^p \psi_{21}^j \Delta y_{1,t-j} + \sum_{j=1}^p \psi_{22}^j \Delta y_{2,t-j} + \varepsilon_{2t} \quad (6.3)\end{aligned}$$

สมการข้างต้นแสดงพฤติกรรมเชิงพลวัตของ  $y_{1t}$  และ  $y_{2t}$  โดยแสดงการปรับตัวระยะสั้นเมื่อตัวแปรตัวใดตัวหนึ่งเคลื่อนตัวออกไปจากดุลยภาพ ซึ่งแบบจำลอง ECM ส่งผลให้เกิดประโยชน์ในการวิเคราะห์ข้อมูลการเงิน

### ตัวอย่าง 6.2: ECM สำหรับราคาหุ้นและเงินปันผล

กำหนดให้ล็อกของราคาหุ้น ( $s_t$ ) และล็อกของเงินปันผล ( $d_t$ ) เป็น  $I(1)$  ถ้าล็อกของสัดส่วนเงินปันผลต่อราคา ( $\log(D_t/S_t)$ ) เป็น  $I(0)$  ดังนั้น  $d_t - s_t \sim I(0)$  หรือเขียนเป็นสมการความสัมพันธ์ระยะยาวได้เป็น

$$d_t = s_t + \mu + u_t \quad (6.4)$$

โดยที่  $u_t \sim I(0)$  และสามารถเขียน ECM ได้ดังนี้

$$\Delta s_t = c_s + \alpha_s(d_{t-1} - s_{t-1} - \mu) + \varepsilon_{st} \quad (6.5)$$

$$\Delta d_t = c_d + \alpha_d(d_{t-1} - s_{t-1} - \mu) + \varepsilon_{dt} \quad (6.6)$$

โดยที่สมการ ?? แสดงความสัมพันธ์ระหว่างอัตราการเปลี่ยนแปลงของราคาหุ้นกับ disequilibrium error ( $d_{t-1} - s_{t-1} - \mu$ ) ในขณะที่สมการ ?? แสดงความสัมพันธ์ระหว่างอัตราการเปลี่ยนแปลงของเงินปันผลกับ disequilibrium error โดยมีการตอบสนองของราคาหุ้นและเงินปันผลขึ้นอยู่กับค่าสัมประสิทธิ์การปรับตัว (adjustment coefficient)  $\alpha_s$  และ  $\alpha_d$

สมมติให้  $\alpha_s = 0.5$  และ  $\alpha_d = 0$  จะได้

$$\Delta s_t = c_s + 0.5(d_{t-1} - s_{t-1} - \mu) + \varepsilon_{st}$$

$$\Delta d_t = c_d + \varepsilon_{dt}$$

ดังนั้นมีเพียงราคาหุ้นที่ตอบสนองต่อ disequilibrium error โดยที่ค่าเฉลี่ยของการเปลี่ยนแปลงของตัวแปรทั้งสองจะขึ้นอยู่กับข้อมูลในอดีต

$$E(\Delta s_t | F_{t-1}) = c_s + 0.5(d_{t-1} - s_{t-1} - \mu)$$

$$E(\Delta d_t | F_{t-1}) = c_d$$

ซึ่งเราสามารถพิจารณาการเปลี่ยนแปลงได้ดังนี้

1. หาก  $d_{t-1} - s_{t-1} - \mu = 0$  ดังนั้น  $E(\Delta s_t | F_{t-1}) = c_s$  และ  $E(\Delta d_t | F_{t-1}) = c_d$  หากไม่มีการเปลี่ยนแปลงออกจากดุลยภาพระยะยาวในคาบที่ผ่านมา อัตราการเปลี่ยนแปลงของทั้งสองตัวแปรจะเท่ากับค่าเฉลี่ยของการเปลี่ยนแปลง
2. หาก  $d_{t-1} - s_{t-1} - \mu > 0$  ดังนั้น  $E(\Delta s_t | F_{t-1}) = c_s + 0.5(d_{t-1} - s_{t-1} - \mu) > c_s$  เนื่องจากเงินปันผลสูงกว่าราคาหุ้นที่จะรักษาดุลยภาพระยะยาว ดังนั้น ECM พยากรณ์ว่า  $s_t$  จะเปลี่ยนแปลงที่อัตราสูงกว่าอัตราที่ดุลยภาพในระยะยาว ( $> c_s$ ) เพื่อรักษาสัดส่วนราคาหุ้นต่อเงินปันผล โดยที่ความเร็วในการปรับตัว (speed of adjustment) แสดงได้ด้วยพารามิเตอร์  $\alpha_s = 0.5$

## 6.2.2 multiple cointegrating relationship

เวกเตอร์ของอนุกรมเวลา  $Y_t = (y_{1t}, \dots, y_{nt})'$  ซึ่งเป็นอนุกรมเวลาที่ cointegrated กัน อาจมีความสัมพันธ์ระยะยาวได้  $r$  รูปแบบ ซึ่ง  $0 < r < n$  เช่นกรณีที่  $Y_t = (y_{1t}, y_{2t}, y_{3t})'$  อาจจะมีความสัมพันธ์ในรูป  $\beta_{11}y_{1t} + \beta_{12}y_{2t} + \beta_{13}y_{3t} \sim I(0)$  และ  $\beta_{21}y_{1t} + \beta_{22}y_{2t} + \beta_{23}y_{3t} \sim I(0)$  และเราเรียกเวกเตอร์  $(\beta_{11} \ \beta_{12} \ \beta_{13})'$  และ  $(\beta_{21} \ \beta_{22} \ \beta_{23})'$  ว่า cointegrating vector

## 6.3 การทดสอบ cointegration

หากเรากำหนดให้  $Y_t$  เป็นเวกเตอร์  $n \times 1$  ของอนุกรมเวลา  $I(1)$  ซึ่งมี  $r$  ( $0 < r < n$ ) cointegrating vectors ซึ่งแสดงเป็นสัญลักษณ์ได้ดังนี้

$$\begin{pmatrix} \beta_1' Y_t \\ \vdots \\ \beta_r' Y_t \end{pmatrix} = \begin{pmatrix} u_{1t} \\ \vdots \\ u_{rt} \end{pmatrix} \sim I(0) \quad (6.7)$$

การทดสอบ cointegration อาจแบ่งได้เป็นสองกรณีคือ

1. การทดสอบว่ามีความสัมพันธ์ cointegrating อย่างมากหนึ่งรูปแบบหรือไม่ (Engle and Granger(1986))

2. การทดสอบว่ามี cointegrating vector  $0 \leq r < n$  หรือไม่ (Johansen (1988))

การทดสอบในประเด็นแรกได้ถูกนำเสนอโดย Engle and Granger (1986) ซึ่งเสนอการทดสอบสองขั้นตอน (two-step cointegration test) ซึ่งประกอบด้วย

1. สร้าง cointegrating residuals โดยที่  $u_t = \beta_1 y_{1t} + \dots + \beta_n y_{nt}$
2. ทดสอบ unit root ของ  $u_t$  เพื่อแสดงว่า  $u_t$  เป็น  $I(0)$  หรือไม่ โดยสมมติฐานหลักของการทดสอบนี้คือไม่มี cointegration ซึ่งสมมติฐานดังกล่าวสอดคล้องกับ  $u_t$  เป็น  $I(1)$

การทดสอบ cointegration ตามวิธีการของ Engle and Granger สามารถแบ่งออกได้เป็นสองกรณีคือ *กรณีที่หนึ่ง* เราทราบความสัมพันธ์ของอนุกรมเวลาที่เราสงสัย เช่น จากทฤษฎีเราทราบความสัมพันธ์ระหว่างล๊อคของราคาหุ้น ( $s_t$ ) และล๊อคของเงินปันผล ( $d_t$ ) ว่าสามารถแสดงเป็นสมการ  $s_t - d_t = u_t$  หรือ cointegrating vector สามารถแสดงได้โดย  $\beta = (1 \ -1)'$  ดังนั้นเราสามารถหา cointegrating residuals ได้ทันที *กรณีที่สอง* เราจำเป็นต้องประมาณค่าสำหรับ cointegrating vector และสร้าง cointegrating vector จาก  $\hat{u}_t = \hat{\beta}' Y_t$

### 6.3.1 การทดสอบกรณีที่เราทราบค่า cointegrating vector

กำหนดให้  $Y_t$  เป็นเวกเตอร์  $n \times 1$  ของ  $I(1)$  และ cointegrated กันโดยที่มีความสัมพันธ์สามารถแสดงได้ด้วย cointegrating vector  $\beta$  ซึ่ง  $u_t = \beta' Y_t$  เราต้องการทดสอบสมมติฐานหลัก  $H_0 : u_t = \beta' Y_t \sim I(1)$  หรือไม่มี cointegration กับสมมติฐานรอง  $H_1 : u_t = \beta' Y_t \sim I(0)$  หรือมี cointegration

เราสามารถทดสอบสมมติฐานข้างต้นได้ด้วยการทดสอบยูนิทรูทเช่น ADF หรือ PP กับตัวแปร  $u_t$  ซึ่งเราจะสรุปว่า  $Y_t$  เป็น cointegrated ถ้าเราปฏิเสธสมมติฐานหลัก

### ตัวอย่างที่ 6.3: การพิจารณาความสัมพันธ์ระหว่างราคาปัจจุบันและราคาฟิวเจอร์

ในตัวอย่างนี้เราจะพิจารณาความสัมพันธ์ระหว่างราคาปัจจุบัน (spot price:  $S_t$ ) และราคาฟิวเจอร์ (future price:  $F_t$ ) ของอัตราแลกเปลี่ยน โดยที่ตัวแปรทั้งสองมีความสัมพันธ์ตามแบบจำลอง cost of carry model ซึ่งล๊อคของราคาปัจจุบัน ( $s_t$ ) จะเท่ากับล๊อคของราคาฟิวเจอร์ ( $f_t$ ) บวกกับค่าคงที่ (ซึ่งสะท้อนต้นทุนในการถือสินทรัพย์)

$$f_t = s_t + c$$

อย่างไรก็ตาม ก่อนที่เราจะพิจารณาสมการ cointegration เราอาจจะพิจารณา order of integration ของตัวแปรทั้งสอง โดยการทดสอบ Augmented Dickey Fuller Unit root ด้วยคำสั่ง `ur.df` จาก package `urca`

กรณีของ  $lspot$  พบว่าค่าสถิติเท่ากับ  $-1.3151$  มากกว่าค่า critical value ( $-2.88$ ) แสดงว่า  $lspot$  เป็น unit root แล้วเมื่อพิจารณา  $diff(lspot)$  ค่าสถิติเท่ากับ  $-7.78$  น้อยกว่า critical value แสดงว่า  $diff(lspot)$  เป็น stationary ดังนั้น  $lspot$  เป็น  $I(1)$

เมื่อเราพิจารณา  $lfuture$  เราก็ได้ข้อสรุปเช่นเดียวกัน คือ  $lfuture$  เป็น  $I(1)$  ดังนั้น เราไม่สามารถประมาณค่า OLS กับตัวแปรทั้งสองได้ ยกเว้นในกรณี Cointegration

```

1 > set50_m <- read.csv("C:/teaching/ec435/r/set50_m.csv")
2 > lfutures<-log(set50_m$futures)
3 > lspot<-log(set50_m$spot)
4 > library(urca)
5 > summary(ur.df(lspot, type="drift", selectlags = "BIC"))
6 <Omitted>
7
8 Value of test-statistic is: -1.3151 1.15
9
10 Critical values for test statistics:
11      1pct  5pct 10pct
12 tau2 -3.46 -2.88 -2.57
13 phi1  6.52  4.63  3.81
14
15 > summary(ur.df(diff(lspot), type="drift", selectlags = "BIC"))
16 <Omitted>
17 Value of test-statistic is: -7.7769 30.2417
18
19 Critical values for test statistics:
20      1pct  5pct 10pct
21 tau2 -3.46 -2.88 -2.57
22 phi1  6.52  4.63  3.81
23
24 > summary(ur.df(lfutures, type="drift", selectlags = "BIC"))
25 <Omitted>
26 Value of test-statistic is: -1.3358 1.1551
27
28 Critical values for test statistics:
29      1pct  5pct 10pct
30 tau2 -3.46 -2.88 -2.57
31 phi1  6.52  4.63  3.81
32
33 > summary(ur.df(diff(lfutures), type="drift", selectlags = "BIC"))
34 <Omitted>
35 Value of test-statistic is: -8.1164 32.9392
36
37 Critical values for test statistics:
38      1pct  5pct 10pct
39 tau2 -3.46 -2.88 -2.57
40 phi1  6.52  4.63  3.81

```

ขั้นตอนถัดไป เราสามารถทดสอบ Cointegration จากความสัมพันธ์ระหว่างตัวแปรทั้งสองข้างต้น เราสามารถเขียนสมการความสัมพันธ์ระยะยาวได้เป็น

$$f_t = s_t + c + u_t$$

ดังนั้นในกรณีนี้เราสามารถเขียน  $u_t = f_t - s_t$  หรือ  $\beta = (1 \quad -1)'$  แล้วทดสอบ Augmented Dickey Fuller Unit root กับ  $u$  ด้วยคำสั่งต่อไปนี้

```

1 > u<-lfutures-lspot
2 > summary(ur.df(u, type="drift", selectlags = "BIC"))
3
4 #####
5 # Augmented Dickey-Fuller Test Unit Root Test #
6 #####
7
8 Test regression drift
9
10
11 Call:
12 lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
13
14 Residuals:
15      Min       1Q   Median       3Q      Max
16 -0.053465 -0.005260  0.000870  0.006958  0.035017
17
18 Coefficients:
19             Estimate Std. Error t value Pr(>|t|)
20 (Intercept) -0.003307   0.001250  -2.645  0.00924 **
21 z.lag.1      -0.899482   0.110577  -8.134 4.14e-13 ***
22 z.diff.lag    0.175245   0.089293   1.963  0.05199 .
23 ---
24 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
25
26 Residual standard error: 0.0132 on 121 degrees of freedom
27 Multiple R-squared:  0.4018, Adjusted R-squared:  0.3919
28 F-statistic: 40.64 on 2 and 121 DF, p-value: 3.151e-14
29
30
31 Value of test-statistic is: -8.1345 33.0866
32
33 Critical values for test statistics:
34      1pct  5pct 10pct
35 tau2 -3.46 -2.88 -2.57
36 phi1  6.52  4.63  3.81

```

จากการทดสอบ Augmented Dickey Fuller unit root กับตัวแปร  $u_t$  พบว่าค่าสถิติเท่ากับ -8.13 ซึ่งน้อยกว่า ค่า critical value (-2.88) เราสามารถปฏิเสธสมมติฐานว่า  $u_t$  เป็น unit root และสรุปว่าตัวแปรทั้งสอง Cointegrated กัน

### 6.3.2 การทดสอบกรณีที่เราไม่ทราบค่า cointegrating vector

ในกรณีนี้เราจำเป็นต้องประมาณค่า cointegrating vector ขึ้นมา ดังนั้นในขั้นตอนแรกของการทดสอบเราจำเป็นต้องประมาณค่า  $\beta$  โดยที่เราอาจจะเขียนในรูปบรรทัดฐาน (normalized) ซึ่งเขียนเป็นสมการได้

$$y_{1t} = c + \beta_2 y_{2t} + \dots + \beta_n y_{nt} + u_t \quad (6.8)$$

การทดสอบ cointegration จะเป็นการทดสอบ unit root ของ  $\hat{u}_t = y_{1t} - \hat{c} - \hat{\beta}_2 y_{2t} - \dots - \hat{\beta}_n y_{nt}$  โดยที่  $\hat{c}, \hat{\beta}_2, \dots, \hat{\beta}_n$  เป็นตัวประมาณค่า OLS ของสัมประสิทธิ์

Phillips and Ouliaris (1990) ได้แสดงให้เห็นว่าตัวทดสอบ ADF และ PP ของ cointegrating residual ในกรณีที่เรานำค่าสัมประสิทธิ์ของ cointegrating vector ไม่ได้มีการแจกแจง



แบบ ADF distribution แบบปกติ เนื่องจากตัวประมาณค่า OLS ในขั้นตอนแรกเผชิญกับปัญหา spurious regression ดังนั้นในการทดสอบ cointegration ต้องใช้การแจกแจงจากตารางข้างล่าง

Phillips and Orlaris (1990) Distribution

	No constant			Constant			Constant and trend		
	Significance level			Significance level			Significance level		
n-1	0.1	0.05	0.01	0.1	0.05	0.01	0.1	0.05	0.01
1	-2.4505	-2.7619	-3.3865	-3.0657	-3.3654	-3.9618	-3.5184	-3.8	-4.3628
2	-2.9873	-3.2667	-3.8395	-3.4494	-3.7675	-4.3078	-3.8429	-4.1567	-4.6451
3	-3.4446	-3.7371	-4.3038	-3.8329	-4.1121	-4.7325	-4.195	-4.4895	-5.0433
4	-3.8068	-4.1261	-4.672	-4.1565	-4.4542	-5.0728	-4.4625	-4.7423	-5.3576
5	-4.1416	-4.3999	-4.9897	-4.4309	-4.7101	-5.2812	-4.7311	-5.0282	-5.5849

Note: n is the number of variables.

## ตัวอย่าง 6.4: การทดสอบความสัมพันธ์ระหว่างราคาปัจจุบันและราคาฟิวเจอร์กรณีไม่ทราบค่าสัมประสิทธิ์

ต่อเนื่องจากตัวอย่างที่ผ่านมา ในกรณีนี้สมมุติว่าเราไม่ทราบค่าของ cointegrating vector ดังนั้นสมมุติให้  $\beta = (1 \quad -\beta_2)'$  ดังนั้นเราสามารถพิจารณาสมการถดถอย  $f_t = c + \beta_2 s_t + u_t$  ซึ่งหลังจากที่เราประมาณค่าด้วย OLS เราสามารถที่จะหาค่า  $\hat{u}_t = f_t - \hat{c} - \hat{\beta}_2 s_t$  ตามขั้นตอนในคำสั่งข้างล่าง

```

1 > m1<-lm(1futures~1spot)
2 > summary(m1)
3
4 Call:
5 lm(formula = 1futures ~ 1spot)
6
7 Residuals:
8      Min       1Q   Median       3Q      Max
9 -0.053040 -0.005474  0.001128  0.006023  0.037175
10
11 Coefficients:
12             Estimate Std. Error t value Pr(>|t|)
13 (Intercept) -0.044097   0.023113  -1.908   0.0587 .
14 1spot        1.006206   0.003535 284.610 <2e-16 ***
15
16 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
17
18 Residual standard error: 0.01349 on 124 degrees of freedom
19 Multiple R-squared:  0.9985, Adjusted R-squared:  0.9985
20 F-statistic: 8.1e+04 on 1 and 124 DF, p-value: < 2.2e-16

```

ค่าสัมประสิทธิ์  $\beta_2$  เท่ากับ 1.006 ซึ่งใกล้เคียงกับ 1 มาก หลังจากนั้นเราก็จะทดสอบ cointegrating residuals โดยใช้การทดสอบ Augmented Dickey Fuller Unit root

```

1 > uhat<- m1$residuals
2 > summary(ur.df(uhat, type="drift", selectlags = "BIC"))
3
4 #####
5 # Augmented Dickey-Fuller Test Unit Root Test #
6 #####
7
8 Test regression drift
9
10
11 Call:
12 lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
13
14 Residuals:
15      Min       1Q   Median       3Q      Max
16 -0.052712 -0.005953  0.001036  0.006614  0.035313
17
18 Coefficients:
19             Estimate Std. Error t value Pr(>|t|)
20 (Intercept) -0.0001084  0.0011708  -0.093   0.9264
21 z.lag.1      -0.9224120  0.1112721  -8.290 1.81e-13 ***
22 z.diff.lag    0.1846947  0.0890896   2.073  0.0403 *
23 ---
24 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
25
26 Residual standard error: 0.01304 on 121 degrees of freedom
27 Multiple R-squared:  0.4104, Adjusted R-squared:  0.4007
28 F-statistic: 42.12 on 2 and 121 DF, p-value: 1.311e-14
29
30
31 Value of test-statistic is: -8.2897 34.364
32
33 Critical values for test statistics:
34      1pct  5pct 10pct
35 tau2  -3.46 -2.88 -2.57
36 phi1   6.52  4.63  3.81

```

ได้ค่าสถิติ ADF เท่ากับ -8.4232 นำไปเปรียบเทียบกับค่า critical value ในตาราง Phillips-Orlariis กรณีที่มีค่าคงที่ (เนื่องจากรูปแบบสมการ โคอินทิเกรชันมีพจน์ค่าคงที่) และ  $n-1=1$  (เนื่องจากในกรณีนี้เรามีตัวแปรในสมการ cointegration สองตัวแปร) ที่นัยสำคัญ 0.05 มีค่าเท่ากับ -3.3656 เนื่องจากค่าสถิติที่ได้มีค่าต่ำกว่า critical value ดังนั้นเราสามารถปฏิเสธ  $H_0$  และสรุปได้ว่าตัวแปรทั้งสองเป็น cointegration กัน

## 6.4 การประมาณค่า ECM ด้วย OLS

สมมุติว่าเราสนใจตัวแปร  $(y_{1t}y_{2t})'$  ซึ่งมีความสัมพันธ์ cointegration แสดงได้ด้วยสมการ  $y_{1t} = \beta_2 y_{2t} + u_t$  (หรือ  $y_{1t} - \beta_2 y_{2t} = u_t \sim I(0)$ ) และเรามีตัวประมาณค่า  $\hat{\beta}_2$  ที่มีคุณลักษณะเป็น consistent และเราต้องประมาณค่า ECM ในรูปแบบ

$$\Delta y_{1t} = c_1 + \alpha_1(y_{1,t-1} - \beta_2 y_{2,t-1}) + \sum_{i=1}^p \psi_{11}^i \Delta y_{1,t-i} + \sum_{i=1}^p \psi_{12}^i \Delta y_{2,t-i} + \varepsilon_{1t} \quad (6.9)$$

$$\Delta y_{2t} = c_2 + \alpha_2(y_{1,t-1} - \beta_2 y_{2,t-1}) + \sum_{i=1}^p \psi_{21}^i \Delta y_{1,t-i} + \sum_{i=1}^p \psi_{22}^i \Delta y_{2,t-i} + \varepsilon_{2t} \quad (6.10)$$

เราสามารถแทนค่า  $\hat{\beta}_2$  ลงในสมการเหมือนเป็นพารามิเตอร์ที่เราทราบค่า ดังนั้นเราสามารถพิจารณา disequilibrium error ( $y_{1,t-1} - \beta_2 y_{2,t-1}$ ) เหมือนเป็นตัวแปรที่ทราบค่า เนื่องจากตัวแปรทุกตัวในสมการ ?? และ ?? เป็น  $I(0)$  เราสามารถประมาณค่าสมการดังกล่าวด้วย OLS

### ตัวอย่างที่ 6.5 การประมาณค่า ECM สำหรับสมการราคาปัจจุบันและราคาฟิวเจอร์

เราต้องการประมาณค่าสมการ ECM สำหรับลือกของราคาปัจจุบันและลือกของราคาฟิวเจอร์ซึ่งเราจำเป็นต้องหาอันดับของค่าล่าของผลต่างที่เหมาะสม ซึ่งอาจจะใช้ AIC, BIC ในการเลือก แต่ในที่นี้เราสมมติให้แบบจำลองของเป็นดังนี้

$$\Delta s_t = c_1 + \alpha_1 \hat{u}_{t-1} + \psi_{11} \Delta s_{t-1} + \psi_{12} \Delta f_{t-1} + \varepsilon_{ft} \quad (6.11)$$

$$\Delta f_t = c_2 + \alpha_2 \hat{u}_{t-1} + \psi_{21} \Delta s_{t-1} + \psi_{22} \Delta f_{t-1} + \varepsilon_{st} \quad (6.12)$$

เราเริ่มจากการสร้าง series `dlspot` และ `dlfuture` ซึ่งจะมีสมาชิกจากคาบที่  $t=2, \dots, 126$  โดยที่เวกเตอร์ `dlspot` และ `dlfuture` จะมีสมาชิกทั้งหมด 125 ตัวโดยตัวแรกเป็นข้อมูล ณ คาบที่  $t=2$  นอกจากนี้เรายังปรับให้เวกเตอร์ `uhat` เริ่มต้นที่ช่วงเวลาเดียวกันคือ  $t=2$

```
1 > dlspot<-diff(lspot)
2 > dlfutures<-diff(lfutures)
3 > uhat<-uhat[2:126]
```

เนื่องจากการเรียงของข้อมูลความสัมพันธ์ของสมการที่ ?? และ ?? จะเริ่มที่  $t=3, \dots, 126$  หรือสมาชิกตำแหน่งที่ 2:125 ในเวกเตอร์ `dlspot` และ `dlfuture` หรือคำสั่งที่ใช้ประมาณค่าคือ

```

1 > ecm1<-lm(dlfutures[2:125]~uhat[1:124]+dlfutures[1:124]+dlspot[1:124])
2 > summary(ecm1)
3
4 Call:
5 lm(formula = dlfutures[2:125] ~ uhat[1:124] + dlfutures[1:124] +
6     dlspot[1:124])
7
8 Residuals:
9      Min       1Q   Median       3Q      Max
10 -0.31503 -0.03288  0.01358  0.04233  0.14965
11
12 Coefficients:
13             Estimate Std. Error t value Pr(>|t|)
14 (Intercept)    0.004115   0.006281   0.655   0.5136
15 uhat[1:124]   -1.152182   0.598961  -1.924   0.0568 .
16 dlfutures[1:124] 0.071715   0.478109   0.150   0.8810
17 dlspot[1:124]   0.137282   0.498649   0.275   0.7836
18
19 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
20
21 Residual standard error: 0.06973 on 120 degrees of freedom
22 Multiple R-squared:  0.06491, Adjusted R-squared:  0.04154
23 F-statistic: 2.777 on 3 and 120 DF, p-value: 0.04424
24
25 > ecm2<-lm(dlspot[2:125]~uhat[1:124]+dlfutures[1:124]+dlspot[1:124])
26 > summary(ecm2)
27
28 Call:
29 lm(formula = dlspot[2:125] ~ uhat[1:124] + dlfutures[1:124] +
30     dlspot[1:124])
31
32 Residuals:
33      Min       1Q   Median       3Q      Max
34 -0.34142 -0.03319  0.01113  0.04038  0.13716
35
36 Coefficients:
37             Estimate Std. Error t value Pr(>|t|)
38 (Intercept)    0.004314   0.005893   0.732   0.466
39 uhat[1:124]   -0.212277   0.561883  -0.378   0.706
40 dlfutures[1:124] -0.102953   0.448512  -0.230   0.819
41 dlspot[1:124]   0.288494   0.467780   0.617   0.539
42
43 Residual standard error: 0.06541 on 120 degrees of freedom
44 Multiple R-squared:  0.03337, Adjusted R-squared:  0.009204
45 F-statistic: 1.381 on 3 and 120 DF, p-value: 0.252

```

เขียนเป็นผลการประมาณค่าได้ดังนี้

$$\Delta f_t = 0.004 + -1.152\hat{u}_{t-1} + 0.072\Delta f_{t-1} + 0.137\Delta s_{t-1} + \varepsilon_{st}$$

$$\Delta s_t = 0.004 - 0.212\hat{u}_{t-1} - 0.103\Delta f_{t-1} + 0.289\Delta s_{t-1} + \varepsilon_{ft}$$

หากพิจารณาจากสมการแรก ถ้า  $f_{t-1} > \hat{\beta}s_{t-1} + \hat{c}$  จะส่งผลให้  $\hat{u}_{t-1}$  มากกว่าศูนย์ จากค่าสัมประสิทธิ์  $\hat{\alpha}_1 = -1.152$  แสดงว่าอัตราการเปลี่ยนแปลงของอัตราแลกเปลี่ยน futures จะลดลงมาเพื่อปรับเข้าสู่ดุลยภาพ นอกจากนี้สัมประสิทธิ์หน้า  $\Delta f_{s-1}$  สะท้อนว่าหากอัตราการเปลี่ยนแปลงของอัตราแลกเปลี่ยน future เปลี่ยนแปลงในคาบก่อนหน้าจะส่งผลให้อัตราการเปลี่ยนแปลงของอัตรา

แลกเปลี่ยน futures เปลี่ยนแปลงในทิศทางเดียวกัน

## 6.5 แบบจำลอง เวกเตอร์ เอ เรอ คอ เร คชัน (Vector Error Correction Model: VECM)

Granger นำเสนอแบบจำลองโคอินทิเกรตที่อธิบายความสัมพันธ์ระยะยาว และแบบจำลองเอเรอคอเรคชันซึ่งนำเสนอการปรับตัวระยะสั้น Johansen (1991) ได้รวมความสัมพันธ์ทั้งระยะยาวและการปรับตัวระยะสั้นในรูปแบบของสมการของตัวแปรในรูปเวกเตอร์ โดยมีพื้นฐานจากแบบจำลองเวกเตอร์ออโตรีเกรสชัน ซึ่งหากพิจารณาตัวแปร  $y_{1t}, \dots, y_{nt}$  ในรูปเวกเตอร์  $(n \times 1)$  เขียนเป็นสัญลักษณ์  $Y_t$  ในรูปสมการ  $VAR(p)$  ดังต่อไปนี้

$$Y_t = \Pi_1 Y_{t-1} + \dots + \Pi_p Y_{t-p} + \epsilon_t, t = 1, \dots, T$$

ถ้า  $VAR(p)$  มีลักษณะเป็นมีคุณสมบัติไม่นิ่ง(nonstationary) แสดงว่าตัวแปรบางตัวหรือทั้งหมดใน  $Y_t$  มีลักษณะเป็น  $I(1)$  ซึ่งเราสามารถพิจารณาต่อไปว่าตัวแปรเหล่านั้นโคอินทิเกรตกันหรือไม่

### 6.5.1 รูปแบบของสมการ

Johansen เสนอว่าเราสามารถทดสอบความสัมพันธ์ระยะยาว ได้จากการแปลงแบบจำลองเวกเตอร์ออโตรีเกรสชันของตัวแปร  $Y_t$  ให้อยู่ในรูปของแบบจำลองเวกเตอร์เอเรอคอเรคชัน ซึ่งเขียนเป็นสมการได้ดังนี้

$$\Delta Y_t = \Pi Y_{t-1} + \Gamma_1 \Delta Y_{t-1} + \dots + \Gamma_{p-1} \Delta Y_{t-(p-1)} + \epsilon_t$$

ซึ่งจะเห็นได้ว่าสมการนี้คือแบบจำลอง  $VAR(p-1)$  ของ  $\Delta Y_t$  โดยที่เมตริกซ์  $\Pi$  คือเมตริกซ์สัมประสิทธิ์ที่แสดงความสัมพันธ์ระยะยาว และ  $\Gamma_k$  คือเมตริกซ์สัมประสิทธิ์ที่อธิบายผลของการปรับตัวระยะสั้นในคาบที่ผ่านมา

ในแบบจำลองเวกเตอร์เอเรอคอเรคชันเราพบว่า  $\Delta Y_t$  และค่าล่าของ  $\Delta Y_t$  เป็น  $I(0)$  จะเห็นได้ว่า เหลือเพียงพจน์  $\Pi Y_{t-1}$  ที่มีโอกาสเป็น  $I(1)$  และหากเราพิจารณา  $\Delta Y_t$  เราพบว่า  $\Delta Y_t$  จะเป็น  $I(0)$  ถ้า  $\Pi Y_{t-1}$  เป็น  $I(0)$  ดังนั้น  $\Pi Y_{t-1}$  จะเป็นเมตริกซ์ที่ระบุความสัมพันธ์ระยะยาวหากตัวแปรโคอินทิเกรตกัน

กรณีที่  $Y_t$  มีลักษณะเป็น  $I(1)$  จะเกิดขึ้นเมื่อ  $\Pi$  จะเป็นเมตริกซ์เอกฐาน (singular matrix) ซึ่งกรณีดังกล่าวเกิดขึ้นเมื่อค่าลำดับของเมตริกซ์มีค่าน้อยกว่าจำนวนตัวแปร ( $rank(\Pi) = r < n$ ) ซึ่งค่าดังกล่าวเป็นไปได้สองกรณีคือ

1.  $rank(\Pi) = 0$  แสดงว่า  $\Pi$  และ  $Y_t$  เป็น  $I(1)$  และตัวแปรมิได้โคอินทิเกรตกัน และแบบจำลอง  $VECM(p-1)$  จะลดลงเหลือแค่  $VAR(p-1)$  ของตัวแปรในรูปผลต่างหนึ่งอันดับ

2.  $0 < \text{rank}(\Pi) = r < n$  กรณีนี้แสดงว่า  $Y_t$  เป็น  $I(1)$  และตัวแปรโคอินทิเกรตกัน โดยมี  $r$  จำนวนความสัมพันธ์เท่ากับ  $r$

จากคุณสมบัติข้างต้น การทดสอบโคอินทิเกรชันตามวิธีของ Johansen จะพิจารณา  $\Pi$

### 6.5.2 การทดสอบโคอินทิเกรชันตามวิธีของ Johansen

การทดสอบโคอินทิเกรชันจะพิจารณาจำนวนลำดับ (rank) ของเมทริกซ์  $\Pi$  ซึ่งสัมพันธ์กับค่าลักษณะเฉพาะ (eigenvalues) โดยที่ค่าลักษณะเฉพาะคือรากลักษณะเฉพาะ (characteristic roots) ที่มีค่าไม่เท่ากับศูนย์ กำหนดให้  $\lambda_i$  แทนค่าลักษณะเฉพาะที่  $i$  โดยที่  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$  และค่ารากมีคุณสมบัติ  $|\lambda_i| < 1$  และ  $\lambda_i \geq 0$

ถ้าตัวแปรใน  $Y_t$  ไม่ได้โคอินทิเกรตกัน ค่าลำดับของ  $\Pi$  จะไม่แตกต่างจากศูนย์อย่างมีนัยสำคัญ ดังนั้น  $\lambda_i \approx 0$  สำหรับทุกค่าของ  $i$  อย่างไรก็ตาม ในการทดสอบเราจะพิจารณา  $\ln(1 - \lambda_i)$  ซึ่งหาก  $\lambda_i = 0$  แล้ว  $\ln(1 - \lambda_i) = 0$

หากค่าอันดับของ  $\Pi$  เท่ากับ 1 แล้ว  $\ln(1 - \lambda_1)$  จะมีค่าเป็นลบ ในขณะที่  $\ln(1 - \lambda_i) = 0$  สำหรับ  $i > 1$

Johansen เสนอ ตัว สถิติ ที่ ใช้ ทดสอบ สอง ค่า ได้แก่ Johansen's Trace statistics และ Johansen's Maximum Eigenvalue statistics

#### Johansen's Trace Statistic

Johansen's Trace statistic ทดสอบสมมุติฐานต่อไปนี้

$$H_0(r_0) : r = r_0 \quad \text{vs} \quad H_1(r_0) : r > r_0$$

โดยที่ LR Trace statistics และคำนวณได้ดังนี้

$$LR_{\text{trace}}(r_0) = -T \sum_{i=r_0+1}^n \ln(1 - \hat{\lambda}_i)$$

โดยที่  $r_0$  คือจำนวนความสัมพันธ์ในสมมุติฐานหลัก และ  $\hat{\lambda}_i$  คือค่าประมาณของค่าลักษณะเฉพาะอันดับที่  $i$  ซึ่งหาก  $\text{rank}(\Pi) = r_0$  แล้ว  $\hat{\lambda}_{r_0+1}, \dots, \hat{\lambda}_n$  จะมีค่าเข้าใกล้ศูนย์ และ  $LR_{\text{trace}}(r_0)$  ควรจะมีค่าน้อย

#### Johansen's Maximum Eigenvalue Statistic

Johansen ยังได้เสนอการทดสอบ LR Maximum Eigenvalue statistic สำหรับสมมุติฐานต่อไปนี้

$$H_0(r_0) : r = r_0 \quad \text{vs} \quad H_1(r_0) : r = r_0 + 1$$

โดยเราเรียก LR statistic ว่า *maximum eigenvalue statistic* และคำนวณได้ดังนี้

$$LR_{max}(r_0) = -T \ln(1 - \hat{\lambda}_{r_0+1})$$

Johansen and Juselius (1990) เสนอว่าค่าวิกฤตที่ใช้ทดสอบสำหรับตัวสถิติทั้งสองมีการแจกแจงขึ้นอยู่กับรูปแบบของสมการ ซึ่งหากค่าสถิติสูงกว่าค่าวิกฤตที่ Johansen เสนอ เราจะปฏิเสธสมมุติฐานหลักที่ว่าตัวแปรมีความสัมพันธ์  $r_0$  สมการ และยอมรับว่ามีความสัมพันธ์มากกว่า  $r_0$  สำหรับการทดสอบ Trace statistics ในขณะที่หากเราใช้การทดสอบ Max Eigenvalue statistic เรา จะยอมรับว่ามีความสัมพันธ์เท่ากับ  $r_0 + 1$  ความสัมพันธ์

Johansen เสนอการทดสอบในลักษณะที่เป็นอันดับ (sequential testing procedure) โดยที่ กระบวนการดังกล่าวจะระบุจำนวนของความสัมพันธ์ได้อย่างคงเส้นคงว่า โดยที่กระบวนการเป็นดังนี้

- ขั้นตอนแรกเราทดสอบ  $H_0(r_0 = 0)$  กับ  $H_1(r_0 > 0)$  ถ้าเราไม่สามารถปฏิเสธสมมุติฐานหลัก ตัวแปรไม่โคอินทิเกรตกัน

ถ้าเราปฏิเสธ  $H_0(r_0 = 0)$  เราสามารถสรุปได้ว่า มีจำนวนความสัมพันธ์อย่างน้อยหนึ่งความสัมพันธ์อย่างน้อยหนึ่งความสัมพันธ์และทดสอบในขั้นต่อไป

- ทดสอบ  $H_0(r_0 = 1)$  กับ  $H_1(r_0 > 1)$  ถ้าเราไม่สามารถปฏิเสธสมมุติฐานหลัก เราสรุปว่ามีจำนวนความสัมพันธ์เท่ากับหนึ่ง

แต่ถ้า เราปฏิเสธสมมุติฐาน แสดงว่า มีมีจำนวนความสัมพันธ์อย่างน้อยสองสมการ

- กระบวนการที่เป็นอันดับดังกล่าวจะดำเนินไปเรื่อยๆจนกระทั่งสมมุติฐานหลักถูกปฏิเสธ

ในกรณีที่เราทดสอบแล้วพบว่ามีจำนวนความสัมพันธ์เท่ากับ  $r$  เราสามารถพิจารณาเวกเตอร์  $\Pi$  ซึ่งสามารถแยกออกได้เป็นเมทริกซ์  $\alpha$  และ  $\beta'$  ซึ่งมีมิติเท่ากับ  $n \times r$  และ  $r \times n$  ตามลำดับ

$$\Pi = \alpha\beta'$$

ตัวอย่างเช่น หากเราพิจารณากรณีที่ตัวแปรเท่ากับ 4 หากเราพบความสัมพันธ์เท่ากับหนึ่ง

$$\Pi = \alpha\beta' = \begin{bmatrix} \alpha_{11} \\ \alpha_{12} \\ \alpha_{13} \\ \alpha_{14} \end{bmatrix} \begin{bmatrix} \beta_{11} & \beta_{12} & \beta_{13} & \beta_{14} \end{bmatrix}$$

หากเราพบความสัมพันธ์เท่ากับสอง

$$\Pi = \alpha\beta' = \begin{bmatrix} \alpha_{11} & \alpha_{21} \\ \alpha_{12} & \alpha_{22} \\ \alpha_{13} & \alpha_{23} \\ \alpha_{14} & \alpha_{24} \end{bmatrix} \begin{bmatrix} \beta_{11} & \beta_{12} & \beta_{13} & \beta_{14} \\ \beta_{21} & \beta_{22} & \beta_{23} & \beta_{24} \end{bmatrix}$$

ในกรณีของความสัมพันธ์เท่ากับหนึ่ง เราสามารถเขียนส่วนของ  $\Pi Y_{t-1}$  ได้เป็น

$$\Pi Y_{t-1} = \begin{bmatrix} \alpha_{11} \\ \alpha_{12} \\ \alpha_{13} \\ \alpha_{14} \end{bmatrix} (\beta_{11}y_{1,t-1} + \beta_{12}y_{2,t-1} + \beta_{13}y_{3,t-1} + \beta_{14}y_{4,t-1})$$

ซึ่งเราสามารถนำไปเขียนสมการเอเรอคอเรชันสำหรับแต่ละตัวแปรได้

### 6.5.3 ขั้นตอนในการทดสอบโคอินทิเกรชันและสร้างแบบจำลองเวกเตอร์เอเรอคอเรชัน

ขั้นตอนในการสร้างแบบจำลอง Cointegration ของ Johansen คือ

- ระบุ Order และประมาณค่า VAR(p) สำหรับ  $Y_t$
- สร้าง likelihood ratio tests สำหรับการทดสอบ rank of  $\Pi$  เพื่อระบุจำนวน cointegrating vectors
- หากจำเป็นเราอาจจะสมมุติ normalization และระบุเงื่อนไขของ cointegrating vectors
- จาก normalized cointegrating vectors ที่ได้ระบุไว้ เราสามารถประมาณค่า cointegrated VECM ด้วย MLE

Johansen (1995) ใช้ specification ของ VECM ในรูปแบบต่อไปนี้

$$Y_t = \Phi D_t + \Pi_1 Y_{t-1} + \dots + \Pi_p Y_{t-p} + \epsilon_t, t = 1, \dots, T$$

โดยที่  $\Phi D_t = \mu_t = \mu_0 + \mu_1 t$  เป็น deterministic terms โดยที่พหุนามของ deterministic term ของ  $Y_t$  สามารถแยกออกได้เป็น 5 กรณี

1. Model  $H_2(r) : \mu_0$  (no constant)
2. Model  $H_1^*(r) : \mu_t = \mu_0 = \alpha \rho_0$  (restricted constant)



3. Model  $H_1(r) : \mu_t = \mu_0$  (unrestricted constant)
4. Model  $H^*(r) = \mu_t = \mu_0 + \alpha \rho_1 t$  (restricted trend)
5. Model  $H(r) = \mu_t = \mu_0 + \mu_1 t$  (unrestricted constant and trend)

## ตัวอย่างที่ 6.6 การประมาณค่าสมการ VECM สมการราคาปัจจุบันและราคาฟิวเจอร์

เราจะพิจารณาข้อมูล ใน ตัวอย่างที่ 6.5 ด้วยแบบจำลอง VECM ซึ่งประมาณ ค่าสมการ cointegration และ VECM ไปพร้อม ๆ กัน

ขั้นตอนแรกในการทดสอบ คือการหาอันดับที่เหมาะสมสำหรับ VECM(p-1) โดยจะเป็นอันดับของ VAR(p) ซึ่งในที่นี้เราจะใช้ package *vars* และคำสั่ง VAR ในการประมาณค่าข้อมูล *fsprice* ซึ่งคือเมทริกซ์ที่ประกอบด้วยข้อมูล *lfutures* กับ *lspot* และเลือกใช้ Model selection AIC ในการหาอันดับที่เหมาะสม โดยชุดคำสั่งแสดงในรูปต่อไปนี้

```

1 > fsprice<-cbind(lfutures, lspot)
2 > head(fsprice)
3     lfutures    lspot
4 [1,] 6.287115 6.280134
5 [2,] 6.198682 6.199535
6 [3,] 6.151242 6.156004
7 [4,] 6.164367 6.179250
8 [5,] 6.167307 6.178836
9 [6,] 6.193384 6.174411
10 > library(vars)
11 > var.mod<-VAR(fsprice, lag.max = 4, ic = c("AIC"))
12 > var.mod
13
14 VAR Estimation Results:
15 =====
16
17 Estimated coefficients for equation lfutures:
18 =====
19 Call:
20 lfutures = lfutures.l1 + lspot.l1 + lfutures.l2 + lspot.l2 + lfutures.l3 +
      lspot.l3 + lfutures.l4 + lspot.l4 + const
21
22 lfutures.l1    lspot.l1 lfutures.l2    lspot.l2 lfutures.l3    lspot.l3
23 lfutures.l4    lspot.l4
24 0.03901903 1.20084532 0.06312604 -0.48169298 -0.91804903 1.40139010
25 0.37178420 -0.69722519
26 const
27 0.13406246
28
29 Estimated coefficients for equation lspot:
30 =====
31 Call:
32 lspot = lfutures.l1 + lspot.l1 + lfutures.l2 + lspot.l2 + lfutures.l3 + lspot.l3
      + lfutures.l4 + lspot.l4 + const
33
34 lfutures.l1    lspot.l1 lfutures.l2    lspot.l2 lfutures.l3    lspot.l3
35 lfutures.l4    lspot.l4
36 -0.1738544 1.3769259 0.1714170 -0.5291331 -0.6237252 1.0354564
37 0.3430320 -0.6255168
38 const
39 0.1684990

```

จากผลการประมาณค่า เราจะเห็นได้ว่า lag ที่โปรแกรมเลือก คือ 4 ซึ่งแสดงด้วยสัญลักษณ์ .l4 แสดงว่าอันดับที่เหมาะสมสำหรับ VAR คือ VAR(4) ดังนั้น ในการประมาณค่าแบบจำลอง VECM เราจะเลือกใช้แบบจำลอง VECM(3)

ในการทดสอบ Johansen และ ประมาณค่า VECM เราจะใช้คำสั่ง *ca.jo* ใน package *urca* โดยที่เราต้องระบุข้อมูล (*fsprice*) วิธีในการทดสอบ (*trace*) รูปแบบของสมการ (*const*) และจำนวน lag ในแบบจำลอง *VAR* ซึ่งในที่นี้คือ  $k=4$  โดยเก็บผลไว้ในชื่อ *fsprice.rc* และเรียกดูผลด้วย *summary(fsprice.rc)*

```

1 > library(urca)
2 > fsprice.rc <-ca.jo(fsprice, type = c("trace"), ecdet = c("const"), K=4)
3 > summary(fsprice.rc)
4
5 #####
6 # Johansen-Procedure #
7 #####
8
9 Test type: trace statistic , without linear trend and constant in cointegration
10
11 Eigenvalues (lambda):
12 [1] 2.847322e-01 2.434360e-02 2.081668e-17
13
14 Values of teststatistic and critical values of test:
15
16      test 10pct  5pct  1pct
17 r <= 1 |  3.01  7.52  9.24 12.97
18 r = 0  | 43.89 17.85 19.96 24.60
19
20 Eigenvectors, normalised to first column:
21 (These are the cointegration relations)
22
23      lfutures.l4  lspot.l4  constant
24 lfutures.l4  1.00000000  1.000000  1.000000
25 lspot.l4     -1.00451521 -1.422650 -1.256829
26 constant     0.03337561  2.822588  1.482432
27
28 Weights w:
29 (This is the loading matrix)
30
31      lfutures.l4  lspot.l4  constant
32 lfutures.d     -1.5094647  0.06534493 -1.823573e-13
33 lspot.d        -0.3469295  0.06379890 -3.903367e-14

```

จะได้ค่าสถิติซึ่งมีการทดสอบแบบเป็นลำดับ

- $H_0 : r = 0$  vs  $H_1 : r > 0$  ค่าสถิติ 43.89 มากกว่าค่า c.v.19.96 กรณี significance level = 0.05 เราสามารถปฏิเสธสมมุติฐานหลัก และสรุปว่า  $r > 0$
- $H_0 : r = 1$  vs  $H_1 : r > 1$  ค่าสถิติ 3.01 น้อยกว่าค่า c.v. 9.24 กรณี significance level = 0.05 เราไม่สามารถปฏิเสธสมมุติฐานหลัก และยอมรับว่า  $r = 1$  หรือ  $lfutures$  และ  $lspot$  มี cointegration 1 ความสัมพันธ์

เราสามารถสร้างสมการเวกเตอร์เอเรคโคเรชัน ได้ด้วยคำสั่ง *cajorls* โดยระบุว่าจะใช้รูปแบบจาก *fsprice.rc* และจำนวนความสัมพันธ์เท่ากับ 1 ( $r = 1$ )

```

1 > fsprice.vecm <- cajorls(fsprice.rc, r= 1)
2 > fsprice.vecm
3 $`r1m`
4
5 Call:
6 lm(formula = substitute(form1), data = data.mat)
7
8 Coefficients:
9      1futures.d    1spot.d
10 ect1      -1.50946    -0.34693
11 1futures.d11  -0.98859    -0.20081
12 1spot.d11     1.24993     0.42485
13 1futures.d12  -0.92914    -0.03298
14 1spot.d12     0.76844    -0.10408
15 1futures.d13  -1.86016    -0.66937
16 1spot.d13     2.18017     0.94147
17
18 $beta
19              ect1
20 1futures.14  1.00000000
21 1spot.14    -1.00451521
22 constant    0.03337561

```

จากคำสั่งดังกล่าว เราสามารถเขียนสมการ ECM ซึ่งอยู่ในส่วน \$`r1m` และแต่ละสมการเรียงตามแต่ละคอลัมน์ได้ดังนี้

$$\Delta f_t = -1.51u_{t-1} - 0.99\Delta f_{t-1} + 1.25\Delta s_{t-1} - 0.93\Delta f_{t-2} + 0.77\Delta s_{t-2} - 1.86\Delta f_{t-3} + 2.18\Delta s_{t-3}$$

$$\Delta s_t = -0.35u_{t-1} - 0.20\Delta f_{t-1} + 0.42\Delta s_{t-1} - 0.03\Delta f_{t-2} - 0.1\Delta s_{t-2} - 0.67\Delta f_{t-3} + 0.94\Delta s_{t-3}$$

โดยที่สมการความสัมพันธ์ระยะยาวได้แก่

$$u_t = f_t - 1.005s_t + 0.033$$


## ตัวอย่างที่ 6.7: การทดสอบและประมาณค่า VECM สมการอัตราผลตอบแทนพันธบัตรรัฐบาล

```

1 > tbond
   <- read.csv("https://raw.githubusercontent.com/chaleampong/EC435/master/tbond.csv",
2   header = TRUE)
3 > head(tbond)
4 > m1<-tbond$m1
5 > m3<-tbond$m3
6 > y5<-tbond$y5
7 > ts.plot(cbind(m1,m3,y5), lty=c(1:3), ylab="%", col=c("black", "red", "blue"),
   main="treasury bond at different maturities")
8 > legend("topright", legend = c("1 month", "3 months", "5 years"), col=c("black",
   "red", "blue"), lty = 1:3, xjust = 1, yjust = 1)

```

รูปที่ 6.2: ผลตอบแทนพันธบัตร



ขั้นตอนแรกของการทดสอบคือการหาอันดับที่เหมาะสมของ VECM โดยการจัดตัวแปรทั้งสามให้อยู่ในรูปเมทริกซ์ 'rterm' ด้วยคำสั่ง 'cbind' หลังจากนั้น ประมาณค่า VAR ด้วย package 'vars' และคำสั่ง 'VAR' โดยระบุข้อมูลที่ประมาณค่าคือ 'rterm' จำนวนอันดับที่สูงที่สุด 'lag.max=6' และเลือก model selection คือ AIC ด้วย 'ic=c("AIC")'

```

1 > library(vars)
2 > rterm <- cbind(m1, m3, y5)
3 > var.mod <- VAR(rterm, lag.max=6, ic= c("AIC"))
4 > var.mod
5
6 VAR Estimation Results:
7 =====
8
9 Estimated coefficients for equation m1:
10 =====
11 Call:
12 m1 = m1.l1 + m3.l1 + y5.l1 + m1.l2 + m3.l2 + y5.l2 + m1.l3 + m3.l3 + y5.l3 + const
13
14      m1.l1      m3.l1      y5.l1      m1.l2      m3.l2      y5.l2
15 -0.148170687  1.468544693  0.017887883  0.319187528 -0.565154976  0.035796258
16      -0.100551087
17      m3.l3      y5.l3      const
18  0.015396105 -0.054976949 -0.009814944
19
20 Estimated coefficients for equation m3:
21 =====
22 Call:
23 m3 = m1.l1 + m3.l1 + y5.l1 + m1.l2 + m3.l2 + y5.l2 + m1.l3 + m3.l3 + y5.l3 + const
24
25      m1.l1      m3.l1      y5.l1      m1.l2      m3.l2      y5.l2
26      m1.l3      m3.l3
27 -0.77262617  2.06919377  0.07347698  0.40365078 -0.63296798 -0.00663435
28 -0.35137281  0.25663998
29      y5.l3      const
30 -0.05718647  0.00346167
31
32 Estimated coefficients for equation y5:
33 =====
34 Call:
35 y5 = m1.l1 + m3.l1 + y5.l1 + m1.l2 + m3.l2 + y5.l2 + m1.l3 + m3.l3 + y5.l3 + const
36
37      m1.l1      m3.l1      y5.l1      m1.l2      m3.l2      y5.l2
38      m1.l3      m3.l3
39 -0.94700137  1.02677142  1.27187191 -0.41862278  0.01796799 -0.41027244
40  0.34032262  0.01702885
41      y5.l3      const
42  0.06041757  0.12019345

```

หากพิจารณาแบบจำลอง VAR ที่เหมาะสมคือ VAR(3) ดังนั้น เราจะประมาณค่าแบบจำลอง VECM(2)

เรา ทดสอบ Johansen's test โดยใช้ คำสั่ง 'ca.jo' ใน package 'urca' โดย ระบุ ตัวสถิติที่ใช้คือ trace statistic ด้วย 'type=c("trace")' และ รูปแบบ ของ cointegration มีค่าคงที่ 'ecdet=c("const")' และจำนวนอันดับของ VAR 'k=3' โดยเก็บผลไว้ในชื่อ 'rterm.rc' และเรียกดูผลด้วย 'summary(rterm.rc)'

```

1 > rterm.rc <- ca.jo(rterm, type=c("trace"), ecdet=c("const"), k=3)
2 > summary(rterm.rc)
3
4 #####
5 # Johansen-Procedure #
6 #####
7
8 Test type: trace statistic , without linear trend and constant in cointegration
9
10 Eigenvalues (lambda):
11 [1] 0.15818825 0.10127853 0.02951317 0.00000000
12
13 Values of teststatistic and critical values of test:
14
15      test 10pct  5pct  1pct
16 r <= 2 |  4.31  7.52  9.24 12.97
17 r <= 1 | 19.69 17.85 19.96 24.60
18 r = 0  | 44.49 32.00 34.91 41.07
19
20 Eigenvectors, normalised to first column:
21 (These are the cointegration relations)
22
23      m1.l3      m3.l3      y5.l3  constant
24 m1.l3      1.00000000  1.0000000  1.0000000  1.0000000
25 m3.l3     -1.01768859 -1.8270107 -1.1379178 -1.443085
26 y5.l3      0.02286757  0.6652551  0.4414349  1.046099
27 constant  0.01082500 -0.1360052 -1.0450896 -4.791725
28
29 weights w:
30 (This is the loading matrix)
31
32      m1.l3      m3.l3      y5.l3  constant
33 m1.d -0.9588657  0.034340910 -0.005009448  2.724167e-16
34 m3.d -0.7547702  0.052367170 -0.017945128  2.186883e-16
35 y5.d -0.8972888 -0.004266062 -0.123746712  3.509375e-16

```

จากค่าสถิติซึ่งมีการทดสอบแบบเป็นลำดับ (ในกรณีนี้ใช้ significance level เท่ากับ 0.1)

- $H_0 : r = 0$  vs  $H_1 : r > 0$  ค่าสถิติเท่ากับ  $44.49 > \text{Critical value} (=32)$  เราสามารถปฏิเสธสมมุติฐานหลักที่ว่า  $r = 0$  และยอมรับว่า  $r > 0$
- $H_0 : r = 1$  vs  $H_1 : r > 1$  ค่าสถิติเท่ากับ  $19.69 > \text{Critical value} (=17.85)$  เราสามารถปฏิเสธสมมุติฐานหลักที่ว่า  $r = 1$  และยอมรับว่า  $r > 1$
- $H_0 : r = 2$  vs  $H_1 : r > 2$  ค่าสถิติเท่ากับ  $4.31 < \text{Critical value} (=7.52)$  เราไม่สามารถปฏิเสธสมมุติฐานหลักที่ว่า  $r = 2$

สรุปว่าตัวแปรทั้ง 3 cointegrated กัน และมีความสัมพันธ์ 2 สมการ จากผลการทดสอบเราสามารถประมาณ VECM ด้วยคำสั่ง `cajor1s` โดยระบุรูปแบบสมการเช่นเดียวกับ `rterm.rc` และจำนวนความสัมพันธ์  $r=2$  โดยเก็บผลการประมาณค่าไว้ในชื่อ `rterm.vecm`

```

1 > rterm.vecm <- cajorls(rterm.rc, r=2)
2 > rterm.vecm
3 $`rlm`
4
5 Call:
6 lm(formula = substitute(form1), data = data.mat)
7
8 Coefficients:
9           m1.d           m3.d           y5.d
10 ect1      -0.92452      -0.70240      -0.90155
11 ect2       0.91309       0.67245       0.92095
12 m1.d11     -1.14885     -0.77507     -0.96384
13 m3.d11      1.46761      1.06584      1.00361
14 y5.d11      0.01948      0.07918      0.31122
15 m1.d12     -0.82876     -0.36819     -1.36022
16 m3.d12      0.90168      0.43010      1.00247
17 y5.d12      0.05479      0.07082     -0.11098
18
19
20 $beta
21           ect1           ect2
22 m1.l3      1.000000e+00  2.220446e-16
23 m3.l3     -4.440892e-16  1.000000e+00
24 y5.l3     -7.849079e-01 -7.937354e-01
25 constant  1.954578e-01  1.814237e-01

```

ซึ่งเมื่อเรียกผลออกมา จะสามารถแบ่งออกเป็นสองส่วน

ส่วนแรกในบริเวณ \$beta จะระบุความสัมพันธ์ระยะยาว หรือสมการ cointegration ตามคอลัมน์ โดยที่แต่ละคอลัมน์จะระบุด้วยชื่อ ect1 และ ect2 ซึ่งสามารถเขียนเป็นสมการได้ดังนี้

$ect1_{t-1} = 1m1_t - (-4.44 \times 10^{-16})m3_t - 0.78y5_t + 0.195$  ซึ่งเราค่าสัมประสิทธิ์หน้า m3 มีค่าน้อยมาก เราสามารถตัดออก และเขียนสมการใหม่ได้เป็น  $m1_t = 0.78y5_t - 0.195 + ect1_{t-1}$

$ect2_{t-1} = (2.22 \times 10^{-16})m1_t + 1m3_t - 0.794y5_t - t + 0.181$  ซึ่งเราค่าสัมประสิทธิ์หน้า m1 มีค่าน้อยมาก เราสามารถตัดออก และเขียนสมการใหม่ได้เป็น  $1m3_t = 0.794y5_t - t - 0.181 + ect2_{t-1}$

ส่วนสองในบริเวณ \$rlm จะระบุการปรับตัวในระยะสั้น หรือ VECM โดยแต่ละคอลัมน์จะแทนแต่ละสมการ ได้แก่ m1.d ( $\Delta m1_t$ ) m3.d ( $\Delta m3_t$ ) และ y5.d ( $\Delta y5_t$ ) ยกตัวอย่างเช่น สมการ m1.d สามารถเขียนได้ดังนี้

$$\Delta m1_t = -0.92ect1_{t-1} + 0.91ect2_{t-1} - 1.14\Delta m1_{t-1} + 1.46\Delta m3_{t-1} + 0.02\Delta y5_{t-1} - 0.82\Delta m1_{t-2} + 0.90\Delta m3_{t-2} + 0.05\Delta y5_{t-2}$$



## ภาคผนวก A

# การใช้โปรแกรม R เบื้องต้น

โปรแกรม R เป็นโปรแกรมภาษาคอมพิวเตอร์ขั้นสูงที่ถูกออกแบบมาสำหรับการคำนวณทางสถิติ และใช้กันอย่างแพร่หลายในแวดวงสถิติและการเงิน โปรแกรม R เป็นโปรแกรมที่ให้ผู้ใช้งานสามารถใช้ได้ฟรี และมีคู่มือมากมายที่อธิบายวิธีการใช้ สำหรับการสอนในวิชานี้เราจะใช้โปรแกรมต่อประสาน (interface) ชื่อว่า RStudio สำหรับการทำงานร่วมกับโปรแกรม R เนื่องจากมีหน้าต่างของคำสั่งที่ได้ใช้ตลอดจนผลการวาดกราฟในหน้าต่างย่อย นอกจากนี้เนื่องจากนักศึกษาจำนวนมากอาจจะคุ้นเคยการใช้โปรแกรมผ่าน Graphic User Interface ในวิชานี้ เราจะใช้ package RCmdr ช่วยในการนำเข้าข้อมูลและวิเคราะห์ทางสถิติเบื้องต้น

## A.1 การติดตั้ง R

เพื่อที่จะติดตั้งโปรแกรม R เราสามารถดาวน์โหลดได้ที่ <http://www.cran.r-project.org> โดยที่เราสามารถเลือกระบบปฏิบัติการที่สอดคล้องกับเครื่องคอมพิวเตอร์ของเราได้ไม่ว่าเป็น Microsoft Windows, Linux หรือ Mac OS X ซึ่งในการติดตั้งนี้จะอธิบายในกรณีของระบบปฏิบัติการ Windows

- คลิก CRAN ตรงเมนูด้านซ้ายมือ
- เลือกเว็บที่จะใช้ดาวน์โหลดซึ่งในไทยคือ <http://mirrors.psu.ac.th/pub/cran/>
- เลือก Operation ซึ่งในที่นี้ผมเลือก R for windows
- เลือก Base
- คลิก Download R x.x.x for windows และเลือก default ทุกคำถามที่ถาม

## A.2 การติดตั้ง RStudio

หลังจากที่เราได้ติดตั้งโปรแกรม R แล้วเราจะมี Icon R อยู่บน Desktop เมื่อคลิกที่ไอคอนดังกล่าวจะมี Interface ในการทำงานขึ้นมา อย่างไรก็ตามในวิชานี้เราจะใช้ RStudio Interface ในการ

ทำงาน โดยเราสามารถดาวน์โหลด RStudio ได้ที่ <http://www.rstudio.com/ide/download/> ซึ่งสามารถเลือกระบบปฏิบัติการที่สอดคล้องกับเครื่องที่ใช้อยู่ได้

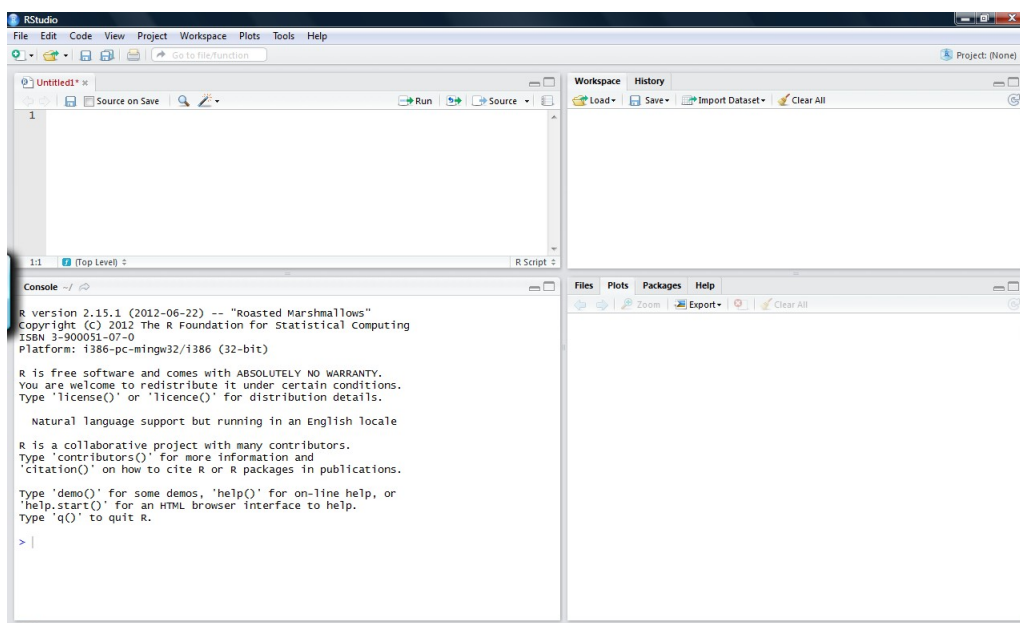
- คลิก Download RStudio Desktop เพื่อดาวน์โหลด
- คลิกไฟล์ที่อยู่ใต้หัวข้อ Recommended For Your System
- Save File และรันโปรแกรม

เนื่องจากโปรแกรม R จำเป็นต้องมีการติดตั้ง โปรแกรมสำเร็จรูปย่อย (package) ดังนั้น เราจะประมวลผลโปรแกรม R จาก Flashdrive หรือ External harddisk หรือ Drive D: ในห้องคอมพิวเตอร์ที่เรามีสิทธิที่จะแก้ไขเปลี่ยนแปลงข้อมูลได้ โดยการคัดลอกไฟล์เตอร์ R/R-x.x.x และ RStudio จากไฟล์เตอร์ Program Files แล้ววางใน Flashdrive และเรียกโปรแกรมมาใช้โดยการคลิก rstudio.exe ในไฟล์เตอร์ Rstudio/bin โดยในครั้งแรกอาจจะมีการถามถึงไฟล์เตอร์ที่มีโปรแกรม R อยู่ใน Flashdrive

### A.3 ผังของโปรแกรม RStudio

ผังของโปรแกรม RStudio จะประกอบด้วยหน้าต่างดังที่แสดงในรูป ??

รูปที่ A.1: ผังโปรแกรม RStudio



หน้าต่างล่างซ้ายเรียกว่า **Console window** หรือ **Command window** ในหน้าต่างดังกล่าวจะมี ">" prompt ซึ่งเราจะใส่คำสั่งหลังเครื่องหมายนั้นเพื่อให้โปรแกรม R ดำเนินการ

หน้าต่างบนซ้ายเรียกว่า **Editor window** หรือ **Script window** เป็นหน้าต่างที่ใช้เก็บชุดคำสั่งเพื่อที่จะเก็บและสามารถเรียกมาใช้ในภายหลังได้

หน้าต่างบนขวาเป็นหน้าต่าง **Workspace/ History window** เป็นหน้าต่างเราสามารถดูข้อมูลหรือค่าต่างๆที่เราคำสั่งเรียกมาอยู่ในหน่วยความจำ และคำสั่งต่างๆที่ได้ดำเนินการไปแล้ว

หน้าต่างล่างขวาเป็นหน้าต่าง **Files/Plots/Packages/Help window** เป็นหน้าต่างที่เราสามารถเรียกข้อมูลขึ้นมา ดูกราฟ และติดตั้งหรือเรียกชุดคำสั่ง (packages)

## A.4 ชุดคำสั่ง (package) หรือห้องสมุด (library)

โปรแกรม R สามารถวิเคราะห์ข้อมูลและสถิติได้อย่างหลากหลาย โดยชุดคำสั่งที่ใช้ร่วมกันจะถูกเก็บใน *packages* หรือ *libraries* โดยในการติดตั้งทั่วไปจะมีการติดตั้ง packages ที่ใช้บ่อยๆอยู่แล้ว โดยที่เราสามารถเรียกดู packages ที่ติดตั้งไว้แล้วในหน้าต่าง packages หรือพิมพ์คำสั่ง `library()` หากกล่องหน้า packages มีเครื่องหมายถูกแสดงว่า packages นั้นได้ถูกโหลดมาไว้ในหน่วยความจำและสามารถใช้งานได้ทันที

ในขณะที่ packages ที่ยังไม่ได้ติดตั้งหรือยังไม่ได้โหลดเข้ามาในหน่วยความจำสามารถดำเนินการได้โดยใน RStudio ตัวอย่างเช่น หากเราต้องการติดตั้ง package ที่ชื่อว่า Rcmdr

- การติดตั้ง package (install package): คลิก `install package` ใน package window แล้วพิมพ์ชื่อ package ที่ต้องการเช่น Rcmdr แล้วคลิก Install หรือพิมพ์ `install.packages("Rcmdr")` ในหน้าต่างคำสั่ง
- การใช้งาน package: เลือกกล่องเพื่อให้มีเครื่องหมายถูกหน้า package ที่เราต้องการเช่น Rcmdr หรือพิมพ์ `library("Rcmdr")` ในหน้าต่างคำสั่ง

## A.5 การทำงานบน Working directory

*Working directory* เป็นโฟลเดอร์ที่เราจะทำงาน โดยโปรแกรม R จะหาข้อมูลตลอดจนโปรแกรมที่เราเขียนไว้จากโฟลเดอร์ดังกล่าว ตลอดจนข้อมูลและรูปภาพที่เราบันทึกไว้จะอยู่ในโฟลเดอร์นั้น ดังนั้นก่อนการเริ่มงานบน R เราควรกำหนดโฟลเดอร์ดังกล่าวด้วยคำสั่งใน command window `setwd("directoryname")` เช่น

```
1 > setwd("D:/Teaching/EC435/R")
```

หรือบน RStudio เมนูเลือก Tools → Set working Directory → Choose Directory

## A.6 การใช้งานเบื้องต้น

### A.6.1 เครื่องคิดเลข

โปรแกรม RStudio เราสามารถคำนวณกระบวนการทางคณิตศาสตร์ได้ด้วยเครื่องหมายดังต่อไปนี้ โดยพิมพ์คำสั่งดังกล่าวในหน้าต่าง Console แล้ว Enter

```

1 > 2+3 # Addition
2 > 2-3 # Subtraction
3 > 2*3 # Multiplication
4 > 2/3 # Division
5 > 2^3 # 2 to the power of 3
6 > sqrt(3) # Square roots
7 > log(3) # Logarithms (to the base e)

```

## A.6.2 พื้นที่ทำงาน (workspace)

เราสามารถเก็บผลการคำนวณไว้ในตัวแปรใดๆ ได้โดยใช้ “assignment operator” `<-`, หรือ `=` เช่น

```

1 > a <- 2 * 3
2 > 2 * a
3 [1] 12

```

## A.6.3 สเกลาร์ เวกเตอร์ และเมทริกซ์

ข้อมูลตัวเลขใน R จะถูกบันทึกในรูปสเกลาร์ เวกเตอร์ หรือเมทริกซ์ เช่นในตัวอย่างที่ผ่าน มา `a` คือสเกลาร์ที่มีค่าเท่ากับ 6 หรือเราสามารถสร้างเวกเตอร์ได้โดยใช้ฟังก์ชัน `c` ดังนี้ เช่นเวกเตอร์ `b` ประกอบด้วยสมาชิกคือ 2,3,4

```

1 > b=c(2,3,4)
2 > b
3 [1] 2 3 4

```

## A.6.4 ฟังก์ชัน

บางครั้งเราต้องการคำนวณค่าบางค่าที่ต้องใช้คำสั่งหลายบรรทัด บางครั้งเราสามารถใช้ ฟังก์ชันที่มีอยู่แล้วในโปรแกรมหลักของ R หรือใน package ต่างๆ เช่น การหาค่าเฉลี่ยสามารถใช้ ฟังก์ชัน `mean()` เช่นเราต้องการหาค่าเฉลี่ยของ 5,9,13,4 เราต้องรวมค่าทั้งหมดไว้ในเวกเตอร์และ หาค่าเฉลี่ยดังนี้

```

1 > x=c(5,9,13,4)
2 > mean(x)
3 [1] 7.75

```

โดยที่ค่าหรือตัวเลือกที่ต้องกำหนดในวงเล็บเรียกว่า *arguments* ตัวอย่างของฟังก์ชันอีกอัน ของฟังก์ชันคือฟังก์ชัน `rnorm` ที่ใช้ในการสร้างค่าทดลอง (generate) ค่าจากการแจกแจงแบบปกติ

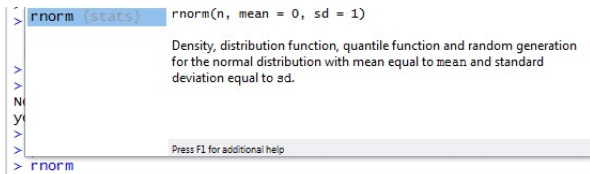
```

1 > rnorm(10)
2 [1] 0.60299 -0.75383 0.97095 1.06657 0.26545 -0.51994 -0.89247 -0.01616
3 [9] 1.11192 -0.31573

```

RStudio มีส่วนประกอบที่ช่วยเหลือเกี่ยวกับ arguments ที่เราจะต้องใส่สำหรับแต่ละฟังก์ชัน เราสามารถเขียนฟังก์ชันใน command window แล้วกดปุ่ม Tab จะมีตัวอย่างของ arguments ขึ้นมาให้เห็นรูป ??

รูปที่ A.2: Tab ช่วยเหลือใน RStudio



## A.6.5 การวาดแผนภาพ

```
1 > x=rnorm(100)
2 > plot(x)
```

## A.7 การช่วยเหลือและเอกสารประกอบฟังก์ชัน

เมื่อพิมพ์ฟังก์ชัน `help` จะมีเอกสารช่วยเหลือในหน้าต่าง `help`

```
1 > help(rnorm)
```

หรือเราสามารถใช้ฟังก์ชัน `example` เพื่อดูตัวอย่างคำสั่งและผลของฟังก์ชัน

```
1 > example(rnorm)
```

## A.8 Scripts

นอกจากการพิมพ์คำสั่งใน command window แล้วเราสามารถประมวลผลโปรแกรมจาก script ซึ่งมีนามสกุล `.R` โดยการเลือกเปิดไฟล์จาก `File` → `Open File` แล้วเลือก Script ขึ้นมาแล้วคลิก `run` ในเมนู editor window

## A.9 โครงสร้างข้อมูล

### A.9.1 เวกเตอร์

เราสามารถสร้างเวกเตอร์ได้ด้วยฟังก์ชัน `c` เช่นคำสั่งในบรรทัดที่ 1 นอกจากนี้เราสามารถเรียกดูข้อมูลในตำแหน่งที่  $i$  ด้วยคำสั่ง `vectorname[i]` เช่นบรรทัดที่ 4 นอกจากนี้เราสามารถสร้างเวกเตอร์ที่มีระยะเท่ากันด้วยฟังก์ชัน `seq` ดังเช่นในบรรทัดที่ 9

```

1 > vec1=c(2,4,6,8,10)
2 > vec1
3 [1] 2 4 6 8 10
4 > vec1[5]
5 [1] 10
6 > vec1[3]=12
7 > vec1
8 [1] 2 4 12 8 10
9 > vec2=seq(from=0,to=1,length=5)
10 > vec2
11 [1] 0.00 0.25 0.50 0.75 1.00
12 > vec1+vec2
13 [1] 2.00 4.25 12.50 8.75 11.00

```

### A.9.2 เมตริกซ์

เราสามารถสร้างเมตริกซ์โดยการระบุข้อมูลและขนาดของเมตริกซ์ด้วย argument `nrow` หรือ `ncol` ซึ่งระบุจำนวนแถวหรือคอลัมน์ของเมตริกซ์

```

1 > m=matrix(data=c(1,2,3,4,5,6),ncol=3)
2 > m
3      [,1] [,2] [,3]
4 [1,]    1    3    5
5 [2,]    2    4    6

```

arguments `data` ในฟังก์ชัน `matrix` กำหนดข้อมูลที่จะใส่ในเมตริกซ์โดยที่ `ncol` เป็นตัวกำหนดจำนวนคอลัมน์ของเมตริกซ์ โดยที่เราอาจเลือกกำหนด `nrow` ก็ได้ การเรียกข้อมูลแต่ละตำแหน่งสามารถทำได้โดยใช้ `[row,column]`

```

1 > m[1,2]
2 [1] 3
3 > m[1,]
4 [1] 1 3 5
5 > m[,2]
6 [1] 3 4

```

### A.9.3 data frame

ข้อมูลอนุกรมเวลามักถูกจัดเก็บในรูปของ `data frame` โดยที่หัวคอลัมน์เป็นชื่อของคอลัมน์ ดังนั้นเราสามารถเรียกคอลัมน์นั้นๆมาใช้โดยไม่ต้องทราบตำแหน่งของข้อมูลเช่น

```

1 > t=data.frame(x=c(1,2,3),y=c(10,20,30),z=c(100,200,300))
2 > t
3   x  y  z
4  1  1 10 100
5  2  2 20 200
6  3  3 30 300
7 > mean(t$y)
8 [1] 20
9 > mean(t[["z"]])
10 [1] 200

```

#### A.9.4 list

โครงสร้างของข้อมูลอีกแบบคือ list โดยที่ข้อมูลจะถูกเก็บเป็นคอลัมน์ซึ่งไม่ได้เรียงลำดับและไม่จำเป็นต้องมีความยาวเท่ากัน โดยที่ฟังก์ชันในการสร้าง list ก็คือ `list` นั่นเอง โดยที่ใน argument เราจะใส่ตัวแปรต่างๆลงไป โดยในที่ตัวแปร `one` เป็นตัวแปรสเกลาร์ที่มีค่าเท่ากับ 1 ตัวแปร `two` เป็นตัวแปรเวกเตอร์ และตัวแปร `five` เป็นเวกเตอร์ที่มีสมาชิกห้าตัว

```

1 > L=list(one=1, two=c(1,2), five=seq(1,4,length=5))
2 > L
3 $one
4 [1] 1
5 $two
6 [1] 1 2
7 $five
8 [1] 1.00 1.75 2.50 3.25 4.00
9 > L$five+10
10 [1] 11.00 11.75 12.50 13.25 14.00

```

#### A.10 Graphic

คำสั่งในการสร้างรูปภาพคือ `plot` โดยที่ argument ตัวแรกคือ ข้อมูลที่เราจะ plot ในที่นี้คือ ข้อมูลสุ่มที่สร้างขึ้นจากการแจกแจงแบบปกติจำนวน 100 ตัวอย่าง `rnorm(100)` สำหรับ argument ที่เหลือเป็นการกำหนดรูปและส่วนประกอบได้แก่ `type` คือประเภทของกราฟในที่นี้ `"l"` แทนกราฟเส้น `col` คือสีของกราฟ `ylab` คือชื่อแกน Y `xlab` คือชื่อแกน X และ `main` คือชื่อกราฟ

```

1 > plot(rnorm(100),type="l",col="blue",ylab="values",xlab="observations",main="Generated
   Data of N(0,1)")

```

หรือหากเราจะสร้างเส้นหลายเส้นสามารถทำได้โดยการเพิ่มเส้นทีละเส้น โดยในคำสั่งแรกจะต้องกำหนดระยะแกน Y ให้ครอบคลุมทั้งสามเส้นด้วยคำสั่ง `ylim`

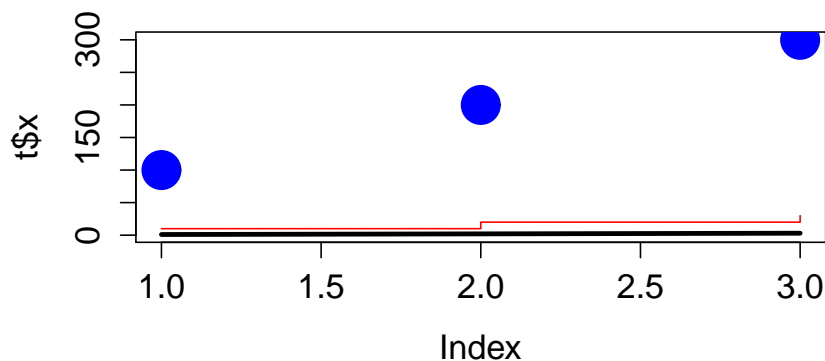
```

1 > plot(t$x,type="l",ylim=range(t),lwd=3)
2 > lines(t$y,type="s",col="red")
3 > points(t$z,pch=20,cex=5,col="blue")

```

และจะได้รูปที่ ??

รูปที่ A.3: ตัวอย่างการสร้างกราฟฟีก



## A.11 การจัดเก็บข้อมูลและนำเข้าข้อมูล

### A.11.1 การจัดเก็บข้อมูลในรูปแบบไฟล์ text

เราสามารถนำเข้าข้อมูลโดยการสร้าง data frame และจัดเก็บในรูปแบบไฟล์ text (นามสกุล .txt) โดยใช้คำสั่ง `write.table` ใน argument ประกอบด้วย ชื่อ data frame, ชื่อไฟล์ที่จะจัดเก็บ และชื่อของตัวแปร ซึ่งในที่นี้ได้กำหนดไว้แล้วใน data frame

```
1 > d=data.frame(a=c(3,4,5),b=c(12,13,15))
2 > d
3   a  b
4 1 3 12
5 2 4 13
6 3 5 15
7 > write.table(d,file="ts0.txt",row.names=FALSE)
```

### A.11.2 การเรียกข้อมูลในรูปแบบไฟล์ text

เราสามารถเรียกข้อมูลที่จัดเก็บในรูปแบบไฟล์ text ด้วยฟังก์ชัน `read.table` โดย argument คือชื่อไฟล์และการระบุว่าไฟล์ดังกล่าวมีชื่อตัวแปรหรือไม่ซึ่งในที่นี้คือมีชื่อตัวแปร `header=TRUE`

```
1 > d2=read.table(file="ts0.txt",header=TRUE)
2 > d2
3   a  b
4 1 3 12
5 2 4 13
6 3 5 15
```

ผู้อ่านสามารถทดลองนำเข้าข้อมูลไฟล์ text ชื่อว่า `setindex.txt`<sup>1</sup> เมื่อเปิดไฟล์ดังกล่าวด้วย

<sup>1</sup>download จาก Moodle ไปยัง workspace directory

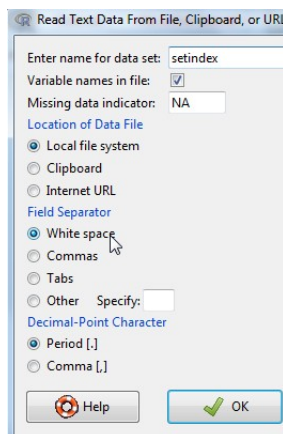


โปรแกรมเช่น Notepad จะเห็นได้ว่าข้อมูลมีการแบ่งด้วยช่องว่าง เราสามารถนำเข้าข้อมูลด้วย R


1	date	index
2	1/5/1998	366.18
3	1/6/1998	370.27
4	1/7/1998	370.31
5	1/8/1998	360.17
6	1/9/1998	349.67
7	1/12/1998	339.17
8	1/13/1998	348.96
9	1/14/1998	367.69
10	1/15/1998	364.12

Commander โดยขั้นตอนต่อไปนี้

1. เลือก Data/Import Data/From text file, clipboard, or URL แล้วคลิก
2. จะได้กล่องให้ใส่เงื่อนไขต่างๆ ใส่ชื่อ Data set เป็น setindex และดูว่า มีการแบ่งข้อมูล(Field separator) เป็น white space ตามรูป



3. จะได้กล่องให้เราระบุตำแหน่งของไฟล์ เลือก Folder และ ไฟล์ที่เราต้องการ (ในที่นี้คือ setindex.txt) แล้ว Open
4. จะเห็นได้ว่าในพื้นที่ได้เมนู จะมีชื่อ Dataset เป็น setindex ที่เรานำเข้ามา และเราสามารถเรียกดูข้อมูลได้โดยคลิก view data




ไฟล์ text อีกประเภทหนึ่งที่เรามักจะเจอเวลาเราดาวน์โหลดข้อมูลคือ .csv โดยเราสามารถนำเข้าข้อมูลได้โดยใช้คำสั่ง read.csv เช่นในที่นี้ชื่อไฟล์ pttstock.csv เมื่อเปิดไฟล์ดังกล่าวด้วยโปรแกรมเช่น Notepad จะเห็นได้ว่าข้อมูลมีการแบ่งด้วย Comma เราสามารถนำเข้าข้อมูลด้วย R Commander โดยขั้นตอนต่อไปนี้

```
1 date,price
2 6/17/2003,65.5
3 6/18/2003,66
4 6/19/2003,67
5 6/20/2003,66.5
6 6/23/2003,68
7 6/24/2003,66.5
8 6/25/2003,66
9 6/26/2003,67.5
10 6/27/2003,66
11 6/30/2003,66.5
12 7/1/2003,66.5
```

1. เลือก Data/Import Data/From text file, clipboard, or URL แล้วคลิก
2. จะได้อีกกล่องให้ใส่เงื่อนไขต่างๆ ใส่ชื่อ Data set เป็น ptt และดูว่า มีการแบ่งข้อมูล(Field separator) เป็น comma
3. จะได้อีกกล่องให้เราระบุตำแหน่งของไฟล์ เลือก Folder และ ไฟล์ที่เราต้องการ (ในที่นี้คือ pttstock.csv) แล้ว Open
4. จะเห็นได้ว่าในพื้นที่ได้เมนู จะมีชื่อ Dataset เป็น ptt ที่เรานำเข้ามา

### A.11.3 การนำเข้าไฟล์ประเภทอื่นๆ

เราสามารถนำเข้าไฟล์ได้หลายประเภทเช่น SPSS, STATA และ Excel ได้ด้วยการเลือก Data/Import Data แล้วเลือกประเภทของไฟล์ที่ต้องการนำเข้าตามรูป



### A.11.4 การบันทึกข้อมูล

เราสามารถบันทึกข้อมูลที่เรานำเข้าและสร้างตัวแปรใหม่ได้โดยการเลือก Data/Active data set/Save active data set... แล้วเลือก Folder ที่เราต้องการบันทึก และกำหนดชื่อ (ชนิดไฟล์ Rdata) แล้ว Save

ในการเปิดไฟล์ที่เราบันทึกครั้งต่อไปเราสามารถเลือก Data/Load data set


นอกจากนี้เราสามารถ Export ข้อมูลในรูปแบบไฟล์ชนิดอื่นเช่น .txt หรือ .csv สำหรับนำเข้าในโปรแกรมอื่นได้ด้วยการเลือก Data/Active data set/Export active data set... เลือกวิธีการแบ่งคอลัมน์แล้วคลิก OK หลังจากนั้นกำหนดชื่อไฟล์และชนิดไฟล์ที่ต้องการ

## A.12 การคำนวณผลได้ตอบแทนจากตัวอย่างหุ้น PTT

### A.12.1 การวาดกราฟ

จากข้อมูล ptt เราสามารถวาดกราฟได้โดย เปลี่ยน active data set เป็น ptt โดยคลิกที่ Data set แล้วเลือก ptt

เราสามารถสร้างกราฟได้โดยการเลือก Graphs ในที่นี้ข้อมูลของเราเป็นอนุกรมเวลา เราจะเลือก Graphs/epack- time series plots จะได้รูปดังต่อไปนี้ เราสามารถบันทึกรูปไว้โดยเลือก



File/Save as แล้วเลือกประเภทไฟล์ที่ต้องการ หรือหากต้องการนำไปวางใน โปรแกรมเอกสาร เช่น Word เราสามารถเลือก File/Copy to the clipboard

เนื่องจาก data frame ที่เรานำเข้ามายังไม่ได้ระบุตัวแปรเวลาสำหรับการเรียงข้อมูล เราจะใช้ package zoo ในการจัดการข้อมูลให้เรียงตามเวลาที่ระบุใน data frame ดังต่อไปนี้ โดยที่ตัวแปรใหม่จะถูกจัดเก็บใน data set ptt โดยการใส่ชื่อ ptt.z ต่อท้าย ptt\$

```
1 > library(zoo)
2 > ptt$ptt.z<-zoo(x=ptt$price, order.by=as.Date(ptt$date,"%m/%d/%Y"))
3 > head(ptt$ptt.z)
4 2003-06-17 2003-06-18 2003-06-19 2003-06-20 2003-06-23 2003-06-24
5      65.5      66.0      67.0      66.5      68.0      66.5
6 > plot(ptt$ptt.z,xlab="Year",ylab="Baht/share", main="PTT Stock Price")
```


แล้วเราจะได้รูป ??

### A.12.2 การคำนวณผลได้ตอบแทน

การคำนวณผลได้ตอบแทนด้วยคำสั่งหลักใน R

เราสามารถคำนวณผลตอบแทนอย่างง่ายได้โดยนำราคาในตำแหน่งที่  $i$  ลบด้วยตำแหน่งที่  $i-1$  แล้วหารด้วย  $i-1$  โดยการเขียนคำสั่งในบรรทัดที่ 1 อย่างใดก็ตามผลลัพธ์ที่ได้จะมีจำนวนหายไป

รูปที่ A.4: ราคาหุ้น PTT



หนึ่งตำแหน่ง หากเราจะนำข้อมูล ไปรวมใน data frame จะต้องมีการสมมุติให้ตำแหน่งแรกเป็นศูนย์ ตามบรรทัดที่ 2

```
1 > n=length(ptt$price)
2 > sret=(ptt$price[2:n]-ptt$price[1:n-1])/(ptt$price[1:n-1])
```

หากเราต้องการรวมตัวแปรใน data frame เราต้องเพิ่มตัวอย่างแรกในตัวแปร sret เพื่อให้ความยาวเท่ากัน

```
1 > head(sret)
2 [1] 0.007634 0.015152 -0.007463 0.022556 -0.022059 -0.007519
3 > ptt$sret=c(NA,sret)
4 > head(ptt)
5      date price      sret
6 1 6/17/2003 65.5      NA
7 2 6/18/2003 66.0 0.007634
```

หรือสามารถคำนวณผลได้ตอบแทนในรูปของล็อกได้ด้วยคำสั่งในบรรทัดที่ 1 หรือบรรทัดที่สอง หรือแปลงค่าจากผลได้ตอบแทนอย่างง่าย

```
1 > lret=log(ptt$price[2:n])-log(ptt$price[1:n-1])
2 > lret2=diff(log(ptt$price))
3 > lret3=log(1+sret)
4 > head(lret)
5 [1] 0.007605 0.015038 -0.007491 0.022306 -0.022306 -0.007547
6 > ptt$lret=c(NA,lret)
7 > head(ptt)
8      date price      sret      lret
9 1 6/17/2003 65.5      NA      NA
10 2 6/18/2003 66.0 0.007634 0.007605
11 3 6/19/2003 67.0 0.015152 0.015038
12 4 6/20/2003 66.5 -0.007463 -0.007491
13 5 6/23/2003 68.0 0.022556 0.022306
14 6 6/24/2003 66.5 -0.022059 -0.022306
```

เราสามารถบันทึก data frame ptt เป็นไฟล์ csv ด้วยคำสั่ง

```
1 > write.csv(ptt, file="pttreturn.csv", row.names=FALSE)
```

### R package สำหรับคำนวณผลได้ตอบแทน

เราสามารถคำนวณผลได้ตอบแทนได้ด้วย package PerformanceAnalytics โดยที่ตัวแปรนั้นต้องอยู่ในรูป zoo ซึ่งในที่นี้คือ ptt\$pptz คำสั่งที่ใช้ในการคำนวณคือ Return.calculate(price, method) โดยที่ discrete คือ simple return


```
1 > ptt$sret2=Return.calculate(ptt$ptt.z, method = "discrete")
2 > ptt$lret2=Return.calculate(ptt$ptt.z, method = "log")
3 > head(ptt)
4      date price ptt.z      sret      lret      sret2      lret2
5 1 6/17/2003  65.5  65.5      NA      NA      NA      NA
6 2 6/18/2003  66.0  66.0  0.007633588  0.007604599  0.007633588  0.007604599
7 3 6/19/2003  67.0  67.0  0.015151515  0.015037877  0.015151515  0.015037877
8 4 6/20/2003  66.5  66.5 -0.007462687 -0.007490672 -0.007462687 -0.007490672
9 5 6/23/2003  68.0  68.0  0.022556391  0.022305758  0.022556391  0.022305758
10 6 6/24/2003  66.5  66.5 -0.022058824 -0.022305758 -0.022058824 -0.022305758
```

เนื่องจากข้อมูลในแถวแรกเป็น NA เราอาจจะลบข้อมูลในแถวแรกโดยที่ในท R Commander menu เลือก **Data>Active data set> Remove row(s) from active data set** จะมีกล่องให้ระบุแถวที่ต้องการลบซึ่งในที่นี้คือ 1 หลังจากนั้น save ข้อมูลในไฟล์ชื่อ ptt.Rdata สำหรับการวิเคราะห์ทางสถิติต่อไป

แล้วสามารถวางแผนภาพของผลได้ตอบแทนได้ในรูปล๊อตได้ตามรูปที่ ??

```
1 > plot(ptt$lret2,xlab="Year",ylab="%", main="Log Return of PTT Stock Price",col="blue")
```

รูปที่ A.5: ผลได้ตอบแทนจากราคาหุ้น PTT



## บรรณานุกรม

Bollerslev, T. (1986), 'Generalized autoregressive conditional heteroskedasticity', *Journal of econometrics* 31(3), 307--327.

- [0] [1] Brooks, C. (2008), *Introductory econometrics for finance*, Cambridge university press.
- [2] Campbell, J. Y.; Lo, A. W.-C. MacKinlay, A. C. (1997), *The econometrics of financial markets*, princeton University press.
- [3] Engle, R. F. Granger, C. W. (1987), 'Co-integration and error correction: representation, estimation, and testing', *Econometrica: journal of the Econometric Society*, 251--276.
- [4] Engle, R. F.; Lilien, D. M. Robins, R. P. (1987), 'Estimating time varying risk premia in the term structure: the ARCH-M model', *Econometrica: Journal of the Econometric Society*, 391--407.
- [5] Johansen, S. (1988), 'Statistical analysis of cointegration vectors', *Journal of economic dynamics and control* 12(2), 231--254.
- [6] Kwiatkowski, D.; Phillips, P. C.; Schmidt, P. Shin, Y. (1992), 'Testing the null hypothesis of stationarity against the alternative of a unit root: How sure are we that economic time series have a unit root?', *Journal of econometrics* 54(1), 159--178.
- [7] Nelson, D. B. (1991), 'Conditional heteroskedasticity in asset returns: A new approach', *Econometrica: Journal of the Econometric Society*, 347--370.
- [8] Phillips, P. C. Ouliaris, S. (1990), 'Asymptotic properties of residual based tests for cointegration', *Econometrica: Journal of the Econometric Society*, 165--193.
- [9] Phillips, P. C. Perron, P. (1988), 'Testing for a unit root in time series regression', *Biometrika* 75(2), 335--346.
- [10] Tsay, R. S. (2010), *Analysis of financial time series*, Vol. 543, Wiley-Interscience.
- [11] Zivot, E. Wang, J. (2003), *Modeling financial time series with S-PLUS*, Vol. 191, Springer.